

ModelArts 7.2.1-HCS API 参考

文档版本 01
发布日期 2025-10-30



版权所有 © 华为云计算技术有限公司 2026。保留一切权利。

非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

商标声明



HUAWEI和其他华为商标均为华为技术有限公司的商标。

本文档提及的其他所有商标或注册商标，由各自的所有人拥有。

注意

您购买的产品、服务或特性等应受华为云计算技术有限公司商业合同和条款的约束，本文档中描述的全部或部分产品、服务或特性可能不在您的购买或使用范围之内。除非合同另有约定，华为云计算技术有限公司对本文档内容不做任何明示或暗示的声明或保证。

由于产品版本升级或其他原因，本文档内容会不定期进行更新。除非另有约定，本文档仅作为使用指导，本文档中的所有陈述、信息和建议不构成任何明示或暗示的担保。

华为云计算技术有限公司

地址：贵州省贵安新区黔中大道交兴功路华为云数据中心 邮编：550029

网址：<https://www.huaweicloud.com/>

目录

1 使用前必读.....	1
2 API 概览.....	3
3 如何调用 API.....	16
3.1 构造请求.....	16
3.2 认证鉴权.....	19
3.3 返回结果.....	22
4 模型训练.....	24
4.1 算法管理.....	24
4.1.1 创建算法.....	24
4.1.2 查询算法列表.....	38
4.1.3 查询算法详情.....	47
4.1.4 更新算法.....	54
4.1.5 删除算法.....	69
4.2 训练作业管理.....	70
4.2.1 创建训练作业.....	70
4.2.2 查询训练作业详情.....	110
4.2.3 更新训练作业描述.....	132
4.2.4 删除训练作业.....	133
4.2.5 终止训练作业.....	134
4.2.6 查询训练作业指定任务的日志（预览）.....	155
4.2.7 查询训练作业指定任务的日志（OBS 链接）.....	157
4.2.8 查询训练作业指定任务的运行指标.....	158
4.2.9 查询训练作业列表.....	160
4.2.10 创建训练作业镜像保存任务.....	182
4.2.11 查询训练作业镜像保存任务.....	185
4.2.12 批量删除训练作业.....	187
4.3 资源和引擎规格.....	188
4.3.1 查询训练作业支持的公共规格列表.....	188
4.4 训练作业标签管理.....	193
4.4.1 创建训练作业标签.....	193
4.4.2 删除训练作业标签.....	194
4.4.3 查询训练作业标签.....	196

5 模型管理（旧版推理）	198
5.1 导入模型	198
5.2 查询模型列表	206
5.3 查询模型详情	209
5.4 删除模型	216
5.5 获取模型事件信息	217
6 服务管理（旧版推理）	221
6.1 部署服务	221
6.2 查询服务列表	240
6.3 查询服务详情	245
6.4 删除服务实例	259
6.5 更新服务配置	260
6.6 更新服务实例数	271
6.7 局部更新服务配置	274
6.8 查询服务监控信息	276
6.9 查询服务更新日志	279
6.10 查询服务事件日志	286
6.11 删除服务	290
6.12 查询支持的服务部署规格	290
6.13 添加资源标签	294
6.14 删除资源标签	297
6.15 查询推理服务标签	299
6.16 创建自动扩缩容策略	302
6.17 查询自动扩缩容策略列表	304
6.18 更新自动扩缩容	307
6.19 查询自动扩缩容策略	309
6.20 删除自动扩缩容	311
6.21 获取服务的模型信息	312
6.22 获取服务模型实例的运行日志	314
6.23 获取服务模型单个节点的运行日志	316
6.24 获取服务 API	318
6.25 查询服务 host 信息	320
7 服务管理（新版推理）	323
7.1 在线服务生命周期管理	323
7.1.1 停止在线服务	323
7.1.2 中断服务	349
7.1.3 查询服务列表	376
7.1.4 启动在线服务	389
7.1.5 创建服务	415
7.1.6 查询服务详情	477
7.1.7 更新服务配置	503
7.1.8 获取在线服务事件列表	565

7.1.9 查询服务 exec 登录信息.....	571
7.1.10 删除指定服务列表.....	575
7.2 服务标签管理.....	602
7.2.1 删除资源标签.....	602
7.2.2 添加标签.....	607
7.2.3 查询资源标签.....	613
7.2.4 查询某一类资源下的标签.....	618
7.2.5 通过标签反查资源列表.....	622
7.2.6 通过标签查询资源数量.....	630
7.3 服务版本管理.....	637
7.3.1 切换服务到指定版本.....	637
7.3.2 查询在线服务版本详情.....	663
7.3.3 查询在线服务版本列表.....	685
7.3.4 删除在线服务版本.....	691
7.4 专属池.....	713
7.4.1 查询纳管集群详情.....	713
7.4.2 查询支持可切换规格列表.....	721
7.5 应用密钥管理.....	730
7.5.1 绑定应用密钥.....	731
7.5.2 删除应用密钥.....	735
7.5.3 解绑应用密钥.....	739
7.5.4 查询应用密钥.....	744
7.5.5 创建应用密钥.....	751
7.5.6 批量绑定应用密钥.....	755
7.5.7 批量解绑应用密钥.....	761
7.6 服务实例管理.....	767
7.6.1 查询服务实例组列表.....	767
7.6.2 查询服务实例列表.....	773
7.6.3 查询服务的 pod 的列表.....	780
7.6.4 删除服务实例.....	786
7.6.5 删除 Pod.....	791
7.6.6 查询 Pod 事件.....	796
7.7 RMS.....	803
7.7.1 查询区域下资源实例列表.....	803
7.7.2 查询区域下资源实例详情.....	810
7.8 内网接入管理.....	815
7.8.1 创建内网接入.....	815
7.8.2 变更内网申请.....	821
7.8.3 查询当前租户的内网接入申请列表.....	823
7.8.4 查询当前租户的内网接入审批列表.....	830
7.8.5 批量删除内网接入.....	836
7.9 扩缩容策略.....	838

7.9.1 创建自动扩缩容策略.....	838
7.9.2 查看自动扩缩容策略.....	846
7.9.3 删除自动扩缩容策略.....	851
7.9.4 修改自动扩缩容策略.....	854
7.9.5 查看自动扩缩容策略事件.....	864
8 服务作业管理（旧版推理）.....	871
8.1 创建服务作业.....	871
8.2 获取服务作业列表.....	879
8.3 查询服务作业.....	890
8.4 更新服务作业.....	898
8.5 删除服务作业.....	912
8.6 启动服务作业.....	914
8.7 停止服务作业.....	916
9 AI Hub.....	918
9.1 资产.....	918
9.1.1 发布资产.....	918
9.1.2 修改资产属性.....	921
9.1.3 获取资产详情.....	923
9.1.4 删除资产.....	929
9.1.5 获取用户发布的某个类型的所有资产.....	930
9.1.6 修改资产上下架.....	933
9.1.7 查询同种类型所有资产.....	934
9.1.8 获取资产准备进度.....	940
9.2 版本.....	942
9.2.1 资产增加版本.....	942
9.2.2 获取资产版本详情.....	944
9.2.3 修改资产版本信息.....	947
9.2.4 删除资产版本.....	948
9.3 订阅.....	950
9.3.1 创建订阅.....	950
9.3.2 查询用户订阅的资产.....	951
9.3.3 创建资产的 license.....	957
9.3.4 查询订阅资产的版本.....	958
9.3.5 找回订阅.....	961
9.3.6 取消订阅.....	962
9.4 入库.....	963
9.4.1 资产版本入库.....	963
9.5 审核.....	965
9.5.1 管理员审核资产.....	965
9.5.2 用户重试审核资产.....	967
10 专属资源池.....	969

10.1 资源池作业管理.....	969
10.1.1 查询专属资源池作业列表.....	969
10.1.2 查询专属资源池作业统计信息.....	975
10.2 配置管理.....	978
10.2.1 查询 OS 的配置参数.....	978
10.2.2 查询 OS 的配额.....	981
10.3 插件模板管理.....	983
10.3.1 查询插件模板.....	983
10.3.2 查询插件模板列表.....	986
10.4 虚拟资源规格.....	997
10.4.1 查询虚拟资源规格模板.....	997
10.4.2 查询虚拟资源规格列表.....	1000
10.5 节点管理.....	1003
10.5.1 查询资源池节点列表.....	1003
10.5.2 批量删除节点.....	1008
10.5.3 批量更新节点.....	1010
10.5.4 批量为节点绑定逻辑子池.....	1012
10.6 网络管理.....	1014
10.6.1 创建网络资源.....	1014
10.6.2 查询网络资源列表.....	1020
10.6.3 查询网络资源.....	1026
10.6.4 删除网络资源.....	1031
10.6.5 更新网络资源.....	1036
10.7 标签管理.....	1044
10.7.1 查询资源池的所有资源标签.....	1044
10.7.2 查询资源池的资源标签.....	1047
10.7.3 修改资源池的资源标签.....	1049
10.7.4 查询节点的所有资源标签.....	1052
10.7.5 查询节点的资源标签.....	1055
10.7.6 修改节点的资源标签.....	1057
10.8 事件管理.....	1061
10.8.1 查询事件列表.....	1061
10.9 插件管理.....	1065
10.9.1 创建插件.....	1065
10.9.2 查询插件列表.....	1070
10.9.3 更新插件.....	1075
10.9.4 删除插件.....	1079
10.9.5 查询指定插件详情.....	1083
10.10 资源规格管理.....	1089
10.10.1 查询资源规格列表.....	1089
10.11 订单管理.....	1095
10.11.1 查询订单列表.....	1095

10.11.2 查询订单详情.....	1099
10.12 资源池管理.....	1103
10.12.1 创建资源池.....	1103
10.12.2 查询资源池列表.....	1117
10.12.3 查询资源池.....	1126
10.12.4 删除资源池.....	1135
10.12.5 更新资源池.....	1144
10.12.6 资源池监控.....	1157
10.12.7 资源池统计.....	1165
10.12.8 重试启用失败的作业类型.....	1167
10.13 资源指标.....	1169
10.13.1 查询资源实时利用率.....	1169
11 边缘资源池.....	1173
11.1 边缘池管理.....	1173
11.1.1 创建边缘池.....	1173
11.1.2 获取边缘池列表.....	1176
11.1.3 查询边缘池.....	1183
11.1.4 修改边缘资源池.....	1190
11.1.5 删除边缘池.....	1194
11.1.6 删除边缘池节点.....	1196
11.1.7 添加边缘池节点.....	1198
11.1.8 添加边缘资源池标签.....	1200
11.1.9 删除边缘资源池标签.....	1202
11.1.10 查询边缘资源池标签.....	1205
11.1.11 查询指定边缘资源池标签.....	1207
11.1.12 通过标签查询边缘资源池列表.....	1210
11.1.13 通过标签查询边缘资源池数量.....	1212
11.2 边缘节点管理.....	1214
11.2.1 注册边缘节点.....	1214
11.2.2 激活边缘节点.....	1218
11.2.3 查询边缘节点详情.....	1220
11.2.4 更新边缘节点信息.....	1227
11.2.5 删除边缘节点.....	1230
11.2.6 查询边缘节点列表.....	1231
11.2.7 绑定设备.....	1237
11.2.8 边缘节点链接上云.....	1239
11.3 负载均衡管理.....	1240
11.3.1 查询负载均衡列表.....	1240
11.3.2 添加负载均衡.....	1245
11.3.3 查询负载均衡详情.....	1251
11.3.4 更新负载均衡.....	1254
11.3.5 删除负载均衡.....	1260

11.4 访问端口.....	1262
11.4.1 查询访问端口列表.....	1262
11.4.2 添加访问端口.....	1265
11.4.3 查询访问端口详情.....	1268
11.4.4 更新访问端口.....	1270
11.4.5 删除访问端口.....	1273
12 密钥管理.....	1275
12.1 创建密钥.....	1275
12.2 获取密钥列表.....	1279
12.3 获取密钥详情.....	1282
12.4 更新密钥.....	1285
12.5 删除密钥.....	1288
13 工作空间管理.....	1291
13.1 查询工作空间详情.....	1291
13.2 修改工作空间.....	1294
13.3 删除工作空间.....	1296
13.4 查询工作空间配额.....	1298
13.5 修改工作空间配额.....	1300
13.6 查询工作空间列表.....	1302
13.7 创建工作空间.....	1305
14 授权管理.....	1310
14.1 配置授权.....	1310
14.2 查看授权列表.....	1312
14.3 删除授权.....	1315
14.4 创建 ModelArts 委托.....	1316
15 应用示例.....	1319
15.1 管理 ModelArts 服务的委托授权.....	1319
15.2 创建和修改工作空间.....	1321
16 权限策略和授权项.....	1326
16.1 策略及授权项说明.....	1326
16.2 训练作业权限.....	1327
16.3 模型管理权限.....	1329
16.4 服务管理权限.....	1329
16.5 资源管理权限.....	1331
16.6 工作空间管理权限.....	1332
16.7 新版推理权限.....	1333
17 公共参数.....	1339
17.1 状态码.....	1339
17.2 错误码.....	1342
17.3 获取资源空间 ID 和名称.....	1386

17.4 获取租户名和租户 ID.....	1387
17.5 获取用户名和用户 ID.....	1387
17.6 获取 Token.....	1387
18 修订记录.....	1390

1 使用前必读

概述

ModelArts平台提供了模型训练、模型管理、模型部署和资源池管理能力，将您训练所得的模型，统一管理并部署为推理服务。您可以根据本文档提供的API来使用ModelArts推理服务。

调用说明

ModelArts提供了REST（Representational State Transfer）风格API，支持您通过HTTPS请求调用，调用方法请参见[如何调用API](#)。

终端节点

各服务的Endpoint信息由服务名、Region ID和外部域名三部分组成，格式为“{service_name}.{region_id}.{external_domain_name}”。其中，每一项参数的获取方式参见[表1-1](#)。

表 1-1 Endpoint 信息的获取方式

参数	描述	获取方式
service_name	服务名缩写（不区分大小写）	ModelArts服务默认为“modelarts”。
region_id	Region ID	从安装ModelArts服务时由HCC Turnkey工程导出的《xxx_export_all_v2_CN.xlsx》文件的“基本参数”页签中搜索“region0_id”获取。
external_domain_name	外部域名后缀	从安装ModelArts服务时由HCC Turnkey工程导出的《xxx_export_all_v2_CN.xlsx》文件的“基本参数”页签中搜索“external_global_domain_name”获取。

说明

当Endpoint使用域名方式时，需要在本地PC配置hosts文件，格式为“{float-ip}{service_name}.{region_id}.{external_domain_name}”。其中“float-ip”从安装ModelArts服务时由HCC Turnkey工程导出的《xxx_export_all_v2_CN.xlsx》文件的“基本参数”页签中搜索“shubao_lb_float_ip”获取。

基本概念

- **账号**
用户注册时的账号，账号对其所拥有的资源及云服务具有完全的访问权限，可以重置用户密码、分配用户权限等。
- **区域**
指云资源所在的物理位置，同一区域内可用区间内网互通，不同区域间内网不互通。通过在不同地区创建云资源，可以将应用程序设计的更接近特定客户的要求，或满足不同地区的法律或其他要求。
- **可用区**
一个可用区（AZ）是一个或多个物理数据中心的集合，有独立的风火水电，AZ内逻辑上再将计算、网络、存储等资源划分成多个集群。一个Region中的多个AZ间通过高速光纤相连，以满足用户跨AZ构建高可用性系统的需求。
- **资源空间**
区域默认对应一个资源空间，这个资源空间由系统预置，用来隔离物理区域间的资源（计算资源、存储资源和网络资源），以默认资源空间为单位进行授权，用户可以访问您账号中该区域的所有资源。如果您希望进行更加精细的权限控制，可以在区域默认的资源空间中创建子资源空间，并在子资源空间中创建资源，然后以子资源空间为单位进行授权，使得用户仅能访问特定子资源空间中资源，使得资源的权限控制更加精确。

2 API 概览

ModelArts服务所提供的接口均为自研接口。

模型训练接口

表 2-1 算法管理接口

API	说明
创建算法	创建一个算法。
查询算法列表	查询算法列表。
查询算法详情	根据算法ID查询指定算法。
更新算法	更新算法。
删除算法	删除算法。

表 2-2 训练作业管理接口

API	说明
创建训练作业	创建训练作业。
查询训练作业详情	查询训练作业详情。
更新训练作业描述	更新训练作业描述。
删除训练作业	删除训练作业。
终止训练作业	终止训练作业，只可终止创建中、等待中、运行中的作业。
查询训练作业指定任务的日志（预览）	查询训练作业指定任务的日志（预览）。
查询训练作业指定任务的日志（OBS链接）	查询训练作业指定任务的日志（OBS链接），可全量查看或直接下载。

API	说明
查询训练作业指定任务的运行指标	查询训练作业指定任务的运行指标。
查询训练作业列表	根据指定查询条件查询用户创建的训练作业列表。
创建训练作业镜像保存任务	创建训练作业镜像保存任务。
查询训练作业镜像保存任务	查询训练作业镜像保存任务。

表 2-3 训练资源和引擎规格接口

API	说明
查询训练作业支持的公共规格列表	查询训练作业支持的公共规格列表。

表 2-4 训练作业标签管理接口

API	说明
创建训练作业标签	为训练作业创建一个或多个标签。
删除训练作业标签	删除训练作业标签。
查询训练作业标签	查询创建的训练作业标签。

模型管理接口（旧版推理）

表 2-5 模型管理接口

API	说明
导入模型	导入模型。
查询模型列表	查询模型列表，可以根据不同的检索参数进行查询。
查询模型详情	查询模型详情，根据模型ID查询模型的详细信息。
删除模型	删除模型，根据模型ID删除指定模型，可以级联删除该模型下的所有版本。

服务管理接口（旧版推理）

表 2-6 服务管理接口

API	说明
部署服务	部署模型服务。
查询服务列表	查询模型服务列表。
查询服务详情	查询模型服务详情，根据服务ID查询服务详情。
删除服务实例	删除服务实例，不适用于同步在线服务和ModelArts Edge服务。
更新服务配置	更新模型服务配置。也可以使用此接口启停服务。
更新服务实例数	更新模型服务的单个属性，目前只支持更新模型服务实例数量，仅运行中、告警、异常状态下的在线服务可以执行该操作。
局部更新服务配置	通过patch操作对服务进行更新。patch的格式可以参照json patch。
查询服务监控信息	查询服务监控信息。
查询服务更新日志	查询实时服务更新日志。
查询服务事件日志	查询服务事件日志，包含服务的操作记录及部署过程中的关键动作、部署失败原因。
删除服务	删除模型服务。
查询支持的服务部署规格	查询支持的服务部署规格列表。
添加资源标签	给指定服务添加标签。
删除资源标签	删除添加的资源标签。
查询推理服务标签	查询当前项目下的推理服务标签。
创建自动扩缩容策略	创建自动扩缩容策略。
查询自动扩缩容策略列表	查询自动扩缩容策略列表信息。
更新自动扩缩容	更新自动扩缩容策略。
查询自动扩缩容策略	获取自动扩缩容策略详情。
删除自动扩缩容	删除创建的自动扩缩容策略。

服务管理（新版推理）

表 2-7 服务管理接口

API	说明
停止在线服务	用于终止正在运行或处于其他可操作状态的服务实例。该功能适用于需要维护、升级或检测到异常的服务场景，支持在服务处于"运行中"、"部署中"、"失败"、"异常"或"告警"状态时执行停止操作。
中断服务	用于中断处于“升级中”或“部署中”状态的服务，使其快速停止。
查询服务列表	查询在线服务列表，支持分页和筛选，适用于用户和管理控制台或通过API需要查看特定条件下（如服务状态、名称等）的服务列表的情况。
启动在线服务	使服务从“停止”或“失败”状态进入“部署中”状态，适用于用户需要重新启动已停止或启动失败的服务的情况。
创建服务	将模型部署为在线服务，适用于用户在开发或运维过程中需要将训练好的模型部署为在线服务，以便通过API或HTTP接口提供预测或处理能力的场景。
查询服务详情	通过服务ID查询对应的服务详情，调用者可以通过有效的服务ID获取服务的名称、状态、服务实例、配置参数等详细信息。
更新服务配置	该接口适用于需要动态调整模型服务配置的场景，对模型的性能参数、资源池配置、服务调用配置等进行更新升级。
获取在线服务事件列表	该接口适用于需要监控和管理在线服务事件的场景，例如用户或运维人员需要定期检查服务的日志事件，以及及时发现和处理问题。
查询服务exec登录信息	适用于需要获取容器登录信息的场景，例如用户希望通过exec命令登录到在线服务的容器中进行调试或查看操作。
删除指定服务列表	用户批量删除多个服务实例，适用于需要清理资源、释放计算能力或管理多个服务的场景。
删除资源标签	适用于需要从资源（如模型、数据集、服务等）中移除特定标签的场景，例如在资源管理或分类中，用户可以通过删除标签来调整或清理资源的元数据。
添加标签	为资源（如模型、数据集、服务等）添加元数据标签。
查询资源标签	获取资源（如模型、数据集、服务等）的标签信息。
查询某一类资源下的标签	获取用户当前项目中某一类资源（如指定的Service）的标签信息。

API	说明
通过标签反查资源列表	根据标签或资源名称查找相关资源。
通过标签查询资源数量	统计和获取符合特定标签或资源名称条件的资源数量。
切换服务到指定版本	将服务切换到指定版本，适用于需要在不同版本间进行切换以测试或回滚的场景。
查询在线服务版本列表	获取指定在线服务的版本列表，适用于需要了解当前服务可用版本的场景，例如进行版本选择或确认当前版本信息。
查询在线服务版本详情	获取指定服务版本的详细信息，适用于需要查看特定版本的详细配置和状态的场景，例如确认版本的功能、性能参数或发布历史。
删除在线服务版本	删除指定服务的某个在线版本，适用于需要清理不再使用的版本或优化资源管理的场景。
查询纳管集群详情	用户通过指定资源池的ID来查询纳管集群的详细信息，包括实例ID、名称、Flavor规格、实例状态和实例可访问的URL。此功能适用于需要监控或管理云资源的用户。
查询支持可切换规格列表	用户查询当前资源实例支持的可切换规格列表，适用于需要调整实例资源配置的场景。
绑定应用密钥	用于将生成的API Key与指定服务进行绑定，适用于应用程序需要调用特定服务的场景。
删除应用密钥	用于删除指定的API Key，适用于管理员需要撤销对某个应用程序或用户的访问权限的场景。
解绑应用密钥	用于将已绑定的API Key从指定服务中解绑，适用于需要撤销某个API Key对特定服务的访问权限的场景。
查询应用密钥	用于查询当前系统中的API Key列表，适用于管理员或用户需要查看和管理API Key的场景。
创建应用密钥	用于在系统中创建一个新的API Key，适用于需要为用户或应用程序生成访问凭证的场景。
批量绑定应用密钥	用于将生成的多个API Key与指定服务进行批量绑定，用于访问特定服务。
批量解绑应用密钥	用于将已绑定的API Key从指定服务中批量解绑，适用于需要撤销多个API Key对特定服务的访问权限的场景。
查询服务实例组列表	用于查询当前租户的服务实例组列表，并支持根据服务实例组的状态进行筛选，包括运行中、已删除、错误和初始化等状态，还支持分页查询。适用于需要管理和监控服务实例组状态的场景。

API	说明
查询服务实例列表	用于查询当前租户的服务实例列表，并支持根据服务实例的状态进行筛选，包括运行中和已删除状态，同时支持分页和关键词筛选。适用于需要管理和监控服务实例状态的场景。
查询服务的pod的列表	用于查询指定服务的Pod列表，并支持选择是否只获取当前运行中的Pod。适用于需要管理和监控服务Pod状态的场景。
删除服务实例	用于删除指定的单个服务实例，适用于需要清理或释放不再使用的服务实例资源的场景。
删除Pod	用于删除指定的单个Pod，适用于需要清理或释放不再使用的Pod资源的场景。
查询Pod事件	用于查询指定Pod的Kubernetes事件，适用于需要监控和排查Pod运行状态的场景。
查询区域下资源实例列表	用于查询指定Region下的所有资源实例列表，适用于需要管理和监控特定Region中资源的场景。
查询区域下资源实例详情	用于查询指定Region下某个资源实例的详细信息，适用于需要获取特定资源实例详细配置和状态的场景。
创建内网接入	用于在指定Region中创建内网接入点，适用于需要为应用程序或服务配置内网连接的场景。
变更内网申请	用于对当前租户的内网接入申请进行变更操作，支持通过（APPROVE）、拒绝（REJECT）、取消（CANCEL）和重试（RETRY）等操作。适用于需要管理内网接入申请审批流程的场景。
查询当前租户的内网接入申请列表	用于查询当前租户所有的内网接入申请记录，适用于需要管理和监控内网接入申请状态的场景。
查询当前租户的内网接入审批列表	用于查询当前租户所有的内网接入审批记录，适用于需要管理和监控内网接入审批状态的场景。
批量删除内网接入	用于批量删除指定的内网接入点，适用于需要清理多个不再使用的内网接入点的场景。
创建自动扩缩容策略	用于在已部署的服务上创建定时扩缩容策略，适用于需要根据业务负载或特定时间自动调整服务实例个数的场景。
查看自动扩缩容策略	用于在已部署的服务上查看自动扩缩容策略。
删除自动扩缩容策略	用于在已部署的服务上删除定时扩缩容策略，适用于需要根据业务负载或特定时间自动删除服务的场景。
修改自动扩缩容策略	用于在已部署的服务上修改定时扩缩容策略，适用于需要根据业务负载或特定时间自动调整服务实例个数的场景。

API	说明
查看自动扩缩容策略事件	用于在已部署的服务上查看自动扩缩容策略事件，适用于查看自动扩缩容策略变动历史记录。

服务作业管理（旧版推理）

表 2-8 服务作业管理接口

API	说明
创建服务作业	创建服务作业。
获取服务作业列表	获取服务作业列表信息。
查询服务作业	用于查询服务作业信息。
更新服务作业	更新服务作业参数。
删除服务作业	用于删除服务作业。
启动服务作业	用于启动服务作业。
停止服务作业	用于停止服务作业。

AI Hub 接口

表 2-9 AI Hub 接口

类型	API	说明
资产	发布资产	发布资产运营信息，整体上架资产的流程包括：发布资产、发布版本、版本入库。
	修改资产属性	修改资产属性，包括标题名称、描述、可见性、可获得性、标签等。
	获取资产详情	获取资产详情信息。
	删除资产	删除一个资产。有用户订阅则会删除失败，取消订阅之后也不可删除。
	获取用户发布的某个类型的所有资产	获取用户发布的某个类型的所有资产。
	修改资产上下架	修改资产上下架。
	查询同种类型所有资产	查询同种类型所有资产。

类型	API	说明
	获取资产准备进度	获取资产准备进度状态。
版本	资产增加版本	对已有资产新增一个版本，再调用入库接口，实现多版本功能。
	获取资产版本详情	获取资产版本详情。
	修改资产版本信息	修改资产版本信息。
	删除资产版本	删除资产版本。资产可用时，必须保证删除版本后，至少还有一个上架的可用的版本；资产不可用时则无限制。
订阅	创建订阅	创建订阅，每个用户对每个资产只能订阅1次，订阅后可以取消订阅。
	查询用户订阅的资产	查询用户订阅的所有资产列表。
	创建资产的license	接入license管控的资产。
	查询订阅资产的版本	查询某个订阅资产的所有可用版本。
	找回订阅	对取消了订阅的资产，进行找回订阅。这个操作会将订阅从取消状态改为订阅中。
	取消订阅	取消订阅。在个人中心的订阅列表中仍能查询到，但是在ModelArts界面看不到。只修改订阅状态。
入库	资产版本入库	在增加版本接口中，没有填写location信息，则需要手动调这个接口来完成入库操作。意义在于，只有完成入库，资产才算真正发布到AI Hub中。
审核	管理员审核资产	对用户发布的资产，管理员提交审核意见。
	用户重试审核资产	对管理员审核为不通过的资产，用户重试审核，让管理员重新审核。

资源池管理接口

表 2-10 专属资源池管理

类型	API	说明
资源池作业管理	查询专属资源池作业列表	查询专属资源池作业列表。
	查询专属资源池作业统计信息	查询专属资源池作业统计信息。
配置管理	查询OS的配置参数	获取OS的配置参数信息。
	查询OS的配额	获取ModelArts OS服务中部分资源的配额，如资源池配额、网络配额等。
插件模板管理	查询插件模板	获取指定插件模板的详细信息。
虚拟资源规格	查询虚拟资源规格模板	获取指定虚拟资源切分模板的详细信息。
	查询虚拟资源规格列表	获取虚拟资源规格列表。
网络管理	创建网络资源	创建网络资源。
	查询网络资源列表	查询网络资源列表。
	查询网络资源	查询指定网络资源的详细信息。
	删除网络资源	删除指定网络资源。
	更新网络资源	更新指定网络资源。
节点管理	查询资源池节点列表	查询资源池中的节点列表。
	批量删除节点	批量删除指定资源池中的节点。
	批量更新节点	批量更新资源池中节点。
	批量为节点绑定逻辑子池	当物理专属池开启节点绑定时，可以对逻辑子池中的节点进行逻辑子池的换绑。
标签管理	查询资源池的所有资源标签	查询用户当前项目下资源池的所有标签。
	查询资源池的资源标签	查询指定资源池的资源标签。
	修改资源池的资源标签	修改指定资源池的资源标签。
	查询节点的所有资源标签	查询用户当前项目下节点的所有标签。
	查询节点的资源标签	查询指定节点的资源标签。

类型	API	说明
	修改节点的资源标签	修改指定节点的资源标签。
事件管理	查询事件列表	查询资源池事件列表。
订单管理	查询订单列表	查询ModelArts OS服务的订单列表。
资源池管理	创建资源池	用户创建资源池。
	查询资源池列表	查询资源池列表。
	查询资源池	查询指定资源池的详细信息。
	删除资源池	删除指定的资源池。
	更新资源池	更新指定的资源池。
	资源池监控	获取资源池的监控信息。
	资源池统计	获取资源池的统计信息。
	重试启用失败的作业类型	重试启用失败的作业类型。
资源规格管理	查询资源规格列表	查询资源规格列表。
资源指标	查询资源实时利用率	查询当前项目下所有资源池的实时利用率。

边缘资源池

表 2-11 边缘池管理接口

API	说明
创建边缘池	创建边缘池。
获取边缘池列表	获取边缘池列表。
查询边缘池	查询边缘池详情。
删除边缘池	删除边缘池。
修改边缘资源池	更新边缘资源池信息。
删除边缘池节点	用于删除边缘池节点。
添加边缘池节点	用于添加边缘池节点。
添加边缘资源池标签	给指定边缘资源池添加标签，当添加的标签key已存在，则覆盖该标签的value。
删除边缘资源池标签	删除边缘资源池的标签，支持批量删除。
查询边缘资源池标签	查询当前项目下的边缘资源池标签。

API	说明
查询指定边缘资源池标签	查询当前项目下指定的边缘资源池标签。
通过标签查询边缘资源池列表	通过标签查询资源，支持多标签与查询，支持资源名称的模糊查询，不传标签表示查询所有资源。
通过标签查询边缘资源池数量	通过标签查询资源总数量，支持多标签与查询，支持资源名称的模糊查询，不传标签表示查询所有资源，不管有没有打标签。

表 2-12 边缘节点管理接口

API	说明
注册边缘节点	注册边缘节点。
激活边缘节点	激活边缘节点，让节点处于激活状态。
查询边缘节点详情	查询边缘节点详情。
更新边缘节点信息	更新边缘节点日志配置，标签以及描述。
删除边缘节点	删除控制台上的边缘节点，并与端侧的边缘节点进行解绑。
查询边缘节点列表	查询边缘节点列表，可通过节点标签过滤。
绑定设备	将ModelArts控制台边缘节点和硬件绑定。用户无感知，可以不关注。
边缘节点链接上云	硬件绑定之后，通过该接口硬件可以链接上云。本接口仅适用于ModelArts Edge边缘节点触发，用户无感知，可以不关注。

表 2-13 负载均衡管理接口

API	说明
查询负载均衡列表	根据用户请求条件筛选，查询用户创建的负载均衡信息，以列表形式返回。
添加负载均衡	添加负载均衡，将负载均衡添加到ModelArts控制台上，用于集群（或边缘节点）的负载均衡控制。
查询负载均衡详情	支持查询ModelArts控制台上的负载均衡详情。
更新负载均衡	更新指定ID的负载均衡。
删除负载均衡	删除指定ID的负载均衡。

表 2-14 访问端口接口

API	说明
查询访问端口列表	根据查询条件查询用户边缘资源池部署下的访问端口列表。
添加访问端口	创建一个访问端口。
查询访问端口详情	查询一个访问端口的详情。
更新访问端口	更新一个访问端口。
删除访问端口	删除一个访问端口。

密钥管理接口

表 2-15 密钥管理接口

API	说明
创建密钥	用于创建密钥。
获取密钥列表	用于获取密钥列表。
获取密钥详情	用于获取密钥详情。
更新密钥	更新创建的密钥。
删除密钥	删除密钥。

授权管理接口

表 2-16 授权管理接口

API	说明
查看授权列表	查看授权列表。
配置授权	配置ModelArts授权。若没有授权，ModelArts模型训练、在线服务等功能将不能正常使用。
删除授权	删除指定用户的授权或者删除全量用户的授权。
创建ModelArts委托	创建包含OBS、SWR等依赖服务的ModelArts委托。

工作空间管理接口

表 2-17 工作空间管理接口

API	说明
查询工作空间列表	查询工作空间列表，响应消息体中包含详细信息。
创建工作空间	创建工作空间。
查询工作空间详情	查询工作空间详情。
修改工作空间	修改工作空间。
删除工作空间	删除工作空间。
查询工作空间配额	查看工作空间配额。
修改工作空间配额	修改工作空间配额。

3 如何调用 API

3.1 构造请求

本节介绍REST API请求的组成，并以获取用户Token说明如何调用API，Token可以用于调用其他API时的鉴权。

请求 URI

请求URI由如下部分组成：

{URI-scheme} :// {Endpoint} / {resource-path} ? {query-string}


表 3-1 请求 URI

参数	说明
URI-scheme	传输请求的协议，当前所有API均采用HTTPS协议。
Endpoint	承载REST服务端点的服务器域名或IP，不同服务在不同区域时，对应Endpoint不同，可以从 终端节点 中获取。
resource-path	资源路径，即API访问路径。从具体API的URI模块获取，例如“获取用户Token”API的resource-path为“/v3/auth/tokens”。
query-string	查询参数，可选，查询参数前面需要带一个“？”，形式为“参数名=参数取值”，例如“limit=10”，表示查询不超过10条数据。

例如您需要获取某一区域的Token，则需使用此区域的Endpoint，并在获取用户Token的URI部分找到resource-path（**/v3/auth/tokens**），拼接起来如下所示。

`https://{endpoint}/v3/auth/tokens`

图 3-1 URL 示意图



 说明

为查看方便，服务每个具体API的URI，只给出resource-path部分，并将请求方法写在一起。这是因为URI-scheme都是HTTPS，而Endpoint在同一个区域也相同，所以简洁起见将这两部分省略。

请求方法

HTTP请求方法（也称为操作或动词），它告诉服务你正在请求什么类型的操作。

表 3-2 HTTP 方法

方法	说明
GET	请求服务器返回指定资源。
PUT	请求服务器更新指定资源。
POST	请求服务器新增资源或执行特殊操作。
DELETE	请求服务器删除指定资源，如删除对象等。
HEAD	请求服务器资源头部。
PATCH	请求服务器更新资源的部分内容。 当资源不存在的时候，PATCH可能会去创建一个新的资源。

在获取用户Token的URI部分，您可以看到其请求方法为“POST”，则其请求为：
POST https://{iam-endpoint}/v3/auth/tokens

请求消息头

附加请求头字段，如指定的URI和HTTP方法所要求的字段。例如定义消息体类型的请求头“Content-Type”，请求鉴权信息等。

需要添加到请求中的公共消息头如表3-3所示。

表 3-3 公共请求消息头

参数名	说明	是否必选	示例
Content-type	消息体的类型（格式），默认取值为“application/json”。	是	application/json
Content-Length	请求body长度，单位为Byte。	POST/PUT请求必填，GET不能包含。	3495
X-Project-Id	project id，用于不同project取token。	否	e9993fc787d94b6c886cbaa340f9c0f4

参数名	说明	是否必选	示例
X-Auth-Token	用户Token，也就是调用获取用户Token接口的响应值，该接口是唯一不需要认证的接口。	否，使用Token认证时必选。	-

对于获取用户Token接口，由于不需要认证，所以只添加“Content-Type”即可，添加消息头后的请求如下所示。

```
POST https://{iam-endpoint}/v3/auth/tokens
Content-Type: application/json
```

请求消息体

请求消息体通常以结构化格式发出，与请求消息头中Content-type对应，传递除请求消息头之外的内容。若请求消息体中参数支持中文，则中文字符必须为UTF-8编码。

每个接口的请求消息体内容不同，也并不是每个接口都需要有请求消息体（或者说消息体为空），GET、DELETE操作类型的接口就不需要消息体，消息体具体内容需要根据具体接口而定。

获取用户Token接口，您可以从接口的请求部分看到所需的请求参数及参数说明。将消息体加入后的请求如下所示，加粗的斜体字段需要根据实际值填写，其中`user_name`为用户名，`domain_name`为用户所属的租户名，`user_password`为用户登录密码，`project_name`为资源空间名称，获取方法请参见[获取用户名](#)、[获取租户名和租户ID](#)和[获取资源空间名称](#)。

说明

scope参数定义了Token的作用域，示例中获取的Token仅能访问project下的资源。ModelArts使用区域的Endpoint（非全局域名）调用该接口，推荐您将scope设置为project。您还可以设置Token作用域为某个账号下所有资源或账号的某个project下的资源。

```
POST https://iam.{regionId}.myhuaweicloud.com/v3/auth/tokens
Content-Type:application/json
{
  "auth": {
    "identity": {
      "methods": ["password"],
      "password": {
        "user": {
          "name": "user_name",
          "password": "user_password",
          "domain": {
            "name": "domain_name"
          }
        }
      }
    },
    "scope": {
      "project": {
        "name": "project_name"
      }
    }
  }
}
```

到这里为止这个请求需要的内容就具备齐全了，您可以使用[curl](#)、[Postman](#)或直接编写代码等方式发送请求调用API。对于获取用户Token接口，返回的响应消息头中“x-

subject-token”的值，就是需要获取的用户Token。有了Token之后，您就可以使用Token认证调用其他API。

3.2 认证鉴权

调用接口有如下两种认证方式，您可以选择其中一种进行认证鉴权。

- AK/SK认证：通过AK（Access Key ID）/SK（Secret Access Key）加密调用请求。
- Token认证：通过Token认证调用请求。

AK/SK 认证

AK/SK认证就是使用AK/SK对请求进行签名，在请求时将签名信息添加到消息头，从而通过身份认证。

- AK（Access Key ID）：访问密钥ID。与私有访问密钥关联的唯一标识符；访问密钥ID和私有访问密钥一起使用，对请求进行加密签名。
- SK（Secret Access Key）：与访问密钥ID结合使用的密钥，对请求进行加密签名，可标识发送方，并防止请求被修改。

注意

- AK/SK签名认证方式仅支持消息体大小12MB以内，12MB以上的请求请使用Token认证。
- API网关除了校验时间格式外，还会校验该时间值与网关收到请求的时间差，如果时间差大于15分钟，API网关将拒绝请求。因此客户端必须注意本地时间与时钟服务器的同步，避免请求消息头X-Sdk-Date的值出现较大误差。

以下结合一个[Demo](#)来介绍如何对一个请求进行签名，并通过HTTP Client发送一个HTTPS请求的过程。如果您不使用Demo工程，也可以直接下载API网关签名工具在其他工程中引用。

步骤1 生成AK/SK。如果已生成过AK/SK，则可跳过此步骤，找到原来已下载的AK/SK文件，文件名一般为：credentials.csv。

1. 登录ManageOne运营面。
2. 在页面右上角单击用户图标，在下拉列表中选择“个人设置”。
3. 在“个人设置”页面选择“管理访问密钥”页签。
4. 单击“新增访问密钥”，新建AK/SK。
5. 单击“确定”，自动下载访问密钥文件。
6. 下载成功后，在credentials.csv文件中获取AK和SK信息。

注意

- 每个用户仅允许新增两个访问密钥。
 - 为保证访问密钥的安全，访问密钥仅在初次生成时自动下载，后续不可再次通过管理控制台界面获取。请在生成后妥善保管。
-


步骤2 获取示例代码，解压缩。

步骤3 打开IDEA，在菜单栏选择“File > New > Project from Existing Sources”。

选择解压后的“ApiGateway-java-sdk-x.x.x”文件夹，单击“OK”，导入示例工程。

步骤4 在“Import Project”页面，选择“Import project from external model”。

选择“Maven”，然后单击“Create”。



步骤5 IDEA支持在当前窗口或新窗口创建工程。此处，在弹窗中单击“New Window”。

步骤6 修改HttpClientDemo.java中的API请求信息。

1. 本示例以AK和SK保存在环境变量中为例，运行本示例前请先在本地环境中设置环境变量HUAWEICLOUD_SDK_AK和HUAWEICLOUD_SDK_SK。以Linux系统为例在本地将**步骤1**中获取的AK/SK设置为环境变量。

- a. 打开终端，执行以下命令打开环境变量配置文件。

```
vi ~/.bashrc
```

- b. 在文件中添加如下环境变量配置，保存文件并退出编辑器。

```
export HUAWEICLOUD_SDK_AK="已获取的AK值"  
export HUAWEICLOUD_SDK_SK="已获取的SK值"
```

- c. 执行以下命令使配置文件生效。

```
source ~/.bashrc
```

2. 把API信息和已设置的环境变量替换到HttpClientDemo.java中的对应位置。

如下示例所示，加粗部分信息需要替换成实际值。

```
public class HttpClientDemo {  
    private static final Logger LOGGER = LoggerFactory.getLogger(HttpClientDemo.class);  
    public static void main(String[] args) throws Exception {  
        // Create a new request.  
        Request httpClientRequest = new Request();  
        try {  
            // Set the request parameters.
```

```
// AppKey, AppSecret, Method and Url are required parameters.
// Directly writing AK/SK in code is risky. For security, encrypt your AK/SK and store them in
the configuration file or environment variables.
// In this example, the AK/SK are stored in environment variables for identity authentication.
// Before running this example, set environment variables HUAWEICLOUD_SDK_AK and
HUAWEICLOUD_SDK_SK.
httpClientRequest.setKey(System.getenv("HUAWEICLOUD_SDK_AK"));
httpClientRequest.setSecret(System.getenv("HUAWEICLOUD_SDK_SK"));
// Set a request method for http request.
httpClientRequest.setMethod("POST");
// Set a request URL in the format of https://{Endpoint}/{URI}.
httpClientRequest.setUrl("put your request url here");
httpClientRequest.addHeader("Content-Type", "text/plain");
// Set a body for http request.
httpClientRequest.setBody("put your request body here");
} catch (Exception e) {
    LOGGER.error(e.getMessage());
    return;
}
CloseableHttpClient client = null;
try {
    // Sign the request.
    HttpRequestBase signedRequest = Client.sign(httpClientRequest,
Constant.SIGNATURE_ALGORITHM_SDK_HMAC_SHA256);
    if (Constant.DO_VERIFY) {
        // create httpClient and verify ssl certificate
        HostName.setUrlHostName(httpClientRequest.getHost());
        client = (CloseableHttpClient)
SSLCipherSuiteUtil.createHttpClientWithVerify(Constant.INTERNATIONAL_PROTOCOL);
    } else {
        // create httpClient and do not verify ssl certificate
        client = (CloseableHttpClient)
SSLCipherSuiteUtil.createHttpClient(Constant.INTERNATIONAL_PROTOCOL);
    }
    HttpResponse response = client.execute(signedRequest);
    // Print the body of the response.
    HttpEntity resEntity = response.getEntity();
    if (resEntity != null) {
        LOGGER.info("Processing Body with name: {} and value: {}",
System.getProperty("line.separator"),
EntityUtils.toString(resEntity, "UTF-8"));
    }
} catch (Exception e) {
    LOGGER.error(e.getMessage());
} finally {
    if (client != null) {
        client.close();
    }
}
}
```

步骤7 运行HttpClientDemo.java，对请求进行签名、访问API并打印结果。

如果改变AK或SK的值，API网关将返回错误信息error_msg。

----结束

Token 认证

Token在计算机系统中代表令牌（临时）的意思，拥有Token就代表拥有某种权限。Token认证就是在调用API的时候将Token加到请求消息头，从而通过身份认证，获得操作API的权限。

📖 说明

- Token的有效期为24小时，需要使用一个Token鉴权时，可以先缓存起来，避免频繁调用。
- 使用Token前请确保Token离过期有足够的时间，防止调用API的过程中Token过期导致调用API失败。

Token可通过调用“获取用户Token”接口获取，调用本服务API需要project级别的Token，即调用“获取用户Token”接口时，请求body中auth.scope的取值需要选择project，如下所示。

```
{
  "auth": {
    "identity": {
      "methods": [
        "password"
      ],
      "password": {
        "user": {
          "name": "username",
          "password": "*****#",
          "domain": {
            "name": "domainname"
          }
        }
      }
    },
    "scope": {
      "project": {
        "name": "xxxxxxx"
      }
    }
  }
}
```

获取Token后，再调用其他接口时，您需要在请求消息头中添加“X-Auth-Token”，其值即为获取到的Token。例如Token值为“ABCDEFGH....”，则调用接口时将“X-Auth-Token: ABCDEFGH....”加到请求消息头即可，如下所示。

```
GET https://iam-apigateway-proxy.{region0_id}-{external_global_domain_name}/v3/auth/projects
Content-Type: application/json
X-Auth-Token: ABCDEFGH....
```

3.3 返回结果

请求发送以后，您会收到响应，包含：状态码、响应消息头和响应消息体。

状态码

状态码是一组从1xx到5xx的数字代码，状态码表示了请求响应的状态，完整的状态码列表请参见[状态码](#)。

对于获取用户Token接口，如果调用后返回状态码为“201”，则表示请求成功。

响应消息头

对应请求消息头，响应同样也有消息头，如“Content-type”。

响应消息体

响应消息体通常以结构化格式返回，与响应消息头中Content-type对应，传递除响应消息头之外的内容。

接口调用成功后将返回如下消息体。为篇幅起见，这里只展示部分示例。

```
{
  "jobs": [
    {
      "metadata": {
        "id": "9110d96a-55f1-4d6b-a08c-31309bc422f5"
      }
    },
    {
      "metadata": {
        "id": "931939ec-202d-420b-a30f-d7838a92f357"
      }
    }
  ]
}
```

当接口调用出错时，会返回错误码及错误信息说明，错误响应的Body体格式如下所示。

```
{
  "error_msg": "The format of message is error",
  "error_code": "AS.0001"
}
```

其中，error_code表示错误码，error_msg表示错误描述信息，具体请参见[错误码](#)。

4 模型训练

4.1 算法管理

4.1.1 创建算法

功能介绍

创建一个算法。

URI

POST /v2/{project_id}/algorithms

表 4-1 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。

请求参数

表 4-2 请求 Body 参数

参数	是否必选	参数类型	描述
metadata	否	AlgorithmMetadata object	算法的元数据，描述算法基本信息。
job_config	否	AlgorithmJobConfig object	算法配置信息，如启动文件等。

参数	是否必选	参数类型	描述
resource_requirements	否	Array of ResourceRequirement objects	算法资源约束。可不设置。设置后，在算法使用于训练作业时，控制台会过滤可用的公共资源池。
advanced_config	否	AlgorithmAdvancedConfig object	算法高级策略： • auto_search

表 4-3 AlgorithmMetadata

参数	是否必选	参数类型	描述
id	否	Integer	算法uuid，创建算法时无需填写。
name	是	String	算法名称。限制为1-64位只含数字、字母、下划线和中划线的名称。
description	否	String	对算法的描述，默认为“NULL”，字符串的长度限制为[0, 256]。
workspace_id	否	String	指定算法所处的工作空间，默认值为“0”。“0”为默认的工作空间。
ai_project	否	String	指定算法所属的ai项目，默认值为"default-ai-project"。ai项目已下线，无需关注。

表 4-4 AlgorithmJobConfig

参数	是否必选	参数类型	描述
code_dir	否	String	算法的代码目录。如：“/usr/app/”。应与boot_file一同出现。
boot_file	否	String	算法的代码启动文件，需要在代码目录下。如：“/usr/app/boot.py”。应与code_dir一同出现。
command	否	String	自定义镜像算法的容器启动命令。

参数	是否必选	参数类型	描述
parameters	否	Array of Parameters objects	算法的运行参数。
inputs	否	Array of AlgorithmCreateInput objects	算法的数据输入。
outputs	否	Array of AlgorithmCreateOutput objects	算法的数据输出。
engine	否	AlgorithmCreateEngine object	算法的引擎。
parameters_customization	否	Boolean	算法是否允许创建训练作业时自定义超参。

表 4-5 Parameters

参数	是否必选	参数类型	描述
name	否	String	参数名称。
value	否	String	参数值。
description	否	String	参数描述信息。
constraint	否	ParametersConstraint object	参数属性。
i18n_description	否	I18nDescription object	国际化描述。

表 4-6 ParametersConstraint

参数	是否必选	参数类型	描述
type	否	String	参数种类。
editable	否	Boolean	是否可编辑。
required	否	Boolean	是否必须。
sensitive	否	Boolean	是否敏感。该功能暂未实现。
valid_type	否	String	有效种类。

参数	是否必选	参数类型	描述
valid_range	否	Array of strings	有效范围。

表 4-7 l18nDescription

参数	是否必选	参数类型	描述
language	否	String	国际语种。
description	否	String	描述信息。

表 4-8 AlgorithmCreateInput

参数	是否必选	参数类型	描述
name	否	String	数据输入通道名称。
description	否	String	数据输入通道描述信息。
remote_constraints	否	Array of RemoteConstraint objects	数据输入约束。

表 4-9 RemoteConstraint

参数	是否必选	参数类型	描述
data_type	否	String	数据输入类型，支持数据存储位置（ OBS ）、ModelArts数据集两种方式。
attributes	否	Array of Map<String,String> objects	数据输入为数据集时的相关属性。枚举值： - data_format：数据格式。 - data_segmentation：数据切分方式。 - dataset_type：标注类型。

表 4-10 AlgorithmCreateOutput

参数	是否必选	参数类型	描述
name	是	String	数据输出通道名称。

参数	是否必选	参数类型	描述
description	否	String	数据输出通道描述信息。

表 4-11 AlgorithmCreateEngine

参数	是否必选	参数类型	描述
engine_id	否	String	算法选择的引擎规格ID。
engine_name	否	String	算法选择的引擎版本名称。若填入engine_id则无需填写。
engine_version	否	String	算法选择的引擎版本名称。若填入engine_id则无需填写。
image_url	否	String	算法选择的自定义镜像地址。

表 4-12 ResourceRequirement

参数	是否必选	参数类型	描述
key	否	String	资源约束，可选键值如： - flavor_type（资源类型），对应值可选择CPU、GPU； - device_distributed_mode（是否支持多卡训练），对应值可选择multiple（支持）、singular（不支持）； - host_distributed_mode（是否支持分布式训练），对应值可选择multiple（支持）、singular（不支持）。
values	否	Array of strings	资源约束键对应值。
operator	否	String	键与值关系，当前只支持in。例如flavor_type in [CPU,GPU]。

表 4-13 AlgorithmAdvancedConfig

参数	是否必选	参数类型	描述
auto_search	否	AutoSearch object	超参搜索策略。

表 4-14 AutoSearch

参数	是否必选	参数类型	描述
skip_search_params	否	String	需要排除的超参组合。
reward_attrs	否	Array of RewardAttrs objects	搜索指标列表。
search_params	否	Array of SearchParams objects	搜索参数。
algo_configs	否	Array of AlgoConfigs objects	搜索算法配置。

表 4-15 RewardAttrs

参数	是否必选	参数类型	描述
name	否	String	指标名称。
mode	否	String	搜索方向。 - max指定时表示指标值越大越好； - min指定时表示指标值越小越好。
regex	否	String	指标正则表达式。

表 4-16 SearchParams

参数	是否必选	参数类型	描述
name	否	String	超参名称。
param_type	否	String	参数类型。 - continuous：指定时表示这个超参是连续类型的。连续类型的超参在算法使用于训练作业时，控制台显示为输入框。 - discrete：指定时表示这个超参是离散类型的。离散类型的超参在算法使用于训练作业时，控制台显示为下拉选择框架。
lower_bound	否	String	超参下界。
upper_bound	否	String	超参上界。
discrete_points_num	否	String	连续型超参离散化取值个数。

参数	是否必选	参数类型	描述
discrete_values	否	Array of strings	离散型超参的取值列表。

表 4-17 AlgoConfigs

参数	是否必选	参数类型	描述
name	否	String	搜索算法名称。
params	否	Array of AutoSearchAlgoConfigParameter objects	搜索算法参数。

表 4-18 AutoSearchAlgoConfigParameter

参数	是否必选	参数类型	描述
key	否	String	参数键。
value	否	String	参数值。
type	否	String	参数种类。

响应参数

状态码： 201

表 4-19 响应 Body 参数

参数	参数类型	描述
metadata	表4-20 object	算法的元数据，描述算法基本信息。
job_config	表4-21 object	算法配置信息，如启动文件等。
resource_requirements	Array of 表 4-30 objects	算法资源约束，可不设置。设置后，在算法使用于训练作业时，控制台会过滤可用的公共资源池。
advanced_config	表4-31 object	算法高级策略： • auto_search

表 4-20 Metadata

参数	参数类型	描述
id	Integer	算法uuid，创建算法时无需填写。
name	String	算法名称。限制为1-64位只含数字、字母、下划线和中划线的名称。
description	String	对算法的描述，默认为“NULL”，字符串的长度限制为[0, 256]。
workspace_id	String	指定算法所处的工作空间，默认值为“0”。“0”为默认的工作空间。
ai_project	String	指定算法所属的ai项目，默认值为"default-ai-project"。ai项目已下线，无需关注。
user_name	String	用户名称。
domain_id	String	用户的domainID。
source	String	算法来源类型。
api_version	String	算法api版本，标识新旧版。
is_valid	String	算法可用性。
state	String	算法状态。
tags	Array of Map<String,String> objects	算法标签。
attr_list	Array of strings	算法属性列表。
version_num	Integer	算法版本数量，默认为0。
size	Integer	算法大小。
create_time	Long	算法创建时间戳。
update_time	Long	算法更新时间戳。

表 4-21 JobConfig

参数	参数类型	描述
code_dir	String	算法的代码目录。如：“/usr/app/”。应与boot_file一同出现。
boot_file	String	算法的代码启动文件，需要在代码目录下。如：“/usr/app/boot.py”。应与code_dir一同出现。
command	String	自定义镜像算法的容器启动命令。

参数	参数类型	描述
parameters	Array of Parameter objects	算法的运行参数。
inputs	Array of 表 4-25 objects	算法的数据输入。
outputs	Array of 表 4-27 objects	算法的数据输出。
engine	表 4-28 object	算法的引擎。
code_tree	Array of 表 4-29 objects	算法的目录结构树。
parameters_customization	Boolean	算法是否允许创建训练作业时自定义超参。

表 4-22 Parameter

参数	参数类型	描述
name	String	参数名称。
value	String	参数值。
description	String	参数描述信息。
constraint	表 4-23 object	参数属性。
internationalization	表 4-24 object	国际化描述。

表 4-23 Constraint

参数	参数类型	描述
type	String	参数种类。
editable	Boolean	是否可编辑。
required	Boolean	是否必须。
sensitive	Boolean	是否敏感。该功能暂未实现。
valid_type	String	有效种类。
valid_range	Array of strings	有效范围。

表 4-24 I18nDescription

参数	参数类型	描述
language	String	国际语种
description	String	国际化语种的描述信息。

表 4-25 Inputs

参数	参数类型	描述
name	String	数据输入通道名称。
description	String	数据输入通道描述信息。
remote_constraints	Array of 表 4-26 objects	数据输入约束。

表 4-26 RemoteConstraints

参数	参数类型	描述
data_type	String	数据输入类型，包括数据存储位置、数据集两种方式。
attributes	Array of Map<String,String> objects	数据输入为数据集时的相关属性。枚举值： - data_format数据格式。 - data_segmentation数据切分方式。 - dataset_type标注类型。

表 4-27 Outputs

参数	参数类型	描述
name	String	数据输出通道名称。
description	String	数据输出通道描述信息。

表 4-28 Engine

参数	参数类型	描述
engine_id	String	算法选择的引擎规格ID。
engine_name	String	算法选择的引擎版本名称。若填入engine_id则无需填写。

参数	参数类型	描述
engine_version	String	算法选择的引擎版本名称。若填入engine_id则无需填写。
image_url	String	算法选择的自定义镜像地址。

表 4-29 CodeTree

参数	参数类型	描述
name	String	算法目录树当前层级目录名。
children	Object	算法目录树当前层级目录下子文件和子目录。

表 4-30 ResourceRequirements

参数	参数类型	描述
key	String	资源约束，可选值如下： - 资源类型（ flavor_type ），对应值可选择 CPU、GPU； - 是否支持多卡训练（ device_distributed_mode ），对应值可选择支持（ multiple ）、不支持（ singular ）； - 是否支持分布式训练（ host_distributed_mode ），对应值可选择支持（ multiple ）、不支持（ singular ）。
value	Array of strings	资源约束键对应值。
operator	String	键与值关系，当前只支持in。例如flavor_type in [CPU,GPU]。

表 4-31 AdvancedConfig

参数	参数类型	描述
auto_search	表4-32 object	超参搜索策略。

表 4-32 AutoSearch

参数	参数类型	描述
skip_search_params	String	需要排除的超参组合。
reward_attr	Array of 表 4-33 objects	搜索指标列表。
search_params	Array of 表 4-34 objects	搜索参数。
algo_configs	Array of 表 4-35 objects	搜索算法配置。

表 4-33 RewardAttr

参数	参数类型	描述
name	String	指标名称。
mode	String	搜索方向。 - max指定时表示指标值越大越好； - min指定时表示指标值越小越好。
regex	String	指标正则表达式。

表 4-34 SearchParams

参数	参数类型	描述
name	String	超参名称。
param_type	String	参数类型。 - continuous：指定时表示这个超参是连续类型的。连续类型的超参在算法使用于训练作业时，控制台显示为输入框。 - discrete：指定时表示这个超参是离散类型的。离散类型的超参在算法使用于训练作业时，控制台显示为下拉选择框架。
lower_bound	String	超参下界。
upper_bound	String	超参上界。
discrete_points_num	String	连续型超参离散化取值个数。
discrete_values	String	离散型超参的取值列表。

表 4-35 AlgoConfigs

参数	参数类型	描述
name	String	搜索算法名称。
params	Array of AutoSearchAlgoConfigParameter objects	搜索算法参数。

表 4-36 AutoSearchAlgoConfigParameter

参数	参数类型	描述
key	String	参数键。
value	String	参数值。
type	String	参数种类。

请求示例

创建算法。设置算法名称为 “TestModelArtsalgorithm”，描述为 “This is a ModelArts algorithm”。

```
POST https://endpoint/v2/{project_id}/algorithms
{
  "metadata": {
    "name": "TestModelArtsalgorithm",
    "description": "This is a ModelArts algorithm"
  },
  "job_config": {
    "code_dir": "/algo-test/pytorch/work1/code/",
    "boot_file": "/algo-test/pytorch/work1/code/test-pytorch.py",
    "parameters": [ {
      "name": "test-parameter",
      "value": "10",
      "constraint": {
        "type": "String",
        "editable": true,
        "required": false,
        "sensitive": false,
        "valid_type": "None",
        "valid_range": [ ]
      }
    } ],
    "parameters_customization": true,
    "inputs": [ {
      "name": "data_url",
      "description": "data source."
    } ],
    "outputs": [ {
      "name": "train_url",
      "description": "model output."
    } ],
    "engine": {
      "engine_name": "PyTorch",
      "engine_version": "PyTorch-1.3.0-python3.6"
    }
  }
}
```

```
}  
}  
}
```

响应示例

状态码： 201

ok

```
{  
  "metadata": {  
    "id": "2e5451fe-913f-4492-821a-2981031382f7",  
    "name": "TestModelArtsalgorithm",  
    "description": "This is a ModelArts algorithm",  
    "create_time": 1636600721742,  
    "workspace_id": "0",  
    "ai_project": "default-ai-project",  
    "user_name": "",  
    "domain_id": "xxxxxxxxxxxxxxxxxxxxxxxx",  
    "source": "custom",  
    "api_version": "",  
    "is_valid": true,  
    "state": "",  
    "size": 4791,  
    "tags": null,  
    "attr_list": null,  
    "version_num": 0,  
    "update_time": 0  
  },  
  "job_config": {  
    "code_dir": "/algo-test/pytorch/work1/code/",  
    "boot_file": "/algo-test/pytorch/work1/code/test-pytorch.py",  
    "command": "",  
    "parameters": [ {  
      "name": "test-parameter",  
      "description": "",  
      "i18n_description": null,  
      "value": "10",  
      "constraint": {  
        "type": "String",  
        "editable": true,  
        "required": false,  
        "sensitive": false,  
        "valid_type": "None",  
        "valid_range": [ ]  
      }  
    }  
  ],  
  "parameters_customization": true,  
  "inputs": [ {  
    "name": "data_url",  
    "description": "name to translate"  
  } ],  
  "outputs": [ {  
    "name": "train_url",  
    "description": "name to translate"  
  } ],  
  "engine": {  
    "engine_id": "pytorch-cp36-1.3.0",  
    "engine_name": "PyTorch",  
    "engine_version": "PyTorch-1.3.0-python3.6"  
  },  
  "code_tree": {  
    "name": "code/",  
    "children": [ {  
      "name": "test-pytorch.py"  
    } ]  
  }  
},
```

```
"resource_requirements": null,
"advanced_config": { }
}
```

状态码

状态码	描述
201	ok

错误码

请参见[错误码](#)。

4.1.2 查询算法列表

功能介绍

查询算法列表接口用于获取ModelArts平台上所有算法的列表。

该接口适用于以下场景：当用户需要查看平台上的所有可用算法时，可以通过此接口获取算法列表。使用该接口的前提条件是用户具有查看算法列表的权限。查询操作完成后，平台将返回包含算法名称、ID等信息的列表。若用户无权限操作，接口将返回相应的错误信息。

URI

GET /v2/{project_id}/algorithms

表 4-37 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。

表 4-38 Query 参数

参数	是否必选	参数类型	描述
offset	否	Integer	查询算法的偏移量，最小为0。例如设置为1，则表示从第二条开始查。
limit	否	Integer	查询算法的限制量。最小为1，最大为50。
sort_by	否	String	查询算法排列顺序的指标。默认使用create_time排序。

参数	是否必选	参数类型	描述
order	否	String	查询算法排列顺序，默认为“desc”，降序排序。也可以选择对应的“asc”，升序排序。
group_by	否	String	查询算法要搜索的分组条件。
searches	否	String	查询算法所要过滤的条件，如算法名称模糊匹配。
workspace_id	否	String	工作空间ID。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。

请求参数

无

响应参数

状态码： 200

表 4-39 响应 Body 参数

参数	参数类型	描述
total	Integer	查询到当前用户名下的所有算法总数。
count	Integer	查询到当前用户名下的所有符合查询条件的算法总数。
limit	Integer	查询到当前用户名下的所有算法限制个数。
offset	Integer	查询到当前用户名下的所有算法查询偏移量。
sort_by	String	查询到当前用户名下的所有算法排序依赖字段。
order	String	查询到当前用户名下的所有算法排序方式，默认为“desc”，降序排序。也可以选择对应的“asc”，升序排序。
group_by	String	查询到当前用户名下的所有算法分组方式。
items	Array of AlgorithmResponse objects	查询到当前用户名下的所有符合查询条件的算法详情。

表 4-40 AlgorithmResponse

参数	参数类型	描述
metadata	表4-41 object	算法的元数据，描述算法基本信息。
job_config	表4-42 object	算法配置信息，如启动文件等。
resource_requirements	Array of 表4-51 objects	算法资源约束，可不设置。设置后，在算法使用于训练作业时，控制台会过滤可用的公共资源池。
advanced_config	表4-52 object	算法高级策略： • auto_search

表 4-41 Metadata

参数	参数类型	描述
id	Integer	算法uuid，创建算法时无需填写。
name	String	算法名称。限制为1-64位只含数字、字母、下划线和中划线的名称。
description	String	对算法的描述，默认为“NULL”，字符串的长度限制为[0, 256]。
workspace_id	String	指定算法所处的工作空间，默认值为“0”。“0”为默认的工作空间。
ai_project	String	指定算法所属的ai项目，默认值为"default-ai-project"。ai项目已下线，无需关注。
user_name	String	用户名称。
domain_id	String	用户的domainID。
source	String	算法来源类型。
api_version	String	算法api版本，标识新旧版。
is_valid	String	算法可用性。
state	String	算法状态。
tags	Array of Map<String,String> objects	算法标签。
attr_list	Array of strings	算法属性列表。
version_num	Integer	算法版本数量，默认为0。
size	Integer	算法大小。
create_time	Long	算法创建时间戳。

参数	参数类型	描述
update_time	Long	算法更新时间戳。

表 4-42 JobConfig

参数	参数类型	描述
code_dir	String	算法的代码目录。如：“/usr/app/”。应与 boot_file一同出现。
boot_file	String	算法的代码启动文件，需要在代码目录下。如：“/usr/app/boot.py”。应与code_dir一同出现。
command	String	自定义镜像算法的容器启动命令。
parameters	Array of Parameter objects	算法的运行参数。
inputs	Array of 表 4-46 objects	算法的数据输入。
outputs	Array of 表 4-48 objects	算法的数据输出。
engine	表4-49 object	算法的引擎。
code_tree	Array of 表 4-50 objects	算法的目录结构树。
parameters_customization	Boolean	算法是否允许创建训练作业时自定义超参。

表 4-43 Parameter

参数	参数类型	描述
name	String	参数名称。
value	String	参数值。
description	String	参数描述信息。
constraint	表4-44 object	参数属性。
internationalization	表4-45 object	国际化描述。

表 4-44 Constraint

参数	参数类型	描述
type	String	参数种类。
editable	Boolean	是否可编辑。
required	Boolean	是否必须。
sensitive	Boolean	是否敏感。该功能暂未实现。
valid_type	String	有效种类。
valid_range	Array of strings	有效范围。

表 4-45 I18nDescription

参数	参数类型	描述
language	String	国际语种
description	String	国际化语种的描述信息。

表 4-46 Inputs

参数	参数类型	描述
name	String	数据输入通道名称。
description	String	数据输入通道描述信息。
remote_constraints	Array of 表 4-47 objects	数据输入约束。

表 4-47 RemoteConstraints

参数	参数类型	描述
data_type	String	数据输入类型，包括数据存储位置、数据集两种方式。
attributes	Array of Map<String,String> objects	数据输入为数据集时的相关属性。枚举值： - data_format数据格式。 - data_segmentation数据切分方式。 - dataset_type标注类型。

表 4-48 Outputs

参数	参数类型	描述
name	String	数据输出通道名称。
description	String	数据输出通道描述信息。

表 4-49 Engine

参数	参数类型	描述
engine_id	String	算法选择的引擎规格ID。
engine_name	String	算法选择的引擎版本名称。若填入engine_id则无需填写。
engine_version	String	算法选择的引擎版本名称。若填入engine_id则无需填写。
image_url	String	算法选择的自定义镜像地址。

表 4-50 CodeTree

参数	参数类型	描述
name	String	算法目录树当前层级目录名。
children	Object	算法目录树当前层级目录下子文件和子目录。

表 4-51 ResourceRequirements

参数	参数类型	描述
key	String	资源约束，可选值如下： - 资源类型（flavor_type），对应值可选择CPU、GPU； - 是否支持多卡训练（device_distributed_mode），对应值可选择支持（multiple）、不支持（singular）； - 是否支持分布式训练（host_distributed_mode），对应值可选择支持（multiple）、不支持（singular）。
value	Array of strings	资源约束键对应值。
operator	String	键与值关系，当前只支持in。例如flavor_type in [CPU,GPU]。

表 4-52 AdvancedConfig

参数	参数类型	描述
auto_search	表4-53 object	超参搜索策略。

表 4-53 AutoSearch

参数	参数类型	描述
skip_search_params	String	需要排除的超参组合。
reward_attrs	Array of 表 4-54 objects	搜索指标列表。
search_params	Array of 表 4-55 objects	搜索参数。
algo_configs	Array of 表 4-56 objects	搜索算法配置。

表 4-54 RewardAttrs

参数	参数类型	描述
name	String	指标名称。
mode	String	搜索方向。 - max指定时表示指标值越大越好； - min指定时表示指标值越小越好。
regex	String	指标正则表达式。

表 4-55 SearchParams

参数	参数类型	描述
name	String	超参名称。
param_type	String	参数类型。 - continuous：指定时表示这个超参是连续类型的。连续类型的超参在算法使用于训练作业时，控制台显示为输入框。 - discrete：指定时表示这个超参是离散类型的。离散类型的超参在算法使用于训练作业时，控制台显示为下拉选择框架。
lower_bound	String	超参下界。

参数	参数类型	描述
upper_bound	String	超参上界。
discrete_points_num	String	连续型超参离散化取值个数。
discrete_values	String	离散型超参的取值列表。

表 4-56 AlgoConfigs

参数	参数类型	描述
name	String	搜索算法名称。
params	Array of AutoSearchAlgoConfigParameter objects	搜索算法参数。

表 4-57 AutoSearchAlgoConfigParameter

参数	参数类型	描述
key	String	参数键。
value	String	参数值。
type	String	参数种类。

请求示例

如下以查询算法限制个数为1，查询作业名字中包含TestModelArtsalgorithm的所有算法数据为例。

```
GET https://endpoint/v2/{project_id}/algorithms?limit=1&searches=name%3ATestModelArtsalgorithm
```

响应示例

状态码： 200

```
ok
{
  "total": 1,
  "count": 1,
  "limit": 1,
  "offset": 0,
  "sort_by": "create_time",
  "order": "desc",
  "group_by": "",
  "items": [ {
```

```
"metadata" : {
  "id" : "2e5451fe-913f-4492-821a-2981031382f7",
  "name" : "TestModelArtsalgorithm",
  "description" : "This is a ModelArts algorithm",
  "create_time" : 1636600721742,
  "workspace_id" : "0",
  "ai_project" : "default-ai-project",
  "user_name" : "",
  "domain_id" : "xxxxxxxxxxxxxxxxxxxxxxxxxxxx",
  "source" : "custom",
  "api_version" : "",
  "is_valid" : true,
  "state" : "",
  "size" : 4791,
  "tags" : null,
  "attr_list" : null,
  "version_num" : 0,
  "update_time" : 0
},
"job_config" : {
  "code_dir" : "/algo-test/pytorch/work1/code/",
  "boot_file" : "/algo-test/pytorch/work1/code/test-pytorch.py",
  "command" : "",
  "parameters" : [ {
    "name" : "test-parameter",
    "description" : "",
    "i18n_description" : null,
    "value" : "10",
    "constraint" : {
      "type" : "String",
      "editable" : true,
      "required" : false,
      "sensitive" : false,
      "valid_type" : "None",
      "valid_range" : [ ]
    }
  } ],
  "parameters_customization" : true,
  "inputs" : [ {
    "name" : "data_url",
    "description" : "name to translate"
  } ],
  "outputs" : [ {
    "name" : "train_url",
    "description" : "name to translate"
  } ],
  "engine" : {
    "engine_id" : "pytorch-cp36-1.3.0",
    "engine_name" : "PyTorch",
    "engine_version" : "PyTorch-1.3.0-python3.6"
  },
  "code_tree" : {
    "name" : "code/",
    "children" : [ {
      "name" : "test-pytorch.py"
    } ]
  }
},
"resource_requirements" : null,
"advanced_config" : { }
} ] }
```

状态码

状态码	描述
200	ok

错误码

请参见[错误码](#)。

4.1.3 查询算法详情

功能介绍

根据算法id查询指定算法。当用户需要查看特定算法的详细配置和属性时，可以通过此接口获取算法详情。使用该接口的前提条件是用户已知算法ID，并具有查看算法详情的权限。查询操作完成后，平台将返回包含算法名称、描述、版本等详细信息。若算法ID不存在或用户无权限操作，接口将返回相应的错误信息。

URI

GET /v2/{project_id}/algorithms/{algorithm_id}

表 4-58 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
algorithm_id	是	String	算法ID。

请求参数

无

响应参数

状态码： 200

表 4-59 响应 Body 参数

参数	参数类型	描述
metadata	表4-60 object	算法的元数据，描述算法基本信息。
job_config	表4-61 object	算法配置信息，如启动文件等。

参数	参数类型	描述
resource_requirements	Array of 表 4-70 objects	算法资源约束，可不设置。设置后，在算法使用于训练作业时，控制台会过滤可用的公共资源池。
advanced_config	表4-71 object	算法高级策略： • auto_search

表 4-60 Metadata

参数	参数类型	描述
id	Integer	算法uuid，创建算法时无需填写。
name	String	算法名称。限制为1-64位只含数字、字母、下划线和中划线的名称。
description	String	对算法的描述，默认为“NULL”，字符串的长度限制为[0, 256]。
workspace_id	String	指定算法所处的工作空间，默认值为“0”。“0”为默认的工作空间。
ai_project	String	指定算法所属的ai项目，默认值为"default-ai-project"。ai项目已下线，无需关注。
user_name	String	用户名称。
domain_id	String	用户的domainID。
source	String	算法来源类型。
api_version	String	算法api版本，标识新旧版。
is_valid	String	算法可用性。
state	String	算法状态。
tags	Array of Map<String,String> objects	算法标签。
attr_list	Array of strings	算法属性列表。
version_num	Integer	算法版本数量，默认为0。
size	Integer	算法大小。
create_time	Long	算法创建时间戳。
update_time	Long	算法更新时间戳。

表 4-61 JobConfig

参数	参数类型	描述
code_dir	String	算法的代码目录。如：“/usr/app/”。应与 boot_file一同出现。
boot_file	String	算法的代码启动文件，需要在代码目录下。如：“/usr/app/boot.py”。应与code_dir一同出现。
command	String	自定义镜像算法的容器启动命令。
parameters	Array of Parameter objects	算法的运行参数。
inputs	Array of 表 4-65 objects	算法的数据输入。
outputs	Array of 表 4-67 objects	算法的数据输出。
engine	表4-68 object	算法的引擎。
code_tree	Array of 表 4-69 objects	算法的目录结构树。
parameters_customization	Boolean	算法是否允许创建训练作业时自定义超参。

表 4-62 Parameter

参数	参数类型	描述
name	String	参数名称。
value	String	参数值。
description	String	参数描述信息。
constraint	表4-63 object	参数属性。
internationalization	表4-64 object	国际化描述。

表 4-63 Constraint

参数	参数类型	描述
type	String	参数种类。
editable	Boolean	是否可编辑。
required	Boolean	是否必须。

参数	参数类型	描述
sensitive	Boolean	是否敏感。该功能暂未实现。
valid_type	String	有效种类。
valid_range	Array of strings	有效范围。

表 4-64 I18nDescription

参数	参数类型	描述
language	String	国际语种
description	String	国际化语种的描述信息。

表 4-65 Inputs

参数	参数类型	描述
name	String	数据输入通道名称。
description	String	数据输入通道描述信息。
remote_constraints	Array of 表 4-66 objects	数据输入约束。

表 4-66 RemoteConstraints

参数	参数类型	描述
data_type	String	数据输入类型，包括数据存储位置、数据集两种方式。
attributes	Array of Map<String,String> objects	数据输入为数据集时的相关属性。枚举值： - data_format数据格式。 - data_segmentation数据切分方式。 - dataset_type标注类型。

表 4-67 Outputs

参数	参数类型	描述
name	String	数据输出通道名称。
description	String	数据输出通道描述信息。

表 4-68 Engine

参数	参数类型	描述
engine_id	String	算法选择的引擎规格ID。
engine_name	String	算法选择的引擎版本名称。若填入engine_id则无需填写。
engine_version	String	算法选择的引擎版本名称。若填入engine_id则无需填写。
image_url	String	算法选择的自定义镜像地址。

表 4-69 CodeTree

参数	参数类型	描述
name	String	算法目录树当前层级目录名。
children	Object	算法目录树当前层级目录下子文件和子目录。

表 4-70 ResourceRequirements

参数	参数类型	描述
key	String	资源约束，可选值如下： - 资源类型（flavor_type），对应值可选择CPU、GPU； - 是否支持多卡训练（device_distributed_mode），对应值可选择支持（multiple）、不支持（singular）； - 是否支持分布式训练（host_distributed_mode），对应值可选择支持（multiple）、不支持（singular）。
value	Array of strings	资源约束键对应值。
operator	String	键与值关系，当前只支持in。例如flavor_type in [CPU,GPU]。

表 4-71 AdvancedConfig

参数	参数类型	描述
auto_search	表4-72 object	超参搜索策略。

表 4-72 AutoSearch

参数	参数类型	描述
skip_search_params	String	需要排除的超参组合。
reward_attr	Array of 表 4-73 objects	搜索指标列表。
search_params	Array of 表 4-74 objects	搜索参数。
algo_configs	Array of 表 4-75 objects	搜索算法配置。

表 4-73 RewardAttr

参数	参数类型	描述
name	String	指标名称。
mode	String	搜索方向。 - max指定时表示指标值越大越好； - min指定时表示指标值越小越好。
regex	String	指标正则表达式。

表 4-74 SearchParams

参数	参数类型	描述
name	String	超参名称。
param_type	String	参数类型。 - continuous：指定时表示这个超参是连续类型的。连续类型的超参在算法使用于训练作业时，控制台显示为输入框。 - discrete：指定时表示这个超参是离散类型的。离散类型的超参在算法使用于训练作业时，控制台显示为下拉选择框架。
lower_bound	String	超参下界。
upper_bound	String	超参上界。
discrete_points_num	String	连续型超参离散化取值个数。
discrete_values	String	离散型超参的取值列表。

表 4-75 AlgoConfigs

参数	参数类型	描述
name	String	搜索算法名称。
params	Array of AutoSearchAlgoConfigParameter objects	搜索算法参数。

表 4-76 AutoSearchAlgoConfigParameter

参数	参数类型	描述
key	String	参数键。
value	String	参数值。
type	String	参数种类。

请求示例

如下以查询uuid为2e5451fe-913f-4492-821a-2981031382f7的算法为例。

GET https://endpoint/v2/{project_id}/algorithms/2e5451fe-913f-4492-821a-2981031382f7

响应示例

状态码： 200

ok

```
{
  "metadata": {
    "id": "2e5451fe-913f-4492-821a-2981031382f7",
    "name": "TestModelArtsalgorithm",
    "description": "This is a ModelArts algorithm",
    "create_time": 1636600721742,
    "workspace_id": "0",
    "ai_project": "default-ai-project",
    "user_name": "",
    "domain_id": "xxxxxxxxxxxxxxxxxxxxxxxxxxxx",
    "source": "custom",
    "api_version": "",
    "is_valid": true,
    "state": "",
    "size": 4791,
    "tags": null,
    "attr_list": null,
    "version_num": 0,
    "update_time": 0
  },
  "job_config": {
    "code_dir": "/algo-test/pytorch/work1/code/",
    "boot_file": "/algo-test/pytorch/work1/code/test-pytorch.py",
    "command": "",
    "parameters": [ {
      "name": "test-parameter",
```

```
{
  "description": "",
  "i18n_description": null,
  "value": "10",
  "constraint": {
    "type": "String",
    "editable": true,
    "required": false,
    "sensitive": false,
    "valid_type": "None",
    "valid_range": []
  },
},
"parameters_customization": true,
"inputs": [ {
  "name": "data_url",
  "description": "name to translate"
} ],
"outputs": [ {
  "name": "train_url",
  "description": "name to translate"
} ],
"engine": {
  "engine_id": "pytorch-cp36-1.3.0",
  "engine_name": "PyTorch",
  "engine_version": "PyTorch-1.3.0-python3.6"
},
"code_tree": {
  "name": "code/",
  "children": [ {
    "name": "test-pytorch.py"
  } ]
},
},
"resource_requirements": null,
"advanced_config": { }
}
```

状态码

状态码	描述
200	ok。

错误码

请参见[错误码](#)。

4.1.4 更新算法

功能介绍

更新已有算法。该接口适用于以下场景：当算法的描述、标签、模型文件等信息需要更新时，用户可以通过此接口进行修改。使用该接口的前提条件是算法已存在且用户具有相应的权限。更新操作完成后，算法信息将被更新，相关配置也将同步修改。若算法不存在或用户无权限操作，接口将返回相应的错误信息。

URI

PUT /v2/{project_id}/algorithms/{algorithm_id}

表 4-77 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
algorithm_id	是	String	算法ID。

请求参数

表 4-78 请求 Body 参数

参数	是否必选	参数类型	描述
metadata	否	AlgorithmMetadata object	算法的元数据，描述算法基本信息。
job_config	否	AlgorithmJobConfig object	算法配置信息，如启动文件等。
resource_requirements	否	Array of ResourceRequirement objects	算法资源约束。可不设置。设置后，在算法使用于训练作业时，控制台会过滤可用的公共资源池。
advanced_config	否	AlgorithmAdvancedConfig object	算法高级策略： • auto_search

表 4-79 AlgorithmMetadata

参数	是否必选	参数类型	描述
id	否	Integer	算法uuid，创建算法时无需填写。
name	是	String	算法名称。限制为1-64位只含数字、字母、下划线和中划线的名称。
description	否	String	对算法的描述，默认为“NULL”，字符串的长度限制为[0, 256]。
workspace_id	否	String	指定算法所处的工作空间，默认值为“0”。“0”为默认的工作空间。
ai_project	否	String	指定算法所属的ai项目，默认值为"default-ai-project"。ai项目已下线，无需关注。

表 4-80 AlgorithmJobConfig

参数	是否必选	参数类型	描述
code_dir	否	String	算法的代码目录。如： “/usr/app/”。应与boot_file一同出现。
boot_file	否	String	算法的代码启动文件，需要在代码目录下。如：“/usr/app/boot.py”。应与code_dir一同出现。
command	否	String	自定义镜像算法的容器启动命令。
parameters	否	Array of Parameters objects	算法的运行参数。
inputs	否	Array of AlgorithmCreateInput objects	算法的数据输入。
outputs	否	Array of AlgorithmCreateOutput objects	算法的数据输出。
engine	否	AlgorithmCreateEngine object	算法的引擎。
parameters_customization	否	Boolean	算法是否允许创建训练作业时自定义超参。

表 4-81 Parameters

参数	是否必选	参数类型	描述
name	否	String	参数名称。
value	否	String	参数值。
description	否	String	参数描述信息。
constraint	否	ParametersConstraint object	参数属性。
internationalization_description	否	InternationalizationDescription object	国际化描述。

表 4-82 ParametersConstraint

参数	是否必选	参数类型	描述
type	否	String	参数种类。
editable	否	Boolean	是否可编辑。
required	否	Boolean	是否必须。
sensitive	否	Boolean	是否敏感。该功能暂未实现。
valid_type	否	String	有效种类。
valid_range	否	Array of strings	有效范围。

表 4-83 I18nDescription

参数	是否必选	参数类型	描述
language	否	String	国际语种。
description	否	String	描述信息。

表 4-84 AlgorithmCreateInput

参数	是否必选	参数类型	描述
name	否	String	数据输入通道名称。
description	否	String	数据输入通道描述信息。
remote_constraints	否	Array of RemoteConstraint objects	数据输入约束。

表 4-85 RemoteConstraint

参数	是否必选	参数类型	描述
data_type	否	String	数据输入类型，支持数据存储位置（ OBS ）、ModelArts数据集两种方式。

参数	是否必选	参数类型	描述
attributes	否	Array of Map<String,String> objects	数据输入为数据集时的相关属性。枚举值： - data_format：数据格式。 - data_segmentation：数据切分方式。 - dataset_type：标注类型。

表 4-86 AlgorithmCreateOutput

参数	是否必选	参数类型	描述
name	是	String	数据输出通道名称。
description	否	String	数据输出通道描述信息。

表 4-87 AlgorithmCreateEngine

参数	是否必选	参数类型	描述
engine_id	否	String	算法选择的引擎规格ID。
engine_name	否	String	算法选择的引擎版本名称。若填入engine_id则无需填写。
engine_version	否	String	算法选择的引擎版本名称。若填入engine_id则无需填写。
image_url	否	String	算法选择的自定义镜像地址。

表 4-88 ResourceRequirement

参数	是否必选	参数类型	描述
key	否	String	资源约束，可选键值如： - flavor_type（资源类型），对应值可选择CPU、GPU； - device_distributed_mode（是否支持多卡训练），对应值可选择multiple（支持）、singular（不支持）； - host_distributed_mode（是否支持分布式训练），对应值可选择multiple（支持）、singular（不支持）。

参数	是否必选	参数类型	描述
values	否	Array of strings	资源约束键对应值。
operator	否	String	键与值关系，当前只支持in。例如flavor_type in [CPU,GPU]。

表 4-89 AlgorithmAdvancedConfig

参数	是否必选	参数类型	描述
auto_search	否	AutoSearch object	超参搜索策略。

表 4-90 AutoSearch

参数	是否必选	参数类型	描述
skip_search_params	否	String	需要排除的超参组合。
reward_attrs	否	Array of RewardAttrs objects	搜索指标列表。
search_params	否	Array of SearchParams objects	搜索参数。
algo_configs	否	Array of AlgoConfigs objects	搜索算法配置。

表 4-91 RewardAttrs

参数	是否必选	参数类型	描述
name	否	String	指标名称。
mode	否	String	搜索方向。 - max指定时表示指标值越大越好； - min指定时表示指标值越小越好。
regex	否	String	指标正则表达式。

表 4-92 SearchParams

参数	是否必选	参数类型	描述
name	否	String	超参名称。
param_type	否	String	参数类型。 - continuous: 指定时表示这个超参是连续类型的。连续类型的超参在算法使用于训练作业时, 控制台显示为输入框。 - discrete: 指定时表示这个超参是离散类型的。离散类型的超参在算法使用于训练作业时, 控制台显示为下拉选择框架。
lower_bound	否	String	超参下界。
upper_bound	否	String	超参上界。
discrete_points_num	否	String	连续型超参离散化取值个数。
discrete_values	否	Array of strings	离散型超参的取值列表。

表 4-93 AlgoConfigs

参数	是否必选	参数类型	描述
name	否	String	搜索算法名称。
params	否	Array of AutoSearchAlgoConfigParameter objects	搜索算法参数。

表 4-94 AutoSearchAlgoConfigParameter

参数	是否必选	参数类型	描述
key	否	String	参数键。
value	否	String	参数值。
type	否	String	参数种类。

响应参数

状态码： 201

表 4-95 响应 Body 参数

参数	参数类型	描述
metadata	表4-96 object	算法的元数据，描述算法基本信息。
job_config	表4-97 object	算法配置信息，如启动文件等。
resource_requirements	Array of 表4-106 objects	算法资源约束，可不设置。设置后，在算法使用于训练作业时，控制台会过滤可用的公共资源池。
advanced_config	表4-107 object	算法高级策略： • auto_search

表 4-96 Metadata

参数	参数类型	描述
id	Integer	算法uuid，创建算法时无需填写。
name	String	算法名称。限制为1-64位只含数字、字母、下划线和中划线的名称。
description	String	对算法的描述，默认为“NULL”，字符串的长度限制为[0, 256]。
workspace_id	String	指定算法所处的工作空间，默认值为“0”。“0”为默认的工作空间。
ai_project	String	指定算法所属的ai项目，默认值为"default-ai-project"。ai项目已下线，无需关注。
user_name	String	用户名称。
domain_id	String	用户的domainID。
source	String	算法来源类型。
api_version	String	算法api版本，标识新旧版。
is_valid	String	算法可用性。
state	String	算法状态。
tags	Array of Map<String,String> objects	算法标签。
attr_list	Array of strings	算法属性列表。

参数	参数类型	描述
version_num	Integer	算法版本数量，默认为0。
size	Integer	算法大小。
create_time	Long	算法创建时间戳。
update_time	Long	算法更新时间戳。

表 4-97 JobConfig

参数	参数类型	描述
code_dir	String	算法的代码目录。如：“/usr/app/”。应与 boot_file 一同出现。
boot_file	String	算法的代码启动文件，需要在代码目录下。如：“/usr/app/boot.py”。应与 code_dir 一同出现。
command	String	自定义镜像算法的容器启动命令。
parameters	Array of Parameter objects	算法的运行参数。
inputs	Array of 表 4-101 objects	算法的数据输入。
outputs	Array of 表 4-103 objects	算法的数据输出。
engine	表4-104 object	算法的引擎。
code_tree	Array of 表 4-105 objects	算法的目录结构树。
parameters_customization	Boolean	算法是否允许创建训练作业时自定义超参。

表 4-98 Parameter

参数	参数类型	描述
name	String	参数名称。
value	String	参数值。
description	String	参数描述信息。
constraint	表4-99 object	参数属性。

参数	参数类型	描述
i18n_description	表4-100 object	国际化描述。

表 4-99 Constraint

参数	参数类型	描述
type	String	参数种类。
editable	Boolean	是否可编辑。
required	Boolean	是否必须。
sensitive	Boolean	是否敏感。该功能暂未实现。
valid_type	String	有效种类。
valid_range	Array of strings	有效范围。

表 4-100 I18nDescription

参数	参数类型	描述
language	String	国际语种。
description	String	国际化语种的描述信息。

表 4-101 Inputs

参数	参数类型	描述
name	String	数据输入通道名称。
description	String	数据输入通道描述信息。
remote_constraints	Array of 表 4-102 objects	数据输入约束。

表 4-102 RemoteConstraints

参数	参数类型	描述
data_type	String	数据输入类型，包括数据存储位置、数据集两种方式。

参数	参数类型	描述
attributes	Array of Map<String,String> objects	数据输入为数据集时的相关属性。枚举值： - data_format数据格式。 - data_segmentation数据切分方式。 - dataset_type标注类型。

表 4-103 Outputs

参数	参数类型	描述
name	String	数据输出通道名称。
description	String	数据输出通道描述信息。

表 4-104 Engine

参数	参数类型	描述
engine_id	String	算法选择的引擎规格ID。
engine_name	String	算法选择的引擎版本名称。若填入engine_id则无需填写。
engine_version	String	算法选择的引擎版本名称。若填入engine_id则无需填写。
image_url	String	算法选择的自定义镜像地址。

表 4-105 CodeTree

参数	参数类型	描述
name	String	算法目录树当前层级目录名。
children	Object	算法目录树当前层级目录下子文件和子目录。

表 4-106 ResourceRequirements

参数	参数类型	描述
key	String	资源约束，可选值如下： - 资源类型（ flavor_type ），对应值可选择 CPU、GPU； - 是否支持多卡训练（ device_distributed_mode ），对应值可选择支持（ multiple ）、不支持（ singular ）； - 是否支持分布式训练（ host_distributed_mode ），对应值可选择支持（ multiple ）、不支持（ singular ）。
value	Array of strings	资源约束键对应值。
operator	String	键与值关系，当前只支持in。例如flavor_type in [CPU,GPU]。

表 4-107 AdvancedConfig

参数	参数类型	描述
auto_search	表4-108 object	超参搜索策略。

表 4-108 AutoSearch

参数	参数类型	描述
skip_search_params	String	需要排除的超参组合。
reward_attrs	Array of 表 4-109 objects	搜索指标列表。
search_params	Array of 表 4-110 objects	搜索参数。
algo_configs	Array of 表 4-111 objects	搜索算法配置。

表 4-109 RewardAttrs

参数	参数类型	描述
name	String	指标名称。

参数	参数类型	描述
mode	String	搜索方向。 • max指定时表示指标值越大越好； • min指定时表示指标值越小越好。
regex	String	指标正则表达式。

表 4-110 SearchParams

参数	参数类型	描述
name	String	超参名称。
param_type	String	参数类型。 • continuous：指定时表示这个超参是连续类型的。连续类型的超参在算法使用于训练作业时，控制台显示为输入框。 • discrete：指定时表示这个超参是离散类型的。离散类型的超参在算法使用于训练作业时，控制台显示为下拉选择框架。
lower_bound	String	超参下界。
upper_bound	String	超参上界。
discrete_points_num	String	连续型超参离散化取值个数。
discrete_values	String	离散型超参的取值列表。

表 4-111 AlgoConfigs

参数	参数类型	描述
name	String	搜索算法名称。
params	Array of AutoSearchAlgoConfigParameter objects	搜索算法参数。

表 4-112 AutoSearchAlgoConfigParameter

参数	参数类型	描述
key	String	参数键。

参数	参数类型	描述
value	String	参数值。
type	String	参数种类。

请求示例

如下以修改uuid为2e5451fe-913f-4492-821a-2981031382f7的算法为例。

```
PUT https://endpoint/v2/{project_id}/algorithms/2e5451fe-913f-4492-821a-2981031382f7
{
  "metadata": {
    "name": "TestModelArtsalgorithm",
    "description": "This is a ModelArts algorithm modified"
  },
  "job_config": {
    "code_dir": "/algo-test/pytorch/work1/code/",
    "boot_file": "/algo-test/pytorch/work1/code/test-pytorch.py",
    "parameters": [ {
      "name": "test-parameter",
      "value": "10",
      "constraint": {
        "type": "String",
        "editable": true,
        "required": false,
        "sensitive": false,
        "valid_type": "None",
        "valid_range": [ ]
      }
    }
  ],
  "parameters_customization": true,
  "inputs": [ {
    "name": "data_url",
    "description": "data source."
  } ],
  "outputs": [ {
    "name": "train_url",
    "description": "model output."
  } ],
  "engine": {
    "engine_name": "PyTorch",
    "engine_version": "PyTorch-1.3.0-python3.6"
  }
}
```

响应示例

状态码： 201

ok

```
{
  "metadata": {
    "id": "2e5451fe-913f-4492-821a-2981031382f7",
    "name": "TestModelArtsalgorithm",
    "description": "This is a ModelArts algorithm modified",
    "create_time": 1636600721742,
    "workspace_id": "0",
    "ai_project": "default-ai-project",
    "user_name": "",
    "domain_id": "xxxxxxxxxxxxxxxxxxxxxxxxxx",

```

```
{
  "source": "custom",
  "api_version": "",
  "is_valid": true,
  "state": "",
  "size": 4791,
  "tags": null,
  "attr_list": null,
  "version_num": 0,
  "update_time": 0
},
"job_config": {
  "code_dir": "/algo-test/pytorch/work1/code/",
  "boot_file": "/algo-test/pytorch/work1/code/test-pytorch.py",
  "command": "",
  "parameters": [ {
    "name": "test-parameter",
    "description": "",
    "i18n_description": null,
    "value": "10",
    "constraint": {
      "type": "String",
      "editable": true,
      "required": false,
      "sensitive": false,
      "valid_type": "None",
      "valid_range": [ ]
    }
  } ],
  "parameters_customization": true,
  "inputs": [ {
    "name": "data_url",
    "description": "name to translate"
  } ],
  "outputs": [ {
    "name": "train_url",
    "description": "name to translate"
  } ],
  "engine": {
    "engine_id": "pytorch-cp36-1.3.0",
    "engine_name": "PyTorch",
    "engine_version": "PyTorch-1.3.0-python3.6"
  },
  "code_tree": {
    "name": "code/",
    "children": [ {
      "name": "test-pytorch.py"
    } ]
  }
},
"resource_requirements": null,
"advanced_config": { }
}
```

状态码

状态码	描述
201	ok。

错误码

请参见[错误码](#)。

4.1.5 删除算法

功能介绍

删除算法用于从ModelArts平台上移除已注册的算法。

该接口适用于以下场景：当用户需要清理不再使用的算法时，可以通过此接口删除指定的算法。使用该接口的前提条件是算法已存在且用户具有删除算法的权限。删除操作完成后，算法将从平台中永久移除。若算法ID不存在或用户无权限操作，接口将返回相应的错误信息。

URI

DELETE /v2/{project_id}/algorithms/{algorithm_id}

表 4-113 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
algorithm_id	是	String	算法ID。

请求参数

无

响应参数

无

请求示例

如下以修改uuid为2e5451fe-913f-4492-821a-2981031382f7的算法为例。

```
DELETE https://endpoint/v2/{project_id}/algorithms/2e5451fe-913f-4492-821a-2981031382f7
```

响应示例

状态码： 202

No Content

```
null
```

状态码

状态码	描述
202	No Content。

错误码

请参见[错误码](#)。

4.2 训练作业管理

4.2.1 创建训练作业

功能介绍

创建训练作业。

该接口适用于以下场景：当用户需要基于特定的数据集和算法模型进行机器学习训练时，可以通过此接口创建并配置训练作业。使用该接口的前提条件是用户已上传数据集和模型代码至ModelArts平台，并具有创建训练作业的权限。创建训练作业后，平台将根据配置的资源规格启动训练任务，用户可以通过作业ID监控训练进度和状态。若数据集或模型代码不存在、资源规格配置错误或用户无权限操作，接口将返回相应的错误信息。

URI

POST /v2/{project_id}/training-jobs

表 4-114 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。

请求参数

表 4-115 请求 Body 参数

参数	是否必选	参数类型	描述
kind	是	String	训练作业类型。默认使用job，表示训练作业。
metadata	是	JobMetadata object	训练作业元信息。

参数	是否必选	参数类型	描述
algorithm	否	JobAlgorithm object	训练作业算法。目前支持三种形式： • id：只取算法的id； • subscription_id + item_version_id：取算法的订阅id和版本id； • code_dir+boot_file：取训练作业的代码目录和启动文件。
tasks	否	Array of Task objects	任务列表。该功能暂未实现。
spec	否	Spec object	训练作业规格参数。有此字段时，无需填写tasks字段。
endpoints	否	JobEndpoints Req object	远程接入训练作业时需要的相关配置。

表 4-116 JobMetadata

参数	是否必选	参数类型	描述
name	是	String	训练作业名称。限制为1-64位只含数字、字母、下划线和中划线的名称。
workspace_id	否	String	指定作业所处的工作空间，默认值为“0”。
description	否	String	对训练作业的描述，默认为“NULL”，字符串的长度限制为[0, 256]。

参数	是否必选	参数类型	描述
annotations	否	Map<String,String>	训练作业高级功能配置，可选取值如下： • "job_template": "Template RL"（异构作业）。 • "fault-tolerance/job-retry-num": "3"（故障自动重启次数） • "fault-tolerance/job-unconditional-retry": "true"（无条件重启） • "fault-tolerance/hang-retry": "true"（卡死重启） • "jupyter-lab/enable": "true"（JupyterLab训练应用程序）。 • "tensorboard/enable": "true"（TensorBoard训练应用程序）。 • "mindstudio-insight/enable": "true"（MindStudio Insight训练应用程序）。

表 4-117 JobAlgorithm

参数	是否必选	参数类型	描述
id	否	String	算法管理的算法id。
name	否	String	算法名称，无需填写。
subscription_id	否	String	订阅算法的订阅ID。应与item_version_id一同出现。
item_version_id	否	String	订阅算法的版本。应与subscription_id一同出现。
code_dir	否	String	训练作业的代码目录。如：“/usr/app/”。应与boot_file一同出现，如果boot_file填入id或subscription_id+item_version_id，则此参数无需填写。

参数	是否必选	参数类型	描述
boot_file	否	String	训练作业的代码启动文件，需要在代码目录下。如：“/usr/app/boot.py”。应与code_dir一同出现，如果code_dir填入id或subscription_id+item_version_id，则此参数无需填写。
autosearch_config_path	否	String	自动化搜索作业的yaml配置路径，需要提供一个OBS路径。
autosearch_framework_path	否	String	自动化搜索作业的框架代码目录，需要提供一个OBS路径。
command	否	String	自定义镜像场景下，训练作业的自定义镜像的容器的启动命令。
parameters	否	Array of Parameters objects	训练作业的运行参数。
policies	否	JobPolicies object	作业支持的策略，用于超参搜索。
inputs	否	Array of Input objects	训练作业的数据输入。
outputs	否	Array of Output objects	训练作业的结果输出。
engine	否	JobEngine object	训练作业的引擎。使用算法管理的算法id或订阅算法subscription_id+item_version_id创建作业时，无需填写。
local_code_dir	否	String	算法的代码目录下载到训练容器内的本地路径。规则： - 必须为/home下的目录。 - v1兼容模式下，当前字段不生效。 - 当code_dir以file://为前缀时，当前字段不生效。
working_dir	否	String	运行算法时所在的工作目录。规则：v1兼容模式下，当前字段不生效。
environments	否	Map<String,String>	训练作业的环境变量。格式："key":"value"，无需填写。

参数	是否必选	参数类型	描述
summary	否	Summary object	可视化日志summary。

表 4-118 Parameters

参数	是否必选	参数类型	描述
name	否	String	参数名称。
value	否	String	参数值。
description	否	String	参数描述信息。
constraint	否	ParametersConstraint object	参数属性。
i18n_description	否	I18nDescription object	国际化描述。

表 4-119 ParametersConstraint

参数	是否必选	参数类型	描述
type	否	String	参数种类。
editable	否	Boolean	是否可编辑。
required	否	Boolean	是否必须。
sensitive	否	Boolean	是否敏感。该功能暂未实现
valid_type	否	String	有效种类。
valid_range	否	Array of strings	有效范围。

表 4-120 I18nDescription

参数	是否必选	参数类型	描述
language	否	String	国际语种。
description	否	String	描述信息。

表 4-121 JobPolicies

参数	是否必选	参数类型	描述
auto_search	否	AutoSearch object	超参搜索配置。

表 4-122 AutoSearch

参数	是否必选	参数类型	描述
skip_search_params	否	String	需要排除的超参组合。
reward_attrs	否	Array of RewardAttrs objects	搜索指标列表。
search_params	否	Array of SearchParams objects	搜索参数。
algo_configs	否	Array of AlgoConfigs objects	搜索算法配置。

表 4-123 RewardAttrs

参数	是否必选	参数类型	描述
name	否	String	指标名称。
mode	否	String	搜索方向。 - max指定时表示指标值越大越好； - min指定时表示指标值越小越好。
regex	否	String	指标正则表达式。

表 4-124 SearchParams

参数	是否必选	参数类型	描述
name	否	String	超参名称。

参数	是否必选	参数类型	描述
param_type	否	String	参数类型。 - continuous: 指定时表示这个超参是连续类型的。连续类型的超参在算法使用于训练作业时，控制台显示为输入框。 - discrete: 指定时表示这个超参是离散类型的。离散类型的超参在算法使用于训练作业时，控制台显示为下拉选择框架。
lower_bound	否	String	超参下界。
upper_bound	否	String	超参上界。
discrete_points_num	否	String	连续型超参离散化取值个数。
discrete_values	否	Array of strings	离散型超参的取值列表。

表 4-125 AlgoConfigs

参数	是否必选	参数类型	描述
name	否	String	搜索算法名称。
params	否	Array of AutoSearchAlgoConfigParameter objects	搜索算法参数。

表 4-126 AutoSearchAlgoConfigParameter

参数	是否必选	参数类型	描述
key	否	String	参数键。
value	否	String	参数值。
type	否	String	参数种类。

表 4-127 JobEngine

参数	是否必选	参数类型	描述
engine_id	否	String	训练作业选择的引擎规格ID。 engine_id, engine_name +engine_version和image_url方式三选一。
engine_name	否	String	训练作业选择的引擎名称。如果 已填写engine_id, 则此参数无 需填写。
engine_version	否	String	训练作业选择的引擎版本名称。 如果已填写engine_id, 则此参 数无需填写。
image_url	否	String	训练作业选择的自定义镜像地 址, 地址从swr服务获取。

表 4-128 Summary

参数	是否必选	参数类型	描述
log_type	否	String	训练作业可视化日志类型, 配置 后训练作业可作为可视化作业数 据源。可选取值如下: • tensorboard。 • mindstudio-insight。
log_dir	否	LogDir object	训练作业可视化日志输出, log_type非空时必填。
data_sources	否	Array of DataSource object	可视化作业或训练作业调试模式 的可视化日志输入, 训练作业高 级功能开启"tensorboard/ enable": "true"或"mindstudio- insight/enable": "true"时必 填。

表 4-129 LogDir

参数	是否必选	参数类型	描述
pfs	是	PFSSummary object	obs并行文件系统输出。

表 4-130 DataSource

参数	是否必选	参数类型	描述
pfs	是	PFSSummary object	obs并行文件系统输出。

表 4-131 PFSSummary

参数	是否必选	参数类型	描述
pfs_path	是	String	obs并行文件系统路径url。

表 4-132 Task

参数	是否必选	参数类型	描述
role	否	String	任务角色，该功能暂未支持。
algorithm	否	表4-133 object	算法配置。
task_resource	否	表4-154 object	训练作业资源规格信息。

表 4-133 Algorithm

参数	是否必选	参数类型	描述
job_config	否	表4-134 object	算法配置信息，如启动文件等。
code_dir	否	String	算法的代码目录。如： “/usr/app/”。应与boot_file 一同出现。
boot_file	否	String	算法的代码启动文件，需要在代 码目录下。如：“/usr/app/ boot.py”。应与code_dir一同 出现。
engine	否	表4-146 object	异构作业算法的引擎。
inputs	否	Array of 表 4-148 objects	算法的数据输入。
outputs	否	Array of 表 4-151 objects	算法的数据输出。

参数	是否必选	参数类型	描述
local_code_dir	否	String	算法的代码目录下载到训练容器内的本地路径。规则如下： • 必须为/home下的目录； • v1兼容模式下，当前字段不生效； • 当code_dir以file://为前缀时，当前字段不生效。
working_dir	否	String	运行算法时所在的工作目录。规则：v1兼容模式下，当前字段不生效。

表 4-134 JobConfig

参数	是否必选	参数类型	描述
parameters	否	Array of Parameter objects	算法的运行参数。
inputs	否	Array of Input objects	算法的数据输入。
outputs	否	Array of Output objects	算法的数据输出。
engine	否	表4-147 object	算法的引擎。

表 4-135 Parameter

参数	是否必选	参数类型	描述
name	否	String	参数名称。
value	否	String	参数值。
description	否	String	参数描述信息。
constraint	否	表4-174 object	参数属性。
i18n_description	否	表4-137 object	国际化描述。

表 4-136 Constraint

参数	是否必选	参数类型	描述
type	否	String	参数种类。
editable	否	Boolean	是否可编辑。
required	否	Boolean	是否必须。
sensitive	否	Boolean	是否敏感。该功能暂未实现。
valid_type	否	String	有效种类。
valid_range	否	Array of strings	有效范围。

表 4-137 I18nDescription

参数	是否必选	参数类型	描述
language	否	String	国际语种
description	否	String	国际化语种的描述信息。

表 4-138 Input

参数	是否必选	参数类型	描述
name	是	String	数据输入通道名称。
description	否	String	数据输入通道描述信息。
local_dir	否	String	数据输入通道映射的容器本地路径。例如，“/home/ma-user/modelarts/inputs/data_url_0”。
remote	是	InputDataInfo object	数据实际输入信息。枚举值： - dataset：指定输入为数据集； - obs：指定输入为OBS路径。
remote_constraint	否	Array of 表 4-142 objects	数据输入约束。

表 4-139 InputDataInfo

参数	是否必选	参数类型	描述
dataset	否	表4-140 object	数据输入信息为数据集。
obs	否	表4-141 object	数据输入输出信息为OBS方式。

表 4-140 Dataset

参数	是否必选	参数类型	描述
id	是	String	训练作业的数据集ID。
version_id	是	String	训练作业的数据集版本ID。

表 4-141 Obs

参数	是否必选	参数类型	描述
obs_url	是	String	训练作业需要的数据集OBS路径URL。如：“/usr/data/”。

表 4-142 RemoteConstraint

参数	是否必选	参数类型	描述
data_type	否	String	数据输入类型，包括数据存储位置、数据集两种方式。
attributes	否	String	数据输入为数据集时的相关属性。枚举值： - data_format 数据格式； - data_segmentation 数据切分方式； - dataset_type 标注类型。

表 4-143 Output

参数	是否必选	参数类型	描述
name	是	String	数据输出通道名称。
description	否	String	数据输出通道描述信息。

参数	是否必选	参数类型	描述
local_dir	否	String	数据输出通道映射的容器本地路径。
remote	是	Remote object	数据实际输出信息。

表 4-144 Remote

参数	是否必选	参数类型	描述
obs	是	RemoteObs object	数据实际输出到OBS。

表 4-145 RemoteObs

参数	是否必选	参数类型	描述
obs_url	是	String	数据实际输出到OBS的路径。

表 4-146 Engine

参数	是否必选	参数类型	描述
engine_id	否	String	算法选择的引擎规格ID。
engine_name	否	String	算法选择的引擎版本名称。若填入engine_id则无需填写。
engine_version	否	String	算法选择的引擎版本名称。若填入engine_id则无需填写。
image_url	否	String	算法选择的自定义镜像地址。

表 4-147 Engine

参数	是否必选	参数类型	描述
engine_id	否	String	异构作业引擎规格的ID。如“caffe-1.0.0-python2.7”。
engine_name	否	String	异构作业引擎规格的名称。如“Caffe”。
engine_version	否	String	异构作业引擎规格的版本。

参数	是否必选	参数类型	描述
image_url	否	String	算法选择的自定义镜像地址。

表 4-148 Inputs

参数	是否必选	参数类型	描述
name	是	String	数据输入通道名称。
description	否	String	数据输入通道描述信息。
local_dir	否	String	数据输入通道映射的容器本地路径。
remote	是	表4-152 object	数据实际输入信息。枚举值： - dataset：指定输入为数据集； - obs：指定输入为OBS路径。

表 4-149 Remote

参数	是否必选	参数类型	描述
obs	否	表4-153 object	数据输入输出信息为OBS方式。

表 4-150 Obs

参数	是否必选	参数类型	描述
obs_url	是	String	训练作业需要的数据集OBS路径URL。如：“/usr/data/”。

表 4-151 Outputs

参数	是否必选	参数类型	描述
name	是	String	数据输出通道名称。
description	否	String	数据输出通道描述信息。
local_dir	否	String	数据输出通道映射的容器本地路径。
remote	是	表4-144 object	数据实际输出信息。

表 4-152 Remote

参数	是否必选	参数类型	描述
obs	是	表4-153 object	数据实际输出到OBS。

表 4-153 Obs

参数	是否必选	参数类型	描述
obs_url	是	String	数据实际输出到OBS的路径。

表 4-154 TaskResource

参数	是否必选	参数类型	描述
flavor_id	否	String	训练作业选择的资源规格ID。
node_count	是	Integer	训练作业选择的资源副本数。

表 4-155 Spec

参数	是否必选	参数类型	描述
resource	否	SpecResource object	训练作业资源规格信息。 flavor_id和pool_id+[flavor_id] 方式二选一。
volumes	否	Array of Nfs objects	训练作业挂载卷信息。
log_export_path	否	LogExportPath object	训练作业日志输出信息。
auto_stop	否	AutoStop object	训练作业的自动停止配置。
schedule_policy	否	SchedulePolicy object	训练作业调度策略。
custom_metrics	否	Array of CustomMetric objects	训练作业采集prometheus指标。

表 4-156 SpecResource

参数	是否必选	参数类型	描述
flavor_id	否	String	训练作业资源规格id。CPU规格专属资源池不支持指定flavor_id。GPU/Ascend规格专属资源池可选取值举例如下： • modelarts.pool.visual.xlarge（1卡）。 • modelarts.pool.visual.2xlarge（2卡）。 • modelarts.pool.visual.4xlarge（4卡）。 • modelarts.pool.visual.8xlarge（8卡）。
node_count	否	Integer	资源池创建训练作业使用节点数。默认单节点。
pool_id	否	String	专属资源池id。

表 4-157 Nfs

参数	是否必选	参数类型	描述
nfs_server_path	否	String	nfs服务端路径，如：“10.10.10.10:/example/path”。
local_path	否	String	挂载到训练容器中的路径，如：“/example/path”。
read_only	否	Boolean	nfs挂载卷在容器中是否只读。

表 4-158 LogExportPath

参数	是否必选	参数类型	描述
obs_url	否	String	训练作业日志保存的OBS地址，如：“obs://example/path”。
host_path	否	String	训练作业日志保存的宿主机的路径，如：“/example/path”。

表 4-159 AutoStop

参数	是否必选	参数类型	描述
time_unit	是	String	时间单位。可选取值如下： • HOURS
duration	是	Integer	运行时长，最小值为1。

表 4-160 SchedulePolicy

参数	是否必选	参数类型	描述
required_affinity	否	RequiredAffinity object	参数解释： 训练作业亲和要求。 约束限制： 不涉及。
priority	否	Integer	参数解释： 训练作业优先级。 约束限制： • 仅使用专属资源池训练时才支持设置训练作业优先级。 • 作业优先级取值为1~3，默认优先级为1，最高优先级为3。 默认用户权限可选择优先级1和2，配置了“设置作业为高优先级权限”的用户可选择优先级1~3。 取值范围： 0-3 默认取值： 不涉及。
preemptible	否	Boolean	参数解释： 是否可以被抢占。 约束限制： 不涉及。 取值范围： • true：可以被抢占 • false：不可以被抢占 默认取值： 不涉及。

表 4-161 CustomMetric

参数	是否必选	参数类型	描述
http_get	否	HttpGet object	参数解释： http请求方式。 约束限制： 和exec二选一。
exec	否	Exec object	参数解释： 命令行方式。 约束限制： 和http_get二选一。

表 4-162 RequiredAffinity

参数	是否必选	参数类型	描述
affinity_type	否	String	参数解释： 亲和调度策略。 约束限制： 不涉及。 取值范围： - cabinet：强整柜调度 - hyperinstance：超节点亲和调度 默认取值： 不涉及。
affinity_group_size	否	Integer	参数解释： 亲和组实例数大小。 约束限制： affinity_type为hyperinstance时必填，系统会将affinity_group_size个task调度到一个超节点内组成亲和组。用户向超节点资源池投递训练作业，如果未设置亲和组大小，系统会默认赋值为1。 无RoCE组网场景下，系统会自动将affinity_group_size的值设置为与node_count的值相同。 取值范围： 不涉及。 默认取值： 默认值1。
node_labels	否	Map<String,String>	节点标签，可选取值如下： kubernetes.io/hostname 指定调度节点

表 4-163 HttpGet

参数	是否必选	参数类型	描述
path	是	String	参数解释： http请求path部分。 约束限制： /开头。 取值范围： 不涉及。 默认取值： 不涉及。
port	是	Integer	参数解释： http请求端口。 约束限制： 不涉及。 取值范围： 10001-20000。 默认取值： 不涉及。

表 4-164 Exec

参数	是否必选	参数类型	描述
command	是	Array of strings	参数解释：shell命令。 约束限制：长度为2。 取值范围：满足正则表达式 ^[-a-zA-Z0-9_./]+\$。 默认取值：不涉及。

表 4-165 JobEndpointsReq

参数	是否必选	参数类型	描述
ssh	否	SSHReq object	SSH连接信息。

表 4-166 SSHReq

参数	是否必选	参数类型	描述
key_pair_names	否	Array of strings	SSH密钥对名称，可以在云服务器控制台（ECS）“密钥对”页面创建和查看。

响应参数

状态码： 201

表 4-167 响应 Body 参数

参数	参数类型	描述
kind	String	训练作业类型。默认使用job。枚举值： job 训练作业。
metadata	JobMetadata object	训练作业元信息。
status	Status object	训练作业状态信息。创建作业无需填写。
algorithm	JobAlgorithmResponse object	训练作业算法。目前支持三种形式： - id：只取算法的id； - subscription_id+item_version_id：取算法的订阅id和版本id； - code_dir+boot_file：取训练作业的代码目录和启动文件。

参数	参数类型	描述
tasks	Array of TaskResponse objects	异构训练作业的任务列表。
spec	SpecResponse object	训练作业规格参数。
endpoints	JobEndpointsResp object	远程接入训练作业时需要的配置。

表 4-168 JobMetadata

参数	参数类型	描述
id	String	训练作业ID，创建成功后由ModelArts生成返回，无需填写。
name	String	训练作业名称。限制为1-64位只含数字、字母、下划线和中划线的名称。
workspace_id	String	指定作业所处的工作空间，默认值为“0”。
description	String	对训练作业的描述，默认为“NULL”，字符串的长度限制为[0, 256]。
create_time	Long	训练作业创建时间戳，单位为毫秒，创建成功后由ModelArts生成返回，无需填写。
user_name	String	训练作业创建用户的用户名，创建成功后由ModelArts生成返回，无需填写。
annotations	Map<String,String>	训练作业高级功能配置，可选取值如下： • "job_template": "Template RL"（异构作业）。 • "fault-tolerance/job-retry-num": "3"（故障自动重启次数）。 • "fault-tolerance/job-unconditional-retry": "true"（无条件重启）。 • "fault-tolerance/hang-retry": "true"（卡死重启）。 • "jupyter-lab/enable": "true"（JupyterLab训练应用程序）。 • "tensorboard/enable": "true"（TensorBoard训练应用程序）。 • "mindstudio-insight/enable": "true"（MindStudio Insight训练应用程序）。

表 4-169 Status

参数	参数类型	描述
phase	String	训练作业一级状态。可选值如下： - Creating：创建中。 - Pending：等待中。 - Running：运行中。 - Failed：运行失败。 - Completed：已完成。 - Terminating：停止中。 - Terminated：已停止。 - Abnormal：异常。
secondary_phase	String	训练作业二级状态为内部详细状态，可能会增加、修改、删除，不建议依赖。可选值如下： - Creating：创建中。 - Queuing：排队中。 - Running：运行中。 - Failed：运行失败。 - Completed：已完成。 - Terminating：停止中。 - Terminated：已停止。 - CreateFailed：创建失败。 - TerminatedFailed：停止失败。 - Unknown：未知状态。 - Lost：异常。
duration	Long	训练作业运行时长，单位为毫秒。
node_count_metrics	Array<Array<Integer>>	训练作业运行时节点数变化指标。
tasks	Array of strings	训练作业子任务名称。
start_time	Long	训练作业开始时间，格式为时间戳。
task_statuses	Array of TaskStatuses objects	训练在子任务状态信息。
running_records	Array of RunningRecord objects	训练作业运行及故障恢复记录。

表 4-170 TaskStatuses

参数	参数类型	描述
task	String	训练作业子任务名称。
exit_code	Integer	训练作业子任务退出码。
message	String	训练作业子任务错误消息。

表 4-171 RunningRecord

参数	参数类型	描述
start_at	Integer	本次运行开始时间的unix时间戳，单位为秒(s)。
end_at	Integer	本次运行结束时间的unix时间戳，单位为秒(s)。
start_type	String	本地运行的启动方式： • init_or_rescheduled：代表本次启动为被调度后的首次运行，包括初次启动及调度恢复后的运行。 • restarted：代表本次启动非被调度后的首次运行，为进程重启后的运行。
end_reason	String	本次运行结束原因。
end_related_task	String	引发本次运行结束的task worker ID(如worker-0)。
end_recover	String	本次运行结束后所采取的故障容忍策略，枚举值如下： • npu_proc_restart: NPU原地热恢复 • gpu_proc_restart: GPU原地热恢复 • proc_restart: 进程原地重启 • pod_reschedule: Pod级重调度 • job_reschedule: Job级重调度 • job_reschedule_with_taint: 隔离式Job重调度
end_recover_before_downgrade	String	本次运行结束后在故障容忍策略降级前所采取的容忍策略，取值范围同end_recover。

表 4-172 JobAlgorithmResponse

参数	参数类型	描述
id	String	训练作业算法。目前支持三种形式： - id：只取算法的id； - subscription_id+item_version_id：取算法的订阅id和版本id； - code_dir+boot_file：取训练作业的代码目录和启动文件。
name	String	算法名称。
subscription_id	String	订阅算法的订阅ID。应与item_version_id一同出现。
item_version_id	String	订阅算法的版本。应与subscription_id一同出现。
code_dir	String	训练作业的代码目录。如：“/usr/app/”。应与boot_file一同出现，如果boot_file已经填入id或subscription_id+item_version_id，则无需填写此参数。
boot_file	String	训练作业的代码启动文件，需要在代码目录下。如：“/usr/app/boot.py”。应与code_dir一同出现，如果code_dir已经填入id或subscription_id+item_version_id，则无需填写此参数。
autosearch_config_path	String	自动化搜索作业的yaml配置路径，需要提供一个OBS路径。如：“obs://bucket/file.yaml”。
autosearch_framework_path	String	自动化搜索作业的框架代码目录，需要提供一个OBS路径。如：“obs://bucket/files/”。
command	String	自定义镜像训练作业的自定义镜像的容器的启动命令。例如python train.py。
parameters	Array of Parameter objects	训练作业的运行参数。
policies	表4-176 object	作业支持的策略。
inputs	Array of Input objects	训练作业的数据输入。
outputs	Array of Output objects	训练作业的结果输出。
engine	JobEngine object	训练作业的引擎。使用算法管理的算法id或订阅算法subscription_id+item_version_id创建作业时，无需填写。

参数	参数类型	描述
local_code_dir	String	算法的代码目录下载到训练容器内的本地路径。规则如下： • 必须为/home下的目录； • v1兼容模式下，当前字段不生效； • 当code_dir以file://为前缀时，当前字段不生效。
working_dir	String	运行算法时所在的工作目录。规则：v1兼容模式下，当前字段不生效。
environments	Array of Map<String,String> objects	训练作业的环境变量。格式："key":"value"，无需填写。

表 4-173 Parameter

参数	参数类型	描述
name	String	参数名称。
value	String	参数值。
description	String	参数描述信息。
constraint	表4-174 object	参数属性。
i18n_description	表4-175 object	国际化描述。

表 4-174 Constraint

参数	参数类型	描述
type	String	参数种类。
editable	Boolean	是否可编辑。
required	Boolean	是否必须。
sensitive	Boolean	是否敏感。该功能暂未实现。
valid_type	String	有效种类。
valid_range	Array of strings	有效范围。

表 4-175 I18nDescription

参数	参数类型	描述
language	String	国际语种
description	String	国际化语种的描述信息。

表 4-176 Policies

参数	参数类型	描述
auto_search	表4-177 object	超参搜索配置。

表 4-177 AutoSearch

参数	参数类型	描述
skip_search_params	String	需要排除的超参组合。
reward_attr	Array of 表 4-178 objects	搜索指标列表。
search_params	Array of 表 4-179 objects	搜索参数。
algo_configs	Array of 表 4-180 objects	搜索算法配置。

表 4-178 RewardAttrs

参数	参数类型	描述
name	String	指标名称。
mode	String	搜索方向。 - max指定时表示指标值越大越好； - min指定时表示指标值越小越好。
regex	String	指标正则表达式。

表 4-179 SearchParams

参数	参数类型	描述
name	String	超参名称。

参数	参数类型	描述
param_type	String	参数类型。 • continuous：指定时表示这个超参是连续类型的。连续类型的超参在算法使用于训练作业时，控制台显示为输入框。 • discrete：指定时表示这个超参是离散类型的。离散类型的超参在算法使用于训练作业时，控制台显示为下拉选择框架。
lower_bound	String	超参下界。
upper_bound	String	超参上界。
discrete_points_num	String	连续型超参离散化取值个数。
discrete_values	Array of strings	离散型超参的取值列表。

表 4-180 AlgoConfigs

参数	参数类型	描述
name	String	搜索算法名称。
params	Array of AutoSearchAlgoConfigParameter objects	搜索算法参数。

表 4-181 AutoSearchAlgoConfigParameter

参数	参数类型	描述
key	String	参数键。
value	String	参数值。
type	String	参数种类。

表 4-182 Input

参数	参数类型	描述
name	String	数据输入通道名称。
description	String	数据输入通道描述信息。

参数	参数类型	描述
local_dir	String	数据输入通道映射的容器本地路径。例如，“/home/ma-user/modelarts/inputs/data_url_0”。
remote	InputDataInfo object	数据实际输入信息。枚举值： - dataset：指定输入为数据集； - obs：指定输入为OBS路径。
remote_constraint	Array of 表 4-186 objects	数据输入约束。

表 4-183 InputDataInfo

参数	参数类型	描述
dataset	表4-184 object	数据输入信息为数据集。
obs	表4-185 object	数据输入输出信息为OBS方式。

表 4-184 Dataset

参数	参数类型	描述
id	String	训练作业的数据集ID。
version_id	String	训练作业的数据集版本ID。
obs_url	String	训练作业需要的数据集OBS路径URL，ModelArts会通过数据集ID和数据集版本ID自动解析生成。如：“/usr/data/”。

表 4-185 Obs

参数	参数类型	描述
obs_url	String	训练作业需要的数据集OBS路径URL。如：“/usr/data/”。

表 4-186 RemoteConstraint

参数	参数类型	描述
data_type	String	数据输入类型，包括数据存储位置、数据集两种方式。
attributes	String	数据输入为数据集时的相关属性。枚举值： • data_format 数据格式； • data_segmentation 数据切分方式； • dataset_type 标注类型。

表 4-187 Output

参数	参数类型	描述
name	String	数据输出通道名称。
description	String	数据输出通道描述信息。
local_dir	String	数据输出通道映射的容器本地路径。
remote	Remote object	数据实际输出信息。

表 4-188 JobEngine

参数	参数类型	描述
engine_id	String	训练作业选择的引擎规格ID。engine_id，engine_name+engine_version和image_url方式三选一。
engine_name	String	训练作业选择的引擎名称。如果已填写engine_id，则此参数无需填写。
engine_version	String	训练作业选择的引擎版本名称。如果已填写engine_id，则此参数无需填写。
image_url	String	训练作业选择的自定义镜像地址，地址从swr服务获取。

表 4-189 TaskResponse

参数	参数类型	描述
role	String	任务角色，该功能暂未支持。

参数	参数类型	描述
algorithm	TaskResponseAlgorithm object	算法配置。
task_resource	FlavorResponse object	训练作业、算法的规格信息。

表 4-190 TaskResponseAlgorithm

参数	参数类型	描述
code_dir	String	算法启动文件所在目录绝对路径。
boot_file	String	算法启动文件绝对路径。
inputs	AlgorithmInput object	算法输入通道信息。
outputs	AlgorithmOutput object	算法输出通道信息。
engine	AlgorithmEngine object	异构作业所依赖的引擎。
local_code_dir	String	算法的代码目录下载到训练容器内的本地路径。 规则如下： • 必须为/home下的目录； • v1兼容模式下，当前字段不生效； • 当code_dir以file://为前缀时，当前字段不生效。
working_dir	String	运行算法时所在的工作目录。规则：v1兼容模式下，当前字段不生效。

表 4-191 AlgorithmInput

参数	参数类型	描述
name	String	数据输入通道名称。
local_dir	String	数据输入输出通道映射的容器本地路径。
remote	AlgorithmRemote object	数据实际输入信息，异构作业只支持OBS。

表 4-192 AlgorithmRemote

参数	参数类型	描述
obs	RemoteObs object	数据输入输出信息为OBS方式。

表 4-193 AlgorithmOutput

参数	参数类型	描述
name	String	数据输出通道名称。
local_dir	String	数据输出通道映射的容器本地路径。
remote	Remote object	数据实际输出信息。
mode	String	数据传输模式，默认为“upload_periodically”。
period	String	数据传输周期，默认为30s。

表 4-194 Remote

参数	参数类型	描述
obs	RemoteObs object	数据实际输出到OBS。

表 4-195 RemoteObs

参数	参数类型	描述
obs_url	String	数据实际输出到OBS的路径。

表 4-196 AlgorithmEngine

参数	参数类型	描述
engine_id	String	引擎规格的ID。如“caffe-1.0.0-python2.7”。
engine_name	String	引擎规格的名称。如“Caffe”。
engine_version	String	引擎规格的版本。对一个引擎名称，有多个版本的引擎，如使用python2.7的"Caffe-1.0.0-python2.7"等。

参数	参数类型	描述
v1_compatible	Boolean	是否为v1兼容模式。
run_user	String	引擎默认启动用户uid。
image_url	String	算法选择的自定义镜像地址。

表 4-197 FlavorResponse

参数	参数类型	描述
flavor_id	String	资源规格的ID。
flavor_name	String	资源规格的名称。
max_num	Integer	资源规格的最大节点数。
flavor_type	String	资源规格的类型。可选值如下： • CPU。 • GPU。
billing	BillingInfo object	资源规格计费信息。
flavor_info	FlavorInfoResponse object	资源规格详细信息。
attributes	Map<String,String>	其他规格属性。

表 4-198 FlavorInfoResponse

参数	参数类型	描述
max_num	Integer	可以选择的最大节点数量（max_num，为1代表不支持分布式）。
cpu	Cpu object	cpu规格信息。
gpu	Gpu object	gpu规格信息。
npu	Npu object	Ascend规格信息。
memory	Memory object	内存信息。
disk	DiskResponse object	磁盘信息。

表 4-199 DiskResponse

参数	参数类型	描述
size	Integer	磁盘大小。
unit	String	磁盘大小单位。

表 4-200 SpecResponse

参数	参数类型	描述
resource	Resource object	训练作业资源规格信息。flavor_id和pool_id+[flavor_id]方式二选一。
volumes	Array of JobVolume objects	训练作业挂载卷信息。
log_export_path	LogExportPath object	训练作业日志输出信息。
schedule_policy	SchedulePolicy object	训练作业调度策略。

表 4-201 Resource

参数	参数类型	描述
policy	String	训练作业资源规格模式，可选值为regular，表示为标准模式。
flavor_id	String	训练作业资源规格id。CPU规格专属资源池不支持指定flavor_id。GPU/Ascend规格专属资源池可选取值举例如下： • modelarts.pool.visual.xlarge（1卡）。 • modelarts.pool.visual.2xlarge（2卡）。 • modelarts.pool.visual.4xlarge（4卡）。 • modelarts.pool.visual.8xlarge（8卡）。
flavor_name	String	使用flavor_id时，由ModelArts返回的只读规格名称。
node_count	Integer	训练作业选择的资源副本数。
pool_id	String	训练作业选择的资源池ID。
flavor_detail	FlavorDetail object	训练作业、算法的规格信息（该字段只有公共资源池存在）。

表 4-202 FlavorDetail

参数	参数类型	描述
flavor_type	String	资源规格的类型。可选值如下： • CPU • GPU • Ascend
billing	BillingInfo object	资源规格计费信息。
flavor_info	FlavorInfo object	资源规格详细信息。

表 4-203 BillingInfo

参数	参数类型	描述
code	String	计费码。
unit_num	Integer	计费单元。

表 4-204 FlavorInfo

参数	参数类型	描述
max_num	Integer	可以选择的最大节点数量（max_num，为1代表不支持分布式）。
cpu	Cpu object	cpu规格信息。
gpu	Gpu object	gpu规格信息。
npu	Npu object	Ascend规格信息。
memory	Memory object	内存信息。
disk	Disk object	磁盘信息。

表 4-205 Cpu

参数	参数类型	描述
arch	String	cpu架构。
core_num	Integer	核数。

表 4-206 Gpu

参数	参数类型	描述
unit_num	Integer	gpu卡数。
product_name	String	产品名。
memory	String	内存。

表 4-207 Npu

参数	参数类型	描述
unit_num	String	npu卡数。
product_name	String	产品名。
memory	String	内存。

表 4-208 Memory

参数	参数类型	描述
size	Integer	内存大小。
unit	String	内存单元数。

表 4-209 Disk

参数	参数类型	描述
size	String	磁盘大小。
unit	String	磁盘大小单位，一般为GB。

表 4-210 JobVolume

参数	参数类型	描述
nfs	Nfs object	nfs方式的挂载卷。

表 4-211 Nfs

参数	参数类型	描述
nfs_server_path	String	nfs服务端路径，如：“10.10.10.10:/example/path”。
local_path	String	挂载到训练容器中的路径，如：“/example/path”。
read_only	Boolean	nfs挂载卷在容器中是否只读。

表 4-212 LogExportPath

参数	参数类型	描述
obs_url	String	训练作业日志保存的OBS地址，如：“obs://example/path”。
host_path	String	训练作业日志保存的宿主机的路径，如：“/example/path”。

表 4-213 JobEndpointsResp

参数	参数类型	描述
ssh	SSHResp object	SSH连接信息。
jupyter_lab	JupyterLab object	JupyterLab连接信息。
tensorboard	Tensorboard object	Tensorboard连接信息。
mindstudio_insight	MindStudio Insight object	MindStudio Insight连接信息。

表 4-214 SSHResp

参数	参数类型	描述
key_pair_names	Array of strings	SSH密钥对名称，可以在云服务器控制台（ECS）“密钥对”页面创建和查看。
task_urls	Array of TaskUrls objects	SSH连接地址信息。

表 4-215 TaskUrls

参数	参数类型	描述
task	String	训练作业的任务ID。
url	String	训练作业SSH连接地址。

表 4-216 SchedulePolicy

参数	参数类型	描述
required_affinity	RequiredAffinity object	参数解释： 训练作业亲和要求。 取值范围： 不涉及。
priority	Integer	参数解释： 训练作业优先级。 取值范围： 0-3
preemptible	Boolean	参数解释： 是否可以被抢占。 取值范围： • true：可以被抢占 • false：不可以被抢占

表 4-217 RequiredAffinity

参数	参数类型	描述
affinity_type	String	参数解释： 亲和调度策略。 取值范围： • cabinet 强整柜调度 • hyperinstance 超节点亲和调度
affinity_group_size	Integer	参数解释： 亲和组大小，affinity_type为hyperinstance时必填，系统会将affinity_group_size个task调度到一个超节点内组成亲和组。 用户向超节点资源池投递训练作业，如果未设置亲和组大小，系统会默认赋值为1。 取值范围： 不涉及。

表 4-218 CustomMetrics

参数	参数类型	描述
exec	Exec object	命令行方式采集指标。

参数	参数类型	描述
http_get	HttpGet object	http方式采集指标。

表 4-219 Exec

参数	参数类型	描述
command	Array of strings	命令行方式采集指标。

表 4-220 HttpGet

参数	参数类型	描述
path	String	http获取指标的url路径，与下面的端口必须同时填或者不填。
port	Integer	http获取指标的端口，与上面的url路径必须同时填或者不填。

表 4-221 JupyterLab

参数	参数类型	描述
url	String	训练作业的JupyterLab地址。
token	String	训练作业的JupyterLab token。

表 4-222 Tensorboard

参数	参数类型	描述
url	String	训练作业的Tensorboard地址。
token	String	训练作业的Tensorboard token。

表 4-223 MindStudio Insight

参数	参数类型	描述
url	String	训练作业的MindStudio Insight地址。
token	String	训练作业的MindStudio Insight token。

状态码： 400

表 4-224 响应 Body 参数

参数	参数类型	描述
error_msg	String	错误信息。
error_code	String	错误码。
error_solution	String	错误解决建议。

请求示例

- 创建免费规格的训练作业。设置作业名称为“TestModelArtsJob”，描述为“This is a ModelArts job”。算法依赖的是id为3f5d6706-7b67-408d-8ba0-ec08048c45ed的算法，该算法未定义inputs与outputs，规格选用的是gpu免费规格。

```
POST https://endpoint/v2/{project_id}/training-jobs

{
  "kind": "job",
  "metadata": {
    "name": "TestModelArtsJob",
    "description": "This is a ModelArts job"
  },
  "algorithm": {
    "id": "3f5d6706-7b67-408d-8ba0-ec08048c45ed",
    "parameters": [ {
      "name": "input_dir",
      "value": "obs://cn-north-4-rse/test/moxingtest-dir/"
    }, {
      "name": "input_file",
      "value": "obs://cn-north-4-rse/test/moxingtest/"
    }, {
      "name": "large_file_method",
      "value": "1"
    } ],
    "policies": {
      "auto_search": null
    },
    "environments": { }
  },
  "spec": {
    "resource": {
      "flavor_id": "modelarts.p3.large.public.free",
      "node_count": 1
    },
    "log_export_path": {
      "obs_url": ""
    }
  }
}
```

- 使用自定义镜像创建训练作业。设置作业名称为“TestModelArtsJob2”，描述为“This is a ModelArts job2”的自定义镜像训练作业。使用专属资源池和nfs挂载。

```
POST https://endpoint/v2/{project_id}/training-jobs

{
  "kind": "job",
  "metadata": {
    "name": "TestModelArtsJob2",
    "description": "This is a ModelArts job2"
  },
}
```

```
"algorithm" : {
  "engine" : {
    "image_url" : "xxxxxxx/fastseq:1.2"
  },
  "command" : "cd /home/ma-user/ddp_demo && sh run_ddp.sh",
  "parameters" : [ ],
  "policies" : {
    "auto_search" : null
  },
  "environments" : {
    "NCCL_DEBUG" : "INFO",
    "NCCL_IB_DISABLE" : "0"
  }
},
"spec" : {
  "resource" : {
    "flavor_id" : "modelarts.pool.visual.xlarge",
    "node_count" : 1,
    "pool_id" : "poolfaf38d76"
  },
  "log_export_path" : {
    "obs_url" : "/cn-north-4-training-test/limou/ddp-demo-log/"
  },
  "volumes" : [ {
    "nfs" : {
      "nfs_server_path" : "192.168.0.82:/",
      "local_path" : "/home/ma-user/nfs/",
      "read_only" : false
    }
  } ]
}
```

响应示例

状态码： 201

ok。

```
{
  "kind" : "job",
  "metadata" : {
    "id" : "425b7087-83de-49ed-9e40-5bb642be956f",
    "name" : "TestModelArtsJob",
    "description" : "This is a ModelArts job",
    "create_time" : 1637045545982,
    "workspace_id" : "0",
    "user_name" : ""
  },
  "status" : {
    "phase" : "Creating",
    "secondary_phase" : "Creating",
    "duration" : 0,
    "start_time" : 0,
    "node_count_metrics" : null,
    "tasks" : [ "worker-0", "server-0" ]
  },
  "algorithm" : {
    "id" : "3f5d6706-7b67-408d-8ba0-ec08048c45ed",
    "name" : "tnt-obs-gpu",
    "code_dir" : "/cn-north-4-rse/test/moxingtest-code/",
    "boot_file" : "/cn-north-4-rse/test/moxingtest-code/test_obs_gpu.py",
    "parameters" : [ {
      "name" : "input_dir",
      "description" : "",
      "i18n_description" : null,
      "value" : "s://cn-north-4-rse/test/moxingtest-dir/",
      "constraint" : {
        "type" : "String",
```

```
    "editable" : true,
    "required" : true,
    "sensitive" : false,
    "valid_type" : "None",
    "valid_range" : [ ]
  }, {
    "name" : "input_file",
    "description" : "",
    "i18n_description" : null,
    "value" : "obs://cn-north-4-rse/test/moxingtest/",
    "constraint" : {
      "type" : "String",
      "editable" : true,
      "required" : true,
      "sensitive" : false,
      "valid_type" : "None",
      "valid_range" : [ ]
    }
  }, {
    "name" : "large_file_method",
    "description" : "",
    "i18n_description" : null,
    "value" : "1",
    "constraint" : {
      "type" : "Integer",
      "editable" : true,
      "required" : true,
      "sensitive" : false,
      "valid_type" : "None",
      "valid_range" : [ ]
    }
  } ],
  "engine" : {
    "engine_id" : "horovod-cp36-tf-1.16.2",
    "engine_name" : "Horovod",
    "engine_version" : "0.16.2-TF-1.13.1-python3.6"
  },
  "policies" : { }
},
"spec" : {
  "resource" : {
    "policy" : "regular",
    "flavor_id" : "modelarts.p3.large.public.free",
    "flavor_name" : "Computing GPU(Vnt1) instance",
    "node_count" : 1,
    "flavor_detail" : {
      "flavor_type" : "GPU",
      "billing" : {
        "code" : "modelarts.vm.gpu.free",
        "unit_num" : 1
      },
      "flavor_info" : {
        "cpu" : {
          "arch" : "x86",
          "core_num" : 8
        },
        "gpu" : {
          "unit_num" : 1,
          "product_name" : "GP-Vnt1",
          "memory" : "32GB"
        },
        "memory" : {
          "size" : 64,
          "unit" : "GB"
        }
      }
    }
  }
}
```

```
"log_export_path" : { }  
}  
}
```

状态码： 400

通用的错误应答消息体格式；如下为id是3f5d6706-7b67-408d-8ba0-ec08048c45ee的算法未找到时的返回信息。

```
{  
  "error_msg" : "algorithm not found.",  
  "error_code" : "ModelArts.2755",  
  "error_solution" : "Check whether the training project information in the request is valid."  
}
```

状态码

状态码	描述
201	ok。
400	通用的错误应答消息体格式；如下为id是3f5d6706-7b67-408d-8ba0-ec08048c45ee的算法未找到时的返回信息。

错误码

请参见[错误码](#)。

4.2.2 查询训练作业详情

功能介绍

查询指定训练作业的详细信息。

该接口适用于以下场景：当用户需要查看特定训练作业的运行状态和配置信息时，可以通过此接口获取作业详情。使用该接口的前提条件是用户已知训练作业ID，并具有查看作业详情的权限。查询操作完成后，平台将返回包含训练作业的状态、配置、日志等详细信息。若训练作业ID不存在或用户无权限操作，接口将返回相应的错误信息

URI

GET /v2/{project_id}/training-jobs/{training_job_id}

表 4-225 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
training_job_id	是	String	训练作业ID。获取方法请参见 查询训练作业列表 。

请求参数

无

响应参数

状态码： 200

表 4-226 响应 Body 参数

参数	参数类型	描述
kind	String	训练作业类型。默认使用job。枚举值： job 训练作业。
metadata	JobMetadata object	训练作业元信息。
status	Status object	训练作业状态信息。创建作业无需填写。
algorithm	JobAlgorithm Response object	训练作业算法。目前支持三种形式： - id：只取算法的id； - subscription_id+item_version_id：取算法的订阅id和版本id； - code_dir+boot_file：取训练作业的代码目录和启动文件。
tasks	Array of TaskResponse objects	异构训练作业的任务列表。
spec	SpecResponse object	训练作业规格参数。
endpoints	JobEndpoints Resp object	远程接入训练作业时需要的配置。

表 4-227 JobMetadata

参数	参数类型	描述
id	String	训练作业ID，创建成功后由ModelArts生成返回，无需填写。
name	String	训练作业名称。限制为1-64位只含数字、字母、下划线和中划线的名称。
workspace_id	String	指定作业所处的工作空间，默认值为“0”。
description	String	对训练作业的描述，默认为“NULL”，字符串的长度限制为[0, 256]。

参数	参数类型	描述
create_time	Long	训练作业创建时间戳，单位为毫秒，创建成功后由ModelArts生成返回，无需填写。
user_name	String	训练作业创建用户的用户名，创建成功后由ModelArts生成返回，无需填写。
created_by	String	训练作业创建者类型，仅在传递了X-Auth-Token-Provider创建的作业中，会返回值为provider。其余场景不会包含该参数。
annotations	Map<String,String>	训练作业高级功能配置，可选取值如下： • "job_template": "Template RL"（异构作业）。 • "fault-tolerance/job-retry-num": "3"（故障自动重启次数）。 • "fault-tolerance/job-unconditional-retry": "true"（无条件重启）。 • "fault-tolerance/hang-retry": "true"（卡死重启）。 • "jupyter-lab/enable": "true"（JupyterLab训练应用程序）。 • "tensorboard/enable": "true"（TensorBoard训练应用程序）。 • "mindstudio-insight/enable": "true"（MindStudio Insight训练应用程序）。

表 4-228 Status

参数	参数类型	描述
phase	String	训练作业一级状态。可选值如下： • Creating：创建中。 • Pending：等待中。 • Running：运行中。 • Failed：运行失败。 • Completed：已完成。 • Terminating：停止中。 • Terminated：已停止。 • Abnormal：异常。

参数	参数类型	描述
secondary_phase	String	训练作业二级状态为内部详细状态，可能会增加、修改、删除，不建议依赖。可选值如下： • Creating：创建中。 • Queuing：排队中。 • Running：运行中。 • Failed：运行失败。 • Completed：已完成。 • Terminating：停止中。 • Terminated：已停止。 • CreateFailed：创建失败。 • TerminatedFailed：停止失败。 • Unknown：未知状态。 • Lost：异常。
duration	Long	训练作业运行时长，单位为毫秒。
node_count_metrics	Array<Array<Integer>>	训练作业运行时节点数变化指标。
tasks	Array of strings	训练作业子任务名称。
start_time	Long	训练作业开始时间，格式为时间戳。
task_statuses	Array of TaskStatuses objects	训练在子任务状态信息。
running_records	Array of RunningRecord objects	训练作业运行及故障恢复记录。
taskIPs	Array of taskIP objects	训练作业运行的物理节点IP信息。

表 4-229 TaskStatuses

参数	参数类型	描述
task	String	训练作业子任务名称。
exit_code	Integer	训练作业子任务退出码。
message	String	训练作业子任务错误消息。

表 4-230 RunningRecord

参数	参数类型	描述
start_at	Integer	本次运行开始时间的unix时间戳，单位为秒(s)。
end_at	Integer	本次运行结束时间的unix时间戳，单位为秒(s)。
start_type	String	本地运行的启动方式： • init_or_rescheduled：代表本次启动为被调度后的首次运行，包括初次启动及调度恢复后的运行。 • restarted：代表本次启动非被调度后的首次运行，为进程重启后的运行。
end_reason	String	本次运行结束原因。
end_related_task	String	引发本次运行结束的task worker ID(如worker-0)。
end_recover	String	本次运行结束后所采取的故障容忍策略，枚举值如下： • npu_proc_restart: NPU原地热恢复。 • gpu_proc_restart: GPU原地热恢复。 • proc_restart: 进程原地重启。 • pod_reschedule: Pod级重调度。 • job_reschedule: Job级重调度。 • job_reschedule_with_taint: 隔离式Job重调度。
end_recover_before_downgrade	String	本次运行结束后在故障容忍策略降级前所采取的容忍策略，取值范围同end_recover。

表 4-231 taskIP

参数	参数类型	描述
task	String	训练作业任务名。
ip	String	任务IP。
host_ip	String	节点IP。

表 4-232 JobAlgorithmResponse

参数	参数类型	描述
id	String	训练作业算法。目前支持三种形式： - id：只取算法的id； - subscription_id+item_version_id：取算法的订阅id和版本id； - code_dir+boot_file：取训练作业的代码目录和启动文件。
name	String	算法名称。
subscription_id	String	订阅算法的订阅ID。应与item_version_id一同出现。
item_version_id	String	订阅算法的版本。应与subscription_id一同出现。
code_dir	String	训练作业的代码目录。如：“/usr/app/”。应与boot_file一同出现，如果boot_file已经填入id或subscription_id+item_version_id，则无需填写此参数。
boot_file	String	训练作业的代码启动文件，需要在代码目录下。如：“/usr/app/boot.py”。应与code_dir一同出现，如果code_dir已经填入id或subscription_id+item_version_id，则无需填写此参数。
autosearch_config_path	String	自动化搜索作业的yaml配置路径，需要提供一个OBS路径。如：“obs://bucket/file.yaml”。
autosearch_framework_path	String	自动化搜索作业的框架代码目录，需要提供一个OBS路径。如：“obs://bucket/files/”。
command	String	自定义镜像训练作业的自定义镜像的容器的启动命令。例如python train.py。
parameters	Array of Parameter objects	训练作业的运行参数。
policies	表4-236 object	作业支持的策略。
inputs	Array of Input objects	训练作业的数据输入。
outputs	Array of Output objects	训练作业的结果输出。
engine	JobEngine object	训练作业的引擎。使用算法管理的算法id或订阅算法subscription_id+item_version_id创建作业时，无需填写。

参数	参数类型	描述
local_code_dir	String	算法的代码目录下载到训练容器内的本地路径。规则如下： • 必须为/home下的目录； • v1兼容模式下，当前字段不生效； • 当code_dir以file://为前缀时，当前字段不生效。
working_dir	String	运行算法时所在的工作目录。规则：v1兼容模式下，当前字段不生效。
environments	Array of Map<String,String> objects	训练作业的环境变量。格式："key":"value"，无需填写。
summary	Summary object	可视化日志summary。

表 4-233 Parameter

参数	参数类型	描述
name	String	参数名称。
value	String	参数值。
description	String	参数描述信息。
constraint	表4-234 object	参数属性。
i18n_description	表4-235 object	国际化描述。

表 4-234 Constraint

参数	参数类型	描述
type	String	参数种类。
editable	Boolean	是否可编辑。
required	Boolean	是否必须。
sensitive	Boolean	是否敏感。该功能暂未实现。
valid_type	String	有效种类。
valid_range	Array of strings	有效范围。

表 4-235 I18nDescription

参数	参数类型	描述
language	String	国际语种。
description	String	国际化语种的描述信息。

表 4-236 Policies

参数	参数类型	描述
auto_search	表4-237 object	超参搜索配置。

表 4-237 AutoSearch

参数	参数类型	描述
skip_search_params	String	需要排除的超参组合。
reward_attr	Array of 表 4-238 objects	搜索指标列表。
search_params	Array of 表 4-239 objects	搜索参数。
algo_configs	Array of 表 4-240 objects	搜索算法配置。

表 4-238 RewardAttrs

参数	参数类型	描述
name	String	指标名称。
mode	String	搜索方向。 - max指定时表示指标值越大越好； - min指定时表示指标值越小越好。
regex	String	指标正则表达式。

表 4-239 SearchParams

参数	参数类型	描述
name	String	超参名称。

参数	参数类型	描述
param_type	String	参数类型。 • continuous: 指定时表示这个超参是连续类型的。连续类型的超参在算法使用于训练作业时, 控制台显示为输入框。 • discrete: 指定时表示这个超参是离散类型的。离散类型的超参在算法使用于训练作业时, 控制台显示为下拉选择框架。
lower_bound	String	超参下界。
upper_bound	String	超参上界。
discrete_points_num	String	连续型超参离散化取值个数。
discrete_values	Array of strings	离散型超参的取值列表。

表 4-240 AlgoConfigs

参数	参数类型	描述
name	String	搜索算法名称。
params	Array of AutoSearchAlgoConfigParameter objects	搜索算法参数。

表 4-241 AutoSearchAlgoConfigParameter

参数	参数类型	描述
key	String	参数键。
value	String	参数值。
type	String	参数种类。

表 4-242 Input

参数	参数类型	描述
name	String	数据输入通道名称。
description	String	数据输入通道描述信息。

参数	参数类型	描述
local_dir	String	数据输入通道映射的容器本地路径。例如， “/home/ma-user/modelarts/inputs/data_url_0”。
remote	InputDataInfo object	数据实际输入信息。枚举值： - dataset：指定输入为数据集； - obs：指定输入为OBS路径。
remote_constraint	Array of 表 4-246 objects	数据输入约束。

表 4-243 InputDataInfo

参数	参数类型	描述
dataset	表4-244 object	数据输入信息为数据集。
obs	表4-245 object	数据输入输出信息为OBS方式。

表 4-244 Dataset

参数	参数类型	描述
id	String	训练作业的数据集ID。
version_id	String	训练作业的数据集版本ID。
obs_url	String	训练作业需要的数据集OBS路径URL，ModelArts会通过数据集ID和数据集版本ID自动解析生成。如：“/usr/data/”。

表 4-245 Obs

参数	参数类型	描述
obs_url	String	训练作业需要的数据集OBS路径URL。如：“/usr/data/”。

表 4-246 RemoteConstraint

参数	参数类型	描述
data_type	String	数据输入类型，包括数据存储位置、数据集两种方式。
attributes	String	数据输入为数据集时的相关属性。枚举值： - data_format 数据格式； - data_segmentation 数据切分方式； - dataset_type 标注类型。

表 4-247 Output

参数	参数类型	描述
name	String	数据输出通道名称。
description	String	数据输出通道描述信息。
local_dir	String	数据输出通道映射的容器本地路径。
remote	Remote object	数据实际输出信息。

表 4-248 JobEngine

参数	参数类型	描述
engine_id	String	训练作业选择的引擎规格ID。engine_id，engine_name+engine_version和image_url方式三选一。
engine_name	String	训练作业选择的引擎名称。如果已填写engine_id，则此参数无需填写。
engine_version	String	训练作业选择的引擎版本名称。如果已填写engine_id，则此参数无需填写。
image_url	String	训练作业选择的自定义镜像地址，地址从swr服务获取。

表 4-249 Summary

参数	参数类型	描述
log_type	String	训练作业可视化日志类型，配置后训练作业可作为可视化作业数据源。可选取值如下： • tensorboard。 • mindstudio-insight。
log_dir	LogDir object	训练作业可视化日志输出，log_type非空时必须填。
data_sources	Array of DataSource object	可视化作业或训练作业调试模式的可视化日志输入，训练作业高级功能开启"tensorboard/enable": "true"或"mindstudio-insight/enable": "true"时必须填。

表 4-250 LogDir

参数	参数类型	描述
pfs	PFSSummary object	obs并行文件系统输出。

表 4-251 DataSource

参数	参数类型	描述
pfs	PFSSummary object	obs并行文件系统输出。

表 4-252 PFSSummary

参数	参数类型	描述
pfs_path	String	obs并行文件系统路径url。

表 4-253 TaskResponse

参数	参数类型	描述
role	String	任务角色，该功能暂未支持。
algorithm	TaskResponseAlgorithm object	算法配置。

参数	参数类型	描述
task_resource	FlavorResponse object	训练作业、算法的规格信息。

表 4-254 TaskResponseAlgorithm

参数	参数类型	描述
code_dir	String	算法启动文件所在目录绝对路径。
boot_file	String	算法启动文件绝对路径。
inputs	AlgorithmInput object	算法输入通道信息。
outputs	AlgorithmOutput object	算法输出通道信息。
engine	AlgorithmEngine object	异构作业所依赖的引擎。
local_code_dir	String	算法的代码目录下载到训练容器内的本地路径。 规则如下： • 必须为/home下的目录； • v1兼容模式下，当前字段不生效； • 当code_dir以file://为前缀时，当前字段不生效。
working_dir	String	运行算法时所在的工作目录。规则：v1兼容模式下，当前字段不生效。

表 4-255 AlgorithmInput

参数	参数类型	描述
name	String	数据输入通道名称。
local_dir	String	数据输入输出通道映射的容器本地路径。
remote	AlgorithmRemote object	数据实际输入信息，异构作业只支持OBS。

表 4-256 AlgorithmRemote

参数	参数类型	描述
obs	RemoteObs object	数据输入输出信息为OBS方式。

表 4-257 AlgorithmOutput

参数	参数类型	描述
name	String	数据输出通道名称。
local_dir	String	数据输出通道映射的容器本地路径。
remote	Remote object	数据实际输出信息。
mode	String	数据传输模式，默认为“upload_periodically”。
period	String	数据传输周期，默认为30s。

表 4-258 Remote

参数	参数类型	描述
obs	RemoteObs object	数据实际输出到OBS。

表 4-259 RemoteObs

参数	参数类型	描述
obs_url	String	数据实际输出到OBS的路径。

表 4-260 AlgorithmEngine

参数	参数类型	描述
engine_id	String	引擎规格的ID。如“caffe-1.0.0-python2.7”。
engine_name	String	引擎规格的名称。如“Caffe”。
engine_version	String	引擎规格的版本。对一个引擎名称，有多个版本的引擎，如使用python2.7的"Caffe-1.0.0-python2.7"等。
v1_compatible	Boolean	是否为v1兼容模式。
run_user	String	引擎默认启动用户uid。
image_url	String	算法选择的自定义镜像地址。

表 4-261 FlavorResponse

参数	参数类型	描述
flavor_id	String	资源规格的ID。
flavor_name	String	资源规格的名称。
max_num	Integer	资源规格的最大节点数。
flavor_type	String	资源规格的类型。可选值如下： • CPU。 • GPU。
billing	BillingInfo object	资源规格计费信息。
flavor_info	FlavorInfoResponse object	资源规格详细信息。
attributes	Map<String,String>	其他规格属性。

表 4-262 FlavorInfoResponse

参数	参数类型	描述
max_num	Integer	可以选择的最大节点数量（max_num，为1代表不支持分布式）。
cpu	Cpu object	cpu规格信息。
gpu	Gpu object	gpu规格信息。
npu	Npu object	Ascend规格信息。
memory	Memory object	内存信息。
disk	DiskResponse object	磁盘信息。

表 4-263 DiskResponse

参数	参数类型	描述
size	Integer	磁盘大小。
unit	String	磁盘大小单位。

表 4-264 SpecResponse

参数	参数类型	描述
resource	Resource object	训练作业资源规格信息。flavor_id和pool_id+[flavor_id]方式二选一。
volumes	Array of JobVolume objects	训练作业挂载卷信息。
log_export_path	LogExportPath object	训练作业日志输出信息。
schedule_policy	SchedulePolicy object	训练作业调度策略。
custom_metrics	Array of CustomMetric objects	训练作业采集prometheus指标。

表 4-265 Resource

参数	参数类型	描述
policy	String	训练作业资源规格模式，可选值为regular，表示为标准模式。
flavor_id	String	训练作业资源规格id。CPU规格专属资源池不支持指定flavor_id。GPU/Ascend规格专属资源池可选取值如下： • modelarts.pool.visual.xlarge（1卡）。 • modelarts.pool.visual.2xlarge（2卡）。 • modelarts.pool.visual.4xlarge（4卡）。 • modelarts.pool.visual.8xlarge（8卡）。
flavor_name	String	使用flavor_id时，由ModelArts返回的只读规格名称。
node_count	Integer	训练作业选择的资源副本数。
pool_id	String	训练作业选择的资源池ID。
flavor_detail	FlavorDetail object	训练作业、算法的规格信息（该字段只有公共资源池存在）。

表 4-266 FlavorDetail

参数	参数类型	描述
flavor_type	String	资源规格的类型。可选值如下： • CPU。 • GPU。
billing	BillingInfo object	资源规格计费信息。
flavor_info	FlavorInfo object	资源规格详细信息。

表 4-267 BillingInfo

参数	参数类型	描述
code	String	计费码。
unit_num	Integer	计费单元。

表 4-268 FlavorInfo

参数	参数类型	描述
max_num	Integer	可以选择的最大节点数量（max_num，为1代表不支持分布式）。
cpu	Cpu object	cpu规格信息。
gpu	Gpu object	gpu规格信息。
npu	Npu object	Ascend规格信息。
memory	Memory object	内存信息。
disk	Disk object	磁盘信息。

表 4-269 Cpu

参数	参数类型	描述
arch	String	cpu架构。
core_num	Integer	核数。

表 4-270 Gpu

参数	参数类型	描述
unit_num	Integer	gpu卡数。
product_name	String	产品名。
memory	String	内存。

表 4-271 Npu

参数	参数类型	描述
unit_num	String	npu卡数。
product_name	String	产品名。
memory	String	内存。

表 4-272 Memory

参数	参数类型	描述
size	Integer	内存大小。
unit	String	内存单元数。

表 4-273 Disk

参数	参数类型	描述
size	String	磁盘大小。
unit	String	磁盘大小单位，一般为GB。

表 4-274 JobVolume

参数	参数类型	描述
nfs	Nfs object	nfs方式的挂载卷。

表 4-275 Nfs

参数	参数类型	描述
nfs_server_path	String	nfs服务端路径，如：“10.10.10.10:/example/path”。
local_path	String	挂载到训练容器中的路径，如：“/example/path”。
read_only	Boolean	nfs挂载卷在容器中是否只读。

表 4-276 LogExportPath

参数	参数类型	描述
obs_url	String	训练作业日志保存的OBS地址，如：“obs://example/path”。
host_path	String	训练作业日志保存的宿主机的路径，如：“/example/path”。

表 4-277 SchedulePolicy

参数	参数类型	描述
required_affinity	RequiredAffinity object	训练作业亲和要求。
priority	integer	训练作业优先级。设置1-3，1优先级最低，3优先级最高。
preemptible	boolean	训练作业是否可以被抢占。 - False：不可以被抢占。 - True：开启允许被抢占。

表 4-278 CustomMetric

参数	是否必选	参数类型	描述
http_get	否	HttpGet object	http请求方式。
exec	否	Exec object	命令行方式。

表 4-279 JobEndpointsResp

参数	参数类型	描述
ssh	SSHResp object	SSH连接信息。
jupyter_lab	JupyterLab object	JupyterLab连接信息。
tensorboard	Tensorboard object	Tensorboard连接信息。
mindstudio_in_sight	MindStudio Insight object	MindStudio Insight连接信息。

表 4-280 SSHResp

参数	参数类型	描述
key_pair_names	Array of strings	SSH密钥对名称，可以在云服务器控制台（ECS）“密钥对”页面创建和查看。
task_urls	Array of TaskUrls objects	SSH连接地址信息。

表 4-281 TaskUrls

参数	参数类型	描述
task	String	训练作业的任务ID。
url	String	训练作业SSH连接地址。

表 4-282 RequiredAffinity

参数	是否必选	参数类型	描述
affinity_type	否	String	亲和调度策略，可选取值如下： cabinet 强整柜调度。
node_labels	否	Map<String,String>	节点标签，可选取值如下： kubernetes.io/hostname 指定调度节点

表 4-283 HttpGet

参数	是否必选	参数类型	描述
path	是	String	http请求path部分。
port	是	Integer	http请求端口。

表 4-284 Exec

参数	是否必选	参数类型	描述
command	是	Array of strings	shell命令。

表 4-285 JupyterLab

参数	参数类型	描述
url	String	训练作业的JupyterLab地址。
token	String	训练作业的JupyterLab token。

表 4-286 Tensorboard

参数	参数类型	描述
url	String	训练作业的Tensorboard地址。
token	String	训练作业的Tensorboard token。

表 4-287 MindStudio Insight

参数	参数类型	描述
url	String	训练作业的MindStudio Insight地址。
token	String	训练作业的MindStudio Insight token。

请求示例

如下以查询uuid为3faf5c03-aaa1-4cbe-879d-24b05d997347的训练作业为例。

```
GET https://endpoint/v2/{project_id}/training-jobs/3faf5c03-aaa1-4cbe-879d-24b05d997347
```

响应示例

状态码： 200

ok

```
{
  "kind": "job",
  "metadata": {
    "id": "3faf5c03-aaa1-4cbe-879d-24b05d997347",
    "name": "trainjob--py14_mem06-108",
    "description": "",
    "create_time": 1636447346315,
    "workspace_id": "0",
    "user_name": ""
  },
  "status": {
    "phase": "Abnormal",
    "secondary_phase": "CreateFailed",
    "duration": 0,
    "start_time": 0,
    "node_count_metrics": [ [ 1636447746000, 0 ], [ 1636447755000, 0 ], [ 1636447756000, 0 ] ],
    "tasks": [ "worker-0" ],
    "running_records": [ {
      "start_at": 1701327093,
      "end_at": 1701322341,
      "start_type": "init_or_rescheduled",
      "end_recover": "job_reschedule",
      "end_reason": "exit with 127",
      "end_related_task": "worker-2",
      "end_recover_before_downgrade": "npu_proc_restart"
    }, {
      "start_at": 1701323345,
      "end_at": 1701325432,
      "start_type": "init_or_rescheduled",
      "end_reason": "job completed"
    } ]
  },
  "algorithm": {
    "code_dir": "obs://test/economic_test/py_minist/",
    "boot_file": "obs://test/economic_test/py_minist/minist_common.py",
    "inputs": [ {
      "name": "data_url",
      "local_dir": "/home/ma-user/modelarts/inputs/data_url_0",
      "remote": {
        "obs": {
          "obs_url": "/test/data/py_minist/"
        }
      }
    } ],
    "outputs": [ {
      "name": "train_url",
      "local_dir": "/home/ma-user/modelarts/outputs/train_url_0",
      "remote": {
        "obs": {
          "obs_url": "/test/train_output/"
        }
      }
    } ],
    "engine": {
      "engine_id": "pytorch-cp36-1.4.0-v2",
      "engine_name": "PyTorch",
      "engine_version": "PyTorch-1.4.0-python3.6-v2"
    }
  },
  "spec": {
    "resource": {
      "flavor_id": "modelarts.vm.pnt1.large.eco",
      "node_count": 1,
      "flavor_detail": {
        "flavor_type": "GPU",
        "billing": {
          "code": "modelarts.vm.gpu.pnt1.eco",
          "unit_num": 1
        }
      }
    }
  }
}
```

```
    },
    "flavor_info": {
      "cpu": {
        "arch": "x86",
        "core_num": 8
      },
      "gpu": {
        "unit_num": 1,
        "memory": "8GB"
      },
      "memory": {
        "size": 64,
        "unit": "GB"
      }
    }
  }
}
```

状态码

状态码	描述
200	ok

错误码

请参见[错误码](#)。

4.2.3 更新训练作业描述

功能介绍

更新训练作业描述。当用户需要更新训练作业的描述信息时，可以通过此接口进行修改。

URI

PUT /v2/{project_id}/training-jobs/{training_job_id}

表 4-288 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
training_job_id	是	String	训练作业ID。获取方法请参见 查询训练作业列表 。

请求参数

表 4-289 请求 Body 参数

参数	是否必选	参数类型	描述
description	否	String	对训练作业的描述，默认为“NULL”，字符串的长度限制为[0, 256]。

响应参数

无

请求示例

如下以修改uuid为3faf5c03-aaa1-4cbe-879d-24b05d997347的训练作业为例。修改成功后再调用[查询训练作业](#)接口即可看到description已被修改。

```
PUT https://endpoint/v2/{project_id}/training-jobs/3faf5c03-aaa1-4cbe-879d-24b05d997347
{
  "description" : "hahaha"
}
```

响应示例

状态码： 200

No Content

null

状态码

状态码	描述
200	No Content。

错误码

请参见[错误码](#)。

4.2.4 删除训练作业

功能介绍

删除训练作业。

URI

DELETE /v2/{project_id}/training-jobs/{training_job_id}

表 4-290 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
training_job_id	是	String	训练作业ID。获取方法请参见 查询训练作业列表 。

请求参数

无

响应参数

无

请求示例

如下以删除uuid为3faf5c03-aaa1-4cbe-879d-24b05d997347的训练作业为例。

```
DELETE https://endpoint/v2/{project_id}/training-jobs/3faf5c03-aaa1-4cbe-879d-24b05d997347
```

响应示例

状态码： 202

No Content。

""

状态码

状态码	描述
202	No Content。

错误码

请参见[错误码](#)。

4.2.5 终止训练作业

功能介绍

终止训练作业，只可终止创建中、等待中、运行中的作业。

该接口适用于以下场景：当用户需要提前终止正在进行的训练作业时，可以通过此接口停止作业。使用该接口的前提条件是训练作业正在运行且用户具有终止作业的权限。终止操作完成后，训练作业将停止运行，资源将被释放。若训练作业ID不存在、状态不为运行中或用户无权限操作，接口将返回相应的错误信息。

URI

POST /v2/{project_id}/training-jobs/{training_job_id}/actions

表 4-291 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
training_job_id	是	String	训练作业ID。获取方法请参见 查询训练作业列表 。

请求参数

表 4-292 请求 Body 参数

参数	是否必选	参数类型	描述
action_type	是	String	对训练作业的操作请求。参数值设置为terminate时，表示终止训练作业操作。

响应参数

状态码： 202

表 4-293 响应 Body 参数

参数	参数类型	描述
kind	String	训练作业类型。默认使用job。枚举值： job 训练作业。
metadata	JobMetadata object	训练作业元信息。
status	Status object	训练作业状态信息。创建作业无需填写。
algorithm	JobAlgorithmResponse object	训练作业算法。目前支持三种形式： - id：只取算法的id； - subscription_id+item_version_id：取算法的订阅id和版本id； - code_dir+boot_file：取训练作业的代码目录和启动文件。

参数	参数类型	描述
tasks	Array of TaskResponse objects	异构训练作业的任务列表。
spec	SpecResponse object	训练作业规格参数。
endpoints	JobEndpointsResp object	远程接入训练作业时需要的配置。

表 4-294 JobMetadata

参数	参数类型	描述
id	String	训练作业ID，创建成功后由ModelArts生成返回，无需填写。
name	String	训练作业名称。限制为1-64位只含数字、字母、下划线和中划线的名称。
workspace_id	String	指定作业所处的工作空间，默认值为“0”。
description	String	对训练作业的描述，默认为“NULL”，字符串的长度限制为[0, 256]。
create_time	Long	训练作业创建时间戳，单位为毫秒，创建成功后由ModelArts生成返回，无需填写。
user_name	String	训练作业创建用户的用户名，创建成功后由ModelArts生成返回，无需填写。
annotations	Map<String,String>	训练作业高级功能配置，可选取值如下： • "job_template": "Template RL"（异构作业）。 • "fault-tolerance/job-retry-num": "3"（故障自动重启次数）。 • "jupyter-lab/enable": "true"（JupyterLab训练应用程序）。 • "tensorboard/enable": "true"（TensorBoard训练应用程序）。 • "mindstudio-insight/enable": "true"（MindStudio Insight训练应用程序）。

表 4-295 Status

参数	参数类型	描述
phase	String	训练作业一级状态。可选值如下： - Creating：创建中。 - Pending：等待中。 - Running：运行中。 - Failed：运行失败。 - Completed：已完成。 - Terminating：停止中。 - Terminated：已停止。 - Abnormal：异常。
secondary_phase	String	训练作业二级状态为内部详细状态，可能会增加、修改、删除，不建议依赖。可选值如下： - Creating：创建中。 - Queuing：排队中。 - Running：运行中。 - Failed：运行失败。 - Completed：已完成。 - Terminating：停止中。 - Terminated：已停止。 - CreateFailed：创建失败。 - TerminatedFailed：停止失败。 - Unknown：未知状态。 - Lost：异常。
duration	Long	训练作业运行时长，单位为毫秒。
node_count_metrics	Array<Array<Integer>>	训练作业运行时节点数变化指标。
tasks	Array of strings	训练作业子任务名称。
start_time	Long	训练作业开始时间，格式为时间戳。
task_statuses	Array of TaskStatuses objects	训练在子任务状态信息。
running_records	Array of RunningRecord objects	训练作业运行及故障恢复记录。

表 4-296 TaskStatuses

参数	参数类型	描述
task	String	训练作业子任务名称。
exit_code	Integer	训练作业子任务退出码。
message	String	训练作业子任务错误消息。

表 4-297 RunningRecord

参数	参数类型	描述
start_at	Integer	本次运行开始时间的unix时间戳，单位为秒(s)。
end_at	Integer	本次运行结束时间的unix时间戳，单位为秒(s)。
start_type	String	本地运行的启动方式： - init_or_rescheduled：代表本次启动为被调度后的首次运行，包括初次启动及调度恢复后的运行。 - restarted：代表本次启动非被调度后的首次运行，为进程重启后的运行。
end_reason	String	本次运行结束原因。
end_related_task	String	引发本次运行结束的task worker ID(如worker-0)。
end_recover	String	本次运行结束后所采取的故障容忍策略，枚举值如下： - npu_proc_restart: NPU原地热恢复。 - gpu_proc_restart: GPU原地热恢复。 - proc_restart: 进程原地重启。 - pod_reschedule: Pod级重调度。 - job_reschedule: Job级重调度。 - job_reschedule_with_taint: 隔离式Job重调度。
end_recover_before_downgrade	String	本次运行结束后在故障容忍策略降级前所采取的容忍策略，取值范围同end_recover。

表 4-298 JobAlgorithmResponse

参数	参数类型	描述
id	String	训练作业算法。目前支持三种形式： - id：只取算法的id； - subscription_id+item_version_id：取算法的订阅id和版本id； - code_dir+boot_file：取训练作业的代码目录和启动文件。
name	String	算法名称。
subscription_id	String	订阅算法的订阅ID。应与item_version_id一同出现。
item_version_id	String	订阅算法的版本。应与subscription_id一同出现。
code_dir	String	训练作业的代码目录。如：“/usr/app/”。应与boot_file一同出现，如果boot_file已经填入id或subscription_id+item_version_id，则无需填写此参数。
boot_file	String	训练作业的代码启动文件，需要在代码目录下。如：“/usr/app/boot.py”。应与code_dir一同出现，如果code_dir已经填入id或subscription_id+item_version_id，则无需填写此参数。
autosearch_config_path	String	自动化搜索作业的yaml配置路径，需要提供一个OBS路径。如：“obs://bucket/file.yaml”。
autosearch_framework_path	String	自动化搜索作业的框架代码目录，需要提供一个OBS路径。如：“obs://bucket/files/”。
command	String	自定义镜像训练作业的自定义镜像的容器的启动命令。例如python train.py。
parameters	Array of Parameter objects	训练作业的运行参数。
policies	表4-302 object	作业支持的策略。
inputs	Array of Input objects	训练作业的数据输入。
outputs	Array of Output objects	训练作业的结果输出。
engine	JobEngine object	训练作业的引擎。使用算法管理的算法id或订阅算法subscription_id+item_version_id创建作业时，无需填写。

参数	参数类型	描述
local_code_dir	String	算法的代码目录下载到训练容器内的本地路径。规则如下： • 必须为/home下的目录； • v1兼容模式下，当前字段不生效； • 当code_dir以file://为前缀时，当前字段不生效。
working_dir	String	运行算法时所在的工作目录。规则：v1兼容模式下，当前字段不生效。
environments	Array of Map<String,String> objects	训练作业的环境变量。格式："key":"value"，无需填写。
summary	Summary object	可视化日志summary。

表 4-299 Parameter

参数	参数类型	描述
name	String	参数名称。
value	String	参数值。
description	String	参数描述信息。
constraint	表4-300 object	参数属性。
i18n_description	表4-301 object	国际化描述。

表 4-300 Constraint

参数	参数类型	描述
type	String	参数种类。
editable	Boolean	是否可编辑。
required	Boolean	是否必须。
sensitive	Boolean	是否敏感。该功能暂未实现。
valid_type	String	有效种类。
valid_range	Array of strings	有效范围。

表 4-301 I18nDescription

参数	参数类型	描述
language	String	国际语种
description	String	国际化语种的描述信息。

表 4-302 Policies

参数	参数类型	描述
auto_search	表4-303 object	超参搜索配置。

表 4-303 AutoSearch

参数	参数类型	描述
skip_search_params	String	需要排除的超参组合。
reward_attr	Array of 表 4-304 objects	搜索指标列表。
search_params	Array of 表 4-305 objects	搜索参数。
algo_configs	Array of 表 4-306 objects	搜索算法配置。

表 4-304 RewardAttrs

参数	参数类型	描述
name	String	指标名称。
mode	String	搜索方向。 - max指定时表示指标值越大越好； - min指定时表示指标值越小越好。
regex	String	指标正则表达式。

表 4-305 SearchParams

参数	参数类型	描述
name	String	超参名称。

参数	参数类型	描述
param_type	String	参数类型。 • continuous：指定时表示这个超参是连续类型的。连续类型的超参在算法使用于训练作业时，控制台显示为输入框。 • discrete：指定时表示这个超参是离散类型的。离散类型的超参在算法使用于训练作业时，控制台显示为下拉选择框架。
lower_bound	String	超参下界。
upper_bound	String	超参上界。
discrete_points_num	String	连续型超参离散化取值个数。
discrete_values	Array of strings	离散型超参的取值列表。

表 4-306 AlgoConfigs

参数	参数类型	描述
name	String	搜索算法名称。
params	Array of AutoSearchAlgoConfigParameter objects	搜索算法参数。

表 4-307 AutoSearchAlgoConfigParameter

参数	参数类型	描述
key	String	参数键。
value	String	参数值。
type	String	参数种类。

表 4-308 Input

参数	参数类型	描述
name	String	数据输入通道名称。
description	String	数据输入通道描述信息。

参数	参数类型	描述
local_dir	String	数据输入通道映射的容器本地路径。例如，“/home/ma-user/modelarts/inputs/data_url_0”。
remote	InputDataInfo object	数据实际输入信息。枚举值： - dataset：指定输入为数据集； - obs：指定输入为OBS路径。
remote_constraint	Array of 表 4-312 objects	数据输入约束。

表 4-309 InputDataInfo

参数	参数类型	描述
dataset	表4-310 object	数据输入信息为数据集。
obs	表4-311 object	数据输入输出信息为OBS方式。

表 4-310 Dataset

参数	参数类型	描述
id	String	训练作业的数据集ID。
version_id	String	训练作业的数据集版本ID。
obs_url	String	训练作业需要的数据集OBS路径URL，ModelArts会通过数据集ID和数据集版本ID自动解析生成。如：“/usr/data/”。

表 4-311 Obs

参数	参数类型	描述
obs_url	String	训练作业需要的数据集OBS路径URL。如：“/usr/data/”。

表 4-312 RemoteConstraint

参数	参数类型	描述
data_type	String	数据输入类型，包括数据存储位置、数据集两种方式。
attributes	String	数据输入为数据集时的相关属性。枚举值： • data_format 数据格式； • data_segmentation 数据切分方式； • dataset_type 标注类型。

表 4-313 Output

参数	参数类型	描述
name	String	数据输出通道名称。
description	String	数据输出通道描述信息。
local_dir	String	数据输出通道映射的容器本地路径。
remote	Remote object	数据实际输出信息。

表 4-314 JobEngine

参数	参数类型	描述
engine_id	String	训练作业选择的引擎规格ID。engine_id，engine_name+engine_version和image_url方式三选一。
engine_name	String	训练作业选择的引擎名称。如果已填写engine_id，则此参数无需填写。
engine_version	String	训练作业选择的引擎版本名称。如果已填写engine_id，则此参数无需填写。
image_url	String	训练作业选择的自定义镜像地址，地址从swr服务获取。

表 4-315 Summary

参数	是否必选	参数类型	描述
log_type	否	String	训练作业可视化日志类型，配置后训练作业可作为可视化作业数据源。可选取值如下： • tensorboard。 • mindstudio-insight。
log_dir	否	LogDir object	训练作业可视化日志输出，log_type非空时必填。
data_sources	否	Array of DataSource object	可视化作业或训练作业调试模式的可视化日志输入，训练作业高级功能开启"tensorboard/enable": "true"或"mindstudio-insight/enable": "true"时必填。

表 4-316 LogDir

参数	是否必选	参数类型	描述
pfs	是	PFSSummary object	obs并行文件系统输出。

表 4-317 DataSource

参数	是否必选	参数类型	描述
pfs	是	PFSSummary object	obs并行文件系统输出。

表 4-318 PFSSummary

参数	是否必选	参数类型	描述
pfs_path	是	String	obs并行文件系统路径url。

表 4-319 TaskResponse

参数	参数类型	描述
role	String	任务角色，该功能暂未支持。

参数	参数类型	描述
algorithm	TaskResponseAlgorithm object	算法配置。
task_resource	FlavorResponse object	训练作业、算法的规格信息。

表 4-320 TaskResponseAlgorithm

参数	参数类型	描述
code_dir	String	算法启动文件所在目录绝对路径。
boot_file	String	算法启动文件绝对路径。
inputs	AlgorithmInput object	算法输入通道信息。
outputs	AlgorithmOutput object	算法输出通道信息。
engine	AlgorithmEngine object	异构作业所依赖的引擎。
local_code_dir	String	算法的代码目录下载到训练容器内的本地路径。 规则如下： • 必须为/home下的目录； • v1兼容模式下，当前字段不生效； • 当code_dir以file://为前缀时，当前字段不生效。
working_dir	String	运行算法时所在的工作目录。规则：v1兼容模式下，当前字段不生效。

表 4-321 AlgorithmInput

参数	参数类型	描述
name	String	数据输入通道名称。
local_dir	String	数据输入输出通道映射的容器本地路径。
remote	AlgorithmRemote object	数据实际输入信息，异构作业只支持OBS。

表 4-322 AlgorithmRemote

参数	参数类型	描述
obs	RemoteObs object	数据输入输出信息为OBS方式。

表 4-323 AlgorithmOutput

参数	参数类型	描述
name	String	数据输出通道名称。
local_dir	String	数据输出通道映射的容器本地路径。
remote	Remote object	数据实际输出信息。
mode	String	数据传输模式，默认为“upload_periodically”。
period	String	数据传输周期，默认为30s。

表 4-324 Remote

参数	参数类型	描述
obs	RemoteObs object	数据实际输出到OBS。

表 4-325 RemoteObs

参数	参数类型	描述
obs_url	String	数据实际输出到OBS的路径。

表 4-326 AlgorithmEngine

参数	参数类型	描述
engine_id	String	引擎规格的ID。如“caffe-1.0.0-python2.7”。
engine_name	String	引擎规格的名称。如“Caffe”。
engine_version	String	引擎规格的版本。对一个引擎名称，有多个版本的引擎，如使用python2.7的"Caffe-1.0.0-python2.7"等。

参数	参数类型	描述
v1_compatible	Boolean	是否为v1兼容模式。
run_user	String	引擎默认启动用户uid。
image_url	String	算法选择的自定义镜像地址。

表 4-327 FlavorResponse

参数	参数类型	描述
flavor_id	String	资源规格的ID。
flavor_name	String	资源规格的名称。
max_num	Integer	资源规格的最大节点数。
flavor_type	String	资源规格的类型。可选值如下： • CPU。 • GPU。
billing	BillingInfo object	资源规格计费信息。
flavor_info	FlavorInfoResponse object	资源规格详细信息。
attributes	Map<String,String>	其他规格属性。

表 4-328 FlavorInfoResponse

参数	参数类型	描述
max_num	Integer	可以选择的最大节点数量（max_num，为1代表不支持分布式）。
cpu	Cpu object	cpu规格信息。
gpu	Gpu object	gpu规格信息。
npu	Npu object	Ascend规格信息。
memory	Memory object	内存信息。
disk	DiskResponse object	磁盘信息。

表 4-329 DiskResponse

参数	参数类型	描述
size	Integer	磁盘大小。
unit	String	磁盘大小单位。

表 4-330 SpecResponse

参数	参数类型	描述
resource	Resource object	训练作业资源规格信息。flavor_id和pool_id+[flavor_id]方式二选一。
volumes	Array of JobVolume objects	训练作业挂载卷信息。
log_export_path	LogExportPath object	训练作业日志输出信息。

表 4-331 Resource

参数	参数类型	描述
policy	String	训练作业资源规格模式，可选值为regular，表示为标准模式。
flavor_id	String	训练作业资源规格id。CPU规格专属资源池不支持指定flavor_id。GPU/Ascend规格专属资源池可选取值如下： • modelarts.pool.visual.xlarge（1卡）。 • modelarts.pool.visual.2xlarge（2卡）。 • modelarts.pool.visual.4xlarge（4卡）。 • modelarts.pool.visual.8xlarge（8卡）。
flavor_name	String	使用flavor_id时，由ModelArts返回的只读规格名称。
node_count	Integer	训练作业选择的资源副本数。
pool_id	String	训练作业选择的资源池ID。
flavor_detail	FlavorDetail object	训练作业、算法的规格信息（该字段只有公共资源池存在）。

表 4-332 FlavorDetail

参数	参数类型	描述
flavor_type	String	资源规格的类型。可选值如下： • CPU。 • GPU。
billing	BillingInfo object	资源规格计费信息。
flavor_info	FlavorInfo object	资源规格详细信息。

表 4-333 BillingInfo

参数	参数类型	描述
code	String	计费码。
unit_num	Integer	计费单元。

表 4-334 FlavorInfo

参数	参数类型	描述
max_num	Integer	可以选择的最大节点数量（max_num，为1代表不支持分布式）。
cpu	Cpu object	cpu规格信息。
gpu	Gpu object	gpu规格信息。
npu	Npu object	Ascend规格信息。
memory	Memory object	内存信息。
disk	Disk object	磁盘信息。

表 4-335 Cpu

参数	参数类型	描述
arch	String	cpu架构。
core_num	Integer	核数。

表 4-336 Gpu

参数	参数类型	描述
unit_num	Integer	gpu卡数。
product_name	String	产品名。
memory	String	内存。

表 4-337 Npu

参数	参数类型	描述
unit_num	String	npu卡数。
product_name	String	产品名。
memory	String	内存。

表 4-338 Memory

参数	参数类型	描述
size	Integer	内存大小。
unit	String	内存单元数。

表 4-339 Disk

参数	参数类型	描述
size	String	磁盘大小。
unit	String	磁盘大小单位，一般为GB。

表 4-340 JobVolume

参数	参数类型	描述
nfs	Nfs object	nfs方式的挂载卷。

表 4-341 Nfs

参数	参数类型	描述
nfs_server_path	String	nfs服务端路径，如：“10.10.10.10:/example/path”。
local_path	String	挂载到训练容器中的路径，如：“/example/path”。
read_only	Boolean	nfs挂载卷在容器中是否只读。

表 4-342 LogExportPath

参数	参数类型	描述
obs_url	String	训练作业日志保存的OBS地址，如：“obs://example/path”。
host_path	String	训练作业日志保存的宿主机的路径，如：“/example/path”。

表 4-343 JobEndpointsResp

参数	参数类型	描述
ssh	SSHResp object	SSH连接信息。
jupyter_lab	JupyterLab object	JupyterLab连接信息。
tensorboard	Tensorboard object	Tensorboard连接信息。
mindstudio_insight	MindStudio Insight object	MindStudio Insight连接信息。

表 4-344 SSHResp

参数	参数类型	描述
key_pair_names	Array of strings	SSH密钥对名称，可以在云服务器控制台（ECS）“密钥对”页面创建和查看。
task_urls	Array of TaskUrls objects	SSH连接地址信息。

表 4-345 TaskUrls

参数	参数类型	描述
task	String	训练作业的任务ID。
url	String	训练作业SSH连接地址。

表 4-346 JupyterLab

参数	参数类型	描述
url	String	训练作业的JupyterLab地址。
token	String	训练作业的JupyterLab token。

表 4-347 Tensorboard

参数	参数类型	描述
url	String	训练作业的Tensorboard地址。
token	String	训练作业的Tensorboard token。

表 4-348 MindStudio Insight

参数	参数类型	描述
url	String	训练作业的MindStudio Insight地址。
token	String	训练作业的MindStudio Insight token。

请求示例

停止uuid为3faf5c03-aaa1-4cbe-879d-24b05d997347的训练作业。

```
POST https://endpoint/v2/{project_id}/training-jobs/cf63aba9-63b1-4219-b717-708a2665100b/actions
{
  "action_type": "terminate"
}
```

响应示例

状态码： 202

ok。

```
{
  "kind": "job",
  "metadata": {
    "id": "cf63aba9-63b1-4219-b717-708a2665100b",
```

```
"name": "trainjob--py14_mem06-110",
"description": "",
"create_time": 163651522282,
"workspace_id": "0",
"user_name": "ei_modelarts_z00424192_01"
},
"status": {
  "phase": "Terminating",
  "secondary_phase": "Terminating",
  "duration": 0,
  "start_time": 0,
  "node_count_metrics": null,
  "tasks": [ "worker-0" ]
},
"algorithm": {
  "code_dir": "obs://test/economic_test/py_minist/",
  "boot_file": "obs://test/economic_test/py_minist/minist_common.py",
  "inputs": [ {
    "name": "data_url",
    "local_dir": "/home/ma-user/modelarts/inputs/data_url_0",
    "remote": {
      "obs": {
        "obs_url": "/test/data/py_minist/"
      }
    }
  } ],
  "outputs": [ {
    "name": "train_url",
    "local_dir": "/home/ma-user/modelarts/outputs/train_url_0",
    "remote": {
      "obs": {
        "obs_url": "/test/train_output/"
      }
    }
  } ],
  "engine": {
    "engine_id": "pytorch-cp36-1.4.0-v2",
    "engine_name": "PyTorch",
    "engine_version": "PyTorch-1.4.0-python3.6-v2"
  }
},
"spec": {
  "resource": {
    "policy": "economic",
    "flavor_id": "modelarts.vm.pnt1.large.eco",
    "flavor_name": "Computing GPU(Pnt1) instance",
    "node_count": 1,
    "flavor_detail": {
      "flavor_type": "GPU",
      "billing": {
        "code": "modelarts.vm.gpu.pnt1.eco",
        "unit_num": 1
      },
      "flavor_info": {
        "cpu": {
          "arch": "x86",
          "core_num": 8
        },
        "gpu": {
          "unit_num": 1,
          "product_name": "GP-Pnt1",
          "memory": "8GB"
        },
        "memory": {
          "size": 64,
          "unit": "GB"
        }
      }
    }
  }
}
```



```
}  
}  
}
```

状态码

状态码	描述
202	ok。

错误码

请参见[错误码](#)。

4.2.6 查询训练作业指定任务的日志（预览）

功能介绍

查询训练作业指定任务的日志信息。

该接口适用于以下场景：当用户需要查看特定训练任务的运行日志时，可以通过此接口获取日志预览。使用该接口的前提条件是用户已知训练作业ID和任务ID，并具有查看日志的权限。查询操作完成后，平台将返回包含任务日志的预览信息。若训练作业ID或任务ID不存在、任务未生成日志或用户无权限操作，接口将返回相应的错误信息。

URI

GET /v2/{project_id}/training-jobs/{training_job_id}/tasks/{task_id}/logs/preview

表 4-349 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
training_job_id	是	String	训练作业ID。获取方法请参见 查询训练作业列表 。
task_id	是	String	训练作业的任务名称。可从训练作业详情中的status.tasks字段中获取。
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
training_job_id	是	String	训练作业ID。获取方法请参见 查询训练作业列表 。
task_id	是	String	训练作业的任务名称。可从训练作业详情中的status.tasks字段中获取。

请求参数

无

响应参数

状态码： 200

表 4-350 响应 Body 参数

参数	参数类型	描述
content	String	日志内容。如果日志大小没有超过上限（n兆）则返回全部内容，如果日志超过了上限（n兆）则返回最新的n兆的日志。2022/03/01 00:00:00 (GMT+08:00)后，此参数名称由“context”改为“content”。
current_size	Integer	当前返回的日志大小（单位：字节）。最大为5兆。
full_size	Integer	完整的日志大小（单位：字节）。

请求示例

如下以查询uuid为2cd88daa-31a4-40a8-a58f-d186b0e93e4f的训练作业对应worker-0日志内容为例。

```
GET https://endpoint/v2/{project_id}/training-jobs/2cd88daa-31a4-40a8-a58f-d186b0e93e4f/tasks/worker-0/logs/preview
```

响应示例

状态码： 200

ok

```
{
  "content": "[Modelarts Service Log]collect and upload ascend logs end at
2021-05-18-14:28:13\n[Modelarts Service Log]exiting... \n [Modelarts Service Log]exiting...\n[Modelarts
Service Log]exiting... \n [Modelarts Service Log]exiting...\n[Modelarts Service Log]exit with : \n [Modelarts
Service Log]exit with 0\n[Modelarts Service Log]exit with : \n [Modelarts Service Log]exit with
0\n[Modelarts Service Log][INFO][2021/05/18 14:28:14,207]:\n output-handler finalizing due to: [training
finished]\n[Modelarts Service Log][INFO][2021/05/18 14:28:14,207]:\n output-handler finalized
\n[Modelarts Service Log][sidecar] exiting at 2021-05-18-14:28:14\n[Modelarts Service Log][sidecar] wait
python processes exit... \n [Modelarts Service Log][sidecar] wait python processes exit...\n[Modelarts
Service Log][sidecar] exit with :\n [Modelarts Service Log][sidecar] exit with 0",
  "current_size": 126548,
  "full_size": 5242880
}
```

状态码

状态码	描述
200	ok。

错误码

请参见[错误码](#)。

4.2.7 查询训练作业指定任务的日志（ OBS 链接 ）

功能介绍

查询训练作业指定任务的日志接口，用于获取指定训练作业任务的日志文件在OBS中的访问链接。可全量查看或直接下载。

该接口适用于以下场景：当用户需要查看或下载训练作业任务的详细日志信息时，可以通过此接口获取日志文件的OBS链接。使用该接口的前提条件是训练作业任务已存在且用户具有相应的权限。查询操作完成后，接口将返回指定任务的日志文件的OBS链接。若训练作业任务不存在或用户无权限操作，接口将返回相应的错误信息。

URI

GET /v2/{project_id}/training-jobs/{training_job_id}/tasks/{task_id}/logs/url

表 4-351 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
training_job_id	是	String	训练作业ID。获取方法请参见 查询训练作业列表 。
task_id	是	String	训练作业的任务名称。可从训练作业详情中的status.tasks字段中获取。

请求参数

表 4-352 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	否	String	消息体的类型。设置为text/plain，返回临时预览链接。设置为application/octet-stream，返回临时下载链接。

响应参数

状态码： 200

表 4-353 响应 Body 参数

参数	参数类型	描述
obs_url	String	日志OBS临时链接（复制到浏览器可查看当前全量日志）。

请求示例

如下以查询uuid为2cd88daa-31a4-40a8-a58f-d186b0e93e4f的训练作业对应work-0日志OBS临时链接为例。

GET https://endpoint/v2/{project_id}/training-jobs/2cd88daa-31a4-40a8-a58f-d186b0e93e4f/tasks/worker-0/logs/url?Content-Type=text/plain

响应示例

状态码： 200

ok。

```
{
  "obs_url" : "http://10.155.101.248:20000/cnnorth4-test/xk/00chess_test/test11/logs/modelarts-job-0f2ccdbb-4f34-4d53-afb9-d526f3be8c68-ma-platform-init-worker-0-172.16.24.51-01909681.log?AWSAccessKeyId=xxxxx"
}
```

状态码

状态码	描述
200	ok。

错误码

请参见[错误码](#)。

4.2.8 查询训练作业指定任务的运行指标

功能介绍

查询训练作业指定任务的运行指标接口用于获取ModelArts平台上指定训练作业任务的运行指标。

该接口适用于以下场景：当用户需要查看特定训练任务的性能指标时，可以通过此接口获取运行指标。使用该接口的前提条件是用户已知训练作业ID和任务ID，并具有查看运行指标的权限。查询操作完成后，平台将返回包含任务的性能指标信息。若训练作业ID或任务ID不存在、任务未生成指标或用户无权限操作，接口将返回相应的错误信息。

URI

GET /v2/{project_id}/training-jobs/{training_job_id}/metrics/{task_id}

表 4-354 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
training_job_id	是	String	训练作业ID。
task_id	是	String	训练作业的任务名称。

请求参数

无

响应参数

状态码： 200

表 4-355 响应 Body 参数

参数	参数类型	描述
metrics	Array of 表 4-356 objects	运行指标。

表 4-356 Metrics

参数	参数类型	描述
metric	String	运行指标，可选值如下： cpuUsage（CPU使用率）， memUsage（物理内存使用率）， gpuUtil（GPU使用率）， gpuMemUsage（显存使用率）， npuUtil（NPU使用率）， npuMemUsage（NPU显存使用率）。
value	Array of doubles	运行指标对应数值，1min统计一个平均值。

请求示例

如下以查询uuid为2cd88daa-31a4-40a8-a58f-d186b0e93e4f的训练作业对应worker-0运行指标为例

```
GET https://endpoint/v2/{project_id}/training-jobs/2cd88daa-31a4-40a8-a58f-d186b0e93e4f/metrics/worker-0
```

响应示例

状态码： 200

```
ok。

{
  "metrics": [ {
    "metric": "cpuUsage",
    "value": [ -1, -1, 2.43, 4.524, 6.714, 12.422, 9.214, 5.36, 7.5, 10.088, 8.975, 11.423, 11.548, 14.563,
16.833 ]
  }, {
    "metric": "memUsage",
    "value": [ -1, -1, 0.04, 0.521, 1.652, 4.252, 6.433, 7.384, 7.982, 8.718, 9.365, 9.881, 10.192, 9.994, 9.005 ]
  }, {
    "metric": "gpuUtil",
    "value": [ -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1 ]
  }, {
    "metric": "gpuMemUsage",
    "value": [ -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1 ]
  }, {
    "metric": "npuUtil",
    "value": [ -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1 ]
  }, {
    "metric": "npuMemUsage",
    "value": [ -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1 ]
  }
]
```

状态码

状态码	描述
200	ok。

错误码

请参见[错误码](#)。

4.2.9 查询训练作业列表

功能介绍

根据指定查询条件查询用户创建的训练作业列表。

该接口适用于以下场景：当用户需要查看平台上的所有训练作业时，可以通过此接口获取作业列表。使用该接口的前提条件是用户具有查看训练作业列表的权限。查询操作完成后，平台将返回包含训练作业名称、ID、状态等信息的列表。若用户无权限操作，接口将返回相应的错误信息。

URI

POST /v2/{project_id}/training-job-searches

表 4-357 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。

请求参数

表 4-358 请求 Body 参数

参数	是否必选	参数类型	描述
offset	否	Integer	查询作业的页数，最小为0。例如设置为0，则表示从第一页开始查询。
limit	否	Integer	查询作业的每页条目数。最小为1，最大为50。
sort_by	否	String	查询作业排列顺序的指标。默认使用create_time排序。
order	否	String	查询作业排列顺序，默认为“desc”，降序排序。也可以选择对应的“asc”，升序排序。
group_by	否	String	查询作业要搜索的分组条件。
filters	否	Array of Filter objects	查询作业要过滤的一系列条件。

表 4-359 Filter

参数	是否必选	参数类型	描述
key	否	String	分组条件键值。
operator	否	String	分组条件键值键关系，支持 between（范围）、like（类似）、in（包含）、not（非）。
value	否	Array of strings	分组条件键对应值。

响应参数

状态码： 200

表 4-360 响应 Body 参数

参数	参数类型	描述
total	Integer	查询到当前用户名下的所有作业总数。
count	Integer	查询到当前用户名下的所有符合查询条件的作业总数。

参数	参数类型	描述
limit	Integer	查询作业的每页条目数。最小为1，最大为50。
offset	Integer	查询作业的页数，最小为0。例如设置为0，则表示从第一页开始查询。
sort_by	String	查询作业排列顺序的指标。默认使用create_time排序。
order	String	查询作业排列顺序，默认为“desc”，降序排序。也可以选择对应的“asc”，升序排序。
group_by	String	查询作业要搜索的分组条件。
workspace_id	String	作业所处的工作空间，默认值为“0”。
ai_project	String	作业所属的ai项目，默认值为"default-ai-project"。
items	Array of JobResponse objects	查询到当前用户名下的所有符合查询条件的作业详情。

表 4-361 JobResponse

参数	参数类型	描述
kind	String	训练作业类型。默认使用job。枚举值： job 训练作业。
metadata	JobMetadata object	训练作业元信息。
status	Status object	训练作业状态信息。创建作业无需填写。
algorithm	JobAlgorithmResponse object	训练作业算法。目前支持三种形式： - id：只取算法的id； - subscription_id+item_version_id：取算法的订阅id和版本id； - code_dir+boot_file：取训练作业的代码目录和启动文件。
tasks	Array of TaskResponse objects	异构训练作业的任务列表。
spec	SpecResponse object	训练作业规格参数。
endpoints	JobEndpointsResp object	远程接入训练作业时需要的配置。

表 4-362 JobMetadata

参数	参数类型	描述
id	String	训练作业ID，创建成功后由ModelArts生成返回，无需填写。
name	String	训练作业名称。限制为1-64位只含数字、字母、下划线和中划线的名称。
workspace_id	String	指定作业所处的工作空间，默认值为“0”。
description	String	对训练作业的描述，默认为“NULL”，字符串的长度限制为[0, 256]。
create_time	Long	训练作业创建时间戳，单位为毫秒，创建成功后由ModelArts生成返回，无需填写。
user_name	String	训练作业创建用户的用户名，创建成功后由ModelArts生成返回，无需填写。
created_by	String	训练作业创建者类型，仅在传递了X-Auth-Token-Provider创建的作业中，会返回值为provider。其余场景不会包含该参数。
annotations	Map<String,String>	训练作业高级功能配置，可选取值如下： • "job_template": "Template RL"（异构作业）。 • "fault-tolerance/job-retry-num": "3"（故障自动重启次数）。 • "jupyter-lab/enable": "true"（JupyterLab训练应用程序）。 • "tensorboard/enable": "true"（TensorBoard训练应用程序）。 • "mindstudio-insight/enable": "true"（MindStudio Insight训练应用程序）。

表 4-363 Status

参数	参数类型	描述
phase	String	训练作业一级状态。可选值如下： - Creating：创建中。 - Pending：等待中。 - Running：运行中。 - Failed：运行失败。 - Completed：已完成。 - Terminating：停止中。 - Terminated：已停止。 - Abnormal：异常。
secondary_phase	String	训练作业二级状态为内部详细状态，可能会增加、修改、删除，不建议依赖。可选值如下： - Creating：创建中。 - Queuing：排队中。 - Running：运行中。 - Failed：运行失败。 - Completed：已完成。 - Terminating：停止中。 - Terminated：已停止。 - CreateFailed：创建失败。 - TerminatedFailed：停止失败。 - Unknown：未知状态。 - Lost：异常。
duration	Long	训练作业运行时长，单位为毫秒。
node_count_metrics	Array<Array<Integer>>	训练作业运行时节点数变化指标。
tasks	Array of strings	训练作业子任务名称。
start_time	Long	训练作业开始时间，格式为时间戳。
task_statuses	Array of TaskStatuses objects	训练在子任务状态信息。
running_records	Array of RunningRecord objects	训练作业运行及故障恢复记录。

表 4-364 TaskStatuses

参数	参数类型	描述
task	String	训练作业子任务名称。
exit_code	Integer	训练作业子任务退出码。
message	String	训练作业子任务错误消息。

表 4-365 RunningRecord

参数	参数类型	描述
start_at	Integer	本次运行开始时间的unix时间戳，单位为秒(s)。
end_at	Integer	本次运行结束时间的unix时间戳，单位为秒(s)。
start_type	String	本地运行的启动方式： - init_or_rescheduled：代表本次启动为被调度后的首次运行，包括初次启动及调度恢复后的运行。 - restarted：代表本次启动非被调度后的首次运行，为进程重启后的运行。
end_reason	String	本次运行结束原因。
end_related_task	String	引发本次运行结束的task worker ID(如worker-0)。
end_recover	String	本次运行结束后所采取的故障容忍策略，枚举值如下： - npu_proc_restart: NPU原地热恢复。 - gpu_proc_restart: GPU原地热恢复。 - proc_restart: 进程原地重启。 - pod_reschedule: Pod级重调度。 - job_reschedule: Job级重调度。 - job_reschedule_with_taint: 隔离式Job重调度。
end_recover_before_downgrade	String	本次运行结束后在故障容忍策略降级前所采取的容忍策略，取值范围同end_recover。

表 4-366 JobAlgorithmResponse

参数	参数类型	描述
id	String	训练作业算法。目前支持三种形式： - id：只取算法的id； - subscription_id+item_version_id：取算法的订阅id和版本id； - code_dir+boot_file：取训练作业的代码目录和启动文件。
name	String	算法名称。
subscription_id	String	订阅算法的订阅ID。应与item_version_id一同出现。
item_version_id	String	订阅算法的版本。应与subscription_id一同出现。
code_dir	String	训练作业的代码目录。如：“/usr/app/”。应与boot_file一同出现，如果boot_file已经填入id或subscription_id+item_version_id，则无需填写此参数。
boot_file	String	训练作业的代码启动文件，需要在代码目录下。如：“/usr/app/boot.py”。应与code_dir一同出现，如果code_dir已经填入id或subscription_id+item_version_id，则无需填写此参数。
autosearch_config_path	String	自动化搜索作业的yaml配置路径，需要提供一个OBS路径。如：“obs://bucket/file.yaml”。
autosearch_framework_path	String	自动化搜索作业的框架代码目录，需要提供一个OBS路径。如：“obs://bucket/files/”。
command	String	自定义镜像训练作业的自定义镜像的容器的启动命令。例如python train.py。
parameters	Array of Parameter objects	训练作业的运行参数。
policies	表4-370 object	作业支持的策略。
inputs	Array of Input objects	训练作业的数据输入。
outputs	Array of Output objects	训练作业的结果输出。
engine	JobEngine object	训练作业的引擎。使用算法管理的算法id或订阅算法subscription_id+item_version_id创建作业时，无需填写。

参数	参数类型	描述
local_code_dir	String	算法的代码目录下载到训练容器内的本地路径。规则如下： • 必须为/home下的目录； • v1兼容模式下，当前字段不生效； • 当code_dir以file://为前缀时，当前字段不生效。
working_dir	String	运行算法时所在的工作目录。规则：v1兼容模式下，当前字段不生效。
environments	Array of Map<String,String> objects	训练作业的环境变量。格式："key":"value"，无需填写。
summary	Summary object	可视化日志summary。

表 4-367 Parameter

参数	参数类型	描述
name	String	参数名称。
value	String	参数值。
description	String	参数描述信息。
constraint	表4-368 object	参数属性。
i18n_description	表4-369 object	国际化描述。

表 4-368 Constraint

参数	参数类型	描述
type	String	参数种类。
editable	Boolean	是否可编辑。
required	Boolean	是否必须。
sensitive	Boolean	是否敏感。该功能暂未实现。
valid_type	String	有效种类。
valid_range	Array of strings	有效范围。

表 4-369 I18nDescription

参数	参数类型	描述
language	String	国际语种
description	String	国际化语种的描述信息。

表 4-370 Policies

参数	参数类型	描述
auto_search	表4-371 object	超参搜索配置。

表 4-371 AutoSearch

参数	参数类型	描述
skip_search_params	String	需要排除的超参组合。
reward_attr	Array of 表 4-372 objects	搜索指标列表。
search_params	Array of 表 4-373 objects	搜索参数。
algo_configs	Array of 表 4-374 objects	搜索算法配置。

表 4-372 RewardAttrs

参数	参数类型	描述
name	String	指标名称。
mode	String	搜索方向。 - max指定时表示指标值越大越好； - min指定时表示指标值越小越好。
regex	String	指标正则表达式。

表 4-373 SearchParams

参数	参数类型	描述
name	String	超参名称。

参数	参数类型	描述
param_type	String	参数类型。 - continuous：指定时表示这个超参是连续类型的。连续类型的超参在算法使用于训练作业时，控制台显示为输入框。 - discrete：指定时表示这个超参是离散类型的。离散类型的超参在算法使用于训练作业时，控制台显示为下拉选择框架。
lower_bound	String	超参下界。
upper_bound	String	超参上界。
discrete_points_num	String	连续型超参离散化取值个数。
discrete_values	Array of strings	离散型超参的取值列表。

表 4-374 AlgoConfigs

参数	参数类型	描述
name	String	搜索算法名称。
params	Array of AutoSearchAlgoConfigParameter objects	搜索算法参数。

表 4-375 AutoSearchAlgoConfigParameter

参数	参数类型	描述
key	String	参数键。
value	String	参数值。
type	String	参数种类。

表 4-376 Input

参数	参数类型	描述
name	String	数据输入通道名称。
description	String	数据输入通道描述信息。

参数	参数类型	描述
local_dir	String	数据输入通道映射的容器本地路径。例如，“/home/ma-user/modelarts/inputs/data_url_0”。
remote	InputDataInfo object	数据实际输入信息。枚举值： - dataset：指定输入为数据集； - obs：指定输入为OBS路径。
remote_constraint	Array of 表 4-380 objects	数据输入约束。

表 4-377 InputDataInfo

参数	参数类型	描述
dataset	表4-378 object	数据输入信息为数据集。
obs	表4-379 object	数据输入输出信息为OBS方式。

表 4-378 Dataset

参数	参数类型	描述
id	String	训练作业的数据集ID。
version_id	String	训练作业的数据集版本ID。
obs_url	String	训练作业需要的数据集OBS路径URL，ModelArts会通过数据集ID和数据集版本ID自动解析生成。如：“/usr/data/”。

表 4-379 Obs

参数	参数类型	描述
obs_url	String	训练作业需要的数据集OBS路径URL。如：“/usr/data/”。

表 4-380 RemoteConstraint

参数	参数类型	描述
data_type	String	数据输入类型，包括数据存储位置、数据集两种方式。
attributes	String	数据输入为数据集时的相关属性。枚举值： • data_format 数据格式； • data_segmentation 数据切分方式； • dataset_type 标注类型。

表 4-381 Output

参数	参数类型	描述
name	String	数据输出通道名称。
description	String	数据输出通道描述信息。
local_dir	String	数据输出通道映射的容器本地路径。
remote	Remote object	数据实际输出信息。

表 4-382 JobEngine

参数	参数类型	描述
engine_id	String	训练作业选择的引擎规格ID。engine_id, engine_name+engine_version和image_url方式三选一。
engine_name	String	训练作业选择的引擎名称。如果已填写 engine_id, 则此参数无需填写。
engine_version	String	训练作业选择的引擎版本名称。如果已填写 engine_id, 则此参数无需填写。
image_url	String	训练作业选择的自定义镜像地址，地址从swr服务获取。

表 4-383 Summary

参数	参数类型	描述
log_type	String	训练作业可视化日志类型，配置后训练作业可作为可视化作业数据源。可选取值如下： • tensorboard。 • mindstudio-insight。
log_dir	LogDir object	训练作业可视化日志输出，log_type非空时必须填。
data_sources	Array of DataSource object	可视化作业或训练作业调试模式的可视化日志输入，训练作业高级功能开启"tensorboard/enable": "true"或"mindstudio-insight/enable": "true"时必须填。

表 4-384 LogDir

参数	参数类型	描述
pfs	PFSSummary object	obs并行文件系统输出。

表 4-385 DataSource

参数	参数类型	描述
pfs	PFSSummary object	obs并行文件系统输出。

表 4-386 PFSSummary

参数	参数类型	描述
pfs_path	String	obs并行文件系统路径url。

表 4-387 TaskResponse

参数	参数类型	描述
role	String	任务角色，该功能暂未支持。
algorithm	TaskResponseAlgorithm object	算法配置。

参数	参数类型	描述
task_resource	FlavorResponse object	训练作业、算法的规格信息。

表 4-388 TaskResponseAlgorithm

参数	参数类型	描述
code_dir	String	算法启动文件所在目录绝对路径。
boot_file	String	算法启动文件绝对路径。
inputs	AlgorithmInput object	算法输入通道信息。
outputs	AlgorithmOutput object	算法输出通道信息。
engine	AlgorithmEngine object	异构作业所依赖的引擎。
local_code_dir	String	算法的代码目录下载到训练容器内的本地路径。 规则如下： • 必须为/home下的目录； • v1兼容模式下，当前字段不生效； • 当code_dir以file://为前缀时，当前字段不生效。
working_dir	String	运行算法时所在的工作目录。规则：v1兼容模式下，当前字段不生效。

表 4-389 AlgorithmInput

参数	参数类型	描述
name	String	数据输入通道名称。
local_dir	String	数据输入输出通道映射的容器本地路径。
remote	AlgorithmRemote object	数据实际输入信息，异构作业只支持OBS。

表 4-390 AlgorithmRemote

参数	参数类型	描述
obs	RemoteObs object	数据输入输出信息为OBS方式。

表 4-391 AlgorithmOutput

参数	参数类型	描述
name	String	数据输出通道名称。
local_dir	String	数据输出通道映射的容器本地路径。
remote	Remote object	数据实际输出信息。
mode	String	数据传输模式，默认为“upload_periodically”。
period	String	数据传输周期，默认为30s。

表 4-392 Remote

参数	参数类型	描述
obs	RemoteObs object	数据实际输出到OBS。

表 4-393 RemoteObs

参数	参数类型	描述
obs_url	String	数据实际输出到OBS的路径。

表 4-394 AlgorithmEngine

参数	参数类型	描述
engine_id	String	引擎规格的ID。如“caffe-1.0.0-python2.7”。
engine_name	String	引擎规格的名称。如“Caffe”。
engine_version	String	引擎规格的版本。对一个引擎名称，有多个版本的引擎，如使用python2.7的"Caffe-1.0.0-python2.7"等。
v1_compatible	Boolean	是否为v1兼容模式。
run_user	String	引擎默认启动用户uid。
image_url	String	算法选择的自定义镜像地址。

表 4-395 FlavorResponse

参数	参数类型	描述
flavor_id	String	资源规格的ID。
flavor_name	String	资源规格的名称。
max_num	Integer	资源规格的最大节点数。
flavor_type	String	资源规格的类型。可选值如下： • CPU。 • GPU。
billing	BillingInfo object	资源规格计费信息。
flavor_info	FlavorInfoResponse object	资源规格详细信息。
attributes	Map<String,String>	其他规格属性。

表 4-396 FlavorInfoResponse

参数	参数类型	描述
max_num	Integer	可以选择的最大节点数量（max_num，为1代表不支持分布式）。
cpu	Cpu object	cpu规格信息。
gpu	Gpu object	gpu规格信息。
npu	Npu object	Ascend规格信息。
memory	Memory object	内存信息。
disk	DiskResponse object	磁盘信息。

表 4-397 DiskResponse

参数	参数类型	描述
size	Integer	磁盘大小。
unit	String	磁盘大小单位。

表 4-398 SpecResponse

参数	参数类型	描述
resource	Resource object	训练作业资源规格信息。flavor_id和pool_id+[flavor_id]方式二选一。
volumes	Array of JobVolume objects	训练作业挂载卷信息。
log_export_path	LogExportPath object	训练作业日志输出信息。

表 4-399 Resource

参数	参数类型	描述
policy	String	训练作业资源规格模式，可选值为regular，表示为标准模式。
flavor_id	String	训练作业资源规格id。CPU规格专属资源池不支持指定flavor_id。GPU/Ascend规格专属资源池可选取值如下： • modelarts.pool.visual.xlarge（1卡）。 • modelarts.pool.visual.2xlarge（2卡）。 • modelarts.pool.visual.4xlarge（4卡）。 • modelarts.pool.visual.8xlarge（8卡）。
flavor_name	String	使用flavor_id时，由ModelArts返回的只读规格名称。
node_count	Integer	训练作业选择的资源副本数。
pool_id	String	训练作业选择的资源池ID。
flavor_detail	FlavorDetail object	训练作业、算法的规格信息（该字段只有公共资源池存在）。

表 4-400 FlavorDetail

参数	参数类型	描述
flavor_type	String	资源规格的类型。可选值如下： • CPU。 • GPU。
billing	BillingInfo object	资源规格计费信息。

参数	参数类型	描述
flavor_info	FlavorInfo object	资源规格详细信息。

表 4-401 BillingInfo

参数	参数类型	描述
code	String	计费码。
unit_num	Integer	计费单元。

表 4-402 FlavorInfo

参数	参数类型	描述
max_num	Integer	可以选择的最大节点数量（max_num，为1代表不支持分布式）。
cpu	Cpu object	cpu规格信息。
gpu	Gpu object	gpu规格信息。
npu	Npu object	Ascend规格信息。
memory	Memory object	内存信息。
disk	Disk object	磁盘信息。

表 4-403 Cpu

参数	参数类型	描述
arch	String	cpu架构。
core_num	Integer	核数。

表 4-404 Gpu

参数	参数类型	描述
unit_num	Integer	gpu卡数。
product_name	String	产品名。
memory	String	内存。

表 4-405 Npu

参数	参数类型	描述
unit_num	String	npu卡数。
product_name	String	产品名。
memory	String	内存。

表 4-406 Memory

参数	参数类型	描述
size	Integer	内存大小。
unit	String	内存单元数。

表 4-407 Disk

参数	参数类型	描述
size	String	磁盘大小。
unit	String	磁盘大小单位，一般为GB。

表 4-408 JobVolume

参数	参数类型	描述
nfs	Nfs object	nfs方式的挂载卷。

表 4-409 Nfs

参数	参数类型	描述
nfs_server_path	String	nfs服务端路径，如：“10.10.10.10:/example/path”。
local_path	String	挂载到训练容器中的路径，如：“/example/path”。
read_only	Boolean	nfs挂载卷在容器中是否只读。

表 4-410 LogExportPath

参数	参数类型	描述
obs_url	String	训练作业日志保存的OBS地址，如：“obs://example/path”。
host_path	String	训练作业日志保存的宿主机的路径，如：“/example/path”。

表 4-411 JobEndpointsResp

参数	参数类型	描述
ssh	SSHResp object	SSH连接信息。
jupyter_lab	JupyterLab object	JupyterLab连接信息。
tensorboard	Tensorboard object	Tensorboard连接信息。
mindstudio_in_sight	MindStudio Insight object	MindStudio Insight连接信息。

表 4-412 SSHResp

参数	参数类型	描述
key_pair_names	Array of strings	SSH密钥对名称，可以在云服务器控制台（ECS）“密钥对”页面创建和查看。
task_urls	Array of TaskUrls objects	SSH连接地址信息。

表 4-413 TaskUrls

参数	参数类型	描述
task	String	训练作业的任务ID。
url	String	训练作业SSH连接地址。

表 4-414 JupyterLab

参数	参数类型	描述
url	String	训练作业的JupyterLab地址。
token	String	训练作业的JupyterLab token。

表 4-415 Tensorboard

参数	参数类型	描述
url	String	训练作业的Tensorboard地址。
token	String	训练作业的Tensorboard token。

表 4-416 MindStudio Insight

参数	参数类型	描述
url	String	训练作业的MindStudio Insight地址。
token	String	训练作业的MindStudio Insight token。

请求示例

查询训练作业。设置查询训练作业限制个数为1，查询作业名称中包含trainjob的所有训练作业数据。

POST https://endpoint/v2/{project_id}/training-job-searches?limit=1

```
{
  "offset" : 0,
  "limit" : 1,
  "filters" : [ {
    "key" : "name",
    "operator" : "like",
    "value" : [ "trainjob" ]
  }, {
    "key" : "create_time",
    "operator" : "between",
    "value" : [ "", "" ]
  }, {
    "key" : "phase",
    "operator" : "in",
    "value" : [ "" ]
  }, {
    "key" : "algorithm_name",
    "operator" : "like",
    "value" : [ "" ]
  }, {
    "key" : "kind",
    "operator" : "in",
    "value" : [ ]
  }, {
    "key" : "user_id",
    "operator" : "in",
    "value" : [ "" ]
  }
]
```

```
}, {  
  "key": "runtime_type",  
  "operator": "in",  
  "value": [ "production" ]  
}]  
}
```

响应示例

状态码： 200

ok。

```
{  
  "total": 5059,  
  "count": 1,  
  "limit": 1,  
  "offset": 0,  
  "sort_by": "create_time",  
  "order": "desc",  
  "group_by": "",  
  "workspace_id": "0",  
  "ai_project": "default-ai-project",  
  "items": [ {  
    "kind": "job",  
    "metadata": {  
      "id": "3faf5c03-aaa1-4cbe-879d-24b05d997347",  
      "name": "trainjob--py14_mem06-byd-108",  
      "description": "",  
      "create_time": 1636447346315,  
      "workspace_id": "0",  
      "user_name": "ei_modelarts_q00357245_01"  
    },  
    "status": {  
      "phase": "Abnormal",  
      "secondary_phase": "CreateFailed",  
      "duration": 0,  
      "start_time": 0,  
      "node_count_metrics": [ [ 1636447746000, 0 ], [ 1636447755000, 0 ], [ 1636447756000, 0 ] ],  
      "tasks": [ "worker-0" ]  
    },  
    "algorithm": {  
      "code_dir": "obs://test-crq/economic_test/py_minist/",  
      "boot_file": "obs://test-crq/economic_test/py_minist/minist_common.py",  
      "inputs": [ {  
        "name": "data_url",  
        "local_dir": "/home/ma-user/modelarts/inputs/data_url_0",  
        "remote": {  
          "obs": {  
            "obs_url": "/test-crq/data/py_minist/"  
          }  
        }  
      } ],  
      "outputs": [ {  
        "name": "train_url",  
        "local_dir": "/home/ma-user/modelarts/outputs/train_url_0",  
        "remote": {  
          "obs": {  
            "obs_url": "/test-crq/train_output/"  
          }  
        }  
      } ],  
      "engine": {  
        "engine_id": "pytorch-cp36-1.4.0-v2",  
        "engine_name": "PyTorch",  
        "engine_version": "PyTorch-1.4.0-python3.6-v2"  
      }  
    },  
    "spec": {
```

```
"resource": {
  "policy": "economic",
  "flavor_id": "modelarts.vm.pnt1.large.eco",
  "flavor_name": "Computing GPU(Pnt1) instance",
  "node_count": 1,
  "flavor_detail": {
    "flavor_type": "GPU",
    "billing": {
      "code": "modelarts.vm.gpu.pnt1.eco",
      "unit_num": 1
    },
    "flavor_info": {
      "cpu": {
        "arch": "x86",
        "core_num": 8
      },
      "gpu": {
        "unit_num": 1,
        "product_name": "GP-Pnt1",
        "memory": "8GB"
      },
      "memory": {
        "size": 64,
        "unit": "GB"
      }
    }
  }
}
```

状态码

状态码	描述
200	ok。

错误码

请参见[错误码](#)。

4.2.10 创建训练作业镜像保存任务

功能介绍

创建训练作业镜像保存任务接口用于为已存在的训练作业创建一个镜像保存任务。

该接口适用于以下场景：当用户需要将训练作业的当前状态或模型保存为镜像，以便后续复用或分享时，可以通过此接口创建一个镜像保存任务。使用该接口的前提条件是训练作业已存在且用户具有相应的操作权限。镜像保存任务创建成功后，系统将开始保存训练作业的镜像，并在完成后通知用户。若训练作业不存在、用户无权限操作或镜像保存任务创建失败，接口将返回相应的错误信息。

URI

POST /v2/{project_id}/training-jobs/{training_job_id}/tasks/{task_id}/save-image-job

表 4-417 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
training_job_id	是	String	训练作业ID。获取方法请参见 查询训练作业列表 。
task_id	是	String	训练作业的任务名称。可从训练作业详情中的status.tasks字段中获取。

请求参数

表 4-418 请求 Body 参数

参数	是否必选	参数类型	描述
name	否	String	镜像名称，长度限制512个字符，支持小写字母、数字、中划线、下划线和点。
namespace	否	String	镜像所属组织，可以在SWR控制台“组织管理”创建和查看。
tag	否	String	镜像tag，长度限制64个字符，支持大小写字母、数字、中划线、下划线和点。
description	否	String	该镜像所对应的描述信息，长度限制512个字符。

响应参数

状态码： 201

表 4-419 响应 Body 参数

参数	参数类型	描述
name	String	镜像名称，长度限制512个字符，支持小写字母、数字、中划线、下划线和点。
namespace	String	镜像所属组织，可以在SWR控制台“组织管理”创建和查看。
tag	String	镜像tag，长度限制64个字符，支持大小写字母、数字、中划线、下划线和点。

参数	参数类型	描述
description	String	该镜像所对应的描述信息，长度限制512个字符。
status	String	镜像状态。枚举值如下： - INIT：初始化。 - CREATING：镜像保存中，此时训练作业不可用。 - CREATE_FAILED：镜像保存失败。 - ACTIVE：镜像保存成功，保存的镜像可以在SWR控制台查看，同时可以基于保存的镜像创建训练作业。
message	String	镜像创建的时间，UTC毫秒。
create_time	Long	镜像保存操作过程中，展示构建信息。

请求示例

如下以创建uuid为2cd88daa-31a4-40a8-a58f-d186b0e93e4f的训练作业对应worker-0镜像保存任务为例。

```
POST https://endpoint/v2/{project_id}/training-jobs/2cd88daa-31a4-40a8-a58f-d186b0e93e4f/tasks/worker-0/save-image-job
{
  "name" : "imagesave",
  "namespace" : "dev",
  "tag" : 0.1,
  "description" : "hello world!"
}
```

响应示例

状态码： 201
create image save job successfully。

```
{
  "name" : "imagesave",
  "namespace" : "dev",
  "tag" : 0.1,
  "description" : "hello world!",
  "status" : "ACTIVE",
  "message" : "building",
  "create_time" : 1686718209968
}
```

状态码

状态码	描述
201	create image save job successfully。

错误码

请参见[错误码](#)。

4.2.11 查询训练作业镜像保存任务

功能介绍

查询训练作业镜像保存任务接口用于获取ModelArts平台上指定训练作业的镜像保存任务信息。

该接口适用于以下场景：当用户需要查看特定训练作业的镜像保存任务状态时，可以通过此接口获取任务信息。使用该接口的前提条件是用户已知训练作业ID，并具有查看镜像保存任务的权限。查询操作完成后，平台将返回包含镜像保存任务的状态、配置等信息。若训练作业ID不存在或用户无权限操作，接口将返回相应的错误信息。

URI

GET /v2/{project_id}/training-jobs/{training_job_id}/tasks/{task_id}/save-image-job

表 4-420 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
training_job_id	是	String	训练作业ID。获取方法请参见 查询训练作业列表 。
task_id	是	String	训练作业的任务名称。可从训练作业详情中的status.tasks字段中获取。

请求参数

无

响应参数

状态码： 200

表 4-421 响应 Body 参数

参数	参数类型	描述
name	String	镜像名称，长度限制512个字符，支持小写字母、数字、中划线、下划线和点。
namespace	String	镜像所属组织，可以在SWR控制台“组织管理”创建和查看。

参数	参数类型	描述
tag	String	镜像tag，长度限制64个字符，支持大小写字母、数字、中划线、下划线和点。
description	String	该镜像所对应的描述信息，长度限制512个字符。
status	String	镜像状态。枚举值如下： - INIT：初始化。 - CREATING：镜像保存中，此时训练作业不可用。 - CREATE_FAILED：镜像保存失败。 - ACTIVE：镜像保存成功，保存的镜像可以在SWR控制台查看，同时可以基于保存的镜像创建训练作业。
message	String	镜像创建的时间，UTC毫秒。
create_time	Long	镜像保存操作过程中，展示构建信息。

请求示例

如下以查询uuid为2cd88daa-31a4-40a8-a58f-d186b0e93e4f的训练作业对应worker-0镜像保存任务为例。

```
GET https://endpoint/v2/{project_id}/training-jobs/2cd88daa-31a4-40a8-a58f-d186b0e93e4f/tasks/worker-0/save-image-job
```

响应示例

状态码： 200

查询训练作业镜像保存任务成功。

```
{
  "name" : "imagesave",
  "namespace" : "dev",
  "tag" : 0.1,
  "description" : "hello world!",
  "status" : "ACTIVE",
  "message" : "building",
  "create_time" : 1686718209968
}
```

状态码

状态码	描述
200	查询训练作业镜像保存任务成功。

错误码

请参见[错误码](#)。

4.2.12 批量删除训练作业

功能介绍

批量删除已创建的训练作业。

URI

POST /v2/{project_id}/training-jobs/batch-delete

表 4-422 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。

请求参数

表 4-423 请求 Body 参数

参数	是否必选	参数类型	描述
jobs	是	Array of Job objects	需要删除的job列表。单次批量删除作业数量上限为100个。

响应参数

无。

请求示例

如下以删除uuid为9110d96a-55f1-4d6b-a08c-31309bc422f5和931939ec-202d-420b-a30f-d7838a92f357的训练作业为例。

```
POST https://endpoint/v2/{project_id}/training-jobs/batch-delete
{
  "jobs": [
    {
      "metadata": {
        "id": "9110d96a-55f1-4d6b-a08c-31309bc422f5"
      }
    },
    {
      "metadata": {
        "id": "931939ec-202d-420b-a30f-d7838a92f357"
      }
    }
  ]
}
```

```
]
}
```

响应示例

```
状态码： 202

No Content。

""
```

状态码

状态码	描述
202	No Content。

4.3 资源和引擎规格

4.3.1 查询训练作业支持的公共规格列表

功能介绍

查询ModelArts平台上支持的训练作业资源规格列表。

该接口适用于以下场景：当用户需要了解平台支持的资源规格以进行训练作业配置时，可以通过此接口获取规格列表。使用该接口的前提条件是用户具有查看资源规格的权限。查询操作完成后，平台将返回包含支持的资源规格信息。若用户无权限操作，接口将返回相应的错误信息。

URI

```
GET /v2/{project_id}/training-job-flavors
```

表 4-424 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。

表 4-425 Query 参数

参数	是否必选	参数类型	描述
flavor_type	否	String	查询训练作业规格的类型，不填为查询所有。枚举值： • CPU • GPU • Ascend

请求参数

无

响应参数

状态码： 200

表 4-426 响应 Body 参数

参数	参数类型	描述
total_count	Integer	训练作业资源规格总数。
flavors	Array of FlavorResponse objects	训练作业资源规格列表。

表 4-427 FlavorResponse

参数	参数类型	描述
flavor_id	String	资源规格的ID。
flavor_name	String	资源规格的名称。
max_num	Integer	资源规格的最大节点数。
flavor_type	String	资源规格的类型。可选值如下： • CPU； • GPU； • Ascend，该版本暂不支持。
billing	表4-428 object	资源规格计费信息。
job_info	表4-429 object	作业相关信息。

参数	参数类型	描述
flavor_info	表4-430 object	资源规格详细信息。
attributes	Map<String,String>	其他规格属性。

表 4-428 Billing

参数	参数类型	描述
code	String	计费码。
unit_num	Integer	计费卡数。

表 4-429 JobInfo

参数	参数类型	描述
queue_num	Integer	排队中的作业数。queue_num为-1，表示查询公共池上排队的作业失败。queue_num为0，表示当前池子没有作业在排队（如果公共池上作业已满，那么当前下发作业不一定能立即运行）。queue_num为1,2,3...表示当前池子排队的作业数。

表 4-430 FlavorInfo

参数	参数类型	描述
max_num	Integer	可以选择的最大节点数量（max_num，为1代表不支持分布式）。
cpu	表4-431 object	cpu规格信息。
gpu	表4-432 object	gpu规格信息。
npu	表4-433 object	Ascend规格信息，该版本暂不支持。
memory	表4-434 object	内存信息。
disk	表4-435 object	磁盘信息。

表 4-431 Cpu

参数	参数类型	描述
arch	String	cpu架构。
core_num	Integer	核数。

表 4-432 Gpu

参数	参数类型	描述
unit_num	Integer	gpu卡数。
product_name	String	产品名。
memory	String	内存。

表 4-433 Npu

参数	参数类型	描述
unit_num	String	npu卡数。
product_name	String	产品名。
memory	String	内存。

表 4-434 Memory

参数	参数类型	描述
size	Integer	内存大小。
unit	String	内存单元数。

表 4-435 Disk

参数	参数类型	描述
size	Integer	磁盘大小。
unit	String	磁盘大小单位。

请求示例

如下以查询训练作业所有的CPU公共资源规格为例。

GET https://endpoint/v2/{project_id}/training-job-flavors?flavor_type=CPU

响应示例

状态码： 200

ok。

```
{
  "total_count": 2,
  "flavors": [ {
    "flavor_id": "modelarts.vm.cpu.2u",
    "flavor_name": "Computing CPU(2U) instance",
    "flavor_type": "CPU",
    "billing": {
      "code": "modelarts.vm.cpu.2u",
      "unit_num": 1
    },
    "job_info": {
      "queue_num": 0
    },
    "flavor_info": {
      "max_num": 1,
      "cpu": {
        "arch": "x86",
        "core_num": 2
      },
      "memory": {
        "size": 8,
        "unit": "GB"
      },
      "disk": {
        "size": 50,
        "unit": "GB"
      }
    }
  }, {
    "flavor_id": "modelarts.vm.cpu.8u",
    "flavor_name": "Computing CPU(8U) instance",
    "flavor_type": "CPU",
    "billing": {
      "code": "modelarts.vm.cpu.8u",
      "unit_num": 1
    },
    "job_info": {
      "queue_num": 2
    },
    "flavor_info": {
      "max_num": 16,
      "cpu": {
        "arch": "x86",
        "core_num": 8
      },
      "memory": {
        "size": 32,
        "unit": "GB"
      },
      "disk": {
        "size": 50,
        "unit": "GB"
      }
    }
  }
]
}
```

状态码

状态码	描述
200	ok。

错误码

请参见[错误码](#)。

4.4 训练作业标签管理

4.4.1 创建训练作业标签

功能介绍

创建训练作业标签，支持批量添加，当添加的标签key已存在，则覆盖该标签的value。

URI

POST /v2/{project_id}/modelarts-trainJob/{training_job_id}/tags/create

表 4-436 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
training_job_id	是	String	训练作业ID。

请求参数

表 4-437 请求 Body 参数

参数	是否必选	参数类型	描述
tags	是	Array of TmsTag objects	标签列表。

表 4-438 TmsTag

参数	是否必选	参数类型	描述
key	是	String	标签的key。
value	是	String	标签的value。

响应参数

无。

请求示例

创建训练作业标签。设置标签的key/value为“111”和“k3”，标签的key/value为“k3”和“v2”。

```
POST https://endpoint/v2/{project_id}/modelarts-trainJob/{training_job_id}/tags/create
{
  "tags": [ {
    "key": "111",
    "value": "v2"
  }, {
    "key": "k3",
    "value": "v2"
  } ]
}
```

响应示例

无。

状态码

状态码	描述
204	添加成功。

错误码

请参见[错误码](#)。

4.4.2 删除训练作业标签

功能介绍

删除训练作业标签，支持批量删除。

URI

DELETE /v2/{project_id}/modelarts-trainJob/{training_job_id}/tags/delete

表 4-439 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
training_job_id	是	String	训练作业ID。

请求参数

表 4-440 请求 Body 参数

参数	是否必选	参数类型	描述
tags	是	Array of TmsTagForDelete objects	要删除的标签列表。

表 4-441 TmsTagForDelete

参数	是否必选	参数类型	描述
key	是	String	标签的key。
value	否	String	标签的value，非必填

响应参数

无。

请求示例

```
DELETE https://endpoint/v2/{project_id}/modelarts-trainJob/{training_job_id}/tags/delete

{
  "tags": [ {
    "key": "111",
    "value": "v2"
  }, {
    "key": "k3",
    "value": "v2"
  } ]
}
```

响应示例

无。

状态码

状态码	描述
204	删除成功。

错误码

请参见[错误码](#)。

4.4.3 查询训练作业标签

功能介绍

查询训练作业标签。

URI

GET /v2/{project_id}/modelarts-trainJob/{training_job_id}/tags

表 4-442 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
training_job_id	是	String	训练作业ID。

请求参数

无。

响应参数

状态码： 200

表 4-443 响应 Body 参数

参数	参数类型	描述
tags	Array of TmsTag objects	标签结构体。

表 4-444 TmsTag

参数	参数类型	描述
key	String	标签的key。
value	String	标签的value。

请求示例

GET https://endpoint/v2/{project_id}/modelarts-trainJob/{training_job_id}/tags

响应示例

状态码： 200

查询成功。

```
{
  "tags": [ {
    "key": "111",
    "value": "v2"
  }, {
    "key": "k2",
    "value": "v2"
  }, {
    "key": "test",
    "value": "1122"
  } ]
}
```

状态码

状态码	描述
200	查询成功。

错误码

请参见[错误码](#)。

5 模型管理（旧版推理）

5.1 导入模型

功能介绍

导入模型。

执行代码、模型需先上传至OBS。

针对使用自定义镜像方式导入的模型，建议提前构建镜像并上传至SWR。

URI

POST /v1/{project_id}/models

参数说明如[表5-1](#)所示。

表 5-1 参数说明

参数	是否必选	参数类型	说明
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。

请求消息

请求参数如[表5-2](#)所示。

表 5-2 请求参数

参数	是否必选	参数类型	说明
model_name	是	String	模型名称，支持1~64位可见字符（含中文），名称可以包含字母、中文、数字、中划线、下划线。

参数	是否必选	参数类型	说明
model_version	是	String	模型版本，格式需为“数值.数值.数值”，其中数值为1-2位正整数。注意：版本不可以出现如01.01.01等以0开头的版本号形式。
source_location	是	String	模型所在的OBS路径或SWR镜像地址。 - 当“model_type”字段的值为“Custom”时，source_location为模型所在的OBS路径。 - 使用SWR导入方式创建模型时，需要确保创建模型的用户拥有该镜像访问权限；如果使用的镜像是共享镜像，需要确认创建过程中镜像共享期限不会过期，否则会导致模型创建失败。
source_type	否	String	模型来源的类型。当“model_type”字段的值为“Custom”时，该字段为无效字段。
model_type	是	String	模型类型，取值为TensorFlow/Spark_Mllib/Scikit_Learn/XGBoost/Image/PyTorch/Custom，从配置文件读取。
runtime	否	String	模型运行时环境，runtime可选值与model_type相关，当“model_type”字段的值为“Custom”时，runtime的值为SWR镜像地址值。
description	否	String	模型备注信息，不超过100个字符，不能包含&!\\"<>=等特殊字符。
model_algorithm	否	String	模型算法，从配置文件读取，可不填。如：“predict_analysis”、“object_detection”、“image_classification”。只能以英文字母开头，不能包含中文以及&!\\"<>=，不超过36个字符。
execution_code	否	String	执行代码存放的OBS地址，默认值为空，名称固定为“customize_service.py”。推理代码文件需存放在模型“model”目录。该字段不填，系统也能自动识别出model目录下的推理代码。当“model_type”字段的值为“Custom”时，该字段为无效字段，不需要填。

参数	是否必选	参数类型	说明
input_params	否	params结构数组	模型的输入参数集，默认为空，params结构如 表5-3 所示。当从配置文件的apis读取时，用户提供“initial_config”字段即可，可不填该字段，即当initial_config存在时input_params非必选。当"model_type"字段的值为“Custom”时，该字段为无效字段，不需要填。
output_params	否	params结构数组	模型的输出参数集，默认为空，params结构如 表5-3 所示。从配置文件的apis读取，用户提供“initial_config”字段即可，可不填该字段。当"model_type"字段的值为“Custom”时，该字段为无效字段，不需要填。
dependencies	否	dependency结构数组	推理代码及模型需安装的包，默认为空。从配置文件读取，可不填。dependency结构如表5-4所示。当"model_type"字段的值为“Custom”时，该字段为无效字段，不需要填。 说明 “dependencies”参数支持多个“dependency”结构数组，以list格式填入，默认安装包存在先后依赖关系（即写在前面的先安装，写在后面的后安装），且支持线下wheel包安装（wheel包必须与模型文件放在同一目录）。
workspace_id	否	String	工作空间ID。获取方法请参见 查询工作空间列表 。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。
model_metrics	否	String	模型精度信息，从配置文件读取。
apis	否	apis结构体数组	模型所有的apis入参出参信息，从配置文件中读取，可不填。apis结构体如 表5-8 所示。当"model_type"字段的值为“Custom”时，且模式为异步请求时，该字段为无效字段，不需要填。
initial_config	否	String	最终使用的模型配置文件转成的字符串。建议通过配置文件来提供model_algorithm、model_type metrics、apis、runtime、protocol、port、 表5-11 等字段的信息。
model_docs	否	doc结构数组	模型说明文档列表，最多三篇。doc结构如 表5-7 所示。当"model_type"字段的值为“Custom”时，该字段为无效字段。
install_type	否	String数组	部署类型，只支持小写。可选real-time、batch，默认为["real-time","batch"]。

参数	是否必选	参数类型	说明
cmd	否	String	启动命令配置。元模型来源选择“从对象存储服务（OBS）中选择”或“从容器镜像中选择”时可选。
dynamic_load_mode	否	String	是否支持动态加载，None表示不使用动态加载，Single表示单模型简单模式的动态加载；元模型来源选择“从OBS导入”时可选。
deployment_constraints	否	Template object	异步模型部署约束，使用镜像导入，选择异步模式时必选；使用OBS导入元模型，AI引擎选择为Custom类型时该参数可选。配置可参考 表5-12 。
prebuild	否	Boolean	默认false，是否预先构建镜像。
source_copy	否	String	是否复制镜像，元模型从SWR导入时才有该选项。

表 5-3 Params 结构

参数	是否必选	参数类型	说明
url	是	String	api代表的url路径。
method	是	String	请求方法，可选“post”、“get”。
protocol	是	String	请求协议。
param_name	是	String	参数名，建议长度设置不超过64个字符。
param_type	是	String	参数类型，取值可选int/string/float/timestamp/date/file。
min	否	Number	当param_type为int或float时可选填，默认为空。
max	否	Number	当param_type为int或float时可选填，默认为空。
param_desc	否	String	参数描述，建议长度设置不超过100个字符，默认为空。

表 5-4 Dependency 结构

参数	是否必选	参数类型	说明
installer	是	String	安装方式，当前只支持pip。

参数	是否必选	参数类型	说明
packages	是	package结构数组	依赖包集合。详情参见 表5-5 。

表 5-5 Package 结构

参数	是否必选	参数类型	说明
package_name	是	String	依赖包名称。请确保包名正确且存在。不能含有中文及特殊字符&!"'<>=。
package_version	否	String	依赖包版本。不填时默认安装当前环境下的最新版本。不能含有中文及特殊字符&!"'<>=。
restraint	否	String	版本限制条件，取值为EXACT/ATLEAST/ATMOST，当且仅当package_version存在时必填。

表 5-6 Metric 参数说明

参数	是否必选	参数类型	说明
f1	否	Double	平均数。
recall	否	Double	召回率。
precision	否	Double	精确率。
accuracy	否	Double	准确率。

表 5-7 Doc 参数说明

参数	是否必选	参数类型	说明
doc_name	是	String	文档名称，支持1-48位可见字符（含中文），只能以英文大小写字母或者中文字符开头，名称可以包含字母、中文、数字、中划线、下划线。
doc_url	是	String	文档http(s)链接。

表 5-8 Apis 参数说明

参数	是否必选	参数类型	说明
input_params	否	Object	apis中的输入输出参数，以JSON Schema格式描述，InputParams结构体如 表5-9 所示。
method	否	String	请求方法，可选值为post、get。
output_params	否	Object	apis中的输入输出参数，以JSON Schema格式描述，OutputParams结构体如 表5-10 所示。
protocol	否	String	请求协议。
url	否	String	推理请求URL路径。

表 5-9 InputParams 参数说明

参数	是否必选	参数类型	说明
properties	否	Map<String, Object>	JSON Schema中表示对象元素的properties字段，可在其中定义参数，包括参数名及其类型。
type	否	String	JSON Schema中表示类型的字段，可选值为object。

表 5-10 OutputParams 参数说明

参数	是否必选	参数类型	说明
properties	否	Map<String, Object>	JSON Schema中表示对象元素的properties字段，可在其中定义参数，包括参数名及其类型。
type	否	String	JSON Schema中表示类型的字段，可选值为object。

表 5-11 Health 参数说明

参数	是否必选	参数类型	说明
url	是	String	健康检查URL。
protocol	否	String	健康检查接口协议。默认为http。
initial_delay_seconds	否	String	健康检查初始化延迟时间，默认60秒。

参数	是否必选	参数类型	说明
timeout_seconds	否	String	健康检查超时时间，默认60秒。
period_seconds	是	String	健康检查周期。填写大于0且小于等于2147483647的整数，单位为秒。
failure_threshold	是	String	健康检查最大失败次数。填写大于0且小于等于2147483647的整数。
check_method	是	String	健康检查方式：HTTP或者EXEC（命令行）。
command	否	String	命令行命令，以空格分隔的字符串。

表 5-12 DeploymentConstraints 参数说明

参数	是否必选	参数类型	说明
request_mode	是	String	模型类型，分为同步模式和异步模式。
accelerators	否	accelerators数组	加速卡类型，根据环境选择。参数说明请参见 表5-13 。
cpu_type	是	String	系统运行架构。
input_types	是	String数组	异步模型支持的输入数据类型。支持的类型包括OBS、VCN、URL、Restful、EdgeCamera。
output_types	是	String数组	异步模型支持的输出数据类型列表。支持的类型包括OBS、Webhook。
service_config	否	String	异步模型的配置参数，xml格式的字符串。
task_config	否	String	异步模型的作业配置参数xml格式的字符串。

表 5-13 Accelerators 参数说明

参数	是否必选	参数类型	说明
type	是	String	加速卡类型，如gpu、npu（Ascend）。
name	是	String	加速卡名称，如T4、V100、snt3、snt3p-300i、snt3p-300v。
cuda_version	是	String	驱动版本，T4、V100为cuda 10.2，snt3为C32，snt3p-300i、snt3p-300v为C8x。

响应消息

响应参数如表5-14所示。

表 5-14 响应参数

参数	参数类型	说明
model_id	String	模型ID。

示例

如下以导入名为“mnist”，版本为“1.0.0，”类型为“Custom”的模型，模型文件来源于OBS桶为例。

- 请求示例
POST https://endpoint/v1/{project_id}/models

```
{
  "model_name": "mnist",
  "model_version": "1.0.0",
  "source_location": "/xxj/custom/async/model/",
  "model_type": "Custom",
  "runtime": "swr.cn-hcs-1.hcs123.com/xxj/async-arm-custom:v1",
  "dependencies": [],
  "model_docs": [],
  "deployment_constraints": {
    "request_mode": "async",
    "cpu_type": "aarch64",
    "accelerators": [],
    "input_types": [
      "OBS",
      "URL",
      "Restful"
    ],
    "output_types": [
      "OBS"
    ]
  },
  "install_type": [
    "real-time"
  ],
  "prebuild": true,
  "initial_config": "{ \"model_algorithm\": \"unknown_algorithm\", \"metrics\": {}, \"apis\": [], \"protocol\": \"https\", \"port\": \"8080\" }",
  "arch": "aarch64",
  "cmd": "java -jar /home/mind/model/modelarts-task-mocker-0.0.1-SNAPSHOT.jar",
  "dynamic_load_mode": "Single"
}
```
- 响应示例

```
{
  "model_id": "10eb0091-887f-4839-9929-cbc884f1e20e"
}
```

状态码

状态码请参见表17-1。

5.2 查询模型列表

功能介绍

查询模型列表，可以根据不同的检索参数进行查询。

URI

GET /v1/{project_id}/models

参数说明如[表5-15](#)所示。

表 5-15 参数说明

参数	是否必选	参数类型	说明
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。

表 5-16 查询检索参数说明

参数	是否必选	参数类型	说明
model_name	否	String	模型名称，可支持模糊匹配。 说明 当模型名称包含下划线时，由于下划线涉及转义处理，因此需要在请求中增加exact_match参数，且参数值设置为true，确保能够正常执行查询操作。
model_version	否	String	模型版本。
model_status	否	String	模型状态，可根据模型状态执行查询。 模型状态： - publishing - published - failed - building - building_failed
model_type	否	String	模型类型，查询属于该类型的模型列表。model_type与not_model_type为互斥关系，不能同时存在。
not_model_type	否	String	模型类型，查询不属于该类型的模型列表。
description	否	String	描述信息，可支持模糊匹配。
offset	否	Integer	指定要查询页的索引，默认为“0”。

参数	是否必选	参数类型	说明
limit	否	Integer	指定每一页返回的最大条目数，默认为“1000”。
sort_by	否	String	指定排序字段，可选“create_at”、“model_version”、“model_size”，默认是可选“create_at”。
order	否	String	排序方式，可选“asc”或“desc”，代表递增排序及递减排序，默认是“desc”。
workspace_id	否	String	工作空间ID。获取方法请参见 查询工作空间列表 。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。

请求消息

无请求参数。

响应消息

 说明

当前环境支持的接口功能，以如下表格说明为准。当响应消息中，返回如下表格展示以外的其他参数，无需关注。

响应参数如[表5-17](#)所示。

表 5-17 参数说明

参数	参数类型	说明
total_count	Integer	不分页的情况下符合查询条件的总模型数量。
count	Integer	模型数量。
models	model结构数组	模型元数据信息，model结构如 表5-18 所示。

表 5-18 Model 结构

参数	参数类型	说明
model_id	String	模型ID。
model_name	String	模型名称。
model_version	String	模型版本。

参数	参数类型	说明
model_status	String	模型状态。
model_type	String	模型类型，取值为TensorFlow/Spark_MLlib/Scikit_Learn/XGBoost/Image/PyTorch/Custom。
deployment_constraints	Object	模型约束配置参数。
model_size	Long	模型大小，单位为字节数。
workspace_id	String	工作空间ID。获取方法请参见 查询工作空间列表 。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。
tenant	String	模型归属租户。
project	String	模型归属项目。
owner	String	模型归属用户。
create_at	Long	模型创建时间，距'1970.1.1 0:0:0 UTC'的毫秒数。
arch	String	模型运行支持的系统架构，值为"aarch64"或"x86_64"。
runtime	String	模型运行时环境。
description	String	模型描述信息。
model_source	String	模型来源。 ● custom：自定义
tunable	boolean	标识模型是否支持二次调优。 ● true：支持 ● false：不支持
market_flag	boolean	标识模型是否来自市场。 ● true：来自市场 ● false：不来自市场
publishable_flag	boolean	标识模型是否可发布至市场。 ● true：可以发布至市场 ● false：不可以发布至市场
install_type	String数组	模型部署类型，即模型支持的部署方式，如“real-time”、“batch”、“edge”。“real-time”表示在线服务，“batch”表示批量服务，“edge”表示边缘服务。
extra	String	扩展字段。

示例

如下以查询模型为例，返回模型个数及模型列表。

- 请求示例

GET https://endpoint/v1/{project_id}/models

- 响应示例

```
{
  "total_count": 1,
  "count": 1,
  "models": [
    {
      "model_name": "mnist",
      "model_version": "1.0.0",
      "model_id": "10eb0091-887f-4839-9929-cbc884f1e20e",
      "model_type": "tensorflow",
      "request_mode": "sync",
      "model_size": 5012312,
      "tenant": "6d28e85aa78b4e1a9b4bd83501bcd4a1",
      "project": "d04c10db1f264cfeb1966deff1a3527c",
      "owner": "6d28e85aa78b4e1a9b4bd83501bcd4a1",
      "create_at": 1533041553000,
      "description": "mnist model",
      "specification": {}
    }
  ]
}
```

状态码

状态码请参见[表17-1](#)。

5.3 查询模型详情

功能介绍

查询模型详情，根据模型ID查询模型的详细信息。

URI

GET /v1/{project_id}/models/{model_id}

参数说明如[表5-19](#)所示。

表 5-19 参数说明

参数	是否必选	参数类型	说明
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
model_id	是	String	模型ID。

请求消息

无请求参数。

响应消息

说明

当前环境支持的接口功能，以如下表格说明为准。当响应消息中，返回如下表格展示以外的其他参数，无需关注。

响应参数如[表5-20](#)所示。

表 5-20 参数说明

参数	参数类型	说明
model_id	String	模型ID。
model_name	String	模型名称。
model_version	String	模型版本。
create_at	Long	模型创建时间，距'1970.1.1 0:0:0 UTC'的毫秒数。
tenant	String	模型归属租户。
project	String	模型归属项目。
workspace_id	String	String 工作空间ID。获取方法请参见 查询工作空间列表 。 未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。
owner	String	模型归属用户。
source_location	String	模型所在的OBS路径或SWR镜像地址。
model_type	String	模型类型，取值为TensorFlow/Spark_MLlib/Scikit_Learn/XGBoost/Image/PyTorch/Custom。
model_size	Long	模型大小，单位为字节数。
model_status	String	模型状态。
runtime	String	模型运行时环境。
arch	String	模型运行支持的系统架构，值为“aarch64”或“x86_64”。
description	String	模型描述信息。
execution_code	String	执行代码存放的OBS地址，名称固定为“customize_service.py”。
image_address	String	模型打包后的镜像地址。

参数	参数类型	说明
env_image_address	String	选择动态加载时构建环境镜像地址。
dynamic_load_mode	String	是否支持动态加载，None表示不使用动态加载，Single表示单模型简单模式的动态加载。
input_params	params结构数组	模型的输入参数集，params结构如表5-21所示。
output_params	params结构数组	模型的输出参数集，params结构如表5-21所示。
dependencies	dependency结构数组	运行代码及模型需安装的包，dependency结构如表5-22所示。
model_metrics	String	模型精度信息。
apis	String	模型所有的apis入参出参信息（从模型预览中获取）。
model_source	String	模型来源。 custom：自定义
market_flag	boolean	标识模型是否来自市场。 - true：来自市场 - false：不来自市场
publishable_flag	boolean	标识模型是否可发布至市场。 - true：可以发布至市场 - false：不可以发布至市场
model_docs	GuideDoc结构数组	模型文档列表。GuideDoc结构如表5-25所示。
model_algorithm	String	模型算法类型，如“predict_analysis”、“object_detection”、“image_classification”。
model_labels	String数组	模型标签数组。
labels_map	Object	模型标签Map，key固定为labels，value为模型标签数组。
install_type	String数组	支持部署服务类型。
config	String	模型配置参数。
deployment_constraints	Object	异步模型约束配置参数。
cmd	String	模型启动运行命令。

参数	参数类型	说明
health	Object	模型健康检查配置，见 表5-26 。
source_copy	String	是否复制镜像。
protocol	String	容器镜像接口调用http协议。
port	Integer	容器镜像接口调用端口。

表 5-21 Params 结构

参数	参数类型	说明
url	String	API代表的URL路径。
method	String	请求方法，如post。
protocol	String	请求协议，如http。
param_name	String	参数名，不超过64个字符。
param_type	String	参数类型，取值为int/string/float/timestamp/date/file。
min	Number	当param_type为int或float时可选填，默认为空。
max	Number	当param_type为int或float时可选填，默认为空。
param_desc	String	参数描述，不超过100个字符，默认为空。

表 5-22 Dependency 结构

参数	参数类型	说明
installer	String	安装器名称。
packages	package结构数组	依赖包集合，package结构如 表5-23 所示。

表 5-23 Package 结构

参数	参数类型	说明
package_name	String	依赖包名称。
package_version	String	依赖包版本。
restraint	String	版本限制条件，取值为EXACT/ATLEAST/ATMOST。

表 5-24 Metric 参数说明

参数	参数类型	说明
f1	Double	平均数。
recall	Double	召回率。
precision	Double	精确率。
accuracy	Double	准确率。

表 5-25 GuideDoc 参数说明

参数	参数类型	说明
doc_name	String	文档名称。
doc_url	String	文档http(s)链接。

表 5-26 Health 参数说明

参数	参数类型	说明
url	String	健康检查接口路径。
protocol	String	健康检查接口协议。默认为http。
period_seconds	String	健康检查周期(秒)。
failure_threshold	String	健康检查最大失败次数。
initial_delay_seconds	String	健康检查初始化延迟时间。
timeout_seconds	String	健康检查超时时间。
command	String	命令行命令，以空格分隔的字符串。
check_method	String	健康检查方式：HTTP或者EXEC（命令行）。

表 5-27 DeploymentConstraints 参数说明

参数	参数类型	说明
request_mode	String	模型的请求模式，取值为sync、async。 • sync：同步请求模式。 • async：异步请求模式。
cpu_type	String	系统运行架构。
accelerators	accelerators 数组	最小内存。
input_types	String数组	异步模型支持的输入数据类型列表。支持的类型包括OBS、VCN、URL、Restful、EdgeCamera。
output_types	String数组	异步模型支持的输出数据类型列表。支持的类型包括OBS、Webhook。

表 5-28 Accelerators 参数说明

参数	参数类型	说明
type	String	加速卡类型，如gpu、npu（Ascend）。
name	String	加速卡名称，如T4、V100、snt3、snt3p-300i、snt3p-300v。
cuda_version	String	驱动版本，T4、V100为cuda 10.2，snt3为C32，snt3p-300i、snt3p-300v为C8x。

示例

如下以根据模型ID查询模型详情为例，返回模型详细信息。

- 请求示例
GET https://endpoint/v1/{project_id}/models/{model_id}

- 响应示例

```
{
  "model_id": "10eb0091-887f-4839-9929-cbc884f1e20e",
  "model_name": "mnist",
  "model_version": "1.0.0",
  "runtime": "tf2.1-python3.7",
  "tenant": "6d28e85aa78b4e1a9b4bd83501bcd4a1",
  "project": "d04c10db1f264cfef1966deff1a3527c",
  "owner": "6d28e85aa78b4e1a9b4bd83501bcd4a1",
  "source_location": "/models/mnist",
  "model_type": "TensorFlow",
  "model_size": 5633481,
  "model_status": "published",
  "deployment_constraints": {
    "request_mode": "async",
    "cpu_type": "x86_64",
    "accelerators": [{
      "type": "gpu",
      "name": "T4",
```

```

"cuda_version": "default"
}},
"input_types": ["OBS", "URL"],
"output_types": ["OBS", "Webhook"]
},
"execution_code": "https://testmodel.obs.xxx.com/customize_service.py",
"image_address": "100.125.5.235:20202/models/10eb0091-887f-4839-9929-cbc884f1e20e:1.0.0",
"input_params": {
  "url": "/",
  "method": "post",
  "protocol": "http",
  "param_name": "data",
  "param_type": "object",
  "param_desc": "{ \"type\": \"object\", \"properties\": { \"req_data\": { \"items\": { \"type\": \"object\", \"properties\": { \"type\": \"array\" } } } } }",
"output_params": {
  "url": "/",
  "method": "post",
  "protocol": "http",
  "param_name": "data",
  "param_type": "object",
  "param_desc": "{ \"type\": \"object\", \"properties\": { \"resp_data\": { \"type\": \"array\", \"items\": { \"type\": \"object\", \"properties\": { \"type\": \"array\" } } } } }",
"dependencies": {
  "installer": "pip",
  "cmd": "java -jar /opt/modelarts-task-mocker-0.0.1-SNAPSHOT.jar"
  "packages": {
    "package_name": "pkg1",
    "package_version": "1.0.1",
    "restraint": "ATLEAST"
  }
}},
"model_metrics": "{ \"f1\": 0.52381, \"recall\": 0.666667, \"precision\": 0.466667, \"accuracy\": 0.625 }",
"apis": "{ \"protocol\": \"http\", \"method\": \"post\", \"url\": \"/\", \"input_params\": { \"type\": \"object\", \"properties\": { \"data\": { \"type\": \"object\", \"properties\": { \"req_data\": { \"items\": { \"type\": \"object\", \"properties\": { \"type\": \"array\" } } } } } } } } }\", \"output_params\": { \"type\": \"object\", \"properties\": { \"data\": { \"type\": \"object\", \"properties\": { \"resp_data\": { \"type\": \"array\", \"items\": { \"type\": \"object\", \"properties\": { \"type\": \"array\" } } } } } } } } } }\",
"model_labels": [],
"labels_map": { \"labels\": [] },
"workspace_id": "0",
"install_type": [\"realtime\", \"batch\"],
"specification": {
  \"config\": { \"model_algorithm\": \"image_classification\", \"model_source\": \"auto\", \"tunable\": false, \"downloadable_flag\": true, \"algorithm\": \"resnet_v2_50,mobilenet_v1\", \"metrics\": { \"f1\": 0.912078373015873, \"recall\": 0.9125, \"precision\": 0.9340277777777778, \"accuracy\": 0.263250724969475, \"model_type\": \"TensorFlow\", \"runtime\": \"tf1.13-python3.6-cpu\", \"apis\": { \"protocol\": \"https\", \"url\": \"/\", \"method\": \"post\", \"request\": { \"data\": { \"type\": \"object\", \"properties\": { \"images\": { \"type\": \"file\" } } }, \"Content-type\": \"multipart/form-data\" }, \"response\": { \"data\": { \"type\": \"object\", \"required\": { \"predicted_label\", \"scores\" }, \"properties\": { \"predicted_label\": { \"type\": \"string\" }, \"scores\": { \"type\": \"array\", \"items\": { \"type\": \"array\", \"minItems\": 2, \"maxItems\": 2, \"items\": { \"type\": \"string\" }, { \"type\": \"number\" } } } } } } } } }\", \"Content-type\": \"multipart/form-data\" } } }\", \"dependencies\": { \"installer\": \"pip\", \"packages\": { \"package_name\": \"numpy\", \"package_version\": \"1.17.0\", \"restraint\": \"EXACT\" }, { \"package_name\": \"h5py\", \"package_version\": \"2.8.0\", \"restraint\": \"EXACT\" }, { \"package_name\": \"Pillow\", \"package_version\": \"5.2.0\", \"restraint\": \"EXACT\" }, { \"package_name\": \"scipy\", \"package_version\": \"1.2.1\", \"restraint\": \"EXACT\" }, { \"package_name\": \"resampy\", \"package_version\": \"0.2.1\", \"restraint\": \"EXACT\" }, { \"package_name\": \"scikit-learn\", \"package_version\": \"0.19.1\", \"restraint\": \"EXACT\" } } } } }"
}

```

状态码

状态码请参见表17-1。

5.4 删除模型

功能介绍

删除模型，根据模型ID删除指定模型，cascade取值为true时除了删除模型ID指定的模型，还会删除其他与指定模型同名不同版本的模型；默认只删除当前模型ID所对应的模型。

URI

DELETE /v1/{project_id}/models/{model_id}

参数说明如表5-29所示。

表 5-29 参数说明

参数	是否必选	参数类型	说明
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
model_id	是	String	需删除的模型ID。

表 5-30 查询检索参数说明

参数	是否必选	参数类型	说明
cascade	否	Boolean	默认为“false”，只删除当前模型ID所对应的模型。取值为“true”时除了删除模型ID指定的模型，还会删除与指定模型同名不同版本的所有模型；一次最多删除20个模型，超过的模型不删除。

请求消息

无请求参数。

响应消息

响应参数如表5-31所示。

表 5-31 参数说明

参数	参数类型	说明
delete_succes s_name_list	String数组	删除成功的模型名称列表。

参数	参数类型	说明
delete_success_list	String数组	删除成功的模型ID列表。
delete_failed_list	DeleteModelFailResult结构数组	删除失败的模型列表，详细请参见 表5-32 。

表 5-32 DeleteModelFailResult 结构

参数	参数类型	说明
model_id	String	删除失败的模型ID。
error_code	String	删除失败的错误码。
error_msg	String	删除失败的错误信息。

示例

如下以删除模型ID为“023e90be-7e2a-4169-bab4-1bc34ff0ca45”的模型及与其同名不同版本的所有模型为例。

- 请求示例
DELETE https://endpoint/v1/{project_id}/models/023e90be-7e2a-4169-bab4-1bc34ff0ca45?
cascade=true
- 响应示例

```
{
  "delete_success_list": ["fc9e88a1-0005-40b3-867e-7aee61449aeb", "f3f3ba0e-f073-454e-9e3f-14b7d786f45e"],
  "delete_failed_list": [
    {
      "model_id": "759645d9-3672-4db1-bb6d-49ed58b84e10",
      "error_code": "ModelArts.3009",
      "error_msg": "Failed to delete model, model (759645d9-3672-4db1-bb6d-49ed58b84e10) already deploy service."
    }
  ]
}
```

状态码

状态码请参见[表17-1](#)。

5.5 获取模型事件信息

功能介绍

获取导入模型的事件信息。

URI

GET /v1/{project_id}/models/{model_id}/events

表 5-33 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。
model_id	是	String	模型ID。

表 5-34 查询检索参数

参数	是否必选	参数类型	说明
status	否	String	事件的类型。当前类型有: normal、abnormal和notice。
start_time	否	Long	开始时间。如：1761189189000。
end_time	否	Long	结束时间。如：1761296414000。
offset	否	String	指定要查询页的索引，默认为0。
limit	否	String	指定每一页返回的最大条目数，默认为100。
sort_by	否	String	指定排序字段，默认为create_at。支持的排序字段有：create_at。
order	否	String	排序方式，可选asc或desc，代表递增排序及递减排序，默认是desc。

请求消息

表 5-35 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	否	String	该字段内容填为“application/json;charset=utf8”。
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应消息

表 5-36 响应 Body 参数

参数	参数类型	描述
model_name	String	模型名称。

参数	参数类型	描述
model_version	String	模型版本。
model_id	String	模型ID。
count	Integer	返回的事件条数。
total_count	Integer	当前模型事件的总数量。
events	Array of ModelEvent objects	创建模型的事件信息。

表 5-37 ModelEvent

参数	参数类型	描述
status	String	事件类型。
message	String	事件的详细信息。
create_at	Long	事件的创建时间。
url	String	事件描述详情页面的url。

示例

如下以获取服务模型信息为例。

- 请求示例
GET https://endpoint/v1/{project_id}/models/{model_id}/events

- 响应示例

```
{
  "model_name": "model-demo",
  "model_version": "0.0.1",
  "model_id": "fae776c9-c332-4b2d-8e8f-366244d7567e",
  "count": "4",
  "total_count": "4",
  "events": [
    {
      "status": "normal",
      "message": "模型导入成功。",
      "create_at": 1761189189532
    },
    {
      "status": "normal",
      "message": "源镜像大小计算完成。",
      "create_at": 1761189189530
    },
    {
      "status": "normal",
      "message": "源镜像共享成功。",
      "create_at": 1761189189527
    }
  ]
}
```

```
{
  "status": "normal",
  "message": "开始导入模型。",
  "create_at": 1761189189505
}
1,
```

状态码

状态码请参见[表17-1](#)。

6 服务管理（旧版推理）

6.1 部署服务

功能介绍

将模型部署为服务。

URI

POST /v1/{project_id}/services

参数说明如[表6-1](#)所示。

表 6-1 参数说明

参数	是否必选	参数类型	说明
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。

请求消息

请求参数如[表6-2](#)所示。

表 6-2 请求 body 参数

参数	是否必选	参数类型	说明
workspace_id	否	String	工作空间ID。获取方法请参见 查询工作空间列表 。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。

参数	是否必选	参数类型	说明
service_name	是	String	服务名称，支持1-64位可见字符（含中文），名称可以包含字母、中文、数字、中划线、下划线。 当infer_type为edge时，名称只允许英文小写字母、数字、中划线，最大长度32，英文小写字母或数字开头和结尾。
description	否	String	服务备注，默认为空，不超过100个字符。
infer_type	是	String	推理方式，取值为real-time/batch/edge。 • real-time：实时服务，支持定时停止。 • batch：批量服务，可配置批量任务运行，任务运行结束则停止。 • edge：边缘服务同步请求时支持部署到边缘资源池和边缘节点；异步请求时仅支持边缘资源池。
pool_name	否	String	专属资源池ID，默认为空，不使用专属资源池；使用专属资源池部署服务时需确保集群状态正常；配置此参数后，需要使用集群的网络配置，“vpc_id”参数不生效。当与下方real-time config或real-time distributed config中的pool_name同时配置时，优先使用real-time config或real-time distributed config中的pool_name参数。
cluster_id	否	String	边缘专属资源池ID或边缘共享资源池ID，默认为空。当infer_type为edge，且部署方式为资源池时必填。
config	是	对应infer_type的config结构数组	模型运行配置，当推理方式为batch/edge时仅支持配置一个模型；当推理方式为real-time时，可根据业务需要配置多个模型并分配权重，但多个模型的版本号不能相同。当为分布式推理服务时，仅支持部署在专属资源池。 • 当infer_type为real-time时，且为非分布式推理服务时，参见表6-3。 • 当infer_type为real-time时，且为分布式推理服务时，参见表 Real-timeDistributedConfig结构。 • 当infer_type为batch时，参见表6-5。 • 当infer_type为edge时，参见表6-6。
schedule	否	schedule结构数组	服务调度配置，仅在线服务可配置，默认不使用，服务长期运行。请参见 表6-7 。

参数	是否必选	参数类型	说明
additional_properties	否	Map<String, Object>	服务级别附加属性，便于服务管理。请参见表6-8。
tags	否	Set<TmsTag>	服务标签。
load_balancer_policy	否	String	部署在线同步服务可选设置elb转发策略。 枚举值： - ROUND_ROBIN（加权轮询算法）。 - LEAST_CONNECTIONS（加权最少连接）。 - SOURCE_IP（源IP算法）。
priority	否	Integer	抢占优先级，取值范围[1, 3]，通过设置优先级保障高优先级的业务调度。infer_type为real-time、batch时支持抢占优先级设置。
request_timeout	否	Integer	推理预测接口超时时间，单位为秒，默认取值范围0-60秒。如果不传该参数，默认超时时间为60秒。 如果需要设置更长超时时间，请参考《ModelArts 7.2.1-HCS 维护指南(for 华为云Stack 8.6.0)》>运维指南的“修改在线服务超时时间”章节。

表 6-3 Real-timeConfig 结构

参数	是否必选	参数类型	说明
model_id	是	String	模型ID。
weight	是	Integer	权重百分比，分配到此模型的流量权重，仅当infer_type为real-time时需要配置，多个权重相加必须等于100。
stream_count	否	Integer	异步服务单个实例并发分析数据流的能力。默认值为10，表示单个实例可以并发分析10个数据流。
specification	是	String	资源规格，根据所提供版本选择适合业务的规格。
custom_spec	否	Object	自定义规格。使用专属资源池部署的时候可以使用自定义规格。请参见表6-17。

参数	是否必选	参数类型	说明
instance_count	是	Integer	模型部署的实例数。实例数取值必须大于0。
envs	否	Map<String, String>	运行模型需要的环境变量键值对，可选填，默认为空。 为确保您的数据安全，在环境变量中，请勿输入敏感信息。
pool_name	否	string	专属资源池ID，默认为空，不使用专属资源池。配置此参数后，需要使用集群的网络配置，“vpc_id”参数不生效。
additional_properties	否	Map<String, Object>	模型部署附加属性，便于服务实例管理。请参见 表6-10 。
affinity	否	ServiceAffinity object	服务亲和部署。
deploy_timeout_in_seconds	否	Integer	部署实例的超时时间，单位为秒。默认值为1200秒。 • 最小值：180秒 • 最大值：18000秒
deploy_config	否	Object	异步服务专用，用于配置服务部署参数，具体结构由用户定义。

表 6-4 Real-timeDistributedConfig 结构

参数	是否必选	参数类型	说明
model_id	是	String	模型ID。
weight	是	Integer	权重百分比，分配到此模型的流量权重，仅当infer_type为real-time时需要配置，多个权重相加必须等于100。
specification	是	String	资源规格，根据所提供版本选择适合业务的规格。可被“ instance_group ”下层负载中的“cpu”和“memory”配置覆盖。
custom_spec	否	Object	自定义规格。使用专属资源池部署的时候可以使用自定义规格。可被“ instance_group ”下层负载中的“cpu”和“memory”配置覆盖。请参见 表6-17 。

参数	是否必选	参数类型	说明
distributed_inference	否	Boolean	是否为分布式推理服务，当前仅用于查询展示用。当没有配置“instance_group”参数时，默认值为false，当配置了“instance_group”参数时，默认值为true。
distributed_inference_type	否	String	分布式推理的具体类型，当前仅用于查询展示用。可选： PD-Split：PD分离部署。
inference_framework	否	String	分布式推理模型集成的推理框架，当前仅用于查询展示用。可选： MindIE：MindIE推理框架。
instance_group_count	是	Integer	分布式推理模型部署的实例组数。部署分布式推理服务时必须填。实例组数取值必须大于0。
instance_group	是	Object	分布式推理模型部署的实例组配置，用于描述单个实例组内的负载详情。部署分布式推理服务时必须填。 请参见表 InstanceGroup结构 。
envs	否	Map<String, String>	运行模型需要的环境变量键值对，可选填，默认为空。为确保您的数据安全，在环境变量中，请勿输入敏感信息。可被“ instance_group ”下层负载中的“envs”配置覆盖。
pool_name	否	string	专属资源池ID，默认为空，不使用专属资源池。配置此参数后，需要使用集群的网络配置，“vpc_id”参数不生效。
additional_properties	否	Map<String, Object>	模型部署附加属性，便于服务实例管理。请参见 表6-10 。
deploy_timeout_in_seconds	否	Integer	部署实例的超时时间，单位为秒。默认值为1200秒。 - 最小值：180秒 - 最大值：18000秒。

表 6-5 BatchConfig 结构

参数	是否必选	参数类型	说明
model_id	是	String	模型ID。

参数	是否必选	参数类型	说明
specification	是	String	资源规格。
instance_count	是	Integer	模型部署的实例数。
envs	否	Map<String, String>	运行模型需要的环境变量键值对，可选填，默认为空。 为确保您的数据安全，在环境变量中，请勿输入敏感信息。
src_type	否	String	数据来源类型，可选填ManifestFile。默认为空，表示只读取src_path目录下的文件。当取值为ManifestFile时，src_path必须为具体的manifest路径，在manifest文件中可指定多个数据路径（参考《用户指南》的“部署为批量服务”章节）。
custom_src	否	Boolean	输入数据来源是否自定义，默认值为“false”，即来源OBS。如果不从OBS输入数据，填“true”
src_path	否	String	批量任务输入数据的OBS路径，如果“custom_src”为“false”，则必填。
dest_path	否	String	批量任务输出结果的OBS路径，如果“custom_src”为“false”，则必填。
req_uri	否	String	批量任务中调用的推理接口，即模型镜像中暴露的REST接口，需要从模型的“config.json”文件中选取一个api路径用于此次推理；如使用ModelArts提供的预置推理镜像，则此接口为“/”，如果“custom_src”为“false”，则必填。
mapping_type	否	String	输入数据的映射类型，可选“file”或“csv”。 - file指每个推理请求对应到输入数据目录下的一个文件，当使用此方式时，此模型对应req_uri只能有一个输入参数且此参数的类型是file。 - 选择csv时指每个推理请求对应到csv里的一行数据，当使用此方式时，输入数据目录下的文件只能以.csv为后缀，且需配置mapping_rule参数，以表达推理请求体中各个参数对应到csv的索引。 - 如果“custom_src”为“false”，则必填。

参数	是否必选	参数类型	说明
mapping_rule	否	Map	输入参数与csv数据的映射关系，仅当“mapping_type”为“csv”以及“custom_src”为“false”时需要填写。 映射关系生成规则：映射规则来源于模型配置文件“config.json”中输入参数（input_params）。当“type”定义为“string/number/integer/boolean”基本类型时，需要配置映射规则参数，即index参数。具体示例可参见《用户指南》的“部署为批量服务”章节。 index必须是从0开始的连续正整数，当index设置不符合规则时，最终的请求将被忽略。配置映射规则后，其对应的csv数据必须以英文半角逗号分隔。
custom_spec	否	Object	自定义规格。使用专属资源池部署时可使用自定义规格。请参见表6-17。
deploy_timeout_in_seconds	否	Integer	部署单个实例的超时时间。默认值为1200秒。 • 最小值：180秒 • 最大值：18000秒
additional_properties	否	Map<String, Object>	模型部署附加属性，便于服务实例管理。请参见表6-23。

表 6-6 EdgeConfig 结构

参数	是否必选	参数类型	说明
model_id	是	String	模型ID。
specification	是	String	资源规格，当前版本可选。
envs	否	Map<String, String>	运行模型需要的环境变量键值对，可选填，默认为空。 为确保您的数据安全，在环境变量中，请勿输入敏感信息。
custom_spec	否	Object	自定义规格。使用边缘资源池部署的时候可以使用自定义规格。请参见表6-17。
instance_count	否	Integer	模型部署的实例数。实例数取值必须大于0，默认值为1。

参数	是否必选	参数类型	说明
stream_count	否	Integer	异步边缘服务单个实例并发分析数据流的能力。默认值为10，表示单个实例可以并发分析10个数据流。
additional_properties	否	Map<String, Object>	模型部署附加属性，便于服务实例管理。请参见表6-10。
volumes	否	Array of Volume objects	边缘场景挂载卷配置。
ports	否	Array of HostContainerPortMapping objects	边缘场景端口映射配置。
deploy_config	否	Object	异步服务专用，用于配置服务部署参数，具体结构由用户定义。
ief_instance_type	否	String	边缘服务对应的IEF实例类型。当前版本仅支持铂金版。当部署方式为Edge节点时，该参数必填，取值为“6”。
nodes	否	Array of String	边缘节点ID列表。仅边缘同步服务支持。当部署方式为节点时，该参数必填。

表 6-7 Schedule 结构

参数	是否必选	参数类型	说明
type	是	String	调度类型，当前仅支持取值为“stop”。
time_unit	是	String	调度时间单位，可选： • DAYS • HOURS • MINUTES
duration	是	Integer	对应时间单位的数值，比如2小时后停止，则“time_unit”填“HOURS”，“duration”填“2”。

表 6-8 服务级别 AdditionalProperties 已有属性

参数	是否必选	参数类型	说明
smn_notification	是	Object	smn消息通知结构，用于通知用户服务状态变化。请参见表6-9。
websocket_upgrade	否	Boolean	服务接口是否升级为WebSocket。部署服务时，默认值为false；更新服务配置时，默认值为上一次设置的值。 - false：不升级为WebSocket。 - true：升级为WebSocket。开启后，不支持修改。开启WebSocket时，不支持同时设置“服务流量限制”。

表 6-9 SmnNotification 结构

参数	是否必选	参数类型	说明
topic_urn	是	String	smn主题urn地址。
events	是	List<Integer>	事件ID，目前已有事件ID如下。 1: failed 3: running 7: concerning 11: pending

表 6-10 模型级别 AdditionalProperties 已有属性

参数	是否必选	参数类型	说明
persistent_volumes	是	persistentVolume数组结构	持久化存储挂载配置。请参见表6-15。
log_volume	是	logVolume数组结构	主机日志目录挂载。请参见表6-16。 仅支持使用专属资源池部署服务场景。如果用户使用公共资源池部署服务，则不支持配置该参数，否则会报错。
log_report_channels	否	数组<logReportChannel>	运行日志输出的配置列表。请参见表6-18。

参数	是否必选	参数类型	说明
customize_timeout_sec	否	Integer	部署超时时间设置。部署服务时间超过这个参数设置的值，部署服务操作会失败。
npu_type	否	String	使用的NPU加速卡类型。可以通过查询边缘池详情接口的flavors字段获取，取值包含snt3、snt3p、snt9、snt3p-vir01、snt3p-vir02、snt3p-vir04、snt3p-vir02-1c、snt3p-vir04-3c、snt3p-vir04-3c-ndvpp、snt3p-vir04-4c-dvpp。仅支持用于ModelArts Edge边缘资源池。

表 6-11 ServiceAffinity

参数	是否必选	参数类型	描述
node_affinity	否	NodeAffinity object	节点亲和的时候填入该字段。

表 6-12 NodeAffinity

参数	是否必选	参数类型	描述
mode	是	String	节点亲和的方式，required表示强亲和，服务实例只能调度到指定节点，指定节点不存在则失败。preferred表示弱亲和，服务实例倾向于调度到指定节点，指定节点不满足调度条件，则会调度到其他节点。
pool_infos	否	Array of AffinityPoolInfo objects	配置亲和策略到指定的集群，并指定集群的节点。

表 6-13 AffinityPoolInfo

参数	是否必选	参数类型	描述
pool_name	是	String	集群名称，集群名称必须在外层pool_name中。
nodes	是	Array of AffinityNodeInfo objects	亲和的节点列表信息。

表 6-14 AffinityNodeInfo

参数	是否必选	参数类型	描述
name	是	String	节点名称，实际上对应的是节点的私有ip。

表 6-15 PersistentVolume 结构

参数	是否必选	参数类型	说明
name	否	String	存储卷名称。
mount_path	是	String	存储卷在容器中的挂载路径。如：/tmp-obs-mount/。请选择全新目录，选择存量目录会覆盖存量文件。obs挂载仅开放对挂载目录文件新增、查看、修改功能不支持删除挂载目录文件对象，若需要删除文件请到obs并行文件系统中手动删除。
storage_type	是	String	存储类型，枚举值： - obs_pfs：obs并行文件系统。 - obs_bucket：obs桶（批量服务当前支持obs桶）。 - sfs_turbo：极速文件系统。
source_addresses	是	String	源地址，需要满足obs校验格式。与model_manager等其他模块校验保持一致，obs桶和obs并行文件系统支持传子路径，如/obs_bucket_name/sub_path/，会把桶下的子路径挂载至容器中。

表 6-16 LogVolume 结构

参数	是否必选	参数类型	说明
host_path	是	String	主机上要映射的日志路径。
mount_path	是	String	容器中的日志路径。

表 6-17 CustomSpec 自定义规格结构

参数	是否必选	参数类型	说明
cpu	是	Float	CPU核数，支持配置小数，输入值不能小于0.01（最多支持2位小数，小数点后第3位做四舍五入处理）。
memory	是	Integer	内存，单位为MB，仅支持整数。
gpu_p4	否	Float	GPU个数，可选，默认不使用，支持配置小数，输入值不能小于0（最多支持2位小数，小数点后第3位做四舍五入处理）。
ascend_a310	否	Integer	Ascend芯片个数，可选，默认不使用，不支持与gpu_p4同时配置。

表 6-18 LogReportChannel 日志输出配置结构

参数	是否必选	参数类型	说明
type	是	String	运行日志输出类型，目前仅支持云日志服务 LTS。

表 6-19 TmsTag

参数	是否必选	参数类型	描述
key	是	String	TMS标签的key。
value	是	String	TMS标签的value。

表 6-20 Volume

参数	是否必选	参数类型	描述
destination	是	String	卷挂载路径，必须是合法的路径。
server	否	String	nfs服务地址，source为nfs为必填。
name	是	String	卷名称，小写字母或数字，最长63个字符。

参数	是否必选	参数类型	描述
read_only	否	Boolean	读写权限，configMap和secret类型只支持读权限。
source	否	String	卷来源，type为hostPath时输入路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字；secret时输入secret名称，configMap时输入configMap名称，emptyDir时输入disk或memory。
type	是	String	卷的类型，支持nfs、configMap、secret、emptyDir、hostPath。

表 6-21 HostContainerPortMapping

参数	是否必选	参数类型	描述
container_port	是	Integer	容器端口、1到65535之间的整数。
host_ip	是	String	对应主机网卡地址，形如192.168.0.1。
host_port	否	Integer	主机端口、1到65535之间的整数，与主机端口范围二选一。
host_port_range	否	表6-22 object	主机端口范围，在范围内为应用实例自动分配主机端口；与主机端口参数二选一。

表 6-22 HostPortRange

参数	是否必选	参数类型	描述
max_port	是	Integer	主机端口上限值、1到65535之间的整数；max_port需大于min_port。
min_port	是	Integer	主机端口下限值、1到65535之间的整数。

表 6-23 批量服务模型级别 AdditionalProperties 已有属性

参数	是否必选	参数类型	说明
persistent_volumes	是	persistentVolume数组结构	持久化存储挂载配置。请参见 表6-15 。

表 6-24 InstanceGroup 结构

参数	是否必选	参数类型	说明
head	是	Object	head负载的详细配置。请参见 表 head结构 。
workers	否	Array of worker	worker负载的详细配置。请参见 表 worker结构 。

表 6-25 head 结构

参数	是否必选	参数类型	说明
instance_count	是	Integer	head负载部署的实例数。实例数取值为1~50之间的整数。
cpu	否	Float	head负载内单个实例使用的cpu数量，默认为空。必须和“memory”字段搭配使用。不配置该字段时，head负载内单个实例占用资源以“ Real-timeDistributedConfig ”中的“specification”和“custom_spec”为准。配置该字段时，会在head负载中完全忽略“ Real-timeDistributedConfig ”中的“specification”和“custom_spec”配置。
memory	否	Integer	head负载内单个实例使用的内存大小，默认为空。必须和“cpu”字段搭配使用。不配置该字段时，head负载内单个实例占用资源以“ Real-timeDistributedConfig ”中的“specification”和“custom_spec”为准。配置该字段时，会在head负载中完全忽略“ Real-timeDistributedConfig ”中的“specification”和“custom_spec”配置。

参数	是否必选	参数类型	说明
recovery_type	否	String	head负载内Pod出现故障时的恢复策略，默认值为Instance。可选： - Instance：当head负载内实例故障时，判定其它实例仍然可以正常工作，仅重新拉起该故障实例。 - InstanceGroup：当head负载内实例故障时，判定故障实例所在的整个实例组不可用，销毁当前实例组并完整地重新拉起整个实例组。
envs	否	Map<String, String>	head负载使用的环境变量键值对，默认为空。为确保您的数据安全，在环境变量中，请勿输入敏感信息。不配置该字段时，head负载使用“ Real-timeDistributedConfig ”中的“envs”作为环境变量。配置该字段时，会在head负载中完全忽略“ Real-timeDistributedConfig ”中的“envs”配置。

表 6-26 worker 结构

参数	是否必选	参数类型	说明
instance_count	是	Integer	当前worker负载部署的实例数。实例数取值为1到50之间的整数。
cpu	否	Float	当前worker负载内单个实例使用的cpu数量，默认为空。必须和“memory”字段搭配使用。不配置该字段时，当前worker负载内单个实例占用资源以“ Real-timeDistributedConfig ”中的“specification”和“custom_spec”为准。配置该字段时，会在当前worker负载中完全忽略“ Real-timeDistributedConfig ”中的“specification”和“custom_spec”配置。

参数	是否必选	参数类型	说明
memory	否	Integer	当前worker负载内单个实例使用的内存大小，默认为空。必须和“cpu”字段搭配使用。不配置该字段时，当前worker负载内单个实例占用资源以“ Real-timeDistributedConfig ”中的“specification”和“custom_spec”为准。配置该字段时，会在当前worker负载中完全忽略“ Real-timeDistributedConfig ”中的“specification”和“custom_spec”配置。
recovery_type	否	String	当前worker负载内Pod出现故障时的恢复策略，默认值为Instance。可选： - Instance：当前worker负载内实例故障时，判定其它实例仍然可以正常工作，仅重新拉起该故障实例。 - InstanceGroup：当前worker负载内实例故障时，判定故障实例所在的整个实例组不可用，销毁当前实例组并完整地重新拉起整个实例组。
envs	否	Map<String, String>	当前worker负载使用的环境变量键值对，默认为空。为确保您的数据安全，在环境变量中，请勿输入敏感信息。不配置该字段时，当前worker负载使用“ Real-timeDistributedConfig ”中的“envs”作为环境变量。配置该字段时，会在当前worker负载中完全忽略“ Real-timeDistributedConfig ”中的“envs”配置。
port	否	Integer	当前worker负载内实例监听的端口，默认为空。取值为1到65535之间的整数。不配置该字段时，以模型导入时配置的端口为准。配置该字段时，则以当前配置值为准。

响应消息

响应参数如[表6-27](#)所示。

表 6-27 响应参数

参数	参数类型	说明
service_id	String	服务ID。

参数	参数类型	说明
resource_ids	Array of strings	资源id数组，服务对应的模型生成的资源ID。

示例

如下为部署不同类型服务的样例。

- 请求示例，创建在线服务。
POST https://endpoint/v1/{project_id}/services

```
{
  "service_name": "mnist",
  "description": "mnist service",
  "infer_type": "real-time",
  "config": [
    {
      "model_id": "xxxmodel-idxxx",
      "weight": "100",
      "specification": "modelarts.vm.cpu.2u",
      "instance_count": 1
    }
  ]
}
```
- 请求示例，创建在线服务且配置多版本分流

```
{
  "service_name": "mnist",
  "description": "mnist service",
  "infer_type": "real-time",
  "config": [
    {
      "model_id": "xxxmodel-idxxx",
      "weight": "70",
      "specification": "modelarts.vm.cpu.2u",
      "instance_count": 1,
      "envs": {
        "model_name": "mxnet-model-1",
        "load_epoch": "0"
      }
    },
    {
      "model_id": "xxxxxx",
      "weight": "30",
      "specification": "modelarts.vm.cpu.2u",
      "instance_count": 1
    }
  ]
}
```
- 请求示例，创建专属资源池自定义规格在线服务样例。

```
{
  "service_name": "realtime-demo",
  "description": "",
  "infer_type": "real-time",
  "pool_name": "8abf68a969c3cb3a0169c4acb24b0000",
  "config": [{
    "model_id": "eb6a4a8c-5713-4a27-b8ed-c7e694499af5",
    "weight": "100",
    "pool_name": "8abf68a969c3cb3a0169c4acb24b0000",
    "specification": "custom",
    "custom_spec": {
      "cpu": 1.5,
      "memory": 7500,

```

```
    "gpu_p4": 0
  },
  "instance_count": 1
}]
}
```

- 请求示例，创建在线服务设置自动停止。

```
{
  "service_name": "service-demo",
  "description": "demo",
  "infer_type": "real-time",
  "config": [{
    "model_id": "xxxmodel-idxxx",
    "weight": "100",
    "specification": "modelarts.vm.cpu.2u",
    "instance_count": 1
  }],
  "schedule": [{
    "type": "stop",
    "time_unit": "HOURS",
    "duration": 1
  }]
}
```

- 请求示例，创建基于MindIE推理框架的PD分离服务。

```
POST https://endpoint/v1/{project_id}/services
{
  "service_name": "service-pd-split-demo",
  "description": "pd split service",
  "infer_type": "real-time",
  "pool_name": "8abf68a969c3cb3a0169c4acb24b0000",
  "config": [
    {
      "model_id": "xxxmodel-idxxx",
      "weight": "100",
      "specification": "custom",
      "custom_spec": {
        "cpu": 10.0,
        "memory": 153600,
        "ascend_a310": 1
      },
      "pool_name": "8abf68a969c3cb3a0169c4acb24b0000",
      "distributed_inference": true,
      "distributed_inference_type": "PD-Split",
      "inference_framework": "MindIE",
      "instance_group_count": 1,
      "instance_group": {
        "head": {
          "instance_count": 1,
          "cpu": 4,
          "memory": 8192,
          "recovery_type": "InstanceGroup"
        },
        "workers": [
          {
            "instance_count": 1,
            "cpu": 2,
            "memory": 4096,
            "recovery_type": "InstanceGroup"
          },
          {
            "instance_count": 2,
            "recovery_type": "InstanceGroup"
          }
        ]
      }
    }
  ]
}
```

- 请求示例，创建批量服务且输入数据映射方式为“file”。

```
{
  "service_name": "batchservicetest",
  "description": "",
  "infer_type": "batch",
  "pool_name": "8abf68a969c3cb3a0169c4acb24b****",
  "config": [{
    "model_id": "598b913a-af3e-41ba-a1b5-bf065320f1e2",
    "specification": "modelarts.vm.cpu.2u",
    "instance_count": 1,
    "src_path": "https://infers-data.obs.xxx.com/xgboosterdata/",
    "dest_path": "https://infers-data.obs.xxx.com/output/",
    "req_uri": "/",
    "mapping_type": "file"
  }]
}
```

- 请求示例，创建批量服务且输入数据映射方式为“csv”。

```
{
  "service_name": "batchservicetest",
  "description": "",
  "infer_type": "batch",
  "config": [{
    "model_id": "598b913a-af3e-41ba-a1b5-bf065320f1e2",
    "specification": "modelarts.vm.cpu.2u",
    "instance_count": 1,
    "src_path": "https://infers-data.obs.xxx.com/xgboosterdata/batch.manifest",
    "dest_path": "https://infers-data.obs.xxx.com/output/",
    "req_uri": "/",
    "mapping_type": "csv",
    "mapping_rule": {
      "type": "object",
      "properties": {
        "data": {
          "type": "object",
          "properties": {
            "req_data": {
              "type": "array",
              "items": [{
                "type": "object",
                "properties": {
                  "input5": {
                    "type": "number",
                    "index": 0
                  },
                  "input4": {
                    "type": "number",
                    "index": 1
                  },
                  "input3": {
                    "type": "number",
                    "index": 2
                  },
                  "input2": {
                    "type": "number",
                    "index": 3
                  },
                  "input1": {
                    "type": "number",
                    "index": 4
                  }
                }
              }
            }
          }
        }
      }
    }
  }]
}
```

```
}}  
}
```

示例中“mapping_rule”描述的推理请求体格式为：

```
{  
  "data": {  
    "req_data": [{  
      "input1": 1,  
      "input2": 2,  
      "input3": 3,  
      "input4": 4,  
      "input5": 5  
    }]  
  }  
}
```

- 请求示例，创建边缘服务样例。

```
{  
  "service_name": "service-edge-demo",  
  "description": "",  
  "infer_type": "edge",  
  "config": [  
    {  
      "additional_properties": {  
  
      },  
      "model_id": "823d81b0-d287-4c51-a846-b59bb0cfb6b7",  
      "specification": "custom",  
      "instance_count": 1,  
      "envs": {  
  
      },  
      "custom_spec": {  
        "cpu": 1.5,  
        "memory": 512,  
        "gpu_p4": 0  
      }  
    }  
  ],  
  "additional_properties": {  
  
  },  
  "cluster_id": "c715daacbc244b8ca293da6d46aa092b"  
}
```

- 响应示例

```
{  
  "service_id": "10eb0091-887f-4839-9929-cbc884f1e20e",  
  "resource_ids": [ "INF-f878991839647358@1598319442708" ]  
}
```

状态码

状态码请参见[表17-1](#)。

6.2 查询服务列表

功能介绍

查询模型服务列表。

URI

GET /v1/{project_id}/services

参数说明如表6-28所示。

表 6-28 参数说明

参数	是否必选	参数类型	说明
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。

表 6-29 查询检索参数说明

参数	是否必选	参数类型	说明
service_id	否	String	服务ID。
service_name	否	String	服务名称。
model_id	否	String	模型ID。
workspace_id	否	String	工作空间ID。获取方法请参见 查询工作空间列表 。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。
pool_name	否	String	专属资源池ID，默认为空。
cluster_id	否	String	边缘专属资源池ID或边缘共享资源池ID，默认为空。
infer_type	否	String	推理方式，取值为real-time/batch/edge，默认不过滤推理方式。
status	否	String	服务状态，默认不过滤服务状态。可根据服务状态查询，取值为running、deploying、concerning、failed、stopped、finished。可通过“,”连接多个服务状态，也可传入多个status参数。
offset	否	Integer	分页列表的起始页，默认为“0”。
limit	否	Integer	指定每一页返回的最大条目数，默认为“1000”。
sort_by	否	String	指定排序字段，可选“publish_at”、“service_name”，默认是“publish_at”。
order	否	String	排序方式，可选“asc”或“desc”，代表递增排序及递减排序，默认是“desc”。
request_mode	否	String	请求模式，默认为空，可选同步请求“sync”或异步请求“async”

请求消息

无请求参数。

响应消息

 说明

当前环境支持的接口功能，以如下表格说明为准。当响应消息中，返回如下表格展示以外的其他参数，无需关注。

响应参数如[表6-30](#)所示。

表 6-30 参数说明

参数	参数类型	说明
total_count	Integer	不分页的情况下符合查询条件的总服务数量。
count	Integer	当前查询结果的服务数量，不设置offset、limit查询参数时，count与total_count相同。
services	service结构数组	查询到的服务集合，service结构如 表6-31 所示。

表 6-31 Service 结构

参数	参数类型	说明
service_id	String	服务ID。
service_name	String	服务名称。
description	String	服务描述。当描述为空时不返回。
tenant	String	服务归属租户。
project	String	服务归属项目。
owner	String	服务归属用户。
publish_at	Long	服务最新的发布时间，距'1970.1.1 0:0:0 UTC'的毫秒数。
workspace_id	String	工作空间ID。获取方法请参见 查询工作空间列表 。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。
infer_type	String	推理方式，取值为real-time/batch/edge。
request_mode	String	模型的请求模式。默认同步请求模式不返回值，异步请求模式返回async。
workspace_id	String	工作空间ID，不填为主账号/子账号的默认工作空间。

参数	参数类型	说明
status	String	服务状态，取值为running/deploying/concerning/failed/stopped/finished。 • running：运行中，服务正常运行。 • deploying：部署中，服务正在部署，调度资源部署等。 • concerning：告警，后端实例异常（例如多实例的情况下，有的实例正常，有的实例异常，则正常的实例会产生资源消耗，此时服务状态是concerning）。 • failed：失败，服务部署失败，失败原因可以查看事件和日志标签页。 • stopped：停止。 • finished：只有批量服务会有这个状态，表示运行完成。 • waiting：资源排队中（IEF状态，ModelArts Edge无此状态） • pending：待启动（IEF状态，ModelArts Edge无此状态） • stopping：停止中（IEF状态，ModelArts Edge无此状态） • deleting：删除中（IEF状态，ModelArts Edge无此状态）
start_time	Number	批量服务启动时间，距'1970.1.1 0:0:0 UTC'的毫秒数；仅当服务是批量服务时返回。
finished_time	Number	批量服务完成时间，距'1970.1.1 0:0:0 UTC'的毫秒数；仅当服务是批量服务时返回。
progress	integer	部署进度，当状态是deploying时返回。
invocation_times	Long	服务的总调用次数。
failed_times	Long	服务调用失败次数。
schedule	schedule结构数组	服务调度配置。请参见 表6-32 。
due_time	number	在线服务自动停止时间，距'1970.1.1 0:0:0 UTC'的毫秒数。
operation_time	number	当前请求的操作时间。
is_opened_sample_collection	String	是否打开数据采集，默认“false”。
transition_at	number	服务状态转化时间。
additional_properties	Map<String, Object>	服务附加属性，未配置则不返回。

表 6-32 Schedule 结构

参数	是否必选	参数类型	说明
type	是	String	调度类型，当前仅支持取值为“stop”。
time_unit	是	String	调度时间单位，可选： - DAYS - HOURS - MINUTES
duration	是	Integer	对应时间单位的数值，比如2小时后停止，则“time_unit”填“HOURS”，“duration”填“2”。

示例

如下以查询服务信息为例，返回服务个数及服务列表。

- 请求示例
GET https://endpoint/v1/{project_id}/services
- 响应示例

```
{
  "count": 2,
  "total_count": 2,
  "services": [
    {
      "service_id": "8da30673-908d-45a7-90a4-65f98e69fc34",
      "service_name": "service-demo",
      "tenant": "xxx",
      "project": "xxx",
      "owner": "xxx",
      "publish_at": 1584622900171,
      "infer_type": "real-time",
      "status": "stopped",
      "progress": 100,
      "invocation_times": 0,
      "failed_times": 0,

      "schedule": [
        {
          "type": "stop",
          "duration": 1,
          "time_unit": "HOURS"
        }
      ],
      "due_time": 1584626633902,
      "operation_time": 1586250354961,
      "is_opened_sample_collection": false,
      "additional_properties": {},

      "transition_at": 1584623163721,
      "request_mode": "async"
    }
  ],
}
```

```
{
  "service_id": "912f1a4a-5962-455c-b11c-5fdf06045cb3",
  "service_name": "service-demo2",
  "tenant": "xxx",
  "project": "xxx",
  "owner": "xxx",
  "publish_at": 1584618274410,
  "infer_type": "real-time",
  "status": "stopped",
  "progress": 100,
  "invocation_times": 0,
  "failed_times": 0,
  "schedule": [
    {
      "type": "stop",
      "duration": 1,
      "time_unit": "HOURS"
    }
  ],
  "due_time": 1584622027673,
  "operation_time": 1586250354961,
  "is_opened_sample_collection": false,
  "additional_properties": {},

  "transition_at": 1584618498528,
  "request_mode": "async"
}
```

状态码

状态码请参见[表17-1](#)。

6.3 查询服务详情

功能介绍

查询模型服务详情，根据服务ID查询服务详情。

URI

GET /v1/{project_id}/services/{service_id}

参数说明如[表6-33](#)所示。

表 6-33 参数说明

参数	是否必选	参数类型	说明
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。

请求消息

无请求参数。

响应消息

说明

当前环境支持的接口功能，以如下表格说明为准。当响应消息中，返回如下表格展示以外的其他参数，无需关注。

响应参数如[表6-34](#)所示。

表 6-34 参数说明

参数	参数类型	说明
service_id	String	服务ID。
service_name	String	服务名称。
description	String	服务描述。当描述为空时不返回。
tenant	String	服务归属租户。
project	String	服务归属项目。
owner	String	服务归属用户。
publish_at	Number	服务最新的发布时间，距'1970.1.1 0:0:0 UTC'的毫秒数。
infer_type	String	推理方式，取值为real-time/batch/edge。
workspace_id	String	工作空间ID。获取方法请参见 查询工作空间列表 。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。
pool_name	String	在线/批量/边缘服务使用的专属资源池ID，仅当配置专属资源池时返回。
cluster_id	String	边缘专属资源池ID或边缘共享资源池ID。
status	String	服务状态，取值为running/deploying/concerning/failed/stopped/finished。
progress	Integer	部署进度，当状态是deploying时返回。
error_msg	String	错误信息，当status为failed时，返回这个信息注明失败原因。
config	不同infer_type的config结构数组	服务配置（如果是共享过来的服务，只返回model_id、model_name、model_version）。 - 当infer_type为real-time时参见表6-35。 - 当infer_type为batch时参见表6-36。 - 当infer_type为edge时参见表6-37。

参数	参数类型	说明
access_address	String	推理请求的访问地址，当infer_type为real-time时会返回此值。
invocation_times	Number	服务的总调用次数。
failed_times	Number	服务调用失败次数。
schedule	schedule结构数组	服务调度配置，未配置则不返回。请参见表6-39。
update_time	Number	服务当前运行所用配置的更新时间，距'1970.1.1 0:0:0 UTC'的毫秒数。
due_time	number	在线服务自动停止时间，距'1970.1.1 0:0:0 UTC'的毫秒数。
operation_time	number	当前请求的操作时间。
transition_at	number	服务状态转化时间。
additional_properties	Map<String, Object>	服务附加属性。
request_mode	String	模型的请求模式。默认同步请求模式不返回值，异步请求模式返回async。
tags	Set<TmsTag>	服务标签。
load_balancer_policy	String	部署在线同步服务设置的elb转发策略。 • ROUND_ROBIN（加权轮询算法） • LEAST_CONNECTIONS（加权最少连接） • SOURCE_IP（源ip算法）
priority	Integer	部署服务设置的优先级。
request_timeout	Integer	推理预测接口超时时间。

表 6-35 Real-timeConfig 结构

参数	参数类型	说明
model_id	String	模型ID。
model_name	String	模型名称。
model_version	String	模型版本。

参数	参数类型	说明
status	String	模型实例运行状态。取值为如下。 • ready: 已就绪（所有实例已启动） • concerning: 部分就绪（部分实例已启动、部分实例未启动） • notReady: 未就绪（所有实例都没启动）
weight	Integer	权重，分配到此模型的流量权重。
specification	String	资源规格，请根据实际环境进行设置。
custom_spec	Object	自定义规格。详情参见 表6-40 。
envs	Map<String, String>	运行模型需要的环境变量键值对，可选填。为确保您的数据安全，在环境变量中，请勿输入敏感信息。
distributed_inference	Boolean	是否为分布式推理服务。仅分布式推理服务返回该字段。
distributed_inference_type	String	分布式推理的具体类型。仅分布式推理服务返回该字段。取值： • PD-Split: PD分离部署。
inference_framework	String	分布式推理模型集成的推理框架。仅分布式推理服务返回该字段。取值： • MindIE: MindIE推理框架。
instance_count	Integer	模型部署的实例数。
instance_group_count	Integer	分布式推理模型部署的实例组数。仅分布式推理服务返回该字段。
instance_group	Object	分布式推理模型部署的实例组配置，描述单个实例组内的负载详情。仅分布式推理服务返回该字段。详情参见 表 InstanceGroup结构 。
running_instance_count	Integer	服务运行中的实例数。
pool_name	String	服务实例使用的专属资源池ID，仅当配置专属资源池时返回。
support_debug	Boolean	模型是否支持在线调试。
update_time	Number	服务当前运行所用配置的更新时间，距'1970.1.1 0:0:0 UTC'的毫秒数。
create_time	Number	服务当前运行所用配置的创建时间，距'1970.1.1 0:0:0 UTC'的毫秒数。

参数	参数类型	说明
cluster_inner_access_address	String	服务的集群内访问地址。
additional_properties	Map<String, Object>	模型部署附加属性。
affinity	ServiceAffinity object	服务亲和信息。
deploy_timeout_in_seconds	Integer	部署实例的超时时间，单位为秒。默认值为1200秒。
deploy_config	Object	异步服务专用，由用户自定义的部署配置。

表 6-36 BatchConfig 结构

参数	参数类型	说明
model_id	String	模型ID。
model_name	String	模型名称。
model_version	String	模型版本。
specification	String	资源规格，请根据实际环境进行设置。
custom_spec	Object	自定义规格。详情参见 表6-40 。
envs	Map<String, String>	运行模型需要的环境变量键值对，可选填。 为确保您的数据安全，在环境变量中，请勿输入敏感信息。
instance_count	Integer	模型部署的实例数。
running_instance_count	Integer	服务运行中的实例数。
src_type	String	数据来源类型，仅当指定为ManifestFile时返回。
src_path	String	批量任务输入数据的OBS路径。
dest_path	String	批量任务输出结果的OBS路径。
custom_src	Boolean	输入来源是否是自定义。
req_uri	String	批量任务中调用的推理路径。
mapping_type	String	输入数据的映射类型，取值为file或csv。

参数	参数类型	说明
mapping_rule	Map	输入参数与csv数据的映射关系，仅当mapping_type为csv时会返回。
task_id	String	任务ID。
cluster_inner_access_address	String	服务的集群内访问地址。
update_time	Number	服务当前运行所用配置的更新时间，距'1970.1.1 0:0:0 UTC'的毫秒数。
create_time	Number	服务当前运行所用配置的创建时间，距'1970.1.1 0:0:0 UTC'的毫秒数。
start_time	Number	任务启动时间，距'1970.1.1 0:0:0 UTC'的毫秒数；任务未开始时不返回。
finished_time	Number	任务完成时间，距'1970.1.1 0:0:0 UTC'的毫秒数；任务未结束时不返回。
deploy_timeout_in_seconds	Integer	部署实例的超时时间，单位为秒。默认值为1200秒。
additional_properties	Map<String, Object>	模型部署附加属性。

表 6-37 EdgeConfig 结构

参数	参数类型	说明
model_id	String	模型ID。
model_name	String	模型名称。
model_version	String	模型版本。
weight	Integer	权重，分配到此模型的流量权重。
scaling	Boolean	是否扩容。
specification	String	资源规格，请根据实际环境进行设置。
custom_spec	Object	自定义规格。详情参见 表6-40 。
instance_count	Integer	模型部署的实例数。
running_instance_count	Integer	服务运行中的实例数。
custom_src	Boolean	输入来源是否是自定义。
ief_instance_id	String	IEF铂金版实例ID，仅IEF边缘池部署的服务会返回此参数。

参数	参数类型	说明
specification_details	specification_details结构	规格具体对应的数据内容。请参见表6-41。
envs	Map<String, String>	运行模型需要的环境变量键值对。为确保您的数据安全，在环境变量中，请勿输入敏感信息。
nodes	node结构数组	节点信息。详情参见表6-38。
ports	Array of HostContainerPortMapping objects	边缘场景端口映射配置。
volumes	Array of Volume objects	边缘场景挂载卷配置。
update_time	Number	服务当前运行所用配置的更新时间，距'1970.1.1 0:0:0 UTC'的毫秒数。
create_time	Number	服务当前运行所用配置的创建时间，距'1970.1.1 0:0:0 UTC'的毫秒数。
deploy_timeout_in_seconds	Integer	部署实例的超时时间，单位为秒。默认值为1200秒。

表 6-38 Node 结构

参数	参数类型	说明
id	String	节点ID。
name	String	节点名称。
instance_id	String	实例ID。仅IEF边缘服务返回此参数。
instance_status	String	模型实例在该节点的运行状态，取值为running/stopped/notReady/failed。
message	String	状态详情，比如，容器启动异常的原因、模型的下载进度等信息。
predict_url	String	在该节点的预测URL。
node_label	String	节点标签。
description	String	描述。
host_name	String	节点主机名。
os_name	String	节点操作系统名称。
os_type	String	节点操作系统类型。
os_version	String	节点操作系统版本。

参数	参数类型	说明
arch	String	节点架构。
cpu	Integer	CPU核心数。
memory	Integer	内存数(MB)。
gpu_num	Integer	gpu个数。
enable_gpu	String	是否开启GPU。
host_ips	String数组	节点主机IP。
deployment_num	Integer	部署在该节点上的应用实例个数。
state	String	主机状态，取值如下。 • RUNNING：运行中 • FAIL：故障 • UNCONNECTED：未连接
created_at	String	创建时间，格式为YYYY-MM-DDThh:mm:ss，UTC时间。
updated_at	String	更新时间，格式为YYYY-MM-DDThh:mm:ss，UTC时间。

表 6-39 Schedule 结构

参数	参数类型	说明
type	String	调度类型，当前仅支持取值为“stop”。
time_unit	String	调度时间单位，可选： • DAYS • HOURS • MINUTES
duration	Integer	对应时间单位的数值，比如2小时后停止，则“time_unit”填“HOURS”，“duration”填“2”。

表 6-40 CustomSpec 自定义规格结构

参数	参数类型	说明
cpu	Float	CPU数量。
category	String	规格类型，例如：CPU、GPU、NPU。
memory	Integer	内存数量，单位MB。

参数	参数类型	说明
gpu_p4	Float	GPU数量。
ascend_a310	Integer	Ascend芯片个数。
cpu_info	Object	服务规格对应的具体cpu资源占用。请参见表6-42。
memory_info	Object	服务规格对应的具体内存资源占用。请参见表6-43。
npu_info	Object	服务规格对应的具体npu资源占用。请参见表6-44。
gpu_info	Object	服务规格对应的具体gpu资源占用。请参见表6-45。

表 6-41 SpecificationDetails 结构

参数	参数类型	说明
category	string	加速卡类型
cpu_info	cpu_info结构	服务规格对应的具体cpu资源占用。请参见表6-42。
memory_info	memory_info结构	服务规格对应的具体内存资源占用。请参见表6-43。
gpu_info	gpu_info结构	服务规格对应的具体gpu资源占用。请参见表6-44。
npu_info	npu_info结构	服务规格对应的具体npu资源占用。请参见表6-45。
display_en	String	规格的英文描述。
display_cn	String	规格的中文描述。

表 6-42 CpuInfo 结构

参数	参数类型	说明
cpu	int	cpu核数
arch	string	系统架构

表 6-43 MemoryInfo 结构

参数	参数类型	说明
memory	int	内存数量
unit	int	内存单位

表 6-44 GpuInfo 结构

参数	参数类型	说明
gpu	int	gpu核数
unit	string	gpu单位
memory	int	内存数量

表 6-45 NpuInfo 结构

参数	参数类型	说明
npu	int	npu核数
unit	string	npu单位
memory	int	内存数量

表 6-46 TmsTag 结构

参数	参数类型	说明
key	string	标签key
value	string	标签value

表 6-47 Volume

参数	是否必选	参数类型	描述
destination	是	String	卷挂载路径，必须是合法的路径
server	否	String	nfs服务地址，source为nfs为必填
name	是	String	卷名称，小写字母或数字，最长63个字符

参数	是否必选	参数类型	描述
read_only	否	Boolean	读写权限，configMap和secret类型只支持读权限
source	否	String	卷来源，type为hostPath时输入路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字；secret时输入secret名称，configMap时输入configMap名称，emptyDir时输入disk或memory
type	是	String	卷的类型，支持nfs、configMap、secret、emptyDir、hostPath

表 6-48 HostContainerPortMapping

参数	是否必选	参数类型	描述
container_port	是	Integer	容器端口、1到65535之间的整数
host_ip	是	String	对应主机网卡地址，形如192.168.0.1
host_port	否	Integer	主机端口、1到65535之间的整数，与主机端口范围二选一
host_port_range	否	表6-49 object	主机端口范围，在范围内为应用实例自动分配主机端口；与主机端口参数二选一

表 6-49 HostPortRange

参数	是否必选	参数类型	描述
max_port	是	Integer	主机端口上限值、1到65535之间的整数；max_port需大于min_port
min_port	是	Integer	主机端口下限值、1到65535之间的整数

表 6-50 InstanceGroup 结构

参数	参数类型	说明
head	Object	head负载的详细配置。请参见表 head结构 。
workers	Array of worker	worker负载的详细配置。请参见表 worker结构 。

表 6-51 head 结构

参数	参数类型	说明
instance_count	Integer	head负载部署的实例数。
cpu	Float	用户配置的head负载内单个实例使用的cpu数量。仅配置后才会返回。
memory	Integer	用户配置的head负载内单个实例使用的内存大小。仅配置后才会返回。
recovery_type	String	head负载内Pod出现故障时的恢复策略。取值： - Instance：当head负载内实例故障时，判定其它实例仍然可以正常工作，仅重新拉起该故障实例。 - InstanceGroup：当head负载内实例故障时，判定故障实例所在的整个实例组不可用，销毁当前实例组并完整地重新拉起整个实例组。
envs	Map<String, String>	用户配置的head负载使用的环境变量键值对。仅配置后才会返回。

表 6-52 worker 结构

参数	参数类型	说明
instance_count	Integer	当前worker负载部署的实例数。
cpu	Float	用户配置的当前worker负载内单个实例使用的cpu数量。仅配置后才会返回。
memory	Integer	用户配置的当前worker负载内单个实例使用的内存大小。仅配置后才会返回。

参数	参数类型	说明
recovery_type	String	当前worker负载内Pod出现故障时的恢复策略。取值： - Instance：当前worker负载内实例故障时，判定其它实例仍然可以正常工作，仅重新拉起该故障实例。 - InstanceGroup：当前worker负载内实例故障时，判定故障实例所在的整个实例组不可用，销毁当前实例组并完整地重新拉起整个实例组。
envs	Map<String, String>	用户配置的当前worker负载使用的环境变量键值对。仅配置后才会返回。
port	Integer	用户配置的当前worker负载内实例监听的端口。仅配置后才会返回。

表 6-53 ServiceAffinity

参数	参数类型	描述
node_affinity	NodeAffinity object	节点亲和的时候填入该字段。

表 6-54 NodeAffinity

参数	参数类型	描述
mode	String	节点亲和的方式，required表示强亲和，服务实例只能调度到指定节点，指定节点不存在则失败。preferred表示弱亲和，服务实例倾向于调度到指定节点，指定节点不满足调度条件，则会调度到其他节点。
pool_infos	Array of AffinityPoolInfo objects	配置亲和策略到指定的集群，并指定集群的节点。

表 6-55 AffinityPoolInfo

参数	参数类型	描述
pool_name	String	集群名称，集群名称必须在外层pool_name中。
nodes	Array of AffinityNodeInfo objects	亲和的节点列表信息。

表 6-56 AffinityNodeInfo

参数	参数类型	描述
name	String	节点名称，实际上对应的是节点的私有ip。

示例

如下以根据服务ID查询“real-time”类型的服务详情为例。

- 请求示例
GET https://endpoint/v1/{project_id}/services/{service_id}
- 响应示例

```
{
  "service_id": "f76f20ba-78f5-44e8-893a-37c8c600c02f",
  "service_name": "service-demo",
  "tenant": "xxxxx",
  "project": "xxxxx",
  "owner": "xxxxx",
  "publish_at": 1585809231902,
  "update_time": 1585809358259,
  "infer_type": "real-time",
  "status": "running",
  "progress": 100,
  "access_address": "https://xxxxx.apigw.xxxx/v1/infers/088458d9-5755-4110-97d8-1d21065ea10b/f76f20ba-78f5-44e8-893a-37c8c600c02f",
  "pool_name": "088458d9-5755-4110-97d8-1d21065ea10b",
  "workspace_id": "0",
  "additional_properties": {},
  "is_shared": false,
  "invocation_times": 0,
  "failed_times": 0,
  "shared_count": 0,
  "operation_time": 1586249085447,
  "config": [{
    "model_id": "044ebf3d-8bf4-48df-bf40-bad0e664c1e2",
    "model_name": "jar-model",
    "model_version": "1.0.1",
    "specification": "custom",
    "custom_spec": {},
    "status": "notReady",
    "weight": 100,
    "instance_count": 1,
    "envs": {},
    "additional_properties": {},
    "deploy_timeout_in_seconds": 1200,
    "support_debug": false
  }],
  "transition_at": 1585809231902,
  "is_free": false,
  "request_mode": "async"
}
```

状态码

状态码请参见[表17-1](#)。

6.4 删除服务实例

功能介绍

删除服务实例，仅适用于IEF边缘服务。

URI

DELETE /v1/{project_id}/services/{service_id}/instances/{instance_id}

参数说明如[表6-57](#)所示。

表 6-57 参数说明

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。
instance_id	是	String	实例ID。获取方法请参见 查询服务详情 ，即查询服务详情接口响应参数instance_id的值。

请求消息

无请求参数。

响应消息

无响应参数说明。

示例

如下以删除边缘节点实例为例。

- 请求示例
DELETE https://endpoint/v1/{project_id}/services/{service_id}/instances/{instance_id}
- 响应示例
{}

状态码

状态码请参见[表17-1](#)。

6.5 更新服务配置

功能介绍

更新模型服务配置。也可以使用此接口启停服务。

URI

PUT /v1/{project_id}/services/{service_id}

参数说明如[表6-58](#)所示。

表 6-58 参数说明

参数	是否必选	参数类型	说明
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。

请求消息

请求参数如[表6-59](#)所示。

表 6-59 请求参数

参数	是否必选	参数类型	说明
description	否	String	服务描述，不超过100个字符，不设置此参数表示不更新。
status	否	String	服务状态，可设置状态为“running”或“stopped”来启动、停止服务，不设置此参数则不修改状态。status不可跟config同时修改，同时存在则只修改status。

参数	是否必选	参数类型	说明
config	否	对应infer_type的config结构数组	服务配置，不设置此参数表示不更新。只有更新了config的请求，才会修改模型服务并返回参数“update_time”，否则不会返回。 - 当infer_type为real-time时，且为非分布式推理服务时，参见表6-60。 - 当infer_type为real-time时，且为分布式推理服务时，参见表 Real-timeDistributedConfig结构。 - 当infer_type为batch时，参见表6-62。 - 当infer_type为edge时，参见表6-63。
schedule	否	schedule结构数组	服务调度配置，仅在线服务可配置，默认不使用，服务长期运行。请参见 表6-64 。
additional_properties	否	Map<String, Object>	服务级别附加属性，便于服务管理。请参考 表6-8 。
load_balancer_policy	否	String	更新在线同步服务支持设置elb转发策略。 枚举值： - ROUND_ROBIN（加权轮询算法） - LEAST_CONNECTIONS（加权最少连接） - SOURCE_IP（源IP算法）
priority	否	Integer	抢占优先级，取值范围[1, 3]，通过设置优先级保障高优先级的业务调度。infer_type为real-time、batch时支持抢占优先级设置。

表 6-60 Real-timeConfig 结构

参数	是否必选	参数类型	说明
model_id	是	String	模型ID。

参数	是否必选	参数类型	说明
weight	是	Integer	权重百分比，分配到此模型的流量权重，仅当infer_type为real-time时需要配置，多个权重相加必须等于100。
stream_count	否	Integer	异步服务单个实例并发分析数据流的能力。默认值为10，表示单个实例可以并发分析10个数据流。
specification	是	String	资源规格，根据所提供版本选择适合业务的规格。
custom_spec	否	Object	自定义规格。使用专属资源池部署的时候可以使用自定义规格。请参见表6-17。
instance_count	是	Integer	模型部署的实例数。实例数取值必须大于0。
envs	否	Map<String, String>	运行模型需要的环境变量键值对，可选填，默认为空。 为确保您的数据安全，在环境变量中，请勿输入敏感信息。
pool_name	否	string	专属资源池ID，默认为空，不使用专属资源池。配置此参数后，需要使用集群的网络配置，“vpc_id”参数不生效。
additional_properties	否	Map<String, Object>	模型部署附加属性，便于服务实例管理。请参见表6-10。
affinity	否	ServiceAffinity object	服务亲和部署。
deploy_timeout_in_seconds	否	Integer	部署实例的超时时间，单位为秒。默认值为1200秒。 • 最小值：180秒 • 最大值：18000秒

表 6-61 Real-timeDistributedConfig 结构

参数	是否必选	参数类型	说明
model_id	是	String	模型ID。
weight	是	Integer	权重百分比，分配到此模型的流量权重，仅当infer_type为real-time时需要配置，多个权重相加必须等于100。

参数	是否必选	参数类型	说明
specification	是	String	资源规格，根据所提供版本选择适合业务的规格。可被“instance_group”下层负载中的“cpu”和“memory”配置覆盖。
custom_spec	否	Object	自定义规格。使用专属资源池部署的时候可以使用自定义规格。可被“instance_group”下层负载中的“cpu”和“memory”配置覆盖。请参见表6-17。
distributed_inference_type	否	String	分布式推理的具体类型，当前仅用于查询展示用。可选： PD-Split：PD分离部署。
inference_framework	否	String	分布式推理模型集成的推理框架，当前仅用于查询展示用。可选： MindIE：MindIE推理框架。
instance_group_count	是	Integer	分布式推理模型部署的实例组数。部署分布式推理服务时必须填。实例组数取值必须大于0。
instance_group	是	Object	分布式推理模型部署的实例组配置，用于描述单个实例组内的负载详情。部署分布式推理服务时必须填。 请参见7.1-表 InstanceGroup结构。
envs	否	Map<String, String>	运行模型需要的环境变量键值对，可选填，默认为空。为确保您的数据安全，在环境变量中，请勿输入敏感信息。可被“instance_group”下层负载中的“envs”配置覆盖。
pool_name	否	string	专属资源池ID，默认为空，不使用专属资源池。配置此参数后，需要使用集群的网络配置，“vpc_id”参数不生效。
additional_properties	否	Map<String, Object>	模型部署附加属性，便于服务实例管理。请参见表6-10。
deploy_timeout_in_seconds	否	Integer	部署实例的超时时间，单位为秒。默认值为1200秒。 - 最小值：180秒 - 最大值：18000秒

表 6-62 BatchConfig 结构

参数	是否必选	参数类型	说明
model_id	是	String	模型ID。
specification	是	String	资源规格。
instance_count	是	Integer	模型部署的实例数。
custom_spec	否	Object	自定义规格。使用专属资源池部署的时候可以使用自定义规格。请参见表6-17。
envs	否	Map<String, String>	运行模型需要的环境变量键值对，可选填，默认为空。 为确保您的数据安全，在环境变量中，请勿输入敏感信息。
custom_src	否	Boolean	输入数据来源是否自定义，默认值为“false”，即来源OBS。如果不从OBS输入数据，填“true”
src_type	否	String	数据来源类型，可选填ManifestFile。默认为空，表示只读取src_path目录下的文件。当取值为ManifestFile时，src_path必须为具体的manifest路径，在manifest文件中可指定多个数据路径（参考《ModelArts用户指南》的“部署为批量服务”章节）。
src_path	否	String	批量任务输入数据的OBS路径，如果“custom_src”为“false”，则必填。
dest_path	否	String	批量任务输出结果的OBS路径，如果“custom_src”为“false”，则必填。
req_uri	否	String	批量任务中调用的推理接口，即模型镜像中暴露的REST接口，需要从模型的“config.json”文件中选取一个api路径用于此次推理；如使用ModelArts提供的预置推理镜像，则此接口为“/”，如果“custom_src”为“false”，则必填。

参数	是否必选	参数类型	说明
mapping_type	否	String	输入数据的映射类型，可选“file”或“csv”。 - file指每个推理请求对应到输入数据目录下的一个文件，当使用此方式时，此模型对应req_uri只能有一个输入参数且此参数的类型是file。 - 选择csv时指每个推理请求对应到csv里的一行数据，当使用此方式时，输入数据目录下的文件只能以.csv为后缀，且需配置mapping_rule参数，以表达推理请求体中各个参数对应到csv的索引。 - 如果“custom_src”为“false”，则必填。
mapping_rule	否	Map	输入参数与csv数据的映射关系，仅当“mapping_type”为“csv”以及“custom_src”为“false”时需要填写。 映射关系生成规则：映射规则来源于模型配置文件“config.json”中输入参数（input_params）。当“type”定义为“string/number/integer/boolean”基本类型时，需要配置映射规则参数，即index参数。具体示例可参见《ModelArts用户指南》的“部署为批量服务”章节。 index必须是从0开始的连续正整数，当index设置不符合规则时，最终的请求将被忽略。配置映射规则后，其对应的csv数据必须以英文半角逗号分隔。
additional_properties	否	Map<String, Object>	模型部署附加属性，便于服务实例管理。请参见表6-23。

表 6-63 EdgeConfig 结构

参数	是否必选	参数类型	说明
model_id	是	String	模型ID。
model_name	是	String	模型名称。
model_version	是	String	模型版本。
specification	是	String	资源规格。

参数	是否必选	参数类型	说明
instance_count	是	Integer	模型部署的实例数。
custom_spec	否	Object	自定义规格。使用专属资源池部署的时候可以使用自定义规格。请参见表6-17。
envs	否	Map<String, String>	运行模型需要的环境变量键值对。为确保您的数据安全，在环境变量中，请勿输入敏感信息。
volumes	否	Array of Volume objects	边缘场景挂载卷配置
ports	否	Array of HostContainerPortMapping objects	边缘场景端口映射配置
additional_properties	否	Map<String, Object>	模型部署附加属性，便于服务实例管理。参考表6-77。

表 6-64 Schedule 结构

参数	是否必选	参数类型	说明
type	是	String	调度类型，当前仅支持取值为stop。
time_unit	是	String	调度时间单位，可选DAYS/HOURS/MINUTES。
duration	是	Integer	对应时间单位的数值，比如2小时后停止，则time_unit填HOURS，duration填2。

表 6-65 ServiceAffinity

参数	是否必选	参数类型	描述
node_affinity	否	NodeAffinity object	节点亲和的时候填入该字段。

表 6-66 NodeAffinity

参数	是否必选	参数类型	描述
mode	是	String	节点亲和的方式，required表示强亲和，服务实例只能调度到指定节点，指定节点不存在则失败。preferred表示弱亲和，服务实例倾向于调度到指定节点，指定节点不满足调度条件，则会调度到其他节点。
pool_infos	否	Array of AffinityPoolInfo objects	配置亲和策略到指定的集群，并指定集群的节点。

表 6-67 AffinityPoolInfo

参数	是否必选	参数类型	描述
pool_name	是	String	集群名称，集群名称必须在外层 pool_name 中。
nodes	是	Array of AffinityNodeInfo objects	亲和的节点列表信息。

表 6-68 AffinityNodeInfo

参数	是否必选	参数类型	描述
name	是	String	节点名称，实际上对应的是节点的私有ip。

表 6-69 模型级别 AdditionalProperties 已有属性

参数	是否必选	参数类型	说明
persistent_volumes	是	persistentVolume数组结构	持久化存储挂载配置。请参见 表6-70 。
log_volume	是	logVolume数组结构	主机日志目录挂载。请参见 表6-71 。 仅支持使用专属资源池部署服务场景。如果用户使用公共资源池部署服务，则不支持配置该参数，否则会报错。

参数	是否必选	参数类型	说明
log_report_channels	否	数组 <logReportChannel>	运行日志输出的配置列表。请参见表6-73。

表 6-70 PersistentVolume 结构

参数	是否必选	参数类型	说明
name	否	String	存储卷名称。
mount_path	是	String	存储卷在容器中的挂载路径。如：/tmp-obs-mount/。请选择全新目录，选择存量目录会覆盖存量文件。obs挂载仅开放对挂载目录文件新增、查看、修改功能不支持删除挂载目录文件对象，若需要删除文件请到obs并行文件系统中手动删除。
storage_type	是	String	存储类型，枚举值： - obs_pfs：obs并行文件系统 - obs_bucket：obs桶 - sfs_turbo：极速文件系统
source_addresses	是	String	源地址，需要满足obs校验格式。与model_manager等其他模块校验保持一致，obs桶和obs并行文件系统支持传子路径，如/obs_bucket_name/sub_path/，会把桶下的子路径挂载至容器中。

表 6-71 LogVolume 结构

参数	是否必选	参数类型	说明
host_path	是	String	主机上要映射的日志路径。
mount_path	是	String	容器中的日志路径。

表 6-72 CustomSpec 自定义规格结构

参数	是否必选	参数类型	说明
cpu	是	Float	要求的CPU数量。
memory	是	Integer	要求的内存数量，单位MB。
gpu_p4	否	Float	GPU个数，可选，默认不使用，支持配置小数。

表 6-73 LogReportChannel 日志输出配置结构

参数	是否必选	参数类型	说明
type	是	String	运行日志输出类型，目前仅支持云日志服务 LTS。

表 6-74 Volume

参数	是否必选	参数类型	描述
destination	是	String	卷挂载路径，必须是合法的路径
server	否	String	nfs服务地址，source为nfs为必填
name	是	String	卷名称，小写字母或数字，最长63个字符
read_only	否	Boolean	读写权限，configMap和secret类型只支持读权限
source	否	String	卷来源，type为hostPath时输入路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字；secret时输入secret名称，configMap时输入configMap名称，emptyDir时输入disk或memory
type	是	String	卷的类型，支持nfs、configMap、secret、emptyDir、hostPath

表 6-75 HostContainerPortMapping

参数	是否必选	参数类型	描述
container_port	是	Integer	容器端口，1到65535之间的整数
host_ip	是	String	对应主机网卡地址，形如192.168.0.1
host_port	否	Integer	主机端口，1到65535之间的整数，与主机端口范围二选一
host_port_range	否	表6-76 object	主机端口范围，在范围内为应用实例自动分配主机端口；与主机端口参数二选一

表 6-76 HostPortRange

参数	是否必选	参数类型	描述
max_port	是	Integer	主机端口上限值，1到65535之间的整数；max_port需大于min_port
min_port	是	Integer	主机端口下限值，1到65535之间的整数

表 6-77 edgeAdditionalProperties 结构（滚动升级只支持 ModelArts 边缘资源池部署，不支持边缘节点部署）

参数	是否必选	参数类型	说明
max_unavailable	否	String	最大无效实例数：每次滚动升级能释放的最大实例数，应小于目标实例数。若最大无效实例数等于目标实例数，则服务可能会中断。如果传的值为大于1的小数，则向下取整。如果传的值小于1，则表示最大无效实例数占目标实例数的比率，转成绝对数，并向下取整。
max_surge	否	String	最大浪涌数：每次滚动升级扩容能超出目标实例数的最大实例数。如果传的值为大于1的小数，则向下取整。如果传的值小于1，表示最大浪涌实例数占目标实例数的比率，k8s最终会转成绝对数，并向上取整。

响应消息

无响应参数说明。

示例

如下以更新 “real-time” 类型的服务为例。

- 请求示例

```
PUT https://endpoint/v1/{project_id}/services/{service_id}
{
  "description": "",
  "status": "running",
  "config": [{
    "model_id": "xxxx",
    "weight": "100",
    "specification": "modelarts.vm.cpu.2u",
    "instance_count": 1
  }]
}
```
- 响应示例

```
{}
```

状态码

状态码请参见[表17-1](#)。

6.6 更新服务实例数

功能介绍

更新模型服务的单个属性，目前只支持instance_count(更新模型服务实例数量)，仅运行中、告警、异常状态下的在线服务可以执行该操作。

URI

PUT /v1/{project_id}/services/{service_id}/property

表 6-78 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。

请求参数

表 6-79 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户token。

表 6-80 请求 Body 参数

参数	是否必选	参数类型	描述
changed_property	是	String	属性名称，可选： - instance_count：更新模型服务实例数量（仅限非分布式推理服务）。 - instance_group_count：更新模型服务实例组数量（仅限分布式推理服务）。
configs	否	Array of UpdateServiceConfig objects	服务配置。

表 6-81 UpdateServiceConfig

参数	是否必选	参数类型	描述
changed_value	是	String	属性值，只支持整数，changed_property属性值为"instance_count"时，该值必须大于或小于当前实例数。
model_id	是	String	模型ID。

响应参数

状态码： 200

表 6-82 响应 Body 参数

参数	参数类型	描述
update_time	String	本次更新时间，仅触发服务配置升级时会返回，比如修改config参数，可根据此时间从服务更新记录中过滤出此次的更新结果；修改描述或启停服务不会返回此参数。
resource_ids	String	更新的资源ID。

状态码： 401

表 6-83 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

请求示例

更新非分布式推理模型服务的实例数量。

```
PUT https://{endpoint}/v1/{project_id}/services/{service_id}/property
{
  "changed_property": "instance_count",
  "configs": [ {
    "model_id": "98240f41-6c69-437c-b894-9c488b1d9c43",
    "changed_value": 2
  } ]
}
```

更新分布式推理模型服务的实例组数量。

```
PUT https://{endpoint}/v1/{project_id}/services/{service_id}/property
{
  "changed_property": "instance_group_count",
  "configs": [ {
    "model_id": "98240f41-6c69-437c-b894-9c488b1d9c43",
    "changed_value": 2
  } ]
}
```

响应示例

状态码： 200

OK

```
{
  "update_time": 1712026426703
}
```

状态码： 401

Unauthorized

```
{
  "error_code": "ModelArts.0203",
  "error_msg": "Invalid token."
}
```

状态码

状态码请参见[表17-1](#)。

6.7 局部更新服务配置

功能介绍

通过patch操作对服务进行更新。patch的格式可以参照json patch。

URI

PATCH /v1/{project_id}/services/{service_id}

表 6-84 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。

请求参数

表 6-85 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户token。

表 6-86 请求 Body 参数

参数	是否必选	参数类型	描述
[数组元素]	是	Array of PatchService V2RequestBody objects	参照json patch的格式。目前path只能以“/config”为前缀，即只能修改模型数据。

表 6-87 PatchServiceV2RequestBody

参数	是否必选	参数类型	描述
op	否	String	操作类型，目前仅支持 replace，代表值替换操作。
path	否	String	操作路径，符合标准的Json PATCH格式，代表以服务详情的Json返回体为基准，想要执行替换的值的目标路径（Json PATH）。当前支持且仅支持对模型相关所有参数的替换更新，因此前缀固定为“/config/”。例如，当期望更新第一个模型中的实例数量，则路径为“/config/0/instance_count”。
value	否	String	替换的目标值。

响应参数

状态码： 200

表 6-88 响应 Body 参数

参数	参数类型	描述
update_time	String	本次更新时间，仅触发服务配置升级时会返回，比如修改config参数，可根据此时间从服务更新记录中过滤出此次的更新结果；修改描述或启停服务不会返回此参数。
resource_ids	String	更新的资源ID。

状态码： 400

表 6-89 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码。
error_msg	String	具体错误信息。

请求示例

通过patch操作对服务进行更新。

PATCH https://{endpoint}/v1/{project_id}/services/{service_id}

```
[ {
  "op" : "replace",
  "path" : "/config/0/envs",
  "value" : { }
}, {
  "op" : "replace",
  "path" : "/config/0/model_id",
  "value" : "a9542b46-8dfd-4184-bd81-c8d8946edb47"
}, {
  "op" : "replace",
  "path" : "/config/0/additional_properties",
  "value" : {
    "persistent_volumes" : [ {
      "storage_type" : "obs_pfs",
      "source_address" : "/dongcong4",
      "mount_path" : "/var/tmp",
      "storage_type_text" : "atelier_webservice_detail_model_config_volumes_type_obs"
    } ]
  }
}, {
  "op" : "replace",
  "path" : "/config/0/specification",
  "value" : "modelarts.vm.ai1.a310"
}, {
  "op" : "replace",
  "path" : "/config/0/pool_name",
  "value" : "pool-c8e2-04f258c84780d5a52f3bc00dc15aa5e7"
} ]
```

响应示例

状态码： 200

OK

```
{
  "update_time" : 1700625410586,
  "resource_ids" : [ "INF-ae2aa85ce2a3fcac-1700530937033", "INF-ae2aa85ca9542b46-1700530937026" ]
}
```

状态码

状态码请参见[表17-1](#)。

6.8 查询服务监控信息

功能介绍

查询服务监控信息，只支持查询infer_type为real-time和batch的服务。

URI

GET /v1/{project_id}/services/{service_id}/monitor

参数说明如[表6-90](#)所示。

表 6-90 参数说明

参数	是否必选	参数类型	说明
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。

表 6-91 查询检索参数说明

参数	是否必选	参数类型	说明
node_id	否	String	待查询的节点ID，默认查询所有节点。

请求消息

无请求参数。

响应消息

 说明

当前环境支持的接口功能，以如下表格说明为准。当响应消息中，返回如下表格展示以外的其他参数，无需关注。

响应参数如[表6-92](#)所示。

表 6-92 响应参数

参数	参数类型	说明
service_id	String	服务ID。
service_name	String	服务名称。
monitors	服务的infer_type对应的monitor结构数组	监控信息详情。 当infer_type为real-time和batch时，参见表6-93。
service_running_instance_count	Integer	正在运行的服务实例个数。
model_instance_count	Integer	模型实例个数。

表 6-93 Real-time/Batch Monitor 结构

参数	参数类型	说明
model_id	String	模型ID。
model_name	String	模型名称。
model_version	String	模型版本。
invocation_times	Long	模型实例的总调用次数。
failed_times	Long	模型实例调用失败次数。
cpu_core_usage	Float	已使用CPU核数。
cpu_core_total	Float	总CPU核数。
cpu_memory_usage	Integer	已使用内存，单位MB。
cpu_memory_total	Integer	总内存，单位MB。
gpu_usage	Float	已使用GPU个数。
gpu_total	Float	总GPU个数。
service_running_instance_count	Integer	正在运行的服务实例个数。
model_instance_count	Integer	模型实例个数。

示例

如下以查询类型为“real-time”的服务监控信息为例。

- 请求示例
GET https://endpoint/v1/{project_id}/services/{service_id}/monitor

- 响应示例

```
{
  "service_id": "xxx",
  "service_name": "mnist",
  "service_running_instance_count": "1",
  "model_instance_count": "1",
  "monitors":
  [{
    "model_id": "xxxx",
    "model_name": "mnist",
    "model_version": "1.0.0",
    "invocation_times": 50,
    "failed_times": 1,
    "cpu_core_usage": "2.4",
    "cpu_core_total": "4",
    "cpu_memory_usage": "2011",
    "cpu_memory_total": "8192",
    "gpu_usage": "0.6",
    "gpu_total": "1",
```

```
    "service_running_instance_count": "1",  
    "model_instance_count": "1"  
  }  
}
```

状态码

状态码请参见[表17-1](#)。

6.9 查询服务更新日志

功能介绍

查询实时服务更新日志，支持查询infer_type为real-time、batch和edge（IEF）的服务。

URI

GET /v1/{project_id}/services/{service_id}/logs

参数说明如[表6-94](#)所示。

表 6-94 参数说明

参数	是否必选	参数类型	说明
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。
update_time	否	Number	待过滤的更新时间，查询在线服务更新日志可使用，可准确过滤出某次更新任务。默认不过滤。
offset	否	Integer	分页列表的起始页，默认为“0”。
limit	否	Integer	指定每一页返回的最大条目数，默认为“100”。

请求消息

无请求参数。

响应消息

 说明

当前环境支持的接口功能，以如下表格说明为准。当响应消息中，返回如下表格展示以外的其他参数，无需关注。

响应参数如[表6-95](#)所示。

表 6-95 响应参数

参数	参数类型	说明
service_id	String	服务ID。
service_name	String	服务名称。
logs	log结构数组	服务的更新记录，log结构如表6-96所示。
count	Integer	当前查询到的更新日志数量。
total_count	Integer	不分页的情况下符合查询条件的事件总数量。

表 6-96 Log 结构

参数	参数类型	说明
update_time	Number	更新时间，距'1970.1.1 0:0:0 UTC'的毫秒数。
result	String	更新结果，取值为SUCCESS/FAIL/RUNNING。
config	Config结构数组	更新后的服务配置，config结构如表6-97所示。
success_num	Number	操作成功的节点数，当infer_type为edge时会返回此值。
failed_num	Number	操作失败的节点数，当infer_type为edge时会返回此值。
result_detail	Result结构数组	操作结果详情，当infer_type为edge时会返回此值，result结果如表6-107所示。
cluster_id	String	专属资源池ID。仅infer_type为real-time/batch时会返回此值。
extend_config	List	服务个性化配置。

表 6-97 Config 结构

参数	参数类型	说明
model_id	String	模型ID。
model_name	String	模型名称。
model_version	String	模型版本。
weight	Integer	权重，分配到此模型的流量权重，当infer_type为real-time时会返回此值。

参数	参数类型	说明
specification	String	资源规格，当infer_type为real-time/edge时会返回此值。
specification_details	specification_detail结构	规格具体对应的数据内容。请参见表6-98。
custom_spec	Object	自定义规格。定义见表6-108。
instance_count	Integer	模型部署的实例数。
running_instance_count	Integer	运行中的实例数。
pool_name	String	专属池名称。
cluster_inner_access_address	String	集群内部访问地址。
envs	Map<String, String>	运行模型需要的环境变量键值对。 为确保您的数据安全，在环境变量中，请勿输入敏感信息。
deploy_timeout_in_seconds	Integer	部署实例的超时时间，单位为秒。默认值为1200秒。
additional_properties	Map<String, Object>	模型部署附加属性，便于服务实例管理。请参见表6-99。
affinity	ServiceAffinity object	服务亲和信息。

表 6-98 SpecificationDetails 结构

参数	参数类型	说明
category	string	加速卡类型
cpu_info	cpu_info结构	服务规格对应的具体cpu资源占用。请参见表6-103。
memory_info	memory_info结构	服务规格对应的具体内存资源占用。请参见表6-104。
gpu_info	gpu_info结构	服务规格对应的具体gpu资源占用。请参见表6-105。
npu_info	npu_info结构	服务规格对应的具体npu资源占用。请参见表6-106。
display_en	String	规格的英文描述。
display_cn	String	规格的中文描述。

表 6-99 模型级别 AdditionalProperties 已有属性

参数	是否必选	参数类型	说明
persistent_volumes	是	persistentVolume数组结构	持久化存储挂载配置。请参见表6-100。
log_volume	是	logVolume数组结构	主机日志目录挂载。请参见表6-101。 仅支持使用专属资源池部署服务场景。如果用户使用公共资源池部署服务，则不支持配置该参数，否则会报错。
log_report_channels	否	数组 <logReportChannel>	运行日志输出的配置列表。请参见表6-102。
customize_timeout_sec	否	Integer	部署超时时间设置。部署服务时间超过这个参数设置的值，部署服务操作会失败。
max_unavailable	否	Integer	最大无效实例数。

表 6-100 PersistentVolume 结构

参数	是否必选	参数类型	说明
name	否	String	存储卷名称。
mount_path	是	String	存储卷在容器中的挂载路径。
storage_type	是	String	存储类型，枚举值：obs_pfs
source_addresses	是	String	源地址，需要满足obs校验格式。与model_manager等其他模块校验保持一致
sub_path	否	String	子路径，如：/tmp-obs-mount/。使用子路径挂载obs并行文件系统，实现在单一Pod中重复使用同一个Volume。选择全新目录，选择存量目录会覆盖存量文件。obs挂载仅开放对挂载目录文件新增、查看、修改功能不支持删除挂载目录文件对象，若需要删除文件请到obs并行文件系统中手动删除。

表 6-101 LogVolume 结构

参数	是否必选	参数类型	说明
host_path	是	String	主机上要映射的日志路径。
mount_path	是	String	容器中的日志路径。

表 6-102 LogReportChannel 日志输出配置结构

参数	是否必选	参数类型	说明
type	是	String	运行日志输出类型，目前仅支持云日志服务 LTS。

表 6-103 CpuInfo 结构

参数	参数类型	说明
cpu	int	cpu核数
arch	string	系统架构

表 6-104 MemoryInfo 结构

参数	参数类型	说明
memory	int	内存数量
unit	int	内存单位

表 6-105 GpuInfo 结构

参数	参数类型	说明
gpu	int	gpu核数
unit	string	gpu单位
memory	int	内存数量

表 6-106 NpuInfo 结构

参数	参数类型	说明
npu	int	npu核数
unit	string	npu单位
memory	int	内存数量

表 6-107 Result 结果

参数	参数类型	说明
node_id	String	节点ID。
node_name	String	节点名称。
operation	String	操作类型，取值deploy/delete。
result	Boolean	操作结果，true代表成功，false表示操作失败。

表 6-108 CustomSpec 自定义规格结构

参数	参数类型	说明
cpu	Float	CPU数量。
memory	Integer	内存数量，单位MB。
gpu_p4	Float	GPU数量。
ascend_a310	Integer	Ascend芯片个数。

表 6-109 ServiceAffinity

参数	参数类型	描述
node_affinity	NodeAffinity object	节点亲和的时候填入该字段。

表 6-110 NodeAffinity

参数	参数类型	描述
mode	String	节点亲和的方式，required表示强亲和，服务实例只能调度到指定节点，指定节点不存在则失败。preferred表示弱亲和，服务实例倾向于调度到指定节点，指定节点不满足调度条件，则会调度到其他节点。
pool_infos	Array of AffinityPoolInfo objects	配置亲和策略到指定的集群，并指定集群的节点。

表 6-111 AffinityPoolInfo

参数	参数类型	描述
pool_name	String	集群名称，集群名称必须在外层pool_name中。
nodes	Array of AffinityNodeInfo objects	亲和的节点列表信息。

表 6-112 AffinityNodeInfo

参数	参数类型	描述
name	String	节点名称，实际上对应的是节点的私有ip。

示例

如下以服务ID为xxxxxx，服务名为“mnist”的实时服务更新日志为例。

- 请求示例
GET https://endpoint/v1/{project_id}/services/xxxxxx/logs
- 响应示例

```
{
  "service_id": "e2122bbd-f7c8-4bf8-bacc-59616276194b",
  "service_name": "service-demo",
  "logs": [{
    "config": [{
      "model_id": "f565ac47-6239-4e8c-b2dc-0665dc52e302",
      "model_name": "model-demo",
      "model_version": "0.0.1",
      "specification": "modelarts.vm.cpu.2u",
      "specification_details": {
        "display_en": "CPU: 2 vCPUs | 8 GiB",
        "display_cn": "CPU:2 核 8 GiB",
        "category": "CPU",
        "cpu_info": {
          "cpu": 2,
          "arch": "x86"
        }
      }
    }],
  }]
```

```
        "memory_info":{
            "memory":8,
            "unit":"GB"
        },
        "gpu_info":{
            "gpu":0,
            "unit":"MB",
            "memory":0
        },
        "npu_info":{
            "npu":0,
            "unit":"MB",
            "memory":0
        }
    },
    "custom_spec": {},
    "weight": 100,
    "instance_count": 1,
    "scaling": false,
    "envs": {},
    "deploy_timeout_in_seconds": 1200
},
"extend_config": [],
"update_time": 1586250930708,
"result": "RUNNING",
"cluster_id": "2c9080f86d37da64016d381fe5940002"
}
```

状态码

状态码请参见[表17-1](#)。

6.10 查询服务事件日志

功能介绍

查询服务事件日志，包含服务的操作记录及部署过程中的关键动作、部署失败原因。

URI

GET /v1/{project_id}/services/{service_id}/events

参数说明如[表6-113](#)所示。

表 6-113 参数说明

参数	是否必选	参数类型	说明
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。

表 6-114 查询检索参数说明

参数	是否必选	参数类型	说明
event_type	否	String	待过滤的事件类型，默认不过滤事件类型。取值为： - normal：正常事件。 - abnormal：异常事件。
event_info	否	String	事件信息，仅支持英文信息过滤，不超过20个字符，不支持`(){};[]<>/?!¥…&（）【】‘；：”“’。、`？`
start_time	否	Number	待过滤的事件起始时间，取值为距'1970.1.1 0:0:0 UTC'的毫秒数。
end_time	否	Number	待过滤的事件截止时间，取值为距'1970.1.1 0:0:0 UTC'的毫秒数。
offset	否	Integer	分页列表的起始页，默认为“0”。
limit	否	Integer	指定每一页返回的最大条目数，默认为“1000”。
sort_by	否	String	指定排序字段，默认是“occur_time”。
order	否	String	排序方式，默认是“desc”。可选： - asc：递增排序。 - desc：递减排序。

请求消息

表 6-115 请求 Header 参数

参数	是否必选	参数类型	说明
X-Language	否	String	事件返回信息的中英文显示标识。可选： - zh-cn：显示中文 - en-us：显示英文（默认值）

响应消息

说明

当前环境支持的接口功能，以如下表格说明为准。当响应消息中，返回如下表格展示以外的其他参数，无需关注。

响应参数如[表6-116](#)所示。

表 6-116 响应参数

参数	参数类型	说明
service_id	String	服务ID。
service_name	String	服务名称。
events	event结构数组	事件日志，请参见表6-117。
total_count	Integer	不分页的情况下符合查询条件的事件总数量。
count	Integer	当前查询结果的事件数量。

表 6-117 Event 结构

参数	参数类型	说明
occur_time	Number	事件发生时间，取值为距'1970.1.1 0:0:0 UTC'的毫秒数。
event_type	String	事件类型，取值为normal/abnormal，代表此事件是否正常。
event_info	String	事件信息。描述服务的操作记录及部署过程中的关键动作、部署失败原因。
event_count	Integer	事件数量。
last_time	Number	事件最近发生时间，取值为距'1970.1.1 0:0:0 UTC'的毫秒数。
message	String	事件信息补充的详情信息。

示例

如下以查询服务ID为“35de3ca9-1bca-4ae7-9cb0-914f30fa7d3e”的服务事件信息为例。

- 请求示例

```
GET https://endpoint/v1/{project_id}/services/{service_id}/events
```
- 响应示例

```
{
  "service_id": "35de3ca9-1bca-4ae7-9cb0-914f30fa7d3e",
  "service_name": "zcjtest-07085",
  "count": 9,
  "total_count": 9,
  "events": [
    {
      "occur_time": 1562597251764,
      "event_type": "normal",
      "event_info": "start to deploy service",
      "event_count": 1,
      "last_time": 1562597251998
    },
    {
```

```
    "occur_time": 1562597251788,
    "event_type": "normal",
    "event_info": "building image for model [zcjtestTF 3.0.0]",
    "event_count": 1,
    "last_time": 1562597251998
  },
  {
    "occur_time": 1562597251805,
    "event_type": "normal",
    "event_info": "model (zcjtestTF 3.0.0) build image success",
    "event_count": 1,
    "last_time": 1562597251998
  },
  {
    "occur_time": 1562597255744,
    "event_type": "normal",
    "event_info": "preparing environment",
    "event_count": 1,
    "last_time": 1562597251998
  },
  {
    "occur_time": 1562597275915,
    "event_type": "normal",
    "event_info": "[zcjtestTF 3.0.0] prepare environment success",
    "event_count": 1,
    "last_time": 1562597251998
  },
  {
    "occur_time": 1562597275921,
    "event_type": "normal",
    "event_info": "[zcjtestTF 3.0.0] schedule resource success",
    "event_count": 1,
    "last_time": 1562597251998
  },
  {
    "occur_time": 1562597275928,
    "event_type": "normal",
    "event_info": "[zcjtestTF 3.0.0] pulling model image",
    "event_count": 1,
    "last_time": 1562597251998
  },
  {
    "occur_time": 1562597332570,
    "event_type": "normal",
    "event_info": "[zcjtestTF 3.0.0] pull image success",
    "event_count": 1,
    "last_time": 1562597251998,
    "message": "pulled instances: 1"
  },
  {
    "occur_time": 1562597332582,
    "event_type": "normal",
    "event_info": "[zcjtestTF 3.0.0] starting model",
    "event_count": 1,
    "last_time": 1562597251998
  }
]
```

状态码

状态码请参见[表17-1](#)。

6.11 删除服务

功能介绍

删除服务，仅可删除本人名下的服务。

URI

DELETE /v1/{project_id}/services/{service_id}

参数说明如[表6-118](#)所示。

表 6-118 参数说明

参数	是否必选	参数类型	说明
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID，如需批量删除多个服务，则将多个service_id使用英文半角逗号拼接。

请求消息

无请求参数。

响应消息

无响应参数说明。

示例

如下删除服务ID为xxxxxx的模型服务为例。

- 请求示例
DELETE https://endpoint/v1/{project_id}/services/xxxxxx
- 响应示例
{}

状态码

状态码请参见[表17-1](#)。

6.12 查询支持的服务部署规格

功能介绍

查询支持的服务部署规格列表。

URI

GET /v1/{project_id}/services/specifications

表 6-119 参数说明

参数	是否必选	参数类型	说明
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
is_personal_cluster	否	Boolean	是否查询专属资源池支持的服务部署规格列表，默认为false。
infer_type	否	String	推理方式，默认为real-time。取值为：real-time/batch/edge
cluster_id	否	String	资源池ID。可通过查询资源池列表接口获取。
node_flavor	否	String	当选择专属池时，可以根据节点规格过滤匹配的服务规格。
runtime	否	String	根据模型runtime运行环境匹配可用规格。

请求消息

无请求参数。

响应消息

表 6-120 响应参数

参数	参数类型	说明
specifications	specification结构数组	支持的服务部署规格列表。请参见 表 6-121 。
count	Integer	匹配的规格个数。
total_count	Integer	匹配的规格总数。

表 6-121 Specification 结构

参数	参数类型	说明
specification	string	规格的唯一标识。
category	string	加速卡类型。
cpu_info	cpu_info结构	服务规格对应的具体cpu资源占用。请参见 表6-122 。

参数	参数类型	说明
memory_info	memory_info结构	服务规格对应的具体内存资源占用。请参见 表6-123 。
gpu_info	gpu_info结构	服务规格对应的具体gpu资源占用。请参见 表6-124 。
npu_info	npu_info结构	服务规格对应的具体npu资源占用。请参见 表6-125 。
billing_spec	string	计费对应规格的唯一标识。
spec_status	string	规格状态。 - normal：正常 - sellout：无法使用此规格部署服务。
is_open	boolean	是否开放此规格，默认是“true”；取值为“false”时，用户需要提工单申请才可使用此规格。
source_type	string	此规格应用于模型的类型。 空：默认为空，用户自己产生的模型。
is_free	boolean	当前规格是否是免费规格，“true”表示是免费规格。
over_quota	boolean	当前规格是否超过可用配额，“true”表示超过可用配额。
extend_params	integer	计费因子。
display_en	String	规格的英文描述。
display_cn	String	规格的中文描述。

表 6-122 CpuInfo 结构

参数	参数类型	说明
cpu	int	cpu核数
arch	string	系统架构

表 6-123 MemoryInfo 结构

参数	参数类型	说明
memory	int	内存数量
unit	int	内存单位

表 6-124 GpuInfo 结构

参数	参数类型	说明
gpu	int	gpu核数
unit	string	gpu单位
memory	int	内存数量

表 6-125 NpuInfo 结构

参数	参数类型	说明
npu	int	npu核数
unit	string	npu单位
memory	int	内存数量
ai_core	int	切分规格中对应的ai core 数量
ai_cpu	int	切分规格中对应的ai cpu 数量

示例

- 请求示例
GET https://endpoint/v1/{project_id}/services/specifications

- 响应示例

```
{
  "count":1,
  "specifications":[
    {
      "specification":"modelarts.vm.cpu.2u",
      "billing_spec":"modelarts.vm.cpu.2u",
      "display_en":"CPU: 2 vCPUs | 8 GiB",
      "display_cn":"CPU:2 核 8 GiB",
      "is_open":true,
      "spec_status":"normal",
      "is_free":false,
      "over_quota":false,
      "extend_params":1,
      "category":"CPU",
      "cpu_info":{
        "cpu":2,
        "arch":"x86"
      },
      "memory_info":{
        "memory":8,
        "unit":"GB"
      },
      "gpu_info":{
        "gpu":0,
        "unit":"MB",
        "memory":0
      },
      "npu_info":{
```

```
        "npu":0,
        "unit":"MB",
        "memory":0
      }
    ]
  }
```

状态码

状态码请参见[表17-1](#)。

6.13 添加资源标签

功能介绍

给指定服务添加标签（目前只支持在线服务），当添加的标签key已存在，则覆盖该标签的value。

URI

POST /v1/{project_id}/services/{resource_id}/tags/create

表 6-126 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
resource_id	是	String	资源ID，也就是服务ID。

请求参数

表 6-127 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	该字段内容填为“application/json;charset=utf8”。
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 6-128 请求 Body 参数

参数	是否必选	参数类型	描述
tags	是	Array of TmsTag objects	标签列表。

表 6-129 TmsTag

参数	是否必选	参数类型	描述
key	是	String	标签的key。
value	是	String	标签的value。

响应参数

状态码： 400

表 6-130 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 401

表 6-131 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 403

表 6-132 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 404

表 6-133 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

请求示例

为指定服务添加标签。设置标签的key为“test”和“model_version”，标签的value为“service-gpu”和“0.1”。

```
https://{endpoint}/v1/{project_id}/services/a55eba18-1ebf-4e9a-8229-d2d3b593a3dc/tags/create
{
  "tags": [ {
    "key": "test",
    "value": "service-gpu"
  }, {
    "key": "model_version",
    "value": "0.1"
  } ]
}
```

响应示例

无

状态码

状态码	描述
204	添加标签成功。
400	参数非法。
401	鉴权失败。
403	权限不足。
404	资源未找到。

错误码

请参见[错误码](#)。

6.14 删除资源标签

功能介绍

删除服务（目前只支持在线服务）的标签，支持批量删除。

URI

DELETE /v1/{project_id}/services/{resource_id}/tags/delete

表 6-134 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
resource_id	是	String	资源id，如在线服务的服务ID。

请求参数

表 6-135 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	该字段内容填为“application/json;charset=utf8”。
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 6-136 请求 Body 参数

参数	是否必选	参数类型	描述
tags	是	Array of TmsTagForDelete objects	要删除的标签列表。

表 6-137 TmsTagForDelete

参数	是否必选	参数类型	描述
key	是	String	标签的key。
value	否	String	标签的value，非必填

响应参数

状态码： 400

表 6-138 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 401

表 6-139 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 403

表 6-140 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 404

表 6-141 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

请求示例

```
https://{endpoint}/v1/{project_id}/services/a55eba18-1ebf-4e9a-8229-d2d3b593a3dc/tags/delete
{
  "tags" : [ {
    "key" : "dev",
```



```
"value": "dev1"
}]
}
```

响应示例

无

状态码

状态码	描述
204	删除标签成功。
400	参数非法。
401	鉴权失败。
403	权限不足。
404	资源不存在。

错误码

请参见[错误码](#)。

6.15 查询推理服务标签

功能介绍

查询当前项目下的推理服务标签，无权限不返回标签数据。

URI

GET /v1/{project_id}/services/tms/tags

表 6-142 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。

请求参数

表 6-143 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见获取Token。
Content-Type	是	String	该字段内容填为“application/json;charset=utf8”。

响应参数

状态码： 200

表 6-144 响应 Body 参数

参数	参数类型	描述
tags	Array of CombineTms Tags objects	标签的融合结构，相同key合并。

表 6-145 CombineTmsTags

参数	参数类型	描述
key	String	标签的key。
values	Array of strings	相同key的标签value合并后的列表。

状态码： 400

表 6-146 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 401

表 6-147 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 403

表 6-148 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

请求示例

https://{endpoint}/v1/{project_id}/services/tms/tags

响应示例

状态码： 200

查询项目下service资源类型的所有标签，正常返回。

```
{
  "tags": [ {
    "key": "model_version",
    "values": [ "0.1", "0.2" ]
  }, {
    "key": "conda_version",
    "values": [ "10.2", "11.0" ]
  } ]
}
```

状态码

状态码	描述
200	查询项目下service资源类型的所有标签，正常返回。
400	参数非法。
401	鉴权失败。
403	权限不足。

错误码

请参见[错误码](#)。

6.16 创建自动扩缩容策略

功能介绍

创建自动扩缩容策略。

URI

POST /v1/{project_id}/services/{service_id}/models/{model_id}/auto-scaling-policies

表 6-149 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。
model_id	是	String	模型ID。

请求参数

表 6-150 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 6-151 请求 Body 参数

参数	是否必选	参数类型	描述
policy_name	是	String	自动扩缩容策略名称。支持1-64位字符，只能由小写字母、数字、“-”或“.”组成，且必须由字母或数字开头和结尾。
policy_type	是	String	自动扩缩容策略类型。可选值如下： cron：定时扩缩容策略。
rules	是	Array of AutoScalingRuleReq objects	自动扩缩容规则，一条策略可添加多条规则。

表 6-152 AutoScalingRuleReq

参数	是否必选	参数类型	描述
rule_name	是	String	自动扩缩容规则的名称。支持 1-20 位字符，只能由小写字母、数字、“-”或“.”组成，且必须由字母或数字开头和结尾。
schedule	否	String	在定时类型自动扩缩容策略中，任务运行时间与周期。格式为包含 5 个域的 CRON 表达式，5 个域分别代表分、小时、日期、月份、星期。需要特别注意的是，对于星期，0 表示星期天，1~6 表示星期一到星期六。
target_replicas	否	Integer	自动扩缩容的目标实例数。
disable	是	Boolean	规则是否禁用。可选值如下： • true：该规则设置禁用状态。 • false：该规则设置启用状态。

响应参数

状态码： 200

表 6-153 响应 Body 参数

参数	参数类型	描述
policy_id	String	自动扩缩容策略的 ID。

请求示例

创建定时类型自动扩缩容策略。

```
/v1/{project_id}/services/{service_id}/model/{model_id}/auto-scaling
{
  "policy_name": "autoscalingtest001",
  "policy_type": "cron",
  "rules": [ {
    "rule_name": "autoscalingrule001",
    "schedule": "0 0 * * *",
    "target_replicas": 2,
    "disable": false
  }
]
```

```
  }  
}
```

响应示例

状态码： 200

自动扩缩容策略创建成功。

```
{  
  "policy_id" : "a9c8efe54f584caaa087725895a746b5"  
}
```

状态码

状态码请参见[表17-1](#)。

6.17 查询自动扩缩容策略列表

功能介绍

查询自动扩缩容策略列表。

URI

GET /v1/{project_id}/services/{service_id}/models/{model_id}/auto-scaling-policies

表 6-154 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。
model_id	是	String	模型ID。

表 6-155 Query 参数

参数	是否必选	参数类型	描述
policy_name	否	String	自动扩缩容策略名称，默认不过滤策略名称。
policy_type	否	String	自动扩缩容策略类型。可选值如下： cron：定时扩缩容策略
offset	否	Integer	分页列表的起始页，默认为0。
limit	否	Integer	指定每一页返回的最大条目数，默认为1000。

参数	是否必选	参数类型	描述
sort_by	否	String	指定排序字段。可选值如下： - created_at：自动扩缩容策略创建的时间，默认值。 - policy_name：策略名称。
order	否	String	排序方式。可选值如下： - asc：递增排序。 - desc：递减排序，默认值。

请求参数

表 6-156 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见获取Token。

响应参数

状态码： 200

表 6-157 响应 Body 参数

参数	参数类型	描述
total_count	Integer	不分页的情况下符合查询条件的总自动扩缩容策略数量。
count	Integer	分页的情况下，当前查询结果列表中自动扩缩容策略的总数。
policies	Array of AutoScalingPolicyRsp objects	自动扩缩容策略详情列表。

表 6-158 AutoScalingPolicyRsp

参数	参数类型	描述
policy_name	String	自动扩缩容策略的名称。
policy_id	String	自动扩缩容策略的ID。

参数	参数类型	描述
policy_type	String	自动扩缩容策略类型，参数值当前仅支持cron，表示定时扩缩容策略。
created_at	String	创建时间，格式为YYYY-MM-DDThh:mm:ss，UTC时间
updated_at	String	更新时间，格式为YYYY-MM-DDThh:mm:ss，UTC时间。
rules	Array of AutoScalingRuleRsp objects	自动扩缩容规则详情以及状态，一条策略可包含多条规则。

表 6-159 AutoScalingRuleRsp

参数	参数类型	描述
rule_name	String	自动扩缩容规则的名称。
schedule	String	在定时类型自动扩缩容策略中，任务运行的时间与周期。
target_replicas	Integer	自动扩缩容的目标实例数。
disable	Boolean	规则是否禁用。可选值如下： - true：该规则设置禁用状态。 - false：该规则设置启用状态。
status	String	规则最新状态。可选值如下： - creating：规则创建中 - creation-succeed：规则创建成功。 - creation-failed：规则创建失败。 - trigger-succeed：规则触发成功。 - trigger-failed：规则触发失败。
trigger_time	String	最近一次规则触发时间。

请求示例

无

响应示例

状态码： 200
获取自动扩缩容策略成功。


```
{
  "total_count": 1,
  "count": 1,
  "policies": [ {
    "policy_name": "autoscalingtest001",
    "policy_id": "a9c8efe54f584caaa087725895a746b5",
    "policy_type": "cron",
    "created_at": "2024-01-01T00:00:00Z",
    "updated_at": "2024-01-01T00:00:00Z",
    "rules": [ {
      "rule_name": "autoscalingrule001",
      "schedule": "0 0 * * *",
      "target_replicas": 2,
      "disable": false,
      "status": "trigger-succeed",
      "trigger_time": "2024-01-02T00:00:00"
    } ]
  } ]
}
```

状态码

状态码请参见[表17-1](#)。

6.18 更新自动扩缩容

功能介绍

更新自动扩缩容策略。

URI

PUT /v1/{project_id}/services/{service_id}/models/{model_id}/auto-scaling-policies/{policy_id}

表 6-160 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。
model_id	是	String	模型ID。
policy_id	是	String	自动扩缩容策略ID。

请求参数

表 6-161 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见获取Token。

表 6-162 请求 Body 参数

参数	是否必选	参数类型	描述
rules	否	Array of AutoScalingRuleReq objects	自动扩缩容规则，一条策略可添加多条规则。

表 6-163 AutoScalingRuleReq

参数	是否必选	参数类型	描述
rule_name	是	String	自动扩缩容规则的名称。支持1-20位字符，只能由小写字母、数字、“-”或“.”组成，且必须由字母或数字开头和结尾。
schedule	否	String	在定时类型自动扩缩容策略中，任务运行时间与周期。格式为包含5个域的CRON表达式，5个域分别代表分、小时、日期、月份、星期。需要特别注意的是，对于星期，0表示星期天，1~6表示星期一到星期六。
target_replicas	否	Integer	自动扩缩容的目标实例数。
disable	是	Boolean	规则是否禁用。可选值如下： • true：该规则设置禁用状态。 • false：该规则设置启用状态。

响应参数

状态码： 200

表 6-164 响应 Body 参数

参数	参数类型	描述
policy_id	String	自动扩缩容策略的ID。

请求示例

更新定时类型自动扩缩容策略。

```
/v1/{project_id}/services/{service_id}/model/{model_id}/auto-scaling/{policy_id}

{
  "rules": [ {
    "rule_name": "autoscalingrule001",
    "schedule": "0 0 * * *",
    "target_replicas": 2,
    "disable": false
  } ]
}
```

响应示例

状态码： 200

更新自动扩缩容策略成功。

```
{
  "policy_id": "a9c8efe54f584caaa087725895a746b5"
}
```

状态码

状态码请参见[表17-1](#)。

6.19 查询自动扩缩容策略

功能介绍

获取自动扩缩容策略详情。

URI

GET /v1/{project_id}/services/{service_id}/models/{model_id}/auto-scaling-policies/{policy_id}

表 6-165 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。

参数	是否必选	参数类型	描述
model_id	是	String	模型ID。
policy_id	是	String	自动扩缩容策略ID。

请求参数

表 6-166 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见获取Token。

响应参数

状态码： 200

表 6-167 响应 Body 参数

参数	参数类型	描述
policy_name	String	自动扩缩容策略的名称。
policy_id	String	自动扩缩容策略的ID。
policy_type	String	自动扩缩容策略类型，参数值当前仅支持cron，表示定时扩缩容策略。
created_at	String	更新时间，格式为YYYY-MM-DDThh:mm:ss，UTC时间。
updated_at	String	更新时间，格式为YYYY-MM-DDThh:mm:ss，UTC时间。
rules	Array of AutoScalingRuleRsp objects	自动扩缩容规则详情以及状态，一条策略可包含多条规则。

表 6-168 AutoScalingRuleRsp

参数	参数类型	描述
rule_name	String	自动扩缩容规则的名称。
schedule	String	在定时类型自动扩缩容策略中，任务运行的时间与周期。

参数	参数类型	描述
target_replicas	Integer	自动扩缩容的目标实例数。
disable	Boolean	规则是否禁用。可选值如下： - true：该规则设置禁用状态。 - false：该规则设置启用状态。
status	String	规则最新状态。可选值如下： - creating：规则创建中。 - creation-succeed：规则创建成功。 - creation-failed：规则创建失败。 - trigger-succeed：规则触发成功。 - trigger-failed：规则触发失败。
trigger_time	String	最近一次规则触发时间

请求示例

无

响应示例

状态码： 200

获取自动扩缩容策略详情成功。

```
{
  "policy_name": "autoscalingtest001",
  "policy_id": "a9c8efe54f584caaa087725895a746b5",
  "policy_type": "cron",
  "created_at": "2024-01-01T00:00:00Z",
  "updated_at": "2024-01-01T00:00:00Z",
  "rules": [ {
    "rule_name": "autoscalingrule001",
    "schedule": "0 0 * * *",
    "target_replicas": 2,
    "disable": false,
    "status": "trigger-succeed",
    "trigger_time": "2024-01-02T00:00:00"
  } ]
}
```

状态码

状态码请参见[表17-1](#)。

6.20 删除自动扩缩容

功能介绍

删除自动扩缩容策略。

URI

DELETE /v1/{project_id}/services/{service_id}/models/{model_id}/auto-scaling-policies/{policy_id}

表 6-169 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。
model_id	是	String	模型ID。
policy_id	是	String	自动扩缩容策略ID。

请求参数

表 6-170 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

无

请求示例

无

响应示例

无

状态码

状态码请参见[表17-1](#)。

6.21 获取服务的模型信息

功能介绍

获取服务对应的模型信息，支持的服务类型有：同步在线服务、异步在线服务、批量服务。

URI

GET /v1/{project_id}/services/{service_id}/models

表 6-171 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。

请求消息

表 6-172 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。
Content-Type	否	String	该字段内容填为“application/json;charset=utf8”。

响应消息

表 6-173 响应 Body 参数

参数	参数类型	描述
service_model_nodes	Array of ServiceModelNode objects	服务的模型。

表 6-174 ServiceModelNode

参数	参数类型	描述
model_id	String	模型的id。
model_alias	String	模型的别名。
model_nodes	Array of ModelNode objects	模型实例的信息。

表 6-175 ModelNode

参数	参数类型	描述
model_nodes_id	String	模型实例的id。
model_nodes_alias	String	模型实例的别名。
model_nodes_status	String	模型实例的状态。如：Running、Abnormal、Finishing等。

请求示例

如下以获取服务模型信息为例。

- 请求示例
GET https://endpoint/v1/{project_id}/services/{service_id}/models
- 响应示例

```
{
  "service_model_nodes": [{
    "model_id": "044ebf3d-8bf4-48df-bf40-bad0e664c1e2",
    "model_alias": "model-demo_0.0.1",
    "model_nodes": [{
      "model_nodes_id": "3e1239a8-2fd2-48be-9470-26177421aece-0l5fx1p0-8599568b59-ds4lc",
      "model_nodes_alias": "model-demo_0.0.1_1",
      "model_nodes_status": "Running"
    }],
  }],
}
```

状态码

状态码请参见[表17-1](#)。

6.22 获取服务模型实例的运行日志

功能介绍

获取服务的模型实例的运行日志数据，支持的服务类型有：同步在线服务和批量服务。

URI

POST /v1/{project_id}/services/{service_id}/models/{model_id}/runlogs

表 6-176 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。

参数	是否必选	参数类型	描述
service_id	是	String	服务ID。
model_id	是	String	模型ID。

请求消息

表 6-177 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见获取Token。
Content-Type	是	String	该字段内容填为“application/json;charset=utf8”。

表 6-178 请求 Body 参数

参数	是否必选	参数类型	描述
start_time	否	Long	查询的日志开始时间。
end_time	否	Long	查询的日志结束时间。
type	是	String	查询的日志类型。支持类型有init、next、pre。
keyword	否	String	查询的日志关键字。
line_num	否	Long	查询的日志行数。
size	否	Integer	请求日志的大小。

响应消息

表 6-179 响应 Body 参数

参数	参数类型	描述
model_nodes_id	Array of ModelNode Info objects	模型实例信息。
start_line_num	Long	日志起始行数。
end_line_num	Long	日志结束行数。
logs	String	日志信息。

表 6-180 ModelNodeInfo

参数	参数类型	描述
model_nodes_id	String	模型实例的id。
model_nodes_alias	String	模型实例的别名。

示例

如下以获取服务模型实例运行日志为例。

- 请求示例
POST https://endpoint/v1/{project_id}/services/{service_id}/models/{model_id}/runlogs
- 响应示例

```
{  "model_nodes_id": [{    "model_nodes_id": "a75cab26-59e9-41de-a298-c348543d137a-f87bdz78-78b9d559ff-mrv8t",    "model_nodes_alias": "model-demo_0.0.1_1"  }],  "logs": "2025-10-22 18:04:57.984 +0800 | INFO | j_BW8ZTH0X/main.go:35 | start http server, listen and serve at 0.0.0.0:8080\n2025-10-22 18:04:57.985 +0800 | INFO | j_BW8ZTH0X/main.go:28 | start https server, listen and serve at 0.0.0.0:9876\n",  "start_line_num": 1761127497985071463,  "end_line_num": 1761127497985259668}
```

状态码

状态码请参见[表17-1](#)。

6.23 获取服务模型单个节点的运行日志

功能介绍

查询服务的具体模型实例的节点运行日志数据，支持的服务类型有：同步、异步在线服务以及批量服务。

URI

POST /v1/{project_id}/services/{service_id}/models/{model_id}/nodes/{model_node_id}/runlogs

表 6-181 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。
model_id	是	String	模型ID。
model_node_id	是	String	模型实例ID。

请求消息

表 6-182 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。
Content-Type	是	String	该字段内容填为“application/json;charset=utf8”。

表 6-183 请求 Body 参数

参数	是否必选	参数类型	描述
start_time	否	Long	查询的日志开始时间。
end_time	否	Long	查询的日志结束时间。
type	是	String	查询的日志类型。支持类型有init、next、pre。
keyword	否	String	查询的日志关键字。
line_num	否	Long	查询的日志行数。
size	否	Integer	请求日志的大小。

响应消息

表 6-184 响应 Body 参数

参数	参数类型	描述
start_line_num	Long	起始行数。

参数	参数类型	描述
end_line_num	Long	结束行数。
logs	String	日志信息。

示例

如下以获取服务具体模型实例运行日志为例。

- 请求示例
POST https://endpoint/v1/{project_id}/services/{service_id}/models/{model_id}/nodes/{model_node_id}/runlogs
- 响应示例

```
{
  "logs": "W1023 10:59:26.633167      1 connection.go:173] Still connecting to unix:///run/csi/
socket\nW1023 10:59:36.633489      1 connection.go:173] Still connecting to unix:///run/csi/socket\n",
  "start_line_num": 1761127497985071463,
  "end_line_num": 1761127497985259668
}
```

状态码

状态码请参见[表17-1](#)。

6.24 获取服务 API

功能介绍

获取服务API，获取的服务类型为异步在线服务。

URI

GET /v1/{project_id}/services/{service_id}/api

表 6-185 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。

请求消息

表 6-186 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。
Content-Type	否	String	该字段内容填为“application/json;charset=utf8”。

响应消息

表 6-187 响应 Body 参数

参数	参数类型	描述
service_id	String	服务ID。
create_url	UriInfo 结构	创建任务的URL信息。
create_url_ipv6	UriInfo 结构	创建任务的IPv6 URL信息。
delete_url	UriInfo 结构	删除任务的URL信息。
delete_url_ipv6	UriInfo 结构	删除任务的IPv6 URL信息。
list_url	UriInfo 结构	列表任务的URL信息。
list_url_ipv6	UriInfo 结构	列表任务的IPv6 URL信息。
update_url	UriInfo 结构	更新任务的URL信息。
update_url_ipv6	UriInfo 结构	更新任务的IPv6 URL信息。
detail_url	UriInfo 结构	详情任务的URL信息。
detail_url_ipv6	UriInfo 结构	详情任务的IPv6 URL信息。
start_url	UriInfo 结构	启动任务的URL信息。
start_url_ipv6	UriInfo 结构	启动任务的IPv6 URL信息。
stop_url	UriInfo 结构	停止任务的URL信息。
stop_url_ipv6	UriInfo 结构	停止任务的IPv6 URL信息。

表 6-188 UriInfo

参数	参数类型	描述
name	String	任务名称。

参数	参数类型	描述
value	String	任务请求的URL。

示例

如下以获取服务模型信息为例。

- 请求示例
GET https://endpoint/v1/{project_id}/services/{service_id}/api
- 响应示例

```
{
  "service_id": "74be7118-cd52-4349-8850-86c483d9abca",
  "create_url": {
    "name": "POST(Create Task)",
    "value": "https://8.27.112.49:8080/v1/4f8520ca9025493ea612b33c4897f14a/services/74be7118-cd52-4349-8850-86c483d9abca/tasks"
  },
  "delete_url": {
    "name": "DELETE(Delete Task)",
    "value": "https://8.27.112.49:8080/v1/4f8520ca9025493ea612b33c4897f14a/services/74be7118-cd52-4349-8850-86c483d9abca/tasks/{task_id}"
  },
  "list_url": {
    "name": "GET(List Task)",
    "value": "https://8.27.112.49:8080/v1/4f8520ca9025493ea612b33c4897f14a/services/74be7118-cd52-4349-8850-86c483d9abca/tasks"
  },
  "update_url": {
    "name": "PUT(Update Task)",
    "value": "https://8.27.112.49:8080/v1/4f8520ca9025493ea612b33c4897f14a/services/74be7118-cd52-4349-8850-86c483d9abca/tasks/{task_id}"
  },
  "detail_url": {
    "name": "GET(Detail Task)",
    "value": "https://8.27.112.49:8080/v1/4f8520ca9025493ea612b33c4897f14a/services/74be7118-cd52-4349-8850-86c483d9abca/tasks/{task_id}"
  },
  "start_url": {
    "name": "POST(Start Task)",
    "value": "https://8.27.112.49:8080/v1/4f8520ca9025493ea612b33c4897f14a/services/74be7118-cd52-4349-8850-86c483d9abca/tasks/{task_id}/start"
  },
  "stop_url": {
    "name": "POST(Stop Task)",
    "value": "https://8.27.112.49:8080/v1/4f8520ca9025493ea612b33c4897f14a/services/74be7118-cd52-4349-8850-86c483d9abca/tasks/{task_id}/stop"
  },
}
```

状态码

状态码请参见[表17-1](#)。

6.25 查询服务 host 信息

功能介绍

查询服务host信息。

URI

GET /v1/{project_id}/services/{service_id}/predict/endpoints

表 6-189 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。

表 6-190 查询检索参数

参数	是否必选	参数类型	说明
type	否	String	endpoint类型。当前支持类型有: host_endpoints、cluster_inner。

请求消息

表 6-191 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。
Content-Type	否	String	该字段内容填为“application/json;charset=utf8”。

响应消息

表 6-192 响应 Body 参数

参数	参数类型	描述
service_name	String	服务名称。
endpoints	array of HostEndpointDetail object	endpoint信息。

表 6-193 HostEndpointDetail

参数	参数类型	描述
model_name	String	模型名称。
model_version	String	模型版本。
weight	Integer	权重。
schema	String	schema信息。
host_ips	array of String	host信息。
port	String	端口。

示例

如下以获取服务模型信息为例。

- 请求示例
GET https://endpoint/v1/{project_id}/services/{service_id}/predict/endpoints
- 响应示例

```
{
  "service_name": "service-demo",
  "endpoints": [{
    "model_name": "model_demo",
    "model_version": "0.0.1",
    "weight": 100,
    "schema": "HTTP",
    "host_ips": [
      "127.0.0.1"
    ],
    "port": "30324"
  }]
}
```

状态码

状态码请参见[表17-1](#)。

7 服务管理（新版推理）

7.1 在线服务生命周期管理

7.1.1 停止在线服务

功能介绍

停止在线服务功能允许用户在特定状态下主动终止正在运行或处于其他可操作状态的服务实例。该功能适用于需要维护、升级或检测到异常的服务场景，支持在服务处于"运行中"、"部署中"、"失败"、"异常"或"告警"状态时执行停止操作。使用此功能前，请确保服务实例处于可停止状态，并具备相应的API调用权限。成功执行后，服务将进入停止状态，释放相关资源并停止处理新的请求。若服务不在允许停止的状态、调用权限不足或系统内部出现错误，将返回相应的错误信息。

URI

POST /v2/{project_id}/services/{service_id}/stop

表 7-1 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

请求参数

表 7-2 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json。 • application/json;charset=utf-8。 默认取值： 不涉及。

表 7-3 请求 Body 参数

参数	是否必选	参数类型	描述
id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

响应参数

状态码：200

表 7-4 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 取值范围： 不涉及。
name	String	参数解释： 服务名，用户在 创建服务 时自定义的名称。 取值范围： 支持1-64位字符，可包含字母、中文、数字、中划线、下划线。
dispatcher_group_id	String	参数解释： 服务绑定的dispatcher组ID。 取值范围： 不涉及。

参数	参数类型	描述
workspace_id	String	参数解释： 工作空间ID。 取值范围： 0：默认空间ID。 - 由数字和小写字母组成的32位字符：其他空间ID，可参考工作空间创建。
type	String	参数解释： 推理服务类型。 取值范围： REAL_TIME：在线服务。
deploy_type	String	参数解释： 部署方式。 取值范围： - SINGLE：单机单卡。 - MULTI：多机多卡。
status	String	参数解释： 服务当前状态。 取值范围： - DEPLOYING：部署中。 - FAILED：失败。 - STOPPED：停止。 - RUNNING：运行中。 - DELETING：删除中。 - STOPPING：停止中。 - CONCERNING：告警。 - UPGRADING：升级中。 - ERROR：异常。 - INTERRUPTING：中断中。
failure_reason	String	参数解释： 在线服务失败原因。 取值范围： 不涉及。
version	ServiceVersionResponse object	参数解释： 当前服务版本信息。
predict_url	Array of predict_url_Response objects	参数解释： 在线服务访问地址。

参数	参数类型	描述
tags	Array of TmsTag_Response objects	参数解释： TMS对接标签类。
create_at	String	参数解释： 创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
update_at	String	参数解释： 更新时间，根据更新时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
schedule	Array of ScheduleConfig_Response objects	参数解释： 定时停止配置。
provider	String	参数解释： 服务提供者的账号id（创建服务时通过X-Auth-Token-Provider请求头解析iam token而来），该值不为空时，该服务的所有更新操作需要在请求头中添加X-Auth-Token-Provider，取值为该账号id的domain级或project级token。

表 7-5 ServiceVersionResponse

参数	参数类型	描述
id	String	参数解释： 版本id。 取值范围： 不涉及。
version	String	参数解释： 版本号。 取值范围： 不涉及。

参数	参数类型	描述
description	String	参数解释： 描述。 取值范围： 不涉及。
predict_url	String	参数解释： 推理请求的访问地址。 取值范围： 不涉及。
runtime_config	RuntimeConfig_Response object	参数解释： 服务运行配置。
upgrade_config	UpgradeConfig_Response object	参数解释： 服务升级配置。
instance_groups	Array of GroupConfig_Response objects	参数解释： 服务实例组信息。
log_configs	Array of LogConfig_Response objects	参数解释： 服务日志配置信息。
deploy_timeout_minutes	Integer	参数解释： 部署超时时间。 取值范围： 不涉及。

表 7-6 RuntimeConfig_Response

参数	参数类型	描述
service_invoke	ServiceInvoke_Response object	参数解释： 服务调用时的相关配置。
service_limit	ServiceLimit_Response object	参数解释： 服务限制信息。 约束限制： 不涉及。
service_secret	ServiceSecret_Response object	参数解释： 服务密钥挂载。

表 7-7 ServiceInvoke_Response

参数	参数类型	描述
port	Integer	参数解释： 服务端口号。 取值范围： [1, 65535]。
protocol	String	参数解释： 服务请求协议。当选择WSS与WS时，服务接口会升级为WebSocket。开启WebSocket时，不支持同时设置“服务流量限制”。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
auth_type	String	参数解释： 认证类型。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。
direct_channel_enable	Boolean	参数解释： 是否开启专属通道。 取值范围： • TRUE：开启专属通道。 • FALSE：不开启专属通道。
direct_channel_auth_enable	Boolean	参数解释： 专属通道模式下proxy是否开启鉴权。 取值范围： • TRUE：开启鉴权。 • FALSE：不开启鉴权。
internet_access_enable	Boolean	参数解释： 外网访问。 取值范围： • TRUE：要外网访问。 • FALSE：不要外网访问。

参数	参数类型	描述
intranet_approve_enable	Boolean	参数解释： 内网审批。 取值范围： • TRUE：要内网审批。 • FALSE：不要内网审批。
dynamic_routing_enable	Boolean	参数解释： 动态路由开关。 取值范围： • TRUE：开启动态路由。 • FALSE：不开启动态路由。
strategy	String	参数解释： 智能路由策略。 取值范围： • ROUND_ROBIN：轮询。 • ORIGIN_IP_HASH：源IP哈希。 • MIN_CONN：最小连接数。 • MIN_FIRST_TOKEN_TIME：最小首token时延。 • COMPOSITE：综合负载。 • SLO_BASED：SLO优先级。
metric_api_scheme	String	参数解释： 指标接口服务请求协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。
metric_api_port	String	参数解释： 指标接口端口号。 取值范围： [1, 65535]。
metric_api_path	String	参数解释： 指标接口path。 取值范围： 默认值metrics。

参数	参数类型	描述
ems_enable	Boolean	参数解释： 是否开启EMS加速。 取值范围： - TRUE：开启EMS加速。 - FALSE：不开启EMS加速。
request_retry_enable	Boolean	参数解释： proxy支持请求重调度开关。 取值范围： - true：开启proxy支持请求重调度。 - false：不开启proxy支持请求重调度。
request_retry_cnt_max	Integer	参数解释： proxy支持请求重调度的重试次数 取值范围： [1, 10]。
request_retry_interval_ms	Integer	参数解释： proxy支持请求重调度的重试间隔，单位ms 取值范围： [1, 10000]。

表 7-8 ServiceLimit_Response

参数	参数类型	描述
rate_limit	RateLimit_Response object	参数解释： 流控相关指标。
request_size_limit	Integer	参数解释： 请求大小限制。 取值范围： 1-50M。
request_timeout	Integer	参数解释： 超时时间。 取值范围： 1到7200秒。
ip_white_list	Array of strings	参数解释： IP白名单。

参数	参数类型	描述
ip_black_list	Array of strings	参数解释： IP黑名单。

表 7-9 RateLimit_Response

参数	参数类型	描述
num	Integer	参数解释： 服务流量限制是指指定单位内一个服务能够被访问的次数上限。 取值范围： 1-500。
unit	String	参数解释： 流量限制单元。 取值范围： • NANOS（纳秒）。 • MICROS（微秒）。 • MILLIS（毫秒）。 • SECONDS（秒）。 • MINUTES（分钟）。 • HOURS（小时）。 • DAYS（天）。

表 7-10 ServiceSecret_Response

参数	参数类型	描述
secret_enable	Boolean	参数解释： 是否启用密钥。 取值范围： • true：启用密钥。 • false：不启用密钥。
secret_type	String	参数解释： 密钥类型。 取值范围： • custom：自定义密钥。

参数	参数类型	描述
secret_volumes	SecretVolume_Response object	参数解释： 密钥挂载。 约束限制： 上限30个。
group_enable	Boolean	参数解释： 是否启用镜像的用户组。 取值范围： • true：启用镜像的用户组。 • false：不启用镜像的用户组。
group_id	Long	参数解释： 镜像的用户组id。 取值范围： 1000~4294967294。

表 7-11 SecretVolume_Response

参数	参数类型	描述
secret_name	String	参数解释： 密钥名称。 取值范围： 不涉及。
secret_key	String	参数解释： 密钥key。 取值范围： 长度不大于63。
secret_value	String	参数解释： 密钥值。 取值范围： 长度不大于32768。
mountPath	String	参数解释： 挂载路径。 取值范围： 不涉及。

表 7-12 UpgradeConfig_Response

参数	参数类型	描述
type	String	参数解释： 升级类型。 取值范围： ROLLING：滚动升级，默认值。
rolling_update	RollingUpdate_Response object	参数解释： 滚动更新配置。

表 7-13 RollingUpdate_Response

参数	参数类型	描述
max_surge	String	参数解释： 滚动更新时最多可以启动多少个Pod。 取值范围： 不涉及。
max_unavailable	String	参数解释： 滚动更新时最多可以删除多少个Pod。 取值范围： 不涉及。

表 7-14 GroupConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例组ID。 取值范围： 不涉及。
name	String	参数解释： 实例组名称。 取值范围： 不涉及。

参数	参数类型	描述
pool_id	String	参数解释： 资源池ID，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 取值范围： 不涉及。
count	Integer	参数解释： 部署场景下，服务实例数量。 约束限制： 不涉及。 取值范围： [1, 128]。 默认取值： 不涉及。
system_log_dump_enable	Boolean	参数解释： 系统日志转储开关量。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： false
unit_configs	Array of UnitConfig_Response objects	参数解释： 实例单元配置。
weight	Integer	参数解释： 权重百分比，分配到此模型的流量权重，仅当模型部署为在线服务时需要配置。 取值范围： [0, 100]。
secret_type	String	参数解释： 凭证类型相关配置，用户可以在此处选择使用的凭证类型（dew, cce） 约束限制： 不涉及。

参数	参数类型	描述
secret_name	String	参数解释： 凭证名称，用户使用dew类型凭证时可以在此处选择使用的凭证。 约束限制： 不涉及。
priority	Integer	参数解释： 服务优先级。 约束限制： 不涉及。 取值范围： [1, 3]。 默认取值： 不涉及。
high_avail_switch	Boolean	参数解释： 高可用开关，开启后不同实例的pod将尽量均匀分布到不同的节点上。 取值范围： true: 高可用开启 false: 高可用关闭
framework	String	参数解释： 算法框架。 取值范围： COMMON：普通在线服务。

表 7-15 UnitConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例单元ID。 取值范围： 不涉及。
role	String	参数解释： 实例单元角色。 取值范围： common：表示其他角色。
custom_spec	CustomSpecResponse object	参数解释： 自定义资源规格配置。

参数	参数类型	描述
flavor	String	参数解释： 资源规格，根据所提供版本选择适合业务的规格。当specification为custom时表示自定义规格。由custom_spec指定部署的规格配置。 取值范围： 不涉及。
image	Image_Response object	参数解释： 镜像配置信息，包含镜像地址，镜像来源。
models	Array of Model_Response objects	参数解释： 模型相关配置，用户可以在此处选择模型及权重文件配合镜像使用。
codes	Array of Code_Response objects	参数解释： 代码相关配置，用户可以在此处选择代码所在的obs路径等。
dumps	Array of DumpResponse objects	参数解释： 转储相关配置，用户可以在此处选择转储的目的obs路径等。
count	Integer	参数解释： 配置实例个数，单机推理无需配置。 取值范围： 不涉及。
cmd	String	参数解释： 启动命令。 取值范围： 不涉及。
envs	Map<String,String>	参数解释： 环境变量。
readiness_health	Health_Response object	参数解释： 就绪健康检查。
startup_health	Health_Response object	参数解释： 启动健康检查。
liveness_health	Health_Response object	参数解释： 存活健康检查。

参数	参数类型	描述
port	Integer	参数解释： 端口。 取值范围： [1,65535]。
recovery	String	参数解释： 恢复策略重启等级。 取值范围： - Instance：实例级，故障时重新拉起整个实例。 - Pod：Pod级，故障时重新拉起故障pod。 - Custom：自定义级，故障时不做处理，留给用户处理。
npu_reset_enable	Boolean	参数解释： 是否开启恢复策略。 取值范围： - true：开启恢复策略。 - false：不开启恢复策略。
affinity	Affinity_Response object	参数解释： 节点亲和调度设置。

表 7-16 CustomSpecResponse

参数	参数类型	描述
gpu	Number	参数解释： GPU个数。 取值范围： 支持配置小数，输入值不能小于0（最多支持2位小数，小数点后第3位做四舍五入处理）。
memory	Integer	参数解释： 内存，单位为MB。 取值范围： 仅支持整数。

参数	参数类型	描述
cpu	Number	参数解释： CPU核数。 取值范围： 支持配置小数，输入值不能小于0.01（最多支持2位小数，小数点后第3位做四舍五入处理）。
ascend	Integer	参数解释： Ascend芯片个数。 取值范围： 不涉及。

表 7-17 Image_Response

参数	参数类型	描述
id	String	参数解释： 镜像id。 取值范围： 不涉及。
source	String	参数解释： 镜像类别，标识镜像来源。 取值范围： • swr：软件仓库服务。
swr_path	String	参数解释： 镜像地址，source不同取值时，地址为不同值。 取值范围： 不涉及。
category	String	参数解释： 镜像支持的规格。 取值范围： • GPU：图形处理器。 • CPU：中央处理器。 • ASCEND：昇腾芯片。

表 7-18 Model_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。 • LOCAL：挂载宿主机本地存储目录。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： 当存储类别为EFS时，支持配置子目录。 取值范围： 不涉及。
read_only	Boolean	参数解释： 挂载权限设置，是否只读。 取值范围： • true：只读。 • false：非只读。
os_warm_up	Boolean	参数解释： os预热。 取值范围： • true：预热。 • false：不预热。

表 7-19 Code_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
source_id	String	参数解释： 代码来源id，与address二选一，当且仅当source为EFS时，可以传入sfs turbo的id。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： sfs 子路径。 取值范围： 不涉及。

参数	参数类型	描述
read_only	Boolean	参数解释： 是否只读。 取值范围： • true：只读。 • false：非只读。

表 7-20 DumpResponse

参数	参数类型	描述
source	String	参数解释： 用户转储来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。
address	String	参数解释： 用户转储来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及。
type	String	参数解释： 转储类型。 取值范围： • DUMP：用户自定义转储。 • DUMP_SYS：系统转储。

表 7-21 Health_Response

参数	参数类型	描述
check_method	String	参数解释： 健康检查方式：HTTP 或者 EXEC（命令行）。 取值范围： • HTTP：超文本传输协议。 • EXEC：命令行。
cmd	String	参数解释： 当健康检查方式为EXEC时，配置的命令行。 取值范围： 不涉及。
url	String	参数解释： 当健康检查方式为HTTP 时，配置的请求地址。 取值范围： 不涉及。
protocol	String	参数解释： 连接协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
initial_delay_seconds	Integer	参数解释： 执行首次探测时，应该等待的时间。 取值范围： 不涉及。
timeout_seconds	Integer	参数解释： 执行探测的超时时间，默认1秒，最小1秒。 取值范围： 不涉及。

参数	参数类型	描述
period_seconds	Integer	参数解释： 执行健康检查的周期时间，执行探测的频率。默认是10秒，最小1秒。 取值范围： 不涉及。
failure_threshold	Integer	参数解释： 探测成功后，最少连续探测失败多少次才被认定为失败。默认是3。最小值是1。 取值范围： 不涉及。

表 7-22 Affinity_Response

参数	参数类型	描述
affinity_type	String	参数解释： 节点亲和类型。 取值范围： - AFFINITY：亲和。 - ANTI_AFFINITY：反亲和。
required	Boolean	参数解释： 是否设置强亲和。 取值范围： - true：设置强亲和。 - false：不设置强亲和。
selection_mode	String	参数解释： 选择节点方式。 取值范围： IP。
targets	Map<String,String>	参数解释： 通过上述方式选择的列表，长度不能超过20。

表 7-23 LogConfig_Response

参数	参数类型	描述
type	String	参数解释： 日志输出类型。 取值范围： • STDOUT：日志输出到控制台或终端。 • FILE：日志输出到文件。
status	String	参数解释： 日志服务状态。 取值范围： • ON：开启。 • OFF：关闭。
log_group_id	String	参数解释： 日志组id，用户选择自己已有的日志组，不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
log_stream_id	String	参数解释： 日志流id，用户选择自己已有的日志组。不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-24 predict_url_Response

参数	参数类型	描述
type	String	参数解释： 访问方式。 取值范围： • CONSOLE：通过控制台界面访问。 • PUBLIC：通过公网访问。 • INTERNAL：通过内网访问。 • DIRECT_CHANNEL：通过直接通道访问。
urls	Array of strings	参数解释： 推理请求的访问地址，仅当type为real-time时，且服务部署完成后才会确保该字段有值。

表 7-25 TmsTag_Response

参数	参数类型	描述
key	String	参数解释： 标签键字段。 约束限制： 不涉及。 取值范围： 长度为1~128，标签的键可以包含任意语种字母、数字、空格，以及_ . : = + - @ 特殊字符，但首尾不能含有空格，不能以_sys_开头。 默认取值： 不涉及。
value	String	参数解释： 标签值字段。 取值范围： 长度为255，包括字母、数字、下划线、点、斜杠、等号、加号、减号和@符号。

表 7-26 ScheduleConfig_Response

参数	参数类型	描述
due_time	Long	参数解释： 触发时间，13位时间戳。 取值范围： 不涉及。
duration	Integer	参数解释： 对应的时间单位的数值。 取值范围： 不涉及。
time_unit	String	参数解释： 调度时间单位。 取值范围： - MINUTES：分钟。 - HOURS：小时。 - DAYS：天。
type	String	参数解释： 调度类型，当前仅支持取值为stop。 取值范围： STOP：停止。
processed	Boolean	参数解释： 表示是否处理完成。 取值范围： - true：该定时任务已经执行过。 - false：该定时任务尚未执行。

请求示例

停止在线服务。

POST https://{endpoint}/v2/{project_id}/services/{service_id}/stop

响应示例

状态码：200

停止服务信息。

```
{
  "create_at" : 1751608828683,
  "deploy_timeout_minutes" : 60,
  "deploy_type" : "SINGLE",
  "dispatcher_group_id" : "dispatcher_group_id",
  "failure_reason" : ""
```

```
"id" : "id",
"name" : "service-2aa2",
"predict_url" : [ {
  "type" : "PUBLIC",
  "urls" : [ "12.23.123.233" ]
}, {
  "type" : "CONSOLE",
  "urls" : [ "12.23.123.233" ]
}, {
  "type" : "DIRECT_CHANNEL",
  "urls" : [ ]
} ],
"schedule" : [ ],
"status" : "STOPPING",
"tags" : [ ],
"type" : "REAL_TIME",
"update_at" : 1751609483288,
"version" : {
  "deploy_timeout_minutes" : 60,
  "description" : "API_KEY",
  "id" : "id",
  "instance_groups" : [ {
    "count" : 1,
    "framework" : "COMMON",
    "id" : "id",
    "name" : "instance-a39b",
    "pool_id" : "pool_id",
    "priority" : 1,
    "unit_configs" : [ {
      "cmd" : "",
      "codes" : [ ],
      "count" : 1,
      "custom_spec" : {
        "arch" : "x86",
        "cpu" : 0.1,
        "memory" : 40
      },
      "id" : "id",
      "image" : {
        "category" : "CPU",
        "id" : "id",
        "source" : "SWR",
        "swr_path" : "swr.example.com/example/helloworld-example:0.0.1"
      },
      "models" : [ ],
      "npu_reset_enable" : false
    } ],
    "weight" : 100
  } ],
  "log_configs" : [ {
    "status" : "OFF",
    "type" : "STDOUT"
  } ],
  "runtime_config" : {
    "service_invoke" : {
      "auth_type" : "API_KEY",
      "direct_channel_auth_enable" : false,
      "direct_channel_enable" : false,
      "dynamic_routing_enable" : false,
      "ems_enable" : false,
      "internet_access_enable" : true,
      "intranet_approval_enable" : true,
      "port" : 9876,
      "protocol" : "HTTPS"
    },
    "service_limit" : {
      "ip_black_list" : [ ],
      "ip_white_list" : [ ],
      "rate_limit" : {
```

```
{
  "num": 200,
  "unit": "SECONDS"
},
"request_size_limit": 20,
"request_timeout": 30
},
"service_secret": {
  "group_enable": false,
  "secret_enable": false,
  "secret_volumes": [ ]
}
},
"upgrade_config": {
  "rolling_update": {
    "max_surge": "1%",
    "max_unavailable": "1%"
  },
  "type": "ROLLING"
},
"version": "0.0.1"
},
"workspace_id": "0"
}
```

状态码

状态码	描述
200	停止服务信息。

错误码

请参见[错误码](#)。

7.1.2 中断服务

功能介绍

中断服务接口用于中断处于“升级中”或“部署中”状态的服务，使其快速停止。该接口适用于以下场景：当服务出现严重故障需要立即修复、资源需要快速释放以部署更高优先级的服务，或在测试环境中需要快速迭代时，用户可通过此接口中断指定服务。使用该接口的前提条件是服务当前状态为“升级中”或“部署中”，且用户具有中断服务的权限。若服务为“部署中”状态，执行中断操作，服务状态将变成“停止”，相关资源将被释放，且中断操作将被记录；若服务为“升级中”状态，执行中断操作，服务状态将变成“运行中”。若服务当前状态不是“升级中”或“部署中”，接口将返回相应的错误信息。

URI

POST /v2/{project_id}/services/{service_id}/interrupt

表 7-27 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

请求参数

表 7-28 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json • application/json;charset=utf-8 默认取值： 不涉及。

表 7-29 请求 Body 参数

参数	是否必选	参数类型	描述
id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

响应参数

状态码：200

表 7-30 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 取值范围： 不涉及。
name	String	参数解释： 服务名，用户在 创建服务 时自定义的名称。 取值范围： 支持1-64位字符，可包含字母、中文、数字、中划线、下划线。
dispatcher_group_id	String	参数解释： 服务绑定的dispatcher组ID。 取值范围： 不涉及。
workspace_id	String	参数解释： 工作空间ID。 取值范围： 0：默认空间ID。 - 由数字和小写字母组成的32位字符：其他空间ID，可参考工作空间创建。
type	String	参数解释： 推理服务类型。 取值范围： REAL_TIME：在线服务。
deploy_type	String	参数解释： 部署方式。 取值范围： - SINGLE：单机单卡。 - MULTI：多机多卡。

参数	参数类型	描述
status	String	参数解释： 服务当前状态。 取值范围： • DEPLOYING：部署中。 • FAILED：失败。 • STOPPED：停止。 • RUNNING：运行中。 • DELETING：删除中。 • STOPPING：停止中。 • CONCERNING：告警。 • UPGRADING：升级中。 • ERROR：异常。 • INTERRUPTING：中断中。
failure_reason	String	参数解释： 在线服务失败原因。 取值范围： 不涉及。
version	ServiceVersionResponse object	参数解释： 当前服务版本信息。
predict_url	Array of predict_url_Response objects	参数解释： 在线服务访问地址。
tags	Array of TmsTag_Response objects	参数解释： TMS对接标签类。
create_at	String	参数解释： 创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
update_at	String	参数解释： 更新时间，根据更新时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。

参数	参数类型	描述
schedule	Array of ScheduleConfig_Response objects	参数解释： 定时停止配置。
provider	String	参数解释： 服务提供者的账号id（创建服务时通过X-Auth-Token-Provider请求头解析iam token而来），该值不为空时，该服务的所有更新操作需要在请求头中添加X-Auth-Token-Provider，取值为该账号id的domain级或project级token。

表 7-31 ServiceVersionResponse

参数	参数类型	描述
id	String	参数解释： 版本id。 取值范围： 不涉及。
version	String	参数解释： 版本号。 取值范围： 不涉及。
description	String	参数解释： 描述。 取值范围： 不涉及。
predict_url	String	参数解释： 推理请求的访问地址。 取值范围： 不涉及。
runtime_config	RuntimeConfig_Response object	参数解释： 服务运行配置。
upgrade_config	UpgradeConfig_Response object	参数解释： 服务升级配置。
instance_groups	Array of GroupConfig_Response objects	参数解释： 服务实例组信息。

参数	参数类型	描述
log_configs	Array of LogConfig_Response objects	参数解释： 服务日志配置信息。
deploy_timeout_minutes	Integer	参数解释： 部署超时时间。 取值范围： 不涉及。

表 7-32 RuntimeConfig_Response

参数	参数类型	描述
service_invoke	ServiceInvoke_Response object	参数解释： 服务调用时的相关配置。
service_limit	ServiceLimit_Response object	参数解释： 服务限制信息。 约束限制： 不涉及。
service_secret	ServiceSecret_Response object	参数解释： 服务密钥挂载。

表 7-33 ServiceInvoke_Response

参数	参数类型	描述
port	Integer	参数解释： 服务端口号。 取值范围： [1, 65535]。

参数	参数类型	描述
protocol	String	参数解释： 服务请求协议。当选择WSS与WS时，服务接口会升级为WebSocket。开启WebSocket时，不支持同时设置“服务流量限制”。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
auth_type	String	参数解释： 认证类型。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。
direct_channel_enable	Boolean	参数解释： 是否开启专属通道。 取值范围： • TRUE：开启专属通道。 • FALSE：不开启专属通道。
direct_channel_auth_enable	Boolean	参数解释： 专属通道模式下proxy是否开启鉴权。 取值范围： • TRUE：开启鉴权。 • FALSE：不开启鉴权。
internet_access_enable	Boolean	参数解释： 外网访问。 取值范围： • TRUE：要外网访问。 • FALSE：不要外网访问。
intranet_approve_enable	Boolean	参数解释： 内网审批。 取值范围： • TRUE：要内网审批。 • FALSE：不要内网审批。

参数	参数类型	描述
dynamic_routing_enable	Boolean	参数解释： 动态路由开关。 取值范围： • TRUE：开启动态路由。 • FALSE：不开启动态路由。
strategy	String	参数解释： 智能路由策略。 取值范围： • ROUND_ROBIN：轮询。 • ORIGIN_IP_HASH：源IP哈希。 • MIN_CONN：最小连接数。 • MIN_FIRST_TOKEN_TIME：最小首token时延。 • COMPOSITE：综合负载。 • SLO_BASED：SLO优先级。
metric_api_scheme	String	参数解释： 指标接口服务请求协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。
metric_api_port	String	参数解释： 指标接口端口号。 取值范围： [1, 65535]。
metric_api_path	String	参数解释： 指标接口path。 取值范围： 默认值metrics。
ems_enable	Boolean	参数解释： 是否开启EMS加速。 取值范围： • TRUE：开启EMS加速。 • FALSE：不开启EMS加速。

参数	参数类型	描述
request_retry_enable	Boolean	参数解释： proxy支持请求重调度开关。 取值范围： • true：开启proxy支持请求重调度。 • false：不开启proxy支持请求重调度。
request_retry_cnt_max	Integer	参数解释： proxy支持请求重调度的重试次数 取值范围： [1, 10]。
request_retry_interval_ms	Integer	参数解释： proxy支持请求重调度的重试间隔，单位ms 取值范围： [1, 10000]。

表 7-34 ServiceLimit_Response

参数	参数类型	描述
rate_limit	RateLimit_Response object	参数解释： 流控相关指标。
request_size_limit	Integer	参数解释： 请求大小限制。 取值范围： 1-50M。
request_timeout	Integer	参数解释： 超时时间。 取值范围： 1到7200秒。
ip_white_list	Array of strings	参数解释： IP白名单。
ip_black_list	Array of strings	参数解释： IP黑名单。

表 7-35 RateLimit_Response

参数	参数类型	描述
num	Integer	参数解释： 服务流量限制是指指定单位内一个服务能够被访问的次数上限。 取值范围： 1-500。
unit	String	参数解释： 流量限制单元。 取值范围： • NANOS（纳秒）。 • MICROS（微秒）。 • MILLIS（毫秒）。 • SECONDS（秒）。 • MINUTES（分钟）。 • HOURS（小时）。 • DAYS（天）。

表 7-36 ServiceSecret_Response

参数	参数类型	描述
secret_enable	Boolean	参数解释： 是否启用密钥。 取值范围： • true：启用密钥。 • false：不启用密钥。
secret_type	String	参数解释： 密钥类型。 取值范围： • custom：自定义密钥。
secret_volumes	SecretVolume_Response object	参数解释： 密钥挂载。 约束限制： 上限30个。

参数	参数类型	描述
group_enable	Boolean	参数解释： 是否启用镜像的用户组。 取值范围： • true：启用镜像的用户组。 • false：不启用镜像的用户组。
group_id	Long	参数解释： 镜像的用户组id。 取值范围： 1000~4294967294。

表 7-37 SecretVolume_Response

参数	参数类型	描述
secret_name	String	参数解释： 密钥名称。 取值范围： 不涉及。
secret_key	String	参数解释： 密钥key。 取值范围： 长度不大于63。
secret_value	String	参数解释： 密钥值。 取值范围： 长度不大于32768。
mountPath	String	参数解释： 挂载路径。 取值范围： 不涉及。

表 7-38 UpgradeConfig_Response

参数	参数类型	描述
type	String	参数解释： 升级类型。 取值范围： ROLLING：滚动升级，默认值。
rolling_update	RollingUpdate_Response object	参数解释： 滚动更新配置。

表 7-39 RollingUpdate_Response

参数	参数类型	描述
max_surge	String	参数解释： 滚动更新时最多可以启动多少个Pod。 取值范围： 不涉及。
max_unavailable	String	参数解释： 滚动更新时最多可以删除多少个Pod。 取值范围： 不涉及。

表 7-40 GroupConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例组ID。 取值范围： 不涉及。
name	String	参数解释： 实例组名称。 取值范围： 不涉及。

参数	参数类型	描述
pool_id	String	参数解释： 资源池ID，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 取值范围： 不涉及。
count	Integer	参数解释： 部署场景下，服务实例数量。 约束限制： 不涉及。 取值范围： [1, 128]。 默认取值： 不涉及。
system_log_dump_enable	Boolean	参数解释： 系统日志转储开关量。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： false
unit_configs	Array of UnitConfig_Response objects	参数解释： 实例单元配置。
weight	Integer	参数解释： 权重百分比，分配到此模型的流量权重，仅当模型部署为在线服务时需要配置。 取值范围： [0, 100]。
secret_type	String	参数解释： 凭证类型相关配置，用户可以在此处选择使用的凭证类型（dew，cce） 约束限制： 不涉及。

参数	参数类型	描述
secret_name	String	参数解释： 凭证名称，用户使用dew类型凭证时可以在此处选择使用的凭证。 约束限制： 不涉及。
priority	Integer	参数解释： 服务优先级。 约束限制： 不涉及。 取值范围： [1, 3]。 默认取值： 不涉及。
high_avail_switch	Boolean	参数解释： 高可用开关，开启后不同实例的pod将尽量均匀分布到不同的节点上。 取值范围： true: 高可用开启 false: 高可用关闭
framework	String	参数解释： 算法框架。 取值范围： COMMON：普通在线服务。

表 7-41 UnitConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例单元ID。 取值范围： 不涉及。
role	String	参数解释： 实例单元角色。 取值范围： common：表示其他角色。
custom_spec	CustomSpecResponse object	参数解释： 自定义资源规格配置。

参数	参数类型	描述
flavor	String	参数解释： 资源规格，根据所提供版本选择适合业务的规格。当specification为custom时表示自定义规格。由custom_spec指定部署的规格配置。 取值范围： 不涉及。
image	Image_Response object	参数解释： 镜像配置信息，包含镜像地址，镜像来源。
models	Array of Model_Response objects	参数解释： 模型相关配置，用户可以在此处选择模型及权重文件配合镜像使用。
codes	Array of Code_Response objects	参数解释： 代码相关配置，用户可以在此处选择代码所在的obs路径等。
dumps	Array of DumpResponse objects	参数解释： 转储相关配置，用户可以在此处选择转储的目的obs路径等。
count	Integer	参数解释： 配置实例个数，单机推理无需配置。 取值范围： 不涉及。
cmd	String	参数解释： 启动命令。 取值范围： 不涉及。
envs	Map<String,String>	参数解释： 环境变量。
readiness_health	Health_Response object	参数解释： 就绪健康检查。
startup_health	Health_Response object	参数解释： 启动健康检查。
liveness_health	Health_Response object	参数解释： 存活健康检查。

参数	参数类型	描述
port	Integer	参数解释： 端口。 取值范围： [1,65535]。
recovery	String	参数解释： 恢复策略重启等级。 取值范围： - Instance：实例级，故障时重新拉起整个实例。 - Pod：Pod级，故障时重新拉起故障pod。 - Custom：自定义级，故障时不做处理，留给用户处理。
npu_reset_enable	Boolean	参数解释： 是否开启恢复策略。 取值范围： - true：开启恢复策略。 - false：不开启恢复策略。
affinity	Affinity_Response object	参数解释： 节点亲和调度设置。

表 7-42 CustomSpecResponse

参数	参数类型	描述
gpu	Number	参数解释： GPU个数。 取值范围： 支持配置小数，输入值不能小于0（最多支持2位小数，小数点后第3位做四舍五入处理）。
memory	Integer	参数解释： 内存，单位为MB。 取值范围： 仅支持整数。

参数	参数类型	描述
cpu	Number	参数解释： CPU核数。 取值范围： 支持配置小数，输入值不能小于0.01（最多支持2位小数，小数点后第3位做四舍五入处理）。
ascend	Integer	参数解释： Ascend芯片个数。 取值范围： 不涉及。

表 7-43 Image_Response

参数	参数类型	描述
id	String	参数解释： 镜像id。 取值范围： 不涉及。
source	String	参数解释： 镜像类别，标识镜像来源。 取值范围： • swr：软件仓库服务。
swr_path	String	参数解释： 镜像地址，source不同取值时，地址为不同值。 取值范围： 不涉及。
category	String	参数解释： 镜像支持的规格。 取值范围： • GPU：图形处理器。 • CPU：中央处理器。 • ASCEND：昇腾芯片。

表 7-44 Model_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。 • LOCAL：挂载宿主机本地存储目录。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： 当存储类别为EFS时，支持配置子目录。 取值范围： 不涉及。
read_only	Boolean	参数解释： 挂载权限设置，是否只读。 取值范围： • true：只读。 • false：非只读。
os_warm_up	Boolean	参数解释： os预热。 取值范围： • true：预热。 • false：不预热。

表 7-45 Code_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
source_id	String	参数解释： 代码来源id，与address二选一，当且仅当source为EFS时，可以传入sfs turbo的id。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： sfs 子路径。 取值范围： 不涉及。

参数	参数类型	描述
read_only	Boolean	参数解释： 是否只读。 取值范围： • true：只读。 • false：非只读。

表 7-46 DumpResponse

参数	参数类型	描述
source	String	参数解释： 用户转储来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。
address	String	参数解释： 用户转储来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及。
type	String	参数解释： 转储类型。 取值范围： • DUMP：用户自定义转储。 • DUMP_SYS：系统转储。

表 7-47 Health_Response

参数	参数类型	描述
check_method	String	参数解释： 健康检查方式：HTTP 或者 EXEC（命令行）。 取值范围： • HTTP：超文本传输协议。 • EXEC：命令行。
cmd	String	参数解释： 当健康检查方式为EXEC时，配置的命令行。 取值范围： 不涉及。
url	String	参数解释： 当健康检查方式为HTTP 时，配置的请求地址。 取值范围： 不涉及。
protocol	String	参数解释： 连接协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
initial_delay_seconds	Integer	参数解释： 执行首次探测时，应该等待的时间。 取值范围： 不涉及。
timeout_seconds	Integer	参数解释： 执行探测的超时时间，默认1秒，最小1秒。 取值范围： 不涉及。

参数	参数类型	描述
period_seconds	Integer	参数解释： 执行健康检查的周期时间，执行探测的频率。默认是10秒，最小1秒。 取值范围： 不涉及。
failure_threshold	Integer	参数解释： 探测成功后，最少连续探测失败多少次才被认定为失败。默认是3。最小值是1。 取值范围： 不涉及。

表 7-48 Affinity_Response

参数	参数类型	描述
affinity_type	String	参数解释： 节点亲和类型。 取值范围： - AFFINITY：亲和。 - ANTI_AFFINITY：反亲和。
required	Boolean	参数解释： 是否设置强亲和。 取值范围： - true：设置强亲和。 - false：不设置强亲和。
selection_mode	String	参数解释： 选择节点方式。 取值范围： IP。
targets	Map<String,String>	参数解释： 通过上述方式选择的列表，长度不能超过20。

表 7-49 LogConfig_Response

参数	参数类型	描述
type	String	参数解释： 日志输出类型。 取值范围： • STDOUT：日志输出到控制台或终端。 • FILE：日志输出到文件。
status	String	参数解释： 日志服务状态。 取值范围： • ON：开启。 • OFF：关闭。
log_group_id	String	参数解释： 日志组id，用户选择自己已有的日志组，不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
log_stream_id	String	参数解释： 日志流id，用户选择自己已有的日志组。不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-50 predict_url_Response

参数	参数类型	描述
type	String	参数解释： 访问方式。 取值范围： • CONSOLE：通过控制台界面访问。 • PUBLIC：通过公网访问。 • INTERNAL：通过内网访问。 • DIRECT_CHANNEL：通过直接通道访问。
urls	Array of strings	参数解释： 推理请求的访问地址，仅当type为real-time时，且服务部署完成后才会确保该字段有值。

表 7-51 TmsTag_Response

参数	参数类型	描述
key	String	参数解释： 标签键字段。 约束限制： 不涉及。 取值范围： 长度为1~128，标签的键可以包含任意语种字母、数字、空格，以及_ . : = + - @ 特殊字符，但首尾不能含有空格，不能以_sys_开头。 默认取值： 不涉及。
value	String	参数解释： 标签值字段。 取值范围： 长度为255，包括字母、数字、下划线、点、斜杠、等号、加号、减号和@符号。

表 7-52 ScheduleConfig_Response

参数	参数类型	描述
due_time	Long	参数解释： 触发时间，13位时间戳。 取值范围： 不涉及。
duration	Integer	参数解释： 对应的时间单位的数值。 取值范围： 不涉及。
time_unit	String	参数解释： 调度时间单位。 取值范围： - MINUTES：分钟。 - HOURS：小时。 - DAYS：天。
type	String	参数解释： 调度类型，当前仅支持取值为stop。 取值范围： STOP：停止。
processed	Boolean	参数解释： 表示是否处理完成。 取值范围： - true：该定时任务已经执行过。 - false：该定时任务尚未执行。

请求示例

中断指定的在线服务。

```
POST https://{endpoint}/v2/{project_id}/services/{service_id}/interrupt
```

响应示例

状态码：200

中断指定的在线服务。

```
{
  "create_at" : 1751608828683,
  "deploy_timeout_minutes" : 60,
  "deploy_type" : "SINGLE",
  "dispatcher_group_id" : "dispatcher_group_id",
  "failure_reason" : ""
}
```

```
"id" : "id",
"name" : "service-2aa2",
"predict_url" : [ {
  "type" : "PUBLIC",
  "urls" : [ "12.12.123.123" ]
}, {
  "type" : "CONSOLE",
  "urls" : [ "12.12.123.123" ]
}, {
  "type" : "DIRECT_CHANNEL",
  "urls" : [ ]
} ],
"schedule" : [ ],
"status" : "INTERRUPTING",
"tags" : [ ],
"type" : "REAL_TIME",
"update_at" : 1751609729600,
"version" : {
  "deploy_timeout_minutes" : 60,
  "description" : "API_KEY",
  "id" : "id",
  "instance_groups" : [ {
    "count" : 1,
    "framework" : "COMMON",
    "id" : "id",
    "name" : "instance-533c",
    "pool_id" : "pool_id",
    "priority" : 1,
    "unit_configs" : [ {
      "cmd" : "",
      "codes" : [ ],
      "count" : 1,
      "custom_spec" : {
        "cpu" : 0.1,
        "memory" : 50
      },
      "id" : "id",
      "image" : {
        "category" : "CPU",
        "id" : "8d4f342d298b157c6b31697d9012f907404f318ab5d9c270a22087f4e08e6883",
        "source" : "SWR",
        "swr_path" : "swr.cn-north-7.myhuaweicloud.com/example/helloworld-example:0.0.1"
      },
      "models" : [ ],
      "npu_reset_enable" : false
    } ],
    "weight" : 100
  } ],
  "log_configs" : [ {
    "status" : "OFF",
    "type" : "STDOUT"
  } ],
  "runtime_config" : {
    "service_invoke" : {
      "auth_type" : "API_KEY",
      "direct_channel_auth_enable" : false,
      "direct_channel_enable" : false,
      "dynamic_routing_enable" : false,
      "ems_enable" : false,
      "internet_access_enable" : true,
      "intranet_approval_enable" : true,
      "port" : 9876,
      "protocol" : "HTTPS"
    },
    "service_limit" : {
      "ip_black_list" : [ ],
      "ip_white_list" : [ ],
      "rate_limit" : {
        "num" : 200,
```

```
    "unit": "SECONDS"
  },
  "request_size_limit": 20,
  "request_timeout": 30
},
"service_secret": {
  "group_enable": false,
  "secret_enable": false,
  "secret_volumes": [ ]
}
},
"upgrade_config": {
  "rolling_update": {
    "max_surge": "1%",
    "max_unavailable": "1%"
  },
  "type": "ROLLING"
},
"version": "0.0.2"
},
"workspace_id": "0"
}
```

状态码

状态码	描述
200	中断指定的在线服务。

错误码

请参见[错误码](#)。

7.1.3 查询服务列表

功能介绍

支持分页和筛选，适用于用户在管理控制台或通过API需要查看特定条件下（如服务状态、名称等）的服务列表的情况。调用此接口前，用户必须具有查询服务列表的权限，并提供合法的分页参数（如页码、每页条数）和筛选条件（如服务状态、名称、推理服务类型等）。调用成功后，系统将返回符合筛选条件的服务列表，包含指定页码的数据，并返回总页数和总记录数。如果用户没有查询服务列表的权限，或提供的分页参数和筛选条件不合法，调用将返回相应的错误信息。如果系统在查询过程中遇到内部错误，也将返回错误信息并记录日志。

URI

GET /v2/{project_id}/services

表 7-53 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

表 7-54 Query 参数

参数	是否必选	参数类型	描述
id	否	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。
pool_id	否	String	参数解释： 资源池ID，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
pool_name	否	String	参数解释： 资源池name，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
sort_key	否	String	参数解释： 排序字段，多个字段以","分隔，支持create_at, update_at，默认值update_at。 约束限制： 不涉及。 取值范围： ● create_at：按创建时间排序。 ● update_at：按更新时间排序。 默认取值： update_at。

参数	是否必选	参数类型	描述
status	否	String	参数解释： 服务当前状态，一次只支持一种状态筛选。默认不过滤。 约束限制： 不涉及。 取值范围： • DEPLOYING：部署中。 • FAILED：失败。 • STOPPED：停止。 • RUNNING：运行中。 • DELETING：删除中。 • STOPPING：停止中。 • CONCERNING：告警。 • UPGRADING：升级中。 • ERROR：异常。 • INTERRUPTING：中断中。 默认取值： 不涉及。
name	否	String	参数解释： 服务名，用户在 创建服务 时自定义。 约束限制： 服务在删除之前名字不能重复。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
auth_type	否	String	参数解释： 认证类型，默认不过滤。 约束限制： 不涉及。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。 默认取值： 不涉及。
type	否	String	参数解释： 推理服务类型。 约束限制： 不涉及。 取值范围： • REAL_TIME：在线服务。 默认取值： 不涉及。
description	否	String	参数解释： 服务描述，模糊查询，默认不过滤。由用户 创建服务 时自行填写。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
workspace_id	否	String	参数解释： 工作空间ID。 取值范围： 0：默认空间ID - 由数字和小写字母组成的32位字符：其他空间ID，可参考工作空间创建 约束限制： 不涉及。 默认取值： 不涉及。
user_name	否	String	参数解释： 创建者，即创建服务的用户名。 约束限制： 不涉及。 取值范围： 创建服务的用户名。 默认取值： 不涉及。
tags	否	String	参数解释： 标签，查询指定标签的服务，默认不过滤。根据标签过滤service参数，格式：每组tag之间使用英文逗号分隔，每个标签内的key和value使用英文竖划线分隔，例：tag_key1 tag_value1,tag_key2 tag_value2 约束限制： 不以逗号，竖划线开头，不以逗号结尾，不出现连续的竖划线和逗号，允许中文、西文、葡文等语言以及空格_./=+-@特殊字符，且字符间以逗号或者竖划线分隔。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
sort_dir	否	String	参数解释： 排序方式 约束限制： 不涉及。 取值范围： • ASC: 递增排序。 • DESC: 递减排序。 默认取值： DESC。
limit	否	Integer	参数解释： 指定返回的最大条目数。 约束限制： 不涉及。 取值范围： [1,500] 默认取值： 10。
offset	否	Integer	参数解释： 分页列表查询的偏移量。 约束限制： offset必须是limit的整数倍。 取值范围： 不涉及。 默认取值： 0。

请求参数

表 7-55 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json。 • application/json;charset=utf-8。 默认取值： 不涉及。

响应参数

状态码：200

表 7-56 响应 Body 参数

参数	参数类型	描述
data	Array of data objects	参数解释： 在线服务数据。
current	Integer	参数解释： 当前页码，从0开始计数。 取值范围： 不涉及。

参数	参数类型	描述
size	Integer	参数解释： 当前页数量。 取值范围： 不涉及。
pages	Integer	参数解释： 总页数，根据传入的limit字段和数据总条数计算得出。如总记录条数为10，limit（单页最大条目数）为3，则页数为4。 取值范围： 不涉及。
total	Integer	参数解释： 总记录条数。 取值范围： 不涉及。
schedule	Array of ScheduleConfig_Response objects	参数解释： 定时停止配置。

表 7-57 data

参数	参数类型	描述
id	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 取值范围： 服务ID。
name	String	参数解释： 服务名，用户在 创建服务 时自定义。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。

参数	参数类型	描述
status	String	参数解释： 服务当前状态，一次只支持一种状态筛选。默认不过滤。 取值范围： • DEPLOYING：部署中。 • FAILED：失败。 • STOPPED：停止。 • RUNNING：运行中。 • DELETING：删除中。 • STOPPING：停止中。 • CONCERNING：告警。 • UPGRADING：升级中。 • ERROR：异常。 • INTERRUPTING：中断中。
version	String	参数解释： 服务版本号，以数字及点号组成，形如 1.0.1。 取值范围： 版本长度不超过8位。
version_count	Integer	参数解释： 服务版本数量。 取值范围： 不涉及。
description	String	参数解释： 服务描述，由用户 创建服务 时自行填写。 取值范围： 不涉及
type	String	参数解释： 推理服务类型。 约束限制： 不涉及。 取值范围： • REAL_TIME：在线服务。 默认取值： 不涉及。

参数	参数类型	描述
deploy_type	String	参数解释： 部署类型。 取值范围： • SINGLE：单机单卡。 • MULTI：多机多卡。
user_name	String	参数解释： 创建服务的用户名。 取值范围： 用户名。
workspace_id	String	参数解释： 工作空间ID。 取值范围： • 0：默认空间ID。 • 由数字和小写字母组成的32位字符：其他空间ID，可参考工作空间创建。
create_at	Long	参数解释： 创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字
update_at	Long	参数解释： 更新时间，根据更新时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字。
auth_type	String	参数解释： 在线服务认证类型。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。
tags	Array of TmsTag_Response objects	参数解释： 在线服务标签数据

表 7-58 TmsTag_Response

参数	参数类型	描述
key	String	参数解释： 标签键字段。 约束限制： 不涉及。 取值范围： 长度为1~128，标签的键可以包含任意语种字母、数字、空格，以及_ . : = + - @ 特殊字符，但首尾不能含有空格，不能以_sys_开头。 默认取值： 不涉及。
value	String	参数解释： 标签值字段。 取值范围： 长度为255，包括字母、数字、下划线、点、斜杠、等号、加号、减号和@符号。

表 7-59 ScheduleConfig_Response

参数	参数类型	描述
due_time	Long	参数解释： 触发时间，13位时间戳。 取值范围： 不涉及。
duration	Integer	参数解释： 对应的时间单位的数值。 取值范围： 不涉及。
time_unit	String	参数解释： 调度时间单位。 取值范围： • MINUTES：分钟。 • HOURS：小时。 • DAYS：天。

参数	参数类型	描述
type	String	参数解释： 调度类型，当前仅支持取值为stop。 取值范围： • STOP：停止。
processed	Boolean	参数解释： 表示是否处理完成。 取值范围： • true：该定时任务已经执行过。 • false：该定时任务尚未执行。

请求示例

查询服务列表。其中limit表示一次查询返回的最大数量，offset表示从第几个开始往后返回，status必须为大写，name为模糊查询字段，表示本次查询结果中服务name所包含的值，id为精准查询字段，表示本次查询结果的服务id。

```
GET https://{endpoint}/v2/{project_id}/services?  
limit=50&offset=0&type=REAL_TIME&status=STOPPED&name=test&id=testid
```

响应示例

状态码：200

服务列表信息。

```
{  
  "current": 0,  
  "data": [  
    {  
      "id": "841e8dc2-2640-4916-ad21-a18b147b9149",  
      "name": "123zyq-raw2505231619",  
      "status": "STOPPED",  
      "version": "0.0.0",  
      "version_count": 1,  
      "description": "infer-description",  
      "type": "REAL_TIME",  
      "deploy_type": "SINGLE",  
      "user_name": "hongchong",  
      "workspace_id": "0",  
      "create_at": 1747990876171,  
      "update_at": 1747994527244,  
      "auth_type": "API_KEY",  
      "tags": [  
        {  
          "key": "标签key",  
          "value": "标签value"  
        }  
      ]  
    },  
    {  
      "id": "841e8dc2-2640-4916-ad21-a18b147b9149",  
      "name": "123zyq-raw2505231619",  
      "status": "STOPPED",  
      "version": "0.0.0",  
      "version_count": 1,  
      "description": "infer-description",  
      "type": "REAL_TIME",  
      "deploy_type": "SINGLE",  
      "user_name": "hongchong",  
      "workspace_id": "0",  
      "create_at": 1747990876171,  
      "update_at": 1747994527244,  
      "auth_type": "API_KEY",  
      "tags": [  
        {  
          "key": "标签key",  
          "value": "标签value"  
        }  
      ]  
    }  
  ],  
  "schedule": [  
    {  
      "due_time": 1749798035000,  
      "duration": 3,  
      "processed": true,  
      "time_unit": "HOURS",  
      "type": "STOP"  
    }  
  ]  
}
```

```
    }  
  ]  
}  
],  
"pages": 1,  
"size": 1,  
"total": 1  
}
```

状态码

状态码	描述
200	服务列表信息。

错误码

请参见[错误码](#)。

7.1.4 启动在线服务

功能介绍

使服务从“停止”或“失败”状态进入“部署中”状态，适用于用户需要重新启动已停止或启动失败的服务的情况。调用此接口前，服务状态必须为“停止”或“失败”，且用户需具有启动服务的权限。调用成功后，服务状态将变为“部署中”，系统将开始执行部署流程，包括资源准备、配置加载等。如果服务当前状态不是“停止”或“失败”，或用户没有启动服务的权限，调用将返回错误。

URI

POST /v2/{project_id}/services/{service_id}/start

表 7-60 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

请求参数

表 7-61 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json。 • application/json;charset=utf-8。 默认取值： 不涉及。

表 7-62 请求 Body 参数

参数	是否必选	参数类型	描述
id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

响应参数

状态码：200

表 7-63 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 取值范围： 不涉及。
name	String	参数解释： 服务名，用户在 创建服务 时自定义的名称。 取值范围： 支持1-64位字符，可包含字母、中文、数字、中划线、下划线。
dispatcher_group_id	String	参数解释： 服务绑定的dispatcher组ID。 取值范围： 不涉及。

参数	参数类型	描述
workspace_id	String	参数解释： 工作空间ID。 取值范围： 0：默认空间ID。 - 由数字和小写字母组成的32位字符：其他空间ID，可参考工作空间创建。
type	String	参数解释： 推理服务类型。 取值范围： REAL_TIME：在线服务。
deploy_type	String	参数解释： 部署方式。 取值范围： - SINGLE：单机单卡。 - MULTI：多机多卡。
status	String	参数解释： 服务当前状态。 取值范围： - DEPLOYING：部署中。 - FAILED：失败。 - STOPPED：停止。 - RUNNING：运行中。 - DELETING：删除中。 - STOPPING：停止中。 - CONCERNING：告警。 - UPGRADING：升级中。 - ERROR：异常。 - INTERRUPTING：中断中。
failure_reason	String	参数解释： 在线服务失败原因。 取值范围： 不涉及。
version	ServiceVersionResponse object	参数解释： 当前服务版本信息。
predict_url	Array of predict_url_Response objects	参数解释： 在线服务访问地址。

参数	参数类型	描述
tags	Array of TmsTag_Response objects	参数解释： TMS对接标签类。
create_at	String	参数解释： 创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
update_at	String	参数解释： 更新时间，根据更新时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
schedule	Array of ScheduleConfig_Response objects	参数解释： 定时停止配置。
provider	String	参数解释： 服务提供者的账号id（创建服务时通过X-Auth-Token-Provider请求头解析iam token而来），该值不为空时，该服务的所有更新操作需要在请求头中添加X-Auth-Token-Provider，取值为该账号id的domain级或project级token。

表 7-64 ServiceVersionResponse

参数	参数类型	描述
id	String	参数解释： 版本id。 取值范围： 不涉及。
version	String	参数解释： 版本号。 取值范围： 不涉及。

参数	参数类型	描述
description	String	参数解释： 描述。 取值范围： 不涉及。
predict_url	String	参数解释： 推理请求的访问地址。 取值范围： 不涉及。
runtime_config	RuntimeConfig_Response object	参数解释： 服务运行配置。
upgrade_config	UpgradeConfig_Response object	参数解释： 服务升级配置。
instance_groups	Array of GroupConfig_Response objects	参数解释： 服务实例组信息。
log_configs	Array of LogConfig_Response objects	参数解释： 服务日志配置信息。
deploy_timeout_minutes	Integer	参数解释： 部署超时时间。 取值范围： 不涉及。

表 7-65 RuntimeConfig_Response

参数	参数类型	描述
service_invoke	ServiceInvoke_Response object	参数解释： 服务调用时的相关配置。
service_limit	ServiceLimit_Response object	参数解释： 服务限制信息。 约束限制： 不涉及。
service_secret	ServiceSecret_Response object	参数解释： 服务密钥挂载。

表 7-66 ServiceInvoke_Response

参数	参数类型	描述
port	Integer	参数解释： 服务端口号。 取值范围： [1, 65535]。
protocol	String	参数解释： 服务请求协议。当选择WSS与WS时，服务接口会升级为WebSocket。开启WebSocket时，不支持同时设置“服务流量限制”。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
auth_type	String	参数解释： 认证类型。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。
direct_channel_enable	Boolean	参数解释： 是否开启专属通道。 取值范围： • TRUE：开启专属通道。 • FALSE：不开启专属通道。
direct_channel_auth_enable	Boolean	参数解释： 专属通道模式下proxy是否开启鉴权。 取值范围： • TRUE：开启鉴权。 • FALSE：不开启鉴权。
internet_access_enable	Boolean	参数解释： 外网访问。 取值范围： • TRUE：要外网访问。 • FALSE：不要外网访问。

参数	参数类型	描述
intranet_approve_enable	Boolean	参数解释： 内网审批。 取值范围： • TRUE：要内网审批。 • FALSE：不要内网审批。
dynamic_routing_enable	Boolean	参数解释： 动态路由开关。 取值范围： • TRUE：开启动态路由。 • FALSE：不开启动态路由。
strategy	String	参数解释： 智能路由策略。 取值范围： • ROUND_ROBIN：轮询。 • ORIGIN_IP_HASH：源IP哈希。 • MIN_CONN：最小连接数。 • MIN_FIRST_TOKEN_TIME：最小首token时延。 • COMPOSITE：综合负载。 • SLO_BASED：SLO优先级。
metric_api_scheme	String	参数解释： 指标接口服务请求协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。
metric_api_port	String	参数解释： 指标接口端口号。 取值范围： [1, 65535]。
metric_api_path	String	参数解释： 指标接口path。 取值范围： 默认值metrics。

参数	参数类型	描述
ems_enable	Boolean	参数解释： 是否开启EMS加速。 取值范围： - TRUE：开启EMS加速。 - FALSE：不开启EMS加速。
request_retry_enable	Boolean	参数解释： proxy支持请求重调度开关。 取值范围： - true：开启proxy支持请求重调度。 - false：不开启proxy支持请求重调度。
request_retry_cnt_max	Integer	参数解释： proxy支持请求重调度的重试次数 取值范围： [1, 10]。
request_retry_interval_ms	Integer	参数解释： proxy支持请求重调度的重试间隔，单位ms 取值范围： [1, 10000]。

表 7-67 ServiceLimit_Response

参数	参数类型	描述
rate_limit	RateLimit_Response object	参数解释： 流控相关指标。
request_size_limit	Integer	参数解释： 请求大小限制。 取值范围： 1-50M。
request_timeout	Integer	参数解释： 超时时间。 取值范围： 1到7200秒。
ip_white_list	Array of strings	参数解释： IP白名单。

参数	参数类型	描述
ip_black_list	Array of strings	参数解释： IP黑名单。

表 7-68 RateLimit_Response

参数	参数类型	描述
num	Integer	参数解释： 服务流量限制是指指定单位内一个服务能够被访问的次数上限。 取值范围： 1-500。
unit	String	参数解释： 流量限制单元。 取值范围： • NANOS（纳秒）。 • MICROS（微秒）。 • MILLIS（毫秒）。 • SECONDS（秒）。 • MINUTES（分钟）。 • HOURS（小时）。 • DAYS（天）。

表 7-69 ServiceSecret_Response

参数	参数类型	描述
secret_enable	Boolean	参数解释： 是否启用密钥。 取值范围： • true：启用密钥。 • false：不启用密钥。
secret_type	String	参数解释： 密钥类型。 取值范围： • custom：自定义密钥。

参数	参数类型	描述
secret_volumes	SecretVolume_Response object	参数解释： 密钥挂载。 约束限制： 上限30个。
group_enable	Boolean	参数解释： 是否启用镜像的用户组。 取值范围： • true：启用镜像的用户组。 • false：不启用镜像的用户组。
group_id	Long	参数解释： 镜像的用户组id。 取值范围： 1000~4294967294。

表 7-70 SecretVolume_Response

参数	参数类型	描述
secret_name	String	参数解释： 密钥名称。 取值范围： 不涉及。
secret_key	String	参数解释： 密钥key。 取值范围： 长度不大于63。
secret_value	String	参数解释： 密钥值。 取值范围： 长度不大于32768。
mountPath	String	参数解释： 挂载路径。 取值范围： 不涉及。

表 7-71 UpgradeConfig_Response

参数	参数类型	描述
type	String	参数解释： 升级类型。 取值范围： ROLLING：滚动升级，默认值。
rolling_update	RollingUpdate_Response object	参数解释： 滚动更新配置。

表 7-72 RollingUpdate_Response

参数	参数类型	描述
max_surge	String	参数解释： 滚动更新时最多可以启动多少个Pod。 取值范围： 不涉及。
max_unavailable	String	参数解释： 滚动更新时最多可以删除多少个Pod。 取值范围： 不涉及。

表 7-73 GroupConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例组ID。 取值范围： 不涉及。
name	String	参数解释： 实例组名称。 取值范围： 不涉及。

参数	参数类型	描述
pool_id	String	参数解释： 资源池ID，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 取值范围： 不涉及。
count	Integer	参数解释： 部署场景下，服务实例数量。 约束限制： 不涉及。 取值范围： [1, 128]。 默认取值： 不涉及。
system_log_dump_enable	Boolean	参数解释： 系统日志转储开关量。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： false
unit_configs	Array of UnitConfig_Response objects	参数解释： 实例单元配置。
weight	Integer	参数解释： 权重百分比，分配到此模型的流量权重，仅当模型部署为在线服务时需要配置。 取值范围： [0, 100]。
secret_type	String	参数解释： 凭证类型相关配置，用户可以在此处选择使用的凭证类型（dew，cce） 约束限制： 不涉及。

参数	参数类型	描述
secret_name	String	参数解释： 凭证名称，用户使用dew类型凭证时可以在此处选择使用的凭证。 约束限制： 不涉及。
priority	Integer	参数解释： 服务优先级。 约束限制： 不涉及。 取值范围： [1, 3]。 默认取值： 不涉及。
high_avail_switch	Boolean	参数解释： 高可用开关，开启后不同实例的pod将尽量均匀分布到不同的节点上。 取值范围： true: 高可用开启 false: 高可用关闭
framework	String	参数解释： 算法框架。 取值范围： COMMON： 普通在线服务。

表 7-74 UnitConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例单元ID。 取值范围： 不涉及。
role	String	参数解释： 实例单元角色。 取值范围： common： 表示其他角色。
custom_spec	CustomSpecResponse object	参数解释： 自定义资源规格配置。

参数	参数类型	描述
flavor	String	参数解释： 资源规格，根据所提供版本选择适合业务的规格。当specification为custom时表示自定义规格。由custom_spec指定部署的规格配置。 取值范围： 不涉及。
image	Image_Response object	参数解释： 镜像配置信息，包含镜像地址，镜像来源。
models	Array of Model_Response objects	参数解释： 模型相关配置，用户可以在此处选择模型及权重文件配合镜像使用。
codes	Array of Code_Response objects	参数解释： 代码相关配置，用户可以在此处选择代码所在的obs路径等。
dumps	Array of DumpResponse objects	参数解释： 转储相关配置，用户可以在此处选择转储的目的obs路径等。
count	Integer	参数解释： 配置实例个数，单机推理无需配置。 取值范围： 不涉及。
cmd	String	参数解释： 启动命令。 取值范围： 不涉及。
envs	Map<String,String>	参数解释： 环境变量。
readiness_health	Health_Response object	参数解释： 就绪健康检查。
startup_health	Health_Response object	参数解释： 启动健康检查。
liveness_health	Health_Response object	参数解释： 存活健康检查。

参数	参数类型	描述
port	Integer	参数解释： 端口。 取值范围： [1,65535]。
recovery	String	参数解释： 恢复策略重启等级。 取值范围： - Instance：实例级，故障时重新拉起整个实例。 - Pod：Pod级，故障时重新拉起故障pod。 - Custom：自定义级，故障时不做处理，留给用户处理。
npu_reset_enable	Boolean	参数解释： 是否开启恢复策略。 取值范围： - true：开启恢复策略。 - false：不开启恢复策略。
affinity	Affinity_Response object	参数解释： 节点亲和调度设置。

表 7-75 CustomSpecResponse

参数	参数类型	描述
gpu	Number	参数解释： GPU个数。 取值范围： 支持配置小数，输入值不能小于0（最多支持2位小数，小数点后第3位做四舍五入处理）。
memory	Integer	参数解释： 内存，单位为MB。 取值范围： 仅支持整数。

参数	参数类型	描述
cpu	Number	参数解释： CPU核数。 取值范围： 支持配置小数，输入值不能小于0.01（最多支持2位小数，小数点后第3位做四舍五入处理）。
ascend	Integer	参数解释： Ascend芯片个数。 取值范围： 不涉及。

表 7-76 Image_Response

参数	参数类型	描述
id	String	参数解释： 镜像id。 取值范围： 不涉及。
source	String	参数解释： 镜像类别，标识镜像来源。 取值范围： • swr：软件仓库服务。
swr_path	String	参数解释： 镜像地址，source不同取值时，地址为不同值。 取值范围： 不涉及。
category	String	参数解释： 镜像支持的规格。 取值范围： • GPU：图形处理器。 • CPU：中央处理器。 • ASCEND：昇腾芯片。

表 7-77 Model_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。 • LOCAL：挂载宿主机本地存储目录。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： 当存储类别为EFS时，支持配置子目录。 取值范围： 不涉及。
read_only	Boolean	参数解释： 挂载权限设置，是否只读。 取值范围： • true：只读。 • false：非只读。
os_warm_up	Boolean	参数解释： os预热。 取值范围： • true：预热。 • false：不预热。

表 7-78 Code_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
source_id	String	参数解释： 代码来源id，与address二选一，当且仅当source为EFS时，可以传入sfs turbo的id。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： sfs 子路径。 取值范围： 不涉及。

参数	参数类型	描述
read_only	Boolean	参数解释： 是否只读。 取值范围： • true：只读。 • false：非只读。

表 7-79 DumpResponse

参数	参数类型	描述
source	String	参数解释： 用户转储来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。
address	String	参数解释： 用户转储来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及。
type	String	参数解释： 转储类型。 取值范围： • DUMP：用户自定义转储。 • DUMP_SYS：系统转储。

表 7-80 Health_Response

参数	参数类型	描述
check_method	String	参数解释： 健康检查方式：HTTP 或者 EXEC（命令行）。 取值范围： • HTTP：超文本传输协议。 • EXEC：命令行。
cmd	String	参数解释： 当健康检查方式为EXEC时，配置的命令行。 取值范围： 不涉及。
url	String	参数解释： 当健康检查方式为HTTP 时，配置的请求地址。 取值范围： 不涉及。
protocol	String	参数解释： 连接协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
initial_delay_seconds	Integer	参数解释： 执行首次探测时，应该等待的时间。 取值范围： 不涉及。
timeout_seconds	Integer	参数解释： 执行探测的超时时间，默认1秒，最小1秒。 取值范围： 不涉及。

参数	参数类型	描述
period_seconds	Integer	参数解释： 执行健康检查的周期时间，执行探测的频率。默认是10秒，最小1秒。 取值范围： 不涉及。
failure_threshold	Integer	参数解释： 探测成功后，最少连续探测失败多少次才被认定为失败。默认是3。最小值是1。 取值范围： 不涉及。

表 7-81 Affinity_Response

参数	参数类型	描述
affinity_type	String	参数解释： 节点亲和类型。 取值范围： - AFFINITY：亲和。 - ANTI_AFFINITY：反亲和。
required	Boolean	参数解释： 是否设置强亲和。 取值范围： - true：设置强亲和。 - false：不设置强亲和。
selection_mode	String	参数解释： 选择节点方式。 取值范围： IP。
targets	Map<String,String>	参数解释： 通过上述方式选择的列表，长度不能超过20。

表 7-82 LogConfig_Response

参数	参数类型	描述
type	String	参数解释： 日志输出类型。 取值范围： • STDOUT：日志输出到控制台或终端。 • FILE：日志输出到文件。
status	String	参数解释： 日志服务状态。 取值范围： • ON：开启。 • OFF：关闭。
log_group_id	String	参数解释： 日志组id，用户选择自己已有的日志组，不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
log_stream_id	String	参数解释： 日志流id，用户选择自己已有的日志组。不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-83 predict_url_Response

参数	参数类型	描述
type	String	参数解释： 访问方式。 取值范围： • CONSOLE：通过控制台界面访问。 • PUBLIC：通过公网访问。 • INTERNAL：通过内网访问。 • DIRECT_CHANNEL：通过直接通道访问。
urls	Array of strings	参数解释： 推理请求的访问地址，仅当type为real-time时，且服务部署完成后才会确保该字段有值。

表 7-84 TmsTag_Response

参数	参数类型	描述
key	String	参数解释： 标签键字段。 约束限制： 不涉及。 取值范围： 长度为1~128，标签的键可以包含任意语种字母、数字、空格，以及_ . : = + - @ 特殊字符，但首尾不能含有空格，不能以_sys_开头。 默认取值： 不涉及。
value	String	参数解释： 标签值字段。 取值范围： 长度为255，包括字母、数字、下划线、点、斜杠、等号、加号、减号和@符号。

表 7-85 ScheduleConfig_Response

参数	参数类型	描述
due_time	Long	参数解释： 触发时间，13位时间戳。 取值范围： 不涉及。
duration	Integer	参数解释： 对应的时间单位的数值。 取值范围： 不涉及。
time_unit	String	参数解释： 调度时间单位。 取值范围： - MINUTES：分钟。 - HOURS：小时。 - DAYS：天。
type	String	参数解释： 调度类型，当前仅支持取值为stop。 取值范围： STOP：停止。
processed	Boolean	参数解释： 表示是否处理完成。 取值范围： - true：该定时任务已经执行过。 - false：该定时任务尚未执行。

请求示例

启动指定的在线服务。

```
POST https://{endpoint}/v2/{project_id}/services/{service_id}/start
```

响应示例

状态码：200

服务的启动响应。

```
{
  "create_at" : 1751608828683,
  "deploy_timeout_minutes" : 60,
  "deploy_type" : "SINGLE",
  "dispatcher_group_id" : "dispatcher_group_id",
  "failure_reason" : ""
}
```

```
"id" : "id",
"name" : "service-2aa2",
"predict_url" : [ {
  "type" : "PUBLIC",
  "urls" : [ "12.23.123.233" ]
}, {
  "type" : "CONSOLE",
  "urls" : [ "12.23.123.233" ]
}, {
  "type" : "DIRECT_CHANNEL",
  "urls" : [ ]
} ],
"schedule" : [ ],
"status" : "DEPLOYING",
"tags" : [ ],
"type" : "REAL_TIME",
"update_at" : 1751609619920,
"version" : {
  "deploy_timeout_minutes" : 60,
  "description" : "API_KEY",
  "id" : "id",
  "instance_groups" : [ {
    "count" : 1,
    "framework" : "COMMON",
    "id" : "id",
    "name" : "instance-a39b",
    "pool_id" : "pool_id",
    "priority" : 1,
    "unit_configs" : [ {
      "cmd" : "",
      "codes" : [ ],
      "count" : 1,
      "custom_spec" : {
        "arch" : "x86",
        "cpu" : 0.1,
        "memory" : 40
      },
      "id" : "id",
      "image" : {
        "category" : "CPU",
        "id" : "id",
        "source" : "SWR",
        "swr_path" : "swr.cn-north-7.myhuaweicloud.com/example/helloworld-example:0.0.1"
      },
      "models" : [ ],
      "npu_reset_enable" : false
    } ],
    "weight" : 100
  } ],
  "log_configs" : [ {
    "status" : "OFF",
    "type" : "STDOUT"
  } ],
  "runtime_config" : {
    "service_invoke" : {
      "auth_type" : "API_KEY",
      "direct_channel_auth_enable" : false,
      "direct_channel_enable" : false,
      "dynamic_routing_enable" : false,
      "ems_enable" : false,
      "internet_access_enable" : true,
      "intranet_approval_enable" : true,
      "port" : 9876,
      "protocol" : "HTTPS"
    },
    "service_limit" : {
      "ip_black_list" : [ ],
      "ip_white_list" : [ ],
      "rate_limit" : {
```

```
    "num": 200,
    "unit": "SECONDS"
  },
  "request_size_limit": 20,
  "request_timeout": 30
},
"service_secret": {
  "group_enable": false,
  "secret_enable": false,
  "secret_volumes": [ ]
}
},
"upgrade_config": {
  "rolling_update": {
    "max_surge": "1%",
    "max_unavailable": "1%"
  },
  "type": "ROLLING"
},
"version": "0.0.1"
},
"workspace_id": "0"
}
```

状态码

状态码	描述
200	服务的启动响应。

错误码

请参见[错误码](#)。

7.1.5 创建服务

功能介绍

将模型部署为在线服务，适用于用户在开发或运维过程中需要将训练好的模型部署为在线服务，以便通过API或HTTP接口提供预测或处理能力的场景。调用此接口前，用户必须具有创建服务的权限，并提供合法的模型镜像路径和完整的服务配置信息（如服务名称、模型镜像路径、资源配置、升级配置等）。调用成功后，系统将成功创建并部署服务，服务状态变为“部署中”，并生成服务的唯一ID返回给用户。服务的详细信息（如状态、创建时间、更新时间等）也会记录在系统中。如果用户没有创建服务的权限，或提供的模型镜像路径不合法，或服务配置信息不完整，调用将返回相应的错误信息。如果系统在部署过程中遇到资源不足或其他内部错误，也将返回错误信息并记录日志。

URI

POST /v2/{project_id}/services

表 7-86 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

请求参数

表 7-87 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： - application/json。 - application/json;charset=utf-8。 默认取值： 不涉及。

表 7-88 请求 Body 参数

参数	是否必选	参数类型	描述
name	是	String	参数解释： 服务名，用户在 创建服务 时自定义的名称。 约束限制： 服务在删除之前名字不能重复。 取值范围： 支持1-64位字符，可包含字母、中文、数字、中划线、下划线。 默认取值： 不涉及。
deploy_timeout_minutes	否	Integer	参数解释： 服务部署超时时间，integer类型，取值在1~300 约束限制： 不涉及。 取值范围： 版本长度不超过8位。 默认取值： 不涉及。
version	是	String	参数解释： 服务版本号，以数字及点号组成，形如1.0.1。 约束限制： 不涉及。 取值范围： 版本长度不超过8位。 默认取值： 不涉及。
type	否	String	参数解释： 推理服务类型。 约束限制： 不涉及。 取值范围： REAL_TIME：在线服务。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
deploy_type	否	String	参数解释： 部署类型。 约束限制： 不涉及。 取值范围： • SINGLE：单机单卡。 • MULTI：多机多卡。 默认取值： 不涉及。
group_configs	是	Array of GroupConfig objects	参数解释： 服务实例组配置，当推理方式为 BATCH/EDGE时仅支持配置一个模型；当推理方式为 REAL_TIME时，可根据业务需要配置多个服务实例并分配权重。 约束限制： HCS环境下，group_configs的最大元素数量为1；
runtime_config	是	RuntimeConfig object	参数解释： 服务运行配置。 约束限制： 不涉及。
upgrade_config	是	UpgradeConfig object	参数解释： 升级服务配置。 约束限制： 不涉及。
log_configs	否	Array of LtsConfiguration objects	参数解释： 日志配置。 约束限制： 不涉及。
tags	否	Array of tags objects	参数解释： 服务标签。 约束限制： 上限20个。

参数	是否必选	参数类型	描述
description	否	String	参数解释： 服务备注。 约束限制： 不涉及。 取值范围： 长度不可以超过100，不能包含感叹号，大于号，小于号，等号，与，单引号，双引号。 默认取值： 默认为空。
workspace_id	否	String	参数解释： 工作空间ID。 约束限制： 不涉及。 取值范围： 0：默认空间ID。 - 由数字和小写字母组成的32位字符：其他空间ID，可参考工作空间创建。 默认取值： 不涉及。
schedule	否	Array of ScheduleConfig objects	参数解释： 定时停止配置。 约束限制： 最多支持一个定时任务。

参数	是否必选	参数类型	描述
custom_metrics_path	是	String	参数解释： 该参数值由英文逗号隔开的协议、端口号、地址组成，比如： [http,8080,metrics]，其中地址长度不超过255，且需要与镜像给定的协议、地址、端口一致，否则指标无法上报。 约束限制： 长度不超过255。 取值范围： • 协议范围：http/https。 • 端口范围：1-65535。 • 地址范围：仅包含字母、数字、点号（.）、中划线（-）、下划线（_）、斜杠（/）的路径，非斜杠（/）开头。 默认取值： 不涉及。
system_log_dump_enable	否	Boolean	参数解释： 系统日志转储开关。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： false

表 7-89 GroupConfig

参数	是否必选	参数类型	描述
id	否	String	参数解释： 实例组ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
name	是	String	参数解释： 实例组名称。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
pool_id	否	String	参数解释： 资源池ID，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
count	否	Integer	参数解释： 部署场景下，服务实例数量。 约束限制： 不涉及。 取值范围： [1, 128]。 默认取值： 不涉及。
system_log_dump_enable	否	Boolean	参数解释： 系统日志转储开关。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false

参数	是否必选	参数类型	描述
unit_configs	否	Array of UnitConfig objects	参数解释： 实例单元配置。 约束限制： 单机推理时，个数只会为1；如果是分布式推理时，根据不同框架，实例单元配置可灵活配置。
weight	是	Integer	参数解释： 权重百分比，分配到此模型的流量权重，仅当模型部署为在线服务时需要配置。 约束限制： 不涉及。 取值范围： [0, 100]。 默认取值： 不涉及。
secret_type	否	String	参数解释： 凭证类型相关配置，用户可以在此处选择使用的凭证类型（dew, cce） 约束限制： 不涉及。
secret_name	否	String	参数解释： 凭证名称，用户使用dew类型凭证时可以在此处选择使用的凭证。 约束限制： 不涉及。
priority	否	Integer	参数解释： 服务优先级。 约束限制： - 如服务处于“运行中”，priority字段为必要参数，且value必须为原版的值； - 如服务处于“停止”，priority字段为非必要参数。 取值范围： [1, 3]。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
high_avail_switch	否	Boolean	参数解释： 高可用开关，开启后不同实例的pod将尽量均匀分布到不同的节点上。 约束限制： 不涉及 取值范围： true: 高可用开启 false: 高可用关闭 默认取值： true

表 7-90 UnitConfig

参数	是否必选	参数类型	描述
id	否	String	参数解释： 实例单元ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
name	否	String	参数解释： 实例单元角色名称。 约束限制： 最大长度为16字符，且需满足正则：^[a-z0-9]([-a-z0-9]*[a-z0-9])?\$ 默认取值： 不涉及。

参数	是否必选	参数类型	描述
role	否	String	参数解释： 实例单元角色。 约束限制： 不涉及。 取值范围： mindle场景下： • scheduler：表示调度单元。 • manager：表示管理单元。 • worker：表示工作单元。 vllm场景下： • prefill：表示全量单元。 • decode：表示增量单元。 • common：表示其他角色。 默认取值： 不涉及。
custom_spec	否	CustomSpec object	参数解释： 自定义资源规格配置。 约束限制： 不涉及。 参数示例： "custom_spec": { "arch": "x86", "cpu": 0.51, "memory": 1024.0 },
flavor	否	String	参数解释： 资源规格，根据所提供版本选择适合业务的规格。当 specification 为 custom 为自定义规格。由 custom_spec 指定部署的规格配置。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
image	是	Image object	参数解释： 镜像配置信息，包含镜像地址，镜像来源。 约束限制： 不涉及。
models	否	Array of Model objects	参数解释： 模型相关配置，用户可以在此处选择模型及权重文件配合镜像使用。 约束限制： 不涉及。
codes	否	Array of Code objects	参数解释： 代码相关配置，用户可以在此处选择代码所在的obs路径等。 约束限制： 不涉及。
dumps	否	Array of Dump objects	参数解释： 用户转储配置，用户可以在此处选择要转储的目的obs。 约束限制： 最多配置20组。
count	否	Integer	参数解释： 配置实例个数，单机推理无需配置。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
cmd	否	String	参数解释： 启动命令。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
envs	否	Map<String,String>	参数解释： 环境变量。 约束限制： 变量键长度不大于64，由字母、数字、下划线、中划线、点组成，不能以数字开头。值的输入内容不能存在HTML标签，包括<^>。
readiness_health	否	Health object	参数解释： 就绪健康检查。 约束限制： 不涉及。
startup_health	否	Health object	参数解释： 启动健康检查。 约束限制： 不涉及。
liveness_health	否	Health object	参数解释： 存活健康检查。 取值范围： 不涉及。
port	否	Integer	参数解释： 端口。 约束限制： 不涉及。 取值范围： [1,65535]。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
recovery	否	String	参数解释： 恢复策略重启等级。 约束限制： 不涉及。 取值范围： - Instance：实例级，故障时重新拉起整个实例。 - Pod：Pod级，故障时重新拉起故障pod。 - Custom：自定义级，故障时不做处理，留给用户处理。 默认取值： 不涉及。
npu_reset_enable	否	Boolean	参数解释： 是否开启恢复策略。 约束限制： 不涉及。 取值范围： - true：开启恢复策略。 - false：不开启恢复策略。 默认取值： 不涉及。
affinity	否	Affinity object	参数解释： 节点亲和调度设置。 约束限制： 不涉及。

表 7-91 CustomSpec

参数	是否必选	参数类型	描述
gpu	否	Number	参数解释： GPU个数。 约束限制： 不涉及。 取值范围： 支持配置小数，输入值不能小于0（最多支持2位小数，小数点后第3位做四舍五入处理）。 默认取值： 不涉及。
memory	否	Integer	参数解释： 内存，单位为MB。 约束限制： 不涉及。 取值范围： 仅支持整数。 默认取值： 不涉及。
cpu	否	Number	参数解释： CPU核数。 约束限制： 不涉及。 取值范围： 支持配置小数，输入值不能小于0.01（最多支持2位小数，小数点后第3位做四舍五入处理）。 默认取值： 不涉及。
ascend	否	Integer	参数解释： Ascend芯片个数。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-92 Image

参数	是否必选	参数类型	描述
id	否	String	参数解释： 镜像id。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
source	是	String	参数解释： 镜像类别，标识镜像来源。 约束限制： 不涉及。 取值范围： • swr：软件仓库服务。 默认取值： 不涉及。
swr_path	是	String	参数解释： 镜像地址，source不同取值时，地址为不同值。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
category	否	String	参数解释： 镜像支持的规格。 约束限制： 不涉及。 取值范围： • GPU：图形处理器。 • CPU：中央处理器。 • ASCEND：昇腾芯片。 默认取值： CPU。

表 7-93 Model

参数	是否必选	参数类型	描述
source	是	String	参数解释： 代码来源类别。 约束限制： 不涉及。 取值范围： 如下参数不区分大小写 • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。 • LOCAL：挂载宿主机本地存储目录。 默认取值： 不涉及。
address	否	String	参数解释： 代码来源地址，格式遵循不同存储系统。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
mount_path	是	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
efs_sub_path	否	String	参数解释： 当存储类别为EFS时，支持配置子目录。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
read_only	否	Boolean	参数解释： 挂载权限设置，是否只读。 约束限制： 不涉及。 取值范围： • true：只读。 • false：非只读。 默认取值： 不涉及。
os_warm_up	否	Boolean	参数解释： os预热。 约束限制： 不涉及。 取值范围： • true：预热。 • false：不预热。 默认取值： 不涉及。
source_name	否	String	参数解释： 预热名称。 约束限制： os_warm_up为true时必填。 取值范围： 支持1-64位字符，可包含字母、中文、数字、中划线、下划线。 默认取值： 不涉及。

表 7-94 Code

参数	是否必选	参数类型	描述
source	是	String	参数解释： 代码来源类别。 约束限制： 不涉及。 取值范围： ● OBS：对象存储服务。 ● OBSFS：OBS的文件系统接口。 ● EFS：弹性文件服务。 默认取值： 不涉及。
address	否	String	参数解释： 代码来源地址，格式遵循不同存储系统。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
source_id	否	String	参数解释： 代码来源id，与address二选一，当且仅当source为EFS时，可以传入sfs turbo的id。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
mount_path	是	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	否	String	参数解释： sfs 子路径。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
read_only	否	Boolean	参数解释： 是否只读。 约束限制： 不涉及。 取值范围： • true：只读。 • false：非只读。 默认取值： 不涉及。

表 7-95 Dump

参数	是否必选	参数类型	描述
source	是	String	参数解释： 转储挂载目录来源类别。 约束限制： 不涉及。 取值范围： ● OBS：对象存储服务。 ● OBSFS：OBS的文件系统接口。 默认取值： 不涉及。
address	否	String	参数解释： 转储挂载目录来源地址，支持https或obs协议的obs地址。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
mount_path	是	String	参数解释： 挂载到容器内的路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-96 Health

参数	是否必选	参数类型	描述
check_method	否	String	参数解释： 健康检查方式：HTTP 或者 EXEC（命令行）。 约束限制： 不涉及。 取值范围： • HTTP：超文本传输协议。 • EXEC：命令行。 默认取值： 不涉及。
cmd	否	String	参数解释： 当健康检查方式为EXEC时，配置的命令行。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
url	否	String	参数解释： 当健康检查方式为HTTP 时，配置的请求地址。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
protocol	否	String	参数解释： 连接协议。 约束限制： 不涉及。 取值范围： • HTTPS：超文本传输协议安全版。 • HTTP：超文本传输协议。 • WSS：网络通信协议安全版。 • WS：网络通信协议。 默认取值： 不涉及。
initial_delay_seconds	是	Integer	参数解释： 执行首次探测时，应该等待的时间。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
timeout_seconds	是	Integer	参数解释： 执行探测的超时时间，默认1秒，最小1秒。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
period_seconds	是	Integer	参数解释： 执行健康检查的周期时间，执行探测的频率。默认是10秒，最小1秒。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
failure_threshold	是	Integer	参数解释： 探测成功后，最少连续探测失败多少次才被认定为失败。默认是3。最小值是1。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-97 Affinity

参数	是否必选	参数类型	描述
affinity_type	是	String	参数解释： 节点亲和类型。 约束限制： 不涉及。 取值范围： - AFFINITY：亲和。 - ANTI_AFFINITY：反亲和。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
required	是	Boolean	参数解释： 是否设置强亲和。 约束限制： 不涉及。 取值范围： • true：设置强亲和。 • false：不设置强亲和。 默认取值： 不涉及。
selection_mode	是	String	参数解释： 选择节点方式。 约束限制： 不涉及。 取值范围： IP 默认取值： 不涉及。
targets	是	Map<String,String>	参数解释： 通过上述方式选择的列表，长度不能超过20。 约束限制： 不涉及。

表 7-98 RuntimeConfig

参数	是否必选	参数类型	描述
service_invoke	是	ServiceInvoke object	参数解释： 服务调用时的相关配置。 约束限制： 不涉及。
service_limit	是	ServiceLimit object	参数解释： 服务限制信息。 约束限制： 不涉及。

参数	是否必选	参数类型	描述
service_secret	否	ServiceSecret object	参数解释： 服务密钥挂载。 约束限制： 不涉及。

表 7-99 ServiceInvoke

参数	是否必选	参数类型	描述
port	是	Integer	参数解释： 服务端口号。 约束限制： 不涉及。 取值范围： [1, 65535]。 默认取值： 不涉及。
protocol	是	String	参数解释： 服务请求协议。当选择WSS与WS时，服务接口会升级为WebSocket。开启WebSocket时，不支持同时设置“服务流量限制”。 约束限制： 不涉及。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
auth_type	是	String	参数解释： 认证类型。 约束限制： 不涉及。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。 默认取值： 不涉及。
direct_channel_enable	否	Boolean	参数解释： 是否开启专属通道。 约束限制： 不涉及。 取值范围： • TRUE：开启专属通道。 • FALSE：不开启专属通道。 默认取值： 不涉及。
direct_channel_auth_enable	否	Boolean	参数解释： 专属通道模式下proxy是否开启鉴权。 约束限制： 不涉及。 取值范围： • TRUE：开启鉴权。 • FALSE：不开启鉴权。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
internet_access_enable	否	Boolean	参数解释： 外网访问。 不涉及。 约束限制： 不涉及。 取值范围： • TRUE：要外网访问。 • FALSE：不要外网访问。 默认取值： 不涉及。
intranet_approve_enable	否	Boolean	参数解释： 内网审批。 不涉及。 取值范围： • TRUE：要内网审批。 • FALSE：不要内网审批。 默认取值： 不涉及。
dynamic_routing_enable	否	Boolean	参数解释： 动态路由开关。 不涉及。 取值范围： • TRUE：开启动态路由。 • FALSE：不开启动态路由。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
strategy	否	String	参数解释： 智能路由策略。 约束限制： 不涉及。 取值范围： • ROUND_ROBIN：轮询。 • ORIGIN_IP_HASH：源IP哈希。 • MIN_CONN：最小连接数。 • MIN_FIRST_TOKEN_TIME：最小首token时延。 • COMPOSITE：综合负载。 • SLO_BASED：SLO优先级 默认取值： 不涉及。
metric_api_scheme	否	String	参数解释： 指标接口服务请求协议。 约束限制： 不涉及。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 默认取值： 不涉及。
metric_api_port	否	String	参数解释： 指标接口端口号。 约束限制： 不涉及。 取值范围： [1, 65535]。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
metric_api_path	否	String	参数解释： 指标接口path。 约束限制： 不涉及。 取值范围： 默认值metrics。 默认取值： metrics
emsEnable	否	Boolean	参数解释： 是否开启EMS加速。 约束限制： 不涉及。 取值范围： • TRUE：开启EMS加速。 • FALSE：不开启EMS加速。 默认取值： 不涉及。
request_retry_enable	否	Boolean	参数解释： proxy支持请求重调度开关。 约束限制： 不涉及。 取值范围： • true：开启proxy支持请求重调度。 • false：不开启proxy支持请求重调度。 默认取值： false
request_retry_cnt_max	否	Integer	参数解释： proxy支持请求重调度的重试次数 约束限制： 不涉及。 取值范围： [1, 10]。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
request_retry_interval_ms	否	Integer	参数解释： proxy支持请求重调度的重试间隔，单位ms 约束限制： 不涉及。 取值范围： [1, 10000]。 默认取值： 不涉及。

表 7-100 ServiceLimit

参数	是否必选	参数类型	描述
rate_limit	是	RateLimit object	参数解释： 流控相关指标。 约束限制： 不涉及。
request_size_limit	是	Integer	参数解释： 请求大小限制。 约束限制： 不涉及。 取值范围： 1-50M。 默认取值： 不涉及。
request_timeout	是	Integer	参数解释： 超时时间。 约束限制： 不涉及。 取值范围： 1到7200秒。 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
ip_white_list	否	Array of strings	参数解释： IP白名单。 约束限制： 不涉及。
ip_black_list	否	Array of strings	参数解释： IP黑名单。 约束限制： 不涉及。

表 7-101 RateLimit

参数	是否必选	参数类型	描述
num	是	Integer	参数解释： 服务流量限制是指指定单位内一个服务能够被访问的次数上限。 约束限制： 不涉及。 取值范围： 1-500。 默认取值： 不涉及。
unit	是	String	参数解释： 流量限制单元。 约束限制： 不涉及。 取值范围： • SECONDS（秒）。 • MINUTES（分钟）。 默认取值： 不涉及。

表 7-102 ServiceSecret

参数	是否必选	参数类型	描述
secret_enable	否	Boolean	参数解释： 是否启用密钥。 约束限制： 不涉及。 取值范围： • true：启用密钥。 • false：不启用密钥。 默认取值： false。
secret_type	否	String	参数解释： 密钥类型。 约束限制： 不涉及。 取值范围： • custom：自定义密钥。 默认取值： 不涉及。
secret_volumes	否	SecretVolume object	参数解释： 密钥挂载。 约束限制： 上限30个。
group_enable	否	Boolean	参数解释： 是否启用镜像的用户组。 约束限制： 不涉及。 取值范围： • true：启用镜像的用户组。 • false：不启用镜像的用户组。 默认取值： false。

参数	是否必选	参数类型	描述
group_id	否	Long	参数解释： 镜像的用户组id。 约束限制： 不涉及。 取值范围： 1000~4294967294。 默认取值： 不涉及。

表 7-103 SecretVolume

参数	是否必选	参数类型	描述
secret_key	否	String	参数解释： 密钥key。 约束限制： 匹配一个长度在1到63之间的字符串，只能包含字母、数字、点、下划线和连字符，并且不能以两个连续的点（..）开头。 取值范围： 不涉及。 默认取值： 不涉及。
secret_value	否	String	参数解释： 密钥值。 约束限制： 长度在1~32768，Base64编码后的密钥值。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
mountPath	是	String	参数解释： 挂载路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。

表 7-104 UpgradeConfig

参数	是否必选	参数类型	描述
type	否	String	参数解释： 升级类型。 约束限制： 不涉及。 取值范围： ROLLING：滚动升级，默认值。 默认取值： 不涉及。
rolling_update	否	RollingUpdate object	参数解释： 滚动更新配置。 约束限制： 不涉及。

表 7-105 RollingUpdate

参数	是否必选	参数类型	描述
max_surge	否	String	参数解释： 滚动更新时最多可以启动多少个 Pod。 约束限制： 百分数类型字符串。 取值范围： 1%-100%。 默认取值： 1%。
max_unavailable	否	String	参数解释： 滚动更新时最多可以删除多少个 Pod。 约束限制： 百分数类型字符串。 取值范围： 1%-100%。 默认取值： 1%。

表 7-106 LtsConfiguration

参数	是否必选	参数类型	描述
status	是	String	参数解释： 日志服务状态。 取值范围： - ON：开启。 - OFF：关闭。
type	是	String	参数解释： 当前只支持 标准日志输入输出 STDOUT。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
log_group_id	否	String	参数解释： 日志组id，用户选择自己已有的日志组，不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
log_stream_id	否	String	参数解释： 日志流id，用户选择自己已有的日志组。不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-107 tags

参数	是否必选	参数类型	描述
key	否	String	参数解释： 标签key值。 约束限制： 不能为空，最大长度为128。 取值范围： 字符串不能以空格开始或结束，并且不能以"sys"开始，同时可以包含任意数量的指定字符。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
value	否	String	参数解释： 标签value值。 约束限制： 最大长度为256。 取值范围： 任意数量的字母、数字、空格、下划线、点、冒号、斜杠、等号、加号、减号、@等字符开始和结束的字符串。 默认取值： 不涉及。

表 7-108 ScheduleConfig

参数	是否必选	参数类型	描述
duration	否	Integer	参数解释： 对应的时间单位的数值。 约束限制： 与time_unit共同确认时间设置的范围是1分钟~7天之间。 取值范围： 不涉及。 默认取值： 不涉及。
time_unit	否	String	参数解释： 时间的单位。 约束限制： 与duration共同确认时间设置的范围是1分钟~7天之间。 取值范围： • MINUTES：分钟。 • HOURS：小时。 • DAYS：天。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
type	否	String	参数解释： 调度类型，当前仅支持取值为stop。 约束限制： 不涉及。 取值范围： • STOP：停止。 默认取值： 不涉及。

响应参数

状态码：200

表 7-109 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 取值范围： 不涉及。
name	String	参数解释： 服务名，用户在 创建服务 时自定义的名称。 取值范围： 支持1-64位字符，可包含字母、中文、数字、中划线、下划线。
dispatcher_group_id	String	参数解释： 服务绑定的dispatcher组ID。 取值范围： 不涉及。

参数	参数类型	描述
workspace_id	String	参数解释： 工作空间ID。 取值范围： 0：默认空间ID。 - 由数字和小写字母组成的32位字符：其他空间ID，可参考工作空间创建。
type	String	参数解释： 推理服务类型。 取值范围： REAL_TIME：在线服务。
deploy_type	String	参数解释： 部署方式。 取值范围： - SINGLE：单机单卡。 - MULTI：多机多卡。
status	String	参数解释： 服务当前状态。 取值范围： - DEPLOYING：部署中。 - FAILED：失败。 - STOPPED：停止。 - RUNNING：运行中。 - DELETING：删除中。 - STOPPING：停止中。 - CONCERNING：告警。 - UPGRADING：升级中。 - ERROR：异常。 - INTERRUPTING：中断中。
failure_reason	String	参数解释： 在线服务失败原因。 取值范围： 不涉及。
version	ServiceVersionResponse object	参数解释： 当前服务版本信息。
predict_url	Array of predict_url_Response objects	参数解释： 在线服务访问地址。

参数	参数类型	描述
tags	Array of TmsTag_Response objects	参数解释： TMS对接标签类。
create_at	String	参数解释： 创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
update_at	String	参数解释： 更新时间，根据更新时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
schedule	Array of ScheduleConfig_Response objects	参数解释： 定时停止配置。
provider	String	参数解释： 服务提供者的账号id（创建服务时通过X-Auth-Token-Provider请求头解析iam token而来），该值不为空时，该服务的所有更新操作需要在请求头中添加X-Auth-Token-Provider，取值为该账号id的domain级或project级token。

表 7-110 ServiceVersionResponse

参数	参数类型	描述
id	String	参数解释： 版本id。 取值范围： 不涉及。
version	String	参数解释： 版本号。 取值范围： 不涉及。

参数	参数类型	描述
description	String	参数解释： 描述。 取值范围： 不涉及。
predict_url	String	参数解释： 推理请求的访问地址。 取值范围： 不涉及。
runtime_config	RuntimeConfig_Response object	参数解释： 服务运行配置。
upgrade_config	UpgradeConfig_Response object	参数解释： 服务升级配置。
instance_groups	Array of GroupConfig_Response objects	参数解释： 服务实例组信息。
log_configs	Array of LogConfig_Response objects	参数解释： 服务日志配置信息。
deploy_timeout_minutes	Integer	参数解释： 部署超时时间。 取值范围： 不涉及。

表 7-111 RuntimeConfig_Response

参数	参数类型	描述
service_invoke	ServiceInvoke_Response object	参数解释： 服务调用时的相关配置。
service_limit	ServiceLimit_Response object	参数解释： 服务限制信息。 约束限制： 不涉及。
service_secret	ServiceSecret_Response object	参数解释： 服务密钥挂载。

表 7-112 ServiceInvoke_Response

参数	参数类型	描述
port	Integer	参数解释： 服务端口号。 取值范围： [1, 65535]。
protocol	String	参数解释： 服务请求协议。当选择WSS与WS时，服务接口会升级为WebSocket。开启WebSocket时，不支持同时设置“服务流量限制”。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
auth_type	String	参数解释： 认证类型。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。
direct_channel_enable	Boolean	参数解释： 是否开启专属通道。 取值范围： • TRUE：开启专属通道。 • FALSE：不开启专属通道。
direct_channel_auth_enable	Boolean	参数解释： 专属通道模式下proxy是否开启鉴权。 取值范围： • TRUE：开启鉴权。 • FALSE：不开启鉴权。
internet_access_enable	Boolean	参数解释： 外网访问。 取值范围： • TRUE：要外网访问。 • FALSE：不要外网访问。

参数	参数类型	描述
intranet_approve_enable	Boolean	参数解释： 内网审批。 取值范围： • TRUE：要内网审批。 • FALSE：不要内网审批。
dynamic_routing_enable	Boolean	参数解释： 动态路由开关。 取值范围： • TRUE：开启动态路由。 • FALSE：不开启动态路由。
strategy	String	参数解释： 智能路由策略。 取值范围： • ROUND_ROBIN：轮询。 • ORIGIN_IP_HASH：源IP哈希。 • MIN_CONN：最小连接数。 • MIN_FIRST_TOKEN_TIME：最小首token时延。 • COMPOSITE：综合负载。 • SLO_BASED：SLO优先级。
metric_api_scheme	String	参数解释： 指标接口服务请求协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。
metric_api_port	String	参数解释： 指标接口端口号。 取值范围： [1, 65535]。
metric_api_path	String	参数解释： 指标接口path。 取值范围： 默认值metrics。

参数	参数类型	描述
ems_enable	Boolean	参数解释： 是否开启EMS加速。 取值范围： - TRUE：开启EMS加速。 - FALSE：不开启EMS加速。
request_retry_enable	Boolean	参数解释： proxy支持请求重调度开关。 取值范围： - true：开启proxy支持请求重调度。 - false：不开启proxy支持请求重调度。
request_retry_cnt_max	Integer	参数解释： proxy支持请求重调度的重试次数 取值范围： [1, 10]。
request_retry_interval_ms	Integer	参数解释： proxy支持请求重调度的重试间隔，单位ms 取值范围： [1, 10000]。

表 7-113 ServiceLimit_Response

参数	参数类型	描述
rate_limit	RateLimit_Response object	参数解释： 流控相关指标。
request_size_limit	Integer	参数解释： 请求大小限制。 取值范围： 1-50M。
request_timeout	Integer	参数解释： 超时时间。 取值范围： 1到7200秒。
ip_white_list	Array of strings	参数解释： IP白名单。

参数	参数类型	描述
ip_black_list	Array of strings	参数解释： IP黑名单。

表 7-114 RateLimit_Response

参数	参数类型	描述
num	Integer	参数解释： 服务流量限制是指指定单位内一个服务能够被访问的次数上限。 取值范围： 1-500。
unit	String	参数解释： 流量限制单元。 取值范围： • NANOS（纳秒）。 • MICROS（微秒）。 • MILLIS（毫秒）。 • SECONDS（秒）。 • MINUTES（分钟）。 • HOURS（小时）。 • DAYS（天）。

表 7-115 ServiceSecret_Response

参数	参数类型	描述
secret_enable	Boolean	参数解释： 是否启用密钥。 取值范围： • true：启用密钥。 • false：不启用密钥。
secret_type	String	参数解释： 密钥类型。 取值范围： • custom：自定义密钥。

参数	参数类型	描述
secret_volumes	SecretVolume_Response object	参数解释： 密钥挂载。 约束限制： 上限30个。
group_enable	Boolean	参数解释： 是否启用镜像的用户组。 取值范围： • true：启用镜像的用户组。 • false：不启用镜像的用户组。
group_id	Long	参数解释： 镜像的用户组id。 取值范围： 1000~4294967294。

表 7-116 SecretVolume_Response

参数	参数类型	描述
secret_name	String	参数解释： 密钥名称。 取值范围： 不涉及。
secret_key	String	参数解释： 密钥key。 取值范围： 长度不大于63。
secret_value	String	参数解释： 密钥值。 取值范围： 长度不大于32768。
mountPath	String	参数解释： 挂载路径。 取值范围： 不涉及。

表 7-117 UpgradeConfig_Response

参数	参数类型	描述
type	String	参数解释： 升级类型。 取值范围： ROLLING：滚动升级，默认值。
rolling_update	RollingUpdate_Response object	参数解释： 滚动更新配置。

表 7-118 RollingUpdate_Response

参数	参数类型	描述
max_surge	String	参数解释： 滚动更新时最多可以启动多少个Pod。 取值范围： 不涉及。
max_unavailable	String	参数解释： 滚动更新时最多可以删除多少个Pod。 取值范围： 不涉及。

表 7-119 GroupConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例组ID。 取值范围： 不涉及。
name	String	参数解释： 实例组名称。 取值范围： 不涉及。

参数	参数类型	描述
pool_id	String	参数解释： 资源池ID，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 取值范围： 不涉及。
count	Integer	参数解释： 部署场景下，服务实例数量。 约束限制： 不涉及。 取值范围： [1, 128]。 默认取值： 不涉及。
system_log_dump_enable	Boolean	参数解释： 系统日志转储开关量。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： false
unit_configs	Array of UnitConfig_Response objects	参数解释： 实例单元配置。
weight	Integer	参数解释： 权重百分比，分配到此模型的流量权重，仅当模型部署为在线服务时需要配置。 取值范围： [0, 100]。
secret_type	String	参数解释： 凭证类型相关配置，用户可以在此处选择使用的凭证类型（dew，cce） 约束限制： 不涉及。

参数	参数类型	描述
secret_name	String	参数解释： 凭证名称，用户使用dew类型凭证时可以在此处选择使用的凭证。 约束限制： 不涉及。
priority	Integer	参数解释： 服务优先级。 约束限制： 不涉及。 取值范围： [1, 3]。 默认取值： 不涉及。
high_avail_switch	Boolean	参数解释： 高可用开关，开启后不同实例的pod将尽量均匀分布到不同的节点上。 取值范围： true: 高可用开启 false: 高可用关闭
framework	String	参数解释： 算法框架。 取值范围： COMMON： 普通在线服务。

表 7-120 UnitConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例单元ID。 取值范围： 不涉及。
role	String	参数解释： 实例单元角色。 取值范围： common： 表示其他角色。
custom_spec	CustomSpecResponse object	参数解释： 自定义资源规格配置。

参数	参数类型	描述
flavor	String	参数解释： 资源规格，根据所提供版本选择适合业务的规格。当specification为custom时表示自定义规格。由custom_spec指定部署的规格配置。 取值范围： 不涉及。
image	Image_Response object	参数解释： 镜像配置信息，包含镜像地址，镜像来源。
models	Array of Model_Response objects	参数解释： 模型相关配置，用户可以在此处选择模型及权重文件配合镜像使用。
codes	Array of Code_Response objects	参数解释： 代码相关配置，用户可以在此处选择代码所在的obs路径等。
dumps	Array of DumpResponse objects	参数解释： 转储相关配置，用户可以在此处选择转储的目的obs路径等。
count	Integer	参数解释： 配置实例个数，单机推理无需配置。 取值范围： 不涉及。
cmd	String	参数解释： 启动命令。 取值范围： 不涉及。
envs	Map<String,String>	参数解释： 环境变量。
readiness_health	Health_Response object	参数解释： 就绪健康检查。
startup_health	Health_Response object	参数解释： 启动健康检查。
liveness_health	Health_Response object	参数解释： 存活健康检查。

参数	参数类型	描述
port	Integer	参数解释： 端口。 取值范围： [1,65535]。
recovery	String	参数解释： 恢复策略重启等级。 取值范围： - Instance：实例级，故障时重新拉起整个实例。 - Pod：Pod级，故障时重新拉起故障pod。 - Custom：自定义级，故障时不做处理，留给用户处理。
npu_reset_enable	Boolean	参数解释： 是否开启恢复策略。 取值范围： - true：开启恢复策略。 - false：不开启恢复策略。
affinity	Affinity_Response object	参数解释： 节点亲和调度设置。

表 7-121 CustomSpecResponse

参数	参数类型	描述
gpu	Number	参数解释： GPU个数。 取值范围： 支持配置小数，输入值不能小于0（最多支持2位小数，小数点后第3位做四舍五入处理）。
memory	Integer	参数解释： 内存，单位为MB。 取值范围： 仅支持整数。

参数	参数类型	描述
cpu	Number	参数解释： CPU核数。 取值范围： 支持配置小数，输入值不能小于0.01（最多支持2位小数，小数点后第3位做四舍五入处理）。
ascend	Integer	参数解释： Ascend芯片个数。 取值范围： 不涉及。

表 7-122 Image_Response

参数	参数类型	描述
id	String	参数解释： 镜像id。 取值范围： 不涉及。
source	String	参数解释： 镜像类别，标识镜像来源。 取值范围： swr：软件仓库服务。
swr_path	String	参数解释： 镜像地址，source不同取值时，地址为不同值。 取值范围： 不涉及。
category	String	参数解释： 镜像支持的规格。 取值范围： - GPU：图形处理器。 - CPU：中央处理器。 - ASCEND：昇腾芯片。

表 7-123 Model_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。 • LOCAL：挂载宿主机本地存储目录。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： 当存储类别为EFS时，支持配置子目录。 取值范围： 不涉及。
read_only	Boolean	参数解释： 挂载权限设置，是否只读。 取值范围： • true：只读。 • false：非只读。
os_warm_up	Boolean	参数解释： os预热。 取值范围： • true：预热。 • false：不预热。

表 7-124 Code_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
source_id	String	参数解释： 代码来源id，与address二选一，当且仅当source为EFS时，可以传入sfs turbo的id。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： sfs 子路径。 取值范围： 不涉及。

参数	参数类型	描述
read_only	Boolean	参数解释： 是否只读。 取值范围： • true：只读。 • false：非只读。

表 7-125 DumpResponse

参数	参数类型	描述
source	String	参数解释： 用户转储来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。
address	String	参数解释： 用户转储来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及。
type	String	参数解释： 转储类型。 取值范围： • DUMP：用户自定义转储。 • DUMP_SYS：系统转储。

表 7-126 Health_Response

参数	参数类型	描述
check_method	String	参数解释： 健康检查方式：HTTP 或者 EXEC（命令行）。 取值范围： • HTTP：超文本传输协议。 • EXEC：命令行。
cmd	String	参数解释： 当健康检查方式为EXEC时，配置的命令行。 取值范围： 不涉及。
url	String	参数解释： 当健康检查方式为HTTP 时，配置的请求地址。 取值范围： 不涉及。
protocol	String	参数解释： 连接协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
initial_delay_seconds	Integer	参数解释： 执行首次探测时，应该等待的时间。 取值范围： 不涉及。
timeout_seconds	Integer	参数解释： 执行探测的超时时间，默认1秒，最小1秒。 取值范围： 不涉及。

参数	参数类型	描述
period_seconds	Integer	参数解释： 执行健康检查的周期时间，执行探测的频率。默认是10秒，最小1秒。 取值范围： 不涉及。
failure_threshold	Integer	参数解释： 探测成功后，最少连续探测失败多少次才被认定为失败。默认是3。最小值是1。 取值范围： 不涉及。

表 7-127 Affinity_Response

参数	参数类型	描述
affinity_type	String	参数解释： 节点亲和类型。 取值范围： - AFFINITY：亲和。 - ANTI_AFFINITY：反亲和。
required	Boolean	参数解释： 是否设置强亲和。 取值范围： - true：设置强亲和。 - false：不设置强亲和。
selection_mode	String	参数解释： 选择节点方式。 取值范围： IP。
targets	Map<String,String>	参数解释： 通过上述方式选择的列表，长度不能超过20。

表 7-128 LogConfig_Response

参数	参数类型	描述
type	String	参数解释： 日志输出类型。 取值范围： • STDOUT：日志输出到控制台或终端。 • FILE：日志输出到文件。
status	String	参数解释： 日志服务状态。 取值范围： • ON：开启。 • OFF：关闭。
log_group_id	String	参数解释： 日志组id，用户选择自己已有的日志组，不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
log_stream_id	String	参数解释： 日志流id，用户选择自己已有的日志组。不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-129 predict_url_Response

参数	参数类型	描述
type	String	参数解释： 访问方式。 取值范围： • CONSOLE：通过控制台界面访问。 • PUBLIC：通过公网访问。 • INTERNAL：通过内网访问。 • DIRECT_CHANNEL：通过直接通道访问。
urls	Array of strings	参数解释： 推理请求的访问地址，仅当type为real-time时，且服务部署完成后才会确保该字段有值。

表 7-130 TmsTag_Response

参数	参数类型	描述
key	String	参数解释： 标签键字段。 约束限制： 不涉及。 取值范围： 长度为1~128，标签的键可以包含任意语种字母、数字、空格，以及_ . : = + - @ 特殊字符，但首尾不能含有空格，不能以_sys_开头。 默认取值： 不涉及。
value	String	参数解释： 标签值字段。 取值范围： 长度为255，包括字母、数字、下划线、点、斜杠、等号、加号、减号和@符号。

表 7-131 ScheduleConfig_Response

参数	参数类型	描述
due_time	Long	参数解释： 触发时间，13位时间戳。 取值范围： 不涉及。
duration	Integer	参数解释： 对应的时间单位的数值。 取值范围： 不涉及。
time_unit	String	参数解释： 调度时间单位。 取值范围： - MINUTES：分钟。 - HOURS：小时。 - DAYS：天。
type	String	参数解释： 调度类型，当前仅支持取值为stop。 取值范围： STOP：停止。
processed	Boolean	参数解释： 表示是否处理完成。 取值范围： - true：该定时任务已经执行过。 - false：该定时任务尚未执行。

请求示例

创建在线推理服务。

```
POST https://{endpoint}/v2/{project_id}/services
{
  "schedule": [{
    "time_unit": "HOURS",
    "type": "STOP",
    "duration": 1
  }],
  "version": "0.0.1",
  "description": "",
  "deploy_timeout_minutes": 60,
  "tags": [],
  "name": "service-example",
  "type": "REAL_TIME",
  "deploy_type": "SINGLE",
}
```



```
"group_configs": [ {
  "weight": 100,
  "name": "instance-example",
  "pool_id": "pool-example",
  "framework": "COMMON",
  "count": 1,
  "unit_configs": [ {
    "image": {
      "id": "71ad5a75-14c4-1d14-883f-f350969ea9c7",
      "source": "SWR",
      "swr_path": "swr.cn-north-7.myhuaweicloud.com/example/helloworld-example:0.0.1"
    },
    "flavor": "flavor-example"
  } ]
},
],
"runtime_config": {
  "service_invoke": {
    "port": 123,
    "protocol": "HTTPS",
    "auth_type": "NONE",
    "direct_channel_enable": false,
    "direct_channel_auth_enable": false,
    "dynamic_routing_enable": false
  },
  "service_limit": {
    "request_size_limit": 20,
    "request_timeout": 30,
    "ip_white_list": [ ],
    "ip_black_list": [ ],
    "rate_limit": {
      "num": 200,
      "unit": "SECONDS"
    }
  }
},
"workspace_id": "0",
"upgrade_config": {
  "type": "ROLLING",
  "rolling_update": {
    "max_surge": "20%",
    "max_unavailable": "20%"
  }
}
}
```

响应示例

状态码：200

创建在线推理服务成功。

```
{
  "id": "123e4567-e89b-12d3-a456-426655440000",
  "name": "service-example",
  "schedule": [ {
    "due_time": 0,
    "duration": 1,
    "processed": false,
    "time_unit": "HOURS",
    "type": "STOP"
  } ],
  "version": {
    "deploy_timeout_minutes": 60,
    "description": "infer-description",
    "id": "081cd8c0-af1b-4300-b077-a1b87d2d2fa8",
    "instance_groups": [ {
      "count": 1,
      "framework": "COMMON",
      "id": "8a927efb-43f6-4a0b-8222-a1b87d2d2fa8",

```

```
"name": "instance-example",
"pool_id": "pool-xinfer-1216-dev-04f258c84780d5a52f3bc00dc15aa5e7",
"priority": 1,
"unit_configs": [ {
  "codes": [ ],
  "count": 1,
  "custom_spec": {
    "cpu": 0.1,
    "memory": 50
  },
  "envs": {
    "additionalProp1": "string",
    "additionalProp2": "string",
    "a": "1"
  },
  "id": "8a0e4ab7970bc24d01970bcd7f460003",
  "image": {
    "category": "CPU",
    "id": "bc84b0e49e910cd7918b1dfaeaa478f9c7e5242c6733525ca88304f026fa24e4",
    "source": "SWR",
    "swr_path": "swr.cn-north-7.myhuaweicloud.com/mock-service/helloworld-
x86_64:1.0.20241214164419"
  },
  "npu_reset_enable": false,
  "port": 65535,
  "role": "COMMON"
} ],
"weight": 100
} ],
"log_configs": [ ],
"runtime_config": {
  "service_invoke": {
    "auth_type": "API_KEY",
    "direct_channel_auth_enable": true,
    "direct_channel_enable": true,
    "dynamic_routing_enable": false,
    "ems_enable": false,
    "internet_access_enable": true,
    "intranet_approval_enable": true,
    "port": 9876,
    "protocol": "HTTPS"
  },
  "service_limit": {
    "ip_black_list": [ ],
    "ip_white_list": [ ],
    "rate_limit": {
      "num": 2000,
      "unit": "SECONDS"
    },
    "request_size_limit": 50,
    "request_timeout": 600
  },
  "service_secret": {
    "group_enable": false,
    "secret_enable": false,
    "secret_volumes": [ ]
  }
},
"upgrade_config": {
  "rolling_update": {
    "max_surge": "20%",
    "max_unavailable": "20%"
  },
  "type": "ROLLING"
},
"version": "0.0.0"
},
"type": "REAL_TIME",
"workspace_id": "0",
```

```
"deploy_type" : "SINGLE",  
"tags" : []  
}
```

状态码

状态码	描述
200	创建在线推理服务成功。

错误码

请参见[错误码](#)。

7.1.6 查询服务详情

功能介绍

通过服务ID查询对应的服务详情，调用者可以通过有效的服务ID获取服务的名称、状态、服务实例、配置参数等详细信息。调用者需具有足够的权限，且输入的服务ID必须有效。查询成功时返回服务详细信息，查询失败时返回特定的错误码和错误信息。若服务ID无效、版本号不存在或用户无权限，则返回400 Bad Request或403 Forbidden；

URI

GET /v2/{project_id}/services/{service_id}

表 7-132 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

请求参数

表 7-133 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json。 • application/json;charset=utf-8。 默认取值： 不涉及。

响应参数

状态码：200

表 7-134 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 取值范围： 不涉及。
name	String	参数解释： 服务名，用户在 创建服务 时自定义的名称。 取值范围： 支持1-64位字符，可包含字母、中文、数字、中划线、下划线。
dispatcher_group_id	String	参数解释： 服务绑定的dispatcher组ID。 取值范围： 不涉及。
workspace_id	String	参数解释： 工作空间ID。 取值范围： 0：默认空间ID。 - 由数字和小写字母组成的32位字符：其他空间ID，可参考工作空间创建。
type	String	参数解释： 推理服务类型。 取值范围： REAL_TIME：在线服务。
deploy_type	String	参数解释： 部署方式。 取值范围： - SINGLE：单机单卡。 - MULTI：多机多卡。

参数	参数类型	描述
status	String	参数解释： 服务当前状态。 取值范围： • DEPLOYING：部署中。 • FAILED：失败。 • STOPPED：停止。 • RUNNING：运行中。 • DELETING：删除中。 • STOPPING：停止中。 • CONCERNING：告警。 • UPGRADING：升级中。 • ERROR：异常。 • INTERRUPTING：中断中。
failure_reason	String	参数解释： 在线服务失败原因。 取值范围： 不涉及。
version	ServiceVersionResponse object	参数解释： 当前服务版本信息。
predict_url	Array of predict_url_Response objects	参数解释： 在线服务访问地址。
tags	Array of TmsTag_Response objects	参数解释： TMS对接标签类。
create_at	String	参数解释： 创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
update_at	String	参数解释： 更新时间，根据更新时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。

参数	参数类型	描述
schedule	Array of ScheduleConfig_Response objects	参数解释： 定时停止配置。
provider	String	参数解释： 服务提供者的账号id（创建服务时通过X-Auth-Token-Provider请求头解析iam token而来），该值不为空时，该服务的所有更新操作需要在请求头中添加X-Auth-Token-Provider，取值为该账号id的domain级或project级token。

表 7-135 ServiceVersionResponse

参数	参数类型	描述
id	String	参数解释： 版本id。 取值范围： 不涉及。
version	String	参数解释： 版本号。 取值范围： 不涉及。
description	String	参数解释： 描述。 取值范围： 不涉及。
predict_url	String	参数解释： 推理请求的访问地址。 取值范围： 不涉及。
runtime_config	RuntimeConfig_Response object	参数解释： 服务运行配置。
upgrade_config	UpgradeConfig_Response object	参数解释： 服务升级配置。
instance_groups	Array of GroupConfig_Response objects	参数解释： 服务实例组信息。

参数	参数类型	描述
log_configs	Array of LogConfig_Response objects	参数解释： 服务日志配置信息。
deploy_timeout_minutes	Integer	参数解释： 部署超时时间。 取值范围： 不涉及。

表 7-136 RuntimeConfig_Response

参数	参数类型	描述
service_invoke	ServiceInvoke_Response object	参数解释： 服务调用时的相关配置。
service_limit	ServiceLimit_Response object	参数解释： 服务限制信息。 约束限制： 不涉及。
service_secret	ServiceSecret_Response object	参数解释： 服务密钥挂载。

表 7-137 ServiceInvoke_Response

参数	参数类型	描述
port	Integer	参数解释： 服务端口号。 取值范围： [1, 65535]。

参数	参数类型	描述
protocol	String	参数解释： 服务请求协议。当选择WSS与WS时，服务接口会升级为WebSocket。开启WebSocket时，不支持同时设置“服务流量限制”。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
auth_type	String	参数解释： 认证类型。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。
direct_channel_enable	Boolean	参数解释： 是否开启专属通道。 取值范围： • TRUE：开启专属通道。 • FALSE：不开启专属通道。
direct_channel_auth_enable	Boolean	参数解释： 专属通道模式下proxy是否开启鉴权。 取值范围： • TRUE：开启鉴权。 • FALSE：不开启鉴权。
internet_access_enable	Boolean	参数解释： 外网访问。 取值范围： • TRUE：要外网访问。 • FALSE：不要外网访问。
intranet_approve_enable	Boolean	参数解释： 内网审批。 取值范围： • TRUE：要内网审批。 • FALSE：不要内网审批。

参数	参数类型	描述
dynamic_routing_enable	Boolean	参数解释： 动态路由开关。 取值范围： - TRUE：开启动态路由。 - FALSE：不开启动态路由。
strategy	String	参数解释： 智能路由策略。 取值范围： - ROUND_ROBIN：轮询。 - ORIGIN_IP_HASH：源IP哈希。 - MIN_CONN：最小连接数。 - MIN_FIRST_TOKEN_TIME：最小首token时延。 - COMPOSITE：综合负载。 - SLO_BASED：SLO优先级。
metric_api_scheme	String	参数解释： 指标接口服务请求协议。 取值范围： - HTTP：HTTP协议。 - HTTPS：HTTPS协议。
metric_api_port	String	参数解释： 指标接口端口号。 取值范围： [1, 65535]。
metric_api_path	String	参数解释： 指标接口path。 取值范围： 默认值metrics。
ems_enable	Boolean	参数解释： 是否开启EMS加速。 取值范围： - TRUE：开启EMS加速。 - FALSE：不开启EMS加速。

参数	参数类型	描述
request_retry_enable	Boolean	参数解释： proxy支持请求重调度开关。 取值范围： • true：开启proxy支持请求重调度。 • false：不开启proxy支持请求重调度。
request_retry_cnt_max	Integer	参数解释： proxy支持请求重调度的重试次数 取值范围： [1, 10]。
request_retry_interval_ms	Integer	参数解释： proxy支持请求重调度的重试间隔，单位ms 取值范围： [1, 10000]。

表 7-138 ServiceLimit_Response

参数	参数类型	描述
rate_limit	RateLimit_Response object	参数解释： 流控相关指标。
request_size_limit	Integer	参数解释： 请求大小限制。 取值范围： 1-50M。
request_timeout	Integer	参数解释： 超时时间。 取值范围： 1到7200秒。
ip_white_list	Array of strings	参数解释： IP白名单。
ip_black_list	Array of strings	参数解释： IP黑名单。

表 7-139 RateLimit_Response

参数	参数类型	描述
num	Integer	参数解释： 服务流量限制是指指定单位内一个服务能够被访问的次数上限。 取值范围： 1-500。
unit	String	参数解释： 流量限制单元。 取值范围： • NANOS（纳秒）。 • MICROS（微秒）。 • MILLIS（毫秒）。 • SECONDS（秒）。 • MINUTES（分钟）。 • HOURS（小时）。 • DAYS（天）。

表 7-140 ServiceSecret_Response

参数	参数类型	描述
secret_enable	Boolean	参数解释： 是否启用密钥。 取值范围： • true：启用密钥。 • false：不启用密钥。
secret_type	String	参数解释： 密钥类型。 取值范围： • custom：自定义密钥。
secret_volumes	SecretVolume_Response object	参数解释： 密钥挂载。 约束限制： 上限30个。

参数	参数类型	描述
group_enable	Boolean	参数解释： 是否启用镜像的用户组。 取值范围： • true：启用镜像的用户组。 • false：不启用镜像的用户组。
group_id	Long	参数解释： 镜像的用户组id。 取值范围： 1000~4294967294。

表 7-141 SecretVolume_Response

参数	参数类型	描述
secret_name	String	参数解释： 密钥名称。 取值范围： 不涉及。
secret_key	String	参数解释： 密钥key。 取值范围： 长度不大于63。
secret_value	String	参数解释： 密钥值。 取值范围： 长度不大于32768。
mountPath	String	参数解释： 挂载路径。 取值范围： 不涉及。

表 7-142 UpgradeConfig_Response

参数	参数类型	描述
type	String	参数解释： 升级类型。 取值范围： ROLLING：滚动升级，默认值。
rolling_update	RollingUpdate_Response object	参数解释： 滚动更新配置。

表 7-143 RollingUpdate_Response

参数	参数类型	描述
max_surge	String	参数解释： 滚动更新时最多可以启动多少个Pod。 取值范围： 不涉及。
max_unavailable	String	参数解释： 滚动更新时最多可以删除多少个Pod。 取值范围： 不涉及。

表 7-144 GroupConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例组ID。 取值范围： 不涉及。
name	String	参数解释： 实例组名称。 取值范围： 不涉及。

参数	参数类型	描述
pool_id	String	参数解释： 资源池ID，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 取值范围： 不涉及。
count	Integer	参数解释： 部署场景下，服务实例数量。 约束限制： 不涉及。 取值范围： [1, 128]。 默认取值： 不涉及。
system_log_dump_enable	Boolean	参数解释： 系统日志转储开关量。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： false
unit_configs	Array of UnitConfig_Response objects	参数解释： 实例单元配置。
weight	Integer	参数解释： 权重百分比，分配到此模型的流量权重，仅当模型部署为在线服务时需要配置。 取值范围： [0, 100]。
secret_type	String	参数解释： 凭证类型相关配置，用户可以在此处选择使用的凭证类型（dew，cce） 约束限制： 不涉及。

参数	参数类型	描述
secret_name	String	参数解释： 凭证名称，用户使用dew类型凭证时可以在此处选择使用的凭证。 约束限制： 不涉及。
priority	Integer	参数解释： 服务优先级。 约束限制： 不涉及。 取值范围： [1, 3]。 默认取值： 不涉及。
high_avail_switch	Boolean	参数解释： 高可用开关，开启后不同实例的pod将尽量均匀分布到不同的节点上。 取值范围： true: 高可用开启 false: 高可用关闭
framework	String	参数解释： 算法框架。 取值范围： COMMON：普通在线服务。

表 7-145 UnitConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例单元ID。 取值范围： 不涉及。
role	String	参数解释： 实例单元角色。 取值范围： common：表示其他角色。
custom_spec	CustomSpecResponse object	参数解释： 自定义资源规格配置。

参数	参数类型	描述
flavor	String	参数解释： 资源规格，根据所提供版本选择适合业务的规格。当specification为custom时表示自定义规格。由custom_spec指定部署的规格配置。 取值范围： 不涉及。
image	Image_Response object	参数解释： 镜像配置信息，包含镜像地址，镜像来源。
models	Array of Model_Response objects	参数解释： 模型相关配置，用户可以在此处选择模型及权重文件配合镜像使用。
codes	Array of Code_Response objects	参数解释： 代码相关配置，用户可以在此处选择代码所在的obs路径等。
dumps	Array of DumpResponse objects	参数解释： 转储相关配置，用户可以在此处选择转储的目的obs路径等。
count	Integer	参数解释： 配置实例个数，单机推理无需配置。 取值范围： 不涉及。
cmd	String	参数解释： 启动命令。 取值范围： 不涉及。
envs	Map<String,String>	参数解释： 环境变量。
readiness_health	Health_Response object	参数解释： 就绪健康检查。
startup_health	Health_Response object	参数解释： 启动健康检查。
liveness_health	Health_Response object	参数解释： 存活健康检查。

参数	参数类型	描述
port	Integer	参数解释： 端口。 取值范围： [1,65535]。
recovery	String	参数解释： 恢复策略重启等级。 取值范围： - Instance：实例级，故障时重新拉起整个实例。 - Pod：Pod级，故障时重新拉起故障pod。 - Custom：自定义级，故障时不做处理，留给用户处理。
npu_reset_enable	Boolean	参数解释： 是否开启恢复策略。 取值范围： - true：开启恢复策略。 - false：不开启恢复策略。
affinity	Affinity_Response object	参数解释： 节点亲和调度设置。

表 7-146 CustomSpecResponse

参数	参数类型	描述
gpu	Number	参数解释： GPU个数。 取值范围： 支持配置小数，输入值不能小于0（最多支持2位小数，小数点后第3位做四舍五入处理）。
memory	Integer	参数解释： 内存，单位为MB。 取值范围： 仅支持整数。

参数	参数类型	描述
cpu	Number	参数解释： CPU核数。 取值范围： 支持配置小数，输入值不能小于0.01（最多支持2位小数，小数点后第3位做四舍五入处理）。
ascend	Integer	参数解释： Ascend芯片个数。 取值范围： 不涉及。

表 7-147 Image_Response

参数	参数类型	描述
id	String	参数解释： 镜像id。 取值范围： 不涉及。
source	String	参数解释： 镜像类别，标识镜像来源。 取值范围： • swr：软件仓库服务。
swr_path	String	参数解释： 镜像地址，source不同取值时，地址为不同值。 取值范围： 不涉及。
category	String	参数解释： 镜像支持的规格。 取值范围： • GPU：图形处理器。 • CPU：中央处理器。 • ASCEND：昇腾芯片。

表 7-148 Model_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。 • LOCAL：挂载宿主机本地存储目录。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： 当存储类别为EFS时，支持配置子目录。 取值范围： 不涉及。
read_only	Boolean	参数解释： 挂载权限设置，是否只读。 取值范围： • true：只读。 • false：非只读。
os_warm_up	Boolean	参数解释： os预热。 取值范围： • true：预热。 • false：不预热。

表 7-149 Code_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
source_id	String	参数解释： 代码来源id，与address二选一，当且仅当source为EFS时，可以传入sfs turbo的id。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： sfs 子路径。 取值范围： 不涉及。

参数	参数类型	描述
read_only	Boolean	参数解释： 是否只读。 取值范围： • true：只读。 • false：非只读。

表 7-150 DumpResponse

参数	参数类型	描述
source	String	参数解释： 用户转储来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。
address	String	参数解释： 用户转储来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及。
type	String	参数解释： 转储类型。 取值范围： • DUMP：用户自定义转储。 • DUMP_SYS：系统转储。

表 7-151 Health_Response

参数	参数类型	描述
check_method	String	参数解释： 健康检查方式：HTTP 或者 EXEC（命令行）。 取值范围： • HTTP：超文本传输协议。 • EXEC：命令行。
cmd	String	参数解释： 当健康检查方式为EXEC时，配置的命令行。 取值范围： 不涉及。
url	String	参数解释： 当健康检查方式为HTTP 时，配置的请求地址。 取值范围： 不涉及。
protocol	String	参数解释： 连接协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
initial_delay_seconds	Integer	参数解释： 执行首次探测时，应该等待的时间。 取值范围： 不涉及。
timeout_seconds	Integer	参数解释： 执行探测的超时时间，默认1秒，最小1秒。 取值范围： 不涉及。

参数	参数类型	描述
period_seconds	Integer	参数解释： 执行健康检查的周期时间，执行探测的频率。默认是10秒，最小1秒。 取值范围： 不涉及。
failure_threshold	Integer	参数解释： 探测成功后，最少连续探测失败多少次才被认定为失败。默认是3。最小值是1。 取值范围： 不涉及。

表 7-152 Affinity_Response

参数	参数类型	描述
affinity_type	String	参数解释： 节点亲和类型。 取值范围： - AFFINITY：亲和。 - ANTI_AFFINITY：反亲和。
required	Boolean	参数解释： 是否设置强亲和。 取值范围： - true：设置强亲和。 - false：不设置强亲和。
selection_mode	String	参数解释： 选择节点方式。 取值范围： IP。
targets	Map<String,String>	参数解释： 通过上述方式选择的列表，长度不能超过20。

表 7-153 LogConfig_Response

参数	参数类型	描述
type	String	参数解释： 日志输出类型。 取值范围： • STDOUT：日志输出到控制台或终端。 • FILE：日志输出到文件。
status	String	参数解释： 日志服务状态。 取值范围： • ON：开启。 • OFF：关闭。
log_group_id	String	参数解释： 日志组id，用户选择自己已有的日志组，不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
log_stream_id	String	参数解释： 日志流id，用户选择自己已有的日志组。不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-154 predict_url_Response

参数	参数类型	描述
type	String	参数解释： 访问方式。 取值范围： • CONSOLE：通过控制台界面访问。 • PUBLIC：通过公网访问。 • INTERNAL：通过内网访问。 • DIRECT_CHANNEL：通过直接通道访问。
urls	Array of strings	参数解释： 推理请求的访问地址，仅当type为real-time时，且服务部署完成后才会确保该字段有值。

表 7-155 TmsTag_Response

参数	参数类型	描述
key	String	参数解释： 标签键字段。 约束限制： 不涉及。 取值范围： 长度为1~128，标签的键可以包含任意语种字母、数字、空格，以及_ . : = + - @ 特殊字符，但首尾不能含有空格，不能以_sys_开头。 默认取值： 不涉及。
value	String	参数解释： 标签值字段。 取值范围： 长度为255，包括字母、数字、下划线、点、斜杠、等号、加号、减号和@符号。

表 7-156 ScheduleConfig_Response

参数	参数类型	描述
due_time	Long	参数解释： 触发时间，13位时间戳。 取值范围： 不涉及。
duration	Integer	参数解释： 对应的时间单位的数值。 取值范围： 不涉及。
time_unit	String	参数解释： 调度时间单位。 取值范围： • MINUTES：分钟。 • HOURS：小时。 • DAYS：天。
type	String	参数解释： 调度类型，当前仅支持取值为stop。 取值范围： • STOP：停止。
processed	Boolean	参数解释： 表示是否处理完成。 取值范围： • true：该定时任务已经执行过。 • false：该定时任务尚未执行。

请求示例

查询服务详情成功。

```
GET https://{endpoint}/v2/{project_id}/services/{service_id}
```

响应示例

状态码：200

查询服务详情成功。

```
{
  "create_at" : 1751608828683,
  "deploy_timeout_minutes" : 60,
  "deploy_type" : "SINGLE",
  "dispatcher_group_id" : "ca29ce14-b475-12d3-a456-12345e678c99",
  "failure_reason" : ""
```

```
"id" : "123e4567-e89b-12d3-a456-426655440000",
"name" : "service-2aa2",
"predict_url" : [ {
  "type" : "PUBLIC",
  "urls" : [ "12.23.345.456" ]
}, {
  "type" : "CONSOLE",
  "urls" : [ "12.23.345.456" ]
}, {
  "type" : "DIRECT_CHANNEL",
  "urls" : [ ]
} ],
"schedule" : [ ],
"status" : "RUNNING",
"tags" : [ ],
"type" : "REAL_TIME",
"update_at" : 1751609745758,
"version" : {
  "deploy_timeout_minutes" : 60,
  "description" : "API_KEY",
  "id" : "2f31802f-1b43-4295-815c-f79047c3a14e",
  "instance_groups" : [ {
    "count" : 1,
    "framework" : "COMMON",
    "id" : "0ce5ef38-c2a1-46b0-9738-f79047c3a14e",
    "name" : "instance-a39b",
    "pool_id" : "infer-cpu-853-0621b83ffd694586b51a7b79c621ec42",
    "priority" : 1,
    "unit_configs" : [ {
      "cmd" : "",
      "codes" : [ ],
      "count" : 1,
      "custom_spec" : {
        "arch" : "x86",
        "cpu" : 0.1,
        "memory" : 40
      },
      "id" : "2c12345678c3bca70197d405a308046a",
      "image" : {
        "category" : "CPU",
        "id" : "8d4f342d298b157c6b12345d9012f12345f318ab5d9c270a22087f4e08e6883",
        "source" : "SWR",
        "swr_path" : "swr.cn-north-7.myhuaweicloud.com/example/helloworld-example:0.0.1"
      },
      "models" : [ ],
      "npu_reset_enable" : false
    } ],
    "weight" : 100
  } ],
  "log_configs" : [ {
    "status" : "OFF",
    "type" : "STDOUT"
  } ],
  "runtime_config" : {
    "service_invoke" : {
      "auth_type" : "API_KEY",
      "direct_channel_auth_enable" : false,
      "direct_channel_enable" : false,
      "dynamic_routing_enable" : false,
      "ems_enable" : false,
      "internet_access_enable" : true,
      "intranet_approval_enable" : true,
      "port" : 9876,
      "protocol" : "HTTPS"
    },
    "service_limit" : {
      "ip_black_list" : [ ],
      "ip_white_list" : [ ],
      "rate_limit" : {
```

```
    "num" : 200,
    "unit" : "SECONDS"
  },
  "request_size_limit" : 20,
  "request_timeout" : 30
},
"service_secret" : {
  "group_enable" : false,
  "secret_enable" : false,
  "secret_volumes" : [ ]
}
},
"upgrade_config" : {
  "rolling_update" : {
    "max_surge" : "1%",
    "max_unavailable" : "1%"
  },
  "type" : "ROLLING"
},
"version" : "0.0.1"
},
"workspace_id" : "0"
}
```

状态码

状态码	描述
200	查询服务详情成功。

错误码

请参见[错误码](#)。

7.1.7 更新服务配置

功能介绍

该接口适用于需要动态调整模型服务配置的场景，对模型的性能参数、资源池配置、服务调用配置等进行更新升级。通过调用此接口，用户可以在原有服务的情况下，升级成一个新的服务版本。调用此接口前，服务状态必须为“停止”、“失败”或“运行中”，且用户需具有修改服务的权限。更新成功后，新配置立即生效；若失败，服务保持原有配置并返回错误信息。常见异常包括参数验证错误、权限验证错误和服务状态错误。若服务ID无效、版本号不存在或用户无权限，则返回400 Bad Request或403 Forbidden；若服务状态不允许切换，则返回400 Bad Request。

URI

PUT /v2/{project_id}/services/{service_id}

表 7-157 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

请求参数

表 7-158 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 消息体的类型（格式） 约束限制： 不涉及。 取值范围： • application/json • application/json;charset=utf-8 默认取值： 不涉及。

表 7-159 请求 Body 参数

参数	是否必选	参数类型	描述
id	是	String	参数解释： 服务ID，在创建服务时即可在返回体中获取，也可通过查询服务列表接口获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： 不涉及
deploy_timeout_minutes	否	Integer	参数解释： 服务部署超时时间，integer类型，取值在1~300 约束限制： 不涉及。 取值范围： 版本长度不超过8位。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
version	是	String	参数解释： 必填，填了之后，数据库中如果存在相同版本号，将会报错（仅修改描述的场景除外）。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： 不涉及
description	否	String	参数解释： 非必填，仅更新描述的场景直接修改对应version的数据库字段，不新增版本号。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： 不涉及
group_configs	否	Array of GroupConfig objects	参数解释： 修改实例组场景下，必填，仅修改一个组，其他组信息也需要填，不修改，不修改/不删除场景下不填 约束限制： HCS环境下，group_configs的最大元素数量为1； 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
runtime_config	否	RuntimeConfig object	参数解释： 服务运行配置 约束限制： 不涉及。 取值范围： 不涉及 默认取值： 不涉及
upgrade_config	否	UpgradeConfig object	参数解释： 升级配置 约束限制： 不涉及。 取值范围： 不涉及 默认取值： 不涉及
log_configs	否	Array of LtsConfiguration objects	参数解释： 日志配置。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： 不涉及
tags	否	String	参数解释： 服务标签,上限20个 约束限制： 不涉及。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间id，默认是“0” 约束限制： 不涉及。 取值范围： 不涉及 默认取值： 不涉及
schedule	否	Array of ScheduleConfig objects	参数解释： 定时停止配置。 约束限制： 仅当body中另一个参数description为空时，此参数才生效。
custom_metrics_path	否	String	参数解释： 该参数值由英文逗号隔开的协议、端口号、地址组成，其中地址长度不超过255，且需要与镜像给定的协议、地址、端口一致，否则指标无法上报。

表 7-160 GroupConfig

参数	是否必选	参数类型	描述
id	否	String	参数解释： 实例组ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
name	是	String	参数解释： 实例组名称。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
pool_id	否	String	参数解释： 资源池ID，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
count	否	Integer	参数解释： 部署场景下，服务实例数量。 约束限制： 不涉及。 取值范围： [1, 128]。 默认取值： 不涉及。
system_log_dump_enable	否	Boolean	参数解释： 系统日志转储开关。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false

参数	是否必选	参数类型	描述
unit_configs	否	Array of UnitConfig objects	参数解释： 实例单元配置。 约束限制： 单机推理时，个数只会为1；如果是分布式推理时，根据不同框架，实例单元配置可灵活配置。
weight	是	Integer	参数解释： 权重百分比，分配到此模型的流量权重，仅当模型部署为在线服务时需要配置。 约束限制： 不涉及。 取值范围： [0, 100]。 默认取值： 不涉及。
secret_type	否	String	参数解释： 凭证类型相关配置，用户可以在此处选择使用的凭证类型（dew, cce） 约束限制： 不涉及。
secret_name	否	String	参数解释： 凭证名称，用户使用dew类型凭证时可以在此处选择使用的凭证。 约束限制： 不涉及。
priority	否	Integer	参数解释： 服务优先级。 约束限制： - 如服务处于“运行中”，priority字段为必要参数，且value必须为原版的值； - 如服务处于“停止”，priority字段为非必要参数。 取值范围： [1, 3]。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
high_avail_switch	否	Boolean	参数解释： 高可用开关，开启后不同实例的pod将尽量均匀分布到不同的节点上。 约束限制： 不涉及 取值范围： true: 高可用开启 false: 高可用关闭 默认取值： true

表 7-161 UnitConfig

参数	是否必选	参数类型	描述
id	否	String	参数解释： 实例单元ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
name	否	String	参数解释： 实例单元角色名称。 约束限制： 最大长度为16字符，且需满足正则：^[a-z0-9]([-a-z0-9]*[a-z0-9])?\$ 默认取值： 不涉及。

参数	是否必选	参数类型	描述
role	否	String	参数解释： 实例单元角色。 约束限制： 不涉及。 取值范围： mindle场景下： • scheduler：表示调度单元。 • manager：表示管理单元。 • worker：表示工作单元。 vllm场景下： • prefill：表示全量单元。 • decode：表示增量单元。 • common：表示其他角色。 默认取值： 不涉及。
custom_spec	否	CustomSpec object	参数解释： 自定义资源规格配置。 约束限制： 不涉及。 参数示例： "custom_spec": { "arch": "x86", "cpu": 0.51, "memory": 1024.0 },
flavor	否	String	参数解释： 资源规格，根据所提供版本选择 适合业务的规格。当 specification为custom为自定义 规格。由custom_spec指定部署 的规格配置。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
image	是	Image object	参数解释： 镜像配置信息，包含镜像地址，镜像来源。 约束限制： 不涉及。
models	否	Array of Model objects	参数解释： 模型相关配置，用户可以在此处选择模型及权重文件配合镜像使用。 约束限制： 不涉及。
codes	否	Array of Code objects	参数解释： 代码相关配置，用户可以在此处选择代码所在的obs路径等。 约束限制： 不涉及。
dumps	否	Array of Dump objects	参数解释： 用户转储配置，用户可以在此处选择要转储的目的obs。 约束限制： 最多配置20组。
count	否	Integer	参数解释： 配置实例个数，单机推理无需配置。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
cmd	否	String	参数解释： 启动命令。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
envs	否	Map<String,String>	参数解释： 环境变量。 约束限制： 变量键长度不大于64，由字母、数字、下划线、中划线、点组成，不能以数字开头。值的输入内容不能存在HTML标签，包括<^>。
readiness_health	否	Health object	参数解释： 就绪健康检查。 约束限制： 不涉及。
startup_health	否	Health object	参数解释： 启动健康检查。 约束限制： 不涉及。
liveness_health	否	Health object	参数解释： 存活健康检查。 取值范围： 不涉及。
port	否	Integer	参数解释： 端口。 约束限制： 不涉及。 取值范围： [1,65535]。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
recovery	否	String	参数解释： 恢复策略重启等级。 约束限制： 不涉及。 取值范围： - Instance：实例级，故障时重新拉起整个实例。 - Pod：Pod级，故障时重新拉起故障pod。 - Custom：自定义级，故障时不做处理，留给用户处理。 默认取值： 不涉及。
npu_reset_enable	否	Boolean	参数解释： 是否开启恢复策略。 约束限制： 不涉及。 取值范围： - true：开启恢复策略。 - false：不开启恢复策略。 默认取值： 不涉及。
affinity	否	Affinity object	参数解释： 节点亲和调度设置。 约束限制： 不涉及。

表 7-162 CustomSpec

参数	是否必选	参数类型	描述
gpu	否	Number	参数解释： GPU个数。 约束限制： 不涉及。 取值范围： 支持配置小数，输入值不能小于0（最多支持2位小数，小数点后第3位做四舍五入处理）。 默认取值： 不涉及。
memory	否	Integer	参数解释： 内存，单位为MB。 约束限制： 不涉及。 取值范围： 仅支持整数。 默认取值： 不涉及。
cpu	否	Number	参数解释： CPU核数。 约束限制： 不涉及。 取值范围： 支持配置小数，输入值不能小于0.01（最多支持2位小数，小数点后第3位做四舍五入处理）。 默认取值： 不涉及。
ascend	否	Integer	参数解释： Ascend芯片个数。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-163 Image

参数	是否必选	参数类型	描述
id	否	String	参数解释： 镜像id。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
source	是	String	参数解释： 镜像类别，标识镜像来源。 约束限制： 不涉及。 取值范围： • swr：软件仓库服务。 默认取值： 不涉及。
swr_path	是	String	参数解释： 镜像地址，source不同取值时，地址为不同值。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
category	否	String	参数解释： 镜像支持的规格。 约束限制： 不涉及。 取值范围： • GPU：图形处理器。 • CPU：中央处理器。 • ASCEND：昇腾芯片。 默认取值： CPU。

表 7-164 Model

参数	是否必选	参数类型	描述
source	是	String	参数解释： 代码来源类别。 约束限制： 不涉及。 取值范围： 如下参数不区分大小写 • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。 • LOCAL：挂载宿主机本地存储目录。 默认取值： 不涉及。
address	否	String	参数解释： 代码来源地址，格式遵循不同存储系统。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
mount_path	是	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
efs_sub_path	否	String	参数解释： 当存储类别为EFS时，支持配置子目录。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
read_only	否	Boolean	参数解释： 挂载权限设置，是否只读。 约束限制： 不涉及。 取值范围： • true：只读。 • false：非只读。 默认取值： 不涉及。
os_warm_up	否	Boolean	参数解释： os预热。 约束限制： 不涉及。 取值范围： • true：预热。 • false：不预热。 默认取值： 不涉及。
source_name	否	String	参数解释： 预热名称。 约束限制： os_warm_up为true时必填。 取值范围： 支持1-64位字符，可包含字母、中文、数字、中划线、下划线。 默认取值： 不涉及。

表 7-165 Code

参数	是否必选	参数类型	描述
source	是	String	参数解释： 代码来源类别。 约束限制： 不涉及。 取值范围： ● OBS：对象存储服务。 ● OBSFS：OBS的文件系统接口。 ● EFS：弹性文件服务。 默认取值： 不涉及。
address	否	String	参数解释： 代码来源地址，格式遵循不同存储系统。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
source_id	否	String	参数解释： 代码来源id，与address二选一，当且仅当source为EFS时，可以传入sfs turbo的id。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
mount_path	是	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	否	String	参数解释： sfs 子路径。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
read_only	否	Boolean	参数解释： 是否只读。 约束限制： 不涉及。 取值范围： • true：只读。 • false：非只读。 默认取值： 不涉及。

表 7-166 Dump

参数	是否必选	参数类型	描述
source	是	String	参数解释： 转储挂载目录来源类别。 约束限制： 不涉及。 取值范围： ● OBS：对象存储服务。 ● OBSFS：OBS的文件系统接口。 默认取值： 不涉及。
address	否	String	参数解释： 转储挂载目录来源地址，支持https或obs协议的obs地址。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
mount_path	是	String	参数解释： 挂载到容器内的路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-167 Health

参数	是否必选	参数类型	描述
check_method	否	String	参数解释： 健康检查方式：HTTP 或者 EXEC（命令行）。 约束限制： 不涉及。 取值范围： • HTTP：超文本传输协议。 • EXEC：命令行。 默认取值： 不涉及。
cmd	否	String	参数解释： 当健康检查方式为EXEC时，配置的命令行。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
url	否	String	参数解释： 当健康检查方式为HTTP 时，配置的请求地址。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
protocol	否	String	参数解释： 连接协议。 约束限制： 不涉及。 取值范围： • HTTPS：超文本传输协议安全版。 • HTTP：超文本传输协议。 • WSS：网络通信协议安全版。 • WS：网络通信协议。 默认取值： 不涉及。
initial_delay_seconds	是	Integer	参数解释： 执行首次探测时，应该等待的时间。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
timeout_seconds	是	Integer	参数解释： 执行探测的超时时间，默认1秒，最小1秒。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
period_seconds	是	Integer	参数解释： 执行健康检查的周期时间，执行探测的频率。默认是10秒，最小1秒。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
failure_threshold	是	Integer	参数解释： 探测成功后，最少连续探测失败多少次才被认定为失败。默认是3。最小值是1。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-168 Affinity

参数	是否必选	参数类型	描述
affinity_type	是	String	参数解释： 节点亲和类型。 约束限制： 不涉及。 取值范围： - AFFINITY：亲和。 - ANTI_AFFINITY：反亲和。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
required	是	Boolean	参数解释： 是否设置强亲和。 约束限制： 不涉及。 取值范围： • true：设置强亲和。 • false：不设置强亲和。 默认取值： 不涉及。
selection_mode	是	String	参数解释： 选择节点方式。 约束限制： 不涉及。 取值范围： IP 默认取值： 不涉及。
targets	是	Map<String,String>	参数解释： 通过上述方式选择的列表，长度不能超过20。 约束限制： 不涉及。

表 7-169 RuntimeConfig

参数	是否必选	参数类型	描述
service_invoke	是	ServiceInvoke object	参数解释： 服务调用时的相关配置。 约束限制： 不涉及。
service_limit	是	ServiceLimit object	参数解释： 服务限制信息。 约束限制： 不涉及。

参数	是否必选	参数类型	描述
service_secret	否	ServiceSecret object	参数解释： 服务密钥挂载。 约束限制： 不涉及。

表 7-170 ServiceInvoke

参数	是否必选	参数类型	描述
port	是	Integer	参数解释： 服务端口号。 约束限制： 不涉及。 取值范围： [1, 65535]。 默认取值： 不涉及。
protocol	是	String	参数解释： 服务请求协议。当选择WSS与WS时，服务接口会升级为WebSocket。开启WebSocket时，不支持同时设置“服务流量限制”。 约束限制： 不涉及。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
auth_type	是	String	参数解释： 认证类型。 约束限制： 不涉及。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。 默认取值： 不涉及。
direct_channel_enable	否	Boolean	参数解释： 是否开启专属通道。 约束限制： 不涉及。 取值范围： • TRUE：开启专属通道。 • FALSE：不开启专属通道。 默认取值： 不涉及。
direct_channel_auth_enable	否	Boolean	参数解释： 专属通道模式下proxy是否开启鉴权。 约束限制： 不涉及。 取值范围： • TRUE：开启鉴权。 • FALSE：不开启鉴权。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
internet_access_enable	否	Boolean	参数解释： 外网访问。 不涉及。 约束限制： 不涉及。 取值范围： • TRUE：要外网访问。 • FALSE：不要外网访问。 默认取值： 不涉及。
intranet_approve_enable	否	Boolean	参数解释： 内网审批。 不涉及。 取值范围： • TRUE：要内网审批。 • FALSE：不要内网审批。 默认取值： 不涉及。
dynamic_routing_enable	否	Boolean	参数解释： 动态路由开关。 不涉及。 取值范围： • TRUE：开启动态路由。 • FALSE：不开启动态路由。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
strategy	否	String	参数解释： 智能路由策略。 约束限制： 不涉及。 取值范围： • ROUND_ROBIN：轮询。 • ORIGIN_IP_HASH：源IP哈希。 • MIN_CONN：最小连接数。 • MIN_FIRST_TOKEN_TIME：最小首token时延。 • COMPOSITE：综合负载。 • SLO_BASED：SLO优先级 默认取值： 不涉及。
metric_api_scheme	否	String	参数解释： 指标接口服务请求协议。 约束限制： 不涉及。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 默认取值： 不涉及。
metric_api_port	否	String	参数解释： 指标接口端口号。 约束限制： 不涉及。 取值范围： [1, 65535]。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
metric_api_path	否	String	参数解释： 指标接口path。 约束限制： 不涉及。 取值范围： 默认值metrics。 默认取值： metrics
emsEnable	否	Boolean	参数解释： 是否开启EMS加速。 约束限制： 不涉及。 取值范围： • TRUE：开启EMS加速。 • FALSE：不开启EMS加速。 默认取值： 不涉及。
request_retry_enable	否	Boolean	参数解释： proxy支持请求重调度开关。 约束限制： 不涉及。 取值范围： • true：开启proxy支持请求重调度。 • false：不开启proxy支持请求重调度。 默认取值： false
request_retry_cnt_max	否	Integer	参数解释： proxy支持请求重调度的重试次数 约束限制： 不涉及。 取值范围： [1, 10]。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
request_retry_interval_ms	否	Integer	参数解释： proxy支持请求重调度的重试间隔，单位ms 约束限制： 不涉及。 取值范围： [1, 10000]。 默认取值： 不涉及。

表 7-171 ServiceLimit

参数	是否必选	参数类型	描述
rate_limit	是	RateLimit object	参数解释： 流控相关指标。 约束限制： 不涉及。
request_size_limit	是	Integer	参数解释： 请求大小限制。 约束限制： 不涉及。 取值范围： 1-50M。 默认取值： 不涉及。
request_timeout	是	Integer	参数解释： 超时时间。 约束限制： 不涉及。 取值范围： 1到7200秒。 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
ip_white_list	否	Array of strings	参数解释： IP白名单。 约束限制： 不涉及。
ip_black_list	否	Array of strings	参数解释： IP黑名单。 约束限制： 不涉及。

表 7-172 RateLimit

参数	是否必选	参数类型	描述
num	是	Integer	参数解释： 服务流量限制是指指定单位内一个服务能够被访问的次数上限。 约束限制： 不涉及。 取值范围： 1-500。 默认取值： 不涉及。
unit	是	String	参数解释： 流量限制单元。 约束限制： 不涉及。 取值范围： • SECONDS（秒）。 • MINUTES（分钟）。 默认取值： 不涉及。

表 7-173 ServiceSecret

参数	是否必选	参数类型	描述
secret_enable	否	Boolean	参数解释： 是否启用密钥。 约束限制： 不涉及。 取值范围： • true：启用密钥。 • false：不启用密钥。 默认取值： false。
secret_type	否	String	参数解释： 密钥类型。 约束限制： 不涉及。 取值范围： • custom：自定义密钥。 默认取值： 不涉及。
secret_volumes	否	SecretVolume object	参数解释： 密钥挂载。 约束限制： 上限30个。
group_enable	否	Boolean	参数解释： 是否启用镜像的用户组。 约束限制： 不涉及。 取值范围： • true：启用镜像的用户组。 • false：不启用镜像的用户组。 默认取值： false。

参数	是否必选	参数类型	描述
group_id	否	Long	参数解释： 镜像的用户组id。 约束限制： 不涉及。 取值范围： 1000~4294967294。 默认取值： 不涉及。

表 7-174 SecretVolume

参数	是否必选	参数类型	描述
secret_key	否	String	参数解释： 密钥key。 约束限制： 匹配一个长度在1到63之间的字符串，只能包含字母、数字、点、下划线和连字符，并且不能以两个连续的点（..）开头。 取值范围： 不涉及。 默认取值： 不涉及。
secret_value	否	String	参数解释： 密钥值。 约束限制： 长度在1~32768，Base64编码后的密钥值。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
mountPath	是	String	参数解释： 挂载路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。

表 7-175 UpgradeConfig

参数	是否必选	参数类型	描述
type	否	String	参数解释： 升级类型。 约束限制： 不涉及。 取值范围： ROLLING：滚动升级，默认值。 默认取值： 不涉及。
rolling_update	否	RollingUpdate object	参数解释： 滚动更新配置。 约束限制： 不涉及。

表 7-176 RollingUpdate

参数	是否必选	参数类型	描述
max_surge	否	String	参数解释： 滚动更新时最多可以启动多少个 Pod。 约束限制： 百分数类型字符串。 取值范围： 1%-100%。 默认取值： 1%。
max_unavailable	否	String	参数解释： 滚动更新时最多可以删除多少个 Pod。 约束限制： 百分数类型字符串。 取值范围： 1%-100%。 默认取值： 1%。

表 7-177 LtsConfiguration

参数	是否必选	参数类型	描述
status	是	String	参数解释： 日志服务状态。 取值范围： - ON：开启。 - OFF：关闭。
type	是	String	参数解释： 当前只支持 标准日志输入输出 STDOUT。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
log_group_id	否	String	参数解释： 日志组id，用户选择自己已有的日志组，不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
log_stream_id	否	String	参数解释： 日志流id，用户选择自己已有的日志组。不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-178 ScheduleConfig

参数	是否必选	参数类型	描述
duration	否	Integer	参数解释： 对应的时间单位的数值。 约束限制： 与time_unit共同确认时间设置的范围是1分钟~7天之间。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
time_unit	否	String	参数解释： 时间的单位。 约束限制： 与duration共同确认时间设置的范围是1分钟~7天之间。 取值范围： • MINUTES：分钟。 • HOURS：小时。 • DAYS：天。 默认取值： 不涉及。
type	否	String	参数解释： 调度类型，当前仅支持取值为stop。 约束限制： 不涉及。 取值范围： • STOP：停止。 默认取值： 不涉及。

响应参数

状态码：200

表 7-179 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 取值范围： 不涉及。

参数	参数类型	描述
name	String	参数解释： 服务名，用户在 创建服务 时自定义的名称。 取值范围： 支持1-64位字符，可包含字母、中文、数字、中划线、下划线。
dispatcher_group_id	String	参数解释： 服务绑定的dispatcher组ID。 取值范围： 不涉及。
workspace_id	String	参数解释： 工作空间ID。 取值范围： 0：默认空间ID。 - 由数字和小写字母组成的32位字符：其他空间ID，可参考工作空间创建。
type	String	参数解释： 推理服务类型。 取值范围： REAL_TIME：在线服务。
deploy_type	String	参数解释： 部署方式。 取值范围： - SINGLE：单机单卡。 - MULTI：多机多卡。

参数	参数类型	描述
status	String	参数解释： 服务当前状态。 取值范围： • DEPLOYING：部署中。 • FAILED：失败。 • STOPPED：停止。 • RUNNING：运行中。 • DELETING：删除中。 • STOPPING：停止中。 • CONCERNING：告警。 • UPGRADING：升级中。 • ERROR：异常。 • INTERRUPTING：中断中。
failure_reason	String	参数解释： 在线服务失败原因。 取值范围： 不涉及。
version	ServiceVersionResponse object	参数解释： 当前服务版本信息。
predict_url	Array of predict_url_Response objects	参数解释： 在线服务访问地址。
tags	Array of TmsTag_Response objects	参数解释： TMS对接标签类。
create_at	String	参数解释： 创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
update_at	String	参数解释： 更新时间，根据更新时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。

参数	参数类型	描述
schedule	Array of ScheduleConfig_Response objects	参数解释： 定时停止配置。
provider	String	参数解释： 服务提供者的账号id（创建服务时通过X-Auth-Token-Provider请求头解析iam token而来），该值不为空时，该服务的所有更新操作需要在请求头中添加X-Auth-Token-Provider，取值为该账号id的domain级或project级token。

表 7-180 ServiceVersionResponse

参数	参数类型	描述
id	String	参数解释： 版本id。 取值范围： 不涉及。
version	String	参数解释： 版本号。 取值范围： 不涉及。
description	String	参数解释： 描述。 取值范围： 不涉及。
predict_url	String	参数解释： 推理请求的访问地址。 取值范围： 不涉及。
runtime_config	RuntimeConfig_Response object	参数解释： 服务运行配置。
upgrade_config	UpgradeConfig_Response object	参数解释： 服务升级配置。
instance_groups	Array of GroupConfig_Response objects	参数解释： 服务实例组信息。

参数	参数类型	描述
log_configs	Array of LogConfig_Response objects	参数解释： 服务日志配置信息。
deploy_timeout_minutes	Integer	参数解释： 部署超时时间。 取值范围： 不涉及。

表 7-181 RuntimeConfig_Response

参数	参数类型	描述
service_invoke	ServiceInvoke_Response object	参数解释： 服务调用时的相关配置。
service_limit	ServiceLimit_Response object	参数解释： 服务限制信息。 约束限制： 不涉及。
service_secret	ServiceSecret_Response object	参数解释： 服务密钥挂载。

表 7-182 ServiceInvoke_Response

参数	参数类型	描述
port	Integer	参数解释： 服务端口号。 取值范围： [1, 65535]。

参数	参数类型	描述
protocol	String	参数解释： 服务请求协议。当选择WSS与WS时，服务接口会升级为WebSocket。开启WebSocket时，不支持同时设置“服务流量限制”。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
auth_type	String	参数解释： 认证类型。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。
direct_channel_enable	Boolean	参数解释： 是否开启专属通道。 取值范围： • TRUE：开启专属通道。 • FALSE：不开启专属通道。
direct_channel_auth_enable	Boolean	参数解释： 专属通道模式下proxy是否开启鉴权。 取值范围： • TRUE：开启鉴权。 • FALSE：不开启鉴权。
internet_access_enable	Boolean	参数解释： 外网访问。 取值范围： • TRUE：要外网访问。 • FALSE：不要外网访问。
intranet_approve_enable	Boolean	参数解释： 内网审批。 取值范围： • TRUE：要内网审批。 • FALSE：不要内网审批。

参数	参数类型	描述
dynamic_routing_enable	Boolean	参数解释： 动态路由开关。 取值范围： • TRUE：开启动态路由。 • FALSE：不开启动态路由。
strategy	String	参数解释： 智能路由策略。 取值范围： • ROUND_ROBIN：轮询。 • ORIGIN_IP_HASH：源IP哈希。 • MIN_CONN：最小连接数。 • MIN_FIRST_TOKEN_TIME：最小首token时延。 • COMPOSITE：综合负载。 • SLO_BASED：SLO优先级。
metric_api_scheme	String	参数解释： 指标接口服务请求协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。
metric_api_port	String	参数解释： 指标接口端口号。 取值范围： [1, 65535]。
metric_api_path	String	参数解释： 指标接口path。 取值范围： 默认值metrics。
ems_enable	Boolean	参数解释： 是否开启EMS加速。 取值范围： • TRUE：开启EMS加速。 • FALSE：不开启EMS加速。

参数	参数类型	描述
request_retry_enable	Boolean	参数解释： proxy支持请求重调度开关。 取值范围： • true：开启proxy支持请求重调度。 • false：不开启proxy支持请求重调度。
request_retry_cnt_max	Integer	参数解释： proxy支持请求重调度的重试次数 取值范围： [1, 10]。
request_retry_interval_ms	Integer	参数解释： proxy支持请求重调度的重试间隔，单位ms 取值范围： [1, 10000]。

表 7-183 ServiceLimit_Response

参数	参数类型	描述
rate_limit	RateLimit_Response object	参数解释： 流控相关指标。
request_size_limit	Integer	参数解释： 请求大小限制。 取值范围： 1-50M。
request_timeout	Integer	参数解释： 超时时间。 取值范围： 1到7200秒。
ip_white_list	Array of strings	参数解释： IP白名单。
ip_black_list	Array of strings	参数解释： IP黑名单。

表 7-184 RateLimit_Response

参数	参数类型	描述
num	Integer	参数解释： 服务流量限制是指指定单位内一个服务能够被访问的次数上限。 取值范围： 1-500。
unit	String	参数解释： 流量限制单元。 取值范围： • NANOS（纳秒）。 • MICROS（微秒）。 • MILLIS（毫秒）。 • SECONDS（秒）。 • MINUTES（分钟）。 • HOURS（小时）。 • DAYS（天）。

表 7-185 ServiceSecret_Response

参数	参数类型	描述
secret_enable	Boolean	参数解释： 是否启用密钥。 取值范围： • true：启用密钥。 • false：不启用密钥。
secret_type	String	参数解释： 密钥类型。 取值范围： • custom：自定义密钥。
secret_volumes	SecretVolume_Response object	参数解释： 密钥挂载。 约束限制： 上限30个。

参数	参数类型	描述
group_enable	Boolean	参数解释： 是否启用镜像的用户组。 取值范围： • true：启用镜像的用户组。 • false：不启用镜像的用户组。
group_id	Long	参数解释： 镜像的用户组id。 取值范围： 1000~4294967294。

表 7-186 SecretVolume_Response

参数	参数类型	描述
secret_name	String	参数解释： 密钥名称。 取值范围： 不涉及。
secret_key	String	参数解释： 密钥key。 取值范围： 长度不大于63。
secret_value	String	参数解释： 密钥值。 取值范围： 长度不大于32768。
mountPath	String	参数解释： 挂载路径。 取值范围： 不涉及。

表 7-187 UpgradeConfig_Response

参数	参数类型	描述
type	String	参数解释： 升级类型。 取值范围： ROLLING：滚动升级，默认值。
rolling_update	RollingUpdate_Response object	参数解释： 滚动更新配置。

表 7-188 RollingUpdate_Response

参数	参数类型	描述
max_surge	String	参数解释： 滚动更新时最多可以启动多少个Pod。 取值范围： 不涉及。
max_unavailable	String	参数解释： 滚动更新时最多可以删除多少个Pod。 取值范围： 不涉及。

表 7-189 GroupConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例组ID。 取值范围： 不涉及。
name	String	参数解释： 实例组名称。 取值范围： 不涉及。

参数	参数类型	描述
pool_id	String	参数解释： 资源池ID，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 取值范围： 不涉及。
count	Integer	参数解释： 部署场景下，服务实例数量。 约束限制： 不涉及。 取值范围： [1, 128]。 默认取值： 不涉及。
system_log_dump_enable	Boolean	参数解释： 系统日志转储开关量。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： false
unit_configs	Array of UnitConfig_Response objects	参数解释： 实例单元配置。
weight	Integer	参数解释： 权重百分比，分配到此模型的流量权重，仅当模型部署为在线服务时需要配置。 取值范围： [0, 100]。
secret_type	String	参数解释： 凭证类型相关配置，用户可以在此处选择使用的凭证类型（dew，cce） 约束限制： 不涉及。

参数	参数类型	描述
secret_name	String	参数解释： 凭证名称，用户使用dew类型凭证时可以在此处选择使用的凭证。 约束限制： 不涉及。
priority	Integer	参数解释： 服务优先级。 约束限制： 不涉及。 取值范围： [1, 3]。 默认取值： 不涉及。
high_avail_switch	Boolean	参数解释： 高可用开关，开启后不同实例的pod将尽量均匀分布到不同的节点上。 取值范围： true: 高可用开启 false: 高可用关闭
framework	String	参数解释： 算法框架。 取值范围： COMMON：普通在线服务。

表 7-190 UnitConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例单元ID。 取值范围： 不涉及。
role	String	参数解释： 实例单元角色。 取值范围： common：表示其他角色。
custom_spec	CustomSpecResponse object	参数解释： 自定义资源规格配置。

参数	参数类型	描述
flavor	String	参数解释： 资源规格，根据所提供版本选择适合业务的规格。当specification为custom时表示自定义规格。由custom_spec指定部署的规格配置。 取值范围： 不涉及。
image	Image_Response object	参数解释： 镜像配置信息，包含镜像地址，镜像来源。
models	Array of Model_Response objects	参数解释： 模型相关配置，用户可以在此处选择模型及权重文件配合镜像使用。
codes	Array of Code_Response objects	参数解释： 代码相关配置，用户可以在此处选择代码所在的obs路径等。
dumps	Array of DumpResponse objects	参数解释： 转储相关配置，用户可以在此处选择转储的目的obs路径等。
count	Integer	参数解释： 配置实例个数，单机推理无需配置。 取值范围： 不涉及。
cmd	String	参数解释： 启动命令。 取值范围： 不涉及。
envs	Map<String,String>	参数解释： 环境变量。
readiness_health	Health_Response object	参数解释： 就绪健康检查。
startup_health	Health_Response object	参数解释： 启动健康检查。
liveness_health	Health_Response object	参数解释： 存活健康检查。

参数	参数类型	描述
port	Integer	参数解释： 端口。 取值范围： [1,65535]。
recovery	String	参数解释： 恢复策略重启等级。 取值范围： - Instance：实例级，故障时重新拉起整个实例。 - Pod：Pod级，故障时重新拉起故障pod。 - Custom：自定义级，故障时不做处理，留给用户处理。
npu_reset_enable	Boolean	参数解释： 是否开启恢复策略。 取值范围： - true：开启恢复策略。 - false：不开启恢复策略。
affinity	Affinity_Response object	参数解释： 节点亲和调度设置。

表 7-191 CustomSpecResponse

参数	参数类型	描述
gpu	Number	参数解释： GPU个数。 取值范围： 支持配置小数，输入值不能小于0（最多支持2位小数，小数点后第3位做四舍五入处理）。
memory	Integer	参数解释： 内存，单位为MB。 取值范围： 仅支持整数。

参数	参数类型	描述
cpu	Number	参数解释： CPU核数。 取值范围： 支持配置小数，输入值不能小于0.01（最多支持2位小数，小数点后第3位做四舍五入处理）。
ascend	Integer	参数解释： Ascend芯片个数。 取值范围： 不涉及。

表 7-192 Image_Response

参数	参数类型	描述
id	String	参数解释： 镜像id。 取值范围： 不涉及。
source	String	参数解释： 镜像类别，标识镜像来源。 取值范围： • swr：软件仓库服务。
swr_path	String	参数解释： 镜像地址，source不同取值时，地址为不同值。 取值范围： 不涉及。
category	String	参数解释： 镜像支持的规格。 取值范围： • GPU：图形处理器。 • CPU：中央处理器。 • ASCEND：昇腾芯片。

表 7-193 Model_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。 • LOCAL：挂载宿主机本地存储目录。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： 当存储类别为EFS时，支持配置子目录。 取值范围： 不涉及。
read_only	Boolean	参数解释： 挂载权限设置，是否只读。 取值范围： • true：只读。 • false：非只读。
os_warm_up	Boolean	参数解释： os预热。 取值范围： • true：预热。 • false：不预热。

表 7-194 Code_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
source_id	String	参数解释： 代码来源id，与address二选一，当且仅当source为EFS时，可以传入sfs turbo的id。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： sfs 子路径。 取值范围： 不涉及。

参数	参数类型	描述
read_only	Boolean	参数解释： 是否只读。 取值范围： • true：只读。 • false：非只读。

表 7-195 DumpResponse

参数	参数类型	描述
source	String	参数解释： 用户转储来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。
address	String	参数解释： 用户转储来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及。
type	String	参数解释： 转储类型。 取值范围： • DUMP：用户自定义转储。 • DUMP_SYS：系统转储。

表 7-196 Health_Response

参数	参数类型	描述
check_method	String	参数解释： 健康检查方式：HTTP 或者 EXEC（命令行）。 取值范围： • HTTP：超文本传输协议。 • EXEC：命令行。
cmd	String	参数解释： 当健康检查方式为EXEC时，配置的命令行。 取值范围： 不涉及。
url	String	参数解释： 当健康检查方式为HTTP 时，配置的请求地址。 取值范围： 不涉及。
protocol	String	参数解释： 连接协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
initial_delay_seconds	Integer	参数解释： 执行首次探测时，应该等待的时间。 取值范围： 不涉及。
timeout_seconds	Integer	参数解释： 执行探测的超时时间，默认1秒，最小1秒。 取值范围： 不涉及。

参数	参数类型	描述
period_seconds	Integer	参数解释： 执行健康检查的周期时间，执行探测的频率。默认是10秒，最小1秒。 取值范围： 不涉及。
failure_threshold	Integer	参数解释： 探测成功后，最少连续探测失败多少次才被认定为失败。默认是3。最小值是1。 取值范围： 不涉及。

表 7-197 Affinity_Response

参数	参数类型	描述
affinity_type	String	参数解释： 节点亲和类型。 取值范围： - AFFINITY：亲和。 - ANTI_AFFINITY：反亲和。
required	Boolean	参数解释： 是否设置强亲和。 取值范围： - true：设置强亲和。 - false：不设置强亲和。
selection_mode	String	参数解释： 选择节点方式。 取值范围： IP。
targets	Map<String,String>	参数解释： 通过上述方式选择的列表，长度不能超过20。

表 7-198 LogConfig_Response

参数	参数类型	描述
type	String	参数解释： 日志输出类型。 取值范围： • STDOUT：日志输出到控制台或终端。 • FILE：日志输出到文件。
status	String	参数解释： 日志服务状态。 取值范围： • ON：开启。 • OFF：关闭。
log_group_id	String	参数解释： 日志组id，用户选择自己已有的日志组，不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
log_stream_id	String	参数解释： 日志流id，用户选择自己已有的日志组。不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-199 predict_url_Response

参数	参数类型	描述
type	String	参数解释： 访问方式。 取值范围： • CONSOLE：通过控制台界面访问。 • PUBLIC：通过公网访问。 • INTERNAL：通过内网访问。 • DIRECT_CHANNEL：通过直接通道访问。
urls	Array of strings	参数解释： 推理请求的访问地址，仅当type为real-time时，且服务部署完成后才会确保该字段有值。

表 7-200 TmsTag_Response

参数	参数类型	描述
key	String	参数解释： 标签键字段。 约束限制： 不涉及。 取值范围： 长度为1~128，标签的键可以包含任意语种字母、数字、空格，以及_ . : = + - @ 特殊字符，但首尾不能含有空格，不能以_sys_开头。 默认取值： 不涉及。
value	String	参数解释： 标签值字段。 取值范围： 长度为255，包括字母、数字、下划线、点、斜杠、等号、加号、减号和@符号。

表 7-201 ScheduleConfig_Response

参数	参数类型	描述
due_time	Long	参数解释： 触发时间，13位时间戳。 取值范围： 不涉及。
duration	Integer	参数解释： 对应的时间单位的数值。 取值范围： 不涉及。
time_unit	String	参数解释： 调度时间单位。 取值范围： • MINUTES：分钟。 • HOURS：小时。 • DAYS：天。
type	String	参数解释： 调度类型，当前仅支持取值为stop。 取值范围： • STOP：停止。
processed	Boolean	参数解释： 表示是否处理完成。 取值范围： • true：该定时任务已经执行过。 • false：该定时任务尚未执行。

请求示例

修改服务配置。

```
PUT https://{endpoint}/v2/{project_id}/services/{service_id}

{
  "schedule": [{
    "time_unit": "HOURS",
    "type": "STOP",
    "duration": 10
  }],
  "id": "123e4567-e89b-12d3-a456-426655440000",
  "name": "service-example",
  "version": "0.0.1",
  "deploy_timeout_minutes": 60,
  "type": "REAL_TIME",
  "description": "",
  "workspace_id": "0",
```



```
"deploy_type": "SINGLE",
"group_configs": [ {
  "framework": "COMMON",
  "name": "instance-example",
  "pool_id": "pool-example",
  "weight": 100,
  "count": 1,
  "unit_configs": [ {
    "image": {
      "source": "SWR",
      "swr_path": "swr.cn-north-7.myhuaweicloud.com/example/helloworld-example:0.0.1"
    },
    "flavor": "flavor-example",
    "cmd": "/bin/bash -c shart.sh"
  } ]
},
],
"tags": [ ],
"runtime_config": {
  "service_invoke": {
    "port": 123,
    "protocol": "HTTPS",
    "auth_type": "NONE",
    "direct_channel_enable": false,
    "direct_channel_auth_enable": false,
    "dynamic_routing_enable": false
  },
  "service_limit": {
    "request_size_limit": 20,
    "request_timeout": 30,
    "ip_white_list": [ ],
    "ip_black_list": [ ],
    "rate_limit": {
      "num": 200,
      "unit": "SECONDS"
    }
  }
},
"upgrade_config": {
  "type": "ROLLING",
  "rolling_update": {
    "max_surge": "20%",
    "max_unavailable": "20%"
  }
}
}
```

响应示例

状态码：200

修改服务配置成功。

```
{
  "create_at": 1733470423880,
  "failure_reason": "",
  "id": "123e4567-e89b-12d3-a456-426655440000",
  "name": "infer-10",
  "schedule": [ {
    "due_time": 0,
    "duration": 1,
    "processed": false,
    "time_unit": "HOURS",
    "type": "STOP"
  } ],
  "status": "DEPLOYING",
  "deploy_timeout_minutes": 60,
  "type": "REAL_TIME",
  "update_at": 1733482797586,
  "version": {
```

```
"description" : "0.1.0版本更新",
"id" : "0ed64919-729c-4ecc-bbdf-87381013322b",
"instance_groups" : [ {
  "count" : 1,
  "framework" : "COMMON",
  "id" : "f702f711-1cc1-4b5b-921e-87381013322b",
  "name" : "xxxxx1",
  "pool_id" : "pool-infer-xxxx",
  "unit_configs" : [ {
    "cmd" : "",
    "codes" : [ {
      "address" : "https://example.obs.example1.com",
      "mount_path" : "/codes/",
      "source" : "EFS",
      "source_id" : "98b57430-a738-4bce-9dea-2c70eb5f1005"
    } ],
    "envs" : {
      "additionalProp1" : "string1",
      "additionalProp3" : "string2",
      "additionalProp2" : "string3"
    },
    "flavor" : "CPU: 2核 8GB",
    "id" : "8a0e84c0939b9c2101939ba30846004d",
    "image" : {
      "category" : "CPU",
      "source" : "SWR",
      "swr_path" : "swr.huaweicloud.com/atelier/pytorch_1_4:pytorch_1.4-cuda_10.1-py37-ubuntu_18.04-x86_64-041ba2e"
    },
    "models" : [ {
      "mount_path" : "/models/",
      "source" : "EFS",
      "source_id" : "98b57430-a738-4bce-9dea-2c70eb5f1005"
    } ],
    "role" : "COMMON"
  } ],
  "weight" : 100
} ],
"runtime_config" : {
  "service_invoke" : {
    "auth_type" : "TOKEN",
    "port" : 65534,
    "protocol" : "HTTPS",
    "dynamic_routing_enable" : false
  },
  "service_limit" : {
    "rate_limit" : {
      "num" : 1999,
      "unit" : "NANOS"
    },
    "request_size_limit" : 49,
    "request_timeout" : 1799
  }
},
"version" : "0.1.0"
},
"workspace_id" : "0"
}
```

状态码

状态码	描述
200	修改服务配置成功。

错误码

请参见[错误码](#)。

7.1.8 获取在线服务事件列表

功能介绍

该接口适用于需要监控和管理在线服务事件的场景，例如用户或运维人员需要定期检查服务的日志事件，以及时发现和处理问题。通过调用此接口，用户可以获取当前在线服务的所有事件记录，包括事件类型、事件信息、时间、发生次数等信息。用户必须具有查询服务事件列表的权限，才能成功访问该接口。获取成功后，返回事件列表；若失败，返回具体的错误信息。常见异常包括权限验证错误、服务状态错误和参数验证错误。

URI

GET /v2/{project_id}/services/{service_id}/events

表 7-202 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

表 7-203 Query 参数

参数	是否必选	参数类型	描述
event_type	否	String	参数解释： 在线服务事件类型。 约束限制： 不涉及。 取值范围： • NORMAL：正常 • ABNORMAL：异常 • WARNING：警告 默认取值： 不涉及。
start_time	否	Long	参数解释： 事件开始时间。 约束限制： 不涉及。 取值范围： 毫秒级时间戳，13位数字。 默认取值： 不涉及。
end_time	否	Long	参数解释： 事件结束时间。 约束限制： 不涉及。 取值范围： 毫秒级时间戳，13位数字。 默认取值： 不涉及。
event_info_key	否	String	参数解释： 事件信息过滤关键字。 约束限制： 不支持";%_!*!@#\$\$&\这些字符的查询。

参数	是否必选	参数类型	描述
limit	否	Integer	参数解释： 指定返回的最大条目数。 约束限制： 不涉及。 取值范围： [1,500] 默认取值： 10。
offset	否	Integer	参数解释： 分页列表查询的偏移量。 约束限制： offset必须是limit的整数倍。 取值范围： 不涉及。 默认取值： 0。
sort_key	否	String	参数解释： 排序字段，多个字段以","分隔，支持create_at, update_at，默认值update_at。 约束限制： 不涉及。 取值范围： • create_at: 按创建时间排序。 • update_at: 按更新时间排序。 默认取值： update_at。
sort_dir	否	String	参数解释： 排序方式。 约束限制： 不涉及。 取值范围： • ASC: 递增排序。 • DESC: 递减排序。 默认取值： DESC。

请求参数

表 7-204 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json • application/json;charset=utf-8 默认取值： 不涉及。

响应参数

状态码：200

表 7-205 响应 Body 参数

参数	参数类型	描述
current	Integer	参数解释： 当前页。 取值范围： 不涉及。

参数	参数类型	描述
pages	Integer	参数解释： 总页数。 取值范围： 不涉及。
size	Integer	参数解释： 每一页的数量。 取值范围： 不涉及。
total	Integer	参数解释： 总记录数。 取值范围： 不涉及。
data	ServiceEventResponse object	参数解释： 服务事件列表。 取值范围： 不涉及。

表 7-206 ServiceEventResponse

参数	参数类型	描述
id	String	参数解释： 服务事件id 取值范围： 不涉及。
service_id	String	参数解释： 服务ID 取值范围： 不涉及。
service_version_id	String	参数解释： 服务版本ID 取值范围： 不涉及。
url	String	参数解释： 服务事件faq链接 取值范围： 不涉及。

参数	参数类型	描述
count	Integer	参数解释： 服务事件发生计数 取值范围： 不涉及。
type	String	参数解释： 服务事件类型：NORMAL/ABNORMAL/ WARNING 取值范围： 不涉及。
info	String	参数解释： 服务事件信息（英文） 取值范围： 不涉及。
info_cn	String	参数解释： 服务事件信息（中文） 取值范围： 不涉及。
message	String	参数解释： 服务事件消息（英文） 取值范围： 不涉及。
message_cn	String	参数解释： 服务事件消息（中文） 取值范围： 不涉及。
create_at	Long	参数解释： 服务事件第一次发生时间 取值范围： 不涉及。
update_at	Long	参数解释： 服务事件最后发生时间 取值范围： 不涉及。

请求示例

获取在线服务事件列表。

GET https://{endpoint}/v2/{project_id}/services/{service_id}/events

响应示例

状态码：200

获取在线服务事件列表。

```
{
  "current" : 0,
  "data" : [ {
    "create_at" : 1730446221357,
    "event_count" : 1,
    "event_info" : "Start to deploy service [xxx], version: 0.0.1, id: dcbadcba-dcba-dcba-dcbadcba.",
    "event_info_cn" : "开始部署服务【xxx】，版本：0.0.1，ID：dcbadcba-dcba-dcba-dcbadcba。",
    "event_type" : "NORMAL",
    "id" : "abcdabcd-abcd-abcd-abcd-abcdabcd",
    "service_id" : "dcbadcba-dcba-dcba-dcbadcba",
    "service_version_id" : "dcbadcba-dcba-dcba-dcbadcba",
    "update_at" : 1730446221357
  }, {
    "create_at" : 1730446254868,
    "event_count" : 1,
    "event_info" : "Service [xxx] create success.",
    "event_info_cn" : "服务【xxx】部署成功",
    "event_type" : "NORMAL",
    "id" : "abcdabcd-abcd-abcd-abcd-abcdabcd",
    "service_id" : "dcbadcba-dcba-dcba-dcbadcba",
    "service_version_id" : "dcbadcba-dcba-dcba-dcbadcba",
    "update_at" : 1730446254868
  } ],
  "pages" : 1,
  "size" : 10,
  "total" : 2
}
```

状态码

状态码	描述
200	获取在线服务事件列表。

错误码

请参见[错误码](#)。

7.1.9 查询服务 exec 登录信息

功能介绍

该接口适用于需要获取容器登录信息的场景，例如用户希望通过exec命令登录到在线服务的容器中进行调试或查看操作。通过调用此接口，用户可以获取到必要的登录信息，如容器ID、登录命令等。用户必须具有足够的权限，且目标容器需处于运行状态。查询成功后，返回容器的exec登录信息；若失败，返回具体的错误信息。常见异常包括权限验证错误、容器状态错误和参数验证错误。

URI

GET /v2/{project_id}/services/{service_id}/exec

表 7-207 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

表 7-208 Query 参数

参数	是否必选	参数类型	描述
instance_group	是	String	参数解释： 实例组名，在 创建服务 后会自动生成实例组的名称，也可以通过 查询服务实例组列表 获取。 约束限制： 不涉及。 取值范围： 实例组ID。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
instance_name	是	String	参数解释： 实例名，在 创建服务 后由用户填写，也可以通过 查询服务实例列表 获取。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
pod_name	是	String	参数解释： Pod实例的名字，在 创建服务 后由K8S自动生成，也可以通过 查询服务的pod列表 获取。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-209 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json • application/json;charset=utf-8 默认取值： 不涉及。

响应参数

状态码：200

表 7-210 响应 Body 参数

参数	参数类型	描述
endpoint	String	参数解释： 资源池api-server地址。 取值范围： 不涉及。
pod_name	String	参数解释： 待登录的容器名。 取值范围： 不涉及。
pod_status	String	参数解释： pod状态。 取值范围： 不涉及。
container_name	String	参数解释： 待登录的容器名。 取值范围： 不涉及。

参数	参数类型	描述
namespace	String	参数解释： pod所在的namespace。 取值范围： 不涉及。
cluster_token	String	参数解释： 集群所属租户token。 取值范围： 不涉及。

请求示例

查询服务exec登录信息，将相关实例组名和实例名拼接到URL中，并指定pod名称。

```
GET https://{endpoint}/v2/{project_id}/services/{service_id}/exec?instance_group=example&instance_name=example&pod_name=example
```

响应示例

状态码：200

服务exec登录信息。

```
{
  "endpoint" : "http://api.example.com",
  "pod_name" : "my-pod-example",
  "pod_status" : "Running",
  "container_name" : "my-container",
  "namespace" : "default",
  "cluster_token" : "example"
}
```

状态码

状态码	描述
200	服务exec登录信息。

错误码

请参见[错误码](#)。

7.1.10 删除指定服务列表

功能介绍

删除指定服务列表功能允许用户批量删除多个服务实例，适用于需要清理资源、释放计算能力或管理多个服务的场景。使用此功能前，请确保您具备删除服务的权限，并

提供有效的服务ID列表。成功执行后，指定的服务将被终止运行并释放相关资源。若服务ID无效、权限不足或服务状态不允许删除，将返回相应的错误信息。

URI

POST /v2/{project_id}/services/delete

表 7-211 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

请求参数

表 7-212 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json。 • application/json;charset=utf-8。 默认取值： 不涉及。

表 7-213 请求 Body 参数

参数	是否必选	参数类型	描述
service_ids	是	Array of strings	参数解释： 待删除的servicesid列表。服务ID在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

响应参数

状态码：200

表 7-214 响应 Body 参数

参数	参数类型	描述
service_responses	ServiceResponse object	参数解释： 服务响应返回体。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-215 ServiceResponse

参数	参数类型	描述
id	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 取值范围： 不涉及。
name	String	参数解释： 服务名，用户在 创建服务 时自定义的名称。 取值范围： 支持1-64位字符，可包含字母、中文、数字、中划线、下划线。
dispatcher_group_id	String	参数解释： 服务绑定的dispatcher组ID。 取值范围： 不涉及。
workspace_id	String	参数解释： 工作空间ID。 取值范围： 0：默认空间ID。 - 由数字和小写字母组成的32位字符：其他空间ID，可参考工作空间创建。

参数	参数类型	描述
type	String	参数解释： 推理服务类型。 取值范围： REAL_TIME：在线服务。
deploy_type	String	参数解释： 部署方式。 取值范围： - SINGLE：单机单卡。 - MULTI：多机多卡。
status	String	参数解释： 服务当前状态。 取值范围： - DEPLOYING：部署中。 - FAILED：失败。 - STOPPED：停止。 - RUNNING：运行中。 - DELETING：删除中。 - STOPPING：停止中。 - CONCERNING：告警。 - UPGRADING：升级中。 - ERROR：异常。 - INTERRUPTING：中断中。
failure_reason	String	参数解释： 在线服务失败原因。 取值范围： 不涉及。
version	ServiceVersionResponse object	参数解释： 当前服务版本信息。
predict_url	Array of predict_url_Response objects	参数解释： 在线服务访问地址。
tags	Array of TmsTag_Response objects	参数解释： TMS对接标签类。

参数	参数类型	描述
create_at	String	参数解释： 创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
update_at	String	参数解释： 更新时间，根据更新时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
schedule	Array of ScheduleConfig_Response objects	参数解释： 定时停止配置。
provider	String	参数解释： 服务提供者的账号id（创建服务时通过X-Auth-Token-Provider请求头解析iam token而来），该值不为空时，该服务的所有更新操作需要在请求头中添加X-Auth-Token-Provider，取值为该账号id的domain级或project级token。

表 7-216 ServiceVersionResponse

参数	参数类型	描述
id	String	参数解释： 版本id。 取值范围： 不涉及。
version	String	参数解释： 版本号。 取值范围： 不涉及。
description	String	参数解释： 描述。 取值范围： 不涉及。

参数	参数类型	描述
predict_url	String	参数解释： 推理请求的访问地址。 取值范围： 不涉及。
runtime_config	RuntimeConfig_Response object	参数解释： 服务运行配置。
upgrade_config	UpgradeConfig_Response object	参数解释： 服务升级配置。
instance_groups	Array of GroupConfig_Response objects	参数解释： 服务实例组信息。
log_configs	Array of LogConfig_Response objects	参数解释： 服务日志配置信息。
deploy_timeout_minutes	Integer	参数解释： 部署超时时间。 取值范围： 不涉及。

表 7-217 RuntimeConfig_Response

参数	参数类型	描述
service_invoke	ServiceInvoke_Response object	参数解释： 服务调用时的相关配置。
service_limit	ServiceLimit_Response object	参数解释： 服务限制信息。 约束限制： 不涉及。
service_secret	ServiceSecret_Response object	参数解释： 服务密钥挂载。

表 7-218 ServiceInvoke_Response

参数	参数类型	描述
port	Integer	参数解释： 服务端口号。 取值范围： [1, 65535]。
protocol	String	参数解释： 服务请求协议。当选择WSS与WS时，服务接口会升级为WebSocket。开启WebSocket时，不支持同时设置“服务流量限制”。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
auth_type	String	参数解释： 认证类型。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。
direct_channel_enable	Boolean	参数解释： 是否开启专属通道。 取值范围： • TRUE：开启专属通道。 • FALSE：不开启专属通道。
direct_channel_auth_enable	Boolean	参数解释： 专属通道模式下proxy是否开启鉴权。 取值范围： • TRUE：开启鉴权。 • FALSE：不开启鉴权。
internet_access_enable	Boolean	参数解释： 外网访问。 取值范围： • TRUE：要外网访问。 • FALSE：不要外网访问。

参数	参数类型	描述
intranet_approve_enable	Boolean	参数解释： 内网审批。 取值范围： • TRUE：要内网审批。 • FALSE：不要内网审批。
dynamic_routing_enable	Boolean	参数解释： 动态路由开关。 取值范围： • TRUE：开启动态路由。 • FALSE：不开启动态路由。
strategy	String	参数解释： 智能路由策略。 取值范围： • ROUND_ROBIN：轮询。 • ORIGIN_IP_HASH：源IP哈希。 • MIN_CONN：最小连接数。 • MIN_FIRST_TOKEN_TIME：最小首token时延。 • COMPOSITE：综合负载。 • SLO_BASED：SLO优先级。
metric_api_scheme	String	参数解释： 指标接口服务请求协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。
metric_api_port	String	参数解释： 指标接口端口号。 取值范围： [1, 65535]。
metric_api_path	String	参数解释： 指标接口path。 取值范围： 默认值metrics。

参数	参数类型	描述
ems_enable	Boolean	参数解释： 是否开启EMS加速。 取值范围： • TRUE：开启EMS加速。 • FALSE：不开启EMS加速。
request_retry_enable	Boolean	参数解释： proxy支持请求重调度开关。 取值范围： • true：开启proxy支持请求重调度。 • false：不开启proxy支持请求重调度。
request_retry_cnt_max	Integer	参数解释： proxy支持请求重调度的重试次数 取值范围： [1, 10]。
request_retry_interval_ms	Integer	参数解释： proxy支持请求重调度的重试间隔，单位ms 取值范围： [1, 10000]。

表 7-219 ServiceLimit_Response

参数	参数类型	描述
rate_limit	RateLimit_Response object	参数解释： 流控相关指标。
request_size_limit	Integer	参数解释： 请求大小限制。 取值范围： 1-50M。
request_timeout	Integer	参数解释： 超时时间。 取值范围： 1到7200秒。
ip_white_list	Array of strings	参数解释： IP白名单。

参数	参数类型	描述
ip_black_list	Array of strings	参数解释： IP黑名单。

表 7-220 RateLimit_Response

参数	参数类型	描述
num	Integer	参数解释： 服务流量限制是指指定单位内一个服务能够被访问的次数上限。 取值范围： 1-500。
unit	String	参数解释： 流量限制单元。 取值范围： • NANOS（纳秒）。 • MICROS（微秒）。 • MILLIS（毫秒）。 • SECONDS（秒）。 • MINUTES（分钟）。 • HOURS（小时）。 • DAYS（天）。

表 7-221 ServiceSecret_Response

参数	参数类型	描述
secret_enable	Boolean	参数解释： 是否启用密钥。 取值范围： • true：启用密钥。 • false：不启用密钥。
secret_type	String	参数解释： 密钥类型。 取值范围： • custom：自定义密钥。

参数	参数类型	描述
secret_volumes	SecretVolume_Response object	参数解释： 密钥挂载。 约束限制： 上限30个。
group_enable	Boolean	参数解释： 是否启用镜像的用户组。 取值范围： • true：启用镜像的用户组。 • false：不启用镜像的用户组。
group_id	Long	参数解释： 镜像的用户组id。 取值范围： 1000~4294967294。

表 7-222 SecretVolume_Response

参数	参数类型	描述
secret_name	String	参数解释： 密钥名称。 取值范围： 不涉及。
secret_key	String	参数解释： 密钥key。 取值范围： 长度不大于63。
secret_value	String	参数解释： 密钥值。 取值范围： 长度不大于32768。
mountPath	String	参数解释： 挂载路径。 取值范围： 不涉及。

表 7-223 UpgradeConfig_Response

参数	参数类型	描述
type	String	参数解释： 升级类型。 取值范围： ROLLING：滚动升级，默认值。
rolling_update	RollingUpdate_Response object	参数解释： 滚动更新配置。

表 7-224 RollingUpdate_Response

参数	参数类型	描述
max_surge	String	参数解释： 滚动更新时最多可以启动多少个Pod。 取值范围： 不涉及。
max_unavailable	String	参数解释： 滚动更新时最多可以删除多少个Pod。 取值范围： 不涉及。

表 7-225 GroupConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例组ID。 取值范围： 不涉及。
name	String	参数解释： 实例组名称。 取值范围： 不涉及。

参数	参数类型	描述
pool_id	String	参数解释： 资源池ID，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 取值范围： 不涉及。
count	Integer	参数解释： 部署场景下，服务实例数量。 约束限制： 不涉及。 取值范围： [1, 128]。 默认取值： 不涉及。
system_log_dump_enable	Boolean	参数解释： 系统日志转储开关量。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： false
unit_configs	Array of UnitConfig_Response objects	参数解释： 实例单元配置。
weight	Integer	参数解释： 权重百分比，分配到此模型的流量权重，仅当模型部署为在线服务时需要配置。 取值范围： [0, 100]。
secret_type	String	参数解释： 凭证类型相关配置，用户可以在此处选择使用的凭证类型（dew，cce） 约束限制： 不涉及。

参数	参数类型	描述
secret_name	String	参数解释： 凭证名称，用户使用dew类型凭证时可以在此处选择使用的凭证。 约束限制： 不涉及。
priority	Integer	参数解释： 服务优先级。 约束限制： 不涉及。 取值范围： [1, 3]。 默认取值： 不涉及。
high_avail_switch	Boolean	参数解释： 高可用开关，开启后不同实例的pod将尽量均匀分布到不同的节点上。 取值范围： true: 高可用开启 false: 高可用关闭
framework	String	参数解释： 算法框架。 取值范围： COMMON：普通在线服务。

表 7-226 UnitConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例单元ID。 取值范围： 不涉及。
role	String	参数解释： 实例单元角色。 取值范围： common：表示其他角色。
custom_spec	CustomSpecResponse object	参数解释： 自定义资源规格配置。

参数	参数类型	描述
flavor	String	参数解释： 资源规格，根据所提供版本选择适合业务的规格。当specification为custom时表示自定义规格。由custom_spec指定部署的规格配置。 取值范围： 不涉及。
image	Image_Response object	参数解释： 镜像配置信息，包含镜像地址，镜像来源。
models	Array of Model_Response objects	参数解释： 模型相关配置，用户可以在此处选择模型及权重文件配合镜像使用。
codes	Array of Code_Response objects	参数解释： 代码相关配置，用户可以在此处选择代码所在的obs路径等。
dumps	Array of DumpResponse objects	参数解释： 转储相关配置，用户可以在此处选择转储的目的obs路径等。
count	Integer	参数解释： 配置实例个数，单机推理无需配置。 取值范围： 不涉及。
cmd	String	参数解释： 启动命令。 取值范围： 不涉及。
envs	Map<String,String>	参数解释： 环境变量。
readiness_health	Health_Response object	参数解释： 就绪健康检查。
startup_health	Health_Response object	参数解释： 启动健康检查。
liveness_health	Health_Response object	参数解释： 存活健康检查。

参数	参数类型	描述
port	Integer	参数解释： 端口。 取值范围： [1,65535]。
recovery	String	参数解释： 恢复策略重启等级。 取值范围： - Instance：实例级，故障时重新拉起整个实例。 - Pod：Pod级，故障时重新拉起故障pod。 - Custom：自定义级，故障时不做处理，留给用户处理。
npu_reset_enable	Boolean	参数解释： 是否开启恢复策略。 取值范围： - true：开启恢复策略。 - false：不开启恢复策略。
affinity	Affinity_Response object	参数解释： 节点亲和调度设置。

表 7-227 CustomSpecResponse

参数	参数类型	描述
gpu	Number	参数解释： GPU个数。 取值范围： 支持配置小数，输入值不能小于0（最多支持2位小数，小数点后第3位做四舍五入处理）。
memory	Integer	参数解释： 内存，单位为MB。 取值范围： 仅支持整数。

参数	参数类型	描述
cpu	Number	参数解释： CPU核数。 取值范围： 支持配置小数，输入值不能小于0.01（最多支持2位小数，小数点后第3位做四舍五入处理）。
ascend	Integer	参数解释： Ascend芯片个数。 取值范围： 不涉及。

表 7-228 Image_Response

参数	参数类型	描述
id	String	参数解释： 镜像id。 取值范围： 不涉及。
source	String	参数解释： 镜像类别，标识镜像来源。 取值范围： • swr：软件仓库服务。
swr_path	String	参数解释： 镜像地址，source不同取值时，地址为不同值。 取值范围： 不涉及。
category	String	参数解释： 镜像支持的规格。 取值范围： • GPU：图形处理器。 • CPU：中央处理器。 • ASCEND：昇腾芯片。

表 7-229 Model_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。 • LOCAL：挂载宿主机本地存储目录。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： 当存储类别为EFS时，支持配置子目录。 取值范围： 不涉及。
read_only	Boolean	参数解释： 挂载权限设置，是否只读。 取值范围： • true：只读。 • false：非只读。
os_warm_up	Boolean	参数解释： os预热。 取值范围： • true：预热。 • false：不预热。

表 7-230 Code_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
source_id	String	参数解释： 代码来源id，与address二选一，当且仅当source为EFS时，可以传入sfs turbo的id。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： sfs 子路径。 取值范围： 不涉及。

参数	参数类型	描述
read_only	Boolean	参数解释： 是否只读。 取值范围： • true：只读。 • false：非只读。

表 7-231 DumpResponse

参数	参数类型	描述
source	String	参数解释： 用户转储来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。
address	String	参数解释： 用户转储来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及。
type	String	参数解释： 转储类型。 取值范围： • DUMP：用户自定义转储。 • DUMP_SYS：系统转储。

表 7-232 Health_Response

参数	参数类型	描述
check_method	String	参数解释： 健康检查方式：HTTP 或者 EXEC（命令行）。 取值范围： • HTTP：超文本传输协议。 • EXEC：命令行。
cmd	String	参数解释： 当健康检查方式为EXEC时，配置的命令行。 取值范围： 不涉及。
url	String	参数解释： 当健康检查方式为HTTP 时，配置的请求地址。 取值范围： 不涉及。
protocol	String	参数解释： 连接协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
initial_delay_seconds	Integer	参数解释： 执行首次探测时，应该等待的时间。 取值范围： 不涉及。
timeout_seconds	Integer	参数解释： 执行探测的超时时间，默认1秒，最小1秒。 取值范围： 不涉及。

参数	参数类型	描述
period_seconds	Integer	参数解释： 执行健康检查的周期时间，执行探测的频率。默认是10秒，最小1秒。 取值范围： 不涉及。
failure_threshold	Integer	参数解释： 探测成功后，最少连续探测失败多少次才被认定为失败。默认是3。最小值是1。 取值范围： 不涉及。

表 7-233 Affinity_Response

参数	参数类型	描述
affinity_type	String	参数解释： 节点亲和类型。 取值范围： - AFFINITY：亲和。 - ANTI_AFFINITY：反亲和。
required	Boolean	参数解释： 是否设置强亲和。 取值范围： - true：设置强亲和。 - false：不设置强亲和。
selection_mode	String	参数解释： 选择节点方式。 取值范围： IP。
targets	Map<String,String>	参数解释： 通过上述方式选择的列表，长度不能超过20。

表 7-234 LogConfig_Response

参数	参数类型	描述
type	String	参数解释： 日志输出类型。 取值范围： • STDOUT：日志输出到控制台或终端。 • FILE：日志输出到文件。
status	String	参数解释： 日志服务状态。 取值范围： • ON：开启。 • OFF：关闭。
log_group_id	String	参数解释： 日志组id，用户选择自己已有的日志组，不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
log_stream_id	String	参数解释： 日志流id，用户选择自己已有的日志组。不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-235 predict_url_Response

参数	参数类型	描述
type	String	参数解释： 访问方式。 取值范围： • CONSOLE：通过控制台界面访问。 • PUBLIC：通过公网访问。 • INTERNAL：通过内网访问。 • DIRECT_CHANNEL：通过直接通道访问。
urls	Array of strings	参数解释： 推理请求的访问地址，仅当type为real-time时，且服务部署完成后才会确保该字段有值。

表 7-236 TmsTag_Response

参数	参数类型	描述
key	String	参数解释： 标签键字段。 约束限制： 不涉及。 取值范围： 长度为1~128，标签的键可以包含任意语种字母、数字、空格，以及_ . : = + - @ 特殊字符，但首尾不能含有空格，不能以_sys_开头。 默认取值： 不涉及。
value	String	参数解释： 标签值字段。 取值范围： 长度为255，包括字母、数字、下划线、点、斜杠、等号、加号、减号和@符号。

表 7-237 ScheduleConfig_Response

参数	参数类型	描述
due_time	Long	参数解释： 触发时间，13位时间戳。 取值范围： 不涉及。
duration	Integer	参数解释： 对应的时间单位的数值。 取值范围： 不涉及。
time_unit	String	参数解释： 调度时间单位。 取值范围： - MINUTES：分钟。 - HOURS：小时。 - DAYS：天。
type	String	参数解释： 调度类型，当前仅支持取值为stop。 取值范围： STOP：停止。
processed	Boolean	参数解释： 表示是否处理完成。 取值范围： - true：该定时任务已经执行过。 - false：该定时任务尚未执行。

请求示例

根据传入的服务ID列表来批量删除指定服务。

```
POST https://{endpoint}/v2/{project_id}/services/delete
{
  "service_ids" : [ "example1", "example2", "example3" ]
}
```

响应示例

状态码：200

删除结果响应信息。

```
{
  "service_responses" : [ {
```

```
"create_at": 1741944835249,
"deploy_type": "MULTI",
"failure_reason": "",
"id": "example",
"name": "service-example",
"predict_url": [],
"status": "DELETING",
"tags": [],
"type": "REAL_TIME",
"update_at": 1742007744317,
"version": {
  "description": "1",
  "id": "example",
  "instance_groups": [ {
    "count": 1,
    "framework": "COMMON",
    "id": "example",
    "name": "instance-example",
    "pool_id": "pool-example",
    "unit_configs": [ {
      "cmd": "",
      "codes": [],
      "count": 1,
      "flavor": "example",
      "id": "example",
      "image": {
        "category": "CPU",
        "id": "example",
        "source": "IMAGE",
        "swr_path": "swr.cn-north-7.myhuaweicloud.com/example/example:0.0.1"
      },
      "models": [],
      "npv_reset_enable": false,
      "recovery": "Instance",
      "role": "COMMON"
    } ],
    "weight": 100
  } ],
  "log_configs": [],
  "runtime_config": {
    "service_invoke": {
      "auth_type": "TOKEN",
      "direct_channel_auth_enable": false,
      "direct_channel_enable": false,
      "port": 8080,
      "protocol": "HTTPS"
    },
    "service_limit": {
      "ip_black_list": [],
      "ip_white_list": [],
      "rate_limit": {
        "num": 200,
        "unit": "SECONDS"
      },
      "request_size_limit": 20,
      "request_timeout": 30
    }
  },
  "upgrade_config": {
    "rolling_update": {
      "max_surge": "1%",
      "max_unavailable": "1%"
    },
    "type": "ROLLING"
  },
  "version": "0.0.1"
},
"workspace_id": "0"
```

```
    }}  
  }
```

状态码

状态码	描述
200	删除结果响应信息。

错误码

请参见[错误码](#)。

7.2 服务标签管理

7.2.1 删除资源标签

功能介绍

该接口适用于需要从资源（如模型、数据集、服务等）中移除特定标签的场景，例如在资源管理或分类中，用户可以通过删除标签来调整或清理资源的元数据。通过调用此接口，用户可以批量删除指定的标签。用户必须具有足够的权限，且目标资源需存在。删除成功后，资源将不再包含指定的标签信息；若失败，返回具体的错误信息。常见异常包括权限验证错误、资源不存在错误和参数验证错误。

URI

DELETE /v2/{project_id}/modelarts-service-v2/{resource_id}/tags/delete

表 7-238 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
resource_id	是	String	参数解释： 待创建标签的资源ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-239 Query 参数

参数	是否必选	参数类型	描述
workspace_id	否	String	参数解释： 工作空间ID，workspaceId将会被设置为null。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-240 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	否	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： - application/json。 - application/json;charset=utf-8。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-241 请求 Body 参数

参数	是否必选	参数类型	描述
tags	是	Array of TmsTagForDelete objects	参数解释： 要删除的标签列表。
resource_id	否	String	参数解释： 待删除标签的资源ID。 取值范围： 不涉及。

表 7-242 TmsTagForDelete

参数	是否必选	参数类型	描述
key	是	String	参数解释： Tms标签的key。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
value	否	String	参数解释： Tms标签的value，非必填 约束限制： 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：204

删除成功。

状态码：400

表 7-243 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：401

表 7-244 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。

参数	参数类型	描述
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：403

表 7-245 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-246 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

删除资源标签。

`https://{endpoint}/v2/{project_id}/modelarts-service/a55eba18-1ebf-4e9a-8229-d2d3b593a3dc/tags/delete`

```
{
  "tags": [{
    "key": "dev",
    "value": "dev1"
  }]
}
```

响应示例

无

状态码

状态码	描述
204	删除成功。
400	请求参数不合法。
401	鉴权失败。
403	权限不足。
404	资源不存在。

错误码

请参见[错误码](#)。

7.2.2 添加标签

功能介绍

该接口适用于需要为资源（如模型、数据集、服务等）添加元数据标签的场景，例如在资源管理或分类中，用户可以通过添加标签来标注资源的用途、状态或其他属性。通过调用此接口，用户可以批量添加标签，如果标签key已存在，则更新其value。用户必须具有足够的权限，且目标资源需存在。添加成功后，资源将包含新的标签信息；若失败，返回具体的错误信息。常见异常包括权限验证错误、资源不存在错误和参数验证错误。

URI

POST /v2/{project_id}/modelarts-service-v2/{resource_id}/tags/create

表 7-247 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
resource_id	是	String	参数解释： 待创建标签的资源ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-248 Query 参数

参数	是否必选	参数类型	描述
workspace_id	否	String	参数解释： 工作空间ID，workspaceId将会被设置为null。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-249 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json。 • application/json;charset=utf-8。 默认取值： 不涉及。
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-250 请求 Body 参数

参数	是否必选	参数类型	描述
tags	是	Array of TmsTag objects	参数解释： Tms标签列表。 约束限制： 字段长度在1到20之间。
resource_id	否	String	参数解释： 资源ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-251 TmsTag

参数	是否必选	参数类型	描述
key	是	String	参数解释： 标签键字段。 约束限制： 不涉及。 取值范围： 长度为1~128，标签的键可以包含任意语种字母、数字、空格，以及_ . : = + - @特殊字符，但首尾不能含有空格，不能以_sys_开头。 默认取值： 不涉及。
value	是	String	参数解释： 标签值字段。 约束限制： 字母、数字、下划线、点、斜杠、等号、加号、减号和@符号 取值范围： 长度为0~255。 默认取值： 不涉及。

响应参数

状态码：204
正常添加成功。

状态码：400

表 7-252 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。

参数	参数类型	描述
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：401

表 7-253 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：403

表 7-254 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-255 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

添加标签。

```
https://{endpoint}/v2/{project_id}/modelarts-service-v2/a55eba18-1ebf-4e9a-8229-d2d3b593a3dc/tags/create
{
  "tags": [ {
    "key": "test",
    "value": "service-gpu"
  }, {
    "key": "model_version",
    "value": "0.1"
  } ]
}
```

响应示例

无

状态码

状态码	描述
204	正常添加成功。
400	请求参数不合法。
401	鉴权失败。
403	权限不足。
404	资源未找到。

错误码

请参见[错误码](#)。

7.2.3 查询资源标签

功能介绍

该接口适用于需要获取资源（如模型、数据集、服务等）的标签信息的场景，例如在资源管理或分类中，用户可以通过查询标签来了解资源的用途、状态或其他属性。通过调用此接口，用户可以通过资源ID获取指定资源的所有标签列表。用户必须具有足够的权限，且目标资源需存在。查询成功后，返回资源的标签列表；若失败，返回具体的错误信息。常见异常包括权限验证错误、资源不存在错误和参数验证错误。

URI

GET /v2/{project_id}/modelarts-service-v2/{resource_id}/tags

表 7-256 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
resource_id	是	String	参数解释： 待创建标签的资源ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-257 Query 参数

参数	是否必选	参数类型	描述
workspace_id	否	String	参数解释： 工作空间ID，workspaceId将会被设置为null。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-258 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json。 • application/json;charset=utf-8。 默认取值： 不涉及。
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-259 响应 Body 参数

参数	参数类型	描述
tags	Array of TmsTag objects	参数解释： 资源标签返回列表。

表 7-260 TmsTag

参数	参数类型	描述
key	String	参数解释： 标签键字段。 约束限制： 不涉及。 取值范围： 长度为1~128，标签的键可以包含任意语种字母、数字、空格，以及_ . : = + - @ 特殊字符，但首尾不能含有空格，不能以_sys_开头。 默认取值： 不涉及。
value	String	参数解释： 标签值字段。 约束限制： 字母、数字、下划线、点、斜杠、等号、加号、减号和@符号 取值范围： 长度为0~255。 默认取值： 不涉及。

状态码：400

表 7-261 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：401

表 7-262 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：403

表 7-263 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-264 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

查询资源标签。

https://{endpoint}/v2/{project_id}/service/a55eba18-1ebf-4e9a-8229-d2d3b593a3dc/tags

响应示例

状态码：200

正常查询返回。

```
{
  "tags": [ {
    "key": "test",
    "value": "service-gpu"
  }, {
    "key": "model_version",
    "value": "0.1"
  } ]
}
```

状态码

状态码	描述
200	正常查询返回。
400	请求参数不合法。
401	鉴权非法。
403	权限不足。
404	资源未找到。

错误码

请参见[错误码](#)。

7.2.4 查询某一类资源下的标签

功能介绍

该接口适用于需要获取用户当前项目中某一类资源（如指定的Service）的标签信息的场景，例如在资源管理和监控中，用户可以通过查询标签来了解各类资源的分类和属性。通过调用此接口，用户可以获取指定Service在所有工作空间中的标签列表，但无权限的工作空间标签数据将被过滤不返回。用户必须具有足够的权限，且目标资源需存在。查询成功后，返回指定Service的标签列表；若失败，返回具体的错误信息。常见异常包括权限验证错误、资源不存在错误和参数验证错误。

URI

GET /v2/{project_id}/modelarts-service-v2/tags

表 7-265 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

表 7-266 Query 参数

参数	是否必选	参数类型	描述
workspace_id	否	String	参数解释： 工作空间ID，workspaceId将会被设置为null。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-267 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json。 • application/json;charset=utf-8。 默认取值： 不涉及。
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-268 响应 Body 参数

参数	参数类型	描述
tags	Array of CombineTmsTags objects	参数解释： 标签的融合结构，相同key合并。

表 7-269 CombineTmsTags

参数	参数类型	描述
key	String	参数解释： 标签的key。 取值范围： 不涉及。
values	Array of strings	参数解释： 相同key的标签value合并后的列表。 取值范围： 不涉及。

状态码：400

表 7-270 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：401

表 7-271 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：403

表 7-272 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

查询某一类资源下的标签。

```
https://{endpoint}/v2/{project_id}/modelarts-service-v2/tags
```

响应示例

状态码：200

查询项目下指定资源类型的所有标签，正常返回。

```
{
  "tags": [ {
    "key": "model_version",
    "values": [ "0.1", "0.2" ]
  }, {
    "key": "conda_version",
    "values": [ "10.2", "11.0" ]
  } ]
}
```

状态码

状态码	描述
200	查询项目下指定资源类型的所有标签，正常返回。
400	参数非法。
401	鉴权失败。
403	权限不足。

错误码

请参见[错误码](#)。

7.2.5 通过标签反查资源列表

功能介绍

该接口适用于需要根据标签或资源名称查找相关资源的场景，例如在资源管理和搜索中，用户可以通过指定标签或进行模糊查询来查找符合特定条件的资源。通过调用此接口，用户可以基于多个标签或资源名称进行精确或模糊查询，若不传标签则返回所有资源。用户必须具有足够的权限，且目标资源需存在。查询成功后，返回符合条件的资源列表；若失败，返回具体的错误信息。常见异常包括权限验证错误、资源不存在错误和参数验证错误。

URI

POST /v2/{project_id}/modelarts-service-v2/resource-instances/filter

表 7-273 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

表 7-274 Query 参数

参数	是否必选	参数类型	描述
limit	否	Integer	参数解释： 指定返回的最大条目数。 约束限制： 不涉及。 取值范围： [1,500] 默认取值： 10。

参数	是否必选	参数类型	描述
offset	否	Integer	参数解释： 分页列表查询的偏移量。 约束限制： offset必须是limit的整数倍。 取值范围： 不涉及。 默认取值： 0。
workspace_id	否	String	参数解释： 工作空间ID，workspaceId将会被设置为null。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-275 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json。 • application/json;charset=utf-8。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-276 请求 Body 参数

参数	是否必选	参数类型	描述
matches	否	Array of TmsMatch objects	参数解释： 匹配项，目前只支持资源名称的模糊匹配。 约束限制： 不涉及。
tags	否	Array of CombineTmsTags objects	参数解释： 标签匹配项，只支持多个标签与操作，不携带表示查询所有资源。 约束限制： 不涉及。
without_any_tag	否	Boolean	参数解释： 是否只查询没有打标签的资源。 约束限制： 不涉及。 取值范围： true：只查询没有打标签的资源。 false：查询所有资源。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
limit	否	Integer	参数解释： 指定每一页返回的最大条目数。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 10。
offset	否	Integer	参数解释： 分页列表的起始页。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 0。

表 7-277 TmsMatch

参数	是否必选	参数类型	描述
key	是	String	参数解释： 匹配项名称，目前只支持 resource_name。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
value	是	String	参数解释： 匹配项的值，不区分大小写，key为resource_name时使用模糊查询，匹配资源名称。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-278 CombineTmsTags

参数	是否必选	参数类型	描述
key	是	String	参数解释： 标签的key。 取值范围： 不涉及。
values	是	Array of strings	参数解释： 相同key的标签value合并后的列表。 取值范围： 不涉及。

响应参数

状态码：200

表 7-279 响应 Body 参数

参数	参数类型	描述
resources	Array of TmsResource objects	参数解释： 通过标签反查出来的资源列表。
total_count	Integer	参数解释： 总记录数。 取值范围： 不涉及

表 7-280 TmsResource

参数	参数类型	描述
resource_detail	Object	参数解释： 资源详情，用于扩展，默认为空。 取值范围： 不涉及
resource_id	String	参数解释： 资源ID。 取值范围： 不涉及
resource_name	String	参数解释： 资源名称。 取值范围： 不涉及
tags	Array of TmsTag objects	参数解释： 当前资源的所有标签。 取值范围： 不涉及

表 7-281 TmsTag

参数	参数类型	描述
key	String	参数解释： 标签键字段。 约束限制： 不涉及。 取值范围： 长度为1~128，标签的键可以包含任意语种字母、数字、空格，以及_ . : = + - @ 特殊字符，但首尾不能含有空格，不能以_sys_开头。 默认取值： 不涉及。

参数	参数类型	描述
value	String	参数解释： 标签值字段。 约束限制： 字母、数字、下划线、点、斜杠、等号、加号、减号和@符号 取值范围： 长度为0~255。 默认取值： 不涉及。

状态码：400

表 7-282 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：401

表 7-283 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：403

表 7-284 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-285 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

通过标签resource_name反查资源列表，匹配资源名称中有resource1的资源，注：模糊匹配。

```
https://{endpoint}/v2/{project_id}/modelarts-service-v2/resource-instances/filter
{
  "matches": [ {
    "key": "resource_name",
    "value": "resource1"
  } ],
  "tags": [ {
    "key": "key1",
    "values": [ "*"value1", "value2" ]
  } ]
}
```

响应示例

状态码：200

正常查询返回。

```
{
  "resources": [ {
    "resource_id": "6efce7bf-677d-400f-b451-3543ed997a24",
    "resource_name": "service-79ca",
    "tags": [ {
      "key": "model_version",
      "value": "0.1"
    }, {
      "key": "gpu_type",
      "value": "v100"
    } ]
  } ],
  "total_count": 1000
}
```

状态码

状态码	描述
200	正常查询返回。
400	参数非法。
401	鉴权失败。
403	权限不足。
404	资源未找到。

错误码

请参见[错误码](#)。

7.2.6 通过标签查询资源数量

功能介绍

该接口适用于需要统计和获取符合特定标签或资源名称条件的资源数量的场景，例如在资源管理和监控中，用户可以通过指定标签或资源名称进行精确或模糊查询来统计资源数量。通过调用此接口，用户可以基于多个标签或资源名称进行查询，若不传标签则返回所有资源的总数。用户必须具有足够的权限，且目标资源需存在。查询成功后，返回符合条件的资源总数；若失败，返回具体的错误信息。常见异常包括权限验证错误、资源不存在错误和参数验证错误。

URI

POST /v2/{project_id}/modelarts-service-v2/resource-instances/count

表 7-286 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

表 7-287 Query 参数

参数	是否必选	参数类型	描述
workspace_id	否	String	参数解释： 工作空间ID，workspaceId将会被设置为null。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-288 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json。 • application/json;charset=utf-8。 默认取值： 不涉及。
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-289 请求 Body 参数

参数	是否必选	参数类型	描述
matches	否	Array of TmsMatch objects	参数解释： 匹配项，目前只支持资源名称的模糊匹配。 约束限制： 不涉及。
tags	否	Array of CombineTmsTags objects	参数解释： 标签匹配项，只支持多个标签与操作，不携带表示查询所有资源。 约束限制： 不涉及。

参数	是否必选	参数类型	描述
without_any_tag	否	Boolean	参数解释： 是否只查询没有打标签的资源。 约束限制： 不涉及。 取值范围： true：只查询没有打标签的资源。 false：查询所有资源。 默认取值： 不涉及。

表 7-290 TmsMatch

参数	是否必选	参数类型	描述
key	是	String	参数解释： 匹配项名称，目前只支持 resource_name。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
value	是	String	参数解释： 匹配项的值，不区分大小写，key为resource_name时使用模糊查询，匹配资源名称。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-291 CombineTmsTags

参数	是否必选	参数类型	描述
key	是	String	参数解释： 标签的key。 取值范围： 不涉及。
values	是	Array of strings	参数解释： 相同key的标签value合并后的列表。 取值范围： 不涉及。

响应参数

状态码：200

表 7-292 响应 Body 参数

参数	参数类型	描述
total_count	Integer	参数解释： 资源实例总数量。 取值范围： 不涉及

状态码：400

表 7-293 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：401

表 7-294 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：403

表 7-295 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-296 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。

参数	参数类型	描述
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

通过标签resource_name反查资源列表，匹配资源名称中有resource1的资源，注：模糊匹配。

```
https://{endpoint}/v2/{project_id}/modelarts-service-v2/resource-instances/count

{
  "matches": [ {
    "key": "resource_name",
    "value": "service"
  } ],
  "tags": [ {
    "key": "model_version",
    "values": [ "0.1", "0.2" ]
  } ]
}
```

响应示例

状态码：200

参数解释：

标签查询资源总量返回体。

```
{
  "total_count": 10
}
```

状态码

状态码	描述
200	参数解释： 标签查询资源总量返回体。
400	参数非法。
401	鉴权失败。
403	权限不足。
404	资源未找到。

错误码

请参见[错误码](#)。

7.3 服务版本管理

7.3.1 切换服务到指定版本

功能介绍

此接口用于将服务切换到指定版本，适用于需要在不同版本间进行切换以测试或回滚的场景。请求需包含有效的服务ID及目标版本号，版本号必须是已发布的有效版本。用户必须具有对目标服务的管理权限，并且服务处于运行状态。切换成功后，服务将立即使用新的版本，若版本切换涉及重启，服务可能短暂停机。若服务ID无效、版本号不存在或用户无权限，则返回400 Bad Request或403 Forbidden；若服务状态不允许切换，则返回400 Bad Request。

URI

POST /v2/{project_id}/services/{service_id}/versions/switch

表 7-297 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
service_id	是	String	参数解释： 服务ID，在创建服务时即可在返回体中获取，也可通过查询服务列表接口获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-298 请求 Body 参数

参数	是否必选	参数类型	描述
id	否	String	参数解释： 服务id。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
target_version_id	否	String	参数解释： 待切换的目标版本id。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-299 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 取值范围： 不涉及。

参数	参数类型	描述
name	String	参数解释： 服务名，用户在 创建服务 时自定义的名称。 取值范围： 支持1-64位字符，可包含字母、中文、数字、中划线、下划线。
dispatcher_group_id	String	参数解释： 服务绑定的dispatcher组ID。 取值范围： 不涉及。
workspace_id	String	参数解释： 工作空间ID。 取值范围： 0：默认空间ID。 - 由数字和小写字母组成的32位字符：其他空间ID，可参考工作空间创建。
type	String	参数解释： 推理服务类型。 取值范围： REAL_TIME：在线服务。
deploy_type	String	参数解释： 部署方式。 取值范围： - SINGLE：单机单卡。 - MULTI：多机多卡。

参数	参数类型	描述
status	String	参数解释： 服务当前状态。 取值范围： • DEPLOYING：部署中。 • FAILED：失败。 • STOPPED：停止。 • RUNNING：运行中。 • DELETING：删除中。 • STOPPING：停止中。 • CONCERNING：告警。 • UPGRADING：升级中。 • ERROR：异常。 • INTERRUPTING：中断中。
failure_reason	String	参数解释： 在线服务失败原因。 取值范围： 不涉及。
version	ServiceVersionResponse object	参数解释： 当前服务版本信息。
predict_url	Array of predict_url_Response objects	参数解释： 在线服务访问地址。
tags	Array of TmsTag_Response objects	参数解释： TMS对接标签类。
create_at	String	参数解释： 创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
update_at	String	参数解释： 更新时间，根据更新时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。

参数	参数类型	描述
schedule	Array of ScheduleConfig_Response objects	参数解释： 定时停止配置。
provider	String	参数解释： 服务提供者的账号id（创建服务时通过X-Auth-Token-Provider请求头解析iam token而来），该值不为空时，该服务的所有更新操作需要在请求头中添加X-Auth-Token-Provider，取值为该账号id的domain级或project级token。

表 7-300 ServiceVersionResponse

参数	参数类型	描述
id	String	参数解释： 版本id。 取值范围： 不涉及。
version	String	参数解释： 版本号。 取值范围： 不涉及。
description	String	参数解释： 描述。 取值范围： 不涉及。
predict_url	String	参数解释： 推理请求的访问地址。 取值范围： 不涉及。
runtime_config	RuntimeConfig_Response object	参数解释： 服务运行配置。
upgrade_config	UpgradeConfig_Response object	参数解释： 服务升级配置。
instance_groups	Array of GroupConfig_Response objects	参数解释： 服务实例组信息。

参数	参数类型	描述
log_configs	Array of LogConfig_Response objects	参数解释： 服务日志配置信息。
deploy_timeout_minutes	Integer	参数解释： 部署超时时间。 取值范围： 不涉及。

表 7-301 RuntimeConfig_Response

参数	参数类型	描述
service_invoke	ServiceInvoke_Response object	参数解释： 服务调用时的相关配置。
service_limit	ServiceLimit_Response object	参数解释： 服务限制信息。 约束限制： 不涉及。
service_secret	ServiceSecret_Response object	参数解释： 服务密钥挂载。

表 7-302 ServiceInvoke_Response

参数	参数类型	描述
port	Integer	参数解释： 服务端口号。 取值范围： [1, 65535]。

参数	参数类型	描述
protocol	String	参数解释： 服务请求协议。当选择WSS与WS时，服务接口会升级为WebSocket。开启WebSocket时，不支持同时设置“服务流量限制”。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
auth_type	String	参数解释： 认证类型。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。
direct_channel_enable	Boolean	参数解释： 是否开启专属通道。 取值范围： • TRUE：开启专属通道。 • FALSE：不开启专属通道。
direct_channel_auth_enable	Boolean	参数解释： 专属通道模式下proxy是否开启鉴权。 取值范围： • TRUE：开启鉴权。 • FALSE：不开启鉴权。
internet_access_enable	Boolean	参数解释： 外网访问。 取值范围： • TRUE：要外网访问。 • FALSE：不要外网访问。
intranet_approve_enable	Boolean	参数解释： 内网审批。 取值范围： • TRUE：要内网审批。 • FALSE：不要内网审批。

参数	参数类型	描述
dynamic_routing_enable	Boolean	参数解释： 动态路由开关。 取值范围： • TRUE：开启动态路由。 • FALSE：不开启动态路由。
strategy	String	参数解释： 智能路由策略。 取值范围： • ROUND_ROBIN：轮询。 • ORIGIN_IP_HASH：源IP哈希。 • MIN_CONN：最小连接数。 • MIN_FIRST_TOKEN_TIME：最小首token时延。 • COMPOSITE：综合负载。 • SLO_BASED：SLO优先级。
metric_api_scheme	String	参数解释： 指标接口服务请求协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。
metric_api_port	String	参数解释： 指标接口端口号。 取值范围： [1, 65535]。
metric_api_path	String	参数解释： 指标接口path。 取值范围： 默认值metrics。
ems_enable	Boolean	参数解释： 是否开启EMS加速。 取值范围： • TRUE：开启EMS加速。 • FALSE：不开启EMS加速。

参数	参数类型	描述
request_retry_enable	Boolean	参数解释： proxy支持请求重调度开关。 取值范围： • true：开启proxy支持请求重调度。 • false：不开启proxy支持请求重调度。
request_retry_cnt_max	Integer	参数解释： proxy支持请求重调度的重试次数 取值范围： [1, 10]。
request_retry_interval_ms	Integer	参数解释： proxy支持请求重调度的重试间隔，单位ms 取值范围： [1, 10000]。

表 7-303 ServiceLimit_Response

参数	参数类型	描述
rate_limit	RateLimit_Response object	参数解释： 流控相关指标。
request_size_limit	Integer	参数解释： 请求大小限制。 取值范围： 1-50M。
request_timeout	Integer	参数解释： 超时时间。 取值范围： 1到7200秒。
ip_white_list	Array of strings	参数解释： IP白名单。
ip_black_list	Array of strings	参数解释： IP黑名单。

表 7-304 RateLimit_Response

参数	参数类型	描述
num	Integer	参数解释： 服务流量限制是指指定单位内一个服务能够被访问的次数上限。 取值范围： 1-500。
unit	String	参数解释： 流量限制单元。 取值范围： • NANOS（纳秒）。 • MICROS（微秒）。 • MILLIS（毫秒）。 • SECONDS（秒）。 • MINUTES（分钟）。 • HOURS（小时）。 • DAYS（天）。

表 7-305 ServiceSecret_Response

参数	参数类型	描述
secret_enable	Boolean	参数解释： 是否启用密钥。 取值范围： • true：启用密钥。 • false：不启用密钥。
secret_type	String	参数解释： 密钥类型。 取值范围： • custom：自定义密钥。
secret_volumes	SecretVolume_Response object	参数解释： 密钥挂载。 约束限制： 上限30个。

参数	参数类型	描述
group_enable	Boolean	参数解释： 是否启用镜像的用户组。 取值范围： • true：启用镜像的用户组。 • false：不启用镜像的用户组。
group_id	Long	参数解释： 镜像的用户组id。 取值范围： 1000~4294967294。

表 7-306 SecretVolume_Response

参数	参数类型	描述
secret_name	String	参数解释： 密钥名称。 取值范围： 不涉及。
secret_key	String	参数解释： 密钥key。 取值范围： 长度不大于63。
secret_value	String	参数解释： 密钥值。 取值范围： 长度不大于32768。
mountPath	String	参数解释： 挂载路径。 取值范围： 不涉及。

表 7-307 UpgradeConfig_Response

参数	参数类型	描述
type	String	参数解释： 升级类型。 取值范围： ROLLING：滚动升级，默认值。
rolling_update	RollingUpdate_Response object	参数解释： 滚动更新配置。

表 7-308 RollingUpdate_Response

参数	参数类型	描述
max_surge	String	参数解释： 滚动更新时最多可以启动多少个Pod。 取值范围： 不涉及。
max_unavailable	String	参数解释： 滚动更新时最多可以删除多少个Pod。 取值范围： 不涉及。

表 7-309 GroupConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例组ID。 取值范围： 不涉及。
name	String	参数解释： 实例组名称。 取值范围： 不涉及。

参数	参数类型	描述
pool_id	String	参数解释： 资源池ID，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 取值范围： 不涉及。
count	Integer	参数解释： 部署场景下，服务实例数量。 约束限制： 不涉及。 取值范围： [1, 128]。 默认取值： 不涉及。
system_log_dump_enable	Boolean	参数解释： 系统日志转储开关量。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： false
unit_configs	Array of UnitConfig_Response objects	参数解释： 实例单元配置。
weight	Integer	参数解释： 权重百分比，分配到此模型的流量权重，仅当模型部署为在线服务时需要配置。 取值范围： [0, 100]。
secret_type	String	参数解释： 凭证类型相关配置，用户可以在此处选择使用的凭证类型（dew，cce） 约束限制： 不涉及。

参数	参数类型	描述
secret_name	String	参数解释： 凭证名称，用户使用dew类型凭证时可以在此处选择使用的凭证。 约束限制： 不涉及。
priority	Integer	参数解释： 服务优先级。 约束限制： 不涉及。 取值范围： [1, 3]。 默认取值： 不涉及。
high_avail_switch	Boolean	参数解释： 高可用开关，开启后不同实例的pod将尽量均匀分布到不同的节点上。 取值范围： true: 高可用开启 false: 高可用关闭
framework	String	参数解释： 算法框架。 取值范围： COMMON：普通在线服务。

表 7-310 UnitConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例单元ID。 取值范围： 不涉及。
role	String	参数解释： 实例单元角色。 取值范围： common：表示其他角色。
custom_spec	CustomSpecResponse object	参数解释： 自定义资源规格配置。

参数	参数类型	描述
flavor	String	参数解释： 资源规格，根据所提供版本选择适合业务的规格。当specification为custom时表示自定义规格。由custom_spec指定部署的规格配置。 取值范围： 不涉及。
image	Image_Response object	参数解释： 镜像配置信息，包含镜像地址，镜像来源。
models	Array of Model_Response objects	参数解释： 模型相关配置，用户可以在此处选择模型及权重文件配合镜像使用。
codes	Array of Code_Response objects	参数解释： 代码相关配置，用户可以在此处选择代码所在的obs路径等。
dumps	Array of DumpResponse objects	参数解释： 转储相关配置，用户可以在此处选择转储的目的obs路径等。
count	Integer	参数解释： 配置实例个数，单机推理无需配置。 取值范围： 不涉及。
cmd	String	参数解释： 启动命令。 取值范围： 不涉及。
envs	Map<String,String>	参数解释： 环境变量。
readiness_health	Health_Response object	参数解释： 就绪健康检查。
startup_health	Health_Response object	参数解释： 启动健康检查。
liveness_health	Health_Response object	参数解释： 存活健康检查。

参数	参数类型	描述
port	Integer	参数解释： 端口。 取值范围： [1,65535]。
recovery	String	参数解释： 恢复策略重启等级。 取值范围： - Instance：实例级，故障时重新拉起整个实例。 - Pod：Pod级，故障时重新拉起故障pod。 - Custom：自定义级，故障时不做处理，留给用户处理。
npu_reset_enable	Boolean	参数解释： 是否开启恢复策略。 取值范围： - true：开启恢复策略。 - false：不开启恢复策略。
affinity	Affinity_Response object	参数解释： 节点亲和调度设置。

表 7-311 CustomSpecResponse

参数	参数类型	描述
gpu	Number	参数解释： GPU个数。 取值范围： 支持配置小数，输入值不能小于0（最多支持2位小数，小数点后第3位做四舍五入处理）。
memory	Integer	参数解释： 内存，单位为MB。 取值范围： 仅支持整数。

参数	参数类型	描述
cpu	Number	参数解释： CPU核数。 取值范围： 支持配置小数，输入值不能小于0.01（最多支持2位小数，小数点后第3位做四舍五入处理）。
ascend	Integer	参数解释： Ascend芯片个数。 取值范围： 不涉及。

表 7-312 Image_Response

参数	参数类型	描述
id	String	参数解释： 镜像id。 取值范围： 不涉及。
source	String	参数解释： 镜像类别，标识镜像来源。 取值范围： • swr：软件仓库服务。
swr_path	String	参数解释： 镜像地址，source不同取值时，地址为不同值。 取值范围： 不涉及。
category	String	参数解释： 镜像支持的规格。 取值范围： • GPU：图形处理器。 • CPU：中央处理器。 • ASCEND：昇腾芯片。

表 7-313 Model_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。 • LOCAL：挂载宿主机本地存储目录。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： 当存储类别为EFS时，支持配置子目录。 取值范围： 不涉及。
read_only	Boolean	参数解释： 挂载权限设置，是否只读。 取值范围： • true：只读。 • false：非只读。
os_warm_up	Boolean	参数解释： os预热。 取值范围： • true：预热。 • false：不预热。

表 7-314 Code_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
source_id	String	参数解释： 代码来源id，与address二选一，当且仅当source为EFS时，可以传入sfs turbo的id。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： sfs 子路径。 取值范围： 不涉及。

参数	参数类型	描述
read_only	Boolean	参数解释： 是否只读。 取值范围： • true：只读。 • false：非只读。

表 7-315 DumpResponse

参数	参数类型	描述
source	String	参数解释： 用户转储来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。
address	String	参数解释： 用户转储来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及。
type	String	参数解释： 转储类型。 取值范围： • DUMP：用户自定义转储。 • DUMP_SYS：系统转储。

表 7-316 Health_Response

参数	参数类型	描述
check_method	String	参数解释： 健康检查方式：HTTP 或者 EXEC（命令行）。 取值范围： • HTTP：超文本传输协议。 • EXEC：命令行。
cmd	String	参数解释： 当健康检查方式为EXEC时，配置的命令行。 取值范围： 不涉及。
url	String	参数解释： 当健康检查方式为HTTP 时，配置的请求地址。 取值范围： 不涉及。
protocol	String	参数解释： 连接协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
initial_delay_seconds	Integer	参数解释： 执行首次探测时，应该等待的时间。 取值范围： 不涉及。
timeout_seconds	Integer	参数解释： 执行探测的超时时间，默认1秒，最小1秒。 取值范围： 不涉及。

参数	参数类型	描述
period_seconds	Integer	参数解释： 执行健康检查的周期时间，执行探测的频率。默认是10秒，最小1秒。 取值范围： 不涉及。
failure_threshold	Integer	参数解释： 探测成功后，最少连续探测失败多少次才被认定为失败。默认是3。最小值是1。 取值范围： 不涉及。

表 7-317 Affinity_Response

参数	参数类型	描述
affinity_type	String	参数解释： 节点亲和类型。 取值范围： - AFFINITY：亲和。 - ANTI_AFFINITY：反亲和。
required	Boolean	参数解释： 是否设置强亲和。 取值范围： - true：设置强亲和。 - false：不设置强亲和。
selection_mode	String	参数解释： 选择节点方式。 取值范围： IP。
targets	Map<String,String>	参数解释： 通过上述方式选择的列表，长度不能超过20。

表 7-318 LogConfig_Response

参数	参数类型	描述
type	String	参数解释： 日志输出类型。 取值范围： • STDOUT：日志输出到控制台或终端。 • FILE：日志输出到文件。
status	String	参数解释： 日志服务状态。 取值范围： • ON：开启。 • OFF：关闭。
log_group_id	String	参数解释： 日志组id，用户选择自己已有的日志组，不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
log_stream_id	String	参数解释： 日志流id，用户选择自己已有的日志组。不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-319 predict_url_Response

参数	参数类型	描述
type	String	参数解释： 访问方式。 取值范围： • CONSOLE：通过控制台界面访问。 • PUBLIC：通过公网访问。 • INTERNAL：通过内网访问。 • DIRECT_CHANNEL：通过直接通道访问。
urls	Array of strings	参数解释： 推理请求的访问地址，仅当type为real-time时，且服务部署完成后才会确保该字段有值。

表 7-320 TmsTag_Response

参数	参数类型	描述
key	String	参数解释： 标签键字段。 约束限制： 不涉及。 取值范围： 长度为1~128，标签的键可以包含任意语种字母、数字、空格，以及_ . : = + - @ 特殊字符，但首尾不能含有空格，不能以_sys_开头。 默认取值： 不涉及。
value	String	参数解释： 标签值字段。 取值范围： 长度为255，包括字母、数字、下划线、点、斜杠、等号、加号、减号和@符号。

表 7-321 ScheduleConfig_Response

参数	参数类型	描述
due_time	Long	参数解释： 触发时间，13位时间戳。 取值范围： 不涉及。
duration	Integer	参数解释： 对应的时间单位的数值。 取值范围： 不涉及。
time_unit	String	参数解释： 调度时间单位。 取值范围： - MINUTES：分钟。 - HOURS：小时。 - DAYS：天。
type	String	参数解释： 调度类型，当前仅支持取值为stop。 取值范围： STOP：停止。
processed	Boolean	参数解释： 表示是否处理完成。 取值范围： - true：该定时任务已经执行过。 - false：该定时任务尚未执行。

请求示例

切换服务到指定版本。id即为服务id。

```
POST https://{end_point}/v2/{project_id}/services/{service_id}/versions/switch
{
  "id": "example_id",
  "target_version_id": "example_version_id"
}
```

响应示例

状态码：200

版本切换成功。

```
{
  "create_at": 1733470423880,
```

```
"failure_reason" : "",
"id" : "d200c4fc-3bf4-433c-81d2-87381013322b",
"name" : "infer-10",
"status" : "DEPLOYING",
"type" : "REAL_TIME",
"update_at" : 1733482797586,
"version" : {
  "description" : "0.1.0版本更新",
  "id" : "0ed64919-729c-4ecc-bbdf-87381013322b",
  "instance_groups" : [ {
    "count" : 1,
    "framework" : "COMMON",
    "id" : "f702f711-1cc1-4b5b-921e-87381013322b",
    "name" : "xxxxx1",
    "pool_id" : "pool-infer-xxxx",
    "unit_configs" : [ {
      "cmd" : "",
      "codes" : [ {
        "address" : "https://example.obs.example1.com",
        "mount_path" : "/codes/",
        "source" : "EFS",
        "source_id" : "98b57430-a738-4bce-9dea-2c70eb5f1005"
      } ],
      "envs" : {
        "additionalProp1" : "string1",
        "additionalProp3" : "string2",
        "additionalProp2" : "string3"
      },
      "flavor" : "CPU: 2核 8GB",
      "id" : "8a0e84c0939b9c2101939ba30846004d",
      "image" : {
        "category" : "CPU",
        "source" : "SWR",
        "swr_path" : "swr.huaweicloud.com/atelier/pytorch_1_4:pytorch_1.4-cuda_10.1-py37-ubuntu_18.04-x86_64-041ba2e"
      },
      "models" : [ {
        "mount_path" : "/models/",
        "source" : "EFS",
        "source_id" : "98b57430-a738-4bce-9dea-2c70eb5f1005"
      } ],
      "role" : "COMMON"
    } ],
    "weight" : 100
  } ],
  "runtime_config" : {
    "service_invoke" : {
      "auth_type" : "TOKEN",
      "port" : 65534,
      "protocol" : "HTTPS"
    },
    "service_limit" : {
      "rate_limit" : {
        "num" : 1999,
        "unit" : "NANOS"
      },
      "request_size_limit" : 49,
      "request_timeout" : 1799
    }
  },
  "version" : "0.1.0"
},
"workspace_id" : "0"
}
```

状态码

状态码	描述
200	版本切换成功。

错误码

请参见[错误码](#)。

7.3.2 查询在线服务版本详情

功能介绍

此接口用于获取指定服务版本的详细信息，适用于需要查看特定版本的详细配置和状态的场景，例如确认版本的功能、性能参数或发布历史。请求需包含有效的服务ID及版本号。用户必须具有对目标服务的查看权限。请求成功后，返回该版本的详细信息，包括版本号、发布时间、配置参数和状态。若服务ID无效、版本号不存在或用户无权限，则返回400 Bad Request或403 Forbidden；若服务无该版本信息，则返回404 Not Found。

URI

GET /v2/{project_id}/services/{service_id}/versions/{version_id}

表 7-322 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
service_id	是	String	参数解释： 服务ID，在创建服务时即可在返回体中获取，也可通过查询服务列表接口获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
version_id	是	String	参数解释： 版本id，可通过查询version列表查询。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-323 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	否	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-324 请求 Body 参数

参数	是否必选	参数类型	描述
id	否	String	参数解释： 服务ID 约束限制： UUID格式 取值范围： 不涉及 默认取值： 不涉及
version_id	否	String	参数解释： 版本ID 约束限制： UUID格式 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 7-325 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 版本id。 取值范围： 不涉及。
version	String	参数解释： 版本号。 取值范围： 不涉及。
description	String	参数解释： 描述。 取值范围： 不涉及。

参数	参数类型	描述
predict_url	String	参数解释： 推理请求的访问地址。 取值范围： 不涉及。
runtime_config	RuntimeConfig_Response object	参数解释： 服务运行配置。
upgrade_config	UpgradeConfig_Response object	参数解释： 服务升级配置。
instance_groups	Array of GroupConfig_Response objects	参数解释： 服务实例组信息。
log_configs	Array of LogConfig_Response objects	参数解释： 服务日志配置信息。
deploy_timeout_minutes	Integer	参数解释： 部署超时时间。 取值范围： 不涉及。

表 7-326 RuntimeConfig_Response

参数	参数类型	描述
service_invoke	ServiceInvoke_Response object	参数解释： 服务调用时的相关配置。
service_limit	ServiceLimit_Response object	参数解释： 服务限制信息。 约束限制： 不涉及。
service_secret	ServiceSecret_Response object	参数解释： 服务密钥挂载。

表 7-327 ServiceInvoke_Response

参数	参数类型	描述
port	Integer	参数解释： 服务端口号。 取值范围： [1, 65535]。
protocol	String	参数解释： 服务请求协议。当选择WSS与WS时，服务接口会升级为WebSocket。开启WebSocket时，不支持同时设置“服务流量限制”。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
auth_type	String	参数解释： 认证类型。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。
direct_channel_enable	Boolean	参数解释： 是否开启专属通道。 取值范围： • TRUE：开启专属通道。 • FALSE：不开启专属通道。
direct_channel_auth_enable	Boolean	参数解释： 专属通道模式下proxy是否开启鉴权。 取值范围： • TRUE：开启鉴权。 • FALSE：不开启鉴权。
internet_access_enable	Boolean	参数解释： 外网访问。 取值范围： • TRUE：要外网访问。 • FALSE：不要外网访问。

参数	参数类型	描述
intranet_approve_enable	Boolean	参数解释： 内网审批。 取值范围： • TRUE：要内网审批。 • FALSE：不要内网审批。
dynamic_routing_enable	Boolean	参数解释： 动态路由开关。 取值范围： • TRUE：开启动态路由。 • FALSE：不开启动态路由。
strategy	String	参数解释： 智能路由策略。 取值范围： • ROUND_ROBIN：轮询。 • ORIGIN_IP_HASH：源IP哈希。 • MIN_CONN：最小连接数。 • MIN_FIRST_TOKEN_TIME：最小首token时延。 • COMPOSITE：综合负载。 • SLO_BASED：SLO优先级。
metric_api_scheme	String	参数解释： 指标接口服务请求协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。
metric_api_port	String	参数解释： 指标接口端口号。 取值范围： [1, 65535]。
metric_api_path	String	参数解释： 指标接口path。 取值范围： 默认值metrics。

参数	参数类型	描述
ems_enable	Boolean	参数解释： 是否开启EMS加速。 取值范围： • TRUE：开启EMS加速。 • FALSE：不开启EMS加速。
request_retry_enable	Boolean	参数解释： proxy支持请求重调度开关。 取值范围： • true：开启proxy支持请求重调度。 • false：不开启proxy支持请求重调度。
request_retry_cnt_max	Integer	参数解释： proxy支持请求重调度的重试次数 取值范围： [1, 10]。
request_retry_interval_ms	Integer	参数解释： proxy支持请求重调度的重试间隔，单位ms 取值范围： [1, 10000]。

表 7-328 ServiceLimit_Response

参数	参数类型	描述
rate_limit	RateLimit_Response object	参数解释： 流控相关指标。
request_size_limit	Integer	参数解释： 请求大小限制。 取值范围： 1-50M。
request_timeout	Integer	参数解释： 超时时间。 取值范围： 1到7200秒。
ip_white_list	Array of strings	参数解释： IP白名单。

参数	参数类型	描述
ip_black_list	Array of strings	参数解释： IP黑名单。

表 7-329 RateLimit_Response

参数	参数类型	描述
num	Integer	参数解释： 服务流量限制是指指定单位内一个服务能够被访问的次数上限。 取值范围： 1-500。
unit	String	参数解释： 流量限制单元。 取值范围： • NANOS（纳秒）。 • MICROS（微秒）。 • MILLIS（毫秒）。 • SECONDS（秒）。 • MINUTES（分钟）。 • HOURS（小时）。 • DAYS（天）。

表 7-330 ServiceSecret_Response

参数	参数类型	描述
secret_enable	Boolean	参数解释： 是否启用密钥。 取值范围： • true：启用密钥。 • false：不启用密钥。
secret_type	String	参数解释： 密钥类型。 取值范围： • custom：自定义密钥。

参数	参数类型	描述
secret_volumes	SecretVolume_Response object	参数解释： 密钥挂载。 约束限制： 上限30个。
group_enable	Boolean	参数解释： 是否启用镜像的用户组。 取值范围： • true：启用镜像的用户组。 • false：不启用镜像的用户组。
group_id	Long	参数解释： 镜像的用户组id。 取值范围： 1000~4294967294。

表 7-331 SecretVolume_Response

参数	参数类型	描述
secret_name	String	参数解释： 密钥名称。 取值范围： 不涉及。
secret_key	String	参数解释： 密钥key。 取值范围： 长度不大于63。
secret_value	String	参数解释： 密钥值。 取值范围： 长度不大于32768。
mountPath	String	参数解释： 挂载路径。 取值范围： 不涉及。

表 7-332 UpgradeConfig_Response

参数	参数类型	描述
type	String	参数解释： 升级类型。 取值范围： ROLLING：滚动升级，默认值。
rolling_update	RollingUpdate_Response object	参数解释： 滚动更新配置。

表 7-333 RollingUpdate_Response

参数	参数类型	描述
max_surge	String	参数解释： 滚动更新时最多可以启动多少个Pod。 取值范围： 不涉及。
max_unavailable	String	参数解释： 滚动更新时最多可以删除多少个Pod。 取值范围： 不涉及。

表 7-334 GroupConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例组ID。 取值范围： 不涉及。
name	String	参数解释： 实例组名称。 取值范围： 不涉及。

参数	参数类型	描述
pool_id	String	参数解释： 资源池ID，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 取值范围： 不涉及。
count	Integer	参数解释： 部署场景下，服务实例数量。 约束限制： 不涉及。 取值范围： [1, 128]。 默认取值： 不涉及。
system_log_dump_enable	Boolean	参数解释： 系统日志转储开关量。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： false
unit_configs	Array of UnitConfig_Response objects	参数解释： 实例单元配置。
weight	Integer	参数解释： 权重百分比，分配到此模型的流量权重，仅当模型部署为在线服务时需要配置。 取值范围： [0, 100]。
secret_type	String	参数解释： 凭证类型相关配置，用户可以在此处选择使用的凭证类型（dew，cce） 约束限制： 不涉及。

参数	参数类型	描述
secret_name	String	参数解释： 凭证名称，用户使用dew类型凭证时可以在此处选择使用的凭证。 约束限制： 不涉及。
priority	Integer	参数解释： 服务优先级。 约束限制： 不涉及。 取值范围： [1, 3]。 默认取值： 不涉及。
high_avail_switch	Boolean	参数解释： 高可用开关，开启后不同实例的pod将尽量均匀分布到不同的节点上。 取值范围： true: 高可用开启 false: 高可用关闭
framework	String	参数解释： 算法框架。 取值范围： COMMON：普通在线服务。

表 7-335 UnitConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例单元ID。 取值范围： 不涉及。
role	String	参数解释： 实例单元角色。 取值范围： common：表示其他角色。
custom_spec	CustomSpecResponse object	参数解释： 自定义资源规格配置。

参数	参数类型	描述
flavor	String	参数解释： 资源规格，根据所提供版本选择适合业务的规格。当specification为custom时表示自定义规格。由custom_spec指定部署的规格配置。 取值范围： 不涉及。
image	Image_Response object	参数解释： 镜像配置信息，包含镜像地址，镜像来源。
models	Array of Model_Response objects	参数解释： 模型相关配置，用户可以在此处选择模型及权重文件配合镜像使用。
codes	Array of Code_Response objects	参数解释： 代码相关配置，用户可以在此处选择代码所在的obs路径等。
dumps	Array of DumpResponse objects	参数解释： 转储相关配置，用户可以在此处选择转储的目的obs路径等。
count	Integer	参数解释： 配置实例个数，单机推理无需配置。 取值范围： 不涉及。
cmd	String	参数解释： 启动命令。 取值范围： 不涉及。
envs	Map<String,String>	参数解释： 环境变量。
readiness_health	Health_Response object	参数解释： 就绪健康检查。
startup_health	Health_Response object	参数解释： 启动健康检查。
liveness_health	Health_Response object	参数解释： 存活健康检查。

参数	参数类型	描述
port	Integer	参数解释： 端口。 取值范围： [1,65535]。
recovery	String	参数解释： 恢复策略重启等级。 取值范围： - Instance：实例级，故障时重新拉起整个实例。 - Pod：Pod级，故障时重新拉起故障pod。 - Custom：自定义级，故障时不做处理，留给用户处理。
npu_reset_enable	Boolean	参数解释： 是否开启恢复策略。 取值范围： - true：开启恢复策略。 - false：不开启恢复策略。
affinity	Affinity_Response object	参数解释： 节点亲和调度设置。

表 7-336 CustomSpecResponse

参数	参数类型	描述
gpu	Number	参数解释： GPU个数。 取值范围： 支持配置小数，输入值不能小于0（最多支持2位小数，小数点后第3位做四舍五入处理）。
memory	Integer	参数解释： 内存，单位为MB。 取值范围： 仅支持整数。

参数	参数类型	描述
cpu	Number	参数解释： CPU核数。 取值范围： 支持配置小数，输入值不能小于0.01（最多支持2位小数，小数点后第3位做四舍五入处理）。
ascend	Integer	参数解释： Ascend芯片个数。 取值范围： 不涉及。

表 7-337 Image_Response

参数	参数类型	描述
id	String	参数解释： 镜像id。 取值范围： 不涉及。
source	String	参数解释： 镜像类别，标识镜像来源。 取值范围： • swr：软件仓库服务。
swr_path	String	参数解释： 镜像地址，source不同取值时，地址为不同值。 取值范围： 不涉及。
category	String	参数解释： 镜像支持的规格。 取值范围： • GPU：图形处理器。 • CPU：中央处理器。 • ASCEND：昇腾芯片。

表 7-338 Model_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。 • LOCAL：挂载宿主机本地存储目录。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： 当存储类别为EFS时，支持配置子目录。 取值范围： 不涉及。
read_only	Boolean	参数解释： 挂载权限设置，是否只读。 取值范围： • true：只读。 • false：非只读。
os_warm_up	Boolean	参数解释： os预热。 取值范围： • true：预热。 • false：不预热。

表 7-339 Code_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
source_id	String	参数解释： 代码来源id，与address二选一，当且仅当source为EFS时，可以传入sfs turbo的id。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： sfs 子路径。 取值范围： 不涉及。

参数	参数类型	描述
read_only	Boolean	参数解释： 是否只读。 取值范围： • true：只读。 • false：非只读。

表 7-340 DumpResponse

参数	参数类型	描述
source	String	参数解释： 用户转储来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。
address	String	参数解释： 用户转储来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及。
type	String	参数解释： 转储类型。 取值范围： • DUMP：用户自定义转储。 • DUMP_SYS：系统转储。

表 7-341 Health_Response

参数	参数类型	描述
check_method	String	参数解释： 健康检查方式：HTTP 或者 EXEC（命令行）。 取值范围： • HTTP：超文本传输协议。 • EXEC：命令行。
cmd	String	参数解释： 当健康检查方式为EXEC时，配置的命令行。 取值范围： 不涉及。
url	String	参数解释： 当健康检查方式为HTTP 时，配置的请求地址。 取值范围： 不涉及。
protocol	String	参数解释： 连接协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
initial_delay_seconds	Integer	参数解释： 执行首次探测时，应该等待的时间。 取值范围： 不涉及。
timeout_seconds	Integer	参数解释： 执行探测的超时时间，默认1秒，最小1秒。 取值范围： 不涉及。

参数	参数类型	描述
period_seconds	Integer	参数解释： 执行健康检查的周期时间，执行探测的频率。默认是10秒，最小1秒。 取值范围： 不涉及。
failure_threshold	Integer	参数解释： 探测成功后，最少连续探测失败多少次才被认定为失败。默认是3。最小值是1。 取值范围： 不涉及。

表 7-342 Affinity_Response

参数	参数类型	描述
affinity_type	String	参数解释： 节点亲和类型。 取值范围： - AFFINITY：亲和。 - ANTI_AFFINITY：反亲和。
required	Boolean	参数解释： 是否设置强亲和。 取值范围： - true：设置强亲和。 - false：不设置强亲和。
selection_mode	String	参数解释： 选择节点方式。 取值范围： IP。
targets	Map<String,String>	参数解释： 通过上述方式选择的列表，长度不能超过20。

表 7-343 LogConfig_Response

参数	参数类型	描述
type	String	参数解释： 日志输出类型。 取值范围： • STDOUT：日志输出到控制台或终端。 • FILE：日志输出到文件。
status	String	参数解释： 日志服务状态。 取值范围： • ON：开启。 • OFF：关闭。
log_group_id	String	参数解释： 日志组id，用户选择自己已有的日志组，不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
log_stream_id	String	参数解释： 日志流id，用户选择自己已有的日志组。不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求示例

查询特定服务的特定版本信息。

```
GET https://{end_point}/v2/{project_id}/services/{service_id}/versions/{version_id}
```

响应示例

状态码：200

该服务某版本详情信息。

```
{
  "description": "0.2.0版本更新",
  "id": "2d472478-c6ee-47b3-a135-87381013322b",
  "instance_groups": [ {
    "count": 1,
    "framework": "COMMON",
    "id": "f702f711-1cc1-4b5b-921e-87381013322b",
    "name": "group_name1",
    "pool_id": "pool-infer2-04f258c84780d5a52f3bc00dc15aa5e7",
    "unit_configs": [ {
      "cmd": "",
      "codes": [ {
        "address": "https://example.obs.example1.com",
        "mount_path": "/codes/",
        "source": "EFS",
        "source_id": "98b57430-a738-4bce-9dea-2c70eb5f1005"
      } ],
      "envs": {
        "additionalProp1": "string1",
        "additionalProp3": "string2",
        "additionalProp2": "string3"
      },
      "flavor": "CPU: 2核 8GB",
      "id": "8a0e84c0939b9c2101939f2877102319",
      "image": {
        "category": "CPU",
        "source": "SWR",
        "swr_path": "swr.cn-north-7.myhuaweicloud.com/atelier/pytorch_1_4:pytorch_1.4-cuda_10.1-py37-ubuntu_18.04-x86_64-20220926104017-041ba2e"
      },
      "models": [ {
        "mount_path": "/models/",
        "source": "EFS",
        "source_id": "98b57430-a738-4bce-9dea-2c70eb5f1005"
      } ],
      "role": "COMMON"
    } ],
    "weight": 100
  }, {
    "count": 1,
    "framework": "COMMON",
    "id": "f702f711-92ca-4325-a51c-87381013322b",
    "name": "group_name1",
    "pool_id": "pool-infer2-04f258c84780d5a52f3bc00dc15aa5e7",
    "unit_configs": [ {
      "codes": [ {
        "address": "https://example.obs.example1.com",
        "mount_path": "/codes/",
        "source": "EFS",
        "source_id": "98b57430-a738-4bce-9dea-2c70eb5f1005"
      } ],
      "count": 1,
      "envs": {
        "additionalProp1": "string",
        "additionalProp2": "string",
        "additionalProp3": "string"
      },
      "flavor": "CPU: 2核 8GB",
      "id": "8a0e84c0939b9c2101939f2877102315",
      "image": {
        "category": "CPU",
        "source": "SWR",
        "swr_path": "swr.cn-north-7.myhuaweicloud.com/atelier/pytorch_1_4:pytorch_1.4-cuda_10.1-py37-ubuntu_18.04-x86_64-20220926104017-041ba2e"
      },
      "models": [ {
        "mount_path": "/models/",
        "source": "EFS",
```

```
    "source_id" : "98b57430-a738-4bce-9dea-2c70eb5f1005"
  },
  "port" : 65535,
  "role" : "COMMON"
},
"weight" : 100
},
"runtime_config" : {
  "service_invoke" : {
    "auth_type" : "TOKEN",
    "port" : 65534,
    "protocol" : "HTTPS"
  },
  "service_limit" : {
    "rate_limit" : {
      "num" : 1999,
      "unit" : "NANOS"
    },
    "request_size_limit" : 49,
    "request_timeout" : 1799
  }
},
"version" : "0.2.0"
}
```

状态码

状态码	描述
200	该服务某版本详情信息。

错误码

请参见[错误码](#)。

7.3.3 查询在线服务版本列表

功能介绍

此接口用于获取指定服务的在线版本列表，适用于需要了解当前服务可用版本的场景，例如进行版本选择或确认当前版本信息。请求需包含有效的服务ID，也可通过排序参数对列表进行排序。用户必须具有对目标服务的查看权限。请求成功后，返回该服务的所有在线版本信息，包括版本号、发布时间和状态。若服务ID无效或用户无权限，则返回400 Bad Request或403 Forbidden；若服务无在线版本，则返回空列表。

URI

GET /v2/{project_id}/services/{service_id}/versions

表 7-344 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
service_id	是	String	参数解释： 服务ID，在创建服务时即可在返回体中获取，也可通过查询服务列表接口获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-345 Query 参数

参数	是否必选	参数类型	描述
workspace_id	否	String	参数解释： 工作空间ID。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 0。

参数	是否必选	参数类型	描述
sort_key	否	String	参数解释： 排序参数，排序字段，支持 update_at/create_at 默认值 update_at。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： update_at。
limit	否	Integer	参数解释： 指定返回的最大条目数。 约束限制： 不涉及。 取值范围： [1,500] 默认取值： 10。
offset	否	Integer	参数解释： 分页列表查询的偏移量。 约束限制： offset必须是limit的整数倍。 取值范围： 不涉及。 默认取值： 0。

请求参数

表 7-346 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-347 请求 Body 参数

参数	是否必选	参数类型	描述
service_id	否	String	参数解释： 服务ID 约束限制： UUID格式 取值范围： 不涉及 默认取值： 不涉及
workspace_id	否	String	参数解释： 工作空间ID 约束限制： UUID格式 取值范围： 不涉及 默认取值： 0

响应参数

状态码：200

表 7-348 响应 Body 参数

参数	参数类型	描述
[数组元素]	Array of VersionItemResponse objects	

表 7-349 VersionItemResponse

参数	参数类型	描述
id	String	参数解释： 版本id。 取值范围： 不涉及。
version	String	参数解释： 服务版本 取值范围： 不涉及。
status	String	参数解释： 版本状态 取值范围： 不涉及。
group_num	Integer	参数解释： 实例组数量 取值范围： 不涉及。
description	String	参数解释： 版本描述 取值范围： 不涉及。
user_name	String	参数解释： 创建者 取值范围： 不涉及。
workspace_id	String	参数解释： 工作空间id 取值范围： 不涉及。

参数	参数类型	描述
create_at	String	参数解释： 创建时间 取值范围： 不涉及。
update_at	String	参数解释： 更新时间 取值范围： 不涉及。

请求示例

查询service_id的版本信息列表并按照创建时间倒序排序。

GET https://{end_point}/v2/{project_id}/services/{service_id}/versions?sort_key=create_at

响应示例

状态码：200

返回该服务下的所有历史版本信息。

```
{
  "current" : 0,
  "data" : [ {
    "create_at" : 1733542049557,
    "description" : "0.2.0版本更新",
    "group_num" : 2,
    "id" : "2d472478-c6ee-47b3-a135-87381013322b",
    "status" : "INACTIVE",
    "update_at" : 1733542781855,
    "user_name" : "user1",
    "version" : "0.2.0",
    "workspace_id" : "0"
  }, {
    "create_at" : 1733470423880,
    "description" : "0.0.0版本更新描述3",
    "group_num" : 1,
    "id" : "33cede41-966c-4250-9034-87381013322b",
    "status" : "ACTIVE",
    "update_at" : 1733542781855,
    "user_name" : "user1",
    "version" : "0.0.0",
    "workspace_id" : "0"
  }, {
    "create_at" : 1733482973262,
    "description" : "0.1.0版本更新",
    "group_num" : 1,
    "id" : "0ed64919-729c-4ecc-bbdf-87381013322b",
    "status" : "INACTIVE",
    "update_at" : 1733483028119,
    "user_name" : "user1",
    "version" : "0.1.0",
    "workspace_id" : "0"
  } ],
  "pages" : 1,
  "size" : 10,
}
```



```
"total" : 3
}
```

状态码

状态码	描述
200	返回该服务下的所有历史版本信息。

错误码

请参见[错误码](#)。

7.3.4 删除在线服务版本

功能介绍

此接口用于删除指定服务的某个在线版本，适用于需要清理不再使用的版本或优化资源管理的场景。

请求需包含有效的服务ID及版本号。用户必须具有对目标服务的管理权限，并且该版本当前未处于活跃状态。

删除成功后，指定版本将从在线服务中移除，相关资源将被释放。

若服务ID无效、版本号不存在或用户无权限，则返回400 Bad Request或403 Forbidden；若版本处于活跃状态或有其他依赖，则返回400 Bad Request。

URI

DELETE /v2/{project_id}/services/{service_id}/versions/{version_id}

表 7-350 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
service_id	是	String	参数解释： 服务ID，在创建服务时即可在返回体中获取，也可通过查询服务列表接口获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
version_id	是	String	参数解释： 目标版本id，可通过查询version列表查询。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-351 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	否	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-352 请求 Body 参数

参数	是否必选	参数类型	描述
id	否	String	参数解释： 服务ID 约束限制： UUID格式 取值范围： 不涉及 默认取值： 不涉及
version_id	否	String	参数解释： 版本ID 约束限制： UUID格式 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 7-353 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 版本id。 取值范围： 不涉及。
version	String	参数解释： 版本号。 取值范围： 不涉及。
description	String	参数解释： 描述。 取值范围： 不涉及。

参数	参数类型	描述
predict_url	String	参数解释： 推理请求的访问地址。 取值范围： 不涉及。
runtime_config	RuntimeConfig_Response object	参数解释： 服务运行配置。
upgrade_config	UpgradeConfig_Response object	参数解释： 服务升级配置。
instance_groups	Array of GroupConfig_Response objects	参数解释： 服务实例组信息。
log_configs	Array of LogConfig_Response objects	参数解释： 服务日志配置信息。
deploy_timeout_minutes	Integer	参数解释： 部署超时时间。 取值范围： 不涉及。

表 7-354 RuntimeConfig_Response

参数	参数类型	描述
service_invoke	ServiceInvoke_Response object	参数解释： 服务调用时的相关配置。
service_limit	ServiceLimit_Response object	参数解释： 服务限制信息。 约束限制： 不涉及。
service_secret	ServiceSecret_Response object	参数解释： 服务密钥挂载。

表 7-355 ServiceInvoke_Response

参数	参数类型	描述
port	Integer	参数解释： 服务端口号。 取值范围： [1, 65535]。
protocol	String	参数解释： 服务请求协议。当选择WSS与WS时，服务接口会升级为WebSocket。开启WebSocket时，不支持同时设置“服务流量限制”。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
auth_type	String	参数解释： 认证类型。 取值范围： • TOKEN：Token认证。 • API_KEY：API密钥认证。 • NONE：无认证。
direct_channel_enable	Boolean	参数解释： 是否开启专属通道。 取值范围： • TRUE：开启专属通道。 • FALSE：不开启专属通道。
direct_channel_auth_enable	Boolean	参数解释： 专属通道模式下proxy是否开启鉴权。 取值范围： • TRUE：开启鉴权。 • FALSE：不开启鉴权。
internet_access_enable	Boolean	参数解释： 外网访问。 取值范围： • TRUE：要外网访问。 • FALSE：不要外网访问。

参数	参数类型	描述
intranet_approve_enable	Boolean	参数解释： 内网审批。 取值范围： • TRUE：要内网审批。 • FALSE：不要内网审批。
dynamic_routing_enable	Boolean	参数解释： 动态路由开关。 取值范围： • TRUE：开启动态路由。 • FALSE：不开启动态路由。
strategy	String	参数解释： 智能路由策略。 取值范围： • ROUND_ROBIN：轮询。 • ORIGIN_IP_HASH：源IP哈希。 • MIN_CONN：最小连接数。 • MIN_FIRST_TOKEN_TIME：最小首token时延。 • COMPOSITE：综合负载。 • SLO_BASED：SLO优先级。
metric_api_scheme	String	参数解释： 指标接口服务请求协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。
metric_api_port	String	参数解释： 指标接口端口号。 取值范围： [1, 65535]。
metric_api_path	String	参数解释： 指标接口path。 取值范围： 默认值metrics。

参数	参数类型	描述
ems_enable	Boolean	参数解释： 是否开启EMS加速。 取值范围： - TRUE：开启EMS加速。 - FALSE：不开启EMS加速。
request_retry_enable	Boolean	参数解释： proxy支持请求重调度开关。 取值范围： - true：开启proxy支持请求重调度。 - false：不开启proxy支持请求重调度。
request_retry_cnt_max	Integer	参数解释： proxy支持请求重调度的重试次数 取值范围： [1, 10]。
request_retry_interval_ms	Integer	参数解释： proxy支持请求重调度的重试间隔，单位ms 取值范围： [1, 10000]。

表 7-356 ServiceLimit_Response

参数	参数类型	描述
rate_limit	RateLimit_Response object	参数解释： 流控相关指标。
request_size_limit	Integer	参数解释： 请求大小限制。 取值范围： 1-50M。
request_timeout	Integer	参数解释： 超时时间。 取值范围： 1到7200秒。
ip_white_list	Array of strings	参数解释： IP白名单。

参数	参数类型	描述
ip_black_list	Array of strings	参数解释： IP黑名单。

表 7-357 RateLimit_Response

参数	参数类型	描述
num	Integer	参数解释： 服务流量限制是指指定单位内一个服务能够被访问的次数上限。 取值范围： 1-500。
unit	String	参数解释： 流量限制单元。 取值范围： • NANOS（纳秒）。 • MICROS（微秒）。 • MILLIS（毫秒）。 • SECONDS（秒）。 • MINUTES（分钟）。 • HOURS（小时）。 • DAYS（天）。

表 7-358 ServiceSecret_Response

参数	参数类型	描述
secret_enable	Boolean	参数解释： 是否启用密钥。 取值范围： • true：启用密钥。 • false：不启用密钥。
secret_type	String	参数解释： 密钥类型。 取值范围： • custom：自定义密钥。

参数	参数类型	描述
secret_volumes	SecretVolume_Response object	参数解释： 密钥挂载。 约束限制： 上限30个。
group_enable	Boolean	参数解释： 是否启用镜像的用户组。 取值范围： • true：启用镜像的用户组。 • false：不启用镜像的用户组。
group_id	Long	参数解释： 镜像的用户组id。 取值范围： 1000~4294967294。

表 7-359 SecretVolume_Response

参数	参数类型	描述
secret_name	String	参数解释： 密钥名称。 取值范围： 不涉及。
secret_key	String	参数解释： 密钥key。 取值范围： 长度不大于63。
secret_value	String	参数解释： 密钥值。 取值范围： 长度不大于32768。
mountPath	String	参数解释： 挂载路径。 取值范围： 不涉及。

表 7-360 UpgradeConfig_Response

参数	参数类型	描述
type	String	参数解释： 升级类型。 取值范围： ROLLING：滚动升级，默认值。
rolling_update	RollingUpdate_Response object	参数解释： 滚动更新配置。

表 7-361 RollingUpdate_Response

参数	参数类型	描述
max_surge	String	参数解释： 滚动更新时最多可以启动多少个Pod。 取值范围： 不涉及。
max_unavailable	String	参数解释： 滚动更新时最多可以删除多少个Pod。 取值范围： 不涉及。

表 7-362 GroupConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例组ID。 取值范围： 不涉及。
name	String	参数解释： 实例组名称。 取值范围： 不涉及。

参数	参数类型	描述
pool_id	String	参数解释： 资源池ID，查询指定资源池下的服务，默认不过滤。可通过 查询资源池列表 获取。 取值范围： 不涉及。
count	Integer	参数解释： 部署场景下，服务实例数量。 约束限制： 不涉及。 取值范围： [1, 128]。 默认取值： 不涉及。
system_log_dump_enable	Boolean	参数解释： 系统日志转储开关量。 约束限制： 不涉及。 取值范围： 不涉及 默认取值： false
unit_configs	Array of UnitConfig_Response objects	参数解释： 实例单元配置。
weight	Integer	参数解释： 权重百分比，分配到此模型的流量权重，仅当模型部署为在线服务时需要配置。 取值范围： [0, 100]。
secret_type	String	参数解释： 凭证类型相关配置，用户可以在此处选择使用的凭证类型（dew，cce） 约束限制： 不涉及。

参数	参数类型	描述
secret_name	String	参数解释： 凭证名称，用户使用dew类型凭证时可以在此处选择使用的凭证。 约束限制： 不涉及。
priority	Integer	参数解释： 服务优先级。 约束限制： 不涉及。 取值范围： [1, 3]。 默认取值： 不涉及。
high_avail_switch	Boolean	参数解释： 高可用开关，开启后不同实例的pod将尽量均匀分布到不同的节点上。 取值范围： true: 高可用开启 false: 高可用关闭
framework	String	参数解释： 算法框架。 取值范围： COMMON：普通在线服务。

表 7-363 UnitConfig_Response

参数	参数类型	描述
id	String	参数解释： 实例单元ID。 取值范围： 不涉及。
role	String	参数解释： 实例单元角色。 取值范围： common：表示其他角色。
custom_spec	CustomSpecResponse object	参数解释： 自定义资源规格配置。

参数	参数类型	描述
flavor	String	参数解释： 资源规格，根据所提供版本选择适合业务的规格。当specification为custom时表示自定义规格。由custom_spec指定部署的规格配置。 取值范围： 不涉及。
image	Image_Response object	参数解释： 镜像配置信息，包含镜像地址，镜像来源。
models	Array of Model_Response objects	参数解释： 模型相关配置，用户可以在此处选择模型及权重文件配合镜像使用。
codes	Array of Code_Response objects	参数解释： 代码相关配置，用户可以在此处选择代码所在的obs路径等。
dumps	Array of DumpResponse objects	参数解释： 转储相关配置，用户可以在此处选择转储的目的obs路径等。
count	Integer	参数解释： 配置实例个数，单机推理无需配置。 取值范围： 不涉及。
cmd	String	参数解释： 启动命令。 取值范围： 不涉及。
envs	Map<String,String>	参数解释： 环境变量。
readiness_health	Health_Response object	参数解释： 就绪健康检查。
startup_health	Health_Response object	参数解释： 启动健康检查。
liveness_health	Health_Response object	参数解释： 存活健康检查。

参数	参数类型	描述
port	Integer	参数解释： 端口。 取值范围： [1,65535]。
recovery	String	参数解释： 恢复策略重启等级。 取值范围： - Instance：实例级，故障时重新拉起整个实例。 - Pod：Pod级，故障时重新拉起故障pod。 - Custom：自定义级，故障时不做处理，留给用户处理。
npu_reset_enable	Boolean	参数解释： 是否开启恢复策略。 取值范围： - true：开启恢复策略。 - false：不开启恢复策略。
affinity	Affinity_Response object	参数解释： 节点亲和调度设置。

表 7-364 CustomSpecResponse

参数	参数类型	描述
gpu	Number	参数解释： GPU个数。 取值范围： 支持配置小数，输入值不能小于0（最多支持2位小数，小数点后第3位做四舍五入处理）。
memory	Integer	参数解释： 内存，单位为MB。 取值范围： 仅支持整数。

参数	参数类型	描述
cpu	Number	参数解释： CPU核数。 取值范围： 支持配置小数，输入值不能小于0.01（最多支持2位小数，小数点后第3位做四舍五入处理）。
ascend	Integer	参数解释： Ascend芯片个数。 取值范围： 不涉及。

表 7-365 Image_Response

参数	参数类型	描述
id	String	参数解释： 镜像id。 取值范围： 不涉及。
source	String	参数解释： 镜像类别，标识镜像来源。 取值范围： swr：软件仓库服务。
swr_path	String	参数解释： 镜像地址，source不同取值时，地址为不同值。 取值范围： 不涉及。
category	String	参数解释： 镜像支持的规格。 取值范围： - GPU：图形处理器。 - CPU：中央处理器。 - ASCEND：昇腾芯片。

表 7-366 Model_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。 • LOCAL：挂载宿主机本地存储目录。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： 当存储类别为EFS时，支持配置子目录。 取值范围： 不涉及。
read_only	Boolean	参数解释： 挂载权限设置，是否只读。 取值范围： • true：只读。 • false：非只读。
os_warm_up	Boolean	参数解释： os预热。 取值范围： • true：预热。 • false：不预热。

表 7-367 Code_Response

参数	参数类型	描述
source	String	参数解释： 代码来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。 • EFS：弹性文件服务。
address	String	参数解释： 代码来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
source_id	String	参数解释： 代码来源id，与address二选一，当且仅当source为EFS时，可以传入sfs turbo的id。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径。 约束限制： 不涉及。 取值范围： 以(/)开头和结尾，可包含字母、数字、中划线、下划线，整个挂载路径长度不能超过255位。 默认取值： 不涉及。
efs_sub_path	String	参数解释： sfs 子路径。 取值范围： 不涉及。

参数	参数类型	描述
read_only	Boolean	参数解释： 是否只读。 取值范围： • true：只读。 • false：非只读。

表 7-368 DumpResponse

参数	参数类型	描述
source	String	参数解释： 用户转储来源类别。 取值范围： • OBS：对象存储服务。 • OBSFS：OBS的文件系统接口。
address	String	参数解释： 用户转储来源地址，格式遵循不同存储系统。 取值范围： 不涉及。
mount_path	String	参数解释： 挂载到容器内的路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及。
type	String	参数解释： 转储类型。 取值范围： • DUMP：用户自定义转储。 • DUMP_SYS：系统转储。

表 7-369 Health_Response

参数	参数类型	描述
check_method	String	参数解释： 健康检查方式：HTTP 或者 EXEC（命令行）。 取值范围： • HTTP：超文本传输协议。 • EXEC：命令行。
cmd	String	参数解释： 当健康检查方式为EXEC时，配置的命令行。 取值范围： 不涉及。
url	String	参数解释： 当健康检查方式为HTTP 时，配置的请求地址。 取值范围： 不涉及。
protocol	String	参数解释： 连接协议。 取值范围： • HTTP：HTTP协议。 • HTTPS：HTTPS协议。 • WSS：WebSocket Secure协议。 • WS：WebSocket协议。
initial_delay_seconds	Integer	参数解释： 执行首次探测时，应该等待的时间。 取值范围： 不涉及。
timeout_seconds	Integer	参数解释： 执行探测的超时时间，默认1秒，最小1秒。 取值范围： 不涉及。

参数	参数类型	描述
period_seconds	Integer	参数解释： 执行健康检查的周期时间，执行探测的频率。默认是10秒，最小1秒。 取值范围： 不涉及。
failure_threshold	Integer	参数解释： 探测成功后，最少连续探测失败多少次才被认定为失败。默认是3。最小值是1。 取值范围： 不涉及。

表 7-370 Affinity_Response

参数	参数类型	描述
affinity_type	String	参数解释： 节点亲和类型。 取值范围： - AFFINITY：亲和。 - ANTI_AFFINITY：反亲和。
required	Boolean	参数解释： 是否设置强亲和。 取值范围： - true：设置强亲和。 - false：不设置强亲和。
selection_mode	String	参数解释： 选择节点方式。 取值范围： IP。
targets	Map<String,String>	参数解释： 通过上述方式选择的列表，长度不能超过20。

表 7-371 LogConfig_Response

参数	参数类型	描述
type	String	参数解释： 日志输出类型。 取值范围： • STDOUT：日志输出到控制台或终端。 • FILE：日志输出到文件。
status	String	参数解释： 日志服务状态。 取值范围： • ON：开启。 • OFF：关闭。
log_group_id	String	参数解释： 日志组id，用户选择自己已有的日志组，不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
log_stream_id	String	参数解释： 日志流id，用户选择自己已有的日志组。不填的时候，会自动创建。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求示例

删除在线服务某特定版本。

```
DELETE https://{end_point}/v2/{project_id}/services/{service_id}/versions/{version_id}
```

响应示例

状态码：200

删除的版本信息。

```
{
  "description": "0.2.0版本更新",
  "id": "ff003ce3-c95f-48b0-9d79-87381013322b",
  "instance_groups": [ {
    "count": 1,
    "framework": "COMMON",
    "id": "f702f711-1cc1-4b5b-921e-87381013322b",
    "name": "group_name1",
    "pool_id": "pool-infer2-04f258c84780d5a52f3bc00dc15aa5e7",
    "unit_configs": [ {
      "cmd": "",
      "codes": [ {
        "address": "https://example.obs.example1.com",
        "mount_path": "/codes/",
        "source": "EFS",
        "source_id": "98b57430-a738-4bce-9dea-2c70eb5f1005"
      } ],
      "envs": {
        "additionalProp1": "string1",
        "additionalProp3": "string2",
        "additionalProp2": "string3"
      },
      "flavor": "CPU: 2核 8GB",
      "id": "8a0e84c0939b9c2101939ba84f0f009b",
      "image": {
        "category": "CPU",
        "source": "SWR",
        "swr_path": "swr.cn-north-7.myhuaweicloud.com/atelier/pytorch_1_4:pytorch_1.4-cuda_10.1-py37-ubuntu_18.04-x86_64-20220926104017-041ba2e"
      },
      "models": [ {
        "mount_path": "/models/",
        "source": "EFS",
        "source_id": "98b57430-a738-4bce-9dea-2c70eb5f1005"
      } ],
      "role": "COMMON"
    } ],
    "weight": 100
  }, {
    "count": 1,
    "framework": "COMMON",
    "id": "f702f711-3c77-448a-8eef-87381013322b",
    "name": "group_name1",
    "pool_id": "pool-infer2-04f258c84780d5a52f3bc00dc15aa5e7",
    "unit_configs": [ {
      "codes": [ {
        "address": "https://example.obs.example1.com",
        "mount_path": "/codes/",
        "source": "EFS",
        "source_id": "98b57430-a738-4bce-9dea-2c70eb5f1005"
      } ],
      "count": 1,
      "envs": {
        "additionalProp1": "string",
        "additionalProp2": "string",
        "additionalProp3": "string"
      },
      "flavor": "CPU: 2核 8GB",
      "id": "8a0e84c0939b9c2101939ba84f0f0097",
      "image": {
        "category": "CPU",
        "source": "SWR",
        "swr_path": "swr.cn-north-7.myhuaweicloud.com/atelier/pytorch_1_4:pytorch_1.4-cuda_10.1-py37-ubuntu_18.04-x86_64-20220926104017-041ba2e"
      },
      "models": [ {
        "mount_path": "/models/",
        "source": "EFS",
```

```
    "source_id": "98b57430-a738-4bce-9dea-2c70eb5f1005"
  },
  "port": 65535,
  "role": "COMMON"
},
"weight": 100
},
"runtime_config": {
  "service_invoke": {
    "auth_type": "TOKEN",
    "port": 65534,
    "protocol": "HTTPS"
  },
  "service_limit": {
    "rate_limit": {
      "num": 1999,
      "unit": "NANOS"
    },
    "request_size_limit": 49,
    "request_timeout": 1799
  }
},
"version": "0.2.0"
}
```

状态码

状态码	描述
200	删除的版本信息。

错误码

请参见[错误码](#)。

7.4 专属池

7.4.1 查询纳管集群详情

功能介绍

该接口允许用户通过指定资源池的ID来查询纳管集群的详细信息，包括实例ID、名称、Flavor规格、实例状态和实例可访问的URL。此功能适用于需要监控或管理云资源的用户，使用该接口前，用户需确保已拥有访问权限及正确的资源池ID。执行成功后，用户将获得所需的实例详情，可用于进一步的资源管理和配置。如果资源池ID无效或用户没有相应的访问权限，接口将返回错误信息，如404 Not Found或401 Unauthorized。

URI

GET /v2/{project_id}/services/clusters/{id}

表 7-372 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
id	是	String	参数解释： 需要获取资源池的ID，可以是资源池的pool_id，资源池的logic_cluster_id。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-373 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： op账号的集群所在的项目TOKEN。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
X-User-Token	否	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-374 响应 Body 参数

参数	参数类型	描述
workspace_id	String	参数解释： 工作空间ID。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。 取值范围： 不涉及。
logic_cluster_id	String	参数解释： 资源池ID。 取值范围： 不涉及。
status	String	参数解释： 资源当前状态，一次只支持一种状态筛选。默认不过滤。 取值范围： - ACTIVE：初始化。 - PENDING：待处理。 - INITIALIZING：初始化中。 - INITIALIZE_FAILED：初始化失败。 - DELETED：已删除。 - DELETING：删除中。 - DELETE_FAILED：删除失败。 - MIGRATING：迁移中。

参数	参数类型	描述
pool_id	String	参数解释： 专属资源池ID。 取值范围： 不涉及。
type	String	参数解释： 专属池类型。 取值范围： • MANAGED：初始化。 • MANAGED_ROMA：待处理。 • DEDICATED：初始化中。 • DEDICATED_ROMA：初始化失败。
resource_categories	Array of strings	参数解释： 资源池类型。
project_id	String	参数解释： 用户项目ID。 取值范围： 不涉及。
create_at	Long	参数解释： 资源池启用的时间，UTC毫秒。 取值范围： 不涉及。
update_at	Long	参数解释： 资源池最后更新的时间，UTC毫秒。 取值范围： 不涉及。
flavors	Array of NotebookFlavor objects	参数解释： 当前专属池支持的规格。

表 7-375 NotebookFlavor

参数	参数类型	描述
arch	String	参数解释： 架构类型。 取值范围： • X86_64 • AARCH64
ascend	AscendInfo object	参数解释： NPU信息。
billing	BillingInfo object	参数解释： 话单信息。
category	String	参数解释： 规格处理器类型。 取值范围： • CPU • GPU
description	String	参数解释： 规格描述信息。 取值范围： 不涉及。
feature	String	参数解释： 规格类别。 取值范围： • DEFAULT：CodeLab规格。 • NOTEBOOK：Notebook规格。
free	Boolean	参数解释： 是否为免费规格。 取值范围： • true: 免费规格。 • false: 付费规格。
gpu	GPUInfo object	参数解释： GPU信息。 取值范围： 不涉及。

参数	参数类型	描述
id	String	参数解释： 规格ID。 取值范围： 不涉及。
memory	Long	参数解释： 内存大小。 取值范围： 不涉及。
name	String	参数解释： 规格名称。 取值范围： 不涉及。
sold_out	Boolean	参数解释： 资源是否充足。 取值范围： • true 资源不足。 • false 资源充足。
storages	Array of strings	参数解释： 规格支持的存储类型。
vcpus	Integer	参数解释： CPU核数。 取值范围： 不涉及。

表 7-376 AscendInfo

参数	参数类型	描述
npu	Integer	参数解释： NPU数量。 取值范围： 不涉及
npu_memory	String	参数解释： NPU内存。 取值范围： 不涉及。

参数	参数类型	描述
type	String	参数解释： NPU类型。 取值范围： 不涉及。

表 7-377 BillingInfo

参数	参数类型	描述
code	String	参数解释： 计费码。 取值范围： 不涉及。
unit_num	Integer	参数解释： 计费单元。 取值范围： 不涉及。

表 7-378 GPUInfo

参数	参数类型	描述
gpu	Integer	参数解释： GPU卡数。 取值范围： 不涉及。
gpu_memory	String	参数解释： GPU内存。 取值范围： 不涉及。
type	String	参数解释： GPU类型。 取值范围： 不涉及。

请求示例

指定资源池的ID来查询纳管集群的详细信息。

```
http://{endpoint}/v2/{project_id}/services/clusters/{id}

{
  "id": "123e4567-e89b-12d3-a456-426655440000"
}
```

响应示例

状态码：200

成功获取纳管集群的详细信息。

```
{
  "logic_cluster_id": "df7ab421-4c12-4032-a344-b2e41aa1a962",
  "status": "ACTIVE",
  "pool_id": "pool-maostest-train-06024304be00d5092fbd0013d201342",
  "type": "DEDICATED",
  "resource_categories": [ "CPU" ],
  "flavors": [ {
    "arch": "x86_64",
    "billing": {
      "unit_num": 0
    },
    "category": "CPU",
    "description": "General-purpose CPU specifications, ideal for data exploration and algorithm discovery",
    "evs_max_size": "4096",
    "feature": "NOTEBOOK",
    "free": false,
    "id": "modelarts.vm.cpu.2u.8g",
    "memory": 8388608,
    "name": "CPU: 2vCPUs 8GB",
    "sold_out": false,
    "storages": [ "OBS", "EFS_DEDICATED", "EVS", "OBSFS" ],
    "vcpus": 2
  }, {
    "arch": "x86_64",
    "billing": {
      "code": "modelarts.vm.cpu.4u",
      "unit_num": 1
    },
    "category": "CPU",
    "description": "General-purpose Intel CPU specifications, ideal for data exploration and algorithm
discovery.",
    "evs_max_size": "4096",
    "feature": "NOTEBOOK",
    "free": false,
    "id": "modelarts.vm.cpu.4u",
    "memory": 16777216,
    "name": "CPU: 4vCPUs 16GB",
    "sold_out": false,
    "storages": [ "OBS", "EFS_DEDICATED", "EVS", "OBSFS" ],
    "vcpus": 4
  }, {
    "arch": "x86_64",
    "billing": {
      "code": "modelarts.vm.cpu.8u",
      "unit_num": 1
    },
    "category": "CPU",
    "description": "General computing-plus Intel CPU specifications, ideal for compute-intensive
applications.",
    "evs_max_size": "4096",
    "feature": "NOTEBOOK",
    "free": false,
    "id": "modelarts.vm.cpu.8u",
    "memory": 33554432,
    "name": "CPU: 8vCPUs 32GB",
    "sold_out": false,
    "storages": [ "OBS", "EFS_DEDICATED", "EVS", "OBSFS" ],
  }
```

```
    "vcpus" : 8
  },
  "workspace_id" : "0",
  "create_at" : 1721795441423,
  "update_at" : 1724767716067,
  "project_id" : "06024304be00d5092fbdc0013d201342"
}
```

状态码

状态码	描述
200	成功获取纳管集群的详细信息。

错误码

请参见[错误码](#)。

7.4.2 查询支持可切换规格列表

功能介绍

该接口允许用户查询当前资源实例支持的可切换规格列表，适用于需要调整实例资源配置的场景。使用该接口前，用户需确保已登录并拥有查询权限。执行成功后，用户将获得一个包含各种可切换规格的详细列表，包括规格ID、名称、资源配额等信息，可用于后续的实例规格变更操作。如果用户没有相应的查询权限或资源实例ID无效，接口将返回错误信息，如401 Unauthorized或404 Not Found。

URI

GET /v2/{project_id}/services/flavors

表 7-379 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

表 7-380 Query 参数

参数	是否必选	参数类型	描述
type	否	String	参数解释： 资源归属类型。 约束限制： 不涉及。 取值范围： • MANAGED • MANAGED_ROMA • DEDICATE • DEDICATED_ROMA 默认取值： 不涉及。
flavor_type	否	String	参数解释： 规格类型。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
limit	否	Integer	参数解释： 指定返回的最大条目数。 约束限制： 不涉及。 取值范围： [1,500] 默认取值： 10。
offset	否	Integer	参数解释： 分页列表查询的偏移量。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 0。

请求参数

表 7-381 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	否	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： - application/json - application/json;charset=utf-8 默认取值： 不涉及。

响应参数

状态码：200

表 7-382 响应 Body 参数

参数	参数类型	描述
flavors	Array of NotebookFlavor objects	参数解释： 规格列表。

表 7-383 NotebookFlavor

参数	参数类型	描述
arch	String	参数解释： 架构类型。 取值范围： • X86_64 • AARCH64
ascend	AscendInfo object	参数解释： NPU信息。
billing	BillingInfo object	参数解释： 话单信息。
category	String	参数解释： 规格处理器类型。 取值范围： • CPU • GPU
description	String	参数解释： 规格描述信息。 取值范围： 不涉及。
feature	String	参数解释： 规格类别。 取值范围： • DEFAULT：CodeLab规格。 • NOTEBOOK：Notebook规格。
free	Boolean	参数解释： 是否为免费规格。 取值范围： • true: 免费规格。 • false: 付费规格。
gpu	GPUInfo object	参数解释： GPU信息。 取值范围： 不涉及。

参数	参数类型	描述
id	String	参数解释： 规格ID。 取值范围： 不涉及。
memory	Long	参数解释： 内存大小。 取值范围： 不涉及。
name	String	参数解释： 规格名称。 取值范围： 不涉及。
sold_out	Boolean	参数解释： 资源是否充足。 取值范围： • true 资源不足。 • false 资源充足。
storages	Array of strings	参数解释： 规格支持的存储类型。
vcpus	Integer	参数解释： CPU核数。 取值范围： 不涉及。

表 7-384 AscendInfo

参数	参数类型	描述
npu	Integer	参数解释： NPU数量。 取值范围： 不涉及
npu_memory	String	参数解释： NPU内存。 取值范围： 不涉及。

参数	参数类型	描述
type	String	参数解释： NPU类型。 取值范围： 不涉及。

表 7-385 BillingInfo

参数	参数类型	描述
code	String	参数解释： 计费码。 取值范围： 不涉及。
unit_num	Integer	参数解释： 计费单元。 取值范围： 不涉及。

表 7-386 GPUInfo

参数	参数类型	描述
gpu	Integer	参数解释： GPU卡数。 取值范围： 不涉及。
gpu_memory	String	参数解释： GPU内存。 取值范围： 不涉及。
type	String	参数解释： GPU类型。 取值范围： 不涉及。

状态码：401

表 7-387 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：403

表 7-388 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-389 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

查询支持可切换规格列表

```
GET https://{endpoint}/v2/04f258c84780d5a52f3bc00dc15aa5e7/services/flavors
```

响应示例

状态码：200

OK

```
{
  "current" : 1,
  "data" : [ {
    "arch" : "x86_64",
    "billing" : {
      "unit_num" : 1
    },
    "category" : "CPU",
    "description" : "CPU算力增强型，适用于密集计算场景下运算",
    "evs_max_size" : "4096",
    "feature" : "NOTEBOOK",
    "free" : false,
    "id" : "modelarts.vm.cpu.8u.32g",
    "memory" : 33554432,
    "name" : "CPU: 8核 32GB",
    "sold_out" : true,
    "storages" : [ "EFS", "OBS", "EVS", "OBSFS" ],
    "vcpus" : 8
  }, {
    "arch" : "x86_64",
    "billing" : {
      "unit_num" : 1
    },
    "category" : "CPU",
    "description" : "CPU通用规格，用于快速数据探索和实验",
    "evs_max_size" : "4096",
    "feature" : "NOTEBOOK",
    "free" : false,
    "id" : "modelarts.vm.cpu.2u.8g",
    "memory" : 8388608,
    "name" : "CPU: 2核 8GB",
    "sold_out" : true,
    "storages" : [ "EFS", "OBS", "EVS", "OBSFS" ],
    "vcpus" : 2
  }, {
    "arch" : "x86_64",
    "billing" : {
      "unit_num" : 1
    },
    "category" : "GPU",
    "description" : "GPU规格，适合深度学习场景下的算法训练和调测",
    "evs_max_size" : "4096",
    "feature" : "NOTEBOOK",
    "free" : false,
    "gpu" : {
      "gpu" : 1,
      "type" : "nvidia-a30"
    },
    "id" : "modelarts.vm.gpu.1a30",
    "memory" : 100663296,
    "name" : "GPU: 1*A30|CPU: 24核 96GB",
    "sold_out" : true,
    "storages" : [ "EFS", "OBS", "EVS", "OBSFS" ],
```

```
"vcpus" : 24
}, {
  "arch" : "x86_64",
  "billing" : {
    "unit_num" : 1
  },
  "category" : "GPU",
  "description" : "GPU规格，适合深度学习场景下的算法训练和调测",
  "evs_max_size" : "4096",
  "feature" : "NOTEBOOK",
  "free" : false,
  "gpu" : {
    "gpu" : 8,
    "type" : "nvidia-hnt8-nv80"
  },
  "id" : "modelarts.vm.gpu.8hnt8",
  "memory" : 2147483648,
  "name" : "GPU: 8*HNT8|CPU: 176核 2048GB",
  "sold_out" : true,
  "storages" : [ "EFS", "OBS", "EVS", "OBSFS" ],
  "vcpus" : 176
}, {
  "arch" : "x86_64",
  "billing" : {
    "unit_num" : 1
  },
  "category" : "GPU",
  "description" : "GPU规格，适合深度学习场景下的算法训练和调测",
  "evs_max_size" : "4096",
  "feature" : "NOTEBOOK",
  "free" : false,
  "gpu" : {
    "gpu" : 1,
    "type" : "nvidia-hnt8-nv80"
  },
  "id" : "modelarts.vm.gpu.1hnt8",
  "memory" : 268435456,
  "name" : "GPU: 1*HNT8|CPU: 22核 256GB",
  "sold_out" : true,
  "storages" : [ "EFS", "OBS", "EVS", "OBSFS" ],
  "vcpus" : 22
}, {
  "arch" : "x86_64",
  "billing" : {
    "unit_num" : 1
  },
  "category" : "GPU",
  "description" : "GPU规格，适合深度学习场景下的算法训练和调测",
  "evs_max_size" : "4096",
  "feature" : "NOTEBOOK",
  "free" : false,
  "gpu" : {
    "gpu" : 1,
    "type" : "nvidia-t4"
  },
  "id" : "modelarts.vm.gpu.1t4",
  "memory" : 3354432,
  "name" : "GPU: 1*T4|CPU: 8核 32GB",
  "sold_out" : true,
  "storages" : [ "EFS", "OBS", "EVS", "OBSFS" ],
  "vcpus" : 8
}, {
  "arch" : "aarch64",
  "ascend" : {
    "npu" : 8,
    "type" : "ascend-d910b"
  },
  "billing" : {
    "unit_num" : 1
```

```
    },
    "category": "ASCEND",
    "description": "昇腾规格，适合深度学习场景下的模型训练和调测",
    "evs_max_size": "4096",
    "feature": "NOTEBOOK",
    "free": false,
    "id": "modelarts.vm.arm.192u.npu.8d910b",
    "memory": 1610612736,
    "name": "Ascend: 8*D910B|ARM: 192核 1536GB",
    "sold_out": true,
    "storages": [ "EFS", "OBS", "EVS", "OBSFS" ],
    "vcpus": 192
  }, {
    "arch": "aarch64",
    "ascend": {
      "npu": 1,
      "type": "ascend-d910b"
    },
    "billing": {
      "unit_num": 1
    },
    "category": "ASCEND",
    "description": "昇腾规格，适合深度学习场景下的模型训练和调测",
    "evs_max_size": "4096",
    "feature": "NOTEBOOK",
    "free": false,
    "id": "modelarts.vm.arm.24u.npu.1d910b",
    "memory": 201326592,
    "name": "Ascend: 1*D910B|ARM: 24核 192GB",
    "sold_out": true,
    "storages": [ "EFS", "OBS", "EVS", "OBSFS" ],
    "vcpus": 24
  } ],
  "pages": 1,
  "size": 8,
  "total": 8
}
```

状态码

状态码	描述
200	OK
401	鉴权失败。
403	权限不足
404	资源未找到。

错误码

请参见[错误码](#)。

7.5 应用密钥管理

7.5.1 绑定应用密钥

功能介绍

本接口用于将生成的apikey与指定服务进行绑定，适用于应用程序需要调用特定服务的场景。调用此接口前，确保已成功创建服务实例，并获取到有效的apikey。绑定成功后，apikey将作为服务调用时的身份验证凭证，确保仅授权用户能够访问该服务。如果尝试绑定已失效的apikey，将返回相应的异常信息，提示用户检查apikey的有效性和绑定状态。

URI

POST /v2/{project_id}/services/{service_id}/api-keys/{key_id}/bind

表 7-390 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及 取值范围： 账号的资源空间ID。 默认取值： 不涉及
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及 取值范围： 服务ID 默认取值： 不涉及

参数	是否必选	参数类型	描述
key_id	是	String	参数解释： apikey_id，在 创建API_KEY 时即可在返回体中获取，也可通过 查询api-keys列表 获取当前用户拥有的apikey，其中key_id字段即为apikey_id。 约束限制： 不涉及 取值范围： apikey_id只能由英文小写字母、数字组成，且长度为32个字符。 默认取值： 不涉及

请求参数

表 7-391 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： - application/json。 - application/json;charset=utf-8。 默认取值： 不涉及。

响应参数

状态码：200

表 7-392 响应 Body 参数

参数	参数类型	描述
key_id	String	参数解释： api-key的ID，在 创建API_KEY 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的api-key，其中id字段即为服务ID。 取值范围： UUID格式。
name	String	参数解释： api-key的名称，在 创建API_KEY 时自定义。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。
description	String	参数解释： api-key的描述，在 创建API_KEY 时自定义。 取值范围： 支持1-256个字符，可以包含字母、汉字、数字、连字符和下划线。
create_time	String	参数解释： api-key的创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
scope	String	参数解释： api-key生效范围。 取值范围： - USER：表示生效范围为用户级别，可以访问该用户创建的所有在线服务。 - SERVICE：表示生效范围为单个服务，可以访问绑定该api-key的在线服务。

参数	参数类型	描述
domain_id	String	参数解释： 用户domain ID。获取方法请参见 获取账号名和账号ID 。 取值范围： 账号ID。
project_id	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 取值范围： 账号的项目ID。
services	Array of serviceldName objects	参数解释： 绑定此api-key的在线服务列表。
workspace_id	String	参数解释： 工作空间ID。 取值范围： 工作空间ID。

表 7-393 serviceldName

参数	参数类型	描述
id	String	参数解释： 服务ID。 取值范围： 服务ID。
name	String	参数解释： 服务名。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。

请求示例

给服务绑定apikey。

```
POST https://{endpoint}/v2/{project_id}/services/{service_id}/api-keys/{key_id}/bind
```

响应示例

状态码：200

成功给服务绑定apikey。

```
{
  "create_time": 1743228962325,
  "description": "test",
  "domain_id": "04f258c83e00d5a50f38c****example",
  "key_id": "8a0e4a2d95e088ea0195e****example",
  "name": "zyq3123",
  "project_id": "04f258c84780d5a52f3bc****example",
  "scope": "SERVICE",
  "services": [ {
    "id": "bd689f90-bbf5-4638-a96b-****example",
    "name": "test-infer-raw1234567"
  } ],
  "workspace_id": "0"
}
```

状态码

状态码	描述
200	成功给服务绑定apikey。

错误码

请参见[错误码](#)。

7.5.2 删除应用密钥

功能介绍

本接口用于删除指定的apikey，适用于管理员需要撤销对某个应用程序或用户的访问权限的场景。调用此接口前，确保已获取到需要删除的apikey，并确认apikey未在其他服务中使用。删除成功后，该apikey将无法再用于访问任何相关服务。如果尝试删除不存在或已删除的apikey，将返回相应的异常信息，提示用户检查apikey的有效性。

URI

DELETE /v2/{project_id}/services/api-keys/{key_id}

表 7-394 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
key_id	是	String	参数解释： apikey_id，在 创建API_KEY 时即可在返回体中获取，也可通过 查询api-keys列表 获取当前用户拥有的apikey，其中key_id字段即为apikey_id。 约束限制： 不涉及。 取值范围： apikey_id只能由英文小写字母、数字组成，且长度为32个字符。 默认取值： 不涉及。

请求参数

表 7-395 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-396 响应 Body 参数

参数	参数类型	描述
key_id	String	参数解释： api-key的ID，在 创建API_KEY 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的api-key，其中id字段即为服务ID。 取值范围： UUID格式。
name	String	参数解释： api-key的名称，在 创建API_KEY 时自定义。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。
description	String	参数解释： api-key的描述，在 创建API_KEY 时自定义。 取值范围： 支持1-256个字符，可以包含字母、汉字、数字、连字符和下划线。
create_time	String	参数解释： api-key的创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
scope	String	参数解释： api-key生效范围。 取值范围： - USER：表示生效范围为用户级别，可以访问该用户创建的所有在线服务。 - SERVICE：表示生效范围为单个服务，可以访问绑定该api-key的在线服务。

参数	参数类型	描述
domain_id	String	参数解释： 用户domain ID。获取方法请参见 获取账号名和账号ID 。 取值范围： 账号ID。
project_id	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 取值范围： 账号的项目ID。
services	Array of serviceldName objects	参数解释： 绑定此api-key的在线服务列表。
workspace_id	String	参数解释： 工作空间ID。 取值范围： 工作空间ID。

表 7-397 serviceldName

参数	参数类型	描述
id	String	参数解释： 服务ID。 取值范围： 服务ID。
name	String	参数解释： 服务名。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。

请求示例

删除应用密钥。

DELETE https://{endpoint}/v2/{project_id}/services/api-keys/{key_id}

响应示例

状态码：200

apikey信息。

```
{
  "create_time": 1743494875405,
  "description": "test",
  "domain_id": "04f258c83e00d5a50f38c****example",
  "key_id": "8a0e847095f063aa0195f****example",
  "name": "api-keys-name-test",
  "project_id": "04f258c84780d5a52f3b****example",
  "scope": "SERVICE",
  "services": [ ],
  "workspace_id": "0"
}
```

状态码

状态码	描述
200	apikey信息。

错误码

请参见[错误码](#)。

7.5.3 解绑应用密钥

功能介绍

本接口用于将已绑定的apikey从指定服务中解绑，适用于需要撤销某个apikey对特定服务的访问权限的场景。调用此接口前，确保已获取到需要解绑的apikey，并确认该apikey当前绑定在指定服务上。解绑成功后，该apikey将不再对指定服务生效，但仍可继续用于其他服务。如果尝试解绑不存在或未绑定到指定服务的apikey，将返回相应的异常信息，提示用户检查apikey的有效性和绑定状态。

URI

POST /v2/{project_id}/services/{service_id}/api-keys/{key_id}/unbind

表 7-398 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。
key_id	是	String	参数解释： apikey_id，在 创建API_KEY 时即可在返回体中获取，也可通过 查询api-keys列表 获取当前用户拥有的apikey，其中key_id字段即为apikey_id。 约束限制： 不涉及。 取值范围： apikey_id只能由英文小写字母、数字组成，且长度为32个字符。 默认取值： 不涉及。

请求参数

表 7-399 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-400 响应 Body 参数

参数	参数类型	描述
key_id	String	参数解释： api-key的ID，在 创建API_KEY 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的api-key，其中id字段即为服务ID。 取值范围： UUID格式。
name	String	参数解释： api-key的名称，在 创建API_KEY 时自定义。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。
description	String	参数解释： api-key的描述，在 创建API_KEY 时自定义。 取值范围： 支持1-256个字符，可以包含字母、汉字、数字、连字符和下划线。

参数	参数类型	描述
create_time	String	参数解释： api-key的创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
scope	String	参数解释： api-key生效范围。 取值范围： • USER：表示生效范围为用户级别，可以访问该用户创建的所有在线服务。 • SERVICE：表示生效范围为单个服务，可以访问绑定该api-key的在线服务。
domain_id	String	参数解释： 用户domain ID。获取方法请参见 获取账号名和账号ID 。 取值范围： 账号ID。
project_id	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 取值范围： 账号的项目ID。
services	Array of serviceName objects	参数解释： 绑定此api-key的在线服务列表。
workspace_id	String	参数解释： 工作空间ID。 取值范围： 工作空间ID。

表 7-401 serviceName

参数	参数类型	描述
id	String	参数解释： 服务ID。 取值范围： 服务ID。
name	String	参数解释： 服务名。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。

请求示例

解绑api-key。

POST https://{endpoint}/v2/{project_id}/services/{service_id}/api-keys/{key_id}/unbind

响应示例

状态码：200

apikey信息

```
{
  "create_time": 1743228962325,
  "description": "test",
  "domain_id": "04f258c83e00d5a50f****example",
  "key_id": "8a0e4a2d95e088ea0195e08****example",
  "name": "test3123",
  "project_id": "04f258c84780d5a52f3bc0****example",
  "scope": "SERVICE",
  "services": [ ],
  "workspace_id": "0"
}
```

状态码

状态码	描述
200	apikey信息

错误码

请参见[错误码](#)。

7.5.4 查询应用密钥

功能介绍

本接口用于查询当前系统中的apikey列表，适用于管理员或用户需要查看和管理apikey的场景。调用此接口前，确保已具备相应的查询权限。返回的列表将包含每个apikey的基本信息，如apikey值、创建时间、绑定的服务等。如果当前系统中没有apikey，将返回空列表或相应的异常信息，提示用户检查查询条件。

URI

GET /v2/{project_id}/services/api-keys

表 7-402 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

表 7-403 Query 参数

参数	是否必选	参数类型	描述
scope	否	String	参数解释： 生效范围，枚举值，可选值为USER、SERVICE。 约束限制： 不涉及。 取值范围： - USER：表示生效范围为用户级别，可以访问该用户创建的所有在线服务。 - SERVICE：表示生效范围为单个服务，可以访问绑定该api-key的在线服务。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
service_id	否	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。
name	否	String	参数解释： apikey_name，通过 查询api-keys列表 获取当前用户拥有的apikey，其中name字段即为apikey_name。 约束限制： 不涉及。 取值范围： apikey_name。 默认取值： 不涉及。
service_name	否	String	参数解释： 服务名，用户在 创建服务 时自定义。 约束限制： 服务在删除之前名字不能重复。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
key_id	否	String	参数解释： apikey_id，在 创建API_KEY 时即可在返回体中获取，也可通过 查询api-keys列表 获取当前用户拥有的apikey，其中key_id字段即为apikey_id。 约束限制： 不涉及。 取值范围： apikey_id只能由英文小写字母、数字组成，且长度为32个字符。 默认取值： 不涉及。
limit	否	Integer	参数解释： 指定返回的最大条目数。 约束限制： 不涉及。 取值范围： [1,500] 默认取值： 10。
offset	否	Integer	参数解释： 分页列表查询的偏移量。 约束限制： offset必须是limit的整数倍。 取值范围： 不涉及。 默认取值： 0。
workspace_id	否	String	工作空间id

参数	是否必选	参数类型	描述
with_user_scope	否	Boolean	参数解释： 是否查询鉴权范围为USER类型的API KEY，当同时指定service_id时可查询该服务所有可访问的API KEY。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： false。

请求参数

表 7-404 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： - application/json。 - application/json;charset=utf-8。 默认取值： 不涉及。

响应参数

状态码：200

表 7-405 响应 Body 参数

参数	参数类型	描述
data	Array of ApiKeyResponse objects	参数解释： api-key数据。
current	Integer	参数解释： 当前页码，从0开始计数 取值范围： 不涉及。
pages	Integer	参数解释： 总页数，根据传入的limit字段和数据总条数计算得出。如总记录条数为10，limit（单页最大条目数）为3，则页数为4 取值范围： 不涉及。
size	Integer	参数解释： 当前页数量 取值范围： 不涉及。
total	Integer	参数解释： 总记录条数。 取值范围： 不涉及。

表 7-406 ApiKeyResponse

参数	参数类型	描述
key_id	String	参数解释： api-key的ID，在 创建API_KEY 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的api-key，其中id字段即为服务ID。 取值范围： UUID格式。

参数	参数类型	描述
name	String	参数解释： api-key的名称，在 创建API_KEY 时自定义。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。
description	String	参数解释： api-key的描述，在 创建API_KEY 时自定义。 取值范围： 支持1-256个字符，可以包含字母、汉字、数字、连字符和下划线。
create_time	String	参数解释： api-key的创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
scope	String	参数解释： api-key生效范围。 取值范围： • USER：表示生效范围为用户级别，可以访问该用户创建的所有在线服务。 • SERVICE：表示生效范围为单个服务，可以访问绑定该api-key的在线服务。
domain_id	String	参数解释： 用户domain ID。获取方法请参见 获取账号名和账号ID 。 取值范围： 账号ID。
project_id	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 取值范围： 账号的项目ID。
services	Array of serviceIdName objects	参数解释： 绑定此api-key的在线服务列表。

参数	参数类型	描述
workspace_id	String	参数解释： 工作空间ID。 取值范围： 工作空间ID。

表 7-407 serviceIdName

参数	参数类型	描述
id	String	参数解释： 服务ID。 取值范围： 服务ID。
name	String	参数解释： 服务名。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。

请求示例

查询api-keys列表。

GET https://{endpoint}/v2/{project_id}/services/api-keys

响应示例

状态码：200

查询api-keys列表成功

```
{
  "current" : 0,
  "data" : [ {
    "create_time" : 1743494875405,
    "description" : "test",
    "domain_id" : "04f258c83e00d5a50f****example",
    "key_id" : "8a0e847095f063aa0195f0****example",
    "name" : "api-keys-name-test",
    "project_id" : "04f258c84780d5a52f3bc****example",
    "scope" : "SERVICE",
    "services" : [ ]
  }, {
    "create_time" : 1743228962325,
    "description" : "test",
    "domain_id" : "04f258c83e00d5a50f38c00****example",
    "key_id" : "8a0e4a2d95e088ea01****example",
    "name" : "zyq3123",
    "project_id" : "04f258c84780d5a5****example",
    "scope" : "SERVICE",
```

```
{
  "services": [ ]
}, {
  "create_time": 1743228957659,
  "description": "test",
  "domain_id": "04f258c83e00d5a50****example",
  "key_id": "8a0e4a2d95e088ea0195****example",
  "name": "test3124",
  "project_id": "04f258c84780d5a52f3bc0****example",
  "scope": "SERVICE",
  "services": [ ]
}],
"pages": 1,
"size": 10,
"total": 3
}
```

状态码

状态码	描述
200	查询api-keys列表成功

错误码

请参见[错误码](#)。

7.5.5 创建应用密钥

功能介绍

本接口用于在系统中创建一个新的API_KEY，适用于需要为用户或应用程序生成访问凭证的场景。调用此接口前，确保已具备相应的创建权限，并提供必要的参数，如用户ID或应用程序ID。创建成功后，系统将生成一个唯一的API_KEY，并返回该API_KEY的详细信息，包括API_KEY值、创建时间等。如果提供的参数无效或系统中已存在相同的API_KEY，将返回相应的异常信息，提示用户检查输入数据的有效性。

URI

POST /v2/{project_id}/services/api-keys

表 7-408 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

请求参数

表 7-409 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	否	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： - application/json。 - application/json;charset=utf-8。 默认取值： 不涉及。

表 7-410 请求 Body 参数

参数	是否必选	参数类型	描述
name	是	String	参数解释： api-key名称，用户在 创建服务 时自定义。 约束限制： api-key在删除之前名字不能重复。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。 默认取值： 不涉及。
description	否	String	参数解释： api-key描述。 约束限制： 不涉及。 取值范围： 长度不可以超过256，不能包含感叹号，大于号，小于号，等号，与，单引号，双引号。 默认取值： 默认为空。
scope	是	String	参数解释： api-key生效范围。 约束限制： 不涉及。 取值范围： ● USER：表示生效范围为用户级别，可以访问该用户创建的所有在线服务。 ● SERVICE：表示生效范围为单个服务，可以访问绑定该api-key的在线服务。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
expire_time	否	Long	参数解释： 过期时间。 约束限制： 不涉及。 取值范围： 13位时间戳。 默认取值： 默认长期有效。

响应参数

状态码：200

表 7-411 响应 Body 参数

参数	参数类型	描述
-	File	应用密钥文件。

请求示例

创建应用密钥。

```
https://{endpoint}/v2/{project_id}/services/api-keys
{
  "name" : "apikey_test",
  "scope" : "SERVICE"
}
```

响应示例

状态码：200

应用密钥文件。

```
id,api_key,scope,workspace_id,create_time,domain_id,project_id
2c9080f0971471ef01****example,*****,SERVICE,0,2025-05-28T10:04:53.272696578,e57495061d744b2cb5e8***
*example4,b33fd65d96474f4a****example
```

状态码

状态码	描述
200	应用密钥文件。

错误码

请参见[错误码](#)。

7.5.6 批量绑定应用密钥

功能介绍

本接口用于将生成的多个apikey与指定服务进行批量绑定，用于访问特定服务。调用此接口前，确保已成功创建服务实例，并获取到有效的apikey。绑定成功后，apikey将作为服务调用时的身份验证凭证，确保仅授权用户能够访问该服务。如果尝试绑定已失效或已绑定当前服务的apikey将返回相应的异常信息，提示用户检查apikey的有效性和绑定状态。

URI

POST /v2/{project_id}/services/{service_id}/api-keys/batch-bind

表 7-412 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及 取值范围： 服务ID 默认取值： 不涉及

请求参数

表 7-413 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json。 • application/json;charset=utf-8。 默认取值： 不涉及。

表 7-414 请求 Body 参数

参数	是否必选	参数类型	描述
key_ids	是	Array of key_ids objects	参数解释： 请求批量绑定的api-key的id数组。 约束限制： 请求批量绑定api-key的id个数不超过10个。

表 7-415 key_ids

参数	是否必选	参数类型	描述
key_id	是	String	参数解释： apikey_id，在创建API_KEY时即可在返回体中获取，也可通过查询api-keys列表获取当前用户拥有的apikey，其中key_id字段即为apikey_id。 约束限制： 不涉及 取值范围： apikey_id只能由英文小写字母、数字组成，且长度为32个字符。 默认取值： 不涉及

响应参数

状态码：200

表 7-416 响应 Body 参数

参数	参数类型	描述
total	Integer	参数解释： 请求绑定apikey总个数。 取值范围： 不涉及。
success_count	Integer	参数解释： 绑定apikey成功个数。 取值范围： 不涉及。
success_items	Array of ApiKeyResponse objects	参数解释： 绑定成功的apikey列表。
failure_count	Integer	参数解释： 绑定apikey失败个数。 取值范围： 不涉及。

参数	参数类型	描述
failure_items	Array of ApiKeyFailureResponse objects	参数解释： 绑定失败的apikey列表。

表 7-417 ApiKeyResponse

参数	参数类型	描述
key_id	String	参数解释： api-key的ID，在 创建API_KEY 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的api-key，其中id字段即为服务ID。 取值范围： UUID格式。
name	String	参数解释： api-key的名称，在 创建API_KEY 时自定义。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。
description	String	参数解释： api-key的描述，在 创建API_KEY 时自定义。 取值范围： 支持1-256个字符，可以包含字母、汉字、数字、连字符和下划线。
create_time	String	参数解释： api-key的创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
scope	String	参数解释： api-key生效范围。 取值范围： • USER：表示生效范围为用户级别，可以访问该用户创建的所有在线服务。 • SERVICE：表示生效范围为单个服务，可以访问绑定该api-key的在线服务。

参数	参数类型	描述
domain_id	String	参数解释： 用户domain ID。获取方法请参见 获取账号名和账号ID 。 取值范围： 账号ID。
project_id	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 取值范围： 账号的项目ID。
services	Array of serviceldName objects	参数解释： 绑定此api-key的在线服务列表。
workspace_id	String	参数解释： 工作空间ID。 取值范围： 工作空间ID。

表 7-418 serviceldName

参数	参数类型	描述
id	String	参数解释： 服务ID。 取值范围： 服务ID。
name	String	参数解释： 服务名。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。

表 7-419 ApiKeyFailureResponse

参数	参数类型	描述
key_id	String	参数解释： api-key的ID，在 创建API_KEY 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的api-key，其中id字段即为服务ID。 取值范围： UUID格式。
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

给服务批量绑定多个apikey。

```
POST /v2/{project_id}/services/{service_id}/api-keys/batch-bind
```

响应示例

状态码：200

成功给服务绑定apikey。

```
{
  "total": 2,
  "success_count": 1,
  "success_items": [ {
    "create_time": 1743228962325,
    "description": "test",
    "domain_id": "04f258c83e00d5a50f38****example",
    "key_id": "8a0e4a2d95e088ea0195e0****example",
    "name": "zyq3123",
    "project_id": "04f258c84780d5a52f3bc****example",
    "scope": "SERVICE",
    "services": [ {
      "id": "bd689f90-bbf5-4638-a96b-****example",
      "name": "test-infer-raw1234567"
    } ],
    "workspace_id": "eab57afd5e8a4fc9a****example"
  } ],
  "failure_count": 1,
  "failure_items": [ {
    "key_id": "8a0e4a2d95e088ea0195****example",
    "error_code": "ModelArts.8024",
    "error_msg": "bd689f90-bbf5-4638-a96b-****example service not found"
  } ]
}
```

```
  }  
}
```

状态码

状态码	描述
200	成功给服务绑定apikey。

错误码

请参见[错误码](#)。

7.5.7 批量解绑应用密钥

功能介绍

本接口用于将已绑定的apikey从指定服务中批量解绑，适用于需要撤销多个apikey对特定服务的访问权限的场景。调用此接口前，确保已获取到需要解绑的多个apikey，并确认这些apikey当前绑定在指定服务上。解绑成功后，这些apikey将不再对指定服务生效，但仍可继续用于其他服务。如果尝试解绑不存在或未绑定到指定服务的apikey，将返回相应的异常信息，提示用户检查apikey的有效性和绑定状态。

URI

POST /v2/{project_id}/services/{service_id}/api-keys/batch-unbind

表 7-420 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及 取值范围： 服务ID 默认取值： 不涉及

请求参数

表 7-421 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json。 • application/json;charset=utf-8。 默认取值： 不涉及。

表 7-422 请求 Body 参数

参数	是否必选	参数类型	描述
key_ids	是	Array of key_ids objects	参数解释： 请求批量解绑的api-key的id数组。 约束限制： 请求批量解绑api-key的id个数不超过10个。

表 7-423 key_ids

参数	是否必选	参数类型	描述
key_id	是	String	参数解释： apikey_id，在创建API_KEY时即可在返回体中获取，也可通过查询api-keys列表获取当前用户拥有的apikey，其中key_id字段即为apikey_id。 约束限制： 不涉及。 取值范围： apikey_id只能由英文小写字母、数字组成，且长度为32个字符。 默认取值： 不涉及。

响应参数

状态码：200

表 7-424 响应 Body 参数

参数	参数类型	描述
total	Integer	参数解释： 请求解绑apikey总个数。 取值范围： 不涉及。

参数	参数类型	描述
success_count	Integer	参数解释： 解绑apikey成功个数。 取值范围： 不涉及。
success_items	Array of ApiKeyResponse objects	参数解释： 解绑成功的apikey列表。
failure_count	Integer	参数解释： 解绑apikey失败个数。 取值范围： 不涉及。
failure_items	Array of ApiKeyFailureResponse objects	参数解释： 解绑失败的apikey列表。

表 7-425 ApiKeyResponse

参数	参数类型	描述
key_id	String	参数解释： api-key的ID，在 创建API_KEY 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的api-key，其中id字段即为服务ID。 取值范围： UUID格式。
name	String	参数解释： api-key的名称，在 创建API_KEY 时自定义。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。
description	String	参数解释： api-key的描述，在 创建API_KEY 时自定义。 取值范围： 支持1-256个字符，可以包含字母、汉字、数字、连字符和下划线。

参数	参数类型	描述
create_time	String	参数解释： api-key的创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
scope	String	参数解释： api-key生效范围。 取值范围： • USER：表示生效范围为用户级别，可以访问该用户创建的所有在线服务。 • SERVICE：表示生效范围为单个服务，可以访问绑定该api-key的在线服务。
domain_id	String	参数解释： 用户domain ID。获取方法请参见 获取账号名和账号ID 。 取值范围： 账号ID。
project_id	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 取值范围： 账号的项目ID。
services	Array of serviceName objects	参数解释： 绑定此api-key的在线服务列表。
workspace_id	String	参数解释： 工作空间ID。 取值范围： 工作空间ID。

表 7-426 serviceName

参数	参数类型	描述
id	String	参数解释： 服务ID。 取值范围： 服务ID。
name	String	参数解释： 服务名。 取值范围： 支持1-64个字符，可以包含字母、汉字、数字、连字符和下划线。

表 7-427 ApiKeyFailureResponse

参数	参数类型	描述
key_id	String	参数解释： api-key的ID，在 创建API_KEY 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的api-key，其中id字段即为服务ID。 取值范围： UUID格式。
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

给服务批量解绑多个apikey。

POST /v2/{project_id}/services/{service_id}/api-keys/batch-unbind

响应示例

状态码：200

成功给服务解绑多个apikey。

```
{
  "total": 2,
  "success_count": 1,
  "success_items": [{
    "create_time": 1743228962325,
    "description": "test",
    "domain_id": "04f258c83e00d5a50f38c****example",
    "key_id": "8a0e4a2d95e088ea0195e0****example",
    "name": "zyq3123",
    "project_id": "04f258c84780d5a52****example",
    "scope": "SERVICE",
    "services": [{
      "id": "bd689f90-bbf5-4638-a96b-****example",
      "name": "testinfer-raw1234567"
    }],
    "workspace_id": "eab57afd5e8****example"
  }],
  "failure_count": 1,
  "failure_items": [{
    "key_id": "8a0e4a2d95e088ea0195****example",
    "error_code": "ModelArts.8024",
    "error_msg": "bd689f90-bbf5-4638-a96b-****example service not found"
  }]
}
```

状态码

状态码	描述
200	成功给服务解绑多个apikey。

错误码

请参见[错误码](#)。

7.6 服务实例管理

7.6.1 查询服务实例组列表

功能介绍

本接口用于查询当前租户的服务实例组列表，并支持根据服务实例组的状态进行筛选，包括运行中、已删除、错误和初始化等状态，还支持分页查询。适用于需要管理和监控服务实例组状态的场景。调用此接口前，确保已具备相应的查询权限，并提供可选的筛选条件和分页参数。返回的列表将包含每个服务实例组的基本信息，如实例组ID、更新时间、状态等。如果当前租户没有符合条件的服务实例组或提供的参数无效，将返回空列表或相应的异常信息，提示用户检查输入数据的有效性和权限。

URI

GET /v2/{project_id}/services/{id}/service-instance-groups

表 7-428 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

表 7-429 Query 参数

参数	是否必选	参数类型	描述
status	否	Array of strings	参数解释： 服务实例组状态，一次支持多种状态筛选，多种状态以","连接，不能存在空格。默认不过滤。取值范围有4种RUNNING（运行中）、ERROR（错误）、INIT（初始化）、DELETED（已删除）。 约束限制： 不涉及。

参数	是否必选	参数类型	描述
limit	否	Integer	参数解释： 指定返回的最大条目数。 约束限制： 不涉及。 取值范围： [1,500] 默认取值： 10。
offset	否	String	参数解释： 分页列表查询的偏移量。 约束限制： offset必须是limit的整数倍。 取值范围： 不涉及。 默认取值： 0。

请求参数

表 7-430 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-431 响应 Body 参数

参数	参数类型	描述
current	Integer	参数解释： 当前页码，从0开始计数。 取值范围： 不涉及。
data	Array of ServiceInstanceGroupResponse objects	参数解释： 服务实例组列表。
pages	Integer	参数解释： 总页数，根据传入的limit字段和数据总条数计算得出。如总记录条数为10，limit（单页最大条目数）为3，则页数为4。 取值范围： 不涉及。
size	Integer	参数解释： 当前页数量。 取值范围： 不涉及。
total	Integer	参数解释： 总记录条数。 取值范围： 不涉及。

表 7-432 ServiceInstanceGroupResponse

参数	参数类型	描述
service_group_name	String	参数解释： 服务实例组id。 取值范围： 不涉及。

参数	参数类型	描述
status	String	参数解释： 服务实例组状态。 取值范围： • RUNNING：运行中 • ERROR：错误 • INIT：初始化 • DELETED：已删除
update_at	Long	参数解释： 服务实例组最近更新时间。 取值范围： 不涉及。

状态码：400

表 7-433 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：401

表 7-434 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。

参数	参数类型	描述
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：403

表 7-435 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-436 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

查询指定服务实例组列表。

```
GET https://{endpoint}/v2/{project_id}/services/{id}/service-instance-groups
```

响应示例

状态码：200

OK。

```
{
  "current": 1,
  "data": [ {
    "service_group_name": "infer-a07f5c03-18c5-4dfb-849a-****example",
    "status": "ERROR",
    "update_at": 1747820496683
  } ],
  "pages": 1,
  "size": 1,
  "total": 1
}
```

状态码

状态码	描述
200	OK。
400	请求参数不合法。
401	鉴权非法。
403	权限不足。
404	资源未找到。

错误码

请参见[错误码](#)。

7.6.2 查询服务实例列表

功能介绍

本接口用于查询当前租户的服务实例列表，并支持根据服务实例的状态进行筛选，包括运行中和已删除状态，同时支持分页和关键词筛选。适用于需要管理和监控服务实例状态的场景。调用此接口前，确保已具备相应的查询权限，并提供可选的筛选条件和分页参数。返回的列表将包含每个服务实例的基本信息，如服务实例名字、最新更新时间、状态等。如果当前租户没有符合条件的服务实例或提供的参数无效，将返回空列表或相应的异常信息，提示用户检查输入数据的有效性和权限。

URI

GET /v2/{project_id}/services/{service_id}/service-instance-groups/{name}/service-instances

表 7-437 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。
name	是	String	参数解释： 服务实例组名字，可以为all，为all时去查询所有的服务实例组。 约束限制： 不涉及。 取值范围： 服务实例组名字。 默认取值： 不涉及。

表 7-438 Query 参数

参数	是否必选	参数类型	描述
status	否	Array of strings	参数解释： 服务实例组状态，一次支持多种状态筛选，多种状态以","连接，不能存在空格。默认不过滤。取值范围有4种RUNNING（运行中）、ERROR（错误）、INIT（初始化）、DELETED（已删除）。 约束限制： 不涉及。
limit	否	Integer	参数解释： 指定返回的最大条目数。 约束限制： 不涉及。 取值范围： [1,500] 默认取值： 10。
offset	否	String	参数解释： 分页列表查询的偏移量。 约束限制： offset必须是limit的整数倍。 取值范围： 不涉及。 默认取值： 0。

请求参数

表 7-439 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-440 响应 Body 参数

参数	参数类型	描述
current	Integer	参数解释： 当前页码，从0开始计数。 取值范围： 不涉及。
data	Array of ServiceInstanceResponse objects	参数解释： 服务实例列表。
pages	Integer	参数解释： 总页数，根据传入的limit字段和数据总条数计算得出。如总记录条数为10，limit（单页最大条目数）为3，则页数为4。 取值范围： 不涉及。
size	Integer	参数解释： 当前页数量。 取值范围： 不涉及。

参数	参数类型	描述
total	Integer	参数解释： 总记录条数。 取值范围： 不涉及。

表 7-441 ServiceInstanceResponse

参数	参数类型	描述
instance_name	String	参数解释： 服务实例名字。 取值范围： 不涉及。
status	String	参数解释： 服务实例状态。 取值范围： • RUNNING：运行中 • PENDING：未就绪 • CONCERNING：告警 • FAILED：失败 • UNKNOWN：未知 • DELETED：已删除
update_at	Long	参数解释： 服务实例最近更新时间。 取值范围： 不涉及。

状态码：400

表 7-442 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。

参数	参数类型	描述
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：401

表 7-443 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：403

表 7-444 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-445 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

查询指定服务实例列表。

```
GET https://{endpoint}/v2/{project_id}/services/{id}/service-instance-groups/{name}/service-instances
```

响应示例

状态码：200

OK。

```
{
  "current" : 1,
  "data" : [ {
    "instance_name" : "infer-a07f5c03-18c5-4dfb-849a-c3506020a1f8-1ghsj",
    "status" : "DELETED",
    "update_at" : 1747766464765
  }, {
    "instance_name" : "infer-a07f5c03-18c5-4dfb-849a-c3506020a1f8-ecfip",
    "status" : "DELETED",
    "update_at" : 1747785331567
  } ],
  "pages" : 1,
  "size" : 2,
  "total" : 2
}
```

状态码

状态码	描述
200	OK。
400	请求参数不合法。
401	鉴权非法。
403	权限不足。
404	资源未找到。

错误码

请参见[错误码](#)。

7.6.3 查询服务的 pod 的列表

功能介绍

本接口用于查询指定服务的pod列表，并支持选择是否只获取当前运行中的pod。适用于需要管理和监控服务pod状态的场景。调用此接口前，确保已具备相应的查询权限，并提供有效的服务ID和可选的筛选参数pod status（如是否只获取当前运行中的pod）。返回的列表将包含每个pod的基本信息，如pod名称、pod所在node的IP、pod所在node名字、pod角色、状态、最近更新时间等。如果指定的服务ID无效或当前服务没有pod，将返回空列表或相应的异常信息，提示用户检查输入数据的有效性和权限。

URI

GET /v2/{project_id}/services/{id}/service-instance-groups/{group_name}/service-instances/{name}/pods

表 7-446 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
group_name	是	String	参数解释： 服务实例组名字，可以为all，为all时去查询所有的服务实例组。 约束限制： 不涉及。 取值范围： 服务实例组名字。 默认取值： 不涉及。
name	是	String	参数解释： 服务实例名字，可以为all，为all时去查询所有的服务实例。 约束限制： 不涉及。 取值范围： 服务实例名字。 默认取值： 不涉及。

表 7-447 Query 参数

参数	是否必选	参数类型	描述
status	否	Array of strings	参数解释： pod状态，一次支持多种状态筛选，多种状态以","连接，不能存在空格。默认不过滤。取值范围有7种RUNNING（运行中）、PENDING（未就绪）、SUCCEEDED（成功）、FAILED（失败）、ABNORMAL（异常）、UNKNOWN（未知）、DELETED（已删除）。 约束限制： 不涉及。

参数	是否必选	参数类型	描述
limit	否	Integer	参数解释： 指定返回的最大条目数。 约束限制： 不涉及。 取值范围： [1,500] 默认取值： 10。
offset	否	String	参数解释： 分页列表查询的偏移量。 约束限制： offset必须是limit的整数倍。 取值范围： 不涉及。 默认取值： 0。

请求参数

表 7-448 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-449 响应 Body 参数

参数	参数类型	描述
current	Integer	参数解释： 当前页码，从0开始计数。 取值范围： 不涉及。
data	Array of ServicePodResponse objects	参数解释： 服务的pod的列表。
pages	Integer	参数解释： 总页数，根据传入的limit字段和数据总条数计算得出。如总记录条数为10，limit（单页最大条目数）为3，则页数为4。 取值范围： 不涉及。
size	Integer	参数解释： 当前页数量。 取值范围： 不涉及。
total	Integer	参数解释： 总记录条数。 取值范围： 不涉及。

表 7-450 ServicePodResponse

参数	参数类型	描述
pod_name	String	参数解释： pod名字。 取值范围： 不涉及。
pod_node_ip	String	参数解释： pod所在node的IP。 取值范围： 不涉及。

参数	参数类型	描述
pod_node_name	String	参数解释： pod所在node的名字。 取值范围： 不涉及。
pod_role	String	参数解释： pod角色。 取值范围： 不涉及。
status	String	参数解释： pod服务状态。 取值范围： 有7种状态。RUNNING（运行中）、PENDING（未就绪）、SUCCEEDED（成功）、FAILED（失败）、ABNORMAL（异常）、UNKNOWN（未知）、DELETED（已删除）。
update_time	Long	参数解释： 最近更新时间。 取值范围： 不涉及。

状态码：400

表 7-451 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：401

表 7-452 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：403

表 7-453 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-454 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

查询指定pod列表。

```
GET https://{endpoint}/v2/{project_id}/services/{id}/service-instance-groups/{group_name}/service-instances/{name}/pods?status=DELETED,SUCCEEDED
```

响应示例

状态码：200

OK。

```
{
  "current" : 1,
  "data" : [ {
    "pod_name" : "infer-a07f5c03-18c5-4dfb-849a-c3506020a1f8-1ghsj-role-0-64xph4d",
    "pod_node_ip" : "192.168.158.168",
    "pod_node_name" : "os-node-created-wrxd7",
    "pod_role" : "role-0",
    "status" : "DELETED",
    "update_at" : 1747766009248
  } ],
  "pages" : 1,
  "size" : 1,
  "total" : 1
}
```

状态码

状态码	描述
200	OK。
400	请求参数不合法。
401	鉴权非法。
403	权限不足。
404	资源未找到。

错误码

请参见[错误码](#)。

7.6.4 删除服务实例

功能介绍

本接口用于删除指定的单个服务实例，适用于需要清理或释放不再使用的服务实例资源的场景。调用此接口前，确保已具备相应的删除权限，并提供有效的服务实例ID。删除成功后，指定的服务实例将被彻底移除，不再对任何请求生效。如果提供的服务实例ID无效、服务实例已删除或权限不足，将返回相应的异常信息，提示用户检查输入数据的有效性和权限。

URI

DELETE /v2/{project_id}/services/{id}/service-instance-groups/{group_name}/
service-instances/{name}

表 7-455 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。
group_name	是	String	参数解释： 服务实例组名字。 约束限制： 不涉及。 取值范围： 服务实例组名字。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
name	是	String	参数解释： 服务实例名字。 约束限制： 不涉及。 取值范围： 服务实例名字。 默认取值： 不涉及。

表 7-456 Query 参数

参数	是否必选	参数类型	描述
force	否	Boolean	参数解释： 是否强制删除。 约束限制： 不涉及。 取值范围： • true：强制删除。 • false：不强制删除。 默认取值： false。
operation	否	String	参数解释： 删除操作类型。 约束限制： 枚举值。 取值范围： • DELETE：直接删除，释放资源。 • RECREATE：删除后重建。 默认取值： RECREATE。

请求参数

表 7-457 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-458 响应 Body 参数

参数	参数类型	描述
instance_name	String	参数解释： 服务实例名字。 取值范围： 不涉及。

状态码：400

表 7-459 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：401

表 7-460 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：403

表 7-461 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-462 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。

参数	参数类型	描述
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

强制删除指定服务实例。

```
DELETE https://{endpoint}/v2/{project_id}/services/{id}/service-instance-groups/{group_name}/service-
instances/{name}?force=true
```

响应示例

状态码：200

OK。

```
{
  "instance_name": "infer-689e24bb-3cf7-48c3-9ab5-67c0ade4dba7-fp74f"
}
```

状态码

状态码	描述
200	OK。
400	请求参数不合法。
401	鉴权非法。
403	权限不足。
404	资源未找到。

错误码

请参见[错误码](#)。

7.6.5 删除 Pod

功能介绍

本接口用于删除指定的单个Pod，适用于需要清理或释放不再使用的Pod资源的场景。调用此接口前，确保已具备相应的删除权限，并提供有效的Pod ID。删除成功后，指定的Pod将被彻底移除，不再对任何服务请求生效。如果提供的Pod ID无效、Pod已删除或权限不足，将返回相应的异常信息，提示用户检查输入数据的有效性和权限。

URI

DELETE /v2/{project_id}/services/{id}/service-instance-groups/{group_name}/
service-instances/{instance_name}/pods/{name}

表 7-463 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。
group_name	是	String	参数解释： 服务实例组名字。 约束限制： 不涉及。 取值范围： 服务实例组名字。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
instance_name	是	String	参数解释： 服务实例名字。 约束限制： 不涉及。 取值范围： 服务实例名字。 默认取值： 不涉及。
name	是	String	参数解释： Pod名称。 约束限制： 不涉及。 取值范围： Pod名称。 默认取值： 不涉及。

表 7-464 Query 参数

参数	是否必选	参数类型	描述
force	否	Boolean	参数解释： 是否强制删除。 约束限制： 不涉及。 取值范围： • true：是，强制删除 • false：否，不强制删除 默认取值： false。

请求参数

表 7-465 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-466 响应 Body 参数

参数	参数类型	描述
pod_name	String	参数解释： pod名字。 取值范围： 不涉及。

状态码：400

表 7-467 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：401

表 7-468 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：403

表 7-469 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-470 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。

参数	参数类型	描述
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

强制删除指定pod。

```
DELETE https://{endpoint}/v2/{project_id}/services/{id}/service-instance-groups/{group_name}/service-  
instances/{instance_name}/pods/{name}?force=true
```

响应示例

状态码：200

OK。

```
{  
  "pod_name" : "infer-689e24bb-4489-499b-becb-9ec539ebac93-cfvs4-role-0-68cj4gd"  
}
```

状态码

状态码	描述
200	OK。
400	请求参数不合法。
401	鉴权非法。
403	权限不足。
404	资源未找到。

错误码

请参见[错误码](#)。

7.6.6 查询 Pod 事件

功能介绍

本接口用于查询指定Pod的Kubernetes事件，适用于需要监控和排查Pod运行状态的场景。调用此接口前，确保已具备相应的查询权限，并提供有效的Pod ID。返回的事件列表将包含每个事件的详细信息，如事件类型、发生次数、事件名称、事件信息、发生时间等。如果提供的Pod ID无效、Pod不存在或权限不足，将返回相应的异常信息，提示用户检查输入数据的有效性和权限。

URI

GET /v2/{project_id}/services/{id}/service-instance-groups/{group_name}/service-instances/{instance_name}/pods/{name}/events

表 7-471 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。
group_name	是	String	参数解释： 服务实例组名字。 约束限制： 不涉及。 取值范围： 服务实例组名字。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
instance_name	是	String	参数解释： 服务实例名字。 约束限制： 不涉及。 取值范围： 服务实例名字。 默认取值： 不涉及。
name	是	String	参数解释： Pod名称。 约束限制： 不涉及。 取值范围： Pod名称。 默认取值： 不涉及。

表 7-472 Query 参数

参数	是否必选	参数类型	描述
limit	否	Integer	参数解释： 指定返回的最大条目数。 约束限制： 不涉及。 取值范围： [1,500] 默认取值： 10。
offset	否	Integer	参数解释： 分页列表查询的偏移量。 约束限制： offset必须是limit的整数倍。 取值范围： 不涉及。 默认取值： 0。

参数	是否必选	参数类型	描述
start_time	否	String	参数解释： 查询POD事件开始时间。 约束限制： 和end_time必须同时传或者不传，不传查的是原来K8s原生事件数据。 取值范围： 时间戳字符串。 默认取值： null
end_time	否	String	参数解释： 查询POD事件结束时间。 约束限制： 和start_time必须同时传或者不传，不传查的是原来K8s原生事件数据。 取值范围： 时间戳字符串。 默认取值： null

请求参数

表 7-473 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-474 响应 Body 参数

参数	参数类型	描述
[数组元素]	Array of ServicePodEventResponse objects	

表 7-475 ServicePodEventResponse

参数	参数类型	描述
count	Integer	参数解释： 事件发生次数。 取值范围： 不涉及。
first_timestamp	String	参数解释： 首次发生时间。 取值范围： 不涉及。
last_timestamp	String	参数解释： 最近发生时间。 取值范围： 不涉及。
message	String	参数解释： 事件信息。 取值范围： 不涉及。
reason	String	参数解释： 事件名称。 取值范围： 不涉及。
reporting_component	String	参数解释： 上报该事件的k8s组件名。 取值范围： 不涉及。
type	String	参数解释： 事件类型。 取值范围： NORMAL/ABNORMAL/WARNING。

状态码：400

表 7-476 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：401

表 7-477 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：403

表 7-478 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。

参数	参数类型	描述
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-479 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

查询指定Pod事件。

```
GET https://{endpoint}/v2/{project_id}/services/{id}/service-instance-groups/{group_name}/service-instances/{instance_name}/pods/{name}/events
```

响应示例

状态码：200

参数解释：

服务Pod事件列表。

约束限制：

不涉及。

```
[ {
  "count" : 5,
  "first_timestamp" : "2025-05-24T08:11:24Z",
  "last_timestamp" : "2025-05-24T08:11:53Z",
  "message" : "Back-off restarting failed container infer-5efd9b09-1f85-49f7-8735-9ec539ebac93 in pod infer-689e24bb-4489-499b-becb-9ec539ebac93-cfvs4-role-0-68cj4gd_pool-x-infer-04f258c84780d5a52f3bc00dc15aa5e7(bc6663ae-657c-4a4b-bb3e-35011483e4e9)",
  "reason" : "BackOffStart",
  "reporting_component" : "kubelet",
  "type" : "Warning"
```



```
}, {  
  "count" : 5,  
  "first_timestamp" : "2025-05-24T08:11:24Z",  
  "last_timestamp" : "2025-05-24T08:11:53Z",  
  "message" : "the failed container exited with ExitCode: 1",  
  "reason" : "BackOffStart",  
  "reporting_component" : "kubelet",  
  "type" : "Warning"  
}, {  
  "count" : 3,  
  "first_timestamp" : "2025-05-24T08:11:23Z",  
  "last_timestamp" : "2025-05-24T08:11:38Z",  
  "message" : "Started container infer-5efd9b09-1f85-49f7-8735-9ec539ebac93",  
  "reason" : "Started",  
  "reporting_component" : "kubelet",  
  "type" : "Normal"  
}]
```

状态码

状态码	描述
200	参数解释： 服务Pod事件列表。 约束限制： 不涉及。
400	请求参数不合法。
401	鉴权非法。
403	权限不足。
404	资源未找到。

错误码

请参见[错误码](#)。

7.7 RMS

7.7.1 查询区域下资源实例列表

功能介绍

本接口用于查询指定Region下的所有资源实例列表，适用于需要管理和监控特定Region中资源的场景。调用此接口前，确保已具备相应的查询权限，并提供有效的Region ID。返回的列表将包含每个资源实例的基本信息，如实例ID、创建时间、状态等。如果指定的Region ID不存在或当前Region中没有资源实例，将返回空列表或相应的异常信息，提示用户检查Region ID的有效性。

URI

GET /providers/modelarts/v1/domains/{domain_id}/regions/{region_id}/serviceV2

表 7-480 路径参数

参数	是否必选	参数类型	描述
domain_id	是	String	参数解释： 用户账号ID。获取方法请参见 获取账号名和账号ID 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
region_id	是	String	参数解释： 区域ID，用于明确资源所属区域。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-481 Query 参数

参数	是否必选	参数类型	描述
limit	否	Integer	参数解释： 指定返回的最大条目数。 约束限制： 不涉及。 取值范围： [1,200] 默认取值： 100。

参数	是否必选	参数类型	描述
next_token	否	String	参数解释： 分页查询时，下一页记录的起始位置。由response返回，有该字段，表示还有资源记录未遍历，下次查询时赋值给next_token参数，若response中不包含该字段，表示所有资源记录已全部遍历。 约束限制： 不传该参数或传入错误参数时，默认查询第一页。 取值范围： 取值由response返回。 默认取值： 不涉及。

请求参数

无

响应参数

状态码：200

表 7-482 响应 Body 参数

参数	参数类型	描述
value	Array of ResourceQueryResponse objects	参数解释： 区域资源列表。
next_token	String	参数解释： 分页返回时，用于标记下一页记录的起始位置，有该字段，表示还有资源记录未遍历；若response中不包含该字段，表示所有资源记录已全部遍历。 取值范围： 不涉及。

表 7-483 ResourceQueryResponse

参数	参数类型	描述
id	String	参数解释： 云服务资源的uuid，代表目标资源的唯一身份。 取值范围： 不涉及。
name	String	参数解释： 资源名称。 取值范围： 不涉及。
type	String	参数解释： 资源类型，建议使用复数，如vpcs；注意，需要与IAM细粒度授权中action的resourceType严格一致。 取值范围： 不涉及。
provider	String	参数解释： Resource Provider Name，取值同服务名一致，字母全小写，与IAM细粒度授权中action的type严格一致。 取值范围： 不涉及。
region_id	String	参数解释： regionId；如果是global服务，写global，否则按照华为云regionId填写，如cn-north-1等。 取值范围： 不涉及。
project_id	String	参数解释： 当前租户projectId，租户在每Region默认分配一个唯一projectId。 取值范围： 不涉及。
ep_id	String	参数解释： 企业项目ID，启用企业多项目的租户，云资源包含该属性。 取值范围： 不涉及。

参数	参数类型	描述
tags	tags object	参数解释： 租户通过TMS服务为云资源做的标记。
properties	Object	参数解释： 云资源的属性详情，json表述，需要与云服务给用户暴露的资源查询接口返回的内容等价。
provisioning_state	String	参数解释： 资源操作状态。 取值范围： Succeeded：资源操作成功 Failed：资源操作异常 Canceled：资源操作取消 Processing：资源操作正在进行中。
created_at	String	参数解释： 云资源初始创建时间。 取值范围： 日期类型，遵循ISO8601格式，UTC时区（ e.g. 2018-11-14T08:59:14Z ）
updated_at	String	参数解释： 云资源最后更新时间。 取值范围： 日期类型，遵循ISO8601格式，UTC时区（ e.g. 2018-11-14T08:59:14Z ）

表 7-484 tags

参数	参数类型	描述
env	String	参数解释： TMS标签的键。 取值范围： 最大长度127个utf8字符。key不能为空，并且不能包含dots(.) 符号。只要用户tag，不要系统的tag。
team	String	参数解释： TMS标签的值。 取值范围： 最大长度255个utf8字符。如果是一维标签没有值，则为空字符串。

请求示例

查询区域下资源实例列表

`https://{endpoint}/providers/modelarts/v1/domains/{domain_id}/regions/{region_id}/serviceV2`

响应示例

状态码：200

参数解释：

区域资源列表。

```
{
  "next_token": "MTAx",
  "value": [ {
    "created_at": "2025-07-01T08:38:05Z",
    "ep_id": "0",
    "id": "123d4567-d5b4-1234-9876-eb02c4daad25",
    "name": "zlj-701-001",
    "project_id": "1111b11ffd11111b11a1b11c111ec11",
    "properties": {
      "rate_limit_num": 200,
      "request_timeout": 30,
      "created_at": 1751359085153,
      "pool_ids": [ "infer-cpu-853-0621b83ffd694586b51a7b79c621ec42" ],
      "type": "REAL_TIME",
      "node_ids": [ ],
      "sfs_turbo_ids": [ ],
      "domain_id": "2222b22ffd22222b22a2b22c222ec22",
      "workspace_id": "0621b83ffd694586b51a7b79c621ec42",
      "cpu_arch": "x86_64",
      "protocol": "HTTPS",
      "domain_name": "ModelArts测试",
      "cpu_core_total": 0.25,
      "sfs_turbo_paths": [ ],
      "updated_at": 1751895092171,
      "project_id": "1111b11ffd11111b11a1b11c111ec11",
      "rate_limit_unit": "SECONDS",
      "max_unavailable": "1%",
      "max_surge": "1%",
      "direct_channel_auth_enable": false,
      "memory_total": 512,
      "workspace_name": "default",
      "auth_type": "API_KEY",
      "eps_id": "0",
      "deploy_type": "SINGLE",
      "pool_id": "infer-cpu-853-0621b83ffd694586b51a7b79c621ec42",
      "version": "0.0.1",
      "upgrade_type": "ROLLING",
      "pod_ids": [ ],
      "obs_paths": [ ],
      "gpu_count_total": 0,
      "port": 9876,
      "npu_count_total": 0,
      "request_size_limit": 20,
      "instance_count": 1,
      "status": "deploying",
      "direct_channel_enable": false
    },
    "provider": "modelarts",
    "provisioning_state": "Processing",
    "region_id": "eima01",
    "tags": { },
    "type": "serviceV2",
    "updated_at": "2025-07-07T13:31:32Z"
  } ], {
```

```
"created_at": "2025-06-25T11:58:32Z",
"ep_id": "0",
"id": "ccbcfb11-c11f-1ca1-111b-11bde1111cc1",
"name": "zlz-bda1副本副本副本副本",
"project_id": "1111b11ffd11111b11a1b11c111ec11",
"properties": {
  "rate_limit_num": 200,
  "request_timeout": 30,
  "description": "不删",
  "created_at": 1750852712842,
  "pool_ids": [ "infer-cpu-853-1111b11ffd11111b11a1b11c111ec11" ],
  "type": "REAL_TIME",
  "node_ids": [ ],
  "sfs_turbo_ids": [ ],
  "domain_id": "2222b22ffd22222b22a2b22c222ec22",
  "workspace_id": "1111b11ffd11111b11a1b11c111ec11",
  "cpu_arch": "x86_64",
  "protocol": "HTTPS",
  "domain_name": "ModelArts测试",
  "cpu_core_total": 0.5,
  "sfs_turbo_paths": [ ],
  "updated_at": 1751895039695,
  "project_id": "1111b11ffd11111b11a1b11c111ec11",
  "rate_limit_unit": "SECONDS",
  "max_unavailable": "1%",
  "max_surge": "1%",
  "direct_channel_auth_enable": false,
  "memory_total": 1024,
  "workspace_name": "default",
  "auth_type": "NONE",
  "eps_id": "0",
  "deploy_type": "SINGLE",
  "pool_id": "infer-cpu-853-1111b11ffd11111b11a1b11c111ec11",
  "version": "0.0.2",
  "upgrade_type": "ROLLING",
  "pod_ids": [ ],
  "obs_paths": [ ],
  "gpu_count_total": 0,
  "port": 9876,
  "npu_count_total": 0,
  "request_size_limit": 20,
  "instance_count": 1,
  "status": "stopping",
  "direct_channel_enable": false
},
"provider": "modelarts",
"provisioning_state": "Processing",
"region_id": "eima01",
"tags": { },
"type": "serviceV2",
"updated_at": "2025-07-07T13:30:39Z"
}]
}
```

状态码

状态码	描述
200	参数解释： 区域资源列表。

错误码

请参见[错误码](#)。

7.7.2 查询区域下资源实例详情

功能介绍

本接口用于查询指定Region中某个资源实例的详细信息，适用于需要获取特定资源实例详细配置和状态的场景。调用此接口前，确保已具备相应的查询权限，并提供有效的Region ID和资源实例ID。返回的信息将包括资源实例的详细属性，如实例ID、创建时间、状态、配置参数等。如果指定的Region ID或资源实例ID不存在，将返回相应的异常信息，提示用户检查输入数据的有效性。

URI

GET /providers/modelarts/v1/domains/{domain_id}/regions/{region_id}/serviceV2/{resource_id}

表 7-485 路径参数

参数	是否必选	参数类型	描述
domain_id	是	String	参数解释： 用户账号ID。获取方法请参见 获取账号名和账号ID 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
region_id	是	String	参数解释： 区域ID，用于明确资源所属区域。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
resource_id	是	String	参数解释： 资源ID，如Notebook实例ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-486 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 合法的op_service租户Token。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-487 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 云服务资源的uuid，代表目标资源的唯一身份。 取值范围： 不涉及。

参数	参数类型	描述
name	String	参数解释： 资源名称。 取值范围： 不涉及。
type	String	参数解释： 资源类型，建议使用复数，如vpcs；注意，需要与IAM细粒度授权中action的resourceType严格一致。 取值范围： 不涉及。
provider	String	参数解释： Resource Provider Name，取值同服务名一致，字母全小写，与IAM细粒度授权中action的type严格一致。 取值范围： 不涉及。
region_id	String	参数解释： regionId；如果是global服务，写global，否则按照华为云regionId填写，如cn-north-1等。 取值范围： 不涉及。
project_id	String	参数解释： 当前租户projectId，租户在每Region默认分配一个唯一projectId。 取值范围： 不涉及。
ep_id	String	参数解释： 企业项目ID，启用企业多项目的租户，云资源包含该属性。 取值范围： 不涉及。
tags	tags object	参数解释： 租户通过TMS服务为云资源做的标记。
properties	Object	参数解释： 云资源的属性详情，json表述，需要与云服务给用户暴露的资源查询接口返回的内容等价。

参数	参数类型	描述
provisioning_state	String	参数解释： 资源操作状态。 取值范围： Succeeded：资源操作成功 Failed：资源操作异常 Canceled：资源操作取消 Processing：资源操作正在进行中。
created_at	String	参数解释： 云资源初始创建时间。 取值范围： 日期类型，遵循ISO8601格式，UTC时区（ e.g. 2018-11-14T08:59:14Z ）
updated_at	String	参数解释： 云资源最后更新时间。 取值范围： 日期类型，遵循ISO8601格式，UTC时区（ e.g. 2018-11-14T08:59:14Z ）

表 7-488 tags

参数	参数类型	描述
env	String	参数解释： TMS标签的键。 取值范围： 最大长度127个utf8字符。key不能为空，并且不能包含dots(.) 符号。只要用户tag，不要系统的tag。
team	String	参数解释： TMS标签的值。 取值范围： 最大长度255个utf8字符。如果是一维标签没有值，则为空字符串。

请求示例

查询区域下资源实例详情

https://{endpoint}/providers/modelarts/v1/domains/{domain_id}/regions/{region_id}/{resource_type}/{resource_id}

响应示例

状态码：200

参数解释：

资源详情。

```
{
  "created_at": "2025-07-01T08:38:05Z",
  "ep_id": "0",
  "id": "123d4567-d5b4-1234-9876-eb02c4daad25",
  "name": "zls-701-001",
  "project_id": "1111b11ffd11111b11a1b11c111ec11",
  "properties": {
    "rate_limit_num": 200,
    "request_timeout": 30,
    "created_at": 1751359085153,
    "pool_ids": [ "infer-cpu-853-0621b83ffd694586b51a7b79c621ec42" ],
    "type": "REAL_TIME",
    "node_ids": [ ],
    "sfs_turbo_ids": [ ],
    "domain_id": "2222b22ffd22222b22a2b22c222ec22",
    "workspace_id": "1111b11ffd11111b11a1b11c111ec11",
    "cpu_arch": "x86_64",
    "protocol": "HTTPS",
    "domain_name": "ModelArts测试",
    "cpu_core_total": 0.25,
    "sfs_turbo_paths": [ ],
    "updated_at": 1751895217089,
    "project_id": "1111b11ffd11111b11a1b11c111ec11",
    "rate_limit_unit": "SECONDS",
    "max_unavailable": "1%",
    "max_surge": "1%",
    "direct_channel_auth_enable": false,
    "memory_total": 512,
    "workspace_name": "default",
    "auth_type": "API_KEY",
    "eps_id": "0",
    "deploy_type": "SINGLE",
    "pool_id": "infer-cpu-853-1111b11ffd11111b11a1b11c111ec11",
    "version": "0.0.1",
    "upgrade_type": "ROLLING",
    "pod_ids": [ ],
    "obs_paths": [ ],
    "gpu_count_total": 0,
    "port": 9876,
    "npu_count_total": 0,
    "request_size_limit": 20,
    "instance_count": 1,
    "status": "failed",
    "direct_channel_enable": false
  },
  "provider": "modelarts",
  "provisioning_state": "Failed",
  "region_id": "eima01",
  "tags": { },
  "type": "serviceV2",
  "updated_at": "2025-07-07T13:33:37Z"
}
```

状态码

状态码	描述
200	参数解释： 资源详情。

错误码

请参见[错误码](#)。

7.8 内网接入管理

7.8.1 创建内网接入

功能介绍

本接口用于在指定Region中创建内网接入点，适用于需要为应用程序或服务配置内网连接的场景。调用此接口前，确保已具备相应的创建权限，并提供必要的参数，如Region ID、内网接入点名称和网络配置信息。创建成功后，系统将生成一个内网接入点，并返回该接入点的详细信息，包括接入点ID、创建时间、状态等。如果提供的参数无效或内网接入配置冲突，将返回相应的异常信息，提示用户检查输入数据的有效性和配置冲突情况。

URI

POST /v2/{project_id}/intranet-connection

表 7-489 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 资源空间ID。 默认取值： 不涉及。

请求参数

表 7-490 请求 Header 参数

参数	是否必选	参数类型	描述
x-auth-token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-491 请求 Body 参数

参数	是否必选	参数类型	描述
service_id	否	String	参数解释： 服务id。 约束限制： type为SERVICE时，必填 取值范围： 不涉及。 默认取值： 不涉及。
scene	是	String	参数解释： 内网访问场景。 约束限制： 不涉及。 取值范围： • VPC：用户vpc网络接入场景 • POOL：用户资源池网络接入场景 默认取值： 不涉及。

参数	是否必选	参数类型	描述
vpc_id	否	String	参数解释： vpc id vpc场景需要填写。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
subnet_id	否	String	参数解释： 子网 id vpc场景需要填写。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
pool_id	否	String	参数解释： 资源池id POOL场景需要填写。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
type	否	String	参数解释： 内网访问接入粒度，不填默认为SERVICE SERVICE：服务粒度 GLOBAL：global粒度 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
dispatcher_group_id	否	String	参数解释： global粒度拟接入的dispatcher group组的id，不填默认为公共dispatcher group组的id 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-492 响应 Body 参数

参数	参数类型	描述
applicant_user_name	String	参数解释： 申请方用户名。 取值范围： 不涉及。
id	String	参数解释： 内网接入id。 取值范围： 不涉及。
message	String	参数解释： 申请描述。 取值范围： 不涉及。
owner_domain_name	String	参数解释： 审核方domain name。 取值范围： 不涉及。

参数	参数类型	描述
scene	String	参数解释： 内网访问场景。 约束限制： 不涉及。 取值范围： POOL：用户资源池接入场景 默认取值： 不涉及。
service_id	String	参数解释： 服务id。 取值范围： 不涉及。
service_name	String	参数解释： 服务名。 取值范围： 不涉及。
status	String	参数解释： 内网接入状态，支持列表查询。 约束限制： 不涉及。 取值范围： - APPROVING：审批中 - REJECTED：拒绝 - CONNECTING：接入中 - CONNECTED：已接入 - CANCELED：已取消 - FAILED：失败 - DELETING：删除中 - DELETED：已删除 默认取值： 不涉及。
subnet_id	String	参数解释： 子网id。 取值范围： 不涉及。
url_list	Array of strings	参数解释： 访问地址列表。

参数	参数类型	描述
vpc_id	String	参数解释： vpc id。 取值范围： 不涉及。
dispatcher_group_id	String	参数解释： global粒度拟接入的dispatcher group组的id 取值范围： 不涉及。
type	String	参数解释： 接入粒度：SERVICE、GLOBAL 取值范围： 不涉及。

请求示例

```
http://127.0.0.1:8443/v2/{project_id}/intranet-connection
{
  "service_id": "e78773fa-4b27-446e-801d-42c586d7d8cb",
  "scene": "vpc",
  "vpc_id": "15e04c58-45df-44ee-8b5c-f73271fc1c38",
  "subnet_id": "339e64b8-ec66-4a08-b710-c51f408cff13"
}
```

响应示例

状态码：200

OK。

```
{
  "applicant_user_name": "test",
  "dispatcher_group_id": "ca29ce14-b475-4bee-93b4-24951e280c77",
  "id": "566149dd-d0ce-43e6-9f2d-57608a36de80",
  "owner_domain_name": "test",
  "scene": "VPC",
  "service_id": "e78773fa-4b27-446e-801d-42c586d7d8cb",
  "service_name": "service-ll-722-10",
  "status": "CONNECTING",
  "subnet_id": "339e64b8-ec66-4a08-b710-c51f408cff13",
  "type": "SERVICE",
  "vpc_id": "15e04c58-45df-44ee-8b5c-f73271fc1c38"
}
```

状态码

状态码	描述
200	OK。

错误码

请参见[错误码](#)。

7.8.2 变更内网申请

功能介绍

本接口用于对当前租户的内网接入申请进行状态变更操作，支持通过（APPROVE）、拒绝（REJECT）、取消（CANCEL）和重试（RETRY）等操作。适用于需要管理内网接入申请审批流程的场景。调用此接口前，确保已具备相应的变更权限，并提供有效的内网申请ID和所需的操作类型。变更成功后，内网申请的状态将更新为指定的操作结果，并记录相关日志。如果提供的内网申请ID无效、操作类型不支持或权限不足，将返回相应的异常信息，提示用户检查输入数据的有效性和权限。

URI

PUT /v2/{project_id}/intranet-connection/{id}

表 7-493 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
id	是	String	参数解释： 内网接入id。id可以根据 查询当前租户的内网接入申请列表 返回body的id字段得到。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-494 请求 Header 参数

参数	是否必选	参数类型	描述
x-auth-token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-495 请求 Body 参数

参数	是否必选	参数类型	描述
action	是	String	参数解释： 内网申请操作。 约束限制： 不涉及。 取值范围： ● APPROVE：通过申请。只有当服务处于“审批中”状态时，才可进行此操作。 ● REJECT：拒绝申请。只有当服务处于“审批中”状态时，才可进行此操作。 ● CANCEL：取消授权，只有当服务处于“通过”（CONNECTED）状态时，才可进行取消授权操作。 ● RETRY：重试申请，只有当服务处于“异常”状态并且异常原因为“连接失败，请重试”时，才可进行重试操作。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
reason	否	String	参数解释： 拒绝和取消时可以填入的原因。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：204

OK。

无

请求示例

```
http://127.0.0.1:8443/v2/{project_id}/intranet-connection/{id}

{
  "action": "APPROVE",
  "reason": "ok"
}
```

响应示例

无

状态码

状态码	描述
204	OK。

错误码

请参见[错误码](#)。

7.8.3 查询当前租户的内网接入申请列表

功能介绍

本接口用于查询当前租户所有的内网接入申请记录，适用于需要管理和监控内网接入申请状态的场景。调用此接口前，确保已具备相应的查询权限。返回的列表将包含每个内网接入申请的基本信息，如申请ID、创建时间、状态、Region ID等。如果当前租

户没有内网接入申请记录，将返回空列表。如果调用时出现权限不足或其他系统异常，将返回相应的异常信息，提示用户检查权限或联系技术支持。

URI

GET /v2/{project_id}/intranet-connection/requests

表 7-496 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-497 Query 参数

参数	是否必选	参数类型	描述
scene	否	String	参数解释： 内网访问场景。 约束限制： 不涉及。 取值范围： ● POOL：用户资源池接入场景 默认取值： 不涉及。

参数	是否必选	参数类型	描述
status	否	String	参数解释： 内网接入状态，支持列表查询。 约束限制： 不涉及。 取值范围： • APPROVING：审批中 • REJECTED：拒绝 • CONNECTING：接入中 • CONNECTED：已接入 • CANCELED：已取消 • FAILED：失败 • DELETING：删除中 • DELETED：已删除 默认取值： 不涉及。
id	否	String	参数解释： 内网接入id。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
service_id	否	String	参数解释： 服务id。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-498 请求 Header 参数

参数	是否必选	参数类型	描述
x-auth-token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-499 响应 Body 参数

参数	参数类型	描述
current	Integer	参数解释： 当前页。 取值范围： 不涉及。
pages	Integer	参数解释： 总页数。 取值范围： 不涉及。
size	Integer	参数解释： 每页大小。 取值范围： 不涉及。
total	Integer	参数解释： 数据总量。 取值范围： 不涉及。

参数	参数类型	描述
data	Array of IntranetConnectionInfo objects	参数解释： 申请信息列表。

表 7-500 IntranetConnectionInfo

参数	参数类型	描述
applicant_user_name	String	参数解释： 申请方用户名。 取值范围： 不涉及。
id	String	参数解释： 内网接入id。 取值范围： 不涉及。
message	String	参数解释： 申请描述。 取值范围： 不涉及。
owner_domain_name	String	参数解释： 审核方domain name。 取值范围： 不涉及。
scene	String	参数解释： 内网访问场景。 约束限制： 不涉及。 取值范围： • POOL：用户资源池接入场景 默认取值： 不涉及。
service_id	String	参数解释： 服务id。 取值范围： 不涉及。

参数	参数类型	描述
service_name	String	参数解释： 服务名。 取值范围： 不涉及。
status	String	参数解释： 内网接入状态，支持列表查询。 约束限制： 不涉及。 取值范围： • APPROVING：审批中 • REJECTED：拒绝 • CONNECTING：接入中 • CONNECTED：已接入 • CANCELED：已取消 • FAILED：失败 • DELETING：删除中 • DELETED：已删除 默认取值： 不涉及。
subnet_id	String	参数解释： 子网id。 取值范围： 不涉及。
url_list	Array of strings	参数解释： 访问地址列表。
vpc_id	String	参数解释： vpc id。 取值范围： 不涉及。
dispatcher_group_id	String	参数解释： global粒度拟接入的dispatcher group组的id 取值范围： 不涉及。

参数	参数类型	描述
type	String	参数解释： 接入粒度：SERVICE、GLOBAL 取值范围： 不涉及。

请求示例

查询当前租户的内网接入申请列表。

https://{endpoint}/v2/{project_id}/intranet-connection/requests

响应示例

状态码：200

OK。

```
{
  "current" : 0,
  "data" : [ {
    "applicant_user_name" : "test",
    "create_at" : 1753156304363,
    "dispatcher_group_id" : "ca29ce14-b475-4bee-93b4-24951e280c77",
    "id" : "566149dd-d0ce-43e6-9f2d-57608a36de80",
    "owner_domain_name" : "test",
    "scene" : "VPC",
    "service_id" : "e78773fa-4b27-446e-801d-42c586d7d8cb",
    "service_name" : "service-ll-722-10",
    "status" : "CONNECTED",
    "subnet_id" : "339e64b8-ec66-4a08-b710-c51f408cff13",
    "type" : "SERVICE",
    "update_at" : 1753156315023,
    "url_list" : [ "https://192.168.0.90/v2/infer/e78773fa-4b27-446e-801d-42c586d7d8cb" ],
    "vpc_id" : "15e04c58-45df-44ee-8b5c-f73271fc1c38"
  } ],
  "pages" : 15,
  "size" : 1,
  "total" : 15
}
```

状态码

状态码	描述
200	OK。

错误码

请参见[错误码](#)。

7.8.4 查询当前租户的内网接入审批列表

功能介绍

本接口用于查询当前租户所有的内网接入审批记录，适用于需要管理和监控内网接入审批状态的场景。调用此接口前，确保已具备相应的查询权限。返回的列表将包含每个内网接入审批的基本信息，如审批ID、申请时间、状态（如待审批、已批准、已拒绝）、申请者信息、Region ID等。如果当前租户没有内网接入审批记录，将返回空列表。如果调用时出现权限不足或其他系统异常，将返回相应的异常信息，提示用户检查权限或联系技术支持。

URI

GET /v2/{project_id}/intranet-connection/reviews

表 7-501 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-502 Query 参数

参数	是否必选	参数类型	描述
scene	否	String	参数解释： 内网访问场景。 约束限制： 不涉及。 取值范围： • POOL：用户资源池接入场景 默认取值： 不涉及。

参数	是否必选	参数类型	描述
id	否	String	参数解释： 内网接入id。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
applicant_domain_id	否	String	参数解释： 申请方domain id。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
service_id	否	String	参数解释： 服务id。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-503 请求 Header 参数

参数	是否必选	参数类型	描述
x-auth-token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-504 响应 Body 参数

参数	参数类型	描述
current	Integer	参数解释： 当前页。 取值范围： 不涉及。
pages	Integer	参数解释： 总页数。 取值范围： 不涉及。
size	Integer	参数解释： 每页大小。 取值范围： 不涉及。
total	Integer	参数解释： 数据总量。 取值范围： 不涉及。

参数	参数类型	描述
data	Array of IntranetConnectionInfo objects	参数解释： 申请信息列表。

表 7-505 IntranetConnectionInfo

参数	参数类型	描述
applicant_user_name	String	参数解释： 申请方用户名。 取值范围： 不涉及。
id	String	参数解释： 内网接入id。 取值范围： 不涉及。
message	String	参数解释： 申请描述。 取值范围： 不涉及。
owner_domain_name	String	参数解释： 审核方domain name。 取值范围： 不涉及。
scene	String	参数解释： 内网访问场景。 约束限制： 不涉及。 取值范围： • POOL：用户资源池接入场景 默认取值： 不涉及。
service_id	String	参数解释： 服务id。 取值范围： 不涉及。

参数	参数类型	描述
service_name	String	参数解释： 服务名。 取值范围： 不涉及。
status	String	参数解释： 内网接入状态，支持列表查询。 约束限制： 不涉及。 取值范围： • APPROVING：审批中 • REJECTED：拒绝 • CONNECTING：接入中 • CONNECTED：已接入 • CANCELED：已取消 • FAILED：失败 • DELETING：删除中 • DELETED：已删除 默认取值： 不涉及。
subnet_id	String	参数解释： 子网id。 取值范围： 不涉及。
url_list	Array of strings	参数解释： 访问地址列表。
vpc_id	String	参数解释： vpc id。 取值范围： 不涉及。
dispatcher_group_id	String	参数解释： global粒度拟接入的dispatcher group组的id 取值范围： 不涉及。

参数	参数类型	描述
type	String	参数解释： 接入粒度：SERVICE、GLOBAL 取值范围： 不涉及。

请求示例

查询当前租户的内网接入审批列表

https://{endpoint}/v2/{project_id}/intranet-connection/reviews

响应示例

状态码：200

OK。

```
{
  "current" : 0,
  "data" : [ {
    "applicant_user_name" : "fadsfasd",
    "create_at" : 1745245018845,
    "id" : "1d7812a3-0032-4f7a-bf31-87849ed41577",
    "owner_domain_name" : "fadsfasd",
    "scene" : "VPC",
    "service_id" : "58865106-c6c6-427a-9e0b-1c9e3f5bac4f",
    "service_name" : "service-fadsfasd",
    "status" : "APPROVING",
    "subnet_id" : "f4f58570-0f91-43c6-9981-8f19397caab4",
    "update_at" : 1745245455478,
    "vpc_id" : "ea697f73-ffc8-40bc-a11f-e8a6bfc8ae36"
  }, {
    "applicant_user_name" : "fadsfasd",
    "create_at" : 1745307967369,
    "id" : "6ff637dc-30ee-4e85-ab75-0b46ec665453",
    "owner_domain_name" : "fadsfasd",
    "scene" : "VPC",
    "service_id" : "58865106-c6c6-427a-9e0b-1c9e3f5bac4f",
    "service_name" : "service-fadsfasd",
    "status" : "APPROVING",
    "subnet_id" : "cf47bd54-0676-4367-b99e-4876670c732c",
    "update_at" : 1745307967369,
    "vpc_id" : "3e2a8f0f-f61e-4ad8-b6ce-d97333e6e0b7"
  } ],
  "pages" : 1,
  "size" : 10,
  "total" : 2
}
```

状态码

状态码	描述
200	OK。

错误码

请参见[错误码](#)。

7.8.5 批量删除内网接入

功能介绍

本接口用于批量删除指定的内网接入点，适用于需要清理多个不再使用的内网接入点的场景。调用此接口前，确保已具备相应的删除权限，并提供一个有效的内网接入点ID列表。删除成功后，所指定的内网接入点将被彻底移除，不再对任何服务生效。如果提供的内网接入点ID列表中包含无效或已删除的ID，将返回相应的异常信息，提示用户检查ID的有效性。此外，如果调用时出现权限不足或其他系统异常，也将返回相应的异常信息，提示用户检查权限或联系技术支持。

URI

POST /v2/{project_id}/intranet-connection/delete

表 7-506 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 7-507 请求 Header 参数

参数	是否必选	参数类型	描述
x-auth-token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 7-508 请求 Body 参数

参数	是否必选	参数类型	描述
intranet_connection_ids	是	Array of strings	内网接入的id列表

响应参数

状态码：204

OK。

无

请求示例

```
http://127.0.0.1:8443/v2/:project_id/intranet-connection/delete
{
  "intranet_connection_ids" : [ "a6ea6bfc-a52f-44fb-81b1-ca7cd57977eb", "cfe5caf2-147a-4d07-b843-dbc8a6964466" ]
}
```

响应示例

无

状态码

状态码	描述
204	OK。

错误码

请参见[错误码](#)。

7.9 扩缩容策略

7.9.1 创建自动扩缩容策略

功能介绍

本接口用于在已部署的服务上创建定时扩缩容策略，适用于需要在特定时间自动调整服务实例个数的场景。调用此接口前，确保服务已成功部署并获取了有效的服务ID，并提供详细的扩缩容策略参数，如扩缩容时间、实例个数范围、条件触发器等。创建成功后，系统将根据设定的策略自动调整服务实例个数，确保服务在指定时间内的性能和可用性。如果提供的服务ID无效、参数配置错误或系统资源不足，将返回相应的异常信息，提示用户检查输入数据的有效性或联系技术支持。

URI

POST /v2/{project_id}/services/{service_id}/{group_id}/hpa

表 7-509 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
group_id	是	String	参数解释： 实例组ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务详情 获取当前服务的实例组ID，其中version内的instance_groups内的id字段即为实例组ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

请求参数

表 7-510 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： - application/json - application/json;charset=utf-8 默认取值： 不涉及。

表 7-511 请求 Body 参数

参数	是否必选	参数类型	描述
type	是	String	参数解释： 自动扩缩容类型。 取值范围： • CRON_HPA：定时扩缩容策略 约束限制： 不涉及。 默认取值： 不涉及。
target_resource_type	是	String	参数解释： 自动扩缩容策略绑定的目标类型。 取值范围： • GROUP：实例组 约束限制： 不涉及。 默认取值： 不涉及。
hpa_rules	是	Array of HpaRulesCreate objects	参数解释： 自动扩缩容规则。 约束限制： 最多添加10条扩缩容规则。

表 7-512 HpaRulesCreate

参数	是否必选	参数类型	描述
disable	否	Boolean	参数解释： 自动扩缩容规则是否启用。 取值范围： • false：启动 • true：不启动 约束限制： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
type	是	String	参数解释： 自动扩缩容类型。 取值范围： CRON_HPA：定时扩缩容策略 约束限制： 不涉及。 默认取值： 不涉及。
schedule	是	String	参数解释： 定时自动扩缩容执行的cron表达式，不支持秒，从分钟开始设定 取值范围： 不涉及。 约束限制： 不涉及。 默认取值： 不涉及。
target_replicas	是	Integer	参数解释： 自动扩缩容目标实例数。 取值范围： 1-128 约束限制： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-513 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 自动扩缩容策略ID 取值范围： 不涉及。

参数	参数类型	描述
name	String	参数解释： 自动扩缩容策略名称 取值范围： 不涉及。
target_resource_id	String	参数解释： 自动扩缩容策略绑定的目标ID 取值范围： 实例组ID
target_resource_type	String	参数解释： 自动扩缩容策略绑定的目标类型。 取值范围： GROUP：实例组
status	String	参数解释： 自动扩缩容策略状态。 取值范围： - INACTIVE：不启用 - ACTIVE：配置成功 - DELETED：已删除
hpa_rules	Array of HpaRule objects	参数解释： 自动扩缩容规则列表
create_at	String	参数解释： 创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
update_at	String	参数解释： 更新时间，根据更新时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。

表 7-514 HpaRule

参数	参数类型	描述
id	String	参数解释： 自动扩缩容规则ID 取值范围： 不涉及。
hpa_id	String	参数解释： 自动扩缩容规则关联的策略ID 取值范围： 不涉及。
name	String	参数解释： 自动扩缩容规则名 取值范围： 支持4-64个字符，可以包含字母、汉字、数字、中划线和下划线。
type	String	参数解释： 自动扩缩容类型。 取值范围： CRON_HPA：定时扩缩容策略
schedule	String	参数解释： 定时自动扩缩容执行cron表达式，不支持秒，从分钟开始设定 取值范围： 不涉及。
target_replicas	Integer	参数解释： 自动扩缩容目标实例数。 取值范围： 1-128
disable	String	参数解释： 自动扩缩容规则是否启用。 取值范围： - false - true

参数	参数类型	描述
status	String	参数解释： 自动扩缩容规则状态。 取值范围： • CREATING：创建中 • CONFIG_SUCCESS：配置成功 • EXECUTE_SUCCESS：执行成功 • DELETED：已删除 • FAILED：执行失败

状态码：400

表 7-515 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：500

表 7-516 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

用户创建规则，当该服务不存在规则时使用。

```
{{request_url}}/v2/{{project_id}}/services/{{service_id}}/{{group_id}}/hpa
{
  "type": "CRON_HPA",
  "target_resource_id": "8a927efb-2e23-42e5-92ea-de86b4aba750",
  "target_resource_type": "GROUP",
  "hpa_rules": [ {
    "name": "test-rule1",
    "disable": false,
    "type": "CRON_HPA",
    "schedule": "22 9 * * ?",
    "target_replicas": 3
  } ]
}
```

响应示例

状态码：200

创建自动扩缩容返回体。

```
{
  "hpa_rules": [ {
    "disable": true,
    "hpa_id": "8521e55e-219f-4769-8a2f-08a78c02182e",
    "id": "accba651-d3fd-4434-8254-61d30e9e1b45",
    "name": "test-rule2",
    "schedule": "0 0 * * ?",
    "status": "CREATING",
    "target_replicas": 1,
    "type": "CRON_HPA"
  }, {
    "disable": false,
    "hpa_id": "8521e55e-219f-4769-8a2f-08a78c02182e",
    "id": "7447626f-6c94-4ad7-a527-d3fa04706788",
    "name": "test-rule3",
    "schedule": "38 10 * * ?",
    "status": "CREATING",
    "target_replicas": 3,
    "type": "CRON_HPA"
  } ],
  "id": "8521e55e-219f-4769-8a2f-08a78c02182e",
  "name": "cron-hpa-8a927efb-2e23-42e5-92ea-de86b4aba750",
  "status": "ACTIVE",
  "target_resource_id": "8a927efb-2e23-42e5-92ea-de86b4aba750",
  "target_resource_type": "GROUP",
  "type": "CRON_HPA"
}
```

状态码

状态码	描述
200	创建自动扩缩容返回体。
400	资源未找到。
500	maos接口调用异常。

错误码

请参见[错误码](#)。

7.9.2 查看自动扩缩容策略

功能介绍

本接口用于在已部署的服务上查看自动扩缩容策略。调用此接口前，确保服务已成功部署并获取了有效的服务ID。查询成功后，返回服务对应的策略信息，如规则ID，规则名称，扩缩容类型，扩缩容状态，扩缩容cron表达式，目标实例数等。如果提供的服务ID无效、参数配置错误或系统资源不足，将返回相应的异常信息，提示用户检查输入数据的有效性或联系技术支持。

URI

GET /v2/{project_id}/services/{service_id}/{group_id}/hpa

表 7-517 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
group_id	是	String	参数解释： 实例组ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务详情 获取当前服务的实例组ID，其中version内的instance_groups内的id字段即为实例组ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

请求参数

表 7-518 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： - application/json - application/json;charset=utf-8 默认取值： 不涉及。

响应参数

状态码：200

表 7-519 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 自动扩缩容策略ID 取值范围： 不涉及。
name	String	参数解释： 自动扩缩容策略名称 取值范围： 不涉及。
target_resource_id	String	参数解释： 自动扩缩容策略绑定的目标ID 取值范围： 实例组ID
target_resource_type	String	参数解释： 自动扩缩容策略绑定的目标类型。 取值范围： GROUP：实例组
status	String	参数解释： 自动扩缩容策略状态。 取值范围： - INACTIVE：不启用 - ACTIVE：配置成功 - DELETED：已删除
hpa_rules	Array of HpaRule objects	参数解释： 自动扩缩容规则列表
create_at	String	参数解释： 创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。

参数	参数类型	描述
update_at	String	参数解释： 更新时间，根据更新时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。

表 7-520 HpaRule

参数	参数类型	描述
id	String	参数解释： 自动扩缩容规则ID 取值范围： 不涉及。
hpa_id	String	参数解释： 自动扩缩容规则关联的策略ID 取值范围： 不涉及。
name	String	参数解释： 自动扩缩容规则名 取值范围： 支持4-64个字符，可以包含字母、汉字、数字、中划线和下划线。
type	String	参数解释： 自动扩缩容类型。 取值范围： CRON_HPA：定时扩缩容策略
schedule	String	参数解释： 定时自动扩缩容执行的cron表达式，不支持秒，从分钟开始设定 取值范围： 不涉及。
target_replicas	Integer	参数解释： 自动扩缩容目标实例数。 取值范围： 1-128

参数	参数类型	描述
disable	String	参数解释： 自动扩缩容规则是否启用。 取值范围： - false - true
status	String	参数解释： 自动扩缩容规则状态。 取值范围： - CREATING：创建中 - CONFIG_SUCCESS：配置成功 - EXECUTE_SUCCESS：执行成功 - DELETED：已删除 - FAILED: 执行失败

状态码：404

表 7-521 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

无

响应示例

状态码：200

查看自动扩缩容策略。

```
{
  "id" : "85b6562d-df8b-4fec-a646-a6c8fe348185",
  "name" : "hpa_test",
```



```
"type" : null,
"target_resource_id" : null,
"target_resource_type" : null,
"status" : "CRON_HPA",
"min_replicas" : 1,
"max_replicas" : 10,
"hpa_rules" : [ {
  "name" : "rule_test",
  "type" : "CRON_HPA",
  "status" : "CREATING",
  "schedule" : "string",
  "target_replicas" : 2,
  "disable" : false
}, {
  "name" : "rule_test1",
  "type" : "CRON_HPA",
  "status" : "CONFIG_SUCCESS",
  "schedule" : "string",
  "target_replicas" : 2,
  "disable" : false
} ],
"workspace_id" : 0
}
```

状态码

状态码	描述
200	查看自动扩缩容策略。
404	资源未找到。

错误码

请参见[错误码](#)。

7.9.3 删除自动扩缩容策略

功能介绍

本接口用于在已部署的服务上删除定时扩缩容策略。调用此接口前，确保服务已成功部署并获取了有效的服务ID，实例组ID。如果提供的服务ID无效、参数配置错误或系统资源不足，将返回相应的异常信息，提示用户检查输入数据的有效性或联系技术支持。暂时为非开放接口，使用后端清理服务下的自动扩缩容策略规则。

URI

DELETE /v2/{project_id}/services/{service_id}/{group_id}/hpa

表 7-522 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。
group_id	是	String	参数解释： 实例组ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务详情 获取当前服务的实例组ID，其中version内的instance_groups内的id字段即为实例组ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

请求参数

表 7-523 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： - application/json - application/json;charset=utf-8 默认取值： 不涉及。

响应参数

状态码：200

删除自动扩缩容策略。

状态码：404

表 7-524 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。

参数	参数类型	描述
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

无

响应示例

无

状态码

状态码	描述
200	删除自动扩缩容策略。
404	资源未找到。

错误码

请参见[错误码](#)。

7.9.4 修改自动扩缩容策略

功能介绍

本接口用于在已部署的服务上修改定时扩缩容策略，适用于需要在特定时间自动调整服务实例个数的场景。调用此接口前，确保服务已成功部署并获取了有效的服务ID，实例组ID，并提供详细的扩缩容策略参数，如扩缩容时间、实例个数范围、条件触发器等。修改成功后，系统将根据设定的策略自动调整服务实例个数，确保服务在指定时间内的性能和可用性。如果提供的服务ID无效、参数配置错误或系统资源不足，将返回相应的异常信息，提示用户检查输入数据的有效性或联系技术支持。

URI

PUT /v2/{project_id}/services/{service_id}/{group_id}/hpa

表 7-525 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。
group_id	是	String	参数解释： 实例组ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务详情 获取当前服务的实例组ID，其中version内的instance_groups内的id字段即为实例组ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

请求参数

表 7-526 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json • application/json;charset=utf-8 默认取值： 不涉及。

表 7-527 请求 Body 参数

参数	是否必选	参数类型	描述
id	是	String	参数解释： 自动扩缩容策略绑定的目标ID 取值范围： 实例组ID 约束限制： 不涉及。 默认取值： 不涉及。
hpa_rules	否	Array of HpaRules objects	参数解释： 自动扩缩容规则。 约束限制： 目前仅支持修改一条规则。

表 7-528 HpaRules

参数	是否必选	参数类型	描述
name	否	String	参数解释： 自动扩缩容name 取值范围： 支持4-64个字符，可以包含字母、汉字、数字、中划线和下划线。 约束限制： 不涉及。 默认取值： 不涉及。
id	否	String	参数解释： 自动扩缩容id 取值范围： 支持4-64个字符，可以包含字母、汉字、数字、中划线和下划线。 约束限制： 不涉及。 默认取值： 不涉及。
disable	否	Boolean	参数解释： 自动扩缩容规则是否启用。 取值范围： ● false：启动 ● true：不启动 约束限制： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
type	是	String	参数解释： 自动扩缩容类型。 取值范围： • CRON_HPA：定时扩缩容策略 约束限制： 不涉及。 默认取值： 不涉及。
status	否	String	参数解释： 自动扩缩容类型。 取值范围： • CREATING：创建扩缩容策略 • CONFIG_SUCCESS：配置成功扩缩容策略 • EXECUTE_SUCCESS：执行成功扩缩容策略 • DELETED：删除扩缩容策略 • FAILED：失败扩缩容策略 约束限制： 不涉及。 默认取值： 不涉及。
operate	否	String	参数解释： 自动扩缩容类型，兼容大小写。 取值范围： • ADD：添加扩缩容策略规则 • UPDATE：修改扩缩容策略规则 • DELETE：删除扩缩容策略规则 约束限制： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
schedule	是	String	参数解释： 定时自动扩缩容执行的cron表达式，不支持秒，从分钟开始设定 取值范围： 不涉及。 约束限制： 不涉及。 默认取值： 不涉及。
target_replicas	是	Integer	参数解释： 自动扩缩容目标实例数。 取值范围： 1-128 约束限制： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 7-529 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 自动扩缩容策略ID 取值范围： 不涉及。
name	String	参数解释： 自动扩缩容策略名称 取值范围： 不涉及。
target_resource_id	String	参数解释： 自动扩缩容策略绑定的目标ID 取值范围： 实例组ID

参数	参数类型	描述
target_resource_type	String	参数解释： 自动扩缩容策略绑定的目标类型。 取值范围： GROUP：实例组
status	String	参数解释： 自动扩缩容策略状态。 取值范围： - INACTIVE：不启用 - ACTIVE：配置成功 - DELETED：已删除
hpa_rules	Array of HpaRule objects	参数解释： 自动扩缩容规则列表
create_at	String	参数解释： 创建时间，根据创建时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。
update_at	String	参数解释： 更新时间，根据更新时的当前时间自动生成。 取值范围： 毫秒级时间戳，13位数字，如1609459200000。

表 7-530 HpaRule

参数	参数类型	描述
id	String	参数解释： 自动扩缩容规则ID 取值范围： 不涉及。
hpa_id	String	参数解释： 自动扩缩容规则关联的策略ID 取值范围： 不涉及。

参数	参数类型	描述
name	String	参数解释： 自动扩缩容规则名 取值范围： 支持4-64个字符，可以包含字母、汉字、数字、中划线和下划线。
type	String	参数解释： 自动扩缩容类型。 取值范围： CRON_HPA：定时扩缩容策略
schedule	String	参数解释： 定时自动扩缩容执行的cron表达式，不支持秒，从分钟开始设定 取值范围： 不涉及。
target_replicas	Integer	参数解释： 自动扩缩容目标实例数。 取值范围： 1-128
disable	String	参数解释： 自动扩缩容规则是否启用。 取值范围： - false - true
status	String	参数解释： 自动扩缩容规则状态。 取值范围： - CREATING：创建中 - CONFIG_SUCCESS：配置成功 - EXECUTE_SUCCESS：执行成功 - DELETED：已删除 - FAILED：执行失败

状态码：400

表 7-531 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-532 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

- "operate":"ADD" 用于添加规则；确保schedule是不重复的。

```
{{request_url}}/v2/{{project_id}}/services/{{service_id}}/{{group_id}}/hpa
{
  "id": "8a927efb-07bd-48fc-8261-a3f79fb02199",
  "hpa_rules": [ {
    "disable": false,
    "name": "test-rule3",
    "schedule": "38 10 * * ?",
    "target_replicas": 3,
    "type": "CRON_HPA",
    "operate": "ADD"
  } ]
}
```
- "operate":"UPDATE" 用于修改规则；确保hpa_rules中的id是切实存在的规则id；确保schedule是不重复的。

```
{{request_url}}/v2/{{project_id}}/services/{{service_id}}/{{group_id}}/hpa
```

```
{
  "id": "8a927efb-07bd-48fc-8261-a3f79fb02199",
  "hpa_rules": [ {
    "disable": false,
    "id": "accba651-d3fd-4434-8254-61d30e9e1b45",
    "name": "test-rule3",
    "schedule": "38 10 * * ?",
    "target_replicas": 3,
    "type": "CRON_HPA",
    "operate": "UPDATE"
  } ]
}
```

- "operate": "DELETE" 用于删除规则；确保hpa_rules中的id是切实存在的规则id。

{{request_url}}/v2/{{project_id}}/services/{{service_id}}/{{group_id}}/hpa

```
{
  "id": "8a927efb-07bd-48fc-8261-a3f79fb02199",
  "hpa_rules": [ {
    "disable": false,
    "id": "accba651-d3fd-4434-8254-61d30e9e1b45",
    "name": "test-rule3",
    "schedule": "38 10 * * ?",
    "target_replicas": 3,
    "type": "CRON_HPA",
    "operate": "DELETE"
  } ]
}
```

响应示例

状态码：200

修改自动扩缩容策略。

```
{
  "hpa_rules": [ {
    "disable": true,
    "hpa_id": "8521e55e-219f-4769-8a2f-08a78c02182e",
    "id": "accba651-d3fd-4434-8254-61d30e9e1b45",
    "name": "test-rule2",
    "schedule": "0 0 * * ?",
    "status": "CREATING",
    "target_replicas": 1,
    "type": "CRON_HPA"
  }, {
    "disable": false,
    "hpa_id": "8521e55e-219f-4769-8a2f-08a78c02182e",
    "id": "7447626f-6c94-4ad7-a527-d3fa04706788",
    "name": "test-rule3",
    "schedule": "38 10 * * ?",
    "status": "CREATING",
    "target_replicas": 3,
    "type": "CRON_HPA"
  } ],
  "id": "8521e55e-219f-4769-8a2f-08a78c02182e",
  "name": "cron-hpa-8a927efb-2e23-42e5-92ea-de86b4aba750",
  "status": "ACTIVE",
  "target_resource_id": "8a927efb-2e23-42e5-92ea-de86b4aba750",
  "target_resource_type": "GROUP",
  "type": "CRON_HPA"
}
```

状态码

状态码	描述
200	修改自动扩缩容策略。
400	请求参数不合法。
404	资源未找到。

错误码

请参见[错误码](#)。

7.9.5 查看自动扩缩容策略事件

功能介绍

本接口用于在已部署的服务上查看自动扩缩容策略事件，适用于查看自动扩缩容策略变动历史记录。调用此接口前，确保获取了有效的用户项目ID，服务ID，实例组ID。调用成功后，会返回策略事件ID，事件状态，规则执行信息，扩缩容前实例数，扩缩容后实例数，预设目标实例数，执行记录时间。如果提供的服务ID无效、参数配置错误或系统资源不足，将返回相应的异常信息，提示用户检查输入数据的有效性或联系技术支持。

URI

GET /v2/{project_id}/services/{service_id}/{group_id}/hpa/events

表 7-533 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 账号的资源空间ID。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
service_id	是	String	参数解释： 服务ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务列表 获取当前用户拥有的服务，其中service_id字段即为服务ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。
group_id	是	String	参数解释： 实例组ID，在 创建服务 时即可在返回体中获取，也可通过 查询服务详情 获取当前服务的实例组ID，其中version内的instance_groups内的id字段即为实例组ID。 约束限制： 不涉及。 取值范围： 服务ID。 默认取值： 不涉及。

表 7-534 Query 参数

参数	是否必选	参数类型	描述
limit	否	Integer	参数解释： 指定返回的最大条目数。 约束限制： 不涉及。 取值范围： [1,500] 默认取值： 10。

参数	是否必选	参数类型	描述
offset	否	Integer	参数解释： 分页列表查询的偏移量。 约束限制： offset必须是limit的整数倍。 取值范围： 不涉及。 默认取值： 0。
sort_key	否	String	参数解释： 排序字段，多个字段以","分隔，支持create_at, update_at，默认值update_at。 约束限制： 不涉及。 取值范围： - lastProbeTime：按照执行记录事件排序。 - status：按状态排序。 默认取值： update_at。
sort_dir	否	String	参数解释： 排序方式。 约束限制： 不涉及。 取值范围： - ASC: 递增排序。 - DESC: 递减排序。 默认取值： DESC。

请求参数

表 7-535 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。获取方法请参见 获取Token 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 消息体的类型（格式）。 约束限制： 不涉及。 取值范围： • application/json • application/json;charset=utf-8 默认取值： 不涉及。

响应参数

状态码：200

表 7-536 响应 Body 参数

参数	参数类型	描述
current	Integer	参数解释： 当前页。 取值范围： 不涉及。
pages	Integer	参数解释： 总页数。 取值范围： 不涉及。

参数	参数类型	描述
size	Integer	参数解释： 每一页的数量。 取值范围： 不涉及。
total	Integer	参数解释： 总记录数。 取值范围： 不涉及。
data	Array of HpaEventResponse objects	参数解释： 服务事件列表。

表 7-537 HpaEventResponse

参数	参数类型	描述
id	String	参数解释： 自动扩缩容策略事件ID 取值范围： 事件ID
status	String	参数解释： 自动扩缩容事件状态。 取值范围： • SUCCESS: 成功 • FAILED: 失败
message	String	参数解释： 自动扩缩容规则执行信息。 取值范围： 不涉及
current_replicas	Integer	参数解释： 扩缩容前实例数。 取值范围： 不涉及。
target_replicas	Integer	参数解释： 预设目标实例数。 取值范围： 不涉及。

参数	参数类型	描述
final_replicas	Integer	参数解释： 扩缩容后实例数。 取值范围： 不涉及。
record_time	String	参数解释： 执行记录时间。 取值范围： 2025-05-20 10:05:55

状态码：400

表 7-538 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

状态码：404

表 7-539 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： ModelArts错误码。 取值范围： 不涉及。
error_msg	String	参数解释： 具体错误信息。 取值范围： 不涉及。

请求示例

无

响应示例

状态码：200
查看自动扩缩容策略事件。

```
{
  "current" : 0,
  "data" : [ {
    "id" : "58865106-c6c6-427a-9e0b-1c9e3f5bac4f",
    "hpa_id" : "1d7812a3-0032-4f7a-bf31-87849ed41577",
    "status" : "SUCCESS",
    "message" : "scale target replicas success, current replicas:1, target replicas:2, final replicas:2",
    "current_replicas" : 1,
    "target_replicas" : 2,
    "final_replicas" : 2,
    "record_time" : "2025-05-20 01:11:14"
  }, {
    "id" : "85b6562d-df8b-4fec-a646-a6c8fe348185",
    "hpa_id" : "8e767bd5-ca5d-4e2f-af33-f944f15f1602",
    "status" : "SUCCESS",
    "message" : "skip scale target replicas, current replicas:2, target replicas:2, final replicas:2",
    "current_replicas" : 2,
    "target_replicas" : 2,
    "final_replicas" : 2,
    "record_time" : "2025-05-19 01:11:14"
  } ],
  "pages" : 1,
  "size" : 10,
  "total" : 2
}
```

状态码

状态码	描述
200	查看自动扩缩容策略事件。
400	请求参数不合法。
404	资源未找到。

错误码

请参见[错误码](#)。

8 服务作业管理（旧版推理）

8.1 创建服务作业

功能介绍

该接口用于创建服务作业，仅支持边缘资源池，不支持边缘节点。说明：Endpoint通过在线服务详情界面>调用指南页签查看。

URI

POST /v1/{project_id}/services/{service_id}/tasks

表 8-1 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。
service_id	是	String	服务ID。

请求参数

表 8-2 请求 Body 参数

参数	是否必选	参数类型	描述
name	是	String	作业的名称。仅能包含汉字、字母、数字、中划线和下划线，长度介于1~100之间。 注：ModelArts Edge作业名称不能包含汉字。

参数	是否必选	参数类型	描述
description	否	String	作业的描述。长度不超过500。 最小长度：0 最大长度：500
input	是	TaskInput object	作业的输入配置。
output	是	TaskOutput object	作业的输出配置，至少需要配置一项输出方式。
config	否	TaskConfig object	作业运行时指定的算法配置参数，部分服务需填且必填。
schedule	否	ScheduleParams object	定时任务参数。
source_usage_estimate	是	SourceUsageEstimate object	分配给每个作业的计算资源。仅 ModelArts Edge需要配此参数。

表 8-3 TaskInput

参数	是否必选	参数类型	描述
type	是	String	作业的输入类型。可选类型有 obs（对象存储服务桶或者并行文件系统存储的文件），url（指定的文件地址或流地址），restful（从自定义的流媒体服务器通过Restful接口获取流地址），vcn（VCN设备），edgecamera（IEF边缘摄像头）。 枚举值： • obs（ModelArts Edge不支持此输入） • url • restful • vcn（ModelArts Edge不支持此输入） • edgecamera
data	是	Array of TaskInputData objects	作业的输入详情。针对不同的输入类型有不同的配置。创建时允许填写多路输入，但更新时只允许填写一路输入。

参数	是否必选	参数类型	描述
vcn	否	TaskInputVcn object	VCN服务器信息，仅输入类型为VCN时需填且必填。

表 8-4 TaskInputData

参数	是否必选	参数类型	描述
bucket	否	String	OBS桶名，当输入为OBS类型时必填。 最大长度：63
path	否	String	OBS的路径，当输入为OBS类型时必填。 最大长度：1023
url	否	String	url输入源的地址或者获取视频流地址的Restful请求地址。当输入为url类型或者restful类型时必填。 最大长度：1000
headers	否	Object	获取视频流地址的restful请求携带的请求头。当输入为restful类型时可选。整体呈json格式，以键值对的形式表示请求头和取值，最多允许10组。
certificate_check	否	Boolean	是否需要对https请求进行证书校验。当输入为restful类型时必填。取值为true或者false。
rtsp_path_in_response	否	String	restful请求返回的body中，视频流地址的路径。当输入为restful类型时必填。 最大长度：1024
device_id	否	String	VCN设备ID，当输入为VCN类型时必填。
stream_type	否	Integer	准备进行分析的码流，当输入为VCN类型时选填。取值范围为1~3，其中1代表主码流，2代表辅码流1，3代表辅码流2。 最小值：1 最大值：3

表 8-5 TaskInputVcn

参数	是否必选	参数类型	描述
ip	是	String	VCN服务器的IP地址，仅输入类型为VCN时需填且必填。
port	是	Integer	VCN服务器的端口号，仅输入类型为VCN时需填且必填。 最小值：0 最大值：65535
username	是	String	VCN服务器的账号名，仅输入类型为VCN时需填且必填。
password	是	String	VCN服务器的与账号对应的密码，仅输入类型为VCN时需填且必填。
vcn_protocol	否	String	VCN服务器的协议，可选值为sdk、restful，默认值为sdk。

表 8-6 TaskOutput

参数	是否必选	参数类型	描述
obs	否	TaskOutputObs object	输出为OBS类型时的配置信息。 注：ModelArts Edge不支持此输出。
webhook	否	TaskOutputWebhook object	输出为Webhook类型时的配置信息。

表 8-7 TaskOutputObs

参数	是否必选	参数类型	描述
bucket	是	String	OBS桶名，选用OBS类型输出时必填。
path	是	String	OBS的路径，选用OBS类型输出时必填。

表 8-8 TaskOutputWebhook

参数	是否必选	参数类型	描述
url	是	String	结果回调地址，选用Webhook类型输出时必填。 最大长度：1000
headers	是	Object	结果回调时需要携带的请求头，选用Webhook类型输出时必填。整体呈json格式，以键值对的形式表示请求头和取值，至少1组，至多10组。

表 8-9 TaskConfig

参数	是否必选	参数类型	描述
common	否	Object	作业运行时指定的具体的算法配置项，部分服务需填且必填。整体呈json格式，具体配置项参见相应算法服务的说明。

表 8-10 ScheduleParams

参数	是否必选	参数类型	描述
type	是	String	计划任务的类型，使用计划任务时必填。可选类型分别为ONCE（仅执行一次），DAILY（每日执行），WEEKLY（每周执行），MONTHLY（每月执行） 枚举值： ONCE, DAILY, WEEKLY, MONTHLY 说明 ModelArts Edge计划任务只支持ONCE（仅执行一次），DAILY（每日执行）。
timezone	是	String	用户所处的时区，使用计划任务时必填。精确到分钟
days_of_week	否	Array of integers	作业会在一周的哪几天执行，当且仅当计划任务类型为WEEKLY时，该字段需填且必填。1~7分别指代星期一至星期日。

参数	是否必选	参数类型	描述
days_of_month	否	Array of integers	作业会在一个月的哪几天执行，当且仅当计划任务类型为MONTHLY时，该字段需填且必填。1~31分别指代一个月中的1日至31日。
execution_mode	是	String	任务执行模式。 • PERIOD：按时间段 • FREQUENCY：按频率（ModelArts Edge不支持此模式）
periods	否	Array of Period objects	execution_mode为PERIOD时必填，数组大小至少为1
frequency	否	Frequency object	execution_mode为FREQUENCY时必填

表 8-11 Period

参数	是否必选	参数类型	描述
begin_at	是	String	单个时间段执行的起始时间，和end_at需成对出现。计划任务类型为ONCE时，格式为yyyy-MM-ddThh:mm:ss，其余计划任务类型时，格式为hh:mm:ss。
end_at	是	String	单个时间段执行的结束时间，和begin_at需成对出现。计划任务类型为ONCE时，格式为yyyy-MM-ddThh:mm:ss，其余计划任务类型时，格式为hh:mm:ss。

表 8-12 Frequency

参数	是否必选	参数类型	描述
interval	是	Integer	相邻两次执行之间的间隔，频率模式必填。取值范围在5~720之间，单位：分钟 最小值：5 最大值：720

参数	是否必选	参数类型	描述
duration	是	Integer	单次执行的运行时长，频率模式必填。取值范围在5~720之间，单位：分钟。 最小值：5 最大值：720
begin_at	否	String	单日内执行的起始时间，选填。格式形如hh:mm:ss。
end_at	否	String	单日内执行的结束时间，选填。格式形如hh:mm:ss。

表 8-13 SourceUsageEstimate

参数	是否必选	参数类型	描述
cpu	是	Float	分配给每个作业的cpu核数计算资源。
memory	是	Float	分配给每个作业的内存大小计算资源。

响应参数

状态码： 201

表 8-14 响应 Body 参数

参数	参数类型	描述
tasks	Array of CreateResponseBody objects	创建作业响应信息。

表 8-15 CreateResponseBody

参数	参数类型	描述
id	String	创建出的服务作业ID。

状态码： 400

表 8-16 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

状态码： 404

表 8-17 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

请求示例

无

响应示例

状态码： 201

创建服务作业成功。

```
{
  "tasks": [ {
    "id": "53e4xxxxxxxxxxxxxxxxxxxxxb55b3e"
  } ]
}
```

状态码： 400

请求不合法。

```
{
  "error_code": "ModelArts.0101",
  "error_msg": "The request param is invalid. The field [input] is required and cannot be empty."
}
```

状态码： 404

指定的服务不存在。

```
{
  "error_code": "ModelArts.3502",
  "error_msg": "The requested resource is NOT found. Service face-detect/1.0 not found."
}
```

状态码

状态码	描述
201	创建服务作业成功。
400	请求不合法。
404	指定的服务不存在。

错误码

请参见[错误码](#)。

8.2 获取服务作业列表

功能介绍

该接口用于获取服务作业列表，仅支持边缘资源池，不支持边缘节点。说明：
Endpoint通过在线服务详情界面>调用指南页签查看。

URI

GET /v1/{project_id}/services/{service_id}/tasks

表 8-18 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。
service_id	是	String	服务ID。

表 8-19 Query 参数

参数	是否必选	参数类型	描述
id	否	String	作业ID。

参数	是否必选	参数类型	描述
state	否	String	目标服务作业的状态。 枚举值： • PENDING：等待中 • RECOVERING：恢复中（IEF状态，ModelArts Edge无此状态） • CREATE_FAILED：创建失败（IEF状态，ModelArts Edge无此状态） • RUNNING：运行中 • UPGRADING：升级中（IEF状态，ModelArts Edge无此状态） • ABNORMAL：运行异常（IEF状态，ModelArts Edge无此状态） • SUCCEEDED：运行成功 • FAILED：运行失败 • STARTING：启动中（IEF状态，ModelArts Edge无此状态） • START_FAILED：启动失败（IEF状态，ModelArts Edge无此状态） • STOPPING：停止中（IEF状态，ModelArts Edge无此状态） • STOPPED：已停止（IEF状态，ModelArts Edge无此状态） • DELETING：删除中（IEF状态，ModelArts Edge无此状态）
name_like	否	String	目标服务作业的名称，支持模糊匹配。
alg_type	否	String	算法类型，仅支持CLOUD。
created_since	否	Long	目标服务作业的创建起始时间。
created_until	否	Long	目标服务作业的创建截止时间。

参数	是否必选	参数类型	描述
sort_key	否	String	展示服务作业时的排序字段，分别为name（按名称排序），created_at（按创建时间排序），updated_at（按更新时间排序）。 缺省值：created_at 枚举值： - name - created_at - updated_at
sort_dir	否	String	展示服务作业时的排序规则，分别为ASC（升序），DESC（降序）。 缺省值：DESC 枚举值： - ASC - DESC
offset	否	Integer	首个展示的服务作业的偏移量。 最小值：0 最大值：100000 缺省值：0
limit	否	Integer	展示服务作业的数量。 最小值：1 最大值：1000 缺省值：100
workspace_id	否	String	工作空间ID。

请求参数

无

响应参数

状态码： 200

表 8-20 响应 Body 参数

参数	参数类型	描述
count	Long	符合检索条件的总条目数。

参数	参数类型	描述
tasks	Array of TaskDetails objects	检索到的服务作业条目。

表 8-21 TaskDetails

参数	参数类型	描述
id	String	作业ID。
name	String	作业的名称。
creator	String	作业创建者的用户名。注：ModelArts Edge此字段为空。
project_id	String	作业创建者的资源空间ID。
description	String	作业的描述。 最小长度：0 最大长度：500
service_name	String	作业对应服务的名称。 最小长度：2 最大长度：100
service_id	String	服务ID。
created_at	String	作业创建的时间。
updated_at	String	作业最近一次状态更新的时间。

参数	参数类型	描述
state	String	作业当前的状态。 枚举值： • PENDING：等待中 • RECOVERING：恢复中（ModelArts Edge无此状态） • CREATE_FAILED：创建失败 • RUNNING：运行中 • UPGRADING：升级中（ModelArts Edge无此状态） • ABNORMAL：运行异常（ModelArts Edge无此状态） • SUCCEEDED：运行成功 • FAILED：运行失败 • STARTING：启动中（ModelArts Edge无此状态） • START_FAILED：启动失败（ModelArts Edge无此状态） • STOPPING：停止中（ModelArts Edge无此状态） • STOPPED：已停止（ModelArts Edge无此状态） • DELETING：删除中（ModelArts Edge无此状态）
status	String	作业状态的详情信息，仅部分状态会有详情信息。 最小长度：0 最大长度：4096
error	表8-22 object	作业运行失败时收集到的错误信息。
input	TaskInput object	作业 <input/> 的输入配置。
output	TaskOutputForDisplay object	作业的输出配置展示。
config	TaskConfig object	作业运行时指定的算法配置参数，部分服务需填且必填。
schedule	ScheduleParams object	计划作业参数。
schedule_status	String	定时策略状态。

参数	参数类型	描述
source_usage_estimate	SourceUsageEstimate object	分配给每个作业的计算资源。仅ModelArts Edge需要配此参数。
alg_instance_id	String	实例ID。注：ModelArts Edge此字段为空。

表 8-22 Error

参数	参数类型	描述
code	String	算法服务定义的错误码。
message	String	算法服务反馈的错误信息。

表 8-23 TaskInput

参数	参数类型	描述
type	String	作业的输入类型。可选类型有obs（对象存储服务桶或者并行文件系统存储的文件），url（指定的文件地址或流地址），restful（从自定义的流媒体服务器通过Restful接口获取流地址），vcn（VCN设备）。 枚举值： - obs（ModelArts Edge不支持此输入） - url - restful - vcn（ModelArts Edge不支持此输入）
data	Array of TaskInputData objects	作业的输入详情。针对不同的输入类型有不同的配置。创建时允许填写多路输入，但更新时只允许填写一路输入。
vcn	TaskInputVcn object	VCN服务器信息，仅输入类型为VCN时需填且必填。

表 8-24 TaskInputData

参数	参数类型	描述
bucket	String	OBS桶名，当输入为OBS类型时必填。 最大长度：63

参数	参数类型	描述
path	String	OBS的路径，当输入为OBS类型时必填。 最大长度：1023
url	String	url输入源的地址或者获取视频流地址的Restful请求地址。当输入为url类型或者restful类型时必填。 最大长度：1000
headers	Object	获取视频流地址的restful请求携带的请求头。当输入为restful类型时可选。整体呈json格式，以键值对的形式表示请求头和取值，最多允许10组。
certificate_check	Boolean	是否需要https请求进行证书校验。当输入为restful类型时必填。取值为true或者false。
rtsp_path_in_response	String	restful请求返回的body中，视频流地址的路径。当输入为restful类型时必填。 最大长度： 1024
device_id	String	VCN设备ID，当输入为VCN类型时必填。
stream_type	Integer	准备进行分析的码流，当输入为VCN类型时选填。取值范围为1~3，其中1代表主码流，2代表子码流1，3代表子码流2。 最小值：1 最大值：3

表 8-25 TaskInputVcn

参数	参数类型	描述
ip	String	VCN服务器的IP地址，仅输入类型为VCN时需填且必填。
port	Integer	VCN服务器的端口号，仅输入类型为VCN时需填且必填。 最小值：0 最大值：65535
username	String	VCN服务器的账号名，仅输入类型为VCN时需填且必填。
password	String	VCN服务器的与账号对应的密码，仅输入类型为VCN时需填且必填。

表 8-26 TaskOutputForDisplay

参数	参数类型	描述
obs	TaskOutputObs object	输出为OBS类型时的配置信息。注：ModelArts Edge不支持OBS输出
webhook	TaskOutputWebhook object	输出为Webhook类型时的配置信息。

表 8-27 TaskOutputObs

参数	参数类型	描述
bucket	String	OBS桶名，选用OBS类型输出时必填。
path	String	OBS的路径，选用OBS类型输出时必填。

表 8-28 TaskOutputWebhook

参数	参数类型	描述
url	String	结果回调地址，选用Webhook类型输出时必填。 最大长度：1000
headers	Object	结果回调时需要携带的请求头，选用Webhook类型输出时必填。整体呈json格式，以键值对的形式表示请求头和取值，至少1组，至多10组。

表 8-29 TaskConfig

参数	参数类型	描述
common	Object	作业运行时指定的具体的算法配置项，部分服务需填且必填。整体呈json格式，具体配置项参见相应算法服务的说明。

表 8-30 ScheduleParams

参数	参数类型	描述
type	String	计划任务的类型，使用计划任务时必填。可选类型分别为ONCE（仅执行一次），DAILY（每日执行），WEEKLY（每周执行），MONTHLY（每月执行） 枚举值： ONCE, DAILY, WEEKLY, MONTHLY 说明 ModelArts Edge计划任务只支持ONCE（仅执行一次），DAILY（每日执行）。
timezone	String	用户所处的时区，使用计划任务时必填。精确到分钟
days_of_week	Array of integers	作业会在一周的哪几天执行，当且仅当计划任务类型为WEEKLY时，该字段需填且必填。1~7分别指代星期一至星期日。
days_of_month	Array of integers	作业会在一个月的哪几天执行，当且仅当计划任务类型为MONTHLY时，该字段需填且必填。1~31分别指代一个月中的1日至31日。
execution_mode	String	任务执行模式。 - PERIOD：按时间段 - FREQUENCY：按频率（ModelArts Edge不支持此模式）
periods	Array of Period objects	execution_mode为PERIOD时必填，数组大小至少为1
frequency	Frequency object	execution_mode为FREQUENCY时必填

表 8-31 Period

参数	参数类型	描述
begin_at	String	单个时间段执行的起始时间，和end_at需成对出现。计划任务类型为ONCE时，格式为yyyy-MM-ddThh:mm:ss，其余计划任务类型时，格式为hh:mm:ss。
end_at	String	单个时间段执行的结束时间，和begin_at需成对出现。计划任务类型为ONCE时，格式为yyyy-MM-ddThh:mm:ss，其余计划任务类型时，格式为hh:mm:ss。

表 8-32 Frequency

参数	参数类型	描述
interval	Integer	相邻两次执行之间的间隔，频率模式必填。取值范围在5~720之间，单位：分钟 最小值：5 最大值：720
duration	Integer	单次执行的运行时长，频率模式必填。取值范围在5~720之间，单位：分钟。 最小值：5 最大值：720
begin_at	String	单日内执行的起始时间，选填。格式形如 hh:mm:ss。
end_at	String	单日内执行的结束时间，选填。格式形如 hh:mm:ss。

表 8-33 SourceUsageEstimate

参数	参数类型	描述
cpu	Float	分配给每个作业的cpu核数计算资源。
memory	Float	分配给每个作业的内存大小计算资源。

状态码： 400

表 8-34 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

状态码： 404

表 8-35 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

请求示例

无

响应示例

状态码： 200

获取服务作业列表成功。

```
{
  "count": 1,
  "tasks": [ {
    "id": "53e4xxxxxxxxxxxxxxxxxb55b3e",
    "name": "task-test",
    "creator": "user_test",
    "project_id": "b722xxxxxxxxxxxxxxxxxb4674",
    "description": "hello world",
    "service_name": "face-detect",
    "service_id": "88bbxxx-xxxx-xxxx-xxxx-xxxxxxxbcfe",
    "alg_instance_id": "42a4xxxxxxxxxxxxxxxxxb44b2a",
    "created_at": "2021-01-01T00:00:00Z",
    "updated_at": "2021-01-01T00:00:10Z",
    "state": "RUNNING",
    "input": {
      "type": "url",
      "data": [ {
        "url": "http://xxx"
      } ]
    },
    "output": {
      "obs": {
        "bucket": "obs-modelarts",
        "path": "output/"
      }
    },
    "config": {
      "common": {
        "image_compression_ratio": 90,
        "render_result_sw": 0,
        "video_sampling_interval": 1
      }
    }
  } ]
}
```

状态码： 400

请求不合法。

```
{
  "error_code": "ModelArts.0101",
  "error_msg": "The request param is invalid. The param [state] should be one of [PENDING, RECOVERING, CREATE_FAILED, RUNNING, ABNORMAL, SUCCEEDED, FAILED, DELETING]"
}
```

状态码： 404

指定的服务不存在。

```
{
  "error_code": "ModelArts.3502",
  "error_msg": "The requested resource is NOT found. Service face-detect not found."
}
```

状态码

状态码	描述
200	获取服务作业列表成功。
400	请求不合法。
404	指定的服务不存在。

错误码

请参见[错误码](#)。

8.3 查询服务作业

功能介绍

该接口用于查询服务作业，仅支持边缘资源池，不支持边缘节点。说明：Endpoint通过在线服务详情界面>调用指南页签查看。

URI

GET /v1/{project_id}/services/{service_id}/tasks/{task_id}

表 8-36 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。
service_id	是	String	服务ID。
task_id	是	String	指定的服务作业ID。

请求参数

无

响应参数

状态码： 200

表 8-37 响应 Body 参数

参数	参数类型	描述
id	String	作业ID。

参数	参数类型	描述
name	String	作业的名称。
creator	String	作业创建者的用户名。ModelArts Edge此字段为空。
project_id	String	作业创建者的资源空间ID。
description	String	作业的描述。 最小长度：0 最大长度：500
service_name	String	作业对应服务的名称。 最小长度：2 最大长度：100
service_id	String	服务ID。
created_at	String	作业创建的时间。
updated_at	String	作业最近一次状态更新的时间。
state	String	作业当前的状态。 枚举值： • PENDING：等待中 • RECOVERING：恢复中（ModelArts Edge无此状态） • CREATE_FAILED：创建失败（ModelArts Edge无此状态） • RUNNING：运行中 • UPGRADING：升级中（ModelArts Edge无此状态） • ABNORMAL：运行异常（ModelArts Edge无此状态） • SUCCEEDED：运行成功 • FAILED：运行失败 • STARTING：启动中（ModelArts Edge无此状态） • START_FAILED：启动失败（ModelArts Edge无此状态） • STOPPING：停止中（ModelArts Edge无此状态） • STOPPED：已停止（ModelArts Edge无此状态） • DELETING：删除中（ModelArts Edge无此状态）

参数	参数类型	描述
status	String	作业状态的详情信息，仅部分状态会有详情信息。 最小长度：0 最大长度：4096
error	表8-38 object	作业运行失败时收集到的错误信息。
input	TaskInput object	作业的输入配置。
output	TaskOutputForDisplay object	作业的输出配置展示。
config	TaskConfig object	作业运行时指定的算法配置参数，部分服务需填且必填。
schedule	ScheduleParams object	计划作业参数。
schedule_status	String	定时策略状态。
source_usage_estimate	SourceUsageEstimate object	分配给每个作业的计算资源。仅ModelArts Edge需要配此参数。
alg_instance_id	String	实例ID。注：ModelArts Edge此字段为空。
workspace_id	String	工作空间ID。

表 8-38 Error

参数	参数类型	描述
code	String	算法服务定义的错误码。
message	String	算法服务反馈的错误信息。

表 8-39 TaskInput

参数	参数类型	描述
type	String	作业的输入类型。可选类型有obs（对象存储服务桶或者并行文件系统存储的文件），url（指定的文件地址或流地址），restful（从自定义的流媒体服务器通过Restful接口获取流地址），vcn（VCN设备），edgecamera（IEF边缘摄像头）。 枚举值： • obs（ModelArts Edge不支持此输入） • url • restful • vcn（ModelArts Edge不支持此输入） • edgecamera
data	Array of TaskInputData objects	作业的输入详情。针对不同的输入类型有不同的配置。创建时允许填写多路输入，但更新时只允许填写一路输入。
vcn	TaskInputVcn object	VCN服务器信息，仅输入类型为VCN时需填且必填。

表 8-40 TaskInputData

参数	参数类型	描述
bucket	String	OBS桶名，当输入为OBS类型时必填。 最大长度：63
path	String	OBS的路径，当输入为OBS类型时必填。 最大长度：1023
url	String	url输入源的地址或者获取视频流地址的Restful请求地址。当输入为url类型或者restful类型时必填。 最大长度：1000
headers	Object	获取视频流地址的restful请求携带的请求头。当输入为restful类型时可选。整体呈json格式，以键值对的形式表示请求头和取值，最多允许10组。
certificate_check	Boolean	是否需要https请求进行证书校验。当输入为restful类型时必填。取值为true或者false。
rtsp_path_in_response	String	restful请求返回的body中，视频流地址的路径。当输入为restful类型时必填。 最大长度：1024

参数	参数类型	描述
device_id	String	VCN设备ID，当输入为VCN类型时必填。
stream_type	Integer	准备进行分析的码流，当输入为VCN类型时选填。取值范围为1~3，其中1代表主码流，2代表子码流1，3代表子码流2。 最小值：1 最大值：3

表 8-41 TaskInputVcn

参数	参数类型	描述
ip	String	VCN服务器的IP地址，仅输入类型为VCN时需填且必填。
port	Integer	VCN服务器的端口号，仅输入类型为VCN时需填且必填。 最小值：0 最大值：65535
username	String	VCN服务器的账号名，仅输入类型为VCN时需填且必填。
password	String	VCN服务器的与账号对应的密码，仅输入类型为VCN时需填且必填。

表 8-42 TaskOutputForDisplay

参数	参数类型	描述
obs	TaskOutputObs object	输出为OBS类型时的配置信息。注：ModelArts Edge不支持此输出
webhook	TaskOutputWebhook object	输出为Webhook类型时的配置信息。

表 8-43 TaskOutputObs

参数	参数类型	描述
bucket	String	OBS桶名，选用OBS类型输出时必填。
path	String	OBS的路径，选用OBS类型输出时必填。

表 8-44 TaskOutputWebhook

参数	参数类型	描述
url	String	结果回调地址，选用Webhook类型输出时必填。 最大长度：1000
headers	Object	结果回调时需要携带的请求头，选用Webhook类型输出时必填。整体呈json格式，以键值对的形式表示请求头和取值，至少1组，至多10组。

表 8-45 TaskConfig

参数	参数类型	描述
common	Object	作业运行时指定的具体的算法配置项，部分服务需填且必填。整体呈json格式，具体配置项参见相应算法服务的说明。

表 8-46 ScheduleParams

参数	参数类型	描述
type	String	计划任务的类型，使用计划任务时必填。可选类型分别为ONCE（仅执行一次），DAILY（每日执行），WEEKLY（每周执行），MONTHLY（每月执行） 枚举值： ONCE, DAILY, WEEKLY, MONTHLY 说明 ModelArts Edge计划任务只支持ONCE（仅执行一次），DAILY（每日执行）。
timezone	String	用户所处的时区，使用计划任务时必填。精确到分钟。
days_of_week	Array of integers	作业会在一周的哪几天执行，当且仅当计划任务类型为WEEKLY时，该字段需填且必填。1~7分别指代星期一至星期日。
days_of_month	Array of integers	作业会在一个月的哪几天执行，当且仅当计划任务类型为MONTHLY时，该字段需填且必填。1~31分别指代一个月中的1日至31日。
execution_mode	String	任务执行模式。 - PERIOD：按时间段 - FREQUENCY：按频率（ModelArts Edge不支持此模式）

参数	参数类型	描述
periods	Array of Period objects	execution_mode为PERIOD时必填，数组大小至少为1。
frequency	Frequency object	execution_mode为FREQUENCY时必填。

表 8-47 Period

参数	参数类型	描述
begin_at	String	单个时间段执行的起始时间，和end_at需成对出现。计划任务类型为ONCE时，格式为yyyy-MM-ddThh:mm:ss，其余计划任务类型时，格式为hh:mm:ss。
end_at	String	单个时间段执行的结束时间，和begin_at需成对出现。计划任务类型为ONCE时，格式为yyyy-MM-ddThh:mm:ss，其余计划任务类型时，格式为hh:mm:ss。

表 8-48 Frequency

参数	参数类型	描述
interval	Integer	相邻两次执行之间的间隔，频率模式必填。取值范围在5~720之间，单位：分钟。 最小值：5 最大值：720
duration	Integer	单次执行的运行时长，频率模式必填。取值范围在5~720之间，单位：分钟。 最小值：5 最大值：720
begin_at	String	单日内执行的起始时间，选填。格式形如hh:mm:ss。
end_at	String	单日内执行的结束时间，选填。格式形如hh:mm:ss。

表 8-49 SourceUsageEstimate

参数	参数类型	描述
cpu	Float	分配给每个作业的cpu核数计算资源。

参数	参数类型	描述
memory	Float	分配给每个作业的内存大小计算资源。

状态码： 400

表 8-50 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

状态码： 404

表 8-51 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

请求示例

无

响应示例

状态码： 200

获取服务作业信息成功。

```
{
  "id": "53e4xxxxxxxxxxxxxxxxxxxxb55b3e",
  "name": "task-test",
  "creator": "user_test",
  "project_id": "b722xxxxxxxxxxxxxxxxxxxxeb4674",
  "description": "hello world",
  "service_name": "face-detect",
  "service_id": "88bbxxx-xxxx-xxxx-xxxx-xxxxxxxxbcfe",
  "alg_instance_id": "42a4xxxxxxxxxxxxxxxxxxxxb44b2a",
  "created_at": "2021-01-01T00:00:00Z",
  "updated_at": "2021-01-01T00:00:10Z",
  "state": "RUNNING",
  "input": {
    "type": "url",
    "data": [ {
      "url": "http://xxx"
    } ]
  },
  "output": {
    "obs": {
```

```
{
  "bucket": "obs-modelarts",
  "path": "output/"
},
"config": {
  "common": {
    "image_compression_ratio": 90,
    "render_result_sw": 0,
    "video_sampling_interval": 1
  }
}
```

状态码： 400

请求不合法。

```
{
  "error_code": "ModelArts.0101",
  "error_msg": "The request param is invalid. parameter [task_id] does not match ^[0-9a-f]{32}task\\w{8}$."
}
```

状态码： 404

指定的服务不存在。

```
{
  "error_code": "ModelArts.3502",
  "error_msg": "The requested resource is NOT found. Service face-detect not found."
}
```

状态码

状态码	描述
200	获取服务作业信息成功。
400	请求不合法。
404	指定的服务不存在。

错误码

请参见[错误码](#)。

8.4 更新服务作业

功能介绍

该接口用于更新服务作业，仅支持边缘资源池，不支持边缘节点。说明：Endpoint通过在线服务详情界面>调用指南页签查看。

URI

PUT /v1/{project_id}/services/{service_id}/tasks/{task_id}

表 8-52 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
service_id	是	String	服务ID。
task_id	是	String	指定的服务作业ID。

请求参数

表 8-53 请求 Body 参数

参数	是否必选	参数类型	描述
name	否	String	作业的名称。仅能包含汉字、字母、数字、中划线和下划线，长度介于1~100之间。 注：ModelArts Edge作业名称不能包含汉字。
description	否	String	作业的描述。长度不超过500。 最小长度：0 最大长度：500
input	否	TaskInput object	作业的输入配置。
output	否	TaskOutput object	作业的输出配置，至少需要配置一项输出方式。
config	否	TaskConfig object	作业运行时指定的算法配置参数，部分服务需填且必填。
schedule	否	ScheduleParams object	定时任务参数。
source_usage_estimate	是	SourceUsageEstimate object	分配给每个作业的计算资源。仅ModelArts Edge需要配此参数。

表 8-54 TaskInput

参数	是否必选	参数类型	描述
type	是	String	作业的输入类型。可选类型有 obs（对象存储服务桶或者并行文件系统存储的文件），url（指定的文件地址或流地址），restful（从自定义的流媒体服务器通过Restful接口获取流地址），vcn（VCN设备），edgecamera（IEF边缘摄像头）。 枚举值： • obs（ModelArts Edge不支持此输入） • url • restful • vcn（ModelArts Edge不支持此输入） • edgecamera
data	是	Array of TaskInputData objects	作业的输入详情。针对不同的输入类型有不同的配置。创建时允许填写多路输入，但更新时只允许填写一路输入。
vcn	否	TaskInputVcn object	VCN服务器信息，仅输入类型为VCN时需填且必填。

表 8-55 TaskInputData

参数	是否必选	参数类型	描述
bucket	否	String	OBS桶名，当输入为OBS类型时必填。 最大长度：63
path	否	String	OBS的路径，当输入为OBS类型时必填。 最大长度：1023
url	否	String	url输入源的地址或者获取视频流地址的Restful请求地址。当输入为url类型或者restful类型时必填。 最大长度：1000

参数	是否必选	参数类型	描述
headers	否	Object	获取视频流地址的restful请求携带的请求头。当输入为restful类型时可选。整体呈json格式，以键值对的形式表示请求头和取值，最多允许10组。
certificate_check	否	Boolean	是否需要https请求进行证书校验。当输入为restful类型时必须填。取值为true或者false。
rtsp_path_in_response	否	String	restful请求返回的body中，视频流地址的路径。当输入为restful类型时必须填。 最大长度：1024
device_id	否	String	VCN设备ID，当输入为VCN类型时必须填。
stream_type	否	Integer	准备进行分析的码流，当输入为VCN类型时选填。取值范围为1~3，其中1代表主码流，2代表辅码流1，3代表辅码流2。 最小值：1 最大值：3

表 8-56 TaskInputVcn

参数	是否必选	参数类型	描述
ip	是	String	VCN服务器的IP地址，仅输入类型为VCN时需填且必填。
port	是	Integer	VCN服务器的端口号，仅输入类型为VCN时需填且必填。 最小值：0 最大值：65535
username	是	String	VCN服务器的账号名，仅输入类型为VCN时需填且必填。
password	是	String	VCN服务器的与账号对应的密码，仅输入类型为VCN时需填且必填。
vcn_protocol	否	String	VCN服务器的协议，可选值为sdk、restful，默认值为sdk。

表 8-57 TaskOutput

参数	是否必选	参数类型	描述
obs	否	TaskOutputObs object	输出为OBS类型时的配置信息。 注：ModelArts Edge不支持此输出。
webhook	否	TaskOutputWebhook object	输出为Webhook类型时的配置信息。

表 8-58 TaskOutputObs

参数	是否必选	参数类型	描述
bucket	是	String	OBS桶名，选用OBS类型输出时必须填。
path	是	String	OBS的路径，选用OBS类型输出时必须填。

表 8-59 TaskOutputWebhook

参数	是否必选	参数类型	描述
url	是	String	结果回调地址，选用Webhook类型输出时必须填。 最大长度：1000
headers	是	Object	结果回调时需要携带的请求头，选用Webhook类型输出时必须填。整体呈json格式，以键值对的形式表示请求头和取值，至少1组，至多10组。

表 8-60 TaskConfig

参数	是否必选	参数类型	描述
common	否	Object	作业运行时指定的具体的算法配置项，部分服务需填且必填。整体呈json格式，具体配置项参见相应算法服务的说明。

表 8-61 ScheduleParams

参数	是否必选	参数类型	描述
type	是	String	计划任务的类型，使用计划任务时必填。可选类型分别为ONCE（仅执行一次），DAILY（每日执行），WEEKLY（每周执行），MONTHLY（每月执行） 枚举值： ONCE, DAILY, WEEKLY, MONTHLY 说明 ModelArts Edge计划任务只支持ONCE（仅执行一次），DAILY（每日执行）。
timezone	是	String	用户所处的时区，使用计划任务时必填。精确到分钟
days_of_week	否	Array of integers	作业会在一周的哪几天执行，当且仅当计划任务类型为WEEKLY时，该字段需填且必填。1~7分别指代星期一至星期日。
days_of_month	否	Array of integers	作业会在一个月的哪几天执行，当且仅当计划任务类型为MONTHLY时，该字段需填且必填。1~31分别指代一个月中的1日至31日。
execution_mode	是	String	任务执行模式。 - PERIOD：按时间段 - FREQUENCY：按频率（ModelArts Edge不支持此模式）
periods	否	Array of Period objects	execution_mode为PERIOD时必填，数组大小至少为1
frequency	否	Frequency object	execution_mode为FREQUENCY时必填

表 8-62 Period

参数	是否必选	参数类型	描述
begin_at	是	String	单个时间段执行的起始时间，和 end_at 需成对出现。计划任务类型为 ONCE 时，格式为 yyyy-MM-ddThh:mm:ss，其余计划任务类型时，格式为 hh:mm:ss。
end_at	是	String	单个时间段执行的结束时间，和 begin_at 需成对出现。计划任务类型为 ONCE 时，格式为 yyyy-MM-ddThh:mm:ss，其余计划任务类型时，格式为 hh:mm:ss。

表 8-63 Frequency

参数	是否必选	参数类型	描述
interval	是	Integer	相邻两次执行之间的间隔，频率模式必填。取值范围在 5~720 之间，单位：分钟 最小值：5 最大值：720
duration	是	Integer	单次执行的运行时长，频率模式必填。取值范围在 5~720 之间，单位：分钟。 最小值：5 最大值：720
begin_at	否	String	单日内执行的起始时间，选填。格式形如 hh:mm:ss。
end_at	否	String	单日内执行的结束时间，选填。格式形如 hh:mm:ss。

表 8-64 SourceUsageEstimate

参数	是否必选	参数类型	描述
cpu	是	Float	分配给每个作业的 cpu 核数计算资源。
memory	是	Float	分配给每个作业的内存大小计算资源。

响应参数

状态码： 200

表 8-65 响应 Body 参数

参数	参数类型	描述
id	String	作业ID。
name	String	作业的名称。
creator	String	作业创建者的用户名。
project_id	String	作业创建者的资源空间ID。
description	String	作业的描述。 最小长度：0 最大长度：500
service_name	String	作业对应服务的名称。 最小长度：2 最大长度：100
service_id	String	服务ID。
created_at	String	作业创建的时间。
updated_at	String	作业最近一次状态更新的时间。
state	String	作业当前的状态。 枚举值： ● PENDING：等待中 ● RECOVERING：恢复中 ● CREATE_FAILED：创建失败 ● RUNNING：运行中 ● UPGRADING：升级中 ● ABNORMAL：运行异常 ● SUCCEEDED：运行成功 ● FAILED：运行失败 ● STARTING：启动中（ModelArts Edge无此状态） ● START_FAILED：启动失败（ModelArts Edge无此状态） ● STOPPING：停止中（ModelArts Edge无此状态） ● STOPPED：已停止（ModelArts Edge无此状态） ● DELETING：删除中

参数	参数类型	描述
status	String	作业状态的详情信息，仅部分状态会有详情信息。 最小长度：0 最大长度：4096
error	表8-66 object	作业运行失败时收集到的错误信息。
input	TaskInput object	作业的输入配置。
output	TaskOutputForDisplay object	作业的输出配置展示。
config	TaskConfig object	作业运行时指定的算法配置参数，部分服务需填且必填。
schedule	ScheduleParams object	计划作业参数。
schedule_status	String	定时策略状态。

表 8-66 Error

参数	参数类型	描述
code	String	算法服务定义的错误码。
message	String	算法服务反馈的错误信息。

表 8-67 TaskInput

参数	参数类型	描述
type	String	作业的输入类型。可选类型有obs（对象存储服务桶或者并行文件系统存储的文件），url（指定的文件地址或流地址），restful（从自定义的流媒体服务器通过Restful接口获取流地址），vcn（VCN设备），edgecamera（IEF边缘摄像头）。 枚举值： • obs（ModelArts Edge不支持此输入） • url • restful • vcn（ModelArts Edge不支持此输入） • edgecamera

参数	参数类型	描述
data	Array of TaskInputData objects	作业的输入详情。针对不同的输入类型有不同的配置。创建时允许填写多路输入，但更新时只允许填写一路输入。
vcn	TaskInputVcn object	VCN服务器信息，仅输入类型为VCN时需填且必填。

表 8-68 TaskInputData

参数	参数类型	描述
bucket	String	OBS桶名，当输入为OBS类型时必填。 最大长度：63
path	String	OBS的路径，当输入为OBS类型时必填。 最大长度：1023
url	String	url输入源的地址或者获取视频流地址的Restful请求地址。当输入为url类型或者restful类型时必填。 最大长度：1000
headers	Object	获取视频流地址的restful请求携带的请求头。当输入为restful类型时可选。整体呈json格式，以键值对的形式表示请求头和取值，最多允许10组。
certificate_check	Boolean	是否需要https请求进行证书校验。当输入为restful类型时必填。取值为true或者false。
rtsp_path_in_response	String	restful请求返回的body中，视频流地址的路径。当输入为restful类型时必填。 最大长度：1024
device_id	String	VCN设备ID，当输入为VCN类型时必填。
stream_type	Integer	准备进行分析的码流，当输入为VCN类型时选填。取值范围为1~3，其中1代表主码流，2代表子码流1，3代表子码流2。 最小值：1 最大值：3

表 8-69 TaskInputVcn

参数	参数类型	描述
ip	String	VCN服务器的IP地址，仅输入类型为VCN时需填且必填。

参数	参数类型	描述
port	Integer	VCN服务器的端口号，仅输入类型为VCN时需填且必填。 最小值：0 最大值：65535
username	String	VCN服务器的账号名，仅输入类型为VCN时需填且必填。
password	String	VCN服务器的与账号对应的密码，仅输入类型为VCN时需填且必填。

表 8-70 TaskOutputForDisplay

参数	参数类型	描述
obs	TaskOutputObs object	输出为OBS类型时的配置信息。（ModelArts Edge不支持此输出）
webhook	TaskOutputWebhook object	输出为Webhook类型时的配置信息。

表 8-71 TaskOutputObs

参数	参数类型	描述
bucket	String	OBS桶名，选用OBS类型输出时必填。
path	String	OBS的路径，选用OBS类型输出时必填。

表 8-72 TaskOutputWebhook

参数	参数类型	描述
url	String	结果回调地址，选用Webhook类型输出时必填。 最大长度：1000
headers	Object	结果回调时需要携带的请求头，选用Webhook类型输出时必填。整体呈json格式，以键值对的形式表示请求头和取值，至少1组，至多10组。

表 8-73 TaskConfig

参数	参数类型	描述
common	Object	作业运行时指定的具体的算法配置项，部分服务需填且必填。整体呈json格式，具体配置项参见相应算法服务的说明。

表 8-74 ScheduleParams

参数	参数类型	描述
type	String	计划任务的类型，使用计划任务时必填。可选类型分别为ONCE（仅执行一次），DAILY（每日执行），WEEKLY（每周执行），MONTHLY（每月执行） 枚举值： ONCE, DAILY, WEEKLY, MONTHLY 说明 ModelArts Edge计划任务只支持ONCE（仅执行一次），DAILY（每日执行）。
timezone	String	用户所处的时区，使用计划任务时必填。精确到分钟
days_of_week	Array of integers	作业会在一周的哪几天执行，当且仅当计划任务类型为WEEKLY时，该字段需填且必填。1~7分别指代星期一至星期日。
days_of_month	Array of integers	作业会在一个月的哪几天执行，当且仅当计划任务类型为MONTHLY时，该字段需填且必填。1~31分别指代一个月中的1日至31日。
execution_mode	String	任务执行模式。 - PERIOD：按时间段 - FREQUENCY：按频率（ModelArts Edge不支持此模式）
periods	Array of Period objects	execution_mode为PERIOD时必填，数组大小至少为1
frequency	Frequency object	execution_mode为FREQUENCY时必填

表 8-75 Period

参数	参数类型	描述
begin_at	String	单个时间段执行的起始时间，和end_at需成对出现。计划任务类型为ONCE时，格式为yyyy-MM-ddThh:mm:ss，其余计划任务类型时，格式为hh:mm:ss。
end_at	String	单个时间段执行的结束时间，和begin_at需成对出现。计划任务类型为ONCE时，格式为yyyy-MM-ddThh:mm:ss，其余计划任务类型时，格式为hh:mm:ss。

表 8-76 Frequency

参数	参数类型	描述
interval	Integer	相邻两次执行之间的间隔，频率模式必填。取值范围在5~720之间，单位：分钟 最小值：5 最大值：720
duration	Integer	单次执行的运行时长，频率模式必填。取值范围在5~720之间，单位：分钟。 最小值：5 最大值：720
begin_at	String	单日内执行的起始时间，选填。格式形如hh:mm:ss。
end_at	String	单日内执行的结束时间，选填。格式形如hh:mm:ss。

状态码： 400

表 8-77 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

状态码： 404

表 8-78 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

请求示例

无

响应示例

状态码：200

更新服务作业信息成功。

```
{
  "id": "53e4xxxxxxxxxxxxxxxxxxxxb55b3e",
  "name": "task-test",
  "creator": "user_test",
  "project_id": "b722xxxxxxxxxxxxxxxxxxeb4674",
  "description": "hello world",
  "service_name": "face-detect",
  "service_id": "88bbxxx-xxx-xxx-xxx-xxxxxxbcfe",
  "alg_instance_id": "42a4xxxxxxxxxxxxxxxxxxb44b2a",
  "created_at": "2021-01-01T00:00:00Z",
  "updated_at": "2021-10-01T00:00:10Z",
  "state": "STOPPED",
  "input": {
    "type": "url",
    "data": [ {
      "url": "rtsp://xxx"
    } ]
  },
  "output": {
    "obs": {
      "bucket": "obs-modelarts",
      "path": "output/"
    }
  },
  "config": {
    "common": {
      "image_compression_ratio": 90,
      "render_result_sw": 0,
      "video_sampling_interval": 1
    }
  }
}
```

状态码：400

请求不合法。

```
{
  "error_code": "ModelArts.0101",
  "error_msg": "The request param is invalid. The length of the field [name] cannot exceed 100."
}
```

状态码：403

请求不合法。

```
{
  "error_code" : "ModelArts.3408",
  "error_msg" : "Tasks in this state cannot be updated."
}
```

状态码： 404

指定的服务不存在。

```
{
  "error_code" : "ModelArts.3401",
  "error_msg" : "Task 53e4xxxxxxxxxxxxxxxxxxxxb55b3e does not exist."
}
```

状态码

状态码	描述
200	更新服务作业成功。
400	请求不合法。
403	指定的服务作业当前状态不可更新。
404	指定的服务作业不存在。

错误码

请参见[错误码](#)。

8.5 删除服务作业

功能介绍

该接口用于删除服务作业，仅支持边缘资源池，不支持边缘节点。说明：Endpoint通过在线服务详情界面>调用指南页签查看。

URI

DELETE /v1/{project_id}/services/{service_id}/tasks/{task_id}

表 8-79 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。
service_id	是	String	服务名称。
task_id	是	String	指定的服务作业ID。

请求参数

无

响应参数

状态码： 400

表 8-80 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

状态码： 404

表 8-81 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

请求示例

无

响应示例

状态码： 400

请求不合法。

```
{
  "error_code" : "ModelArts.0101",
  "error_msg" : "The request param is invalid. parameter [task_id] does not match ^[0-9a-f]{32}task\\w{8}$."
}
```

状态码： 404

指定的服务不存在。

```
{
  "error_code" : "ModelArts.3502",
  "error_msg" : "The requested resource is NOT found. Service face-detect not found."
}
```

状态码

状态码	描述
202	删除服务作业请求已接受。
400	请求不合法。
404	指定的服务不存在。

错误码

请参见[错误码](#)。

8.6 启动服务作业

功能介绍

该接口用于启动服务作业（在线异步作业和ief支持）。说明：Endpoint通过在线服务详情界面>调用指南页签查看。

URI

POST /v1/{project_id}/services/{service_id}/tasks/{task_id}/start

表 8-82 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。
service_id	是	String	服务ID。
task_id	是	String	指定的服务作业ID。

请求参数

无

响应参数

状态码： 400

表 8-83 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。

参数	参数类型	描述
error_msg	String	错误信息。

状态码： 404

表 8-84 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

请求示例

无

响应示例

状态码： 400

请求不合法。

```
{
  "error_code" : "ModelArts.0101",
  "error_msg" : "The request param is invalid. parameter [task_id] does not match ^[0-9a-f]{32}task\w{8}$."
}
```

状态码： 404

指定的服务不存在。

```
{
  "error_code" : "ModelArts.3502",
  "error_msg" : "The requested resource is NOT found. Service face-detect not found."
}
```

状态码

状态码	描述
202	启动服务作业请求已接受。
400	请求不合法。
404	指定的服务不存在。

错误码

请参见[错误码](#)。

8.7 停止服务作业

功能介绍

该接口用于停止服务作业（在线异步作业和ief支持）。说明：Endpoint通过在线服务详情界面>调用指南页签查看。

URI

POST /v1/{project_id}/services/{service_id}/tasks/{task_id}/stop

表 8-85 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。
service_id	是	String	服务ID。
task_id	是	String	指定的服务作业ID。

请求参数

无

响应参数

状态码： 400

表 8-86 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

状态码： 404

表 8-87 响应 Body 参数

参数	参数类型	描述
error_code	String	服务内部错误码。
error_msg	String	错误信息。

请求示例

无

响应示例

状态码： 400

请求不合法。

```
{
  "error_code" : "ModelArts.0101",
  "error_msg" : "The request param is invalid. parameter [task_id] does not match ^[0-9a-f]{32}task\w{8}$."
}
```

状态码： 404

指定的服务不存在。

```
{
  "error_code" : "ModelArts.3502",
  "error_msg" : "The requested resource is NOT found. Service face-detect not found."
}
```

状态码

状态码	描述
202	停止服务作业请求已接受。
400	请求不合法。
404	指定的服务不存在。

错误码

请参见[错误码](#)。

9 AI Hub

9.1 资产

9.1.1 发布资产

功能介绍

发布资产运营信息，整体上架资产的流程包括：发布资产、发布版本、版本入库。

URI

POST /v2/aihub/contents

请求参数

表 9-1 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 9-2 请求 Body 参数

参数	是否必选	参数类型	描述
title	是	String	资产名称

参数	是否必选	参数类型	描述
type	是	String	资产类型，模型、算法、Workflow。值如下： • model：模型 • algo：算法 • simple_workflow：Workflow
sell_type	是	Integer	固定值“0”，表示不上报应用商城
description	否	String	资产描述内容
visibility	否	String	可见性。可设置为public（全部可见）、group（组内可见）和private（仅自己可见）。当sell_type为0时，此参数必填。
group_users	否	Object	组内用户，当可见性为“public”或“private”时，该参数不需要设置；当可见性为“group”，至少需要填写一个用户的租户ID值。
version_info	否	AddNewVersionRequest object	资产版本信息
location_info	否	ImportContentRequest object	资产实体存储地址信息

表 9-3 AddNewVersionRequest

参数	是否必选	参数类型	描述
version_num	是	String	版本id，格式为：x.x.x。由两个小数点分隔的三个数字，数字最多两位数。例如2.3.10
desc	否	String	版本描述，最长90个字符
extra_info	否	String	资产版本的附加信息。ModelArts各模块平台需要展示的信息
metadata	否	String	元数据信息，如算法模型的运行环境等
object_id	否	String	对象ID。ModelArts平台的资产ID

表 9-4 ImportContentRequest

参数	是否必选	参数类型	描述
asset_locations	是	Array of AssetLocation objects	资产实体文件所在的路径信息

表 9-5 AssetLocation

参数	是否必选	参数类型	描述
location_type	是	Integer	位置类型，取值为0-1，0表示OBS，1表示SWR
region	是	String	区域名
source_mark	否	String	用于区分多个地址的标志位
location_uri	是	String	来源uri。obs地址：/桶名/文件夹名/。swr地址：repo/imageName:tag

响应参数

状态码： 201

表 9-6 响应 Body 参数

参数	参数类型	描述
content_uri	String	资产详情页
content_id	String	资产ID

请求示例

发布一个资产

```
POST https://{endpoint}/v2/aihub/contents
{
  "title": "面部识别模型",
  "type": "algo",
  "sell_type": 0,
  "visibility": "group",
  "group_users": [ "e50cf9eeb071436c8f8d554ef294f3dc" ],
  "version_info": {
    "version_num": "0.0.1",
    "desc": "init version",
    "extra_info": "{ \"runtime\": \"batch\" }",
    "metadata": "{ \"algo_version\": \"v2\", \"algo\": { \"metadata\": { \"id\": \"\", \"name\": \"\", \"description\": \"\", \"create_time\": 0, \"user_name\": \"\", \"domain_id\": \"\", \"source\": \"\", \"api_version\": \"\", \"is_valid\": false, \"state\": \"\", \"size\": 0, \"tags\": null, \"attr_list\": null, \"version_num\": 0, \"update_time\": 0, \"share_info\"
```

```
\":{},"job_config\":{\"code_dir\":\"/automation-use-only/Original/TrainJob/TrainJob-v2/TF-1.13.1-python3.6/code/\",\"boot_file\":\"/automation-use-only/Original/TrainJob/TrainJob-v2/TF-1.13.1-python3.6/code/tf1-test.py\",\"parameters_customization\":{\"true\",\"inputs\":{\"name\":\"data_url\",\"description\":\"数据来源1\",\"access_method\":\"\",\"outputs\":{\"name\":\"train_url\",\"description\":\"输出数据1\",\"access_method\":\"\",\"prefetch_to_local\":{\"false}},\"engine\":{\"engine_id\":\"tensorflow-cp36-1.13.1\",\"engine_name\":\"TensorFlow\",\"engine_version\":\"TF-1.13.1-python3.6\",\"tags\":{\"key\":\"enableHeteroLearner\",\"value\":\"True\"},{\"key\":\"enableHeteroWorker\",\"value\":\"True\"}},\"v1_compatible\":{\"true\",\"non_swr_image\":{\"false,\"run_user\":\"\",\"image_info\":{\"cpu_image_url\":\"modelarts-job-dev-image/tensorflow-cpu-cp36:1.13.1\",\"gpu_image_url\":\"modelarts-job-dev-image/tensorflow-gpu-cuda10-cp36:1.13.1\",\"image_version\":\"2.0.10\"},\"image_source\":{\"false},\"code_tree\":{\"name\":\"code/\",\"children\":{\"name\":\"config.json\"},{\"name\":\"customize_service.py\"},{\"name\":\"tf1-test.py\"},{\"name\":\"备份/\",\"children\":{\"name\":\"tf1-test.py\"}}}}},\"resource_requirements\":{},\"advanced_config\":{}}\"},\"location_info\":{\"asset_locations\":[{\"region\":\"example\",\"location_type\":0,\"location_uri\":\"/bucket/folder/algo/\"}]}}
```

响应示例

状态码： 201

发布资产成功

```
{
  "content_uri" : "https://marketplace.xxxxxxx.huawei.com/markets2/aihub/datasets/detail/?content_id=8658fbc4-bbbc-4f90-81ce-020768aada7c",
  "content_id" : "8658fbc4-bbbc-4f90-81ce-020768aada7c"
}
```

状态码

状态码	描述
201	发布资产成功

错误码

请参见[错误码](#)。

9.1.2 修改资产属性

功能介绍

修改资产属性，包括标题名称、描述、可见性、可获得性、标签等。

URI

PUT /v1/aihub/contents/{content_id}

表 9-7 路径参数

参数	是否必选	参数类型	描述
content_id	是	String	资产id

请求参数

表 9-8 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 9-9 请求 Body 参数

参数	是否必选	参数类型	描述
short_desc	否	String	资产二级标题、短描述
visibility	否	String	资产可见性
content_title	否	String	资产标题
description	否	String	资产详情描述
tag_codes	否	Array of strings	标签列表
whitelist_users	否	Array of strings	白名单用户id，这些id的用户可查看本资产详情

响应参数

无

请求示例

修改资产属性

```
PUT https://{endpoint}/v1/aihub/contents/{content_id}

{
  "short_desc": "Init",
  "visibility": "group",
  "content_title": "发布资产",
  "description": "资产详情描述",
  "tag_codes": [ "180600" ],
  "whitelist_users": [ "9332aab245ea4d56871e75d6966aa273" ]
}
```


响应示例

无

状态码

状态码	描述
204	更新成功

错误码

请参见[错误码](#)。

9.1.3 获取资产详情

功能介绍

获取资产详情信息。

URI

GET /v1/aihub/contents/{content_id}

表 9-10 路径参数

参数	是否必选	参数类型	描述
content_id	是	String	资产id

请求参数

表 9-11 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 9-12 响应 Body 参数

参数	参数类型	描述
content_detail	ContentDetailInfo object	资产详情
content_statistic	ContentStatistic object	资产统计信息
content_statuses	ContentStatusResp object	资产状态信息，包括是否订阅、是否精选等信息
content_tags	Array of ContentTags objects	资产标签信息
content_paper	ItemPaperVO object	论文复现相关信息
content_applicable_platform	Array of ApplicablePlatform objects	资产平台信息。订阅之后的跳转平台地址信息

表 9-13 ContentDetailInfo

参数	参数类型	描述
content_id	String	ID
type	String	对象类型
content_title	String	资产标题
desc_type	Integer	描述信息的格式类型。可选值如下： 0: markdown 1: 富媒体
description	String	描述信息
short_desc	String	短描述
cover_url	String	封面图的地址
latest_version_id	String	最大gmt_create的版本且状态为0的版本id（原则上，也是最大版本号的版本）
latest_version_num	String	最大gmt_create的版本且状态为0的版本号（原则上，也是最大版本号的版本）
visibility	String	可见性，分为public，private，group

参数	参数类型	描述
whitelist_users	Array of WhiteListDetail objects	白名单用户信息
content_license	Array of strings	资产license
sell_type	Integer	付费类型。0-免费资产。

表 9-14 WhiteListDetail

参数	参数类型	描述
name	String	白名单用户在AI Hub的昵称
domain_name	String	白名单用户的domain name
domain_id	String	白名单用户的domain id
user_logo	String	白名单用户在AI Hub的logo

表 9-15 ContentStatistic

参数	参数类型	描述
time_create	Long	创建时间，13位时间戳
time_modified	Long	更新时间，13位时间戳
count_stars	Integer	收藏量
count_subscribes	Integer	订阅量
count_comments	Integer	评论量
count_views	Integer	浏览量
latest_version_file_size	Long	最新可用版本的尺寸，单位为字节
latest_version_file_num	Long	最新可用版本的文件数量

表 9-16 ContentStatusResp

参数	参数类型	描述
is_stared	Integer	取值0或1。0表示该资产未收藏过，1表示已收藏
is_official_release	Integer	取值0或1。0表示不是官方发布，1表示属于官方发布
is_available	Integer	是否可使用，0不可以使用，1可以使用
is_owner	Integer	取值0或1。0代表不是自己发布的，1代表是自己发布的
vendor_id	Integer	发布者id
vendor_name	String	发布者名字
vendor_logo	String	作者封面图地址
is_featured	Boolean	是否是精选资产
is_liked	String	是否点赞
is_subscribed	Integer	用户对这个资产的订阅信息。可选值如下： ● 0：订阅后取消订阅 ● 1：正常订阅中 ● 2：订阅超期了 ● 3：未订阅或者无需订阅
promotion_state	Integer	资产运营置顶指标，1表示置顶，其他值表示非置顶
purchase_limit_status	Integer	订阅的接入license管控次数是否达到上限。可选值如下： ● 0：未达到次数上限，可以再次接入license ● 1：已达次数限制，不允许再次接入license
vendor_desc	String	该资产发布者的简要描述信息

表 9-17 ContentTags

参数	参数类型	描述
id	Integer	标签id
tagParentCode	String	父标签编码
tagCNName	String	标签中文名
tagENName	String	标签英文名
joinAggs	String	是否参与聚合统计，1表示参与，0表示不参与

参数	参数类型	描述
tagCode	String	标签编码

表 9-18 ItemPaperVO

参数	参数类型	描述
paper_title	String	论文名称
paper_url	String	论文链接

表 9-19 ApplicablePlatform

参数	参数类型	描述
name_res	NameRes object	平台名称
url	String	平台链接地址

表 9-20 NameRes

参数	参数类型	描述
value_zh_cn	String	中文名称
value_en_us	String	英文名称

请求示例

获取资产详情

GET https://{endpoint}/v1/aihub/contents/{content_id}

响应示例

状态码： 200

获取资产详情成功

```
{
  "content_detail": {
    "content_id": "5d0396cb-f7fd-4a7b-bf82-02e6c398cb66",
    "type": "algo",
    "content_title": "面部识别算法",
    "desc_type": 0,
    "description": "这是一个面部识别算法",
    "short_desc": "基于开源算法修改的面部识别算法",
    "cover_url": "https://xx.obs.xxxxxxxx.xx.com/meta/contentCover/algo-default.jpg",
    "latest_version_id": "2.0.0",
```

```
"latest_version_num" : "2.0.0",
"visibility" : "public",
"whitelist_users" : "[]",
"content_license" : "[]"
},
"content_statistic" : {
  "time_create" : 1660114459000,
  "time_modified" : 1660114459000,
  "count_stars" : 1,
  "count_subscribes" : 1,
  "count_comments" : 2,
  "count_views" : 22,
  "latest_version_file_size" : 8441436,
  "latest_version_file_num" : 3
},
"content_status" : {
  "is_stared" : 0,
  "is_official_release" : 0,
  "is_available" : 1,
  "is_owner" : 0,
  "vendor_id" : 11,
  "vendor_name" : "vendor_user",
  "vendor_logo" : "https://xx.obs.regionId.xx.com/meta/partnerLogo/3943d6a4-4038-47fe-bfda-
a51af422e60b.png",
  "is_featured" : true,
  "is_liked" : 0,
  "is_subscribed" : 3,
  "promotion_state" : 1,
  "purchase_limit_status" : 0,
  "vendor_desc" : "this is a short desc."
},
"content_tags" : [ {
  "id" : 228,
  "tagParentCode" : 180500,
  "tagCNName" : "银行",
  "tagENName" : "Banking",
  "joinAggs" : 1,
  "tagCode" : 18050000
} ],
"content_paper" : {
  "paper_title" : "xx论文",
  "paper_url" : "https://xxx/xx.html"
},
"content_applicable_platform" : [ {
  "name_res" : {
    "value_zh_cn" : "ModelArts",
    "value_en_us" : "ModelArts"
  },
  "url" : "https://console.xx.com/modelarts"
} ]
}
```

状态码

状态码	描述
200	获取资产详情成功

错误码

请参见[错误码](#)。

9.1.4 删除资产

功能介绍

删除一个资产。有用户订阅则会删除失败，取消订阅之后也不可删除。

URI

DELETE /v1/aihub/contents/{content_id}

表 9-21 路径参数

参数	是否必选	参数类型	描述
content_id	是	String	资产ID

请求参数

表 9-22 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 9-23 响应 Body 参数

参数	参数类型	描述
is_success	Boolean	操作成功

请求示例

删除资产

```
DELETE https://{endpoint}/v1/aihub/contents/{content_id}
```

响应示例

状态码： 200

操作成功

```
{
  "is_success": true
}
```

状态码

状态码	描述
200	操作成功

错误码

请参见[错误码](#)。

9.1.5 获取用户发布的某个类型的所有资产

功能介绍

获取用户发布的某个类型的所有资产。

URI

GET /v1/aihub/contents/mine

表 9-24 Query 参数

参数	是否必选	参数类型	描述
content_type	是	String	资产类型， algo、model、simple_workflow分别表示发布资产类别为算法、模型、Workflow。查询多种类型时使用逗号分隔开
status	否	Integer	商品状态。0-上架，1-下架，2-草稿。草稿状态是商品不可用状态
search_string	否	String	搜索关键字，资产id和资产名称模糊匹配
sort_key	否	String	指定排序字段。可选值如下： - gmt_modified：根据更新时间排序 - gmt_create：根据创建时间排序
sort_dir	否	String	指定排序顺序。可选值如下： - desc：降序排序 - asc：升序排序

参数	是否必选	参数类型	描述
offset	否	Integer	分页的偏移量，大于等于0的数字，默认是0
limit	否	Integer	分页显示的每页的数量。取值是[5, 100]，默认是10

请求参数

表 9-25 请求 Header 参数

参数	是否必选	参数类型	描述
x-auth-token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 9-26 响应 Body 参数

参数	参数类型	描述
total_count	Integer	总数
content_infos	ContentInfo object	资产列表

表 9-27 ContentInfo

参数	参数类型	描述
content_id	String	资产id
content_type	String	资产类型，如algo、model等
content_title	String	资产名称
status	Integer	资产状态，0-上架，1-下架，2-草稿
create_time	Long	资产最开始创建时间，13位时间戳
count_views	Integer	资产浏览量
count_stars	Integer	资产收藏量
count_subscribes	Integer	资产订阅量

参数	参数类型	描述
cover_url	String	资产封面图
review_status	ItemAudit object	资产审核信息

表 9-28 ItemAudit

参数	参数类型	描述
id	Long	审核的id，无需处理。
item_id	String	资产id
status	Integer	审核状态
reason	String	审核原因。如审核不通过，则不通过的原因

请求示例

获取发布的所有算法

```
GET https://{endpoint}/v1/aihub/contents/mine?offset=0&limit=8&content_type=algo

{
  "total_count": 1,
  "content_infos": [ {
    "content_id": "5d0396cb-f7fd-4a7b-bf82-02e6c398cb66",
    "content_type": "algo",
    "content_title": "facial recognition algorithm",
    "status": 0,
    "create_time": 1676452476000,
    "count_views": 7,
    "count_stars": 0,
    "count_subscribes": 0,
    "cover_url": "https://bucketname.obs.xxxxxxxx.huawei.com/meta/contentCover/algo-default.jpg",
    "review_status": {
      "id": 0,
      "item_id": "5d0396cb-f7fd-4a7b-bf82-02e6c398cb66",
      "status": 1,
      "reason": "pass"
    }
  }
]
```

响应示例

无

状态码

状态码	描述
200	更新成功

错误码

请参见[错误码](#)。

9.1.6 修改资产上下架

功能介绍

修改资产上下架。

URI

PUT /v1/aihub/contents/{content_id}/lifecycle

表 9-29 路径参数

参数	是否必选	参数类型	描述
content_id	是	String	资产id

请求参数

表 9-30 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 9-31 请求 Body 参数

参数	是否必选	参数类型	描述
lifecycle	是	Integer	资产上下架状态。0-上架，1-下架

响应参数

无

请求示例

修改资产上下架。

```
PUT https://{endpoint}/v1/aihub/contents/{content_id}/lifecycle
{
  "lifecycle" : 1
}
```

响应示例

无

状态码

状态码	描述
200	修改成功

错误码

请参见[错误码](#)。

9.1.7 查询同种类型所有资产

功能介绍

查询同种类型所有资产。

URI

GET /v1/aihub/contents

表 9-32 Query 参数

参数	是否必选	参数类型	描述
content_type	是	Array	指定对象类型。可选值如下： - algo：算法 - model：模型 - simple_workflow：Workflow
list_type	否	String	查询列表类型。可选值如下： - all：首页查询的资产 - star：我收藏的资产
offset	否	Integer	页偏移量。默认为0
limit	否	Integer	每页展示对象数量。默认为20
sort_by	否	String	指定排序顺序。可选值如下： - desc：降序排序 - asc：升序排序

参数	是否必选	参数类型	描述
sort_column	否	String	指定排序字段。可选值如下： - time_create：根据更新时间排序 - time_modified：根据创建时间排序 - count_stars：根据最多收藏排序 - count_subscribes：根据最多订阅排序 - count_views：根据最多浏览量排序
search_string	否	String	列表搜索筛选内容，小于200字符
license_group_id	否	Array	证书id
vendor_id	否	Array	发布者id
visibility	否	Array	指定资产可见性，可多选，不填则不对可见性做过滤，查询全部。可选值如下： - public：公开 - group：白名单可见 - private：私有
is_owner	否	Boolean	指定查询是否是我发布的对象，不填则不做过滤，查询所有人发布的对象。可选值如下： - true：查询我发布的 - false：查询不是我发布的
is_available	否	Array	标签字符串数组，用于过滤标签查询
list_promotion	否	Boolean	是否置顶推广，默认是true
is_featured	否	Boolean	是否过滤精选

请求参数

表 9-33 请求 Header 参数

参数	是否必选	参数类型	描述
x-auth-token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 9-34 响应 Body 参数

参数	参数类型	描述
total_contents	Integer	对象列表的总数
content_list	Array of ContentList objects	资产列表
valid_filters	Array of ValidFilters objects	资产过滤信息

表 9-35 ContentList

参数	参数类型	描述
content_detail	ContentDetail object	资产详情信息
content_statistics	ContentStatistic object	资产统计信息
content_statuses	ContentStatusResp object	资产状态信息

表 9-36 ContentDetail

参数	参数类型	描述
content_id	String	资产id
content_name	String	资产名
status	Integer	0-成功, 1-失败

参数	参数类型	描述
content_uri	String	资产详情URI
create_time	Long	资产最开始创建时间，13位时间戳
count_views	Integer	浏览量
count_stars	Integer	收藏量
count_subscribes	Integer	订阅量
cover_url	String	资产图片URI
version_detail	Array of VersionDetail objects	版本详情

表 9-37 VersionDetail

参数	参数类型	描述
version_id	String	版本id
version_num	String	版本号

表 9-38 ContentStatistic

参数	参数类型	描述
time_create	Long	创建时间，13位时间戳
time_modified	Long	更新时间，13位时间戳
count_stars	Integer	收藏量
count_subscribes	Integer	订阅量
count_comments	Integer	评论量
count_views	Integer	浏览量
latest_version_file_size	Long	最新可用版本的尺寸，单位为字节
latest_version_file_num	Long	最新可用版本的文件数量

表 9-39 ContentStatusResp

参数	参数类型	描述
is_stared	Integer	取值0或1。0表示该资产未收藏过，1表示已收藏
is_official_release	Integer	取值0或1。0表示不是官方发布，1表示属于官方发布
is_available	Integer	是否可使用，0不可以使用，1可以使用
is_owner	Integer	取值0或1。0代表不是自己发布的，1代表是自己发布的
vendor_id	Integer	发布者id
vendor_name	String	发布者名字
vendor_logo	String	作者封面图地址
is_featured	Boolean	是否是精选资产
is_liked	String	是否点赞
is_subscribed	Integer	用户对这个资产的订阅信息。可选值如下： 0：订阅后取消订阅 1：正常订阅中 2：订阅超期了 3：未订阅或者无需订阅
promotion_state	Integer	资产运营置顶指标，1表示置顶，其他值表示非置顶
purchase_limit_status	Integer	订阅的接入license管控次数是否达到上限。可选值如下： 0：未达到次数上限，可以再次接入license 1：已达次数限制，不允许再次接入license
vendor_desc	String	该资产发布者的简要描述信息

表 9-40 ValidFilters

参数	参数类型	描述
valid_visibility	Array of ValidVisibility objects	查询结果中有所有资产的可见性归类。
valid_tags	Array of ValidTags objects	查询结果中标签的聚合

表 9-41 ValidVisibility

参数	参数类型	描述
visibility	String	资产可见性信息。可选值如下： • public：公开 • group：白名单可见 • private：仅owner可见
count	Integer	对象数量

表 9-42 ValidTags

参数	参数类型	描述
count	Integer	数量
tag_code	String	标签编码
cn_name	String	中文名称
en_name	String	英文名称
sons	Array of ValidTags objects	子标签信息

请求示例

获取某个类型的商品列表

```
GET https://{endpoint}/v1/aihub/contents?
content_type=algo&offset=0&list_promotion=true&limit=20&list_type=all&sort_column=correlation&is_available=true
```

响应示例

状态码： 200

获取商品列表成功

```
{
  "total_contents" : 1,
  "content_list" : [ {
    "content_detail" : {
      "content_id" : "5142ac43-2796-495f-acef-79401c21cb2b",
      "content_type" : "algo",
      "content_title" : "facial recognition algorithm",
      "short_desc" : "a algorithm",
      "cover_url" : "https://xx.obs.xxx.xx.com/meta/itemCover/algo-default.jpg",
      "commercial_sell" : false
    },
    "content_statistic" : {
      "time_create" : 1660114459000,
      "time_modified" : 1660114459000,
      "count_stars" : 1,

```

```
{
  "count_subscribes" : 1,
  "count_comments" : 2,
  "count_views" : 22,
  "latest_version_file_size" : 8441436,
  "latest_version_file_num" : 3
},
"content_status" : {
  "is_stared" : 0,
  "is_official_release" : 0,
  "is_available" : 1,
  "is_owner" : 0,
  "vendor_id" : 11,
  "vendor_name" : "vendor_user",
  "vendor_logo" : "https://xx.obs.xxx.xx.com/meta/partnerLogo/1.png",
  "is_featured" : true,
  "is_liked" : 0,
  "is_subscribed" : 3,
  "promotion_state" : 1,
  "purchase_limit_status" : 0,
  "vendor_desc" : "this is a short desc."
}
}],
"valid_filters" : {
  "valid_visibility" : [ {
    "visibility" : "public",
    "count" : 1
  } ],
  "valid_tags" : [ {
    "count" : null,
    "tag_code" : 15,
    "cn_name" : "框架引擎",
    "en_name" : "Framework"
  } ]
}
}
```

状态码

状态码	描述
200	获取商品列表成功

错误码

请参见[错误码](#)。

9.1.8 获取资产准备进度

功能介绍

获取资产准备进度状态。

URI

GET /v1/aihub/market-place/status

表 9-43 Query 参数

参数	是否必选	参数类型	描述
ext_id	是	String	资产和版本信息，格式是 content_id:version_id。如 f18a99a7-b00e-4b00-ad16-0190f32562d2:1.0.0

请求参数

表 9-44 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。
Service-Transaction-ID	是	String	事务ID

响应参数

状态码： 202

表 9-45 响应 Body 参数

参数	参数类型	描述
error_code	String	接口调用方的错误码
error_msg	String	接口调用方的错误消息
readiness_info	ReadinessInfo object	准备度信息

表 9-46 ReadinessInfo

参数	参数类型	描述
check_result	String	资产准备度确认结果，可选值如下： - PASS：资产已经准备好。 - PROCESSING：资产处理中，需要等待。 - FAILED：资产准备失败。
description	String	准备度状态说明

请求示例

GET https://{endpoint}/v1/aihub/market-place/status?ext_id=b940d356-a6c4-4c84-8dfb-e2c4bfa060b1:1.0.0

响应示例

状态码： 202

状态返回结果

```
{
  "content_detail": {
    "error_msg": "",
    "error_code": "CMM.0000",
    "readiness_info": {
      "description": "",
      "check_result": "PASS"
    }
  }
}
```

状态码

状态码	描述
202	状态返回结果

错误码

请参见[错误码](#)。

9.2 版本

9.2.1 资产增加版本

功能介绍

对已有资产新增一个版本，再调用入库接口，实现多版本功能。

URI

POST /v1/aihub/contents/{content_id}/versions

表 9-47 路径参数

参数	是否必选	参数类型	描述
content_id	是	String	资产id

请求参数

表 9-48 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 9-49 请求 Body 参数

参数	是否必选	参数类型	描述
version_num	是	String	版本id，格式为：x.x.x。由两个小数点分隔的三个数字，数字最多两位数。例如2.3.10
desc	否	String	版本描述，最长90个字符
extra_info	否	String	资产版本的附加信息。ModelArts各模块平台需要展示的信息
metadata	否	String	元数据信息，如算法模型的运行环境等
object_id	否	String	对象ID。ModelArts平台的资产ID

响应参数

状态码： 201

表 9-50 响应 Body 参数

参数	参数类型	描述
content_id	String	资产id
version_id	String	新版本的版本id
version_num	String	资产版本号

请求示例

给资产增加版本

```
POST https://{endpoint}/v1/aihub/contents/{content_id}/versions
{
  "version_num": "1.0.0",
```

```
"desc" : "add new version",
"extra_info" : "{ \"runtime\" : \"batch\" }",
"metadata" : "{ \"env\" : \"x86\" }",
"object_id" : "LQWG02CYUPYWHEY6"
}
```

响应示例

状态码： 201

增加新版本成功

```
{
  "content_id" : "5142ac43-2796-495f-acef-79401c21cb2b",
  "version_id" : "wd2Dw3",
  "version_num" : "1.0.0"
}
```

状态码

状态码	描述
201	增加新版本成功

错误码

请参见[错误码](#)。

9.2.2 获取资产版本详情

功能介绍

获取资产版本详情。

URI

GET /v1/aihub/contents/{content_id}/versions

表 9-51 路径参数

参数	是否必选	参数类型	描述
content_id	是	String	资产ID

请求参数

表 9-52 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 9-53 响应 Body 参数

参数	参数类型	描述
total_count	Integer	版本数量
versions	Array of VersionInfoResponse objects	版本详情列表
latest_version_id	String	最新且状态为0的版本id

表 9-54 VersionInfoResponse

参数	参数类型	描述
version_num	String	版本号
version_id	String	版本id
version_desc	String	版本短描述
time_create	String	版本创建时间
time_modified	String	版本修改时间

参数	参数类型	描述
status	Integer	版本状态.值如下: ● 0: 版本发布成功。 ● 1: 版本资产拷贝中 ● 2: 版本发布失败 ● 3: 版本已经下线 ● 4: 版本已经被删除 ● 5: 等待拷贝，即将进入1状态 ● 6: 付费资产未上报到付费平台 ● 7: 版本发布未调用入库接口，待入库
life_cycle	String	版本的生命周期。0表示上架，1表示下架。
extra_info	String	Json字符串，内部包含算法约束及代码开放的目录信息
region_ready	String	资产在主区域是否准备好且是否能在ModelArts中运行。
file_size	String	版本的OBS文件大小。
share_code_status	String	0-代码开放任务还没开始，1-已经开放完成，2-代码开放准备中，3-代码开放失败，稍后自动重试，没有开启代码开放则为null。
code_download_urls	String	代码开放地址，没有开启代码开放则返回null。
code_view_urls	String	代码开放预览，没有开启代码开放则返回null。
preview_dir_structure	String	数据集目录预览，不可预览则返回null。

请求示例

获取资产版本详情

GET https://{endpoint}/v1/aihub/contents/{content_id}/versions

响应示例

状态码： 200

获取成功

```
{
  "total_count": 1,
  "versions": [ {
    "version_num": "1.0.0",
    "version_id": "Q7EPZr",
    "version_desc": "Init",
    "time_create": 1662037833000,
```



```
"time_modified" : 1662039111000,
"status" : 0,
"life_cycle" : 0,
"extra_info" : "{\"runtime\":\"batch\"}"
}],
"latest_version_id" : "Q7EPZr"
}
```

状态码

状态码	描述
200	获取成功

错误码

请参见[错误码](#)。

9.2.3 修改资产版本信息

功能介绍

修改资产版本信息。

URI

PUT /v1/aihub/contents/{content_id}/versions/{version_id}

表 9-55 路径参数

参数	是否必选	参数类型	描述
content_id	是	String	资产ID
version_id	是	String	版本ID

请求参数

表 9-56 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 9-57 请求 Body 参数

参数	是否必选	参数类型	描述
version_desc	否	String	对象版本说明
status	否	Integer	要将版本修改为什么状态。可选值如下： 0：上架状态 3：下架状态

响应参数

无

请求示例

更新资产版本信息

```
PUT https://{endpoint}/v1/aihub/contents/{content_id}/versions/{version_id}
{
  "version_desc": "fix bug",
  "status": 3
}
```

响应示例

无

状态码

状态码	描述
204	更新成功

错误码

请参见[错误码](#)。

9.2.4 删除资产版本

功能介绍

删除资产版本。资产可用时，必须保证删除版本后，至少还有一个上架的可用的版本；资产不可用时则无限制。

URI

DELETE /v1/aihub/contents/{content_id}/versions/{version_id}

表 9-58 路径参数

参数	是否必选	参数类型	描述
content_id	是	String	资产ID
version_id	是	String	版本ID

请求参数

表 9-59 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 9-60 响应 Body 参数

参数	参数类型	描述
is_success	Boolean	操作成功

请求示例

删除资产版本

DELETE https://{endpoint}/v1/aihub/contents/{content_id}/versions/{version_id}

响应示例

状态码： 200

删除成功

```
{
  "is_success": true
}
```

状态码

状态码	描述
200	删除成功

错误码

请参见[错误码](#)。

9.3 订阅

9.3.1 创建订阅

功能介绍

创建订阅，每个用户对每个资产只能订阅1次，订阅后可以取消订阅。

URI

POST /v1/aihub/subscriptions

请求参数

表 9-61 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 9-62 请求 Body 参数

参数	是否必选	参数类型	描述
content_id	是	String	资产id

响应参数

状态码： 201

表 9-63 响应 Body 参数

参数	参数类型	描述
subscription_id	String	订阅id

请求示例

创建订阅

```
POST https://{endpoint}/v1/aihub/subscriptions
{
  "content_id" : "5d0396cb-f7fd-4a7b-bf82-02e6c398cb66"
}
```

响应示例

状态码： 201

创建订阅成功，返回订阅id

```
{
  "subscription_id" : "36f00736-54d2-47f1-8e72-ce9e8f221ff5"
}
```

状态码

状态码	描述
201	创建订阅成功，返回订阅id

错误码

请参见[错误码](#)。

9.3.2 查询用户订阅的资产

功能介绍

查询用户订阅的所有资产列表。

URI

GET /v1/aihub/subscriptions

表 9-64 Query 参数

参数	是否必选	参数类型	描述
search_content	否	String	搜索内容，该参数取值包括 content_id、subscription_id或资产名称，content_id表示资产id，subscription_id表示订阅id，资产名进行模糊搜索
content_types	否	Array	资产类型，取值为model，algo，simple_workflow，model表示模型，algo表示算法，simple_workflow表示Workflow，支持多选来筛选出多种资产类型的资产

参数	是否必选	参数类型	描述
offset	否	Integer	偏移量，取值范围大于等于0，默认为0
limit	否	String	每页显示的资产数量，默认为20
sort_dir	否	String	指定排序顺序，默认为desc。 可选值如下： • desc：降序排序 • asc：升序排序
sort_key	否	String	排序字段：取值为gmt_create、gmt_modified、subscription_id，分别表示按照资产创建时间排序、按照资产修改时间排序、按照订阅id号排序，默认为gmt_modified
tag_codes	否	Array	标签id，支持多选筛选出满足标签并订阅过的资产。
status	否	String	订阅状态，取值范围为0-2，0表示订阅取消，1表示正常订阅中，2表示订阅超期
sell_type	否	String	是否上报应用商城，取值为0或1，0表示不上报，1表示上报
region	否	String	region，用于处理返回值中的applicable_platform

请求参数

表 9-65 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 9-66 响应 Body 参数

参数	参数类型	描述
total	Integer	订阅资产总数量
subscription_infos	Array of SubscriptionInfo objects	订阅资产列表

表 9-67 SubscriptionInfo

参数	参数类型	描述
subscription_id	String	订阅id
content_id	String	资产id
content_type	String	资产类型
content_name	String	资产名称
short_desc	String	资产短描述
cover_url	String	资产封面图url
vendor_name	String	供应商名称
vendor_logo	String	供应商头像图url
time_create	Long	首次订阅时间
time_modified	Long	更新时间
license_summary	LicenseSummary object	license相关信息
version_info	VersionInfo object	版本信息
sell_type	Integer	固定值0，是否上报应用商城，取值为0或1，0表示不上报，1表示上报
applicable_platform	ApplicablePlatform object	适用平台
status	Integer	0-订阅取消，1-正常订阅中
content_detail_info	ContentDetailInfo object	资产详情信息
item_time_modified	Long	资产更新时间

参数	参数类型	描述
asset_source	Integer	资产来源，可选值如下： 0：资产来自MA 1：资产来自AI Hub 2：资产来自Pangu

表 9-68 LicenseSummary

参数	参数类型	描述
duration_amount	Integer	剩余时长，-1表示无时间约束，可以永久使用
duration_total	Integer	总时间量
physical_amount	Integer	剩余物理量纲数量，-1表示无该量纲
physical_total	Integer	物理量纲总量
measure_unit	Integer	计量枚举。可选值如下： 1：天 2：月 3：年
valid_count	Integer	未过期的license个数，如果为0表示全部过期，为1表示只有一个未过期，不需要弹窗选择配额，大于1表示有多个有效配额
recent_license_info	LicenseInfo object	配额信息

表 9-69 LicenseInfo

参数	参数类型	描述
license_id	String	配额id
duration_amount	Integer	剩余时长，-1表示无时间约束，可以永久使用
duration_total	Integer	总时间量
physical_amount	Integer	剩余物理量纲数量，-1表示无该量纲
physical_total	Integer	物理量纲总量
measure_unit	Integer	计量枚举，1表示日，8表示实例，9表示实例·天

参数	参数类型	描述
status	Integer	取值为1或2，1表示未激活使用，2表示激活使用中
expired_time	Long	到期时间

表 9-70 VersionInfo

参数	参数类型	描述
total	Integer	总版本数量（当前用户的可用版本数量）
last_version_num	String	用户名下最新可用的，资产版本号
last_version_id	String	用户名下最新可用的，资产版本id号，视情况而定，有就返回

表 9-71 ApplicablePlatform

参数	参数类型	描述
name_res	NameRes object	平台名称
url	String	平台链接地址

表 9-72 NameRes

参数	参数类型	描述
value_zh_cn	String	中文名称
value_en_us	String	英文名称

表 9-73 ContentDetailInfo

参数	参数类型	描述
description	String	资产描述
tag_codes	Array of strings	标签列表

请求示例

获取订阅列表

```
GET https://{endpoint}/v1/aihub/subscriptions?offset=0&limit=10&sort_dir=desc&region=xx-xxxx-xx&attribute_id=&sort_key=gmt_modified&search_content=&content_types=algo&status=1
```

响应示例

状态码： 200

获取我的订阅成功

```
{
  "total": 1,
  "subscription_infos": [ {
    "status": 1,
    "subscription_id": "e329fa81-4826-40d5-87d8-8b3403f88177",
    "content_id": "750c93a1-ec45-43a5-a99a-5bcc6e242be7",
    "content_type": "algo",
    "content_name": "面部识别算法",
    "short_desc": "algo for test",
    "cover_url": "https://xx.obs.example.xx.com/meta/itemCover/algo -default -.jpg",
    "content_detail_info": {
      "description": "License: cc0",
      "tag_codes": ["18000000"]
    },
    "vendor_name": "vendor_user",
    "vendor_logo": "https://xx.obs.example.xx.com/meta/userLogo/3283e9ea-dc73- -4af5 -
b366-649f8e27e58d.jpeg",
    "time_create": 1632280489000,
    "time_modified": 1632280489000,
    "item_time_modified": 1740399227000,
    "license_summary": {
      "duration_amount": 35291,
      "duration_total": 35640,
      "physical_amount": -1,
      "physical_total": -1,
      "measure_unit": 1,
      "valid_count": 1,
      "recent_license_Info": {
        "license_id": "01a7871a-2764-4235-9ca3-8e0d3a92b83e",
        "duration_amount": 35291,
        "duration_total": 35640,
        "physical_amount": -1,
        "physical_total": -1,
        "expired_time": 4819764590480,
        "measure_unit": 1,
        "status": 2
      }
    },
    "version_info": {
      "total": 2,
      "last_version_num": "2.0.0",
      "last_version_id": "2.0.0"
    },
    "sell_type": 0,
    "asset_source": 0,
    "applicable_platform": {
      "name_res": {
        "value_zh_cn": "ModelArts",
        "value_en_us": "ModelArts"
      },
      "platform_address": "https://console.xxxxxxxx.xx.com/modelarts2/#/algorithms?
activeTab=subscribedAlgos&searchContent=750c93a1-ec45-43a5-a99a-5bcc6e242be7"
    }
  } ]
}
```

状态码

状态码	描述
200	获取我的订阅成功

错误码

请参见[错误码](#)。

9.3.3 创建资产的 license

功能介绍

接入license管控的资产。

URI

POST /v1/aihub/subscription/license-orders

请求参数

表 9-74 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 9-75 请求 Body 参数

参数	是否必选	参数类型	描述
content_id	是	String	资产id
sku_code	否	String	需要创建的套餐，可选参数，不选默认使用唯一sku

响应参数

状态码： 200

表 9-76 响应 Body 参数

参数	参数类型	描述
license_ids	Array of strings	license id

请求示例

创建订阅商品的license

```
POST https://{endpoint}/v1/aihub/subscription/license-orders
{
  "content_id" : "5d0396cb-f7fd-4a7b-bf82-02e6c398cb66",
  "sku_code" : "33499d00-a840-4609-a1b7-3afbcbf10f00"
}
```

响应示例

状态码： 200

创建license成功

```
{
  "license_ids" : [ "7900898a-7ddd-4ec2-a5e0-39e6a23c633d" ]
}
```

状态码

状态码	描述
200	创建license成功

错误码

请参见[错误码](#)。

9.3.4 查询订阅资产的版本

功能介绍

查询某个订阅资产的所有可用版本。

URI

GET /v1/aihub/subscriptions/{subscription_id}/versions

表 9-77 路径参数

参数	是否必选	参数类型	描述
subscription_id	是	String	订阅id

表 9-78 Query 参数

参数	是否必选	参数类型	描述
offset	否	String	表示从此偏移量开始查询，取值需大于等于0，默认为0
limit	否	String	每页的数量，取值范围为[0,200]，默认5
sort_dir	否	String	指定排序顺序，默认为desc。 可选值如下： • desc: 降序排序 • asc: 升序排序
sort_key	否	String	排序字段，默认为gmt_create表示创建时间

请求参数

表 9-79 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 9-80 响应 Body 参数

参数	参数类型	描述
total_count	Integer	查询所订阅资产的版本总数量
versions	Array of VersionsDetail objects	资产版本列表

表 9-81 VersionsDetail

参数	参数类型	描述
content_id	String	资产id
version_num	String	版本号
version_id	String	版本ID
time_create	Long	创建时间，13位时间戳
time_modified	Long	更新时间，13位时间戳
status	Integer	状态，0-成功可用
version_desc	String	版本说明

请求示例

查询订阅资产的版本

```
GET https://{endpoint}/v1/aihub/subscriptions/{subscription_id}/versions?
offset=0&limit=5&sort_dir=desc&sort_key=gmt_create
```

响应示例

状态码： 200

获取我的订阅可用版本成功

```
{
  "total_count": 1,
  "versions": [ {
    "content_id": "94122389-01a1-4a3f-8df7-218176fa6f73",
    "version_num": "1.0.0",
    "version_id": "DXChon",
    "time_create": 1652932026000,
    "time_modified": 1652932054000,
    "status": 0,
    "version_desc": "Init"
  } ]
}
```

状态码

状态码	描述
200	获取我的订阅可用版本成功

错误码

请参见[错误码](#)。

9.3.5 找回订阅

功能介绍

对取消了订阅的资产，进行找回订阅。这个操作会将订阅从取消状态改为订阅中。

URI

POST /v1/aihub/subscriptions/{subscription_id}

表 9-82 路径参数

参数	是否必选	参数类型	描述
subscription_id	是	String	订阅ID

请求参数

表 9-83 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

无

请求示例

找回订阅

POST https://{endpoint}/v1/aihub/subscriptions/{subscription_id}

响应示例

无

状态码

状态码	描述
200	找回订阅成功

错误码

请参见[错误码](#)。

9.3.6 取消订阅

功能介绍

取消订阅。在个人中心的订阅列表中仍能查询到，但是在ModelArts界面看不到。只修改订阅状态。

URI

DELETE /v1/aihub/subscriptions/{subscription_id}

表 9-84 路径参数

参数	是否必选	参数类型	描述
subscription_id	是	String	订阅ID

请求参数

表 9-85 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

无

请求示例

取消订阅

```
DELETE https://{endpoint}/v1/aihub/subscriptions/{subscription_id}
```

响应示例

无

状态码

状态码	描述
204	操作成功

错误码

请参见[错误码](#)。

9.4 入库

9.4.1 资产版本入库

功能介绍

在增加版本接口中，没有填写location信息，则需要手动调这个接口来完成入库操作。意义在于，只有完成入库，资产才算真正发布到AI Hub中。

URI

POST /v1/aihub/contents/{content_id}/versions/{version_id}/cargo

表 9-86 路径参数

参数	是否必选	参数类型	描述
content_id	是	String	资产id
version_id	是	String	版本ID

请求参数

表 9-87 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 9-88 请求 Body 参数

参数	是否必选	参数类型	描述
asset_locations	是	Array of AssetLocation objects	资产实体文件所在的路径信息

表 9-89 AssetLocation

参数	是否必选	参数类型	描述
location_type	是	Integer	位置类型，取值为0-1，0表示OBS，1表示SWR
region	是	String	区域名
source_mark	否	String	用于区分多个地址的标志位
location_uri	是	String	来源uri。obs地址：/桶名/文件夹名/。swr地址：repo/imageName:tag

响应参数

状态码： 201

表 9-90 响应 Body 参数

参数	参数类型	描述
content_uri	String	资产详情页

请求示例

给商品资产进行入库

```
POST https://{endpoint}/v1/aihub/contents/{content_id}/versions/{version_id}/cargo
{
  "asset_locations": [ {
    "region": "example",
    "location_type": 0,
    "source_mark": "obs path",
    "location_uri": "/bucket-1/folder/dir/"
  } ]
}
```

响应示例

状态码： 201

操作成功

```
{
  "content_uri": "https://marketplace.xxxxxxx.huawei.com/markets2/aihub/datasets/detail/?
content_id=8658fbc4-bbbc-4f90-81ce-020768aada7c"
}
```

状态码

状态码	描述
201	操作成功

错误码

请参见[错误码](#)。

9.5 审核

9.5.1 管理员审核资产

功能介绍

对用户发布的资产，管理员提交审核意见。

URI

POST /v1/aihub/contents/{content_id}/review

表 9-91 路径参数

参数	是否必选	参数类型	描述
content_id	是	String	资产ID

请求参数

表 9-92 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 9-93 请求 Body 参数

参数	是否必选	参数类型	描述
status	是	Integer	审核状态。1-审核通过，2-审核不通过
message	否	String	审核意见信息。审核不通过，则必须有审核意见。字符限制为字母、中文、数字和下划线、冒号、顿号和句号，长度不超过1024

响应参数

状态码： 200

表 9-94 响应 Body 参数

参数	参数类型	描述
is_success	Boolean	操作成功

请求示例

管理员审核用户发布的资产

```
POST https://{endpoint}/v1/aihub/contents/5142ac43-2796-495f-acef-79401c21cb2b/review
{
  "status" : 2,
  "message" : "notpass"
}
```

响应示例

状态码： 200

审核成功

```
{
  "is_success" : true
}
```

状态码

状态码	描述
200	审核成功

错误码

请参见[错误码](#)。

9.5.2 用户重试审核资产

功能介绍

对管理员审核为不通过的资产，用户重试审核，让管理员重新审核。

URI

PUT /v1/aihub/contents/{content_id}/review

表 9-95 路径参数

参数	是否必选	参数类型	描述
content_id	是	String	资产ID

请求参数

表 9-96 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 9-97 响应 Body 参数

参数	参数类型	描述
is_success	Boolean	操作成功

请求示例

用户重试审核发布的资产

```
PUT https://{endpoint}/v1/aihub/contents/5142ac43-2796-495f-acef-79401c21cb2b/review
```

响应示例

状态码： 200

重试审核成功

```
{
  "is_success": true
}
```

状态码

状态码	描述
200	重试审核成功

错误码

请参见[错误码](#)。

10 专属资源池

10.1 资源池作业管理

10.1.1 查询专属资源池作业列表

功能介绍

查询专属资源池作业列表。

URI

GET /v2/{project_id}/pools/{pool_name}/workloads

表 10-1 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	作业所属的资源池ID。取值资源池详情的metadata.name字段。

表 10-2 Query 参数

参数	是否必选	参数类型	描述
type	否	Array of strings	作业所属业务。可选值如下： - train：训练作业 - infer：推理作业 - x-infer：新版推理作业

参数	是否必选	参数类型	描述
status	否	String	作业状态。可选值如下： - Queue：排队中 - Pending：等待中 - Abnormal：异常 - Terminating：中止中 - Creating：创建中 - Running：运行中 - Completed：已完成 - Terminated：已终止 - Failed：运行失败
sort	否	String	排序依据字段。可选值： create_time：根据作业创建时间排序
ascend	否	Boolean	是否按照升序排序。
offset	否	String	分页查询，起始位置。
limit	否	Integer	单页查询最大数量，值为空或者0时默认为500，最大值为500。

请求参数

无

响应参数

状态码：200

表 10-3 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： WorkloadList：作业列表
items	Array of Workload objects	作业列表。

表 10-4 Workload

参数	参数类型	描述
apiVersion	String	资源版本。可选值如下： v1
kind	String	资源类型，可选值如下： Workload
type	String	作业所属业务类型。可选值如下： - train：训练作业 - infer：推理服务
namespace	String	作业所属资源池ID。
name	String	作业名称
jobName	String	上层业务作业名称
uid	String	作业uid。
jobUUID	String	上层业务作业id
flavor	String	作业规格。
status	String	作业状态。
resourceRequirement	Array of ResourceRequirement objects	运行作业的资源请求量。
priority	String	作业优先级。
runningDuration	Integer	作业运行时长。
pendingDuration	Integer	作业排队时长。
pendingPosition	Integer	作业排队位置。
createTime	Integer	作业创建时间。
gvk	String	作业GVK。
hostIps	String	作业运行的节点IP列表，逗号分隔。
nodes	WorkloadNodeVO object	

表 10-5 ResourceRequirement

参数	参数类型	描述
cpu	String	CPU使用量。
memory	String	内存使用量。

参数	参数类型	描述
nvidia.com/gpu	String	GPU资源使用量。
huawei.com/ascend-snt3	String	昇腾snt3资源使用量。
huawei.com/ascend-snt9	String	昇腾snt9资源使用量。

表 10-6 WorkloadNodeVO

参数	参数类型	描述
hostIp	String	节点ip
npuTopologyPlacement	String	910卡占用拓扑信息，比特位从右往左卡编号0-15，比特位1代表占用。
resourceRequirement	ResourceRequirementVO object	请求资源量

表 10-7 ResourceRequirementVO

参数	参数类型	描述
cpu	String	cpu使用信息
memory	String	memory使用信息
nvidia.com/gpu	String	nvidia.com/gpu使用信息
huawei.com/ascend-310	String	huawei.com/ascend-310使用信息
huawei.com/ascend-1980	String	huawei.com/ascend-1980使用信息

状态码：400

表 10-8 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：404

表 10-9 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

查询资源池作业列表。

```
GET https://{endpoint}/v2/{project_id}/pools/{pool_name}/workloads?
offset=0&limit=10&sort=create_time&ascend=false&type=train&type=infer
```

响应示例

状态码：200

OK。

```
{
  "kind": "WorkloadList",
  "apiVersion": "v1",
  "metadata": { },
  "items": [ {
    "kind": "Workload",
    "apiVersion": "v1",
    "uid": "6715ceb5-df65-456f-b185-07e047c9745c",
    "jobUUID": "c237e9e1-50e7-4c4d-97ba-f4a5e0f62f70",
    "name": "modelarts-job-c237e9e1-50e7-4c4d-97ba-f4a5e0f62f70",
    "jobName": "autotest_b82d17",
    "type": "train",
    "namespace": "pool-train-dev-cpu-public-fab2c5cf438b4f0c851fdcdf08704898",
    "status": "Queue",
    "resourceRequirement": {
      "cpu": "1 Cores",
      "memory": "6.52 GiB"
    },
    "priority": "0",
    "createTime": 1727254947000,
    "pendingDuration": 1918236,
    "pendingPosition": -1,
    "gvk": "batch.volcano.sh/v1alpha1, Kind=Job",
    "isDeleted": "false"
  }, {
    "kind": "Workload",
    "apiVersion": "v1",
    "uid": "1c65790f-dd05-4ae8-b39f-a8c27eb798be",
    "jobUUID": "3b6fb671-155e-4769-81b9-cdebfade9276",
    "name": "modelarts-job-3b6fb671-155e-4769-81b9-cdebfade9276",
    "jobName": "autotest_626a6a",
    "type": "train",
    "namespace": "pool-train-dev-cpu-public-fab2c5cf438b4f0c851fdcdf08704898",
    "status": "Queue",
    "resourceRequirement": {
      "cpu": "1 Cores",
      "memory": "6.52 GiB"
    },
    "priority": "0",
    "createTime": 1727253353000,
    "pendingDuration": 1919830,
    "pendingPosition": -1,
    "gvk": "batch.volcano.sh/v1alpha1, Kind=Job",
```

```
{
  "isDeleted" : "false"
}, {
  "kind" : "Workload",
  "apiVersion" : "v1",
  "uid" : "27ee2204-d4e1-48be-90ba-6fdf86dbde5c",
  "jobUUID" : "50fad3c2-3704-43d3-9d7b-d989e684b83d",
  "name" : "modelarts-job-50fad3c2-3704-43d3-9d7b-d989e684b83d",
  "jobName" : "autotest_12fk8l",
  "type" : "train",
  "namespace" : "pool-train-dev-cpu-public-fab2c5cf438b4f0c851fdcdf08704898",
  "status" : "Queue",
  "resourceRequirement" : {
    "cpu" : "1 Cores",
    "memory" : "6.52 GiB"
  },
  "priority" : "0",
  "createTime" : 1721980860000,
  "pendingDuration" : 7192323,
  "pendingPosition" : -1,
  "gvk" : "batch.volcano.sh/v1alpha1, Kind=Job",
  "isDeleted" : "false"
}, {
  "kind" : "Workload",
  "apiVersion" : "v1",
  "uid" : "77f9fb8f-2c26-474d-acf3-421c3538fbfa",
  "jobUUID" : "674a754c-9dad-4fa7-b3cf-f00065b9283a",
  "name" : "modelarts-job-674a754c-9dad-4fa7-b3cf-f00065b9283a",
  "jobName" : "autotest_64395q",
  "type" : "train",
  "namespace" : "pool-train-dev-cpu-public-fab2c5cf438b4f0c851fdcdf08704898",
  "status" : "Queue",
  "resourceRequirement" : {
    "cpu" : "1 Cores",
    "memory" : "6.52 GiB"
  },
  "priority" : "0",
  "createTime" : 1721975001000,
  "pendingDuration" : 7198182,
  "pendingPosition" : -1,
  "gvk" : "batch.volcano.sh/v1alpha1, Kind=Job",
  "isDeleted" : "false"
}, {
  "kind" : "Workload",
  "apiVersion" : "v1",
  "uid" : "4bac907d-43a4-44f0-98ee-a802b8e0558d",
  "jobUUID" : "a36ac88b-e54d-49ba-9869-d1fd3b71691c",
  "name" : "modelarts-job-a36ac88b-e54d-49ba-9869-d1fd3b71691c",
  "jobName" : "autotest_949870",
  "type" : "train",
  "namespace" : "pool-train-dev-cpu-public-fab2c5cf438b4f0c851fdcdf08704898",
  "status" : "Queue",
  "resourceRequirement" : {
    "cpu" : "1 Cores",
    "memory" : "6.52 GiB"
  },
  "priority" : "0",
  "createTime" : 1720700120000,
  "pendingDuration" : 8473063,
  "pendingPosition" : -1,
  "gvk" : "batch.volcano.sh/v1alpha1, Kind=Job",
  "isDeleted" : "false"
} ],
"total" : 234
}
```

状态码：400

Bad Request。

```
{
  "error_code" : "ModelArts.50004000",
  "error_msg" : "Bad request."
}
```

状态码：404

Not Found。

```
{
  "error_code" : "ModelArts.50015001",
  "error_msg" : "Pool {name} not found."
}
```

状态码

状态码	描述
200	OK。
400	Bad Request。
404	Not Found。

错误码

请参见[错误码](#)。

10.1.2 查询专属资源池作业统计信息

功能介绍

查询专属资源池作业统计信息。

URI

GET /v2/{project_id}/statistics/pools/{pool_name}/workloads

表 10-10 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	作业所属的资源池ID。取值资源池详情的metadata.name字段。

请求参数

无

响应参数

状态码：200

表 10-11 响应 Body 参数

参数	参数类型	描述
statics	WorkloadListStatistics object	资源池中作业的统计信息。

表 10-12 WorkloadListStatistics

参数	参数类型	描述
total	Integer	统计信息列表数量。
items	Array of WorkloadStatistics objects	不同作业类型统计信息。

表 10-13 WorkloadStatistics

参数	参数类型	描述
type	String	作业类型。可选值如下： - train：训练作业 - infer：推理作业 - x-infer：新版推理作业
total	Integer	作业个数。
status	WorkloadStatusStatistics object	不同状态下作业个数。

表 10-14 WorkloadStatusStatistics

参数	参数类型	描述
Queue	String	资源池中排队的作业个数。
Pending	String	资源池中调度中的作业个数。
Abnormal	String	异常的作业个数。
Terminating	String	终止中的作业个数。
Creating	String	创建中的作业个数。

参数	参数类型	描述
Running	String	运行中的作业个数。
Completed	String	已完成的作业个数。
Terminated	String	已终止的作业个数。
Failed	String	运行失败的作业个数。

状态码：400

表 10-15 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：404

表 10-16 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

查询资源池的作业统计信息。

GET https://{endpoint}/v2/{project_id}/statistics/pools/{pool_name}/workloads

响应示例

状态码：200

OK。

```
{
  "statistics": {
    "total": 234,
    "items": [ {
      "type": "train",
      "total": 234,
      "status": {
        "Pending": 0,
        "Queue": 234,
        "Running": 0
      }
    }
  ]
}
```

```
    }  
  }  
}
```

状态码：400

Bad Request。

```
{  
  "error_code" : "ModelArts.50004000",  
  "error_msg" : "Bad request."  
}
```

状态码：404

Not Found。

```
{  
  "error_code" : "ModelArts.50015001",  
  "error_msg" : "Pool {name} not found."  
}
```

状态码

状态码	描述
200	OK。
400	Bad Request。
404	Not Found。

错误码

请参见[错误码](#)。

10.2 配置管理

10.2.1 查询 OS 的配置参数

功能介绍

获取ModelArts OS服务的配置参数，如网络网段，用户资源配额等。

URI

GET /v1/{project_id}/os-user-config

表 10-17 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

请求参数

无

响应参数

状态码：200

表 10-18 响应 Body 参数

参数	参数类型	描述
networkCidrs	Array of strings	网络配置项。
networkQuota	Integer	用户可创建网络个数配额。
networkSubnetTypes	Array of strings	可选的网络子网类型列表。
poolQuota	Integer	用户可创建资源池个数配额。
poolHighAvailable	Boolean	当前环境/局点是否支持创建高可用资源池。
maxPoolFlavors	Integer	资源池支持包含的最多的资源规格数量。
clusterFlavorSpecs	String	k8s集群管理节点规格列表。
licenseScopeType	String	当前环境导入的license支持创建的作业类型。可选值如下： - single：标识只支持创建单训练、单推理的资源池 - multi：表示支持创建训推共池。
nodeOSVersionSupport	Array of OsVersion objects	支持选择的节点镜像版本列表。
volumeTypes	Array of strings	支持的磁盘类型。
poolScopePlugins	Array of PoolScopePlugin objects	资源池作业类型相关配置信息。

表 10-19 OsVersion

参数	参数类型	描述
name	String	系统镜像的名称。
endOfService	String	系统镜像的服务到期时间。

表 10-20 PoolScopePlugin

参数	参数类型	描述
scope	String	作业类型。可选值如下： - Train：训练作业 - Infer：推理作业 - X-Infer：Kubeinfer作业
plugins	Array of strings	插件列表。
externalDependency	Boolean	是否有外部依赖。可选值如下： - false：启用该作业类型没有外部依赖。 - true：启用该作业类型有外部依赖。
supportRetry	Boolean	是否支持失败重试。可选值如下： - false：不支持。 - true：支持。

状态码：404

表 10-21 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

查询配置参数。

```
GET https://{endpoint}/v1/{project_id}/os-user-config
```

响应示例

状态码：200

OK。

```
{
  "networkCidrs": [ "192.168.0.0/24", "172.16.31.0/16" ],
  "networkQuota": 15,
  "poolQuota": 15,
  "poolHighAvailable": true
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.2.2 查询 OS 的配额

功能介绍

获取ModelArts OS服务中部分资源的配额，如资源池配额、网络配额等。

URI

GET /v1/{project_id}/quotas

表 10-22 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

请求参数

无

响应参数

状态码：200

表 10-23 响应 Body 参数

参数	参数类型	描述
quotas	Quota object	资源配额。

表 10-24 Quota

参数	参数类型	描述
resources	Array of ResourceQuota objects	资源的配额信息。

表 10-25 ResourceQuota

参数	参数类型	描述
type	String	资源类型。
quota	String	资源配额上限。
used	String	已使用配额。

状态码：404

表 10-26 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

查询配额信息。

```
GET https://{endpoint}/v1/{project_id}/quotas
```

响应示例

状态码：200

OK。

```
{
  "quotas": {
    "resources": [ {
      "type": "pool",
      "quota": 15,
      "used": 10
    }, {
      "type": "network",
      "quota": 15,
      "used": 10
    } ]
  }
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.3 插件模板管理

10.3.1 查询插件模板

功能介绍

获取指定插件模板的详细信息。

URI

GET /v1/{project_id}/plugintemplates/{plugintemplate_name}

表 10-27 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
plugintemplate_name	是	String	插件模板的名称。可选值如下： - gpu-driver：GPU驱动插件模板信息 - npu-driver：NPU驱动插件模板信息

请求参数

无

响应参数

状态码：200

表 10-28 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： PluginTemplate：插件模板
metadata	PluginTemplateMetadata object	插件模板的metadata信息。
spec	PluginTemplateSpec object	插件模板的规格信息。

表 10-29 PluginTemplateMetadata

参数	参数类型	描述
name	String	插件模板的名称。
annotations	Map<String,String>	插件模板注解，由key/value组成。

表 10-30 PluginTemplateSpec

参数	参数类型	描述
type	String	插件模板类型。可选值如下： - npu-river：NPU驱动 - gpu-driver：GPU驱动
description	String	插件模板描述。
versions	Map<String, PluginTemplateVersionV2 >	插件模板版本描述信息。

表 10-31 PluginTemplateVersionV2

参数	参数类型	描述
version	String	插件模板的版本号。
creationTimestamp	String	创建时间。
inputs	Object	插件安装参数。

参数	参数类型	描述
translate	Object	供界面使用的翻译信息。
description	String	版本描述信息。
detail	String	版本描述信息。

状态码：404

表 10-32 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

查询插件模板详情。

`https://{endpoint}/v1/{project_id}/plugintemplates/{plugintemplate_name}`

响应示例

状态码：200

OK。

```
{
  "apiVersion": "v1",
  "kind": "PluginTemplate",
  "metadata": {
    "name": "npu-driver"
  },
  "spec": {
    "type": "npuDriver",
    "description": "npu driver"
  },
  "versions": {
    "78-21.0.2": {
      "detail": "c78driver&firmware"
    },
    "77-21.0.cr1": {
      "detail": "c77driver&firmware"
    }
  }
}
```

状态码：404

Not Found。

```
{
  "error_code": "ModelArts.50005101",
  "error_msg": "Plugintemplate {name} not found."
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.3.2 查询插件模板列表

功能介绍

插件模板的查询接口，获取插件模板信息。

URI

GET /v2/{project_id}/plugintemplates

表 10-33 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

表 10-34 Query 参数

参数	是否必选	参数类型	描述
templateName	否	String	指定的插件名称，填写则查询指定名称的插件。
poolName	否	String	指定的资源池名称，填写则查询符合资源池安装条件的插件列表。

请求参数

无

响应参数

状态码：200

表 10-35 响应 Body 参数

参数	参数类型	描述
kind	String	API类型，固定值“PluginTemplateList”，该值不可修改。
apiVersion	String	API版本，固定值“v2”，该值不可修改。
items	Array of PluginTemplateV2 objects	插件模板列表。

表 10-36 PluginTemplateV2

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	资源类型。可选值如下： PluginTemplate：插件模板
metadata	PluginTemplateMetadata object	插件模板的metadata信息。
spec	PluginTemplateSpecV2 object	插件模板的具体信息，如版本列表。

表 10-37 PluginTemplateMetadata

参数	参数类型	描述
name	String	插件模板的名称。
annotations	Map<String,String>	插件模板注解，由key/value组成。

表 10-38 PluginTemplateSpecV2

参数	参数类型	描述
optional	Boolean	是否为必安装插件。
type	String	插件模板类型。可选值如下： - helm：helm类型 - ccePlugin：CCE类型

参数	参数类型	描述
logoURL	String	Logo图片地址。
description	String	插件模板描述。
versions	Array of PluginTemplateVersionV2 objects	插件模板版本的详细信息。

表 10-39 PluginTemplateVersionV2

参数	参数类型	描述
version	String	插件模板的版本号。
creationTimestamp	String	创建时间。
inputs	Object	插件安装参数。
translate	Object	供界面使用的翻译信息。
description	String	版本描述信息。
detail	String	版本描述信息。

状态码：404

表 10-40 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

查询node-local-dns插件模板详情。

```
/v2/${projectId}/plugintemplates?templateName=node-local-dns
{
  "kind": "PluginTemplateList",
  "apiVersion": "v2",
  "items": [ {
    "kind": "PluginTemplate",
    "apiVersion": "v2",
    "metadata": {
      "name": "node-local-dns",
      "annotations": {
        "os.modelarts.plugin/release.name": "NodeLocal DNSCache"
      }
    }
  }
]
```

```
    },
    "spec": {
      "optional": true,
      "versions": [ {
        "version": "1.6.63",
        "description": "NodeLocal DNSCache improves Cluster DNS performance by running a dns caching agent on cluster nodes as a DaemonSet.",
        "creationTimestamp": "2023-05-20T08:50:31Z",
        "inputs": {
          "parameters": {
            "custom": {
              "annotations": { },
              "enable_dnsconfig_admission": true,
              "enable_namespace_admission": true,
              "image": {
                "args": {
                  "healthPort": 8080,
                  "interfaceName": "nodelocaldns",
                  "setupIptables": false,
                  "skipTeardown": true,
                  "skipteardown": true,
                  "syncInterval": "1ns",
                  "upstreamSvc": "coredns"
                },
                "name": "node-cache",
                "pullPolicy": "Always"
              },
              "multiAZBalance": false,
              "multiAZEnabled": false,
              "nameserver": "",
              "ndots": "5",
              "node_match_expressions": [ ],
              "search": "",
              "tolerations": [ {
                "effect": "NoExecute",
                "key": "node.kubernetes.io/not-ready",
                "operator": "Exists",
                "tolerationSeconds": 60
              }, {
                "effect": "NoExecute",
                "key": "node.kubernetes.io/unreachable",
                "operator": "Exists",
                "tolerationSeconds": 60
              } ],
              "zones": [ {
                "plugins": {
                  "cache": {
                    "denial": { },
                    "parameters": 30,
                    "prefetch": { },
                    "server_stale": false,
                    "success": { }
                  },
                  "debug": false,
                  "errors": true,
                  "forward": {
                    "expire": "",
                    "force_tcp": false,
                    "health_check": "",
                    "max_fails": "",
                    "parameters": "__PILLAR_UPSTREAM_SERVERS__",
                    "policy": "",
                    "prefer_udp": false
                  },
                  "log": {
                    "classes": "all",
                    "format": "combined"
                  },
                  "prometheus": true,
```

```
    "reload" : true
  },
  "zone" : ".:53"
}, {
  "plugins" : {
    "cache" : {
      "parameters" : 30
    },
    "debug" : false,
    "errors" : true,
    "forward" : {
      "force_tcp" : true,
      "parameters" : "__PILLAR__CLUSTER__DNS__"
    },
    "log" : {
      "classes" : "all",
      "format" : "combined"
    },
    "prometheus" : true,
    "reload" : true
  },
  "zone" : "ip6.arpa:53"
}, {
  "plugins" : {
    "cache" : {
      "parameters" : 30
    },
    "debug" : false,
    "errors" : true,
    "forward" : {
      "force_tcp" : true,
      "parameters" : "__PILLAR__CLUSTER__DNS__"
    },
    "log" : {
      "classes" : "all",
      "format" : "combined"
    },
    "prometheus" : true,
    "reload" : true
  },
  "zone" : "in-addr.arpa:53"
}, {
  "plugins" : {
    "cache" : {
      "denial" : {
        "size" : 9984,
        "ttl" : 5
      },
      "parameters" : 30,
      "prefetch" : { },
      "success" : {
        "size" : 9984,
        "ttl" : 30
      }
    },
    "debug" : false,
    "errors" : true,
    "forward" : {
      "force_tcp" : true,
      "parameters" : "__PILLAR__CLUSTER__DNS__"
    },
    "health" : {
      "port" : 8080
    },
    "log" : {
      "classes" : "all",
      "format" : "combined"
    },
    "prometheus" : true,
```

```
        "reload" : true
      },
      "zone" : "cluster.local:53"
    } ]
  },
  "flavor1" : {
    "description" : "High availability",
    "is_default" : true,
    "name" : "HA",
    "replicas" : 2,
    "resources" : [ {
      "limitsCpu" : "250m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-admission-controller",
      "replicas" : 2,
      "requestsCpu" : "250m",
      "requestsMem" : "512Mi"
    }, {
      "limitsCpu" : "500m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-cache",
      "requestsCpu" : "25m",
      "requestsMem" : "5Mi"
    } ],
    "size" : "large"
  },
  "flavor2" : {
    "description" : "Has only one instance",
    "name" : "Single",
    "replicas" : 1,
    "resources" : [ {
      "limitsCpu" : "250m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-admission-controller",
      "replicas" : 1,
      "requestsCpu" : "250m",
      "requestsMem" : "512Mi"
    }, {
      "limitsCpu" : "500m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-cache",
      "requestsCpu" : "25m",
      "requestsMem" : "5Mi"
    } ],
    "size" : "small"
  },
  "flavor3" : {
    "description" : "custom resources",
    "name" : "custom-resources",
    "replicas" : 2,
    "resources" : [ {
      "limitsCpu" : "250m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-admission-controller",
      "replicas" : 2,
      "requestsCpu" : "250m",
      "requestsMem" : "512Mi"
    }, {
      "limitsCpu" : "500m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-cache",
      "requestsCpu" : "25m",
      "requestsMem" : "5Mi"
    } ],
    "size" : "custom"
  }
},
"translate" : {
```

```
"zh_CN": {
  "description": {
    "Parameters": {
      "flavor1": {
        "description": "负责DNSConfig自动注入的控制器双副本部署，提升插件可靠性",
        "name": "高可用"
      },
      "flavor2": {
        "description": "负责DNSConfig自动注入的控制器单副本部署，资源消耗低",
        "name": "单实例"
      },
      "flavor3": {
        "description": "自定义规格",
        "name": "自定义规格"
      }
    },
    "Parameters.flavor1.description": "双实例部署，具有高可用能力，需占用更多的计算资源。",
    "Parameters.flavor1.name": "高可用",
    "Parameters.flavor2.description": "单实例部署.",
    "Parameters.flavor2.name": "单实例",
    "Parameters.flavor3.description": "自定义资源规格部署",
    "Parameters.flavor3.name": "自定义"
  },
  "key": null,
  "plugintemplate": {
    "changeLog": "支持Kubernetes v1.31; 更新admission-controller组件日志输出为容器标准输出; node-local-dns支持自定义健康检查端口",
    "components": {
      "node-local-dns-admission-controller": {
        "description": "为Pod提供自动注入DNSConfig功能，会将node-local-dns-cache的地址注入到容器的/etc/resolv.conf中，容器业务解析DNS域名会优先使用本地域名解析的缓存服务",
        "kind": "Deployment"
      },
      "node-local-dns-cache": {
        "description": "为集群中每个节点上部署DNS缓存代理提高集群DNS性能",
        "kind": "DaemonSet"
      }
    },
    "description": "NodeLocal DNSCache是运行在集群节点上的守护程序集，通过DNS缓存代理，提高集群DNS性能。"
  },
  "logoURL": "https://obs.com/plugintemplates/node-local-dnslogo.svg"
}
```

响应示例

状态码：200

OK。

```
{
  "kind": "PluginTemplateList",
  "apiVersion": "v2",
  "items": [ {
    "kind": "PluginTemplate",
    "apiVersion": "v2",
    "metadata": {
      "name": "node-local-dns",
      "annotations": {
        "os.modelarts.plugin/release.name": "NodeLocal DNSCache"
      }
    },
    "spec": {
      "optional": true,

```

```
"versions" : [ {
  "version" : "1.6.63",
  "description" : "NodeLocal DNSCache improves Cluster DNS performance by running a dns caching
agent on cluster nodes as a DaemonSet.",
  "creationTimestamp" : "2023-05-20T08:50:31Z",
  "inputs" : {
    "parameters" : {
      "custom" : {
        "annotations" : { },
        "enable_dnsconfig_admission" : true,
        "enable_namespace_admission" : true,
        "image" : {
          "args" : {
            "healthPort" : 8080,
            "interfaceName" : "nodelocaldns",
            "setupIptables" : false,
            "skipTeardown" : true,
            "skipteardown" : true,
            "syncInterval" : "1ns",
            "upstreamSvc" : "coredns"
          },
          "name" : "node-cache",
          "pullPolicy" : "Always"
        },
        "multiAZBalance" : false,
        "multiAZEnabled" : false,
        "nameserver" : "",
        "ndots" : "5",
        "node_match_expressions" : [ ],
        "search" : "",
        "tolerations" : [ {
          "effect" : "NoExecute",
          "key" : "node.kubernetes.io/not-ready",
          "operator" : "Exists",
          "tolerationSeconds" : 60
        }, {
          "effect" : "NoExecute",
          "key" : "node.kubernetes.io/unreachable",
          "operator" : "Exists",
          "tolerationSeconds" : 60
        } ],
        "zones" : [ {
          "plugins" : {
            "cache" : {
              "denial" : { },
              "parameters" : 30,
              "prefetch" : { },
              "server_stale" : false,
              "success" : { }
            },
            "debug" : false,
            "errors" : true,
            "forward" : {
              "expire" : "",
              "force_tcp" : false,
              "health_check" : "",
              "max_fails" : "",
              "parameters" : "__PILLAR__UPSTREAM__SERVERS__",
              "policy" : "",
              "prefer_udp" : false
            },
            "log" : {
              "classes" : "all",
              "format" : "combined"
            },
            "prometheus" : true,
            "reload" : true
          },
          "zone" : ".:53"
```

```
}, {
  "plugins" : {
    "cache" : {
      "parameters" : 30
    },
    "debug" : false,
    "errors" : true,
    "forward" : {
      "force_tcp" : true,
      "parameters" : "__PILLAR_CLUSTER_DNS__"
    },
    "log" : {
      "classes" : "all",
      "format" : "combined"
    },
    "prometheus" : true,
    "reload" : true
  },
  "zone" : "ip6.arpa:53"
}, {
  "plugins" : {
    "cache" : {
      "parameters" : 30
    },
    "debug" : false,
    "errors" : true,
    "forward" : {
      "force_tcp" : true,
      "parameters" : "__PILLAR_CLUSTER_DNS__"
    },
    "log" : {
      "classes" : "all",
      "format" : "combined"
    },
    "prometheus" : true,
    "reload" : true
  },
  "zone" : "in-addr.arpa:53"
}, {
  "plugins" : {
    "cache" : {
      "denial" : {
        "size" : 9984,
        "ttl" : 5
      },
      "parameters" : 30,
      "prefetch" : { },
      "success" : {
        "size" : 9984,
        "ttl" : 30
      }
    },
    "debug" : false,
    "errors" : true,
    "forward" : {
      "force_tcp" : true,
      "parameters" : "__PILLAR_CLUSTER_DNS__"
    },
    "health" : {
      "port" : 8080
    },
    "log" : {
      "classes" : "all",
      "format" : "combined"
    },
    "prometheus" : true,
    "reload" : true
  },
  "zone" : "cluster.local:53"
```



```
    } ]
  },
  "flavor1" : {
    "description" : "High availability",
    "is_default" : true,
    "name" : "HA",
    "replicas" : 2,
    "resources" : [ {
      "limitsCpu" : "250m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-admission-controller",
      "replicas" : 2,
      "requestsCpu" : "250m",
      "requestsMem" : "512Mi"
    }, {
      "limitsCpu" : "500m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-cache",
      "requestsCpu" : "25m",
      "requestsMem" : "5Mi"
    } ],
    "size" : "large"
  },
  "flavor2" : {
    "description" : "Has only one instance",
    "name" : "Single",
    "replicas" : 1,
    "resources" : [ {
      "limitsCpu" : "250m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-admission-controller",
      "replicas" : 1,
      "requestsCpu" : "250m",
      "requestsMem" : "512Mi"
    }, {
      "limitsCpu" : "500m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-cache",
      "requestsCpu" : "25m",
      "requestsMem" : "5Mi"
    } ],
    "size" : "small"
  },
  "flavor3" : {
    "description" : "custom resources",
    "name" : "custom-resources",
    "replicas" : 2,
    "resources" : [ {
      "limitsCpu" : "250m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-admission-controller",
      "replicas" : 2,
      "requestsCpu" : "250m",
      "requestsMem" : "512Mi"
    }, {
      "limitsCpu" : "500m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-cache",
      "requestsCpu" : "25m",
      "requestsMem" : "5Mi"
    } ],
    "size" : "custom"
  }
},
"translate" : {
  "zh_CN" : {
    "description" : {
      "Parameters" : {
```

```
    "flavor1": {
      "description": "负责DNSConfig自动注入的控制器双副本部署，提升插件可靠性",
      "name": "高可用"
    },
    "flavor2": {
      "description": "负责DNSConfig自动注入的控制器单副本部署，资源消耗低",
      "name": "单实例"
    },
    "flavor3": {
      "description": "自定义规格",
      "name": "自定义规格"
    }
  },
  "Parameters.flavor1.description": "双实例部署，具有高可用能力，需占用更多的计算资源。",
  "Parameters.flavor1.name": "高可用",
  "Parameters.flavor2.description": "单实例部署.",
  "Parameters.flavor2.name": "单实例",
  "Parameters.flavor3.description": "自定义资源规格部署",
  "Parameters.flavor3.name": "自定义"
},
"key": null,
"plugintemplate": {
  "changeLog": "支持Kubernetes v1.31; 更新admission-controller组件日志输出为容器标准输出; node-local-dns支持自定义健康检查端口",
  "components": {
    "node-local-dns-admission-controller": {
      "description": "为Pod提供自动注入DNSConfig功能，会将node-local-dns-cache的地址注入到容器的/etc/resolv.conf中，容器业务解析DNS域名会优先使用本地域名解析的缓存服务",
      "kind": "Deployment"
    },
    "node-local-dns-cache": {
      "description": "为集群中每个节点上部署DNS缓存代理提高集群DNS性能",
      "kind": "DaemonSet"
    }
  },
  "description": "NodeLocal DNSCache是运行在集群节点上的守护程序集，通过DNS缓存代理，提高集群DNS性能。"
}
}
},
"logoURL": "https://obs.com/plugintemplates/node-local-dnslogo.svg"
}
}]
}
```

状态码：404

Not Found。

```
{
  "error_code": "ModelArts.50005101",
  "error_msg": "Plugintemplate {name} not found."
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.4 虚拟资源规格

10.4.1 查询虚拟资源规格模板

功能介绍

获取指定虚拟资源切分模板的详细信息。

URI

GET /v1/{project_id}/virtualresourcetemplates/{virtualresourcetemplate_name}

表 10-41 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
virtualresourc etemplate_na me	是	String	虚拟资源切分模板名称，对应ListVirtualresourceFlavors查出的资源规格的spec的virtualResourceTemplateName字段。

请求参数

无

响应参数

状态码：200

表 10-42 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： VirtualResourceTemplate

参数	参数类型	描述
metadata	VirtualResourceTemplateMetadata object	虚拟资源切分模板的metadata信息。
spec	VirtualResourceTemplateSpec object	虚拟资源切分模板的规格信息。

表 10-43 VirtualResourceTemplateMetadata

参数	参数类型	描述
name	String	npu虚拟资源切分模板名称。

表 10-44 VirtualResourceTemplateSpec

参数	参数类型	描述
resources	String	规格的物理资源信息。
resourceKey	String	NPU卡的resourceKey。
virtualResources	Array of VirtualResource objects	虚拟资源列表信息。

表 10-45 VirtualResource

参数	参数类型	描述
name	String	虚拟资源模板的名称。
resources	Map<String,String>	虚拟化模板使用资源量。
resourceKey	String	虚拟化模板resourcekey。

状态码：404

表 10-46 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

查询虚拟资源模板详情

GET https://{endpoint}/v1/{project_id}/virtualresourcetemplates/{virtualresourcetemplate_name}

响应示例

状态码：200

OK。

```
{
  "apiVersion" : "v1",
  "kind" : "VirtualResourceTemplate",
  "metadata" : {
    "name" : "snt9-280t"
  },
  "spec" : {
    "resources" : {
      "AICORE" : 10,
      "AICPU" : 5,
      "memory" : "32G"
    }
  },
  "virtualResources" : [ {
    "name" : "vir5_1c_8g",
    "resources" : {
      "AICORE" : 5,
      "AICPU" : 1,
      "memory" : "8G"
    },
    "resourceKey" : "npu.accelerator/snt9-5c.1cpu.8g"
  } ]
}
```

状态码：404

Not Found。

```
{
  "error_code" : "ModelArts.50005101",
  "error_msg" : "VirtualResourceTemplate {name} not found."
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.4.2 查询虚拟资源规格列表

功能介绍

获取虚拟资源规格列表。

URI

GET /v1/{project_id}/virtualresourceflavors

表 10-47 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

请求参数

无

响应参数

状态码：200

表 10-48 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： ResourceFlavorList：资源规格列表
metadata	ResourceFlavorListMetadata object	资源规格列表metadata信息。
items	Array of ResourceFlavor objects	资源规格列表。

表 10-49 ResourceFlavorListMetadata

参数	参数类型	描述
continue	String	分页查询时，下一次查询位置。

参数	参数类型	描述
remainingItemCount	Integer	剩余资源个数。

表 10-50 ResourceFlavor

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： ResourceFlavor：资源规格
metadata	ResourceFlavorMetadata object	资源规格的metadata信息。
spec	ResourceFlavorSpec object	资源规格的描述信息

表 10-51 ResourceFlavorMetadata

参数	参数类型	描述
name	String	资源规格名称。

表 10-52 ResourceFlavorSpec

参数	参数类型	描述
type	String	虚拟资源规格类型。可选值如下： Logical：逻辑资源
cpuArch	String	计算机架构。可选值如下： - x86：x86架构 - arm64：ARM架构
cpu	String	CPU核心数量。
memory	String	内存大小，单位为Gi。
npu	ResourceFlavorXpu object	虚拟NPU信息。
virtualResourceTemplateName	String	资源规格对应的npu虚拟资源模板名。

表 10-53 ResourceFlavorXpu

参数	参数类型	描述
type	String	虚拟NPU切分卡类型，和查询到的虚拟资源模板对应。
size	String	均为1。
resourceKey	String	虚拟NPU切分卡resourcekey

状态码：404

表 10-54 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

查询npu虚拟切分资源规格

GET https://{endpoint}/v1/{project_id}/virtualresourceflavors

响应示例

状态码：200

OK。

```
{
  "kind": "ResourceFlavorList",
  "apiVersion": "v1",
  "metadata": { },
  "items": [ {
    "kind": "ResourceFlavor",
    "apiVersion": "v1",
    "metadata": {
      "name": "snt9-280t-vir10-3c-16g",
      "labels": { }
    },
    "spec": {
      "cpuArch": "arm64",
      "cpu": "8",
      "memory": "32Gi",
      "type": "Logical",
      "virtualResourceTemplateName": "snt9-280t",
      "visibility": "invisible"
    }
  } ]
}
```

状态码：404

Not Found。


```
{
  "error_code" : "ModelArts.50005101",
  "error_msg" : "VirtualResourceTemplate {name} not found."
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.5 节点管理

10.5.1 查询资源池节点列表

功能介绍

查询资源池中的节点列表。

URI

GET /v2/{project_id}/pools/{pool_name}/nodes

表 10-55 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池ID。取值资源池详情的 metadata.name 字段。

表 10-56 Query 参数

参数	是否必选	参数类型	描述
continue	否	String	分页查询时上一页位置。
limit	否	Integer	分页单次查询返回数。

请求参数

无

响应参数

状态码：200

表 10-57 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	资源类型。可选值如下： NodeList：节点列表
metadata	NodeListMetadata object	资源列表的metadata，包含分页等信息。
items	Array of Node objects	节点列表。

表 10-58 NodeListMetadata

参数	参数类型	描述
continue	String	分页查询时，下一次查询位置。
remainingItemCount	Long	剩余资源个数。

表 10-59 Node

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	资源类型。可选值如下： Node：节点
metadata	NodeMetadata object	节点metadata信息，包括节点名称，创建时间以及计费模式等信息。
spec	NodeSpec object	节点期望信息。
status	NodeStatus object	节点状态信息。

表 10-60 NodeMetadata

参数	参数类型	描述
name	String	节点名称。
creationTimestamp	String	创建时间。
labels	NodeLabels object	节点上的标签信息。
annotations	NodeVOAnnotations object	节点annotations信息

表 10-61 NodeLabels

参数	参数类型	描述
os.modelarts.node/cluster	String	节点所在的集群名称。

表 10-62 NodeVOAnnotations

参数	参数类型	描述
os.modelarts/npu-topology-placement	String	910卡占用拓扑信息，比特位从右往左卡编号0-15，比特位1代表占用。
os.modelarts.node/drain	String	节点排水信息。

表 10-63 NodeSpec

参数	参数类型	描述
flavor	String	节点规格。
hostNetwork	NodeNetwork object	节点网络信息。

表 10-64 NodeNetwork

参数	参数类型	描述
vpc	String	vpc id。
subnet	String	子网id。

参数	参数类型	描述
securityGroups	Array of strings	安全组id集合。

表 10-65 NodeStatus

参数	参数类型	描述
phase	String	节点当前状态。可选值如下： - Available：节点可用 - Creating：节点创建中 - Deleting：节点删除中 - Abnormal：节点不正常
az	String	节点所在的可用区。
privateIp	String	节点的IP地址。
resources	NodeResource object	节点资源量信息。
availableResources	NodeResource object	节点可用资源量信息。

表 10-66 NodeResource

参数	参数类型	描述
cpu	String	CPU资源量。
memory	String	内存资源量。
nvidia.com/gpu	String	GPU节点的GPU资源量。
huawei.com/ascend-snt3	String	昇腾snt3节点的NPU资源量，包括ascend-snt3或ascend-snt3p。
huawei.com/ascend-1980	String	昇腾1980节点的NPU资源量，包括ascend-1980。

状态码：404

表 10-67 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

查询资源池的节点列表。

```
GET https://{endpoint}/v2/{project_id}/pools/{pool_name}/nodes
{ }
```

响应示例

状态码：200

OK。

```
{
  "kind" : "NodeList",
  "apiVersion" : "v2",
  "metadata" : { },
  "items" : [ {
    "kind" : "Node",
    "apiVersion" : "v2",
    "metadata" : {
      "name" : "os-node-created-zlncn",
      "creationTimestamp" : "2022-09-16T05:32:44Z"
    },
    "spec" : {
      "flavor" : "modelarts.vm.cpu.4ud"
    },
    "status" : {
      "phase" : "Available",
      "az" : "xx-xxxx-xx",
      "privateIp" : "192.168.0.1",
      "resources" : {
        "cpu" : "3920m",
        "memory" : "6270Mi"
      },
      "availableResources" : {
        "cpu" : "2970m",
        "memory" : "4558Mi"
      }
    }
  }, {
    "kind" : "Node",
    "apiVersion" : "v2",
    "metadata" : {
      "name" : "os-node-created-4s522",
      "creationTimestamp" : "2022-09-16T03:20:53Z"
    },
    "spec" : {
      "flavor" : "modelarts.vm.cpu.4ud"
    },
    "status" : {
      "phase" : "Available",
      "az" : "xx-xxxx-xx",
      "privateIp" : "192.168.0.2",
      "resources" : {
        "cpu" : "3920m",
        "memory" : "6270Mi"
      },
      "availableResources" : {
        "cpu" : "2970m",
        "memory" : "4558Mi"
      }
    }
  }
], { }
```

```
"kind": "Node",
"apiVersion": "v2",
"metadata": {
  "name": "os-node-created-v7hfj",
  "creationTimestamp": "2022-09-16T09:16:37Z"
},
"spec": {
  "flavor": "modelarts.vm.cpu.4ud"
},
"status": {
  "phase": "Available",
  "az": "xx-xxx-xx",
  "privateIp": "192.168.0.3",
  "resources": {
    "cpu": "3920m",
    "memory": "6270Mi"
  },
  "availableResources": {
    "cpu": "3720m",
    "memory": "5670Mi"
  }
}
}]
}
```

状态码：404

Not Found。

```
{
  "error_code": "ModelArts.50015001",
  "error_msg": "pool not found"
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.5.2 批量删除节点

功能介绍

批量删除指定资源池中的节点，资源池中至少保留一个节点。

URI

POST /v2/{project_id}/pools/{pool_name}/nodes/batch-delete

表 10-68 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池ID。取值资源池详情的 metadata.name 字段。

请求参数

表 10-69 请求 Body 参数

参数	是否必选	参数类型	描述
deleteNodeNames	是	Array of strings	待删除的节点名称列表。

响应参数

状态码：200

OK。

状态码：404

表 10-70 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

```
POST /v2/{project_id}/pools/{pool_name}/nodes/batch-delete
{
  "deleteNodeNames": [ "os-node-created-mnmc" ]
}
```

响应示例

状态码：404

Not Found。

```
{
  "error_code": "ModelArts.50015001",
  "error_msg": "pool not found"
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.5.3 批量更新节点

功能介绍

批量更新节点。

URI

POST /v2/{project_id}/pools/{pool_name}/nodes/batch-update

表 10-71 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池ID。取值资源池详情的 metadata.name 字段。

请求参数

表 10-72 请求 Body 参数

参数	是否必选	参数类型	描述
nodeNames	是	Array of strings	需要更新的节点名称列表。
action	是	String	节点更新的类型。可选值如下： - openHaRedundant：开启节点的高可用冗余标签 - closeHaRedundant：关闭节点的高可用冗余标签

响应参数

状态码：200

表 10-73 响应 Body 参数

参数	参数类型	描述
successNodeNames	Array of strings	更新成功的节点名称列表。
failNodeNames	Array of strings	更新失败的节点名称列表。

状态码：404

表 10-74 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

开启节点高可用冗余。

```
POST /v2/{project_id}/pools/{pool_name}/nodes/batch-update
{
  "nodeNames": [ "os-node-created-xzz78" ],
  "action": "openHaRedundant"
}
```

响应示例

状态码：200

OK。

```
{
  "nodes": [ {
    "name": "os-node-created-xzz78",
    "status": "success"
  } ]
}
```

状态码：404

Not Found。

```
{
  "error_code": "ModelArts.50015001",
  "error_msg": "pool not found"
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.5.4 批量为节点绑定逻辑子池

功能介绍

当物理专属池开启节点绑定时，可以对逻辑子池中的节点进行逻辑子池的换绑。

URI

POST /v2/{project_id}/pools/{pool_name}/nodes/batch-bind

表 10-75 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池ID。取值资源池详情的metadata.name字段。

请求参数

表 10-76 请求 Body 参数

参数	是否必选	参数类型	描述
nodes	是	Array of BindNodeItem objects	需要进行换绑的节点列表。
drain	否	Boolean	是否对换绑的节点进行排水。 true表示排水。

表 10-77 BindNodeItem

参数	是否必选	参数类型	描述
name	是	String	换绑的节点的名称。
quotaName	是	String	节点绑定的逻辑子池的ID。值为空则节点不绑定任何逻辑子池。

响应参数

状态码：200

OK。

状态码：404

表 10-78 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

将节点绑定到逻辑子池pool-a26d-prjid中。

```
POST /v2/{project_id}/pools/{pool_name}/nodes/batch-bind
{
  "nodes": [ {
    "name": "os-node-created-8888g",
    "quotaName": "pool-a26d-prjid"
  } ]
}
```

响应示例

状态码：200

OK。

```
{}
```

状态码：404

Not Found。

```
{
  "error_code": "ModelArts.50015001",
  "error_msg": "pool not found"
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.6 网络管理

10.6.1 创建网络资源

功能介绍

创建网络资源。

URI

POST /v1/{project_id}/networks

表 10-79 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

请求参数

表 10-80 请求 Body 参数

参数	是否必选	参数类型	描述
apiVersion	是	String	API版本。可选值如下： v1
kind	是	String	资源类型。可选值如下： Network：网络
metadata	是	NetworkMetadataCreation object	网络资源的metadata信息。

参数	是否必选	参数类型	描述
spec	是	NetworkSpecCreation object	网络资源的描述信息。

表 10-81 NetworkMetadataCreation

参数	是否必选	参数类型	描述
labels	是	NetworkMetadataLabels object	网络资源的标签信息。

表 10-82 NetworkMetadataLabels

参数	是否必选	参数类型	描述
os.modelarts/ name	是	String	用户指定的network名称。
os.modelarts/ workspace.id	否	String	工作空间ID，默认值为0。

表 10-83 NetworkSpecCreation

参数	是否必选	参数类型	描述
cidr	是	String	网络的cidr。取值范围： 172.16.0.0/12~24 192.168.0.0/16~24。

响应参数

状态码：200

表 10-84 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： Network：网络

参数	参数类型	描述
metadata	NetworkMetadata object	网络资源的metadata信息。
spec	NetworkSpec object	网络资源的描述信息。
status	NetworkStatus object	网络资源的状态信息。

表 10-85 NetworkMetadata

参数	参数类型	描述
name	String	系统自动生成的network名称，相当于networkId。
creationTimestamp	String	时间戳，"2021-11-01T03:49:41Z"。
labels	NetworkMetadataLabels object	网络资源的标签信息。
annotations	NetworkMetadataAnnotations object	网络资源的注释信息。

表 10-86 NetworkMetadataLabels

参数	参数类型	描述
os.modelarts/name	String	用户指定的network名称。
os.modelarts/workspace.id	String	工作空间ID，默认值为0。

表 10-87 NetworkMetadataAnnotations

参数	参数类型	描述
os.modelarts/description	String	网络资源描述，用于说明用于某种场景。不能包含字符!<>=&"'

表 10-88 NetworkSpec

参数	参数类型	描述
cidr	String	网络的cidr。取值范围： 172.16.0.0/12~24 192.168.0.0/16~24。
connection	NetworkConnection object	当前网络与其他云服务的连通信息。

表 10-89 NetworkConnection

参数	参数类型	描述
peerConnectionList	Array of PeerConnectionItem objects	Peer方式打通网络列表。
sfsTurboConnectionList	Array of SfsTurboConnectionItem objects	挂载网卡方式打通SFS Turbo列表。

表 10-90 PeerConnectionItem

参数	参数类型	描述
peerVpcId	String	对端的VPC ID。
peerSubnetId	String	对端的子网ID。
defaultGateWay	Boolean	创建默认路由的开关，默认为false不创建。

表 10-91 SfsTurboConnectionItem

参数	参数类型	描述
name	String	SFS Turbo实例的名称。
sfsId	String	SFS Turbo实例的ID。

表 10-92 NetworkStatus

参数	参数类型	描述
phase	String	网络的当前状态。可选值如下： - Creating：网络创建中 - Active：网络正常 - Abnormal：网络不正常
connectionStatus	NetworkConnectionStatus object	网络与其他云服务连通状态信息。

表 10-93 NetworkConnectionStatus

参数	参数类型	描述
peerConnectionStatus	Array of PeerConnectionStatus objects	Peer方式打通网络的状态信息列表。
sfsTurboStatus	Array of SfsTurboConnectionStatus objects	网络可连通的SFS Turbo信息列表。

表 10-94 PeerConnectionStatus

参数	参数类型	描述
peerVpcId	String	对端的VPC ID。
peerSubnetId	String	对端的子网ID。
defaultGateWay	Boolean	创建默认路由的开关，默认为false不创建。
phase	String	网络的连接状态。可选值如下： - Connecting：网络连接中 - Active：网络连接正常 - Abnormal：网络连接不正常

表 10-95 SfsTurboConnectionStatus

参数	参数类型	描述
name	String	SFS Turbo实例的名称。
sfsId	String	SFS Turbo实例的ID。

参数	参数类型	描述
connectionType	String	关联方式。可选值如下： - VpcPort：通过挂载网卡直通 - Peering：通过对等连接打通
ipAddr	String	SFS Turbo的访问地址。
status	String	与SFS Turbo的连接状态信息。可选值如下： - Active：SFS连通状态正常 - Abnormal：SFS连通状态异常 - Creating：SFS连通状态创建关联中 - Deleting：SFS连通状态解除关联中

状态码：400

表 10-96 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

创建网络。

```
POST {endpoint}/v1/{project_id}/networks
{
  "apiVersion": "v1",
  "kind": "Network",
  "metadata": {
    "labels": {
      "os.modelarts/name": "network-7a03"
    }
  },
  "spec": {
    "cidr": "192.168.128.0/17"
  }
}
```

响应示例

状态码：200

OK。

```
{
  "kind": "Network",
  "apiVersion": "v1",
```

```
"metadata": {
  "name": "network-7a03-86c13962597848eeb29c5861153a391f",
  "creationTimestamp": "2022-09-16T09:44:59Z",
  "labels": {
    "os.modelarts/name": "network-7a03"
  },
  "annotations": { }
},
"spec": {
  "cidr": "192.168.128.0/17",
  "connection": { }
},
"status": {
  "phase": ""
}
}
```

状态码：400

Bad Request。

```
{
  "error_code": "ModelArts.50004000",
  "error_msg": "Bad request."
}
```

状态码

状态码	描述
200	OK。
400	Bad Request。

错误码

请参见[错误码](#)。

10.6.2 查询网络资源列表

功能介绍

查询网络资源列表。

URI

GET /v1/{project_id}/networks

表 10-97 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

表 10-98 Query 参数

参数	是否必选	参数类型	描述
workspaceId	否	String	工作空间ID，默认值为0。
labelSelector	否	String	标签筛选。
limit	否	Integer	分页单次查询返回数。
continue	否	String	分页查询时上一页位置。

请求参数

无

响应参数

状态码：200

表 10-99 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： NetworkList：网络列表
metadata	NetworkListMetadata object	网络资源列表的metadata信息。
items	Array of Network objects	网络资源列表。

表 10-100 NetworkListMetadata

参数	参数类型	描述
continue	String	分页查询时，下一次查询位置。
remainingItemCount	Integer	剩余资源个数。

表 10-101 Network

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： Network：网络
metadata	NetworkMetadata object	网络资源的metadata信息。
spec	NetworkSpec object	网络资源的描述信息。
status	NetworkStatus object	网络资源的状态信息。

表 10-102 NetworkMetadata

参数	参数类型	描述
name	String	系统自动生成的network名称，相当于networkId。
creationTimestamp	String	时间戳，"2021-11-01T03:49:41Z"。
labels	NetworkMetadataLabels object	网络资源的标签信息。
annotations	NetworkMetadataAnnotations object	网络资源的注释信息。

表 10-103 NetworkMetadataLabels

参数	参数类型	描述
os.modelarts/name	String	用户指定的network名称。
os.modelarts/workspace.id	String	工作空间ID，默认值为0。

表 10-104 NetworkMetadataAnnotations

参数	参数类型	描述
os.modelarts/ description	String	网络资源描述，用于说明用于某种场景。不能包含字符!<>=&'"

表 10-105 NetworkSpec

参数	参数类型	描述
cidr	String	网络的cidr。取值范围： 172.16.0.0/12~24 192.168.0.0/16~24。
connection	NetworkConnection object	当前网络与其他云服务的连通信息。

表 10-106 NetworkConnection

参数	参数类型	描述
peerConnectionList	Array of PeerConnectionItem objects	Peer方式打通网络列表。
sfsTurboConnectionList	Array of SfsTurboConnectionItem objects	挂载网卡方式打通SFS Turbo列表。

表 10-107 PeerConnectionItem

参数	参数类型	描述
peerVpcId	String	对端的VPC ID。
peerSubnetId	String	对端的子网ID。
defaultGateWay	Boolean	创建默认路由的开关，默认为false不创建。

表 10-108 SfsTurboConnectionItem

参数	参数类型	描述
name	String	SFS Turbo实例的名称。

参数	参数类型	描述
sfsId	String	SFS Turbo实例的ID。

表 10-109 NetworkStatus

参数	参数类型	描述
phase	String	网络的当前状态。可选值如下： - Creating：网络创建中 - Active：网络正常 - Abnormal：网络不正常
connectionStatus	NetworkConnectionStatus object	网络与其他云服务连通状态信息。

表 10-110 NetworkConnectionStatus

参数	参数类型	描述
peerConnectionStatus	Array of PeerConnectionStatus objects	Peer方式打通网络的状态信息列表。
sfsTurboStatus	Array of SfsTurboConnectionStatus objects	网络可连通的SFS Turbo信息列表。

表 10-111 PeerConnectionStatus

参数	参数类型	描述
peerVpcId	String	对端的VPC ID。
peerSubnetId	String	对端的子网ID。
defaultGateWay	Boolean	创建默认路由的开关，默认为false不创建。
phase	String	网络的连接状态。可选值如下： - Connecting：网络连接中 - Active：网络连接正常 - Abnormal：网络连接不正常

表 10-112 SfsTurboConnectionStatus

参数	参数类型	描述
name	String	SFS Turbo实例的名称。
sfsId	String	SFS Turbo实例的ID。
connectionType	String	关联方式。可选值如下： - VpcPort：通过挂载网卡直通 - Peering：通过对等连接打通
ipAddr	String	SFS Turbo的访问地址。
status	String	与SFS Turbo的连接状态信息。可选值如下： - Active：SFS连通状态正常 - Abnormal：SFS连通状态异常 - Creating：SFS连通状态创建关联中 - Deleting：SFS连通状态解除关联中

请求示例

查询资源池列表。

GET https://{endpoint}/v1/{project_id}/networks

响应示例

状态码：200

OK。

```
{
  "kind": "NetworkList",
  "apiVersion": "v1",
  "metadata": { },
  "items": [ {
    "kind": "Network",
    "apiVersion": "v1",
    "metadata": {
      "name": "network-7a03-86c13962597848eeb29c5861153a391f",
      "creationTimestamp": "2022-09-16T09:44:59Z",
      "labels": {
        "os.modelarts/name": "network-7a03"
      },
      "annotations": { }
    },
    "spec": {
      "cidr": "192.168.128.0/17",
      "connection": { }
    },
    "status": {
      "phase": "Active",
      "connectionStatus": { }
    }
  } ]
}
```

状态码

状态码	描述
200	OK。

错误码

请参见[错误码](#)。

10.6.3 查询网络资源

功能介绍

查询指定网络资源的详情信息。

URI

GET /v1/{project_id}/networks/{network_name}

表 10-113 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 资源空间ID。获取方法请参见 获取资源空间ID和名称 。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
network_name	是	String	参数解释： 网络的ID，取值自网络详情的metadata.name字段。 约束限制： 不涉及。 取值范围： 只能以小写字母开头，数字、中划线组成，不能以中划线结尾，且长度为[36-63]个字符。 默认取值： 不涉及。

请求参数

无

响应参数

状态码：200

表 10-114 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： Network：网络
metadata	NetworkMetadata object	网络资源的metadata信息。
spec	NetworkSpec object	网络资源的描述信息。
status	NetworkStatus object	网络资源的状态信息。

表 10-115 NetworkMetadata

参数	参数类型	描述
name	String	系统自动生成的network名称，相当于networkId。
creationTimestamp	String	时间戳，"2021-11-01T03:49:41Z"。
labels	NetworkMetadataLabels object	网络资源的标签信息。
annotations	NetworkMetadataAnnotations object	网络资源的注释信息。

表 10-116 NetworkMetadataLabels

参数	参数类型	描述
os.modelarts/name	String	用户指定的network名称。
os.modelarts/workspace.id	String	工作空间ID，默认值为0。

表 10-117 NetworkMetadataAnnotations

参数	参数类型	描述
os.modelarts/ description	String	网络资源描述，用于说明用于某种场景。不能包含字符!<>=&"

表 10-118 NetworkSpec

参数	参数类型	描述
cidr	String	网络的cidr。取值范围： 172.16.0.0/12~24 192.168.0.0/16~24。
connection	NetworkConnection object	当前网络与其他云服务的连通信息。

表 10-119 NetworkConnection

参数	参数类型	描述
peerConnectionList	Array of PeerConnectionItem objects	Peer方式打通网络列表。
sfsTurboConnectionList	Array of SfsTurboConnectionItem objects	挂载网卡方式打通SFS Turbo列表。

表 10-120 PeerConnectionItem

参数	参数类型	描述
peerVpcId	String	对端的VPC ID。
peerSubnetId	String	对端的子网ID。
defaultGateWay	Boolean	创建默认路由的开关，默认为false不创建。

表 10-121 SfsTurboConnectionItem

参数	参数类型	描述
name	String	SFS Turbo实例的名称。

参数	参数类型	描述
sfsId	String	SFS Turbo实例的ID。

表 10-122 NetworkStatus

参数	参数类型	描述
phase	String	网络的当前状态。可选值如下： - Creating：网络创建中 - Active：网络正常 - Abnormal：网络不正常
connectionStatus	NetworkConnectionStatus object	网络与其他云服务连通状态信息。

表 10-123 NetworkConnectionStatus

参数	参数类型	描述
peerConnectionStatus	Array of PeerConnectionStatus objects	Peer方式打通网络的状态信息列表。
sfsTurboStatus	Array of SfsTurboConnectionStatus objects	网络可连通的SFS Turbo信息列表。

表 10-124 PeerConnectionStatus

参数	参数类型	描述
peerVpcId	String	对端的VPC ID。
peerSubnetId	String	对端的子网ID。
defaultGateWay	Boolean	创建默认路由的开关，默认为false不创建。
phase	String	网络的连接状态。可选值如下： - Connecting：网络连接中 - Active：网络连接正常 - Abnormal：网络连接不正常

表 10-125 SfsTurboConnectionStatus

参数	参数类型	描述
name	String	SFS Turbo实例的名称。
sfsId	String	SFS Turbo实例的ID。
connectionType	String	关联方式。可选值如下： - VpcPort：通过挂载网卡直通 - Peering：通过对等连接打通
ipAddr	String	SFS Turbo的访问地址。
status	String	与SFS Turbo的连接状态信息。可选值如下： - Active：SFS连通状态正常 - Abnormal：SFS连通状态异常 - Creating：SFS连通状态创建关联中 - Deleting：SFS连通状态解除关联中

状态码：404

表 10-126 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

查询网络详情。

```
GET https://{endpoint}/v1/{project_id}/networks/{network_name}
{ }
```

响应示例

状态码：200

OK。

```
{
  "kind" : "Network",
  "apiVersion" : "v1",
  "metadata" : {
    "name" : "network-7a03-86c13962597848eeb29c5861153a391f",
    "creationTimestamp" : "2022-09-16T09:44:59Z",
    "labels" : {
      "os.modelarts/name" : "network-7a03"
    }
  }
}
```

```
},
"annotations": { }
},
"spec": {
  "cidr": "192.168.128.0/17",
  "connection": { }
},
"status": {
  "phase": "Active",
  "connectionStatus": { }
}
}
```

状态码：404

Not Found。

```
{
  "error_code": "ModelArts.50025001",
  "error_msg": "Network not exist."
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.6.4 删除网络资源

功能介绍

删除指定网络资源。

URI

DELETE /v1/{project_id}/networks/{network_name}

表 10-127 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
network_name	是	String	网络资源名称。

请求参数

无

响应参数

状态码：200

表 10-128 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： Network：网络
metadata	NetworkMetadata object	网络资源的metadata信息。
spec	NetworkSpec object	网络资源的描述信息。
status	NetworkStatus object	网络资源的状态信息。

表 10-129 NetworkMetadata

参数	参数类型	描述
name	String	系统自动生成的network名称，相当于networkId。
creationTimestamp	String	时间戳，"2021-11-01T03:49:41Z"。
labels	NetworkMetadataLabels object	网络资源的标签信息。
annotations	NetworkMetadataAnnotations object	网络资源的注释信息。

表 10-130 NetworkMetadataLabels

参数	参数类型	描述
os.modelarts/name	String	用户指定的network名称。

参数	参数类型	描述
os.modelarts/ workspace.id	String	工作空间ID，默认值为0。

表 10-131 NetworkMetadataAnnotations

参数	参数类型	描述
os.modelarts/ description	String	网络资源描述，用于说明用于某种场景。不能包含字符!<>=&""

表 10-132 NetworkSpec

参数	参数类型	描述
cidr	String	网络的cidr。取值范围： 172.16.0.0/12~24 192.168.0.0/16~24。
connection	NetworkConnection object	当前网络与其他云服务的连通信息。

表 10-133 NetworkConnection

参数	参数类型	描述
peerConnectionList	Array of PeerConnectionItem objects	Peer方式打通网络列表。
sfsTurboConnectionList	Array of SfsTurboConnectionItem objects	挂载网卡方式打通SFS Turbo列表。

表 10-134 PeerConnectionItem

参数	参数类型	描述
peerVpcId	String	对端的VPC ID。
peerSubnetId	String	对端的子网ID。
defaultGateWay	Boolean	创建默认路由的开关，默认为false不创建。

表 10-135 SfsTurboConnectionItem

参数	参数类型	描述
name	String	SFS Turbo实例的名称。
sfsId	String	SFS Turbo实例的ID。

表 10-136 NetworkStatus

参数	参数类型	描述
phase	String	网络的当前状态。可选值如下： - Creating：网络创建中 - Active：网络正常 - Abnormal：网络不正常
connectionStatus	NetworkConnectionStatus object	网络与其他云服务连通状态信息。

表 10-137 NetworkConnectionStatus

参数	参数类型	描述
peerConnectionStatus	Array of PeerConnectionStatus objects	Peer方式打通网络的状态信息列表。
sfsTurboStatus	Array of SfsTurboConnectionStatus objects	网络可连通的SFS Turbo信息列表。

表 10-138 PeerConnectionStatus

参数	参数类型	描述
peerVpcId	String	对端的VPC ID。
peerSubnetId	String	对端的子网ID。
defaultGateWay	Boolean	创建默认路由的开关，默认为false不创建。
phase	String	网络的连接状态。可选值如下： - Connecting：网络连接中 - Active：网络连接正常 - Abnormal：网络连接不正常

表 10-139 SfsTurboConnectionStatus

参数	参数类型	描述
name	String	SFS Turbo实例的名称。
sfsId	String	SFS Turbo实例的ID。
connectionType	String	关联方式。可选值如下： - VpcPort：通过挂载网卡直通 - Peering：通过对等连接打通
ipAddr	String	SFS Turbo的访问地址。
status	String	与SFS Turbo的连接状态信息。可选值如下： - Active：SFS连通状态正常 - Abnormal：SFS连通状态异常 - Creating：SFS连通状态创建关联中 - Deleting：SFS连通状态解除关联中

状态码：404

表 10-140 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

删除网络。

```
DELETE https://{endpoint}/v1/{project_id}/networks/{network_name}
{ }
```

响应示例

状态码：200

OK。

```
{
  "kind" : "Network",
  "apiVersion" : "v1",
  "metadata" : {
    "name" : "network-7a03-86c13962597848eeb29c5861153a391f",
    "creationTimestamp" : "2022-09-16T09:44:59Z",
    "deletionTimestamp" : "2022-09-16T10:06:27Z",
    "labels" : {
```

```
{
  "os.modelarts/name" : "network-7a03"
},
"annotations" : { }
},
"spec" : {
  "cidr" : "192.168.128.0/17",
  "connection" : {
    "peerConnectionList" : [ {
      "peerVpcId" : "03e4f4d7-fc62-409b-9c52-df885525e30b",
      "peerSubnetId" : "42aeabc3-f7c7-45aa-b884-e6e9ac2f841d"
    } ]
  }
},
"status" : {
  "phase" : "Active",
  "connectionStatus" : {
    "peerConnectionStatus" : [ {
      "peerVpcId" : "03e4f4d7-fc62-409b-9c52-df885525e30b",
      "peerSubnetId" : "42aeabc3-f7c7-45aa-b884-e6e9ac2f841d",
      "phase" : "Active"
    } ]
  }
}
}
```

状态码：404

Not Found。

```
{
  "error_code" : "ModelArts.50025001",
  "error_msg" : "Network not exist."
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.6.5 更新网络资源

功能介绍

更新指定网络资源。

URI

PATCH /v1/{project_id}/networks/{network_name}

表 10-141 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
network_name	是	String	网络资源名称。

请求参数

表 10-142 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	application/merge-patch+json。

表 10-143 请求 Body 参数

参数	是否必选	参数类型	描述
metadata	否	NetworkMetadataUpdate object	网络资源的metadata更新信息。
spec	否	NetworkSpecUpdate object	网络资源的描述更新信息。

表 10-144 NetworkMetadataUpdate

参数	是否必选	参数类型	描述
annotations	否	NetworkMetadataAnnotations object	网络资源的注释信息。
labels	否	NetworkUpdateLabels object	网络资源的标签信息。

表 10-145 NetworkMetadataAnnotations

参数	是否必选	参数类型	描述
os.modelarts/ description	否	String	网络资源描述，用于说明用于某种场景。不能包含字符!<>=&"

表 10-146 NetworkUpdateLabels

参数	是否必选	参数类型	描述
os.modelarts/ workspace.id	否	String	网络所在的工作空间ID。

表 10-147 NetworkSpecUpdate

参数	是否必选	参数类型	描述
connection	否	NetworkConnection object	网络连接更新信息。

表 10-148 NetworkConnection

参数	是否必选	参数类型	描述
peerConnectionList	否	Array of PeerConnectionItem objects	Peer方式打通网络列表。
sfsTurboConnectionList	否	Array of SfsTurboConnectionItem objects	挂载网卡方式打通SFS Turbo列表。

表 10-149 PeerConnectionItem

参数	是否必选	参数类型	描述
peerVpcId	是	String	对端的VPC ID。
peerSubnetId	是	String	对端的子网ID。
defaultGateway	否	Boolean	创建默认路由的开关，默认为false不创建。

表 10-150 SfsTurboConnectionItem

参数	是否必选	参数类型	描述
name	是	String	SFS Turbo实例的名称。
sfsId	是	String	SFS Turbo实例的ID。

响应参数

状态码：200

表 10-151 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： Network：网络
metadata	NetworkMetadata object	网络资源的metadata信息。
spec	NetworkSpec object	网络资源的描述信息。
status	NetworkStatus object	网络资源的状态信息。

表 10-152 NetworkMetadata

参数	参数类型	描述
name	String	系统自动生成的network名称，相当于networkId。
creationTimestamp	String	时间戳，"2021-11-01T03:49:41Z"。
labels	NetworkMetadataLabels object	网络资源的标签信息。
annotations	NetworkMetadataAnnotations object	网络资源的注释信息。

表 10-153 NetworkMetadataLabels

参数	参数类型	描述
os.modelarts/ name	String	用户指定的network名称。
os.modelarts/ workspace.id	String	工作空间ID，默认值为0。

表 10-154 NetworkMetadataAnnotations

参数	参数类型	描述
os.modelarts/ description	String	网络资源描述，用于说明用于某种场景。不能包含字符!<>=&"

表 10-155 NetworkSpec

参数	参数类型	描述
cidr	String	网络的cidr。取值范围： 172.16.0.0/12~24 192.168.0.0/16~24。
connection	NetworkConnection object	当前网络与其他云服务的连通信息。

表 10-156 NetworkConnection

参数	参数类型	描述
peerConnectionList	Array of PeerConnectionItem objects	Peer方式打通网络列表。
sfsTurboConnectionList	Array of SfsTurboConnectionItem objects	挂载网卡方式打通SFS Turbo列表。

表 10-157 PeerConnectionItem

参数	参数类型	描述
peerVpcId	String	对端的VPC ID。
peerSubnetId	String	对端的子网ID。

参数	参数类型	描述
defaultGateWay	Boolean	创建默认路由的开关，默认为false不创建。

表 10-158 SfsTurboConnectionItem

参数	参数类型	描述
name	String	SFS Turbo实例的名称。
sfsId	String	SFS Turbo实例的ID。

表 10-159 NetworkStatus

参数	参数类型	描述
phase	String	网络的当前状态。可选值如下： - Creating：网络创建中 - Active：网络正常 - Abnormal：网络不正常
connectionStatus	NetworkConnectionStatus object	网络与其他云服务连通状态信息。

表 10-160 NetworkConnectionStatus

参数	参数类型	描述
peerConnectionStatus	Array of PeerConnectionStatus objects	Peer方式打通网络的状态信息列表。
sfsTurboStatus	Array of SfsTurboConnectionStatus objects	网络可连通的SFS Turbo信息列表。

表 10-161 PeerConnectionStatus

参数	参数类型	描述
peerVpcId	String	对端的VPC ID。
peerSubnetId	String	对端的子网ID。

参数	参数类型	描述
defaultGateWay	Boolean	创建默认路由的开关，默认为false不创建。
phase	String	网络的连接状态。可选值如下： - Connecting：网络连接中 - Active：网络连接正常 - Abnormal：网络连接不正常

表 10-162 SfsTurboConnectionStatus

参数	参数类型	描述
name	String	SFS Turbo实例的名称。
sfsId	String	SFS Turbo实例的ID。
connectionType	String	关联方式。可选值如下： - VpcPort：通过挂载网卡直通 - Peering：通过对等连接打通
ipAddr	String	SFS Turbo的访问地址。
status	String	与SFS Turbo的连接状态信息。可选值如下： - Active：SFS连通状态正常 - Abnormal：SFS连通状态异常 - Creating：SFS连通状态创建关联中 - Deleting：SFS连通状态解除关联中

状态码：400

表 10-163 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

状态码：404

表 10-164 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

- 打通VPC。

```
PATCH https://{endpoint}/v1/{project_id}/networks/{network_name}

{
  "spec": {
    "connection": {
      "peerConnectionList": [ {
        "peerVpcId": "359668f4-fbef-4404-b9bc-781142518d3b",
        "peerSubnetId": "8f21dbea-df13-4669-8a17-0efba195997b",
        "defaultGateWay": false
      } ]
    }
  }
}
```

- 关联SFS Turbo。

```
PATCH https://{endpoint}/v1/{project_id}/networks/{network_name}

{
  "spec": {
    "connection": {
      "sfsTurboConnectionList": [ {
        "sfsId": "2a220ce2-936c-4041-8478-c731bf934b11",
        "name": "sfs-turbo-a066-bbb"
      } ]
    }
  }
}
```

响应示例

状态码：200

OK。

```
{
  "kind": "Network",
  "apiVersion": "v1",
  "metadata": {
    "name": "network-7a03-86c13962597848eeb29c5861153a391f",
    "creationTimestamp": "2022-09-16T09:44:59Z",
    "labels": {
      "os.modelarts/name": "network-7a03"
    },
    "annotations": { }
  },
  "spec": {
    "cidr": "192.168.128.0/17",
    "connection": {
      "peerConnectionList": [ {
        "peerVpcId": "03e4f4d7-fc62-409b-9c52-df885525e30b",
        "peerSubnetId": "42aeabc3-f7c7-45aa-b884-e6e9ac2f841d"
      } ],
      "sfsTurboConnectionList": [ {
```

```
{
  "sfsId": "97beb2bb-1a5b-41dd-b7fb-65a9c7954517",
  "name": "mulVpc-02"
}]
},
"status": {
  "phase": "Active",
  "connectionStatus": {}
}
}
```

状态码：400

Bad request

```
{
  "error_code": "ModelArts.50004000",
  "error_msg": "Bad request."
}
```

状态码：404

Not Found。

```
{
  "error_code": "ModelArts.50025001",
  "error_msg": "Network not exist."
}
```

状态码

状态码	描述
200	OK。
400	Bad request
404	Not Found。

错误码

请参见[错误码](#)。

10.7 标签管理

10.7.1 查询资源池的所有资源标签

功能介绍

查询用户当前项目下资源池的所有标签。

URI

GET /v1/{project_id}/pools/tags

表 10-165 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

表 10-166 Query 参数

参数	是否必选	参数类型	描述
limit	否	Integer	指定每一页查询返回的最大条目数，默认为200。
offset	否	Integer	分页列表的起始页，默认为0。

请求参数

无

响应参数

状态码：200

表 10-167 响应 Body 参数

参数	参数类型	描述
tags	Tag object	资源标签的列表。

表 10-168 Tag

参数	参数类型	描述
key	String	标签的key。
value	String	标签的value。

状态码：400

表 10-169 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：401

表 10-170 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：403

表 10-171 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

请求示例

https://{endpoint}/v1/{project_id}/pools/tags

响应示例

状态码：200

查询项目下指定资源类型的所有标签。

```
{
  "tags": [ {
    "key": "model_version",
    "values": [ "0.1", "0.2" ]
  }, {
    "key": "conda_version",
    "values": [ "10.2", "11.0" ]
  } ]
}
```

状态码

状态码	描述
200	查询项目下指定资源类型的所有标签。
400	参数非法。
401	鉴权失败。
403	权限不足。

错误码

请参见[错误码](#)。

10.7.2 查询资源池的资源标签

功能介绍

查询指定资源池的资源标签。

URI

GET /v1/{project_id}/pools/{pool_name}/tags

表 10-172 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池ID。取值资源池详情的 metadata.name 字段。

请求参数

无

响应参数

状态码：204

表 10-173 响应 Body 参数

参数	参数类型	描述
tags	Tag object	资源标签的列表。

表 10-174 Tag

参数	参数类型	描述
key	String	标签的key。
value	String	标签的value。

状态码：400

表 10-175 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：401

表 10-176 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：403

表 10-177 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：404

表 10-178 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

请求示例

查询指定资源池的资源标签

`https://{endpoint}/v1/{project_id}/pools/a55eba18-1ebf-4e9a-8229-d2d3b593a3dc/tags`

响应示例

状态码：204

标签列表。

```
{
  "tags": [ {
    "key": "dev",
    "value": "dev1"
  } ]
}
```

状态码

状态码	描述
204	标签列表。
400	参数非法。
401	鉴权失败。
403	权限不足。
404	资源不存在。

错误码

请参见[错误码](#)。

10.7.3 修改资源池的资源标签

功能介绍

修改指定资源池的资源标签。

URI

POST /v1/{project_id}/pools/{pool_name}/tags

表 10-179 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池ID。取值资源池详情的metadata.name字段。

请求参数

表 10-180 请求 Body 参数

参数	是否必选	参数类型	描述
action	是	String	对资源标签的操作类型。可选值如下： - create：添加指定的资源标签。如果标签的key已经存在，则覆盖相应标签的value字段 - delete：删除指定的资源标签。移除资源上key和value都相等的资源标签 - reset：将资源上的资源标签重置为请求中的值。
tags	是	Array of Tag objects	资源标签列表。只有action值为reset时允许为空。

表 10-181 Tag

参数	是否必选	参数类型	描述
key	是	String	标签的key。
value	是	String	标签的value。

响应参数

状态码：204

表 10-182 响应 Body 参数

参数	参数类型	描述
tags	Tag object	资源标签的列表。

表 10-183 Tag

参数	参数类型	描述
key	String	标签的key。
value	String	标签的value。

状态码：400

表 10-184 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：401

表 10-185 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：403

表 10-186 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：404

表 10-187 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

请求示例

- 删除资源池指定资源标签。
`https://{endpoint}/v1/{project_id}/pools/a55eba18-1ebf-4e9a-8229-d2d3b593a3dc/tags`

```
{
  "action": "delete",
  "tags": [ {
    "key": "key1",
```

```
    "value" : "value1"  
  }]  
}
```

- 给资源池添加指定资源标签。

```
https://{endpoint}/v1/{project_id}/pools/a55eba18-1ebf-4e9a-8229-d2d3b593a3dc/tags  
  
{  
  "action" : "create",  
  "tags" : [{  
    "key" : "key1",  
    "value" : "value1"  
  }]  
}
```

响应示例

状态码：204

正常添加成功。

```
{  
  "tags" : [{  
    "key" : "test",  
    "value" : "service-gpu"  
  }, {  
    "key" : "key1",  
    "value" : "value1"  
  }]  
}
```

状态码

状态码	描述
204	正常添加成功。
400	参数非法。
401	鉴权失败。
403	权限不足。
404	资源未找到。

错误码

请参见[错误码](#)。

10.7.4 查询节点的所有资源标签

功能介绍

查询用户当前项目下节点的所有标签。

URI

GET /v1/{project_id}/nodes/tags

表 10-188 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

表 10-189 Query 参数

参数	是否必选	参数类型	描述
pool	否	String	资源池ID。取值资源池详情的 metadata.name 字段。当传递该值时返回指定资源池下所有节点的资源标签列表。

请求参数

无

响应参数

状态码：200

表 10-190 响应 Body 参数

参数	参数类型	描述
tags	Tag object	资源标签的列表。

表 10-191 Tag

参数	参数类型	描述
key	String	标签的key。
value	String	标签的value。

状态码：400

表 10-192 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：401

表 10-193 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：403

表 10-194 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

请求示例

查询节点的资源标签列表

https://{endpoint}/v1/{project_id}/nodes/tags

响应示例

状态码：200

查询项目下节点的所有标签。

```
{
  "tags": [ {
    "key": "model_version",
    "values": [ "0.1", "0.2" ]
  }, {
    "key": "conda_version",
    "values": [ "10.2", "11.0" ]
  } ]
}
```

状态码

状态码	描述
200	查询项目下节点的所有标签。
400	参数非法。
401	鉴权失败。

状态码	描述
403	权限不足。

错误码

请参见[错误码](#)。

10.7.5 查询节点的资源标签

功能介绍

查询指定节点的资源标签。

URI

GET /v1/{project_id}/nodes/{node_name}/tags

表 10-195 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
node_name	是	String	节点ID。取值节点详情的 metadata.name 字段。

请求参数

无

响应参数

状态码：204

表 10-196 响应 Body 参数

参数	参数类型	描述
tags	Tag object	资源标签的列表。

表 10-197 Tag

参数	参数类型	描述
key	String	标签的key。

参数	参数类型	描述
value	String	标签的value。

状态码：400

表 10-198 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：401

表 10-199 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：403

表 10-200 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：404

表 10-201 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

请求示例

查询指定节点上的资源标签。

```
https://{endpoint}/v1/{project_id}/nodes/os-node-create-48d13/tags
```

响应示例

状态码：204

标签列表。

```
{
  "tags": [ {
    "key": "dev",
    "value": "dev1"
  } ]
}
```

状态码

状态码	描述
204	标签列表。
400	参数非法。
401	鉴权失败。
403	权限不足。
404	资源不存在。

错误码

请参见[错误码](#)。

10.7.6 修改节点的资源标签

功能介绍

修改指定节点的资源标签。

URI

```
POST /v1/{project_id}/nodes/{node_name}/tags
```

表 10-202 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

参数	是否必选	参数类型	描述
node_name	是	String	节点ID。取值节点详情的metadata.name字段。

请求参数

表 10-203 请求 Body 参数

参数	是否必选	参数类型	描述
action	是	String	对资源标签的操作类型。可选值如下： - create：添加指定的资源标签。如果标签的key已经存在，则覆盖相应标签的value字段 - delete：删除指定的资源标签。移除资源上key和value都相等的资源标签 - reset：将资源上的资源标签重置为请求中的值。
tags	是	Array of Tag objects	资源标签列表。只有action值为reset时允许为空。

表 10-204 Tag

参数	是否必选	参数类型	描述
key	是	String	标签的key。
value	是	String	标签的value。

响应参数

状态码：204

表 10-205 响应 Body 参数

参数	参数类型	描述
tags	Tag object	资源标签的列表。

表 10-206 Tag

参数	参数类型	描述
key	String	标签的key。
value	String	标签的value。

状态码：400

表 10-207 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：401

表 10-208 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：403

表 10-209 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码：404

表 10-210 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

请求示例

- 删除节点指定资源标签。

```
https://{endpoint}/v1/{project_id}/nodes/os-node-created-520ad/tags

{
  "action": "delete",
  "tags": [ {
    "key": "key1",
    "value": "value1"
  } ]
}
```
- 给节点添加指定资源标签。

```
https://{endpoint}/v1/{project_id}/nodes/os-node-created-520ad/tags

{
  "action": "create",
  "tags": [ {
    "key": "key1",
    "value": "value1"
  } ]
}
```

响应示例

状态码：204

正常添加成功。

```
{
  "tags": [ {
    "key": "test",
    "value": "service-gpu"
  }, {
    "key": "key1",
    "value": "value1"
  } ]
}
```

状态码

状态码	描述
204	正常添加成功。
400	参数非法。
401	鉴权失败。
403	权限不足。
404	资源未找到。

错误码

请参见[错误码](#)。

10.8 事件管理

10.8.1 查询事件列表

功能介绍

查询事件列表。

URI

GET /v1/{project_id}/events

表 10-211 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

表 10-212 Query 参数

参数	是否必选	参数类型	描述
resource	是	String	事件所属资源类型。可选值如下： • pools：资源池
name	是	String	事件所属资源ID。
limit	否	Integer	单页查询最大数量，该值为空或者0时默认返回500条记录，单页最大允许查询500条记录。
offset	否	Integer	分页查询的偏移量，查询第一页时为0。
type	否	String	事件类型。可选值如下： • Normal：查询正常类型的事件 • Warning：查询告警类型的事件 该字段为空则返回所有类型的事件。
since	否	Integer	事件开始时间戳。
until	否	Integer	事件结束时间戳。
ascend	否	Boolean	是否为升序。

请求参数

无

响应参数

状态码：200

表 10-213 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： EventList：事件列表
items	Array of Event objects	事件列表。
total	Integer	总事件条数。

表 10-214 Event

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： Event：事件
type	String	事件类型。可选值如下： - Normal：正常 - Warning：异常
firstTimestamp	String	事件第一次出现时间。
lastTimestamp	String	事件最后一次出现时间。
count	Integer	事件连续出现次数。
reason	String	事件产生的原因。
message	String	事件详细信息。

状态码：400

表 10-215 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：404

表 10-216 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

分页查询资源池pool-6f5da086876d4cd084d36f8bd3346036的事件列表。

```
GET https://{endpoint}/v1/{project_id}/events?
resource=pools&name=pool-5ff6-6f5da086876d4cd084d36f8bd3346036&limit=10&offset=0&ascend=false
```

响应示例

状态码：200

OK。

```
{
  "kind" : "EventList",
  "apiVersion" : "v1",
  "metadata" : {
    "continue" : "52eddc13-cfad-42d3-ae4-92fea5813e7f"
  },
  "items" : [ {
    "kind" : "Event",
    "apiVersion" : "v1",
    "type" : "Warning",
    "firstTimestamp" : "2022-12-30T02:16:19Z",
    "lastTimestamp" : "2022-12-30T02:16:19Z",
    "count" : 1,
    "reason" : "PoolResourcesStatusChange",
    "message" : "Pool resources status changed, available/abnormal/creating/deleting count from 1/0/0/0 to 0/1/0/0, timestamp: 1672366579."
  }, {
    "kind" : "Event",
    "apiVersion" : "v1",
    "type" : "Normal",
    "firstTimestamp" : "2023-01-02T09:02:45Z",
    "lastTimestamp" : "2023-01-02T09:02:45Z",
    "count" : 1,
    "reason" : "PoolResourcesStatusChange",
    "message" : "Pool resources status changed, available/abnormal/creating/deleting count from 0/1/0/0 to 1/0/0/0, timestamp: 1672650165."
  }, {
    "kind" : "Event",
```

```
"apiVersion": "v1",
"type": "Warning",
"firstTimestamp": "2023-01-16T06:55:35Z",
"lastTimestamp": "2023-01-16T06:55:35Z",
"count": 1,
"reason": "PoolStatusChange",
"message": "Pool status changed, from Running to Abnormal, details: ."
}, {
  "kind": "Event",
  "apiVersion": "v1",
  "type": "Warning",
  "firstTimestamp": "2023-01-16T06:57:51Z",
  "lastTimestamp": "2023-01-16T06:57:51Z",
  "count": 1,
  "reason": "PoolResourcesStatusChange",
  "message": "Pool resources status changed, available/abnormal/creating/deleting count from 1/0/0/0 to 0/1/0/0, timestamp: 1673852271."
}, {
  "kind": "Event",
  "apiVersion": "v1",
  "type": "Normal",
  "firstTimestamp": "2023-01-29T02:29:04Z",
  "lastTimestamp": "2023-01-29T02:29:04Z",
  "count": 1,
  "reason": "PoolStatusChange",
  "message": "Pool status changed, from Abnormal to Running."
}]
}
```

状态码：400

Bad Request。

```
{
  "error_code": "ModelArts.50004000",
  "error_msg": "Bad request."
}
```

状态码：404

Not Found。

```
{
  "error_code": "ModelArts.50015001",
  "error_msg": "Pool {name} not found."
}
```

状态码

状态码	描述
200	OK。
400	Bad Request。
404	Not Found。

错误码

请参见[错误码](#)。

10.9 插件管理

10.9.1 创建插件

功能介绍

创建插件实例。

URI

POST /v2/{project_id}/pools/{pool_name}/plugins

表 10-217 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池名称。

请求参数

表 10-218 请求 Body 参数

参数	是否必选	参数类型	描述
apiVersion	是	String	API资源类型，固定值“Plugin”，该值不可修改。
kind	是	String	API版本，固定值“v2”，该值不可修改。
spec	是	PluginSpec object	spec是集合类的元素类型，内容为插件实例安装/升级的具体请求信息。

表 10-219 PluginSpec

参数	是否必选	参数类型	描述
template	是	Template object	插件实例的模板信息。

表 10-220 Template

参数	是否必选	参数类型	描述
name	是	String	待安装插件模板名称，如log-agent。
version	否	String	待安装、升级插件的版本号。
inputs	否	Map<String,Object>	插件模板安装参数（各插件不同），升级插件时需要填写全量安装参数，未填写参数将使用插件模板中的默认值，当前插件安装参数可通过查询插件实例接口获取。

响应参数

状态码：200

表 10-221 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	插件实例的类型。
metadata	PluginMetadata object	插件实例的metadata信息。
spec	PluginSpec object	插件实例的具体信息。
status	PluginStatus object	插件实例的状态信息。

表 10-222 PluginMetadata

参数	参数类型	描述
name	String	插件实例的名称。
creationTimestamp	String	创建时间。

表 10-223 PluginSpec

参数	参数类型	描述
template	Template object	插件实例的模板信息。

表 10-224 Template

参数	参数类型	描述
name	String	待安装插件模板名称，如log-agent。
version	String	待安装、升级插件的版本号。
inputs	Map<String,Object>	插件模板安装参数（各插件不同），升级插件时需要填写全量安装参数，未填写参数将使用插件模板中的默认值，当前插件安装参数可通过查询插件实例接口获取。

表 10-225 PluginStatus

参数	参数类型	描述
phase	String	插件实例的状态。可选值如下： • Pending：安装中，表示插件正在安装中。 • Running：运行中，表示插件全部实例状态都在运行中，插件正常使用。 • Updating：升级中，表示插件正在更新中。 • Abnormal：不可用，表示插件状态异常，插件不可使用。可单击状态查看失败原因。 • Deleting：删除中，表示插件正在删除中。
version	String	插件实例的版本。
reason	String	插件实例安装失败的详细信息。
values	String	插件实例的安装参数（各插件不同）。
resources	Array of PluginResources objects	插件实例占用的资源量。

表 10-226 PluginResources

参数	参数类型	描述
involvedObject	ObjectReference object	插件引用的资源对象。
replicas	Integer	资源对象的副本数。
limits	Map<String,String >	申请的资源限制。
requests	Map<String,String >	申请的资源需求。

表 10-227 ObjectReference

参数	参数类型	描述
kind	String	资源对象的API类型，例如，DaemonSet、Deployment 等。
apiVersion	String	资源对象的API版本。
namespace	String	资源对象的命名空间。
name	String	资源对象的名称。
uid	String	资源对象的唯一标识符（UID）。
resourceVersion	String	资源对象的当前版本。

状态码：400

表 10-228 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

创建插件实例。

```
POST https://{endpoint}/v2/{project_id}/pools/{pool_name}/plugins
{
  "apiVersion": "v2",
  "kind": "Plugin",
  "spec": {
    "template": {
      "version": "1.6.36",
```

```
    "name" : "node-local-dns"  
  }  
}  
}
```

响应示例

状态码：200

OK。

```
{  
  "apiVersion" : "v2",  
  "kind" : "Plugin",  
  "spec" : {  
    "template" : {  
      "name" : "node-local-dns",  
      "version" : "1.6.36",  
      "inputs" : {  
        "flavor" : {  
          "description" : "High available",  
          "name" : "HA",  
          "resources" : [ {  
            "name" : "node-local-dns-admission-controller",  
            "limitsCpu" : "250m",  
            "requestsCpu" : "250m",  
            "replicas" : 2,  
            "limitsMem" : "512Mi",  
            "requestsMem" : "512Mi"  
          }, {  
            "name" : "node-local-dns-cache",  
            "limitsCpu" : "500m",  
            "requestsCpu" : "25m",  
            "limitsMem" : "512Mi",  
            "requestsMem" : "5Mi"  
          } ],  
          "size" : "large"  
        },  
        "custom" : {  
          "enable_dnsconfig_admission" : true,  
          "nameserver" : "135.0.0.1",  
          "ndots" : "8",  
          "search" : "1321"  
        }  
      }  
    }  
  }  
}
```

状态码：400

Bad request

```
{  
  "error_code" : "ModelArts.50004000",  
  "error_msg" : "Bad request."  
}
```

状态码

状态码	描述
200	OK。
400	Bad request

错误码

请参见[错误码](#)。

10.9.2 查询插件列表

功能介绍

查询插件实例列表。

URI

GET /v2/{project_id}/pools/{pool_name}/plugins

表 10-229 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池名称。

请求参数

无

响应参数

状态码：200

表 10-230 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	资源类型。可选值如下： NodePoolList：节点列表
items	Array of Plugin objects	节点池列表。

表 10-231 Plugin

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	插件实例的类型。
metadata	PluginMetadata object	插件实例的metadata信息。
spec	PluginSpec object	插件实例的具体信息。
status	PluginStatus object	插件实例的状态信息。

表 10-232 PluginMetadata

参数	参数类型	描述
name	String	插件实例的名称。
creationTimestamp	String	创建时间。

表 10-233 PluginSpec

参数	参数类型	描述
template	Template object	插件实例的模板信息。

表 10-234 Template

参数	参数类型	描述
name	String	待安装插件模板名称，如log-agent。
version	String	待安装、升级插件的版本号。
inputs	Map<String, Object>	插件模板安装参数（各插件不同），升级插件时需要填写全量安装参数，未填写参数将使用插件模板中的默认值，当前插件安装参数可通过查询插件实例接口获取。

表 10-235 PluginStatus

参数	参数类型	描述
phase	String	插件实例的状态。可选值如下： • Pending：安装中，表示插件正在安装中。 • Running：运行中，表示插件全部实例状态都在运行中，插件正常使用。 • Updating：升级中，表示插件正在更新中。 • Abnormal：不可用，表示插件状态异常，插件不可使用。可单击状态查看失败原因。 • Deleting：删除中，表示插件正在删除中。
version	String	插件实例的版本。
reason	String	插件实例安装失败的详细信息。
values	String	插件实例的安装参数（各插件不同）。
resources	Array of PluginResources objects	插件实例占用的资源量。

表 10-236 PluginResources

参数	参数类型	描述
involvedObject	ObjectReference object	插件引用的资源对象。
replicas	Integer	资源对象的副本数。
limits	Map<String,String>	申请的资源限制。
requests	Map<String,String>	申请的资源需求。

表 10-237 ObjectReference

参数	参数类型	描述
kind	String	资源对象的API类型，例如，DaemonSet、Deployment 等。
apiVersion	String	资源对象的API版本。

参数	参数类型	描述
namespace	String	资源对象的命名空间。
name	String	资源对象的名称。
uid	String	资源对象的唯一标识符（UID）。
resourceVersion	String	资源对象的当前版本。

请求示例

查询插件实例列表。

GET https://{endpoint}/v2/{project_id}/pools/{pool_name}/plugins

```
{
  "kind": "PluginList",
  "apiVersion": "v2",
  "items": [ {
    "kind": "Plugin",
    "apiVersion": "v2",
    "metadata": {
      "name": "lite-cluster-ac7339d4-4858-11ec-9d-0200b0b-gpu-beta",
      "creationTimestamp": "2025-01-22T03:01:53Z"
    },
    "spec": {
      "template": {
        "name": "gpu-beta"
      }
    },
    "status": {
      "phase": "Running",
      "version": "1.2.15",
      "reason": "Upgrade complete"
    }
  }, {
    "kind": "Plugin",
    "apiVersion": "v2",
    "metadata": {
      "name": "lite-cluster-ac7339d4-4858-11ec-a79d-0255ac100b0b-os-node-agent",
      "creationTimestamp": "2025-01-22T03:01:53Z"
    },
    "spec": {
      "template": {
        "name": "os-node-agent",
        "version": "6.8.0-20250219120620",
        "inputs": {
          "configs": {
            "metric_config": {
              "backNodeUp": true,
              "enable": true,
              "exporter": {
                "enable": false,
                "port": "10120"
              }
            },
            "namespaces": [ "monitoring" ],
            "prometheus": {
              "accessCode": "",
              "prometheusId": ""
            }
          },
          "uplink": "both"
        }
      }
    },
    "status": {
      "phase": "Running",
      "version": "6.8.0-20250219120620",
      "reason": "Upgrade complete"
    }
  }
]
```

```
    },  
    "status": {  
      "phase": "Running",  
      "version": "6.8.0-20250219120620",  
      "reason": "Upgrade complete"  
    }  
  }  
}]  
}
```

响应示例

状态码：200

OK。

```
{  
  "kind": "PluginList",  
  "apiVersion": "v2",  
  "items": [ {  
    "kind": "Plugin",  
    "apiVersion": "v2",  
    "metadata": {  
      "name": "lite-cluster-ac7339d4-4858-11ec-9d-0200b0b-gpu-beta",  
      "creationTimestamp": "2025-01-22T03:01:53Z"  
    },  
    "spec": {  
      "template": {  
        "name": "gpu-beta"  
      }  
    },  
    "status": {  
      "phase": "Running",  
      "version": "1.2.15",  
      "reason": "Upgrade complete"  
    }  
  }, {  
    "kind": "Plugin",  
    "apiVersion": "v2",  
    "metadata": {  
      "name": "lite-cluster-ac7339d4-4858-11ec-a79d-0255ac100b0b-os-node-agent",  
      "creationTimestamp": "2025-01-22T03:01:53Z"  
    },  
    "spec": {  
      "template": {  
        "name": "os-node-agent",  
        "version": "6.8.0-20250219120620",  
        "inputs": {  
          "configs": {  
            "metric_config": {  
              "backNodeUp": true,  
              "enable": true,  
              "exporter": {  
                "enable": false,  
                "port": "10120"  
              }  
            },  
            "namespaces": [ "monitoring" ],  
            "prometheus": {  
              "accessCode": "",  
              "prometheusId": ""  
            },  
            "uplink": "both"  
          }  
        }  
      }  
    },  
    "status": {  
      "phase": "Running",  
      "version": "6.8.0-20250219120620",  
      "reason": "Upgrade complete"  
    }  
  }  
]  
}
```



```
    "version": "6.8.0-20250219120620",
    "reason": "Upgrade complete"
  }
}]
}
```

状态码

状态码	描述
200	OK。

错误码

请参见[错误码](#)。

10.9.3 更新插件

功能介绍

更新插件实例。

URI

PATCH /v2/{project_id}/pools/{pool_name}/plugins/{template_name}

表 10-238 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池名称。
template_name	是	String	插件模板名称。

请求参数

表 10-239 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	application/merge-patch+json。

表 10-240 请求 Body 参数

参数	是否必选	参数类型	描述
spec	是	PluginSpec object	更新插件实例的具体请求信息。

表 10-241 PluginSpec

参数	是否必选	参数类型	描述
template	是	Template object	插件实例的模板信息。

表 10-242 Template

参数	是否必选	参数类型	描述
name	是	String	待安装插件模板名称，如log-agent。
version	否	String	待安装、升级插件的版本号。
inputs	否	Map<String,Object>	插件模板安装参数（各插件不同），升级插件时需要填写全量安装参数，未填写参数将使用插件模板中的默认值，当前插件安装参数可通过查询插件实例接口获取。

响应参数

状态码：200

表 10-243 响应 Body 参数

参数	参数类型	描述
spec	PluginSpec object	更新插件实例的具体请求信息。

表 10-244 PluginSpec

参数	参数类型	描述
template	Template object	插件实例的模板信息。

表 10-245 Template

参数	参数类型	描述
name	String	待安装插件模板名称，如log-agent。
version	String	待安装、升级插件的版本号。
inputs	Map<String,Object>	插件模板安装参数（各插件不同），升级插件时需要填写全量安装参数，未填写参数将使用插件模板中的默认值，当前插件安装参数可通过查询插件实例接口获取。

状态码：400

表 10-246 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

更新插件实例。

PATCH https://{endpoint}/v2/{project_id}/pools/{pool_name}/plugins/{template_name}

```
{
  "spec": {
    "template": {
      "version": "1.6.63",
      "inputs": {
        "custom": {
          "enable_dnsconfig_admission": true,
          "nameserver": "123.123.123.123",
          "ndots": "3",
          "search": "123,234"
        },
        "flavor": {
          "name": "custom",
          "replicas": 2,
          "resources": [ {
            "limitsCpu": "234m",
            "limitsMem": "234Mi",
            "name": "node-local-dns-admission-controller",
            "replicas": 1,
            "requestsCpu": "123m",
            "requestsMem": "123Mi"
          }, {
            "limitsCpu": "234m",
            "limitsMem": "234Mi",
            "name": "node-local-dns-cache",
            "requestsCpu": "123m",
            "requestsMem": "123Mi"
          } ]
        }
      }
    }
  }
}
```

```
}  
}  
}  
}
```

响应示例

状态码：200

OK。

```
{  
  "spec": {  
    "template": {  
      "version": "1.6.63",  
      "inputs": {  
        "custom": {  
          "enable_dnsconfig_admission": true,  
          "nameserver": "123.123.123.123",  
          "ndots": "3",  
          "search": "123,234"  
        },  
        "flavor": {  
          "name": "custom",  
          "replicas": 2,  
          "resources": [ {  
            "limitsCpu": "234m",  
            "limitsMem": "234Mi",  
            "name": "node-local-dns-admission-controller",  
            "replicas": 1,  
            "requestsCpu": "123m",  
            "requestsMem": "123Mi"  
          }, {  
            "limitsCpu": "234m",  
            "limitsMem": "234Mi",  
            "name": "node-local-dns-cache",  
            "requestsCpu": "123m",  
            "requestsMem": "123Mi"  
          } ]  
        }  
      }  
    }  
  }  
}
```

状态码：400

Bad request

```
{  
  "error_code": "ModelArts.50004000",  
  "error_msg": "Bad request."  
}
```

状态码

状态码	描述
200	OK。
400	Bad request

错误码

请参见[错误码](#)。

10.9.4 删除插件

功能介绍

删除插件实例。

URI

DELETE /v2/{project_id}/pools/{pool_name}/plugins/{template_name}

表 10-247 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池名称。
template_name	是	String	插件模板名称。

请求参数

无

响应参数

状态码：200

表 10-248 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	插件实例的类型。
metadata	PluginMetadata object	插件实例的metadata信息。
spec	PluginSpec object	插件实例的具体信息。
status	PluginStatus object	插件实例的状态信息。

表 10-249 PluginMetadata

参数	参数类型	描述
name	String	插件实例的名称。
creationTimestamp	String	创建时间。

表 10-250 PluginSpec

参数	参数类型	描述
template	Template object	插件实例的模板信息。

表 10-251 Template

参数	参数类型	描述
name	String	待安装插件模板名称，如log-agent。
version	String	待安装、升级插件的版本号。
inputs	Map<String,Object>	插件模板安装参数（各插件不同），升级插件时需要填写全量安装参数，未填写参数将使用插件模板中的默认值，当前插件安装参数可通过查询插件实例接口获取。

表 10-252 PluginStatus

参数	参数类型	描述
phase	String	插件实例的状态。可选值如下： - Pending：安装中，表示插件正在安装中。 - Running：运行中，表示插件全部实例状态都在运行中，插件正常使用。 - Updating：升级中，表示插件正在更新中。 - Abnormal：不可用，表示插件状态异常，插件不可使用。可单击状态查看失败原因。 - Deleting：删除中，表示插件正在删除中。
version	String	插件实例的版本。

参数	参数类型	描述
reason	String	插件实例安装失败的详细信息。
values	String	插件实例的安装参数（各插件不同）。
resources	Array of PluginResources objects	插件实例占用的资源量。

表 10-253 PluginResources

参数	参数类型	描述
involvedObject	ObjectReference object	插件引用的资源对象。
replicas	Integer	资源对象的副本数。
limits	Map<String,String >	申请的资源限制。
requests	Map<String,String >	申请的资源需求。

表 10-254 ObjectReference

参数	参数类型	描述
kind	String	资源对象的API类型，例如，DaemonSet、Deployment 等。
apiVersion	String	资源对象的API版本。
namespace	String	资源对象的命名空间。
name	String	资源对象的名称。
uid	String	资源对象的唯一标识符（UID）。
resourceVersion	String	资源对象的当前版本。

状态码：400

表 10-255 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

删除插件。

```
DELETE https://{endpoint}/v2/{project_id}/pools/{pool_name}/plugins/{template_name}
{ }
```

响应示例

状态码：200

success

```
{
  "kind": "Plugin",
  "apiVersion": "v2",
  "metadata": {
    "name": "pool-4cd084d36f8bd3346036-node-local-dns",
    "creationTimestamp": "2025-03-17T12:29:18Z"
  },
  "spec": {
    "template": {
      "name": "node-local-dns",
      "version": "1.6.36",
      "inputs": {
        "custom": {
          "enable_dnsconfig_admission": true,
          "nameserver": "135.0.0.1",
          "ndots": "8",
          "search": "1321"
        }
      },
      "flavor": {
        "description": "High available",
        "name": "HA",
        "resources": [ {
          "limitsCpu": "250m",
          "limitsMem": "512Mi",
          "name": "node-local-dns-admission-controller",
          "replicas": 2,
          "requestsCpu": "250m",
          "requestsMem": "512Mi"
        }, {
          "limitsCpu": "500m",
          "limitsMem": "512Mi",
          "name": "node-local-dns-cache",
          "requestsCpu": "25m",
          "requestsMem": "5Mi"
        } ],
        "size": "large"
      }
    }
  },
  "status": {
    "phase": "Running",
    "version": "1.6.36",
    "reason": "Install complete"
  }
}
```

状态码：400

Bad request


```
{
  "error_code" : "ModelArts.50004000",
  "error_msg" : "Bad request."
}
```

状态码

状态码	描述
200	success
400	Bad request

错误码

请参见[错误码](#)。

10.9.5 查询指定插件详情

功能介绍

查询指定插件实例详情。

URI

GET /v2/{project_id}/pools/{pool_name}/plugins/{template_name}

表 10-256 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池名称。
template_name	是	String	插件模板名称。

表 10-257 Query 参数

参数	是否必选	参数类型	描述
detail	否	String	若设置为true，获取插件实例的资源占用量。

请求参数

无

响应参数

状态码：200

表 10-258 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	插件实例的类型。
metadata	PluginMetadata object	插件实例的metadata信息。
spec	PluginSpec object	插件实例的具体信息。
status	PluginStatus object	插件实例的状态信息。

表 10-259 PluginMetadata

参数	参数类型	描述
name	String	插件实例的名称。
creationTimestamp	String	创建时间。

表 10-260 PluginSpec

参数	参数类型	描述
template	Template object	插件实例的模板信息。

表 10-261 Template

参数	参数类型	描述
name	String	待安装插件模板名称，如log-agent。
version	String	待安装、升级插件的版本号。
inputs	Map<String, Object>	插件模板安装参数（各插件不同），升级插件时需要填写全量安装参数，未填写参数将使用插件模板中的默认值，当前插件安装参数可通过查询插件实例接口获取。

表 10-262 PluginStatus

参数	参数类型	描述
phase	String	插件实例的状态。可选值如下： • Pending：安装中，表示插件正在安装中。 • Running：运行中，表示插件全部实例状态都在运行中，插件正常使用。 • Updating：升级中，表示插件正在更新中。 • Abnormal：不可用，表示插件状态异常，插件不可使用。可单击状态查看失败原因。 • Deleting：删除中，表示插件正在删除中。
version	String	插件实例的版本。
reason	String	插件实例安装失败的详细信息。
values	String	插件实例的安装参数（各插件不同）。
resources	Array of PluginResources objects	插件实例占用的资源量。

表 10-263 PluginResources

参数	参数类型	描述
involvedObject	ObjectReference object	插件引用的资源对象。
replicas	Integer	资源对象的副本数。
limits	Map<String,String>	申请的资源限制。
requests	Map<String,String>	申请的资源需求。

表 10-264 ObjectReference

参数	参数类型	描述
kind	String	资源对象的API类型，例如，DaemonSet、Deployment 等。
apiVersion	String	资源对象的API版本。

参数	参数类型	描述
namespace	String	资源对象的命名空间。
name	String	资源对象的名称。
uid	String	资源对象的唯一标识符（UID）。
resourceVersion	String	资源对象的当前版本。

状态码：400

表 10-265 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

查询指定插件实例详情。

GET https://{endpoint}/v2/{project_id}/pools/{pool_name}/plugins/{template_name}?detail=true

```
{
  "kind": "Plugin",
  "apiVersion": "v2",
  "metadata": {
    "name": "pool-6f5da0868084d36f8bd3346036-node-local-dns",
    "creationTimestamp": "2025-03-17T12:29:18Z"
  },
  "spec": {
    "template": {
      "name": "node-local-dns",
      "version": "1.6.36",
      "inputs": {
        "custom": {
          "enable_dnsconfig_admission": true,
          "nameserver": "135.0.0.1",
          "ndots": "8",
          "search": "1321"
        }
      },
      "flavor": {
        "description": "High available",
        "name": "HA",
        "resources": [ {
          "limitsCpu": "250m",
          "limitsMem": "512Mi",
          "name": "node-local-dns-admission-controller",
          "replicas": 2,
          "requestsCpu": "250m",
          "requestsMem": "512Mi"
        }, {
          "limitsCpu": "500m",
          "limitsMem": "512Mi",
          "name": "node-local-dns-cache",
          "requestsCpu": "25m",
          "requestsMem": "5Mi"
        }
      ]
    }
  }
}
```

```

    },
    "size" : "large"
  }
}
},
"status" : {
  "phase" : "Running",
  "version" : "1.6.36",
  "reason" : "Install complete",
  "resources" : [ {
    "limits" : {
      "cpu" : "500m",
      "memory" : "512Mi"
    },
    "requests" : {
      "cpu" : "25m",
      "memory" : "5Mi"
    },
    "involvedObject" : {
      "kind" : "DaemonSet",
      "namespace" : "kube-system",
      "name" : "node-local-dns",
      "uid" : "755437e4-b591-406c-a512-f9a02794082b",
      "apiVersion" : "apps/v1",
      "resourceVersion" : "702874"
    }
  }, {
    "limits" : {
      "cpu" : "250m",
      "memory" : "512Mi"
    },
    "requests" : {
      "cpu" : "250m",
      "memory" : "512Mi"
    },
    "involvedObject" : {
      "kind" : "Deployment",
      "namespace" : "kube-system",
      "name" : "node-local-dns-admission-controller",
      "uid" : "a770edcf-15c2-4caa-b10e-344de7eea7e1",
      "apiVersion" : "apps/v1",
      "resourceVersion" : "705195"
    },
    "replicas" : 2
  } ]
}
}
}

```

响应示例

状态码: 200

OK.

```
{
  "kind": "Plugin",
  "apiVersion": "v2",
  "metadata": {
    "name": "pool-6f5da0868084d36f8bd3346036-node-local-dns",
    "creationTimestamp": "2025-03-17T12:29:18Z"
  },
  "spec": {
    "template": {
      "name": "node-local-dns",
      "version": "1.6.36",
      "inputs": {
        "custom": {
          "enable_dnsconfig_admission": true,

```

```
    "nameserver" : "135.0.0.1",
    "ndots" : "8",
    "search" : "1321"
  },
  "flavor" : {
    "description" : "High available",
    "name" : "HA",
    "resources" : [ {
      "limitsCpu" : "250m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-admission-controller",
      "replicas" : 2,
      "requestsCpu" : "250m",
      "requestsMem" : "512Mi"
    }, {
      "limitsCpu" : "500m",
      "limitsMem" : "512Mi",
      "name" : "node-local-dns-cache",
      "requestsCpu" : "25m",
      "requestsMem" : "5Mi"
    } ],
    "size" : "large"
  }
}
},
"status" : {
  "phase" : "Running",
  "version" : "1.6.36",
  "reason" : "Install complete",
  "resources" : [ {
    "limits" : {
      "cpu" : "500m",
      "memory" : "512Mi"
    },
    "requests" : {
      "cpu" : "25m",
      "memory" : "5Mi"
    },
    "involvedObject" : {
      "kind" : "DaemonSet",
      "namespace" : "kube-system",
      "name" : "node-local-dns",
      "uid" : "755437e4-b591-406c-a512-f9a02794082b",
      "apiVersion" : "apps/v1",
      "resourceVersion" : "702874"
    }
  }, {
    "limits" : {
      "cpu" : "250m",
      "memory" : "512Mi"
    },
    "requests" : {
      "cpu" : "250m",
      "memory" : "512Mi"
    },
    "involvedObject" : {
      "kind" : "Deployment",
      "namespace" : "kube-system",
      "name" : "node-local-dns-admission-controller",
      "uid" : "a770edcf-15c2-4caa-b10e-344de7eea7e1",
      "apiVersion" : "apps/v1",
      "resourceVersion" : "705195"
    },
    "replicas" : 2
  } ]
}
}
```

状态码: 400

Bad request

```
{
  "error_code" : "ModelArts.50004000",
  "error_msg" : "Bad request. invalid nodepool name"
}
```

状态码

状态码	描述
200	OK。
400	Bad request

错误码

请参见[错误码](#)。

10.10 资源规格管理

10.10.1 查询资源规格列表

功能介绍

查询资源规格列表。

URI

GET /v1/{project_id}/resourceflavors

表 10-266 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

表 10-267 Query 参数

参数	是否必选	参数类型	描述
continue	否	String	分页查询时上一页位置。
labelSelector	否	String	标签筛选。
limit	否	Integer	分页数目。

请求参数

无

响应参数

状态码：200

表 10-268 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： ResourceFlavorList: 资源规格列表
metadata	ResourceFlavorListMetadata object	资源规格列表metadata信息。
items	Array of ResourceFlavor objects	资源规格列表。

表 10-269 ResourceFlavorListMetadata

参数	参数类型	描述
continue	String	分页查询时，下一次查询位置。
remainingItemCount	Integer	剩余资源个数。

表 10-270 ResourceFlavor

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v1
kind	String	资源类型。可选值如下： ResourceFlavor: 资源规格
metadata	ResourceFlavorMetadata object	资源规格的metadata信息。
spec	ResourceFlavorSpec object	资源规格的描述信息

参数	参数类型	描述
status	ResourceFlavorStatus object	资源规格的状态信息。

表 10-271 ResourceFlavorMetadata

参数	参数类型	描述
name	String	资源规格名称。
labels	ResourceFlavorLabel object	资源规格的标签信息。
annotations	ResourceFlavorAnnotations object	资源规格的注释信息。

表 10-272 ResourceFlavorLabel

参数	参数类型	描述
os.modelarts/scope	String	资源规格对应的作业类型。
os.modelarts.flavor/baremetal	String	裸金属规格标志。true表示该规格是裸金属规格。
os.modelarts.flavor/localdisk	String	是否含有本地盘标志。true表示该规格含有本地盘。

表 10-273 ResourceFlavorAnnotations

参数	参数类型	描述
os.modelarts.resourceflavor/volume.configs	String	资源规格额外挂载磁盘的约束信息。

表 10-274 ResourceFlavorSpec

参数	参数类型	描述
type	String	资源规格类型。可选值如下： • Dedicate：物理资源 • Logical：逻辑资源

参数	参数类型	描述
cpuArch	String	计算机架构。可选值如下： - x86：x86架构 - arm64：ARM架构
cpu	String	CPU核心数量。
memory	String	内存大小，单位为Gi。
gpu	ResourceFlavorXpu object	GPU信息。
npu	ResourceFlavorXpu object	NPU信息。
dataVolumes	Array of DataVolumeItem objects	数据盘列表。
rootVolume	RootVolume object	系统盘信息。
billingModes	Array of integers	资源规格支持的计费模式。
jobFlavors	Array of strings	资源规格支持的作业类型列表。
nodeConfigTemplate	String	资源规格使用的节点配置模板。
flavorBootType	String	裸金属服务器启动源。可选值如下： - LocalDisk：本地盘 - Volume：云硬盘（快速发放）
localDiskDetail	String	磁盘物理规格描述信息。

表 10-275 ResourceFlavorXpu

参数	参数类型	描述
type	String	XPU卡类型。
size	String	XPU卡数量。
memory	String	XPU显存大小。

表 10-276 DataVolumeItem

参数	参数类型	描述
volumeType	String	磁盘类型。可选值如下： - SSD：超高IO硬盘 - GPSSD：通用型SSD - SAS：高IO硬盘 - SATA：普通硬盘
size	String	磁盘大小，单位为Gi。

表 10-277 RootVolume

参数	参数类型	描述
volumeType	String	磁盘类型。可选值如下： - SSD：超高IO硬盘 - GPSSD：通用型SSD - SAS：高IO硬盘 - SATA：普通硬盘
size	String	磁盘大小，单位为Gi。

表 10-278 ResourceFlavorStatus

参数	参数类型	描述
phase	Map<String,String>	资源规格在各AZ的售罄状态。值内容为：(AZ,Status)。Status可选值如下： - normal：正常 - soldout：售罄

状态码：401

表 10-279 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

状态码：404

表 10-280 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

查询资源规格列表。

```
GET https://{endpoint}/v1/{project_id}/resourceflavors
{ }
```

响应示例

状态码：200

OK。

```
{
  "kind" : "ResourceFlavorList",
  "apiVersion" : "v1",
  "metadata" : { },
  "items" : [ {
    "kind" : "ResourceFlavor",
    "apiVersion" : "v1",
    "metadata" : {
      "name" : "modelarts.vm.cpu8u32g",
      "labels" : { }
    },
    "spec" : {
      "cpuArch" : "x86",
      "cpu" : "8",
      "memory" : "32Gi",
      "type" : "Dedicate",
      "billingModes" : [ 0 ],
      "dataVolumes" : [ {
        "volumeType" : "SSD",
        "size" : "500Gi"
      } ]
    }
  },
  "status" : {
    "phase" : {
      "cn-north-7a" : "soldout",
      "cn-north-7b" : "soldout",
      "cn-north-7c" : "normal"
    }
  }
} ] }
```

状态码：401

Authorization failed.

```
{
  "error_code" : "ModelArts.50001000",
  "error_msg" : "token is invalid"
}
```

状态码：404

Not found.

```
{
  "error_code" : "ModelArts.50005101",
  "error_msg" : "Resourceflavor not found."
}
```

状态码

状态码	描述
200	OK。
401	Authorization failed.
404	Not found.

错误码

请参见[错误码](#)。

10.11 订单管理

10.11.1 查询订单列表

功能介绍

查询订单列表。

URI

GET /v1/{project_id}/orders

表 10-281 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

表 10-282 Query 参数

参数	是否必选	参数类型	描述
involvedName	否	String	关联资源的name。比如资源池的display name

参数	是否必选	参数类型	描述
limit	否	Integer	单次查询最大数量，该值为空或者0时默认返回100条记录，最大允许查询500条记录。
offset	否	Integer	查询的起始位置，取值范围是[0, 500]
phase	否	String	事件处理状态。可选值如下： - pending：等待中，通常是未支付或者未审核导致 - running：处理中 - succesed：成功 - failed：失败

请求参数

表 10-283 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户的token

响应参数

状态码：200

表 10-284 响应 Body 参数

参数	参数类型	描述
count	Integer	符合查询条件的结果总数
items	Array of Order objects	实际返回的事件详情

表 10-285 Order

参数	参数类型	描述
creationTimestamp	Long	订单创建时间，单位毫秒。
endTimeStamp	Long	订单结束时间，单位毫秒。如果还未结束，则返回0。

参数	参数类型	描述
beginTimestamp	Long	订单开始处理时间，单位毫秒。如果还未开始处理，则返回0。
orderName	String	订单名称。
orderId	String	订单ID。
resourceName	String	订单关联的资源name。
resourceDisplayName	String	订单关联的资源展示name。
initCount	Array of PoolResourceFlavorCount objects	订单对应资源池初始状态，如果是新建池，则为空。
specCount	Array of PoolResourceFlavorCount objects	订单对应资源池目标状态。
resultCount	Array of PoolResourceFlavorCount objects	订单对应资源池最终资源状态。
billingMode	String	订单计费类型。可选值如下： 0：按需
operation	String	订单动作。可选值如下： - apply：新建 - modify：变更 - delete：删除
phase	String	订单结果。可选值如下： - pending：订单等待中 - processing：订单处理中 - succesed：成功 - failed：失败
failReason	String	如果phase是失败状态，则返回失败原因。

表 10-286 PoolResourceFlavorCount

参数	参数类型	描述
flavor	String	资源规格名称，比如：modelarts.vm.gpu.t4u8。
count	Integer	规格保障使用量。

参数	参数类型	描述
maxCount	Integer	资源规格的弹性使用量，物理池该值和count相同，逻辑池该值大于等于count。
azs	Array of azs objects	资源所在的AZ的数量。

表 10-287 azs

参数	参数类型	描述
az	String	AZ的名称。
count	Integer	AZ的资源数量。

状态码：400

表 10-288 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：404

表 10-289 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

分页查询资源池pool-5ed5的订单列表，返回20个结果，并只要成功的订单

```
/v1/{project_id}/orders?involvedName=pool-5ed5&limit=20&offset=0&result=successeed
{ }
```

响应示例

状态码：200

OK。

```
{
  "count" : 1,
  "items" : [{
    "creationTimestamp" : 1682043883000,
    "endTimestamp" : 1682043893000,
    "beginTimestamp" : 1682043893000,
    "orderName" : "order.pool-5ed5-w4l2n",
    "orderId" : "CS2304191748WNW2R",
    "resourceName" : "pool-5ed5-04f258c84780d5a52f3bc00dc15aa5e7",
    "resourceDisplayName" : "pool-5ed5",
    "specCount" : [{
      "flavor" : "modelarts.vm.cpu.2u.d",
      "count" : 1
    }],
    "billingMode" : "1",
    "periodType" : "2",
    "periodNum" : "1",
    "operation" : "apply",
    "result" : "succeeded",
    "phase" : "completed"
  }]
}
```

状态码：400

Bad Request。

```
{
  "error_code" : "ModelArts.50004000",
  "error_msg" : "Bad request."
}
```

状态码：404

Not Found。

```
{
  "error_code" : "ModelArts.50015001",
  "error_msg" : "Pool {name} not found."
}
```

状态码

状态码	描述
200	OK。
400	Bad Request。
404	Not Found。

错误码

请参见[错误码](#)。

10.11.2 查询订单详情

功能介绍

查询订单详情

URI

GET /v1/{project_id}/orders/{order_name}

表 10-290 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
order_name	是	String	订单ID。取值自订单列表返回的orderName字段。

请求参数

表 10-291 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户的token

响应参数

状态码：200

表 10-292 响应 Body 参数

参数	参数类型	描述
count	Integer	参数解释：订单关联的资源数量。 约束限制：不涉及。 取值范围：不涉及。 默认取值：不涉及。
items	Array of OrderDetailItem objects	参数解释：订单关联的资源信息列表。 约束限制：不涉及。 取值范围：不涉及。 默认取值：不涉及。

表 10-293 OrderDetailItem

参数	参数类型	描述
resourceName	String	参数解释： 资源的ID，取值自资源详情的metadata.name字段。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
action	String	参数解释： 订单关联的资源变更动作类型。 约束限制： 不涉及。 取值范围： 可选值如下： • createPool：创建资源池。 • deletePool：删除资源池。 • createNode：创建节点。 默认取值： 不涉及。
status	String	参数解释： 订单关联资源的变更状态。 约束限制： 不涉及。 取值范围： 可选值如下： • processing：处理中，资源正在处理中。 • succeed：成功，资源处理成功。 • failed：失败，资源处理失败。 默认取值： 不涉及。
beginTimestamp	String	参数解释： 资源开始变更时间戳，形如1744285793000，单位毫秒。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
updateTimestamp	String	参数解释： 资源变更最后更新时间戳，形如1744285793000，单位毫秒。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
message	String	参数解释： 资源变更的执行信息，如失败原因。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

状态码：400

表 10-294 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：404

表 10-295 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

查询订单详情中的资源信息。

```
/v1/{project_id}/orders/{order_name}
```

响应示例

状态码：200

OK。

```
{
  "count": 4,
  "items": [ {
    "action": "createPool",
    "resourceName": "pool-9495-6f5da086876d4cd084d36f8bd3346036",
    "status": "succeed",
    "beginTimestamp": 1744285793000,
    "updateTimestamp": 1744286479000
  }, {
    "action": "createNode",
    "resourceName": "os-node-created-8jsnk",
    "status": "succeed",
    "beginTimestamp": 1744286228000,
    "updateTimestamp": 1744286479000
  }, {
    "action": "createNode",
    "resourceName": "os-node-created-lq4f8",
    "status": "succeed",
    "beginTimestamp": 1744286228000,
    "updateTimestamp": 1744286479000
  }, {
    "action": "createNode",
    "resourceName": "os-node-created-ggthb",
    "status": "succeed",
    "beginTimestamp": 1744286228000,
    "updateTimestamp": 1744286479000
  } ]
}
```

```
  }]  
}
```

状态码：400

Bad Request。

```
{  
  "error_code" : "ModelArts.50004000",  
  "error_msg" : "Bad request."  
}
```

状态码：404

Not Found。

```
{  
  "error_code" : "ModelArts.50015001",  
  "error_msg" : "Order {name} not found."  
}
```

状态码

状态码	描述
200	OK。
400	Bad Request。
404	Not Found。

错误码

请参见[错误码](#)。

10.12 资源池管理

10.12.1 创建资源池

功能介绍

用户创建资源池。

URI

POST /v2/{project_id}/pools

表 10-296 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

请求参数

表 10-297 请求 Header 参数

参数	是否必选	参数类型	描述
request-type	否	String	请求的来源，只有设置 "console" 才会启用订单功能。

表 10-298 请求 Body 参数

参数	是否必选	参数类型	描述
apiVersion	是	String	API版本。可选值如下： v2
kind	是	String	资源类型。可选值如下： Pool：资源池
metadata	是	PoolMetadataCreation object	资源池的metadata信息。
spec	否	PoolSpecCreation object	资源池的描述信息。

表 10-299 PoolMetadataCreation

参数	是否必选	参数类型	描述
labels	是	PoolLabelsCreation object	资源池的标签信息。
annotations	否	PoolAnnotationsCreation object	资源池的注释信息。

表 10-300 PoolLabelsCreation

参数	是否必选	参数类型	描述
os.modelarts/workspace.id	否	String	工作空间ID，默认值0。
os.modelarts/name	是	String	用户指定的pool名称。最小长度为4，最大长度为25的小写字母、中划线-、数字组成

表 10-301 PoolAnnotationsCreation

参数	是否必选	参数类型	描述
os.modelarts/ description	否	String	资源池的描述信息。
os.modelarts/ billing.mode	否	String	计费模式。
os.modelarts. pool/ scheduler.que ue.strategy	否	String	作业调度策略： • FIFO: FIFO调度，默认值，如果队列中的第一个作业因资源配额原因无法被调度，系统将反复尝试它，不会跳过。 • Range: Range调度，如果队列中的第一个作业因资源配额原因无法被调度，则跳过它并依次尝试后续队列的作业。

表 10-302 PoolSpecCreation

参数	是否必选	参数类型	描述
type	是	String	资源池类型。可选值如下： • Dedicate: 物理资源池，独立的网络，支持网络打通，定制驱动，定制作业类型
scope	否	Array of strings	启用的作业类型，对于逻辑池不支持指定。可选值如下： • Train: 训练作业 • Infer: 推理作业 • X-Infer: 新版推理作业
resources	是	Array of PoolResource objects	资源池中的资源规格信列表，包括资源规格和相应规格的资源数量。
parent	否	String	父资源池ID。基于指定资源池创建逻辑子池的场景下需要传递该参数。
network	否	PoolNetwork object	资源池网络参数。创建物理资源池时必选；创建逻辑资源池时不可选。

参数	是否必选	参数类型	描述
masters	否	Array of PoolClusterMaster objects	资源池控制节点参数。物理资源池可选，逻辑资源池不可选。
clusterFlavor	否	String	标准池的集群规格。
driver	否	PoolDriver object	资源池的驱动信息。

表 10-303 PoolResource

参数	是否必选	参数类型	描述
flavor	是	String	资源规格名称，比如：modelarts.vm.gpu.tnt004。
count	是	Integer	规格保障使用量。
maxCount	否	Integer	资源规格的弹性使用量，物理池该值和count相同，逻辑池该值大于等于count。
azs	否	Array of PoolNodeAz objects	资源池中节点的AZ信息。
extendParams	否	PoolResourceExtendParams object	自定义配置，比如设置节点 dockerSize。

表 10-304 PoolNodeAz

参数	是否必选	参数类型	描述
az	是	String	az名称。
count	是	Integer	指定az扩容时，指定az的节点数。

表 10-305 PoolResourceExtendParams

参数	是否必选	参数类型	描述
dockerBaseSize	否	String	节点的容器镜像空间大小。 - 指定大小：dockerBaseSize的大小范围默认为50-500，单位GiB，但实际上限受到节点的容器数据盘大小约束。 - 不限制：dockerBaseSize="0"，表示不限制容器镜像空间大小。
postInstall	否	String	安装后执行脚本，输入的值需要经过Base64编码。

表 10-306 PoolNetwork

参数	是否必选	参数类型	描述
name	否	String	网络名称，取值来自网络资源详情中metadata.name字段的值。

表 10-307 PoolClusterMaster

参数	是否必选	参数类型	描述
az	否	String	控制节点所在AZ。

表 10-308 PoolDriver

参数	是否必选	参数类型	描述
gpuVersion	否	String	GPU驱动版本，物理资源池中 含有GPU规格时可填，例如： "440.33"。
npuVersion	否	String	NPU驱动版本，物理资源池中 含有ascend规格时可填，例如： "C78"。
updateStrategy	否	String	驱动升级策略。可选值如下： - force：强制升级，立即升级节点驱动，可能影响节点上正在运行的作业 - idle：安全升级，待节点上没有作业运行时进行驱动升级

响应参数

状态码：200

表 10-309 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	资源类型。可选值如下： Pool: 资源池
metadata	PoolMetadata object	资源池的metadata信息。
spec	PoolSpec object	资源池的期望信息。
status	PoolStatus object	资源池的状态信息。

表 10-310 PoolMetadata

参数	参数类型	描述
name	String	系统自动生成的pool名称，相当于pool ID。
creationTimestamp	String	时间戳，"2021-11-01T03:49:41Z"。
labels	PoolMetaLabels object	资源池的标签信息。
annotations	PoolMetaAnnotations object	资源池的注释信息。

表 10-311 PoolMetaLabels

参数	参数类型	描述
os.modelarts/workspace.id	String	工作空间ID。
os.modelarts/name	String	用户指定的资源池名称。
os.modelarts/resource.id	String	资源池的资源id。

参数	参数类型	描述
os.modelarts/ tenant.domain.id	String	资源池的租户id，记录资源池创建在哪个租户账号下。
os.modelarts/ create-from	String	资源池创建来源，比如admin-console，标记来自admin创建，console标记来自ma console。
os.modelarts.pool/ biz	String	资源池商业类型，public是公共池，private个人专属池。

表 10-312 PoolMetaAnnotations

参数	参数类型	描述
os.modelarts/ description	String	资源池的描述信息。
os.modelarts/ billing.mode	String	计费模式。
os.modelarts/ flavor.resource.ids	String	每种规格对应的资源ID。
os.modelarts/ tms.tags	String	创建资源池的时候由用户指定的资源标签。
os.modelarts.pool/ subpools.count	String	资源池包含的逻辑子池的数量。
os.modelarts.pool/ scope.external.dep endency.Train	String	训练外部依赖标识。
os.modelarts.pool/ scope.external.dep endency.Infer	String	推理外部依赖标识。
os.modelarts.pool/ scope.external.dep endency.X-Infer	String	新版推理外部依赖标识。
os.modelarts.pool/ scheduler.queue.st rategy	String	作业调度策略： • FIFO: FIFO调度，默认值，如果队列中的第一个作业因资源配额原因无法被调度，系统将反复尝试它，不会跳过。 • Range: Range调度，如果队列中的第一个作业因资源配额原因无法被调度，则跳过它并依次尝试后续队列的作业。

表 10-313 PoolSpec

参数	参数类型	描述
type	String	资源池类型。可选值如下： • Dedicate：物理资源池，独立的网络，支持网络打通，定制驱动，定制作业类型 • Logical：逻辑资源池。没有独立的网络，不支持网络打通，资源池创建和扩缩容相较物理资源池更快。
scope	Array of strings	启用的作业类型，对于逻辑池不支持指定。可选值如下： • Train：训练作业 • Infer：推理作业 • X-Infer：新版推理作业
resources	Array of PoolResource objects	资源池中的资源规格列表，包括资源规格和相应规格的资源数量。
network	PoolNetwork object	资源池网络参数。物理资源池时必选；逻辑资源池时不可选。
masters	Array of PoolClusterMaster objects	资源池控制节点参数。物理资源池可选，逻辑资源池不可选。
clusterFlavor	String	标准池的集群规格。
driver	PoolDriver object	资源池的驱动信息。

表 10-314 PoolResource

参数	参数类型	描述
flavor	String	资源规格名称，比如： modelarts.vm.gpu.tnt004。
count	Integer	规格保障使用量。
maxCount	Integer	资源规格的弹性使用量，物理池该值和count相同，逻辑池该值大于等于count。
azs	Array of PoolNodeAz objects	资源池中节点的AZ信息。
extendParams	PoolResourceExtendParams object	自定义配置，比如设置节点dockerSize。

表 10-315 PoolResourceExtendParams

参数	参数类型	描述
dockerBaseSize	String	节点的容器镜像空间大小。 - 指定大小：dockerBaseSize的大小范围默认为50-500，单位GiB，但实际上限受到节点的容器数据盘大小约束。 - 不限制：dockerBaseSize="0"，表示不限制容器镜像空间大小。
postInstall	String	安装后执行脚本，输入的值需要经过Base64编码。

表 10-316 PoolNetwork

参数	参数类型	描述
name	String	网络名称，取值来自网络资源详情中metadata.name字段的值。

表 10-317 PoolClusterMaster

参数	参数类型	描述
az	String	控制节点所在AZ。

表 10-318 PoolDriver

参数	参数类型	描述
gpuVersion	String	GPU驱动版本，物理资源池中含有GPU规格时可填，例如："440.33"。
npuVersion	String	NPU驱动版本，物理资源池中含有ascend规格时可填，例如："C78"。
updateStrategy	String	驱动升级策略。可选值如下： - force：强制升级，立即升级节点驱动，可能影响节点上正在运行的作业 - idle：安全升级，待节点上没有作业运行时进行驱动升级

表 10-319 PoolStatus

参数	参数类型	描述
phase	String	资源池集群状态。可选值如下： - Creating：创建中 - Running：运行中 - Abnormal：资源池存在异常节点 - Deleting：删除中 - Error：资源池错误
message	String	资源池处于当前状态的提示信息。
resources	PoolResourceStatus object	资源池中不同状态的资源量。
scope	Array of PoolScopeStatus objects	资源池业务状态信息。
driver	PoolDriverListStatus object	资源池驱动信息。
parent	String	资源池父节点名称，物理池为空。
root	String	资源池根节点名称，物理池为自己的名称。

表 10-320 PoolResourceStatus

参数	参数类型	描述
creating	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
available	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
abnormal	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
deleting	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。

表 10-321 PoolResourceFlavorCount

参数	参数类型	描述
flavor	String	资源规格名称，比如： modelarts.vm.gpu.tnt004。
count	Integer	规格保障使用量。
maxCount	Integer	资源规格的弹性使用量，物理池该值和 count相同，逻辑池该值大于等于 count。
azs	Array of PoolNodeAz objects	资源池中节点的AZ信息。

表 10-322 PoolNodeAz

参数	参数类型	描述
az	String	az名称。
count	Integer	指定az扩容时，指定az的节点数。

表 10-323 PoolScopeStatus

参数	参数类型	描述
scopeType	String	启用的作业类型。可选值如下： • Train：训练作业 • Infer：推理作业 • X-Infer：新版推理作业
state	String	业务状态。可选值如下： • Enabling：启动中 • Enabled：已启动 • EnableFailed：启用失败 • Disabling：关闭中 • Disabled：已关闭
plugins	Array of PoolScopePlugin Phase objects	插件状态信息。
message	String	环境开启、关闭失败原因。

表 10-324 PoolScopePluginPhase

参数	参数类型	描述
name	String	插件类型。
phase	String	插件状态。可选值如下： • Pending：等待中。 • Running：运行中。 • Updating：更新中。 • Abnormal：异常。 • Deleting：删除中。

表 10-325 PoolDriverListStatus

参数	参数类型	描述
gpu	PoolDriverStatus object	GPU驱动信息。
npu	PoolDriverStatus object	NPU驱动信息。

表 10-326 PoolDriverStatus

参数	参数类型	描述
version	String	当前驱动版本。
state	String	当前驱动状态。可选值如下： • Creating：创建中 • Upgrading：升级中 • Running：运行中 • Abnormal：不正常

状态码：400

表 10-327 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

状态码：409

表 10-328 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

- 创建物理池。

```
POST https://{endpoint}/v2/{project_id}/pools

{
  "kind": "Pool",
  "apiVersion": "v2",
  "metadata": {
    "annotations": {
      "os.modelarts/description": ""
    },
    "labels": {
      "os.modelarts/name": "pool-ae01",
      "os.modelarts/workspace.id": "0"
    }
  },
  "spec": {
    "type": "Dedicate",
    "scope": [
      "Train"
    ],
    "network": {
      "name": "network-21e1-6f5da086876d4cd084d36f8bd3346036"
    },
    "resources": [
      {
        "count": 1,
        "flavor": "modelarts.vm.cpu.8ud",
      }
    ]
  }
}
```

- 创建逻辑池。

```
POST https://{endpoint}/v2/{project_id}/pools

{
  "kind" : "Pool",
  "apiVersion" : "v1",
  "metadata" : {
    "labels" : {
      "os.modelarts/name" : "pool-logic-01"
    },
    "annotations" : {
      "os.modelarts/description" : "",
      "os.modelarts/billing.mode" : 0,
      "os.modelarts/product.id" : "xxx"
    }
  },
  "spec" : {
    "type" : "Logical",
    "scope" : [ "Train" ],
    "resources" : [ {
```

```
    "flavor": "modelarts.vm.gpu.tnt004",  
    "count": 2  
  }  
}
```

响应示例

状态码：200

OK。

```
{  
  "kind": "Pool",  
  "apiVersion": "v2",  
  "metadata": {  
    "name": "pool-ae01-6f5da086876d4cd084d36f8bd3346036",  
    "creationTimestamp": "2024-10-24T12:42:43Z",  
    "labels": {  
      "os.modelarts/name": "pool-ae01",  
      "os.modelarts/workspace.id": "0",  
      "os.modelarts/node.prefix": "",  
      "os.modelarts/resource.id": "maos-pool-ae01-d7mjs",  
      "os.modelarts/tenant.domain.id": "75fef1f8a9d64d0cb8de795599185b48",  
      "os.modelarts/tenant.project.id": "6f5da086876d4cd084d36f8bd3346036",  
      "os.modelarts.pool/biz": "private",  
      "os.modelarts/create-from": "console"  
    },  
    "annotations": {  
      "os.modelarts/billing.mode": "0",  
      "os.modelarts.pool/subpools.count": "0",  
      "os.modelarts/flavor.resource.ids": "{\"modelarts.vm.cpu.8ud\":\"maos.vm.cpu.8ud.1976103046\"}",  
      "os.modelarts/tenant.domain.name": "ei_batch_t00420620_01"  
    }  
  },  
  "spec": {  
    "type": "Dedicate",  
    "scope": [ "Train" ],  
    "resources": [ {  
      "flavor": "modelarts.vm.cpu.8ud",  
      "count": 1,  
      "maxCount": 1  
    } ],  
    "network": {  
      "name": "network-21e1-6f5da086876d4cd084d36f8bd3346036"  
    }  
  },  
  "status": {  
    "resources": { }  
  }  
}
```

状态码：400

Bad request

```
{  
  "error_code": "ModelArts.50004000",  
  "error_msg": "Bad request"  
}
```

状态码：409

Already exists

```
{  
  "error_code": "ModelArts.50015000",  
  "error_msg": "Pool already exists."  
}
```

状态码

状态码	描述
200	OK。
400	Bad request
409	Already exists

错误码

请参见[错误码](#)。

10.12.2 查询资源池列表

功能介绍

查询资源池列表。

URI

GET /v2/{project_id}/pools

表 10-329 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

表 10-330 Query 参数

参数	是否必选	参数类型	描述
workspaceId	否	String	工作空间ID，默认值为0。
labelSelector	否	String	标签筛选。
status	否	String	资源池状态。可选值如下： - created: 创建成功的资源池 - failed: 状态错误的资源池 - creating: 创建中的资源池
parent	否	String	父资源池的名称。查询指定资源池下的子池列表。

请求参数

无

响应参数

状态码：200

表 10-331 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	资源类型。可选值如下： PoolList：资源池列表
items	Array of Pool objects	资源池列表。

表 10-332 Pool

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	资源类型。可选值如下： Pool：资源池
metadata	PoolMetadata object	资源池的metadata信息。
spec	PoolSpec object	资源池的期望信息。
status	PoolStatus object	资源池的状态信息。

表 10-333 PoolMetadata

参数	参数类型	描述
name	String	系统自动生成的pool名称，相当于pool ID。
creationTimestamp	String	时间戳，"2021-11-01T03:49:41Z"。
labels	PoolMetaLabels object	资源池的标签信息。

参数	参数类型	描述
annotations	PoolMetaAnnotations object	资源池的注释信息。

表 10-334 PoolMetaLabels

参数	参数类型	描述
os.modelarts/ workspace.id	String	工作空间ID。
os.modelarts/ name	String	用户指定的资源池名称。
os.modelarts/ resource.id	String	资源池的资源id。
os.modelarts/ tenant.domain.id	String	资源池的租户id，记录资源池创建在哪个租户账号下。
os.modelarts/ create-from	String	资源池创建来源，比如admin-console，标记来自admin创建，console标记来自ma console。
os.modelarts.pool/ biz	String	资源池商业类型，public是公共池，private个人专属池。

表 10-335 PoolMetaAnnotations

参数	参数类型	描述
os.modelarts/ description	String	资源池的描述信息。
os.modelarts/ billing.mode	String	计费模式。
os.modelarts/ flavor.resource.ids	String	每种规格对应的资源ID。
os.modelarts/ tms.tags	String	创建资源池的时候由用户指定的资源标签。
os.modelarts.pool/ subpools.count	String	资源池包含的逻辑子池的数量。
os.modelarts.pool/ scope.external.dependency.Train	String	训练外部依赖标识。

参数	参数类型	描述
os.modelarts.pool/scope.external.dependency.Infer	String	推理外部依赖标识。
os.modelarts.pool/scope.external.dependency.X-Infer	String	新版推理外部依赖标识。
os.modelarts.pool/scheduler.queue.strategy	String	作业调度策略： - FIFO：FIFO调度，默认值，如果队列中的第一个作业因资源配额原因无法被调度，系统将反复尝试它，不会跳过。 - Range：Range调度，如果队列中的第一个作业因资源配额原因无法被调度，则跳过它并依次尝试后续队列的作业。

表 10-336 PoolSpec

参数	参数类型	描述
type	String	资源池类型。可选值如下： - Dedicate：物理资源池，独立的网络，支持网络打通，定制驱动，定制作业类型 - Logical：逻辑资源池。没有独立的网络，不支持网络打通，资源池创建和扩缩容相较物理资源池更快。
scope	Array of strings	启用的作业类型，对于逻辑池不支持指定。可选值如下： - Train：训练作业 - Infer：推理作业 - X-Infer：新版推理作业
resources	Array of PoolResource objects	资源池中的资源规格列表，包括资源规格和相应规格的资源数量。
network	PoolNetwork object	资源池网络参数。物理资源池时必选；逻辑资源池时不可选。
masters	Array of PoolClusterMaster objects	资源池控制节点参数。物理资源池可选，逻辑资源池不可选。
clusterFlavor	String	标准池的集群规格。

参数	参数类型	描述
driver	PoolDriver object	资源池的驱动信息。

表 10-337 PoolResource

参数	参数类型	描述
flavor	String	资源规格名称，比如： modelarts.vm.gpu.tnt004。
count	Integer	规格保障使用量。
maxCount	Integer	资源规格的弹性使用量，物理池该值和 count相同，逻辑池该值大于等于 count。
azs	Array of PoolNodeAz objects	资源池中节点的AZ信息。
extendParams	PoolResourceExt endParams object	自定义配置，比如设置节点dockerSize。

表 10-338 PoolResourceExtendParams

参数	参数类型	描述
dockerBaseSize	String	节点的容器镜像空间大小。 - 指定大小：dockerBaseSize的大小范围默认为50-500，单位GiB，但实际上限受到节点的容器数据盘大小约束。 - 不限制：dockerBaseSize="0"，表示不限制容器镜像空间大小。
postInstall	String	安装后执行脚本，输入的值需要经过Base64编码。

表 10-339 PoolNetwork

参数	参数类型	描述
name	String	网络名称，取值来自网络资源详情中 metadata.name字段的值。

表 10-340 PoolClusterMaster

参数	参数类型	描述
az	String	控制节点所在AZ。

表 10-341 PoolDriver

参数	参数类型	描述
gpuVersion	String	GPU驱动版本，物理资源池中 含有GPU规格时可填，例如： "440.33"。
npuVersion	String	NPU驱动版本，物理资源池中 含有ascend规格时可填，例如： "C78"。
updateStrategy	String	驱动升级策略。可选值如下： - force：强制升级，立即升级节点驱动，可能影响节点上正在运行的作业 - idle：安全升级，待节点上没有作业运行时进行驱动升级

表 10-342 PoolStatus

参数	参数类型	描述
phase	String	资源池集群状态。可选值如下： - Creating：创建中 - Running：运行中 - Abnormal：资源池存在异常节点 - Deleting：删除中 - Error：资源池错误
message	String	资源池处于当前状态的提示信息。
resources	PoolResourceStatus object	资源池中不同状态的资源量。
scope	Array of PoolScopeStatus objects	资源池业务状态信息。
driver	PoolDriverListStatus object	资源池驱动信息。
parent	String	资源池父节点名称，物理池为空。
root	String	资源池根节点名称，物理池为自己的名称。

表 10-343 PoolResourceStatus

参数	参数类型	描述
creating	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
available	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
abnormal	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
deleting	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。

表 10-344 PoolResourceFlavorCount

参数	参数类型	描述
flavor	String	资源规格名称，比如： modelarts.vm.gpu.tnt004。
count	Integer	规格保障使用量。
maxCount	Integer	资源规格的弹性使用量，物理池该值和count相同，逻辑池该值大于等于count。
azs	Array of PoolNodeAz objects	资源池中节点的AZ信息。

表 10-345 PoolNodeAz

参数	参数类型	描述
az	String	az名称。
count	Integer	指定az扩容时，指定az的节点数。

表 10-346 PoolScopeStatus

参数	参数类型	描述
scopeType	String	启用的作业类型。可选值如下： - Train：训练作业 - Infer：推理作业 - X-Infer：新版推理作业
state	String	业务状态。可选值如下： - Enabling：启动中 - Enabled：已启动 - EnableFailed：启用失败 - Disabling：关闭中 - Disabled：已关闭
plugins	Array of PoolScopePluginPhase objects	插件状态信息。
message	String	环境开启、关闭失败原因。

表 10-347 PoolScopePluginPhase

参数	参数类型	描述
name	String	插件类型。
phase	String	插件状态。可选值如下： - Pending：等待中。 - Running：运行中。 - Updating：更新中。 - Abnormal：异常。 - Deleting：删除中。

表 10-348 PoolDriverListStatus

参数	参数类型	描述
gpu	PoolDriverStatus object	GPU驱动信息。
npu	PoolDriverStatus object	NPU驱动信息。

表 10-349 PoolDriverStatus

参数	参数类型	描述
version	String	当前驱动版本。
state	String	当前驱动状态。可选值如下： - Creating：创建中 - Upgrading：升级中 - Running：运行中 - Abnormal：不正常

请求示例

查询资源池列表。

```
GET https://{endpoint}/v2/{project_id}/pools
{ }
```

响应示例

状态码：200

OK。

```
{
  "kind": "PoolList",
  "apiVersion": "v2",
  "items": [ {
    "kind": "Pool",
    "apiVersion": "v2",
    "metadata": {
      "name": "auto-pool-os-86c13962597848eeb29c5861153a391f",
      "creationTimestamp": "2022-09-16T03:10:40Z",
      "labels": {
        "os.modelarts/name": "auto-pool-os",
        "os.modelarts/resource.id": "maos-auto-pool-os-72w8d"
      },
      "annotations": {
        "os.modelarts/description": "",
        "os.modelarts/billing.mode": "0",
        "os.modelarts/external-access": "elb"
      }
    },
    "spec": {
      "type": "Dedicate",
      "scope": [ "Train", "Infer" ],
      "resources": [ {
        "flavor": "modelarts.vm.cpu.4ud",
        "count": 2
      } ],
      "network": {
        "name": "network-maos-86c13962597848eeb29c5861153a391f"
      }
    },
    "status": {
      "phase": "Running",
      "root": "auto-pool-os-86c13962597848eeb29c5861153a391f",
      "scope": [ {
        "scopeType": "Train",
```

```
{
  "state": "Enabled"
}, {
  "scopeType": "Infer",
  "state": "Enabled"
}],
"resources": {
  "available": [ {
    "flavor": "modelarts.vm.cpu.4ud",
    "count": 2,
    "azs": [ {
      "az": "cn-north-7c",
      "count": 2
    } ]
  } ]
} ]
}
```

状态码

状态码	描述
200	OK。

错误码

请参见[错误码](#)。

10.12.3 查询资源池

功能介绍

查询指定资源池的详细信息。

URI

GET /v2/{project_id}/pools/{pool_name}

表 10-350 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池ID。取值资源池详情的 metadata.name 字段。

请求参数

无

响应参数

状态码：200

表 10-351 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	资源类型。可选值如下： Pool：资源池
metadata	PoolMetadata object	资源池的metadata信息。
spec	PoolSpec object	资源池的期望信息。
status	PoolStatus object	资源池的状态信息。

表 10-352 PoolMetadata

参数	参数类型	描述
name	String	系统自动生成的pool名称，相当于pool ID。
creationTimestamp	String	时间戳，"2021-11-01T03:49:41Z"。
labels	PoolMetaLabels object	资源池的标签信息。
annotations	PoolMetaAnnotations object	资源池的注释信息。

表 10-353 PoolMetaLabels

参数	参数类型	描述
os.modelarts/workspace.id	String	工作空间ID。
os.modelarts/name	String	用户指定的资源池名称。
os.modelarts/resource.id	String	资源池的资源id。
os.modelarts/tenant.domain.id	String	资源池的租户id，记录资源池创建在哪个租户账号下。

参数	参数类型	描述
os.modelarts/ create-from	String	资源池创建来源，比如admin-console，标记来自admin创建，console标记来自ma console。
os.modelarts.pool/ biz	String	资源池商业类型，public是公共池，private个人专属池。

表 10-354 PoolMetaAnnotations

参数	参数类型	描述
os.modelarts/ description	String	资源池的描述信息。
os.modelarts/ billing.mode	String	计费模式。
os.modelarts/ flavor.resource.ids	String	每种规格对应的资源ID。
os.modelarts/ tms.tags	String	创建资源池的时候由用户指定的资源标签。
os.modelarts.pool/ subpools.count	String	资源池包含的逻辑子池的数量。
os.modelarts.pool/ scope.external.dep endency.Train	String	训练外部依赖标识。
os.modelarts.pool/ scope.external.dep endency.Infer	String	推理外部依赖标识。
os.modelarts.pool/ scope.external.dep endency.X-Infer	String	新版推理外部依赖标识。
os.modelarts.pool/ scheduler.queue.st rategy	String	作业调度策略： • FIFO: FIFO调度，默认值，如果队列中的第一个作业因资源配额原因无法被调度，系统将反复尝试它，不会跳过。 • Range: Range调度，如果队列中的第一个作业因资源配额原因无法被调度，则跳过它并依次尝试后续队列的作业。

表 10-355 PoolSpec

参数	参数类型	描述
type	String	资源池类型。可选值如下： • Dedicate：物理资源池，独立的网络，支持网络打通，定制驱动，定制作业类型 • Logical：逻辑资源池。没有独立的网络，不支持网络打通，资源池创建和扩缩容相较物理资源池更快。
scope	Array of strings	启用的作业类型，对于逻辑池不支持指定。可选值如下： • Train：训练作业 • Infer：推理作业 • X-Infer：新版推理作业
resources	Array of PoolResource objects	资源池中的资源规格列表，包括资源规格和相应规格的资源数量。
network	PoolNetwork object	资源池网络参数。物理资源池时必选；逻辑资源池时不可选。
masters	Array of PoolClusterMaster objects	资源池控制节点参数。物理资源池可选，逻辑资源池不可选。
clusterFlavor	String	标准池的集群规格。
driver	PoolDriver object	资源池的驱动信息。

表 10-356 PoolResource

参数	参数类型	描述
flavor	String	资源规格名称，比如： modelarts.vm.gpu.tnt004。
count	Integer	规格保障使用量。
maxCount	Integer	资源规格的弹性使用量，物理池该值和count相同，逻辑池该值大于等于count。
azs	Array of PoolNodeAz objects	资源池中节点的AZ信息。
extendParams	PoolResourceExtendParams object	自定义配置，比如设置节点dockerSize。

表 10-357 PoolResourceExtendParams

参数	参数类型	描述
dockerBaseSize	String	节点的容器镜像空间大小。 - 指定大小：dockerBaseSize的大小范围默认为50-500，单位GiB，但实际上限受到节点的容器数据盘大小约束。 - 不限制：dockerBaseSize="0"，表示不限制容器镜像空间大小。
postInstall	String	安装后执行脚本，输入的值需要经过Base64编码。

表 10-358 PoolNetwork

参数	参数类型	描述
name	String	网络名称，取值来自网络资源详情中metadata.name字段的值。

表 10-359 PoolClusterMaster

参数	参数类型	描述
az	String	控制节点所在AZ。

表 10-360 PoolDriver

参数	参数类型	描述
gpuVersion	String	GPU驱动版本，物理资源池中含有GPU规格时可填，例如："440.33"。
npuVersion	String	NPU驱动版本，物理资源池中含有ascend规格时可填，例如："C78"。
updateStrategy	String	驱动升级策略。可选值如下： - force：强制升级，立即升级节点驱动，可能影响节点上正在运行的作业 - idle：安全升级，待节点上没有作业运行时进行驱动升级

表 10-361 PoolStatus

参数	参数类型	描述
phase	String	资源池集群状态。可选值如下： - Creating：创建中 - Running：运行中 - Abnormal：资源池存在异常节点 - Deleting：删除中 - Error：资源池错误
message	String	资源池处于当前状态的提示信息。
resources	PoolResourceStatus object	资源池中不同状态的资源量。
scope	Array of PoolScopeStatus objects	资源池业务状态信息。
driver	PoolDriverListStatus object	资源池驱动信息。
parent	String	资源池父节点名称，物理池为空。
root	String	资源池根节点名称，物理池为自己的名称。

表 10-362 PoolResourceStatus

参数	参数类型	描述
creating	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
available	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
abnormal	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
deleting	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。

表 10-363 PoolResourceFlavorCount

参数	参数类型	描述
flavor	String	资源规格名称，比如： modelarts.vm.gpu.tnt004。
count	Integer	规格保障使用量。
maxCount	Integer	资源规格的弹性使用量，物理池该值和 count相同，逻辑池该值大于等于 count。
azs	Array of PoolNodeAz objects	资源池中节点的AZ信息。

表 10-364 PoolNodeAz

参数	参数类型	描述
az	String	az名称。
count	Integer	指定az扩容时，指定az的节点数。

表 10-365 PoolScopeStatus

参数	参数类型	描述
scopeType	String	启用的作业类型。可选值如下： • Train：训练作业 • Infer：推理作业 • X-Infer：新版推理作业
state	String	业务状态。可选值如下： • Enabling：启动中 • Enabled：已启动 • EnableFailed：启用失败 • Disabling：关闭中 • Disabled：已关闭
plugins	Array of PoolScopePlugin Phase objects	插件状态信息。
message	String	环境开启、关闭失败原因。

表 10-366 PoolScopePluginPhase

参数	参数类型	描述
name	String	插件类型。
phase	String	插件状态。可选值如下： • Pending：等待中。 • Running：运行中。 • Updating：更新中。 • Abnormal：异常。 • Deleting：删除中。

表 10-367 PoolDriverListStatus

参数	参数类型	描述
gpu	PoolDriverStatus object	GPU驱动信息。
npu	PoolDriverStatus object	NPU驱动信息。

表 10-368 PoolDriverStatus

参数	参数类型	描述
version	String	当前驱动版本。
state	String	当前驱动状态。可选值如下： • Creating：创建中 • Upgrading：升级中 • Running：运行中 • Abnormal：不正常

状态码：404

表 10-369 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

查询资源池详情。

GET https://{endpoint}/v2/{project_id}/pools/{pool_name}

{ }

响应示例

状态码: 200

OK.

```
{
  "kind": "Pool",
  "apiVersion": "v2",
  "metadata": {
    "name": "auto-pool-os-86c13962597848eeb29c5861153a391f",
    "creationTimestamp": "2022-09-16T03:10:40Z",
    "labels": {
      "os.modelarts/name": "auto-pool-os",
      "os.modelarts/resource.id": "maos-auto-pool-os-72w8d"
    },
    "annotations": {
      "os.modelarts/description": "",
      "os.modelarts/billing.mode": "0",
      "os.modelarts/external-access": "elb",
      "os.modelarts.pool/scope.external.dependency.Train": "{\"type\":\"Enabled\",\"status\":\"True\\\",\\\"message\\\":\\\"\\\",\\\"network_access\\\":{\\\"type\\\":\\\"Enabled\\\",\\\"status\\\":\\\"True\\\",\\\"message\\\":\\\"\\\"}}",
    }
  },
  "spec": {
    "type": "Dedicate",
    "scope": [ "Train", "Infer" ],
    "resources": [ {
      "flavor": "modelarts.vm.cpu.4ud",
      "count": 2
    } ],
    "network": {
      "name": "network-maos-86c13962597848eeb29c5861153a391f"
    }
  },
  "status": {
    "phase": "Running",
    "root": "auto-pool-os-86c13962597848eeb29c5861153a391f",
    "scope": [ {
      "scopeType": "Train",
      "state": "Enabled"
    }, {
      "scopeType": "Infer",
      "state": "Enabled"
    } ],
    "resources": {
      "available": [ {
        "flavor": "modelarts.vm.cpu.4ud",
        "count": 2,
        "azs": [ {
          "az": "cn-north-7c",
          "count": 2
        } ]
      } ]
    }
  }
}
```

状态码: 404

Not Found。

```
{
  "error_code" : "ModelArts.50015001",
  "error_msg" : "pool not found"
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.12.4 删除资源池

功能介绍

删除指定的资源池。

URI

DELETE /v2/{project_id}/pools/{pool_name}

表 10-370 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池ID。取值资源池详情的 metadata.name 字段。

请求参数

表 10-371 请求 Header 参数

参数	是否必选	参数类型	描述
request-type	否	String	请求的来源，只有设置 "console" 才会启用订单功能

响应参数

状态码：200

表 10-372 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	资源类型。可选值如下： Pool：资源池
metadata	PoolMetadataDeletion object	资源池的metadata信息。
spec	PoolSpec object	资源池的描述信息。
status	PoolStatus object	资源池的状态信息。

表 10-373 PoolMetadataDeletion

参数	参数类型	描述
name	String	系统自动生成的pool名称，相当于poolId。
creationTimestamp	String	时间戳，"2021-11-01T03:49:41Z"。
deletionTimestamp	String	时间戳，"2021-11-01T03:49:41Z"。
labels	PoolMetaLabels object	资源池的标签信息。
annotations	PoolMetaAnnotations object	资源池的注释信息。

表 10-374 PoolMetaLabels

参数	参数类型	描述
os.modelarts/workspace.id	String	工作空间ID。
os.modelarts/name	String	用户指定的资源池名称。
os.modelarts/resource.id	String	资源池的资源id。

参数	参数类型	描述
os.modelarts/ tenant.domain.id	String	资源池的租户id，记录资源池创建在哪个租户账号下。
os.modelarts/ create-from	String	资源池创建来源，比如admin-console，标记来自admin创建，console标记来自ma console。
os.modelarts.pool/ biz	String	资源池商业类型，public是公共池，private个人专属池。

表 10-375 PoolMetaAnnotations

参数	参数类型	描述
os.modelarts/ description	String	资源池的描述信息。
os.modelarts/ billing.mode	String	计费模式。
os.modelarts/ flavor.resource.ids	String	每种规格对应的资源ID。
os.modelarts/ tms.tags	String	创建资源池的时候由用户指定的资源标签。
os.modelarts.pool/ subpools.count	String	资源池包含的逻辑子池的数量。
os.modelarts.pool/ scope.external.dep endency.Train	String	训练外部依赖标识。
os.modelarts.pool/ scope.external.dep endency.Infer	String	推理外部依赖标识。
os.modelarts.pool/ scope.external.dep endency.X-Infer	String	新版推理外部依赖标识。
os.modelarts.pool/ scheduler.queue.st rategy	String	作业调度策略： • FIFO：FIFO调度，默认值，如果队列中的第一个作业因资源配额原因无法被调度，系统将反复尝试它，不会跳过。 • Range：Range调度，如果队列中的第一个作业因资源配额原因无法被调度，则跳过它并依次尝试后续队列的作业。

表 10-376 PoolSpec

参数	参数类型	描述
type	String	资源池类型。可选值如下： • Dedicate：物理资源池，独立的网络，支持网络打通，定制驱动，定制作业类型 • Logical：逻辑资源池。没有独立的网络，不支持网络打通，资源池创建和扩缩容相较物理资源池更快。
scope	Array of strings	启用的作业类型，对于逻辑池不支持指定。可选值如下： • Train：训练作业 • Infer：推理作业 • X-Infer：新版推理作业
resources	Array of PoolResource objects	资源池中的资源规格列表，包括资源规格和相应规格的资源数量。
network	PoolNetwork object	资源池网络参数。物理资源池时必选；逻辑资源池时不可选。
masters	Array of PoolClusterMaster objects	资源池控制节点参数。物理资源池可选，逻辑资源池不可选。
clusterFlavor	String	标准池的集群规格。
driver	PoolDriver object	资源池的驱动信息。

表 10-377 PoolResource

参数	参数类型	描述
flavor	String	资源规格名称，比如： modelarts.vm.gpu.tnt004。
count	Integer	规格保障使用量。
maxCount	Integer	资源规格的弹性使用量，物理池该值和count相同，逻辑池该值大于等于count。
azs	Array of PoolNodeAz objects	资源池中节点的AZ信息。
extendParams	PoolResourceExtendParams object	自定义配置，比如设置节点dockerSize。

表 10-378 PoolResourceExtendParams

参数	参数类型	描述
dockerBaseSize	String	节点的容器镜像空间大小。 - 指定大小：dockerBaseSize的大小范围默认为50-500，单位GiB，但实际上限受到节点的容器数据盘大小约束。 - 不限制：dockerBaseSize="0"，表示不限制容器镜像空间大小。
postInstall	String	安装后执行脚本，输入的值需要经过Base64编码。

表 10-379 PoolNetwork

参数	参数类型	描述
name	String	网络名称，取值来自网络资源详情中metadata.name字段的值。

表 10-380 PoolClusterMaster

参数	参数类型	描述
az	String	控制节点所在AZ。

表 10-381 PoolDriver

参数	参数类型	描述
gpuVersion	String	GPU驱动版本，物理资源池中含有GPU规格时可填，例如："440.33"。
npuVersion	String	NPU驱动版本，物理资源池中含有ascend规格时可填，例如："C78"。
updateStrategy	String	驱动升级策略。可选值如下： - force：强制升级，立即升级节点驱动，可能影响节点上正在运行的作业 - idle：安全升级，待节点上没有作业运行时进行驱动升级

表 10-382 PoolStatus

参数	参数类型	描述
phase	String	资源池集群状态。可选值如下： - Creating：创建中 - Running：运行中 - Abnormal：资源池存在异常节点 - Deleting：删除中 - Error：资源池错误
message	String	资源池处于当前状态的提示信息。
resources	PoolResourceStatus object	资源池中不同状态的资源量。
scope	Array of PoolScopeStatus objects	资源池业务状态信息。
driver	PoolDriverListStatus object	资源池驱动信息。
parent	String	资源池父节点名称，物理池为空。
root	String	资源池根节点名称，物理池为自己的名称。

表 10-383 PoolResourceStatus

参数	参数类型	描述
creating	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
available	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
abnormal	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
deleting	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。

表 10-384 PoolResourceFlavorCount

参数	参数类型	描述
flavor	String	资源规格名称，比如： modelarts.vm.gpu.tnt004。
count	Integer	规格保障使用量。
maxCount	Integer	资源规格的弹性使用量，物理池该值和 count相同，逻辑池该值大于等于 count。
azs	Array of PoolNodeAz objects	资源池中节点的AZ信息。

表 10-385 PoolNodeAz

参数	参数类型	描述
az	String	az名称。
count	Integer	指定az扩容时，指定az的节点数。

表 10-386 PoolScopeStatus

参数	参数类型	描述
scopeType	String	启用的作业类型。可选值如下： • Train：训练作业 • Infer：推理作业 • X-Infer：新版推理作业
state	String	业务状态。可选值如下： • Enabling：启动中 • Enabled：已启动 • EnableFailed：启用失败 • Disabling：关闭中 • Disabled：已关闭
plugins	Array of PoolScopePlugin Phase objects	插件状态信息。
message	String	环境开启、关闭失败原因。

表 10-387 PoolScopePluginPhase

参数	参数类型	描述
name	String	插件类型。
phase	String	插件状态。可选值如下： • Pending：等待中。 • Running：运行中。 • Updating：更新中。 • Abnormal：异常。 • Deleting：删除中。

表 10-388 PoolDriverListStatus

参数	参数类型	描述
gpu	PoolDriverStatus object	GPU驱动信息。
npu	PoolDriverStatus object	NPU驱动信息。

表 10-389 PoolDriverStatus

参数	参数类型	描述
version	String	当前驱动版本。
state	String	当前驱动状态。可选值如下： • Creating：创建中 • Upgrading：升级中 • Running：运行中 • Abnormal：不正常

状态码：404

表 10-390 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

删除资源池。

```
DELETE https://{endpoint}/v2/{project_id}/pools/{pool_name}
{ }
```

响应示例

状态码：200

OK。

```
{
  "kind": "Pool",
  "apiVersion": "v2",
  "metadata": {
    "name": "auto-pool-os-86c13962597848eeb29c5861153a391f",
    "creationTimestamp": "2022-09-16T03:10:40Z",
    "labels": {
      "os.modelarts/name": "auto-pool-os",
      "os.modelarts/resource.id": "maos-auto-pool-os-72w8d"
    },
    "annotations": {
      "os.modelarts/description": "",
      "os.modelarts/billing.mode": "0",
      "os.modelarts/external-access": "elb"
    }
  },
  "spec": {
    "type": "Dedicate",
    "scope": [ "Train", "Infer" ],
    "resources": [ {
      "flavor": "modelarts.vm.cpu.4ud",
      "count": 2
    } ],
    "network": {
      "name": "network-maos-86c13962597848eeb29c5861153a391f"
    }
  },
  "status": {
    "phase": "Running",
    "root": "auto-pool-os-86c13962597848eeb29c5861153a391f",
    "scope": [ {
      "scopeType": "Train",
      "state": "Enabled"
    }, {
      "scopeType": "Infer",
      "state": "Enabled"
    } ],
    "resources": {
      "available": [ {
        "flavor": "modelarts.vm.cpu.4ud",
        "count": 2,
        "azs": [ {
          "az": "cn-north-7c",
          "count": 2
        } ]
      } ]
    }
  }
}
```

状态码：404

Not Found。

```
{
  "error_code" : "ModelArts.50015001",
  "error_msg" : "pool not found"
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.12.5 更新资源池

功能介绍

更新指定的资源池。

URI

PATCH /v2/{project_id}/pools/{pool_name}

表 10-391 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池ID。取值资源池详情的 metadata.name 字段。

请求参数

表 10-392 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	application/merge-patch+json。
request-type	否	String	请求的来源，hcs环境下只有设置"console"才会启用订单功能，其他环境下没有作用

表 10-393 请求 Body 参数

参数	是否必选	参数类型	描述
metadata	否	PoolMetadataUpdate object	资源池的metadata信息。
spec	否	PoolSpecUpdate object	资源池的描述信息。

表 10-394 PoolMetadataUpdate

参数	是否必选	参数类型	描述
labels	否	PoolLabelsUpdate object	资源池的标签信息。
annotations	否	PoolAnnotationsUpdate object	资源池的注释信息。

表 10-395 PoolLabelsUpdate

参数	是否必选	参数类型	描述
os.modelarts/workspace.id	否	String	目标工作空间ID。修改工作空间ID不能和其他资源池修改操作（比如扩缩容）同时进行。

表 10-396 PoolAnnotationsUpdate

参数	是否必选	参数类型	描述
os.modelarts/description	否	String	资源池描述信息，用于说明资源池用于某种指定场景。不能包含特殊字符!<>=&"'。
os.modelarts/billing.mode	否	String	计费模式。

参数	是否必选	参数类型	描述
os.modelarts.pool/scheduler.queue.strategy	否	String	作业调度策略： • FIFO: FIFO调度，默认值，如果队列中的第一个作业因资源配额原因无法被调度，系统将反复尝试它，不会跳过。 • Range: Range调度，如果队列中的第一个作业因资源配额原因无法被调度，则跳过它并依次尝试后续队列的作业。

表 10-397 PoolSpecUpdate

参数	是否必选	参数类型	描述
scope	否	Array of strings	启用的作业类型，对于逻辑池不支持指定。可选值如下： • Train: 训练作业 • Infer: 推理作业 • X-Infer: 新版推理作业
resources	否	Array of PoolResource objects	资源池资源规格资源量配置数据模型。
driver	否	PoolDriver object	资源池驱动信息，对于逻辑池不支持指定。

表 10-398 PoolResource

参数	是否必选	参数类型	描述
flavor	是	String	资源规格名称，比如：modelarts.vm.gpu.tnt004。
count	是	Integer	规格保障使用量。
maxCount	否	Integer	资源规格的弹性使用量，物理池该值和count相同，逻辑池该值大于等于count。
azs	否	Array of PoolNodeAz objects	资源池中节点的AZ信息。

参数	是否必选	参数类型	描述
extendParams	否	PoolResourceExtendParams object	自定义配置，比如设置节点 dockerSize。

表 10-399 PoolNodeAz

参数	是否必选	参数类型	描述
az	是	String	az名称。
count	是	Integer	指定az扩容时，指定az的节点数。

表 10-400 PoolResourceExtendParams

参数	是否必选	参数类型	描述
dockerBaseSize	否	String	节点的容器镜像空间大小。 - 指定大小：dockerBaseSize的大小范围默认为50-500，单位GiB，但实际上限受到节点的容器数据盘大小约束。 - 不限制：dockerBaseSize="0"，表示不限制容器镜像空间大小。
postInstall	否	String	安装后执行脚本，输入的值需要经过Base64编码。

表 10-401 PoolDriver

参数	是否必选	参数类型	描述
gpuVersion	否	String	GPU驱动版本，物理资源池中 含有GPU规格时可填，例如： "440.33"。
npuVersion	否	String	NPU驱动版本，物理资源池中 含有ascend规格时可填，例如： "C78"。

参数	是否必选	参数类型	描述
updateStrategy	否	String	驱动升级策略。可选值如下： - force：强制升级，立即升级节点驱动，可能影响节点上正在运行的作业 - idle：安全升级，待节点上没有作业运行时进行驱动升级

响应参数

状态码：200

表 10-402 响应 Body 参数

参数	参数类型	描述
apiVersion	String	API版本。可选值如下： v2
kind	String	资源类型。可选值如下： Pool：资源池
metadata	PoolMetadata object	资源池的metadata信息。
spec	PoolSpec object	资源池的期望信息。
status	PoolStatus object	资源池的状态信息。

表 10-403 PoolMetadata

参数	参数类型	描述
name	String	系统自动生成的pool名称，相当于pool ID。
creationTimestamp	String	时间戳，"2021-11-01T03:49:41Z"。
labels	PoolMetaLabels object	资源池的标签信息。
annotations	PoolMetaAnnotations object	资源池的注释信息。

表 10-404 PoolMetaLabels

参数	参数类型	描述
os.modelarts/ workspace.id	String	工作空间ID。
os.modelarts/ name	String	用户指定的资源池名称。
os.modelarts/ resource.id	String	资源池的资源id。
os.modelarts/ tenant.domain.id	String	资源池的租户id，记录资源池创建在哪个租户账号下。
os.modelarts/ create-from	String	资源池创建来源，比如admin-console，标记来自admin创建，console标记来自ma console。
os.modelarts.pool/ biz	String	资源池商业类型，public是公共池，private个人专属池。

表 10-405 PoolMetaAnnotations

参数	参数类型	描述
os.modelarts/ description	String	资源池的描述信息。
os.modelarts/ billing.mode	String	计费模式。
os.modelarts/ flavor.resource.ids	String	每种规格对应的资源ID。
os.modelarts/ tms.tags	String	创建资源池的时候由用户指定的资源标签。
os.modelarts.pool/ subpools.count	String	资源池包含的逻辑子池的数量。
os.modelarts.pool/ scope.external.dep endency.Train	String	训练外部依赖标识。
os.modelarts.pool/ scope.external.dep endency.Infer	String	推理外部依赖标识。
os.modelarts.pool/ scope.external.dep endency.X-Infer	String	新版推理外部依赖标识。

参数	参数类型	描述
os.modelarts.pool/scheduler.queue.strategy	String	作业调度策略： - FIFO: FIFO调度，默认值，如果队列中的第一个作业因资源配额原因无法被调度，系统将反复尝试它，不会跳过。 - Range: Range调度，如果队列中的第一个作业因资源配额原因无法被调度，则跳过它并依次尝试后续队列的作业。

表 10-406 PoolSpec

参数	参数类型	描述
type	String	资源池类型。可选值如下： - Dedicate: 物理资源池，独立的网络，支持网络打通，定制驱动，定制作业类型 - Logical: 逻辑资源池。没有独立的网络，不支持网络打通，资源池创建和扩缩容相较物理资源池更快。
scope	Array of strings	启用的作业类型，对于逻辑池不支持指定。可选值如下： - Train: 训练作业 - Infer: 推理作业 - X-Infer: 新版推理作业
resources	Array of PoolResource objects	资源池中的资源规格列表，包括资源规格和相应规格的资源数量。
network	PoolNetwork object	资源池网络参数。物理资源池时必选；逻辑资源池时不可选。
masters	Array of PoolClusterMaster objects	资源池控制节点参数。物理资源池可选，逻辑资源池不可选。
clusterFlavor	String	标准池的集群规格。
driver	PoolDriver object	资源池的驱动信息。

表 10-407 PoolResource

参数	参数类型	描述
flavor	String	资源规格名称，比如：modelarts.vm.gpu.tnt004。
count	Integer	规格保障使用量。
maxCount	Integer	资源规格的弹性使用量，物理池该值和count相同，逻辑池该值大于等于count。
azs	Array of PoolNodeAz objects	资源池中节点的AZ信息。
extendParams	PoolResourceExtendParams object	自定义配置，比如设置节点dockerSize。

表 10-408 PoolResourceExtendParams

参数	参数类型	描述
dockerBaseSize	String	节点的容器镜像空间大小。 - 指定大小：dockerBaseSize的大小范围默认为50-500，单位GiB，但实际上限受到节点的容器数据盘大小约束。 - 不限制：dockerBaseSize="0"，表示不限制容器镜像空间大小。
postInstall	String	安装后执行脚本，输入的值需要经过Base64编码。

表 10-409 PoolNetwork

参数	参数类型	描述
name	String	网络名称，取值来自网络资源详情中metadata.name字段的值。

表 10-410 PoolClusterMaster

参数	参数类型	描述
az	String	控制节点所在AZ。

表 10-411 PoolDriver

参数	参数类型	描述
gpuVersion	String	GPU驱动版本，物理资源池中含有GPU规格时可填，例如："440.33"。
npuVersion	String	NPU驱动版本，物理资源池中含有ascend规格时可填，例如："C78"。
updateStrategy	String	驱动升级策略。可选值如下： - force：强制升级，立即升级节点驱动，可能影响节点上正在运行的作业 - idle：安全升级，待节点上没有作业运行时进行驱动升级

表 10-412 PoolStatus

参数	参数类型	描述
phase	String	资源池集群状态。可选值如下： - Creating：创建中 - Running：运行中 - Abnormal：资源池存在异常节点 - Deleting：删除中 - Error：资源池错误
message	String	资源池处于当前状态的提示信息。
resources	PoolResourceStatus object	资源池中不同状态的资源量。
scope	Array of PoolScopeStatus objects	资源池业务状态信息。
driver	PoolDriverListStatus object	资源池驱动信息。
parent	String	资源池父节点名称，物理池为空。
root	String	资源池根节点名称，物理池为自己的名称。

表 10-413 PoolResourceStatus

参数	参数类型	描述
creating	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
available	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
abnormal	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。
deleting	Array of PoolResourceFlavorCount objects	资源池资源规格资源量数据模型。

表 10-414 PoolResourceFlavorCount

参数	参数类型	描述
flavor	String	资源规格名称，比如： modelarts.vm.gpu.tnt004。
count	Integer	规格保障使用量。
maxCount	Integer	资源规格的弹性使用量，物理池该值和 count相同，逻辑池该值大于等于 count。
azs	Array of PoolNodeAz objects	资源池中节点的AZ信息。

表 10-415 PoolNodeAz

参数	参数类型	描述
az	String	az名称。
count	Integer	指定az扩容时，指定az的节点数。

表 10-416 PoolScopeStatus

参数	参数类型	描述
scopeType	String	启用的作业类型。可选值如下： • Train：训练作业 • Infer：推理作业 • X-Infer：新版推理作业
state	String	业务状态。可选值如下： • Enabling：启动中 • Enabled：已启动 • EnableFailed：启用失败 • Disabling：关闭中 • Disabled：已关闭
plugins	Array of PoolScopePluginPhase objects	插件状态信息。
message	String	环境开启、关闭失败原因。

表 10-417 PoolScopePluginPhase

参数	参数类型	描述
name	String	插件类型。
phase	String	插件状态。可选值如下： • Pending：等待中。 • Running：运行中。 • Updating：更新中。 • Abnormal：异常。 • Deleting：删除中。

表 10-418 PoolDriverListStatus

参数	参数类型	描述
gpu	PoolDriverStatus object	GPU驱动信息。
npu	PoolDriverStatus object	NPU驱动信息。

表 10-419 PoolDriverStatus

参数	参数类型	描述
version	String	当前驱动版本。
state	String	当前驱动状态。可选值如下： - Creating：创建中 - Upgrading：升级中 - Running：运行中 - Abnormal：不正常

状态码：400

表 10-420 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

状态码：404

表 10-421 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

资源池扩容。

```
PATCH https://{endpoint}/v2/{project_id}/pools/{pool_name}
{
  "spec": {
    "resources": [ {
      "flavor": "modelarts.vm.cpu.4ud",
      "count": 3
    } ]
  }
}
```

响应示例

状态码：200

OK。

```
{
  "kind": "Pool",
  "apiVersion": "v2",
  "metadata": {
    "name": "auto-pool-os-86c13962597848eeb29c5861153a391f",
    "creationTimestamp": "2022-09-16T03:10:40Z",
    "labels": {
      "os.modelarts/name": "auto-pool-os",
      "os.modelarts/resource.id": "maos-auto-pool-os-72w8d"
    },
    "annotations": {
      "os.modelarts/description": "",
      "os.modelarts/billing.mode": "0"
    }
  },
  "spec": {
    "type": "Dedicate",
    "scope": [ "Train", "Infer" ],
    "resources": [ {
      "flavor": "modelarts.vm.cpu.4ud",
      "count": 3
    } ],
    "network": {
      "name": "network-maos-86c13962597848eeb29c5861153a391f"
    },
    "status": {
      "phase": "Running",
      "root": "auto-pool-os-86c13962597848eeb29c5861153a391f",
      "scope": [ {
        "scopeType": "Train",
        "state": "Enabled"
      }, {
        "scopeType": "Infer",
        "state": "Enabled"
      } ],
      "resources": {
        "creating": [ {
          "flavor": "modelarts.vm.cpu.4ud",
          "count": 1,
          "azs": [ {
            "az": "cn-north-7c",
            "count": 1
          } ]
        } ],
        "available": [ {
          "flavor": "modelarts.vm.cpu.4ud",
          "count": 2,
          "azs": [ {
            "az": "cn-north-7c",
            "count": 2
          } ]
        } ]
      }
    }
  }
}
```

状态码：400

Bad request

```
{
  "error_code": "ModelArts.50004000",
  "error_msg": "Bad request"
}
```

状态码：404

Not Found。

```
{
  "error_code" : "ModelArts.50015001",
  "error_msg" : "pool not found"
}
```

状态码

状态码	描述
200	OK。
400	Bad request
404	Not Found。

错误码

请参见[错误码](#)。

10.12.6 资源池监控

功能介绍

获取资源池的监控信息。

URI

GET /v2/{project_id}/pools/{pool_name}/monitor

表 10-422 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
pool_name	是	String	资源池ID。取值资源池详情的metadata.name字段。

表 10-423 Query 参数

参数	是否必选	参数类型	描述
time_range	否	String	查询时间范围，默认值“-1.-1.60”。格式为startTimelnMillis.endTimelnMi llis.durationInMinutes，参数解释： • startTimelnMillis: 查询的开始时间，格式为UTC毫秒，如果指定为-1，服务端将按(endTimelnMillis - durationInMinutes * 60 * 1000)计算开始时间 • endTimelnMillis: 查询的结束时间，格式为UTC毫秒，如果指定为-1，服务端将按(startTimelnMillis + durationInMinutes * 60 * 1000)计算结束时间，如果计算出的结束时间大于当前系统时间，则使用当前系统时间 • durationInMinutes: 查询时间的跨度分钟数。取值范围大于0并且大于等于(endTimelnMillis - startTimelnMillis) / (60 * 1000) - 1 当开始时间与结束时间都设置为-1时，系统会将结束时间设置为当前时间UTC毫秒值，并按(endTimelnMillis - durationInMinutes * 60 * 1000)计算开始时间。 如：-1.-1.60(表示最近60分钟) 约束：单次请求中，查询时长与周期需要满足以下条件： durationInMinutes * 60 / period <= 1440。
statistics	否	String	统计方式。可选值如下： • maximum：最大值统计，默认值 • minimum：最小值统计 • sum：求和统计 • average：平均值统计

参数	是否必选	参数类型	描述
period	否	String	监控数据粒度，单位为秒。可选值如下： 60：粒度为1分钟，默认值 300：粒度为5分钟 900：粒度为15分钟 3600：粒度为1小时

请求参数

无

响应参数

状态码：200

表 10-424 响应 Body 参数

参数	参数类型	描述
metrics	Array of PoolMetricItem objects	指标对象列表。JSON数组大小不超过20。

表 10-425 PoolMetricItem

参数	参数类型	描述
metric	Array of PoolMetricItemValue objects	指标参数集合。
dataPoints	Array of PoolMetricDataPoint objects	重点指标。

表 10-426 PoolMetricItemValue

参数	参数类型	描述
metricName	String	指标名称。可选值如下： - cpuUsage: CPU使用量 - memUsedRate: 内存利用率 - gpuUtil: GPU显卡使用量 - gpuMemUsage: GPU显存使用量 - npuUtil: NPU显卡使用量 - npuMemUsage: NPU显存使用量 - diskCapacity: 磁盘容量 - diskAvailableCapacity: 磁盘可用容量 - diskUsedRate: 磁盘利用率
namespace	String	指标命名空间。可选值如下： - PAAS.CONTAINER: 组件指标、实例指标、进程指标和容器指标的命名空间 - PAAS.NODE: 主机指标、网络指标、磁盘指标和文件系统指标的命名空间 - PAAS.SLA: SLA指标的命名空间 - PAAS.AGGR: 集群指标的命名空间 - CUSTOMMETRICS: 默认的自定义指标的命名空间
dimensions	Array of PoolMetricDimensionItem objects	指标维度列表。

表 10-427 PoolMetricDimensionItem

参数	参数类型	描述
name	String	指标维度名称。
value	String	指标维度取值。

表 10-428 PoolMetricDataPoint

参数	参数类型	描述
timestamp	Integer	时间戳。

参数	参数类型	描述
unit	String	时间序列单位。
statistics	Array of PoolMetricDataPointValue objects	统计值列表。

表 10-429 PoolMetricDataPointValue

参数	参数类型	描述
statistic	String	统计方式。可选值如下： - maximum：最大值统计 - average：平均值统计
value	Float	统计结果。值为-1表示无效数据。

状态码：404

表 10-430 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

查询资源池监控信息。

```
GET https://{endpoint}/v2/{project_id}/pools/{pool_name}/monitor
{ }
```

响应示例

状态码：200

OK。

```
{
  "metrics": [ {
    "metric": {
      "dimensions": [ {
        "name": "clusterId",
        "value": "83df17f1-d74c-11ec-a070-0255ac1000c3"
      } ],
      "metricName": "cpuUsage",
      "namespace": "PAAS.AGGR"
    }
  } ],
}
```

```
"dataPoints": [ {
  "timestamp": 1655193600000,
  "unit": "Percent",
  "statistics": [ {
    "statistic": "average",
    "value": 7.944
  } ]
}, {
  "timestamp": 1655197200000,
  "unit": "Percent",
  "statistics": [ {
    "statistic": "average",
    "value": 7.88
  } ]
} ]
}, {
  "metric": {
    "dimensions": [ {
      "name": "clusterId",
      "value": "83df17f1-d74c-11ec-a070-0255ac1000c3"
    } ],
    "metricName": "memUsedRate",
    "namespace": "PAAS.AGGR"
  },
  "dataPoints": [ {
    "timestamp": 1655193600000,
    "unit": "Percent",
    "statistics": [ {
      "statistic": "average",
      "value": 13.83
    } ]
  }, {
    "timestamp": 1655197200000,
    "unit": "Percent",
    "statistics": [ {
      "statistic": "average",
      "value": 13.836
    } ]
  } ]
}, {
  "metric": {
    "dimensions": [ {
      "name": "clusterId",
      "value": "83df17f1-d74c-11ec-a070-0255ac1000c3"
    } ],
    "metricName": "gpuUtil",
    "namespace": "PAAS.AGGR"
  },
  "dataPoints": [ {
    "timestamp": 1655193600000,
    "unit": "Percent",
    "statistics": [ {
      "statistic": "average",
      "value": -1
    } ]
  }, {
    "timestamp": 1655197200000,
    "unit": "Percent",
    "statistics": [ {
      "statistic": "average",
      "value": -1
    } ]
  } ]
}, {
  "metric": {
    "dimensions": [ {
      "name": "clusterId",
      "value": "83df17f1-d74c-11ec-a070-0255ac1000c3"
    } ],
```



```
    "metricName": "gpuMemUsage",
    "namespace": "PAAS.AGGR"
  },
  "dataPoints": [ {
    "timestamp": 1655193600000,
    "unit": "Percent",
    "statistics": [ {
      "statistic": "average",
      "value": -1
    } ]
  }, {
    "timestamp": 1655197200000,
    "unit": "Percent",
    "statistics": [ {
      "statistic": "average",
      "value": -1
    } ]
  } ],
  {
    "metric": {
      "dimensions": [ {
        "name": "clusterId",
        "value": "83df17f1-d74c-11ec-a070-0255ac1000c3"
      } ],
      "metricName": "npuUtil",
      "namespace": "PAAS.AGGR"
    },
    "dataPoints": [ {
      "timestamp": 1655193600000,
      "unit": "",
      "statistics": [ {
        "statistic": "average",
        "value": -1
      } ]
    }, {
      "timestamp": 1655197200000,
      "unit": "",
      "statistics": [ {
        "statistic": "average",
        "value": -1
      } ]
    } ]
  },
  {
    "metric": {
      "dimensions": [ {
        "name": "clusterId",
        "value": "83df17f1-d74c-11ec-a070-0255ac1000c3"
      } ],
      "metricName": "npuMemUsage",
      "namespace": "PAAS.AGGR"
    },
    "dataPoints": [ {
      "timestamp": 1655193600000,
      "unit": "",
      "statistics": [ {
        "statistic": "average",
        "value": -1
      } ]
    }, {
      "timestamp": 1655197200000,
      "unit": "",
      "statistics": [ {
        "statistic": "average",
        "value": -1
      } ]
    } ]
  },
  {
    "metric": {
      "dimensions": [ {
```

```
    "name": "clusterId",
    "value": "83df17f1-d74c-11ec-a070-0255ac1000c3"
  }],
  "metricName": "diskAvailableCapacity",
  "namespace": "PAAS.AGGR"
},
"dataPoints": [ {
  "timestamp": 1655193600000,
  "unit": "Megabytes",
  "statistics": [ {
    "statistic": "average",
    "value": 834383.4
  } ]
}, {
  "timestamp": 1655197200000,
  "unit": "Megabytes",
  "statistics": [ {
    "statistic": "average",
    "value": 834379.2
  } ]
} ]
}, {
  "metric": {
    "dimensions": [ {
      "name": "clusterId",
      "value": "83df17f1-d74c-11ec-a070-0255ac1000c3"
    } ],
    "metricName": "diskCapacity",
    "namespace": "PAAS.AGGR"
  },
  "dataPoints": [ {
    "timestamp": 1655193600000,
    "unit": "Megabytes",
    "statistics": [ {
      "statistic": "average",
      "value": 1105920
    } ]
  }, {
    "timestamp": 1655197200000,
    "unit": "Megabytes",
    "statistics": [ {
      "statistic": "average",
      "value": 1105920
    } ]
  } ]
}, {
  "metric": {
    "dimensions": [ {
      "name": "clusterId",
      "value": "83df17f1-d74c-11ec-a070-0255ac1000c3"
    } ],
    "metricName": "diskUsedRate",
    "namespace": "PAAS.AGGR"
  },
  "dataPoints": [ {
    "timestamp": 1655193600000,
    "unit": "Percent",
    "statistics": [ {
      "statistic": "average",
      "value": 24.553
    } ]
  }, {
    "timestamp": 1655197200000,
    "unit": "Percent",
    "statistics": [ {
      "statistic": "average",
      "value": 24.553
    } ]
  } ]
} ]
```

```
  }  
}
```

状态码：404

Not Found。

```
{  
  "error_code" : "ModelArts.50015001",  
  "error_msg" : "pool not found"  
}
```

状态码

状态码	描述
200	OK。
404	Not Found。

错误码

请参见[错误码](#)。

10.12.7 资源池统计

功能介绍

获取资源池的统计信息。

URI

GET /v2/{project_id}/statistics/pools

表 10-431 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

表 10-432 Query 参数

参数	是否必选	参数类型	描述
workspaceId	否	String	工作空间ID，默认值为0。

请求参数

无

响应参数

状态码：200

表 10-433 响应 Body 参数

参数	参数类型	描述
statistics	PoolStatisticsItem object	资源池统计信息。
operationTime	String	统计的时间。

表 10-434 PoolStatisticsItem

参数	参数类型	描述
status	PoolStatisticsStatus object	不同状态下的资源池统计信息。

表 10-435 PoolStatisticsStatus

参数	参数类型	描述
creating	Integer	正在创建中的资源池数量。
created	Integer	创建成功的资源池数量。
failed	Integer	最近三天内创建失败的资源池数量，最大值为500。
pending	Integer	等待中的资源池数量，通常是未支付的包周期资源池。

状态码：500

表 10-436 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

查询资源池统计信息。

```
GET https://{endpoint}/v2/{project_id}/statistics/pools
```

响应示例

状态码：200

OK。

```
{
  "statistics": {
    "status": {
      "created": 3,
      "creating": 0,
      "failed": 1,
      "pending": 0
    }
  },
  "operationTime": "2022-12-05 11:15:59.329633162 +0000 UTC"
}
```

状态码：500

Internal error

```
{
  "error_code": "ModelArts.50005000",
  "error_msg": "internal error"
}
```

状态码

状态码	描述
200	OK。
500	Internal error

错误码

请参见[错误码](#)。

10.12.8 重试启用失败的作业类型

功能介绍

重试启用失败的作业类型。

URI

POST /v2/{project_id}/pools/{pool_name}/retry-scope

表 10-437 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

参数	是否必选	参数类型	描述
pool_name	是	String	资源池ID。取值资源池详情的metadata.name字段。

请求参数

表 10-438 请求 Body 参数

参数	是否必选	参数类型	描述
scope	是	String	需要重试开启的作业类型。

响应参数

状态码：200

OK。

状态码：400

表 10-439 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述信息。

请求示例

重试Infer。

```
/v2/{project_id}/pools/{pool_name}/retry-scope
{
  "scope": "Infer"
}
```

响应示例

状态码：200

OK。

```
{}
```

状态码：400

Bad request。

```
{
  "error_code": "ModelArts.50004000",
```

```
"error_msg": "Bad request. The pool pool-dly-op-0c2098ebae80d3e22f31c011e23a97cd scope Train cannot be enabled."
}
```

状态码

状态码	描述
200	OK。
400	Bad request。

错误码

请参见[错误码](#)。

10.13 资源指标

10.13.1 查询资源实时利用率

功能介绍

查询当前项目下所有资源池的实时利用率。

URI

GET /v2/{project_id}/metrics/runtime/pools

表 10-440 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。

请求参数

无

响应参数

状态码：200

表 10-441 响应 Body 参数

参数	参数类型	描述
apiVersion	String	资源版本。可选值如下： v2
kind	String	资源类型。可选值如下： PoolMetricsList
items	Array of MetricItem objects	指标列表。

表 10-442 MetricItem

参数	参数类型	描述
table	MetricTableItem object	资源列表。
metadata	ResourceMetrics Metadata object	资源指标的元信息。

表 10-443 MetricTableItem

参数	参数类型	描述
allocated	Allocated object	已分配的资源信息。
capacity	Capacity object	资源的容量信息。

表 10-444 Allocated

参数	参数类型	描述
value	Value object	资源量
timestamp	String	UTC时间，格式yyyy-MM-dd'T'HH:mm:ss'Z'
window	String	统计间隔，1s表示1秒，1m表示一分钟，1h为一小时

表 10-445 Capacity

参数	参数类型	描述
value	Value object	资源量。
maxValue	Value object	最大弹性资源量。
timestamp	String	UTC时间，格式yyyy-MM-dd'T'HH:mm:ss'Z'。
window	String	统计间隔，1s表示1秒，1m表示一分钟，1h为一小时。

表 10-446 Value

参数	参数类型	描述
cpu	String	cpu量
memory	String	内存
tnt004	String	AI资源数量

表 10-447 ResourceMetricsMetadata

参数	参数类型	描述
name	String	资源指标的名称。
labels	Object	资源指标的标签信息。

请求示例

查询资源池资源实时利用率。

GET https://{endpoint}/v2/{project_id}/metrics/runtime/pools

响应示例

状态码：200

OK。

```
{
  "apiVersion": "v2",
  "kind": "PoolMetricsList",
  "items": [ {
    "table": {
      "allocated": {
        "value": {
          "cpu": 5,
          "memory": "15548Mi",
          "tnt004": "1073m"
        }
      }
    }
  }
]
```

```
    },
    "timestamp": "2022-03-30T07:09:10Z",
    "window": "1m"
  },
  "capacity": {
    "value": {
      "cpu": 16,
      "memory": "64Gi",
      "tnt004": 2
    },
    "maxValue": {
      "cpu": 16,
      "memory": "64Gi",
      "tnt004": 2
    },
    "timestamp": "2022-03-30T07:09:10Z",
    "window": "1m"
  }
},
"metadata": {
  "name": "hougang-rse-pool"
}
}]
}
```

状态码

状态码	描述
200	OK。

错误码

请参见[错误码](#)。

11 边缘资源池

11.1 边缘池管理

11.1.1 创建边缘池

功能介绍

该接口用于创建边缘池。

URI

POST /v1/{project_id}/edge-pools

表 11-1 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID。

请求参数

表 11-2 请求 Body 参数

参数	是否必选	参数类型	描述
name	是	String	边缘池名称。只能以小写字母开头，由小写字母、数字、中划线（-）组成，不能以中划线结尾。

参数	是否必选	参数类型	描述
description	否	String	边缘池描述。 最小长度：0 最大长度：255
ief_service_instance_id	否	String	IEF的铂金版实例ID。
nodes	是	Array of objects	边缘节点列表。
max_nodes	否	Integer	ModelArts Edge边缘资源池必填，指定的最大工作节点数量。
controller_ids	否	Array of String	ModelArts Edge边缘资源池时必填，指定的Master节点列表。
edge_type	否	String	ModelArts Edge边缘资源池时必填modelarts。
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间。
tags	否	Set<TmsTag>	边缘资源池标签。
ownership	否	String	共享池标识，值为share表示创建共享池。
share_project_infos	否	Array of 表 11-4	共享池的可见资源空间。

表 11-3 TmsTag

参数	是否必选	参数类型	描述
key	是	String	标签的key。 最小长度：1 最大长度：128 正则表达式： <code>^((?!s)(?!_sys_)[\p{L}\p{Z}\p{N}_:=+~\-\@]*)(<?!s)\$</code>
value	是	String	标签的value。 最小长度：0 最大长度：255 正则表达式： <code>^([\p{L}\p{Z}\p{N}_:=+~\-\@]*)\$</code>

表 11-4 edge_pool_project_info

参数	是否必选	参数类型	描述
domain_id	是	String	主账号id，获取方式请参考 获取租户名和租户ID 。
project_ids	是	Array of String	资源空间id列表。 最小长度：1 最大长度：100 正则表达式：^[a-zA-Z0-9-]{1,64}\$

响应参数

状态码： 201

表 11-5 响应 Body 参数

参数	参数类型	描述
id	String	创建出的边缘池ID。

状态码： 400

表 11-6 响应 Body 参数

参数	参数类型	描述
error_code	String	边缘池内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

请求示例

无

响应示例

状态码： 201

创建边缘池成功。

```
[ {  
  "id" : "53e4xxxxxxxxxxxxxxxxxxxxb55b3e"  
}]
```

状态码： 400

请求不合法。

```
{
  "error_code" : "ModelArts.0101",
  "error_msg" : "The length of the field [name] should be in range [4,32]."
```

状态码

状态码	描述
201	创建边缘池成功。
400	请求不合法。

错误码

请参见[错误码](#)。

11.1.2 获取边缘池列表

功能介绍

该接口用于获取边缘池列表。

URI

GET /v1/{project_id}/edge-pools

表 11-7 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。 获取方法请参见获取资源空间ID。

表 11-8 Query 参数

参数	是否必选	参数类型	描述
name_like	否	String	目标边缘池的名称，支持模糊匹配。

参数	是否必选	参数类型	描述
sort_dir	否	String	展示边缘池列表时的排序规则，分别为ASC（升序），DESC（降序） 缺省值：DESC 枚举值： • ASC • DESC
sort_key	否	String	展示边缘池列表时的排序字段，分别为created_at（按创建时间排序），updated_at（按更新时间排序）。 缺省值：created_at 枚举值： • created_at • updated_at
edge_type	否	String	边缘池类型，缺省为ief。 枚举值： • modelarts • ief
offset	否	Integer	首个展示的边缘池的偏移量。 最小值：0 最大值：2147483647 缺省值：0
limit	否	Integer	展示边缘池的数量。 最小值：1 最大值：1000 缺省值：100
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间。
tags	否	String	边缘资源池标签。
ownership	否	String	共享池标识，值为share表示查询共享池。

请求参数

无

响应参数

状态码： 200

表 11-9 响应 Body 参数

参数	参数类型	描述
count	Long	符合检索条件的总条目数。
edge_pools	Array of EdgePoolResponse objects	检索到的服务作业条目。

表 11-10 EdgePoolResponse

参数	参数类型	描述
id	String	边缘池ID。
name	String	边缘池名称。
state	String	边缘池状态。 枚举值： - Running - Abnormal
project_id	String	边缘池创建者的资源空间ID。
description	String	边缘资源池描述信息。
ief_service_instance_id	String	IEF的铂金版实例ID。
ief_node_group_id	String	IEF的节点组ID。
edge_type	String	边缘类型。
max_nodes	Int	最大节点数。
created_at	Long	边缘池的创建时间。
updated_at	Long	边缘池的更新时间。
node_resources	Array of 表 11-11 objects	节点资源信息。
cluster_resource	表11-15	资源池资源信息汇总
realtime_cluster_resources_free	表11-14	实时边缘池资源剩余信息。

参数	参数类型	描述
realtime_node_resources_free	Array of 表 11-14 objects	实时边缘池每个节点资源剩余信息。
ownership	String	共享池标识，值为share表示共享池。

表 11-11 NodeResource

参数	参数类型	描述
node_id	String	节点ID。
node_name	String	节点名称。
status	String	状态。
virtual_info	表11-17	虚拟化类型和参数
resources	Array of 表 11-12 objects	资源总量。
availableResources	Array of 表6 Resource objects	资源可用量。

表 11-12 Resource

参数	参数类型	描述	单位
cpu	BigDecimal	CPU数量。	cpu物理核数
npu_num	BigDecimal	NPU数量。	NPU数量
gpu_num	BigDecimal	GPU数量。	gpu个数
memory	BigDecimal	内存。	内存大小 单位:KB

状态码： 400

表 11-13 响应 Body 参数

参数	参数类型	描述
error_code	String	边缘池内部错误码。

参数	参数类型	描述
error_msg	String	错误信息。 最小长度：0 最大长度：4096

表 11-14 edge_pool_resources_free

参数	参数类型	描述	单位
cpu_free_core	double	剩余CPU。	百分比 (Percent)
memory_free	double	剩余内存容量。	百分比 (Percent)
disk_free	double	剩余磁盘容量。	兆字节 (Megabytes)
gpu_free	double	剩余GPU。	百分比 (Percent)
gpu_mem_free	double	剩余GPU存储容量。	百分比 (Percent)
npu_core_free	double	剩余NPU。	百分比 (Percent)
npu_memory_free	double	剩余NPU存储容量。	兆字节 (Megabytes)
cpu_total_core	double	CPU总量。	核 (Core)
cpu_used_core	double	使用CPU总量。	核 (Core)
memory_total_megabytes	double	内存总量。	兆字节 (Megabytes)
memory_used_megabytes	double	使用内存总量。	兆字节 (Megabytes)

参数	参数类型	描述	单位
disk_total	double	磁盘总量。	兆字节 (Megabytes)
disk_used	double	使用磁盘总量。	兆字节 (Megabytes)
gpu_util	double	GPU使用率。	百分比 (Percent)
gpu_mem_total_megabytes	double	GPU显存容量。	兆字节 (Megabytes)
gpu_mem_used_megabytes	double	GPU显存使用量。	兆字节 (Megabytes)
npu_ai_core_util	double	CORE利用率。	百分比 (Percent)
npu_memory_used_megabyte	double	NPU显存使用量。	兆字节 (Megabytes)
npu_memory_total_megabytes	double	NPU显存容量。	兆字节 (Megabytes)
project_id	String	项目ID	-
cluster_id	String	资源池ID	-
node_id	String	节点ID, 仅 realtime_node_resources_free包含, realtime_cluster_resources_free没有	-

表 11-15 ClusterResource

参数	参数类型	描述
resources	表11-16	资源总量。
availableResources	表11-16	资源可用量。

表 11-16 Resource

参数	参数类型	描述	单位
cpu	BigDecimal	CPU数量。	cpu物理核数
npu_num	BigDecimal	NPU数量。	NPU数量
gpu_num	BigDecimal	GPU数量。	gpu个数
memory	BigDecimal	内存。	内存大小 单位:KB

表 11-17 virtual_info

参数	参数类型	描述
type	String	虚拟化类型。目前仅支持算力共享（share）。 枚举值： share
share_dev_cnt	Integer	单颗芯片虚拟化出来的共享设备个数。当值为0或1时，表示没有开启算力共享。

请求示例

无

响应示例

状态码： 200

获取边缘池列表成功。

```
{
  "count": 1,
  "edge_pools": [ {
    "id": "53e4xxxxxxxxxxxxxxxxxb55b3e",
    "name": "edge_pool-test",
    "project_id": "b722xxxxxxxxxxxxxxxxxb4674",
    "state": "Running",
    "iefServiceInstanceId": "88bbxxx-xxx-xxx-xxxxxxxbcfe",
    "iefNodeGroupId": "2945cxxx-xxx-xxx-xxx-xxxxxxxbcfe",
    "created_at": 1643076677766,
    "updated_at": 1643076677766,
    "workspaceId": "0"
  } ]
}
```

状态码： 400

请求不合法

```
{
  "error_code": "ModelArts.0101",
  "error_msg": "The param [name_like] should match ^[a-z0-9-]{1,30}$."
}
```

状态码

状态码	描述
200	获取边缘池列表成功。
400	请求不合法

错误码

请参见[错误码](#)。

11.1.3 查询边缘池

功能介绍

该接口用于查询边缘池详情。

URI

GET /v1/{project_id}/edge-pools/{edge_pool_id}

表 11-18 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID。
edge_pool_id	是	String	边缘池ID。

请求参数

表 11-19 查询参数

参数	是否必选	参数类型	描述
edge_type	否	String	边缘池类型，缺省为ief。 枚举值： - modelarts - ief
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间。

响应参数

状态码： 200

表 11-20 响应 Body 参数

参数	参数类型	描述
id	String	边缘池ID。
name	String	边缘池名称。
state	String	边缘池状态。 枚举值： - Running - Abnormal
project_id	String	边缘池创建者的资源空间ID。
description	String	边缘资源池描述信息。
ief_service_instance_id	String	IEF的铂金版实例ID。
ief_node_group_id	String	IEF的节点组ID。
edge_type	String	边缘类型。
max_nodes	Int	最大节点数。
created_at	Long	边缘池的创建时间。
updated_at	Long	边缘池的更新时间。
nodes	Array of EdgeNodeResponse objects	边缘节点列表。
tags	Set< TmsTag >	边缘资源池标签。
node_resources	Array of 表 11-25	节点资源信息。
cluster_resource	表11-29	资源池资源信息汇总
realtime_cluster_resources_free	表11-28	边缘池资源剩余信息。
realtime_node_resources_free	Array of 表 11-28 objects	边缘池所有节点资源剩余信息。
ownership	String	共享池标识，值为share表示共享池。
share_project_infos	Array of 表 11-31	共享池的可见资源空间。

表 11-21 EdgeNodeResponse

参数	参数类型	描述
id	String	边缘节点ID。
name	String	边缘节点名称。
state	String	节点状态。
arch	String	边缘节点架构。
cpu	Float	边缘节点CPU核心数。
memory	Long	边缘节点内存。
gpu_info	Array of EdgeGpuInfo objects	GPU信息。
gpu_num	Integer	边缘节点GPU个数。
enable_gpu	Boolean	是否启用GPU。
npu_info	Array of EdgeNpuInfo objects	NPU信息。
npu_num	Integer	边缘节点NPU个数。
enable_npu	Boolean	是否启用NPU。
virtual_info	EdgeVirtualInfo	虚拟化信息。
firmware_version	String	固件版本。
ief_node_version	String	IEF节点版本。
node_resources	Array of 表11-25 objects	节点资源信息。

表 11-22 EdgeGpuInfo

参数	参数类型	描述
capacity	String	容量信息。
driver_version	String	驱动版本。
name	String	名称。
type	String	类型。

表 11-23 EdgeNpuInfo

参数	参数类型	描述。
capacity	String	容量信息。
driver_version	String	驱动版本。
name	String	名称。
type	String	类型。

表 11-24 EdgeVirtualInfo

参数	参数类型	描述。
type	String	虚拟化类型。share-NPU算力共享，none-关闭。 枚举值： • none • share
share_dev_cnt	Integer	单颗芯片虚拟化出来的共享设备个数。当值为0或1时，表示没有开启算力共享。

表 11-25 NodeResource

参数	参数类型	描述
node_id	String	节点ID。
node_name	String	节点名称。
status	String	状态。
virtual_info	表11-24	虚拟化类型和参数
resources	表11-26	资源总量。
availableResources	表11-26	资源可用量。

表 11-26 Resource

参数	参数类型	描述
cpu	BigDecimal	CPU数量。单位：CPU物理核数
npu_num	BigDecimal	NPU数量。
gpu_num	BigDecimal	GPU数量。

参数	参数类型	描述
memory	BigDecimal	内存大小，单位KB。

表 11-27 TmsTag 结构

参数	参数类型	说明
key	string	标签key。
value	string	标签value。

表 11-28 realtime_cluster_resources_free

参数	参数类型	描述
cpu_free_core	double	剩余CPU。
memory_free	double	剩余内存容量。
disk_free	double	剩余磁盘容量。
gpu_free	double	剩余GPU。
gpu_mem_free	double	剩余GPU存储容量。
npu_core_free	double	剩余NPU。
npu_memory_free	double	剩余NPU存储容量。
cpu_total_core	double	CPU总量。
cpu_used_core	double	使用CPU总量。
memory_total_megabytes	double	内存总量。
memory_used_megabytes	double	使用内存总量。
disk_total	double	磁盘总量。
disk_used	double	使用磁盘总量。
gpu_util	double	GPU使用率。
gpu_mem_total_megabytes	double	GPU显存容量。

参数	参数类型	描述
gpu_mem_used_megabytes	double	GPU显存使用量。
npu_ai_core_util	double	CORE利用率。
npu_memory_used_megabyte	double	NPU显存使用量。
npu_memory_total_megabytes	double	NPU显存容量。
project_id	String	项目ID
cluster_id	String	资源池ID
node_id	String	节点ID 仅realtime_node_resources_free包含，realtime_cluster_resources_free没有

表 11-29 ClusterResource

参数	参数类型	描述
resources	表11-30	资源总量。
availableResources	表11-30	资源可用量。

表 11-30 Resource

参数	参数类型	描述	单位
cpu	BigDecimal	CPU数量。	cpu物理核数
npu_num	BigDecimal	NPU数量。	NPU数量
gpu_num	BigDecimal	GPU数量。	gpu个数
memory	BigDecimal	内存。	内存大小 单位:KB

表 11-31 edge_pool_project_info

参数	参数类型	描述
domain_id	String	主账号id，获取方式请参考 获取租户名和租户ID 。

参数	参数类型	描述
project_ids	Array of String	资源空间id列表。 最小长度：1 最大长度：100 正则表达式：^[a-zA-Z0-9-]{1,64}\$

状态码： 400

表 11-32 响应 Body 参数

参数	参数类型	描述
error_code	String	边缘池内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

状态码： 404

表 11-33 响应 Body 参数

参数	参数类型	描述
error_code	String	边缘池内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

请求示例

无

响应示例

状态码： 200

获取边缘池信息成功。

```
{
  "id": "53e4xxxxxxxxxxxxxxxxxxxxb55b3e",
  "name": "edge-pool",
  "project_id": "b722xxxxxxxxxxxxxxxxxxxxeb4674",
  "ief_service_instance_id": "88bbxxxx-xxxx-xxxx-xxxx-xxxxxxxxbcfe",
  "ief_node_group_id": "aassxxxx-xxxx-xxxx-xxxx-xxxxxxxxbcfe",
  "created_at": 1643076638573,
```

```
"updated_at": 1643076638573,
"state": "RUNNING",
"nodes": {
  "name": "edgenode1",
  "id": "dd8xxxxx-xxxx-xxxx-xxxx-xxxxxx2f5bcb"
},
"tags": [ {
  "key": "k1",
  "values": [ "v1" ]
}]
}
```

状态码： 400

请求不合法。

```
{
  "error_code": "ModelArts.0101",
  "error_msg": "Parameter [project_id] does not match ^[a-zA-Z0-9-]{1,64}$."
}
```

状态码： 404

指定的边缘池不存在。

```
{
  "error_code": "ModelArts.0101",
  "error_msg": "Edge resource pool ID xxx not found."
}
```

状态码

状态码	描述
200	获取边缘池信息成功。
400	请求不合法。
404	指定的边缘池不存在。

错误码

请参见[错误码](#)。

11.1.4 修改边缘资源池

功能介绍

更新边缘资源池。

URI

PUT /v1/{project_id}/edge-pools/{edge_pool_id}

表 11-34 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID 。
edge_pool_id	是	String	指定的边缘池ID。

请求参数

表 11-35 请求 Body 参数

参数	是否必选	参数类型	描述
name	是	String	边缘池名称。只能以小写字母开头，由小写字母、数字、中划线（-）组成，不能以中划线结尾。
description	否	String	边缘池描述。
ief_service_instance_id	是	String	IEF的铂金版实例ID。边缘池edge_type类型为ief时必填。
nodes	是	Array of objects	边缘节点列表。
max_nodes	否	Integer	最大工作节点数，有效范围为1到64，边缘池edge_type类型为modelarts时不支持修改。
controller_ids	否	Array of String	控制节点id列表，边缘池edge_type类型为modelarts时不支持修改。
edge_type	否	String	边缘池类型，ief或者modelarts，默认为ief。
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间。
share_project_infos	否	Array of 表 11-36	共享池的可见资源空间。

表 11-36 edge_pool_project_info

参数	是否必选	参数类型	描述
domain_id	是	String	主账号id，获取方式请参考 获取租户名和租户ID 。

参数	是否必选	参数类型	描述
project_ids	是	Array of String	资源空间id列表。 最小长度：1 最大长度：100 正则表达式：^[a-zA-Z0-9-]{1,64}\$

响应参数

状态码： 200

表 11-37 响应 Body 参数

参数	参数类型	描述
id	String	边缘池ID。
name	String	边缘池名称。
state	String	边缘池状态。 枚举值： - Running - Abnormal
project_id	String	边缘池创建者的资源空间ID。
ief_service_instance_id	String	IEF的铂金版实例ID。
ief_node_group_id	String	IEF的节点组ID。
created_at	Long	边缘池的创建时间。
updated_at	Long	边缘池的更新时间。
nodes	Array of EdgeNodeResponse objects	边缘节点列表。

表 11-38 EdgeNodeResponse

参数	参数类型	描述
id	String	边缘池ID。
name	String	边缘池名称。

状态码： 400

表 11-39 响应 Body 参数

参数	参数类型	描述
error_code	String	边缘池错误码。
error_msg	String	错误信息。

请求示例

修改边缘池成功。

```
{
  "name": "edge-pool",
  "description": "hello world!",
  "ief_service_instance_id": "b771c25e-9245-xxxx-bbd8-1xxxxxdf90f",
  "nodes": [
    "e7e67c6f-0c89-496e-9dfd-08bb2859738f",
    "e7e67c6f-0c89-496e-9dfd-08bb2859738e"
  ],
  "edge_type": "string",
  "max_nodes": 3,
  "controller_ids": [
    "xxx"
  ],
  "workspace_id": "0"
}
```

响应示例

状态码： 200

修改边缘池成功。

```
{
  "id": "53e4xxxxxxxxxxxxxxxxxxxxb55b3e",
  "name": "edge-pool",
  "project_id": "b722xxxxxxxxxxxxxxxxxxeb4674",
  "ief_service_instance_id": "88bbxxxx-xxxx-xxxx-xxxx-xxxxxxxxbcfe",
  "ief_node_group_id": "aassxxxx-xxxx-xxxx-xxxx-xxxxxxxxbcfe",
  "created_at": 1643076638573,
  "updated_at": 1643076638573,
  "state": "RUNNING",
  "nodes": [
    {
      "id": "dd8xxxxx-xxxx-xxxx-xxxx-xxxxxx2f5bcb",
      "name": "edge-test",
      "state": "Running",
      "arch": "x86_64",
      "cpu": "4.0RmxvYXRFbmRaZXJv",
      "memory": "15869.0RmxvYXRFbmRaZXJv",
      "gpu_info": [],
      "enable_gpu": false,
      "npu_info": [],
      "npu_num": 0,
      "enable_npu": false,
      "ief_node_version": "2.52.1"
    }
  ]
}
```

状态码： 400

请求不合法。

```
{
  "error_code": "ModelArts.0101",
  "error_msg": "Invalid argument, Node 0b000809-0c90-4e49-8fda-acf4b666d80a is in FAIL state but not in RUNNING state."
}
```

状态码

状态码	描述
201	修改边缘池成功。
400	请求不合法。

错误码

请参见[错误码](#)。

11.1.5 删除边缘池

功能介绍

该接口用于删除边缘池。

URI

DELETE /v1/{project_id}/edge-pools/{edge_pool_id}

表 11-40 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID。
edge_pool_id	是	String	指定的边缘池ID。

请求参数

表 11-41 请求参数

参数	是否必选	参数类型	描述
edge_type	否	String	边缘池类型，缺省为ief。 枚举值： - modelarts - ief

参数	是否必选	参数类型	描述
force_delete	否	boolean	是否强制删除边缘资源池，只针对ModelArts Edge边缘池。
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

响应参数

状态码： 400

表 11-42 响应 Body 参数

参数	参数类型	描述
error_code	String	边缘池内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

状态码： 404

表 11-43 响应 Body 参数

参数	参数类型	描述
error_code	String	边缘池内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

请求示例

无

响应示例

状态码： 400

请求不合法。

```
{
  "error_code" : "ModelArts.0101",
  "error_msg" : "Invalid argument, Parameter [edge_pool_id] is invalid, does not match Uuid pattern."
}
```

状态码： 404

指定的边缘池不存在。

```
{
  "error_code" : "ModelArts.0101",
  "error_msg" : "Invalid argument, Edge resource pool ID: 2451f51f7fxxxxc48a086xxx26f7422 not found."
}
```

状态码

状态码	描述
204	删除边缘池成功。
400	请求不合法。
404	指定的边缘池不存在。

错误码

请参见[错误码](#)。

11.1.6 删除边缘池节点

功能介绍

该接口用于删除边缘池节点。

URI

DELETE /v1/{project_id}/edge-pools/{edge_pool_id}/nodes/{node_id}

表 11-44 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID。
edge_pool_id	是	String	指定的边缘池ID。
node_id	是	String	指定的边缘节点ID。

请求参数

表 11-45 查询参数

参数	是否必选	参数类型	描述
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

响应参数

状态码： 400

表 11-46 响应 Body 参数

参数	参数类型	描述
error_code	String	边缘池内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

状态码： 404

表 11-47 响应 Body 参数

参数	参数类型	描述
error_code	String	边缘池内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

请求示例

无

响应示例

状态码： 400

请求不合法。

```
{
  "error_code": "ModelArts.0101",
  "error_msg": "Invalid argument, Parameter [edge_pool_id] is invalid, does not match Uuid pattern."
}
```

状态码： 404

指定的边缘池节点不存在。

```
{
  "error_code" : "ModelArts.0101",
  "error_msg" : "Invalid argument, Edge resource pool ID: 2451f51f7fxxxxc48a086xxx26f7422 not found."
}
```

状态码

状态码	描述
202	删除边缘池节点成功。
400	请求不合法。
404	指定的边缘池不存在。

错误码

请参见[错误码](#)。

11.1.7 添加边缘池节点

功能介绍

该接口用于添加边缘池节点。

URI

POST /v1/{project_id}/edge-pools/{edge_pool_id}/nodes

表 11-48 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID。
edge_pool_id	是	String	指定的边缘池ID。

请求参数

表 11-49 查询参数

参数	是否必选	参数类型	描述
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

表 11-50 请求 Body 参数

参数	是否必选	参数类型	描述
nodes	是	Array of objects	边缘节点列表。

响应参数

状态码： 400

表 11-51 响应 Body 参数

参数	参数类型	描述
error_code	String	边缘池内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

状态码： 404

表 11-52 响应 Body 参数

参数	参数类型	描述
error_code	String	边缘池内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

请求示例

无

响应示例

状态码： 400

请求不合法。

```
{
  "error_code" : "ModelArts.0101",
  "error_msg" : "Invalid argument, Parameter [edge_pool_id] is invalid, does not match Uuid pattern."
}
```

状态码： 404

指定的边缘池节点不存在。

```
{
  "error_code" : "ModelArts.0101",
  "error_msg" : "Invalid argument, Edge resource pool ID: 2451f51f7fxxxxc48a086xxx26f7422 not found."
}
```

状态码

状态码	描述
200	添加边缘池节点成功。
400	请求不合法。
404	指定的边缘池不存在。

错误码

请参见[错误码](#)。

11.1.8 添加边缘资源池标签

功能介绍

给指定边缘资源池添加标签，当添加的标签key已存在，则覆盖该标签的value。

URI

POST /v1/{project_id}/edge-pools/{resource_id}/tags/create

表 11-53 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。
resource_id	是	String	资源ID，也就是边缘资源池ID。

请求参数

表 11-54 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	该字段内容填为 “application/json;charset=utf8”。
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 11-55 请求 Body 参数

参数	是否必选	参数类型	描述
tags	是	Array of TmsTag objects	标签列表。

表 11-56 TmsTag

参数	是否必选	参数类型	描述
key	是	String	标签的key。 最小长度：1 最大长度：128 正则表达式： <code>^(?!\\s)(?!_sys_) [\\p{L}\\p{Z}\\p{N}_:=+\\-@]*</code> (? <\\s)\$
value	是	String	标签的value。 最小长度：0 最大长度：255 正则表达式： <code>^([\\p{L}\\p{Z} \\p{N}_:=+\\-@]*)\$</code>

响应参数

状态码： 400

表 11-57 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 401

表 11-58 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 403

表 11-59 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 404

表 11-60 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码	描述
204	正常添加成功。
400	参数非法。
401	鉴权失败。
403	权限不足。
404	资源未找到。

11.1.9 删除边缘资源池标签

功能介绍

删除边缘资源池的标签，支持批量删除。

URI

DELETE /v1/{project_id}/edge-pools/{resource_id}/tags/delete

表 11-61 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。

参数	是否必选	参数类型	描述
resource_id	是	String	资源id，这里指边缘资源池ID。

请求参数

表 11-62 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	该字段内容填为“application/json;charset=utf8”。
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 11-63 请求 Body 参数

参数	是否必选	参数类型	描述
tags	是	Array of TmsTagForDelete objects	要删除的标签列表。

表 11-64 TmsTagForDelete

参数	是否必选	参数类型	描述
key	是	String	标签的key。
value	否	String	标签的value，非必填

响应参数

状态码： 400

表 11-65 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 401

表 11-66 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 403

表 11-67 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 404

表 11-68 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

请求示例

```
https://{endpoint}/v1/{project_id}/edge-pools/hilens-d2d3b593a3dcd2d3b593a3dc/tags/delete
{
  "tags": [{
    "key": "dev",
    "value": "dev1"
  }]
}
```

响应示例

无

状态码

状态码	描述
204	删除标签成功。
400	参数非法。

状态码	描述
401	鉴权失败。
403	权限不足。
404	资源不存在。

错误码

请参见[错误码](#)。

11.1.10 查询边缘资源池标签

功能介绍

查询当前项目下的边缘资源池标签，无权限不返回标签数据。

URI

GET /v1/{project_id}/edge-pools/tags

表 11-69 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。

请求参数

表 11-70 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。
Content-Type	是	String	该字段内容填为“application/json;charset=utf8”。

响应参数

状态码： 200

表 11-71 响应 Body 参数

参数	参数类型	描述
tags	Array of CombineTmsTags objects	标签的融合结构，相同key合并。

表 11-72 CombineTmsTags

参数	参数类型	描述
key	String	标签的key。
values	Array of strings	相同key的标签value合并后的列表。

状态码： 400

表 11-73 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 401

表 11-74 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 403

表 11-75 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

请求示例

https://{endpoint}/v1/{project_id}/edge-pools/tms/tags

响应示例

状态码： 200

查询项目下service资源类型的所有标签，正常返回。

```
{
  "tags": [ {
    "key": "k1",
    "values": [ "v1" ]
  }, {
    "key": "k2",
    "values": [ "v2" ]
  } ]
}
```

状态码

状态码	描述
200	查询项目下service资源类型的所有标签，正常返回。
400	参数非法。
401	鉴权失败。
403	权限不足。

错误码

请参见[错误码](#)。

11.1.11 查询指定边缘资源池标签

功能介绍

查询当前项目下指定的边缘资源池标签，无权限不返回标签数据。

URI

GET /v1/{project_id}/edge-pools/{resource_id}/tags

表 11-76 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。
resource_id	是	String	资源id，这里指边缘资源池ID。

请求参数

表 11-77 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。
Content-Type	是	String	该字段内容填为“application/json;charset=utf8”。

响应参数

状态码： 200

表 11-78 响应 Body 参数

参数	参数类型	描述
tags	Array of CombineTmsTags objects	标签的融合结构，相同key合并。

表 11-79 CombineTmsTags

参数	参数类型	描述
key	String	标签的key。
values	Array of strings	相同key的标签value合并后的列表。

状态码： 400

表 11-80 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 401

表 11-81 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 403

表 11-82 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

请求示例

https://{endpoint}/v1/{project_id}/edge-pools/tms/tags

响应示例

状态码： 200

查询项目下service资源类型的所有标签，正常返回。

```
{
  "tags": [ {
    "key": "k1",
    "values": [ "v1" ]
  }, {
    "key": "k2",
    "values": [ "v2" ]
  } ]
}
```

状态码

状态码	描述
200	查询项目下service资源类型的所有标签，正常返回。
400	参数非法。
401	鉴权失败。
403	权限不足。

错误码

请参见[错误码](#)。

11.1.12 通过标签查询边缘资源池列表

功能介绍

通过标签查询资源，支持多标签与查询，支持资源名称的模糊查询，不传标签表示查询所有资源。

URI

POST /v1/{project_id}/edge-pools/resource-instances/filter

表 11-83 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。

请求参数

表 11-84 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	该字段内容填为“application/json;charset=utf8”。
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 11-85 请求 Body 参数

参数	是否必选	参数类型	描述
tags	是	Array of TmsTag objects	标签列表。

表 11-86 TmsTag

参数	是否必选	参数类型	描述
key	是	String	标签的key。
value	是	String	标签的value。

表 11-87 Query 参数

参数	是否必选	参数类型	描述
offset	否	Integer	首个展示的边缘池的偏移量。 最小值：0 最大值：100000 缺省值：0
limit	否	Integer	展示边缘池的数量。 最小值：1 最大值：1000 缺省值：100

响应参数

状态码： 400

表 11-88 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码。
error_msg	String	具体错误信息。

状态码： 401

表 11-89 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码。
error_msg	String	具体错误信息。

状态码： 403

表 11-90 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码。
error_msg	String	具体错误信息。

状态码： 404

表 11-91 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码。
error_msg	String	具体错误信息。

状态码	描述
200	正常查询返回。
400	参数非法。
401	鉴权失败。
403	权限不足。
404	资源未找到。

11.1.13 通过标签查询边缘资源池数量

功能介绍

通过标签查询资源总数量，支持多标签与查询，支持资源名称的模糊查询，不传标签表示查询所有资源，不管有没有打标签。

URI

POST /v1/{project_id}/edge-pools/resource-instances/count

表 11-92 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。

请求参数

表 11-93 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	是	String	该字段内容填为“application/json;charset=utf8”。
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 11-94 请求 Body 参数

参数	是否必选	参数类型	描述
tags	是	Array of TmsTag objects	标签列表。

表 11-95 TmsTag

参数	是否必选	参数类型	描述
key	是	String	标签的key。
value	是	String	标签的value。

响应参数

状态码： 400

表 11-96 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 401

表 11-97 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码

参数	参数类型	描述
error_msg	String	具体错误信息。

状态码： 403

表 11-98 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码： 404

表 11-99 响应 Body 参数

参数	参数类型	描述
error_code	String	ModelArts错误码
error_msg	String	具体错误信息。

状态码	描述
200	正常请求返回。
400	参数非法。
401	鉴权失败。
403	权限不足。
404	资源未找到。

11.2 边缘节点管理

11.2.1 注册边缘节点

功能介绍

注册边缘节点。

URI

POST /v1/{project_id}/services/edge/nodes

表 11-100 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID 。

请求参数

表 11-101 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token

表 11-102 请求 Body 参数

参数	是否必选	参数类型	描述
node	是	NodeReqDetail object	注册边缘节点信息请求体

表 11-103 NodeReqDetail

参数	是否必选	参数类型	描述
batch	否	Integer	批量注册数量。默认为单边缘节点注册，即batch=1，如果大于1即为批量注册的最大数量。最大上限数量为100000
description	否	String	边缘节点描述，最大长度255，不允许^, ~, #, \$, %, &, *, <, >, (,), [,], {, }, ', ", \
enable_gpu	否	Boolean	是否开启GPU，true表示开启，false表示不开启，默认为false
enable_npu	否	Boolean	是否开启NPU，true表示开启，false表示不开启，默认为false
log_configs	否	Array of LogConfig objects	边缘节点日志配置

参数	是否必选	参数类型	描述
name	是	String	边缘节点名称，只允许中文字符、英文字母、数字、下划线、中划线，最大长度64
npu_type	否	String	• Snt3 节点NPU类型为Snt3 • Snt3p 节点NPU类型为Snt3p • Snt9 节点NPU类型包括Snt9和Snt9b
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

表 11-104 LogConfig

参数	是否必选	参数类型	描述
component	是	String	• app 开启Agent应用日志 • system 开启Agent系统日志
level	否	String	• error 开启错误级别的日志 • warning 开启告警级别的日志 • info 开启信息级别的日志，正常情况，不传默认为info • debug 开启调试级别的日志
rotate_num	否	Integer	设置日志滚动个数，默认5，取值范围[1,30]
size	否	Integer	日志文件大小限制，单位MB，默认50，取值范围[10, 1000]
type	是	String	• LTS 将用户端侧Agent产生的日志上传到云日志服务（Log Tank Service，简称LTS） • local 用户端侧Agent只产生本地日志，不上传到LTS

响应参数

状态码： 200

表 11-105 响应 Body 参数

参数	参数类型	描述
id	String	边缘节点ID
name	String	边缘节点名称，只允许中文字符、英文字母、数字、下划线、中划线，最大长度64
package	String	将边缘节点配置和证书文件node.conf/certificate/private_key打成.tar.gz包后用base64编码的字符串。node.conf包含节点信息配置

状态码： 400

表 11-106 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码
error_msg	String	错误描述

请求示例

```
https://{modelarts_endpoint}/v1/{project_id}/services/edge/nodes
{
  "node": {
    "batch": 1,
    "description": "",
    "enable_gpu": false,
    "enable_npu": false,
    "iam_user_id": "04f258c8fb00d42a1f65c00df88cc4dc",
    "log_configs": [ {
      "component": "app",
      "level": "debug",
      "rotate_num": 7,
      "size": 50,
      "type": "local"
    }, {
      "component": "system",
      "level": "debug",
      "rotate_num": 7,
      "size": 50,
      "type": "local"
    } ],
    "name": "edgeNode-d5Ta",
    "workspace_id": "0"
  }
}
```

响应示例

状态码： 200

请求成功

```
{
  "package": "xxxxx",
  "id": "hilens-1c92793376624366b2de406fbd07a8ed",
  "name": "edgeNode-d5Ta"
}
```

状态码

状态码	描述
200	请求成功
400	Error response

错误码

请参见[错误码](#)。

11.2.2 激活边缘节点

功能介绍

激活边缘节点，让节点处于激活状态。

URI

POST /v1/{project_id}/services/edge/nodes/activate

表 11-107 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID 。

请求参数

表 11-108 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 11-109 请求 Body 参数

参数	是否必选	参数类型	描述
activate_type	是	String	激活类型 cluster：容器+集群模式 process：进程模式 container：容器模式
node_ids	是	Array of strings	边缘节点id列表，上限50个

响应参数

状态码： 200

表 11-110 响应 Body 参数

参数	参数类型	描述
result	Array of ActivateNodeResult objects	激活结果

表 11-111 ActivateNodeResult

参数	参数类型	描述
node_id	String	节点Id
error_code	String	错误码，当激活失败时该字段不为空。该节点激活成功，则没有此字段
error_msg	String	错误信息，当激活失败时该字段不为空。该节点激活成功，则没有此字段

状态码： 400

表 11-112 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码
error_msg	String	错误描述

请求示例

```
https://{modelarts_endpoint}/v1/{project_id}/services/edge/nodes/activate

{
  "activate_type": "cluster",
  "node_ids": [ "xxx" ]
}
```

响应示例

状态码： 200

请求成功

```
{
  "result": [ {
    "node_id": "xxx",
    "error_code": "ModelArts.00xxx",
    "error_msg": "xxxxx"
  } ]
}
```

状态码

状态码	描述
200	请求成功
400	Error response

错误码

请参见[错误码](#)。

11.2.3 查询边缘节点详情

功能介绍

查询边缘节点详情。

URI

GET /v1/{project_id}/services/edge/nodes/{node_id}

表 11-113 路径参数

参数	是否必选	参数类型	描述
node_id	是	String	边缘节点ID。
project_id	是	String	资源空间ID。获取方法请参见获取资源空间ID。

请求参数

表 11-114 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 11-115 响应 Body 参数

参数	参数类型	描述
node	NodeDetail object	获取边缘节点详情响应

表 11-116 NodeDetail

参数	参数类型	描述
id	String	边缘节点ID
arch	String	边缘节点架构
memory	Long	边缘节点内存
name	String	边缘节点名称，只允许中文字符、英文字母、数字、下划线、中划线，最大长度64
description	String	边缘节点描述，最大长度255，不允许^, ~, #, \$, %, &, *, <, >, (,), [,], {, }, ', ", \
created_at	String	产生时间，如2021-10-15 14:45:22 GMT+08:00
updated_at	String	更新时间，如2021-10-15 14:45:22 GMT+08:00
user_name	String	IAM用户名
cluster_id	String	当该边缘节点处于边缘资源池时，显示边缘节点所属的边缘资源池ID
cluster_node_type	String	当该边缘节点处于边缘资源池时，显示所属的边缘资源池边缘节点类型。 - cluster_controller 控制边缘节点（主控节点） - cluster_worker 工作边缘节点（工作节点）

参数	参数类型	描述
firmware_name	String	固件名称。可包含大小写字母、数字、下划线、中划线,长度不超过60字符。必须以字母开头,字母或数字结尾
firmware_version	String	固件版本。支持X.Y.Z格式。每一个子版本号不超过三位且为非负整数。禁止在数字前补0
firmware_version_type	String	固件版本类型。
upgrade_firmware_version	String	固件正在升级的版本
firmware_status	String	固件升级状态 1 升级中 2 升级失败 3 升级成功
firmware_upgrade_record	Array of FirmwareUpdateRecord objects	该边缘节点上升级过的固件记录
state	String	边缘节点状态 - UNCONNECTED 未注册 - RUNNING 运行中 - UPGRADING 升级中 - FAIL 故障
type	String	边缘节点类型
active_status	String	边缘节点激活状态 - INACTIVE: 未激活 - ACTIVATED: 已激活
cpu	Integer	边缘节点CPU个数
gpu_num	Integer	边缘节点GPU个数
npu_num	Integer	边缘节点NPU个数
npu_type	String	边缘节点NPU类型
os_name	String	边缘节点操作系统名称
os_type	String	边缘节点操作系统类型
os_version	String	边缘节点操作系统版本
enable_container	Boolean	是否启用容器

参数	参数类型	描述
enable_gpu	Boolean	是否启用GPU
enable_npu	Boolean	是否启用NPU
host_ips	Array of strings	主机IP列表
tags	Map<String,String>	边缘节点标签对列表
npu_info	Array of EdgeNpuInfo objects	NPU信息
virtual_info	EdgeVirtualInfo object	虚拟化信息。
log_configs	Array of LogConfig objects	边缘节点日志配置
event_validity_period	Integer	事件有效时间（单位：分钟）
firmware_auto_upgrade	Boolean	固件自动升级开关
cpu_num	Integer	cpu物理个数
cpu_logic_core	Integer	cpu逻辑核数
policies	Array of Map<String,String> objects	策略
log_stream_info	LogStreamInfo object	日志流信息
firmware_expire_time	String	固件过期时间
cert_update_number	Integer	证书升级次数
container_runtime_version	String	容器运行时版本
activate_expire_time	String	激活到期时间
cluster_name	String	所属资源池
workspace_id	String	工作空间ID

表 11-117 FirmwareUpdateRecord

参数	参数类型	描述
firmware_name	String	固件名称
firmware_version	String	固件版本
firmware_size	Integer	固件大小
firmware_upgrade_time	String	固件升级时间
status	Integer	固件升级状态
record_id	String	固件升级ID
firmware_version_type	String	固件版本类型

表 11-118 EdgeNpuInfo

参数	参数类型	描述
capacity	String	容量信息
driver_version	String	驱动版本
name	String	名称
type	String	类型

表 11-119 EdgeVirtualInfo

参数	参数类型	描述
type	String	虚拟化类型。share-NPU算力共享，none-关闭。 枚举值： • none • share
share_dev_cnt	Integer	单颗芯片虚拟化出来的共享设备个数。当该值为0或1时，表示没有开启算力共享。

表 11-120 LogConfig

参数	参数类型	描述
component	String	- app 开启Agent应用日志 - system 开启Agent系统日志
level	String	- error 开启错误级别的日志 - warning 开启告警级别的日志 - info 开启信息级别的日志，正常情况，不传默认为info - debug 开启调试级别的日志
rotate_num	Integer	设置日志滚动个数，默认5，取值范围[1,7]
rotate_period	String	日志滚动周期，HCS暂不支持
size	Integer	日志文件大小限制，单位MB，默认50，取值范围[10, 1000]
type	String	- LTS 将用户端侧Agent产生的日志上传到云日志服务（Log Tank Service，简称LTS） - local 用户端侧Agent只产生本地日志，不上传到LTS
log_group_id	String	日志组id，指定传到某个日志组。HCS暂不支持

表 11-121 LogStreamInfo

参数	参数类型	描述
log_group_id	String	日志组id
log_group_name	String	日志组名称
log_stream_id	String	日志流id
log_stream_name	String	日志流名称

状态码： 400

表 11-122 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码
error_msg	String	错误描述

请求示例

```
https://{endpoint}/v1/{project_id}/services/edge/nodes/{node_id}
```

不涉及

响应示例

状态码： 200

请求成功

```
{
  "node": {
    "id": "hilens-3c8e978edccc45549500326a8aa0eca5",
    "arch": "x86_64",
    "memory": 16768624,
    "name": "edgeNode-win64",
    "description": "0",
    "created_at": "2023-08-29 16:57:51 GMT+08:00",
    "updated_at": "2023-10-14 16:12:18 GMT+08:00",
    "user_name": "EI_modelarts_00382652_02",
    "firmware_name": "HiLens_Device_Agent_win_x86",
    "firmware_version": "2.0.24",
    "state": "FAIL",
    "type": "Windows",
    "active_status": "INACTIVE",
    "cpu": 4,
    "gpu_num": 0,
    "npu_num": 0,
    "os_name": "windows",
    "os_type": "Windows",
    "os_version": "6.2 (9200)",
    "enable_container": false,
    "enable_gpu": false,
    "enable_npu": false,
    "host_ips": [ "127.0.0.1", "170.4.3.157", "8.16.9.169", "52.170.129.209", "10.190.88.179", "70.254.25.132",
    "140.8.10.12", "169.254.11.111", "169.254.66.68", "169.254.150.2", "169.254.91.28", "169.254.59.218",
    "169.254.231.97", "169.254.94.82", "169.254.158.250" ],
    "tags": { },
    "npu_info": [ ],
    "log_configs": [ {
      "component": "app",
      "level": "debug",
      "rotate_num": 5,
      "rotate_period": "7",
      "size": 50,
      "type": "local"
    }, {
      "component": "system",
      "level": "debug",
      "rotate_num": 5,
      "rotate_period": "7",
      "size": 50,
      "type": "local"
    } ],
    "event_validity_period": 10080,
    "firmware_auto_upgrade": false,
    "cpu_num": 1,
    "cpu_logic_core": 4,
    "policies": [ ],
    "log_stream_info": { },
    "workspace_id": "0"
  }
}
```


状态码

状态码	描述
200	请求成功
400	Error response

错误码

请参见[错误码](#)。

11.2.4 更新边缘节点信息

功能介绍

更新边缘节点日志配置，标签以及描述。

URI

PUT /v1/{project_id}/services/edge/nodes/{node_id}

表 11-123 路径参数

参数	是否必选	参数类型	描述
node_id	是	String	边缘节点ID。
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID 。

请求参数

表 11-124 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 11-125 请求 Body 参数

参数	是否必选	参数类型	描述
node	是	UpdateNodeReqDetail object	更新边缘节点信息请求体。

表 11-126 UpdateNodeReqDetail

参数	是否必选	参数类型	描述
description	否	String	边缘节点描述，最大长度255，不允许^, ~, #, \$, %, &, *, <, >, (), [], { }, ' , " , \
enable_gpu	否	Boolean	是否支持gpu
enable_npu	否	Boolean	是否支持npu
npu_type	否	String	npu类型
log_configs	否	Array of LogConfig objects	边缘节点日志配置

表 11-127 LogConfig

参数	是否必选	参数类型	描述
component	是	String	- app 开启Agent应用日志 - system 开启Agent系统日志
level	否	String	- error 开启错误级别的日志 - warning 开启告警级别的日志 - info 开启信息级别的日志，正常情况，不传默认为info - debug 开启调试级别的日志
rotate_num	否	Integer	设置日志滚动个数，默认5，取值范围[1,7]
size	否	Integer	日志文件大小限制，单位MB，默认50，取值范围[10, 1000]
type	是	String	- LTS 将用户端侧Agent产生的日志上传到云日志服务（Log Tank Service，简称LTS） - local 用户端侧Agent只产生本地日志，不上传到LTS

响应参数

状态码： 400

表 11-128 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码
error_msg	String	错误描述

请求示例

```
https://{endpoint}/v1/{project_id}/services/edge/nodes/{node_id}

{
  "node": {
    "description": "dd",
    "log_configs": [ {
      "component": "app",
      "level": "debug",
      "rotate_num": 7,
      "size": 50,
      "type": "local"
    }, {
      "component": "system",
      "level": "debug",
      "rotate_num": 7,
      "size": 50,
      "type": "local"
    } ],
    "enable_npu": false,
    "enable_gpu": false,
    "npu_type": "Snt3"
  }
}
```

响应示例

状态码： 200

请求成功

不涉及

状态码

状态码	描述
200	请求成功
400	Error response

错误码

请参见[错误码](#)。

11.2.5 删除边缘节点

功能介绍

删除控制台上的边缘节点，并与端侧的边缘节点进行解绑。

URI

DELETE /v1/{project_id}/services/edge/nodes/{node_id}

表 11-129 路径参数

参数	是否必选	参数类型	描述
node_id	是	String	边缘节点ID。
project_id	是	String	资源空间ID。获取方法请参见获取资源空间ID。

表 11-130 Query 参数

参数	是否必选	参数类型	描述
force_delete	否	Boolean	是否强制删除，true代表是，false代表否

请求参数

表 11-131 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 400

表 11-132 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码
error_msg	String	错误描述

请求示例

```
https://{modelarts_endpoint}/v1/{project_id}/services/edge/nodes/{node_id}
```

不涉及

响应示例

状态码： 200

请求成功

```
{
  "node_id" : "xxx"
}
```

状态码

状态码	描述
200	请求成功
400	Error response

错误码

请参见[错误码](#)。

11.2.6 查询边缘节点列表

功能介绍

查询边缘节点列表，可通过节点标签过滤。

URI

GET /v1/{project_id}/services/edge/nodes

表 11-133 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见获取资源空间ID。

表 11-134 Query 参数

参数	是否必选	参数类型	描述
limit	否	String	指定每一页返回的最大条目数，默认为1000

参数	是否必选	参数类型	描述
name	否	String	边缘节点名称
offset	否	String	分页列表的起始页，默认为0
provider	是	String	节点的提供者。当前需要输入modelarts
state	否	String	节点状态。provider为modelarts时支持 • UNCONNECTED 未注册 • RUNNING 运行中 • FAIL 故障 • UPGRADING 升级中
active_status	否	String	激活状态。provider为modelarts时支持 • INACTIVE 未激活 • ACTIVATED 已激活
pool_id	否	String	资源池id
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

请求参数

表 11-135 请求 Header 参数

参数	是否必选	参数类型	描述
Content-Type	否	String	content-type
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token

响应参数

状态码： 200

表 11-136 响应 Body 参数

参数	参数类型	描述
count	Integer	节点个数

参数	参数类型	描述
nodes	Array of ServiceEdgeNodeInfo objects	节点列表

表 11-137 ServiceEdgeNodeInfo

参数	参数类型	描述
arch	String	节点架构
cpu	Float	CPU核心数
created_at	String	创建时间，格式为YYYY-MM-DDThh:mm:ss，UTC时间
deployment_num	Integer	部署在该节点上的应用实例个数
description	String	节点描述信息
enable_gpu	Boolean	是否开启GPU
enable_npu	Boolean	是否开启NPU
gpu_num	Integer	gpu个数
host_ips	Array of strings	节点主机IP
host_name	String	节点主机名
id	String	边缘节点ID
instance_statuses	String	模型实例在该节点的运行状态 ● running 运行中 ● stopped 停止， ● notReady 未就绪 ● failed 运行失败
memory	Integer	内存数(MB)，provider为ief时返回。
message	String	当 instance_status 为failed或者是notReady时，解释原因
name	String	边缘节点名称
node_type	String	节点类型
npu_info	Array of EdgeNpuInfo objects	NPU详情

参数	参数类型	描述
npu_num	Integer	npu个数
os_name	String	节点操作系统名称
os_type	String	节点操作系统类型
os_version	String	节点操作系统版本
predict_url	String	在该节点的预测URL
resource	RseNodeResource object	资源使用情况
state	String	• UNCONNECTED 未注册 • RUNNING 运行中 • FAIL 故障
updated_at	String	更新时间，格式为YYYY-MM-DDThh:mm:ss，UTC时间。
active_status	String	边缘节点激活状态，分别是未激活（INACTIVE）、已激活（ACTIVATED）、已到期（EXPIRED），provider为modelarts时返回。
pool_node_type	String	资源池节点类型，ief或者modelarts，默认为ief
firmware_version	String	固件版本

表 11-138 EdgeNpuInfo

参数	参数类型	描述
capacity	String	容量信息
driver_version	String	驱动版本
name	String	名称
type	String	类型

表 11-139 RseNodeResource

参数	参数类型	描述
totalResource	RseResource object	资源总量
usedResource	RseResource object	已经使用的资源情况

表 11-140 RseResource

参数	参数类型	描述
aiChips	Array of RseAiChip objects	AI芯片信息
cpu	Float	cpu个数
mem	Integer	内存大小（MB）

表 11-141 RseAiChip

参数	参数类型	描述
amount	Float	数量
chipType	String	芯片类型
driverVersion	String	驱动版本

请求示例

查询边缘节点列表

GET https://{endpoint}/v1/{project_id}/services/edge/nodes?
provider=modelarts&limit=5&offset=0&state=&active_status=&name=&workspace_id=0

```
{
  "count": 1441,
  "nodes": [ {
    "id": "hilens-5adc3c1fbce54fb6ad53b5cab4571620",
    "name": "edgeNode-baidu",
    "cpu": 32,
    "memory": 0,
    "state": "RUNNING",
    "gpu_num": 0,
    "npu_num": 4,
    "enable_gpu": false,
    "enable_npu": false,
    "host_ips": [ "10.174.216.164", "127.0.0.1", "172.17.0.1" ],
    "deployment_num": 0,
    "created_at": "2023-12-18 12:05:45 GMT+08:00",
    "updated_at": "2024-02-05 16:32:18 GMT+08:00",
    "active_status": "ACTIVATED",
    "pool_node_type": "cluster_controller",
    "firmware_version": "2.0.25"
  }, {
    "id": "hilens-f1dfc94ded414b2ba8ecb0781f24a419",
    "name": "edgeNode-DL",
    "description": "90.91.65.237-登临L128",
    "cpu": 0,
    "memory": 0,
    "state": "UNCONNECTED",
    "gpu_num": 0,
    "npu_num": 0,
  }
]
```

```
"enable_gpu" : false,
"enable_npu" : false,
"host_ips" : [ ],
"deployment_num" : 0,
"created_at" : "2023-12-10 10:11:52 GMT+08:00",
"updated_at" : "2023-12-10 10:12:00 GMT+08:00",
"active_status" : "INACTIVE"
}, {
  "id" : "hilens-00ff2e84bb9a4fc587567ebd15796401",
  "name" : "edgeNode-HWJx8",
  "description" : "HWJ X8 90.90.130.89",
  "cpu" : 0,
  "memory" : 0,
  "state" : "UNCONNECTED",
  "gpu_num" : 0,
  "npu_num" : 0,
  "enable_gpu" : false,
  "enable_npu" : false,
  "host_ips" : [ ],
  "deployment_num" : 0,
  "created_at" : "2023-12-09 16:09:07 GMT+08:00",
  "updated_at" : "2023-12-11 14:36:55 GMT+08:00",
  "active_status" : "INACTIVE"
}, {
  "id" : "hilens-0b9054e736434a12a8ca522a1abdc9aa",
  "name" : "edgeNode-236",
  "description" : "自动化专用，勿删！1220",
  "cpu" : 2,
  "memory" : 0,
  "state" : "RUNNING",
  "gpu_num" : 0,
  "npu_num" : 0,
  "enable_gpu" : false,
  "enable_npu" : false,
  "host_ips" : [ "172.16.0.46", "127.0.0.1", "172.17.0.1", "10.43.0.1", "10.43.0.10", "10.43.114.84" ],
  "deployment_num" : 0,
  "created_at" : "2023-12-06 10:14:34 GMT+08:00",
  "updated_at" : "2024-02-04 19:16:46 GMT+08:00",
  "active_status" : "ACTIVATED",
  "firmware_version" : "2.0.26"
}, {
  "id" : "hilens-6967dfe6bb3346e29dd96ded8d4cdab1",
  "name" : "edgeNode-wr1120",
  "cpu" : 0,
  "memory" : 0,
  "state" : "UNCONNECTED",
  "gpu_num" : 0,
  "npu_num" : 0,
  "enable_gpu" : false,
  "enable_npu" : false,
  "host_ips" : [ ],
  "deployment_num" : 0,
  "created_at" : "2023-11-20 15:18:35 GMT+08:00",
  "updated_at" : "2023-11-20 15:18:35 GMT+08:00",
  "active_status" : "INACTIVE"
}
}]
}
```

响应示例

无

状态码

状态码	描述
200	OK
401	Unauthorized
403	Forbidden
404	Not Found

错误码

请参见[错误码](#)。

11.2.7 绑定设备

功能介绍

在ModelArts边缘节点执行一行命令，将ModelArts控制台边缘节点和硬件绑定。本接口仅适用于ModelArts Edge边缘节点触发，执行命令：hdctl register_bind -p ./[证书名称].tar.gz。用户无感知，可以不关注。

URI

PUT /v3/{project_id}/ai-mgr/nodes/{node_id}/bind

表 11-142 路径参数

参数	是否必选	参数类型	描述
node_id	是	String	ModelArts控制台边缘节点ID。
project_id	是	String	项目ID。获取方法请参见获取资源空间ID。

请求参数

表 11-143 请求 Header 参数

参数	是否必选	参数类型	描述
X-Node-License	是	String	通过端侧设备证书加密的认证字符串

表 11-144 请求 Body 参数

参数	是否必选	参数类型	描述
hardware_id	否	String	硬件ID
firmware_name	否	String	固件名称。可包含大小写字母、数字、下划线、中划线，长度不超过60字符。必须以字母开头，字母或数字结尾
firmware_version	否	String	固件版本。支持X.Y.Z格式。每一个子版本号不超过三位且为非负整数，禁止在数字前补0
type	否	String	设备类型
arch	否	String	架构
cpu	否	Integer	设备CPU个数
gpu_num	否	Integer	设备GPU个数
npu_num	否	Integer	设备NPU个数
npu_type	否	String	设备NPU类型
os_name	否	String	设备操作系统名称
os_type	否	String	设备操作系统类型
os_version	否	String	设备操作系统版本
enable_container	否	Boolean	是否启用容器
container_runtime_version	否	Boolean	容器运行时版本
memory	否	Long	设备内存
npu_info	否	Object	NPU信息
host_ips	否	Array of strings	主机IP列表

响应参数

无

请求示例

绑定设备

```
PUT https://{endpoint}/v3/{project_id}/ai-mgr/nodes/{node_id}/bind

Request Header:
Content-Type: application/json
```

X-Node-License:YL9385x9B2UcMgdpinAyTGg8X4z3MKI3+Uzcinp5sV....
Request Body:

```
{
  "cpu": 4,
  "arch": "arm",
  "firmware_name": "hsfw",
  "firmware_version": "1.3.0",
  "memory": 4096,
  "os_name": "EulerOS",
  "os_version": "2.0 (SP8)",
  "os_type": "unix",
  "type": "HiLens Kit",
  "enable_container": false,
  "host_ips": [
    "1.1.1.1",
    "192.168.0.137"
  ],
  "hardware_id": "123456"
}
```

响应示例

状态码： 200

请求成功

```
{
  "name" : "hc_node_1",
  "id" : "hilens-ff2e579f627549cda552a0b2098ef025",
  "package" : "H4slAAAAPOV6.....bEnACAAAA=="
}
```

状态码

状态码	描述
200	请求成功
201	创建成功
401	认证不通过
403	拒绝执行请求
404	请求的资源不存在
500	服务器内部错误

错误码

请参见[错误码](#)。

11.2.8 边缘节点链接上云

功能介绍

硬件绑定之后，通过该接口硬件可以链接上云。本接口仅适用于ModelArts Edge边缘节点触发，用户无感知，可以不关注。

URI

GET /v3/login

请求参数

无

响应参数

无

请求示例

边缘节点链接上云

GET https://{endpoint}/v3/login

响应示例

无

状态码

状态码	描述
200	请求链接成功
401	认证不通过
403	拒绝执行请求
404	请求的资源不存在
500	服务器内部错误

错误码

请参见[错误码](#)。

11.3 负载均衡管理

11.3.1 查询负载均衡列表

功能介绍

根据用户请求条件筛选，查询用户创建的负载均衡信息，以列表形式返回。

URI

GET /v1/{project_id}/services/edge/loadbalancers

表 11-145 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见获取资源空间ID和名称。

表 11-146 Query 参数

参数	是否必选	参数类型	描述
cluster_id	否	String	集群ID
cluster_name	否	String	集群名称，模糊匹配，只允许中英文、数字、下划线、中划线，长度1~60
description	否	String	负载均衡描述
name	否	String	负载均衡名称，模糊匹配，只允许中英文、数字、下划线、中划线，长度1~60
service_name	否	String	服务名称，模糊匹配，只允许中英文、数字、下划线、中划线，长度1~60
deployment_name	否	String	部署名称，中英文、数字、下划线、中划线，长度[1-60]
node_name	否	String	节点名称，中英文、数字、下划线、中划线，长度[1-64]
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

请求参数

无

响应参数

状态码： 200

表 11-147 响应 Body 参数

参数	参数类型	描述
count	Integer	符合查询条件的负载均衡总数

参数	参数类型	描述
load_balancers	LoadbalancerResponseMap object	负载均衡响应详情

表 11-148 LoadbalancerResponseMap

参数	参数类型	描述
cluster_name	String	负载均衡所在集群名称
apig_port	Integer	负载均衡输入端口
reason	String	负载均衡状态异常原因上报
scheme	String	负载均衡通信策略，HTTP或者HTTPS
description	String	负载均衡描述
lb_algorithm	String	轮询算法，支持ROUND_ROBIN
created_at	String	创建时间
apig_net_seg	String	负载均衡接收的IP网段
secrets	Secrets object	负载均衡的证书机构、证书和密钥
routes	Array of RouteDto objects	路由列表
cluster_id	String	负载均衡所在的集群的ID
updated_at	String	负载均衡更新时间
project_id	String	资源空间ID
node_id	String	节点ID 仅为边缘节点创建有值
node_name	String	节点名称 仅为边缘节点创建有值
name	String	负载均衡名称
id	String	负载均衡ID
session_affinity_mode	String	负载均衡亲和性，SOURCE_IP或者NONE
status	String	负载均衡状态，创建中（CREATING）、创建失败（CREATE_FAILED）、更新中（UPDATING）、更新失败（UPDATE_FAILED）、删除中（DELETING）、删除失败（DELETE_FAILED）、运行中（RUNNING）

参数	参数类型	描述
host_ips	Array of strings	访问IP列表

表 11-149 Secrets

参数	参数类型	描述
ca	Secret object	CA证书机构，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存
cert	Secret object	创建负载均衡所需证书，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存
key	Secret object	创建负载均衡密钥，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存

表 11-150 Secret

参数	参数类型	描述
key	String	以英文字母和中划线开头，由英文字母、数字、点号、中划线和下划线组成，长度1-63位
name	String	以英文小写字母开头，由中文字符，英文字母，数字，下划线和中划线组成，不能以中划线结尾，长度4-64位

表 11-151 RouteDto

参数	参数类型	描述
path_type	String	路径匹配模式
port	Integer	服务访问端口
service_name	String	服务名称，只允许英文小写字母、数字、中划线，最大长度64，英文小写字母开头，数字或小写字母结尾
uri	String	用来检验负载均衡路径，规则：以/开头，只允许字母、数字、下划线、中划线、斜杆、*号，长度不超过255
deployment_name	String	单节点创建负载均衡的时候，节点部署的名称，只允许英文小写字母、数字、中划线，最大长度32，英文小写字母或数字开头和结尾

参数	参数类型	描述
backend_uri	String	重写后的后端路径。规则：以/开头，只允许字母、数字、下划线、中划线、/、\$和括号，长度不超过255

请求示例

获取负载均衡列表

GET https://{endpoints}/v1/{project_id}/services/edge/loadbalancers?offset=0&limit=10&workspace_id=0

Request Header: Content-Type: application/jsonX-Auth-Token:
MIINRwYJKoZIhvcNAQcCoIINODCCDTQCAQExDTALBgIghkgBZQMEAgEwgguVBgkqhkiG...

响应示例

状态码： 200

请求成功

```
{
  "load_balancers": [ {
    "cluster_name": "hilens-209",
    "apig_port": 8199,
    "reason": null,
    "scheme": "HTTP",
    "description": null,
    "lb_algorithm": "ROUND_ROBIN",
    "created_at": "2021-11-14 20:34:54 GMT+08:00",
    "apig_net_seg": null,
    "secrets": null,
    "host_ips": [
      "172.16.0.236"
    ],
    "routes": [ {
      "port": 8083,
      "loadbalancer_id": "hilens-62442cbe52a845c7870848f92353477f",
      "service_name": "service-209-001",
      "service_id": "hilens-faf397ebbec84184a8ad094fc7c372a4",
      "path_type": "PREFIX",
      "id": "8a2c20fa7d1319d1017d1e7180930001",
      "uri": "/a"
    } ],
    "cluster_id": "hilens-73fcae2fc6942a19600c1bbda26bfe3",
    "updated_at": "2021-11-14 20:34:54 GMT+08:00",
    "project_id": "fff47e1722f94c4e98531bae56821372",
    "name": "loadbalancer-209-17",
    "id": "hilens-62442cbe52a845c7870848f92353477f",
    "session_affinity_mode": "NONE",
    "status": "DELETING"
  } ],
  "count": 64
}
```

状态码

状态码	描述
200	请求成功

状态码	描述
401	认证不通过
403	拒绝执行请求
404	请求的资源不存在
500	服务器内部错误

错误码

请参见[错误码](#)。

11.3.2 添加负载均衡

功能介绍

添加负载均衡，将负载均衡添加到ModelArts控制台上，用于集群（或边缘节点）的负载均衡控制。

URI

POST /v1/{project_id}/services/edge/loadbalancers

表 11-152 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称

请求参数

表 11-153 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	租户Token。获取方法请参见 获取Token

表 11-154 查询参数

参数	是否必选	参数类型	描述
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

表 11-155 请求 Body 参数

参数	是否必选	参数类型	描述
apig_port	是	Integer	负载均衡端口
cluster_id	否	String	负载均衡所在的集群ID
description	否	String	负载均衡描述的正则表达式，最大长度255，不允许^、~、#、\$、%、&、*、<、>、(、)、[、]、{、}、'、"、\、/
lb_algorithm	否	String	负载均衡轮询算法
name	是	String	负载均衡名称，只允许英文小写字母、数字、中划线，最大长度64，最小长度2，英文小写字母开头，数字或小写字母结尾
routes	否	Array of RouteDto objects	负载均衡的路由配置
scheme	否	String	负载均衡通信策略，可选HTTP和HTTPS
secrets	否	Secrets object	密钥配置，用于存放证书CERT、机构CA和密钥
session_affinity_mode	否	String	会话保持模式，可选SOURCE_IP或者NONE
node_id	否	String	单节点负载均衡，对应的节点ID

表 11-156 RouteDto

参数	是否必选	参数类型	描述
path_type	否	String	路径匹配模式。取值为PREFIX, EXACT, REGEX。 • PREFIX：前缀匹配 • EXACT：精确匹配 • REGEX：正则匹配
port	是	Integer	服务访问端口
service_name	否	String	服务名称，只允许英文小写字母、数字、中划线，最大长度64，英文小写字母开头，数字或小写字母结尾

参数	是否必选	参数类型	描述
uri	是	String	用来检验负载均衡路径。规则：以/ 开头，只允许字母、数字、下划线、中划线、/、*号，长度不超过255
deployment_name	否	String	单节点创建负载均衡的时候，节点部署的名称，只允许英文小写字母、数字、中划线，最大长度32，英文小写字母或数字开头和结尾
backend_uri	否	String	重写后的后端路径。规则：以/ 开头，只允许字母、数字、下划线、中划线、/、\$和括号，长度不超过255

表 11-157 Secrets

参数	是否必选	参数类型	描述
ca	是	Secret object	CA证书机构，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存
cert	是	Secret object	创建负载均衡所需证书，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存
key	是	Secret object	创建负载均衡密钥，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存

表 11-158 Secret

参数	是否必选	参数类型	描述
key	否	String	以英文字母和中划线开头，由英文字母、数字、点号、中划线和下划线组成，长度1-63位
name	否	String	以英文小写字母开头，由中文字符，英文字母，数字，下划线和中划线组成，不能以中划线结尾，长度4-64位

响应参数

状态码： 200

表 11-159 响应 Body 参数

参数	参数类型	描述
cluster_name	String	负载均衡所在集群名称
apig_port	Integer	负载均衡输入端口
reason	String	负载均衡状态异常原因上报
scheme	String	负载均衡通信策略，HTTP或者HTTPS
description	String	负载均衡描述
lb_algorithm	String	轮询算法，支持ROUND_ROBIN
created_at	String	创建时间
apig_net_seg	String	负载均衡接收的IP网段
secrets	Secrets object	负载均衡的证书机构、证书和密钥
routes	Array of RouteDto objects	路由列表
cluster_id	String	负载均衡所在的集群的ID
updated_at	String	负载均衡更新时间
project_id	String	资源空间ID
node_id	String	节点ID 仅为边缘节点创建有值
node_name	String	节点名称 仅为边缘节点创建有值
name	String	负载均衡名称
id	String	负载均衡ID
session_affinity_mode	String	负载均衡亲和性，SOURCE_IP或者NONE
status	String	负载均衡状态，创建中（CREATING）、创建失败（CREATE_FAILED）、更新中（UPDATING）、更新失败（UPDATE_FAILED）、删除中（DELETING）、删除失败（DELETE_FAILED）、运行中（RUNNING）

表 11-160 Secrets

参数	参数类型	描述
ca	Secret object	CA证书机构，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存

参数	参数类型	描述
cert	Secret object	创建负载均衡所需证书，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存
key	Secret object	创建负载均衡密钥，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存

表 11-161 Secret

参数	参数类型	描述
key	String	以英文字母和中划线开头，由英文字母、数字、点号、中划线和下划线组成，长度1-63位
name	String	以英文小写字母开头，由中文字符，英文字母，数字，下划线和中划线组成，不能以中划线结尾，长度4-64位

表 11-162 RouteDto

参数	参数类型	描述
path_type	String	路径匹配模式
port	Integer	服务访问端口
service_name	String	服务名称，只允许英文小写字母、数字、中划线，最大长度64，英文小写字母开头，数字或小写字母结尾
uri	String	用来检验负载均衡路径。规则：以/开头，只允许字母、数字、下划线、中划线、/、*号，长度不超过255
deployment_name	String	单节点创建负载均衡时，节点部署的名称，只允许英文小写字母、数字、中划线，最大长度32，英文小写字母或数字开头和结尾
backend_uri	String	重写后的后端路径。规则：以/开头，只允许字母、数字、下划线、中划线、/、\$和括号，长度不超过255

请求示例

- 负载均衡采用https策略

POST https://{endpoints}/v1/{project_id}/services/edge/loadbalancers

Request Header: Content-Type: application/jsonX-Auth-Token: MIINRwYJKoZIhvcNAQcColINODCCDTQCAQExDTALBgIghkgBZQMEAgEwgguVBgkqhkiG...Request Body:{ "name": "lb-example", "description": "负载均衡", "cluster_id": "hilens-6fc07ac7a0034504b7a9895ebb4cf7f9", "apig_port": "8092", "lb_algorithm":

```
"ROUND_ROBIN", "session_affinity_mode": "NONE", "scheme": "HTTPS", "secrets": {  "cert":  
{  "key": "cert",  "name": "loadbalancer_cert_005"  }, "key": {  "key": "key",  "name":  
"loadbalancer_cert_005"  }, "ca": {  "key": "ca",  "name": "loadbalancer_cert_005"  } },  
"routes": []}
```

- 添加负载均衡

POST https://{endpoint}/v1/fff47e1722f94c4e98531bae56821372/services/edge/loadbalancers

Request Header: Content-Type: application/jsonX-Auth-Token:
MIINRwYJKoZIhvcNAQcCollNODCCDTQCAQExDTALBglghkgBZQMEAgEwgguVBgkqhkiG...Request
Body:{ "name": "loadbalancer-example", "description": "负载均衡样例", "cluster_id":
"hilens-6fc07ac7a0034504b7a9895ebb4cf7f9", "apig_port": "8090", "lb_algorithm":
"ROUND_ROBIN", "session_affinity_mode": "SOURCE_IP", "scheme": "HTTP", "routes":
[{ "path_type": "PREFIX", "uri": "/abc", "service_name": "service-example1", "port":
"1222" }]}

响应示例

状态码： 200

请求成功

```
{  
  "cluster_name" : "hilens-208",  
  "apig_port" : 8090,  
  "reason" : null,  
  "scheme" : "HTTP",  
  "description" : "负载均衡样例",  
  "lb_algorithm" : "ROUND_ROBIN",  
  "created_at" : "2022-04-14 19:34:45 GMT+08:00",  
  "apig_net_seg" : null,  
  "secrets" : null,  
  "routes" : [ {  
    "port" : 1222,  
    "loadbalancer_id" : "hilens-d460b283d50f44d3879200ef93c8af82",  
    "service_name" : "service-example1",  
    "service_id" : "hilens-a5db88ae11a34136bf4533d08032ca27",  
    "path_type" : "PREFIX",  
    "id" : null,  
    "uri" : "/abc"  
  } ],  
  "cluster_id" : "hilens-6fc07ac7a0034504b7a9895ebb4cf7f9",  
  "updated_at" : "2022-04-14 19:34:45 GMT+08:00",  
  "project_id" : "fff47e1722f94c4e98531bae56821372",  
  "name" : "loadbalancer-example",  
  "id" : "hilens-d460b283d50f44d3879200ef93c8af82",  
  "session_affinity_mode" : "SOURCE_IP",  
  "status" : "CREATING"  
}
```

状态码

状态码	描述
200	请求成功
201	已创建
401	未授权
403	拒绝执行
404	请求资源找不到

错误码

请参见[错误码](#)。

11.3.3 查询负载均衡详情

功能介绍

支持查询ModelArts控制台上的负载均衡详情。

URI

GET /v1/{project_id}/services/edge/loadbalancers/{loadbalancer_id}

表 11-163 路径参数

参数	是否必选	参数类型	描述
loadbalancer_id	是	String	负载均衡ID，可从 查询负载均衡列表 获取
project_id	是	String	资源空间ID。获取方法请参见获取资源空间ID和名称

请求参数

表 11-164 查询参数

参数	是否必选	参数类型	描述
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

响应参数

状态码： 200

表 11-165 响应 Body 参数

参数	参数类型	描述
cluster_name	String	负载均衡所在集群名称
apig_port	Integer	负载均衡输入端口
reason	String	负载均衡状态异常原因上报
scheme	String	负载均衡通信策略，HTTP或者HTTPS

参数	参数类型	描述
description	String	负载均衡描述
lb_algorithm	String	轮询算法，支持ROUND_ROBIN
created_at	String	创建时间
apig_net_seg	String	负载均衡接收的IP网段
secrets	Secrets object	负载均衡的证书机构、证书和密钥
routes	Array of RouteDto objects	路由列表
cluster_id	String	负载均衡所在的集群的ID
updated_at	String	负载均衡更新时间
node_id	String	节点ID 仅为边缘节点创建有值
node_name	String	节点名称 仅为边缘节点创建有值
project_id	String	资源空间ID
name	String	负载均衡名称
id	String	负载均衡ID
session_affinity_mode	String	负载均衡亲和性，SOURCE_IP或者NONE
status	String	负载均衡状态，创建中（CREATING）、创建失败（CREATE_FAILED）、更新中（UPDATING）、更新失败（UPDATE_FAILED）、删除中（DELETING）、删除失败（DELETE_FAILED）、运行中（RUNNING）
host_ips	Array of strings	访问IP列表

表 11-166 Secrets

参数	参数类型	描述
ca	Secret object	CA证书机构，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存
cert	Secret object	创建负载均衡所需证书，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存
key	Secret object	创建负载均衡密钥，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存

表 11-167 Secret

参数	参数类型	描述
key	String	以英文字母和中划线开头，由英文字母、数字、点号、中划线和下划线组成，长度1-63位
name	String	以英文小写字母开头，由中文字符，英文字母，数字，下划线和中划线组成，不能以中划线结尾，长度4-64位

表 11-168 RouteDto

参数	参数类型	描述
path_type	String	路径匹配模式
port	Integer	服务访问端口
service_name	String	服务名称，只允许英文小写字母、数字、中划线，最大长度64，英文小写字母开头，数字或小写字母结尾
uri	String	用来检验负载均衡路径，规则：以/ 开头，只允许字母、数字、下划线、中划线、斜杆、*号，长度不超过255
deployment_name	String	单节点创建负载均衡的时候，节点部署的名称，只允许英文小写字母、数字、中划线，最大长度32，英文小写字母或数字开头和结尾
backend_uri	String	重写后的后端路径。规则：以/开头，只允许字母、数字、下划线、中划线、/、\$和括号，长度不超过255

请求示例

查询负载均衡详情

GET https://{endpoints}/v1/{project_id}/services/edge/loadbalancers/{loadbalancer_id}

Request Header: Content-Type: application/jsonX-Auth-Token: MIINRwYJKoZlhvcNAQcColINODCCDTQCAQExDTALBgIhgkgBZQMEAgEwgguVBgkqhkiG...

响应示例

状态码： 200

请求成功

```
{
  "cluster_name": "hilens-208",
  "apig_port": 8091,
  "reason": null,
  "scheme": "HTTP",
  "description": "负载均衡样例",
```

```
"lb_algorithm" : "ROUND_ROBIN",
"created_at" : "2022-04-14 19:37:41 GMT+08:00",
"apig_net_seg" : null,
"secrets" : null,
"host_ips" : [
  "172.16.0.236"
],
"routes" : [ {
  "port" : 1222,
  "loadbalancer_id" : "hilens-d460b283d50f44d3879200ef93c8af82",
  "service_name" : "service-example1",
  "service_id" : "hilens-a5db88ae11a34136bf4533d08032ca27",
  "path_type" : "PREFIX",
  "id" : "8abfafa58025c82e018027dd6345006a",
  "uri" : "/abc"
} ],
"cluster_id" : "hilens-6fc07ac7a0034504b7a9895ebb4cf7f9",
"updated_at" : "2022-04-14 19:37:41 GMT+08:00",
"project_id" : "fff47e1722f94c4e98531bae56821372",
"name" : "loadbalancer-example",
"id" : "hilens-d460b283d50f44d3879200ef93c8af82",
"session_affinity_mode" : "SOURCE_IP",
"status" : "RUNNING"
}
```

状态码

状态码	描述
200	请求成功
401	未授权
403	拒绝执行
404	请求资源找不到

错误码

请参见[错误码](#)。

11.3.4 更新负载均衡

功能介绍

更新指定ID的负载均衡。

URI

PUT /v1/{project_id}/services/edge/loadbalancers/{loadbalancer_id}

表 11-169 路径参数

参数	是否必选	参数类型	描述
loadbalancer_id	是	String	负载均衡ID，可从 查询负载均衡列表 获取

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见获取资源空间ID和名称

请求参数

表 11-170 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	租户Token。获取方法请参见 获取Token

表 11-171 查询参数

参数	是否必选	参数类型	描述
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

表 11-172 请求 Body 参数

参数	是否必选	参数类型	描述
apig_port	是	Integer	负载均衡端口
description	否	String	负载均衡描述的正则表达式，最大长度255，不允许^、~、#、\$、%、&、*、<、>、(、)、[、]、{、}、'、"、\、/
lb_algorithm	否	String	负载均衡轮询算法
name	是	String	负载均衡名称，只允许英文小写字母、数字、中划线，最大长度64，最小长度2，英文小写字母开头，数字或小写字母结尾
routes	否	Array of RouteDto objects	负载均衡的路由配置
scheme	否	String	负载均衡通信策略，可选HTTP和HTTPS
secrets	是	Secrets object	密钥配置，用于存放证书CERT、机构CA和密钥

参数	是否必选	参数类型	描述
session_affinity_mode	否	String	会话保持模式，可选SOURCE_IP或者NONE

表 11-173 RouteDto

参数	是否必选	参数类型	描述
path_type	否	String	路径匹配模式
port	是	Integer	服务访问端口
service_name	否	String	服务名称，只允许英文小写字母、数字、中划线，最大长度64，英文小写字母开头，数字或小写字母结尾
uri	是	String	用来检验负载均衡路径，规则：以/开头，只允许字母、数字、下划线、中划线、斜杆、*号，长度不超过255
deployment_name	否	String	单节点创建负载均衡的时候，节点部署的名称，只允许英文小写字母、数字、中划线，最大长度32，英文小写字母或数字开头和结尾
backend_uri	否	String	重写后的后端路径。规则：以/开头，只允许字母、数字、下划线、中划线、/、\$和括号，长度不超过255

表 11-174 Secrets

参数	是否必选	参数类型	描述
ca	是	Secret object	CA证书机构，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存
cert	是	Secret object	创建负载均衡所需证书，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存
key	是	Secret object	创建负载均衡密钥，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存

表 11-175 Secret

参数	是否必选	参数类型	描述
key	否	String	以英文字母和中划线开头，由英文字母、数字、点号、中划线和下划线组成，长度1-63位
name	否	String	以英文小写字母开头，由中文字符，英文字母，数字，下划线和中划线组成，不能以中划线结尾，长度4-64位

响应参数

状态码： 200

表 11-176 响应 Body 参数

参数	参数类型	描述
cluster_name	String	负载均衡所在集群名称
apig_port	Integer	负载均衡输入端口
reason	String	负载均衡状态异常原因上报
scheme	String	负载均衡通信策略，HTTP或者HTTPS
description	String	负载均衡描述
lb_algorithm	String	轮询算法，支持ROUND_ROBIN
created_at	String	创建时间
apig_net_seg	String	负载均衡接收的IP网段
secrets	Secrets object	负载均衡的证书机构、证书和密钥
routes	Array of RouteDto objects	路由列表
cluster_id	String	负载均衡所在的集群的ID
node_id	String	节点ID 仅为边缘节点创建有值
node_name	String	节点名称 仅为边缘节点创建有值
updated_at	String	负载均衡更新时间
project_id	String	资源空间ID
name	String	负载均衡名称
id	String	负载均衡ID

参数	参数类型	描述
session_affinity_mode	String	负载均衡亲和性，SOURCE_IP或者NONE
status	String	负载均衡状态，创建中（CREATING）、创建失败（CREATE_FAILED）、更新中（UPDATING）、更新失败（UPDATE_FAILED）、删除中（DELETING）、删除失败（DELETE_FAILED）、运行中（RUNNING）

表 11-177 Secrets

参数	参数类型	描述
ca	Secret object	CA证书机构，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存
cert	Secret object	创建负载均衡所需证书，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存
key	Secret object	创建负载均衡密钥，需要通过调添加密钥接口提前保存好，注意是以BASE64格式保存

表 11-178 Secret

参数	参数类型	描述
key	String	以英文字母和中划线开头，由英文字母、数字、点号、中划线和下划线组成，长度1-63位
name	String	以英文小写字母开头，由中文字符，英文字母，数字，下划线和中划线组成，不能以中划线结尾，长度4-64位

表 11-179 RouteDto

参数	参数类型	描述
path_type	String	路径匹配模式
port	Integer	服务访问端口
service_name	String	服务名称，只允许英文小写字母、数字、中划线，最大长度64，英文小写字母开头，数字或小写字母结尾

参数	参数类型	描述
uri	String	用来检验负载均衡路径，规则：以/开头，只允许字母、数字、下划线、中划线、斜杆、*号，长度不超过255
deployment_name	String	单节点创建负载均衡的时候，节点部署的名称，只允许英文小写字母、数字、中划线，最大长度32，英文小写字母或数字开头和结尾
backend_uri	String	重写后的后端路径。规则：以/开头，只允许字母、数字、下划线、中划线、/、\$和括号，长度不超过255

请求示例

- 更新负载均衡

```
PUT https://{endpoints}/v1/{project_id}/services/edge/loadbalancers/hilens-d460b283d50f44d3879200ef93c8af82
```

```
Request Header: Content-Type: application/jsonX-Auth-Token:
MIINRwYJKoZIhvcNAQcCoIINODCCDTQCAQExDTALBgIghkgBZQMEAgEwguVBgkqhkiG...Request
Body:{ "name": "loadbalancer-example", "description": "负载均衡样例", "apig_port": "8091",
"lb_algorithm": "ROUND_ROBIN", "session_affinity_mode": "SOURCE_IP", "scheme": "HTTP",
"routes": [ { "path_type": "PREFIX", "uri": "/abc", "service_name": "service-example1",
"port": "1222" } ] }
```

- 负载均衡更新为HTTPS策略

```
PUT https://{endpoints}/v1/{project_id}/services/edge/loadbalancers/{loadbalancer_id}
```

```
Request Header: Content-Type: application/jsonX-Auth-Token:
MIINRwYJKoZIhvcNAQcCoIINODCCDTQCAQExDTALBgIghkgBZQMEAgEwguVBgkqhkiG...Request
Body:{ "name": "loadbalancer-example", "description": "负载均衡样例", "apig_port": "8091",
"lb_algorithm": "ROUND_ROBIN", "session_affinity_mode": "SOURCE_IP", "scheme": "HTTPS",
"secrets": { "cert": { "key": "cert", "name": "loadbalancer_cert_005" }, "key": { "key":
"key", "name": "loadbalancer_cert_005" }, "ca": { "key": "ca", "name":
"loadbalancer_cert_005" } }, "routes": [ { "path_type": "PREFIX", "uri": "/abc",
"service_name": "service-example1", "port": "1222" } ] }
```

响应示例

状态码： 200

请求成功

```
{
  "cluster_name": "hilens-208",
  "apig_port": 8091,
  "reason": null,
  "scheme": "HTTP",
  "description": "负载均衡样例",
  "lb_algorithm": "ROUND_ROBIN",
  "created_at": "2022-04-14 19:37:41 GMT+08:00",
  "apig_net_seg": null,
  "secrets": null,
  "routes": [ {
    "port": 1222,
    "loadbalancer_id": "hilens-d460b283d50f44d3879200ef93c8af82",
    "service_name": "service-example1",
    "service_id": "hilens-a5db88ae11a34136bf4533d08032ca27",
    "path_type": "PREFIX",
```

```
{
  "id": "8abfafa58025c82e018027dd6345006a",
  "uri": "/abc"
}],
"cluster_id": "hilens-6fc07ac7a0034504b7a9895ebb4cf7f9",
"updated_at": "2022-04-14 19:37:41 GMT+08:00",
"project_id": "fff47e1722f94c4e98531bae56821372",
"name": "loadbalancer-example",
"id": "hilens-d460b283d50f44d3879200ef93c8af82",
"session_affinity_mode": "SOURCE_IP",
"status": "UPDATING"
}
```

状态码

状态码	描述
200	请求成功
201	已创建
401	未授权
403	拒绝执行
404	请求资源没找到
500	服务器内部错误

错误码

请参见[错误码](#)。

11.3.5 删除负载均衡

功能介绍

删除指定ID的负载均衡。

URI

DELETE /v1/{project_id}/services/edge/loadbalancers/{loadbalancer_id}

表 11-180 路径参数

参数	是否必选	参数类型	描述
loadbalancer_id	是	String	负载均衡ID，可从 查询负载均衡列表 获取
project_id	是	String	资源空间ID。获取方法请参见获取资源空间ID和名称

表 11-181 Query 参数

参数	是否必选	参数类型	描述
force_delete	否	Boolean	是否强制删除负载均衡，true为强制删除，false为常规删除。强制删除的时候，将不需要等待端侧返回成功，直接删除数据
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

请求参数

表 11-182 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	租户Token。获取方法请参见 获取Token 。

响应参数

无

请求示例

删除指定的负载均衡

```
DELETE https://{endpoints}/v1/{project_id}/services/edge/loadbalancers/{loadbalancer_id}

Request Header: Content-Type: application/jsonX-Auth-Token:
MIINRwYJKoZihvcNAQcColINODCCDTQCAQExDTALBglghkgBZQMEAgEwggguVBgkqhkiG...
```

响应示例

状态码： 200

请求成功

```
""
```

状态码

状态码	描述
200	请求成功
204	无内容
401	未授权

状态码	描述
403	拒绝执行
500	服务器内部错误

错误码

请参见[错误码](#)。

11.4 访问端口

11.4.1 查询访问端口列表

功能介绍

根据查询条件查询用户边缘资源池部署下的访问端口列表。

URI

GET /v1/{project_id}/services/edge/accessport

表 11-183 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见获取资源空间ID和名称

表 11-184 Query 参数

参数	是否必选	参数类型	描述
offset	否	Integer	查询的起始位置，取值范围为非负整数，默认为0
limit	否	Integer	每页显示的条目数量，取值范围1~100，默认为100，超过100时也只能返回100条
name	否	String	访问端口名称，只允许英文小写字母、数字、中划线，长度2-63，英文小写字母开头，数字或小写字母结尾

参数	是否必选	参数类型	描述
app	否	String	边缘服务名称，模糊匹配，只允许英文小写字母、数字、中划线，长度2-32，英文小写字母或数字开头和结尾
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

请求参数

表 11-185 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	租户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 11-186 响应 Body 参数

参数	参数类型	描述
count	Integer	满足条件的总数
services	Array of ServiceReqDetail objects	访问端口列表

表 11-187 ServiceReqDetail

参数	参数类型	描述
id	Object	访问端口id
created_at	Object	创建时间
cause	Object	失败原因
status	Object	状态，分别为创建中（CREATING）、创建失败（CREATE_FAILED）、更新中（UPDATE_FAILED）、删除中（DELETING）、删除失败（DELETE_FAILED）、运行中（RUNNING）

参数	参数类型	描述
meta_data	SvcMetadata object	访问端口的静态属性
spec	SvcSpec object	访问端口的动态属性

表 11-188 SvcMetadata

参数	参数类型	描述
name	String	访问端口名称，只允许英文小写字母、数字、中划线，长度2-63，英文小写字母或数字开头和结尾

表 11-189 SvcSpec

参数	参数类型	描述
cluster_ip	String	虚拟服务IP地址。采用控制节点的IP作为对外服务IP列表
ports	Array of SvcPort objects	服务支持的端口列表
selector	Object	Map<String,String>类型，指定一个应用部署
type	String	访问端口的类型。仅支持ClusterIP类型

表 11-190 SvcPort

参数	参数类型	描述
node_port	String	当spec.type=NodePort时，指定映射到物理机的端口号
port	String	服务侦听的端口号
protocol	String	网络协议，目前仅支持TCP
target_port	String	需要转发到后端Pod的端口号

请求示例

查询服务列表

```
GET https://{endpoint}/v1/{project_id}/services/edge/accessport
```

Request Header: Content-Type: application/jsonX-Auth-Token:
MIINRwYJKoZlHvcNAQcColINODCCDTQCAQExDTALBglghkgBZQMEAgEwgguVBgkqhkiG...

响应示例

状态码： 200

请求成功

```
{
  "count" : 1,
  "services" : [ {
    "updated_at" : "2022-05-25 14:47:06 GMT+08:00",
    "meta_data" : {
      "name" : "test1",
      "tags" : { }
    },
    "cause": null,
    "status": "RUNNING",
    "created_at" : "2022-05-25 14:47:06 GMT+08:00",
    "id" : "hilens-f47c0b06c335479e8df13df4e5323e21",
    "spec" : {
      "selector" : {
        "app" : "hilens-test"
      },
      "type" : "ClusterIP",
      "ports" : [ {
        "target_port" : "55555",
        "protocol" : "TCP",
        "port" : "55555",
        "name" : "a2d42daa81c8490cb54ac4032d1d3e60",
        "node_port" : null
      } ],
      "cluster_ip" : null
    }
  } ]
}
```

状态码

状态码	描述
200	请求成功
401	认证不通过
403	拒绝执行请求
404	请求的资源不存在
500	服务器内部错误

错误码

请参见[错误码](#)。

11.4.2 添加访问端口

功能介绍

创建一个访问端口。同一个边缘服务最多支持添加10个访问端口。

URI

POST /v1/{project_id}/services/edge/accessport

表 11-191 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见获取资源空间ID和名称

请求参数

表 11-192 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	租户Token。获取方法请参见 获取Token

表 11-193 请求 Body 参数

参数	是否必选	参数类型	描述
service	是	ADDorUpdateServiceReqDetail object	更新访问端口请求体
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

表 11-194 ADDorUpdateServiceReqDetail

参数	是否必选	参数类型	描述
meta_data	否	SvcMetadata object	访问端口的静态属性
spec	否	SvcSpec object	访问端口的动态属性

表 11-195 SvcMetadata

参数	是否必选	参数类型	描述
name	是	String	访问端口名称，只允许英文小写字母、数字、中划线，长度 2-63，英文小写字母或数字开头和结尾

表 11-196 SvcSpec

参数	是否必选	参数类型	描述
cluster_ip	否	String	虚拟服务IP地址。采用控制节点的IP作为对外服务IP列表。
ports	是	Array of SvcPort objects	服务支持的端口列表
selector	是	Object	Map<String,String>类型，指定一个应用部署
type	是	String	访问端口的类型。仅支持 ClusterIP类型

表 11-197 SvcPort

参数	是否必选	参数类型	描述
node_port	否	String	当spec.type=NodePort时，指定映射到物理机的端口号
port	否	String	服务侦听的端口号
protocol	否	String	网络协议，目前仅支持TCP
target_port	否	String	需要转发到后端Pod的端口号

响应参数

无

请求示例

创建服务

```
POST https://{endpoint}/v1/{project_id}/services/edge/accessport

Request Header: Content-Type: application/jsonX-Auth-Token:
MIINRwYJKoZlHvcNAQcColINODCCDTQCAQExDTALBglghkgBZQMEAgEwgguVBgkqhkiG...Request Body:
{ "service": { "meta_data": { "name": "fff47e1722f" }, "spec": { "ports":
```

```
[ { "protocol": "TCP", "port": "222", "target_port": "655" }, { "protocol": "UDP", "port": "222", "target_port": "655" } ], "type": "ClusterIP", "selector": { "app": "test-208-001" } }
```

响应示例

无

状态码

状态码	描述
200	请求成功
201	创建成功
401	认证不通过
403	拒绝执行请求
404	请求的资源不存在
500	服务器内部错误

错误码

请参见[错误码](#)。

11.4.3 查询访问端口详情

功能介绍

查询一个访问端口的详情。

URI

GET /v1/{project_id}/services/edge/accessport/{accessport_id}

表 11-198 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称
accessport_id	是	String	访问端口ID，从接口API 查询访问端口列表 获取

请求参数

表 11-199 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	租户Token。获取方法请参见 获取Token

响应参数

无

请求示例

查询一个访问端口的详情

```
GET https://{endpoint}/v1/{project_id}/services/edge/accessport/{accessport_id}

Request Header: Content-Type: application/jsonX-Auth-Token:
MIINRwYJKoZlhvcNAQcColINODCCDTQCAQExDTALBgIghkgBZQMEAgEwgguVBgkqhkiG...
```

响应示例

状态码： 200

请求成功

```
{
  "service": {
    "updated_at": "2022-05-25 14:47:06 GMT+08:00",
    "meta_data": {
      "name": "test1",
      "tags": { }
    },
  },
  "cause": null,
  "status": "RUNNING",
  "created_at": "2022-05-25 14:47:06 GMT+08:00",
  "id": "hilens-f47c0b06c335479e8df13df4e5323e21",
  "spec": {
    "selector": {
      "app": "hilens-test"
    },
    "type": "ClusterIP",
    "ports": [ {
      "target_port": "55555",
      "protocol": "TCP",
      "port": "55555",
      "name": "a2d42daa81c8490cb54ac4032d1d3e60",
      "node_port": null
    } ],
    "cluster_ip": null
  }
}
```

状态码

状态码	描述
200	请求成功
401	认证不通过
403	拒绝执行请求
404	请求的资源不存在
500	服务器内部错误

错误码

请参见[错误码](#)。

11.4.4 更新访问端口

功能介绍

更新一个访问端口。

URI

PUT /v1/{project_id}/services/edge/accessport/{accessport_id}

表 11-200 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称
accessport_id	是	String	访问端口ID，从接口API查询访问端口列表获取

请求参数

表 11-201 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	租户Token。获取方法请参见 获取Token

表 11-202 请求 Body 参数

参数	是否必选	参数类型	描述
service	是	ADDorUpdateServiceReqDetail object	更新访问端口请求体
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

表 11-203 ADDorUpdateServiceReqDetail

参数	是否必选	参数类型	描述
meta_data	否	SvcMetadata object	访问端口的静态属性
spec	否	SvcSpec object	访问端口的动态属性

表 11-204 SvcMetadata

参数	是否必选	参数类型	描述
name	是	String	访问端口名称，只允许英文小写字母、数字、中划线，长度 2-63，英文小写字母或数字开头和结尾

表 11-205 SvcSpec

参数	是否必选	参数类型	描述
cluster_ip	否	String	虚拟服务IP地址。采用控制节点的IP作为对外服务IP列表。
ports	是	Array of SvcPort objects	服务支持的端口列表
selector	是	Object	Map<String,String>类型，指定一个应用部署
type	是	String	访问端口的类型。仅支持 ClusterIP类型

表 11-206 SvcPort

参数	是否必选	参数类型	描述
node_port	否	String	当spec.type=NodePort时，指定映射到物理机的端口号
port	否	String	服务侦听的端口号
protocol	否	String	网络协议，目前仅支持TCP
target_port	否	String	需要转发到后端Pod的端口号

响应参数

无

请求示例

更新一个访问端口

```
PUT https://{endpoint}/v1/{project_id}/services/edge/accessport/{accessport_id}

Request Header: Content-Type: application/jsonX-Auth-Token:
MIINRwYJKoZlhvcNAQcCoIIODCCDTQCAQExDTALBglghkgBZQMEAgEwgguVBgkqhkiG...Request Body:
{ "service": { "meta_data": { "name": "test0930-sctp" }, "spec": { "ports":
[ { "protocol": "TCP", "port": "1442", "target_port": "1444" }, ], "type":
"ClusterIP", "selector": { "app": "studio-manager" } } }
```

响应示例

无

状态码

状态码	描述
200	请求成功
201	创建成功
401	认证不通过
403	拒绝执行请求
404	请求的资源不存在
500	服务器内部错误

错误码

请参见[错误码](#)。

11.4.5 删除访问端口

功能介绍

删除一个访问端口。

URI

DELETE /v1/{project_id}/services/edge/accessport/{accessport_id}

表 11-207 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见获取资源空间ID和名称。
accessport_id	是	String	访问端口ID，从接口API查询访问端口列表获取。

请求参数

表 11-208 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	租户Token。获取方法请参见 获取Token

表 11-209 查询参数

参数	是否必选	参数类型	描述
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

响应参数

无

请求示例

删除一个服务

```
DELETE https://{endpoint}/v1/{project_id}/services/edge/accessport/{accessport_id}
```

Request Header: Content-Type: application/jsonX-Auth-Token:
MIINRwYJKoZihvcNAQcColINODCCDTQCAQExDTALBgIghkgBZQMEAgEwgguVBGkqhkiG...

响应示例

无

状态码

状态码	描述
200	请求成功
204	删除成功
401	认证不通过
403	拒绝执行请求
404	请求的资源不存在
500	服务器内部错误

错误码

请参见[错误码](#)。

12 密钥管理

12.1 创建密钥

功能介绍

该接口用于创建密钥。

URI

POST /v1/{project_id}/services/secrets

表 12-1 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID。

请求参数

表 12-2 请求 header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 12-3 请求 body

参数	参数类型	描述
secret	SecretInfo Object	密钥信息。

表 12-4 SecretInfo Object

参数	参数类型	描述
id	String	密钥ID。
name	String	密钥名称，以英文小写字母开头，由中文字符，英文字母，数字，下划线和中划线组成，不能以中划线结尾，长度4-64位。
description	String	密钥描述，不允许~#\$%^&*<>()[]{}'"\，长度0-255位。
project_id	String	密钥创建者的资源空间ID。
create_time	String	密钥创建时间。
update_time	String	密钥更新时间。
secrets	Array of 表5 Secret	密钥信息列表，最多可添加20对
workspace_id	String	工作空间ID，不填为主账号/子账号的默认工作空间

表 12-5 Secret

参数	参数类型	描述
key	String	密钥键，以英文字母和中划线开头，由英文字母、数字、点号、中划线和下划线组成，长度1-63位。
value	String	密钥值，不允许#\$%^&()[]{}<>\\'`及中文字符，长度1到10000个字符。

 说明

密钥管理创建密钥时，会对密钥的value进行加密存入数据库，在页面展示时，会使用"*"来屏蔽密钥的具体信息。挂载到服务，会将密钥从数据库中读出，进行解密，再将解密后的密钥挂载到服务中。

为确保您的数据安全，用户需要对自身的敏感信息自行加密后进行密钥创建。

响应参数

状态码： 200

表 12-6 响应 Body 参数

参数	参数类型	描述
secret	SecretInfo Object	密钥信息

表 12-7 SecretInfo Object

参数	参数类型	描述
id	String	密钥ID。
name	String	密钥名称，以英文小写字母开头，由中文字符，英文字母，数字，下划线和中划线组成，不能以中划线结尾，长度4-64位。
description	String	密钥描述，不允许~#\$%^&*<>()[]{}'\，长度0-255位。
project_id	String	密钥创建者的资源空间ID。
create_time	String	密钥创建时间。
update_time	String	密钥更新时间。
secrets	Array of 表8 Secret	密钥信息列表，最多可添加20对

表 12-8 Secret

参数	参数类型	描述
key	String	密钥键，以英文字母和中划线开头，由英文字母、数字、点号、中划线和下划线组成，长度1-63位。
value	String	密钥值，不允许#\$%^&()[]{}<> '及中文字符，长度1到10000个字符。

状态码： 400

表 12-9 返回体

参数	参数类型	描述
error_code	String	密钥内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

请求示例

无

响应示例

状态码： 200

创建密钥成功。

```
{
  "secret": {
    "id": "ma-40d2ef28-f099-4fe2-9c47-6c9cfb275800",
    "name": "secret-test-3",
    "description": "test",
    "project_id": "827fa1abf4d6449da082dc9acadc228f",
    "create_time": "2024-08-26 16:27:46 GMT+08:00",
    "update_time": "2024-08-26 16:27:46 GMT+08:00",
    "secrets": [
      {
        "key": "test-3",
        "value": "*****"
      }
    ]
  }
}
```

状态码： 400

请求不合法

```
{
  "error_code" : "ModelArts.4007",
  "error_msg" : "create service secrets failed."
}
```

状态码

状态码	描述
200	创建密钥成功。
400	请求不合法。

错误码

请参见[错误码](#)。

12.2 获取密钥列表

功能介绍

该接口用于获取密钥列表。

URI

GET /v1/{project_id}/services/secrets

表 12-10 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID。

表 12-11 Query 参数

参数	是否必选	参数类型	描述
name	否	String	密钥的名称，支持模糊匹配。
sort	否	String	展示密钥列表时的排序规则，分别为asc（升序），desc（降序） 缺省值：desc 枚举值： - asc - desc
order	否	String	展示密钥列表时的排序字段，分别为createTime（按创建时间排序），updateTime（按更新时间排序） 缺省值：createTime
offset	否	Integer	首个展示的密钥的偏移量。 最小值：0 最大值：65535 缺省值：0
limit	否	Integer	展示密钥的数量。 最小值：1 最大值：65535 缺省值：100

参数	是否必选	参数类型	描述
workspace_id	否	String	工作空间ID，不填为主账号/子账号的默认工作空间

请求参数

表 12-12 请求 header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 12-13 响应 Body 参数

参数	参数类型	描述
count	Long	符合检索条件的总条目数。
secrets	Array of SecretInfo objects	检索到的secret条目。

表 12-14 SecretInfo Object

参数	参数类型	描述
id	String	密钥ID。
name	String	密钥名称，以英文小写字母开头，由中文字符，英文字母，数字，下划线和中划线组成，不能以中划线结尾，长度4-64位。
description	String	密钥描述，不允许~#\$%^&*<>()[]{}'\，长度0-255位。
project_id	String	密钥创建者的资源空间ID。
create_time	String	密钥创建时间。
update_time	String	密钥更新时间。

参数	参数类型	描述
secrets	Array of 表6 Secret	密钥信息列表，最多可添加20对

表 12-15 Secret

参数	参数类型	描述
key	String	密钥键，以英文字母和中划线开头，由英文字母、数字、点号、中划线和下划线组成，长度1-63位。
value	String	密钥值，不允许#\$%^&()[]{}<>\\ '及中文字符，长度1到10000个字符。

状态码： 400

表 12-16 响应 Body 参数

参数	参数类型	描述
error_code	String	密钥内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

请求示例

无

响应示例

状态码： 200

获取密钥列表成功。

```
{
  "count": 1,
  "secrets": [
    {
      "id": "ma-6927ca9f-2584-4172-967b-a10a7a9f599c",
      "name": "secret-test-2",
      "description": "test",
      "project_id": "827fa1abf4d6449da082dc9acadc228f",
      "create_time": "2024-08-26 16:08:27 GMT+08:00",
      "update_time": "2024-08-26 16:08:27 GMT+08:00",
      "secrets": [
        {
          "key": "test-2",
```

```
      "value": "*****"
    }
  ]
}
```

状态码： 400

请求不合法

```
{
  "error_code" : "ModelArts.4007",
  "error_msg" : "get service secrets failed."
}
```

状态码

状态码	描述
200	获取密钥列表成功。
400	请求不合法

错误码

请参见[错误码](#)。

12.3 获取密钥详情

功能介绍

该接口用于获取密钥详情。

URI

GET /v1/{project_id}/services/secrets/{secret_id}

表 12-17 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID。
secret_id	是	String	密钥ID。

请求参数

表 12-18 请求 header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 12-19 响应 Body 参数

参数	参数类型	描述
secret	SecretInfo Object	密钥信息

表 12-20 SecretInfo Object

参数	参数类型	描述
id	String	密钥ID。
name	String	密钥名称，以英文小写字母开头，由中文字符，英文字母，数字，下划线和中划线组成，不能以中划线结尾，长度4-64位。
description	String	密钥描述，不允许~#\$%^&*<>()[]{}'\，长度0-255位。
project_id	String	密钥创建者的资源空间ID。
create_time	String	密钥创建时间。
update_time	String	密钥更新时间。
secrets	Array of 表5 Secret	密钥信息列表，最多可添加20对

表 12-21 Secret

参数	参数类型	描述
key	String	密钥键，以英文字母和中划线开头，由英文字母、数字、点号、中划线和下划线组成，长度1-63位。

参数	参数类型	描述
value	String	密钥值，不允许#\$%^&()[]{}<>\\ '`及中文字符，长度1到10000个字符。

状态码： 400

表 12-22 响应参数

参数	参数类型	描述
error_code	String	密钥内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

状态码： 404

表 12-23 响应 Body 参数

参数	参数类型	描述
error_code	String	密钥内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

请求示例

无

响应示例

状态码： 200

获取密钥信息成功。

```
{
  "secret": {
    "id": "ma-6927ca9f-2584-4172-967b-a10a7a9f599c",
    "name": "secret-test-2",
    "description": "test",
    "project_id": "827fa1abf4d6449da082dc9acadc228f",
    "create_time": "2024-08-26 16:08:27 GMT+08:00",
    "update_time": "2024-08-26 16:08:27 GMT+08:00",
    "secrets": [
      {
        "key": "test-2",
```

```
      "value": "*****"
    }
  ]
}
```

状态码： 400

请求不合法。

```
{
  "error_code" : "ModelArts.4007",
  "error_msg" : "get services secrets list failed."
}
```

状态码

状态码	描述
200	获取密钥信息成功。
400	请求不合法。

错误码

请参见[错误码](#)。

12.4 更新密钥

功能介绍

更新密钥信息。

URI

PUT /v1/{project_id}/services/secrets/{secret_id}

表 12-24 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID。
secret_id	是	String	指定的密钥ID。

请求参数

表 12-25 请求 body

参数	参数类型	描述
secret	SecretsObject	密钥具体信息。

表 12-26 SecretsObject

参数	参数类型	描述
description	string	密钥描述，不允许~#\$%^&*(<>[]{}'"\，长度0-255位。
secrets	array of secret	密钥对。
workspace_id	string	工作空间ID，不填为主账号/子账号的默认工作空间。

表 12-27 Secret

参数	参数类型	描述
key	String	密钥键，以英文字母和中划线开头，由英文字母、数字、点号、中划线和下划线组成，长度1-63位。
value	String	密钥值，不允许#\$%^&()[]{}<>\\ '`及中文字符，长度1到10000个字符。

响应参数

状态码： 200

表 12-28 响应 Body 参数

参数	参数类型	描述
secret	SecretInfo Object	密钥信息

表 12-29 SecretInfo Object

参数	参数类型	描述
id	String	密钥ID。

参数	参数类型	描述
name	String	密钥名称，以英文小写字母开头，由中文字符，英文字母，数字，下划线和中划线组成，不能以中划线结尾，长度4-64位。
description	String	密钥描述，不允许~#\$\$%^&*<>()[]{}`\，长度0-255位。
project_id	String	密钥创建者的资源空间ID。
create_time	String	密钥创建时间。
update_time	String	密钥更新时间。
secrets	Array of 表7 Secret	密钥信息列表，最多可添加20对

状态码： 400

表 12-30 响应 Body 参数

参数	参数类型	描述
error_code	String	密钥内部错误码。
error_msg	String	错误信息。

请求示例

更新密钥成功。

```
{
  "secret": {
    "id": "ma-40d2ef28-f099-4fe2-9c47-6c9cfb275800",
    "name": "secret-test-3",
    "description": "test333",
    "project_id": "827fa1abf4d6449da082dc9acadc228f",
    "create_time": "2024-08-26 16:27:46 GMT+08:00",
    "update_time": "2024-08-26 16:28:15 GMT+08:00",
    "secrets": [
      {
        "key": "test-3",
        "value": "*****"
      }
    ]
  }
}
```

响应示例

状态码： 200

更新密钥成功。

```
{
  "secret": {
```

```
{
  "id": "ma-40d2ef28-f099-4fe2-9c47-6c9cfb275800",
  "name": "secret-test-3",
  "description": "test333",
  "project_id": "827fa1abf4d6449da082dc9acadc228f",
  "create_time": "2024-08-26 16:27:46 GMT+08:00",
  "update_time": "2024-08-26 16:28:15 GMT+08:00",
  "secrets": [
    {
      "key": "test-3",
      "value": "*****"
    }
  ]
}
```

状态码： 400

请求不合法。

```
{
  "error_code": "ModelArts.4007",
  "error_msg": "update services secrets failed."
}
```

状态码

状态码	描述
201	修改密钥成功。
400	请求不合法。

错误码

请参见[错误码](#)。

12.5 删除密钥

功能介绍

该接口用于删除密钥。

URI

DELETE /v1/{project_id}/services/secrets/{secret_id}

表 12-31 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID。
secret_id	是	String	指定的密钥ID。

请求参数

表1 请求header参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 400

表 12-32 响应 Body 参数

参数	参数类型	描述
error_code	String	密钥内部错误码。
error_msg	String	错误信息。 最小长度：0 最大长度：4096

请求示例

无

响应示例

状态码： 400

请求不合法。

```
{
  "error_code" : "ModelArts.4007",
  "error_msg" : "delete services secrets failed."
}
```

状态码

状态码	描述
204	删除密钥成功。
400	请求不合法。

错误码

请参见[错误码](#)。

13 工作空间管理

13.1 查询工作空间详情

功能介绍

查询工作空间详情。

URI

GET /v1/{project_id}/workspaces/{workspace_id}

表 13-1 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。
workspace_id	是	String	工作空间ID。获取方法请参见 查询工作空间列表 。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。

请求参数

表 13-2 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 13-3 响应 Body 参数

参数	参数类型	描述
grants	Array of grants objects	授权用户列表。默认为空。需要与“auth_type”参数配合使用，且仅当授权类型为“INTERNAL”时才会生效。
owner	String	创建者名称。
auth_type	String	授权类型。可选值有PUBLIC、PRIVATE、INTERNAL。默认值为PUBLIC。 • PUBLIC：租户内部公开访问。 • PRIVATE：仅创建者和主账号可访问。 • INTERNAL：创建者、主账号、指定IAM子账号可访问，需要与grants参数配合使用。
enterprise_project_id	String	企业项目ID。
update_time	Integer	最后修改时间，UTC。
create_time	Integer	创建时间，UTC。
enterprise_project_name	String	企业项目名称。
name	String	工作空间名称。长度限制为4-64字符，支持中文、大小写字母、数字、中划线和下划线。同时'default'为系统预留的默认工作空间名称，用户无法自己创建名为'default'的工作空间。
description	String	工作空间描述，默认为空。长度限制为0-256字符。
id	String	工作空间ID，系统生成的32位UUID，不带横线。
status	String	工作空间状态。 • CREATE_FAILED：创建失败。 • NORMAL：状态正常。 • DELETING：正在删除。 • DELETE_FAILED：删除失败。
status_info	String	状态描述，默认为空。该字段会补充显示状态的详细信息。如删除失败时，可通过该字段查看删除失败的原因。

表 13-4 grants

参数	参数类型	描述
user_id	String	IAM用户ID。此参数与user_name必填一个。两者都填优先使用user_id。
user_name	String	IAM用户名称。此参数与user_id必填一个。
lock	boolean	是否锁定，第三方可以设置锁定委托，锁定后不能移除。
user_type	string	用户类型。 IAM：子用户 AGENCY：委托用户

请求示例

```
GET https://{endpoint}/v1/{project_id}/workspaces/ccd05d1a553b4e188ea878e7dcb85e47
```

响应示例

状态码： 200

查询工作空间详情成功的响应参数。

```
{
  "id": "ccd05d1a553b4e188ea878e7dcb85e47",
  "name": "test-workspace",
  "status": "NORMAL",
  "status_info": "",
  "description": "",
  "owner": "testUser",
  "create_time": 1470000020000,
  "update_time": 1470000030000,
  "enterprise_project_id": "****b0091-887f-4839-9929-cbc884f1e****",
  "enterprise_project_name": "test-eps",
  "auth_type": "INTERNAL",
  "grants": [ {
    "user_id": "***55d2cd53b4x458ea878e7dcb85****",
    "user_name": "test-iam-user"
  } ]
}
```

状态码

状态码	描述
200	查询工作空间详情成功的响应参数。
400	BadRequest
403	Forbidden
500	InternalServerError

错误码

请参见[错误码](#)。

13.2 修改工作空间

功能介绍

修改工作空间。

URI

PUT /v1/{project_id}/workspaces/{workspace_id}

表 13-5 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见 获取资源空间ID和名称 。
workspace_id	是	String	工作空间ID。获取方法请参见 查询工作空间列表 。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。

请求参数

表 13-6 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 13-7 请求 Body 参数

参数	是否必选	参数类型	描述
grants	否	Array of grants objects	训练作业使用的数据集。不可与 data_url或dataset_id/dataset_version_id同时使用。

参数	是否必选	参数类型	描述
auth_type	是	String	授权类型。可选值有PUBLIC、PRIVATE、INTERNAL。默认值为PUBLIC。 • PUBLIC：租户内部公开访问。 • PRIVATE：仅创建者和主账号可访问。 • INTERNAL：创建者、主账号、指定子账号可访问，需要与grants参数配合使用。
enterprise_project_id	是	String	企业项目ID。
name	否	String	工作空间名称。长度限制为4-64字符，支持中文、大小写字母、数字、中划线和下划线。同时'default'为系统预留的默认工作空间名称，用户无法自己创建名为'default'的工作空间。
description	否	String	工作空间描述，默认为空。长度限制为0-256字符。

表 13-8 grants

参数	是否必选	参数类型	描述
user_id	是	String	IAM子用户场景填用户ID，委托场景填委托ID。
user_name	是	String	IAM子用户场景是用户名称，委托场景是委托的名称。前端的名称显示是根据该参数显示的。

响应参数

状态码： 200

表 13-9 响应 Body 参数

参数	参数类型	描述
workspace_id	String	工作空间ID。

请求示例

```
PUT https://{endpoint}/v1/{project_id}/workspaces/ccd05d1a553b4e188ea878e7dcb85e47
{
  "name" : "my_workspace",
  "description" : "It is my workspace",
  "auth_type" : "INTERNAL",
  "grants" : [ {
    "user_name" : "my_iam_user",
    "user_type": "IAM"
  } ]
}
```

响应示例

状态码： 200

修改工作空间成功的响应参数。

```
{
  "workspace_id" : "ccd05d1a553b4e188ea878e7dcb85e47"
}
```

状态码

状态码	描述
200	修改工作空间成功的响应参数。

错误码

请参见[错误码](#)。

13.3 删除工作空间

功能介绍

删除工作空间。

URI

DELETE /v1/{project_id}/workspaces/{workspace_id}

表 13-10 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID。获取方法请参见获取资源空间ID和名称。

参数	是否必选	参数类型	描述
workspace_id	是	String	工作空间ID。获取方法请参见 查询工作空间列表 。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。

请求参数

表 13-11 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 13-12 响应 Body 参数

参数	参数类型	描述
workspace_id	String	工作空间ID。获取方法请参见 查询工作空间列表 。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。

请求示例

```
DELETE https://{endpoint}/v1/{project_id}/workspaces/ccd05d1a553b4e188ea878e7dcb85e47
```

响应示例

状态码： 200

删除工作空间成功的响应参数。

```
{
  "workspace_id": "ccd05d1a553b4e188ea878e7dcb85e47"
}
```

状态码

状态码	描述
200	删除工作空间成功的响应参数。

错误码

请参见[错误码](#)。

13.4 查询工作空间配额

功能介绍

查询工作空间配额。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/quotas

表 13-13 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
workspace_id	是	String	工作空间ID。获取方法请参见 查询工作空间列表 。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。

请求参数

表 13-14 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 13-15 响应 Body 参数

参数	参数类型	描述
quotas	Array of WorkspaceQuotasResponse objects	工作空间配额数据。

表 13-16 WorkspaceQuotasResponse

参数	参数类型	描述
max_quota	Integer	配额允许设置的最大值。
update_time	Integer	最后修改时间，UTC。如用户未修改过该资源配额,则该值默认为该工作空间的创建时间。
resource	String	资源的唯一标识。
quota	Integer	当前配额值。配额值为-1代表不限制配额。
min_quota	Integer	配额允许设置的最小值。
name_cn	String	配额名称(中文)。
unit_cn	String	数量单位(中文)。
name_en	String	工作空间ID，系统生成的32位UUID，不带横线。默认的工作空间id为'0'。
unit_en	String	数量单位(英文)。
used_quota	Integer	已用配额值。当quota为-1（不限制配额）时，used_quota为null。

请求示例

GET https://{endpoint}/v1/{project_id}/workspaces/ccd05d1a553b4e188ea878e7dcb85e47/quotas

响应示例

状态码： 200

查询工作空间配额成功的响应参数。

```
{
  "quotas": [ {
    "max_quota": 60000,
    "update_time": 1470000020000,
    "resource": "exemlProject.gpu_duration",
    "used_quota": 5,
    "quota": 10,
    "min_quota": -1,
    "name_cn": "自动学习（图像分类、物体检测、声音分类）训练时长",
    "unit_cn": "分钟",
    "name_en": "ExeMLtraining duration (image classification, object detection, and soundclassification)",
    "unit_en": "minute"
  } ]
}
```

状态码

状态码	描述
200	查询工作空间配额成功的响应参数。

错误码

请参见[错误码](#)。

13.5 修改工作空间配额

功能介绍

修改工作空间配额。

URI

PUT /v1/{project_id}/workspaces/{workspace_id}/quotas

表 13-17 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见 获取资源空间ID和名称 。
workspace_id	是	String	工作空间ID。获取方法请参见 查询工作空间列表 。未创建工作空间时默认值为“0”，存在创建并使用的工作空间，以实际取值为准。

请求参数

表 13-18 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

表 13-19 请求 Body 参数

参数	是否必选	参数类型	描述
quotas	是	Array of quotas objects	工作空间配额数据。

表 13-20 quotas

参数	是否必选	参数类型	描述
resource	是	String	资源标识。
quota	是	Integer	要修改的配额值。配额值为正整数或-1，-1代表不限制配额。配额值范围不能超过配额的最大值与最小值。可通过调用查询工作空间配额接口查询配额的最大值。

响应参数

状态码： 200

表 13-21 响应 Body 参数

参数	参数类型	描述
quotas	Array of WorkspaceQuotasUpdateResponse objects	工作空间配额数据。

表 13-22 WorkspaceQuotasUpdateResponse

参数	参数类型	描述
max_quota	Integer	配额允许设置的最大值。
update_time	Integer	最后修改时间，UTC。如用户未修改过该资源配额,则该值默认为该工作空间的创建时间。
resource	String	资源的唯一标识。
quota	Integer	当前配额值。配额值为-1代表不限制配额。
min_quota	Integer	配额允许设置的最小值。
name_cn	String	配额名称（中文）。
unit_cn	String	数量单位（中文）。
name_en	String	工作空间ID，系统生成的32位UUID，不带横线。默认的工作空间id为'0'。
unit_en	String	数量单位(英文)。

请求示例

```
PUT https://{endpoint}/v1/{project_id}/workspaces/ccd05d1a553b4e188ea878e7dcb85e47/quotas
{
  "quotas": [ {
    "resource": "exeMLProject.gpu_duration",
    "quota": 10
  } ]
}
```

响应示例

状态码： 200

修改工作空间配额成功的响应参数。

```
{
  "quotas": [ {
    "max_quota": 60000,
    "update_time": 1574339372000,
    "resource": "exeMLProject.gpu_duration",
    "quota": 20,
    "min_quota": -1,
    "name_cn": "自动学习（图像分类、物体检测、声音分类）训练时长",
    "unit_cn": "分钟",
    "name_en": "ExeML training duration (image classification, object detection, and sound classification)",
    "unit_en": "minute"
  } ]
}
```

状态码

状态码	描述
200	修改工作空间配额成功的响应参数。

错误码

请参见[错误码](#)。

13.6 查询工作空间列表

功能介绍

查询工作空间列表，响应消息体中包含详细信息。

URI

GET /v1/{project_id}/workspaces

表 13-23 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见获取资源空间ID和名称。

表 13-24 Query 参数

参数	是否必选	参数类型	描述
offset	否	Integer	分页列表的起始页，默认为'0'。
limit	否	Integer	指定每一页返回的最大条目数，默认为'1000'。
sort_by	否	String	指定排序字段，可选'name'、'update_time'、'status'，默认是'name'。
order	否	String	可选值。'asc'为递增排序。'desc'为递减排序，默认为'desc'。
enterprise_project_id	否	String	企业项目id，指定此参数会只返回该企业项目id下的工作空间。默认显示所有工作空间。
name	否	String	工作空间名称查询参数，指定此参数会模糊查询该名称的工作空间。默认显示所有工作空间。
filter_accessible	否	Boolean	该参数用于筛选可访问的工作空间。指定该参数为true，则会筛选掉当前用户无权限访问的工作空间。该参数默认为false，即为显示所有工作空间。

请求参数

表 13-25 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参见 获取Token 。

响应参数

状态码： 200

表 13-26 响应 Body 参数

参数	参数类型	描述
total_count	Integer	工作空间的总数。
count	Integer	此次请求返回的工作空间个数。
workspaces	Array of WorkspaceResponse objects	workspace属性列表。

表 13-27 WorkspaceResponse

参数	参数类型	描述
owner	String	创建者名称。
auth_type	String	授权类型。默认值为PUBLIC。 • PUBLIC：租户内部公开访问。 • PRIVATE：仅创建者和主账号可访问。 • INTERNAL：创建者、主账号、指定IAM子账号可访问，需要与grants参数配合使用。
enterprise_project_id	String	企业项目ID。
update_time	Integer	最后修改时间，UTC。
create_time	Integer	创建时间，UTC。
enterprise_project_name	String	企业项目名称。
name	String	工作空间名称。
description	String	工作空间描述。
id	String	工作空间ID，系统生成的32位UUID，不带横线。默认的工作空间id为“0”。
status	String	工作空间状态。 • CREATE_FAILED：创建失败。 • NORMAL：状态正常。 • DELETING：正在删除。 • DELETE_FAILED：删除失败。
status_info	String	状态描述，默认为空。该字段会补充显示状态的详细信息。如删除失败时，可通过该字段查看删除失败的原因。

请求示例

```
GET https://{endpoint}/v1/{project_id}/workspaces?  
limit=2&offset=3&sort_by=name&order=desc&enterprise_project_id=0
```

响应示例

状态码： 200

查询工作空间列表成功的响应参数。

```
{  
  "total_count": 10,  
  "count": 1,  
  "workspaces": [ {  
    "id": 0,  
    "name": "default",  
    "description": "",  
    "owner": "testUser",  
    "enterprise_project_id": "****b0091-887f-4839-9929-cbc884f1e****",  
    "enterprise_project_name": "default",  
    "auth_type": "public",  
    "create_time": 1460000010000,  
    "update_time": 1460000010000,  
    "status": "NORMAL",  
    "status_info": ""  
  } ]  
}
```

状态码

状态码	描述
200	查询工作空间列表成功的响应参数。
400	BadRequest
403	Forbidden
500	InternalServerError

错误码

请参见[错误码](#)。

13.7 创建工作空间

功能介绍

创建工作空间（"default"为系统预留的默认工作空间名称，不能使用）。

URI

POST /v1/{project_id}/workspaces

表 13-28 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	资源空间ID。获取方法请参见获取资源空间ID和名称。

请求参数

表 13-29 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。获取方法请参考 获取Token 。

表 13-30 请求 Body 参数

参数	是否必选	参数类型	描述
grants	否	Array of grants objects	授权用户列表，默认为空。需要与“auth_type”参数配合使用，且仅当授权类型为“INTERNAL”时才会生效。
auth_type	是	String	授权类型。可选值有PUBLIC、PRIVATE、INTERNAL。默认值为PUBLIC。 • PUBLIC：租户内部公开访问。 • PRIVATE：仅创建者和主账号可访问。 • INTERNAL：创建者、主账号、指定子账号可访问，需要与grants参数配合使用。
enterprise_project_id	是	String	企业项目ID。
name	是	String	工作空间名称。长度限制为4-64字符，支持中文、大小写字母、数字、中划线和下划线。同时'default'为系统预留的默认工作空间名称，用户无法自己创建名为'default'的工作空间。
description	否	String	工作空间描述，默认为空。长度限制为0-256字符。

表 13-31 grants

参数	是否必选	参数类型	描述
user_id	是	String	IAM子用户场景填用户ID，委托场景填委托ID。
user_name	是	String	IAM子用户场景是用户名称，委托场景是委托的名称。前端的名称显示是根据该参数显示的。

响应参数

状态码： 200

表 13-32 响应 Body 参数

参数	参数类型	描述
owner	String	创建者名称。
auth_type	String	授权类型。默认值为PUBLIC。PUBLIC：租户内部公开访问。PRIVATE：仅创建者和主账号可访问。INTERNAL：创建者、主账号、指定IAM子账号可访问，需要与grants参数配合使用。
enterprise_project_id	String	企业项目ID。
update_time	Integer	最后修改时间，UTC。
create_time	Integer	创建时间，UTC。
enterprise_project_name	String	企业项目名称。
name	String	工作空间名称。
description	String	工作空间描述。
id	String	工作空间ID，系统生成的32位UUID，不带横线。
status	String	工作空间状态。 ● CREATE_FAILED：创建失败。 ● NORMAL：状态正常。 ● DELETING：正在删除。 ● DELETE_FAILED：删除失败。
status_info	String	状态描述，默认为空。该字段会补充显示状态的详细信息。如删除失败时，可通过该字段查看删除失败的原因。

参数	参数类型	描述
grants	Array of grants objects	授权用户列表。默认为空。需要与“auth_type”参数配合使用，且仅当授权类型为“INTERNAL”时才会生效。

表 13-33 grants

参数	参数类型	描述
user_id	String	用户ID,此参数与user_name必填一个。两者都填优先使用user_id。
user_name	String	IAM用户名称。此参数与user_id必填一个。

请求示例

创建工作空间。设置工作空间名称为“test-workspace”，授权类型为“internal”，授权的IAM用户名称为“test”。

```
POST https://{endpoint}/v1/{project_id}/workspaces
{
  "name" : "test-workspace",
  "description" : "It is a test project",
  "enterprise_project_id" : "****b0091-887f-4839-9929-cbc884f1e****",
  "auth_type" : "internal",
  "grants" : [{
    "user_name" : "test",
    "user_type": "IAM"
  }]
}
```

响应示例

状态码： 200

创建工作空间成功的响应参数。

```
{
  "id" : "****d05d1a553b4e188ea878e7dcb85e****",
  "name" : "test-workspace",
  "description" : "It is a test project",
  "owner" : "testUser",
  "create_time" : 1470000020000,
  "update_time" : 1470000030000,
  "enterprise_project_id" : "****b0091-887f-4839-9929-cbc884f1e****",
  "enterprise_project_name" : "test-eps",
  "auth_type" : "public",
  "status" : "NORMAL",
  "status_info" : ""
}
```

状态码

状态码	描述
200	创建工作空间成功的响应参数。
400	BadRequest
403	Forbidden
500	InternalServerError

错误码

请参见[错误码](#)。

14 授权管理

14.1 配置授权

功能介绍

配置ModelArts授权。若没有授权，ModelArts训练管理、在线服务等功能将不能正常使用。该API支持管理员给所有用户设置委托，支持设置当前用户的访问密钥。

URI

POST /v2/{project_id}/authorizations

表 14-1 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID，获取方法请参见获取资源空间ID。

请求参数

表 14-2 请求 Body 参数

参数	是否必选	参数类型	描述
user_id	否	String	用户ID，获取方法请参见 获取用户ID 。当user_id为all-users时，表示对所有用户进行授权，如果已有部分用户已授权，则更新授权。仅当授权类型为委托时，需要该字段。

参数	是否必选	参数类型	描述
type	是	String	授权类型。推荐使用委托方式。 可选值： - agency：委托 - credential：访问密钥（AK/SK） 缺省值： agency
content	是	String	授权内容。 - 当授权类型是委托，该字段为委托名称。 - 当授权类型是访问密钥，该字段为访问密钥ID（AK）。
secret_key	否	String	秘密访问密钥（SK）。仅当授权类型为访问密钥时，需要该字段。
user_name	否	String	用户名，当user_id为all-users时，为所有用户。

响应参数

无

请求示例

上传授权

```
POST https://{endpoint}/v2/{project_id}/authorizations
{
  "user_id": "****d80fb058844ae8b82aa66d9fe****",
  "type": "agency",
  "content": "modelarts_agency"
}
```

响应示例

状态码： 200

```
{
  "result": true,
  "serviceResults": [
    {
      "body": null,
      "serviceName": "Algorancher"
    },
    {
      "body": null,
      "serviceName": "Upredict"
    },
    {
      "body": null,
      "serviceName": "Exeml"
    }
  ]
}
```

```
    }  
  ]  
}
```

状态码

状态码	描述
200	OK
400	Bad Request
401	Unauthorized
403	Forbidden
404	Not Found

错误码

请参见[错误码](#)。

14.2 查看授权列表

功能介绍

查看授权列表。

URI

GET /v2/{project_id}/authorizations

表 14-3 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID，获取方法请参见获取资源空间ID。

表 14-4 Query 参数

参数	是否必选	参数类型	描述
sort_by	否	String	指定排序字段。 可选值： - user_name：用户名称 - create_time：创建时间 缺省值： user_name

参数	是否必选	参数类型	描述
order	否	String	排序方式。 可选值： - asc：递增排序 - desc：递减排序 缺省值： asc
limit	否	Integer	指定每一页返回的最大条目数，默认为1000。 取值范围[1，1000]。
offset	否	Integer	分页列表的起始页，默认为0。

请求参数

无

响应参数

状态码： 200

表 14-5 响应 Body 参数

参数	参数类型	描述
total_count	Number	授权信息总数。
auth	Array of AuthorizationResponse objects	授权信息列表。

表 14-6 AuthorizationResponse

参数	参数类型	描述
user_id	String	用户ID，获取方法请参见 获取用户ID 。当user_id为all-users时，表示对所有用户进行授权，如果已有部分用户已授权，则更新授权。仅当授权类型为委托时，需要该字段。
type	String	授权类型。推荐使用委托方式。 可选值： - agency：委托 - credential：访问密钥（AK/SK） 缺省值： agency

参数	参数类型	描述
content	String	授权内容。 - 当授权类型是委托，该字段为委托名称。 - 当授权类型是访问密钥，该字段为访问密钥ID（AK）。
secret_key	String	秘密访问密钥（SK）。仅当授权类型为访问密钥时，需要该字段。
user_name	String	用户名，当user_id为all-users时，为所有用户。
create_time	Long	创建时间戳。

请求示例

查看授权列表

GET https://{endpoint}/v2/{project_id}/authorizations

响应示例

状态码： 200

OK

```
{
  "total_count": 1,
  "auth": [{
    "user_id": "****d80fb058844ae8b82aa66d9fe****",
    "user_name": "iam-user01",
    "type": "agency",
    "content": "modelarts_agency",
    "create_time": 15657747821288
  }]
}
```

状态码

状态码	描述
200	OK
400	Bad Request
401	Unauthorized
403	Forbidden
404	Not Found

错误码

请参见[错误码](#)。

14.3 删除授权

功能介绍

删除指定用户的授权或者删除全量用户的授权。

URI

DELETE /v2/{project_id}/authorizations

表 14-7 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID，获取方法请参见获取资源空间ID。

表 14-8 Query 参数

参数	是否必选	参数类型	描述
user_id	是	String	用户ID。 - user_id为用户ID时，表示删除当前指定用户的授权。 - user_id为all，表示清空当前所有的授权。 - user_id为all-users，表示删除授权对象为所有用户的授权，不包含对单个子用户的授权。

请求参数

无

响应参数

无

请求示例

删除指定用户的授权

```
DELETE https://{endpoint}/v2/{project_id}/authorizations?user_id=****d80fb058844ae8b82aa66d9fe****
```

响应示例

状态码： 200

```
{
  "result": true,
  "serviceResults": [
    {
      "body": null,
      "serviceName": "Algorancher"
    },
    {
      "body": null,
      "serviceName": "Upredict"
    },
    {
      "body": null,
      "serviceName": "Exeml"
    }
  ]
}
```

状态码

状态码	描述
200	OK
400	Bad Request
401	Unauthorized
403	Forbidden
404	Not Found

错误码

请参见[错误码](#)。

14.4 创建 ModelArts 委托

功能介绍

创建包含OBS、SWR等依赖服务的ModelArts委托。

URI

POST /v2/{project_id}/agency

表 14-9 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	用户资源空间ID，获取方法请参见获取资源空间ID。

请求参数

表 14-10 请求 Body 参数

参数	是否必选	参数类型	描述
agency_name_suffix	否	String	委托名称后缀，包含大小写字母、汉字、数字、空格、下划线、中划线、英文逗号和句点，不能以句点开头；长度不大于54位。 委托名称前缀固定为ma_agency。 如该字段为iam-user01，则创建出来的委托名称为ma_agency_iam-user01。 默认为空，表示创建名称为modelarts_agency的委托。

响应参数

无

请求示例

创建ModelArts委托

```
POST https://{endpoint}/v2/{project_id}/agency
{
  "agency_name_suffix": "iam-user01"
}
```

响应示例

状态码： 200

OK

```
{
  "agency_name": "ma_agency_iam-user01"
}
```

状态码

状态码	描述
200	OK
400	Bad Request
401	Unauthorized
403	Forbidden
404	Not Found

错误码

请参见[错误码](#)。

15 应用示例

15.1 管理 ModelArts 服务的委托授权

本节通过调用一系列API，以管理ModelArts服务的委托授权为例介绍ModelArts API的使用流程。

概述

管理ModelArts服务的委托授权流程如下：

1. [获取用户的Token](#)，在后续的请求中需要将Token放到请求消息头中作为认证。
2. 调用[创建ModelArts委托](#)接口完成包含OBS、SWR、IEF等依赖服务的ModelArts委托。
3. 调用[配置授权](#)接口配置ModelArts授权。该接口支持管理员给用户设置委托，支持设置当前用户的访问密钥。

说明

若没有授权，ModelArts服务的模型训练、在线服务等功能将不能正常使用。

4. 调用[查看授权列表](#)接口查看用户的授权信息。
5. 在管理用户授权时，可以调用[删除授权](#)接口删除指定用户的授权或者删除全量用户的授权。

前提条件

- 已获取[ModelArts的终端节点EndPoint](#)。
- 确认服务的部署区域，[获取资源空间名称和ID](#)、[获取账号名和ID](#)和[获取用户名和ID](#)。

操作步骤

1. [获取用户的Token](#)。
2. 调用[创建ModelArts委托](#)接口完成包含OBS、SWR、IEF等依赖服务的ModelArts委托。
 - a. 请求消息体：

URI: POST https://{*endpoint*}/v2/{*project_id*}/agency

请求消息头:

- X-auth-Token →
***MIIZmgYJKoZlhvcNAQcCollZizCCGYcCAQExDTALBglghkgBZQMEA
gEwgXXXXXX...***
- Content-Type → application/json

请求Body:

```
{  
  "agency_name_suffix" : "iam-user01"  
}
```

其中, 加粗的斜体字段需要根据实际值填写:

- ***endpoint***为ModelArts的终端节点。
 - ***project_id***为用户的资源空间ID。
 - “X-auth-Token” 是上一步获取到的Token值。
 - “agency_name_suffix” 是自定义的委托名称后缀。
- b. 返回状态码 “200 OK” 表示委托 “ma_agency_iam-user01” 创建成功, 响应Body如下所示:

```
{  
  "agency_name": "ma_agency_iam-user01"  
}
```

3. 调用[配置授权](#)接口配置ModelArts授权。该接口支持管理员给用户设置委托, 支持设置当前用户的访问密钥。

- a. 请求消息体:

URI: POST https://{*endpoint*}/v2/{*project_id*}/authorizations

请求消息头:

- X-auth-Token →
***MIIZmgYJKoZlhvcNAQcCollZizCCGYcCAQExDTALBglghkgBZQMEA
gEwgXXXXXX...***
- Content-Type → application/json

请求Body:

```
{  
  "user_id": "****af917080f5d21f55c018ba19****",  
  "type": "agency",  
  "content": "ma_agency_iam-user01"  
}
```

其中, 加粗的斜体字段需要根据实际值填写, “user_id” 为用户ID, “content” 为上一步创建的ModelArts委托。

- b. 返回状态码 “200 OK” 表示配置授权完成, 响应Body如下所示:

```
{  
  "result": true  
}
```

4. 调用[查看授权列表](#)接口查看用户的授权信息。

- a. 请求消息体:

URI: GET https://{*endpoint*}/v2/{*project_id*}/authorizations

请求消息头: X-auth-Token →

MIIZmgYJKoZIhvcNAQcCollZizCCGYcCAQExDTALBgIghkgBZQMEAgEwgXXXXXX...

其中, 加粗的斜体字段需要根据实际值填写。

- b. 返回状态码 “200 OK”, 响应Body如下所示:

```
{
  "auth": [
    {
      "create_time": 1622804433221,
      "user_id": "all-users",
      "user_name": "all-users",
      "type": "agency",
      "content": "modelarts_agency"
    },
    {
      "create_time": 1625457065365,
      "user_id": "****af917080f5d21f55c018ba19****",
      "user_name": null,
      "type": "agency",
      "content": "ma_agency_iam-user01"
    }
  ],
  "total_count": 2
}
```

根据响应可以了解用户的授权信息。

5. 在管理用户授权时, 可以调用[删除授权](#)接口删除指定用户的授权或者删除全量用户的授权。

- a. 请求消息体:

URI: DELETE https://{endpoint}/v2/{project_id}/authorizations?
user_id=****d80fb058844ae8b82aa66d9fe****

请求消息头: X-auth-Token →

MIIZmgYJKoZIhvcNAQcCollZizCCGYcCAQExDTALBgIghkgBZQMEAgEwgXXXXXX...

其中, 加粗的斜体字段需要根据实际值填写,

“****d80fb058844ae8b82aa66d9fe****”是指定用户ID。

- b. 返回状态码 “200” 表示删除成功, 响应Body如下所示:

```
{
  "result": true,
  "serviceResults": [
    {
      "body": null,
      "serviceName": "Algorancher"
    },
    {
      "body": null,
      "serviceName": "Upredict"
    },
    {
      "body": null,
      "serviceName": "Exeml"
    }
  ]
}
```

15.2 创建和修改工作空间

本节通过调用一系列API, 以创建和修改工作空间为例介绍ModelArts API的使用流程。

概述

创建和修改工作空间的流程如下：

1. 调用**认证鉴权**接口获取用户Token，在后续的请求中需要将Token放到请求消息头中作为认证。
2. 调用**创建工作空间**接口创建一个工作空间。
3. 调用**查询工作空间详情**接口根据工作空间ID查询工作空间的详细信息。
4. 调用**修改工作空间**接口根据工作空间ID修改工作空间的名称、描述、授权类型等信息。
5. 当不需要该工作空间时，可以调用**删除工作空间**接口删除工作空间。

前提条件

- 已获取**ModelArts的终端节点EndPoint**。
- 确认服务的部署区域，**获取项目名称和ID**、**获取账号名和ID**和**获取用户名和ID**。

操作步骤

1. 调用**认证鉴权**接口获取用户的Token。

a. 请求消息体：

URI格式：POST https://{**endpoint**}/v3/auth/tokens

请求消息头：Content-Type → application/json

请求Body：

```
{
  "auth": {
    "identity": {
      "methods": ["password"],
      "password": {
        "user": {
          "name": "user_name",
          "password": "user_password",
          "domain": {
            "name": "domain_name"
          }
        }
      }
    },
    "scope": {
      "project": {
        "name": "xx-xxxxx-x"
      }
    }
  }
}
```

其中，加粗的斜体字段需要根据实际值填写：

- **endpoint**为终端节点。
- **user_name**为用户名。
- **user_password**为用户登录密码。
- **domain_name**为用户所属的账号名。
- **xx-xxxxx-x**为项目名，代表服务的部署区域。

- b. 返回状态码“201 Created”，在响应Header中获取“X-Subject-Token”的值即为Token，如下所示：

```
x-subject-token →  
MIIZmgYJKoZIhvcNAQcColIZizCCGYcCAQExDTALBglghkgBZQMEAgEwgXXXXXX...
```

2. 调用[创建工作空间](#)接口创建一个工作空间。

- a. 请求消息体：

URI: POST https://{*endpoint*}/v1/{*project_id*}/workspaces

请求消息头：

- X-auth-Token →
MIIZmgYJKoZIhvcNAQcColIZizCCGYcCAQExDTALBglghkgBZQMEAgEwgXXXXXX...
- Content-Type → application/json

请求Body：

```
{  
  "name": "test_workspace",  
  "description": "It is my workspace",  
  "enterprise_project_id": "0",  
  "auth_type": "PUBLIC",  
  "grants": [  
    {  
      "user_id": "aa7efa8801024da08a7fa92dc0*****",  
      "user_name": ""  
    }  
  ]  
}
```

其中，加粗的斜体字段需要根据实际值填写：

- ***endpoint***为ModelArts的终端节点。
- ***project_id***为用户的项目ID。
- “X-auth-Token”是上一步获取到的Token值。
- “user_id”为用户ID。

- b. 返回状态码“200 OK”，响应Body如下所示：

```
{  
  "id": "f3deca1406da4910a50f3919940b9bda",  
  "name": "test_workspace",  
  "description": "It is my workspace",  
  "owner": "test166",  
  "create_time": 1625453558000,  
  "update_time": 1625453558000,  
  "enterprise_project_id": "0",  
  "enterprise_project_name": "default",  
  "auth_type": "public",  
  "status": "NORMAL",  
  "status_info": ""  
}
```

“id”为新建的工作空间ID，记录该值用于后续步骤。

3. 调用[查询工作空间详情](#)接口根据工作空间ID查询工作空间的详细信息。

- a. 请求消息体：

URI: GET https://{*endpoint*}/v1/{*project_id*}/workspaces/
{workspaces_id}

请求消息头: X-auth-Token →

MIIZmgYJKoZIhvcNAQcCollZizCCGYcCAQExDTALBglghkgBZQMEAgEwgXXXXXX...

其中, 加粗的斜体字段需要根据实际值填写, “workspace_id” 为2获取的工作空间ID。

- b. 返回状态码 “200 OK”, 响应Body如下所示:

```
{
  "id": "f3deca1406da4910a50f3919940b9bda",
  "name": "test_workspace",
  "description": "It is my workspace",
  "owner": "test166",
  "create_time": 1625453558000,
  "update_time": 1625453558000,
  "enterprise_project_id": "0",
  "enterprise_project_name": "default",
  "auth_type": "public",
  "status": "NORMAL",
  "status_info": ""
}
```

根据响应可以了解工作空间的详细信息, 其中 “status” 为 “NORMAL” 表示工作空间的状态正常。

4. 调用[修改工作空间](#)接口根据工作空间ID修改工作空间的名称、描述、授权类型等信息。

- a. 请求消息体:

URI: PUT https://{endpoint}/v1/{project_id}/workspaces/{workspaces_id}

请求消息头:

- X-auth-Token →

MIIZmgYJKoZIhvcNAQcCollZizCCGYcCAQExDTALBglghkgBZQMEAgEwgXXXXXX...

- Content-Type → application/json

请求Body:

```
{
  "name": "new_name",
  "description": "update description",
  "auth_type": "INTERNAL",
  "grants": [
    { "user_id": "aa7efa8801024da08a7fa92dc0*****" }
  ]
}
```

其中, 加粗的斜体字段需要根据实际值填写, “name” 和 “description” 填写要修改的工作空间名称和描述。

- b. 返回状态码 “200 OK” 表示修改完成, 响应Body如下所示:

```
{
  "workspace_id": "f3deca1406da4910a50f3919940b9bda"
}
```

5. 当不需要该工作空间时, 可以调用[删除工作空间](#)接口删除工作空间。

- a. 请求消息体:

URI: DELETE https://{endpoint}/v1/{project_id}/workspaces/{workspaces_id}

请求消息头: X-auth-Token →

MIIZmgYJKoZIhvcNAQcCollZizCCGYcCAQExDTALBglghkgBZQMEAgEwgXXXXXX...

其中, 加粗的斜体字段需要根据实际值填写。

- b. 返回状态码 “200 OK” 表示删除成功, 响应Body如下所示:

```
{  
  "workspace_id": "f3deca1406da4910a50f3919940b9bda"  
}
```

16 权限策略和授权项

16.1 策略及授权项说明

默认情况下，新建的用户没有任何权限，如果您需要对您所拥有的ModelArts进行精细的权限管理，您需要将其加入用户组，并给用户组授予策略或角色，才能使用户组中的用户获得相应的权限，这一过程称为授权。授权后，用户就可以基于已有权限对云服务进行操作。

说明

如果您要允许或禁止某个接口的操作权限，请使用细粒度策略。

账号具备所有接口的调用权限，发起API请求时，该用户必须具备调用该接口所需的权限，否则，API请求将调用失败。每个接口所需要的权限，与各个接口所对应的授权项相对应，只有发起请求的用户被授予授权项所对应的策略，该用户才能成功调用该接口。

支持的授权项

策略包含系统策略和自定义策略，如果系统策略不满足授权要求，管理员可以创建自定义策略，并通过给用户组授予自定义策略来进行精细的访问控制。策略支持的操作与API相对应，授权项列表说明如下：

- 权限：允许或拒绝某项操作。
- 对应API接口：自定义策略实际调用的API接口。
- 授权项：自定义策略中支持的Action，在自定义策略中的Action中写入授权项，可以实现授权项对应的权限功能。
- 依赖的授权项：部分Action存在对其他Action的依赖，需要将依赖的Action同时写入授权项，才能实现对应的权限功能。

16.2 训练作业权限

表 16-1 训练作业细化权限说明

权限	对应API接口	授权项	依赖的授权项
创建训练作业	POST /v2/{project_id}/training-jobs	modelarts:trainJob:create	obs:object:GetObjectAcl obs:object:PutObjectAcl obs:object:PutObject obs:object:GetObject obs:object:DeleteObject obs:object:ModifyObjectMetaData
更新训练作业	PUT /v2/{project_id}/training-jobs/{training_job_id}	modelarts:trainJob:update	-
删除训练作业	DELETE /v2/{project_id}/training-jobs/{training_job_id}	modelarts:trainJob:delete	-
查询训练作业详情	GET /v2/{project_id}/training-jobs/{training_job_id}	modelarts:trainJob:get	-
查询训练作业列表	POST /v2/{project_id}/training-job-searches	modelarts:trainJob:list	-
训练作业日志预览	GET /v2/{project_id}/training-jobs/{training_job_id}/tasks/{task_id}/logs/preview	modelarts:trainJob:previewLog	-

权限	对应API接口	授权项	依赖的授权项
训练作业日志下载	GET /v2/ {project_id}/ training-jobs/ {training_job_id}/ tasks/{task_id}/ logs/url	modelarts:trainJob: logExport	-
创建算法	POST /v2/ {project_id}/ algorithms	modelarts:aiAlgori thm:create	-
更新算法	PUT /v2/ {project_id}/ algorithms/ {algorithm_id}	modelarts:aiAlgori thm:update	-
删除算法	DELETE /v2/ {project_id}/ algorithms/ {algorithm_id}	modelarts:aiAlgori thm:delete	-
查询算法列表	GET /v2/ {project_id}/ algorithms	modelarts:aiAlgori thm:get	-
查询算法详情	GET /v2/ {project_id}/ algorithms/ {algorithm_id}	modelarts:aiAlgori thm:get	-

16.3 模型管理权限

表 16-2 模型管理细化权限说明

权限	对应API接口	授权项	依赖的授权项
导入模型	POST /v1/{project_id}/models	modelarts:model:create	obs:bucket:ListAllMybuckets obs:object:PutObjectAcl obs:bucket:ListBucket obs:bucket:HeadBucket obs:object:GetObject obs:object:PutObject SWR Administrator
查询模型列表	GET /v1/{project_id}/models	modelarts:model:list	-
删除模型	DELETE /v1/{project_id}/models/{model_id}	modelarts:model:delete	SWR Administrator
查询模型详情	GET /v1/{project_id}/models/{model_id}	modelarts:model:get	-

16.4 服务管理权限

表 16-3 服务管理细化权限说明

权限	对应API接口	授权项	依赖的授权项
部署模型服务	POST /v1/{project_id}/services	modelarts:service:create	SWR Administrator
查询模型服务列表	GET /v1/{project_id}/services	modelarts:service:list	-

权限	对应API接口	授权项	依赖的授权项
查询模型服务详情	GET /v1/ {project_id}/ services/ {service_id}	modelarts:service: get	-
更新模型服务	PUT /v1/ {project_id}/ services/ {service_id}	modelarts:service: update	-
删除模型服务	DELETE /v1/ {project_id}/ services/ {service_id}	modelarts:service: delete	-
启动停止服务	PUT /v1/ {project_id}/ services/ {service_id} (request body携带 status信息)	modelarts:service: action	-
启动停止边缘节点服务实例	PUT /v1/ {project_id}/ services/ {service_id}/nodes/ {node_id}/status (request body携带 status信息)	modelarts:nodeser vice:action	Tenant Administrator
查询服务监控信息	GET /v1/ {project_id}/ services/ {service_id}/ monitor	modelarts:service: getMonitor	-
查询服务更新日志	GET /v1/ {project_id}/ services/ {service_id}/logs	modelarts:service: getLogs	-
查询服务事件日志	GET /v1/ {project_id}/ services/ {service_id}/events	modelarts:service: getEvents	-

16.5 资源管理权限

表 16-4 资源池管理细化权限说明

权限	对应API接口	授权项	依赖的授权项
查询资源池列表	GET /v2/{project_id}/pools	modelarts:pool:list	--
查询资源池详情	GET /v2/{project_id}/pools/{pool_name}	modelarts:pool:get	--
修改资源池	PATCH /v2/{project_id}/pools/{pool_name}	modelarts:pool:update	--
创建资源池	POST /v2/{project_id}/pools	modelarts:pool:create	--
删除资源池	DELETE /v2/{project_id}/pools/{pool_name}	modelarts:pool:delete	--
根据标签获取所有符合条件资源池列表	GET /v1/{project_id}/pools/resource-instances/filter	modelarts:tag:list	--
根据标签统一所有符合条件资源池总数	GET /v1/{project_id}/pools/resource-instances/count	modelarts:tag:list	--

表 16-5 网络管理细化权限说明

权限	对应API接口	授权项	依赖的授权项
查询网络列表	GET /v1/{project_id}/networks	modelarts:network:list	--
查询网络详情	GET /v1/{project_id}/networks/{network_name}	modelarts:network:get	--
修改网络	PATCH /v1/{project_id}/networks/{network_name}	modelarts:network:update	vpc:*.get vpc:*.list vpc:peerings:*. vpc:routeTables:*
创建网络	POST /v1/{project_id}/networks	modelarts:network:create	vpc:*.get vpc:*.list

权限	对应API接口	授权项	依赖的授权项
删除网络	DELETE /v1/{project_id}/ networks/ {network_name}	modelarts:network :delete	--

表 16-6 边缘池管理细化权限说明

权限	对应API接口	授权项	依赖的授权项
查询边缘池列表	GET /v1/{project_id}/ edge-pools	modelarts:edgePool:list	ief.*.get ief.*.list
查询边缘池详情	GET /v1/{project_id}/ edge-pools/ {edge_pool_id}	modelarts:edgePool:get	ief.*.get ief.*.list
修改边缘池	PUT /v1/{project_id}/ edge-pools/ {edge_pool_id}	modelarts:edgePool:up date	ief.*.get ief.*.list
创建边缘池	POST /v1/{project_id}/ edge-pools	modelarts:edgePool:cre ate	ief.*.get ief.*.list
删除边缘池	DELETE /v1/{project_id}/ edge-pools/ {edge_pool_id}	modelarts:edgePool:del ete	--

16.6 工作空间管理权限

表 16-7 工作空间管理细化权限说明

权限	对应API接口	授权项	依赖的授权项	IA M 项目	企 业 项目
创建工作空间	POST /v1/ {project_id}/ workspaces	modelarts:work space:create	-	√	√
查询工作空间列表	GET /v1/ {project_id}/ workspaces	modelarts:work space:list	-	√	√

权限	对应API接口	授权项	依赖的授权项	IA M 项目	企业 项目
查询工作空间详情	GET /v1/{project_id}/workspaces/{ws_id}	modelarts:work space:get	-	√	√
修改工作空间	PUT /v1/{project_id}/workspaces/{ws_id}	modelarts:work space:update	-	√	√
删除工作空间	DELETE /v1/{project_id}/workspaces/{ws_id}	modelarts:work space:delete modelarts:service:delete modelarts:model:delete modelarts:trainJob:delete	-	√	√
查询工作空间配额	GET /v1/{project_id}/workspaces/{workspace_id}/quotas	modelarts:work space:getQuotas	-	√	√
修改工作空间配额	PUT /v1/{project_id}/workspaces/{workspace_id}/quotas	modelarts:work space:updateQuotas	-	√	√

16.7 新版推理权限

表 16-8 在线服务生命周期管理细化权限说明

权限	对应api接口	授权项	依赖的授权项
停止在线服务	POST /v2/{project_id}/services/{service_id}/stop	modelarts:service:update	-
中断在线服务	POST /v2/{project_id}/services/{service_id}/interrupt	modelarts:service:update	-
查询在线服务列表	GET /v2/{project_id}/services	modelarts:service:get	-

权限	对应api接口	授权项	依赖的授权项
启动在线服务	POST /v2/{project_id}/services/{service_id}/start	modelarts:service:update	-
创建在线服务	POST /v2/{project_id}/services	modelarts:service:create	-
查询在线服务详情	GET /v2/{project_id}/services/{service_id}	modelarts:service:get	-
更新在线服务配置	PUT /v2/{project_id}/services/{service_id}	modelarts:service:update	-
获取在线服务事件列表	GET /v2/{project_id}/services/{service_id}/events	modelarts:service:get	-
查询服务exec登录信息	GET /v2/{project_id}/services/{service_id}/exec	-	-
删除指定服务列表	POST /v2/{project_id}/services/delete	modelarts:service:delete	-

表 16-9 服务版本管理细化权限说明

权限	对应api接口	授权项	依赖的授权项
查询在线服务版本列表	GET /v2/{project_id}/services/{service_id}/versions	modelarts:service:get	-
切换服务到指定版本	POST /v2/{project_id}/services/{service_id}/versions/switch	modelarts:service:update	-
删除在线服务版本	DELETE /v2/{project_id}/services/{service_id}/versions/{version_id}	modelarts:service:update	-
查询在线服务版本详情	GET /v2/{project_id}/services/{service_id}/versions/{version_id}	modelarts:service:get	-

表 16-10 服务实例管理细化权限说明

权限	对应api接口	授权项	依赖的授权项
查询服务实例组列表	GET /v2/{project_id}/services/{id}/service-instance-groups	modelarts:service:get	-

权限	对应api接口	授权项	依赖的授权项
删除Pod	DELETE /v2/{project_id}/services/{id}/service-instance-groups/{group_name}/service-instances/{instance_name}/pods/{name}	modelarts:service:update	-
查询Pod事件	GET /v2/{project_id}/services/{id}/service-instance-groups/{group_name}/service-instances/{instance_name}/pods/{name}/events	modelarts:service:get	-
删除服务实例	DELETE /v2/{project_id}/services/{id}/service-instance-groups/{group_name}/service-instances/{name}	modelarts:service:update	-
查询服务的Pod列表	GET /v2/{project_id}/services/{id}/service-instance-groups/{group_name}/service-instances/{name}/pods	modelarts:service:get	-
查询服务实例列表	GET /v2/{project_id}/services/{service_id}/service-instance-groups/{name}/service-instances	modelarts:service:get	-

表 16-11 服务扩缩容策略细化权限说明

权限	对应api接口	授权项	依赖的授权项
删除自动扩缩容策略	DELETE /v2/{project_id}/services/{service_id}/{group_id}/hpa	modelarts:hpa:delete	-
查看自动扩缩容策略	GET /v2/{project_id}/services/{service_id}/{group_id}/hpa	modelarts:hpa:get	-
创建自动扩缩容策略	POST /v2/{project_id}/services/{service_id}/{group_id}/hpa	modelarts:hpa:create	-

权限	对应api接口	授权项	依赖的授权项
修改自动扩缩容策略	PUT /v2/{project_id}/services/{service_id}/{group_id}/hpa	modelarts:hpa:update	-
查看自动扩缩容策略事件	GET /v2/{project_id}/services/{service_id}/{group_id}/hpa/events	modelarts:hpaEvent:get	-

表 16-12 服务标签管理细化权限说明

权限	对应api接口	授权项	依赖的授权项
通过标签查询资源数量	POST /v2/{project_id}/modelarts-service-v2/resource-instances/count	modelarts:tag:list	-
通过标签反查资源列表	POST /v2/{project_id}/modelarts-service-v2/resource-instances/filter	modelarts:tag:list	-
查询某一类资源下的标签	GET /v2/{project_id}/modelarts-service-v2/tags	modelarts:tag:list	-
查询资源标签	GET /v2/{project_id}/modelarts-service-v2/{resource_id}/tags	modelarts:tag:list	-
添加标签。	POST /v2/{project_id}/modelarts-service-v2/{resource_id}/tags/create	modelarts:service:update	-
删除资源标签。	DELETE /v2/{project_id}/modelarts-service-v2/{resource_id}/tags/delete	modelarts:service:update	-

表 16-13 应用密钥管理细化权限说明

权限	对应api接口	授权项	依赖的授权项
查询应用密钥	GET /v2/{project_id}/services/api-keys	modelarts:apikey:list	-
创建应用密钥	POST /v2/{project_id}/services/api-keys	modelarts:apikey:create	-
删除应用密钥	DELETE /v2/{project_id}/services/api-keys/{key_id}	modelarts:apikey:delete	-

权限	对应api接口	授权项	依赖的授权项
批量绑定应用密钥	POST /v2/{project_id}/services/{service_id}/api-keys/batch-bind	modelarts:apikey:bind	-
批量解绑应用密钥	POST /v2/{project_id}/services/{service_id}/api-keys/batch-unbind	modelarts:apikey:unbind	-
绑定应用密钥	POST /v2/{project_id}/services/{service_id}/api-keys/{key_id}/bind	modelarts:apikey:bind	-
解绑应用密钥	POST /v2/{project_id}/services/{service_id}/api-keys/{key_id}/unbind	modelarts:apikey:unbind	-

表 16-14 专属资源池管理细化权限说明

权限	对应api接口	授权项	依赖的授权项
查询纳管集群详情	GET /v2/{project_id}/services/clusters/{id}	modelarts:pool:get	-
查询集群规格列表	GET /v2/{project_id}/services/flavors	modelarts:clusterFlavor:list	-

表 16-15 RMS 资源管理细化权限说明

权限	对应api接口	授权项	依赖的授权项
查询区域下资源实例列表	GET /providers/modelarts/v1/domains/{domain_id}/regions/{region_id}/serviceV2	-	-
查询区域下资源实例详情	GET /providers/modelarts/v1/domains/{domain_id}/regions/{region_id}/serviceV2/{resource_id}	-	-

表 16-16 内网接入细化权限说明

权限	对应api接口	授权项	依赖的授权项
创建内网接入	POST /v2/{project_id}/intranet-connection	modelarts:intranetConnection:create	VPC Endpoint Administrator
变更内网申请	PUT /v2/{project_id}/intranet-connection/{id}	modelarts:intranetConnection:update	VPC Endpoint Administrator
查询当前租户的内网接入申请列表	GET /v2/{project_id}/intranet-connection/requests	modelarts:intranetConnection:list	-
查询当前租户的内网接入审批列表	GET /v2/{project_id}/intranet-connection/reviews	modelarts:intranetConnection:list	-
批量删除内网接入	POST /v2/{project_id}/intranet-connection/delete	modelarts:intranetConnection:delete	VPC Endpoint Administrator

17公共参数

17.1 状态码

状态码如表17-1所示。

表 17-1 状态码

状态码	编码	状态码说明
100	Continue	继续请求。 这个临时响应用来通知客户端，它的部分请求已经被服务器接收，且仍未被拒绝。
101	Switching Protocols	切换协议。只能切换到更高级的协议。 例如，切换到HTTP的新版本协议。
200	OK	接口调用成功。
201	Created	创建类的请求完全成功。
202	Accepted	已经接受请求，但未处理完成。
203	Non-Authoritative Information	非授权信息，请求成功。
204	NoContent	请求完全成功，同时HTTP响应不包含响应体。 在响应OPTIONS方法的HTTP请求时返回此状态码。
205	Reset Content	重置内容，服务器处理成功。
206	Partial Content	服务器成功处理了部分GET请求。
300	Multiple Choices	多种选择。请求的资源可包括多个位置，相应可返回一个资源特征与地址的列表用于用户终端（例如：浏览器）选择。

状态码	编码	状态码说明
301	Moved Permanently	永久移动，请求的资源已被永久的移动到新的URI，返回信息会包括新的URI。
302	Found	资源被临时移动。
303	See Other	查看其它地址。 使用GET和POST请求查看。
304	Not Modified	所请求的资源未修改，服务器返回此状态码时，不会返回任何资源。
305	Use Proxy	所请求的资源必须通过代理访问。
306	Unused	已经被废弃的HTTP状态码。
400	BadRequest	非法请求。 建议直接修改该请求，不要重试该请求。
401	Unauthorized	在客户端提供认证信息后，返回该状态码，表明服务端指出客户端所提供的认证信息不正确或非法。
402	Payment Required	保留请求。
403	Forbidden	请求被拒绝访问。 返回该状态码，表明请求能够到达服务端，且服务端能够理解用户请求，但是拒绝做更多的事情，因为该请求被设置为拒绝访问，建议直接修改该请求，不要重试该请求。
404	NotFound	所请求的资源不存在。 建议直接修改该请求，不要重试该请求。
405	MethodNotAllowed	请求中带有该资源不支持的方法。 建议直接修改该请求，不要重试该请求。
406	Not Acceptable	服务器无法根据客户端请求的内容特性完成请求。
407	Proxy Authentication Required	请求要求代理的身份认证，与401类似，但请求者应当使用代理进行授权。
408	Request Time-out	服务器等候请求时发生超时。 客户端可以随时再次提交该请求而无需进行任何更改。
409	Conflict	服务器在完成请求时发生冲突。 返回该状态码，表明客户端尝试创建的资源已经存在，或者由于冲突请求的更新操作不能被完成。

状态码	编码	状态码说明
410	Gone	客户端请求的资源已经不存在。 返回该状态码，表明请求的资源已被永久删除。
411	Length Required	服务器无法处理客户端发送的不带 Content-Length 的请求信息。
412	Precondition Failed	未满足前提条件，服务器未满足请求者在请求中设置的其中一个前提条件。
413	Request Entity Too Large	由于请求的实体过大，服务器无法处理，因此拒绝请求。为防止客户端的连续请求，服务器可能会关闭连接。如果只是服务器暂时无法处理，则会包含一个 Retry-After 的响应信息。
414	Request-URI Too Large	请求的 URI 过长（URI 通常为网址），服务器无法处理。
415	Unsupported Media Type	服务器无法处理请求附带的媒体格式。
416	Requested range not satisfiable	客户端请求的范围无效。
417	Expectation Failed	服务器无法满足 Expect 的请求头信息。
422	UnprocessableEntity	请求格式正确，但是由于含有语义错误，无法响应。
429	TooManyRequests	表明请求超出了客户端访问频率的限制或者服务端接收到多于它能处理的请求。建议客户端读取相应的 Retry-After 首部，然后等待该首部指出的时间后再重试。
500	InternalServerError	表明服务端能被请求访问到，但是不能理解用户的请求。
501	Not Implemented	服务器不支持请求的功能，无法完成请求。
502	Bad Gateway	充当网关或代理的服务器，从远端服务器接收到了一个无效的请求。
503	ServiceUnavailable	被请求的服务无效。 建议直接修改该请求，不要重试该请求。
504	ServerTimeout	请求在给定的时间内无法完成。客户端仅在为请求指定超时（Timeout）参数时会得到该响应。
505	HTTP Version not supported	服务器不支持请求的 HTTP 协议的版本，无法完成处理。

17.2 错误码

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.1120	Parameter verification failed.	参数校验失败	查看请求参数，根据页面参数校验规则填写请求参数。
400	ModelArts.0425	Failed to add user authorization information.	添加授权信息失败	请联系运维接口人排查处理问题。
400	ModelArts.0427	Failed to get user authorization information.	查询授权信息失败	用户获取授权信息较为频繁，请稍后重新获取。
400	ModelArts.3082	Request Mode does not the same as before.	模型的请求模式需要和之前的模型保持一致	模型的请求模式需要和之前的模型保持一致
400	ModelArts.3111	License control expiry	license到期	请联系运维接口人排查原因
400	ModelArts.1002	OBS operation failed.	操作对象存储服务（OBS）失败。	请确认对象存储服务（OBS）是否可用。
204	ModelArts.2776	NotReadyToFetchLog	日志未就绪，等待训练回传数据	请稍后重试
204	ModelArts.2777	NotReadyToFetchMetric	指标未就绪，等待训练回传数据	请稍后重试
400	ModelArts.2751	DuplicateTrainingJobName	创建的训练作业（name %s）已存在	请更换训练作业名称
400	ModelArts.2753	InputsOutputsMessageError	输入输出路径映射配置信息填写不规范	请检查请求中输入输出路径映射配置信息的合法性
400	ModelArts.2755	AiAlgorithmNotFound	算法未找到	请检查请求中算法信息的合法性
400	ModelArts.2756	HasSameNameWithMarketAlgorithm	与已订阅算法重名	请检查请求中算法信息的合法性

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.2757	CodeDirError	代码目录路径错误	请检查请求中代码目录和启动文件的合法性
400	ModelArts.2758	BootFileDirError	代码启动文件路径错误	请检查请求中代码目录和启动文件的合法性
400	ModelArts.2763	DoNotHaveFlavor	选择的实例规格无效	请检查请求中的实例规格是否有效
400	ModelArts.2764	QueryParamsError	查询参数 (%s) 无效	请检查请求参数的合法性
400	ModelArts.2765	StringParameterError	字符型变量必须在预设参数范围内	请根据预设范围填写变量值
400	ModelArts.2771	NotHavePermission	没有修改权限	请检查用户权限
400	ModelArts.2773	GetObsObjectContentError	获取文件内容失败	请检查文件权限
400	ModelArts.2775	TrainingJobNotFound	训练作业 (id: %s) 未找到	请检查请求中训练作业信息的合法性
400	ModelArts.2781	FlavorNotFound	规格 (%s) 未找到	请检查请求中的规格的合法性
400	ModelArts.2787	InvalidJsonBody	非法Json请求体	请检查请求体的合法性
400	ModelArts.2788	InvalidParam	参数无效 (%s)	请检查请求参数的合法性
400	ModelArts.2789	UnsupportedFilterBy	不支持的过滤项	请检查过滤项的合法性
400	ModelArts.2790	UnsupportedSortBy	不支持的排序项	请检查排序项的合法性
400	ModelArts.2791	InvalidObsPath	非法的obs路径: %s	请检查obs路径的合法性
400	ModelArts.2806	MustHaveCmdAndImage	自定义镜像作业command和engine.url不能为空	请检查请求中command和engine.url的合法性
400	ModelArts.2810	SWRQueryImageInfoError	自定义镜像查询失败	请检查请求中image_url是否输入正确

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.2811	SWRCreateShareError	自定义镜像添加共享失败	请检查请求中image_url是否输入正确
400	ModelArts.2812	UnsupportedActionType	不支持的操作类型: %s	请检查操作类型的合法性
400	ModelArts.2818	LogFileNotGenerated	日志文件未生成	请待日志生成后再查看
400	ModelArts.2819	LogFileHasCleared	日志文件已经被清理	请在创建训练作业时选择要上传的obs路径
400	ModelArts.2820	LogPathNotFound	找不到日志存储路径	请使用旧版API查看日志
400	ModelArts.2821	DuplicateAlgorithmName	创建的算法 (name %s) 已存在	算法名称已存在, 请更换算法名称
400	ModelArts.2827	FailureAnalysisNotPossible	无法对未失败的作业进行失败分析	请对运行失败的训练作业进行失败分析
400	ModelArts.2837	FrozenAccount	账号受限或冻结	请检查账号的合法性
403	ModelArts.2784	InvalidToken	非法Token	请检查请求Token的合法性
403	ModelArts.2785	AuthorizationNotFound	用户未给ModelArts服务授权, 无法使用ModelArts服务	请在全局配置中给ModelArts服务授权
404	ModelArts.2786	TokenProjectIDNotMatch	请求中的project_id (%s) 和Token中的project_id (%s) 不匹配	请更换请求Token或者更换请求参数的ProjectID
404	ModelArts.2836	PathNotFound	未找到路径	请确认路径是否正确
405	ModelArts.2803	MethodNotAllowed	不允许的方法	请确认HTTP方法是否正确
409	ModelArts.2796	NotAllowedToTerminate	不允许终止该作业	请检查作业状态的合法性

状态码	错误码	错误信息	描述	处理措施
429	ModelArts.2799	TooManyRequests	服务请求频次超限	请稍后重试
500	ModelArts.2950	Unknown	未知错误	系统错误，请联系技术支持。
500	ModelArts.2952	ExtServiceDB	数据库服务异常	系统错误，请联系技术支持。
500	ModelArts.2955	ExtServiceAOM	AOM服务异常	系统错误，请联系技术支持。
400	ModelArts.0101	Invalid Argument.	无效的参数	根据提示输入正确的参数。
400	ModelArts.0107	The values of the request parameters ({0},{1}) are invalid.	请求的参数值({0},{1})是无效的。	检查提示的参数值是否是有效的。
400	ModelArts.0204	Token must contain projectId info.	token信息中必须包含projectId的信息。	检查token是否为project token。
400	ModelArts.3015	Config json file does not conform to the specification.	模型配置文件不符合规范。	检查输入的config.json或者输入的initial_config字段是否为标准格式。
400	ModelArts.3016	Failed to parse config json file because of unsupported fields, types, or formats({0},{1}).	解析config文件时由于不支持的字段、类型或格式导致失败({0},{1})。	按提示检查对应字段输入是否正确。
400	ModelArts.3017	Failed to publish model because source location noncompliance.	模型发布失败, 模型源路径不满足规范。	检查输入的source_location字段是否符合规范。

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.3023	Invalid labels({0}) of model.	模型标签({0})不合法。	模型标签含有特殊字符，当前只支持大小写字母或中文字符开头，包含大小写字母，数字，中文字符和下划线，最大长度不超过64。
400	ModelArts.3024	The templateInputs field is incorrectly configured, check if the input is consistent with the template requirements.	输入项配置错误，请检查输入是否与模板的要求保持一致	模板的参数和模板的要求不匹配，检查输入项是否和模板参数匹配。
400	ModelArts.3026	Failed to delete infer format, infer format ({0}) already be used by template.	输入输出模式删除失败，模式 ({0}) 已经被模板使用。	找到使用的模板，清理后再删除输入输出模式。
400	ModelArts.3028	Failed to publish model, please select input and output mode.	模型发布失败，请选择输入输出模式	选择输入输出模式后重新发布。
400	ModelArts.3029	Model publishing failed because the Template model must provide the template ID used.	模型发布失败，Template 模型必须提供所使用的模板 ID	模板模型发布时输入模板ID。

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.3030	Model publishing failed, template ({0}) does not support modifying its built-in input and output mode.	模型发布失败，模板({0})不支持修改其内置输入输出模式	模板模型发布时不支持修改内置的输入输出模式。
400	ModelArts.3031	Cancel sharing failed, ({0}) has not been shared with other tenants.	取消共享失败，({0})没有共享给其他租户	镜像取消共享失败，镜像没有共享给其他租户。
400	ModelArts.3032	Image ({0}) cannot be shared to admin ({1}), please check the image permissions.	镜像({0})无法共享给管理员({0})，请检查镜像权限	按错误提示进行操作。
400	ModelArts.3033	Template publishing failed, please provide template label.	模板发布失败，请提供模板标签	模型标签字段为空，需要填写值。
400	ModelArts.3034	Template model failed to be published, template field is required.	Template模型发布失败，template字段是必需的	模板发布情况下，template字段不能为空。
400	ModelArts.3035	Profile preview failed, sourceLocation and previewConfig fields need to provide at least one.	配置文件预览失败，sourceLocation与preview_config字段需至少提供一个	source_location和preview_config至少有一个不能为空。

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.3036	Parameter verification failed, parameter ({0}) is required.	参数校验失败，参数({0})是必需的	参数校验失败，按错误提示填写对应的参数。
400	ModelArts.3037	Parameter ({0}:{1}) is invalid.	参数({0}:{1})是无效的	按照提示参数进行修改。
400	ModelArts.3038	When isSpecific is true, domainId is required.	is_specific为true时，domain_id是必需的	按照提示进行提供domain_id。
400	ModelArts.3039	Template input input_id cannot be repeated.	模板输入项input_id不能重复	输入不重复的input_id。
400	ModelArts.3040	When the installer installer is yum or apt-get, and the version packageVersion exists, the version constraint restraint can only be EXACT.	安装方式installer为yum或apt-get，且版本package_version存在时，版本约束restraint只能为EXACT	检查版本约束。
400	ModelArts.3041	When the installer installer is conda or pip, and the version packageVersion exists, the version constraint restraint can only be EXACT, ATLEAST, ATMOST.	安装方式installer为conda或pip，且版本package_version存在时，版本约束restraint只能为EXACT、ATLEAST、ATMOST	检查版本约束。

状态码	错误码	错误信息	描述	处理措施
403	ModelArts.0108	You are not authorized to perform the ({0}) operation.	您未被授权执行({0})的操作。	检查是否有OBS权限或者接口操作权限。
403	ModelArts.0203	Invalid token.	无效的token。	重新生成一个token进行重试。
403	ModelArts.0206	Invalid AK/SK.	无效的AK/SK。	根据用户Token获取临时AK/SK失败，需要检查Token是否合法。
403	ModelArts.3010	Failed to copy model, you don't have permission to copy the model ({0}).	复制模型失败，你没有权限复制模型({0})。	没有权限复制模型，检查token或者model_id是否输入正确。
404	ModelArts.3001	Model ({0}) does not exist.	模型({0})不存在。	检查model_id是否输入正确。
404	ModelArts.3003	Failed to get model names list.	模型名称列表获取失败。	模型名称列表不存在，查询账号是否正确。
404	ModelArts.3019	Infer format ({0}) does not exist.	输入输出模式({0})不存在。	当前的输入输出模式不存在，考虑更换输入输出模式进行操作。
404	ModelArts.3021	Template ({0}) does not exist.	模板({0})不存在。	模板不存在，重新选择模板。
409	ModelArts.3002	Model ({0}, {1}) already exists.	模型({0}, {1})已经存在了。	模型名称和版本已经存在，更换名称或版本后重试。
409	ModelArts.3020	Infer format ({0}) already exists.	输入输出模式({0})已经存在了。	当前输入输出模式已经存在，考虑更换输入输出模式进行操作。
409	ModelArts.3022	Template ({0}) already exists.	模板({0})已经存在了。	该模板已经存在，重新选择模板。
500	ModelArts.0010	Internal error.	内部错误。	内部错误，联系开发运维人员进行处理。

状态码	错误码	错误信息	描述	处理措施
500	ModelArts.3006	Failed to publish model.	模型发布失败。	模型存储元数据到数据库失败，需要联系开发运维人员解决。
500	ModelArts.3009	Failed to delete model, model ({0}) already deploy service.	模型删除失败, 模型 ({0}) 已经部署成服务。	模型id已经部署成服务，删除部署的服务后进行重试。
500	ModelArts.3043	User ({0}) does not have obs: object: PutObjectAcl permission.	用户({0})没有OBS的obs:object:PutObjectAcl权限	用户没有提示中的OBS权限，需要添加权限后重试。
500	ModelArts.3044	Model file ({0}) is larger than 5G and cannot be imported.	模型文件({0})大于5G，无法导入	不支持单文件5G以上的OBS模型导入。
500	ModelArts.3045	Parameter ({0}) is null.	参数({0})为空。	检查当前提示的输入参数是否为空。
500	ModelArts.3065	The image of the model is being built so the runtime cannot be updated.	模型镜像构建中，不能更新runtime。	打镜像过程中不能更新runtime。
500	ModelArts.3301	Failed to build image.	构建镜像失败。	打镜像失败，检查镜像或者联系开发运维人员解决。
500	ModelArts.3801	invalid token, can not get template ak/sk.	无效的token，无法获取模板ak/sk。	模型加密时使用的token无法生成临时aksk，重新生成token进行重试。
500	ModelArts.3803	download file from obs failed.	从obs下载文件失败。	模型加密，从obs下载文件失败，检查OBS路径是否存在。
500	ModelArts.3805	file can not be empty.	文件不能为空。	模型加密文件接口，要传递需要加密的文件，字段名为file。

状态码	错误码	错误信息	描述	处理措施
500	ModelArts.3976	No resources are available for the selected specification.	所选规格没有资源可用。	检查当前环境对应的节点规格是否开放，如部署时未填写GPU主机组，相关规格则不会开放。当前环境则无法创建对应GPU规格类型的资源池。 如果使用公共资源池，查看公共资源池是否有资源。
400	ModelArts.3514	Field [input_params] must be set for the model that is used to deploy the batch service.	批量服务中的模型必须配置input_params参数。	补充input_params参数配置。
400	ModelArts.3515	The model {id} cannot be used for deploying services because it is still being published.	模型{ID}未就绪，无法部署服务。	等待模型就绪后重试。
400	ModelArts.3516	Failed to deploy services because the version of the model that is used for deploying services is the same.	部署服务失败，服务的模型版本不能相同。	更正模型版本列表，使模型版本无重复。
400	ModelArts.3519	Services only in one of states in [deploying, running, stopping, deleting] can be updated.	不允许更新状态为[部署中，运行中，停止中，删除中]的服务。	不对状态为[部署中，运行中，停止中，删除中]的服务进行更新。

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.3520	A maximum of {number} {service_type} services are allowed.	{类型}服务总数超限，限制为{数量}。	删除不再使用的服务或者联系服务运维人员增加服务数量的配额。
400	ModelArts.3522	A maximum of {number} {service_type} service instances are allowed.	{类型}服务实例总数超限，限制为{数量}。	删除不再使用的服务或者联系服务运维人员增加服务实例的配额。
400	ModelArts.3529	Model {id} under service {id} does not exist.	服务{ID}下的模型{ID}不存在。	检查模型ID是否设置正确，并确认其是否属于对应的服务下。
400	ModelArts.3531	Service {id} has created the QR code.	服务{ID}已创建QR code。	服务已创建QR code，无需重复创建。
400	ModelArts.3532	No QR code found for service {id}.	服务{ID}未创建QR code。	对服务创建QR code后重试。
400	ModelArts.3534	The security group must contain at least one inbound rule to allow the TCP request from source address 0.0.0.0/0 and port 8080.	安全组须包含至少一条入方向规则，对协议为TCP、源地址为0.0.0.0/0、端口为8080的请求放行。	在安全组中添加一条入方向规则：对协议为TCP、源地址为0.0.0.0/0、端口为8080的请求放行。
400	ModelArts.3547	Cluster {id} does not exist.	集群{ID}不存在。	检查集群ID是否设置正确。
400	ModelArts.3550	Domain {name} has been used.	域{名词}已被使用。	换用其他域名称后重试。
400	ModelArts.3551	OBS path {path} does not exist.	OBS路径{路径}不存在。	检查OBS路径是否正确。
400	ModelArts.3554	Cluster name {name} has been used.	集群名{名称}已经被使用。	更改集群名称后重试。

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.3561	Insufficient node quota.	节点配额不足。	联系服务运维人员申请增加配额或者删除无用的节点释放资源。
400	ModelArts.3567	OBS error occurs because {reason}.	OBS异常，因为{原因}	根据提示失败原因进行排查。
400	ModelArts.3568	OBS client error occurs.	OBS客户端异常。	联系服务运维人员解决。
400	ModelArts.3572	Invalid OBS URL {url}.	OBS路径{路径}格式不合法。	检查OBS路径是否正确。
400	ModelArts.3573	Failed to obtain the bucket name from OBS URL {url}.	无法从OBS路径{路径}中获取桶名。	检查OBS路径是否正确。
400	ModelArts.3574	Failed to validate the correctness of OBS URL {url}.	OBS路径{路径}校验失败。	检查OBS路径是否正确。
400	ModelArts.3589	Model {id} cannot be used to deploy {service_type} service.	模型{ID}不能用于部署{类型}服务。	重试选择其他部署类型。
400	ModelArts.3591	There are duplicate rules in the extend-configs.	在extend-configs中存在重复的规则。	修改表达式规格，避免重复。
400	ModelArts.3614	The customized input/output mode of batch service cannot be modified.	自定义输入输出参数（custom_src）无法更改	保持原服务 custom_src参数不变重试

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.3615	Shared resource pool does not support customized input/output mode.	共享资源池不支持自定义输入输出模式	使用专属资源池重试
400	ModelArts.3628	Failed to deploy service. {0}.	部署服务失败，原因：{0}。	请根据提示检查输入参数。
400	ModelArts.3648	Edge service is not allowed to delete a unique instance.	不允许删除边缘服务唯一实例	删除边缘服务而不是删除边缘唯一实例。
400	ModelArts.3822	The batch service task does not exist.	批量服务任务不存在。	输入正确的批量服务ID。
400	ModelArts.3894	The specification configuration information of runtime environment {name} does not exist.	运行环境{0}的规格配置信息不存在。	对应运行环境设置规格配置信息后重试。
400	ModelArts.3895	The specification configuration information of runtime environment {name} already exists.	运行环境{0}的规格配置信息已存在。	对应运行环境的规格配置信息已存在，无需重复设置。
400	ModelArts.3952	Insufficient resources. Please try later.	资源不足，请稍后重试。	进行重试，或联系服务运维人员解决。
400	ModelArts.3962	Operation is not allowed, {0}.	操作不允许，{0}。	请根据提示检查输入参数。

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.3988	The selected flavor does not support model deployment.	所选的规格不支持当前模型的部署	确保服务的（在线服务或批量服务）模型架构或加速卡类型与规格一致
400	ModelArts.3989	The number of edge service instances cannot exceed the number of nodes in the edge resource pool.	边缘服务实例个数不能超过边缘资源池节点个数	增加边缘资源池节点。
400	ModelArts.4105	The JSON format of the input data is incorrect.	请求body体json格式不对	请使用正确的JSON格式请求体
400	ModelArts.4201	Request url need service id. The request url not contain serviceId/ requestURI.	请求url中需要包含服务ID	请求地址不合法，请使用正确的预测地址
400	ModelArts.4202	Request url format invalid. The url not follow http(s):// domain/v1/ infers/ serviceId/ requestURI.	请求url格式不合法	请求地址不合法，请使用正确的预测地址
400	ModelArts.4203	Invalid request. The requested service %s was not started.	请求的服务未启动	请确认服务是否正常启动
400	ModelArts.4902	The app-auth api didn't bind to apig app %s.	APP认证接口未授权给所用的APP	请检查AppCode是否有权访问指定服务

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.4903	The app-auth api didn't bind to signature.	APP认证接口未绑定签名密钥	内部错误, 请联系技术支持
400	ModelArts.4904	The app-auth api didn't bind to apig sign whose key is %s.	APP认证接口未绑定所用的签名密钥	内部错误, 请联系技术支持
400	ModelArts.4905	Verify the authorization header failed.	Authorization 请求头校验失败	请使用正确的 appcode 预测地址, 或联系技术支持
401	ModelArts.0201	Token header cannot be empty. No key X-Auth-Token in header.	Token 为空	请在请求头中添加正确 token
401	ModelArts.0202	Invalid Token header. Token expired, please refresh it.	无效 Token, Token 已过期	请更换有效 token
401	ModelArts.0203	Invalid Token header. Can't decode the Token.	无效 Token, 无法解析	请更换有效 token
401	ModelArts.0204	Parse Token error. Have error when decode Token, please check it format or integrity.	解析 Token 失败	请更换有效 token
401	ModelArts.0205	No key Authorization in header.	缺少 Authorization 请求头	请使用正确的 appcode 预测地址, 或联系技术支持
401	ModelArts.0206	Authorization header format incorrect, please check its format or integrity.	Authorization 请求头格式错误	请使用正确的 appcode 预测地址, 或联系技术支持

状态码	错误码	错误信息	描述	处理措施
401	ModelArts.0207	Token must contain project info of current region.	Token必须包含项目信息。	请使用包含项目信息的Token。
401	ModelArts.0208	Verify Authorization header failed.	Authorization请求头校验失败	请使用正确的appcode预测地址，或联系技术支持
401	ModelArts.0209	No key appld in header.	缺少appld请求头	请使用apig的预测地址
401	ModelArts.0210	No key apild in header.	缺少apild请求头	请使用apig的预测地址
401	ModelArts.0212	Invalid Token header. The Token not contain project item.	无效Token，Token中缺少project信息	请使用项目级token
401	ModelArts.3801	User credential (AK and SK) does not exist.	用户证书不存在。	重新添加AkSk。
401	ModelArts.4203	Invalid request. Access denied! You do not have permission.	没有权限访问	没有权限访问，请确认权限
403	ModelArts.0210	The project id in the request URL does not match the token.	请求URL中的Project ID和Token不匹配。	请使用正确的Project ID生成Token。
403	ModelArts.3936	The app-auth API {id} does not belong to service {id}.	支持APP认证的接口{ID}不属于服务{ID}。	检查请求参数或者联系服务运维人员解决。
404	ModelArts.3502	Service {name} does not exist.	服务{名称}不存在。	检查服务名称是否设置正确。
404	ModelArts.3507	Model {name} does not exist.	模型{ID}不存在。	检查模型ID是否设置正确。

状态码	错误码	错误信息	描述	处理措施
404	ModelArts.3923	Application {id} does not exist.	应用{ID}不存在。	检查应用ID是否设置正确。
404	ModelArts.3935	The app-auth API {id} does not exist.	支持APP认证的接口{ID}不存在。	检查接口ID是否设置正确。
404	ModelArts.4901	The app-auth api doesn't exist.	APP认证接口不存在	请检查app预测地址是否存在
408	ModelArts.4205	Request connection error. Connection timeout.	连接后端服务超时	连接在线服务超时，重试或者等待一段时间
409	ModelArts.3503	Service {name} already exists.	服务{名称}已存在。	更改服务名称后重试。
409	ModelArts.3929	Failed to create the application because {reason}.	创建应用失败，因为{原因}。	根据提示失败原因进行排查。
413	ModelArts.4104	Invalid Request Content Length. The request body content have beyond limit.	请求body体长度不合法	请使用小于12M的请求体
429	ModelArts.4206	Too many requests, reached api %s.	请求数量达到限制	达到限流，请稍后重试
500	ModelArts.3501	Failed to deploy the service.	部署服务失败。	联系服务运维人员解决。
500	ModelArts.3504	Failed to delete the service.	删除服务失败。	联系服务运维人员解决。
500	ModelArts.3505	Failed to update the service.	查询服务失败。	联系服务运维人员解决。

状态码	错误码	错误信息	描述	处理措施
500	ModelArts.3506	Model {id} does not exist.	更新服务失败。	联系服务运维人员解决。
500	ModelArts.3508	Failed to query the service monitoring information.	服务监控信息获取失败。	联系服务运维人员解决。
500	ModelArts.3509	Failed to query the service edge node.	边缘节点列表获取失败。	联系服务运维人员解决。
500	ModelArts.3546	Failed to create the cluster.	创建专属资源池失败。	联系服务运维人员解决。
500	ModelArts.3579	Failed to query the model information.	查询模型信息失败。	联系服务运维人员解决。
500	ModelArts.3802	Failed to create API group {name} because {reason}.	创建API group {名称}失败，因为{原因}。	根据提示失败原因进行排查。
500	ModelArts.3803	Failed to register API {name} because {reason}.	注册API {名称}失败，因为{原因}。	根据提示失败原因进行排查。
500	ModelArts.3805	Failed to create AI service {name} because {reason}.	创建AI服务{名称}失败，因为{原因}。	根据提示失败原因进行排查。
500	ModelArts.3921	Failed to create the app-auth API because {reason}.	注册支持APP认证的接口失败，因为{原因}。	根据提示失败原因进行排查。

状态码	错误码	错误信息	描述	处理措施
500	ModelArts.3924	Failed to create the application code for application {id} because {reason}.	创建应用{ID}的AppCode失败，因为{原因}。	根据提示失败原因进行排查。
500	ModelArts.3925	Failed to delete app-auth api {id} because {reason}.	删除支持APP认证的接口{ID}失败，因为{原因}。	根据提示失败原因进行排查。
500	ModelArts.3926	Failed to reset the secret of application {id} because {reason}.	重置应用{ID}的私钥失败，因为{原因}。	根据提示失败原因进行排查。
500	ModelArts.3927	Failed to reset the application code of application {id} because {reason}.	重置应用{ID}的AppCode失败，因为{原因}。	根据提示失败原因进行排查。
500	ModelArts.3928	Failed to obtain the app-auth API information because {reason}.	获取支持APP认证的接口信息失败，因为{原因}。	根据提示失败原因进行排查。
500	ModelArts.3932	Failed to obtain the application information because {reason}.	获取应用信息失败，因为{原因}。	根据提示失败原因进行排查。
500	ModelArts.3933	Failed to delete application {id} because {reason}.	删除应用{ID}失败，因为{原因}。	根据提示失败原因进行排查。

状态码	错误码	错误信息	描述	处理措施
500	ModelArts.3934	Failed to delete the application code of application {id} because {reason}.	删除应用{ID}的AppCode失败，因为{原因}。	根据提示失败原因进行排查。
500	ModelArts.3937	Failed to authorize the app-auth API to the application because {reason}.	授权接口至应用失败，因为{原因}。	根据提示失败原因进行排查。
500	ModelArts.3938	Failed to unbind the app-auth API from the application because {reason}.	解除接口至应用的授权失败，因为{原因}。	根据提示失败原因进行排查。
500	ModelArts.4302	Gateway forwarding error. Failed to invoke backend service due to connection refused.	访问服务失败，拒绝连接	请检查访问的服务是否正常
500	ModelArts.4503	Failed to connect to backend service.	服务连接失败	请检查访问的服务是否正常
500	ModelArts.4505	Backend service internal error. Backend service read timed out.	服务内部错误	请检查访问的服务是否正常
503	ModelArts.4302	Backend service is not available, please retry later.	后端服务不可用	内部错误，请联系技术支持

状态码	错误码	错误信息	描述	处理措施
503	ModelArts.4700	Gateway service is in shutdown process.	网关服务正在关闭	平台正在升级，请重试
504	ModelArts.4503	Backend service respond timeout.	服务响应超时	请检查访问的服务是否正常
400	ModelArts.50004000	Invalid request. {message}	请求不合法。	请参考错误信息中的详细内容进行错误处理，或联系技术人员支持。
400	ModelArts.50004100	Invalid Content-Type. {message}	请求头中的 Content-Type 参数不合法。	请参考API文档使用支持的Content-Type。
400	ModelArts.50005102	Insufficient quota.	资源配额不足。	请检查当前租户是否有足够的资源配额，或联系技术支持人员增加资源配额。
400	ModelArts.50005103	No license.	用户的 ModelArts License 余量不足。	请联系技术支持人员增加License配额。
400	ModelArts.50005104	License expired.	用户当前使用的 ModelArts License 已过期。	请联系技术支持人员续费License。
401	ModelArts.50001000	Authorization failed. {message}	认证失败。	请参考错误信息中的详细内容进行错误处理，或联系技术人员支持。
403	ModelArts.50002000	Access prohibited. {message}	禁止访问。	请参考错误信息中的详细内容进行错误处理，或联系技术人员支持。
404	ModelArts.50005101	The resource does not exist.	未找到资源。	请确认待访问的资源是否存在，或资源名称是否正确。
404	ModelArts.50015001	The resource pool does not exist.	指定名称的资源池未找到。	请确认待访问的资源池是否存在，或资源池名称是否正确。

状态码	错误码	错误信息	描述	处理措施
404	ModelArts.50015007	The pool {pool_name} scope {scope_type} cannot be enabled.	逻辑子池禁止开启非法作业类型	请先开启逻辑子池的物理池的作业类型，保障启用成功。
404	ModelArts.50015011	The pool {pool_name} scope {scope_type} cannot be disabled, because some subpools are in use.	逻辑子池禁止取消正在使用的作业类型	请先释放逻辑子池中需要关闭的作业类型负载。
404	ModelArts.50015012	The pool {pool_name} has logical pools.	当前物理池已经创建过逻辑子池，无法直接在物理池上创建作业。	请先释放逻辑子池或在逻辑子池中创建作业。
404	ModelArts.50015014	The resources of pool {pool_name} are insufficient for its subpools.	逻辑子池的资源需求量大于物理池的剩余量。	扩容物理池或减少逻辑子池的资源需求量。
404	ModelArts.50015016	The resources of pool {pool_name} are insufficient for its workloads.	缩容逻辑子池时的目标资源量小于已使用剩余量。	释放逻辑子池中占用资源的作业。
404	ModelArts.50025001	The network does not exist.	指定名称的网络未找到。	请确认待访问的网络是否存在，或网络名称是否正确。
409	ModelArts.50005100	Duplicate resource name.	指定名称的资源已存在。	请删除同名资源后重试创建，或使用其他名称创建资源。
409	ModelArts.50015000	Duplicate resource pool name.	指定名称的资源池已经存在。	请删除同名资源池后重试创建，或使用其他名称创建资源池。

状态码	错误码	错误信息	描述	处理措施
409	ModelArts.50015002	Pending orders.	资源池有未完成处理的订单。	请等待当前订单完成后，再创建新的订单。
409	ModelArts.50025000	Duplicate network name.	指定名称的网络已存在。	请删除同名网络后重试创建，或使用其他名称创建网络。
413	ModelArts.50004400	Oversized request body. {message}	请求体过大。	请参考错误信息中的详细内容进行错误处理，或联系技术人员支持。
500	ModelArts.50005000	Internal error. {message}	服务内部错误。	请参考错误信息中的详细内容进行错误处理，或联系技术人员支持。
400	ModelArts.7501	Preset module name %s not exists.	Step中预置的module不存在。	建议使用存在的预置module，支持的workflow预置module参考workflowSDK中的StepTypeEnum。
400	ModelArts.7502	Custom module name %s already exists.	自定义Module名称%s已存在。	请更换新的module名称后进行重试。
400	ModelArts.7503	Step name %s not exists.	Step name %s不存在。	请使用Workflow中现已存在的step name。
400	ModelArts.7504	Module output channel %s not exists.	Module output channel %s不存在。	请更换channel名称后进行重试。
400	ModelArts.7505	Custom module namespace %s is occupied, please choose a new one.	自定义Module名称空间%s已被占用。	请重新定义一个未被使用的Module名称空间。
400	ModelArts.7506	Custom module %s not found.	Step %s中的自定义Module %s未找到。	请更换module名称后进行重试。

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.7507	You do not have the permission to access custom module %s.	无权限访问该自定义Module %s。	确认用户是否有权访问Module。
400	ModelArts.7508	Custom module namespace %s not found.	自定义Module命名空间%s未找到。	确认命名空间是否存在。
400	ModelArts.7509	Access to custom module namespace %s Permission denied.	无权限访问该自定义Module命名空间%s。	确认是否有访问module命名空间的权限。
400	ModelArts.7510	step_name: %s, python expression: %s error.	python语句错误。	请填写正确的python语句。
400	ModelArts.7511	Workflow Execution %s not found.	Workflow Execution %s未找到。	改用存在的executionID。
400	ModelArts.7512	Workflow %s not found.	Workflow %s未找到。	改用存在的WorkflowID。
400	ModelArts.7513	Template %s not found.	Template %s未找到。	确认预置Template在数据库中是否存在。
400	ModelArts.7514	Custom module name %s not exists.	自定义Module名称%s不存在。	确认自定义module名称是否正确。
400	ModelArts.7515	A running Custom module (%s) instance exists.	存在运行中的自定义Module %s实例。	确认module是否已经在运行。
400	ModelArts.7517	Workflow Version %s not found.	Workflow Version %s未找到。	确认Workflow的版本是否存在。
400	ModelArts.7518	Workflow Step Execution %s not found.	Workflow Step Execution %s未找到。	确认Step在Workflow中是否存在。

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.7519	Subscription %s not found.	Subscription %s未找到。	确认Subscription是否存在。
400	ModelArts.7520	Parameter %s value is invalid.	参数%s值错误。	请填写正确的参数值进行重试。
500	ModelArts.5000	Please try again later or contact customer service to solve the problem ({0}).	内部异常。	内部错误，联系运维开发人员处理。
500	ModelArts.5003	Internal Error: access IAM service failed({0}).	IAM服务访问失败。	IAM服务访问报错，联系运维开发人员处理。
500	ModelArts.5005	Internal Error: access ModelArts service failed ({0}).	ModelArts服务访问失败。	ModelArts服务访问失败，联系运维开发人员处理。
500	ModelArts.5006	Internal Error: access AI service failed ({0}).	AI Hub的service服务访问失败。	AI市场service服务访问失败，联系运维开发人员处理。
500	ModelArts.5007	Internal Error: access AI manager failed ({0}).	AI Hub的manager服务访问失败。	联系运维开发人员处理。
500	ModelArts.5009	Database operation failed.	AI Hub数据库操作异常。	连接数据库失败，联系运维开发人员处理。
500	ModelArts.5010	OBS operation failed ({0}).	对象存储服务访问失败。	访问对象存储服务失败，联系运维开发人员处理。
400	ModelArts.5011	Invalid parameter ({0}).	参数错误。	参数错误，填写正确参数。
403	ModelArts.5014	Permission deny ({0}).	没有权限。	资产权限问题，无权查看和操作。

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.5016	The original model ({0}) does not exist during model release.	创建的资产源模型不存在。	模型已经被删除不存在，重新发布。
400	ModelArts.5022	Unsupported model type.	不支持的模型类型。	模型类型不支持。
500	ModelArts.5039	Dear User,the traffic is a little busy. Please try again later.	流量超限。	当前访问太过频繁，稍后重试。
400	ModelArts.5041	Duplicate version. Refresh the page and try again.	版本重复，请刷新后再试。	版本重复，刷新页面查看之后再操作。
400	ModelArts.5052	The user does not have the agency permission ({0}).	用户没有提供委托权限。	未正确创建委托，在ModelArts页面创建委托再操作。
403	ModelArts.5053	Product has been recycled.	资产已回收。	资产已经下架，不可再操作。
403	ModelArts.5054	At least one available version must exist.	资产至少要存在一个可用版本。	最后一个可用资产版本不可下架。
403	ModelArts.5055	The subscription has expired.	订阅已过期。	订阅已经过期，需重新订阅。
400	ModelArts.5303	The obs source data is empty.	源目录为空。	发布的资产，资产存储地址为空。不可发布空文件夹。
400	ModelArts.5304	The maximum number of files has been exceeded ({0}).	文件总个数超过最大值。	减少发布的文件数量。

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.5305	The maximum size of files has been exceeded ({0}).	文件总大小超过最大值。	发布文件总大小过大。
400	ModelArts.5306	The maximum depth of files has been exceeded ({0}).	文件最大深度超过最大值。	资产所在地址文件夹过深。
403	ModelArts.3990	Cannot stop/delete the async service. There are still tasks related.	无法停止或删除该异步服务，该服务下仍有作业关联。	删除该异步服务下的所有作业后重新执行该操作即可。
500	ModelArts.3627	The license has expired.	License已过期。	从AI Hub重新订阅模型或者续订模型即可。
404	ModelArts.3401	Task {0} does not exist.	指定的作业不存在。	请检查指定的作业ID是否正确。
400	ModelArts.3402	The number of tasks of service {0} should not exceed {1}.	指定服务的作业数量不应超过配额。	请清理指定服务下的存量作业。
400	ModelArts.3403	Agency error. Please recheck your agency to ModelArts.	用户对ModelArts的委托异常。	请检查对ModelArts的委托是否被修改或删除。
403	ModelArts.3405	Tasks in this state cannot be started.	无法在该状态下启动作业。	该状态下的作业不支持启动。
403	ModelArts.3406	Tasks in this state cannot be stopped.	无法在该状态下停止作业。	该状态下的作业不支持停止。
403	ModelArts.3407	You do not have permission to access the resource.	无权访问该资源。	该资源（API、输入输出源、作业等）无权访问或不具备访问条件。

状态码	错误码	错误信息	描述	处理措施
403	ModelArts.3408	Tasks in this state cannot be updated.	无法在该状态下修改作业。	该状态下的作业不支持修改。
400	HIL.0841	The certificate can be downloaded up to 10 times when node is offline	证书无法下载超过10次	请确认设备证书是否下载超过10次，请重新在页面上创建新设备，申请新证书
400	ModelArts.3941	Failed to activate all nodes.Check the node status or whether the license is sufficient.	节点激活失败，请检查节点状态或license是否充足。	请确认节点状态是运行中，并且确保license充足。
400	ModelArts.3551	OBS path {0} does not exist.	obs路径不存在。	检查obs路径是否正确。
400	ModelArts.50015013	Your account has no OBS policy agency to modelarts, error info {0}.	obs权限的委托不存在。	请检查授予ModelArts云服务的委托是否包括OBS权限。
500	ModelArts.6204	OBS connect fail. Please check whether the OBS service is normal or not.	OBS链接失败	请检查OBS云服务是否正常
400	ModelArts.3067	Failed to obtain image size due to {0}.	无法获取镜像大小 常见原因可能为 • SWR限流 • 用户对镜像没有权限或者共享镜像已过期。	• 可稍后重试。 • 使用共享镜像创建模型时需要将该镜像共享给ModelArts租户，同时确保创建模型时共享镜像未过期。

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.6400	不合法的请求{0}, 请检查。	不合法的请求{0}, 请检查。	参数不合法, 请根据具体错误信息处理参数
400	ModelArts.6715	找不到project_id {0}和user_id {1}的委托记录。	找不到对应用户的委托记录。	添加用户委托后进行重试。
400	ModelArts.6927	挂载路径{0}格式无效, 挂载路径由"/[a-zA-Z0-9_-]"组成。	挂载路径{0}格式无效, 挂载路径由"/[a-zA-Z0-9_-]"组成。	参数不合法, 请根据具体错误信息处理参数
400	ModelArts.6978	URL中的project_id与token中的project_id不匹配	URL中的project_id与token中的project_id不匹配	参数不合法, 请根据具体错误信息处理参数
400	ModelArts.8000	无法按类型{0}找到推理服务管理器。	无法按类型{0}找到推理服务管理器。	请检查推理服务类型, 当前只支持REAL_TIME
400	ModelArts.8001	Env变量名称非法, 最长达64个字符, 由字母、数字、下划线、中划线、点组成, 不能以数字开头。	Env变量名称非法, 最长达64个字符, 由字母、数字、下划线、中划线、点组成, 不能以数字开头。	请检查环境变量键值对的合法性
400	ModelArts.8002	Env变量值错误, 输入内容不能存在HTML标签, 包括<^>。	Env变量值错误, 输入内容不能存在HTML标签, 包括<^>。	请检查环境变量键值对的合法性
400	ModelArts.8003	找不到特定的规格。	找不到特定的规格。	请检查是否有可用的规格
400	ModelArts.8004	无效的镜像来源{0}。	无效的镜像来源{0}。	请修改镜像来源
400	ModelArts.8007	单机部署类型只有一个实例单元	单机部署类型只有一个实例单元	请确保只有一个实例单元

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.8009	mindie框架调度单元、管理单元和工作单元各需要一个。	mindie框架调度单元、管理单元和工作单元各需要一个。	请确保mindie框架调度单元、管理单元和工作单元各一个
400	ModelArts.8010	vllm框架调度单元、全量推理单元和增量推理单元各需要一个。	vllm框架调度单元、全量推理单元和增量推理单元各需要一个。	请确保vllm框架调度单元、全量推理单元和增量推理单元各需要一个
400	ModelArts.8011	当前部署类型{0}仅支持Mindie和VLLM框架。	当前部署类型{0}仅支持Mindie和VLLM框架。	请确保部署类型为Mindie和VLLM框架
400	ModelArts.8012	分离部署实例单元总数必须是三个。	分离部署实例单元总数必须是三个。	请检查实例单元总数为三个
400	ModelArts.8013	无效的部署类型{0}，请重试。	无效的部署类型{0}，请重试。	切换正确的部署类型后进行重新部署
400	ModelArts.8014	当前部署类型{0}只支持common框架。	当前部署类型{0}只支持common框架。	参数校验失败，按错误提示填写对应的参数
400	ModelArts.8015	此api-key正在被其他服务使用。	此api-key正在被其他服务使用。	换一个api-key使用
400	ModelArts.8016	当前服务已绑定此api-key。	当前服务已绑定此api-key。	当前服务已绑定此api-key，请换未绑定过的api-key
400	ModelArts.8017	api-key数量达到了上限。	api-key数量达到了上限。	请删除已有的api-key后，再进行新建操作
400	ModelArts.8019	授权全部在线服务的API Key不支持绑定/解绑单个服务。	授权全部在线服务的API Key不支持绑定/解绑单个服务。	重新调用服务
400	ModelArts.8020	此api-key没有绑定当前服务。	此api-key没有绑定当前服务。	请输入已绑定当前服务的api-key

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.8023	无法根据服务ID{0}找到dispatcher群组。	无法根据服务ID{0}找到dispatcher群组。	重新选择服务。
400	ModelArts.8027	sfs turbo{0}不可用。	sfs turbo{0}不可用。	请检查sfs turbo网络关联是否正常
400	ModelArts.8028	仅支持[hpc]型sfs-turbo。	仅支持[hpc]型sfs-turbo。	检查turbo规格是否正确
400	ModelArts.8029	调用ModelArts资源管理服务操作失败，出现异常{0}	调用ModelArts资源管理服务操作失败，出现异常{0}	联系服务运维人员解决
400	ModelArts.8030	当前在线服务{0}创建的版本数量已达上限{1}，请删除版本后重试。	当前在线服务{0}创建的版本数量已达上限{1}，请删除版本后重试。	最大版本数量超过限制，需要根据提示将版本数量删除到提示的版本数量以下
400	ModelArts.8031	当前在线服务{0}下已有版本{1}，仅修改描述时，允许选择已有版本进行修改。	当前在线服务{0}下已有版本{1}，仅修改描述时，允许选择已有版本进行修改。	当前升级的目标版本号已经存在，需要选择一个未被占用的版本号；或查看请求体，如果需要修改一个版本号已经存在的服务，只能修改描述description字段
400	ModelArts.8032	无法根据请求体数据找到对应的服务升级类型，需要根据api文档检查更新请求体是否正确。	无法根据请求体数据找到对应的服务升级类型，需要根据api文档检查更新请求体是否正确。	无法根据请求体数据找到对应的服务构建器，需要检查更新请求体是否正确
400	ModelArts.8033	无法根据请求体数据找到对应的实例组，需要检查更新请求体group_configs参数是否正确。	无法根据请求体数据找到对应的实例组，需要检查更新请求体group_configs参数是否正确。	无法根据请求体数据找到对应的实例组构建器，需要检查请求体是否正确

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.8034	系统规格和自定义规格不能同时设置	系统规格和自定义规格不能同时设置	系统规格和自定义规格不能同时设置，需要检查请求中flavor字段和custom_spec字段是否同时存在
400	ModelArts.8035	ws,wss协议和ratelimit不能同时存在。	ws,wss协议和ratelimit不能同时存在。	ws,wss协议和ratelimit不能同时存在
400	ModelArts.8036	流量限制单元只支持seconds和minutes。	流量限制单元只支持seconds和minutes。	流量限制单元只支持seconds和minutes
400	ModelArts.8037	RateLimit不能为空。	RateLimit不能为空。	非 WS/WSS 协议必须设置流量限制
400	ModelArts.8040	不支持的升级参数类型{0}。	不支持的升级参数类型{0}。	请输入服务支持的参数类型
400	ModelArts.8041	日志流配额不足，请删除无用日志流。	日志流配额不足，请删除无用日志流。	请增加配额或删除无用日志流后，进行重试
400	ModelArts.8042	找不到该日志组{0}。	找不到该日志组{0}。	请确保该日志组存在
400	ModelArts.8043	找不到该日志流{0}。	找不到该日志流{0}。	请确保该日志流存在
400	ModelArts.8044	配额不足，创建日志组失败。	配额不足，创建日志组失败。	请增加配额后重试
400	ModelArts.8045	创建在指定日志组中创建日志流失败，请联系运维人员。	在指定日志组{0}中创建日志流{1}失败	联系服务运维人员解决
400	ModelArts.8046	每种日志类型只能创建一个日志配置。	每种日志类型只能创建一个日志配置。	请检查日志类型，STDOUT和FILE日志类型只能选一个
400	ModelArts.8047	非新增实例组场景下，不允许修改flavor和custom_spec	非新增实例组场景下，不允许修改flavor和custom_spec	不允许修改flavor和custom_spec

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.8048	资源池{0}创建专属通道失败{1}。	资源池{0}创建专属通道失败{1}。	联系服务运维人员解决
400	ModelArts.8049	无法{0}服务{1}，因为服务被并发操作。	无法{0}服务{1}，因为服务被并发操作。	请稍后重试
400	ModelArts.8050	在线服务运行配置中协议选项仅支持{0}，当前入参为{1}。	在线服务运行配置中协议选项仅支持{0}，当前入参为{1}。	参数校验失败，按错误提示填写对应的参数
400	ModelArts.8051	在线服务运行配置中协议选项仅支持{0}，当前入参为{1}。	在线服务运行配置中协议选项仅支持{0}，当前入参为{1}。	参数校验失败，按错误提示填写对应的参数
400	ModelArts.8052	实例单元的个数不能超过{0}。	实例单元的个数不能超过{0}。	请确保实例单元的个数在{0}个以内
400	ModelArts.8053	单角色为scheduler或者manager,这些角色单元数量要为{0}。	单角色为scheduler或者manager,这些角色单元数量要为{0}。	修改实例个数
400	ModelArts.8054	当前服务不可进行中断：{0}。	当前服务不可进行中断：{0}。	联系服务运维人员解决
400	ModelArts.8055	ip黑白名单仅支持ipv4或cidr。	ip黑白名单仅支持ipv4或cidr。	请检查IP黑白名单配置，ip黑白名单配置仅支持IPv4形式或者cidr形式
400	ModelArts.8056	ip黑白名单不能同时存在。	ip黑白名单不能同时存在。	请检查黑白名单策略，访问控制策略的黑名单ip_black_list和白名单ip_white_list策略只能同时存在一个
400	ModelArts.8058	无法找到pod {0}。	无法找到pod {0}。	请输入正确的pod id
400	ModelArts.8059	pod {0}中不存在可用的容器。	pod {0}中不存在可用的容器。	请确保该pod有可用容器

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.8064	找不到内网申请 {0}。	找不到内网申请 {0}。	请确保该内网申请已存在
400	ModelArts.8065	非法的内网申请变更参数 {0}。	非法的内网申请变更参数 {0}。	参数校验失败，按错误提示填写对应的参数
400	ModelArts.8067	在当前子网下已存在该服务的内网接入申请，服务id: {0}。	在当前子网下已存在该服务的内网接入申请，服务id: {0}。	请先删除已有的内网接入申请后，再重新申请
400	ModelArts.8069	当前只支持处于运行中、告警、升级中的服务创建内网接入。	服务（{0}）当前状态（{0}）不支持创建内网接入。	服务当前状态不支持创建内网接入。
400	ModelArts.8071	非法的内网接入创建参数。	非法的内网接入创建参数。	请检查是否有对应权限
400	ModelArts.8072	subpath:{0}无效.因为: {0}。	subpath:{0}无效.因为: {0}。	联系服务运维人员解决
400	ModelArts.8073	模型来源{0}不支持本地挂载加速。	模型来源{0}不支持本地挂载加速。	检查参数是否符合规格，是否正确
400	ModelArts.8074	共享资源池不支持本地挂载加速。	共享资源池不支持本地挂载加速。	检查参数是否符合规格，公共资源池不支持挂载加速
400	ModelArts.8075	磁盘空间{0}gb小于1tb，不支持本地挂载加速。	磁盘空间{0}gb小于1tb，不支持本地挂载加速。	检查参数是否符合规格，磁盘空间小于1T，不支持挂载加速
400	ModelArts.8077	公共池的服务 {0} 不支持 cloud shell。	公共池的服务 {0} 不支持 cloud shell。	公共池服务不支持 cloud shell。
400	ModelArts.8079	公共池不支持专属通道。	公共池不支持专属通道。	公共池不支持专属通道，请使用专属资源池
400	ModelArts.8080	公共池不支持智能路由。	公共池不支持智能路由。	公共池不支持智能路由，请使用专属资源池

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.8082	公共池创建服务的时候不支持 custom_spec 参数。	公共池创建服务的时候不支持 custom_spec 参数。	参数校验失败，按错误提示填写对应的参数
400	ModelArts.8083	公共池创建服务不支持EFS挂载。	公共池创建服务不支持EFS挂载。	参数校验失败，按错误提示填写对应的参数
400	ModelArts.8084	规格 {0} 没有找到对应的资源池。	规格 {0} 没有找到对应的资源池。	请确保输入正确的规格
400	ModelArts.8085	kubeinfer实例【{0}】只剩一个，禁止删除。	kubeinfer实例【{0}】只剩一个，禁止删除。	在实例个数只剩一个时，禁止删除 kubeinfer实例
400	ModelArts.8086	服务id{0}未找到。	服务id{0}未找到。	请输入正确的服务id
400	ModelArts.8088	无法获取资源池 {0} 的节点。	无法获取资源池 {0} 的节点。	请确保输入正确的资源池id
400	ModelArts.8089	公共池不支持 priority。	公共池不支持 priority。	公共池不支持 priority，请使用专属资源池
400	ModelArts.8090	公共池不支持企业镜像。	公共池不支持企业镜像。	公共池不支持企业镜像，请使用专属资源池
400	ModelArts.8091	无法获取项目 {0} 的资源池。	无法获取项目 {0} 的资源池。	请确保输入正确的项目id
400	ModelArts.8092	公共资源池{1}的{0}资源不足, 需求大小: {2}, 余量: {3}。	公共资源池{1}的{0}资源不足, 需求大小: {2}, 余量: {3}。	请检查公共资源池对应的配额
400	ModelArts.8093	公共池资源紧张，无法分配资源，请减少本次请求资源配额	公共池资源紧张，无法分配资源，请减少本次请求资源配额	资源余量不足，释放其他资源或减少本次请求资源规格
400	ModelArts.8094	公共池不支持节点亲和配置。	公共池不支持节点亲和配置。	公共池不支持节点亲和配置，请使用专属资源池

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.8095	License校验错误，请联系管理员。	License校验错误	联系服务运维人员解决
400	ModelArts.8096	license已过期，请联系管理员。	license已过期，请联系管理员。	联系服务运维人员解决
400	ModelArts.8097	非法的密钥参数。{0}	非法的密钥参数。{0}	密钥参数非法。
400	ModelArts.8098	请求的配额资源已超限制：{0}	请求的配额资源已超限制：{0}	重新检查配额资源。
400	ModelArts.8099	旧实例 {0} 不能被重建，只能删除。	旧实例 {0} 不能被重建，只能删除。	切勿重建旧实例，请删除后新建实例
400	ModelArts.8102	apikey绑定或解绑操作失败，失败原因： workspace id 不一致， apikey {0} workspace id={1}， service {2} workspace id={3}	apikey绑定或解绑操作失败，失败原因： workspace id 不一致， apikey {0} workspace id={1}， service {2} workspace id={3}	请检查工作空间与api-key信息
400	ModelArts.8103	OBS密钥创建失败 {0}.	OBS密钥创建失败 {0}.	请重试，或者找运维人员解决
400	ModelArts.8104	扩展规则中存在重复字段：{0}	扩展规则中存在重复字段：{0}	检查参数中扩展规则字段，值已存在
400	ModelArts.8105	扩缩容策略已经存在，不允许执行当前操作。	扩缩容策略已经存在，不允许执行当前操作。	检查参数数据，该策略已存在
400	ModelArts.8108	扩缩容规格不允许为空。	扩缩容规格不允许为空。	检查参数是否符合规格，其中规则不能为空

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.8109	自动扩缩容策略操作字段不能为空或值不正确	自动扩缩容策略操作字段不能为空或值不正确	检查参数是否符合规格，其中规则中操作字段不能为空或值不为ADD、UPDATE、DELETE。
400	ModelArts.8110	自动扩缩容策略规则ID不能为空或值不正确	自动扩缩容策略规则ID不能为空或值不正确	检查参数是否符合规格，其中规则ID不能为空或值不存在
400	ModelArts.8112	当前场景最大实例组数量为1	当前场景最大实例组数量为1	检查实例参数实例组数量是否超过限制1
400	ModelArts.8113	在当前vpc下已存在该服务的内网接入申请，内网接入id: {0}。	在当前vpc下已存在该服务的内网接入申请，内网接入id: {0}。	对于同一个服务，在同一个vpc下只能创建一个内网接入申请，请检查是否存在审批中、接入中或者接入成功的申请
400	ModelArts.8114	vpc与子网id不匹配。	vpc与子网id不匹配。	请检查vpc下是否有对应的子网。
400	ModelArts.8115	不支持创建pool类型的内网接入。	不支持创建pool类型的内网接入。	请使用vpc类型的内网接入
400	ModelArts.8116	内网连接ID不能为空	内网连接ID不能为空	检查内网连接ID是否存在空值
400	ModelArts.8117	专属资源池{1}的{0}资源不足, 需求大小: {2}, 余量: {3}.	专属资源池{1}的{0}资源不足, 需求大小: {2}, 余量: {3}.	请检查专属资源池资源余额。
400	ModelArts.8118	专属池资源不足，无法完成部署	专属池资源不足，无法完成部署，请释放其他资源或减少本次请求资源配额	请释放其他资源或减少本次请求资源配额
400	ModelArts.8119	父池未开启节点绑定时，逻辑子池不支持节点亲和	父池未开启节点绑定时，逻辑子池不支持节点亲和	请开启父池的节点绑定

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.8120	未提供任何有效的亲和节点	未提供任何有效的亲和节点	检查提供的亲和节点列表，校验时会去除异常/不可调度/开启高可用的节点，当前剔除后无可用节点
400	ModelArts.8121	服务仅在运行中、告警和停止状态下支持扩缩容规则添加、修改和删除	服务仅在运行中、告警和停止状态下支持扩缩容规则添加、修改和删除	检查当前服务状态，是否处于运行中、告警或停止状态
400	ModelArts.8122	参数错误，其中service_id和group_id不匹配	参数错误，其中service_id和group_id不匹配	检查您的参数，查看当前group_id是否属于service_id下
400	ModelArts.8123	查询子网失败，权限不足。	查询子网失败，权限不足。	检查当前用户是否有对应的权限
400	ModelArts.8124	标签数量不能超过{0}。	标签数量不能超过{0}。	请确保标签数量在{0}个以内
400	ModelArts.8125	自动停止任务的时间范围需要在1分钟-7天之间。	自动停止任务的时间范围需要在1分钟-7天之间。	超出时间范围限制。自动停止任务的时间范围需要在1分钟-7天之间。
400	ModelArts.8126	只能修改定时扩缩容规则是否启用。	只能修改定时扩缩容规则是否启用。	只能修改定时扩缩容规则是否启用。
400	ModelArts.8127	服务状态不支持该操作：{0}	服务状态不支持该操作：{0}	检查服务状态。
400	ModelArts.8134	SWR服务繁忙，请稍后重试。	SWR服务繁忙，请稍后重试。	SWR服务繁忙，请稍后重试。
400	ModelArts.8149	当前服务：{0}的authType不支持bind。auth_type为{1}而不是API_KEY。</td><td>绑定前请检查服务的认证类型是否为API_KEY	当前服务：{0}的authType不支持bind。auth_type为{1}而不是API_KEY。</td><td>绑定前请检查服务的认证类型是否为API_KEY	绑定前请检查服务的认证类型是否为API_KEY

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.8167	该服务部署取消，服务资源未就绪，API KEY无法绑定。		启动服务，等服务成功创建出来，ConfigMap存在之后再绑定API KEY。
400	ModelArts.8168	参数异常，模型来源同时传入了多种类型。	模型挂载类型必须唯一	检查模型来源是否同时传入了多种类型，例如同时开启了obs和sfs turbo挂载。
400	ModelArts.8169	挂载Maas网关时，需填写模型名称和模型类型。	挂载Maas网关时，需填写模型名称和模型类型。	请检查模型相关参数是否填写
400	ModelArts.8170	请求的offset必须是limit的整数倍。	请求的offset必须是limit的整数倍。	请检查offset、limit参数是否满足要求。
400	ModelArts.8171	存在无效的cron表达式或新的cron表达式无效。cron: {0}	存在无效的cron表达式或新的cron表达式无效。cron: {0}	检查cron表达式是否有效
400	ModelArts.8172	扩缩容规则的触发时间{0}和已存在扩缩容规则的触发时间{1}在未来的一年内有重合，重合时间为{2}	扩缩容规则的触发时间{0}和已存在扩缩容规则的触发时间{1}在未来的一年内有重合，重合时间为{2}	检查扩缩容规则触发时间cron是否与已存在扩缩容规则触发时间cron在未来一年内有重合
400	ModelArts.8173	模型挂载类型必须唯一	模型挂载类型必须唯一	检查模型来源是否同时传入了多种类型，例如同时开启了obs和sfs turbo挂载。
400	ModelArts.8174	当前服务状态：{0}，此状态下不允许修改优先级	当前服务状态：{0}，此状态下不允许修改优先级	运行状态、告警状态和异常状态的在线服务不允许修改优先级
400	ModelArts.8177	挂载Maas网关时，认证方式需设置为无认证。	挂载Maas网关时，认证方式需设置为无认证。	挂载Maas网关时，认证方式需设置为无认证。

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.8178	挂载Maas网关时，需关闭外网访问。	挂载Maas网关时，需关闭外网访问。	挂载Maas网关时，需关闭外网访问。
400	ModelArts.8179	资源池{0}不存在或者未启用新版推理服务。	资源池{0}不存在或者未启用新版推理服务。	请检查资源池是否存在或启用新版推理服务
400	ModelArts.8180	未找到预热镜像{0}。	未找到预热镜像{0}，请检查该预热镜像是否删除。	请检查该预热镜像是否删除。
400	ModelArts.8181	预热镜像{0}的地址不匹配。	预热镜像{0}的地址不匹配，请检查。	请检查预热镜像的地址是否正确。
400	ModelArts.8182	VPC ID 错误。	VPC ID 错误。	使用正确的VPC id
400	ModelArts.8183	无法设置{0}规格：{1}，请检查资源池的资源规格。	无法设置{0}规格：{1}，请检查资源池的资源规格。	无法设置{0}规格：{1}，请检查资源池的资源规格。
400	ModelArts.8184	挂载路径{0}的挂载模式为只读，不支持将其他挂载路径设置为此路径的子路径。	挂载路径{0}的挂载模式为只读，不支持将其他挂载路径设置为此路径的子路径。	检查模型、密钥或代码挂载路径是否为只读路径的子路径
400	ModelArts.8185	当前部署{0}已存在版本{1}。现有版本，仅可修改描述。	当前部署{0}已存在版本{1}。现有版本，仅可修改描述。	当前升级的目标版本号已经存在，需要选择一个未被占用的版本号；或查看请求体，如果需要修改一个版本号已经存在的服务，只能修改描述description字段
400	ModelArts.8186	并行文件系统PFS不支持嵌套子路径的挂载，请检查	并行文件系统PFS不支持嵌套子路径的挂载，请检查	请检查挂载路径是否存在路径间的嵌套
400	ModelArts.8187	升级部署时不支持传入密钥配置参数，请使用正确的参数升级部署	升级部署时不支持传入密钥配置参数，请使用正确的参数升级部署	升级部署时不支持传入密钥配置参数，请使用正确的参数升级部署

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.8188	OBS挂载时获取了错误的部署实例		请联系管理员，修改正确的挂载参数配置
400	ModelArts.8189	缺少部署{0}的权重配置。	缺少部署{0}的权重配置。	参数校验失败，按错误提示填写对应的参数。
400	ModelArts.8190	服务认证方式不是API_KEY，禁止API_KEY绑定操作。	服务认证方式不是API_KEY，禁止API_KEY绑定操作。	修改服务的认证方式为API_KEY。
400	ModelArts.8191	当前存在部署处于中间状态，无法执行该操作，请稍后再试。	当前存在部署处于中间状态，无法执行该操作，请稍后再试。	当前存在部署处于中间状态，无法执行该操作，请稍后再试。
400	ModelArts.8192	部署版本切换失败。	部署版本切换失败。	部署版本切换失败。
400	ModelArts.8193	服务没有部署不支持绑定API_KEY。	服务没有部署不支持绑定API_KEY。	给服务添加一个部署。
400	ModelArts.8194	单个服务最多支持{0}个部署	单个服务最多支持{0}个部署	单个服务最多支持{0}个部署
400	ModelArts.8195	环境变量 ”{0}” 不支持设置	环境变量 ”{0}” 不支持设置	环境变量 ”{0}” 不支持设置
400	ModelArts.8910	请求的协议是{0}与服务的协议{1}不匹配	请求的协议与服务的协议不匹配	请使用正确的协议发起请求
400	ModelArts.8915	服务id不合法。	服务id不合法。	请检查服务id
400	ModelArts.8917	长连接升级错误：{0}	长连接升级错误	长连接升级错误，请稍后重试
400	ModelArts.8918	当前不可用，请稍后重连	当前不可用，请稍后重连	当前不可用，请稍后重连
400	ModelArts.8922	请求会话id长度%d超过了允许的最大长度%d	请求会话id长度%d超过了允许的最大长度%d	请求会话id长度超过了允许的最大长度
400	ModelArts.8924	Task id不合法。	Task id不合法。	Task id不合法。

状态码	错误码	错误信息	描述	处理措施
400	ModelArts.8925	无法读取请求体: %s	无法读取请求体: %s	无法读取请求体: %s
400	ModelArts.8926	请求体JSON格式错误	请求体JSON格式错误	请求体JSON格式错误
401	ModelArts.0201	Token为空	Token为空	请在请求头中添加正确token
401	ModelArts.0203	无效Token, 无法解析	无效Token, 无法解析	请更换有效token
401	ModelArts.0204	解析Token失败	解析Token失败	请更换有效token
401	ModelArts.8900	服务{0}暂不支持{0}的鉴权类型	服务暂不支持的鉴权类型	请使用正确的鉴权类型
401	ModelArts.8901	无效的api key, {0}	无效的api key	请使用正确的api key
401	ModelArts.8902	Api key校验失败, {0}	Api key校验失败	1. 检查Api key已绑定当前服务; 2. 检查Api key没有失效。
403	ModelArts.8060	{0}权限策略缺失	iam5细粒度鉴权action权限策略缺失	查看用户对应action的iam5权限是否缺失
403	ModelArts.8061	认证失败{0}。	认证失败{0}。	联系服务运维人员解决
403	ModelArts.8066	用户无权访问这个资源池{0}。	用户无权访问这个资源池{0}。	请检查是否有对应权限
403	ModelArts.8070	用户（{0}）无权操作这个内网连接（{1}）。	用户（{0}）无权操作这个内网连接（{1}）。	请检查是否有对应权限
403	ModelArts.8804	推理服务未开启专属通道功能	推理服务未开启专属通道功能	推理服务未开启专属通道功能
403	ModelArts.8914	拒绝访问, {0}	拒绝访问	拒绝访问, 请稍后重试
403	ModelArts.8919	源地址禁止通过内网访问服务: {0}	源地址禁止通过内网访问服务: {0}	源地址禁止通过内网访问服务

状态码	错误码	错误信息	描述	处理措施
403	ModelArts.8920	服务（{0}）禁止通过公网访问服务	服务禁止通过公网访问服务	服务禁止通过公网访问服务
403	ModelArts.8921	未知的访问类型: {0}	未知的访问类型	未知的访问类型
404	ModelArts.2836	未找到路径	未找到路径	请确认路径是否正确
404	ModelArts.8024	找不到id为 {0} 且项目为 {1} 的服务或没有操作权限。	找不到id为 {0} 且项目为 {1} 的服务或没有操作权限。	请检查是否有对应权限
404	ModelArts.8063	找不到 dispatcher group {0}。	找不到 dispatcher group {0}。	请确保输入正确的实例组id
404	ModelArts.8106	没有操作权限。	没有操作权限。	检查用户权限是否符合
404	ModelArts.8107	无法找到自动扩缩容策略	无法找到自动扩缩容策略	检查参数实例组ID下是否存在自动扩缩容策略
404	ModelArts.8800	服务{0}不存在	服务不存在	服务不存在
404	ModelArts.8904	服务{0}不存在	服务不存在	检查服务是否存在
405	ModelArts.2803	不允许的方法	不允许的方法	请确认 HTTP 方法是否正确
409	ModelArts.8006	服务名称{0}冲突，请更新后重试。	服务名称{0}冲突，请更新后重试。	输入不重复的服务名称
409	ModelArts.8021	api-key名称: {0} 已存在。	api-key名称: {0} 已存在。	输入不重复的api-key名称
413	ModelArts.4104	请求body体长度不合法	请求body体长度不合法	请使用合适大小的请求体
429	ModelArts.4206	请求数量达到限制	请求数量达到限制	达到限流，请稍后重试
429	ModelArts.8913	服务请求被熔断，{0}	服务请求被熔断	服务请求被熔断，请稍后重试
429	ModelArts.8916	请求连接数超过系统阈值	请求连接数超过系统阈值	请求连接数超过系统阈值，请稍后重试

状态码	错误码	错误信息	描述	处理措施
500	ModelArts.2950	未知错误	未知错误	系统错误，请联系技术支持。
500	ModelArts.6500	出现内部错误，请稍后重试或联系服务运维人员解决	出现内部错误，请稍后重试或联系服务运维人员解决	请稍后重试或联系服务运维人员解决
500	ModelArts.8801	服务{0}的配置信息不存在，请稍后重试	服务的配置信息不存在，请稍后重试	服务的配置信息不存在，请稍后重试
500	ModelArts.8803	请求失败:{0}	请求失败，请联系技术支持。	请求失败，请联系技术支持。
500	ModelArts.8905	服务{0}的配置信息不存在，请稍后重试	服务的配置信息不存在，请稍后重试	服务的配置信息不存在，请稍后重试
500	ModelArts.8906	服务{0}的实例分组不存在，请稍后重试	服务的实例分组不存在，请稍后重试	服务的实例分组不存在，请稍后重试
500	ModelArts.8907	服务{0}的配置信息查询失败，请稍后重试	服务的配置信息查询失败，请稍后重试	服务的配置信息查询失败，请稍后重试
500	ModelArts.8908	服务{0}的实例分组查询失败，请稍后重试	服务的实例分组查询失败，请稍后重试	服务的实例分组查询失败，请稍后重试
500	ModelArts.8909	请求失败:{0}	请求失败，请联系技术支持。	请求失败，请联系技术支持。
500	ModelArts.8923	插件处理失败	插件处理失败	插件处理失败
503	ModelArts.8903	服务{0}没有可用的后端节点，请稍后重试	服务没有可用的后端节点，请稍后重试	服务没有可用的后端节点，请稍后重试

17.3 获取资源空间 ID 和名称

操作场景

在调用接口的时候，部分请求中需要填入资源空间ID或资源空间名称，所以需要获取到资源空间ID和名称。有如下两种获取方式：

- [从控制台获取资源空间ID和名称](#)
- [调用API获取资源空间ID](#)

从控制台获取资源空间 ID 和名称

从控制台获取资源空间ID（ project_id ）和名称（ project name ）的步骤如下：

1. 登录管理控制台。
2. 在页面右上角单击用户图标，在下拉列表中选择“个人设置”。
3. 在“个人设置”的“资源空间列表”页签下，获取“ID”即资源空间ID，“资源空间名称”即资源空间名称。

图 17-1 查看资源空间 ID 和名称



资源空间列表	管理访问密钥	用户组列表
资源空间名称	资源空间别名	ID

调用 API 获取资源空间 ID

获取资源空间ID的接口为GET <https://{iam-endpoint}/v3/projects>，其中{iam-endpoint}的获取方式请参见[请求URI](#)。

响应示例如下，例如ModelArts部署的区域为"xxx"，响应消息体中查找“name”为"xxx"，其中projects下的“id”即为资源空间ID。

```
{
  "projects": [{
    "domain_id": "65382450e8f64ac0870cd180d14e684b",
    "is_domain": false,
    "parent_id": "65382450e8f64ac0870cd180d14e684b",
    "name": "xxx",
    "description": "",
    "links": {
      "next": null,
      "previous": null,
      "self": "https://www.example.com/v3/projects/a4a5d4098fb4474fa22cd05f897d6b99"
    },
    "id": "a4a5d4098fb4474fa22cd05f897d6b99",
    "enabled": true
  }],
  "links": {
    "next": null,
    "previous": null,
    "self": "https://www.example.com/v3/projects"
  }
}
```



```
}  
}
```

17.4 获取租户名和租户 ID

在调用接口的时候，部分请求中需要填入租户名（domain name）和租户ID（domain_id）。获取步骤如下：

1. 登录管理控制台。
2. 在页面右上角单击用户图标，在下拉列表中选择“个人设置”。
在“个人设置”页面，查看“所属租户”和“租户ID”。

17.5 获取用户名和用户 ID

在调用接口的时候，部分请求中需要填入用户名（user name）和用户ID（user_id）。获取步骤如下：

1. 登录管理控制台。
2. 在页面右上角单击用户图标，在下拉列表中选择“个人设置”。
在“个人设置”页面，查看“用户名”和“用户ID”。

17.6 获取 Token

当通过调用API接口进行相关业务操作时，需要先获取Token。本节提供两种方法获取用户的Token。

- [使用Postman获取用户Token](#)
- [登录ModelArts Common-Proxy虚拟机获取Token](#)

使用 Postman 获取用户 Token

1. 提前下载Postman工具。
2. 准备获取Token所需的参数值。

表 17-2 获取 Token 所需的参数值

参数	描述	获取方式
float_ip	APIGW LB虚拟机浮动IP	联系管理员获取，从安装ModelArts服务时由HCC Turnkey工程导出的《xxx_export_all_v2_CN.xlsx》文件的“基本参数”页签中搜索“shubao_lb_float_ip”获取。
external_domain_name	外部域名后缀	联系管理员获取，从安装ModelArts服务时由HCC Turnkey工程导出的《xxx_export_all_v2_CN.xlsx》文件的“基本参数”页签中搜索“external_global_domain_name”获取。

参数	描述	获取方式
region_id	Region ID	联系管理员获取，从安装ModelArts服务时由HCC Turnkey工程导出的《xxx_export_all_v2_CN.xlsx》文件的“基本参数”页签中搜索“region0_id”获取。
user_name/ user_password	用户名和密码	获取方法请参见 获取用户名 。
domain_name	用户所属的租户名	获取方法请参见 获取租户名 。
project_name	资源空间名称	获取方法请参见 获取资源空间名称 。

- （可选，若已配置则跳过）在本地hosts文件中添加global域名信息，如下所示：
{float_ip} iam-apigateway-proxy.{region_id}.{external_domain_name}
- 使用Postman获取Token。其中加粗斜体的参数值由2获取。
 - 请求方法：POST
 - 请求URL：
`https://iam-apigateway-proxy.{region_id}.{external_domain_name}/v3/auth/tokens`
 - 请求Header：
`headers = {"Content-Type": "application/json"}`
 - 请求Body：

```
{
  "auth": {
    "identity": {
      "methods": ["password"],
      "password": {
        "user": {
          "name": "{user_name}",
          "password": "{user_password}",
          "domain": {
            "name": "{domain_name}"
          }
        }
      }
    }
  },
  "scope": {
    "project": {
      "name": "{project_name}"
    }
  }
}
```
- 返回状态码“201 Created”后，在响应Header中获取“X-Subject-Token”的值即为用户的Token。

登录 ModelArts Common-Proxy 虚拟机获取 Token

- 准备获取Token所需的参数值。

表 17-3 获取 Token 所需的参数值

参数	描述	获取方式
internal_domain_name	内部global域名后缀	联系管理员获取，从安装ModelArts服务时由HCC Turnkey工程导出的《xxx_export_all_v2_CN.xlsx》文件的“基本参数”页签中搜索“global_domain_name”获取。
user_name/ user_password	用户名和密码	获取方法请参见 获取用户名 。
domain_name	用户所属的租户名	获取方法请参见 获取租户名 。
project_name	资源空间名称	获取方法请参见 获取资源空间名称 。

2. 登录ModelArts服务Common-Proxy虚拟机。
- 登录ServiceOM，前往[服务列表 > 计算资源 > 虚拟机](#)页面，搜索名称为**ModelArts-Common-Proxy**的虚拟机，任选其中一个虚拟机的IP地址通过SSH命令登录。
- ssh opsadmin@<ModelArts-Common-Proxy节点IP>
- opsadmin账号的默认密码：参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索“ModelArts-Common-Proxy”获取。
3. 使用curl命令获取Token。其中加粗斜体的参数值由1获取。
- 执行命令如下：
- curl -kv -X POST https://iam-cache-proxy.{internal_domain_name}:26335/v3/auth/tokens -H 'Content-Type: application/json; charset=utf-8' -d '{
- {
- "auth": {
- "identity": {
- "methods": ["password"],
- "password": {
- "user": {
- "name": "{user_name}",
- "password": "{user_password}",
- "domain": {
- "name": "{domain_name}"
- }
- }
- }
- }
- },
- "scope": {
- "project": {
- "name": "{project_name}"
- }
- }
- }
- }
4. 返回状态码“201”后，获取“X-Subject-Token”的值即为用户的Token。

18 修订记录

表 18-1 修订记录

发布版本	修订记录
7.2.0-HCS	更新API概览，新增新版推理的接口列表。 新增服务管理（新版推理）。 新增查询订单详情。 修改获取Token章节，新增了在节点获取Token的方法。 修改查询工作空间详情、创建工作空间章节，更新了响应示例。