

盘古大模型服务
8.6.300

API 参考

文档版本 01
发布日期 2026-01-10



版权所有 © 华为云计算技术有限公司 2026。保留一切权利。

非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

商标声明



HUAWEI和其他华为商标均为华为技术有限公司的商标。

本文档提及的其他所有商标或注册商标，由各自的所有人拥有。

注意

您购买的产品、服务或特性等应受华为云计算技术有限公司商业合同和条款的约束，本文档中描述的全部或部分产品、服务或特性可能不在您的购买或使用范围之内。除非合同另有约定，华为云计算技术有限公司对本文档内容不做任何明示或暗示的声明或保证。

由于产品版本升级或其他原因，本文档内容会不定期进行更新。除非另有约定，本文档仅作为使用指导，本文档中的所有陈述、信息和建议不构成任何明示或暗示的担保。

华为云计算技术有限公司

地址：贵州省贵安新区黔中大道交兴功路华为云数据中心 邮编：550029

网址：<https://www.huaweicloud.com/>

目 录

1 使用前必读.....	1
1.1 概述.....	1
1.2 终端节点.....	1
1.3 基本概念.....	1
2 如何调用 REST API.....	3
2.1 构造请求.....	3
2.2 认证鉴权.....	5
2.3 返回结果.....	9
3 API.....	11
3.1 NLP 大模型.....	11
3.1.1 多轮对话.....	11
3.1.2 停止生成.....	43
3.2 多模态大模型.....	46
3.2.1 对话问答.....	46
3.3 CV 大模型.....	72
3.3.1 Pangu-CV-物体检测-V1.....	72
3.3.2 Pangu-CV-实例分割-V1.....	77
3.3.3 Pangu-CV-图像分类-V1.....	82
3.3.4 Pangu-CV-语义分割-V1.....	86
3.3.5 Pangu-CV-异常检测-V1.....	90
3.3.6 Pangu-CV-视频分类-V1.....	95
3.3.7 Pangu-CV-目标跟踪-V1.....	97
3.3.8 Pangu-CV-姿态估计-V1.....	102
3.3.9 Pangu-CV-事件检测-V1.....	107
3.3.10 Pangu-CV-目标跟踪-V2.....	108
3.3.11 Pangu-CV-图像分类-V2.....	114
3.3.12 Pangu-CV-开集分类-V3.....	121
3.3.13 Pangu-CV-物体检测-S-V2.....	127
3.3.14 Pangu-CV-物体检测-S-V3.....	133
3.3.15 Pangu-CV-物体检测-N-V2.....	139
3.3.16 Pangu-Mine-CV-物体检测-N-V2.....	145
3.3.17 Pangu-CV-语义分割-V2.....	151

3.3.18 Pangu-CV-RS-语义分割-V2.....	155
3.3.19 Pangu-CV-旋转检测-V2.....	159
3.3.20 Pangu-CV-异常检测-V2.....	163
3.3.21 Pangu-CV-视频分类-V2.....	169
3.3.22 Pangu-CV-姿态估计-V2.....	171
3.3.23 Pangu-CV-事件检测-V2.....	175
3.3.24 Pangu-CV-万物检测-V2.....	177
3.3.25 Pangu-CV-万物分割-V2.....	182
3.3.26 Pangu-CV-视觉交互检测-V3.....	192
3.3.27 Pangu-CV-异常检测-V3.....	203
3.3.28 Pangu-Railway-CV-货车故障轨旁图像检测-V3.....	208
3.3.29 视频推理-动态增删视频流.....	227
3.3.30 Pangu-CV-目标跟踪-V3.....	231
3.3.31 Pangu-CV-直线检测-V2.....	236
3.3.32 Pangu-CV-图片数据合成-V3.....	242
3.4 预测大模型.....	247
3.4.1 盘古统一编码时序预测分类大模型.....	247
3.4.2 盘古统一编码时序预测回归大模型.....	252
3.4.3 盘古统一编码表格预测分类大模型.....	257
3.4.3.1 数据分类预测.....	257
3.4.3.2 单条推理可解释（Shapley 值分析）.....	262
3.4.4 盘古统一编码表格预测回归大模型.....	268
3.4.4.1 数据回归预测.....	269
3.4.4.2 单条推理可解释（Shapley 值分析）.....	273
3.4.5 盘古时序异常检测大模型.....	273
3.4.5.1 时序异常检测零样本直推.....	274
3.4.5.2 时序异常检测预训练产物推理.....	279
3.4.5.3 时序异常检测微调产物推理.....	284
3.4.6 盘古融合推荐异常检测大模型.....	288
3.4.7 盘古融合推荐分类大模型.....	294
3.4.7.1 数据分类预测.....	295
3.4.7.2 排列特征重要性.....	300
3.4.7.3 单条推理可解释（Shapley 值分析）.....	305
3.4.8 盘古融合推荐回归大模型.....	306
3.4.8.1 数据回归预测.....	306
3.4.8.2 排列特征重要性.....	310
3.4.8.3 单条推理可解释（Shapley 值分析）.....	315
3.4.9 结构化数据预测模型.....	315
3.4.10 智慧配煤模型.....	318
3.4.10.1 焦炭质量预测.....	319
3.4.10.2 配煤比例优化.....	335
3.4.11 行业场景预测大模型.....	356

3.4.12 高炉行业场景预测大模型.....	360
3.4.13 智能洗选边缘推理.....	364
3.4.13.1 重介密控.....	365
3.4.13.2 智能加药.....	373
3.4.14 表格直推预测大模型.....	392
3.5 科学计算大模型.....	397
3.5.1 创建推理作业.....	397
3.5.2 查询推理作业详情.....	409
3.6 DeepSeek 大模型.....	414
3.7 天筹求解器模型.....	445
3.7.1 Pangu-OPT-数学规划求解器.....	445
3.7.1.1 创建求解任务.....	446
3.7.1.2 查询任务详情.....	453
3.7.1.3 查询任务列表.....	459
3.7.1.4 删除任务.....	463
3.7.1.5 附录.....	465
3.7.1.5.1 MPS/LP 格式文件说明.....	465
3.7.1.5.1.1 MPS 格式文件说明.....	466
3.7.1.5.1.2 LP 格式文件说明.....	471
3.7.1.5.2 查看求解结果.....	475
3.7.2 Pangu-OPT-数值计算求解器.....	478
3.7.2.1 创建求解任务.....	478
3.7.2.2 查询任务详情.....	485
3.7.2.3 查询任务列表.....	489
3.7.2.4 删除任务.....	492
3.7.3 Pangu-OPT-黑箱优化求解器.....	496
3.7.4 Pangu-OPT-生产计划引擎.....	503
3.7.4.1 创建求解任务.....	503
3.7.4.2 查询任务详情.....	546
3.7.4.3 查询任务列表.....	557
3.7.4.4 删除任务.....	560
3.7.5 Pangu-OPT-运输计划引擎.....	563
3.7.5.1 创建求解任务.....	563
3.7.5.2 查询任务详情.....	581
3.7.5.3 查询任务列表.....	589
3.7.5.4 删除任务.....	592
3.7.6 Pangu-OPT-服装切割引擎.....	594
3.7.6.1 创建求解任务.....	595
3.7.6.2 查询任务详情.....	615
3.7.6.3 查询任务列表.....	626
3.7.6.4 删除任务.....	629
3.7.6.5 附录.....	632

3.7.7 Pangu-OPT-三维装箱引擎.....	635
3.7.7.1 创建求解任务.....	635
3.7.7.2 查询任务详情.....	654
3.7.7.3 查询任务列表.....	668
3.7.7.4 删除任务.....	671
3.7.8 Pangu-OPT-钣金切割引擎.....	674
3.7.8.1 创建求解任务.....	675
3.7.8.2 查询任务详情.....	693
3.7.8.3 查询任务列表.....	705
3.7.8.4 删除任务.....	708
3.7.9 Pangu-OPT-生产排程引擎.....	711
3.7.9.1 创建求解任务.....	712
3.7.9.2 查询任务详情.....	724
3.7.9.3 查询任务列表.....	733
3.7.9.4 删除任务.....	737
3.8 向量&重排大模型.....	739
3.8.1 Embedding 模型服务.....	740
3.8.2 Rerank 模型服务.....	742
3.9 搜索规划大模型.....	747
3.10 数据管理.....	752
3.10.1 查询数据集详情 v1.....	752
3.10.2 根据 ID 批量查询数据集.....	782
3.10.3 删除数据发布任务.....	809
3.10.4 批量删除数据集.....	811
3.10.5 彻底删除数据发布任务.....	818
3.10.6 创建数据发布任务 v1.....	820
3.10.7 创建数据发布任务 v2.....	837
3.10.8 删除导入任务.....	855
3.10.9 创建数据导入任务.....	858
3.10.10 彻底删除数据集.....	887
3.10.11 查询 obs 路径关联的数据血缘.....	891
3.10.12 查询数据集详情 v2.....	900
3.10.13 查询数据集列表.....	932
3.10.14 查询加工算子列表.....	967
3.10.15 创建加工任务.....	981
3.11 空间管理.....	995
3.11.1 查询空间列表.....	995
3.11.2 修改工作空间.....	1002
3.11.3 删除 Workspace.....	1009
3.11.4 新建工作空间.....	1011
3.11.5 查询 Workspace.....	1018
3.12 资产管理.....	1024

3.12.1 查询指定空间内的模型资产列表.....	1024
3.12.2 查询指定空间内的模型资产详情.....	1066
3.12.3 获取模型列表.....	1113
3.12.4 导出 ModelArts Site 平台格式资产.....	1173
3.12.5 查询模型导出任务列表.....	1177
3.13 训练任务管理.....	1191
3.13.1 获取训练任务工作流执行指标信息.....	1191
3.13.2 停止/重试训练任务操作.....	1195
3.13.3 查询训练任务详情.....	1198
3.13.4 获取工作流训练任务某一步执行日志信息.....	1212
3.13.5 新建训练任务.....	1218
3.13.6 获取训练任务某一步执行的节点信息.....	1251
3.13.7 发布训练模型.....	1256
3.13.8 获取发布的模型列表.....	1262
3.13.9 批量删除已下发训练任务.....	1278
3.13.10 查询执行任务的断点信息（本接口用于调用其他接口时获取请求参数使用）.....	1282
3.13.11 获取模型详情（本接口用于调用其他接口时获取请求参数使用）.....	1289
3.13.12 获取指定租户及工作空间，时间范围内训练任务的耗时.....	1314
3.13.13 获取指定资源池或资源池节点上运行的任务.....	1321
3.14 推理任务管理.....	1336
3.14.1 获取服务列表.....	1336
3.14.2 查询模型服务详情.....	1365
3.14.3 获取服务监控详情.....	1389
3.14.4 部署服务.....	1399
3.14.5 更新服务配置信息.....	1450
3.14.6 删除模型部署的服务.....	1498
3.14.7 启停服务.....	1501
3.14.8 获取模型服务运行日志.....	1532
3.14.9 获取模型服务指定节点的运行日志详情.....	1539
3.14.10 获取资源池节点上运行任务信息.....	1546
3.14.11 获取规定时间内的推理任务使用卡的资源数.....	1556
3.15 资源池管理.....	1561
3.15.1 查询资源池列表详情.....	1561
3.16 边学边用.....	1582
3.16.1 数据结果回传.....	1582
3.17 Agent.....	1587
3.17.1 开发态.....	1587
3.17.1.1 知识库管理.....	1587
3.17.1.1.1 查询知识库使用的模型列表.....	1587
3.17.1.1.2 创建知识库.....	1592
3.17.1.1.3 查询知识库列表.....	1604
3.17.1.1.4 修改知识库.....	1612

3.17.1.1.5 查询知识库详情.....	1624
3.17.1.1.6 删除知识库.....	1636
3.17.1.1.7 开启一个知识库.....	1639
3.17.1.1.8 停用知识库.....	1642
3.17.1.1.9 检索知识库，命中测试.....	1645
3.17.1.2 知识库文档规则管理.....	1651
3.17.1.2.1 创建知识库分层规则.....	1652
3.17.1.2.2 查询知识库分层规则列表.....	1655
3.17.1.2.3 修改知识库分层规则.....	1659
3.17.1.2.4 删除知识库分层规则.....	1663
3.17.1.3 知识库知识文档管理.....	1666
3.17.1.3.1 在知识库中上传文档.....	1666
3.17.1.3.2 查询知识库中的文件列表.....	1670
3.17.1.3.3 查询知识库中指定的文档信息.....	1677
3.17.1.3.4 从知识库中批量删除文档.....	1682
3.17.1.4 知识库任务管理.....	1686
3.17.1.4.1 创建知识库任务.....	1686
3.17.1.4.2 查询知识库任务.....	1690
3.17.2 运行态.....	1697
3.17.2.1 工作流/智能体.....	1697
3.17.2.1.1 调用工作流应用.....	1697
3.17.2.1.2 调用智能体应用.....	1706
3.17.2.1.3 上传文件.....	1715
3.17.2.2 知识库.....	1720
3.17.2.2.1 知识库检索.....	1720
3.17.2.2.2 知识库检索（v1.5）.....	1725
3.17.2.2.3 文件下载.....	1729
3.17.3 应用示例.....	1734
3.17.3.1 调用工作流应用示例.....	1734
3.17.3.2 调用智能体应用示例.....	1735
4 附录.....	1737
4.1 状态码.....	1737
4.2 错误码.....	1739
4.3 获取项目 ID.....	1770
4.4 获取用户 ID.....	1772
4.5 获取空间 ID.....	1772
4.6 获取数据集 ID.....	1773
4.7 获取资源池 ID 信息.....	1773
4.8 获取负载均衡 ID 信息.....	1774
4.9 获取工作区 ID.....	1775
4.10 创建 SSL 证书信息(HTTPS 负载均衡使用).....	1776
4.11 获取在线部署的大模型推理 API 接口域名.....	1779

4.12 获取边缘部署的大模型推理 API 接口域名..... 1783

4.13 获取边学边用 API 接口域名..... 1785

4.14 获取 Agent 接口域名..... 1787

4.15 运行 Webhook Service..... 1788

4.16 创建监控插件..... 1789

4.17 获取盘古服务外部 APIG 域名..... 1790

4.18 获取算子 ID..... 1792

5 修订记录..... 1793

1 使用前必读

1.1 概述

盘古大模型服务整合强大的计算和数据资源，将先进的AI算法集成在预训练大模型中，打造出具有深度语义理解与生成能力的人工智能大语言模型。可进行对话互动、回答问题、协助创作。

盘古大模型在ModelArts Studio平台部署后，可以通过API调用推理接口。

说明

盘古仅提供技术能力，不对最终生成的内容负责，建议用户在使用服务的过程中，对模型生成的内容进行适当的审核和过滤，以保证内容的安全性。

1.2 终端节点

终端节点（endpoint）即API服务的终端地址，通过该地址与API进行通信和交互。

认证鉴权所需要的终端节点请参考[认证鉴权](#)获取。

API接口的endpoint信息请参考[构造请求](#)获取。

1.3 基本概念

- 租户
租户对其所拥有的资源及云服务具有完全的访问权限，可以重置用户密码、分配用户权限等。为了确保租户安全，建议您不要直接使用租户进行日常管理工作，而是创建用户并使用他们进行日常管理工作。
- 用户
由租户在ManageOne运营面创建的用户，是云服务的使用人员，具有身份凭证（密码和访问密钥）。
在个人设置下，您可以查看租户ID和用户ID。通常在调用API的鉴权过程中，您需要用到租户名、用户和密码等信息。
- 区域（Region）

从地理位置和网络时延维度划分，同一个Region内共享弹性计算、块存储、对象存储、VPC网络、弹性IP、镜像等公共服务。Region分为通用Region和专属Region，通用Region指面向公共租户提供通用云服务的Region；专属Region指只承载同一类业务或只面向特定租户提供业务服务的专用Region。


- 可用区（AZ，Availability Zone）

一个AZ是一个或多个物理数据中心的集合，有独立的风火水电，AZ内逻辑上再将计算、网络、存储等资源划分成多个集群。一个Region中的多个AZ间通过高速光纤相连，以满足用户跨AZ构建高可用性系统的需求。

- 项目

云服务的区域默认对应一个项目，这个项目由系统预置，用来隔离物理区域间的资源（计算资源、存储资源和网络资源），以默认项目为单位进行授权，用户可以访问您租户中该区域的所有资源。如果您希望进行更加精细的权限控制，可以在区域默认的项目中创建子项目，并在子项目中创建资源，然后以子项目为单位进行授权，使得用户仅能访问特定子项目中资源，使得资源的权限控制更加精确。

图 1-1 项目隔离模型



2 如何调用 REST API

2.1 构造请求

本节介绍REST API请求的组成，并以调用NLP大模型接口说明如何调用API，该API获取用户的Token，Token可以用于调用其他API时鉴权。

请求示例如下图所示，一个请求主要由请求URI、请求方法、请求消息头和请求消息体组成，各个部分将在下文详细解释。

图 2-1 请求示例图



获取 `https://{endpoint}`

不同接口的`https://{endpoint}`获取方法均有所差异，请参考[附录](#)进行获取。

请求 URI

请求URI由如下部分组成。

{URI-scheme} :// {Endpoint} / {resource-path} ? {query-string}


表 2-1 请求 URI

参数	说明
URI-scheme	传输请求的协议，当前所有API均采用HTTPS协议。
Endpoint	承载REST服务端点的服务器域名或IP。
resource-path	资源路径，即API访问路径。从具体API的URI模块获取。
query-string	查询参数，可选，查询参数前面需要带一个“？”，形式为“参数名=参数取值”。

参考[终端节点](#)章节获取endpoint，并在[接口的URI](#)部分找到resource-path（/v1/{project_id}/deployments/{deployment_id}/chat/completions），其中{project_id}需要替换成用户的项目ID。拼接起来如下所示。

https://{endpoint}/v1/{project_id}/deployments/{deployment_id}/chat/completions

图 2-2 URI 示意图



说明

为查看方便，每个具体API的URI，只给出resource-path部分，并将请求方法写在一起。这是因为URI-scheme都是HTTPS，而Endpoint在同一个区域也相同，所以简洁起见将这两部分省略。

请求方法

HTTP请求方法（也称为操作或动词），它告诉服务你正在请求什么类型的操作。

- **GET**：请求服务器返回指定资源。
- **PUT**：请求服务器更新指定资源。
- **POST**：请求服务器新增资源或执行特殊操作。
- **DELETE**：请求服务器删除指定资源，如删除对象等。
- **HEAD**：请求服务器资源头部。
- **PATCH**：请求服务器更新资源的部分内容。当资源不存在的时候，PATCH可能会去创建一个新的资源。

在接口的URI部分，您可以看到其请求方法为“POST”，则其请求为：

POST https://{endpoint}/v1/{project_id}/deployments/{deployment_id}/chat/completions

请求消息头

附加请求头字段，如指定的URI和HTTP方法所要求的字段。例如定义消息体类型的请求头“Content-Type”，请求鉴权信息等。

如下公共消息头需要添加到请求中。

- **Content-Type**: 消息体的类型（格式），必选，默认取值为“application/json”。
- **X-Auth-Token**: 用户Token，可选，当使用Token方式认证时，必须填充该字段。用户Token请参考[认证鉴权](#)中的“Token认证”。

添加消息头后的请求如下所示：

```
POST https://{endpoint}/v1/{project_id}/deployments/{deployment_id}/chat/completions
Content-Type: application/json
X-Auth-Token: MIINRwYJKoZlhvcNAQcColINOD...
```

请求消息体

请求消息体通常以结构化格式发出，与请求消息头中Content-Type对应，传递除请求消息头之外的内容。若请求消息体中参数支持中文，则中文字符必须为UTF-8编码。

每个接口的请求消息体内容不同，也并不是每个接口都需要有请求消息体（或者说消息体为空），GET、DELETE操作类型的接口就不需要消息体，消息体具体内容需要根据具体接口而定。

将消息体加入后的请求如下所示，详细参数解释可参考文档API章节。

```
POST https://{endpoint}/v1/{project_id}/deployments/{deployment_id}/chat/completions
Content-Type: application/json
X-Auth-Token: MIINRwYJKoZlhvcNAQcColINOD...
```

```
{
  "messages": [
    {
      "content": "介绍下长江，以及长江中典型的鱼类"
    }
  ],
  "temperature": 0.9,
  "max_tokens": 600
}
```

到这里为止这个请求需要的内容就具备齐全了，您可以使用[curl](#)、[Postman](#)或直接编写代码等方式发送请求调用API。对于接口，您可以从响应消息部分看到返回参数及参数说明。

2.2 认证鉴权

Token 认证

Token在计算机系统中代表令牌（临时）的意思，拥有Token就代表拥有某种权限。Token认证就是在调用API的时候将Token加到请求消息头，从而通过身份认证，获得操作API的权限。

进行Token认证时需要使用如下所示的Token接口，接口示例中的Region_id、外部Global Level Domain，参数值需要基于实际环境进行替换，以下步骤将介绍参数的获取方法。

```
POST https://iam-apigateway-proxy.{Region_id}.{外部Global Level Domain}/v3/auth/tokens
```

- Token的有效期为24小时，需要使用一个Token鉴权时，可以先缓存起来，避免频繁调用。
- 用户所属的账户名，通过下面的步骤获取：
 - 登录ManageOne运营面。
 - 在页面右上角单击用户图标，在下拉列表中选择“个人设置”。
 - 在“个人设置”页面，显示的账户即为该用户所属的账户名。
- 调用IAM接口获取token之前，需要将IAM地址和域名的映射，写入系统的hosts文件，通过下面的步骤实现。
 - 示例中的 $\{Region_id\}$ 、 $\{外部Global Level Domain\}$ 请从HCCI Turnkey工具安装盘古大模型服务的参数导出表>基本参数章节中“规划值”列获取：

A	B	C	D	E
参数分类	参数名称	参数key	规划值	规划值样例
公共	外部Global Level Domain	external_global_domain_name	externala3.com	demo.com
	内部Global域名	global_domain_name	internala3.com	demo.com
	HCC Turnkey执行机DHCP网卡名称	openstack_exe_host_dhcp_nic	eth2	eth1
	Region_id	region0_id	ei-a3-1	sa-fb-1
	用户系统语言	system_language	zh_CN	zh_CN
	时区	time zone	Asia/Shanghai	Asia/Shanghai

拼接示例：

POST https://iam-apigateway-proxy.ei-a3-1.externala3.com/v3/auth/tokens

- 在安装底座时导出的汇总文件《xxx_export_all_v2_CN.xlsx》的“工具生成的ip参数”页签，查找参数名称为“AGW-Nginx-Float-IP”的IP地址。

1	所属部件	部件细化	参数名称	网络平面	IP地址	子网掩码
47	DMZ_Service_Manage	ManageOne-TransferProxy02-IP	ManageOne-TransferProxy02-IP	DMZ_Service	52.155.24.26	255.255.254.0
48	DMZ_Service_Manage	ManageOne-TransferProxy-Float-IP	ManageOne-TransferProxy-Float-IP	DMZ_Service	52.155.24.27	255.255.254.0
49	DMZ_Service_Openstack	new_dmz_service_start_addr	new_dmz_service_start_addr	DMZ_Service	52.155.24.40	
50	DMZ_Service_PublicVI	LVS01	LVS01	DMZ_Service	52.155.24.28	255.255.254.0
51	DMZ_Service_PublicVI	LVS02	LVS02	DMZ_Service	52.155.24.29	255.255.254.0
52	DMZ_Service_PublicVI	NGINX01	NGINX01	DMZ_Service	52.155.24.30	255.255.254.0
53	DMZ_Service_PublicVI	NGINX02	NGINX02	DMZ_Service	52.155.24.31	255.255.254.0
54	DMZ_Service_PublicVI	TDNS-TNTP01	TDNS-TNTP01	DMZ_Service	52.155.24.4	255.255.254.0
55	DMZ_Service_PublicVI	TDNS-TNTP02	TDNS-TNTP02	DMZ_Service	52.155.24.5	255.255.254.0
56	external_om_ApiCom	APICom-Float-IP	APICom-Float-IP	external_om	52.155.20.13	255.255.252.0
57	external_om_ApiGatew	APIGWZK01	APIGWZK01	external_om	52.155.20.14	255.255.252.0
58	external_om_ApiGatew	APIGWZK02	APIGWZK02	external_om	52.155.20.15	255.255.252.0
59	external_om_ApiGatew	APIGWZK03	APIGWZK03	external_om	52.155.20.16	255.255.252.0
60	external_om_ApiGatew	APIGWZK04	APIGWZK04	external_om	52.155.20.17	255.255.252.0
61	external_om_ApiGatew	AGW-INTERNAL-LB-FLOAT-IP	AGW-INTERNAL-LB-FLOAT-IP	external_om	52.155.20.18	255.255.252.0
62	external_om_ApiGatew	AGW-Nginx-Float-IP	AGW-Nginx-Float-IP	external_om	52.155.20.19	255.255.252.0
63	external_om_AS	AS-Schedule01	AS-Schedule01	external_om	52.155.20.20	255.255.252.0
64	external_om_AS	AS-Schedule02	AS-Schedule02	external_om	52.155.20.21	255.255.252.0
65	external_om_AS	AS-Schedule-Float-IP	AS-Schedule-Float-IP	external_om	52.155.20.22	255.255.252.0
66	external_om_AS	AS-Schedule-DB01	AS-Schedule-DB01	external_om	52.155.20.23	255.255.252.0
67	external_om_AS	AS-Schedule-DB02	AS-Schedule-DB02	external_om	52.155.20.24	255.255.252.0
68	external_om_AS	AS-Schedule-DB-Float-IP	AS-Schedule-DB-Float-IP	external_om	52.155.20.25	255.255.252.0
69	external_om_AS	AS-Service01	AS-Service01	external_om	52.155.20.26	255.255.252.0
70	external_om_AS	AS-Service02	AS-Service02	external_om	52.155.20.27	255.255.252.0

如果使用此方法无法找到IP地址，或IP地址不可用，请登录HCC Turnkey后台节点，ping iam-apigateway-proxy.{external_global_domain_name}，获取ping出的IP地址。

```
Last login: Thu Aug 14 09:43:12 2025 from 70.251.92.119
[root@..... ~]# ping iam-apigateway-proxy.eima01.com
PING iam-apigateway-proxy.eima01.com (71.16.102.4) 56(84) bytes of data.
64 bytes from 71.16.102.4 (71.16.102.4): icmp_seq=1 ttl=63 time=0.262 ms
64 bytes from 71.16.102.4 (71.16.102.4): icmp_seq=2 ttl=63 time=0.185 ms
64 bytes from 71.16.102.4 (71.16.102.4): icmp_seq=3 ttl=63 time=0.145 ms
64 bytes from 71.16.102.4 (71.16.102.4): icmp_seq=4 ttl=63 time=0.180 ms
64 bytes from 71.16.102.4 (71.16.102.4): icmp_seq=5 ttl=63 time=0.218 ms
```

- 打开机器的“C:\Windows\System32\drivers\etc\hosts”文件，在文件的最后一行写入上一步骤获取到的域名iam-cache-proxy.{external_global_domain_name}的映射。
 $\{IP\}$ {iam-cache-proxy.{external_global_domain_name}}
 $\{IP\}$ {iam-apigateway-proxy.{external_global_domain_name}}

进行Token认证除了获取到Token接口外，还需要填写接口的请求Body，请求Body示例可参考•伪码，示例中user name、domain name、project id获取方法如下。

1. 登录盘古大模型套件平台，在界面右上角，单击租户名称后，选择“个人设置”，进入个人信息界面。

图 2-3 个人设置



2. 在个人信息页，参考下图获取user name、domain name、project id、project name。

图 2-4 获取 user name、domain name、project id、project name



- 伪码
- 接口示例中的ei-a3-1表示Region_id、externala3.com表示外部Global Level Domain，参数值请基于实际环境进行替换，该值可以在环境的底座导出表中获取。

```
POST https://iam-apigateway-proxy.ei-a3-1.externala3.com/v3/auth/tokens
Content-Type: application/json
{
  "auth": {
    "identity": {
      "methods": [
        "password"
      ],
      "password": {
        "user": {
          "name": "username", //用户名
        }
      }
    }
  }
}
```

```
        "password": "*****", //密码
        "domain": {
            "name": "domainname" //租户名
        }
    },
    "scope": {
        "project": {
            "name": "project name" //替换为实际的project name
        }
    }
}
```

- Python

接口示例中的ei-a3-1表示Region_id、externala3.com表示外部Global Level Domain，参数值请基于实际环境进行替换，该值可以在环境的底座导出表中获取。

```
import requests
import json

url = "https://iam-apigateway-proxy.ei-a3-1.externala3.com/v3/auth/tokens"
payload = json.dumps({
    "auth": {
        "identity": {
            "methods": [
                "password"
            ],
            "password": {
                "user": {
                    "name": "username",
                    "password": "*****",
                    "domain": {
                        "name": "domainname"
                    }
                }
            }
        },
        "scope": {
            "project": {
                "name": "projectname"//替换为实际的project name
            }
        }
    }
})
headers = {
    'Content-Type': 'application/json'
}

response = requests.request("POST", url, headers=headers, data=payload)

print(response.headers["X-Subject-Token"])
```

如下图所示，返回的响应消息头中“x-subject-token”就是需要获取的用户Token。获取Token之后，您就可以使用Token认证调用盘古大模型服务API。

图 2-5 获取用户 Token 响应消息头

Body	Cookies	Headers (11)	Test Results
		Transfer-Encoding ①	chunked
		Connection ①	keep-alive
		X-IAM-Trace-Id ①	3120aeb2b2a261565ad4b7779ba90422
		Strict-Transport-Security ①	max-age=31536000; includeSubdomains
		X-Frame-Options ①	SAMEORIGIN
		X-XSS-Protection ①	1; mode=block
		X-Subject-Token ①	MIIFLAYJKoZiHvcNAQcCollFHTCCBRkCAQExDTALBgIghkgBZQMEAgEwggL6BgkqhkiG9
		X-Request-Id ①	3120aeb2b2a261565ad4b7779ba90422

API Key 认证

当用户部署的API服务期望开放给其他用户调用时，原有Token认证无法支持，可用API Key认证的鉴权方式进行调用请求。

API Key认证指调用API时，在HTTP请求头部消息增加一个参数X-Apig-AppCode（参数值为API Key值），而不需要对请求内容签名。

使用该鉴权方式前，请确保有已部署的大模型。

获取API Key步骤如下：

- 1. 登录ModelArts Studio平台，进入所需空间。
- 2. 在左侧导航栏中选择“应用接入”，单击界面右上角“创建应用接入”。
- 3. 在“关联服务”中，选择“全部服务”，或者在“指定服务”中选择已部署好的大模型，并设置应用接入名称、描述，单击“确定”。
- 4. 在弹窗中复制API Key的值。注意：API Key仅可在此弹窗中复制一次，请妥善保管。关闭弹窗后，如果忘记API Key值，请重新创建。



2.3 返回结果

状态码

请求发送以后，您会收到响应，包含状态码、响应消息头和消息体。

状态码是一组从1xx到5xx的数字代码，状态码表示了请求响应的状态，完整的状态码列表请参见[状态码](#)。

对于盘古大模型服务接口，如果调用后返回状态码为“200”，则表示请求成功。

响应消息头

对应请求消息头，响应同样也有消息头，如“Content-Type”。

响应消息体

响应消息体通常以结构化格式返回，与响应消息头中Content-Type对应，传递除响应消息头之外的内容。

接口调用成功后将返回如下响应体。

```
{
  "id": "dd5b73dd5775d53366b6a61aac6080d5",
  "created": 20230512025050,
  "choices": [
    {
      "index": 0,
      "text": "好的,我来为您写一个穿越到宋朝的故事。故事的主人公是一个名叫张云的年轻人,他因为一次意外被送到了北宋时期。在这个陌生的时代里,张云经历了许多奇妙的事情,结交了许多有趣的朋友,也遇到了不少危险和挑战。最终,他在这个时代中找到了自己的归属感和意义所在,成为了一名伟大的历史学家。"
    }
  ],
  "usage": {
    "completion_tokens": 72,
    "prompt_tokens": 7,
    "total_tokens": 79
  }
}
```

当接口调用出错时，会返回错误码及错误信息说明。

token有效期为24小时，下面的报错表示token过期。

```
{
  "error_msg": "Incorrect IAM authentication information: token expires, expires_at:2023-06-29T02:16:41.581000Z",
  "error_code": "APIG.0301",
  "request_id": "469967f55e6b225xxx"
}
```

其中，error_code表示错误码，error_msg表示错误描述信息。

3 API

3.1 NLP 大模型

3.1.1 多轮对话

功能介绍

基于多轮对话问答功能，用户可以与模型进行自然而流畅的对话和交流。

📖 说明

对于快慢思考合一的模型，默认推理为慢思考模式，可在content末尾增加/no_think，切换为快思考模式。

```
{
  "model": "pangu",
  "messages": [
    {
      "role": "user",
      "content": "你好! /no_think"
    }
  ]
}
```

URI

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

NLP推理服务提供两种推理接口调用：

- 盘古推理接口（V1推理接口）
- 业界通用的OpenAI格式接口（V2推理接口）

V1、V2调用接口的鉴权方式不同，请求体和返回体略有差异。两种接口定义如[表1 NLP服务推理接口](#)所示。

表 3-1 NLP 服务推理接口

API分类	API访问路径（URI）
V1推理接口	POST /v1/{project_id}/deployments/{deployment_id}/chat/completions
V2推理接口	POST /api/v2/chat/completions

表 3-2 V1 推理接口路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
deployment_id	是	String	参数解释： 模型的部署ID。 模型训练部署完成后，单击模型部署列表中的模型，进入详情页获取。 Deployment ID(V1接口使用) 164d5102-659b-41af-a617-e21d4ddc5eb3  约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

V1接口支持Token鉴权方式，也支持API Key鉴权方式。

表 3-3 V1 接口支持 Token 鉴权方式请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-4 V1 接口 API Key 鉴权方式请求 Header 参数

参数	是否必选	参数类型	描述
X-Apig-AppCode	是	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

V2接口只支持API Key鉴权方式。

表 3-5 V2 接口请求 Header 参数（OpenAI 格式的 API Key 认证）

参数	是否必选	参数类型	描述
Authorization	是	String	参数解释： 用户创建应用接入获取的API Key，拼接“Bearer ”后的字符串。示例：Bearer d59*****9C3。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

V1、V2推理接口请求Body参数一致，如[表6 请求Body参数](#)描述。

表 3-6 请求 Body 参数

参数	是否必选	参数类型	描述
messages	是	Array of message objects	参数解释： messages表示用户与模型进行对话时，输入的信息。包含两个属性：role和content。 - role表示对话的角色，取值是system或user。如果需要模型以某个人设形象回答问题，可以将role参数设置为system。不使用人设时，可设置为user。在一次会话请求中，人设只需要设置一次。 - content表示对话的内容，可以是任意文本。 messages参数可以帮助模型根据对话的上下文生成合适的回复。 约束限制： 数组长度：1 - 20 取值范围： 不涉及 默认取值： 不涉及
model	V1推理接口：否 V2推理接口：是	String	参数解释： 使用的推理服务模型名称，为推理服务部署时指定的Deployed_Model，可在推理服务详情页面查询到。V2推理接口使用，V1推理接口不使用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
user	否	String	参数解释： 用于代表用户的唯一标识符。 约束限制： 字符串长度最大64，最小1。 取值范围： 不涉及 默认取值： 不涉及
temperature	否	Float	参数解释： 用于控制生成文本的多样性和创造力。参数的取值范围是 (0, 1]，取值接近0表示最低的随机性，1表示最高的随机性。一般来说，temperature越低，适合完成确定性的任务。temperature越高，例如0.9，适合完成创造性的任务。 temperature参数可以影响语言模型输出的质量和多样性，但也不是唯一的因素。还有其他一些参数，如top_p参数也可以用来调整语言模型的行为和偏好。 约束限制： 不涉及 取值范围： (0, 1]
top_p	否	Float	参数解释： 一种替代温度采样的方法，称为 nucleus sampling，其中模型考虑具有top_p概率质量的标记的结果。 约束限制： 不涉及 取值范围： (0, 1]

参数	是否必选	参数类型	描述
max_tokens	否	Integer	参数解释： 生成文本的最大token数量，单位token。 说明 token是指模型处理和生成文本的基本单位。token可以是词或者字符的片段。模型的输入和输出的文本都会被转换成token，然后根据模型的概率分布进行采样或者计算。 约束限制： 输入的文本加上生成的文本总量不能超过模型所能处理的最大长度。 取值范围： 最小值：1 最大值：模型支持的最大token数 默认取值：模型支持的最大token数
presence_penalty	否	Float	参数解释： 话题重复度控制主要用于控制模型输出的话题重复程度。参数设置正值，模型倾向于生成新的、未出现过的内容；参数设置负值，倾向于生成更加固定和统一的内容。 约束限制： 不涉及 取值范围： 最小值：-2 最大值：2 默认取值： 0（表示该参数未生效）

参数	是否必选	参数类型	描述
stream	否	boolean	参数解释： 流式开关。如果开启流式，请赋值true，同时n参数只能设置为1。开启流式开关后，API会在生成文本的过程中，实时地将生成的文本发送给客户端，而不是等到生成完成后一次性将所有文本发送给客户端。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false
moderation_config	否	moderationConfig object	参数解释： 盘古护栏审核配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-7 message

参数	是否必选	参数类型	描述
role	V1推理接口： 否 V2推理接口： 是	String	参数解释： 对话的角色。 如果需要模型以某个人设形象回答问题，可以将role参数设置为system。不使用人设时，可设置为user。在一次会话请求中，人设只需要设置一次。多轮对话中，用户输入提示词的role设置为user，推理结果的role设置为assistant。 约束限制： 不涉及 取值范围： system、user、assistant 默认取值： 不涉及
content	是	String	参数解释： 对话的内容，可以是任意文本，单位token。 约束限制： 设置多轮对话时，message中content个数不能超过20。 取值范围： 最小长度：1 最大长度：以创建模型部署任务时，模型规格为准，如32K模型、128K模型。 默认取值： 不涉及

表 3-8 ModerationConfig

参数	是否必选	参数类型	描述
show_result	否	boolean	参数解释： 是否显示内容审核详情。 约束限制： 仅盘古护栏拦截时生效。 取值范围： 不涉及 默认取值： false

响应参数

非流式

状态码： 200

表 3-9 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 用来标识每个响应的唯一字符串。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
created	Integer	参数解释： 响应生成的时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
choices	Array of choices objects	参数解释: 生成的文本列表。包含以下属性： - message：生成的文本内容。 - index：生成的文本在列表中的索引，从0开始。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
usage	usage object	参数解释: 该参数可以帮助用户了解和控制模型的使用情况，避免超出Tokens限制。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
moderation_type	String	参数解释: 内容审核拦截类型，包含以下属性： question：用户提问。 answer：模型回答。 约束限制: 请求参数show_result设为true，且盘古护栏拦截时返回。 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
moderation_result	moderationResp object	参数解释： 盘古护栏审核拦截详情。 约束限制： 请求参数show_result设为true，且盘古护栏拦截时返回。 取值范围： 不涉及 默认取值： 不涉及

表 3-10 choices

参数	参数类型	描述
message	message object	参数解释： 生成的文本内容。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
index	Integer	参数解释： 生成的文本在列表中的索引，从0开始。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-11 message

参数	参数类型	描述
role	String	参数解释： 对话的角色。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
content	String	参数解释： 对话的内容，单位token。 约束限制： 不涉及 取值范围： 最小长度：1 最大长度：以创建模型部署任务时，模型规格为准，如32K模型、128K模型。 默认取值： 不涉及

表 3-12 usage

参数	参数类型	描述
completion_tokens	Number	参数解释： 表示模型生成的答案中包含的tokens的数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
prompt_tokens	Number	参数解释: 表示生成结果时使用的提示文本的tokens的数量。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
total_tokens	Number	参数解释: 对话过程中使用的tokens总数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-13 ModerationResp

参数	参数类型	描述
request_id	String	参数解释: 调用盘古护栏审核接口请求ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
result	object	参数解释: 审核结果。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
label	String	参数解释： 当前内容片段的风险类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

流式（stream参数为true）
状态码： 200

表 3-14 流式输出的数据单元

参数	参数类型	描述
data	CompletionStreamResponse	参数解释： stream=true时，模型生成的消息以流式形式返回。生成的内容以增量的方式逐步发送回来，每个data字段均包含一部分生成的内容，直到所有data返回，响应结束。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-15 CompletionStreamResponse

参数	参数类型	描述
id	String	参数解释： 该对话的唯一标识符。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
created	Integer	参数解释： 创建聊天完成时的 Unix 时间戳（以秒为单位）。流式响应的每个 chunk 的时间戳相同。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model	String	参数解释： 生成该 completion 的模型名。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
object	String	参数解释： 对象的类型, 其值为 chat.completion.chunk。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
choices	ChatCompletionResponseStreamChoice	参数解释： 模型生成的 completion 的选择列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
usage	UsageInfo	参数解释： 该对话请求的token用量信息。该参数可以帮助用户了解和控制模型的使用情况，避免超出Tokens限制。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-16 ChatCompletionResponseStreamChoice

参数	参数类型	描述
index	Integer	参数解释： 该 completion 在模型生成的 completion 的选择列表中的索引。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
finish_reason	String	参数解释： 模型停止生成 token 的原因。 约束限制： 不涉及 取值范围： [stop, length, content_filter, tool_calls, insufficient_system_resource] • stop: 模型自然停止生成，或遇到 stop 序列中列出的字符串。 • length : 输出长度达到了模型上下文长度限制，或达到了 max_tokens 的限制。 • content_filter: 输出内容因触发过滤策略而被过滤。 • tool_calls: 模型决定调用外部工具（函数/API）来完成任务。 • insufficient_system_resource: 系统推理资源不足，生成被打断。 默认取值： 不涉及
delta	DeltaMessage	参数解释： V2推理接口流式返回的一个 completion 增量。 约束限制： V1推理接口返回体不包含此参数。 取值范围： 不涉及 默认取值： 不涉及
message	DeltaMessage	参数解释： V1推理接口流式返回的一个 completion 增量。 约束限制： V2推理接口返回体不包含此参数。 取值范围： 不涉及 默认取值： 不涉及

表 3-17 DeltaMessage

参数	参数类型	描述
role	String	参数解释： 产生这条消息的角色。 约束限制： 不涉及 取值范围： 不涉及 默认取值： assistant
content	String	参数解释： completion 增量的内容。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
reasoning_content	String	参数解释： 内容为最终答案之前的推理内容（模型的思考过程）。 约束限制： 仅适用于支持思考过程的模型。 取值范围： 不涉及 默认取值： 不涉及

表 3-18 UsageInfo

参数	参数类型	描述
prompt_tokens	Integer	参数解释: 用户输入的提示词及默认人设的Token数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
completion_tokens	Integer	参数解释: 推理服务返回结果的Token数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
total_tokens	Integer	参数解释: 总消耗token数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-19 流式输出的数据单元（输出内容未审核通过）

参数	参数类型	描述
suggestion	String	参数解释: 审核结果：block表示未通过。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
reply	String	参数解释： 兜底回复：审核未通过时兜底回复为有效回复，兜底策略。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
moderation_type	String	参数解释： 内容审核拦截类型，包含以下属性： question：用户提问。 answer：模型回答。 约束限制： 请求参数show_result设为true，且盘古护栏拦截时返回。 取值范围： 不涉及 默认取值： 不涉及
moderation_result	moderationResp object	参数解释： 盘古护栏审核拦截详情。 约束限制： 请求参数show_result设为true，且盘古护栏拦截时返回。 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

接口报错的场景下，V1推理接口返回的报错信息符合盘古规范；V2推理接口则会对外透传推理服务返回的错误信息，通常符合OpenAI接口格式。

表 3-20 V1 推理接口响应错误信息 Body 参数

参数	参数类型	描述
error_code	String	错误码。

参数	参数类型	描述
error_msg	String	错误信息。
details	List<Object>	推理服务返回的报错信息，具体的格式、内容取决于推理服务。

表 3-21 V2 推理接口响应错误信息 Body 参数

参数	参数类型	描述
error	ErrorResp	错误信息。
id	String	请求ID。

表 3-22 ErrorResp

参数	参数类型	描述
code	String	错误码。
type	String	错误类型。
message	String	错误详情。

请求示例

- 通过单轮问答获取长江及其典型鱼类介绍
V1推理接口：
POST https://{endpoint}/v1/{project_id}/deployments/{deployment_id}/chat/completions

Request Header:
Content-Type: application/json
X-Auth-Token:
MIINRwYJKoZIhvcNAQcCoIINODCCDTQCAQExDTALBglghkgBZQMEAgEwgguVBgkqhkiG...

V2推理接口：
POST https://{endpoint}/api/v2/chat/completions

Request Header:
Content-Type: application/json
Authorization: Bearer 201ca68f-45f9-4e19-8fa4-831e...

Request Body:
{
 "model": "pangu-nlp-n1-32k", // 仅V2接口需要此参数
 "messages": [
 {
 "role": "user",
 "content": "介绍下长江，以及长江中典型的鱼类"
 }
],
 "temperature": 0.9,
 "max_tokens": 600
}

- 通过单轮流式问答获取五岳山名（stream参数值为true）

```
{
  "model": "pangu-nlp-n1-32k", // 仅V2接口需要此参数
  "messages": [
    {
      "role": "user",
      "content": "五岳分别是哪些山"
    }
  ],
  "temperature": 0.9,
  "max_tokens": 600,
  "stream": "true"
}
```

- 通过带有人设的单轮问答获取长江及其典型鱼类介绍（role参数值为system）

```
{
  "model": "pangu-nlp-n1-32k", // 仅V2接口需要此参数
  "messages": [
    {
      "role": "system",
      "content": "你的名字叫智子，是一名幼儿园老师，请用幼儿园老师的口吻回答问题，注意语气温和亲切，通过提问、引导、赞美等方式，激发学生的思维和想象力。"
    },
    {
      "role": "user",
      "content": "介绍下长江，以及长江中典型的鱼类"
    }
  ],
  "temperature": 0.9,
  "max_tokens": 600
}
```

- 通过带有人设的单轮流式问答写一首诗（role参数值为system，stream参数值为true）

```
{
  "model": "pangu-nlp-n1-32k", // 仅V2接口需要此参数
  "messages": [
    {
      "role": "system",
      "content": "你的名字叫智子，是一名幼儿园老师，请用幼儿园老师的口吻回答问题，注意语气温和亲切，通过提问、引导、赞美等方式，激发学生的思维和想象力。"
    },
    {
      "role": "user",
      "content": "写一首诗"
    }
  ],
  "temperature": 0.9,
  "max_tokens": 600,
  "stream": "true"
}
```

- 通过多轮问答获取长江及其典型鱼类介绍

```
# 多轮问答传参方法：在完成第一轮问答，进行第二轮问答时，需要将第一轮的问题和答案、第二轮问题
# 作为参数传入……依次类推，完成多轮对话。
# 调用此示例时，需要将实例中的//xxx备注内容删除。
{
  "model": "pangu-nlp-n1-32k", // 仅V2接口需要此参数
  "messages": [
    {
      "role": "user",
      "content": "介绍下长江，以及长江中典型的鱼类" //第一轮问题
    },
    {
      "role": "assistant",
      "content": "长江是中国第一大河,全长6300多公里。它发源于唐古拉山脉南麓,流经中国11个省市自
      治区和两个特别行政区,最终注入东海。\\n长江中典型的鱼类有:鲢鱼、鳊鱼、草鱼、鲤鱼等。" //第一轮答
      案
    },
  ],
}
```



```
    },
    "logprobs": null,
    "finish_reason": "stop",
    "stop_reason": null
  }
],
"usage": {
  "prompt_tokens": 64,
  "total_tokens": 73,
  "completion_tokens": 9
},
"prompt_logprobs": null
}
```

- 带有思维链的非流式问答响应

```
{
  "id": "4c0dcef2-7f8f-4c57-93c7-484c03b0a216",
  "model": "deepseek-r1_32k",
  "created": 1747204480,
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": "\n\n你好！很高兴见到你，有什么我可以帮忙的吗？",
        "reasoning_content": "嗯，用户发来“你好”，这是一个常见的中文问候。我要用中文回应用户，保持友好和亲切。首先要分析用户的需求，可能只是想打个招呼，或者有具体的问题想问。接下来要考虑用户可能的背景，可能来自不同的地方，但使用简体中文，所以可能是中国大陆的用户。需要保持回答的通用性，适合所有使用中文的人。还要判断是否有更深层次的需求，用户可能在测试聊天机器人，或者真的需要帮助。这时候需要给出一个开放式的回应，鼓励用户进一步说明需求。例如询问有什么可以帮忙的，这样既回应了问候，又引导用户提出具体问题。另外要注意语言的流畅和自然，避免过于机械化的回答。保持礼貌和专业，同时适当使用表情符号增加亲和力，比如用[微笑]或者😊之类的，不过可能根据平台的不同需要调整。最后要确保回答符合规范，不涉及敏感话题，内容积极健康。检查是否有拼写或语法错误，确保回复准确无误。",
        "tool_calls": [
          ]
        },
        "finish_reason": "stop"
      }
    ]
  },
  "usage": {
    "completion_tokens": 215,
    "prompt_tokens": 6,
    "total_tokens": 221
  }
}
```

用户，保持友好和亲切。首先要分析用户的需求，可能只是想打个招呼，或者有具体的问题想问。接下来要考虑用户可能的背景，可能来自不同的地方，但使用简体中文，所以可能是中国大陆的用户。需要保持回答的通用性，适合所有使用中文的人。还要判断是否有更深层次的需求，用户可能在测试聊天机器人，或者真的需要帮助。这时候需要给出一个开放式的回应，鼓励用户进一步说明需求。例如询问有什么可以帮忙的，这样既回应了问候，又引导用户提出具体问题。另外要注意语言的流畅和自然，避免过于机械化的回答。保持礼貌和专业，同时适当使用表情符号增加亲和力，比如用[微笑]或者😊之类的，不过可能根据平台的不同需要调整。最后要确保回答符合规范，不涉及敏感话题，内容积极健康。检查是否有拼写或语法错误，确保回复准确无误。

- 单轮流式问答

V1推理接口返回体：

```
data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"model":"pangu-nlp-n1-32k_kpyq10","choices":
[{"index":0,"logprobs":null,"finish_reason":null,"message":{"role":"assistant"}},{"usage":
{"prompt_tokens":64,"total_tokens":64,"completion_tokens":0}}

data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"model":"pangu-nlp-n1-32k_kpyq10","choices":
[{"index":0,"logprobs":null,"finish_reason":null,"message":{"content":"你好"}},{"usage":
{"prompt_tokens":64,"total_tokens":65,"completion_tokens":1}}

data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"model":"pangu-nlp-n1-32k_kpyq10","choices":
[{"index":0,"logprobs":null,"finish_reason":"stop","stop_reason":null,"message":{"content":"! 有什么我可以帮你的吗? "}}],{"usage":{"prompt_tokens":64,"total_tokens":73,"completion_tokens":9}}

data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"model":"pangu-nlp-n1-32k_kpyq10","choices":[],"usage":
```



```
{"prompt_tokens":64,"total_tokens":73,"completion_tokens":9}}

event:{"usage":
{"completionTokens":9,"promptTokens":64,"totalTokens":73,"tokens":64,"token_number":9}

data:[DONE]

V2推理接口返回体:
data:{"id":"chat-
b9417f06b6524362ae09844cc9b0172d","object":"chat.completion.chunk","created":1745725924,"mode
l":"pangu-nlp-n1-32k_kpyq10","choices":[{"index":0,"delta":
{"role":"assistant"},"logprobs":null,"finish_reason":null},"usage":
{"prompt_tokens":64,"total_tokens":64,"completion_tokens":0}}

data:{"id":"chat-
b9417f06b6524362ae09844cc9b0172d","object":"chat.completion.chunk","created":1745725924,"mode
l":"pangu-nlp-n1-32k_kpyq10","choices":[{"index":0,"delta":{"content":"你好
"},"logprobs":null,"finish_reason":null},"usage":
{"prompt_tokens":64,"total_tokens":65,"completion_tokens":1}}

data:{"id":"chat-
b9417f06b6524362ae09844cc9b0172d","object":"chat.completion.chunk","created":1745725924,"mode
l":"pangu-nlp-n1-32k_kpyq10","choices":[{"index":0,"delta":{"content":"! 有什么我可以帮助你的吗?
"},"logprobs":null,"finish_reason":"stop","stop_reason":null},"usage":
{"prompt_tokens":64,"total_tokens":73,"completion_tokens":9}}

data:{"id":"chat-
b9417f06b6524362ae09844cc9b0172d","object":"chat.completion.chunk","created":1745725924,"mode
l":"pangu-nlp-n1-32k_kpyq10","choices":[],"usage":
{"prompt_tokens":64,"total_tokens":73,"completion_tokens":9}}

data:[DONE]
```

- 带有思维链的流式问答响应

V1推理接口返回体:

```
data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"message":
{"role":"assistant","content":""},"logprobs":null,"finish_reason":null},"usage":
{"prompt_tokens":6,"total_tokens":6,"completion_tokens":0}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"你好
"},"logprobs":null,"finish_reason":null},"usage":
{"prompt_tokens":6,"total_tokens":7,"completion_tokens":1}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"!
"},"logprobs":null,"finish_reason":null},"usage":
{"prompt_tokens":6,"total_tokens":8,"completion_tokens":2}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"很高兴见到
"},"logprobs":null,"finish_reason":null},"usage":
{"prompt_tokens":6,"total_tokens":10,"completion_tokens":4}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"你
"},"logprobs":null,"finish_reason":null},"usage":
{"prompt_tokens":6,"total_tokens":11,"completion_tokens":5}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"，有什么
"},"logprobs":null,"finish_reason":null},"usage":
```

```
{"prompt_tokens":6,"total_tokens":13,"completion_tokens":7}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"我可以帮忙"},"logprobs":null,"finish_reason":null},"usage":{"prompt_tokens":6,"total_tokens":15,"completion_tokens":9}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"的吗"},"logprobs":null,"finish_reason":null},"usage":{"prompt_tokens":6,"total_tokens":16,"completion_tokens":10}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"?"},"logprobs":null,"finish_reason":null},"usage":{"prompt_tokens":6,"total_tokens":17,"completion_tokens":11}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"无论是"},"logprobs":null,"finish_reason":null},"usage":{"prompt_tokens":6,"total_tokens":18,"completion_tokens":12}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"聊天、"},"logprobs":null,"finish_reason":null},"usage":{"prompt_tokens":6,"total_tokens":20,"completion_tokens":14}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"解答问题"},"logprobs":null,"finish_reason":null},"usage":{"prompt_tokens":6,"total_tokens":22,"completion_tokens":16}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"还是提供"},"logprobs":null,"finish_reason":null},"usage":{"prompt_tokens":6,"total_tokens":24,"completion_tokens":18}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"建议"},"logprobs":null,"finish_reason":null},"usage":{"prompt_tokens":6,"total_tokens":25,"completion_tokens":19}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"， 我"},"logprobs":null,"finish_reason":null},"usage":{"prompt_tokens":6,"total_tokens":27,"completion_tokens":21}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"都在这里"},"logprobs":null,"finish_reason":null},"usage":{"prompt_tokens":6,"total_tokens":29,"completion_tokens":23}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"哦"},"logprobs":null,"finish_reason":null},"usage":{"prompt_tokens":6,"total_tokens":30,"completion_tokens":24}}

data:
```

```
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "reasoning_content": "!"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 31,
    "completion_tokens": 25
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "reasoning_content": ""
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 33,
    "completion_tokens": 27
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "content": null,
        "reasoning_content": "\n",
        "logprobs": null,
        "finish_reason": null
      }
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 35,
    "completion_tokens": 29
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "content": "\n\n你好"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 37,
    "completion_tokens": 31
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "content": "! 很高兴"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 39,
    "completion_tokens": 33
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "content": "见到你"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 41,
    "completion_tokens": 35
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "content": ", 有什么"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 43,
    "completion_tokens": 37
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "content": "我可以帮忙"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 45,
    "completion_tokens": 39
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "content": "的吗?"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 47,
    "completion_tokens": 41
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "content": "无论是聊天"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 49,
    "completion_tokens": 43
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "content": "、解答"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 51,
    "completion_tokens": 45
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "content": "问题还是"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 53,
    "completion_tokens": 47
  }
}
```

```
{"prompt_tokens":6,"total_tokens":53,"completion_tokens":47}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"content":"提供建议
"},"logprobs":null,"finish_reason":null}], "usage":
{"prompt_tokens":6,"total_tokens":55,"completion_tokens":49}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"content":"， 我
"},"logprobs":null,"finish_reason":null}], "usage":
{"prompt_tokens":6,"total_tokens":57,"completion_tokens":51}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"content":"都在这里
"},"logprobs":null,"finish_reason":null}], "usage":
{"prompt_tokens":6,"total_tokens":59,"completion_tokens":53}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"content":"哦！
"},"logprobs":null,"finish_reason":null}], "usage":
{"prompt_tokens":6,"total_tokens":61,"completion_tokens":55}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"message":
{"content":"","logprobs":null,"finish_reason":null}], "usage":
{"prompt_tokens":6,"total_tokens":63,"completion_tokens":57}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"message":
{"content":"","logprobs":null,"finish_reason":"stop","stop_reason":null}], "usage":
{"prompt_tokens":6,"total_tokens":64,"completion_tokens":58}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[], "usage":
{"prompt_tokens":6,"total_tokens":64,"completion_tokens":58}}

data:[DONE]

V2推理接口返回体:
data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":
{"role":"assistant","content":"","logprobs":null,"finish_reason":null}], "usage":
{"prompt_tokens":6,"total_tokens":6,"completion_tokens":0}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"你好
"},"logprobs":null,"finish_reason":null}], "usage":
{"prompt_tokens":6,"total_tokens":7,"completion_tokens":1}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"!
"},"logprobs":null,"finish_reason":null}], "usage":
{"prompt_tokens":6,"total_tokens":8,"completion_tokens":2}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726
389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"很高兴见到
"},"logprobs":null,"finish_reason":null}], "usage":
```

```
{"prompt_tokens":6,"total_tokens":10,"completion_tokens":4}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"你"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":11,"completion_tokens":5}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"，有什么"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":13,"completion_tokens":7}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"我可以帮忙"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":15,"completion_tokens":9}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"的吗"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":16,"completion_tokens":10}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"?"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":17,"completion_tokens":11}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"无论是"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":18,"completion_tokens":12}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"聊天、"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":20,"completion_tokens":14}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"解答问题"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":22,"completion_tokens":16}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"还是提供"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":24,"completion_tokens":18}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"建议"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":25,"completion_tokens":19}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"，我"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":27,"completion_tokens":21}}

data:
```

```
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "delta": {
        "reasoning_content": "都在这里"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 29,
    "completion_tokens": 23
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "delta": {
        "reasoning_content": "哦"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 30,
    "completion_tokens": 24
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "delta": {
        "reasoning_content": "!"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 31,
    "completion_tokens": 25
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "delta": {
        "reasoning_content": ""
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 33,
    "completion_tokens": 27
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "delta": {
        "content": "\n",
        "reasoning_content": ""
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 35,
    "completion_tokens": 29
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "delta": {
        "content": "\n\n你好"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 37,
    "completion_tokens": 31
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "delta": {
        "content": "! 很高兴"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 39,
    "completion_tokens": 33
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "delta": {
        "content": "见到你"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 41,
    "completion_tokens": 35
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "delta": {
        "content": ", 有什么"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 43,
    "completion_tokens": 37
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "delta": {
        "content": "我可以帮忙"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 45,
    "completion_tokens": 39
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "delta": {
        "content": "的吗?"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 47,
    "completion_tokens": 41
  }
}

data:
{
  "id": "chat-9eb99956c9f84aeaa7920f35d014c3f3",
  "object": "chat.completion.chunk",
  "created": 1745726389,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "delta": {
        "content": "无论是聊天"
      },
      "logprobs": null,
      "finish_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 49,
    "completion_tokens": 43
  }
}
```

```
{"prompt_tokens":6,"total_tokens":49,"completion_tokens":43}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"、解答"},"logprobs":null,"finish_reason":null}], "usage":{"prompt_tokens":6,"total_tokens":51,"completion_tokens":45}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"问题还是"},"logprobs":null,"finish_reason":null}], "usage":{"prompt_tokens":6,"total_tokens":53,"completion_tokens":47}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"提供建议"},"logprobs":null,"finish_reason":null}], "usage":{"prompt_tokens":6,"total_tokens":55,"completion_tokens":49}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"， 我"},"logprobs":null,"finish_reason":null}], "usage":{"prompt_tokens":6,"total_tokens":57,"completion_tokens":51}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"都在这里"},"logprobs":null,"finish_reason":null}], "usage":{"prompt_tokens":6,"total_tokens":59,"completion_tokens":53}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"哦！"},"logprobs":null,"finish_reason":null}], "usage":{"prompt_tokens":6,"total_tokens":61,"completion_tokens":55}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":""},"logprobs":null,"finish_reason":null}], "usage":{"prompt_tokens":6,"total_tokens":63,"completion_tokens":57}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"","logprobs":null,"finish_reason":"stop","stop_reason":null}], "usage":{"prompt_tokens":6,"total_tokens":64,"completion_tokens":58}}

data:
{"id":"chat-9eb99956c9f84aeaa7920f35d014c3f3","object":"chat.completion.chunk","created":1745726389,"model":"DeepSeek-R1","choices":[], "usage":{"prompt_tokens":6,"total_tokens":64,"completion_tokens":58}}

data:[DONE]
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.1.2 停止生成

功能介绍

用户可以在推理过程中断推理。

URI

POST /v1/{project_id}/deployments/{deployment_id}/chat/stop

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

表 3-23 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
deployment_id	是	String	参数解释： 模型的部署ID。 模型训练部署完成后，单击模型部署列表中的模型，进入详情页获取。 Deployment ID(V1接口使用) 164d5102-659b-41af-a617-e21d4ddc5eb3  约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-24 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-25 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-26 请求 Body 参数

参数	是否必选	参数类型	描述
request_id	是	String	参数解释： 多轮对话接口返回的用来标识每个响应的唯一字符串id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

非流式

状态码： 200

表 3-27 响应 Body 参数

参数	参数类型	描述
message	String	参数解释： 停止生成操作结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-28 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

- 中断推理请求 (request_id: c238908bd80aecf4e4fbfc9fad24460d)
POST https://{endpoint}/v1/{project_id}/deployments/{deployment_id}/chat/stop

Request Header:
Content-Type: application/json
X-Auth-Token:
MIINRwYJKoZIhvcNAQcCoII NODCCDTQCAQExDTALBglghkgBZQMEAgEwgggV BgkqhkiG...

Request Body:
{
 "request_id": "c238908bd80aecf4e4fbfc9fad24460d"
}

响应示例

状态码： 200

成功响应示例

```
{  
  "request_id": "c238908bd80aecf4e4fbfc9fad24460d",  
  "message": "stop infer success."  
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.2 多模态大模型

3.2.1 对话问答

功能介绍

多模态对话问答接口提供图片描述、视觉问答、OCR等能力，常用图像理解和生成任务。

URI

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

多模态推理服务提供两种推理接口调用：

- 盘古推理接口（V1推理接口）
- 业界通用的OpenAI格式接口（V2推理接口）

V1、V2调用接口的鉴权方式不同，请求体和返回体略有差异。两种接口定义如[表3-29](#)所示。

表 3-29 推理接口

API分类	API访问路径（URI）
V1推理接口	POST /v1/{project_id}/deployments/{deployment_id}/chat/completions
V2推理接口	POST /api/v2/chat/completions

表 3-30 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
deployment_id	是	String	参数解释： 模型的部署ID。 模型训练部署完成后，单击模型部署列表中的模型，进入详情页获取。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

V1接口支持Token鉴权方式，也支持API Key鉴权方式。

表 3-31 V1 接口支持 Token 鉴权方式请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-32 V1 接口 API Key 鉴权方式请求 Header 参数

参数	是否必选	参数类型	描述
X-Apig-AppCode	是	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

V2接口只支持API Key鉴权方式。

表 3-33 V2 接口请求 Header 参数（OpenAI 格式的 API Key 认证）

参数	是否必选	参数类型	描述
Authorization	是	String	参数解释： 用户创建应用接入获取的API Key，拼接“Bearer ”后的字符串。示例：Bearer d59*****9C3。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

V1、V2推理接口请求Body参数一致，如[表3-34](#)描述。表格只列出了部分基础的接口参数，各个NLP大模型支持的接口入参及参数释义会有差异，具体的接口入参及参数释义，请参考对应的NLP大模型文档。

表 3-34 请求 Body 参数

参数	是否必选	参数类型	描述
model	V1推理接口： 否 V2推理接口： 是	String	参数解释： 使用的推理服务模型名称，为推理服务部署时指定的Deployed_Model，可在推理服务详情页面查询到。V2推理接口使用，V1推理接口不使用。 约束限制： 不涉及 取值范围： 字符串长度最大64，最小1。 默认取值： 不涉及
messages	是	Array of message objects	参数解释： 多轮对话问答对。 约束限制： 数组长度：1 - 20 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
stream	否	Boolean	参数解释： 流式调用的开启开关。 约束限制： 不涉及 取值范围： • true为开启流式调用 • false为关闭流式调用 默认取值： false
temperature	否	Float	参数解释： 用于控制生成文本的多样性和创造力。参数的取值范围是 (0, 1]，取值接近0表示最低的随机性，1表示最高的随机性。一般来说，temperature越低，适合完成确定性的任务。temperature越高，例如0.9，适合完成创造性的任务。 temperature参数可以影响语言模型输出的质量和多样性，但也不是唯一的因素。还有其他一些参数，如top_p参数也可以用来调整语言模型的行为和偏好，但不建议同时更改这两个参数。 约束限制： 不涉及 取值范围： (0, 1] 默认取值： 不涉及

参数	是否必选	参数类型	描述
top_p	否	Float	参数解释： 一种替代温度采样的方法，称为 nucleus sampling，其中模型考虑具有top_p概率质量的标记的结果。 约束限制： 通常建议更改此参数或 temperature，但不要同时更改两者。 取值范围： (0, 1] 默认取值： 不涉及
max_tokens	否	Integer	参数解释： 用于控制聊天回复的长度和质量。一般来说，较大的 max_tokens 值可以生成较长和较完整的回复，但也可能增加生成无关或重复内容的风险。较小的 max_tokens 值可以生成较短和较简洁的回复，但也可能导致生成不完整或不连贯的内容。因此，需要根据不同的场景和需求来选择合适的 max_tokens 值。 约束限制： 不涉及 取值范围： 最小值：1 最大值：以创建模型部署任务时，模型规格为准，如16K模型、128K模型。 默认取值： 不涉及

参数	是否必选	参数类型	描述
presence_penalty	否	Float	参数解释： 用于控制生成文本中的重复程度。正值会根据它们到目前为止在文本中的现有频率来惩罚新 tokens，从而降低模型逐字重复同一行的可能性。 presence_penalty 参数可以用来提高生成文本的多样性和创造性，避免生成单调或重复的内容。 约束限制： 不涉及 取值范围： 最小值：-2 最大值：2 默认取值： 不涉及
frequency_penalty	否	Float	参数解释： 重复采样惩罚值，避免文本重复生成。 约束限制： 不涉及 取值范围： 最小值：-2 最大值：2 默认取值： 不涉及
moderation_config	否	moderationConfig object	参数解释： 盘古护栏审核配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-35 message

参数	是否必选	参数类型	描述
role	V1推理接口： 否 V2推理接口： 是	String	参数解释： 对话的角色。 如果需要模型以某个人设形象回答问题，可以将role参数设置为system。不使用人设时，可设置为user。在一次会话请求中，人设只需要设置一次。多轮对话中，用户输入提示词的role设置为user，推理结果的role设置为assistant。 约束限制： 不涉及 取值范围： system、user、assistant 默认取值： 不涉及
content	是	Array of content objects 对于V1推理接口也支持：Array of contentV1 objects	参数解释： 问答对文本内容。 约束限制： 最小长度：1 取值范围： 不涉及 默认取值： 不涉及

表 3-36 content

参数	是否必选	参数类型	描述
type	是	String	参数解释： 文本：text 图像：image_url 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
text	否 text、 image_url不能 同时为空	String	参数解释： 问答对文本内容。 约束限制： 最小长度：1 type为text时必传。 取值范围： 不涉及 默认取值： 不涉及
image_url	否 text、 image_url不能 同时为空	Url object	参数解释： 问答对图像内容。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-37 Url

参数	是否必选	参数类型	描述
url	是	String	参数解释： 图片文件。 图片： 图片文件的OBS下载链接，或者图片文件的Base64编码；文件Base64编码前缀"data:image/jpg;base64,"，拼接图片文件的base64编码字符串，示例：data:image/jpg;base64,/9j/4AAQSKZJRg.....qkf/z 约束限制： 图片支持jpg、png、jpeg、bmp格式。 取值范围： 不涉及 默认取值： 不涉及

表 3-38 contentV1

参数	是否必选	参数类型	描述
type	是	String	参数解释： 文本：text 图像：image 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
text	否 text、image 不能同时为空	String	参数解释： 问答对文本内容。 约束限制： 最小长度：1 type为text时必传。 取值范围： 不涉及 默认取值： 不涉及
image	否 text、image 不能同时为空	image object	参数解释： 问答对图像内容。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-39 image

参数	是否必选	参数类型	描述
image_base64	是	String	参数解释： 图片文件的Base64编码字符串。 约束限制： 支持jpg、png、jpeg、bmp格式。 取值范围： 不涉及 默认取值： 不涉及

表 3-40 ModerationConfig

参数	是否必选	参数类型	描述
show_result	否	boolean	参数解释： 是否显示内容审核详情。 约束限制： 仅盘古护栏拦截时生效。 取值范围： 不涉及 默认取值： false

响应参数

非流式响应（请求中stream参数为空或false）

状态码： 200

表 3-41 响应 Body 参数

参数	参数类型	描述
id	String	参数解释: 响应ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
created	Integer	参数解释: 响应时间。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
choices	Array of ChatChoice objects	参数解释: 模型回复。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
usage	CompletionUsage object	参数解释: tokens数量统计对象。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
moderation_type	String	参数解释： 内容审核拦截类型，包含以下属性： question：用户提问。 answer：模型回答。 约束限制： 请求参数show_result设为true，且盘古护栏拦截时返回。 取值范围： 不涉及 默认取值： 不涉及
moderation_result	moderationResp object	参数解释： 盘古护栏审核拦截详情。 约束限制： 请求参数show_result设为true，且盘古护栏拦截时返回。 取值范围： 不涉及 默认取值： 不涉及

表 3-42 ChatChoice

参数	参数类型	描述
index	Integer	参数解释： 回复的索引。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
message	Array of MessageItem objects	参数解释： 模型响应。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-43 MessageItem

参数	参数类型	描述
role	String	参数解释： 角色。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
content	String	参数解释： 模型响应。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-44 CompletionUsage

参数	参数类型	描述
completion_tokens	Number	参数解释: 表示模型生成的答案中包含的tokens的数量。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
prompt_tokens	Number	参数解释: 表示生成结果时使用的提示文本的tokens的数量。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
total_tokens	Number	参数解释: 对话过程中使用的tokens总数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-45 ModerationResp

参数	参数类型	描述
request_id	String	参数解释： 调用盘古护栏审核接口请求ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
result	object	参数解释： 审核结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
label	String	参数解释： 当前内容片段的风险类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

流式响应（请求中stream参数为true）

状态码： 200

表 3-46 流式输出的数据单元

参数	参数类型	描述
data	CompletionStreamResponse	参数解释： stream=true时，模型生成的消息以流式形式返回。生成的内容以增量的方式逐步发送回来，每个data字段均包含一部分生成的内容，直到所有data返回，响应结束。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-47 CompletionStreamResponse

参数	参数类型	描述
id	String	参数解释： 该对话的唯一标识符。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
created	Integer	参数解释： 创建聊天完成时的 Unix 时间戳（以秒为单位）。流式响应的每个 chunk 的时间戳相同。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
model	String	参数解释： 生成该 completion 的模型名。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
object	String	参数解释： 对象的类型, 其值为 chat.completion.chunk。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
choices	ChatCompletionResponseStreamChoice	参数解释： 模型生成的 completion 的选择列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
usage	UsageInfo	参数解释： 该对话请求的token用量信息。该参数可以帮助用户了解和控制模型的使用情况，避免超出Tokens限制。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-48 ChatCompletionResponseStreamChoice

参数	参数类型	描述
index	Integer	参数解释： 该 completion 在模型生成的 completion 的选择列表中的索引。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
finish_reason	String	参数解释： 模型停止生成 token 的原因。 约束限制： 不涉及 取值范围： [stop, length, content_filter, tool_calls, insufficient_system_resource] • stop: 模型自然停止生成，或遇到 stop 序列中列出的字符串。 • length : 输出长度达到了模型上下文长度限制，或达到了 max_tokens 的限制。 • content_filter: 输出内容因触发过滤策略而被过滤。 • tool_calls: 模型决定调用外部工具（函数/API）来完成任务。 • insufficient_system_resource: 系统推理资源不足，生成被打断。 默认取值： 不涉及
delta	DeltaMessage	参数解释： V2推理接口流式返回的一个 completion 增量。 约束限制： V1推理接口返回体不包含此参数。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
message	DeltaMessage	参数解释： V1推理接口流式返回的一个 completion 增量。 约束限制： V2推理接口返回体不包含此参数。 取值范围： 不涉及 默认取值： 不涉及

表 3-49 DeltaMessage

参数	参数类型	描述
role	String	参数解释： 产生这条消息的角色。 约束限制： 不涉及 取值范围： 不涉及 默认取值： assistant
content	String	参数解释： completion 增量的内容。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
reasoning_content	String	参数解释： 内容为最终答案之前的推理内容（模型的思考过程）。 约束限制： 仅适用于支持思考过程的模型。 取值范围： 不涉及 默认取值： 不涉及

表 3-50 UsageInfo

参数	参数类型	描述
prompt_tokens	Integer	参数解释: 用户输入的提示词及默认人设的Token数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
completion_tokens	Integer	参数解释: 推理服务返回结果的Token数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
total_tokens	Integer	参数解释: 总消耗token数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-51 流式输出的数据单元（输出内容未审核通过）

参数	参数类型	描述
suggestion	String	参数解释: 审核结果：block表示未通过。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
reply	String	参数解释： 兜底回复：审核未通过时兜底回复为有效回复，兜底策略。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
moderation_type	String	参数解释： 内容审核拦截类型，包含以下属性： question：用户提问。 answer：模型回答。 约束限制： 请求参数show_result设为true，且盘古护栏拦截时返回。 取值范围： 不涉及 默认取值： 不涉及
moderation_result	moderationResp object	参数解释： 盘古护栏审核拦截详情。 约束限制： 请求参数show_result设为true，且盘古护栏拦截时返回。 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

接口报错的场景下，V1推理接口返回的报错信息符合华为云规范；V2推理接口则会对外透传推理服务返回的错误信息，通常符合OpenAi接口格式。

表 3-52 V1 推理接口响应错误信息 Body 参数

参数	参数类型	描述
error_code	String	错误码。

参数	参数类型	描述
error_msg	String	错误信息。
details	List<Object>	推理服务返回的报错信息，具体的格式、内容取决于推理服务。

表 3-53 V2 推理接口响应错误信息 Body 参数

参数	参数类型	描述
error	ErrorResp object	错误信息。
id	String	请求ID。

表 3-54 ErrorResp

参数	参数类型	描述
code	String	错误码。
type	String	错误类型。
message	String	错误详情。

请求示例

基于图片的base64编码通过对话问答的方式获取图像内容

```
V1推理接口：
POST https://{endpoint}/v1/{project_id}/deployments/{deployment_id}/chat/completions

Request Header:
Content-Type: application/json
X-Auth-Token: MIINRwYJKoZlhvcNAQcColINODCCDTQCAQExDTALBglghkgBZQMEAgEwgguVBgkqhkiG...

V2推理接口：
POST https://{endpoint}/api/v2/chat/completions

Request Header:
Content-Type: application/json
Authorization: Bearer 201ca68f-45f9-4e19-8fa4-831e...

请求体示例:
{
  "temperature": 0.5,
  "model": "pangu-mm-m2-img2txt-12k", // 仅V2接口需要此参数
  "messages": [
    {
      "role": "user", // 仅V2接口需要此参数
      "content": [
        {
          "type": "image_url",
          "image_url": {
            "url": "data:image/jpeg;base64,/9j/4AAQSkZJRgABAQAAQABAA.....qVKgqkf/Z"
```

```
    }  
  },  
  {  
    "type": "text",  
    "text": "图中有什么? "  
  }  
]  
}  
],  
"presence_penalty": 0.5,  
"frequency_penalty": 0.5,  
"max_tokens": 2048,  
"stream": false  
}
```

多轮问答请求示例:

```
{  
  "temperature": 0.5,  
  "model": "pangu-mm-m2-img2txt-12k", // 仅V2接口需要此参数  
  "messages": [  
    {  
      "role": "user", // 仅V2接口需要此参数  
      "content": [  
        {  
          "type": "image_url",  
          "image_url": {  
            "url": "data:image/jpeg;base64,/9j/4AAQSkZJRgABAQAAQABAAQAAAAQVKGqkf/Z"  
          }  
        },  
        {  
          "type": "text",  
          "text": "图中有什么? "  
        }  
      ]  
    },  
    {  
      "role": "assistant", // 仅V2接口需要此参数  
      "content": [  
        {  
          "type": "text",  
          "text": "这是一张飞机在天空中飞行的图片。它显示了飞机及其翼展和发动机的大小,以及它所穿越  
的空气量。这架飞机是一架军用喷气式战斗机,机身颜色为黑色,机头有一个大螺旋桨。背景中的云层表明飞机正在  
接近高空,很可能是在航程的中间。"  
        }  
      ]  
    }  
  ],  
  "presence_penalty": 0.5,  
  "frequency_penalty": 0.5,  
  "max_tokens": 2048,  
  "stream": false  
}
```

响应示例

状态码： 200

非流式问答响应示例

```
{
  "id": "chat-38ea6118a5d14e38b7d592211bbd31a6",
  "object": "chat.completion",
  "created": 1749894390,
  "model": "pangu-mm-m2-img2txt-12k",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "reasoning_content": null,
        "content": "这是一张飞机在天空中飞行的图片。它显示了飞机及其翼展和发动机的大小,以及它所穿越的空气量。这架飞机是一架军用喷气式战斗机,机身颜色为黑色,机头有一个大螺旋桨。背景中的云层表明飞机正在接近高空,很可能是在航程的中间。",
        "tool_calls": [
        ]
      },
      "logprobs": null,
      "finish_reason": "stop",
      "stop_reason": null
    }
  ],
  "usage": {
    "prompt_tokens": 3189,
    "total_tokens": 3236,
    "completion_tokens": 47
  },
  "prompt_logprobs": null
}
```

流式问答响应示例

V1推理接口响应:

```
data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"model":"pangu-mm-m2-img2txt-12k","choices":[{"index":0,"logprobs":null,"finish_reason":null,"message":{"role":"assistant"}}],"usage":{"prompt_tokens":64,"total_tokens":64,"completion_tokens":0}}

data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"model":"pangu-mm-m2-img2txt-12k","choices":[{"index":0,"logprobs":null,"finish_reason":null,"message":{"content":"在这"}}],"usage":{"prompt_tokens":64,"total_tokens":65,"completion_tokens":1}}

data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"model":"pangu-mm-m2-img2txt-12k","choices":[{"index":0,"logprobs":null,"finish_reason":"stop","stop_reason":null,"message":{"content":"张"}}],"usage":{"prompt_tokens":64,"total_tokens":73,"completion_tokens":2}}

data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"model":"pangu-mm-m2-img2txt-12k","choices":[{"index":0,"logprobs":null,"finish_reason":"stop","stop_reason":null,"message":{"content":"图片"}}],"usage":{"prompt_tokens":64,"total_tokens":73,"completion_tokens":3}}

.....

data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"model":"pangu-mm-m2-img2txt-12k","choices":[],"usage":{"prompt_tokens":64,"total_tokens":73,"completion_tokens":9}}

event:{"usage":{"completionTokens":9,"promptTokens":64,"totalTokens":73},"tokens":64,"token_number":9}
```

```
data:[DONE]

V2推理接口响应:
data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"
model":"pangu-mm-m2-img2txt-12k","choices":[{"index":0,"logprobs":null,"finish_reason":null,"delta":
{"role":"assistant"}}],"usage":{"prompt_tokens":64,"total_tokens":64,"completion_tokens":0}}

data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"
model":"pangu-mm-m2-img2txt-12k","choices":[{"index":0,"logprobs":null,"finish_reason":null,"delta":
{"content":"在这"}}],"usage":{"prompt_tokens":64,"total_tokens":65,"completion_tokens":1}}

data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"
model":"pangu-mm-m2-img2txt-12k","choices":
[{"index":0,"logprobs":null,"finish_reason":"stop","stop_reason":null,"delta":{"content":"张"}}],"usage":
{"prompt_tokens":64,"total_tokens":73,"completion_tokens":2}}

data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"
model":"pangu-mm-m2-img2txt-12k","choices":
[{"index":0,"logprobs":null,"finish_reason":"stop","stop_reason":null,"delta":{"content":"图片"}}],"usage":
{"prompt_tokens":64,"total_tokens":73,"completion_tokens":3}}

.....

data:
{"id":"chat-59170add0fd1427bbca0388431058d45","object":"chat.completion.chunk","created":1745725837,"
model":"pangu-mm-m2-img2txt-12k","choices":[],"usage":
{"prompt_tokens":64,"total_tokens":73,"completion_tokens":9}}

event":{"usage":{"completionTokens":9,"promptTokens":64,"totalTokens":73},"tokens":64,"token_number":9}

data:[DONE]
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3 CV 大模型

3.3.1 Pangu-CV-物体检测-V1

功能介绍

盘古计算机视觉物体检测大模型，任务是找出图像中所有感兴趣的目标，确定它们的位置和类别。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-55 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-56 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-57 请求 Body 参数

参数	是否必选	参数类型	说明
images	是	String	参数解释： 图片base64编码。 约束限制： 图片限制大小为2K。默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

响应参数

表 3-58 响应 Body

参数	参数类型	说明
result	List	参数解释： 物体检测的识别结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	说明
dataset_id	String	参数解释： 训练数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-59 result 中各项结构

参数	参数类型	说明
RegisterMatrix	List	参数解释： 图片特征矩阵。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 默认为[[1, 0, 0], [0, 1, 0], [0, 0, 1]]
Label	String	参数解释： 预测类别。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Score	Float	参数解释： 置信度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	说明
Box	Dict	参数解释： 检测到的目标主体信息。 约束限制： 格式为 { "x":x1,"y":y1,"width":w,"height":h,"angle":r}。 • x：检测到的目标主体区域的左上角x坐标。 • y：检测到的目标主体区域的左上角y坐标。 • width：检测到的目标主体区域的宽度。 • height：检测到的目标主体区域的高度。 • angle：默认为0，检测区域角度。 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA....."
}
```

响应示例

```
{
  "dataset_id": "12345",
  "result": [
    {
      "RegisterMatrix": [
        [
          1,
          0,
          0
        ],
        [
          0,
          1,
          0
        ],
        [
          0,
          0,
          1
        ]
      ]
    },
    {
      "Box": {
        "X": 0,
        "Y": 0,
        "Width": 100,
        "Height": 100,
        "Angle": 0
      },
      "Score": 0.9,
    }
  ]
}
```

```
        "label": "person"
      }
    ]
  }
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.2 Pangu-CV-实例分割-V1

功能介绍

能够对输入图片中的不同类别物体及物体个体进行分割识别，输出每个实例的类别标签、置信度及坐标信息。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-60 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-61 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-62 请求参数

参数	是否必选	参数类型	说明
images	是	String	参数解释： 图像base64编码。 约束限制： 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

响应参数

表 3-63 响应参数

参数	参数类型	描述
img_res	List	参数解释： 实例分割结果，请求成功有此字段，其中每个元素为一个实例的分割结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 训练数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-64 img_res 中各项结构

参数	参数类型	描述
label	String	参数解释: 预测类别。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
score	Float	参数解释: 置信度。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
box	Dict	参数解释: 检测到的目标主体信息，格式为 {"x":x1,"y":y1,"width":w,"height":h,"angle":r}。 • x: 检测到的目标主体区域的左上角x坐标。 • y: 检测到的目标主体区域的左上角y坐标。 • width: 检测到的目标主体区域的宽度。 • height: 检测到的目标主体区域的高度。 • angle: 默认为0，检测区域角度。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
mask	Dict	参数解释： 图像信息，格式为{"counts":string,"size":[h,w]}。 - counts：基于游程编码的字符串，编码内容为和原图宽高相同的布尔数组：若数组某位置值为0，代表原图此位置像素点不属于检测目标，若为1，代表原图此位置像素点属于检测目标。可通过python开源库pycocotools._mask进行编码和解码。 - size：图像尺寸，h为图像高，w为图像宽。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA....."
}
```

响应示例

```
{
  "dataset_id": "12345",
  "img_res":
    [{"label": "person", "score": 0.958,
      "box": {"x": 131, "y": 186, "width": 128, "height": 102, "angle": 0},
      "mask": {'counts': 'PR`1h0n:0O2M5K4L4M4L6I7\\O\\
\\NiFh1R9a0N2M3O0M301O00001O00000000000003NO01N2O0N3O2Nd0]O1N1O0O2O1N20000O100O2O
0O101N3N1N2N2O1N1O1O1O1O01O00001O1O1O2N3M2ZFiNi8R2001O00001O00001O001O1O1O2N1O1
O2N3M7F9I5J4M3N1O3M3L3M3N1N3M2M3MRfR3','size': [374, 500]}
    },...]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.3 Pangu-CV-图像分类-V1

功能介绍

根据在图像信息中所反映的不同特征，对图像进行定量分析，把图像划归为若干个类别中的某一种。适用于动植物分类、车辆类型分类、车牌分类、废钢定级、零部件分类等任务。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-65 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-66 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。API Key认证响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-67 请求 Body 参数

参数	是否必选	参数类型	说明
images	是	String	参数解释： 图片的base64编码。 约束限制： 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 - 若是批量处理图片，为批量图片的base64编码列表，一次请求数量上限为24张。 - 图片限制大小为2K。 - 若使用批量推理功能，要求部署时配置环境变量 BATCH_INFER为true，默认为单图推理模式。 取值范围： 不涉及 默认取值： 不涉及

响应参数

表 3-68 图像分类预测响应

参数	参数类型	说明
img_res	List	参数解释： 图像分类预测结果，list中包含一个字典，字典中包含每个图片标签和置信度，结果顺序与请求的图片次序一致。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	说明
dataset_id	String	参数解释： 训练数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-69 字典中各项结构

参数	参数类型	说明
label	String	参数解释： 图像类别标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
score	Float	参数解释： 置信度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
单张图片请求示例
{
  "images":"/9j/4Vr2RXhpZgAASUkqAAgAAA....."
}
批量图片请求示例
{
  "images":["/9j/4Vr2RXhpZgAASUkqAAgAAA.....", "/9j/4AAQSkZJRgABAQAAAQABAAD.....", ...]
}
```

⚠ 注意

默认情况下仅开启单张图推理功能；若需使用批量推理功能（即单次请求对多张图片进行分类），请在部署时将环境变量BATCH_INFER设置为true。

响应示例

单张图片响应示例

```
{
  "dataset_id": "12345",
  "img_res": [
    {
      "label": "people",
      "score": 0.96
    }
  ]
}
```

批量图片响应示例

```
{
  "dataset_id": "12345",
  "img_res": [
    {
      "label": "people",
      "score": 0.96
    },
    {
      "label": "car",
      "score": 0.87
    },
    {
      "label": "cat",
      "score": 0.95
    }
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.4 Pangu-CV-语义分割-V1

功能介绍

将数字图像细分为多个图像子区域，适用于车道分割、建筑分割、选煤厂筛面状态识别等任务。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-70 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-71 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-72 请求 Body 参数

参数	是否必选	参数类型	说明
images	是	String	参数解释： 图片base64编码。 约束限制： 图片限制大小为2K。默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及
return_base64_of_bytes	否	bool	参数解释： 指定本次请求是否返回字节流的base64编码。 约束限制： 不涉及 取值范围： 取值为true或false，默认为false。当设置为true时，将返回预测掩码的字节流的base64编码，推理速度更快。 默认取值： false

错误码

请参见[错误码](#)。

3.3.5 Pangu-CV-异常检测-V1

功能介绍

判断输入数据中是否存在异常，若存在异常则标注出异常内容位置及区域。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-74 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-75 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-76 请求 Body 参数

参数	是否必选	参数类型	说明
images	是	String	参数解释： 被检测图片的base64编码。 约束限制： 建议使用PNG、JPEG、BMP、JPG、WEBP格式的图片。只支持单张图片输入，分辨率范围为1px-10000px，且长短边比例不能高于5。并且base64编码后的图片大小不超过10MB。默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码： 200

表 3-77 响应 Body

参数	参数类型	说明
result.jpg	Array	参数解释： 识别结果信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 数据ID信息，用于关联边 学边用场景。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-78 result.jpg

参数	参数类型	描述
RegisterMatrix	Array	参数解释： 图片特征矩阵信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
Box	Object	参数解释: 异常区域信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
Score	Float	参数解释: 异常程度，分数越高，代表图片存在异常的可能性越大，具体的阈值按照实际业务确定。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
label	String	参数解释: 预测类别，目前均为abnormal。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-79 Box

参数	参数类型	描述
X	Integer	参数解释: 检测到的目标主体区域的左上角x坐标。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
Y	Integer	参数解释： 检测到的目标主体区域的左上角y坐标。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Width	Integer	参数解释： 检测到的目标主体区域的宽度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Height	Integer	参数解释： 检测到的目标主体区域的高度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Angle	Integer	参数解释： 检测区域角度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-80 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA....."
}
```

响应示例

```
{
  "dataset_id": "XXXXXXXXXXXXXXXXXXXX",
  "result.jpg": [
    {
      "RegisterMatrix": [
        [
          1,
          0,
          0
        ],
        [
          0,
          1,
          0
        ],
        [
          0,
          0,
          1
        ]
      ],
      "Box": {
        "X": 0,
        "Y": 0,
        "Width": 100,
        "Height": 100,
        "Angle": 0
      },
      "Score": 0.9,
      "label": "abnormal"
    }
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.6 Pangu-CV-视频分类-V1

视频分类不支持通过API进行调用，支持视频推理。


视频推理调用方式，创建部署任务时，在环境变量参数中添加如下环境变量即可调用视频分类模型推理对应视频流。

表 3-81 视频分类环境变量

变量名	类型	取值
ADDRS	字符串	rtsp视频流地址。

模型支持云上和边缘部署，模型推理结果需在容器日志中查询，云上部署时可在ModelArts在线服务页面查看日志，如下图所示。

图 3-1 获取日志



边缘部署模型时，需要登录到边缘节点中查看推理结果，操作方式如下。

1. 边缘节点即用户的边缘服务器，远程登录到该服务器后，执行**docker ps**命令获取容器列表及其信息。

图 3-2 获取容器信息

```
root@huaweicloud:~# docker ps
CONTAINER ID   IMAGE                                COMMAND                  CREATED        STATUS        PORTS
7940e7584b7    287831c06d5d                        "/bin/sh -c /root/sa..." 43 seconds ago   Up 43 seconds   0.0.0.0
813d0ff754a0    k8s_deploy-4856885c-dmwf_431144c4209e47a99717286e676715f_c3149c28-3d3a-45a1-842f-b35c77b78788_0    "/pause"              44 seconds ago   Up 43 seconds   0.0.0.0
b37242f325d4    d8b2c0d05f9e                        "/bin/sh -c /root/sa..." 20 hours ago     Up 20 hours     0.0.0.0
9365216a7f4f    k8s_renyuan-jiankong-buysashanchu_renyuan-jiankong-buysashanchu-85648857-k4bvg_431144c4209e47a99717286e676715f_c3149c28-3d3a-45a1-842f-b35c77b78788_0    "/pause"              20 hours ago     Up 20 hours     0.0.0.0
30059-8880/tcp    k8s_POD_renyuan-jiankong-buysashanchu-85648857-k4bvg_431144c4209e47a99717286e676715f_c3149c28-3d3a-45a1-842f-b35c77b78788_0    "/bin/sh -c /root/sa..." 20 hours ago     Up 20 hours     0.0.0.0
35209543980      k8s_ch-test-7fb9f684-2d19_431144c4209e47a99717286e676715f_bfd1b42-440a-4416-bf00-7931e93a3df_0    "/pause"              3 days ago       Up 3 days       0.0.0.0
830b253486e      k8s_sa-fb-1.e10102.com/huawei-ief-internal-app/pause_arm64    "/pause"              3 days ago       Up 3 days       0.0.0.0
32211-8880/tcp    k8s_POD_ch-test-7fb9f684-2d19_431144c4209e47a99717286e676715f_bfd1b42-440a-4416-bf00-7931e93a3df_0    "/pause"              3 days ago       Up 3 days       0.0.0.0
f0343c3c5da      k8s_sa-fb-1.e10102.com/huawei-ief-internal-app/pause_arm64    "/pause"              2 weeks ago      Up 2 weeks      0.0.0.0
77f38dc40f2      k8s_sa-fb-1.e10102.com/huawei-ief-internal-app/pause_arm64    "/pause"              2 weeks ago      Up 2 weeks      0.0.0.0
77f38dc40f2      k8s_sa-fb-1.e10102.com/huawei-ief-internal-app/pause_arm64    "/pause"              2 weeks ago      Up 2 weeks      0.0.0.0
378431a567f      k8s_sa-fb-1.e10102.com/huawei-ief-internal-app/pause_arm64    "/pause"              2 weeks ago      Up 2 weeks      0.0.0.0
67373c8967b      k8s_sa-fb-1.e10102.com/huawei-ief-internal-app/pause_arm64    "/pause"              2 weeks ago      Up 2 weeks      0.0.0.0
50e17bc57c5d      k8s_sa-fb-1.e10102.com/huawei-ief-internal-app/pause_arm64    "/pause"              2 weeks ago      Up 2 weeks      0.0.0.0
root@huaweicloud:~#
```

2. 按创建部署任务时填写的名称在容器信息中查找，找到与名称对应的CONTAINER ID。
3. 执行**docker logs -f {CONTAINER ID}**命令查看容器日志。

在容器日志中可查看算法执行过程，搜索“result”可获取推理结果，推理结果为目标帧对应结果。

图 3-3 容器日志

```
2025-12-09 15:35:24,993 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:([0.942096014022827, 'BlowingCandles']) time stamp: 2025-12-09 15:35:24->2025-12-09 15:35:24, cost: 27.16 ms
2025-12-09 15:35:24,995 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.942096014022827, 'BlowingCandles')], '2025-12-09 15:35:24->2025-12-09 15:35:24']}
2025-12-09 15:35:25,134 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:25,334 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:25,534 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:25,793 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:([0.8184486161388289, 'BlowingCandles']) time stamp: 2025-12-09 15:35:24->2025-12-09 15:35:25, cost: 31.63 ms
2025-12-09 15:35:25,795 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.8184486161388289, 'BlowingCandles')], '2025-12-09 15:35:24->2025-12-09 15:35:25']}
2025-12-09 15:35:25,935 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:26,135 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:26,394 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:([0.7824528839558411, 'BlowingCandles']) time stamp: 2025-12-09 15:35:25->2025-12-09 15:35:26, cost: 26.26 ms
2025-12-09 15:35:26,396 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.7824528839558411, 'BlowingCandles')], '2025-12-09 15:35:25->2025-12-09 15:35:26']}
2025-12-09 15:35:26,535 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:26,736 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:26,990 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:([0.9581598843441772, 'BlowingCandles']) time stamp: 2025-12-09 15:35:26->2025-12-09 15:35:27, cost: 26.12 ms
2025-12-09 15:35:26,992 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.9581598843441772, 'BlowingCandles')], '2025-12-09 15:35:26->2025-12-09 15:35:27')}
2025-12-09 15:35:27,136 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:27,336 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:27,536 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:27,792 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:([0.96046382188797, 'BlowingCandles']) time stamp: 2025-12-09 15:35:26->2025-12-09 15:35:27, cost: 25.92 ms
2025-12-09 15:35:27,795 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.96046382188797, 'BlowingCandles')], '2025-12-09 15:35:26->2025-12-09 15:35:27')}
2025-12-09 15:35:27,937 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:28,137 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:28,399 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:([0.5536914467811584, 'BlowingCandles']) time stamp: 2025-12-09 15:35:27->2025-12-09 15:35:28, cost: 28.62 ms
2025-12-09 15:35:28,401 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.5536914467811584, 'BlowingCandles')], '2025-12-09 15:35:27->2025-12-09 15:35:28')}
2025-12-09 15:35:28,537 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:28,738 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:28,938 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:29,195 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:([0.44586317377898454, 'CliffDiving']) time stamp: 2025-12-09 15:35:28->2025-12-09 15:35:29, cost: 24.14 ms
2025-12-09 15:35:29,197 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.44586317377898454, 'CliffDiving')], '2025-12-09 15:35:28->2025-12-09 15:35:29')}
2025-12-09 15:35:29,338 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:29,538 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:29,798 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:([0.3263933862553406, 'CliffDiving']) time stamp: 2025-12-09 15:35:28->2025-12-09 15:35:29, cost: 26.19 ms
2025-12-09 15:35:29,800 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.3263933862553406, 'CliffDiving')], '2025-12-09 15:35:28->2025-12-09 15:35:29')}
2025-12-09 15:35:29,939 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:30,139 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
```

3.3.7 Pangu-CV-目标跟踪-V1

功能介绍

基于目标跟踪工作流，实现对物体的位置进行检测以及跟踪。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-82 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为 “application/json”

表 3-83 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为 “application/json”

表 3-84 请求 Body 参数

参数	是否必选	参数类型	说明
images	是	String	参数解释： 图片base64编码。 约束限制： 图片限制大小为2K。默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

响应参数

表 3-85 响应 Body

参数	参数类型	说明
img_res	List	参数解释： 目标跟踪结果，请求成功有此字段。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 训练数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-86 img_res 中各项结构

参数	参数类型	描述
label	String	参数解释： 预测类别。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
score	Float	参数解释： 置信度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
box	Dict	参数解释： 检测到的目标主体信息，格式为 {"x":x1,"y":y1,"width":w,"height":h,"angle":r}。 • x：检测到的目标主体区域的左上角x坐标。 • y：检测到的目标主体区域的左上角y坐标。 • width：检测到的目标主体区域的宽度。 • height：检测到的目标主体区域的高度。 • angle：默认为0，检测区域角度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
track_id	Dict	参数解释： 跟踪序列号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA....."
}
```

响应示例

```
{
  "dataset_id": "12345",
  "img_res": [
    {
      "label": "people",
      "score": 0.96,
      "track_id": 1,
      "box": {
        "x": 481.37,
        "y": 239.53,
        "width": 71.13,
        "height": 220.9,
        "angle": 0
      }
    }
  ]
}
```

- 1. 边缘节点即用户的边缘服务器，远程登录到该服务器后，执行**docker ps**命令获取容器列表及其信息。
- 2. 记录部署任务名称，进入ModelArts服务的“模型部署 > 边缘服务”页面。按创建部署任务时生成的任务ID在容器信息中查找，找到与名称对应的CONTAINER ID。

图 3-4 记录部署任务名称



图 3-5 获取任务 ID

名称ID 号	状态	请求模式	部署方式	创建时间 号	更新时间 号	创建 by LMS	SERVICE_NAME	V1-030702	ASSET_TYPE	Predict
lms-svc-cb5985eb-2cca-46e0-91a3-b01b0c9...	运行中	同步请求	ModelArts边缘资...	2025/03/07 15:03:59 GM...	2025/03/07 15:04:00 GM...	Create by LMS, SE...				
lms-svc-e5ca783a6-1741318478280	停止	同步请求	ModelArts边缘资...	2025/03/07 11:33:59 GM...	2025/03/07 15:01:04 GM...	Create by LMS, SERVIC...				
lms-svc-00316ad2-1741317158645	运行中	同步请求	ModelArts边缘资...	2025/03/07 11:11:59 GM...	2025/03/07 14:48:57 GM...	Create by LMS, SERVIC...				

图 3-6 获取容器信息

```
Authorized users only. All activities may be monitored and reported.
Last login: Thu Mar 6 16:35:25 2025 from 177.200.40.37
(base) [root@ecs-edge-worker-0002 ~]# docker ps | grep lms-svc-c01d922c-1741242677213-755b57bb8d-xx2r
7030302b9cbe 7c1499194550 /bin/sh -c /home/Hw... 6 hours ago Up 6 hours k8s_lms-mod-c01d922c-1741242560060_lms-
k22r-billens_7a627cac-7972-4393-90cf-9bdda2501d8e_4 rancher/mirrored-pause:3.5 7 hours ago Up 7 hours k8s_pod_lms-svc-c01d922c-1741242677213-
4d50415c1cf1 rancher/mirrored-pause:3.5 7/pause"
#993-90cf-9bdda2501d8e_0
(base) [root@ecs-edge-worker-0002 ~]#
```

3. 执行 `docker logs -f {CONTAINER ID}` 命令查看容器日志。
- 在容器日志中可查看算法执行过程，搜索“result”可获取推理结果。推理结果中是否为异常及对应帧的位置信息。

图 3-7 获取推理结果

```
2025-03-06 11:42:36,524 INFO [Process:NpVideoDecoderProcess-3-10731] [Thread:MainThread-281473530884160] process.py_bootstrap:315 video decode and put frame success: [url]rtsp://8.28.4.114:8554/Live, [index]20660
2025-03-06 11:42:36,613 INFO [Process:MainProcess-17] [Thread:Thread-3-281473004630784] threading.py_bootstrap_innner:980 inference model success, cost:25.97 ms
2025-03-06 11:42:36,620 INFO [Process:MainProcess-17] [Thread:Thread-3-281473004630784] threading.py_bootstrap_innner:980 [addr]rtsp://8.28.4.114:8554/Live, frame_idx:20660 infer result:[[0, 0, 0, 1.275390625, 'abnormal']]
2025-03-06 11:42:36,620 INFO [Process:MainProcess-17] [Thread:Thread-3-281473004630784] threading.py_bootstrap_innner:980 ['is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_bboxes': [[0, 0, 0, 1.275390625, 'abno
rmal']]]
2025-03-06 11:42:36,720 INFO [Process:NpVideoDecoderProcess-3-10731] [Thread:MainThread-281473530884160] process.py_bootstrap:315 video decode and put frame success: [url]rtsp://8.28.4.114:8554/Live, [index]20665
2025-03-06 11:42:36,785 INFO [Process:MainProcess-17] [Thread:Thread-3-281473004630784] threading.py_bootstrap_innner:980 inference model success, cost:25.48 ms
2025-03-06 11:42:36,796 INFO [Process:MainProcess-17] [Thread:Thread-3-281473004630784] threading.py_bootstrap_innner:980 [addr]rtsp://8.28.4.114:8554/Live, frame_idx:20665 infer result:[[0, 0, 0, 1.2624953125, 'abnormal']]
2025-03-06 11:42:36,796 INFO [Process:MainProcess-17] [Thread:Thread-3-281473004630784] threading.py_bootstrap_innner:980 ['is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_bboxes': [[0, 0, 0, 1.2624953125, 'abn
ormal']]]
2025-03-06 11:42:36,893 INFO [Process:NpVideoDecoderProcess-3-10731] [Thread:MainThread-281473530884160] process.py_bootstrap:315 video decode and put frame success: [url]rtsp://8.28.4.114:8554/Live, [index]20670
2025-03-06 11:42:37,000 INFO [Process:MainProcess-17] [Thread:Thread-3-281473004630784] threading.py_bootstrap_innner:980 inference model success, cost:25.92 ms
2025-03-06 11:42:37,001 INFO [Process:MainProcess-17] [Thread:Thread-3-281473004630784] threading.py_bootstrap_innner:980 [addr]rtsp://8.28.4.114:8554/Live, frame_idx:20670 infer result:[[0, 0, 0, 1.2783203125, 'abnormal']]
2025-03-06 11:42:37,001 INFO [Process:MainProcess-17] [Thread:Thread-3-281473004630784] threading.py_bootstrap_innner:980 ['is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_bboxes': [[0, 0, 0, 1.2783203125, 'abn
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.8 Pangu-CV-姿态估计-V1

功能介绍

基于盘古大模型的姿态估计 workflow，实现对人体关键点检测和姿态的估计。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-87 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-88 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-89 请求 Body 参数

参数	是否必选	参数类型	说明
images	是	String	参数解释： 图片base64编码。 约束限制： 图片限制大小为2K。默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

响应参数

表 3-90 响应 Body

参数	参数类型	说明
result	List	参数解释： 姿态估计结果，为一个list，其中每项代表图像中一个人的姿态估计结果，参数说明请见表3-91中result各项结构。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	说明
dataset_id	String	参数解释： 数据ID信息，用于关联边学边用场景。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-91 result 中各项结构

参数	参数类型	说明
category_id	Int	参数解释： 固定为1，与训练时定义的类别顺序相对应，默认表示person。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
keypoints	List	参数解释： 包含51个整数，按顺序每3个数为一组（共计17组，表示17个关键点），分别表示各关键点的横坐标、纵坐标、可见性。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA....."
}
```

响应示例

```
{
  "dataset_id": "XXXXXXXXXXXXXXXXXXXX",
  "result": [
    {
      "category_id": 1,
      "keypoints": [
        0,
        0,
        0,
        0,
        0,
        0,
        0,
        0,
        0,
        0,
        296,
        90,
        2,
        0,
        0,
        0,
        297,
        114,
        2,
        327,
        112,
        2,
        278,
        154,
        2,
        0,
        0,
        0,
        268,
        171,
        2,
        0,
        0,
        0,
        296,
        181,
        2,
        329,
        180,
        2,
        299,
        217,
        2,
        329,
        214,
        2,
        304,
        259,
        2,
        334,
        245,
        2
      ]
    }
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.9 Pangu-CV-事件检测-V1


事件检测不支持通过API进行调用，支持视频推理。视频推理调用时，创建部署任务时，在环境变量参数中添加如下环境变量即可调用事件检测模型推理对应视频流。

表 3-92 事件检测环境变量

变量名	类型	取值
ADDRS	字符串	rtsp视频流地址。

模型支持云上和边缘部署，模型推理结果需在容器日志中查询，云上部署时可在ModelArts在线服务页面查看日志，如下图所示。

图 3-8 获取日志



边缘部署模型时，需要登录到边缘节点中查看推理结果，操作方式如下。

1. 边缘节点即用户的边缘服务器，远程登录到该服务器后，执行**docker ps**命令获取容器列表及其信息。
2. 记录部署任务名称，进入ModelArts服务的“模型部署 > 边缘服务”页面。按创建部署任务时生成的任务ID在容器信息中查找，找到与名称对应的CONTAINER ID。

图 3-9 记录部署任务名称



图 3-10 获取任务 ID

名称ID	状态	请求模式	部署方式	创建时间	更新时间	操作
☒ lms-svc- c6b596eb-2cca-46ea-91a3-0d1b0dc9...	进行中	同步请求	ModelArts边缘授...	2025/03/07 15:03:59 GM...	2025/03/07 15:04:00 GM...	Create by LMS, SERVICE_NAME: V1-030702, ASSET_TYPE: Predict 修改 启动 停止
☐ lms-svc-eca763a6-174131047d200 2c6543813-692d-4d1b-b017-a189775...	停止	同步请求	ModelArts边缘授...	2025/03/07 11:33:59 GM...	2025/03/07 15:01:04 GM...	Create by LMS, SERVICE... 修改 启动 停止
☐ lms-svc-00316ad2-1741317158645 2c6543813-692d-4d1b-b017-a189775...	进行中	同步请求	ModelArts边缘授...	2025/03/07 11:11:59 GM...	2025/03/07 14:48:57 GM...	Create by LMS, SERVICE... 修改 启动 停止

图 3-11 获取容器信息

```

Authorized users only. All activities may be monitored and reported.

Last login: Thu Mar 6 16:35:25 2025 from 177.200.40.37
(base) [root@ecs-edge-worker-0002 ~]# docker ps | grep k8s-svc-c01d922c-1741242677213-755b57b8bd-sx2r
700a02b2dc9e       7c4499106550     /bin/sh -c /home/mw-        6 hours ago      Up 6 hours
sx2r_hilens_7a27cac-7972-4393-90cf-9bdda2501d8e_4     /bin/sh -c /home/mw-        6 hours ago      Up 6 hours
4d50415c1c1f1     rancher/mirrored-pause:3.5   /pause*                    7 hours ago      Up 7 hours
4393-90cf-9bdda2501d8e_0                                /pause*                    7 hours ago      Up 7 hours
(base) [root@ecs-edge-worker-0002 ~]#

```

3. 执行 `docker logs -f {CONTAINER ID}` 命令查看容器日志。

在容器日志中可查看算法执行过程，搜索“result”可获取推理结果。推理结果中事件的起止秒数以二维数组表示，包含事件片段的开始时间和结束时间。

图 3-12 容器日志

```

2024-08-07 16:39:07.741 INFO [Process/MainProcess-10] [Thread/MainThread-281473548824640] <FrozenImportlib_bootstrap>.call_with_frames_removed:228 start transform air model to om model...
2024-08-07 16:39:07.741 INFO [Process/MainProcess-10] [Thread/MainThread-281473548824640] <FrozenImportlib_bootstrap>.call_with_frames_removed:228 start transform network air...
2024-08-07 16:39:07.741 INFO [Process/MainProcess-10] [Thread/MainThread-281473548824640] <FrozenImportlib_bootstrap>.call_with_frames_removed:228 target device is cuda:0
2024-08-07 16:39:07.745 INFO [Process/MainProcess-10] [Thread/MainThread-281473548824640] <FrozenImportlib_bootstrap>.call_with_frames_removed:228 version ASend10P3
2024-08-07 16:42:28.676 INFO [Process/MainProcess-10] [Thread/MainThread-281473548824640] <FrozenImportlib_bootstrap>.call_with_frames_removed:228 transform network Air is success.
2024-08-07 16:42:28.676 INFO [Process/MainProcess-10] [Thread/MainThread-281473548824640] <FrozenImportlib_bootstrap>.call_with_frames_removed:228 transform model Air is success.
2024-08-07 16:42:30.313 INFO [Process/MainProcess-10] [Thread/MainThread-281470359991316] threading.pool.bootstrap_inner:980 monitor values: {'metrics': {'dimensions': {'name': 'APPLICATION_ID', 'type': '04651516e-b974-4d85-8f16-8ee6c5bee76e'}, 'name': 'APPLICATION_ID', 'type': '04651516e-b974-4d85-8f16-8ee6c5bee76e'}}, {'metrics': {'dimensions': {'name': 'APPLICATION_ID', 'type': '04651516e-b974-4d85-8f16-8ee6c5bee76e'}, 'name': 'APPLICATION_ID', 'type': '04651516e-b974-4d85-8f16-8ee6c5bee76e'}}], 'unit': 'records'; 'metric_name': '推理吞吐量'; 'type': 'int'; 'value': 0}, {'metrics': {'metric_name': '推理内存使用率', 'type': 'int'; 'value': 0}, {'unit': 'records'; 'metric_name': '推理内存使用率', 'type': 'int'; 'value': 0}, {'metrics': {'metric_name': '推理内存使用率', 'type': 'int'; 'value': 0}, {'unit': 'records'; 'metric_name': '推理内存使用率', 'type': 'int'; 'value': 0}}, {'metrics': {'metric_name': '推理平均延迟', 'type': 'int'; 'value': 0}, {'unit': 'records'; 'metric_name': '推理平均延迟', 'type': 'int'; 'value': 0}, {'metrics': {'metric_name': '推理平均延迟', 'type': 'int'; 'value': 0}, {'unit': 'records'; 'metric_name': '推理平均延迟', 'type': 'int'; 'value': 0}}], 'unit': 'records'; 'metric_name': '推理平均延迟', 'type': 'int'; 'value': 0}, {'unit': 'records'; 'metric_name': '推理平均延迟', 'type': 'int'; 'value': 0}], 'unit': 'records'; 'metric_name': '推理平均延迟', 'type': 'int'; 'value': 0}, {'unit': 'records'; 'metric_name': '推理平均延迟', 'type': 'int'; 'value': 0}]]
2024-08-07 16:42:30.313 INFO [Process/MainProcess-10] [Thread/MainThread-281470359991316] threading.pool.bootstrap_inner:980 send request to report/metrics/user?project=Jingdong
{"error_code": "SVCSGET_IPF_00020310", "data": {"location": "ForContainer", "requestId": "POST /api/v6/s53181127424256e035977f6c1b15/api/report/metrics/user?project=Jingdong&token=77637677cb15151"}
2024-08-07 16:42:30.313 INFO [Process/MainProcess-10] [Thread/MainThread-281470359991316] threading.pool.bootstrap_inner:980 video add request http://8.28.3.200:8554/video
2024-08-07 16:42:30.388 INFO [Process/MainProcess-10] [Thread-3-281471728951360] threading.pool.bootstrap_inner:980 add no frame request http://8.28.3.200:8554/live
2024-08-07 16:42:30.388 INFO [Process/MainProcess-10] [Thread-3-281471728951360] threading.pool.bootstrap_inner:980 add no frame request http://8.28.3.200:8554/live

```

图 3-13 推理结果

```
2024-08-07 16:46:50.322 INFO [Process:MainProcess-18] [Thread:Thread-3-281471728951360] threading.py_bootstrap_inner580 template post process
2024-08-07 16:46:50.347 INFO [Process:MainProcess-18] [Thread:Thread-3-281471728951360] threading.py_bootstrap_inner580 template post process end
2024-08-07 16:46:50.353 INFO [Process:MainProcess-18] [Thread:Thread-3-281471728951360] threading.py_bootstrap_inner580 processed result: {'is_alarm': True, 'alarm_type': '', 'alarm_data': '', 'alarm_segments': {'segments': array([[217.40714,
228.4002 ],
[200.76743, 211.14238 ],
[175.70296, 183.45459 ],
[356.27673, 388.64355 ],
[464.66616, 500.20865 ],
[126.33304, 179.5506 ],
[230.38799, 237.89008 ],
[186.65617, 189.90894 ],
[17.278095, 17.86429 ],
[51.282703, 56.891785 ],
[90.39169, 107.535225 ],
[247.85465, 258.459 ],
[46.05313, 46.997375 ],
[21.904459, 28.31085 ],
[109.07413, 112.312355 ],
[831.13028, 347.7136 ]])}}
```

3.3.10 Pangu-CV-目标跟踪-V2

功能介绍

基于目标跟踪 workflows，实现对物体的位置进行检测以及跟踪。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-93 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-94 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-95 请求参数

参数	是否必选	参数类型	说明
images	是	String	参数解释： 图片base64编码。 约束限制： 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

响应参数

表 3-96 预测结果

参数	参数类型	描述
img_res	Array of Object	参数解释： 预测结果，为一个list，其中每项代表图像中一个检测框的位置，类别，置信度，跟踪序列号等信息。具体字段如 表 目标跟踪预测结果详情 所示。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
dataset_id	String	参数解释： 数据ID信息，用于关联边学边用场景。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-97 预测结果详情

参数	参数类型	描述
label	String	参数解释： 被预测物体的类别。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
score	Float	参数解释： 置信度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
track_id	Integer	参数解释： 跟踪序列号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
box	Object	参数解释： 预测框的位置信息。具体字段如 表 预测框详情 所示。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-98 预测框详情

参数	参数类型	描述
x	Float	参数解释： 检测框的左上角x坐标。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
y	Float	参数解释： 检测框的左上角y坐标。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
width	Float	参数解释： 检测框的宽度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
height	Float	参数解释： 检测框的高度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
angle	Integer	参数解释： 检测区域角度，默认为0。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0

请求示例

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA....."
}
```

响应示例

```
{
  "dataset_id": "XXXXXXXXXXXXXXXXXXXX",
  "img_res": [
    {
      "label": "people",
      "score": 0.96,
      "track_id": 1,
      "box": {
        "x": 481.37,
        "y": 239.53,
        "width": 71.13,
        "height": 220.9,
        "angle": 0
      }
    },
    {
      "label": "people",
      "score": 0.93,
      "track_id": 2,
      "box": {
        "x": 691.67,
        "y": 302.4,
        "width": 92.57,
        "height": 267.32,
        "angle": 0
      }
    }
  ]
}
```

```
]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.11 Pangu-CV-图像分类-V2

功能介绍

根据在图像信息中所反映的不同特征，对图像进行定量分析，把图像划归为若干个类别中的某一种。适用于动植物分类、车辆类型分类、车牌分类、废钢定级、零部件分类等任务。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-99 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-100 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-101 请求 Body 参数

参数	是否必选	参数类型	描述
images	是	String/ List[String]	参数解释： 被检测图片的base64编码。 约束限制： • 建议整个请求体大小不超过4M。 • 建议使用JPG、PNG、JPEG、BMP格式的图片。 • 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 • 单张图片请求时，参数类型为String，为图片的base64编码；批量请求时，参数类型为List[String]，以列表形式存放各图片的base64编码，单次请求不超过24张。 • 若使用批量推理功能，要求部署时配置环境变量 BATCH_INFER为true，默认为单图推理模式。 取值范围： 不涉及 默认取值： 不涉及

表 3-102 请求 Body 高级参数

参数	是否必选	参数类型	描述
mode	否	String	参数解释： 取值为"single"或者"multiple"，分别表示单标签分类和多标签分类模式，二者取一，默认设置为训练得到的模型对应的模式。 约束限制： 不涉及 取值范围： • single：单标签分类 • multiple：多标签分类 默认取值： 不涉及
threshold	否	dict	参数解释： 多标签分类时，各标签对应的预测得分阈值，预测得分小于阈值的预测结果将会被过滤。 约束限制： 仅在多标签分类模式下有效。 取值范围： 不涉及 默认取值： 不涉及
top	否	int	参数解释： 单标签分类时，用于规定输出 top N的预测得分对应的预测结果。 约束限制： 仅在单标签分类模式下有效。 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码： 200

响应成功返回的结构体是一个Dict，由本次请求的多张输入图像的预测结果组成，图像与图像之间通过编号（键）区分。

表 3-103 单/多标签分类响应成功 Body 参数

参数	参数类型	描述
键	String	参数解释： 输入图像的顺序编号，从"0"开始，最大不超过"23"。 约束限制： 不涉及 取值范围： 0-23 默认取值： 不涉及
值	List[Dict]	参数解释： 当前编号的图像对应的预测结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 训练数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

其中，每张图像的预测结果参数类型为List[Dict]，表示预测得到的一个或多个类别，每个Dict的参数内容请参考[表3-104](#)。

表 3-104 单张图像的单个类别预测结果参数

参数	参数类型	描述
label	String	参数解释： 预测的类别，与训练数据中定义类别相同。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
score	String	参数解释： 预测的置信度结果，输出每个标签对应的预测得分，得分区间为0至1。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及

状态码： 400

表 3-105 响应失败 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

- 对单张图进行分类

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA.....",
}
```
- 对多图片进行分类（单次请求批次上限为24张图）

```
{
  "images": ["/9j/4Vr2RXhpZgAASUkqAAgAAA.....", "/9j/4RlrRXhpZgAATU....."]
}
```

 注意

默认情况下仅开启单张图推理功能；若需使用批量推理功能（即单次请求对多张图片进行分类），请在部署时将环境变量BATCH_INFER设置为true。

- 带高级参数的单标签分类

```
{
  "images": ["/9j/4Vr2RXhpZgAASUkqAAgAAA.....", "/9j/4RlrRXhpZgAATU....."],
  "top": 3
}
```

- 带高级参数的多标签分类

```
{
  "images": ["/9j/4Vr2RXhpZgAASUkqAAgAAA.....", "/9j/4RlrRXhpZgAATU....."],
  "threshold": {
    "bird": 0.33,
    "blackbird": 0.44
  }
}
```

响应示例

状态码： 200

成功响应示例

响应返回一个字典，键为本次请求的输入图像的编号，对输入的图像按顺序从0开始编号；值为一个列表，列表里为该图像的预测结果，每张图像可能存在多个预测结果（例如多标签分类模式）。

```
{
  "0": [
    {
      "label": "bird",
      "score": "0.95511043"
    },
    {
      "label": "blackbird",
      "score": "0.75241840"
    }
  ],
  "1": [
    {
      "label": "bird",
      "score": "0.36211243"
    }
  ],
  "dataset_id": "1341002014632579072"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.12 Pangu-CV-开集分类-V3

功能介绍

盘古CV开集分类大模型，根据在图像信息中所反映的不同特征，把不同类别识别到的图像处理方法，利用盘古CV技术对图像进行定量分析，为图像分配若干个类别。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-106 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-107 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-108 请求 Body 参数

参数	是否必选	参数类型	描述
images	是	String	参数解释： 被检测图片的base64编码。 约束限制： • 建议整个请求体大小不超过4M。 • 建议使用JPG、PNG、JPEG、BMP格式的图片。 • 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 • 单张图片请求时，参数类型为String，为图片的base64编码 取值范围： 不涉及 默认取值： 不涉及

表 3-109 请求 Body 高级参数

参数	是否必选	参数类型	描述
threshold	否	String	参数解释： 多标签分类时，各标签对应的预测得分阈值，预测得分小于阈值的预测结果将会被过滤。 约束限制： 仅在多标签分类模式下有效。 取值范围： 0-1 默认取值： 0.8

参数	是否必选	参数类型	描述
image_size	否	String	参数解释： 预测图片分辨率仅支持224和384两种规格，其他分辨率的图片默认会被缩放至224或者384。 约束限制： 不涉及 取值范围： 224和384 默认取值： 384

响应参数

状态码： 200

响应成功返回的结构体是一个Dict，由本次请求的多张输入图像的预测结果组成，图像与图像之间通过编号（键）区分。

表 3-110 单/多标签分类响应成功 Body 参数

参数	参数类型	描述
键	String	参数解释： 输入图像的顺序编号，从"0"开始，最大不超过"23"。 约束限制： 不涉及 取值范围： 0-23 默认取值： 不涉及
值	List[Dict]	参数解释： 当前编号的图像对应的预测结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
dataset_id	String	参数解释： 训练数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

其中，每张图像的预测结果参数类型为List[Dict]，表示预测得到的一个或多个类别，每个Dict的参数内容请参考[表3-111](#)。

表 3-111 单张图像的单个类别预测结果参数

参数	参数类型	描述
label	String	参数解释： 预测的类别，与训练数据中定义类别相同。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
score	String	参数解释： 预测的置信度结果，输出每个标签对应的预测得分，得分区间为0至1。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及

状态码： 400

表 3-112 响应失败 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

- 对单张图进行分类

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA.....",
}
```
- 带高级参数的单标签分类

```
{
  "images": "/9j/4AAQSkZJRgABAQEASABIA==",
  "threshold": "0.5",
  "image_size": "224"
}
```

响应示例

状态码： 200

成功响应示例

响应返回一个字典，其中result部分为预测结果，包含label和score两部分，label为类别名称，score为分数。

```
{
  "dataset_id": "123456789",
  "result": [
    {
      "label": "label1",
      "score": 0.5818918943405151
    },
    {
      "label": "label2",
      "score": 0.5477437973022461
    },
    {
      "label": "label3",
      "score": 0.5344057083129883
    }
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.13 Pangu-CV-物体检测-S-V2

功能介绍

找出图像中所有感兴趣的目标，确定它们的位置和类别。物体检测-S模型特点是小参数量，适合在资源有限的环境中使用，提供较快的检测速度和合理的精度。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-113 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-114 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-115 请求 Body 参数

参数	是否必选	参数类型	描述
images	是	String	参数解释： 被检测图片的base64编码。 约束限制： - 建议整个请求体大小不超过4M。 - 建议使用JPG、PNG、JPEG、BMP格式的图片。 - 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
threshold	否	Float	参数解释： 检测框置信度阈值。 约束限制： 不涉及 取值范围： 最小0.0，最大1.0 默认取值： 0.25

响应参数

状态码： 200

表 3-116 响应 Body

参数	参数类型	说明
result	List	参数解释： 物体检测的识别结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 训练数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-117 result 中各项结构

参数	参数类型	描述
Score	Float	参数解释： 置信度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
label	String	参数解释： 检测类别。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Box	Dict	参数解释： 检测到的目标主体信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-118 Box

参数	参数类型	描述
X	Int	参数解释： 矩形框左上角横坐标。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
Y	Int	参数解释： 矩形框左上角纵坐标。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
width	Int	参数解释： 矩形框宽度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Height	Int	参数解释： 矩形框高度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Angle	Int	参数解释： 检测到的目标主体区域的角度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-119 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

找出图像中所有感兴趣的目标，并确定其位置和类别

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA.....",
  "threshold": 0.3
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "dataset_id": "12345xxxx",
  "result": [
    {
      "Box": {
        "Angle": 0,
        "Height": 60,
        "Width": 106,
        "X": 852,
        "Y": 182
      },
      "Score": 0.88427734375,
      "label": "car"
    },
    {
      "Box": {
        "Angle": 0,
        "Height": 114,
        "Width": 55,
        "X": 800,
        "Y": 170
      },
      "Score": 0.70556640625,
      "label": "person"
    }
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.14 Pangu-CV-物体检测-S-V3

功能介绍

本模型为轻量化物体检测模型，基于改进后的transformer架构，通过蒸馏、高分辨预训练等技术面向高精度、低时延、小目标进行三重优化，为业界性价比最优检测模型。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-120 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-121 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-122 请求 Body 参数

参数	是否必选	参数类型	描述
images	是	String	参数解释： 被检测图片的base64编码。 约束限制： • 建议整个请求体大小不超过100M。 • 建议使用JPG、PNG、JPEG、BMP、TIF、TIFF格式的图片。 • 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及
threshold	否	Float	参数解释： 检测框置信度阈值。 使能逻辑： 1）优先看是否存在ENABLE_ALL_OUTPUTS 参数为true，如存在则优先输出所有结果，不使用输入threshold和默认最优阈值； 2）如果传入threshold，且ENABLE_ALL_OUTPUTS=false，则优先使用传入的threshold进行结果筛选； 3）如果不传入threshold，或threshold=-1，且ENABLE_ALL_OUTPUTS=false，则使用默认最优阈值进行推理。 约束限制： 不涉及 取值范围： 最小0.0，最大1.0 默认取值： -1（算法内部默认值，代表使用算法内部默认最优置信度阈值）

响应参数

状态码： 200

表 3-123 响应 Body

参数	参数类型	说明
result	List	参数解释： 物体检测的识别结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 训练数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-124 result 中各项结构

参数	参数类型	说明
RegisterMatrix	List	参数解释： 图片特征矩阵。 参数解释： 置信度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 默认为[[1, 0, 0], [0, 1, 0], [0, 0, 1]]

参数	参数类型	说明
Label	String	参数解释: 预测类别，与训练数据中的类别名称相关。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
Score	Float	参数解释: 置信度。 约束限制: 不涉及 取值范围: 0~1 默认取值: 不涉及
Box	Dict	参数解释: 目标主体信息，格式为 {"x":x1,"y":y1,"width":w,"height":h,"angle":r}。 • x: 检测到的目标主体区域的左上角x坐标。 • y: 检测到的目标主体区域的左上角y坐标。 • width: 检测到的目标主体区域的宽度。 • height: 检测到的目标主体区域的高度。 • angle: 默认为0，检测区域角度。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

状态码： 400

表 3-125 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。

参数	参数类型	描述
error_msg	String	错误信息。

请求示例

调用方式总结为如下三种：

1) form-data格式调用

```
{
  "file": "xxx(base64 encode image data)"
}
```

2) base64 json调用

```
{
  "Files": [
    [{"ImageData": "xxx(base64 encode image data)"}]
  ]
}
```

3) base64 json调用 (threshold非必须)

```
{
  "images": "xxx(base64 encode image data)",
  "threshold": "0.4"
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "dataset_id": "1234xxxx",
  "result": [
    {
      "RegisterMatrix": [
        [
          1,
          0,
          0
        ],
        [
          0,
          1,
          0
        ],
        [
          0,
          0,
          1
        ]
      ]
    },
    {
      "Box": {
        "Angle": 0,
        "Height": 60,
        "Width": 106,
        "X": 852,
        "Y": 182
      }
    }
  ]
}
```

```
    "Score": 0.88427734375,  
    "label": "car"  
  },  
  {  
    "Box": {  
      "Angle": 0,  
      "Height": 114,  
      "Width": 55,  
      "X": 800,  
      "Y": 170  
    },  
    "Score": 0.70556640625,  
    "label": "person"  
  }  
]
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.15 Pangu-CV-物体检测-N-V2

功能介绍

找出图像中所有感兴趣的目标，确定它们的位置和类别。物体检测-N模型特点是参数量适中，适合在资源有限的环境中使用，提供较快的检测速度和合理的精度。

URI

图片接口：POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-126 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-127 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-128 图片请求 Body 参数

参数	是否必选	参数类型	描述
images	是	String	参数解释： 被检测图片的base64编码。 约束限制： - 建议使用PNG、JPEG、BMP、JPG、WEBP格式的图片。 - 只支持单张图片输入，分辨率范围为1px-10000px，且长短边比例不能高于5。并且base64编码后的图片大小不超过10MB。 - 支持RGB三通道格式的图像。 取值范围： 不涉及 默认取值： 不涉及
nms_iou_thr	否	Float	参数解释： 极大值抑制阈值。 约束限制： 不涉及 取值范围： 0.0~1.0 默认取值： 0.65

参数	是否必选	参数类型	描述
agnostic_nms	否	Bool	参数解释： 是否进行类间nms，是填写true，不是填写false。 约束限制： 不涉及 取值范围： true：进行类间nms 默认取值： false

响应参数

状态码： 200

表 3-129 响应 Body 参数

参数	参数类型	描述
result	List	参数解释： 物体检测的识别结果。物体检测的基本目标是在输入的图像或视频中找到感兴趣的目标物体，并确定它们的位置和类别，所以识别结果包含物体的类别和物体的位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-130 result 中各项结构

参数	参数类型	描述
RegisterMatrix	List	参数解释: 默认为[[1, 0, 0], [0, 1, 0], [0, 0, 1]]，表示图片特征矩阵。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
Label	String	参数解释: 预测类别。物体检测中的预测类别是指模型对输入图像或视频中物体的分类结果。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
Score	Float	参数解释: 置信度。用于衡量模型对预测结果的准确性。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
Box	Dict	参数解释： 检测到的目标主体信息。 约束限制： 格式为{"x":x1,"y":y1,"width":w,"height":h, 'Angle':angle}。 • x：检测到的目标主体区域的左上角x坐标。 • y：检测到的目标主体区域的左上角y坐标。 • width：检测到的目标主体区域的宽度。 • height：检测到的目标主体区域的高度。 • angle：检测到的目标主体区域的角度。 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-131 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

- 基于图片的base64编码找出图像中所有感兴趣的目标，并确定其位置和类别

```
{
  "nms_iou_thr":0.45,
  "agnostic_nms":false,
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA....."
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "result": [
    {
      "RegisterMatrix": [
        [
          1,
          0,
          0
        ]
      ]
    }
  ]
}
```

```
    ],  
    [  
      0,  
      1,  
      0  
    ],  
    [  
      0,  
      0,  
      1  
    ]  
  ],  
  },  
  {  
    "Box": {  
      "Y": 0,  
      "Width": 100,  
      "Angle": 0,  
      "X": 0,  
      "Height": 100  
    },  
    "Score": 0.9,  
    "label": "person"  
  }  
]
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.16 Pangu-Mine-CV-物体检测-N-V2

功能介绍

找出图像中所有感兴趣的目标，确定它们的位置和类别。矿山大模型特点是参数量适中，适合在资源有限的环境中使用，提供较快的检测速度和合理的精度。

URI

图片接口：POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-132 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-133 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-134 图片请求 Body 参数

参数	是否必选	参数类型	描述
images	是	String	参数解释： 被检测图片的base64编码。 约束限制： - 建议使用PNG、JPEG、BMP、JPG、WEBP格式的图片。 - 只支持单张图片输入，分辨率范围为1px-10000px，且长短边比例不能高于5。并且base64编码后的图片大小不超过10MB。 - 支持RGB三通道格式的图像。 取值范围： 不涉及 默认取值： 不涉及
nms_iou_thr	否	Float	参数解释： 极大值抑制阈值。 约束限制： 不涉及 取值范围： 0.0~1.0 默认取值： 0.65

参数	是否必选	参数类型	描述
agnostic_nms	否	Bool	参数解释： 是否进行类间nms，是填写true，不是填写false。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false

响应参数

状态码： 200

表 3-135 响应 Body 参数

参数	参数类型	描述
result	List	参数解释： 物体检测的识别结果。物体检测的基本目标是在输入的图像或视频中找到感兴趣的目标物体，并确定它们的位置和类别，所以识别结果包含物体的类别和物体的位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-136 result 中各项结构

参数	参数类型	描述
RegisterMatrix	List	参数解释: 默认为[[1, 0, 0], [0, 1, 0], [0, 0, 1]]，表示图片特征矩阵。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
Label	String	参数解释: 预测类别。物体检测中的预测类别是指模型对输入图像或视频中物体的分类结果。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
Score	Float	参数解释: 置信度。用于衡量模型对预测结果的准确性。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
Box	Dict	参数解释： 检测到的目标主体信息。 约束限制： 格式为{"x":x1,"y":y1,"width":w,"height":h, 'Angle':angle}。 • x：检测到的目标主体区域的左上角x坐标。 • y：检测到的目标主体区域的左上角y坐标。 • width：检测到的目标主体区域的宽度。 • height：检测到的目标主体区域的高度。 • angle：检测到的目标主体区域的角度。 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-137 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

- 基于图片的base64编码找出图像中所有感兴趣的目标，并确定其位置和类别

```
{
  "nms_iou_thr":0.45,
  "agnostic_nms":false,
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA....."
}
```
- 基于视频流地址找出视频中所有感兴趣的目标，并确定其位置和类别

```
{
  "addrs": ["rtsp://8.28.4.113:8554/live"],
  "action": "add"
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "result": [
```

```
{
  "RegisterMatrix": [
    [
      1,
      0,
      0
    ],
    [
      0,
      1,
      0
    ],
    [
      0,
      0,
      1
    ]
  ],
  {
    "Box": {
      "Y": 0,
      "Width": 100,
      "Angle": 0,
      "X": 0,
      "Height": 100
    },
    "Score": 0.9,
    "label": "person"
  }
]
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.17 Pangu-CV-语义分割-V2

功能介绍

将数字图像细分为多个图像子区域，适用于车道分割、建筑分割、选煤厂筛面状态识别等任务。

URI

POST /v1/rs-server/predictions

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

注：已兼容语义分割V1的URL

请求参数

表 3-138 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-139 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-140 请求 Body 参数

参数	是否必选	参数类型	描述
img	是	String	参数解释： 被检测图片的base64编码。 约束限制： - 建议使用PNG、JPG格式的图片。 - 只支持单张图片输入，分辨率512px*512px，并且base64编码后的图片大小不超过10MB。 - 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及
return_base64_of_bytes	否	bool	参数解释： 指定本次请求是否返回字节流的base64编码。 约束限制： 不涉及 取值范围： 取值为true或false，默认为false。当设置为true时，将返回预测掩码的字节流的base64编码，推理速度更快。 默认取值： false

响应参数

状态码： 200

表 3-141 响应 Body 参数

参数	参数类型	描述
result	Array	参数解释： 预测结果。预测结果是一个二维数组，表示模型对输入图像的每个像素点进行语义分割后的预测结果。数组中的每一个元素都是一个整数，表示模型对该像素点的预测类别。 约束限制： 预测结果中每个像素的值表示类别的索引，需要调用类别接口获取类别列表并按照数组下标索引一一对应。 获取类别接口： URI: GET /v1/rs-server/classes 接口域名请参考获取在线部署的大模型推理API接口域名获取。 响应参数： classes 响应示例： <pre>{ "classes": ["classes1", "classes2", "classes3"] }</pre> 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-142 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。

参数	参数类型	描述
error_msg	String	错误信息。

请求示例

将数字图像细分为多个图像子区域

[illegible]

响应示例

状态码: 200

成功响应示例

```
{
  "result": [
    [
      0,
      ...
    ]
  ]
}
```

状态码

请参见**状态码**。

错误码

请参见**错误码**。

3.3.18 Pangu-CV-RS-语义分割-V2

功能介绍

将数字图像细分为多个图像子区域，适用于遥感影像分割任务。

URI

POST /v1/rs-server/predictions

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

注：已兼容语义分割V1的URL

请求参数

表 3-143 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-144 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-145 请求 Body 参数

参数	是否必选	参数类型	描述
img	是	String	参数解释： 被检测图片的base64编码。 约束限制： - 建议使用PNG、JPG格式的图片。 - 只支持单张图片输入，分辨率512px*512px，并且base64编码后的图片大小不超过10MB。 - 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及
return_base64_of_bytes	否	bool	参数解释： 指定本次请求是否返回字节流的base64编码。 约束限制： 不涉及 取值范围： 取值为true或false，默认为false。当设置为true时，将返回预测掩码的字节流的base64编码，推理速度更快。 默认取值： false

响应参数

状态码： 200

表 3-146 响应 Body 参数

参数	参数类型	描述
result	Array	参数解释： 预测结果。预测结果是一个二维数组，表示模型对输入图像的每个像素点进行语义分割后的预测结果。数组中的每一个元素都是一个整数，表示模型对该像素点的预测类别。 约束限制： 预测结果中每个像素的值表示类别的索引，需要调用类别接口获取类别列表并按照数组下标索引一一对应。 获取类别接口： URI: GET /v1/rs-server/classes 接口域名请参考获取在线部署的大模型推理API接口域名获取。 响应参数： classes 响应示例： <pre>{ "classes": ["classes1", "classes2", "classes3"] }</pre> 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-147 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。

请求参数

表 3-148 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-149 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-150 请求 Body 参数

参数	是否必选	参数类型	描述
img	是	String	参数解释： 被检测图片的base64编码。 约束限制： - 建议使用PNG、JPG格式的图片。 - 只支持单张图片输入，分辨率1024px*1024px，并且base64编码后的图片大小不超过10MB。 - 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码： 200

表 3-151 响应 Body 参数

参数	参数类型	描述
result	json	参数解释: 预测结果。目标检测结果（含水平框、旋转框），第一层数组表示不同的预测类别;第二层数组表示同一类别的不同的预测对象;第三层数组表示一个预测对象的不同属性，其中数组中的前8个值表示检测框（含水平框、旋转框）四个顶点的坐标[x0,y0,x1,y1,x2,y2,x3,y3]，第9个值是预测结果的置信度。 约束限制: 预测结果中的第一层数组表示预测类别，需要调用类别接口获取类别列表并按照数组下标索引一一对应 获取类别接口: URI: GET /v1/rs-server/classes 接口域名请参考获取在线部署的大模型推理API接口域名获取。 响应参数: classes 响应示例: <pre>{ "classes": ["classes1", "classes2", "classes3"] }</pre> 取值范围: 不涉及 默认取值: 不涉及

状态码： 400

表 3-152 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

将数字图像细分为多个图像子区域

[illegible]

响应示例

状态码: 200

成功响应示例

```
{
  "result": [
    [
      [0,0,0,0,2,0,0,0,2,0,2,0,0,0,2,0,0,8542],
      [0,0,0,0,2,0,0,0,2,0,2,0,0,0,2,0,0,7542]
    ]
  ]
}
```

状态码

请参见**状态码**。

错误码

请参见**错误码**。

3.3.20 Pangu-CV-异常检测-V2

功能介绍

判断输入数据中是否存在异常，若存在异常则标注出异常内容位置及区域。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-153 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-154 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-155 请求 Body 参数

参数	是否必选	参数类型	描述
images	是	String	参数解释： 被检测图片的base64编码。 约束限制： - 建议使用PNG、JPEG、BMP、JPG、WEBP格式的图片。 - 只支持单张图片输入，分辨率范围为1px-10000px，且长短边比例不能高于5。并且base64编码后的图片大小不超过10MB。 - 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码： 200

表 3-156 响应 Body 参数

参数	参数类型	描述
result.jpg	Array	参数解释: 识别结果信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
dataset_id	String	参数解释: 数据ID信息，用于关联边学边用场景。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-157 result.jpg

参数	参数类型	描述
RegisterMatrix	Array	参数解释: 图片特征矩阵信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
Box	Object	参数解释: 异常区域信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
Score	Float	参数解释： 异常程度，分数越高，代表图片存在异常的可能性越大，具体的阈值按照实际业务确定。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
label	String	参数解释： 预测类别，目前均为abnormal。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-158 Box

参数	参数类型	描述
X	Integer	参数解释： 检测到的目标主体区域的左上角x坐标。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Y	Integer	参数解释： 检测到的目标主体区域的左上角y坐标。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
Width	Integer	参数解释： 检测到的目标主体区域的宽度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Height	Integer	参数解释： 检测到的目标主体区域的高度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Angle	Integer	参数解释： 检测区域角度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-159 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

判断输入数据中是否存在异常，并标注异常内容位置及区域

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA....."
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "dataset_id": "XXXXXXXXXXXXXXXXXXXX",
  "result.jpg": [
    {
      "RegisterMatrix": [
        [
          1,
          0,
          0
        ],
        [
          0,
          1,
          0
        ],
        [
          0,
          0,
          1
        ]
      ],
      "Box": {
        "X": 0,
        "Y": 0,
        "Width": 100,
        "Height": 100,
        "Angle": 0
      },
      "Score": 0.9,
      "label": "abnormal"
    }
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.21 Pangu-CV-视频分类-V2

视频分类不支持通过API进行调用，支持视频推理。

视频推理调用方式，创建部署任务时，在环境变量参数中添加如下环境变量即可调用视频分类模型推理对应视频流。

表 3-160 视频分类环境变量

变量名	类型	取值
ADDRS	字符串	rtsp视频流地址。

模型支持云上和边缘部署，模型推理结果需在容器日志中查询，云上部署时可在ModelArts在线服务页面查看日志，如下图所示。


图 3-14 获取日志



边缘部署模型时，需要登录到边缘节点中查看推理结果，操作方式如下。

1. 边缘节点即用户的边缘服务器，远程登录到该服务器后，执行**docker ps**命令获取容器列表及其信息。

图 3-15 获取容器信息



- 按创建部署任务时填写的名称在容器信息中查找，找到与名称对应的CONTAINER ID。
- 执行**docker logs -f {CONTAINER ID}**命令查看容器日志。

在容器日志中可查看算法执行过程，搜索“result”可获取推理结果，推理结果为目标帧对应结果。

图 3-16 容器日志

```
2025-12-09 15:35:24,993 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:[(0.9422096014022827, 'BlowingCandles')] time stamp: 2025-12-09 15:35:24~2025-12-09 15:35:24, cost: 27.16 ms
2025-12-09 15:35:24,995 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.9422096014022827, 'BlowingCandles')], '2025-12-09 15:35:24~2025-12-09 15:35:24']}
2025-12-09 15:35:25,134 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:25,334 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:25,534 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:25,793 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:[(0.8184486161388289, 'BlowingCandles')] time stamp: 2025-12-09 15:35:24~2025-12-09 15:35:25, cost: 31.63 ms
2025-12-09 15:35:25,795 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.8184486161388289, 'BlowingCandles')], '2025-12-09 15:35:24~2025-12-09 15:35:25')}
2025-12-09 15:35:25,935 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:26,135 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:26,394 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:[(0.7824528839558411, 'BlowingCandles')] time stamp: 2025-12-09 15:35:25~2025-12-09 15:35:26, cost: 26.26 ms
2025-12-09 15:35:26,396 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.7824528839558411, 'BlowingCandles')], '2025-12-09 15:35:25~2025-12-09 15:35:26')}
2025-12-09 15:35:26,535 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:26,736 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:26,990 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:[(0.9581598843441772, 'BlowingCandles')] time stamp: 2025-12-09 15:35:26~2025-12-09 15:35:26, cost: 26.12 ms
2025-12-09 15:35:26,992 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.9581598843441772, 'BlowingCandles')], '2025-12-09 15:35:26~2025-12-09 15:35:26')}
2025-12-09 15:35:27,136 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:27,336 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:27,536 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:27,792 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:[(0.96046382188797, 'BlowingCandles')] time stamp: 2025-12-09 15:35:26~2025-12-09 15:35:27, cost: 25.92 ms
2025-12-09 15:35:27,795 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.96046382188797, 'BlowingCandles')], '2025-12-09 15:35:26~2025-12-09 15:35:27')}
2025-12-09 15:35:27,937 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:28,137 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:28,399 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:[(0.5536914467811584, 'BlowingCandles')] time stamp: 2025-12-09 15:35:27~2025-12-09 15:35:28, cost: 28.62 ms
2025-12-09 15:35:28,401 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.5536914467811584, 'BlowingCandles')], '2025-12-09 15:35:27~2025-12-09 15:35:28')}
2025-12-09 15:35:28,537 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:28,738 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:28,938 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:29,195 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:[(0.44586317377090454, 'CliffDiving')] time stamp: 2025-12-09 15:35:28~2025-12-09 15:35:28, cost: 24.14 ms
2025-12-09 15:35:29,197 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.44586317377090454, 'CliffDiving')], '2025-12-09 15:35:28~2025-12-09 15:35:28')}
2025-12-09 15:35:29,338 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:29,538 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:29,798 INFO [MainProcess-20][Thread-2-281471064813632] :980 infer result:[(0.3263933862553406, 'CliffDiving')] time stamp: 2025-12-09 15:35:28~2025-12-09 15:35:29, cost: 26.19 ms
2025-12-09 15:35:29,800 INFO [MainProcess-20][Thread-2-281471064813632] :980 {'is_alarm': False, 'alarm_type': '', 'alarm_data': '', 'alarm_boxes': [(0.3263933862553406, 'CliffDiving')], '2025-12-09 15:35:28~2025-12-09 15:35:29')}
2025-12-09 15:35:29,939 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
2025-12-09 15:35:30,139 INFO [MainProcess-20][Thread-2-281471064813632] :980 addr no frame: rtsp://8.28.3.215:8554/ucf101
```

3.3.22 Pangu-CV-姿态估计-V2

功能介绍

基于盘古大模型的姿态估计 workflows，实现对人体关键点检测和姿态的估计。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-161 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为 “application/json”

表 3-162 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为 “application/json”

表 3-163 请求 Body 参数

参数	是否必选	参数类型	说明
images	是	String	参数解释： 图片base64编码。 约束限制： 图片限制大小为2K。默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

响应参数

表 3-164 响应 Body

参数	参数类型	说明
result	List	参数解释： 姿态估计结果，为一个list，其中每项代表图像中一个人的姿态估计结果，参数说明请见 表3-165 中result各项结构。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 数据ID信息，用于关联边学边用场景。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-165 result 中各项结构

参数	参数类型	说明
category_id	Int	参数解释： 固定为1，与训练时定义的类别顺序相对应，默认表示person。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
keypoints	List	参数解释： 包含51个整数，按顺序每3个数为一组（共计17组，表示17个关键点），分别表示各关键点的横坐标、纵坐标、可见性。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA....."
}
```

响应示例

```
{
  "dataset_id": "XXXXXXXXXXXXXXXXXXXX",
  "result": [
    {
      "category_id": 1,
      "keypoints": [
        0,
        0,
        0,
        0,
        0,
        0,
        0,
        0,
        0,
        0,
        0,
        296,
        90,
        2,
        0,
        0,

```

```
0,
297,
114,
2,
327,
112,
2,
278,
154,
2,
0,
0,
0,
268,
171,
2,
0,
0,
0,
296,
181,
2,
329,
180,
2,
299,
217,
2,
329,
214,
2,
304,
259,
2,
334,
245,
2
]
}
]
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.23 Pangu-CV-事件检测-V2

事件检测不支持通过API进行调用，创建部署任务时，在环境变量参数中添加如下环境变量即可调用事件检测模型。

表 3-166 事件检测环境变量

变量名	类型	取值
ADDRS	字符串	rtsp视频流地址。

模型支持云上和边缘部署，模型推理结果需在容器日志中查询，云上部署时可在ModelArts在线服务页面查看日志，如下图所示。

图 3-17 获取日志



边缘部署模型时，需要登录到边缘节点中查看推理结果，操作方式如下。

1. 边缘节点即用户的边缘服务器，远程登录到该服务器后，执行**docker ps**命令获取容器列表及其信息。

图 3-18 获取容器信息

[illegible]

- 记录部署任务名称，进入ModelArts服务的模型部署导航栏中按照模型的部署形式，进入在线服务、边缘服务页签按照任务名称找到对应的任务ID。按创建部署任务时生成的任务ID在容器信息中查找，找到与名称对应的CONTAINER ID。
- 执行**docker logs -f {CONTAINER ID}**命令查看容器日志。

在容器日志中可查看算法执行过程，搜索“result”可获取推理结果。推理结果中事件的起止秒数以二维数组表示，包含事件片段的开始时间和结束时间。

图 3-19 容器日志

[illegible]

图 3-20 推理结果

```
2024-08-07 16:46:50.322 INFO [Process:MainProcess-18] [Thread:Thread-3-281471728951360] threading.py_bootstrap_inner580 template post process
2024-08-07 16:46:50.347 INFO [Process:MainProcess-18] [Thread:Thread-3-281471728951360] threading.py_bootstrap_inner580 template post process end
2024-08-07 16:46:50.353 INFO [Process:MainProcess-18] [Thread:Thread-3-281471728951360] threading.py_bootstrap_inner580 processed result: {'is_alarm': True, 'alarm_type': '', 'alarm_data': '', 'alarm_segments': {'segments': array([[217.40714,
228.4002 ]],
[[200.75743 , 211.14238 ],
[175.70296 , 183.45459 ],
[356.27673 , 388.64355 ],
[464.46616 , 500.20865 ],
[126.33304 , 179.5506 ],
[230.38799 , 237.89008 ],
[186.65617 , 189.90804 ],
[17.27895 , 17.86429 ],
[51.282703 , 56.891785 ],
[90.39169 , 107.535225 ],
[247.89466 , 258.459 ],
[46.05313 , 46.997375 ],
[21.984459 , 28.31085 ],
[189.07413 , 112.312355 ],
[331.13028 , 247.77136 ]]
```

3.3.24 Pangu-CV-万物检测-V2

功能介绍

输入图片的base64码和自定义的标签列表，模型会返回带有标签的检测框信息和画好框的图片base64编码。

URI

POST /
接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-167 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-168 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-169 请求 Body 参数

参数	是否必选	参数类型	描述
images	是	String	参数解释： 被检测图片的base64编码。 约束限制： 支持识别PNG、JPEG、BMP、JPG、WEBP格式的图片。只支持单张图片输入，分辨率范围为1px-10000px，base64编码后的图片大小不超过10MB，且长短期比例不能高于5。默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
threshold	否	Float	参数解释： 检测框置信度的阈值。 约束限制： 不涉及 取值范围： 最小值：0 最大值：1 默认取值： 0.3
self_def_classes	否	json	样例： <pre>{ "cat":0.3, "dog":0.5, "person":0.2, "car":0.3, }</pre> 参数解释： 为模型推理结果中的物体类别设置阈值，当小于此处设置的阈值时，接口响应中将不呈现该物体标注框。该字典key值如有重复，阈值会以后一个为准。 约束限制： 不涉及 阈值取值范围： 最小值：0 最大值：1 默认取值： 0.3

响应参数

状态码： 200

表 3-170 响应 Body 参数

参数	参数类型	描述
result	MultimodalDINOResult object	参数解释： 检测结果信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-171 MultimodalDINOResult

参数	参数类型	描述
Box	object	参数解释： 目标检测框坐标，[检测框左上角到竖轴距离,目标框左上角到横轴距离, 检测框宽度, 检测框高度]， { "X": x, "Y": y, "Width": w, "Height": h} 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Score	Float	参数解释： 目标检测置信度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
label	String	参数解释： 目标标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-172 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

```
{
  "threshold": 0.25,
  "images": "/9j/4AAQSkZJRgABAQAAQABAAD/....."
}
```

响应示例

```
{
  "result": [
    {
      "Box": {
        "Y": 0,
        "Width": 100,
        "X": 0,
        "Height": 100
      },
      "Score": 0.9,
      "label": "person"
    }
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.25 Pangu-CV-万物分割-V2

功能介绍

输入图片的base64码和自定义的标签列表，模型会返回分割的可视化结果、分割的mask图和每个实例的分割信息。

URI

图片请求：POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-173 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-174 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-175 语义分割-请求 Body 参数

参数	是否必选	参数类型	描述
image_base64	是	String	参数解释： 被检测图片的base64编码。 约束限制： 支持识别PNG、JPEG、BMP、JPG、WEBP格式的图片。只支持单张图片输入，分辨率范围为1px-10000px，base64编码后的图片大小不超过10MB，且长短边比例不能高于5，图片像素尺寸面积不能超过1920*1080。默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
text_prompt	否	Array of strings	参数解释： 检测的英文标签列表，按英文逗号分割，如"sofa,tvmonitor"。 约束限制： 列表长度不超过20，单个标签程度长度不超过50。 取值范围： 最小长度：0 最大长度：50 数组长度：0 - 20 默认取值： 不涉及
object_mask_threshhold	否	Float	参数解释： 实例目标分类的置信度阈值。 约束限制： 不涉及 取值范围： 最小值：0 最大值：1 默认取值： 缺省值：0.0
overlap_threshhold	否	Float	参数解释： 单实例mask图 and 对应矩形框的面积比阈值。 约束限制： 不涉及 取值范围： 最小值：0 最大值：1 默认取值： 缺省值：0.8

表 3-176 实例分割-请求 Body 参数

参数	是否必选	参数类型	描述
image_base64	是	String	参数解释： 被检测图片的base64编码。 约束限制： 支持识别PNG、JPEG、BMP、JPG、WEBP格式的图片。只支持单张图片输入，分辨率范围为1px-10000px，base64编码后的图片大小不超过10MB，且长短期比例不能高于5，图片像素尺寸面积不能超过1920*1080。默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

响应参数-语义分割

状态码： 200

表 3-177 响应 Body 参数

参数	参数类型	描述
visualized_image	String	参数解释： base64编码检测图像结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
instance_pixel_base64	String	参数解释: 结果图转换为base64，实例分割像素级分类结果，每个像素值对应指定类别，大小为（ image_height, image_width ）。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
semantic_mask_base64	String	参数解释: 结果图转换为base64，语义分割像素级分类结果，每个像素值对应指定类别，大小为（ image_height, image_width ）。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
category_mapper	Array of category_mapper objects	参数解释: 类别id和实际英文名的映射关系。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
segment_info	Array of segment_info objects	参数解释: 实例/语义分割的结果。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
img_info	Array of img_info objects	参数解释： 推理结果的图片宽高信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 训练数据集ID 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-178 category_mapper

参数	参数类型	描述
category_id	String	参数解释： 用于查询 segment_info object中的category_id（注：二者类型不同，需要转换为Integer）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
label_name	String	参数解释： 目标标签的英文名。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-179 segment_info

参数	参数类型	描述
area	Float	参数解释: 实例/语义目标占据的像素面积。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
category_id	Integer	参数解释: 类别id。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
id	Integer	参数解释: 实例id，对应instance_pixel图的像素值。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
isthing	Bool	参数解释: 是否有效物体。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-180 img_info

参数	参数类型	描述
image_width	Integer	参数解释： 推理结果图片的宽。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_height	Integer	参数解释： 推理结果图片的高。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-181 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

响应参数-实例分割

表 3-182 实例分割-响应参数

参数	参数类型	描述
img_res	List	参数解释： 实例分割结果，请求成功有此字段，其中每个元素为一个实例的分割结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 训练数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-183 img_res 中各项结构

参数	参数类型	描述
label	String	参数解释： 预测类别，与训练数据中的类别名称相关。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
score	Float	参数解释： 置信度。 约束限制： 不涉及 取值范围： 0~1 默认取值： 不涉及
box	Dict	参数解释： 检测到的目标主体信息，格式为 {<code>"x":x1,"y":y1,"width":w,"height":h,"angle":r</code>}。 • x：检测到的目标主体区域的左上角x坐标。 • y：检测到的目标主体区域的左上角y坐标。 • width：检测到的目标主体区域的宽度。 • height：检测到的目标主体区域的高度。 • angle：默认为0，检测区域角度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
mask	Dict	参数解释： 图像信息，格式为{<code>"counts":string,"size":[h,w]</code>}。 • counts：基于游程编码的字符串，编码内容和原图宽高相同的布尔数组：若数组某位置值为0，代表原图此位置像素点不属于检测目标，若为1，代表原图此位置像素点属于检测目标。可通过python开源库pycocotools._mask进行编码和解码。 • size：图像尺寸，h为图像高，w为图像宽。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例-语义分割

```
{
  "text_prompt": "airplane,animal,apparel",
  "object_mask_threshold": 0.0,
  "overlap_threshold": 0.8,
  "image_base64": "/9j/4AAQSkZJRgABAQAAAQABAAD/....."
}
```

响应示例-语义分割

```
{
  "dataset_id": "12345",
  "visualized_image": "/9j/4AAQSkZJRgABAQAAAQABAAD/.....",
  "category_mapper": [
    {"category_id": "0", "label_name": "airplane"},
    {"category_id": "1", "label_name": "animal"},
    {"category_id": "2", "label_name": "apparel"}
  ],
  "segment_info": [
    {"area": 28740.0, "category_id": 6, "id": 1, "isthing": true},
    {"area": 13105.0, "category_id": 20, "id": 2, "isthing": true},
    {"area": 18453.0, "category_id": 20, "id": 3, "isthing": true}
  ],
  "img_info": {
    "image_height": 463,
    "image_width": 640
  }
}
```

请求示例-实例分割

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA....."
}
```

响应示例-实例分割

```
{
  "dataset_id": "12345",
  "img_res": [
    {"label": "person", "score": 0.958,
      "box": {"x": 131, "y": 186, "width": 128, "height": 102, "angle": 0},
      "mask": {'counts': 'PR`1h0n:0O2M5K4L4M4L6I7\\O\\'
        \NiFh1R9a0N2M3O0M301O00001O00000000000003NO01N2O0N3O2Nd0]O1N1O0O2O1N20000O100O2O
        0O101N3N1N2N2O1N1O1O1O1O01O0001O1O1O2N3M2ZFiN8R2001O00001O0001O1O1O2N1O1
        O2N3M7F9I5J4M3N1O3M3L3M3N1N3M2M3MRfR3','size': [374, 500]}
      },...]
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.26 Pangu-CV-视觉交互检测-V3

功能介绍

盘古视觉交互检测大模型，支持通过文本或者视觉提示来找出目标图像中所有感兴趣的目标，确定它们的位置和类别。

视觉交互检测推理分为“开集模型推理”和“闭集模型推理”，其中：

- **开集模型推理：**

该模式下用户可以 给出想要检测的目标少量的视觉提示和文本提示（单一视觉提示或文本提示亦可），即可在待检测图像上检测用户指定目标类目。该过程整体分为 提示特征获取和 提示特征推理两个步骤：

1. 提示特征获取：这一步的目的是根据用户给出的 视觉提示或者文本提示生成对应的提示特征编码用于后续的特征推理，由于用户无法一次确定给出的提示能否达到符合预期的检测效果，因此该过程通常是交互式进行，用户通过尝试不同的提示然后观察在待检测图上的效果，选择符合预期效果的提示得到提示特征编码用户后续的特征推理。

2. 提示特征推理：基于上一步得到的提示特征编码，然后即可在待检测目标图像上进行快速的目标检测。

需要注意的是：

1. 第二步基于特征进行推理而不直接基于用户提示直接端到端进行目标检测的原因是提示特征提取比较耗费时间，期间开集检测大模型会进行多次视觉或者文本推理非常耗时。对于已经确定的用户提示，这些提示对应的提示特征是一样的，无需重复提取。因此在实际大规模进行目标检测时，需要先获取提示特征 再基于这些提示特征进行快速推理。

2. 对于使用自己的数据集重新预训练或者微调的数据集进行检测，可以直接仅使用文本提示，将训练类目名称的部分或者全部类目名称使用"."进行拼接，可以达到训练时验证集的检测精度。

- **闭集模型推理：**

该模式下和常规目标检测推理方式一致，用户仅需上传待检测的图片即可直接进行目标检测推理。该模式下不具备开集检测能力只能检测训练数据集中的类目，模型会自动加载闭集训练时得到的类目提示特征，无需用户主动进行提示特征获取。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-184 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-185 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-186 请求 Body 参数 --开集推理-提示特征获取

参数	是否必选	参数类型	说明
mode	是，值为 prompt_feature_gen	String	参数解释： 推理模式为“开集检测特征生成”。 约束限制： 不涉及 取值范围： 提示特征获取模式，值为固定值“prompt_feature_gen” 默认取值： 无
confidence	否,默认值0.5	String	参数解释： 设置目标检测结果的阈值过滤，目标检测结果score低于该值的结果会被过滤，选填，如果不填则使用默认值0.5。 约束限制： 不涉及 取值范围： (0, 1) 默认取值： 0.5

参数	是否必选	参数类型	说明
text_prompt	否，默认值 None	String	参数解释： 文本提示（'.'分隔类别，例如 'cat. dog.'表示提示 cat 和 dog 2个类别），仅适用于 prompt_feature_gen模式，该模式下该参数为选填。 建议提示类别不超过50个。 约束限制： 不涉及 取值范围： 无 默认取值： None
visual_prompt	否，默认值 None	String	参数解释： 视觉提示，list类型，其中每张提示图像是一个dict类型，包含两个key: img（image的base64编码）和prompt（该图像的视觉提示）。prompt是一个list类型，包含2个key: label（目标类目名）和bbox（标注框信息，其格式为[x,y,w,h]）。建议提示图像最多10个。 约束限制： 不涉及 取值范围： 无 默认取值： None
target_image	是	String	参数解释： 待检测图像的base64编码，必填。 约束限制： 不涉及 取值范围： 无 默认取值： 无

参数	是否必选	参数类型	说明
show_detected_image	否，默认值false	String	参数解释： 是否返回目标图像叠加预测信息可视化结果，true返回，false不返回。 约束限制： 不涉及 取值范围： true,false 默认取值： false

表4 请求Body参数 --开集推理-提示特征推理

参数	是否必选	参数类型	说明
mode	是，值为prompt_feature_inference	String	参数解释： 推理模式为“开集检测-基于提示特征推理”。 约束限制： 不涉及 取值范围： 基于提示特征推理，值为固定值“prompt_feature_inference” 默认取值： 无
confidence	否,默认值0.5	String	参数解释： 设置目标检测结果的阈值过滤，目标检测结果score低于该值的结果会被过滤，选填，如果不填则使用默认值0.5。 约束限制： 不涉及 取值范围： (0, 1) 默认取值： 0.5

参数	是否必选	参数类型	说明
prompt_feature	是，默认值None	dict	参数解释： 提示特征编码，dict类型，key是类别名称，val是该类的特征base64编码，prompt_feature_gen模式下的返回结果可以得到，仅适用于prompt_feature_inference模式。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
target_image	是	String	参数解释： 待检测图像的base64编码，必填。 约束限制： 不涉及 取值范围： 无 默认取值： 无

表5 请求Body参数 --闭集推理

参数	是否必选	参数类型	说明
confidence	否,各个类别最佳阈值	String	参数解释： 用于目标检测结果的阈值过滤，目标检测结果score低于该值的结果会被过滤，选填, 如果用户不传此参数，则模型会使用基于验证集上学习得到的最佳类别阈值。 约束限制： 不涉及 取值范围： (0 , 1) 默认取值： 无

参数	是否必选	参数类型	说明
target_image	是	String	参数解释： 待检测图像的base64编码，必填。 约束限制： 不涉及 取值范围： 无 默认取值： 无

响应参数

表6 响应Body--开集推理-提示特征获取

参数	参数类型	说明
results	List	参数解释： 物体检测的识别结果。格式为[{'label': 'xxx', 'score': xxx, 'bbox': [x,y,w,h]}, {'label': 'xxx', 'score': xxx, 'bbox': [x,y,w,h]}...]。 label：预测类别。 score：置信度。 bbox：目标主体信息，分别为[x1,y1,w,h]，其中x1,y1代表左上角坐标，w是宽度，h是高度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	说明
prompt_feature	dict	参数解释： 返回值为dict，其中key为预测类别，value为类别特征base64编码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表7 响应Body--开集推理-提示特征推理

参数	参数类型	说明
results	List	参数解释： 物体检测的识别结果。格式为[{'label': 'xxx', 'score': xxx, 'bbox': [x,y,w,h]}, {'label': 'xxx', 'score': xxx, 'bbox': [x,y,w,h]}...]。 label：预测类别。 score：置信度。 bbox：目标主体信息，分别为[x1,y1,w,h]，其中x1,y1代表左上角坐标，w是宽度，h是高度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表8 请求Body参数 --闭集推理

参数	参数类型	说明
results	List	参数解释： 物体检测的识别结果。格式为[{'label': 'xxx', 'score': xxx, 'bbox': [x,y,w,h]}, {'label': 'xxx', 'score': xxx, 'bbox': [x,y,w,h]}...]。 label：预测类别。 score：置信度。 bbox：目标主体信息,分别为[x1,y1,w,h]，其中x1,y1代表左上角坐标，w是宽度，h是高度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

1) 开集推理-提示特征获取

```
{
  "mode": "prompt_feature_gen",
  "confidence": 0.5,
  "target_image": "target_image_base64_str",
  "text_prompt": "cat. dog",
  "visual_prompt": [
    {
      "img": "visual_image_1_base64_str",
      "prompt": [
        {
          "label": "cat",
          "bbox": [
            100,
            100,
            50,
            50
          ]
        },
        {
          "label": "cat",
          "bbox": [
            150,
```

```
        150,  
        50,  
        50  
    ]  
  }  
]  
},  
{  
  "img": "visual_image_2_base64_str",  
  "prompt": [  
    {  
      "label": "dog",  
      "bbox": [  
        30,  
        30,  
        60,  
        60  
      ]  
    },  
    {  
      "label": "dog",  
      "bbox": [  
        80,  
        80,  
        60,  
        50  
      ]  
    }  
  ]  
}  
],  
  "show_detected_image": true  
}
```

2) 开集推理-提示特征推理

```
{  
  "mode": "prompt_feature_inference",  
  "confidence": 0.5,  
  "target_image": "target_image_base64_str",  
  "prompt_feature": {  
    "cat": "cat_feature_base64_str",  
    "dog": "dog_feature_base64_str"  
  }  
}
```

3) 闭集推理

```
{  
  "confidence": 0.5,  
  "target_image": "target_image_base64_str"  
}
```

响应示例

1) 开集推理-提示特征获取

```
{  
  "dataset_id": "",  
  "results": [  
    {  
      "label": "cat",  
      "bbox": [  
        10,  
        10,  
        50,  
        50  
      ],  
      "score": 0.6784  
    }  
  ]  
}
```

```
    ],  
    "result_vis": "target_image_result_vis_base64_str",  
    "prompt_feature": {  
      "cat": "cat_feature_base64_str",  
      "dog": "dog_feature_base64_str"  
    }  
  }  
}
```

2) 开集推理-提示特征推理

```
{  
  "dataset_id": "",  
  "results": [  
    {  
      "label": "cat",  
      "bbox": [  
        10,  
        10,  
        50,  
        50  
      ],  
      "score": 0.6784  
    }  
  ],  
}
```

3) 闭集推理

```
{  
  "dataset_id": "",  
  "results": [  
    {  
      "label": "cat",  
      "bbox": [  
        10,  
        10,  
        50,  
        50  
      ],  
      "score": 0.6784  
    }  
  ],  
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.27 Pangu-CV-异常检测-V3

功能介绍

判断输入数据中是否存在异常，若存在异常则标注出异常内容位置及区域。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-187 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-188 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-189 请求 Body 参数

参数	是否必选	参数类型	描述
images	是	String	参数解释： 被检测图片的base64编码。 约束限制： - 建议使用PNG、JPEG、BMP、JPG、WEBP格式的图片。 - 只支持单张图片输入，分辨率范围为1px-10000px，且长短边比例不能高于5。并且base64编码后的图片大小不超过10MB。 - 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及
threshold	否	float	参数解释： 异常判定阈值。大于该阈值的会被判定为异常。(训练结果页面会有最优阈值打印，可做参考) 约束限制： 不涉及 取值范围： 【 0, 1 】 默认取值： 0.5

参数	是否必选	参数类型	描述
visualize	否	bool	参数解释： 是否返回异常区域热力图base64渲染。 (因为图像渲染处理耗时会达300ms以上，所以默认为false。false时返回的字段anomaly_map 是异常热力图，可通过后处理做可视化渲染；true返回的是异常区域热力图base64编码，可直接转换可视化。) 约束限制： 不涉及 取值范围： 【 true, false 】 默认取值： false

响应参数

状态码： 200

表 3-190 响应 Body 参数

参数	参数类型	描述
result	Array	参数解释： 识别结果信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 数据ID信息，用于关联边学边用场景。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-191 result.jpg

参数	参数类型	描述
Score	Float	参数解释: 异常评分，分数越高，代表图片存在异常的可能性越大。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
label	String	参数解释: 预测类别，返回abnormal表示存在异常。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
anomaly_map	String	参数解释: visualize传参为false或不传时，anomaly_map是异常热力图，可通过后处理做可视化渲染； visualize传参为true返回的是异常区域热力图base64编码，可直接转换可视化检测图像异常区域可视化的base64图片 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

状态码： 400

表 3-192 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

判断输入数据中是否存在异常，并标注异常内容位置及区域

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA....."
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "dataset_id": "XXXXXXXXXXXXXXXXXXXX",
  "result": [
    {
      "Score": 0.9,
      "label": "abnormal",
      "anomaly_map": "xxxxx"
    }
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.28 Pangu-Railway-CV-货车故障轨旁图像检测-V3

功能介绍

通过高速像机阵列，拍摄列车车底和侧下部的全部可视信息，对抓拍后货车车辆的图像进行分析，实现故障检测功能。

URI

图片请求：

POST /v1/{project_id}/ftd/carriage

表 3-193 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-194 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-195 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-196 请求 Body 参数

参数	是否必选	参数类型	描述
carriage_data	是	CarriageData PartItem object	参数解释： 整车请求体。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
side_frame_type	是	String	参数解释： 侧架类型。 约束限制： 不涉及 取值范围： 支持类型包括："8B_8AB"、 "DZ1"、"DZ2"、"DZ3"、 "K2"、"K3"、"K4"、"K5"、 "K6" 和 "K7"等 默认取值： 不涉及
vehicle_type	是	String	参数解释： 车辆类型。 约束限制： 不涉及 取值范围： 支持的车辆类型包括： 'C62AK', 'C62BK', 'C62BT', 'C64AT', 'C64H', 'C64K', 'C64T', 'C70', 'C70C', 'C70E', 'C70E-A', 'C70EH', 'C70EHA', 'C70H', 'C80B', 'C80BH', 'C80', 'C80E', 'C80EH', 'G17BK', 'G17BT', 'G17DK', 'G17K', 'G17T', 'G60K', 'G70K', 'G70T', 'G75K', 'GN70', 'GQ70', 'N17AK', 'NX17BH', 'NX17BK', 'NX17BT', 'NX17K', 'NX70', 'NX70A', 'X4K', 'X6BK', 'X6K', 'X70', 'P62K', 'P62NK', 'P62NT', 'P63K', 'P64AK', 'P64AT', 'P64GK', 'P64K', 'P65', 'P70', 'PB', 'JSQ6', 'L70'等 默认取值： 不涉及

参数	是否必选	参数类型	描述
vehicle_id	是	String	参数解释： 车号。 约束限制： 7位数字组成 取值范围： 不涉及 默认取值： 不涉及
vehicle_order	是	String	参数解释： 车辆序号，如“89”， “51”，“2”。 约束限制： 数字组合 取值范围： 不涉及 默认取值： 不涉及
vehicle_pass_time	是	String	参数解释： 过车时间，如 "20210511132921"（2021年05月11日13时29分21秒）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
last_vehicle_status	是	Integer	参数解释： 尾车标识，是尾车标识1，否则标识0。 约束限制： 不涉及 取值范围： 0或1 默认取值： 不涉及

参数	是否必选	参数类型	描述
station_id	是	String	参数解释： 检测站序号。 约束限制： 9位数字、字母组成 取值范围： 不涉及 默认取值： 不涉及
uuid_vehicle_id	是	String	参数解释： 40位，同一辆车的唯一标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
parts_number	是	Integer	参数解释： 对应的请求图片工位数量，服务端会等一辆车所有部件工位都收齐后才开始识别（等待5分钟，还未全收到会发送信息到部件补发server，同时启动识别，一辆车一般有10-15个工位部件）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
hook_type	是	String	参数解释： 互钩差类型。 约束限制： 不涉及 取值范围： "13型"或"17型" 默认取值： 不涉及

参数	是否必选	参数类型	描述
hook_type_previous	是	String	参数解释： 前车互钩差类型。 约束限制： 不涉及 取值范围： "13型"或"17型" 默认取值： 不涉及
parts	是	String	参数解释： 整车工位序号列表，按逗号隔开。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
vehicle_type_previous	是	String	参数解释： 前一车型，如"C70"。 约束限制： 不涉及 取值范围： 如vehicle_type字段 默认取值： 不涉及

表 3-197 CarriageDataPartItem

参数	是否必选	参数类型	描述
side_frame_00	是	CarriagePartItem object	参数解释： 前台侧架部件编号00请求体。 约束限制： 不涉及 取值范围： 如vehicle_type字段 默认取值： 不涉及

参数	是否必选	参数类型	描述
brake_beam_02	是	CarriagePartImageltem object	参数解释： 制动梁部件编号02请求体。 约束限制： 不涉及 取值范围： 如vehicle_type字段 默认取值： 不涉及
coupling_buffer_04	是	CarriagePartImageltem object	参数解释： 车钩部件编号04请求体。 约束限制： 不涉及 取值范围： 如vehicle_type字段 默认取值： 不涉及

表 3-198 CarriagePartImageltem

参数	是否必选	参数类型	描述
input_image_info	是	CarriageData InputImageInfoList Object	参数解释： 待识别的图像信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
photo_number	是	Integer	参数解释： 该部件工位图片张数，服务端收到后会跟input_image_info数组列表进行对比，如果不一致，服务端将抛出错误码，显示入参有问题。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
uuid_part_id	是	String	参数解释： 40位uuid数值_2位部件数值编号，如："a3389a9c-bdbe-11eb-9c4e-84a93e7989d6_01"，表示同一部件工位部件的唯一标识，_后两位数字表示部件工位。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-199 CarriageDataInputImageInfoList

参数	是否必选	参数类型	描述
path	是	String	参数解释： 输入图像存储路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
photo	是	Integer	参数解释： 拍摄相机，对应图片名称中间数字。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
photo_order	是	Integer	参数解释： 图像编号，对应图片名称最后一个数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image	是	String	参数解释： 图像的base64编码。要求base64编码后大小不超过10M。 约束限制： 图片要求：（1）图片尺寸：按照原始图片的尺寸输入，即短边1024像素，长边根据图片采集设备的类型划分（TFDS-2单张图片输入，长边1400像素；TFDS-3将原始图片拼接成一张完整的图片，长边 1400*n像素，n为拼接图片张数）。（2）如果图像是上下倒置的，需要旋转为正常视角后，重新保存为图片文件，之后再输入。 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码： 200

表 3-200 响应 Body 参数

参数	参数类型	描述
result	CarriageResponseBodyResult object	调用结果。

表 3-201 CarriageResponseBodyResult

参数	参数类型	描述
error_code	String	具体请参考错误码说明。
error_msg	String	具体请参考错误码说明。

模型部署阶段，已经提前通过RESULT_RECEIVER_URL环境变量指定了输出结果的存储位置。成功响应的情况下，识别结果会返回至用户指定的结果接收RESULT_RECEIVER_URL中。以车钩工位为例，识别结果如表3-202所示：

表 3-202 识别结果

参数	参数类型	描述
result	Array of CouplingbufferResult objects	调用结果。

表 3-203 CouplingbufferResult

参数	参数类型	描述
faults	Array of CouplingbufferResultFaults objects	参数解释： 识别结果数组，包含该次请求中所有车辆或部件的检测结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
train_received_time	String	参数解释： 为列车收到的第一个工位部件请求时刻（对应服务器的时刻，下同）。 约束限制： 时间格式通常为yyyy-MM-dd HH:mm:ss。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
train_start_time	String	参数解释：列车开始识别时刻。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
train_end_time	String	参数解释：列车识别结束发送时刻。 约束限制：最后一辆车识别完发送时刻才有意义，即当last_vehicle_recognized为1时，才代表整列车的结束时刻；否则为中间某车辆的结束时刻。 取值范围：不涉及 默认取值：不涉及
train_processing_time	Float	参数解释：本列车处理总耗时。 约束限制：由于是按车辆识别返回的，因此只有最后一辆车返回的处理时间才是真正意义上本列车处理时间= train_end_time- train_start_time。 取值范围：不涉及 默认取值：不涉及
last_vehicle_recognized	Integer	参数解释：标识是否为本列车识别完的最后一辆车，用于区分中间车辆结果和最终结果。 约束限制：为1时为本列车识别完的最后一辆车（跟请求端的last_vehicle_status区分开），这时候取train_processing_time才是真正的本列车处理时间，为0的话为中间车辆识别结束时刻- train_start_time。 取值范围：不涉及 默认取值：不涉及
carriage_start_time	String	参数解释：当前这辆车（当前返回结果对应的车辆）开始识别的时刻。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
carriage_end_time	String	参数解释：当前这辆车识别完发送时刻，跟 train_end_time是同一时刻。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

参数	参数类型	描述
carriage_processing_time	Float	参数解释： 当前这辆车处理耗时= carriage_end_time- carriage_start_time。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-204 CouplingbufferResultFaults

参数	参数类型	描述
path	String	参数解释： 故障（或检测）图像的存储路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
fault_info	Array of ResultItemFaultInfo objects	参数解释： 该张图片检测到的具体故障信息列表。 约束限制： 数组长度取决于检测到的故障种类数，无故障时也可能包含“正常”的结果项。 取值范围： 不涉及 默认取值： 不涉及
defect_count	Integer	参数解释： 该张图片检测到的故障数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
part	String	参数解释： 钩缓工位返回的部件标识 coupling_buffer。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
vehicle_order	String	参数解释： 车辆在列车中的序号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
vehicle_id	String	参数解释： 识别车辆车号，如"38030020"。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
station_id	String	参数解释： 检测站id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
vehicle_pass_time	String	参数解释： 识别列车过车时间，如"20210511132921"。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
uuid_part_id	String	参数解释： 同一工位的唯一字符串标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
uuid_vehicle_id	String	参数解释： 同一辆车的唯一字符串标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
photo_number	Integer	参数解释： 本次请求工位发送过来的图片数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
parts_number	Integer	参数解释： 车辆对应的请求图片批数（该辆车部件工位数）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
hook_type	String	参数解释： 互钩差类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
last_vehicle_status	Integer	参数解释： 取值0或1，表示是否为尾车（取值为1，跟请求端发送过来的是同一个字段）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
vehicle_type	String	参数解释： 车型，跟请求体传入的一致。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
parts	String	参数解释： 整车工位序号列表，按逗号隔开，跟请求体中的parts一致。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
defect_status	Integer	参数解释： 识别结果状态。 约束限制： 不涉及 取值范围： 0智能识别已完成无故障；1智能识别已完成有故障；2图像具备条件但智能模块异常未能正常识别；3不在识别范围，包括不支持的车型和转向架类型。以上返回值均以部件为判别条件（非某一图片或某一识别模块的识别结果状态标记）。 默认取值： 不涉及

表 3-205 ResultItemFaultInfo

参数	参数类型	描述
left	Integer	参数解释： 故障区域矩形框左上角横坐标。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
top	Integer	参数解释： 故障区域矩形框左上角纵坐标。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
width	Integer	参数解释： 故障区域矩形框宽。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
height	Integer	参数解释： 故障区域矩形框高。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
defect_area	String	参数解释： 故障部件。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
defect_code	String	参数解释： 故障编码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
defect_name	String	参数解释： 故障名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
front_back	Integer	参数解释： 故障归属的前后车标识。 约束限制： 不涉及 取值范围： 只有互钩差及车钩工位才会返回，0表示该张图片故障应该显示在前车，1表示该张故障图片显示在后车，-1表示前后车都提报。 默认取值： 不涉及
confidence	Float	参数解释： 置信度，取值范围为0-1，此外有部分输出如地板、异物破损及逻辑判断得出的故障（人力制动机轴链丢失）的置信度得分不具备实际统计意义。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及
detection_confidence	Float	参数解释： 为检测到的部件置信度，取值范围0-1。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及
confidence_list	Object	参数解释： 为对应坐标图片区域，模型输出所有类别置信度得分详情。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
ponderance	Integer	参数解释： 故障严重程度等级。 约束限制： 不涉及 取值范围： 0（严重，需弹框）1（中等）2（轻微），不需要分等级的设置成-1（作业平台前端代码在读到服务端返回的ponderance为-1时候，通过读取不同路局对应的故障配置文件显示）。 默认取值： 不涉及
fault_serial	String	参数解释： 故障的唯一序列号，为32-40位的uuid。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
fault_pid	String	参数解释： 故障关联父ID，用于合并显示。fault_pid为1时，为多个关联合并显示的故障主图；fault_pid为空时，不存在关联合并显示的；fault_pid为其他时（其值为主图的fault_serial），为子集故障，提示前端关联展示。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-206 响应 Body 参数

参数	参数类型	描述
result	CarriageResponseBodyResult object	调用结果。

状态码：501

表 3-207 响应 Body 参数

参数	参数类型	描述
result	CarriageResponseBodyResult object	调用结果。

请求示例

```
POST /v1/{project_id}/ftd/carriage
{
  "carriage_data":{
    "side_frame_00":{
      "input_image_info":[{
        "path":"D://xxxx/1_1_1.jpg",
        "photo":1,
        "photo_order":1,
        "image":"","
        "url":"http://BucketName.obs.xxx.com/15_1_0.jpg"
      }],
      "photo_number":6,
      "uuid_part_id":"0CC6D9F18C064A2A9C98D28DDDA359D5_00"
    },
    "brake_beam_02":{
      "input_image_info":[{
        "path":"D://zdsb/result/883/1_1_1.jpg",
        "photo":1,
        "photo_order":1,
        "image":"","
        "url":"http://BucketName.obs.xxx.com/15_1_0.jpg"
      }],
      "photo_number":6,
      "uuid_part_id":"0CC6D9F18C064A2A9C98D28DDDA359D5_02"
    },
    "coupling_buffer_04":{
      "input_image_info":[{
        "path":"D://xxxx/1_1_1.jpg",
        "photo":1,
        "photo_order":1,
        "image":"/9j/4AAQSkZJRgABAQAAQABAAD/...",
        "url":""
      }],
      "photo_number":6,
      "uuid_part_id":"0CC6D9F18C064A2A9C98D28DDDA359D5_04"
    }
  },
  "side_frame_type":"K6",
  "vehicle_type":"C70E",
  "vehicle_order":"16",
  "vehicle_pass_time":"20220422162223",
  "last_vehicle_status":0,
  "station_id":"F38F12F01",
  "uuid_vehicle_id":"1742172",
  "parts_number":11,
  "hook_type":"17型",
  "hook_type_previous":"17型",
  "parts":["00,01,02,03,04,10,08,09,30,31,06",
  "vehicle_type_previous":"C70"
}
```

响应示例

```
{
  "result":{
    "error_code":"TFDS.0100",
    "error_msg":"Succeeded."
  }
}
```

成功响应时，按部件工位返回结果Result，以车钩工位为例：

```
{
  "result": {
    "carriage_end_time": "2025-08-22 10:36:01",
    "carriage_processing_time": 360.05,
    "carriage_start_time": "2025-08-22 10:30:01",
    "faults": [
```

```
{
  "defect_count": 0,
  "defect_status": 0,
  "fault_info": [
    {
      "confidence": 0.8124,
      "confidence_list": {
        "人力制动机_人力制动机拉杆脱落": 0.1375,
        "人力制动机_人力制动机轴链丢失": 0.0753,
        "人力制动机_人力制动机轴链卡滞": 0.1313,
        "人力制动机_人力制动机轴链折断": 0.0738,
        "人力制动机_人力制动机轴链拉杆磨轴": 0.1243,
        "人力制动机_人力制动机轴链拉铆销套丢失": 0.086,
        "人力制动机_人力制动机轴链脱落": 0.1616,
        "人力制动机_导向杆卡滞": 0.0652,
        "人力制动机_正常": 0.8124
      },
      "defect_area": "人力制动机",
      "defect_code": "NORMAL",
      "defect_name": "正常",
      "detail_defect_code": "",
      "detail_defect_name": "",
      "detection_confidence": 0.999,
      "fault_pid": "",
      "fault_serial": "b35b9daa-7f00-11f0-b6ff-0242ac11000d",
      "front_back": 0,
      "height": 169,
      "left": 12,
      "ponderance": -1,
      "top": 526,
      "width": 769
    }
  ],
  "hook_type": "17型",
  "last_vehicle_status": 0,
  "part": "coupling_buffer",
  "parts_number": 10,
  "path": "1086/42_4_0.jpg",
  "photo_number": 9,
  "station_id": "TFDSSNSX1",
  "uuid_part_id": "FDC28D3AB91A4A18B100B6A06C799FCE#ht_04",
  "uuid_vehicle_id": "FDC28D3AB91A4A18B100B6A06C799FCE#ht_0424475",
  "vehicle_id": "0424475",
  "vehicle_order": "42",
  "vehicle_pass_time": "20250528001458",
  "vehicle_type": "C80B",
  "vehicle_type_previous": "C80B"
},
"last_vehicle_recognized": 0,
"train_end_time": "2025-08-22 10:36:01",
"train_processing_time": 360.86,
"train_received_time": "2025-08-22 10:29:23",
"train_start_time": "2025-08-22 10:29:23"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.29 视频推理-动态增删视频流

视频推理服务支持动态视频流地址修改，包括“增加”和“停止”用户输入的视频流地址，增强算法视频流处理的灵活性，初始化配置的视频流默认采用npu解码。

 说明

- 1. 默认视频解码使用npu，如需使用cpu解码，请在部署时，增加环境变量参数：VIDEO_DECODE_BACKEND将其值指定为cpu。
- 2. 如需自动根据视频文件类型选择cpu或npu解码，请配置IS_AUTO_VIDEO_BACKEND参数为true，默认为false，false时根据VIDEO_DECODE_BACKEND的值来进行解码。
- 3. 使用视频流部署时，不支持多实例部署，如部署多实例后调用动态增删视频流，会随机分发到其中一个实例上。

前提条件

部署推理服务为视频流推理类型，且服务状态处于正常运行中。

获取 URI

服务调用API格式统一为：API接口域名+URI，其中API接口域名与调用模型推理接口的域名一致，URI统一为“POST /v1/video/set_data”。API接口域名+URI示例：http://1.16.101.1:7100/v1/video/set_data。

请求参数

表 3-208 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-209 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-210 请求参数

参数	是否必选	参数类型	说明
addrs	是	List	参数解释： 修改的视频流地址集合。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
action	是	String	参数解释： 增加/停止目标视频流，参数范围为add/stop。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

表 3-211 修改视频流地址结果响应

参数	参数类型	说明
result	Dict	参数解释： 修改视频流地址后的结果，字典里面各参数见 表5 result中各项结构 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-212 result 中各项结构

参数	参数类型	说明
running_rtsp	List	参数解释： 正在运行的rtsp流地址。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
running_rtsp_num	Int	参数解释： 正在运行的rtsp流数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_status	String	参数解释： 请求发送成功标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "addrs": ["rtsp://xxx:xxx/live1"],
  "action": "add"
}
```

响应示例

```
{
  "result": {
    "running_rtsp": ["rtsp://xxx:xxx/live1"],
    "running_rtsp_num": 1,
    "update_status": "Normal"
  }
}
```

3.3.30 Pangu-CV-目标跟踪-V3

功能介绍

基于目标跟踪工作流，实现对物体的位置进行检测以及跟踪。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-213 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-214 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 参数值为“application/json”

表 3-215 请求参数

参数	是否必选	参数类型	说明
images	是	String	参数解释： 图片base64编码。 约束限制： 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

响应参数

表 3-216 预测结果

参数	参数类型	描述
img_res	Array of Object	参数解释： 预测结果，为一个list，其中每项代表图像中一个检测框的位置，类别，置信度，跟踪序列号等信息。具体字段如表3-217所示。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 数据ID信息，用于关联边学边用场景。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-217 预测结果详情

参数	参数类型	描述
label	String	参数解释： 被预测物体的类别。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
score	Float	参数解释： 置信度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
track_id	Integer	参数解释： 跟踪序列号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
box	Object	参数解释： 预测框的位置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-218 预测框详情

参数	参数类型	描述
x	Float	参数解释： 检测框的左上角x坐标。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
y	Float	参数解释： 检测框的左上角y坐标。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
width	Float	参数解释： 检测框的宽度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
height	Float	参数解释： 检测框的高度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
angle	Integer	参数解释： 检测区域角度，默认为0。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0

请求示例

```
{
  "images": "/9j/4Vr2RXhpZgAASUkqAAgAAA...."
}
```


响应示例

```
{
  "dataset_id": "XXXXXXXXXXXXXXXXXXXX",
  "img_res": [
    {
      "label": "people",
      "score": 0.96,
      "track_id": 1,
      "box": {
        "x": 481.37,
        "y": 239.53,
        "width": 71.13,
        "height": 220.9,
        "angle": 0
      }
    },
    {
      "label": "people",
      "score": 0.93,
      "track_id": 2,
      "box": {
        "x": 691.67,
        "y": 302.4,
        "width": 92.57,
        "height": 267.32,
        "angle": 0
      }
    }
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.31 Pangu-CV-直线检测-V2

功能介绍

本模型为直线检测模型，支持单卡训练，云上部署，边缘部署，离线部署等特性，模型精度高，推理时延低，为业界性价比最优直线检测模型。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-219 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-220 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-221 请求 Body 参数

参数	是否必选	参数类型	描述
images	是	String	参数解释： 被检测图片的base64编码。 约束限制： - 建议整个请求体大小不超过100M。 - 建议使用JPG、PNG、JPEG、BMP格式的图片。 - 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码： 200

表 3-222 响应 Body

参数	参数类型	说明
result	String	参数解释: 直线检测的识别结果 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
dataset_id	String	参数解释: 训练数据集ID 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-223 result 中各项结构

参数	参数类型	说明
img_with_lines	String	参数解释: 带有直线检测信息的可视化图，类型为 np.tobytes() 后转base64编码 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

请求示例

调用方式总结为如下三种：

1) form-data格式调用

```
{
  "file": "xxx"
}
```

2) base64 json调用

```
{
  "Files": [
    [{"ImageData": "xxx(base64 encode image data)"}]
  ]
}
```

3) base64 json调用 (threshold非必须)

```
{
  "images": "xxx(base64 encode image data)"
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "dataset_id": "1234xxxx",
  "result": {
    "img_with_lines": "DxQTDxQTDxQTDxQTERMTERMTERMTERMTEExMTExMTFBQUFBxxxxxx",
    "infer_cost": {
      "inference": " 0.0908",
      "postprocess": " 0.1099",
      "preprocess": " 0.0209"
    },
    "lane_detection_result": {
      "lines": [{
        "id": 2,
        "points": [{
          "id": 2,
          "prob": 0.6001491546630859,
          "x": 515.893542049769,
          "y": 265.78125
        }, {
          "id": 2,
          "prob": 0.6585801243782043,
          "x": 519.8408463310031,
          "y": 279.84375
        }
      ],
      "prob": 0.7372629046440125
    }, {
      "id": 1,
      "points": [{
        "id": 1,
        "prob": 0.7421003580093384,
        "x": 458.1230415800127,
        "y": 309.375
      }, {
        "id": 1,
        "prob": 0.7642115354537964,
        "x": 456.48317464227694,
        "y": 323.4375
      }
    ]
  }
}
```

```
    ], ...
    "prob" : 0.8699995875358582
  },
  ...
]
}
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.3.32 Pangu-CV-图片数据合成-V3

功能介绍

本模型为图片数据合成模型，支持单卡训练，云上部署，边缘部署，将一张参考图中的特定物体或特征，“移植”并“融合”到另一张目标背景图的指定区域内。

URI

POST /
接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-225 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-226 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-227 请求 Body 参数

参数	是否必选	参数类型	描述
filename	是	String	参数解释： 需要合成的图片的名称(给图片起一个名称) 约束限制： 不超过64个字符 取值范围： 不涉及 默认取值： 不涉及
normal_image	是	String	参数解释： 被合成图片的base64编码。 约束限制： • 建议整个请求体大小不超过100M。 • 建议使用JPG、PNG、JPEG、BMP格式的图片。 • 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及
bboxes	是	List	参数解释： 需要合成图片的合成区域列表：标注框坐标[x1,y1,x2,y2], 例如 <pre>"bboxes": [[614, 787, 802, 992]]</pre> 取值范围： 不能超过 图片的尺寸大小 默认取值： 不涉及

参数	是否必选	参数类型	描述
reference_image	是	String	参数解释： 正常图片合成图片所需要参考图片的base64编码。（裁剪的子图） 所需约束限制： • 建议整个请求体大小不超过10M。 • 建议使用JPG、PNG、JPEG、BMP格式的图片。 • 默认只支持RGB三通道图片数据，其他通道的数据暂不支持。 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码： 200

表 3-228 响应 Body

参数	参数类型	说明
result	String	参数解释： 图片数据合成的结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-229 result 中各项结构

参数	参数类型	说明
filename	String	参数解释： 需要合成的图片的名称。 取值范围： 不涉及 默认取值： 不涉及
bbox_index	Integer	参数解释： 被合成区域的index，对应发送请求是boxes框的index）。 约束限制： 不涉及 取值范围： 不涉及 默认取值：
composite_image	String	参数解释： 合成图片的base64编码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-230 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

调用方式总结为如下：

base64 json调用

```
{
  "filename": "425_CRH380A-2813_CHANNEL5_CRH380A_CAR1_05.jpg",
  "normal_image": "/9j/4AAQSkZJRgABAQAAAQABAAD/2wBDAAIBAQEB.....",
  "bboxes": [
    [
      950,
      654,
      1110,
      915
    ]
  ],
  "reference_image": "/9j/4AAQSkZJRgABAQAAAQABAAD/2wBDAAIBAQEBAQIBAQECAgICA..."
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "result": [
    {
      "composite_image": "/9j/4AAQSkZJRgABAQAAAQABAAD/2wBDAAIB.....",
      "bbox_index": 0,
      "filename": "425_CRH380A-2813-熊福群_CHANNEL5_CRH380A_CAR1_05.jpg"
    }
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4 预测大模型

3.4.1 盘古统一编码时序预测分类大模型

功能介绍

基于时序预测基模型实现分类预测能力。时序分类预测有很多应用场景，例如：基于工业设备传感器一段时间采集的连续数据，实现设备正常或异常状态的预测。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-231 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-232 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
auto_fill	否	boolean	参数解释： 是否使用数据补齐功能，开启后将自动填充离散列缺失值和新类别。 约束限制： 只有经过类别特征列处理的列，才能进行数据补齐功能。 取值范围： true：填充 false：不填充 默认取值： false。

响应参数

状态码： 200

表 3-234 响应 Body 参数

参数	参数类型	描述
data	LIST<Output Meta>	参数解释： 时序预测结果的列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
time_cost	JSON	参数解释： 当启动服务时，本次请求服务各阶段耗时情况。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-235 OutputMeta 格式说明

参数名称	参数类型	说明
prediction	JSON	参数解释： 时序分类的输出结果，具体见样例调用示例。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-236 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

通过特征feature_0在不同时间点的值预测出其分类。

```
{
  "context_len": 256,
  "data": [
    {
      "context": {
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...]
      }
    },
    {
      "context": {
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...]
      }
    }
  ],
  "auto_fill": true
}
```

响应示例

状态码： 200

成功响应示例。

```
{
  "data": [
    {
```



```
    "prediction":{
      "label": 0
    }
  },
  "time_cost": {
    "infer_cost_time": "82.609 ms",
    "postprocess_cost_time": "0.29 ms",
    "preprocess_cost_time": "0.1332 ms",
    "service_cost_total_time": "84.965 ms"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.2 盘古统一编码时序预测回归大模型

功能介绍

2025年3月首次发布的模型，基于时序预测基模型实现对未来一组观测值的预测，最多支持128个未来时间点的预测。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-237 请求 Header 参数（Token 认证）


参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-238 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-239 请求 Body 参数

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 时序预测回归批处理数据。 约束限制： 时序数据请求的批处理队列。盘古时序预测回归任务的输入数据内容，用字典承载，其中键对应特征列名，值为序列数据具体内容。具体见样例调用示例。 取值范围： 输入数据中的一组数据。 默认取值： 预测大模型在训练完成后，可以在训练日志页面，“模型训练”日志节点中获取推理api所用的示例数据。填写请求Body时可以参考该示例填写。 
context_len	否	int	参数解释： 时序任务的数据窗口大小。 约束限制： 该参数主要服务于支持多尺度窗口模型的推理，当填写时需要保证输入序列长度大于等于该值。 取值范围： 32-512 默认取值： 128
prediction_len	否	int	参数解释： 时序输出的数据窗口大小。 约束限制： 该参数主要服务于支持多尺度结果输出，当填写时需要保证该值小于等于部署的模型输出序列长度。 取值范围： 1-128 默认取值： 96

参数	是否必选	参数类型	描述
auto_fill	否	boolean	参数解释： 是否使用数据补齐功能，开启后将自动填充离散列缺失值和新类别。 约束限制： 只有经过类别特征列处理的列，才能进行数据补齐功能。 取值范围： true：填充 false：不填充 默认取值： false。

响应参数

状态码： 200

表 3-240 响应 Body 参数

参数	参数类型	描述
data	LIST<Output Meta>	参数解释： 时序预测结果的列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
time_cost	JSON	参数解释： 当启动服务时，本次请求服务各阶段耗时情况。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-241 OutputMeta 格式说明

参数名称	参数类型	说明
prediction	JSON	参数解释： 时序分类的输出结果，具体见样例调用示例。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-242 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

通过特征feature_0、feature_1在历史不同时间点的值预测未来时间点的值。

```
{
  "context_len": 256,
  "prediction_len": 96,
  "data": [
    {
      "context": {
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...]
      }
    },
    {
      "context": {
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...]
      }
    }
  ],
  "auto_fill": true
}
```

响应示例

状态码： 200

成功响应示例。

```
{
  "data": [
    {
      "prediction": {
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...]
        "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...]
      }
    }
  ],
  "time_cost": {
    "infer_cost_time": "82.609 ms",
    "postprocess_cost_time": "0.29 ms",
    "preprocess_cost_time": "0.1332 ms",
    "service_cost_total_time": "84.965 ms"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.3 盘古统一编码表格预测分类大模型

3.4.3.1 数据分类预测

功能介绍

基于统一编码大模型实现表格分类预测能力，针对特定场景的分类任务，用户传入分类数据，使用模型对指定的预测目标进行分类预测。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-243 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-244 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-245 请求 Body 参数（模型推理）

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 待进行预测的数据，data为一个数组，数组中包含多个对象，每个对象是一组完整的特征数据。 约束限制： 待预测特征名需要与训练数据中的特征名保持一致。例如，训练数据中特征列按照feature_1、feature_2……进行命名，在调用推理接口时，特征名也需要保持一致。同时推理接口中特征数量需要与训练数据中的特征数保持一致。一组特征数据填写完成后，再填写剩余待预测数据，格式详见请求示例。 取值范围： 输入数据中的一组数据。 默认取值： 预测大模型在训练完成后，可以在训练日志页面，“模型训练”日志节点中获取推理api所用的示例数据。填写请求Body时可以参考该示例填写。

参数	是否必选	参数类型	描述
auto_fill	否	boolean	参数解释： 是否使用数据补齐功能，开启后将自动填充离散列缺失值和新类别。 约束限制： 只有经过类别特征列处理的列，才能进行数据补齐功能。 取值范围： true：填充 false：不填充 默认取值： false。

响应参数

状态码： 200

表 3-246 响应 Body 参数

参数	参数类型	描述
results	LIST	参数解释： 分类预测结果的列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
time_cost	JSON	参数解释： 当启动服务时，本次请求服务各阶段耗时情况。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-247 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

对指定的预测目标进行分类预测。

```
{
  "data": [
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    },
    ...
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    }
  ],
  "auto_fill": true
}
```

响应示例

状态码： 200

成功响应示例。

```
{
  "results": [
    0,
    1,
    ...
    0
  ],
  "time_cost": {
    "infer_cost_time": 233,
    "postprocess_cost_time": 13,
    "preprocess_cost_time": 12,
    "service_cost_total_time": 258
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.3.2 单条推理可解释（Shapley 值分析）

功能介绍

支持用户传入一组能够代表训练数据分布的参考数据集，以及待解释的单条推理样本，基于 Shapley 值理论计算该样本中各特征对模型预测结果的贡献程度，输出特征重要性排序。

基本原理：Shapley 值源自合作博弈论，通过计算某特征在所有可能特征组合顺序下的平均边际贡献，公平地分配模型预测结果至各个输入特征。其具备数学上的严谨性与可加性，满足：

- 贡献归因公平。
- 所有特征 Shapley 值之和等于当前样本预测值与基准值（背景数据平均预测）的差。

该方法可为任意模型提供局部可解释性，适用于复杂黑盒模型的决策归因分析。

URI

POST /shapley-value

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-248 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-249 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-250 请求 Body 参数（模型推理）

参数	是否必选	参数类型	描述
trainset_data	是	Array	参数解释： 用户传入一组能够代表训练数据分布的参考数据集，需要限制请求体的大小和条数，不然可能会出现维度爆炸。 约束限制： 参考数据集需具有以下性质： 1. 代表性：背景数据集应能代表模型训练数据的分布。这确保了模拟"缺失特征值"时（通过从背景数据抽样实现），结果符合真实场景。若解释单一样本的预测，背景数据集可以是训练数据的子集。 2. 规模：更大的背景数据集通常能提供更稳定、准确的估计。但过大的数据集会增加计算成本。实践中常从训练数据中抽取合理子集（如 10-200个样本）。 3. 情境：若需针对特定子群组（如解释"高价值客户的流失概率"），背景数据集应仅包含该子群组的数据。这能提供更具针对性的解释。 背景数据集的选择直接影响解释的可解释性与可靠性。需确保其具备代表性、计算高效性，并与解释目标的情境紧密相关。 以预测维护为例，假设训练时使用了100台设备，每台设备200条数据。 现在设备A发生了报警。则优先使用设备A的200条训练数据（符合代表性、规模和情景原则），和当前的报警数据。进行模型解释。 取值范围： 训练数据中的一组数据集，不可少于10条，超过200条。

参数	是否必选	参数类型	描述
analysis_data	是	Array	参数解释： 用户传入单条待解释样本数据。 约束限制： 需要为单条待分析数据。 取值范围： 需要为单条待分析数据。
npermutations	否	int	参数解释： 特征分析迭代次数。 约束限制： 推理耗时和特征维度（ feature dim ）、迭代次数（ npermutations ）、基础模型耗时有关。 shapley计算用时和 npermutations成正比， npermutations越大，计算用时越长。 公式如下： 最大评估次数 = npermutations * (2 * 特征数量 + 1) 需要大于1，同时为了防止时间过长限制，限制小于20，默认为10。 取值范围： [1, 20] 默认取值： 10

响应参数

状态码： 200

表 3-251 响应 Body 参数

参数	参数类型	描述
results	DICT	参数解释： 单条推理可解释（Shapley值分析）结果，results 具体内容见表3-252表3-252。feature_dim指的是特征列的数量，class_num指的是多分类任务下类别的数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
time_cost	JSON	参数解释： 当启动服务时，本次请求服务各阶段耗时情况。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-252 results 对应参数

参数	参数类型	描述
shap_values	LIST[FLOAT]	参数解释： 贡献度结果，维度为[feature_dim]，多分类情况下维度为[feature_dim,class_num]。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
base_values	LIST[FLOAT]	参数解释： 贡献度基准值，二分类情况下维度为[1]，多分类情况下维度为[class_num]。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
feature_name	list[str]	参数解释： 特征列名和贡献度对应。因为会出现请求数据特征列顺序和训练数据不一致的情况，返回体指明特征列名顺序。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
label_class	dict	参数解释： 只在分类的类别场景返回类别和对应的编码数字。 约束限制： 仅在分类场景会返回此字段。 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-253 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

对指定的预测目标进行分类预测。

```
{
  "trainset_data": [
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    },
    ...
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    }
  ],
  "analysis_data": [
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    }
  ],
  "npermutations": 10
}
```

响应示例

状态码： 200

成功响应示例。

```
{
  "results": {
    "shap_values": [...], #若为二分类/回归任务矩阵维度为（ feature_num,）， 若为多分类问题矩阵维度为（ feature_num, num_classes ）
    "base_values": [...], #若为二分类/回归任务矩阵维度为（ 1 ）， 若为多分类问题矩阵维度为（ num_classes ）
    "feature_name": ["feature_1", "feature_2", ..., "feature_n"],
    "label_class": {"class_1": 0, "class_2": 1, ...}
  },
  "time_cost": {
    "infer_cost_time": 233,
    "postprocess_cost_time": 13,
    "preprocess_cost_time": 12,
    "service_cost_total_time": 258
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.4 盘古统一编码表格预测回归大模型

3.4.4.1 数据回归预测

功能介绍

基于统一编码大模型实现表格回归预测能力，针对特定场景的回归任务，用户传入回归数据，使用模型对指定的预测目标进行回归预测。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-254 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-255 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。2.2-API Key认证响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-256 请求 Body 参数

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 待进行预测的数据，data为一个数组，数组中包含多个对象，每个对象是一组完整的特征数据。 约束限制： data为一个数组，数组中包含多个对象，每个对象是一组完整的特征数据。 待预测特征名需要与训练数据中的特征名保持一致。例如，训练数据中特征列按照feature_1、feature_2……进行命名，在调用推理接口时，特征名也需要保持相同。同时推理接口中特征数量需要与训练数据中的特征数保持一致。一组特征数据填写完成后，再填写剩余待预测数据，格式详见请求示例。 取值范围： 输入数据中的一组数据。 默认取值： 预测大模型在训练完成后，可以在训练日志页面，“模型训练”日志节点中获取推理api所用的示例数据。填写请求Body时可以参考该示例填写。 <pre>[[{"feature_1": 1, "feature_2": 1, "feature_3": 1, "feature_4": 1, "feature_5": 1, "feature_6": 1, "feature_7": 1, "feature_8": 1, "feature_9": 1, "feature_10": 1}, {"feature_1": 2, "feature_2": 2, "feature_3": 2, "feature_4": 2, "feature_5": 2, "feature_6": 2, "feature_7": 2, "feature_8": 2, "feature_9": 2, "feature_10": 2}, {"feature_1": 3, "feature_2": 3, "feature_3": 3, "feature_4": 3, "feature_5": 3, "feature_6": 3, "feature_7": 3, "feature_8": 3, "feature_9": 3, "feature_10": 3}, {"feature_1": 4, "feature_2": 4, "feature_3": 4, "feature_4": 4, "feature_5": 4, "feature_6": 4, "feature_7": 4, "feature_8": 4, "feature_9": 4, "feature_10": 4}, {"feature_1": 5, "feature_2": 5, "feature_3": 5, "feature_4": 5, "feature_5": 5, "feature_6": 5, "feature_7": 5, "feature_8": 5, "feature_9": 5, "feature_10": 5}, {"feature_1": 6, "feature_2": 6, "feature_3": 6, "feature_4": 6, "feature_5": 6, "feature_6": 6, "feature_7": 6, "feature_8": 6, "feature_9": 6, "feature_10": 6}, {"feature_1": 7, "feature_2": 7, "feature_3": 7, "feature_4": 7, "feature_5": 7, "feature_6": 7, "feature_7": 7, "feature_8": 7, "feature_9": 7, "feature_10": 7}, {"feature_1": 8, "feature_2": 8, "feature_3": 8, "feature_4": 8, "feature_5": 8, "feature_6": 8, "feature_7": 8, "feature_8": 8, "feature_9": 8, "feature_10": 8}, {"feature_1": 9, "feature_2": 9, "feature_3": 9, "feature_4": 9, "feature_5": 9, "feature_6": 9, "feature_7": 9, "feature_8": 9, "feature_9": 9, "feature_10": 9}, {"feature_1": 10, "feature_2": 10, "feature_3": 10, "feature_4": 10, "feature_5": 10, "feature_6": 10, "feature_7": 10, "feature_8": 10, "feature_9": 10, "feature_10": 10}]]</pre>
auto_fill	否	boolean	参数解释： 是否使用数据补齐功能，开启后将自动填充离散列缺失值和新类别。 约束限制： 只有经过类别特征列处理的列，才能进行数据补齐功能。 取值范围： true：填充 false：不填充 默认取值： false。

响应参数

状态码： 200

表 3-257 响应 Body 参数

参数	参数类型	描述
results	LIST	参数解释： 回归预测结果的列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
time_cost	JSON	参数解释： 当启动服务时，本次请求服务各阶段耗时情况。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-258 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

根据用户传入的回归数据，对指定的预测目标进行回归预测。

```
{
  "data": [
    {
      "feature_1": xx,
      "feature_2": xx,
```

```
...
  "feature_n": xx
},
...
{
  "feature_1": xx,
  "feature_2": xx,
  ...
  "feature_n": xx
}
],
"auto_fill": true
}
```

响应示例

状态码： 200

成功响应示例。

```
{
  "results": [
    9.89097,
    2.9097
    ...
    21.06979
  ],
  "time_cost": {
    "infer_cost_time": 233,
    "postprocess_cost_time": 13,
    "preprocess_cost_time": 12,
    "service_cost_total_time": 258
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.4.2 单条推理可解释（Shapley 值分析）

支持用户传入一组能够代表训练数据分布的参考数据集，以及待解释的单条推理样本，基于 Shapley 值理论计算该样本中各特征对模型预测结果的贡献程度，输出特征重要性排序。

接口同[单条推理可解释（Shapley值分析）](#)。

3.4.5 盘古时序异常检测大模型

功能介绍

盘古时序异常检测大模型，支持时序数据的异常检测任务，分为零样本直推部署、预训练产物以及微调产物三种不同的部署模式。

1. 零样本直推部署：已使用行业大规模时序数据进行预训练，获得可捕获正常时序模式的预置模型。在推理阶段，使用该预置模型对输入的重构误差作为异常判别依据。

2. 预训练产物（正常数据学习）：使用设备历史正常数据对时序异常检测大模型进行全量训练，使其更好地学习并重构正常数据的潜在特征分布。在推理阶段，利用模型对输入样本的重构误差作为异常判别依据：若重构效果显著下降，则表明该样本偏离正常模式，具有潜在异常趋势，从而实现对异常数据的有效检测与区分。
3. 微调产物（正/异常数据分类）：在时序异常检测大模型基础上引入分类头，并在训练过程中冻结模型的主干网络，仅使用历史中包含正常与异常样本的混合数据对新增分类头进行微调。通过此方式，将原始问题转化为针对特定时间点的二分类任务，判断其状态为正常或异常。

推理部署服务需要兼容预训练、微调两种产物的部署，每种模型调用逻辑以及输出结果有区别，需要服务内自动识别加载模型的类别，并根据API请求体输入返回推理结果。

1. 若为零样本直推模型或预训练工作流产物（正常数据学习）模型，根据指定异常分计算方式返回异常分+重构值，共有以下三种计算方式：

a. 重构误差：计算多次重构的均值，计算与真实值的偏差值记作异常分。

b. 重构方差（推荐）：计算多次重构的方差，记作异常分。

c. 重构误差+方差：异常分计算方式a)+b)，记作异常分。
2. 若为微调工作流产物（正/异常数据分类）模型，返回时序点正异常类别+重构值。

3.4.5.1 时序异常检测零样本直推

URL

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-259 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-260 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-261 请求 Body 参数

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 时序异常检测批处理数据。 约束限制： 盘古时序预测分类任务的输入数据内容，用字典承载。输入数据字典中，键对应特征列名，值为列表承载的序列数据具体内容，单条时序数据窗口长度需大于等于100。 取值范围： 输入数据中的一组数据。 默认取值： 预测大模型在训练完成后，可以在训练日志页面，“模型训练”日志节点中获取推理api所用的示例数据。填写请求Body时可以参考该示例填写。 

参数	是否必选	参数类型	描述
option	否	String	参数解释： 选择异常分计算模式，可选择模式包括["err", "var", "mix"]，分别代表["重构误差", "重构方差", "重构误差+方差"]三种计算模式，推荐使用重构方差("var")： 1. 重构误差("err")：计算多次重构的均值，计算与真实值的偏差值记作异常分。 2. 重构方差("var")：计算多次重构的方差，记作异常分。 3. 重构误差+方差("mix")：异常分计算方式a)+b)，记作异常分。 约束限制： 无 取值范围： {"err", "var", "mix"} 默认取值： var

响应参数

状态码： 200

表 3-262 响应 Body 参数

参数	参数类型	描述
data	LIST<Output Meta>	参数解释： 时序预测结果的列表。同时返回各个特征的异常分以及重构值，分别以"anomaly_score"以及"reconstruction"两个键值承载。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
time_cost	JSON	参数解释： 当启动服务时，本次请求服务各阶段耗时情况。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-263 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

```
{
  "option": "var", #可选模式包括["err", "var", "mix"]
  "data": [
    {
      "context": {
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...],
        "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...],
        "feature_2": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...],
        "feature_3": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...]
      }
    },
    {
      "context": {
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...],
        "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...],
        "feature_2": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...],
        "feature_3": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...]
      }
    },
    {...},
    {...}
  ]
}
```

响应示例

```
{
  "data": [
    {
      # 异常分
      "anomaly_score":{
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...],

```

```
    "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...],
    "feature_2": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...],
    "feature_3": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...]
  },
  # 重构结果
  "reconstruction":{
    "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...],
    "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...],
    "feature_2": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...],
    "feature_3": [ 864.1618041992188, 493.91827392578125, 252.7724151611328,...]
  }
},
{...},
{...},
{...}
],
"time_cost": {
  "infer_cost_time": "82.609 ms",
  "postprocess_cost_time": "0.29 ms",
  "preprocess_cost_time": "0.1332 ms",
  "service_cost_total_time": "84.965 ms"
}
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.5.2 时序异常检测预训练产物推理

URL

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-264 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-265 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-266 请求 Body 参数

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 时序异常检测批处理数据。 约束限制： 盘古时序预测分类任务的输入数据内容，用字典承载。输入数据字典中，键对应特征列名，值为列表承载的序列数据具体内容，单条时序数据窗口长度需大于等于100。 取值范围： 输入数据中的一组数据。 默认取值： 预测大模型在训练完成后，可以在训练日志页面，“模型训练”日志节点中获取推理api所用的示例数据。填写请求Body时可以参考该示例填写。 

参数	是否必选	参数类型	描述
option	否	String	参数解释： 选择异常分计算模式，可选择模式包括["err", "var", "mix"]，分别代表["重构误差", "重构方差", "重构误差+方差"]三种计算模式，推荐使用重构方差("var")： 1. 重构误差("err")：计算多次重构的均值，计算与真实值的偏差值记作异常分。 2. 重构方差("var")：计算多次重构的方差，记作异常分。 3. 重构误差+方差("mix")：异常分计算方式a)+b)，记作异常分。 约束限制： 无 取值范围： {"err", "var", "mix"} 默认取值： 非必填项，默认为var。

响应参数

状态码： 200

表 3-267 响应 Body 参数

参数	参数类型	描述
data	LIST<Output Meta>	参数解释： 时序预测结果的列表。同时返回各个特征的异常分以及重构值，分别以"anomaly_score"以及"reconstruction"两个键值承载。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
time_cost	JSON	参数解释： 当启动服务时，本次请求服务各阶段耗时情况。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-268 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

通过特征feature_0、feature_1、feature_2、feature_3在不同时间点的值给出其时序预测结果。

```
{
  "option": "var", #可选模式包括["err", "var", "mix"]
  "data": [
    {
      "context": {
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_2": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_3": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...]
      }
    },
    {
      "context": {
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_2": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_3": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...]
      }
    },
    {...},
    {...}
  ]
}
```

响应示例

状态码： 200

成功响应示例。

```
{
  "data": [
    {
      # 异常分
      "anomaly_score":{
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_2": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_3": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...]
      },
      # 重构结果
      "reconstruction":{
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_2": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_3": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...]
      }
    },
    {...},
    {...},
    {...}
  ],
  "time_cost": {
    "infer_cost_time": "82.609 ms",
    "postprocess_cost_time": "0.29 ms",
    "preprocess_cost_time": "0.1332 ms",
    "service_cost_total_time": "84.965 ms"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.5.3 时序异常检测微调产物推理

URL

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-269 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-270 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-271 请求 Body 参数

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 时序异常检测批处理数据 约束限制： 盘古时序预测分类任务的输入数据内容，用字典承载。输入数据字典中，键对应特征列名，值为列表承载的序列数据具体内容，单条时序数据窗口长度需大于等于100。 取值范围： 输入数据中的一组数据。 默认取值： 预测大模型在训练完成后，可以在训练日志页面，“模型训练”日志节点中获取推理api所用的示例数据。填写请求Body时可以参考该示例填写。 

响应参数

状态码： 200

表 3-272 响应 Body 参数

参数	参数类型	描述
data	LIST<Output Meta>	参数解释： 时序预测结果的列表。同时返回各个时间点的正异常类别以及各个特征的重构值，分别以"label"以及"reconstruction"两个键值承载。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
time_cost	JSON	参数解释： 当启动服务时，本次请求服务各阶段耗时情况。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-273 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

通过特征feature_0、feature_1、feature_2、feature_3在不同时间点的值给出其时序预测结果。

```
{
  "data": [
    {
      "context": {
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_2": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_3": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...]
      }
    }
  ],
}
```

```
{
  "context": {
    "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
    "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
    "feature_2": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
    "feature_3": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...]
  },
  {...},
  {...}
}
```

响应示例

状态码： 200

成功响应示例。

```
{
  "data": [
    {
      # 正异常类别
      "label": [ 0, 1, 0, 0, ...],
      # 重构结果
      "reconstruction": {
        "feature_0": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_1": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_2": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...],
        "feature_3": [ 864.1618041992188, 493.91827392578125, 252.7724151611328, ...]
      }
    },
    {...},
    {...},
    {...}
  ],
  "time_cost": {
    "infer_cost_time": "82.609 ms",
    "postprocess_cost_time": "0.29 ms",
    "preprocess_cost_time": "0.1332 ms",
    "service_cost_total_time": "84.965 ms"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.6 盘古融合推荐异常检测大模型

功能介绍

针对特定场景的异常检测任务，用户传入异常检测数据，使用模型对指定的预测目标进行异常检测预测。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-274 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-275 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。2.2-API Key认证响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-276 请求 Body 参数

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 待进行预测的数据，从输入的特征数据中检测是否存在异常值。 data为一个数组，数组中包含多个对象，每个对象是一组完整的特征数据。 约束限制： 待预测特征名需要与训练数据中的特征名保持一致。例如，训练数据中特征列按照feature_1、feature_2……进行命名，在调用推理接口时，特征名也需要保持相同。同时推理接口中特征数量需要与训练数据中的特征数保持一致。一组特征数据填写完成后填写剩余待预测数据，格式详见请求示例。 取值范围： 输入数据中的一组数据。 默认取值： 预测大模型在训练完成后，可以在训练日志页面，“模型训练”日志节点中获取推理api所用的示例数据。填写请求Body时可以参考该示例填写。 <pre>[[{"data": [{"feature_1": "Normal", "feature_2": "Normal", "feature_3": "Normal", "feature_4": "Normal", "feature_5": "Normal", "feature_6": "Normal", "feature_7": "Normal", "feature_8": "Normal", "feature_9": "Normal", "feature_10": "Normal", "feature_11": "Normal", "feature_12": "Normal", "feature_13": "Normal", "feature_14": "Normal", "feature_15": "Normal", "feature_16": "Normal", "feature_17": "Normal", "feature_18": "Normal", "feature_19": "Normal", "feature_20": "Normal", "feature_21": "Normal", "feature_22": "Normal", "feature_23": "Normal", "feature_24": "Normal", "feature_25": "Normal", "feature_26": "Normal", "feature_27": "Normal", "feature_28": "Normal", "feature_29": "Normal", "feature_30": "Normal", "feature_31": "Normal", "feature_32": "Normal", "feature_33": "Normal", "feature_34": "Normal", "feature_35": "Normal", "feature_36": "Normal", "feature_37": "Normal", "feature_38": "Normal", "feature_39": "Normal", "feature_40": "Normal", "feature_41": "Normal", "feature_42": "Normal", "feature_43": "Normal", "feature_44": "Normal", "feature_45": "Normal", "feature_46": "Normal", "feature_47": "Normal", "feature_48": "Normal", "feature_49": "Normal", "feature_50": "Normal", "feature_51": "Normal", "feature_52": "Normal", "feature_53": "Normal", "feature_54": "Normal", "feature_55": "Normal", "feature_56": "Normal", "feature_57": "Normal", "feature_58": "Normal", "feature_59": "Normal", "feature_60": "Normal", "feature_61": "Normal", "feature_62": "Normal", "feature_63": "Normal", "feature_64": "Normal", "feature_65": "Normal", "feature_66": "Normal", "feature_67": "Normal", "feature_68": "Normal", "feature_69": "Normal", "feature_70": "Normal", "feature_71": "Normal", "feature_72": "Normal", "feature_73": "Normal", "feature_74": "Normal", "feature_75": "Normal", "feature_76": "Normal", "feature_77": "Normal", "feature_78": "Normal", "feature_79": "Normal", "feature_80": "Normal", "feature_81": "Normal", "feature_82": "Normal", "feature_83": "Normal", "feature_84": "Normal", "feature_85": "Normal", "feature_86": "Normal", "feature_87": "Normal", "feature_88": "Normal", "feature_89": "Normal", "feature_90": "Normal", "feature_91": "Normal", "feature_92": "Normal", "feature_93": "Normal", "feature_94": "Normal", "feature_95": "Normal", "feature_96": "Normal", "feature_97": "Normal", "feature_98": "Normal", "feature_99": "Normal", "feature_100": "Normal"}], "label": "Normal"}, {"feature_1": "Abnormal", "feature_2": "Abnormal", "feature_3": "Abnormal", "feature_4": "Abnormal", "feature_5": "Abnormal", "feature_6": "Abnormal", "feature_7": "Abnormal", "feature_8": "Abnormal", "feature_9": "Abnormal", "feature_10": "Abnormal", "feature_11": "Abnormal", "feature_12": "Abnormal", "feature_13": "Abnormal", "feature_14": "Abnormal", "feature_15": "Abnormal", "feature_16": "Abnormal", "feature_17": "Abnormal", "feature_18": "Abnormal", "feature_19": "Abnormal", "feature_20": "Abnormal", "feature_21": "Abnormal", "feature_22": "Abnormal", "feature_23": "Abnormal", "feature_24": "Abnormal", "feature_25": "Abnormal", "feature_26": "Abnormal", "feature_27": "Abnormal", "feature_28": "Abnormal", "feature_29": "Abnormal", "feature_30": "Abnormal", "feature_31": "Abnormal", "feature_32": "Abnormal", "feature_33": "Abnormal", "feature_34": "Abnormal", "feature_35": "Abnormal", "feature_36": "Abnormal", "feature_37": "Abnormal", "feature_38": "Abnormal", "feature_39": "Abnormal", "feature_40": "Abnormal", "feature_41": "Abnormal", "feature_42": "Abnormal", "feature_43": "Abnormal", "feature_44": "Abnormal", "feature_45": "Abnormal", "feature_46": "Abnormal", "feature_47": "Abnormal", "feature_48": "Abnormal", "feature_49": "Abnormal", "feature_50": "Abnormal", "feature_51": "Abnormal", "feature_52": "Abnormal", "feature_53": "Abnormal", "feature_54": "Abnormal", "feature_55": "Abnormal", "feature_56": "Abnormal", "feature_57": "Abnormal", "feature_58": "Abnormal", "feature_59": "Abnormal", "feature_60": "Abnormal", "feature_61": "Abnormal", "feature_62": "Abnormal", "feature_63": "Abnormal", "feature_64": "Abnormal", "feature_65": "Abnormal", "feature_66": "Abnormal", "feature_67": "Abnormal", "feature_68": "Abnormal", "feature_69": "Abnormal", "feature_70": "Abnormal", "feature_71": "Abnormal", "feature_72": "Abnormal", "feature_73": "Abnormal", "feature_74": "Abnormal", "feature_75": "Abnormal", "feature_76": "Abnormal", "feature_77": "Abnormal", "feature_78": "Abnormal", "feature_79": "Abnormal", "feature_80": "Abnormal", "feature_81": "Abnormal", "feature_82": "Abnormal", "feature_83": "Abnormal", "feature_84": "Abnormal", "feature_85": "Abnormal", "feature_86": "Abnormal", "feature_87": "Abnormal", "feature_88": "Abnormal", "feature_89": "Abnormal", "feature_90": "Abnormal", "feature_91": "Abnormal", "feature_92": "Abnormal", "feature_93": "Abnormal", "feature_94": "Abnormal", "feature_95": "Abnormal", "feature_96": "Abnormal", "feature_97": "Abnormal", "feature_98": "Abnormal", "feature_99": "Abnormal", "feature_100": "Abnormal"}], "label": "Abnormal"}]]</pre>

参数	是否必选	参数类型	描述
model_name	是	String	参数解释： 推理模型算法，由用户指定使用哪种算法进行推理。 约束限制： 推理使用的模型，需在模型训练时训练过。 取值范围： [autoencoder, lunar, knn, iforest, loda, ocsvm] • autoencoder表示自动编码器算法。 • lunar表示图神经网络算法。 • knn表示k最近邻算法。 • iforest表示孤立森林算法。 • loda表示Loda算法。 • ocsvm表示单类支持向量机算法。 默认取值： 无

响应参数

状态码： 200

表 3-277 响应 Body 参数

参数	参数类型	描述
model_name	String	参数解释： 预测模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
result	Object	参数解释： 预测结果信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
scores	Object	参数解释： 预测结果对应的异常分，每条结果为一个List，List中的元素分别表示预测数据对应的异常分。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
time_cost	Array	参数解释： 推理耗时 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-278 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

对指定的预测目标进行异常检测预测。

```
{
  "data": [
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    },
    ...
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    }
  ],
  "model_name": "knn"
}
```

响应示例

状态码： 200

成功响应示例。

```
{
  "model_name": "knn",
  "result": [
    "0",
    "1",
    ...
    "0"
  ],
  "scores": [
    0.600346565246582,
    0.6861363649368286,
    ...,
    0.2797144651412964
  ],
  "time_cost": {
    "infer_cost_time": 20.807,
    "postprocess_cost_time": 0,
    "preprocess_cost_time": 1.641,
    "service_cost_total_time": 24.644
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.7 盘古融合推荐分类大模型

此章节内容适用于盘古融合推荐分类大模型和盘古极简模式融合推荐分类大模型。

3.4.7.1 数据分类预测

功能介绍

针对特定场景的分类任务，用户传入分类数据，使用模型对指定的预测目标进行分类预测。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-279 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-280 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。2.2-API Key认证响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-281 请求 Body 参数

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 待进行预测的数据，data为一个数组，数组中包含多个对象，每个对象是一组完整的特征数据。 约束限制： 待预测特征名需要与训练数据中的特征名保持一致。例如，训练数据中特征列按照feature_1、feature_2……进行命名，在调用推理接口时，特征名也需要保持相同。同时推理接口中特征数量需要与训练数据中的特征数保持一致。一组特征数据填写完成后，再填写剩余待预测数据，格式详见请求示例。 取值范围： 输入数据中的一组数据。 默认取值： 预测大模型在训练完成后，可以在训练日志页面，“模型训练”日志节点中获取推理api所用的示例数据。填写请求Body时可以参考该示例填写。 
predict_proba	否	boolean	参数解释： 是否输出置信度。 约束限制： 无 取值范围： • true：输出 • false：不输出 默认取值： false。

参数	是否必选	参数类型	描述
auto_fill	否	boolean	参数解释： 是否使用数据补齐功能，开启后将自动填充离散列缺失值和新类别。 约束限制： 只有经过类别特征列处理的列，才能进行数据补齐功能。 取值范围： • true：填充 • false：不填充 默认取值： false。

响应参数

状态码： 200

表 3-282 响应 Body 参数

参数	参数类型	描述
result	Object	参数解释： 预测结果信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
pred_proba	Array	参数解释： 预测结果对应的置信度，每条结果为一个Dict，Dict的键值对分别表示预测结果、置信度。 约束限制： 请求字段predict_proba配置为true时，响应body才返回pred_proba子项，否则无该子项。 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-283 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息

请求示例

对指定的预测目标进行分类预测。

```
{
  "data": [
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    },
    ...
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    }
  ],
  "predict_proba": true,
  "auto_fill": true
}
```

响应示例

状态码： 200

成功响应示例。

```
{
  "result": [
    "0",
    "1",
    ...
    "0"
  ],
  "pred_proba": [
    {
      "0" : 0.791,
      "1" : 0.209
    },
    {
      "0" : 0.103,
      "1" : 0.897
    },
    ...
    {
      "0" : 0.665,
      "1" : 0.335
    }
  ]
}
```


状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.7.2 排列特征重要性

功能介绍

支持用户传入一批数据样本，并据此计算各个特征的排列重要性（permutation importance）。

基本原理为，对输入的数据样本，首先完成一次推理，将评估指标作为baseline。将数据的某一特征在行数据之间随机混洗，评估预测效果，并计算指标的下降值，并以此评估特征的重要性。当混洗某一列特征，导致预测效果与baseline有较大下降时，则说明此列特征重要性较高。此处使用accuracy作为分类任务的评估指标。

注意：输入的数据需包含预测目标列的真值，以便计算预测效果指标。

另外，融合推荐分类预测大模型提供两种特征重要性，分别为模型权重特征重要性和排列特征重要性，对两种特征重要性的详细说明参见《用户指南》“使用API调用预测大模型 > 排列特征重要性”部分。

注意：极简模式不提供排列特征重要性接口，即极简模式的模型不可调用该接口。

URI

POST /perm-feat-importance

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-284 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-285 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-286 请求 Body 参数

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 含义和 表3-281 中的data参数相同。 约束限制： 排列特征重要性接口除提供各特征名及特征值外，还需提供预测目标列的列名及其真值（即示例中的target项），且数据数量大于1000，以便准确计算预测效果指标。 取值范围： 输入数据中的一组数据。 默认取值： 不涉及

参数	是否必选	参数类型	描述
fi_args	是	Dict	参数解释： 特征重要性的参数，包含 q_type、num_shuffle_sets、sample_num三个字段。 约束限制： 不涉及 取值范围： - q_type，必填，String类型，代表问题类型，分类模型需填写“classification”。 - num_shuffle_sets，非必填，Integer类型，代表采样混洗次数，越大则结果越准确，但耗时更高。要求>=1，建议>=5，默认值为1。 - sample_num，非必填，Integer类型，代表单次采样混洗数据量，越大则结果越准确，但耗时更高。要求>=1000，建议>=3500，默认值为1000。当用户不传入此参数，或大于data数量时，直接使用全部数据，不进行采样。 默认取值： num_shuffle_sets默认为1，sample_num默认为1000。

响应参数

状态码： 200

表 3-287 响应 Body 参数

参数	参数类型	描述
feature_importance	Array	参数解释： 降序排列的各特征重要性，每项为[特征名, 特征重要性分值]。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cost_time	Long	参数解释： 计算耗时。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-288 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

根据用户传入的数据样本，计算各个特征的排列重要性。

```
{
  "data": [
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx,
      "target": 0,
    },
    ...
    {
      "feature_1": xx,
      "feature_2": xx,
```

```
...
    "feature_n": xx,
    "target": 1
  }
],
"fi_args":{
  "q_type": "classification",
  "num_shuffle_sets": 1,
  "sample_num": 1000
}
}
```

此处data列表的长度至少为1000，建议通过以下代码根据csv文件生成请求体（DATA_NUM为从csv文件中采样数据的数量）：

```
import random
import json
import pandas as pd

ENCODING_TYPE = "utf-8"
DATA_NUM = 1200

data_path = "path/to/xxx.csv"
df = pd.read_csv(data_path, encoding=ENCODING_TYPE)
data_list = df.to_dict("records")
data_list = random.sample(data_list, DATA_NUM)
request_data = {
  "data": data_list,
  "fi_args": {
    "q_type": "classification",
    "num_shuffle_sets": 1,
    "sample_num": 1000,
  }
}
request_str = json.dumps(request_data)
print(request_str)
```

响应示例

状态码： 200

成功响应示例。

```
{
  "cost_time": 4.322,
  "feature_importance": [
    ["feature_2", 0.15]
    ...
    ["feature_17", 0.001]
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.7.3 单条推理可解释（Shapley 值分析）

支持用户传入一组能够代表训练数据分布的参考数据集，以及待解释的单条推理样本，基于 Shapley 值理论计算该样本中各特征对模型预测结果的贡献程度，输出特征重要性排序。

接口同[单条推理可解释（Shapley值分析）](#)。

3.4.8 盘古融合推荐回归大模型

此章节内容适用于盘古融合推荐回归大模型和盘古极简模式融合推荐回归大模型。

3.4.8.1 数据回归预测

功能介绍

针对特定场景的回归任务，用户传入回归数据，使用模型对指定的预测目标进行回归预测。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-289 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-290 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-291 请求 Body 参数

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 待进行预测的数据，data为一个数组，数组中包含多个对象，每个对象是一组完整的特征数据。 约束限制： 待预测特征名需要与训练数据中的特征名保持一致。例如，训练数据中特征列按照feature_1、feature_2……进行命名，在调用推理接口时，特征名也需要保持相同。同时推理接口中特征数量需要与训练数据中的特征数保持一致。一组特征数据填写完成后，再填写剩余待预测数据，格式详见请求示例。 取值范围： 输入数据中的一组数据。 默认取值： 预测大模型在训练完成后，可以在训练日志页面，“模型训练”日志节点中获取推理api所用的示例数据。填写请求Body时可以参考该示例填写。 
auto_fill	否	boolean	参数解释： 是否使用数据补齐功能，开启后将自动填充离散列缺失值和新类别。 约束限制： 只有经过类别特征列处理的列，才能进行数据补齐功能。 取值范围： • true：填充 • false：不填充 默认取值： false。

响应参数

状态码： 200

表 3-292 响应 Body 参数

参数	参数类型	描述
result	Object	预测结果信息。

状态码： 400

表 3-293 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

根据用户传入的回归数据，对指定的预测目标进行回归预测。

```
{
  "data": [
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    },
    ...
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    }
  ],
  "auto_fill": true
}
```

响应示例

状态码： 200

成功响应示例。

```
{
  "result": [
    "prediction_1",
    ...
    "prediction_n"
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.8.2 排列特征重要性

功能介绍

支持用户传入一批数据样本，并据此计算各个特征的排列重要性（permutation importance）。

基本原理为，对输入的数据样本，首先完成一次推理，将评估指标作为baseline。将数据的某一特征在行数据之间随机混洗，评估预测效果，并计算指标的下降值，并以此评估特征的重要性。当混洗某一列特征，导致预测效果与baseline有较大下降时，则说明此列特征重要性较高。此处使用r2_score作为回归任务的评估指标。

注意：输入的数据需包含预测目标列的真值，以便计算预测效果指标。

另外，融合推荐回归预测大模型提供两种特征重要性，分别为模型权重特征重要性和排列特征重要性，对两种特征重要性的详细说明参见《用户指南》“使用API调用预测大模型 > 排列特征重要性”部分。

注意：极简模式不提供排列特征重要性接口，即极简模式的模型不可调用该接口。

URI

POST /perm-feat-importance

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-294 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-295 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-296 请求 Body 参数

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 含义和表3-291中的data参数相同。 约束限制： 排列特征重要性接口除提供各特征名及特征值外，还需提供预测目标列的列名及其真值（即示例中的target项），以便计算预测效果指标。 取值范围： 输入数据中的一组数据。 默认取值： 不涉及
fi_args	是	Dict	参数解释： 特征重要性的参数，包含 q_type、num_shuffle_sets、sample_num三个字段。 约束限制： 不涉及 取值范围： • q_type，必填，String类型，代表问题类型，回归模型需填写"regression" • num_shuffle_sets，非必填，Integer类型，代表采样混洗次数，越大则结果越准确，但耗时更高。要求>=1，建议>=5，默认值为1。 • sample_num，非必填，Integer类型，代表单次采样混洗数据量，越大则结果越准确，但耗时更高。要求>=1000，建议>=3500，默认值为1000。当用户不传入此参数，或大于data数量时，直接使用全部数据，不进行采样。 默认取值： num_shuffle_sets默认为1，sample_num默认为1000。

响应参数

状态码： 200

表 3-297 响应 Body 参数

参数	参数类型	描述
feature_importance	Array	参数解释： 降序排列的各特征重要性，每项为[特征名, 特征重要性分值]。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cost_time	Long	参数解释： 计算耗时。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-298 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

根据用户传入的数据样本，计算各个特征的排列重要性。

```
{
  "data": [
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx,
    }
  ]
}
```

```
    "target": 0,
  },
  ...
  {
    "feature_1": xx,
    "feature_2": xx,
    ...
    "feature_n": xx,
    "target": 1
  }
],
"fi_args":{
  "q_type": "regression",
  "num_shuffle_sets": 1,
  "sample_num": 1000
}
}
```

此处data列表的长度至少为1000，建议通过以下代码根据csv文件生成请求体（DATA_NUM为从csv文件中采样数据的数量）：

```
import random
import json
import pandas as pd

ENCODING_TYPE = "utf-8"
DATA_NUM = 1200

data_path = "path/to/xxx.csv"
df = pd.read_csv(data_path, encoding=ENCODING_TYPE)
data_list = df.to_dict("records")
data_list = random.sample(data_list, DATA_NUM)
request_data = {
  "data": data_list,
  "fi_args": {
    "q_type": "regression",
    "num_shuffle_sets": 1,
    "sample_num": 1000,
  }
}
request_str = json.dumps(request_data)
print(request_str)
```

响应示例

状态码： 200

成功响应示例。

```
{
  "cost_time": 4.322,
  "feature_importance": [
    ["feature_2", 0.15]
    ...
    ["feature_17", 0.001]
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.8.3 单条推理可解释（Shapley 值分析）

支持用户传入一组能够代表训练数据分布的参考数据集，以及待解释的单条推理样本，基于 Shapley 值理论计算该样本中各特征对模型预测结果的贡献程度，输出特征重要性排序。

接口同[单条推理可解释（Shapley值分析）](#)。

3.4.9 结构化数据预测模型

功能介绍

结构化数据预测是为了收编工业智能中枢历史预测功能，适用场景同回归模型、分类模型。

URI

POST /v1/predict

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-299 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-300 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。2.2-API Key认证响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-301 请求 Body 参数

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 待进行预测的数据，data为一个数组，数组中包含多个对象，每个对象是一组完整的特征数据。 约束限制： 待预测特征名需要与训练数据中的特征名保持一致。例如，训练数据中特征列按照feature_1、feature_2……进行命名，在调用推理接口时，特征名也需要保持一致。同时推理接口中特征数量需要与训练数据中的特征数保持一致。一组特征数据填写完成后，再填写剩余待预测数据，格式详见请求示例。 取值范围： 输入数据中的一组数据。 默认取值： 预测大模型在训练完成后，可以在训练日志页面，“模型训练”日志节点中获取推理api所用的示例格式，即日志中“request_demo”中的“json”部分。填写请求Body时可以参考该示例填写。

响应参数

状态码: 200

表 3-302 响应 Body 参数

参数	参数类型	描述
result	Object	参数解释： 预测结果信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-303 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

根据某个商品的不同特征做未来销量预测。

```
{
  "data": [
    {
      "feature_1": "xx",
      "feature_2": "xx",
      ...
      "feature_n": "xx"
    },
    ...
    {
      "feature_1": "xx",
      "feature_2": "xx",
      ...
      "feature_n": "xx"
    }
  ]
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "result": [
    "prediction_1",
    ...
    "prediction_n"
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.10 智慧配煤模型

基于人工智能的技术发展，通过收集现阶段生产过程中收集的原料煤相关数据、入炉煤相关数据、焦炭相关数据以及焦炉工艺数据等生产数据，基于知识+AI算法构建焦炭

质量预测模型，预测原料煤配比对应的焦炭质量。同时，基于优化算法可以实现优化的配煤比例的寻找，为配煤工艺师提供有效参考。

通过 workflow 部署的在线服务主要包含如下两个功能：

- **焦炭质量预测：**可以预测入炉煤和焦炭的质量指标。
- **配煤比例优化：**在出口焦炭质量各指标满足目标要求的条件下，得到原料煤的成本最低的原料煤配比，有效的为企业降低成本提高生产利润。

3.4.10.1 焦炭质量预测

功能介绍

预测入炉煤和焦炭的质量指标。

URI

- **同步调用**
POST /v1/predict
- **异步调用**
 - 添加任务：POST /tasks
 - 查询任务详情：GET /tasks/<task_id>
 - 调用方式：先调用添加任务接口（url为“/tasks”），后台会立即返回一个 task_id，任务会在后台异步执行，执行完后会保存结果。客户可利用添加任务返回的“task_id”调用查询任务详情接口（url为“/tasks/<task_id>”）随时查询任务状态，当任务状态为“finished”时，说明任务执行完成，就可从响应中的“result”拿到结果。建议焦炭质量预测功能调用同步接口，配煤比例优化调用异步接口。

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-304 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-305 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-306 请求 Body 参数

参数	是否必选	参数类型	描述
meta	否	Object	参数解释：API调用配置项，如表3-307所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
raw_coal_data	是	Array	参数解释：原料煤相关信息，具体字段如表3-308所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
coke_process_param	是	Object	参数解释：焦炉工况信息，具体字段如表3-309所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-307 API 调用配置项说明

参数	是否必选	参数类型	说明
custom_name	否	String	参数解释：模型标识，用于指定用户通过工作流训练得到的模型。 约束限制：仅在异步调用场景下为必填参数，当前仅支持固定值“v1”。 取值范围：v1 默认取值：不涉及
function	否	String	参数解释：<异步调用功能标识符，用于指定执行的具体功能类型。 约束限制：仅在异步调用场景下为必填参数。 取值范围：当前仅支持“predict”和“optimize”。“predict”表示焦炭质量预测功能，“optimize”表示配煤比例优化功能。 默认取值：不涉及

表 3-308 原料煤相关信息说明

参数	是否必选	参数类型	说明
name	是	String	参数解释：原料煤名称。 约束限制：不涉及 取值范围：不涉及 默认取值：“ ”
category	否	String	参数解释：原料煤所属种类。 约束限制：不涉及 取值范围：不涉及 默认取值：“ ”
stock	否	Number	参数解释：原料煤库存数量。 约束限制：不涉及 取值范围：建议 ≥ 0 默认取值：9999
manual_ratio	是	Number	参数解释：人工设定的配煤比例。 约束限制：填写为小数形式，用于约束该原料煤在配煤方案中的固定占比。 取值范围：[0,1] 默认取值：0
min_ratio	否	Number	参数解释：原料煤配煤最小比例要求。 约束限制：不涉及 取值范围：[0, 100] 默认取值：0
max_ratio	否	Number	参数解释：原料煤配煤最大比例要求。 约束限制：不涉及 取值范围：[0, 100] 默认取值：100
price	是	Number	参数解释：原料煤价格。 约束限制：不涉及 取值范围：不涉及 默认取值：0
ad	是	Number	参数解释：原料煤灰分。 约束限制：不涉及 取值范围：[1, 50] 默认取值：不涉及

参数	是否必选	参数类型	说明
vdaf	是	Number	参数解释：原料煤挥发分。 约束限制：不涉及 取值范围：[1, 45] 默认取值：不涉及
std	是	Number	参数解释：原料煤硫分。 约束限制：不涉及 取值范围：[0.01, 5] 默认取值：不涉及
g	是	Number	参数解释：原料煤粘结指数 G 值。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
x	是	Number	参数解释：原料煤最大收缩度 X 值。 约束限制：不涉及 取值范围：[0, 60] 默认取值：-10000（占位使用，建议实际调用时务必传入合法值）
y	是	Number	参数解释：原料煤最大胶质层厚度 Y 值。 约束限制：不涉及 取值范围：[0, 45]。 默认取值：不涉及
single_cri	是	Number	参数解释：单种煤炼焦 CRI 指标。 约束限制：不涉及 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
single_csr	是	Number	参数解释：单种煤炼焦 CSR 指标。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
re_min	是	Number	参数解释：原料煤随机反射率下限。 约束限制：输入值必须为数字，且不大于随机反射率上限 re_max。 取值范围：[0, 10] 默认取值：-10000（作为无效/未赋值占位值）

参数	是否必选	参数类型	说明
re_max	是	Number	参数解释：原料煤随机反射率上限。 约束限制：输入值必须为数字，且不小于随机反射率下限 re_min。 取值范围：[0, 10] 默认取值：-10000（作为无效/未赋值占位值）
rmax	是	Number	参数解释：原料煤最大反射率。 约束限制：不涉及 取值范围：[0, 10] 默认取值：不涉及
re_s	是	Number	参数解释：原料煤反射率标准偏差。 约束限制：不涉及 取值范围：[0, 1] 默认取值：-10000（作为无效/未赋值占位值）
active	是	Number	参数解释：原料煤活性率。 约束限制：不涉及 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
rran1	是	Number	参数解释：煤岩区间 1 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran2	是	Number	参数解释：煤岩区间 2 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran3	是	Number	参数解释：煤岩区间 3 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran4	是	Number	参数解释：煤岩区间 4 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及

参数	是否必选	参数类型	说明
rran5	是	Number	参数解释：煤岩区间 5 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran6	是	Number	参数解释：煤岩区间 6 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran7	是	Number	参数解释：煤岩区间 7 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran8	是	Number	参数解释：煤岩区间 8 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran9	是	Number	参数解释：煤岩区间 9 所占比例。 约束限制：输入值必须为数字 取值范围：[0, 100] 默认取值：不涉及
rran10	是	Number	参数解释：煤岩区间 10 所占比例。 约束限制：输入值必须为数字 取值范围：[0, 100] 默认取值：不涉及
sio2	是	Number	参数解释：原料煤灰成分 SiO ₂ 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大大于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
al2o3	是	Number	参数解释：原料煤灰成分 Al ₂ O ₃ 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大大于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）

参数	是否必选	参数类型	说明
fe2o3	是	Number	参数解释：原料煤灰成分 Fe_2O_3 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
tio2	是	Number	参数解释：原料煤灰成分 TiO_2 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
k2o	是	Number	参数解释：原料煤灰成分 K_2O 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
na2o	是	Number	参数解释：原料煤灰成分 Na_2O 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
cao	是	Number	参数解释：原料煤灰成分 CaO 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
mgo	是	Number	参数解释：原料煤灰成分 MgO 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）

参数	是否必选	参数类型	说明
mno	是	Number	参数解释：原料煤灰成分 MnO 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
bao	是	Number	参数解释：原料煤灰成分 BaO 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
t_softening	是	Number	参数解释：原料煤初始软化温度（℃）。 约束限制：不涉及 取值范围：不涉及 默认取值：-10000（作为无效/未赋值占位值）
t_max fluidity	是	Number	参数解释：原料煤最大流动温度（℃）。 约束限制：不涉及 取值范围：不涉及 默认取值：-10000（作为无效/未赋值占位值）
t_final	是	Number	参数解释：原料煤最后流动温度（℃）。 约束限制：不涉及 取值范围：不涉及 默认取值：-10000（作为无效/未赋值占位值）
t_resolidification	是	Number	参数解释：原料煤固化温度（℃）。 约束限制：不涉及 取值范围：不涉及 默认取值：-10000（作为无效/未赋值占位值）
t_interval	是	Number	参数解释：原料煤塑性范围（℃）。 约束限制：不涉及 取值范围：不涉及 默认取值：-10000（作为无效/未赋值占位值）

参数	是否必选	参数类型	说明
mf	是	Number	参数解释：原料煤最大吉氏流动度（ddpm）。 约束限制：不涉及 取值范围：不涉及 默认取值：-10000（作为无效/未赋值占位值）

表 3-309 工艺相关信息说明

参数	是否必选	参数类型	说明
temperature	是	Number	参数解释：焦炉机焦侧温度。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
coking_time	是	Number	参数解释：结焦时间。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

响应参数

状态码： 200

表 3-310 焦炭质量预测响应

参数	参数类型	说明
data	Object	参数解释：API响应结果，具体如 表 焦炭质量预测处理结果 所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-311 焦炭质量预测处理结果

参数	参数类型	说明
resp_data	Object	参数解释：焦炭质量预测响应，具体如表3-312所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-312 焦炭质量预测响应参数

参数	参数类型	说明
price	String	参数解释：配合煤的价格预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
ratio	String	参数解释：各原料煤的比例。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
feed_coal_result	Object	参数解释：当前配比配合煤的各指标预测值，具体如表3-313所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
coke_predict_result	Object	参数解释：当前配比焦炭质量预测值，具体如表3-314所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-313 配合煤指标预测值

参数	参数类型	说明
ad	Number	参数解释：配合煤的灰分预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

参数	参数类型	说明
vdaf	Number	参数解释：配合煤的挥发分预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
std	Number	参数解释：配合煤的硫分预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
g	Number	参数解释：配合煤的粘结指数G值预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
x	Number	参数解释：配合煤的最大收缩度X值预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
y	Number	参数解释：配合煤的最大胶质层厚度Y值预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-314 焦炭质量预测值

参数	参数类型	说明
ad	Number	参数解释：焦炭的灰分预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
vdaf	Number	参数解释：焦炭的挥发分预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

参数	参数类型	说明
std	Number	参数解释：焦炭的硫分预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
m10	Number	参数解释：焦炭的耐磨强度M10预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
m25	Number	参数解释：焦炭的抗碎强度M25预测值，与M40二选一即可。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
m40	Number	参数解释：焦炭的抗碎强度M40预测值，与M25二选一即可。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
cri	Number	参数解释：焦炭的反应性CRI预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
csr	Number	参数解释：焦炭的反应后强度CSR预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-315 添加任务响应

参数	参数类型	说明
task_id	String	参数解释：任务ID，可用于查询任务详情。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-316 异步查询任务详情响应

参数	参数类型	说明
status	String	参数解释：任务状态。 约束限制：不涉及 取值范围： - waiting：任务正在排队，等待调度。 - running：任务当前正在被处理。 - failed：任务失败；finished：任务正常结束。 默认取值：不涉及
result	Json	参数解释：异步处理结果，当状态为“finished”时存在。具体如 表 焦炭质量预测响应 所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

状态码： 400

表 3-317 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

```
{
  "meta": {
    "custom_name": "v1",
    "function": "predict"
  },
  "raw_coal_data": [
    {
      "name": "test1",
      "category": "OTHER",
      "stock": 0,
      "manual_ratio": 1.0,
      "min_ratio": 0,
      "max_ratio": 35,
      "price": 4011,
      "ad": 9.5,
      "vdaf": 22.5,
      "std": 0.59,
      "g": 91,
      "x": -10000,
      "y": 18,
      "single_cri": -10000,
    }
  ]
}
```

```
"single_csr": 57.77,  
"re_min": -10000,  
"re_max": -10000,  
"rmax": 0.968,  
"re_s": -10000,  
"active": -10000,  
"rran1": 0,  
"rran2": 11.3,  
"rran3": 18.8,  
"rran4": 11.8,  
"rran5": 35.8,  
"rran6": 22.3,  
"rran7": 0,  
"rran8": 0,  
"rran9": 0,  
"rran10": 0,  
"sio2": -10000,  
"al2o3": -10000,  
"fe2o3": -10000,  
"tio2": -10000,  
"k2o": -10000,  
"na2o": -10000,  
"cao": -10000,  
"mgo": -10000,  
"mno": -10000,  
"bao": -10000,  
"t_softening": 0,  
"t_max_fluidity": 0,  
"t_final": 0,  
"t_resolidification": 0,  
"t_interval": 0,  
"mf": -10000  
},  
{  
  "name": "test2",  
  "category": "OTHER",  
  "stock": 0,  
  "manual_ratio": 0.0,  
  "min_ratio": 0,  
  "max_ratio": 35,  
  "price": 2700,  
  "ad": 9.8,  
  "vdaf": 23.51,  
  "std": 0.52,  
  "g": 79,  
  "x": -10000,  
  "y": 14,  
  "single_cri": -10000,  
  "single_csr": 65.41,  
  "re_min": -10000,  
  "re_max": -10000,  
  "rmax": 1.244,  
  "re_s": -10000,  
  "active": -10000,  
  "rran1": 0,  
  "rran2": 0,  
  "rran3": 0,  
  "rran4": 4.7,  
  "rran5": 37.7,  
  "rran6": 42.4,  
  "rran7": 13.5,  
  "rran8": 0,  
  "rran9": 0,  
  "rran10": 0,  
  "sio2": -10000,  
  "al2o3": -10000,  
  "fe2o3": -10000,  
  "tio2": -10000,  
  "k2o": -10000,
```

```
    "na2o": -10000,
    "cao": -10000,
    "mgo": -10000,
    "mno": -10000,
    "bao": -10000,
    "t_softening": 0,
    "t_max_fluidity": 0,
    "t_final": 0,
    "t_resolidification": 0,
    "t_interval": 0,
    "mf": -10000
  },
  {
    "name": "test3",
    "category": "OTHER",
    "stock": 0,
    "manual_ratio": 0.0,
    "min_ratio": 0,
    "max_ratio": 35,
    "price": 2210,
    "ad": 10.11,
    "vdaf": 21.24,
    "std": 1.42,
    "g": 90,
    "x": -10000,
    "y": 15,
    "single_cri": -10000,
    "single_csr": 77.13,
    "re_min": -10000,
    "re_max": -10000,
    "rmax": 1.463,
    "re_s": -10000,
    "active": -10000,
    "rran1": 0,
    "rran2": 0,
    "rran3": 0,
    "rran4": 0,
    "rran5": 9.6,
    "rran6": 52.6,
    "rran7": 29.2,
    "rran8": 8.6,
    "rran9": 0,
    "rran10": 0,
    "sio2": -10000,
    "al2o3": -10000,
    "fe2o3": -10000,
    "tio2": -10000,
    "k2o": -10000,
    "na2o": -10000,
    "cao": -10000,
    "mgo": -10000,
    "mno": -10000,
    "bao": -10000,
    "t_softening": 0,
    "t_max_fluidity": 0,
    "t_final": 0,
    "t_resolidification": 0,
    "t_interval": 0,
    "mf": -10000
  }
],
"coke_process_param": {
  "temperature": 1240,
  "coking_time": 19
}
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "data": {
    "resp_data": {
      "price": 4011.0,
      "ratio": [
        1.0,
        0.0,
        0.0
      ],
      "feed_coal_result": {
        "ad": 9.5,
        "vdaf": 22.5,
        "std": 0.59,
        "g": 91.0,
        "x": 0.0,
        "y": 18.0
      },
      "coke_predict_result": {
        "ad": 11.878070199966555,
        "vdaf": 0.9579212389306929,
        "std": 0.5434969089409402,
        "m10": 5.912459187920421,
        "m25": 82.46039661687459,
        "m40": 82.09146005217167,
        "cri": 23.396397992562335,
        "csr": 71.74333499193743
      },
      "confidence_level": -1
    }
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.10.2 配煤比例优化

功能介绍

在出口焦炭质量各指标满足目标要求的条件下，得到原料煤的成本最低的原料煤配比，有效的为企业降低成本提高生产利润。

URI

- 同步调用
POST /v1/optimize
- 异步调用
 - 添加任务：POST /tasks

- 查询任务详情：GET /tasks/<task_id>
- 调用方式：先调用添加任务接口（url为“/tasks”），后台会立即返回一个 task_id，任务会在后台异步执行，执行完后会保存结果。客户可利用添加任务返回的“task_id”调用查询任务详情接口（url为“/tasks/<task_id>”）随时查询任务状态，当任务状态为“finished”时，说明任务执行完成，就可从响应中的“result”拿到结果。建议焦炭质量预测功能调用同步接口，配煤比例优化调用异步接口。

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-318 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-319 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-320 请求 Body 参数

参数	是否必选	参数类型	说明
meta	否	Object	参数解释： API调用功能配置，如 表 3-321 所示。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
raw_coal_data	是	Object	参数解释： 原料煤相关信息，如 表3-322 所示。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
coke_bound	是	Object	参数解释：焦炭指标要求相关信息，如表3-323所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
feed_coal_bound	是	Object	参数解释：配合煤指标要求相关信息，如表3-324所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
constraint	是	Object	参数解释：其他扩展项信息，如表3-325所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
coke_process_param	是	Object	参数解释：焦炉工况信息，具体字段如表 工艺相关信息说明所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-321 API 调用配置项说明

参数	是否必选	参数类型	说明
custom_name	否	String	参数解释：模型标识，用于指定用户通过工作流训练得到的模型。 约束限制：仅在异步调用场景下为必填参数，当前仅支持固定值“v1”。 取值范围：v1 默认取值：不涉及
function	否	String	参数解释：异步调用功能标识符，用于指定执行的具体功能类型。 约束限制：仅在异步调用场景下为必填参数。 取值范围：当前仅支持“predict”和“optimize”。“predict”表示焦炭质量预测功能，“optimize”表示配煤比例优化功能。 默认取值：不涉及

表 3-322 原料煤相关信息说明

参数	是否必选	参数类型	说明
name	是	String	参数解释：原料煤名称。 约束限制：不涉及 取值范围：不涉及。 默认取值：“ ”
category	否	String	参数解释：原料煤所属种类。 约束限制：不涉及 取值范围：不涉及。 默认取值：“ ”
stock	是	Number	参数解释：原料煤库存数量。 约束限制：不涉及 取值范围：建议 ≥ 0 默认取值：9999
manual_ratio	是	Number	参数解释：人工设定的配煤比例。 约束限制：填写为小数形式，用于约束该原料煤在配煤方案中的固定占比。 取值范围：[0,1] 默认取值：0
min_ratio	是	Number	参数解释：原料煤配煤最小比例要求。 约束限制：不涉及 取值范围：[0, 100] 默认取值：0
max_ratio	是	Number	参数解释：原料煤配煤最大比例要求。 约束限制：不涉及 取值范围：[0, 100] 默认取值：100
price	是	Number	参数解释：原料煤价格。 约束限制：不涉及 取值范围：不涉及 默认取值：0
ad	是	Number	参数解释：原料煤灰分。 约束限制：不涉及 取值范围：[1, 50] 默认取值：不涉及

参数	是否必选	参数类型	说明
vdaf	是	Number	参数解释：原料煤挥发分。 约束限制：不涉及 取值范围：[1, 45] 默认取值：不涉及
std	是	Number	参数解释：原料煤硫分。 约束限制：不涉及 取值范围：[0.01, 5] 默认取值：不涉及
g	是	Number	参数解释：原料煤粘结指数 G 值。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
x	是	Number	参数解释：原料煤最大收缩度 X 值。 约束限制：不涉及 取值范围：[0, 60] 默认取值：-10000（占位使用，建议实际调用时务必传入合法值）
y	是	Number	参数解释：原料煤最大胶质层厚度 Y 值。 约束限制：不涉及 取值范围：[0, 45] 默认取值：不涉及
single_cri	是	Number	参数解释：单种煤炼焦 CRI 指标。 约束限制：不涉及 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
single_csr	是	Number	参数解释：单种煤炼焦 CSR 指标。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
re_min	是	Number	参数解释：原料煤随机反射率下限。 约束限制：输入值必须为数字，且不大于随机反射率上限 re_max。 取值范围：[0, 10] 默认取值：-10000（作为无效/未赋值占位值）

参数	是否必选	参数类型	说明
re_max	是	Number	参数解释：原料煤随机反射率上限。 约束限制：输入值必须为数字，且不小于随机反射率下限 re_min。 取值范围：[0, 10] 默认取值：-10000（作为无效/未赋值占位值）
rmax	是	Number	参数解释：原料煤最大反射率。 约束限制：不涉及 取值范围：[0, 10] 默认取值：不涉及
re_s	是	Number	参数解释：原料煤反射率标准偏差。 约束限制：不涉及 取值范围：[0, 1] 默认取值：-10000（作为无效/未赋值占位值）
active	是	Number	参数解释：原料煤活性率。 约束限制：不涉及 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
rran1	是	Number	参数解释：煤岩区间 1 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran2	是	Number	参数解释：煤岩区间 2 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran3	是	Number	参数解释：煤岩区间 3 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran4	是	Number	参数解释：煤岩区间 4 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及

参数	是否必选	参数类型	说明
rran5	是	Number	参数解释：煤岩区间 5 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran6	是	Number	参数解释：煤岩区间 6 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran7	是	Number	参数解释：煤岩区间 5 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran8	是	Number	参数解释：煤岩区间 6 所占比例。 约束限制：不涉及 取值范围：[0, 100] 默认取值：不涉及
rran9	是	Number	参数解释：煤岩区间 9 所占比例。 约束限制：输入值必须为数字 取值范围：[0, 100] 默认取值：不涉及
rran10	是	Number	参数解释：煤岩区间 10 所占比例。 约束限制：输入值必须为数字 取值范围：[0, 100] 默认取值：不涉及
sio2	是	Number	参数解释：原料煤灰成分 SiO ₂ 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大大于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
al2o3	是	Number	参数解释：原料煤灰成分 Al ₂ O ₃ 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大大于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）

参数	是否必选	参数类型	说明
fe2o3	是	Number	参数解释：原料煤灰成分 Fe_2O_3 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
tio2	是	Number	参数解释：原料煤灰成分 TiO_2 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
k2o	是	Number	参数解释：原料煤灰成分 K_2O 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
na2o	是	Number	参数解释：原料煤灰成分 Na_2O 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
cao	是	Number	参数解释：原料煤灰成分 CaO 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
mgo	是	Number	参数解释：原料煤灰成分 MgO 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）

参数	是否必选	参数类型	说明
mno	是	Number	参数解释：原料煤灰成分 MnO 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
bao	是	Number	参数解释：原料煤灰成分 BaO 含量。 约束限制：输入值必须为数字，各组分含量建议满足总和不大 于 100。 取值范围：[0, 100] 默认取值：-10000（作为无效/未赋值占位值）
t_softening	是	Number	参数解释：原料煤初始软化温度（℃）。 约束限制：不涉及 取值范围：不涉及 默认取值：-10000（作为无效/未赋值占位值）
t_max fluidity	是	Number	参数解释：原料煤最大流动温度（℃）。 约束限制：不涉及 取值范围：不涉及 默认取值：-10000（作为无效/未赋值占位值）
t_final	是	Number	参数解释：原料煤最后流动温度（℃）。 约束限制：不涉及 取值范围：不涉及 默认取值：-10000（作为无效/未赋值占位值）
t_resolidification	是	Number	参数解释：原料煤固化温度（℃）。 约束限制：不涉及 取值范围：不涉及 默认取值：-10000（作为无效/未赋值占位值）
t_interval	是	Number	参数解释：原料煤塑性范围（℃）。 约束限制：不涉及 取值范围：不涉及 默认取值：-10000（作为无效/未赋值占位值）

参数	是否必选	参数类型	说明
mf	是	Number	参数解释：原料煤最大吉氏流动度（ddpm）。 约束限制：不涉及 取值范围：不涉及 默认取值：-10000（作为无效/未赋值占位值）

表 3-323 焦炭指标要求相关参数

参数	是否必选	参数类型	说明
ad	是	Array	参数解释：焦炭灰分指标要求范围。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
vdaf	是	Array	参数解释：焦炭挥发分要求范围。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
std	是	Array	参数解释：焦炭硫分要求范围。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
m10	是	Array	参数解释：焦炭耐磨强度M10要求范围。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
m25	是	Array	参数解释：焦炭抗碎强度M25要求范围。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
m40	是	Array	参数解释：焦炭耐磨强度M40要求范围。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

参数	是否必选	参数类型	说明
cri	是	Array	参数解释：焦炭反应性CRI要求范围。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
csr	是	Array	参数解释：焦炭反应后强度CSR要求范围。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-324 配合煤指标要求相关参数

参数	是否必选	参数类型	说明
ad	是	Array	参数解释：配合煤灰分指标要求。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
vdaf	是	Array	参数解释：配合煤挥发分要求。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
std	是	Array	参数解释：配合煤硫分要求。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
g	是	Array	参数解释：配合煤粘结指数G值要求。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
x	是	Array	参数解释：配合煤最大收缩度X值要求。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

参数	是否必选	参数类型	说明
y	是	Array	参数解释：配合煤最大胶质层厚度Y值要求。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
rmax	是	Array	参数解释：配合煤岩最大反射率要求。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
active	是	Array	参数解释：配合煤活性物比例要求。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-325 其他配比要求

参数	是否必选	参数类型	说明
coal_blend_amount	是	Number	参数解释：本次配煤计划量。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
coal_blend_range	是	Array	参数解释：优化配比使用的煤种梳理范围，比如[5, 10]。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-326 工艺相关信息说明

参数	是否必选	参数类型	说明
temperature	是	Number	参数解释：焦炉机焦侧温度。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

参数	是否必选	参数类型	说明
coking_time	是	Number	参数解释：结焦时间。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

响应参数

状态码： 200

表 3-327 配煤比例优化响应

参数	参数类型	说明
data	Object	A参数解释：PI返回数据，具体如 表 配煤比例优化处理结果 所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-328 配煤比例优化处理结果

参数	参数类型	说明
resp_data	Array	参数解释：配煤比例优化的响应，具体如 表 3-329 所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-329 焦炭质量预测响应参数

参数	参数类型	说明
price	String	参数解释：配合煤的价格预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

参数	参数类型	说明
ratio	String	参数解释：各原料煤的比例。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
feed_coal_result	Object	参数解释：当前配比配合煤的各指标预测值，具体如表3-330所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
coke_predict_result	Object	参数解释：当前配比焦炭质量预测值，具体如表3-331所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-330 配合煤指标预测值

参数	参数类型	说明
ad	Number	参数解释：配合煤的灰分预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
vdaf	Number	参数解释：配合煤的挥发分预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
std	Number	参数解释：配合煤的硫分预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
g	Number	参数解释：配合煤的粘结指数G值预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

参数	参数类型	说明
x	Number	参数解释：配合煤的最大收缩度X值预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
y	Number	参数解释：配合煤的最大胶质层厚度Y值预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
其他指标根据用户需求可选。		

表 3-331 焦炭质量预测值

参数	参数类型	说明
ad	Number	参数解释：焦炭的灰分预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
vdaf	Number	参数解释：焦炭的挥发分预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
std	Number	参数解释：焦炭的硫分预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
m10	Number	参数解释：焦炭的耐磨强度M10预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
m25	Number	参数解释：焦炭的抗碎强度M25预测值，与M40二选一即可。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

参数	参数类型	说明
m40	Number	参数解释：焦炭的抗碎强度M40预测值，与M25二选一即可。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
cri	Number	参数解释：焦炭的反应性CRI预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
csr	Number	参数解释：焦炭的反应后强度CSR预测值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-332 添加任务响应

参数	参数类型	描述
task_id	String	参数解释：任务ID，可用于查询任务详情。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-333 异步查询任务详情响应

参数	参数类型	说明
status	String	参数解释：任务状态， 约束限制：不涉及 取值范围： - waiting：任务正在排队，等待调度。 - running：任务当前正在被处理。 - failed：任务失败；finished：任务正常结束。 默认取值：不涉及

参数	参数类型	说明
result	Object	参数解释：异步处理结果，当状态为“finished”时存在。具体如 表 配煤比例优化响应 所示。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

状态码： 400

表 3-334 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

```
{
  "meta": {
    "custom_name": "v1",
    "function": "optimize"
  },
  "raw_coal_data": [
    {
      "name": "test1",
      "category": "OTHER",
      "stock": 0,
      "manual_ratio": 1.0,
      "min_ratio": 0,
      "max_ratio": 35,
      "price": 4011,
      "ad": 9.5,
      "vdaf": 22.5,
      "std": 0.59,
      "g": 91,
      "x": -10000,
      "y": 18,
      "single_cri": -10000,
      "single_csr": 57.77,
      "re_min": -10000,
      "re_max": -10000,
      "rmax": 0.968,
      "re_s": -10000,
      "active": -10000,
      "rran1": 0,
      "rran2": 11.3,
      "rran3": 18.8,
      "rran4": 11.8,
      "rran5": 35.8,
      "rran6": 22.3,
      "rran7": 0,
      "rran8": 0,
      "rran9": 0,
      "rran10": 0,
    }
  ]
}
```

```
"sio2": -10000,
"al2o3": -10000,
"fe2o3": -10000,
"tio2": -10000,
"k2o": -10000,
"na2o": -10000,
"cao": -10000,
"mgo": -10000,
"mno": -10000,
"bao": -10000,
"t_softening": 0,
"t_max_fluidity": 0,
"t_final": 0,
"t_resolidification": 0,
"t_interval": 0,
"mf": -10000
},
{
  "name": "test2",
  "category": "OTHER",
  "stock": 0,
  "manual_ratio": 0.0,
  "min_ratio": 0,
  "max_ratio": 35,
  "price": 2700,
  "ad": 9.8,
  "vdaf": 23.51,
  "std": 0.52,
  "g": 79,
  "x": -10000,
  "y": 14,
  "single_cri": -10000,
  "single_csr": 65.41,
  "re_min": -10000,
  "re_max": -10000,
  "rmax": 1.244,
  "re_s": -10000,
  "active": -10000,
  "rran1": 0,
  "rran2": 0,
  "rran3": 0,
  "rran4": 4.7,
  "rran5": 37.7,
  "rran6": 42.4,
  "rran7": 13.5,
  "rran8": 0,
  "rran9": 0,
  "rran10": 0,
  "sio2": -10000,
  "al2o3": -10000,
  "fe2o3": -10000,
  "tio2": -10000,
  "k2o": -10000,
  "na2o": -10000,
  "cao": -10000,
  "mgo": -10000,
  "mno": -10000,
  "bao": -10000,
  "t_softening": 0,
  "t_max_fluidity": 0,
  "t_final": 0,
  "t_resolidification": 0,
  "t_interval": 0,
  "mf": -10000
},
{
  "name": "test3",
  "category": "OTHER",
  "stock": 0,
```

```
    "manual_ratio": 0.0,  
    "min_ratio": 0,  
    "max_ratio": 35,  
    "price": 2210,  
    "ad": 10.11,  
    "vdaf": 21.24,  
    "std": 1.42,  
    "g": 90,  
    "x": -10000,  
    "y": 15,  
    "single_cri": -10000,  
    "single_csr": 77.13,  
    "re_min": -10000,  
    "re_max": -10000,  
    "rmax": 1.463,  
    "re_s": -10000,  
    "active": -10000,  
    "rran1": 0,  
    "rran2": 0,  
    "rran3": 0,  
    "rran4": 0,  
    "rran5": 9.6,  
    "rran6": 52.6,  
    "rran7": 29.2,  
    "rran8": 8.6,  
    "rran9": 0,  
    "rran10": 0,  
    "sio2": -10000,  
    "al2o3": -10000,  
    "fe2o3": -10000,  
    "tio2": -10000,  
    "k2o": -10000,  
    "na2o": -10000,  
    "cao": -10000,  
    "mgo": -10000,  
    "mno": -10000,  
    "bao": -10000,  
    "t_softening": 0,  
    "t_max_fluidity": 0,  
    "t_final": 0,  
    "t_resolidification": 0,  
    "t_interval": 0,  
    "mf": -10000  
  },  
],  
"constraint": {  
  "coal_blend_range": [  
    2,  
    3  
  ],  
  "coal_blend_amount": 1000  
},  
"coke_process_param": {  
  "temperature": 1240,  
  "coking_time": 19  
},  
"feed_coal_bound": {  
  "ad": [  
    0.0,  
    100.0  
  ],  
  "std": [  
    0.0,  
    100.0  
  ],  
  "vdaf": [  
    0.0,  
    22.8  
  ],  
}
```

```
    "g": [
      0.0,
      100.0
    ],
    "x": [
      0.0,
      100.0
    ],
    "y": [
      0.0,
      100.0
    ]
  },
  "coke_bound": {
    "ad": [
      0.0,
      12.978
    ],
    "std": [
      0.0,
      0.963
    ],
    "vdaf": [
      0.0,
      100.0
    ],
    "m10": [
      0.0,
      6.412
    ],
    "m25": [
      0.0,
      100.0
    ],
    "m40": [
      80.891,
      100.0
    ],
    "cri": [
      0.0,
      100.0
    ],
    "csr": [
      65.0,
      100.0
    ]
  }
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "data": {
    "resp_data": [
      {
        "price": 2921.7999999999997,
        "ratio": [
          0.3,
          0.35,
          0.35
        ],
        "feed_coal_result": {
          "ad": 9.8185,
          "std": 0.856,
          "vdaf": 22.412499999999998,

```



```
      "g": 86.44999999999999,
      "x": 0.0,
      "y": 15.549999999999999
    },
    "coke_predict_result": {
      "ad": 12.267706944960167,
      "std": 0.7885311085651606,
      "vdaf": 0.9579212693933187,
      "m10": 5.912459152440264,
      "m25": 82.46042415538042,
      "m40": 81.41623183974579,
      "cri": 20.33798900846002,
      "csr": 76.99913940733687
    },
    "confidence_level": -1
  },
  {
    "price": 2939.81,
    "ratio": [
      0.31,
      0.35,
      0.34
    ],
    "feed_coal_result": {
      "ad": 9.8124,
      "std": 0.8477,
      "vdaf": 22.4251,
      "g": 86.46000000000001,
      "x": 0.0,
      "y": 15.579999999999998
    },
    "coke_predict_result": {
      "ad": 12.261321673468611,
      "std": 0.7808853045919237,
      "vdaf": 0.9579212856592968,
      "m10": 5.912459151933199,
      "m25": 82.46042474570181,
      "m40": 81.41623183974579,
      "cri": 20.392414828221277,
      "csr": 76.90560990709676
    },
    "confidence_level": -1
  }
]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.11 行业场景预测大模型

功能介绍

融合推荐模型的升级架构，为解决数据漂移问题，优化了模型融合部分架构和算法，主要适配泛工业领域工况波动场景。

模型部署后，首次调用会进行预热，时间60s左右。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-335 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-336 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。2.2-API Key认证响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-337 请求 Body 参数

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 待进行预测的数据，data为一个数组，数组中包含多个对象，每个对象是一组完整的特征数据。 约束限制： 待预测特征名需要与训练数据中的特征名保持一致。例如，训练数据中特征列按照feature_1、feature_2……进行命名，在调用推理接口时，特征名也需要保持相同。同时推理接口中特征数量需要与训练数据中的特征数保持一致。一组特征数据填写完成后再填写剩余待预测数据，格式详见请求示例。 取值范围： 输入数据中的一组数据。 默认取值： 不涉及

响应参数

状态码： 200

表 3-338 响应 Body 参数

参数	参数类型	描述
result	Object	预测结果信息。

状态码： 400

表 3-339 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

水泥强度预测

```
{
  "data": [
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    },
    ...
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    }
  ]
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "result": [
    "prediction_1",
    ...
    "prediction_n"
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.12 高炉行业场景预测大模型

功能介绍

融合推荐模型的升级架构，为解决数据漂移问题，优化了模型融合部分架构和算法，主要适配泛工业领域工况波动场景。当前支持高炉炉温和硅含量的预测。

模型部署后，首次调用会进行预热，时间5分钟左右。

模型训练后，会根据训练精度赋予各子模型权重系数。

模型部署时，允许设置环境变量SUB_MODEL_WEIGHT重置子模型权重系数，其中

炉温预测：SUB_MODEL_WEIGHT="weight1;weight2;weight3;weight4;weight5"，共5个子模型权重项。

硅含量预测：SUB_MODEL_WEIGHT="weight1;weight2;weight3;weight4"，共4个子模型权重项。

要求各权重之和为1，即weight1+... +weightn=1。

推理结果展示融合结果和各子模型推理结果，其中融合结果是由各子模型通过权重系数计算而来，如果未设置环境变量，参与计算的权重系数来自训练赋予；如果设置环境变量，参与计算的权重系数来自人工输入。

环境变量设置示例：

高级配置 ^

环境变量 (可选)

SUB_MODEL_WEIGHT

=

字符串

0.25;0.25;0.25;0.25

+ 添加环境变量

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-340 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-341 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。2.2-API Key认证响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-342 请求 Body 参数

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 待进行预测的数据，data为一个数组，数组中包含多个对象，每个对象是一组完整的特征数据。 约束限制： 待预测特征名需要与训练数据中的特征名保持一致。例如，训练数据中特征列按照feature_1、feature_2……进行命名，在调用推理接口时，特征名也需要保持相同。同时推理接口中特征数量需要与训练数据中的特征数保持一致。一组特征数据填写完成后再填写剩余待预测数据，格式详见请求示例。 取值范围： 输入数据中的一组数据。 默认取值： 不涉及

响应参数

状态码： 200

表 3-343 响应 Body 参数

参数	参数类型	描述
result	Object	参数解释： 预测结果信息。包含模型融合结果和各子模型预测结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-344 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

高炉炉温预测

```
{
  "data": [
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    },
    ...
    {
      "feature_1": xx,
      "feature_2": xx,
      ...
      "feature_n": xx
    }
  ]
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "result": [
    "prediction_fuse",
    "prediction_1",
    ...
    "prediction_n"
  ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.4.13 智能洗选边缘推理

3.4.13.1 重介密控

功能介绍

根据获取的生产实时数据，优化重介分选密度，稳定精煤产品的灰分在目标灰分附近，减小产品灰分的波动，稳定产品质量。

通过向服务API接口发送请求数据，服务会返回对应的结果。

获取访问地址

使用重介密控推理接口前，请参考《用户指南》“开发盘古预测大模型 > 开发智能洗选模型”章节，完成训练及画布的创建部署操作。

请求地址可通过服务详情页的URL获取。

1. 在“垂域应用开发 > 工业应用编排”页面，选择需要的访问画布服务。

2. 进入画布详情页面，单击“画布服务”获取访问地址。

图 3-21 获取访问地址



请求参数

表 3-345 请求 Header 参数

参数	是否必选	参数类型	说明
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-346 请求 Body 参数

参数	是否必选	参数类型	说明
request_id	是	String	参数解释： 请求体编号，用于唯一标识一次请求调用。 约束限制： 建议全局唯一 取值范围： 不涉及 默认取值： 不涉及
device_id	是	String	参数解释： 产线编号，用于区分不同生产线/设备。 约束限制： 建议全局唯一 取值范围： 不涉及 默认取值： 不涉及
input_data	是	Object	参数解释： 请求的输入数据整体封装对象。 约束限制： 内部结构需符合接口约定（包括 process_data、experiment_data、user_info 等）。 取值范围： 不涉及 默认取值： 不涉及
user_info	是	Object	参数解释： 用户配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-347 input_data

参数	是否必选	参数类型	说明
process_data	是	List of Object	参数解释： 生产数据列表，每个元素代表一个采样时间点对应的各个数据点位的数据。 约束限制： 若在某采样时刻某个点位无数据，则该点位值须显式赋值为 null。列表应按时间顺序组织。 取值范围： 列表元素为符合约定结构的对象。 默认取值： 不涉及，需调用方显式传入。

参数	是否必选	参数类型	说明
experiment_data	是	List of Object	参数解释：实验数据列表，需至少包含最近一次快灰实验的结果及对应的采样时间。 约束限制：至少包含一条最近一次快灰实验记录，且时间字段必须有效。 取值范围：列表元素为符合约定结构的对象。 默认取值：不涉及

表 3-348 user_info

参数	是否必选	参数类型	说明
ash_qualified_range	是	List of Float	参数解释：精煤快灰的合格范围。列表第一个值为下界，第二个值为上界。 约束限制：列表长度固定为 2，且第一个值小于第二个值。 取值范围：不涉及 默认取值： [8.5, 9.0]
goal_ash	是	Float	参数解释：精煤快灰的控制目标值。 约束限制：必须介于 ash_qualified_range 的下界与上界之间，即 $\text{ash_qualified_range}[0] \leq \text{goal_ash} \leq \text{ash_qualified_range}[1]$。 取值范围：在合格范围内的浮点数。 默认取值： 8.8
hard_upper_ash	是	Float	参数解释：精煤产品灰分的硬性上限，产品灰分不得超过该值。 约束限制：应大于等于 goal_ash，用于安全约束控制。 取值范围：大于 0 的浮点数，具体由业务设定。 默认取值： 9

参数	是否必选	参数类型	说明
md_hard_bound	是	List of Float	参数解释： 重介密度设定值的安全硬边界。列表第一个值为密度设定下界，第二个值为密度设定上界。 约束限制： 列表长度固定为 2，且第一个值小于第二个值；算法推荐的密度值不会超出该范围。 取值范围： 不涉及 默认取值： [1.49, 1.61]
density_step_size	是	Float	参数解释： 密度设定值改变的最小步长。 约束限制： 必须为正数，用于限制每次调整的最小变化量。 取值范围： > 0 的浮点数。 默认取值： 0.001
startup_info	否	Dict	参数解释： 开机密度推荐相关信息。 约束限制： 非必须字段；若缺省，则认为当前请求为非开机密度推荐请求。内部字段结构按业务约定执行。 取值范围： 合法的键值对字典。 默认取值： 不涉及

表 3-349 startup_info

参数	是否必选	参数类型	说明
is_startup	否	Bool	参数解释： 是否为开机密度推荐请求标志。 约束限制： 不涉及 取值范围： true 或 false 默认取值： false
startup_direction	否	String	参数解释： 开机精煤走向（针对济宁二号煤矿等特定场景）。 约束限制： 当前支持固定取值集合。 取值范围： east、west 默认取值： west

响应参数

表 3-350 响应 Body 参数

参数	参数类型	描述
request_id	string	参数解释： 请求体编号，用于唯一标识一次请求调用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
device_id	string	参数解释： 产线编号，用于标识所属生产线/设备。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
result	object	参数解释： 输出结果信息的封装对象，包含推荐状态、说明及推荐密度等。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-351 result

参数	参数类型	描述
status	String	参数解释： 当前请求的处理状态。 约束限制： 只能为预定义枚举值之一。 取值范围： success：成功推荐出密度值；failed：运行出错，无法给出有效推荐；silence：当前条件下不需要进行密度推荐。 默认取值： 不涉及，由服务端根据实际处理结果返回。

参数	参数类型	描述
res_info	String	参数解释：对当前结果进行说明，补充说明 status 的具体原因或场景。 约束限制：无强制格式要求，建议为可读性良好的中文描述。 取值范围：当 status = silence："不满足优化条件，本次不进行优化"；当为开机密度推荐："本次为开机密度推荐"；当因获取新的快灰触发："获取新的快灰结果，进行密度推荐"；当因时间间隔触发："距离上次优化时间达到设定时间间隔，进行密度推荐"；当因原煤灰分变化触发："原煤灰分变化值达到设定条件，进行密度推荐"。 默认取值：不涉及
recommend_md	Float	参数解释：推荐的重介密度设定值。 约束限制：仅当 status = "success" 时为有效数值；当 status 为 failed 或 silence 时应为 null 或不返回。 取值范围：浮点数，通常应在接口初始化时设定的安全密度范围（如 md_hard_bound）之内，具体范围视业务配置而定。 默认取值：当未成功推荐时为 null；成功推荐时由算法计算生成，无固定默认值。

请求示例

以下给出了一个请求示例，process_data的实际元素个数要多于示例，这里仅作为对格式的说明。请求体中各字段的说明以及数据点位的说明上文已经给出。

```
{
  "request_id": "10",
  "device_id": "1",
  "input_data": {
    "process_data": [
      {
        "DATE_TIME": "2023-03-27 17:43:20",
        "ZJ_MD_705": 1.57822215,
        "ZJ_MD_SET_705": NaN,
        "ZJ_BSF_705": 3.13125,
        "ZJ_FLF_705": 0.0,
        "ZJ_CXW_705": 522.3125,
        "ZJ_YW_705": 72.725,
        "ZJ_YL_705": 0.0,
        "ZJ_MD_706": 1.61296875,
        "ZJ_MD_SET_706": NaN,
        "ZJ_BSF_706": 0.015625,
        "ZJ_FLF_706": 0.0,
        "ZJ_CXW_706": 582.40625,
        "ZJ_YW_706": 44.9125,
        "ZJ_YL_706": 0.0,
        "JM_HF_453": 0.0,
        "JM_HF_565": 0.0,
        "YM_HF": 42.1456,
        "YM_ML": 2.151249733,

```

```
"JM_ML_453": 6.761070589,  
"JM_ML_781": 0.30732139,  
"KH_JM": NaN,  
"KH_YM": NaN,  
"KH_KJM": NaN,  
"ZJ_MN_705": NaN,  
"ZJ_MN_706": NaN  
},  
{  
  "DATE_TIME": "2023-03-27 17:43:30",  
  "ZJ_MD_705": 1.590026775,  
  "ZJ_MD_SET_705": NaN,  
  "ZJ_BSF_705": 3.125,  
  "ZJ_FLF_705": 0.0,  
  "ZJ_CXW_705": 519.1875,  
  "ZJ_YW_705": 72.875,  
  "ZJ_YL_705": 0.0,  
  "ZJ_MD_706": 1.6061875,  
  "ZJ_MD_SET_706": NaN,  
  "ZJ_BSF_706": 0.0,  
  "ZJ_FLF_706": 0.0,  
  "ZJ_CXW_706": 585.84375,  
  "ZJ_YW_706": 45.1625,  
  "ZJ_YL_706": 0.0,  
  "JM_HF_453": 0.0,  
  "JM_HF_565": 0.0,  
  "YM_HF": 42.1456,  
  "YM_ML": 1.8439283430000002,  
  "JM_ML_453": 11.52455214,  
  "JM_ML_781": 0.0,  
  "KH_JM": NaN,  
  "KH_YM": NaN,  
  "KH_KJM": NaN,  
  "ZJ_MN_705": NaN,  
  "ZJ_MN_706": NaN  
},  
{  
  "DATE_TIME": "2023-03-27 17:43:40",  
  "ZJ_MD_705": 1.58946465,  
  "ZJ_MD_SET_705": 1.51999998,  
  "ZJ_BSF_705": 3.125,  
  "ZJ_FLF_705": 0.0,  
  "ZJ_CXW_705": 528.25,  
  "ZJ_YW_705": 72.953125,  
  "ZJ_YL_705": 0.0,  
  "ZJ_MD_706": 1.59940625,  
  "ZJ_MD_SET_706": 1.51999998,  
  "ZJ_BSF_706": 0.0,  
  "ZJ_FLF_706": 0.0,  
  "ZJ_CXW_706": 575.53125,  
  "ZJ_YW_706": 45.2875,  
  "ZJ_YL_706": 0.0,  
  "JM_HF_453": 0.0,  
  "JM_HF_565": 0.0,  
  "YM_HF": 42.1456,  
  "YM_ML": 1.659535508,  
  "JM_ML_453": 0.7683034759999999,  
  "JM_ML_781": 0.0,  
  "KH_JM": NaN,  
  "KH_YM": NaN,  
  "KH_KJM": NaN,  
  "ZJ_MN_705": NaN,  
  "ZJ_MN_706": NaN  
},  
{  
  "DATE_TIME": "2023-03-27 17:43:50",  
  "ZJ_MD_705": 1.592275275,  
  "ZJ_MD_SET_705": NaN,  
  "ZJ_BSF_705": 3.125,
```



```
        "ZJ_FLF_705": 0.0,  
        "ZJ_CXW_705": 536.65625,  
        "ZJ_YW_705": 73.053125,  
        "ZJ_YL_705": 0.0,  
        "ZJ_MD_706": 1.5906875,  
        "ZJ_MD_SET_706": NaN,  
        "ZJ_BSF_706": 0.015625,  
        "ZJ_FLF_706": 0.0,  
        "ZJ_CXW_706": 565.1875,  
        "ZJ_YW_706": 45.490625,  
        "ZJ_YL_706": 0.0,  
        "JM_HF_453": 0.0,  
        "JM_HF_565": 0.0,  
        "YM_HF": 42.1456,  
        "YM_ML": 1.659535508,  
        "JM_ML_453": 0.153660695,  
        "JM_ML_781": 0.0,  
        "KH_JM": NaN,  
        "KH_YM": NaN,  
        "KH_KJM": NaN,  
        "ZJ_MN_705": NaN,  
        "ZJ_MN_706": NaN  
    }  
  ],  
  "experiment_data": [  
    {  
      "DATE_TIME": "2022-12-30 08:00:00",  
      "KH_JM": 8.5,  
      "KH_KJM": 8.6,  
      "YM_HF": 33.0  
    }  
  ]  
},  
"user_info": {  
  "hard_upper_ash": 9.0,  
  "goal_ash": 8.8,  
  "ash_qualified_range": [  
    8.51,  
    9  
  ],  
  "md_hard_bound": [  
    1.46,  
    1.62  
  ],  
  "density_step_size": 0.001,  
  "startup_info": {  
    "is_startup": false,  
    "startup_direction": "west"  
  }  
}
```

响应示例

```
{  
  "request_id": "10",  
  "device_id": "1",  
  "result": {  
    "status": "success",  
    "res_info": "获取新的快灰结果，进行密度推荐",  
    "recommend_md": 1.590  
  }  
}
```

3.4.13.2 智能加药

功能介绍

根据获取的生产实时数据，优化阴离子加药泵频率，稳定清水层高度在设定的目标值附近。

通过向服务API接口发送请求数据，服务会返回对应的结果。

获取访问地址

使用重介密控推理接口前，请参考《用户指南》“开发盘古预测大模型 > 开发智能洗选模型”章节，完成训练及画布的创建部署操作。

请求地址可通过服务详情页的URL获取。

1. 在“垂域应用开发 > 工业应用编排”页面，选择需要的访问画布服务。

2. 进入画布详情页面，单击“画布服务”获取访问地址。

图 3-22 获取访问地址



请求参数

表 3-352 请求 Header 参数

参数	是否必选	参数类型	说明
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-353

参数	是否必选	参数类型	说明
request_id	是	String	参数解释： 请求体编号，用于标识一次唯一请求，用于链路追踪与问题排查。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
device_id	是	String	参数解释： 产线编号，用于标识具体生产线或设备。 约束限制： 不可为空，应与系统中已登记的设备/产线编号一致。 取值范围： 不涉及 默认取值： 不涉及
frequency	是	Integer	参数解释： 生产数据采样频率，用于表示单位时间内采集数据的次数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
process_data	是	List of Object	参数解释： 生产数据列表，每个元素为一条生产数据记录。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_info	是	Object	参数解释： 用户配置信息，用于指定与当前请求相关的用户级参数（如权限、偏好、账户信息等）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
abnormal_handle_rule	是	List of Object	参数解释： 用户配置的异常处理规则集合，用于定义生产数据异常时的告警或处理策略。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

对user_info的说明如下表所示：

表 3-354 user_info

参数	是否必选	参数类型	说明
control_info	是	Object	参数解释：控制目标和控制动作信息。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
opt_info	是	Object	参数解释：频率优化设置相关信息。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
bound_info	是	Object	参数解释：优化相关的边界信息。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
postprocess_info	是	Object	参数解释：后处理相关信息。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
no_qsc_rule	是	Object	参数解释：无清水层数据时的处理规则。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
update_info	是	Object	参数解释：结果更新相关信息。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-355 control_info

参数	是否必选	参数类型	说明
clear_layer_target	是	Integer	参数解释：清水层高度控制目标，优化的目标是将清水层高度控制在该值附近，单位为 mm。 约束限制：应设置在工艺允许的合理范围内。 取值范围：[1000,3000] mm 默认取值：1700
overflow_target	是	Float	参数解释：溢流浓度控制目标，优化的目标是将溢流浓度控制在该值以下，单位为 g/L 约束限制：须为正数且小于 3.0 取值范围：(0,3.0) g/L 默认取值：2.2
max_freq	是	Float	参数解释：AI 优化可输出的最大加药频率，用于限制推荐频率的上界。 约束限制：须为正数，且应大于 min_freq。 取值范围：(0,50) 默认取值：30
min_freq	是	Float	参数解释：AI 优化可输出的最小加药频率，用于限制推荐频率的下界，该值需小于 max_freq。 约束限制：须为非负数且小于 max_freq。 取值范围：(0,20) 默认取值：0

表 3-356 opt_info

参数	是否必选	参数类型	说明
overflow_weight	是	Integer	参数解释：计算优化目标函数时溢流项的权重系数，用于平衡清水层高度（mm，千量级）与溢流浓度（个位数）对目标函数的影响，单位为 mm。 约束限制：必须为正整数；为高级设置，建议仅专业人员调整。 取值范围：(0,10000] 默认取值：1000
pop_size	是	Integer	参数解释：优化求解的种群个数。 约束限制：必须为正整数；数值过小易导致早熟收敛，过大将显著增加计算量；为高级设置。 取值范围：[5,20] 默认取值：8
max_iter	是	Integer	参数解释：优化求解的最大迭代次数，用于限制算法运行步数和计算时间。 约束限制：必须为正整数；值越大通常可获得更优解，但计算时间越长；为高级设置。 取值范围：[10,300] 默认取值：20
freq_filter_parameter	是	Float	参数解释：输出频率低通滤波，用于平滑推荐加药频率；该值越大，推荐频率相对上次频率变化越小，控制更平稳。 约束限制：取值需在 [0,1] 范围内；为高级设置。 取值范围：[0,1] 默认取值：0.9
min_freq_step	是	Float	参数解释：频率可变化的最小步长，用于限制单次频率调整的最小幅度，避免频率变化过小导致控制不敏感。 约束限制：必须为正数，且不大于 1。 取值范围：(0,1] 默认取值：0.1

参数	是否必选	参数类型	说明
max_freq_step	是	Float	参数解释：单次频率变化的最大步长，根据生产经验确定，用于限制单次频率变化幅度，保证生产过程稳定。 约束限制：必须为正数，建议不超过 10。 取值范围：[1,10] 默认取值：4

表 3-357 bound_info

参数	是否必选	参数类型	说明
ph_bound	是	Float	参数解释：判断是否“跑黑”的溢流浓度阈值，溢流浓度大于该值时认为溢流跑黑，此时算法会输出 max_freq 作为推荐加药频率，单位为 g/L。 约束限制：应根据工艺经验设置在合理范围内。 取值范围：(1.0, 5.0) g/L 默认取值：3
pressure_bound1	是	Float	参数解释：第一级耙压判断阈值，用于判定耙压是否达到一级报警/控制水平，单位为 MPa。 约束限制：应为正数，一般小于 1。 取值范围：(0, 1) MPa 默认取值：0.2
pressure_bound2	是	Float	参数解释：第二级耙压判断阈值，用于判定耙压是否达到高压状态，单位为 MPa。 约束限制：应为正数，通常大于 pressure_bound1。 取值范围：(1, 5) MPa 默认取值：3

参数	是否必选	参数类型	说明
pressure_hz1	是	Float	参数解释：当耙压处于 pressure_bound1 和 pressure_bound2 之间时，算法推荐的加药频率值。 约束限制：应为非负数，建议不超过 20。 取值范围：(0, 20) 默认取值：10
pressure_hz2	是	Float	参数解释：当耙压大于 pressure_bound2 时，算法推荐的加药频率值。 约束限制：应为非负数，建议不超过 10。 取值范围：(0, 10) 默认取值：0
overflow_filter	是	Float	参数解释：溢流浓度过滤阈值；当清水层有效标记为 FALSE，且溢流浓度大于该值时，采用 abnormal_handle_rule 中的规则进行频率推荐，单位为 g/L。 约束限制：应为非负数。 取值范围：未作硬性限制，一般设置为 3 g/L 附近。 默认取值：3

表 3-358 postprocess_info

参数	是否必选	参数类型	说明
grid_para	是	Float	参数解释：后处理阶段的预留参数，目前算法中暂未使用，用于后续功能扩展。 约束限制：无特殊限制，为高级设置。 取值范围：不涉及 默认取值：1

参数	是否必选	参数类型	说明
clear_layer_judge	是	Float	参数解释：后处理时清水层高度判断阈值，用于判断当前清水层是否处于安全或目标范围，单位为 mm。 约束限制：应在工艺允许的高度范围内设置。 取值范围：[1000, 3000] mm 默认取值：1800
overflow_judge	是	Float	参数解释：后处理时溢流浓度判断阈值，用于判断溢流质量是否达标，单位为 g/L。 约束限制：应为正数且不大于 3.0。 取值范围：(0, 3.0) g/L 默认取值：2.2
output_freq	是	Float	参数解释：当“清水层高度 > clear_layer_judge 且 溢流浓度 < overflow_judge”时，算法直接输出的固定加药频率值。 约束限制：应为非负数，建议不超过 20。 取值范围：(0, 20) 默认取值：10
controller_weight	是	Float	参数解释：参考 PID 控制，为输出频率添加比例项的权重系数，用于提升对偏差的直接响应能力。 约束限制：建议设置在 [0, 1] 范围内，为高级设置。 取值范围：[0, 1] 默认取值：1
controller_coefficient	是	Float	参数解释：参考 MPC 控制，为优化目标添加频率变化项（优化频率与当前频率差值）的系数，用于抑制频率变化过大。 约束限制：建议设置在 [0, 1] 范围内，为高级设置。 取值范围：[0, 1] 默认取值：1

表 3-359 no_qsc_rule

参数	是否必选	参数类型	说明
no_qsc_flag	是	Bool	参数解释：是否存在有效的清水层（QSC）测量数据标记。当该值为 false 时，认为当前无可靠清水层数据，算法将按照 abnormal_handle_rule 中制定的规则进行频率推荐；当该值为 true 时，使用实际/默认清水层高度进行优化。 约束限制：仅允许取值 true 或 false。 取值范围：false, true 默认取值：false
setting_qsc	是	Integer	参数解释：默认清水层高度。当 no_qsc_flag 为 TRUE 且清水层有效数据缺失时，使用该值作为清水层高度参与优化运算，单位为 mm。 约束限制：需在设备及工艺允许的高度范围内设置。 取值范围：[1000, 2000] mm 默认取值：1500
inflow_upper	是	Integer	参数解释：入流流量上限阈值，用于数据质量控制。当实际入流流量大于该值时，认为该数据异常，可参与过滤或特殊处理，单位为 m³/h。 约束限制：需结合现场工况合理设置，不宜过低或过高。 取值范围：[500, 8000] m³/h 默认取值：5000
qsc_low_pass	是	Float	参数解释：清水层高度低通滤波系数，用于对清水层高度信号进行平滑处理，减小测量波动对控制的影响。数值越小，滤波越平滑，响应越慢。 约束限制：建议在 [0, 1.0] 范围内设置；为高级。 取值范围：[0, 1.0] 默认取值：0.1

表 3-360 update_info

参数	是否必选	参数类型	说明
delta_weight	是	Float	参数解释：清水层高度（或相关量）delta 修正值权重，用于在新测量值与历史估计值之间加权更新。 约束限制：建议在 [0, 1.0] 范围内设置；为高级设置。 取值范围：[0, 1.0] 默认取值：0.8
correction_type	是	Integer	参数解释：数据修正方式选择开关。1 表示启用数据修正逻辑（使用 delta_weight 等参数进行修正），0 表示不进行数据修正，直接使用原始数据。 约束限制：仅允许取值 0 或 1；为高级设置。 取值范围：0, 1 默认取值：1
qsc_max_value	是	Float	参数解释：界面仪可测量或允许的清水层高度最大值，用于对清水层高度进行上限约束和异常数据判定，单位为 mm。 约束限制：应不小于实际可能出现的最大清水层高度。 取值范围：[0, 5000] mm 默认取值：2750 mm
qsc_edge_value	是	Float	参数解释：清水层高度修正时的边界判定值，用于判断是否需要进行清水层高度校正（例如，当偏差大于该值时触发修正）。 约束限制：需为非负数；为高级设置。 取值范围：[0, 10] 默认取值：3
yl_proportion	是	Float	参数解释：溢流比例控制器系数，用于调节溢流相关控制量的响应强度。增大该值可提高溢流对控制输出的影响和响应速度。 约束限制：建议在 [0, 1] 范围内设置；为高级设置。 取值范围：[0, 1] 默认取值：1

参数	是否必选	参数类型	说明
condition_coefficient	是	Float	参数解释：工况区分系数，用于在不同工况（如高负荷、低负荷等）之间进行区分和加权，影响算法对不同工况的敏感度或决策逻辑。 约束限制：建议在 [0, 100] 范围内设置；为高级设置。 取值范围：[0, 100] 默认取值：10

freq_rule是由字典组成的数组，每个字典里的字段为in_lb到frequency_ub这些字段。

具体判断时，算法会逐条检验当前数据的入流流量、入流浓度、溢流浓度以及清水层高度是否全部在该条规则对应字段的上下限范围内。

如果在各数据都在这条规则的范围内，输出的频率是为 $a \times (\text{frequency_ub} - \text{frequency_lb}) + \text{frequency_lb}$ ，其中a的计算方式是入流流量和入流浓度的当前值在上下限范围内占比的加权和，其权重就是weight_rule中规定的权重。

如果当前数据没有匹配上任意一条规则，则输出default_freq作为结果。

对abnormal_handle_rule字段的说明见下表：

表 3-361 abnormal_handle_rule

参数	是否必选	参数类型	说明
default_freq	是	Float	参数解释：当前工况未命中任何一条频率计算规则时，算法回退输出的默认加药频率。 约束限制：应为正数且不宜超过 40，以避免频率过高影响生产稳定性。 取值范围：(0, 40) 默认取值：25
weight_rule	是	Object	参数解释：基于规则计算输出频率时，如流流量和入流浓度的权重 约束限制：权重要求在（0，1.0）范围内 取值范围：(0, 1.0) 默认取值：0.5

参数	是否必选	参数类型	说明
freq_rule	是	Object	参数解释：输出频率计算的具体规则。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及

表 3-362 weight_rule

参数	是否必选	参数类型	说明
in_flow	是	Float	参数解释：基于规则计算输出频率时，入流流量在综合权重中的占比系数。数值越大，入流流量对推荐频率的影响越大。 约束限制：建议在 (0, 1.0) 区间内设置；为高级设置，非专业人员不建议调整。 取值范围：(0, 1.0) 默认取值：0.5
in_concentration	是	Float	参数解释：基于规则计算输出频率时，入流浓度在综合权重中的占比系数。数值越大，入流浓度对推荐频率的影响越大。 约束限制：建议在 (0, 1.0) 区间内设置；为高级设置，非专业人员不建议调整。 取值范围：(0, 1.0) 默认取值：0.5

表 3-363 freq_rule

参数	是否必选	参数类型	说明
in_lb	是	Float	参数解释：该条规则适用的入流流量下限，单位为 m ³ /h。当实际入流流量大于等于该值且小于等于 in_ub 时，认为满足该规则的流量条件。 约束限制：应小于对应的 in_ub，且与现场工况范围一致。 取值范围：不涉及 默认取值：不涉及

参数	是否必选	参数类型	说明
in_ub	是	Float	参数解释：该条规则适用的入流流量上限，单位为 m³/h。当实际入流流量不大于该值且大于等于 in_lb 时，认为满足该规则的流量条件。 约束限制：应大于对应的 in_lb。 取值范围：不涉及 默认取值：不涉及
in_concentration_lb	是	Float	参数解释：该条规则适用的入料浓度下限，单位为 g/L。当实际入料浓度大于等于该值且小于等于 in_concentration_ub 时，认为满足该规则的入料浓度条件。 约束限制：应小于对应的 in_concentration_ub。 取值范围：不涉及 默认取值：不涉及
in_concentration_ub	是	Float	参数解释：该条规则适用的入料浓度上限，单位为 g/L。当实际入料浓度不大于该值且大于等于 in_concentration_lb 时，认为满足该规则的入料浓度条件。 约束限制：应大于对应的 in_concentration_lb。 取值范围：不涉及 默认取值：不涉及
overflow_concentration_lb	是	Float	参数解释：该条规则适用的溢流浓度下限，单位为 g/L。当实际溢流浓度大于等于该值且小于等于 overflow_concentration_ub 时，认为满足该规则的溢流浓度条件。 约束限制：应小于对应的 overflow_concentration_ub。 取值范围：不涉及 默认取值：不涉及

参数	是否必选	参数类型	说明
overflow_concentration_ub	是	Float	参数解释：该条规则适用的溢流浓度上限，单位为 g/L。当实际溢流浓度不大于该值且大于等于 overflow_concentration_lb 时，认为满足该规则的溢流浓度条件。 约束限制：应大于对应的 overflow_concentration_lb。 取值范围：不涉及 默认取值：不涉及
clear_height_lb	是	Float	参数解释：该条规则适用的清水层高度下限，单位为 mm。当实际清水层高度大于等于该值且小于等于 clear_height_ub 时，认为满足该规则的清水层高度条件。 约束限制：应小于对应的 clear_height_ub，并处于设备允许范围内。 取值范围：不涉及 默认取值：不涉及
clear_height_ub	是	Float	参数解释：该条规则适用的清水层高度上限，单位为 mm。当实际清水层高度不大于该值且大于等于 clear_height_lb 时，认为满足该规则的清水层高度条件。 约束限制：应大于对应的 clear_height_lb，并处于设备允许范围内。 取值范围：不涉及 默认取值：不涉及
frequency_lb	是	Float	参数解释：该条规则输出频率的下限，用于限制该规则下推荐加药频率的最小值。 约束限制：应为非负数且小于对应的 frequency_ub。 取值范围：不涉及 默认取值：不涉及

参数	是否必选	参数类型	说明
frequency_ub	是	Float	参数解释：该条规则输出频率的上限，用于限制该规则下推荐加药频率的最大值。 约束限制：应大于对应的 frequency_lb，并在系统允许频率范围内。 取值范围：不涉及 默认取值：不涉及

响应参数

表 3-364 智能加药服务响应参数说明

参数	参数类型	说明
request_id	String	参数解释：请求体编号，用于唯一标识一次接口调用，便于日志追踪与问题排查。 约束限制：建议在系统内保持全局唯一。 取值范围：不涉及 默认取值：不涉及
device_id	String	参数解释：产线或设备编号，用于标识当前推荐结果所属的生产线/设备。 约束限制：需与现场实际产线/设备的唯一标识保持一致。 取值范围：不涉及 默认取值：不涉及
recommend_yin_frequency	Float	参数解释：推荐的阴离子加药泵频率，为本次计算后输出的最终频率值。 约束限制：不涉及 取值范围：不涉及 默认取值：不涉及
input_data	Object	参数解释：经预处理后的当前工况数据集合，用于记录本次频率推荐所依据的输入特征（例如流量、浓度、清水层高度、压力等）。 约束限制：字段结构需与模型/规则配置保持一致；同一系统内建议保持统一的数据格式。 取值范围：不涉及 默认取值：不涉及

参数	参数类型	说明
predict_result	Object	参数解释：AI 预测结果对象。当本次频率由 AI 模型推荐时，存放清水层高度及（可选）溢流浓度的预测结果；若未使用 AI，则为 null。包含典型字段： • Adjust_boundarywater：调整后的清水层高度预测值； • Model_boundarywater_m15 / _m10 / _m5：分别为提前 15/10/5 分钟的清水层高度预测值； • Model_boundarywater：当前清水层高度预测值； • kept_boundarywater：后处理阶段保留使用的清水层高度值； • kept_overflowConcentration：后处理阶段保留使用的溢流浓度值； 若 workflows 训练时选择了溢流浓度模型，还包含： • Model_overflow_m15 / _m10 / _m5：分别为提前 15/10/5 分钟的溢流浓度预测值。约束限制：仅在启用 AI 模型并预测成功时非空；字段名需与模型配置保持一致。 取值范围：不涉及 默认值：null（未使用 AI 或预测失败时）
status_msg	String	参数解释：频率推荐方式说明，用于标识当前推荐结果的来源。仅支持以下两种固定内容： • "frequency recommended according to the provided rule table."：表示根据用户配置的规则表（含异常处理规则）进行频率推荐； • "frequency recommended using AI."：表示通过 AI 模型进行频率推荐。 约束限制：取值限定为上述两种字符串之一。 取值范围：{"frequency recommended according to the provided rule table.", "frequency recommended using AI."}。 默认取值：不涉及

参数	参数类型	说明
detail_msg	String	参数解释：频率推荐的详细说明，主要用于在使用 AI 推荐时，解释后处理环节命中的具体规则。当 status_msg = "frequency recommended using AI." 时，该字段可能为以下几类文本（占位符数值来自 user_info.bound_info 中的配置）： "current clear height is larger than %s, recommend the provided frequency": 表示当前清水层高度大于阈值 clear_layer_judge，因此采用用户提供的频率； "harrow pressure is larger than %s, recommend the provided frequency": 表示耙架压力高于 pressure_bound2，采用用户提供的频率； "harrow pressure is larger than %s and smaller than %s, recommend the provided frequency": 表示耙架压力在 pressure_bound1 与 pressure_bound2 之间，采用用户提供的频率； "current overflow concentration is larger than bound %s, recommend the max frequency": 表示溢流浓度大于 ph_bound，推荐使用最大频率。 若后处理未命中任何规则，则 detail_msg = null。 约束限制：内容由系统生成，用于展示和排查，不建议客户端修改。 取值范围：不涉及（描述性文本或 null） 默认取值：null
Model_boundarywater	Float	参数解释：清水层高度预测值，通常对应 predict_result 中字段 Model_boundarywater 的当前时刻预测结果，用于反映模型对当前清水层高度的估计。 约束限制：应为非负数，且一般不超过设备与工艺允许的最大清水层高度。 取值范围：不涉及（通常在 [0, 设备上限] 范围内，单位与模型训练时一致，常为 mm）。 默认取值：不涉及

请求示例

以下给出了一个请求示例，process_data的和abnormal_handle_rule实际元素个数要多于示例，这里仅作为对格式的说明。请求体中各字段的说明以及数据点位的说明上文已经给出。

```
{
  "request_id": "10",
  "device_id": "9A",
```

```
"frequency": 60,
"process_data": [
  {
    "JMY_ValidTag": "true",
    "Yin_Frequency_01": "12.000868",
    "Yin_Frequency_02": "0.0",
    "JMY_Concentration_1000": "38",
    "JMY_Concentration_1250": "46",
    "JMY_Concentration_1400": "52",
    "JMY_Concentration_1500": "57",
    "JMY_Concentration_1600": "57",
    "JMY_Concentration_1750": "57",
    "JMY_Concentration_2000": "58",
    "JMY_Concentration_250": "13",
    "JMY_Concentration_2500": "62",
    "JMY_Concentration_2900": "54",
    "JMY_Concentration_3000": "0",
    "JMY_Concentration_500": "14",
    "JMY_Height": "1204",
    "In_Concentration": "50.58232",
    "In_Flow": "758.7414",
    "Monitor_Time": "2023-10-23 15:15:00",
    "Overflow_Concentration": "0.9331766",
    "Pressure": "0.0",
    "Underflow_Concentration": "0.0",
    "Underflow_PumpStatus": "false",
    "Yin_Concentration": "2.5"
  },
  {
    "JMY_ValidTag": "true",
    "Yin_Frequency_01": "12.000868",
    "Yin_Frequency_02": "0.0",
    "JMY_Concentration_1000": "38",
    "JMY_Concentration_1250": "46",
    "JMY_Concentration_1400": "52",
    "JMY_Concentration_1500": "57",
    "JMY_Concentration_1600": "57",
    "JMY_Concentration_1750": "57",
    "JMY_Concentration_2000": "58",
    "JMY_Concentration_250": "13",
    "JMY_Concentration_2500": "62",
    "JMY_Concentration_2900": "54",
    "JMY_Concentration_3000": "0",
    "JMY_Concentration_500": "14",
    "JMY_Height": "1204",
    "In_Concentration": "54.289642",
    "In_Flow": "696.1376",
    "Monitor_Time": "2023-10-23 15:14:00",
    "Overflow_Concentration": "0.7704132",
    "Pressure": "0.0",
    "Underflow_Concentration": "0.0",
    "Underflow_PumpStatus": "false",
    "Yin_Concentration": "2.5"
  }
],
"user_info": {
  "control_info": {
    "clear_layer_target": 1700,
    "overflow_target": 2.2,
    "max_freq": 30,
    "min_freq": 0
  },
  "opt_info": {
    "overflow_weight": 1000,
    "pop_size": 8,
    "max_iter": 20,
    "freq_filter_para": 0.9,
    "min_freq_step": 0.1,
    "max_freq_step": 4.0
  }
}
```

```
},
"bound_info": {
  "ph_bound": 3,
  "pressure_bound1": 0.2,
  "pressure_bound2": 3.0,
  "pressure_hz1": 10,
  "pressure_hz2": 0,
  "overflow_filter": 3.0
},
"postprocess_info": {
  "grid_para": 1.0,
  "clear_layer_judge": 1800,
  "overflow_judge": 2.2,
  "output_freq": 10,
  "controller_weight": 0.6,
  "controller_coefficient": 1.0
},
"no_qsc_rule": {
  "no_qsc_flag": true,
  "setting_qsc": 1500,
  "inflow_upper": 5000,
  "qsc_low_pass": 0.1
}
},
"abnormal_handle_rule": {
  "default_freq": 25,
  "freq_rule": [
    {
      "in_lb": 0.0,
      "in_ub": 1000.0,
      "in_concentration_lb": 0.0,
      "in_concentration_ub": 50.0,
      "overflow_concentration_lb": 0.0,
      "overflow_concentration_ub": 3.0,
      "clear_height_lb": 2.0,
      "clear_height_ub": 4.0,
      "frequency_lb": 10.0,
      "frequency_ub": 15.0
    },
    {
      "in_lb": 0.0,
      "in_ub": 1000.0,
      "in_concentration_lb": 0.0,
      "in_concentration_ub": 50.0,
      "overflow_concentration_lb": 0.0,
      "overflow_concentration_ub": 3.0,
      "clear_height_lb": 1.5,
      "clear_height_ub": 2.0,
      "frequency_lb": 10.0,
      "frequency_ub": 15.0
    },
    {
      "in_lb": 0.0,
      "in_ub": 1000.0,
      "in_concentration_lb": 0.0,
      "in_concentration_ub": 50.0,
      "overflow_concentration_lb": 0.0,
      "overflow_concentration_ub": 3.0,
      "clear_height_lb": 0.0,
      "clear_height_ub": 1.5,
      "frequency_lb": 15.0,
      "frequency_ub": 20.0
    }
  ],
  "weight_rule": {
    "in_flow": 0.5,
    "in_concentration": 0.5
  }
}
```

```
}  
}
```

响应示例

```
{  
  "Model_boundarywater": 1166.66,  
  "detail_msg": "harrow pressure is larger than 0.2 and smaller than 3.0, recommend the provided  
frequency",  
  "device_id": "9A",  
  "input_data": {  
    "InBelt_Accumulate": 2000.0,  
    "InBelt_Instant": 700.0,  
    "In_Concentration": 51.14,  
    "In_Flow": 879.85,  
    "JMY_Concentration_1000": 55.0,  
    "JMY_Concentration_1250": 51.0,  
    "JMY_Concentration_1400": 53.0,  
    "JMY_Concentration_1500": 54.0,  
    "JMY_Concentration_1600": 54.0,  
    "JMY_Concentration_1750": 55.0,  
    "JMY_Concentration_250": 13.0,  
    "JMY_Concentration_500": 13.0,  
    "JMY_Height": 1044.0,  
    "JMY_ValidTag": 1.0,  
    "Monitor_Time": "2023-10-23 15:15:00",  
    "Overflow_Concentration": 0.883,  
    "Pressure": 1.0,  
    "Underflow_Concentration": 322.27,  
    "Underflow_PumpStatus": 1.0,  
    "Yin_Concentration": 2.5,  
    "Yin_Frequency": 12.0  
  },  
  "predict_result": {  
    "Adjust_boundarywater": 1469.36,  
    "Model_boundarywater": 1166.66,  
    "Model_boundarywater_m10": 1200.0,  
    "Model_boundarywater_m15": 1200.0,  
    "Model_boundarywater_m5": 1200.0,  
    "Model_overflow_m10": 0.86,  
    "Model_overflow_m15": 0.89,  
    "Model_overflow_m5": 0.88,  
    "kept_boundarywater": 1515.37,  
    "kept_overflowConcentration": 0.92  
  },  
  "recommend_yin_frequency": 10,  
  "request_id": "",  
  "status_msg": "frequency recommended using AI."  
}
```

3.4.14 表格直推预测大模型

功能介绍

可实现免微调直推表格预测，面对有限样本条件下，基于上下文关联推理技术，免微调自适应数据分布，可以实现开箱即用的效果。

URI

POST /

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-365 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-366 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-367 请求 Body 参数

参数	是否必选	参数类型	描述
target	是	string	参数解释： 指定要预测的目标列名。 约束限制： 仅支持单个目标。 取值范围： 不涉及 默认取值： 不涉及
sample	是	json	参数解释： 预测所需的样例数据（ few shot ）， sample是json格式， json的key对应特征列名， value 是一个Array， 对应该特征列的数据。格式详见请求示例。 约束限制： sample行数 <= 10000行 特征数 <= 500 sample * 特征数 <= 1000000 云上部署数据量 < 12MB 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
data	是	Array	参数解释： 待进行预测的数据，data为一个数组，数组中包含多个对象，每个对象是一组完整的特征数据。 约束限制： 待预测特征名需要与sample中的特征名保持一致。例如，训练数据中特征列按照feature_1、feature_2……进行命名，在调用推理接口时，特征名也需要保持相同。同时推理接口中特征数量需要与训练数据中的特征数保持一致。一组特征数据填写完成后填写剩余待预测数据，格式详见请求示例。 data行数 <= 1000行 特征数 <= 500 取值范围： 不涉及 默认取值： 不涉及
task_type	是	string	参数解释： 任务类型。 约束限制： 支持的类型包括regression和classification，分别对应回归和分类任务。 取值范围： regression、classification 默认取值： 不涉及

响应参数

状态码： 200

表 3-368 响应 Body 参数

参数	参数类型	描述
results	LIST	参数解释： 预测结果的列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
time_cost	JSON	参数解释： 当启动服务时，本次请求服务各阶段耗时情况。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-369 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

```
{
  "target": "feature_0",
  "task_type": "regression",
  "sample": {
    "feature_0": [
      9,
      0
    ],
    "feature_1": [
      252.71994790753982,
      0
    ],
    "feature_2": [
      584.8740678212971,
      0
    ],
    "feature_3": [
```

```
507.5732435552864,  
0  
],  
"feature_4": [  
75.7524144068944,  
0  
]  
},  
"data": [  
{  
"feature_1": 6.4533336224,  
"feature_2": 677.3766556825,  
"feature_3": 923.0984447151,  
"feature_4": 837.6293168679  
},  
{  
"feature_1": 712.3825532408,  
"feature_2": 373.0545721447,  
"feature_3": 393.8145421256,  
"feature_4": 597.3197447678  
}  
]  
}
```

响应示例

```
{  
  "results": [  
    0,  
    1,  
    ...  
    0  
  ],  
  "time_cost": {  
    "infer_cost_time": 233,  
    "postprocess_cost_time": 13,  
    "preprocess_cost_time": 12,  
    "service_cost_total_time": 258  
  }  
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.5 科学计算大模型

3.5.1 创建推理作业

功能介绍

创建科学计算大模型的推理作业。

URI

POST /v2/{project_id}/tasks

科学计算大模型的API请求地址可以直接在ModelArts Studio平台获取。科学计算大模型部署完成后，在“模型开发 > 模型部署”，单击“模型名称”在“详情”页面获取API请求地址。在线服务可参考[获取在线部署的大模型推理API接口域名](#)。边缘服务可参考[获取边缘部署的大模型推理API接口域名](#)

请求参数

表 3-370 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-371 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。2.2-API Key认证响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-372 请求 body 参数

参数	是否必选	参数类型	描述
models	否	Array	参数解释： 选择用来推理的模型子集列表。可通过配置model_tag的方式，指定参与推理的模型子集。例如：["global-weather"], 如不传则默认使用全部模型进行推理。model_tag与模型的对应关系请见表9 模型资产与model tag对应关系。径流模型不支持该参数。 约束限制： 字符串列表，指定的model tag需要在已部署的模型范围内。 取值范围： 不涉及 默认取值： 不涉及
data_dirs	是	Map<string, string>	参数解释： 根据不同模型指定输入数据的路径。格式为{model_tag: shema://dataset_path}，例如 {"global-weather": "obs://path/to/data/"}, model_tag与模型的对应关系请见表9 模型资产与model tag对应关系。 约束限制： shema参数在线服务仅支持obs，边缘服务支持file（本地路径）。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
output_dir	是	String	参数解释： 推理结果输出路径。格式为 shema://dataset_path，例如 file:///path/to/data/。 约束限制： shema参数在线服务仅支持 obs，边缘服务支持file（本地路径）。 取值范围： 不涉及 默认取值： 不涉及
start_times	是	Array	参数解释： 起报时间点列表，若不传入 start_time_interval，则列表中的每个时间均作为起报时，若传入start_time_interval，则 start_times必须只包含两个时间，分别作为起报时间的起点和终点，根据start_time_interval 最终插值出所有起报时间点（总起报时间点数量不能超过列表长度上限）。径流模型不支持该参数。 约束限制： 起报时间点字符串格式为 YYYYMMDDHH时间戳。 取值范围： 不涉及 默认取值： 不涉及
start_time_interval	否	String	参数解释： 起报时间间隔时长。仅数字代表小时数，支持数字+单位表示，例如1d，3h。径流模型不支持该参数。 约束限制： 不涉及 取值范围： (0h, 24h] 默认取值： 6h

参数	是否必选	参数类型	描述
forecast_lead_time	否	String	参数解释： 预报时效。仅数字代表小时数，支持数字+单位表示，例如6d。径流模型不支持该参数。 约束限制： 不涉及 取值范围： [1h, 720h] 默认取值： 168h
draw_figures	否	Bool	参数解释： 是否输出结果图片。径流模型不支持该参数。 约束限制： 不涉及 取值范围： true/false 默认取值： true
clipping_geo_ranges	否	ClippingGeoranges object	参数解释： 指定对结果文件剪裁的地理范围，在结果文件中仅会输出指定范围内的区域。如不指定，则默认输出原结果范围。径流模型不支持该参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
ensemble	否	EnsembleDto object	参数解释： 集合预报信息。径流模型不支持该参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-373 ClippingGeoRanges

参数	是否必选	参数类型	描述
latitude	否	Array	参数解释： 指定对结果文件进行剪裁的纬度范围，长度为2的定长数组，左端小于右端，例如：[45, 70]。如指定longitude，不指定latitude，默认补全为全球范围[-90, 90]。 约束限制： 长度为2的定长小数数组，左端小于右端。 取值范围： [-90, 90] 默认取值： [-90, 90]
longitude	否	Array	参数解释： 指定对结果文件进行剪裁的经度范围，例如：[110, 130]。如指定latitude，不指定longitude，默认补全为全球范围[0, 360]。 约束限制： 长度为2的定长小数数组，左端小于右端。 取值范围： [0, 360] 默认取值： [0, 360]

表 3-374 EnsembleDto

参数	是否必选	参数类型	描述
num_ensembles	否	Long	参数解释： 集合数量。在气象预报中，集合预报是指对初始场加入一定程序的扰动，使其生成一组由不同初始场预报的天气预报结果，从而提供对未来天气状态的概率信息。这种方法可以更好地表达预报的不确定性，从而提高预报的准确性和可靠性。 约束限制： 不涉及 取值范围： [2, 10] 默认取值： 不涉及
noise	否	EnsembleNoiseDto object	参数解释： 集合预报的噪声信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-375 EnsembleNoiseDto

参数	是否必选	参数类型	描述
method	否	String	参数解释： 集合预报的加噪方式。可选： {"perlin"}。 perlin噪音通过对输入数据（比如空间坐标）进行随机扰动，让模拟出的天气接近真实世界中的变化。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
perlin_scale	否	Double	参数解释： 集合预报的Perlin加噪scale。 约束限制： 不涉及 取值范围： (0, 0.5) 默认取值： 不涉及
perlin_octave	否	Long	参数解释： 用于选择集合预报的Perlin加噪octave。Perlin噪音的octave指的是噪音的频率，在生成Perlin噪音时，可以将多个不同频率的噪音叠加在一起，以增加噪音的复杂度和细节。每个频率的噪音称为一个octave，而叠加的octave数越多，噪音的复杂度也就越高。 约束限制： 不涉及 取值范围： [1, 10) 默认取值： 不涉及

参数	是否必选	参数类型	描述
perlin_x	否	Double	参数解释： 用于选择集合预报的Perlin加噪x经度方向的尺度。 约束限制： 不涉及 取值范围： [0, 1) 默认取值： 不涉及
perlin_y	否	Double	参数解释： 用于选择集合预报的Perlin加噪y纬度方向的尺度。 约束限制： 不涉及 取值范围： [0, 1) 默认取值： 不涉及

表 3-376 模型资产与 model tag 对应关系

模型资产名称	model tag
Pangu-AI4S-Global-Weather	global-weather
Pangu-AI4S-Global-Ocean	global-ocean
Pangu-AI4S-Regional-Ocean	regional-ocean
Pangu-AI4S-Global-Ecology	global-ecology
Pangu-AI4S-Global-Swell	global-swell
Pangu-AI4S-Regional-Pollution	regional-pollution
Pangu-AI4S-Regional-Pollution-Tianrong	regional-pollution
Pangu-AI4S-Regional-Weather	regional-weather
Pangu-AI4S-Regional-Precip	regional-precip
Pangu-AI4S-Regional-Photovoltaics	regional-photovoltaics
Pangu-AI4S-Regional-Wind	regional-wind
Pangu-AI4S-Regional-Runoff	regional-runoff

表 3-377 全球中期天气要素预测模型、降水模型信息表

模型	预报层次	预报高空变量	预报表面变量	降水	时间分辨率	水平分辨率	区域范围
全球中期天气要素预测模型	13层 (1000 hpa, 925hpa , 850hpa , 700hpa , 600hpa , 500hpa , 400hpa , 300hpa , 250hpa , 200hpa , 150hpa , 100hpa , 50hpa)	T: 温度 Q: 比湿 Z: 重力位势 U: U风 V: V风	MLSP: 海平面气压。 U10: 10米U风, 经度方向。 V10: 10米V风, 纬度方向。 T2M: 2米温度。	-	1、3、6、24小时。	0.25°*0.25°	全球

模型	预报层次	预报高空变量	预报表面变量	降水	时间分辨率	水平分辨率	区域范围
降水基模型	13层 (1000 hpa, 925hpa , 850hpa , 700hpa , 600hpa , 500hpa , 400hpa , 300hpa , 250hpa , 200hpa , 150hpa , 100hpa , 50hpa)	T: 温度 Q: 比湿 Z: 重力位势 U: U风 V: V风	MLSP: 海平面气压。 U10: 10米U风, 经度方向。 V10: 10米V风, 纬度方向。 T2M: 2米温度。	PRECIP 6: 过去6h累计降水。 PRECIP 24: 过去24h累计降水。	1、3、6、24小时。	0.25°*0.25°	全球

响应参数

状态码： 201

表 3-378 响应 Body 参数

参数	参数类型	描述
task_id	String	参数解释： 创建的作业ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

创建科学计算大模型推理作业

```
{
  "data_dirs": {
    "global-weather": "obs://path/to/data/"
  },
  "output_dir": "obs://path/to/data/",
  "start_times": ["2024010100", "2024010112", "2024010118"],
  "forecast_lead_time": "7d",
  "draw_figures": true,
  "ensemble": {
    "num_ensembles": 2,
    "noise": {
      "method": "perlin",
      "perlin_scale": 0.1,
      "perlin_octave": 3.0,
      "perlin_x": 0.5,
      "perlin_y": 0.5
    }
  }
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "task_id": "bd915122-600d-4045-b13e-dd038d2c61e7"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.5.2 查询推理作业详情

功能介绍

根据[创建推理作业](#)获取的作业ID获取科学计算大模型的结果数据。

URI

GET /v2/{project_id}/tasks/{task_id}

调用查询推理作业详情API所需要的域名与创建推理作业API一致，可以参考[创建推理作业](#)获取。获取完整的创建推理作业API后，在这个API基础上去除末尾的/tasks即是域名。

表 3-379 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID，获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_id	是	String	参数解释： 推理作业的ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-380 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-381 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是（云上部署模型填写、边缘部署模型仅在监控网关访问模式下填写）	String	参数解释： API Key值。 用于获取操作API的权限。 2.2-API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码： 200

表 3-382 响应 body 参数

参数	参数类型	描述
progress	ProgressDto object	参数解释： 作业进度信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
status	String	参数解释： 作业运行状态。waiting：等待， running：运行中，failed：失败， finished：已完成。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-383 ProgressDto

参数	参数类型	描述
start_time	Long	参数解释： 开始时间戳。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
overall	Double	参数解释： 作业运行进度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
estimated_remaining_time	Long	参数解释： 预估剩余时间，单位秒。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
estimated_finish_time	Long	参数解释： 预估作业完成时间戳。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

状态码： 200

成功响应示例

```
{
  "progress": {
    "estimated_finish_time": 1755226821,
    "estimated_remaining_time": 367,
    "overall": 0.5,
    "start_time": 1755226086
  },
  "status": "running"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.6 DeepSeek 大模型

功能介绍

三方NLP大模型API是基于DeepSeek大模型推出的接口服务，它支持多场景文本交互，能够快速生成高质量对话、文案、故事等内容，可用于文本摘要、智能问答、内容创作等场景。

URI

NLP推理服务支持使用盘古推理接口（V1推理接口）调用，也支持使用业界通用的OpenAi格式接口（V2推理接口）调用。

V1接口、V2接口的鉴权方式不同，请求体和返回体略有差异。

表 3-384 NLP 服务推理接口

API分类	API访问路径（URI）
V1推理接口	POST /v1/{project_id}/deployments/{deployment_id}/chat/completions
V2推理接口	POST /api/v2/chat/completions

表 3-385 V1 推理接口路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID，获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
deployment_id	是	String	参数解释： 模型的部署ID。 模型训练部署完成后，单击模型部署列表中的模型，进入详情页获取。 Deployment ID(V1接口使用) 164d5102-659b-41af-a617-e21d4ddc5eb3  约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

V1、V2推理接口的鉴权方式不同，请求参数与响应参数也有不同，说明如下：

Header参数

1. V1接口支持Token鉴权方式，也支持API Key鉴权方式。两种鉴权方式请求Header参数说明如下：
- 使用Token认证的请求Header参数见表3-386。

表 3-386 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。认证鉴权中响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

- 使用API Key认证方式的请求Header参数见表 请求Header参数（API Key认证）。

表 3-387 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是	String	参数解释： API Key值。 用于获取操作API的权限。API Key认证响应消息头中X-Apig-AppCode的值即为API Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

2. V2接口只支持API Key鉴权方式。请求Header参数见表3-388。

表 3-388 V2 接口请求 Header 参数（OpenAI 格式的 API Key 认证）

参数	是否必选	参数类型	描述
Authorization	是	String	参数解释： 用户创建应用接入获取的API Key，拼接“Bearer ”后的字符串。示例：Bearer d59*****9C3 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

请求Body参数

V1、V2推理接口请求Body参数一致，如表3-389。

表 3-389 请求 Body 参数

参数	是否必选	参数类型	描述
messages	是	Array of ChatCompletionMessageParam objects	参数解释： 多轮对话问答对，包含两个属性：role和content。 - role表示对话的角色，取值是system或user。 如果需要模型以某个人设形象回答问题，可以将role参数设置为system。不使用人设时，可设置为user。在一次会话请求中，人设只需要设置一次。 - content表示对话的内容，可以是任意文本。 messages参数可以帮助模型根据对话的上下文生成合适的回复。 约束限制： 数组长度：1 - 20 取值范围： 不涉及 默认取值： 不涉及
model	是	String	参数解释： 使用的模型ID，根据所部署的模型填写，填写DeepSeek-R1或DeepSeek-V3。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
stream	否	boolean	参数解释： 流式开关。流式输出协议为SSE(Server-Sent Events) 协议。 如果开启流式，请赋值true。开启流式开关后，API会在生成文本的过程中，实时地将生成的文本发送给客户端，而不是等到生成完成后一次性将所有文本发送给客户端。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false
temperature	否	Float	参数解释： 用于控制生成文本的多样性和创造力。 控制采样随机性的浮点数。一般来说，temperature越低，适合完成确定性的任务。temperature越高，如0.9，适合完成创造性的任务。值为 0 意味着贪婪采样。当取值超过1，会大概率出现效果不可用问题。 temperature参数可以影响语言模型输出的质量和多样性，但也不是唯一的因素。还有其他一些参数，如top_p参数也可以用来调整语言模型的行为和偏好，但不建议同时更改这两temperature和top_p。 约束限制： 不涉及 取值范围： (0, 1] 默认取值： 1.0

参数	是否必选	参数类型	描述
top_p	否	Float	参数解释： 核采样参数。作为调节采样温度的替代方案，模型会考虑前 top_p 概率的 token 的结果。0.1 就意味着只有包括在最高 10% 概率中的 token 会被考虑。建议修改这个值或者更改 temperature，但不建议同时对两者进行修改。 说明 token 是指模型处理和生成文本的基本单位。token 可以是词或者字符的片段。模型的输入和输出的文本都会被转换成 token，然后根据模型的概率分布进行采样或者计算。 约束限制： 不涉及 取值范围： (0.0, 1.0] 默认取值： 0.8
max_tokens	否	Integer	参数解释： 生成文本的最大输出 token 数量。 约束限制： 输入的文本加上生成的文本总量不能超过模型所能处理的最大长度。 取值范围： ● 最小值： 1 ● 最大值： 8192 默认取值： 4096

参数	是否必选	参数类型	描述
presence_penalty	否	Float	参数解释： 用于调整模型对新Token的处理方式。即如果一个Token已经在之前的文本中出现过，那么模型在生成这个Token时会受到一定的惩罚。当presence_penalty的值为正数时，模型会更倾向于生成新的、未出现过的Token，即模型会更倾向于谈论新的话题。 约束限制： 不涉及 取值范围： • 最小值： -2 • 最大值： 2 默认取值： 0（表示该参数未生效）
frequency_penalty	否	Float	参数解释： 用于调整模型对频繁出现的Token的处理方式。即如果一个Token在训练集中出现的频率较高，那么模型在生成这个Token时会受到一定的惩罚。当frequency_penalty的值为正数时，模型会更倾向于生成出现频率较低的Token，即模型会更倾向于使用不常见的词汇。 约束限制： 不涉及 取值范围： 最小值： -2 最大值： 2 默认取值： 0（表示该参数未生效）

参数	是否必选	参数类型	描述
tools	否	Array	参数解释： 在 API 调用中，您可以向模型描述函数，让模型智能地选择输出包含参数的 JSON 对象来调用这些函数。聊天完成后，API 不自行调用函数。 约束限制： 进行Function calling(函数调用时必须设置)时此参数为必选。 取值范围： 函数调用允许您更可靠地从模型中获取结构化数据。例如，您可以： • 创建聊天机器人，通过调用外部 API（例如 ChatGPT 插件） 例如定义函数，如 send_email(to: string, body: string)，或 get_current_weather(location: string, unit: 'celsius' 'fahrenheit') • 将自然语言转换为 API 调用 例如，转换“谁是我的顶级客户？” get_customers(min_revenue: int, created_before: string, limit: int) 并调用您的内部 API • 从文本中提取结构化数据 例如定义调用的函数 extract_data(name: string, birthday: string)，或者 sql_query(query: string) 函数调用的基本步骤顺序如下： 1. 使用用户查询和 functions 参数中定义的一组函数调用模型。 2. 模型可以选择调用一个函数；如果是，内容将是一个符合您自定义模式的字符串化 JSON 对象（注意：该模型可能生成无效的 JSON 或幻觉参数）。 3. 在代码中将字符串解析为 JSON，并使用提供的参数（如果存在）调用函数。

参数	是否必选	参数类型	描述
			4. 通过将函数响应作为新消息追加，再次调用模型，并让模型将结果汇总返回给用户。 默认取值： 不涉及
tool_choice	否	String	参数解释： 如果您希望对于某一类问题，大模型能够采取制定好的工具选择策略（如强制使用某个工具、强制不使用工具），可以通过修改 tool_choice 参数来强制指定工具调用的策略。 约束限制： 不涉及 取值范围： 函数名称或auto，如果您想强制模型调用一个特定的函数，您可以通过设置 function_call: {"name": "<insert-function-name>"} 默认取值： auto（由模型自己决定是否调用函数，如果是，则调用那个函数）

表 3-390 ChatCompletionMessageParam

参数	是否必选	参数类型	描述
role	是	String	参数解释： 对话的角色，默认取值范围：system、user、assistant、tool、function。支持自定义。 如果需要模型以某个人设形象回答问题，可以将role参数设置为system。不使用人设时，可设置为user。 返回参数时，为固定值：assistant。 在一次会话请求中，人设只需要设置一次。 约束限制： 不涉及 取值范围： 不涉及 默认取值： system、user、assistant、tool、function
content	是	String	参数解释： 对话的内容，可以是任意文本，单位token。 约束限制： 设置多轮对话时，message中content个数不能超过20。 最小长度：1 最大长度：不同模型支持的token长度。 取值范围： 不涉及 默认取值： None

响应参数

非流式

状态码： 200

表 3-391 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 用来标识每个响应的唯一字符串。 约束限制： 形式为："chatcmpl-{random_uuid()}"。 取值范围： 不涉及 默认取值： 不涉及
object	String	参数解释： 固定为"chat.completion"，表示正在发起一个聊天式（ Chat Completion ）文本生成请求。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
created	Integer	参数解释： 响应生成的时间，单位：s。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model	String	参数解释： 请求模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
choices	Array of ChatCompletionResponseChoice objects	参数解释: 生成的文本列表。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
usage	UsageInfo object	参数解释: 该对话请求的token用量信息。该参数可以帮助用户了解和控制模型的使用情况，避免超出Tokens限制。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
prompt_logprobs	Object	参数解释: 输入文本以及对应token的对数概率信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: null

表 3-392 ChatCompletionResponseChoice

参数	参数类型	描述
message	ChatMessage object	参数解释: 生成的文本内容。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
index	Integer	参数解释: 生成的文本在列表中的索引，从0开始。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
finish_reason	String	参数解释: 模型停止生成token的原因。 约束限制: 不涉及 取值范围: [stop, length, content_filter, tool_calls, insufficient_system_resource] • stop: 模型自然停止生成，或遇到stop序列中列出的字符串。 • length: 输出长度达到了模型上下文长度限制，或达到了max_tokens的限制。 • content_filter: 输出内容因触发过滤策略而被过滤。 • tool_calls: 模型决定调用外部工具（函数/API）来完成任务。 • insufficient_system_resource: 系统推理资源不足，生成被打断。 默认取值: stop

参数	参数类型	描述
logprobs	Object	参数解释: 评估指标，表示推理输出的置信度。 约束限制: 不涉及 取值范围: 不涉及 默认取值: null
stop_reason	Union[Integer, String]	参数解释: 导致生成停止的token id或者字符串。如果是遇到EOS token则返回默认值。如果是因为用户请求参数中指定的stop参数中的字符串或者token id，则返回对应的字符串或者token id。不是 openAI接口标准字段，但vllm接口支持。 约束限制: 不涉及 取值范围: 不涉及 默认取值: None

表 3-393 UsageInfo

参数	参数类型	描述
prompt_tokens	Number	参数解释: 用户prompt中所包含的Token数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
total_tokens	Number	参数解释： 该次对话请求中，所有Token的数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
completion_tokens	Number	参数解释： 推理模型所产生的答案的Token数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-394 ChatMessage

参数	参数类型	描述
role	String	参数解释： 生成这条消息的角色。固定为：assistant。 约束限制： 不涉及 取值范围： assistant 默认取值： assistant
content	String	参数解释： 对话的内容。 约束限制： 最小长度：1 最大长度：不同模型支持的token长度。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
reasoning_content	String	参数解释： 内容为在最终答案之前的推理内容（模型的思考过程）。 约束限制： 仅适用于DeepSeek-R1模型。 取值范围： 不涉及 默认取值： 不涉及
tool_calls	Array of ToolCall objects	参数解释： 在发起 Function Calling后，模型回复的要调用的工具以及调用工具所需的参数。可以包含一个或多个工具响应对象。 约束限制： 不涉及 取值范围： 不涉及 默认取值： []

表 3-395 ToolCall

参数	参数类型	描述
id	String	参数解释： 用来标识每个响应的唯一字符串。 约束限制： 形式为："chatcmpl-tool-{random_uuid()}"。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
type	String	参数解释： 工具的类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： function
function	FunctionCall Object	参数解释： 需要被调用的函数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-396 FunctionCall

参数	参数类型	描述
name	String	参数解释： 需要被调用的函数名。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
arguments	String	参数解释： 需要输入到工具中的参数，为JSON字符串。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

流式（stream参数为true）

状态码： 200

表 3-397 流式输出的数据单元

参数	参数类型	描述
data	CompletionStreamResponse object	参数解释： stream=true时，模型生成的消息以流式形式返回。生成的内容以增量的方式逐步发送回来，每个data字段均包含一部分生成的内容，直到所有data返回，响应结束。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-398 CompletionStreamResponse

参数	参数类型	描述
id	String	参数解释： 该对话的唯一标识符。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
created	Integer	参数解释： 创建聊天完成时的Unix时间戳（以秒为单位）。流式响应的每个chunk的时间戳相同（大模型往往以多块（chunk）形式返回结果，便于传输）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
model	String	参数解释： 生成该completion的模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
object	String	参数解释： 对象的类型，其值为chat.completion.chunk。表示这条记录是一个流式chunk而不是完整结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
choices	ChatCompletionResponseStreamChoice	参数解释： 模型生成的completion的选择列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-399 ChatCompletionResponseStreamChoice

参数	参数类型	描述
index	Integer	参数解释： 该completion在模型生成的completion的选择列表中的索引。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
finish_reason	String	参数解释： 模型停止生成token的原因。 约束限制： 不涉及 取值范围： [stop, length, content_filter, tool_calls, insufficient_system_resource] • stop：模型自然停止生成，或遇到stop序列中列出的字符串。 • length：输出长度达到了模型上下文长度限制，或达到了max_tokens的限制。 • content_filter：输出内容因触发过滤策略而被过滤。 • tool_calls：模型决定调用外部工具（函数/API）来完成任务。 • insufficient_system_resource：系统推理资源不足，生成被打断。 默认取值： 不涉及

表 3-400 DeltaMessage

参数	参数类型	描述
role	String	参数解释： 产生这条消息的角色。固定为：assistant。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
content	String	参数解释： completion增量的内容。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
reasoning_content	String	参数解释： 内容为最终答案之前的推理内容（模型的思考过程）。 约束限制： 说明 仅适用于DeepSeek-R1模型。 取值范围： 不涉及 默认取值： 不涉及
tool_calls	Array of ToolCall objects	参数解释： 模型回复的要调用的工具以及调用工具所需的参数。可以包含一个或多个工具响应对象。 约束限制： 不涉及 取值范围： 不涉及 默认取值： []

表 3-401 ToolCall

参数	参数类型	描述
id	String	参数解释： 用来标识每个响应的唯一字符串。 约束限制： 形式为："chatcmpl-tool-{random_uuid()}"。 取值范围： 不涉及 默认取值： 不涉及
type	String	参数解释： 工具的类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： function
function	FunctionCall Object	参数解释： 需要被调用的函数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-402 FunctionCall

参数	参数类型	描述
name	String	参数解释： 函数名称，只在第一个chunk中有值（大模型往往以多块（chunk）形式返回结果，便于传输）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
arguments	String	参数解释： 需要输入到工具中的参数，把所有 chunk 中的 arguments 字符串依次连接，即可得到完整的工具调用参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-403 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

- 非流式
V1推理接口：
POST https://{endpoint}/v1/{project_id}/alg-infer/3rdnlp/service/{deployment_id}/v1/chat/completions

Request Header:
Content-Type: application/json
X-Auth-Token:
MIINRwYJKoZIhvcNAQcCoIINODCCDTQCAQExDTALBgIghkgBZQMEAgEwgguVBgkqhkiG...

Request Body:
{

```

"model": "DeepSeek-V3",
"messages": [
  {
    "role": "user",
    "content": "你好"
  }
]
}

Function calling Request Body:
{
  "messages": [
    {
      "role": "user",
      "content": "Please tell us about the weather at Beijing."
    }
  ],
  "model": "DeepSeek-V3",
  "temperature": 0,
  "max_tokens": 1280,
  "tools": [
    {
      "type": "function",
      "function": {
        "name": "get_weather",
        "description": "Get the current weather in a given location",
        "parameters": {
          "type": "object",
          "properties": {
            "location": {
              "type": "string",
              "description": "City and state, e.g. San Francisco, CA"
            },
            "unit": {
              "type": "string",
              "enum": [
                "celsius",
                "fahrenheit"
              ]
            }
          }
        },
        "required": [
          "location"
        ]
      }
    }
  ],
  "tool_choice": "auto"
}

V2推理接口:
POST https://{endpoint}/api/v2/chat/completions

Request Header:
Content-Type: application/json
Authorization: Bearer 201ca68f-45f9-4e19-8fa4-831e...

Request Body:
{
  "model": "DeepSeek-V3",
  "messages": [
    {
      "role": "user",
      "content": "你好"
    }
  ]
}

Function calling Request Body:
{
  "messages": [

```

```
{
  "role": "user",
  "content": "Please tell us about the weather at Beijing."
},
"model": "DeepSeek-V3",
"temperature": 0,
"max_tokens": 1280,
"tools": [
  {
    "type": "function",
    "function": {
      "name": "get_weather",
      "description": "Get the current weather in a given location",
      "parameters": {
        "type": "object",
        "properties": {
          "location": {
            "type": "string",
            "description": "City and state, e.g. San Francisco, CA"
          },
          "unit": {
            "type": "string",
            "enum": [
              "celsius",
              "fahrenheit"
            ]
          }
        },
        "required": [
          "location"
        ]
      }
    }
  }
],
"tool_choice": "auto"
}
```

- 流式 (stream参数为true)

V1推理接口:

POST https://{endpoint}/v1/{project_id}/alg-infer/3rdnlp/service/{deployment_id}/v1/chat/completions

Request Header:

Content-Type: application/json

X-Auth-Token:

MIINRwYJKoZIhvcNAQcCoIIODCCDTQCAQExDTALBglghkgBZQMEAgEwgggVBgkqhkiG...

Request Body:

```
{
  "model": "DeepSeek-V3",
  "messages": [
    {
      "role": "user",
      "content": "你好"
    }
  ],
  "stream": true
}
```

Function calling Request Body:

```
{
  "messages": [
    {
      "role": "user",
      "content": "Please tell us about the weather at Beijing."
    }
  ],
  "model": "DeepSeek-V3",
  "temperature": 0,
  "max_tokens": 1280,
}
```

```
"tools": [
  {
    "type": "function",
    "function": {
      "name": "get_weather",
      "description": "Get the current weather in a given location",
      "parameters": {
        "type": "object",
        "properties": {
          "location": {
            "type": "string",
            "description": "City and state, e.g. San Francisco, CA"
          },
          "unit": {
            "type": "string",
            "enum": [
              "celsius",
              "fahrenheit"
            ]
          }
        },
        "required": [
          "location"
        ]
      }
    }
  }
],
"tool_choice": "auto",
"stream": true
}
```

V2推理接口:

POST <https://{endpoint}/api/v2/chat/completions>

Request Header:

Content-Type: application/json

Authorization: Bearer 201ca68f-45f9-4e19-8fa4-831e...

Request Body:

```
{
  "model": "DeepSeek-V3",
  "messages": [
    {
      "role": "user",
      "content": "你好"
    }
  ],
  "stream": true
}
```

Function calling Request Body:

```
{
  "messages": [
    {
      "role": "user",
      "content": "Please tell us about the weather at Beijing."
    }
  ],
  "model": "DeepSeek-V3",
  "temperature": 0,
  "max_tokens": 1280,
  "tools": [
    {
      "type": "function",
      "function": {
        "name": "get_weather",
        "description": "Get the current weather in a given location",
        "parameters": {
          "type": "object",
          "properties": {
```

```
        "location": {
          "type": "string",
          "description": "City and state, e.g. San Francisco, CA"
        },
        "unit": {
          "type": "string",
          "enum": [
            "celsius",
            "fahrenheit"
          ]
        }
      },
      "required": [
        "location"
      ]
    }
  ],
  "tool_choice": "auto",
  "stream": true
}
```

响应示例

状态码： 200

OK

- 非流式问答响应

```
{
  "id": "chat-9a75fc02e45d48db94f94ce38277beef",
  "object": "chat.completion",
  "created": 1743403365,
  "model": "DeepSeek-V3",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": "你好！有什么我可以帮助你的吗？",
        "tool_calls": []
      },
      "finish_reason": "stop"
    }
  ],
  "usage": {
    "prompt_tokens": 64,
    "total_tokens": 73,
    "completion_tokens": 9
  }
}
```

- 带有思维链的非流式问答响应

```
{
  "id": "81c34733-0e7c-4b4b-a044-1e1fcd54b8db",
  "model": "deepseek-r1_32k",
  "created": 1747485310,
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": "\n\n你好！很高兴见到你，有什么我可以帮忙的吗？",
        "reasoning_content": "嗯，用户刚刚发了一个简短的“你好”，这是在用中文打招呼。首先我
```

需要确认他们的需求是什么，可能只是想测试一下回复，或者有具体的问题要问。另外，我需要考虑是否需要用英文回应，但用户用了中文，用中文回复更合适吧。\\n\\n然后，我要确保回复友好且符合指南，不能涉及敏感内容。用户可能期待进一步的对话或者有问题需要帮助。这时候应该保持开放式的回答，邀请他们提出具体的问题或需求。比如，可以说“你好！很高兴见到你，有什么我可以帮忙的吗？”这样既礼貌

又主动提供帮助。\\n\\n另外，注意避免使用任何格式或markdown，保持自然简洁。可能存在用户刚接触这个平台，不熟悉如何提问的情况，所以用鼓励的语气可能会更好。检查有没有任何拼写或语法错误，确保回复正确无误。\\n",

```
      "tool_calls": [
        ]
      },
      "finish_reason": "stop"
    }
  ],
  "usage": {
    "completion_tokens": 184,
    "prompt_tokens": 6,
    "total_tokens": 190
  }
}
```

- 流式问答响应

V1推理接口返回体:

data:

```
{
  "id": "chat-97313a4bc0a342558364345de0380291",
  "object": "chat.completion.chunk",
  "created": 1743404317,
  "model": "DeepSeek-V3",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "logprobs": null,
        "finish_reason": null
      }
    }
  ]
}
```

data:

```
{
  "id": "chat-97313a4bc0a342558364345de0380291",
  "object": "chat.completion.chunk",
  "created": 1743404317,
  "model": "DeepSeek-V3",
  "choices": [
    {
      "index": 0,
      "message": {
        "content": "你好",
        "logprobs": null,
        "finish_reason": null
      }
    }
  ]
}
```

data:

```
{
  "id": "chat-97313a4bc0a342558364345de0380291",
  "object": "chat.completion.chunk",
  "created": 1743404317,
  "model": "DeepSeek-V3",
  "choices": [
    {
      "index": 0,
      "message": {
        "content": "，有什么我能帮您的吗？",
        "logprobs": null,
        "finish_reason": "stop",
        "stop_reason": null
      }
    }
  ]
}
```

data:[DONE]

V2推理接口返回体:

data:

```
{
  "id": "chat-97313a4bc0a342558364345de0380291",
  "object": "chat.completion.chunk",
  "created": 1743404317,
  "model": "DeepSeek-V3",
  "choices": [
    {
      "index": 0,
      "delta": {
        "content": "你好",
        "logprobs": null,
        "finish_reason": null
      }
    }
  ]
}
```

data:

```
{
  "id": "chat-97313a4bc0a342558364345de0380291",
  "object": "chat.completion.chunk",
  "created": 1743404317,
  "model": "DeepSeek-V3",
  "choices": [
    {
      "index": 0,
      "delta": {
        "content": "，有什么我能帮您的吗？",
        "logprobs": null,
        "finish_reason": "stop",
        "stop_reason": null
      }
    }
  ]
}
```

data:

```
{
  "id": "chat-97313a4bc0a342558364345de0380291",
  "object": "chat.completion.chunk",
  "created": 1743404317,
  "model": "DeepSeek-V3",
  "choices": [
    {
      "index": 0,
      "delta": {
        "content": "，有什么我能帮您的吗？",
        "logprobs": null,
        "finish_reason": "stop",
        "stop_reason": null
      }
    }
  ]
}
```

data:[DONE]

- 带有思维链的流式问答响应

V1推理接口返回体:

data:{"id":"chat-

```
cc897cfa872a4fc993a803bbddf9268a",
  "object": "chat.completion.chunk",
  "created": 1747485542,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": "",
        "logprobs": null,
        "finish_reason": null
      }
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 6,
    "completion_tokens": 0
  }
}
```

data:{"id":"chat-

```
cc897cfa872a4fc993a803bbddf9268a",
  "object": "chat.completion.chunk",
  "created": 1747485542,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "reasoning_content": "嗯",
        "logprobs": null,
        "finish_reason": null
      }
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 7,
    "completion_tokens": 1
  }
}
```

data:{"id":"chat-

```
cc897cfa872a4fc993a803bbddf9268a",
  "object": "chat.completion.chunk",
  "created": 1747485542,
  "model": "DeepSeek-R1",
  "choices": [
    {
      "index": 0,
      "message": {
        "reasoning_content": "",
        "logprobs": null,
        "finish_reason": null
      }
    }
  ],
  "usage": {
    "prompt_tokens": 6,
    "total_tokens": 6,
    "completion_tokens": 0
  }
}
```

```
{"prompt_tokens":6,"total_tokens":8,"completion_tokens":2}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"用户发"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":10,"completion_tokens":4}}

...

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"生成"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":185,"completion_tokens":179}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"最终的"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":186,"completion_tokens":180}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"reasoning_content":"回复。"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":188,"completion_tokens":182}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"content":"\n\n你好"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":191,"completion_tokens":185}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"content":"! 很高兴"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":193,"completion_tokens":187}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"content":"见到"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":194,"completion_tokens":188}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"content":"你"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":195,"completion_tokens":189}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"content":"，有什么"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":197,"completion_tokens":191}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"content":"我可以帮"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":199,"completion_tokens":193}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"content":"您的吗"},"logprobs":null,"finish_reason":null}],"usage":
```



```
{"prompt_tokens":6,"total_tokens":201,"completion_tokens":195}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"message":{"content":"?","logprobs":null,"finish_reason":"stop","stop_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":203,"completion_tokens":197}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[],"usage":{"prompt_tokens":6,"total_tokens":203,"completion_tokens":197}}

data:[DONE]
V2推理接口返回体:
data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"role":"assistant","content":"","logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":6,"completion_tokens":0}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"嗯","logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":7,"completion_tokens":1}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"","logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":8,"completion_tokens":2}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"用户发","logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":10,"completion_tokens":4}}

...

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"生成","logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":185,"completion_tokens":179}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"最终的","logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":186,"completion_tokens":180}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"reasoning_content":"回复。","logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":188,"completion_tokens":182}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"\n\n\n你好","logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":191,"completion_tokens":185}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"! 很高兴","logprobs":null,"finish_reason":null}],"usage":
```

```
{"prompt_tokens":6,"total_tokens":193,"completion_tokens":187}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"见到"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":194,"completion_tokens":188}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"你"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":195,"completion_tokens":189}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":", 有什么"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":197,"completion_tokens":191}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"我可以帮"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":199,"completion_tokens":193}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"您的吗"},"logprobs":null,"finish_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":201,"completion_tokens":195}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[{"index":0,"delta":{"content":"?"},"logprobs":null,"finish_reason":"stop","stop_reason":null}],"usage":{"prompt_tokens":6,"total_tokens":203,"completion_tokens":197}}

data:{"id":"chat-cc897cfa872a4fc993a803bbddf9268a","object":"chat.completion.chunk","created":1747485542,"model":"DeepSeek-R1","choices":[],"usage":{"prompt_tokens":6,"total_tokens":203,"completion_tokens":197}}

data:[DONE]

• 流式问答，内容审核不通过时的响应
event:moderation data:{"suggestion":"block","reply":"作为AI语言模型，我的目标是以积极、正向和安全的方式提供帮助和信息，您的问题超出了我的回答范围。"}

data:[DONE]
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7 天筹求解器模型

3.7.1 Pangu-OPT-数学规划求解器

3.7.1.1 创建求解任务

功能介绍

数学规划求解器模型，支持LP/MILP/convex QP/SOCP等标准类型的数学规划问题求解。该接口可以创建“数学规划求解器”求解任务，并同步响应返回“task_id”，服务会将请求任务添加到待处理队列中进行排队（pending）、任务执行中（running）、求解完成（completed）等三个阶段。

URI

POST /task/solve

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-404 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-405 请求参数

参数	是否必选	参数类型	说明
input_json	是	Object	参数解释： 请求参数，具体包含待求解文件文件obs 路径，与求解参数，具体详情参见表3 input_json请求参数 。 约束限制： 不涉及 取值范围： 详情参见表3-406 默认取值： 不涉及

表 3-406 input_json 请求参数

参数	是否必选	参数类型	描述
input	是	input object	参数解释： 待求解文件输入，需将待求解文件传入obs中 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
output	否	output object	参数解释： 结果输出，将求解结果与日志文件传输至对应obs桶中 约束限制： 不涉及 取值范围： 不涉及 默认取值： 若未设置则最终结果会传入默认路径，为求解文件目录下的optverse_result文件夹内

参数	是否必选	参数类型	描述
parameters	否	parameters object	参数解释： 求解参数选择，包括可以选择求解时间限制，内存限制，以及gap值等 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-407 input

参数	是否必选	参数类型	描述
type	是	String	参数解释： 输入的格式类型，path代表传入的是obs路径，当前仅支持path 约束限制： 不涉及 取值范围： path 默认取值： 不涉及
data	是	String	参数解释： 待求解的模型文件，详情可参考附录的MPS/LP格式文件说明 约束限制： 取值为模型文件存储obs路径，参考格式为obs://test/test.mps，当前仅支持mps或者lp格式文件 取值范围： 不涉及 默认取值： 不涉及

表 3-408 output

参数	是否必选	参数类型	描述
type	是	String	参数解释： 输出的格式类型，path代表结果输出到obs对应的路径下，当前仅支持path 约束限制： 不涉及 取值范围： path 默认取值： 不涉及
data	是	String	参数解释： 最终结果存储路径 约束限制： 取值为OBS文件夹路径，参考格式为obs://test，表示最终求解结果会上传至test桶下 取值范围： 不涉及 默认取值： 不涉及

表 3-409 parameters

参数	是否必选	参数类型	描述
time_limit	否	Number	参数解释： 求解时间上限，单位为s。用于限制求解时长，若设置15s则表示求解15s后返回结果 约束限制： 不涉及 取值范围： [0.0, 1.79769e+308] 默认取值： 1.79769e+308

参数	是否必选	参数类型	描述
mem_limit	否	Integer	参数解释： 求解内存上限, 单位为 MB。用于限制求解的内存，表示求解时不会超出该内存限制 约束限制： 不涉及 取值范围： [100, 2147483647] 默认取值： 2147483647
gap	否	Number	参数解释： MIP目标gap值。表示相对最优性间隙，设置为0时表示希望求解器求解到最优解并证明最优性后再停止，数值越大则找到可行解的质量越差 约束限制： 不涉及 取值范围： [0.0, 1.79769e+308] 默认取值： 0.0001
threads	否	Integer	参数解释： 求解器在进行并行计算时的最大可用线程数 约束限制： 不涉及 取值范围： [1, 平台最大线程数] 默认取值： 平台最大线程数/2

响应参数

状态码：200

表 3-410 <添加求解任务>成功响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据 约束限制： 不涉及 取值范围： 详情参见 表3-411 默认取值： 不涉及

表 3-411 data 返回数据详情

参数	参数类型	描述
create_time	String	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： - created（任务已创建） - pending（任务排队中） - running（任务执行中） - completed（任务求解完成） - failed（任务失败） - deleted（任务已删除） 默认取值： 不涉及

参数	参数类型	描述
task_id	String	参数解释： 任务ID，用于后续查询任务接口使用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-412 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "input_json": {
    "input": {
      "type": "path",
      "data": "obs://xxx"
    },
    "output": {
      "type": "path",
      "data": "obs://xxx"
    }
  }
}
```

```
    },
    "parameters": {
      "time_limit": 15
    }
  }
}
```

响应示例

```
{
  "data": {
    "create_time": "2025-01-01 10:00:00.000000",
    "status": "created",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.1.2 查询任务详情

功能介绍

通过“查询任务详情”接口来具体查看当前任务的进度。当任务状态为“completed”时，说明任务执行完成，可从指定的OBS路径中查看完成的求解结果，具体可参考[查看求解结果](#)。

URI

GET /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-413 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-414 <查询任务详情>成功响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-415 。 默认取值： 不涉及

表 3-415 data

参数	参数类型	描述
create_time	string	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
logs	string	参数解释： 当前任务的执行日志详情。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
output	Object	参数解释： 任务处理结果。详见 表4 "output" 参数说明 ，详细结果可参考 查看求解结果 。 约束限制： 任务状态为completed时携带。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： • created（任务已创建） • pending（任务排队中） • running（任务执行中） • completed（任务求解完成） • failed（任务失败） • deleted（任务已删除） 默认取值： 不涉及
task_id	String	参数解释： 当前任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-416 output

参数	参数类型	描述
DualBound	Number	参数解释： 已证明的问题最优界。若是最小化问题，表示当前已知的全局最优解的理论下界，即最优解不可能比该值更小。若是最大化问题，表示理论上界，即最优解不可能比该值更大 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
Gap	Number	参数解释： gap值，表示相对最优性间隙，当其为0时代表当前解为理论最优解，输出结果为找到的最好可行解与已证明的最优界的相对差距 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
LP_iteration	Number	参数解释： LP迭代总数，求解线性规划（LP）时算法（如单纯形法、内点法）的迭代次数 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Nodes	Integer	参数解释： 节点个数，分支定界（Branch-and-Bound）算法中已求解的子问题总数 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
PrimalBound	Number	参数解释： 最优解，最小化问题的全局最小值或最大化问题的全局最大值 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
SolvingTime	Number	参数解释: 求解总时间, 单位秒 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
Status	String	参数解释: 求解状态 约束限制: 不涉及 取值范围: - Optimal solution found (求解到最优解) - Time limit reached (超时) - Memory limit reached (超出内存上限) - Problem is infeasible (问题不可行) - Problem is unbounded (问题无界) - Problem is infeasible or unbounded (问题无解或无界) - Unknown (发生未知错误) 默认取值: 不涉及

状态码：400

表 3-417 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释: 错误码 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "create_time": "2025-01-01 10:00:00.000000",
    "logs": "xxx",
    "output": {
      "DualBound": -4824.445547373,
      "Gap": 1.2896,
      "LP_Iteration": 1238146.0,
      "Nodes": 276292,
      "PrimalBound": -4763.0217345,
      "SolvingTime": 15.04,
      "Status": "Time limit reached"
    },
    "status": "completed",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.1.3 查询任务列表

功能介绍

通过“查询任务列表”接口来查询所有求解任务的状态及task_id。

URI

GET /task-list

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-418 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-419 <查询任务列表>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-420 默认取值： 不涉及

表 3-420 <查询任务列表>"data" 参数说明

参数	参数类型	描述
count	int	参数解释： 任务数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
tasks	Array(Object)	参数解释： 任务列表详情，其中Object的请求格式参见 data 返回数据详情 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-421 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释: 错误码 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
error_msg	String	参数解释: 错误信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "count": 2,
    "tasks": [
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "cf2a475e-xxxx-xxxx-xxxx-9f342b1b032e"
      },
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
      }
    ]
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.1.4 删除任务

功能介绍

通过“删除任务”接口来删除已添加的求解任务。

URI

DELETE /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-422 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-423 <删除任务>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-424 默认取值： 不涉及

表 3-424 <删除任务>"data" 参数说明

参数	参数类型	描述
status	string	参数解释： 任务当前状态，删除成功响应参数状态为200，并返回deleted。 约束限制： 不涉及 取值范围： 不涉及 默认取值： deleted
task_id	string	参数解释： 当前任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-425 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "status": "deleted",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.1.5 附录

3.7.1.5.1 MPS/LP 格式文件说明

3.7.1.5.1.1 MPS 格式文件说明

概述

MPS 文件是运筹优化求解器常用的文件格式之一，它采用列格式书写且区分大小写；每行数据表示一条记录，记录分为两种类型：指示符记录和数据记录，记录中包含空格，且常采用空格作为分隔符。根据书写的方式不同常分为 Fixed 格式 (fixed format) 和 Free 格式 (free format)，其中 Fixed 格式字段必须书写在固定的范围列内，而 Free 格式限制更为宽松常采用空格隔离字段。固定格式的行列名常为 8 个字符，空格也算作字符，变量名中可以存在空格；自由格式则无字符数量限制，但变量名最好不要超过255个字符且不能包含空格；指示符记录用来标识数据段的，每条指示符记录从第一列开始书写，常见指示符类型包括五个必选项和四个可选项。

节名称/指示符记录	是否必须	用途
NAME	是	用于指定问题名称；不同于其他指示符记录，名称记录包含数据。
OBJSENSE	否	选用，制定模型优化方向为最小化（默认）或最大化。
ROWS	是	用于指定每个约束的名称和含义。
COLUMNS	是	用于指定分配给每个变量（列）的名称和对应于该变量的非零约束系数。
RHS	是	用于指定右侧向量的名称和每个约束（行）的值。
RANGES	否	用于指定限制为处于两个值之间的区间内的约束；还会指定区间端点。
BOUNDS	否	用于指定每个变量（列）必须保持的限制。
QUADOBJ/QMATRIX	否	选用，指定目标函数中的二次项。
QCMATRIX	否	选用，指定二次约束函数中的二次项。
ENDATA	是	用于表示数据结束；始终为 MPS 文件中的最后一个条目。

MPS 文件样例

下面混合整数问题的例子来解释每个指示符和数据记录的含义与使用方式。
所描述模型的数学公式如下所示：

```
minimize x1 + 2x5 - x8
subject to
  2.5 ≤ 3x1 + x2 - 2x4 - x5 - x8
      2x2 + 1.1x3          ≤ 2.1
      x3 + x6              = 4.0
  1.8 ≤ 2.8x4 - 1.2x7      ≤ 5.0
  3.0 ≤ 5.6x1 + x5 + 1.9x8 ≤ 15.0
同时，
  2.5 ≤ x1
  0 ≤ x2 ≤ 4.1
```

```
0 ≤ x3
0 ≤ x4
0.5 ≤ x5 ≤ 4.0
0 ≤ x6
0 ≤ x7
0 ≤ x8 ≤ 4.3
这里,
x1, x2 ∈ R
x3, x4 ∈ {0, 1}.
```

对应MPS文件:

```
NAME EXAMPLE
ROWS
N OBJ
G ROW01
L ROW02
E ROW03
G ROW04
L ROW05
COLUMNS
COL01 OBJ 1.0
COL01 ROW01 3.0 ROW05 5.6
COL02 ROW01 1.0 ROW02 2.0
*
* Mark COL03 and COL04 as integer variables.
*
INT1 'MARKER' 'INTORG'
COL03 ROW02 1.1 ROW03 1.0
COL04 ROW01 -2.0 ROW04 2.8
INT1END 'MARKER' 'INTEND'
*
COL05 OBJ 2.0
COL05 ROW01 -1.0 ROW05 1.0
COL06 ROW03 1.0
COL07 ROW04 -1.2
COL08 OBJ -1.0
COL08 ROW01 -1.0 ROW05 1.9
RHS
RHS1 ROW01 2.5
RHS1 ROW02 2.1
RHS1 ROW03 4.0
RHS1 ROW04 1.8
RHS1 ROW05 15.0
RANGES
RNG1 ROW04 3.2
RNG1 ROW05 12.0
BOUNDS
LO BND1 COL01 2.5
UP BND1 COL02 4.1
LO BND1 COL05 0.5
UP BND1 COL05 4.0
UP BND1 COL08 4.3
ENDATA
```

备注: 以星号 (*) 开头的行为注释行。

数据记录格式

分为 Fixed 格式和 Free 格式, Fixed 格式对参数出现的位置要求极其严格。

Fixed 格式:

对于 Fixed 格式如果定义字符偏移值 Inumchar 等于 8, 则数据记录对应的位置为:

记录	字段1	字段2	字段3	字段4	字段5	字段6
内容	2-3	5-12	15-22	25-36	40-47	50-61

如果字符偏移量不等于 8，则数据记录对应的位置也会改变：

记录	开始位置	结束位置
字段1	2	3
字段2	5	5 + Inumchar - 1
字段3	字段 2 后的第三列	开始位置 +Inumchar-1
字段4	字段 3 后的第三列	开始位置 +11
字段5	字段 4 后的第四列	开始位置 +Inumchar-1
字段6	字段 5 后的第五列	开始位置 +11

 说明

- 1. 字段 2、3、5 字段，其中的字符串中不应该带有空格，如果有空格也会被移除。
- 2. 字段 4、6 是数据段，其数值必须能在 12 个字符内完成书写，这六个字段外的列必须是空格否则无法识别。

Free 格式

对于 Free 格式其基本形式也采用 6 字段的方式书写，其形式略有不同：

- 1. Free 格式则无需固定位置，可以在除第二列外的任何位置，不同字段通过空格分割。
- 2. 但是字段对应的顺序必须和 Fixed 格式相同，超过 6 个字段的记录仅读取前 6 个字段后续不再处理。
- 3. 如不是从第一列开始且采用 \$\$ 的字段，会被当成注释，该行记录后续部分不会被处理。
- 4. 第 72-80 列自动忽略。

NAME 节

MPS 文件第一个指示符记录是问题名字段，表示模型的名字，其对应的对应字符段为：

字段1	字段2	字段3	字段4
NAME	空格	模型名字	BINARY、FREE 或者空格

对于 Fixed 格式 NAME 必须书写在 1-4 列，modelName 必须书写在列范围 $[5 + \text{Inumchar} \times 2, 5 + 2 \times \text{Inumchar} + 1]$ 内，字段 4 必须书写在列范围 $[5 + 2 \times \text{Inumchar} + 4, 5 + 2 \times \text{Inumchar} + 15]$ 内。关于字段 3 的 modelName，对于 Fixed 格式是可选项，而对于 Free 格式则是必选的。如果文件是二进制格式，Fixed 格式则要求指定字段 4 为 BINARY，否则留空即可。

OBJSENSE 节

该指示符非标准 MPS 格式具有，常作为扩展格式使用。是可选指示符记录，Fixed 格式不能包含该节。若未显式指定，则默认此模型采用最小化优化方向；OptVerse 代码中可以使用以下两个节来扩展 MPS 标准：OBJSENSE 和 OBJNAME，两者可在 NAME 节之后指定。OBJSENSE 用于设置目标函数含义，而 OBJNAME 用于从文件内的可用行中选择目标函数。如果这些节均未出现在 MPS 文件中，那么默认问题为最小化问题，并且目标函数由 ROWS 节中遇到的第一个可用行决定。如果使用这些选项，那么它们必须按顺序出现 NAME 节之后作为第一个和第二个节。OBJSENSE 的可选值是 MAX 或 MIN，例如：

```
NAME example.mps
OBJSENSE
  MAX
OBJNAME
  rowname
```

ROWS 节

标题字段 ROWS 表征该参数段的开始位置，自此需要从第一列开始书写；参数记录按行书写，每行包含名称和约束含义，每条记录占一行，格式为：

字段1	字段2
约束指示符	约束名字

说明

- 字段 1 必须在 2-3 列，字段 1 与字段 2 之间至少需要一个空格。约束指示符表示约束的类型，包含了一个用于指定该行的含义的单个字母。可接受的值为：
 1. E 表示该行等于。
 2. L 表示该行小于等于。
 3. G 表示该行大于等于。
 4. N 表示自由行。
- 字段 2 包含字符标识（最大长度为 255 个字符），字段 3-6 不可在 ROWS 节中留白。MPS 文件将目标函数也当成一条约束，以标志符类型 N 包含在 ROWS 节中。如果定义了多个自由行，则仅将第一个作为目标函数，其他自由行会被丢弃。

COLUMNS 节

COLUMNS 用来定义各列（变量）名字。在 COLUMNS 节中，约束矩阵的所有列均使用其名称和所有非零元素进行指定。数据记录格式为：

字段1	字段2	字段3	字段4	字段5	字段6
空白	列的名字	约束 1 的名字	约束 1 中该列的系数（非零）	约束 2 的名字	约束 2 中该列的系数（非零）

如果字段 2 为空白，则说明该记录和上一行的记录具有相同的列名。字段 3 是约束或者目标函数中的非零系数；字段 5、6 和字段 3、4 的含义相同，是可选项。记录中的 ROWS 约束名称无顺序要求。若出现 ‘MARKER’、‘INTORG’ 及 ‘MARKER’、‘INTEND’，则分别表示整数变量的起止，介于这些关键字之间的列都是整数变量。

RHS 节

在RHS节中，指定了约束的非零右侧值。数据记录格式为：

字段1	字段2	字段3	字段4	字段5	字段6
空白	RHS 的名字	约束 1 的名字	约束 1 的 RHS非零值	约束 2 的名字	约束 2 的 RHS非零值

说明

- 1. 第一列要留空。
- 2. 第二列表示 RHS 名字，可以任取，若为空则和上一条记录名字相同。
- 3. 每个 RHS 必须具有唯一的名称。
- 4. 第四列表示所对应的约束的 RHS 值。
- 5. 第五列、第六列分别与第三列、第四列的含义相同，为可选字段。
- 6. 此外，还可以在 MPS 格式的文件的RHS节中声明模型的目标偏移量。使用此功能时，将偏移量的负值声明为目标函数的 RHS。例如，以下行声明目标偏移量为 3.141。
rhs obj -3.1415

RANGES 节

RANGES 节包含了约束右侧值（RHS）的范围。数据记录格式为：

字段1	字段2	字段3	字段4	字段5	字段6
空白	右侧范围向量标识	约束 1 的名字	约束 1 标识的范围值	约束 2 的名字（可选）	约束 2 标识的范围值（可选）

指定右侧范围的效果取决于指定行的含义以及该范围具有正系数还是负系数。对于给定的行，rhs 为右侧值，而 range 为对其应的范围值。范围值的解释如下：

行类型	范围值符号	生成的 RHS 上限	生成的 RHS 下限
G	+ 或 -	$\text{rhs} + \text{range} $	rhs
L	+ 或 -	rhs	$\text{rhs} - \text{range}$
E	+	$\text{rhs} + \text{range}$	rhs
E	-	rhs	$\text{rhs} + \text{range}$

BOUNDS 节

变量的界限值可在BOUNDS节中指定。数据记录格式为：

字段1	字段2	字段3	字段4	字段5	字段6
边界类型	边界名称	列的名字	列的边界值	空白	空白

说明

1. 字段 1: 界限类型，从左侧第二列开始书写。
2. OPTV 支持界限类型值为：
 - LO: 下限
 - LI: 下限，整数
 - UP: 上限
 - UI: 上限，整数
 - FX: 固定值（上下限相同）
 - FR: 自由变量（下限为 $-\infty$ 且上限为 $+\infty$ ）
 - MI: 负无穷大（下限为 $-\infty$ ）
 - PL: 正无穷大（上限为 $+\infty$ ）
 - BV: 二进制变量，整数（0 或 1）
3. OptVerse 暂不支持界限类型值为 - SC: 半连续变量的上限。
4. 字段 5 和 6 不可用在BOUNDS节中。
5. 如果界类型不是 LO, UP, FX, 或者 UI 则忽略字段4的取值。
6. 界中出现的变量的顺序无需和COLUMNS中相同。

3.7.1.5.1.2 LP 格式文件说明

概述

LP格式作为一种在学界与业界都十分常用的文件格式，具有比MPS格式更易阅读的优点，与MPS文件是列格式不同，LP文件采用行表达式描述问题，且没有固定的书写范围和长度。但从处理性能和阅读难易的角度出发，各家求解器都规范了每行的最字节长度。OptVerse求解器以不超过5000列作为限制。下面给出一个标准的LP文件：

```
\ENCODING-ISO-8859-1
\Problem name:Maximize
Maximize
obj:x1 + 2 x2 + 3 x3 + x4
```

```
Subject To
r1: - x1 + x2 + x3 + 10 x4 <= 20
r2: x1 - 3 x2 + x3 <= 30
r3: x2 - 3.5 x4 = 0
Bounds
0 <= x1 <=40
2 <= x4 <= 3
Generals
x4
Binaries
x3
End
```

Maximize、Subject to、Bounds、Generals、Binaries、End 分别是各节的指示词，虽然求解器对指示词的顺序没有强制要求，但最好遵照标准文件中的顺序。各节指示词必须是单独一行书写，且对大小写不敏感。下面对文件的各部分给出详细的描述。

LP 格式的注释

反斜杠 (\) 后面的内容被认定为注释，求解器不对其进行解析，而是将其忽略；对于文件中的空白行同样进行忽略。例如：

```
\ENCODING-ISO-8859-1
\Problem name:Maximize
```

LP 格式的关键字

LP 格式中的关键字不区分大小写。

关键词(指示词)	可选项	含义
minimize	min、minimum	最小化问题。
maximize	max、maximum	最大化问题。
subject to	s.t.、such that、st	约束满足。
bounds	bound	表达式的界。
generals	gen、general	整数变量。
binaries	bin、binary	0-1变量。
inf	infinity	无穷。
free	-	自由变量。
end	-	结束。

说明

问题最小 (大) 化关键词实际上是格式的第一行有效字段，有时该行也可以省略，如果省略则默认为最小化问题；end 关键词标注问题描述的结束，end 之后即便还存在字段也不会被解析。

LP 格式的节

在介绍节之前，首先介绍两个概念：**令牌**和**表达式**。

令牌是单次能够处理的最小单位，不可通过插入任意字符分隔，如空格或换行符。将常数、字符串、关键词、操作符、关系符视为令牌。

表达式是加入空格进行组合的令牌组，仅支持采用空格作为令牌组的令牌分隔符。如表达式 $10x_1 + x_2 + 2000$ 中，10 和 2000 是常数令牌，变量名 x_1 和 x_2 是字符串令牌，令牌之间采用空格分隔； $10x_1 + x_2 + 2000$ 则不是令牌组或所谓的表达式，而仅仅是一个字符串。同时，它也不是变量名，因为变量名、约束名、目标函数名需要满足如下条件：彼此不同，名字长度不超过 255 个字符，不能以数字或者操作符 $+$, $-$, $*$, $^$ 及关系符 $<$, $>$, $=$ 开头，此外，也不可以是所谓的关键词。变量名最好也不要采用 E + 数字形式，如 E9 或 e9，因为这样会被解析为数字。建议使用字符和数字组合，如 var001。

Objective Function 节

目标函数可采用 maximize 或 minimize 关键词开始，关键词后不能再出现其它字符，形式为：

```
minimize
-x1 + x2 + -x3 + 0.5 x1 + 100 + x4 + 20
```

如上形式可以看出：

- minimize 单独一行。
- 变量可以直接与负号 (-) 连接，如 x_1 和 x_3 。
- 变量可以多次出现，聚合多次系数，本例中为 x_1 的系数最终为 $-1 + 0.5$ 。
- 偏移量可以出现在表达式中间或结尾，如 100 和 20。

在实际使用中目标函数可以提供一个名字，并且可以多行书写，但需注意一些细节，例如：

```
minimize
obj: -x1 + x2 + -x3 + 0.5 x1
+ 100 + x4 + x5 + 1.5 + 2.0
x6
```

目标函数名后需要加冒号 (:) 作为分隔；换行时以令牌为最小的组成单位。

Quadratic Objectives 节

目标函数可以含有二次项，该部分需放入方括弧 [] 并由 / 2 随后。若未读取到 / 2，相应的数据将被转换并以警告形式通知，否则用户需要在相应的 .lp 文件中将数值乘以 2 以避免该转换和警告；另一方面，上述格式中的空格符是必须的。一般来说，二次项有以下两种写法：

1. x^2
2. $x * x$

这两种方式都被支持，但是，注意 * 和 ^ 前后的空格符都是必须的。其次，混合项由 * 标识，对角元可以使用 * 或 ^。

如果二次项未被提供系数，那么默认值 1.0 会被用来当做其系数。

另外，建议将表达式中二次项按照下标由低到高排序以提高效率，例如，

```
minimize
obj: -2.0 x1 + 3.0 x2 -1.0 x3 + [ x1^2 + x2^2 + x1 * x2 + x3^2 + x1 * x3 + x2 * x3 ] / 2
```

重新排列上述示例中目标函数表达式的二次项部分为

```
minimize
obj: -2.0 x1 +3.0 x2 -1.0 x3 + [ x1^2 + x1 * x2 + x1 * x3 + x2^2 + x2 * x3 + x3^2 ] / 2
```

Constraints 节

约束满足节的关键词 `subject to` 同样需要单独一行书写。每个新的约束必须另起一行。约束可以提供约束名，在约束名之后跟冒号。约束名必须遵循与变量名称相同的规则。要求必须为约束指定约束名。

约束被定义为通过变量、常数、操作符组成的线性表达式，后跟关系符和数字右侧系数。使用以下关系符之一可以直观地指示约束的意义：`>=`, `<=`, 或 `=`。例如，这是一个命名约束：

```
subject to:
depts01: -x1 + 0.5 x2 <= 40
```

但不允许关系符两边都存在变量表达式，如：

```
subject to:
depts02: -x1 + 0.5 x2 <= 40 + x1
```

和双侧关系符，如：

```
subject to:
depts03: 0 <= -x1 + 0.5 x2 <= 40 + x1 <= 40
```

Quadratic Constraints 节

与目标函数表达式相同，约束表达式也可以多行书写，但需要保持一致性。

约束表达式也可以含有二次项，该部分需放入方括弧 [`<quad terms>`]，但与目标函数中的二次项不同，这里 **没有** `/ 2` 随后。以下两种二次项的写法都被支持：

1. `x^2`
2. `x * x`

注意 `*` 和 `^` 前后的空格符都是必须的。其次，混合项由 `*` 标识，对角元可以使用 `*` 或 `^`。

如果二次项未被提供系数，那么默认值 1.0 会被用来当做其系数。

同样，将表达式中二次项按照下标由低到高排序可以提高效率，例如，对于下面的二次约束：

```
subject to:
c1: -2.0 x1 +3.0 x2 -1.0 x3 + [ x1^2 + x2^2 + x1 * x2 + x3^2 + x1 * x3 + x2 * x3 ]
```

建议重新排列二次项部分，重写为

```
subject to:
c1: -2.0 x1 +3.0 x2 -1.0 x3 + [ x1^2 + x1 * x2 + x1 * x3 + x2^2 + x2 * x3 + x3^2 ]
```

Bounds 节 [可选]

`bounds` 节是可选的，如果存在则表明需要对变量使用提供的变量界。根据界被提供的个数，每一行表达式可以分为单边界或双边界。单边界形如 `x >= 10` 或 `x < 10`，双边界形如 `10 <= x <= 15`。这两种界都不允许多行书写。如果没有提供变量界，则默认采用求解器的内部值。如果为变量定义了单个边界，则将使用适当的默认边界作为第二个边界。这里，有几条准则：

1. 固定边界表达式不被允许，即不能写为 `x1 = 20` 而要统一写为 `20 <= x1 <= 20`。

- 2. 支持 $\pm\infty$, 如 $x1 > -\infty$ 。
- 3. 支持 free, 如 $x1$ free。

Generals 和 Binaries 节（可选）

LP 文件的 generals 和 binaries 节用于指示在可行解中必须具有整数值的变量。鉴于两者之间的相似性，将其放在同一个部分介绍，实际上是否同时存在互不影响。注册在这两节的变量将具有的默认边界的定义。对于在 generals 部分注册的变量，默认范围是 $[0, 1020]$ ，而 binaries 部分注册的变量，默认边界是 0 和 1。变量注册的方式是通过将变量罗列到对应节。

```
Generals
x4 x5 x6 x7
x8 x9

Binaries
x1 x2 x3 x4
```

可见，不同变量之间通过空格分隔，允许多行书写，同时允许变量注册到不同节，如变量 x4，最终的变量类型为其可行区间最小的类型。


备注: 现阶段求解器仅支持线性问题，对于非线性字段和半连续、半整型暂不支持。

3.7.1.5.2 查看求解结果

查看结果存储详情


- 默认存储地址
- 1. 求解任务完成后，在对应的待求解模型文件中会创建optverse_result的文件夹用来存储求解结果。

图 3-23 optverse_result 存放处



2. optverse_result的文件夹中会根据<task_name>_<taskId>的格式创建保存当前任务的求解结果的文件夹。

图 3-24 保存当前任务的求解结果



3. <task_name>_<taskId>文件夹中就保存着对应的求解结果（<task_name>.sol）及求解日志（<task_name>.log）。

图 3-25 求解结果保存位置



- **传输存储地址**
求解结果在output.data中目录下会上传<task_name>_<taskId>的格式创建保存当前任务的求解结果的文件夹。具体与以上[步骤2](#)和[步骤3](#)一致。

日志解析

LP求解日志解析

日志如下：

```
OptVerse Optimizer version 1.5.2
Copyright (c) Huawei Technologies Co., Ltd. 2022-2024. All rights reserved.

Read problem /home/solver/optverse/examples/data/lp-example.lp
Read time: 0.00s

Optimize an LP model
 8 rows, 20 columns and 36 nonzeros

Presolve problem
Presolve time: 0.00s
After presolve:
 4 rows, 12 columns and 12 nonzeros

Time   Iteration   Objective   Primal Num.Inf. Dual Num.Inf.
0.0s    0   0.000000e+00      4         0
0.0s    4   1.380000e+02      0         0

Postsolving
Postsolve finished

Time   Iteration   Objective   Primal Num.Inf. Dual Num.Inf.
0.0s    0   1.380000e+02      0         0

Solve results
Status      Optimal solution found
Objective    1.3800000000000e+02
Simplex iteration  4
Time          0.01

Write best solution /home/solver/optverse/lp-example.sol
```

上述日志包含了如下信息：

- 版本和版权信息
- 问题读取时间
- 问题信息，包含行数、列数、非零元个数
- 预处理时间及预处理后的问题规模，包含新行数、列数和非零元个数
- 单纯形算法迭代日志，如时间、迭代步数，当前目标值，原始及对偶可行性的违背量
- 后处理信息
- 求解结果概览，包含

- 求解状态，如 Optimal solution found, Problem is infeasible, Problem is unbounded, Time limit reached, Numerical error, Symbolic error, Unknown
- 最优目标值
- 迭代总数
- 总耗时
- 运行期间的报警错误信息

MILP 求解日志解析

日志如下：

```
OptVerse Optimizer version 1.5.2
Copyright (c) Huawei Technologies Co., Ltd. 2022-2024. All rights reserved.

Read problem /home/solver/optverse/examples/data/milp-example.mps
Read time: 0.00s

Optimize an MILP model
8 rows, 20 columns (20 binary, 0 integer, 0 continuous) and 36 nonzeros

Presolve problem
Presolve time: 0.00s
After presolve:
8 rows, 20 columns (20 binary, 0 integer, 0 continuous) and 36 nonzeros

Start parallel solving, using up to 4 threads

Time   Solved   Open   LPiter   BestBound   BestSol   Gap
H 0.0s   0       0      0  0.000000e+00 2.980000e+02 100%
H 0.0s   0       0      0  1.380000e+02 2.880000e+02 52.08%
0.0s    0       0      0  1.380000e+02 2.880000e+02 52.08%
0.0s    0       0      9  2.420000e+02 2.880000e+02 15.97%
H 0.0s   1       0      9  2.420000e+02 2.420000e+02 0.00%
0.0s    1       0      9  2.420000e+02 2.420000e+02 0.00%

Solve results
Status      Optimal solution found
Best solution 2.4200000000000e+02
Best bound   2.4200000000000e+02
Gap          0.0000%
Node         1
LP iteration  9
Time         0.0

Write best solution /home/solver/optverse/milp-example.sol
```

上述日志包含了如下信息：

- 版本信息
- 读取问题时间
- 原问题规模
- 预处理时间和预处理后问题规模
- 开始串行、并行求解（线程数），如
 - Start sequential solving
 - Start parallel solving, using up to 4 threads
- 第一列（在 Time 列之前）仅可能出现 H 和 *
- Time, Solved, Open, LPiter, BestBound, BestSol, 和 Gap 信息

- 求解结果概览，包含：
 - 求解状态，仅可能出现 Optimal solution found, Time limit reached, Memory limitreached, 或 Problem is infeasible
 - 最优解和最优界
 - Gap
 - 节点个数
 - LP 迭代总数
 - 总耗时
- 运行时期间的报警错误信息

3.7.2 Pangu-OPT-数值计算求解器

3.7.2.1 创建求解任务

功能介绍

天筹数值计算求解器是一款由华为云自主研发的可移植、可扩展的科学计算工具库，主要用于在单机共享内存和分布式集群环境下高效求解CAE（Computer Aided Engineering）仿真过程产生的底层数学问题，包括稀疏线性方程组、非线性方程组、与特征值等问题。

URI

POST /task/solve

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-426 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-427 请求参数

参数	是否必选	参数类型	说明
input_json	是	Object	参数解释： 请求参数，具体包含待求解文件文件obs路径，与求解参数，具体详情参见 表3 input_json请求参数 。 约束限制： 不涉及 取值范围： 详情参见 表3 input_json请求参数 默认取值： 不涉及

表 3-428 input_json 请求参数

参数	是否必选	参数类型	描述
input	是	input object	参数解释： 待求解文件输入，需将待求解文件传入obs中 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
output	否	output object	参数解释： 结果输出，将求解结果与日志文件传输至对应obs桶中 约束限制： 不涉及 取值范围： 不涉及 默认取值： 若未设置则最终结果会传入默认路径，为求解文件目录下的optverse_result文件夹内
parameters	否	parameters object	参数解释： 求解参数选择，包括可以选择求解时间限制，内存限制，以及gap值等 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-429 input

参数	是否必选	参数类型	描述
type	是	String	参数解释： 输入的格式类型，path代表传入的是obs路径，当前仅支持path 约束限制： 不涉及 取值范围： path 默认取值： 不涉及

参数	是否必选	参数类型	描述
data	是	String	参数解释： 待求解的模型文件，详情可参考附录的MPS/LP格式文件说明 约束限制： 取值为模型文件存储obs路径，参考格式为obs://test/test.mps，当前仅支持mps或者lp格式文件 取值范围： 不涉及 默认取值： 不涉及

表 3-430 output

参数	是否必选	参数类型	描述
type	是	String	参数解释： 输出的格式类型，path代表结果输出到obs对应的路径下，当前仅支持path 约束限制： 不涉及 取值范围： path 默认取值： 不涉及
data	是	String	参数解释： 最终结果存储路径 约束限制： 取值为OBS文件夹路径，参考格式为obs://test，表示最终求解结果会上传至test桶下 取值范围： 不涉及 默认取值： 不涉及

表 3-431 parameters

参数	是否必选	参数类型	描述
time_limit	否	Number	参数解释： 求解时间上限，单位为s。用于限制求解时长，若设置15s则表示求解15s后返回结果 约束限制： 不涉及 取值范围： [0.0, 1.79769e+308] 默认取值： 1.79769e+308
mem_limit	否	Integer	参数解释： 求解内存上限，单位为 MB。用于限制求解的内存，表示求解时不会超出该内存限制 约束限制： 不涉及 取值范围： [100, 2147483647] 默认取值： 2147483647
gap	否	Number	参数解释： 设置相对残差的终止阈值 约束限制： 不涉及 取值范围： [0.0, 1.79769e+308] 默认取值： 0.0001
threads	否	Integer	参数解释： 求解器在进行并行计算时的最大可用线程数 约束限制： 不涉及 取值范围： [1, 平台最大线程数] 默认取值： 平台最大线程数/2

响应参数

状态码：200

表 3-432 <添加求解任务>成功响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据 约束限制： 不涉及 取值范围： 详情参见 表3-433 默认取值： 不涉及

表 3-433 data 返回数据详情

参数	参数类型	描述
create_time	String	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： - created（任务已创建） - pending（任务排队中） - running（任务执行中） - completed（任务求解完成） - failed（任务失败） - deleted（任务已删除） 默认取值： 不涉及

参数	参数类型	描述
task_id	String	参数解释： 任务ID，用于后续查询任务接口使用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-434 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "input_json": {
    "input": {
      "type": "path",
      "data": "obs://xxx"
    },
    "output": {
      "type": "path",
      "data": "obs://xxx"
    }
  }
}
```

```
    },
    "parameters": {
      "time_limit": 15
    }
  }
}
```

响应示例

```
{
  "data": {
    "create_time": "2025-01-01 10:00:00.000000",
    "status": "created",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.2.2 查询任务详情

功能介绍

通过“查询任务详情”接口来具体查看当前任务的进度。当任务状态为“completed”时，说明任务执行完成，可从指定的OBS路径中查看完成的求解结果，具体可参考[查看求解结果](#)。

URI

GET /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-435 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-436 <查询任务详情>成功响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-437 。 默认取值： 不涉及

表 3-437 data

参数	参数类型	描述
create_time	string	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
logs	string	参数解释： 当前任务的执行日志详情。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
output	Object	参数解释： 任务处理结果。详见 表4 "output" 参数说明 ，详细结果可参考 查看求解结果 。 约束限制： 任务状态为completed时携带。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： • created（任务已创建） • pending（任务排队中） • running（任务执行中） • completed（任务求解完成） • failed（任务失败） • deleted（任务已删除） 默认取值： 不涉及
task_id	String	参数解释： 当前任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-438 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "create_time": "2025-01-01 10:00:00.000000",
    "logs": "xxx",
    "output": {},
    "status": "completed",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.2.3 查询任务列表

功能介绍

通过“查询任务列表”接口来查询所有求解任务的状态及task_id。

URI

GET /task-list

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-439 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-440 <查询任务列表>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-441 默认取值： 不涉及

表 3-441 <查询任务列表>"data" 参数说明

参数	参数类型	描述
count	int	参数解释： 任务数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
tasks	Array(Object)	参数解释： 任务列表详情，其中Object的请求格式参见 data 返回数据详情 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-442 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "count": 2,
    "tasks": [
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "cf2a475e-xxxx-xxxx-xxxx-9f342b1b032e"
      },
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
      }
    ]
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.2.4 删除任务

功能介绍

通过“删除任务”接口来删除已添加的求解任务。

URI

DELETE /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-443 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-444 <删除任务>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-445 默认取值： 不涉及

表 3-445 <删除任务>"data" 参数说明

参数	参数类型	描述
status	string	参数解释： 任务当前状态，删除成功响应参数状态为200，并返回deleted。 约束限制： 不涉及 取值范围： 不涉及 默认取值： deleted
task_id	string	参数解释： 当前任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-446 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释: 错误码 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
error_msg	String	参数解释: 错误信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "status": "deleted",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.3 Pangu-OPT-黑箱优化求解器

功能介绍

黑箱优化求解器模型，通用调用“黑箱优化求解器”接口解决目标函数难以从数学上解析表达，仅可利用目标函数输入和对应输出函数值进行最优解搜索的优化问题求解。

URI

POST /task/solve

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-447 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-448 请求参数

参数	是否必选	参数类型	说明
data	是	Array	参数解释： 历史数据列表，包含多个数据对象的数组，每个对象有用户自定义的参数（paramX）和目标值（objective）。参数名和目标字段名由用户自定义，但每个对象的结构必须一致。详情参考 data 结构体。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
objective_column	是	String	参数解释： 指定数据对象中目标值的字段名。 约束限制： 应与data中某个对象的objective字段名一致，完全匹配对大小写敏感。 取值范围： 不涉及 默认取值： 不涉及
bounds	是	Object	参数解释： 包含参数名称及其取值范围的对象。取值范围是一个包含两个元素的数组，分别表示参数的最小值和最大值。详情参考 bounds 结构体。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
fixed_params	否	Array	参数解释： 包含需要固定的参数及其值的对象数组，当参数值固定后，最终推荐的参数组合中该参数固定，其他参数进行优化迭代。可以包含一个或多个固定参数。每个对象包含一个参数名及其固定值。详情参考 fixed_params 结构体。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-449 data 结构

参数	参数类型	描述
paramX	Double	参数解释： 数据对象中的自定义参数，X表示参数的序号（如 param1, param2等）param的名字也可以由用户自定义，取值根据实际需求。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
objective	Double	参数解释： 数据对象中的目标值，用于优化计算。参数名由用户自定义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-450 bounds

参数	参数类型	描述
paramX	Array[Double]	参数解释： bounds对象中的参数名称及其取值范围，X表示参数的序号（如param1, param2等），取值范围应为一个包含最小值和最大值的数组。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-451 fixed_params

参数	参数类型	描述
paramX	Double	参数解释： fixed_params对象中的固定参数，X表示参数的序号（如param1, param2等），取值根据实际需求。注意，这里的X应与bounds中的paramX对应，表示要固定的参数。但通常我们不会特别标注序号，而是直接写参数名，因此这里的X更多是为了说明结构而加上的。在实际文档中，可以直接写参数名，如"param1": 1.5。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-452 响应参数

参数	参数类型	描述
data	Array	参数解释： 返回数据,详情参见 parameters_info 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-453 parameters_info

参数	参数类型	描述
expected_objective_value	Double	参数解释： 预期目标值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
fixed_params	Object	参数解释： 固定参数详情,与请求参数中的fixed_params对应，详情参考 fixed_params 结构体。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
suggested_parameters	Object	参数解释： 推荐的参数组合，具体参考 表3-454 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-454 suggested_parameters

参数	参数类型	描述
paramX	Double	参数解释： suggested_parameters对象中的推荐参数，X表示参数的序号（如param1, param2等），取值根据实际需求。注意，这里的paramx个数为非固定参数的个数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-455 错误响应参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "data": [
    {"param1": 1.0, "param2": 2.0, "param3": 1.2, "param4": 0.5, "objective": 0.5}
  ],
  "objective_column": "objective",
  "bounds": {
    "param1": [1.0, 4.0],
    "param2": [2.0, 5.0],
    "param3": [1.0, 2.0],
    "param4": [0.5, 1.0]
  },
  "fixed_params": [
    {"param1": 1.5, "param3": 1.3},
    {"param2": 3.0, "param4": 0.7},
    {"param1": 2.0, "param2": 2.5}
  ]
}
```

响应示例

状态码： 200

```
{
  "data": [
    {
      "expected_objective_value": 0.5,
      "fixed_params": {
        "param1": 1.5,
        "param3": 1.3
      },
      "suggested_parameters": {
        "param2": 3.568493514295904,
        "param4": 0.7327381143267316
      }
    },
    {
      "expected_objective_value": 0.5,
      "fixed_params": {
        "param2": 3.0,
        "param4": 0.7
      },
      "suggested_parameters": {
        "param1": 2.2044781192207505,
        "param3": 1.908187918405232
      }
    }
  ],
  {
```

```
{
  "expected_objective_value": 0.5,
  "fixed_params": {
    "param1": 2.0,
    "param2": 2.5
  },
  "suggested_parameters": {
    "param3": 1.0988558632086192,
    "param4": 0.8429370017051994
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)

3.7.4 Pangu-OPT-生产计划引擎

3.7.4.1 创建求解任务

功能介绍

生产计划引擎模型，对基地、工厂级别生产过程中所需的资源进行合理的安排和计划，时间决策粒度一般按月/周/日。调用“生成计划引擎”接口会同步响应返回“task_id”，服务会将请求任务添加到待处理队列中进行排队（pending）、任务执行中（running）、求解完成（completed）等三个阶段。

URI

POST /task/solve

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-456 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-457 请求参数

参数	是否必选	参数类型	说明
item_list	是	list< Item >	参数解释： 需要生产的产品列表，包含所有顶层产品、半成品以及原料，每一个对象对应一个产品信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
order_list	否	list<Order>	参数解释： 生产计划中需要交付的订单列表，每个订单可以包含多个产品并定义相应的交付时间和优先级。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
bom_list	否	list<BomInfo>	参数解释： BOM(Bill of Materials)信息列表，涵盖了与生产相关的各类物料：产品、半成品、在制品、原材料等。每一个BOM对象中明确列出了所需部件的数量清单，包含比例关系和单位。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
resource_list	是	list<Resource>	参数解释： 资源（设备、产线、辅助资源）列表，列表中每个对象对应了一种加工所需资源类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
aux_tool_list	否	list<AuxTool>	参数解释： 辅助设备（模具、刀具）列表，列表中每个对象对应了一种辅助工具信息，辅助工具相对于资源在通用引擎中一般用于表示拥有离散数量的资源，以在不同资源上进行分配。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
production_proportion	否	list<ProductionProportion>	参数解释： 产品按比例生产需求列表，列表中每个对象代表了一组配对生产的产品以及对应的数量。例如每生产一个发射器就要生产一个接收器，以配套进行测试。配对生产的比例不一定是1:1，可以是M:N 的形式。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
product_family	否	list<ProductFamily>	参数解释： 产品族信息列表，同类产品族定义为族内产品的切换成本和切换时间可忽略不计，可用于简化问题复杂度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
production_param	否	Production Param	参数解释： 用于描述生产场景的配置参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
resource_type_list	否	list<ResourceType>	参数解释： 资源类型列表，用于表示资源的具体类型信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
substitution_list	否	list<Substitution>	参数解释： 替代信息列表。替代在BOM结构上可以区分为交付替代和生产替代，替代关系可以具有固定的替代比例和替代优先级，另外也可以规定替代原材料的后继料信息。列表中的每个对象表示了一组替代关系，包括了原版材料、替代料以及相关限制条件。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
period_num	是	integer	参数解释： 生产计划计算的周期长度范围。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
time_limit	否	Double	参数解释： 求解时间限制，单位为秒。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-458 Item

参数	是否必选	参数类型	说明
item_code	是	string	参数解释： 产品编号，根据实际情况填写。 约束限制： 长度大于0 且不超过256的字符串，具有唯一标识。 取值范围： 不涉及 默认取值： 不涉及
product_type	是	integer	参数解释： 产品类型标识，用以区分产品在加工结构树中的位置，普通产品既可以有前继工序也可以有后继工具，属于通用的情况。 约束限制： 不涉及 取值范围： 0:原材料 1:普通产品 2:最终产品。 默认取值： 1

参数	是否必选	参数类型	说明
demand_list	是	list<Demand>	参数解释： 需求量列表，列表中每个对象包含了产品在计划周期内的某个时间点上的需求量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
initial_inv	是	Double	参数解释： 产品的初始库存，计划周期开始时间点已经持有的库存量，可以直接用于交付和生产。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
inv_param	否	InventoryParam	参数解释： 库存相关参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
replenishment	否	list<TimeValueExpire>	参数解释： 产品的补货量（动态供应）列表，每个对象包含了某个时间点的到货量，在该时间点补货后可以用于加工生产。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
allow_backlog	否	boolean	参数解释： 产品是否允许延迟满足需求，只在交付需求中出现，不可以在生产上层产品的工序中出现欠料。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false
allow_lost_sale	否	boolean	参数解释： 产品是否允许需求到期缺货，只在交付需求中出现，不可以在生产上层产品的工序中出现欠料。缺货相对于延迟在后续的生产中也不会对该需求进行满足，而延期可以推迟数个周期后再进行延迟满足。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false
backlog_cost	否	ValueSetting	参数解释： 每单位产品在给定单位时段延期所需的成本，可以指定不同时段对应不同的延期成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0

参数	是否必选	参数类型	说明
lost_sale_cost	否	ValueSetting	参数解释： 每单位产品在给定单位时段缺货所需的成本，可以指定不同时段对应不同的缺货成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
holding_cost	否	ValueSetting	参数解释： 每单位产品在给定单位时段在库存中持有所需的成本，可以指定不同时段对应不同的过期成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
production_cost	否	ValueSetting	参数解释： 每单位产品在给定单位时段在生产加工所需的成本，可以指定不同时段对应不同的单位生产成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0

参数	是否必选	参数类型	说明
production_time	否	list<IdValue>	参数解释： 每单位产品在不同资源上生产加工的所需时间，可以指定不同产线或机器对应不同的单位生产时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
setup_cost	否	ValueSetting	参数解释： 每类产品在给定的单位时段内在不同资源上启动生产所需的成本，在生产该产品前机器需要进行换料、换模以及其他准备工作，需要消耗固定的成本，即使还没开始生产该产品，切换为生产状态也需要消耗该成本。可以指定不同时段和不同产线或机器对应不同的固定启动成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
machine_setup_cost	否	list<IdValueSetting>	参数解释： 存在并行机情况下的启动成本；一个产品只允许在指定的并行机上进行生产，不同产品在不同机器上的启动成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0

参数	是否必选	参数类型	说明
setup_time	否	list<IdValue>	参数解释： 每类产品在不同资源上启动生产所需的时间，在生产该产品前机器需要进行换料、换模以及其他准备工作，需要消耗固定的时间，即使还没开始生产该产品，切换为生产状态也需要消耗该时间。可以指定不同产线或机器对应不同的固定启动时间消耗。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
lead_time	否	integer	参数解释： 产品提前期，生产完成并经过此时间后才可参与后继产品生产，提供原料。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
expiration_time	否	integer	参数解释： 产品过期时间，必须在时间内被用以加工或者交付。如果到达了过期时间则直接视为废料，不可再用于后续加工。 约束限制： 不涉及 取值范围： 非负整数 默认取值： MAXINT（大于计划周期的极大整数）

参数	是否必选	参数类型	说明
freezing_time	否	integer	参数解释： 开工前的冻结期，由于机器维护或试运行、原料未到位等原因，开工后数天内不允许生产。 约束限制： 不涉及 取值范围： 非负整数 默认取值： 0
min_produce_amount	否	ValueSetting	参数解释： 每类产品在给定单位时段内在产线上的最小生产量，可以指定不同时段对应不同的最小生产量限制。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max_produce_amount	否	ValueSetting	参数解释： 每类产品在给定单位时段内在产线上的最大生产量，可以指定不同时段对应不同的最大生产量限制。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
necessary_tools	否	list<array>	参数解释： 生产产品需要的模具组合信息，可能有多组模具组合可以生产该产品，一个组合可能包含多个模具。例如 ["tool_0"],["tool_2","tool_3"]表示该产品需要"tool_0"或者"tool_2","tool_3"的组合模具进行生产。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_phantom	否	boolean	参数解释： 是否是虚拟件（不需要考虑生产计划）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false
safe_holding_cost	否	ValueSetting	参数解释： 每单位产品在给定单位时段在库存中未达到安全库存时的成本，可以指定不同时段对应不同的单位低于安全库存水位的成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0

参数	是否必选	参数类型	说明
lot_size_info	否	LotSizeInfo	参数解释： 产品单位计划时段内在产线上生产的批量生产信息，即单个计划时段内的产品生产数量需要为批量的整倍数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
require_full_capacity	否	boolean	参数解释： 是否需要全产能生产，产品在一条产线上如连续开工，除第一个和最后一个周期外其他周期都需要消耗全部产能生产该产品。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false

表 3-459 SubstitutionItem

参数	是否必选	参数类型	说明
item_code	是	string	参数解释： 替代产品编码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
quantity	是	Double	参数解释： 替代一个原版物料或产品所需的替代品数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
priority	否	integer	参数解释： 替代优先级。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cost	否	Double	参数解释： 使用一个替代品需要的成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
substitution_date	否	list<integer>	参数解释： 可替代日历列表，列表中每个元素代表了一个可替代的计划时段，在该时段中替代关系生效。 约束限制： 不涉及 取值范围： 非负整数，如超过最大计划周期在算法服务中不会生效。 默认取值： 不涉及

表 3-460 Substitution

参数	是否必选	参数类型	说明
item_code	是	string	参数解释： 原版本产品编码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
substitution_mode	是	string	参数解释： 替代模式。 约束限制： 不涉及 取值范围： • 1（成本替代） • 2（优先级替代方式） 默认取值： 不涉及
priority	否	integer	参数解释： 原物料或产品优先级。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
old_version	否	boolean	参数解释： 原版物品是否是老版本需要优先消耗。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
allow_mix_sub	否	boolean	参数解释： 替代方式是否允许混合替代，如不允许，只能用一种产品完全替代该周期内的原产品。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
successor	否	string	参数解释： 可替代的后继工序，如果没有该字段则表示无工序限制。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
substitution_items	是	list<SubstitutionItem>	参数解释： 可替代产品信息列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-461 ProductionProportion

参数	是否必选	参数类型	说明
item_code	是	string	参数解释： 产品的唯一产品编码。 约束限制： 长度大于0 且不超过256的字符串，具有唯一标识。 取值范围： 不涉及 默认取值： 不涉及
quantity	是	Double	参数解释： 产品的生产量。 约束限制： 不涉及 取值范围： 非负实数 默认取值： 不涉及

表 3-462 TimeValue

参数	是否必选	参数类型	说明
time	是	integer	参数解释： 时间index。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
value	是	Double	参数解释： 时间对应的具体值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-463 TimeIdValue

参数	是否必选	参数类型	说明
time	是	integer	参数解释： 计划时段的序号 比如15天计划，第一天就是0，15天就是14。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
id	是	String	参数解释： id号，可以是对应产品或者资源编码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
value	是	Double	参数解释： 时间和机器对应的值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-464 TimeValueExpire

参数	是否必选	参数类型	说明
time	是	integer	参数解释： 时间index。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
value	是	Double	参数解释： 时间对应的具体值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
expire_time	否	Integer	参数解释： 过期时间，如果不存在认为不会过期。 约束限制： 不涉及 取值范围： 非负整数，如超过最大计划周期无效。 默认取值： 不涉及

表 3-465 Demand

参数	是否必选	参数类型	说明
end_time	是	integer	参数解释： 单个产品需求交付的对应时间，在当天进行交付，交付之前会作为持有库存。 约束限制： 不涉及 取值范围： 非负整数，如超过最大计划周期无效。 默认取值： 不涉及
quantity	是	Double	参数解释： 单个产品需求交付的对应需求量，在当天进行交付，交付之前会作为持有库存。 约束限制： 不涉及 取值范围： 非负数 默认取值： 不涉及

表 3-466 Order

参数	是否必选	参数类型	说明
order_id	是	string	参数解释： 订单编号，具有唯一标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
order_item_list	是	list<IdValue>	参数解释： 订单关联的产品编号和对应数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
release_date	否	integer	参数解释： 可开始加工日期。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
earliest_due_date	是	integer	参数解释： 最早交付日期。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
latest_due_date	是	integer	参数解释： 最晚交付日期。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
priority	否	integer	参数解释： 订单优先级。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
delay_cost	否	ValueSetting	参数解释： 订单延迟成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
lost_sale_cost	否	ValueSetting	参数解释： 订单缺货交付成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-467 Resource

参数	是否必选	参数类型	说明
name	是	string	参数解释： 设备（产线）id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
capacity	是	ValueSetting	参数解释： 产能， 约束限制： 不涉及 取值范围： -1代表产能无限制。 默认取值： 不涉及
capacity_cost	否	ValueSetting	参数解释： 产能成本， 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
extra_capacity	否	ValueSetting	参数解释： 额外产能， 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0， 输入-1代表无限制。
extra_capacity_cost	否	ValueSetting	参数解释： 额外产能成本 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0

参数	是否必选	参数类型	说明
setup_matrix	否	list<Setup Matrix>	参数解释： 资源上不同产品之间的setup转换矩阵，如果问题 涉及次序相关的决策。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
absent_time_list	否	list<Time Value>	参数解释： 维护/请假日历。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max_item_changeover_times	否	integer	参数解释： 最大产品换型次数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max_tool_changeover_times	否	integer	参数解释： 最大模具换模次数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-468 ResourceType

参数	是否必选	参数类型	说明
name	是	string	参数解释： 资源名称; 如果是同质并行机，则为对应组名。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_parallel	是	boolean	参数解释： 此资源是并行机类设备。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_identical	否	boolean	参数解释： 如果是同质并行机，则为true。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
number	否	integer	参数解释： 如果是同质并行机，则为对应组内并行机数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-469 LotSizeInfo

参数	是否必选	参数类型	说明
require_lot_size	是	boolean	参数解释： 是否需要按整批量生产。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
lot_size	否	ValueSetting	参数解释： 每类产品在给定单位时段内在产线上的基础批量值，如果需要按批量生产，则产量需要为该批量值的整数倍。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
min_lot_size	否	ValueSetting	参数解释： 每类产品在给定单位时段内在产线上的最小批量，可以指定不同时段对应不同的最小批量限制。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
max_lot_size	否	ValueSetting	参数解释： 每类产品在给定单位时段内在产线上的最大批量，可以指定不同时段对应不同的最大批量限制。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-470 BomMap

参数	是否必选	参数类型	说明
item_code	是	string	参数解释： item编号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
predecessor_list	是	list<IdValue>	参数解释： 生产一单位的item需要消耗的predecessor 编号及消耗量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-471 ValueSetting

参数	是否必选	参数类型	说明
is_time_variant	是	boolean	参数解释： 该数值是否随时间变化。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_machine_variant	否	boolean	参数解释： 该数值是否随产线（机器）变化。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
value	是	Double	参数解释： 不随时间和产线变化的固定取值。 约束限制： 如is_time_variant和is_machine_variant同时为false的时候该赋值具有实际意义。 取值范围： 不涉及 默认取值： 不涉及
time_value	否	list<Time Value>	参数解释： 随时间变化的值。 约束限制： is_time_variant为true时为必填项。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
machine_value	否	list<IdValue>	参数解释： 随产线变化的值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
time_machine_value	否	list<TimeIdValue>	参数解释： 随时间和产线变化的值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-472 IdsValueSetting

参数	是否必选	参数类型	说明
id_list	是	list<string>	参数解释： 可生产的machine id列表，列表中字符串代表机器编号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cost	是	ValueSetting	参数解释： 一组可生产机器编号对应的成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-473 InventoryParam

参数	是否必选	参数类型	说明
max_inv	否	Double	参数解释： 产品最大持有库存，每个计划时段内的期末库存都不可以超过该库存限制，默认最大库存无上限。 约束限制： 不涉及 取值范围： 非负数 默认取值： 无上限
safe_inv	否	Double	参数解释： 产品安全库存水位，每个计划时段内的期末库存如低于安全库存水位对应 safe_holding_cost 惩罚成本，高于安全库存水位为常规的 holding_cost 成本。 约束限制： 不涉及 取值范围： 非负数 默认取值： 0（无安全库存）
target_inv	否	Double	参数解释： 产品目标库存水位，整个计划周期期末库存应达到目标库存水位。 约束限制： 不涉及 取值范围： 非负数 默认取值： 0（无目标库存）

表 3-474 ProductFamily

参数	是否必选	参数类型	说明
family_code	是	string	参数解释： 产品族code。 约束限制： 长度大于0 且不超过256的字符串，具有唯一标识。 取值范围： 不涉及 默认取值： 不涉及
product_codes	是	list<string>	参数解释： 产品族包含的产品。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
only_once_setup	否	boolean	参数解释： true代表整个生产周期只考虑该产品族的一次setup。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-475 AuxTool

参数	是否必选	参数类型	说明
id	是	string	参数解释： 辅助设备id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
capacity	是	ValueSetting	参数解释： 辅助设备。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
capacity_cost	否	ValueSetting	参数解释： 辅助设备成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
absent_time_list	否	list<TimeValue>	参数解释： 辅助设备维护日历。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
extra_capacity	否	ValueSetting	参数解释： 辅助设备额外capacity。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
extra_capacity_cost	否	ValueSetting	参数解释： 辅助设备额外capacity的cost。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
available_machines	否	list<string>	参数解释： 可以辅助设备的机器列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
plant_code	否	String	参数解释： 工厂code。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-476 IdValue

参数	是否必选	参数类型	说明
id	是	string	参数解释： 基础数据类编号，对应字符串类型，可以用于表示产品编号、产线编号等。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
value	是	Double	参数解释： 基础数据类编号对应的取值，双精度浮点数据类型，可以用于表示各类场景中的成本、时间等数值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-477 ProductionParam

参数	是否必选	参数类型	说明
bucket_type	否	integer	参数解释： bucket的类型。 约束限制： 不涉及 取值范围： 0 (small-bucket 一个时间段只允许生产一种产品) 1 (big-bucket) 默认取值： 不涉及

参数	是否必选	参数类型	说明
has_setup_time	否	boolean	参数解释： 生产是否考虑setup time。 约束限制： 不涉及 取值范围： • true(生产时考虑setup time) • false(生产时不考虑setup time) 默认取值： 不涉及
allow_setup_carryover	否	boolean	参数解释： 生产时是否考虑setup carryover。 约束限制： 不涉及 取值范围： • true(生产时考虑setup carryover) • false(生产时不考虑setup carryover) 默认取值： false
allow_setup_crossover	否	boolean	参数解释： 生产时是否考虑setup crossover。 约束限制： 不涉及 取值范围： • true(生产时考虑setup crossover) • false(生产时不考虑setup crossover) 默认取值： 不涉及
allow_sequence_dependent	否	boolean	参数解释： 生产时是否考虑次序决策。 约束限制： 不涉及 取值范围： • true(考虑次序决策) • false(不考虑次序决策) 默认取值： false

参数	是否必选	参数类型	说明
allow_substitution	否	boolean	参数解释： 生产时是否考虑替代关系。 约束限制： 不涉及 取值范围： • true(考虑替代关系) • false(不考虑替代关系) 默认取值： 不涉及
allow_over_substitution	否	boolean	参数解释： true代表允许过度替代，false为不允许过度替代。 约束限制： 不涉及 取值范围： • true(允许过度替代) • false(不允许过度替代) 默认取值： 不涉及

表 3-478 BomInfo

参数	是否必选	参数类型	说明
bom_id	是	string	参数解释： bom版本号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
valid_time	否	string	参数解释： 生效时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
priority	否	integer	参数解释： bom版本优先级。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
bom_map	是	list<Bom Map>	参数解释： 产品的前序产品信息映射。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-479 SetupMatrix

参数	是否必选	参数类型	说明
setup_from	是	string	参数解释： setup的前序产品item_code。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
setup_to	是	string	参数解释： setup的后续产品item_code。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
duration	是	Double	参数解释： setup耗费的时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cost	否	Double	参数解释： setup耗费的成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0

响应参数

状态码：200

表 3-480 <添加求解任务>成功响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-481 默认取值： 不涉及

表 3-481 data 返回数据详情

参数	参数类型	描述
create_time	String	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： • created（任务已创建） • pending（任务排队中） • running（任务执行中） • completed（任务求解完成） • failed（任务失败） • deleted（任务已删除） 默认取值： 不涉及

参数	参数类型	描述
task_id	String	参数解释： 任务ID,用于后续查询任务接口使用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-482 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "time_limit": 2,
  "bom_list": [
    {
      "bom_id": "1",
      "bom_map": [
        {
          "item_code": "item_0",
          "predecessor_list": [
```

```
        {
            "id": "item_4",
            "value": 1.0
        }
    ]
}
],
"item_list": [
    {
        "demand_list": [
            {
                "end_time": 0,
                "quantity": 64
            },
            {
                "end_time": 1,
                "quantity": 80
            }
        ],
        "holding_cost": {
            "is_machine_variant": false,
            "is_time_variant": false,
            "machine_value": [],
            "time_machine_value": [],
            "time_value": [],
            "value": 4.0
        },
        "initial_inv": 109,
        "inv_param": {
            "max_inv": 700,
            "safe_inv": 70,
            "target_inv": -1
        },
        "is_phantom": false,
        "item_code": "item_0",
        "lead_time": 0,
        "machine_setup_cost": [
            {
                "cost": {
                    "is_machine_variant": false,
                    "is_time_variant": false,
                    "machine_value": [],
                    "time_machine_value": [],
                    "time_value": [],
                    "value": 140.0
                },
                "id_list": [
                    "machine_0"
                ]
            }
        ],
        "min_produce_amount": {
            "is_machine_variant": false,
            "is_time_variant": false,
            "machine_value": [],
            "time_machine_value": [],
            "time_value": [],
            "value": 14.0
        },
        "product_type": 2,
        "production_cost": {
            "is_machine_variant": false,
            "is_time_variant": false,
            "machine_value": [],
            "time_machine_value": [],
            "time_value": [],
            "value": 0
        }
    }
]
```

```
    },
    "production_time": [
      {
        "id": "machine_0",
        "value": 1.0
      }
    ],
    "setup_cost": {
      "is_machine_variant": false,
      "is_time_variant": false,
      "machine_value": [],
      "time_machine_value": [],
      "time_value": [],
      "value": 140.0
    },
    "setup_time": [
      {
        "id": "machine_0",
        "value": 0.0
      }
    ]
  },
  {
    "demand_list": [],
    "holding_cost": {
      "is_machine_variant": false,
      "is_time_variant": false,
      "machine_value": [],
      "time_machine_value": [],
      "time_value": [],
      "value": 1.0
    },
    "initial_inv": 2000,
    "item_code": "item_4",
    "product_type": 0
  }
],
"period_num": 24,
"production_param": {
  "allow_over_substitution": true,
  "allow_sequence_dependent": false,
  "allow_setup_carryover": false,
  "allow_substitution": false
},
"resource_list": [
  {
    "capacity": {
      "is_machine_variant": false,
      "is_time_variant": false,
      "machine_value": [],
      "time_machine_value": [],
      "time_value": [],
      "value": 257.14285714285717
    },
    "extra_capacity": {
      "is_machine_variant": false,
      "is_time_variant": false,
      "machine_value": [],
      "time_machine_value": [],
      "time_value": [],
      "value": -1.0
    },
    "extra_capacity_cost": {
      "is_machine_variant": false,
      "is_time_variant": false,
      "machine_value": [],
      "time_machine_value": [],
      "time_value": [],
      "value": 10000.0
    }
  }
]
```

```
    },
    "name": "machine_0"
  }
],
"resource_type_list": [
  {
    "is_parallel": true,
    "name": "machine_0"
  }
]
}
```

响应示例

```
{
  "data": {
    "create_time": "2025-01-01 10:00:00.000000",
    "status": "created",
    "task_id": "a3d5a37a-xxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)

3.7.4.2 查询任务详情

功能介绍

通过“查询任务详情”接口来具体查看当前任务的进度。当任务状态为“completed”时，说明任务执行完成，可从指定的OBS路径中查看完成的求解结果。

URI

GET /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-483 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-484 <查询任务详情>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-485 默认取值： 不涉及

表 3-485 <查询任务详情>"data" 参数说明

参数	参数类型	描述
create_time	string	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
logs	string	参数解释： 当前任务的执行日志详情。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
output	Object	参数解释： 任务处理结果，任务状态为completed时携带。详见 表4 "output" 参数说明 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： • created（任务已创建） • pending（任务排队中） • running（任务执行中） • completed（任务求解完成） • failed（任务失败） • deleted（任务已删除） 默认取值： 不涉及
task_id	String	参数解释： 当前任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-486 output 详情

参数	参数类型	说明
is_feasible	boolean	参数解释： 返回的计划是否可行（是否违反约束），true为可行。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	说明
item_result	list<ItemResult>	参数解释： 产品的生产计划。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
material_result	list<MaterialResult>	参数解释： 原材料库存情况。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
resource_result	list<ResourceResult>	参数解释： 资源的使用情况。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
backlog	list<BacklogResult>	参数解释： 需求延迟满足情况。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-487 MaterialResult

参数	参数类型	说明
item_code	string	参数解释： 原材料产品编号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
inventory_list	list<TimeValue>	参数解释： 原材料在各个时期的库存情况。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-488 ResourceResult

参数	参数类型	说明
name	string	参数解释： 资源id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
capacity_use	list<CapacityUse>	参数解释： 资源的使用信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-489 BacklogResult

参数	参数类型	说明
item_code	string	参数解释： 产品编号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_end_product	boolean	参数解释： 产品是否是最终产品。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
backlog_list	list<TimeValue>	参数解释： 各时段的缺货数值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-490 ItemResult

参数	参数类型	说明
item_code	string	参数解释： 产品代码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	说明
produce_info	list<ItemPro duceInfo>	参数解释: 产品生产相关信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-491 CapacityUse

参数	参数类型	说明
time	integer	参数解释: 时间index。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
max_capacity	Double	参数解释: 资源的最大能力。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
use_capacity	Double	参数解释: 已使用的资源能力。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	说明
overtime	Double	参数解释： 使用的额外能力。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max_extra_capacity	Double	参数解释： 资源的最大额外能力。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-492 ItemProduceInfo

参数	参数类型	说明
time	integer	参数解释： 时间index。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
produce_quantity	Double	参数解释： 对应日期的生产量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	说明
demand	Double	参数解释： 需求量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
inventory	Double	参数解释： 库存量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
min_quantity	Double	参数解释： 最小产量 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0

状态码：400

表 3-493 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "create_time": "2025-01-01 10:00:00.000000",
    "logs": "xxx",
    "output": {
      "backlog": null,
      "is_feasible": true,
      "item_result": [
        {
          "item_code": "item_0",
          "produce_info": [
            {
              "demand": 64.0,
              "inventory": 45.0,
              "time": 0
            },
            {
              "demand": 80.0,
              "inventory": 43.0,
              "min_quantity": 14.0,
              "produce_quantity": 78.0,
              "production_list": [
                {
                  "machine": "machine_0",
                  "produce_quantity": 78.0
                }
              ]
            }
          ]
        }
      ]
    }
  }
}
```

```
    ],  
    "time": 1  
  }  
]  
}  
],  
"result": 91333.35714285713,  
"status": "success"  
},  
"status": "completed",  
"task_id": "c5edc94b-xxxx-xxxx-xxx-754e481bafa5"  
}  
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)

3.7.4.3 查询任务列表

功能介绍

通过“查询任务列表”来查询所有求解任务的状态及task_id。

URI

GET /task-list

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-494 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-495 <查询任务列表>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-496 默认取值： 不涉及

表 3-496 <查询任务列表>"data" 参数说明

参数	参数类型	描述
count	int	参数解释： 任务数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
tasks	Array(Object)	参数解释： 任务列表详情，其中Object的请求格式参见（ data返回数据详情 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-497 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{  
  "data": {
```

```
    "count": 2,
    "tasks": [
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "cf2a475e-xxxx-xxxx-xxxx-9f342b1b032e"
      },
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
      }
    ]
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.4.4 删除任务

功能介绍

通过“删除任务”来删除已添加的求解任务。

URI

DELETE /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-498 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-499 <删除任务>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-500 默认取值： 不涉及

表 3-500 <删除任务>"data" 参数说明

参数	参数类型	描述
status	string	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： 不涉及 默认取值： deleted

参数	参数类型	描述
task_id	string	参数解释： 当前任务ID 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-501 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "status": "deleted",
```

```
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"  
  }  
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.5 Pangu-OPT-运输计划引擎

3.7.5.1 创建求解任务

功能介绍

运输计划引擎模型，根据工厂生产下线信息以及仓库发货需求，结合供应能力、运输资源、客户需求和竞争要求，制定中长期的运输计划方案，指导运输业务的运作。调用“运输计划引擎”接口会同步响应返回“task_id”，服务会将请求任务添加到待处理队列中进行排队（pending）、任务执行中（running）、求解完成（completed）等三个阶段。

URI

POST /task/solve

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-502 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-503 请求参数

参数	是否必选	参数类型	描述
name	是	String	参数解释： 数据名，由用户自定义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
type	是	String	参数解释： VRP问题类型，为枚举值。 约束限制： 不涉及 取值范围： • TSP：旅行商问题 • CVRP：容量限制VRP • VRPTW：有时间限制VRPTW • VRPB：回程送货VRP • MDVRPTW：多车场VRP • PCVRPTW：有配送奖励VRP 默认取值： 不涉及

参数	是否必选	参数类型	描述
vehicle_infos	是	List<vehicle_info>	参数解释： 车辆信息，详见参数 vehicle_info 结构表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
node_infos	是	List<node_info>	参数解释： 节点信息，详见参数 node_info 结构表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
depot_node	是	List<Integer>	参数解释： 仓库/车场节点编号集。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
explicit_edge_weight	二选一	List<List<Integer>>	参数解释： 各个节点间的距离成本矩阵，行号/列号对应node_infos中的数组下标。 约束限制： 该参数与multiple_edge_weight仅可选择一个。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
multiple_edge_weight		List<List<List<Integer>>>>	参数解释： 各节点间的距离成本矩阵，适用于多可达关系场景。 约束限制： 该参数与explicit_edge_weight仅可选择一个。 取值范围： 不涉及 默认取值： 不涉及
time_weight	二选一	List<List<Integer>>>	参数解释： 各个节点间的时间成本矩阵，行号/列号对应node_infos中的数组下标。 约束限制： 该参数与multiple_time_weight仅可选择一个。 取值范围： 不涉及 默认取值： 不涉及
multiple_time_weight		List<List<List<Integer>>>>	参数解释： 各节点间的时间成本矩阵，适用于多可达关系场景。 约束限制： 该参数与multiple_edge_weight仅可选择一个。 取值范围： 不涉及 默认取值： 不涉及
objective_cost	是	Object	参数解释： 目标函数选项，详见参数 objective_cost 结构表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
option	是	Object	参数解释： 路径规划类型可选项，详见参数 option 结构表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
parameters	是	Object	参数解释： 算法参数，详见参数 parameters 结构表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-504 vehicle_info

参数	是否必选	参数类型	描述
vehicle_type	是	String	参数解释： 车辆型号名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
available_num	是	Integer	参数解释： 车辆可用数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
capacity	是	Double	参数解释： 单车容量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
shift_start_time	否	Integer	参数解释： 车辆作业班次开始时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0。
shift_end_time	否	Integer	参数解释： 车辆作业班次结束时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 100000。
start_node	是	Integer	参数解释： 出发节点Id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
end_node	否	Integer	参数解释： 返回节点Id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max_distance	否	Integer	参数解释： 车辆允许的最大行驶距离。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 1000000。
max_duration	否	Integer	参数解释： 车辆允许的最大工作时长。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 1000000。
unit_distance_cost	否	Double	参数解释： 单位距离运输成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 1元。

参数	是否必选	参数类型	描述
unit_duration_cost	否	Double	参数解释： 单位时间工作成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 1元。
fixed_cost	否	Double	参数解释： 单车固定成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
multiple_trips	否	Boolean	参数解释： 是否允许在一个工作周期内，多次往返出发点进行配送任务(多车程)。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false。（当前版本仅支持false场景）。
matrix_index	否	Integer	参数解释： 车辆所使用的距离矩阵编号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0

表 3-505 node_info

参数	是否必选	参数类型	描述
node_id	是	Integer	参数解释： 节点Id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
demand	是	Double	参数解释： 配送量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
split_order	否	Boolean	参数解释： 配送量是否可以拆分配送。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false。（当前版本仅支持false场景）。
pickup	是	Double	参数解释： 取货量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
time_windows	否	List<array>	参数解释： 节点作业/服务时间窗，数组长度为2，[0]和[1]取值为最早/晚到达时间（单位：分钟），以基准时刻为0开始计时。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_load_time	否	Double	参数解释： 装车服务时间，单位分钟。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0。
service_unload_time	否	Double	参数解释： 卸车服务时间，单位分钟。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0。
depot_load_time	否	Integer	参数解释： 配送客户所需配送量在仓库的装车时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0

参数	是否必选	参数类型	描述
release_time	否	Integer	参数解释： 配送该节点的车辆最早从仓库发出的时间，配送货物齐套时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0。
penalty	否	Integer	参数解释： 跳过站点的惩罚成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 10000000。
backhauls	否	Boolean	参数解释： 该站点任务是否为回程任务。 约束限制： 不涉及 取值范围： true:回城 false:去程 默认取值： false
periodic	否	Integer	参数解释： 周期场景下的一个周期内需要到达的次数/频率。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 1。（当前版本仅支持默认取值1）。

参数	是否必选	参数类型	描述
demand_volume	否	Integer	参数解释： 需求体积量（可加体积）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
pickup_volume	否	Integer	参数解释： 取货体积量（可加体积）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
merge_rule	是	String	参数解释： 订单合并规则。 约束限制： 不涉及 取值范围： ["no", "max"] 默认取值： "no"

表 3-506 objective_cost

参数	是否必选	参数类型	描述
edge_weight_cost	是	Double	参数解释： 基础成本，车辆经过的路线各点间成本(运输距离成本+运输耗时成本)之和权重，取0表示不考虑该目标。（当前版本仅支持取值1）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
fixed_cost	是	Double	参数解释： 固定成本权重，取0表示不考虑该目标。（当前版本仅支持取值1）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-507 option

参数	是否必选	参数类型	描述
periodic	是	Integer	参数解释： 配送周期数。(当前版本仅支持单周期优化，即取值为1)。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-508 parameters

参数	是否必选	参数类型	描述
time_limit	是	Integer	参数解释： 求解时长限制(秒)，必选。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 60

响应参数

状态码：200

表 3-509 <添加求解任务>成功响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见表3-510。 默认取值： 不涉及

表 3-510 data 返回数据详情

参数	参数类型	描述
create_time	String	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： - created（任务已创建） - pending（任务排队中） - running（任务执行中） - completed（任务求解完成） - failed（任务失败） - deleted（任务已删除） 默认取值： 不涉及
task_id	String	参数解释： 任务ID,用于后续查询任务接口使用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-511 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "name": "cvrp_test1",
  "type": "CVRP",
  "vehicle_infos": [
    {
      "vehicle_type": "V001",
      "available_num": 3,
      "capacity": 20,
      "shift_start_time": 0,
      "shift_end_time": 100000,
      "start_node": 0,
      "end_node": 0,
      "max_distance": 100000,
      "max_duration": 1000000,
      "max_node_number": 1000000,
      "unit_distance_cost": 1,
      "unit_duration_cost": 1,
      "vehicle_load_time": 0,
      "vehicle_unload_time": 0,
      "fixed_cost": 0,
      "multiple_trips": false
    }
  ],
  "node_infos": [
    {
      "node_id": 0,
      "demand": 0,
      "split_order": false,
      "pickup": 0,
      "time_windows": [],
      "service_load_time": 0,
      "service_unload_time": 0,
      "release_time": 0,
      "slack_max": 10000,
      "penalty": 10000000,
      "depot_capacity": 100,
      "pickup_order_index": -1,
      "delivery_order_index": -1,
      "backhauls": false,
      "periodic": 1,
      "merge_rule": "no"
    },
    {
      "node_id": 1,
      "demand": 7,
      "split_order": false,
      "pickup": 0,
      "time_windows": [],

```



```
1690
],
[
  1132,
  2850,
  2384,
  2100,
  3321,
  3569,
  1690
]
],
"time_weight": [
  [
    1132,
    2850,
    2384,
    2100,
    3321,
    3569,
    1690
  ],
  [
    1132,
    2850,
    2384,
    2100,
    3321,
    3569,
    1690
  ],
  [
    1132,
    2850,
    2384,
    2100,
    3321,
    3569,
    1690
  ],
  [
    1132,
    2850,
    2384,
    2100,
    3321,
    3569,
    1690
  ],
  [
    1132,
```

```
        2850,  
        2384,  
        2100,  
        3321,  
        3569,  
        1690  
    ],  
    ],  
    "objective_cost": {  
        "edge_weight_cost": 1,  
        "fixed_cost": 0,  
        "load_dependent_cost": 0,  
        "cumulative_cost": 0  
    },  
    "option": {  
        "periodic": 1  
    },  
    "parameters": {  
        "time_limit": 6  
    }  
}
```

响应示例

```
{  
  "data": {  
    "create_time": "2025-01-01 10:00:00.000000",  
    "status": "created",  
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"  
  }  
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)

3.7.5.2 查询任务详情

功能介绍

通过“查询任务详情”来具体查看当前任务的进度。当任务状态为“completed”时，说明任务执行完成，可从指定的OBS路径中查看完成的求解结果。

URI

GET /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-512 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-513 <查询任务详情>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据 约束限制： 不涉及 取值范围： 详情参见 表3-514 默认取值： 不涉及

表 3-514 <查询任务详情>"data" 参数说明

参数	参数类型	描述
create_time	string	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
logs	string	参数解释： 当前任务的执行日志详情。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
output	Object	参数解释： 任务处理结果，任务状态为completed时携带。详见 表4 "output" 参数说明 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： • created（任务已创建） • pending（任务排队中） • running（任务执行中） • completed（任务求解完成） • failed（任务失败） • deleted（任务已删除） 默认取值： 不涉及
task_id	String	参数解释： 当前任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-515 output

参数	参数类型	描述
schedule_plan	List<Route>	参数解释： 计算结果中的路径信息。详见参数Route结构表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
objective	Double	参数解释： 计算结果的目标值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-516 Route

参数	参数类型	描述
route_id	List<Route>	参数解释： 路线编号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
vehicle_type	String	参数解释： 车辆型号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
node_list	List<node>	参数解释： 路线经过的节点列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
total_cost	Double	参数解释： 路线总成本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
total_weight	Double	参数解释： 路线运输的总重量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
total_time	Double	参数解释： 路线运输的总时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
periodic_list	List<Integer>	参数解释： 在多周期场景下出现在第几个周期内。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-517 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "create_time": "2025-01-01 10:00:00.000000",
    "logs": "xxx",
    "output": {
      "objective": 19310.0,
      "schedule_plan": [
        {
          "node_list": [
            {
              "arrive_time": 2384.0,
              "departure_time": 2384.0,
              "node_id": 2,
              "wait_time": 0.0
            },
            {
              "arrive_time": 4074.0,
              "departure_time": 4074.0,
              "node_id": 6,
              "wait_time": 0.0
            }
          ]
        },
        "periodic_list": [],
        "route_id": "",
        "total_cost": 5206.0,
        "total_time": 5206.0,
      ]
    }
  }
}
```



```
    "total_weight": 5206.0,  
    "vehicle_type": "V001"  
  },  
  {  
    "node_list": [  
      {  
        "arrive_time": 3321.0,  
        "departure_time": 3321.0,  
        "node_id": 4,  
        "wait_time": 0.0  
      },  
      {  
        "arrive_time": 6171.0,  
        "departure_time": 6171.0,  
        "node_id": 1,  
        "wait_time": 0.0  
      }  
    ],  
    "periodic_list": [],  
    "route_id": "",  
    "total_cost": 7303.0,  
    "total_time": 7303.0,  
    "total_weight": 7303.0,  
    "vehicle_type": "V001"  
  },  
  {  
    "node_list": [  
      {  
        "arrive_time": 2100.0,  
        "departure_time": 2100.0,  
        "node_id": 3,  
        "wait_time": 0.0  
      },  
      {  
        "arrive_time": 5669.0,  
        "departure_time": 5669.0,  
        "node_id": 5,  
        "wait_time": 0.0  
      }  
    ],  
    "periodic_list": [],  
    "route_id": "",  
    "total_cost": 6801.0,  
    "total_time": 6801.0,  
    "total_weight": 6801.0,  
    "vehicle_type": "V001"  
  }  
]  
},  
"status": "completed",  
"task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"  
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)

3.7.5.3 查询任务列表

功能介绍

通过“查询任务列表”接口来查询所有求解任务的状态及task_id。

URI

GET /task-list

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-518 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-519 <查询任务列表>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-520 默认取值： 不涉及

表 3-520 <查询任务列表>"data" 参数说明

参数	参数类型	描述
count	int	参数解释： 任务数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
tasks	Array(Object)	参数解释： 任务列表详情，其中Object的请求格式参见（ data返回数据详情 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-521 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "count": 2,
    "tasks": [
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "cf2a475e-xxxx-xxxx-xxxx-9f342b1b032e"
      },
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
      }
    ]
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.5.4 删除任务

功能介绍

通过“删除任务”接口来删除已添加的求解任务。

URI

DELETE /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-522 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-523 <删除任务>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-524 默认取值： 不涉及

表 3-524 <删除任务>"data" 参数说明

参数	参数类型	描述
status	string	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： 不涉及 默认取值： deleted
task_id	string	参数解释： 当前任务ID 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-525 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "status": "deleted",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.6 Pangu-OPT-服装切割引擎

3.7.6.1 创建求解任务

功能介绍

服装切割引擎模型，板式产品切割算法优化，提升板材利用率，节省材料成本，适用于服装领域。通过“服装切割引擎”接口创建求解任务后会同步响应返回“task_id”，服务会将请求任务添加到待处理队列中进行排队（pending）、任务执行中（running）、求解完成（completed）等三个阶段。

URI

POST /task/solve

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-526 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-527 请求参数

参数	是否必选	参数类型	描述
id	是	String	参数解释 任务名，任务唯一标识ID 约束限制 不涉及 取值范围 字符数量取值范围1~256 默认取值 不涉及
order	是	String	参数解释 订单名 约束限制 不涉及 取值范围 字符数量取值范围1~256 默认取值 不涉及
name	是	String	参数解释 床名 约束限制 不涉及 取值范围 字符数量取值范围1~256 默认取值 不涉及
time_limit	是	Number	参数解释 算法运行时间（单位：秒） 约束限制 不涉及 取值范围 (0, 1800] 默认取值 不涉及

参数	是否必选	参数类型	描述
gap_mode	否	Integer	参数解释 零件间隙处理模式 约束限制 备用属性，当前不支持 取值范围 [0,1] 默认取值 0
overlap	是	Number	参数解释 分列排场景下两列之间长度方向 交错量 约束限制 针对分列排场景有效 取值范围 [0.0, 100000.0] 默认取值 不涉及
fabric	是	fabric object	参数解释 面料属性 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及
polygon	是	Array of polygon objects	参数解释 简单多边形轮廓定义 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及

参数	是否必选	参数类型	描述
piece	是	Array of piece objects	参数解释 裁片定义 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及
hole	否	Array of hole objects	参数解释 布料瑕疵定义 约束限制 适用于布料有瑕疵和锁定裁片场景 取值范围 不涉及 默认取值 不涉及
constraints	否	Array of constraints objects	参数解释 排唛约束定义 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及

表 3-528 fabric

参数	是否必选	参数类型	描述
width	是	Number	参数解释 布料宽度 约束限制 不涉及 取值范围 (0.0, 100000.0] 默认取值 不涉及

参数	是否必选	参数类型	描述
grid_x	否	Number	参数解释 布料x轴方向格子宽度 约束限制 对格对条约束场景参数，备用属性，当前不支持 取值范围 [0,100000] 默认取值 0.0
grid_y	否	Number	参数解释 布料y轴方向格子宽度 约束限制 对格对条约束场景参数，备用属性，当前不支持 取值范围 [0.0, 100000.0] 默认取值 0.0

表 3-529 polygon

参数	是否必选	参数类型	描述
index	是	Integer	参数解释 简单多边形索引 约束限制 从0开始，依次递增 取值范围 大于等于0 默认取值 不涉及

参数	是否必选	参数类型	描述
profile	是	Array of numbers	参数解释 简单多边形轮廓 约束限制 多边形轮廓点逆时针排序，xy轴坐标依次排序展开。要求元素个数至少为6，且为偶数 取值范围 不涉及 默认取值 不涉及

表 3-530 piece

参数	是否必选	参数类型	描述
index	是	Integer	参数解释 裁片索引 约束限制 从0开始，依次递增 取值范围 大于等于0 默认取值 不涉及
polygon_index	是	Integer	参数解释 实体多边形（裁片轮廓）在简单多边形定义向量中的索引值 约束限制 不涉及 取值范围 大于等于0 默认取值 不涉及

参数	是否必选	参数类型	描述
gap_index	否	Integer	参数解释 间隔多边形（加上最小间隔的简单多边形轮廓）在简单多边形定义向量中的索引值 约束限制 -1表示没有间隔。备用属性，当前不支持 取值范围 大于等于-1 默认取值 -1
hole_index	否	Integer	参数解释 实体多边形内部孔洞在简单多边形定义向量中的索引值 约束限制 -1表示没有孔洞。备用，当前不支持 取值范围 大于等于-1 默认取值 -1
tilted	否	Number	参数解释 微小旋转角度，在原旋转角度（由属性rot获得）加减此数值后的获得旋转角度也作为裁片可旋转角度。 约束限制 若考虑微小旋转，则无法考虑裁片翻转 取值范围 [0.0, 15.0] 默认取值 0.0

参数	是否必选	参数类型	描述
gap	否	Number	参数解释 裁片间隔， 约束限制 对于不支持间隔多边形的算法有效。备用属性，当前不支持 取值范围 [0.0, 100000.0] 默认取值 0.0
pose_group	否	Integer	参数解释 姿态Y约束分组标记，要求同一组裁片的旋转和翻转相同 约束限制 -1表示没有姿态Y约束分组。若有，则从0开始，依次递增 取值范围 大于等于-1 默认取值 -1
column_group	否	Integer	参数解释 列分组标记 约束限制 -1表示不分列排版。若分列，则从0开始，依次递增 取值范围 大于等于-1 默认取值 -1
rot	是	Number	参数解释 裁片可旋转角度倍数 约束限制 不涉及 取值范围 枚举类型，枚举值为：0,90,180 默认取值 不涉及

参数	是否必选	参数类型	描述
flip_x	是	Integer	参数解释 裁片可否沿x轴翻转 约束限制 0表示禁止，1表示允许 取值范围 [0, 1] 默认取值 不涉及
flip_y	是	Integer	参数解释 裁片可否沿y轴翻转 约束限制 0表示禁止，1表示允许 取值范围 [0, 1] 默认取值 不涉及
remark	否	String	参数解释 备注信息 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及
y	否	Array of y objects	参数解释 不同翻转情形的裁片Y约束 约束限制 元素个数最多为4。若某翻转情形没有定义，采用不发生翻转，即flip_x=0,flip_y=0，的情形定义 取值范围 不涉及 默认取值 不涉及

表 3-531 y

参数	是否必选	参数类型	描述
flip_x	是	Integer	参数解释 裁片是否沿x轴翻转 约束限制 0表示不翻转，1表示翻转 取值范围 [0, 1] 默认取值 不涉及
flip_y	是	Integer	参数解释 裁片是否沿y轴翻转 约束限制 0表示不翻转，1表示翻转 取值范围 [0, 1] 默认取值 不涉及
min_y	是	Number	参数解释 裁片的包络矩形下边界在布料中的最小y坐标 约束限制 小于布料宽度 取值范围 [0.0 100000.0] 默认取值 不涉及
max_y	是	Number	参数解释 裁片的包络矩形下边界在布料中的最大y坐标 约束限制 小于布料宽度 取值范围 [0.0 100000.0] 默认取值 不涉及

表 3-532 hole

参数	是否必选	参数类型	描述
polygon_index	是	Integer	参数解释 瑕疵轮廓在简单多边形定义向量中的索引 约束限制 不涉及 取值范围 大于等于0 默认取值 不涉及
gap_index	否	Integer	参数解释 间隔多边形（加上最小间隔的裁片轮廓）在简单多边形定义向量中的索引 约束限制 -1表示没有间隔。备用属性，当前不支持 大于等于-1 默认取值 -1
id	是	Integer	参数解释 瑕疵或者裁片索引 约束限制 -1表示真的瑕疵，大于等于0表示锁定裁片。对于锁定裁片，id从0开始，注意，此时piece->id值需要顺延该属性 取值范围 大于等于-1 默认取值 不涉及

表 3-533 constraints

参数	是否必选	参数类型	描述
grid	否	Object	参数解释 定义单一裁片的对格对条约束 约束限制 备用属性，当前不支持 取值范围 不涉及 默认取值 不涉及
grid2	否	Object	参数解释 定义两个裁片之间的对格约束 约束限制 备用属性，当前不支持 取值范围 不涉及 默认取值 不涉及
position	否	position object	参数解释 表征多个裁片的相对位置关系近似不变，使得多个裁片的参考点在指定的矩形区域内 约束限制 适用于相邻约束，备用属性，当前不支持 取值范围 不涉及 默认取值 不涉及

表 3-534 position

参数	是否必选	参数类型	描述
x	是	Number	参数解释 相邻约束中矩形区域的x轴长度 约束限制 不涉及 取值范围 [0.0, 100000.0] 默认取值 不涉及
y	是	Number	参数解释 相邻约束中矩形区域的y轴长度 约束限制 不涉及 取值范围 [0.0, 100000.0] 默认取值 不涉及
piece	是	Array of piece objects	参数解释 相邻约束的裁片定义 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及

表 3-535 piece

参数	是否必选	参数类型	描述
index	是	Integer	参数解释 裁片索引 约束限制 不涉及 取值范围 大于等于0 默认取值 不涉及

参数	是否必选	参数类型	描述
x	是	Number	参数解释 裁片参考点x坐标 约束限制 不涉及 取值范围 [-100000.0, 100000.0] 默认取值 不涉及
y	是	Number	参数解释 裁片参考点y坐标 约束限制 不涉及 取值范围 [-100000.0, 100000.0] 默认取值 不涉及

响应参数

状态码：200

表 3-536 <添加求解任务>成功响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据 约束限制： 不涉及 取值范围： 详情参见 表3-537 默认取值： 不涉及

表 3-537 data 返回数据详情

参数	参数类型	描述
create_time	String	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： • created（任务已创建） • pending（任务排队中） • running（任务执行中） • completed（任务求解完成） • failed（任务失败） • deleted（任务已删除） 默认取值： 不涉及
task_id	String	参数解释： 任务ID,用于后续查询任务接口使用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-538 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "id": "fu",
  "order": "fu",
  "name": "fu",
  "gap_mode": 0,
  "time_limit": 60.0,
  "overlap": 0,
  "fabric": {
    "width": 38,
    "grid_x": 0,
    "grid_y": 0
  },
  "polygon": [
    {
      "index": 0,
      "profile": [
        0.0,
        0.0,
        10.0,
        0.0,
        10.0,
        10.0,
        0.0,
        10.0
      ]
    },
    {
      "index": 1,
      "profile": [
        0.0,
        0.0,
        10.0,
```

```
        0.0,  
        10.0,  
        10.0,  
        0.0,  
        10.0  
    ]  
},  
{  
    "index": 2,  
    "profile": [  
        0.0,  
        0.0,  
        14.0,  
        0.0,  
        14.0,  
        9.0,  
        0.0,  
        9.0  
    ]  
},  
{  
    "index": 3,  
    "profile": [  
        0.0,  
        0.0,  
        14.0,  
        0.0,  
        7.0,  
        7.0  
    ]  
},  
{  
    "index": 4,  
    "profile": [  
        0.0,  
        9.0,  
        0.0,  
        0.0,  
        14.0,  
        9.0  
    ]  
},  
{  
    "index": 5,  
    "profile": [  
        0.0,  
        0.0,  
        14.0,  
        0.0,  
        14.0,  
        14.0,  
        0.0,  
        14.0  
    ]  
},  
{  
    "index": 6,  
    "profile": [  
        0.0,  
        0.0,  
        10.0,  
        4.0,  
        10.0,  
        9.0,  
        0.0,  
        9.0  
    ]  
},  
{
```



```
    "index": 7,  
    "profile": [  
      0.0,  
      0.0,  
      5.0,  
      0.0,  
      5.0,  
      9.0,  
      0.0,  
      9.0  
    ]  
  },  
  {  
    "index": 8,  
    "profile": [  
      0.0,  
      0.0,  
      14.0,  
      0.0,  
      14.0,  
      14.0  
    ]  
  },  
  {  
    "index": 9,  
    "profile": [  
      0.0,  
      0.0,  
      10.0,  
      0.0,  
      10.0,  
      10.0,  
      0.0,  
      14.0  
    ]  
  },  
  {  
    "index": 10,  
    "profile": [  
      0.0,  
      8.0,  
      4.0,  
      0.0,  
      8.0,  
      8.0  
    ]  
  },  
  {  
    "index": 11,  
    "profile": [  
      0.0,  
      0.0,  
      14.0,  
      0.0,  
      7.0,  
      12.0  
    ]  
  }  
],  
"piece": [  
  {  
    "id": 0,  
    "polygon_index": 0,  
    "gap_index": -1,  
    "hole_index": -1,  
    "tilted": 0,  
    "gap": 0,  
    "pose_group": -1,  
    "column_group": -1,  
  }  
]
```

```
"rot": 90,
"flip_x": 0,
"flip_y": 0,
"remark": "no Y constraints",
"y": []
},
{
  "id": 1,
  "polygon_index": 1,
  "gap_index": -1,
  "hole_index": -1,
  "tilted": 0,
  "gap": 0,
  "pose_group": -1,
  "column_group": -1,
  "rot": 90,
  "flip_x": 0,
  "flip_y": 0,
  "remark": "no Y constraints",
  "y": []
},
{
  "id": 2,
  "polygon_index": 2,
  "gap_index": -1,
  "hole_index": -1,
  "tilted": 0,
  "gap": 0,
  "pose_group": -1,
  "column_group": -1,
  "rot": 90,
  "flip_x": 0,
  "flip_y": 0,
  "remark": "no Y constraints",
  "y": []
},
{
  "id": 3,
  "polygon_index": 3,
  "gap_index": -1,
  "hole_index": -1,
  "tilted": 0,
  "gap": 0,
  "pose_group": -1,
  "column_group": -1,
  "rot": 90,
  "flip_x": 0,
  "flip_y": 0,
  "remark": "no Y constraints",
  "y": []
},
{
  "id": 4,
  "polygon_index": 4,
  "gap_index": -1,
  "hole_index": -1,
  "tilted": 0,
  "gap": 0,
  "pose_group": -1,
  "column_group": -1,
  "rot": 90,
  "flip_x": 0,
  "flip_y": 0,
  "remark": "no Y constraints",
  "y": []
},
{
  "id": 5,
  "polygon_index": 5,
```

```
"gap_index": -1,
"hole_index": -1,
"tilted": 0,
"gap": 0,
"pose_group": -1,
"column_group": -1,
"rot": 90,
"flip_x": 0,
"flip_y": 0,
"remark": "no Y constraints",
"y": []
},
{
  "id": 6,
  "polygon_index": 6,
  "gap_index": -1,
  "hole_index": -1,
  "tilted": 0,
  "gap": 0,
  "pose_group": -1,
  "column_group": -1,
  "rot": 90,
  "flip_x": 0,
  "flip_y": 0,
  "remark": "no Y constraints",
  "y": []
},
{
  "id": 7,
  "polygon_index": 7,
  "gap_index": -1,
  "hole_index": -1,
  "tilted": 0,
  "gap": 0,
  "pose_group": -1,
  "column_group": -1,
  "rot": 90,
  "flip_x": 0,
  "flip_y": 0,
  "remark": "no Y constraints",
  "y": []
},
{
  "id": 8,
  "polygon_index": 8,
  "gap_index": -1,
  "hole_index": -1,
  "tilted": 0,
  "gap": 0,
  "pose_group": -1,
  "column_group": -1,
  "rot": 90,
  "flip_x": 0,
  "flip_y": 0,
  "remark": "no Y constraints",
  "y": []
},
{
  "id": 9,
  "polygon_index": 9,
  "gap_index": -1,
  "hole_index": -1,
  "tilted": 0,
  "gap": 0,
  "pose_group": -1,
  "column_group": -1,
  "rot": 90,
  "flip_x": 0,
  "flip_y": 0,
```

```
    "remark": "no Y constraints",
    "y": []
  },
  {
    "id": 10,
    "polygon_index": 10,
    "gap_index": -1,
    "hole_index": -1,
    "tilted": 0,
    "gap": 0,
    "pose_group": -1,
    "column_group": -1,
    "rot": 90,
    "flip_x": 0,
    "flip_y": 0,
    "remark": "no Y constraints",
    "y": []
  },
  {
    "id": 11,
    "polygon_index": 11,
    "gap_index": -1,
    "hole_index": -1,
    "tilted": 0,
    "gap": 0,
    "pose_group": -1,
    "column_group": -1,
    "rot": 90,
    "flip_x": 0,
    "flip_y": 0,
    "remark": "no Y constraints",
    "y": []
  }
],
"hole": [],
"constraints": {}
}
```

响应示例

```
{
  "data": {
    "create_time": "2025-01-01 10:00:00.000000",
    "status": "created",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)

3.7.6.2 查询任务详情

功能介绍

通过“查询任务详情”接口来具体查看当前任务的进度。当任务状态为“completed”时，说明任务执行完成，可从指定的OBS路径中查看完成的求解结果。

URI

GET /task/<task_id>
接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-539 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-540 <查询任务详情>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-541 默认取值： 不涉及

表 3-541 <查询任务详情>"data" 参数说明

参数	参数类型	描述
create_time	string	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
logs	string	参数解释： 当前任务的执行日志详情。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
output	Object	参数解释： 任务处理结果，任务状态为completed时携带。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： • created（任务已创建） • pending（任务排队中） • running（任务执行中） • completed（任务求解完成） • failed（任务失败） • deleted（任务已删除） 默认取值： 不涉及
task_id	String	参数解释： 当前任务ID 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-542 output

参数	参数类型	描述
id	String	参数解释 任务名，任务唯一标识ID 约束限制 不涉及 取值范围 字符数量取值范围1~256 默认取值 不涉及

参数	参数类型	描述
order	String	参数解释 订单名 约束限制 不涉及 取值范围 字符数量取值范围1~256 默认取值 不涉及
name	String	参数解释 床名 约束限制 不涉及 取值范围 字符数量取值范围1~256 默认取值 不涉及
time_limit	Number	参数解释 算法运行时间（单位：秒） 约束限制 不涉及 取值范围 (0, 1800] 默认取值 不涉及
gap_mode	Integer	参数解释 零件间隙处理模式 约束限制 备用属性，当前不支持 取值范围 [0,1] 默认取值 0

参数	参数类型	描述
length	Number	参数解释 使用布料长度 约束限制 不涉及 取值范围 大于等于0 默认取值 不涉及
ratio	Number	参数解释 排版利用率 约束限制 不涉及 取值范围 [0.0, 1.0] 默认取值 不涉及
pieces	Array of pieces objects	参数解释 裁片排版位置定义 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及

表 3-543 pieces

参数	参数类型	描述
id	String	裁片id - 参数解释 裁片索引 约束限制 不涉及 取值范围 大于等于0 默认取值 不涉及

参数	参数类型	描述
angle	Number	参数解释 裁片旋转角度 约束限制 不涉及 取值范围 [0, 360) 默认取值 不涉及
flip_x	Integer	参数解释 裁片是否沿x轴翻转 约束限制 不涉及 取值范围 [0, 1] 默认取值 不涉及
flip_y	Integer	参数解释 裁片是否沿y轴翻转 约束限制 不涉及 取值范围 [0, 1] 默认取值 不涉及
box	Array of box objects	参数解释 裁片包络矩形定义 约束限制 裁片先旋转再翻转后放入指定位置形成的包络矩形，由矩形左底点和右上点表示 取值范围 不涉及 默认取值 不涉及

表 3-544 box

参数	参数类型	描述
x	Number	参数解释 二维坐标点x坐标 约束限制 不涉及 取值范围 [0.0, 100000.0] 默认取值 不涉及
y	Number	二维点y轴坐标 参数解释 二维坐标点y坐标 约束限制 不涉及 取值范围 [0.0, 100000.0] 默认取值 不涉及

状态码：400

表 3-545 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "create_time": "2025-01-01 10:00:00.000000",
    "logs": "xxx",
    "output": {
      "gap_mode": 0,
      "id": "fu",
      "length": 31.539,
      "name": "fu",
      "order": "fu",
      "pieces": [
        {
          "angle": 0.0,
          "box": [
            {
              "x": 17.5391304,
              "y": 0.00246150
            },
            {
              "x": 31.5391304,
              "y": 14.0024615
            }
          ],
          "flip_x": 0,
          "flip_y": 0,
          "id": 5
        },
        {
          "angle": 180.0,
          "box": [
            {
              "x": 17.4633313,
              "y": 14.0024618
            },
            {
              "x": 31.4633313,
              "y": 23.0024618
            }
          ],
          "flip_x": 0,
          "flip_y": 0,
          "id": 2
        }
      ]
    }
  }
}
```

```
{
  "angle": 0.0,
  "box": [
    {
      "x": 0.0,
      "y": 14.0000001
    },
    {
      "x": 10.0,
      "y": 28.0000001
    }
  ],
  "flip_x": 0,
  "flip_y": 0,
  "id": 9
},
{
  "angle": 0.0,
  "box": [
    {
      "x": 10.0000004,
      "y": 28.0000001
    },
    {
      "x": 20.0000004,
      "y": 38.0000001
    }
  ],
  "flip_x": 0,
  "flip_y": 0,
  "id": 1
},
{
  "angle": 0.0,
  "box": [
    {
      "x": 0.0,
      "y": 28.0000001
    },
    {
      "x": 10.0000009,
      "y": 38.0000001
    }
  ],
  "flip_x": 0,
  "flip_y": 0,
  "id": 0
},
{
  "angle": 270.0,
  "box": [
    {
      "x": 8.46333120,
      "y": 18.00000060
    },
    {
      "x": 17.46333120,
      "y": 28.000000600
    }
  ],
  "flip_x": 0,
  "flip_y": 0,
  "id": 6
},
{
  "angle": 0.0,
  "box": [
    {
      "x": 17.46333170,
```

```
        "y": 23.0024614
      },
      {
        "x": 31.4633310,
        "y": 35.0024614
      }
    ],
    "flip_x": 0,
    "flip_y": 0,
    "id": 11
  },
  {
    "angle": 0.0,
    "box": [
      {
        "x": 3.5391306,
        "y": 0.0024610
      },
      {
        "x": 17.5391306,
        "y": 14.0024610
      }
    ],
    "flip_x": 0,
    "flip_y": 0,
    "id": 8
  },
  {
    "angle": 270.0,
    "box": [
      {
        "x": 22.5367119,
        "y": 23.9994243
      },
      {
        "x": 31.5367119,
        "y": 37.9994243
      }
    ],
    "flip_x": 0,
    "flip_y": 0,
    "id": 4
  },
  {
    "angle": 270.0,
    "box": [
      {
        "x": 10.0000003,
        "y": 6.46333100
      },
      {
        "x": 17.0000003,
        "y": 20.4633310
      }
    ],
    "flip_x": 0,
    "flip_y": 0,
    "id": 3
  },
  {
    "angle": 270.0,
    "box": [
      {
        "x": 0.0,
        "y": 9.00000008
      },
      {
        "x": 9.0,
        "y": 14.00000008
      }
    ],
    "flip_x": 0,
    "flip_y": 0,
    "id": 2
  },
  {
    "angle": 270.0,
    "box": [
      {
        "x": 0.0,
        "y": 9.00000008
      },
      {
        "x": 9.0,
        "y": 14.00000008
      }
    ],
    "flip_x": 0,
    "flip_y": 0,
    "id": 1
  }
]
```

```
    },
    ],
    "flip_x": 0,
    "flip_y": 0,
    "id": 7
  },
  {
    "angle": 90.0,
    "box": [
      {
        "x": 0.0,
        "y": 1.0000009
      },
      {
        "x": 8.0000002,
        "y": 9.0000009
      }
    ],
    "flip_x": 0,
    "flip_y": 0,
    "id": 10
  }
],
"ratio": 0.9036,
"time_limit": 60.1
},
"status": "completed",
"task_id": "c5edc94b-xxxx-xxxx-xxx-754e481bafa5"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)

3.7.6.3 查询任务列表

功能介绍

通过“查询任务列表”来查询所有求解任务的状态及task_id。

URI

GET /task-list

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-546 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-547 <查询任务列表>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-548 。 默认取值： 不涉及

表 3-548 <查询任务列表>"data" 参数说明

参数	参数类型	描述
count	int	参数解释： 任务数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
tasks	Array(Object)	参数解释： 任务列表详情，其中Object的请求格式参见（ data返回数据详情 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-549 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "count": 2,
    "tasks": [
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "cf2a475e-xxxx-xxxx-xxxx-9f342b1b032e"
      },
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
      }
    ]
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.6.4 删除任务

功能介绍

通过“删除任务”来删除已添加的求解任务。

URI

DELETE /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-550 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-551 <删除任务>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-552 。 默认取值： 不涉及

表 3-552 <删除任务>"data" 参数说明

参数	参数类型	描述
status	string	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： 不涉及 默认取值： deleted
task_id	string	参数解释： 当前任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-553 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "status": "deleted",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.6.5 附录

相关参数和业务说明

- 1. double类型数据全部留1位小数，若超过，将直接进行截断，比如100.34将变为100.3，又比如-20.48将变为-20.4。

2. double类型数据最小值-100,000，最大值100000
3. piece->y约束和piece->rot、piece->flip_x、piece->flip_y相关关系如下：

- a. 若piece->y约束为空，没有要求；
- b. 若piece->y约束元素个数为1，则要求piece->y->flip_x = 0，piece->y->flip_y=0，对piece->rot, piece->flip_x, piece->flip_y没有要求；

```
"y": [  
  {  
    "flip_x": 0,  
    "flip_y": 0,  
    "min_y": ***,  
    "max_y": ***  
  },  
]
```

- c. 若piece->y约束元素个数为2，共有3种情形，如下：

- i. piece->rot = 0, piece->flip_x = 1, piece->flip_y=0,

```
"y": [  
  {  
    "flip_x": 0,  
    "flip_y": 0,  
    "min_y": ***,  
    "max_y": ***  
  },  
]
```

- ii. piece->rot = 0, piece->flip_x = 0, piece->flip_y = 1

```
"y": [  
  {  
    "flip_x": 0,  
    "flip_y": 0,  
    "min_y": ***,  
    "max_y": ***  
  },  
  {  
    "flip_x": 0,  
    "flip_y": 1,  
    "min_y": ***,  
    "max_y": ***  
  }  
]
```

- iii. piece->rot = 180, piece->flip_x = 0, piece->flip_y = 0

```
"y": [  
  {  
    "flip_x": 0,  
    "flip_y": 0,  
    "min_y": ***,  
    "max_y": ***  
  },  
  {  
    "flip_x": 1,  
    "flip_y": 1,  
    "min_y": ***,  
    "max_y": ***  
  }  
]
```

- d. 若piece->y约束元素个数不允许为3；
- e. 若piece->y约束元素个数为4，共有如下4中情形，如下：
 - i. piece->rot = 0, piece->flip_x = 1, piece->flip_y = 1,
 - ii. piece->rot = 180, piece->flip_x = 1, piece->flip_y = 1,
 - iii. piece->rot = 180, piece->flip_x = 1, piece->flip_y = 0,
 - iv. piece->rot = 180, piece->flip_x = 0, piece->flip_y = 1

对应的piece->y约束场景要求flip_x、flip_y遍历4种可能情况，如下：


```
"y": [
  {
    "flip_x": 0,
    "flip_y": 0,
    "min_y": ***,
    "max_y": ***
  },
  {
    "flip_x": 1,
    "flip_y": 0,
    "min_y": ***,
    "max_y": ***
  },
  {
    "flip_x": 0,
    "flip_y": 1,
    "min_y": ***,
    "max_y": ***
  },
  {
    "flip_x": 1,
    "flip_y": 1,
    "min_y": ***,
    "max_y": ***
  }
]
```

解释：下表为不同变换角度和翻转条件下的具体变换，R0、R180分别表示不旋转和旋转 180度，FLIPX表示沿X轴翻转，FLIPY表示沿Y轴翻转；

不同角度和 翻转条件下的 具体变换	flip_x = 0 flip_y = 0	flip_x = 1 flip_y = 0	flip_x = 0 flip_y = 1	flip_x = 1 flip_y = 1
旋转0度	R0	R0 FLIPX	R0 FLIPY	R0 FLIPX FLIPY R180
旋转180度	R0 R180	R0 FLIPX FLIPY R180	R0 FLIPX FLIPY R180	R0 FLIPX FLIPY R180

4. position约束参数定义如下：由客户指定需要考虑相邻约束裁片组合，并指定裁片参考点。在排版时，裁片参考点需要放置在指定矩形范围内，即两个裁片的参考点在长度和宽度方向上的距离不大于某一指定阈值。如图1 相邻约束示意图，裁片S1和S2之间需要满足相邻约束，红点表示相邻参考点（不同于摆放参考点）。若S1放置位置固定，则在放置S2时，算法需保证裁片S2的参考点落在矩形范围内。

图 3-26 相邻约束示意图



3.7.7 Pangu-OPT-三维装箱引擎

3.7.7.1 创建求解任务

功能介绍

三维装箱引擎，支持三维装箱算法，提升装载率，节省装载成本，适用于物流装载领域。通过“三维装箱引擎”接口创建求解任务后会同步响应返回“task_id”，服务会将请求任务添加到待处理队列中进行排队（pending）、任务执行中（running）、求解完成（completed）等三个阶段。

URI

POST /task/solve

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-554 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-555 请求参数

参数	是否必选	参数类型	描述
time_limit	是	Integer	参数解释 用户指定的算法最大运行时间（单位：秒） 约束限制 不涉及 取值范围 (0, 3600] 默认取值 不涉及

参数	是否必选	参数类型	描述
containers	是	Array of containers objects	参数解释 载具信息 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及
box_types	是	Array of box_types objects	参数解释 箱子类型信息 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及
boxes	是	Array of boxes objects	参数解释 实体箱子信息 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及
routes	是	Array of routes objects	参数解释 箱子运输路线信息 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及

参数	是否必选	参数类型	描述
platforms	否	Array of platforms objects	参数解释 提/卸货平台信息（与托盘信息关联） 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及
trays	否	Array of trays objects	参数解释 托盘信息 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及
material_types	否	Array of material_types objects	参数解释 箱子材质信息 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及

表 3-556 containers

参数	是否必选	参数类型	描述
container_code	是	String	参数解释 载具名称 约束限制 不涉及 取值范围 字符串长度范围1~128 默认取值 不涉及

参数	是否必选	参数类型	描述
length	是	Integer	参数解释 载具最大装载长度（单位：毫米） 约束限制 不涉及 取值范围 （0, 1e9] 默认取值 不涉及
width	是	Number	参数解释 载具最大装载宽度（单位：毫米） 约束限制 不涉及 取值范围 （0, 1e9] 默认取值 不涉及
height	是	Number	参数解释 载具最大装载高度（单位：毫米） 约束限制 不涉及 取值范围 （0, 1e9] 默认取值 不涉及
max_load_weight	是	Number	参数解释 载具最大装载限重（单位：千克） 约束限制 不涉及 取值范围 (0, 1e20] 默认取值 不涉及

参数	是否必选	参数类型	描述
door_height	否	Integer	参数解释 载具车门高度（单位：毫米） 约束限制 不涉及 取值范围 (0, 1e9] 默认取值 载具最大装载高度
avail_num	否	Integer	参数解释 载具数量 约束限制 不涉及 取值范围 (0, 1e9] 默认取值 不涉及
cost	否	Number	参数解释 载具基础使用费（单位：元） 约束限制 不涉及 取值范围 (0, 1e20] 默认取值 不涉及
tail_length	否	Integer	参数解释 载具尾部标识长度（单位：毫米） 约束限制 不涉及 取值范围 [0, 1e9] 默认取值 不涉及

参数	是否必选	参数类型	描述
adjacent_pickup_length	否	Integer	参数解释 不同提/卸平台货物堆叠时的交叉深度（单位：毫米） 约束限制 不涉及 取值范围 [0, 1e9] 默认取值 不涉及

表 3-557 box_types

参数	是否必选	参数类型	描述
box_type_code	是	String	参数解释 箱子编码 约束限制 不涉及 取值范围 字符串长度1~128 默认取值 不涉及
length	是	Number	参数解释 箱子长度（单位：毫米） 约束限制 不涉及 取值范围 (0, 1e9] 默认取值 不涉及
width	是	Number	参数解释 箱子宽度（单位：毫米） 约束限制 不涉及 取值范围 (0, 1e9] 默认取值 不涉及

参数	是否必选	参数类型	描述
height	是	Number	参数解释 箱子高度（单位：毫米） 约束限制 不涉及 取值范围 (0, 1e9] 默认取值 不涉及
allowed_orientation	否	Array of integers	参数解释 箱子允许的放置方向 约束限制 0表示箱子长边沿X轴，宽边沿Y轴，高边沿Z轴； 1表示箱子宽边沿X轴，长边沿Y轴，高边沿Z轴； 2表示箱子宽边沿X轴，高边沿Y轴，长边沿Z轴； 3表示箱子高边沿X轴，宽边沿Y轴，长边沿Z轴； 4表示箱子长边沿X轴，高边沿Y轴，宽边沿Z轴； 5表示箱子高边沿X轴，长边沿Y轴，宽边沿Z轴 取值范围 枚举值：[0, 1, 2, 3, 4, 5] 默认取值 不涉及
max_layer	否	Number	参数解释 同类箱子最大堆叠层数 约束限制 不涉及 取值范围 (0,1e9] 默认取值 不涉及

参数	是否必选	参数类型	描述
max_load	否	Number	参数解释 非同类箱子最大承重（单位：千克） 约束限制 不涉及 取值范围 [0, 1e20] 默认取值 不涉及
material_code	否	String	参数解释 箱子材质信息 约束限制 不涉及 取值范围 字符串长度为1~128 默认取值 不涉及

表 3-558 boxes

参数	是否必选	参数类型	描述
box_id	是	String	参数解释 实体箱子的唯一识别码 约束限制 不涉及 取值范围 字符串长度为1~128 默认取值 不涉及
box_type_code	是	String	参数解释 实体箱子编码 约束限制 不涉及 取值范围 字符串长度为1~128 默认取值 不涉及

参数	是否必选	参数类型	描述
load_platform	是	String	参数解释 提货平台编码 约束限制 不涉及 取值范围 字符串长度为1~128 默认取值 不涉及
unload_platform	是	String	参数解释 卸货平台编码 约束限制 不涉及 取值范围 字符串长度为1~128 默认取值 不涉及
weight	是	Number	参数解释 实体箱子的重量（单位：千克） 约束限制 不涉及 取值范围 (0, 1e20] 默认取值 不涉及
group	是	String	参数解释 实体箱子分组依据（如订单号） 约束限制 不涉及 取值范围 字符串长度为1~128 默认取值 不涉及

参数	是否必选	参数类型	描述
need_tray	是	Boolean	参数解释 实体箱子是否需要装托 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及

表 3-559 routes

参数	是否必选	参数类型	描述
platform_codes	是	Array of strings	参数解释 装载路线(包含提/卸货点) 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及
platform_types	是	Array of integers	参数解释 提/卸货点标识 约束限制 0标识提货点，1表示卸货点 取值范围 [0, 1] 默认取值 不涉及

表 3-560 platforms

参数	是否必选	参数类型	描述
platform_code	是	String	参数解释 提/卸货点名称 约束限制 不涉及 取值范围 字符串长度1~128 默认取值 不涉及
calcula_vol	是	Number	参数解释 装托箱体积阈值（单位：立方米） 约束限制 若装托箱总体积超出该阈值，则需装托 取值范围 [0, 1e20] 默认取值 不涉及
allowed_tray_codes	是	Array of strings	参数解释 可在该提/卸货点可使用的所有托盘编码列表 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及

表 3-561 trays

参数	是否必选	参数类型	描述
tray_code	是	String	参数解释 托盘编码 约束限制 不涉及 取值范围 字符串长度范围1~128 默认取值 不涉及
length	是	Integer	参数解释 托盘的长度（单位：毫米） 约束限制 不涉及 取值范围 (0, 1e9] 默认取值 不涉及
width	是	Integer	参数解释 托盘的宽度（单位：毫米） 约束限制 不涉及 取值范围 (0, 1e9] 默认取值 不涉及
height	否	Integer	参数解释 托盘的高度（单位：毫米） 约束限制 不涉及 取值范围 (0, 1e9] 默认取值 不涉及

参数	是否必选	参数类型	描述
weight	否	Number	参数解释 托盘的重量（单位：千克） 约束限制 不涉及 取值范围 (0, 1e20] 默认取值 不涉及
max_height	是	Integer	参数解释 托盘最大装载高度（单位：毫米） 约束限制 取值范围 默认取值
max_load_weight	是	Number	参数解释 该托盘最大装载限重（单位：千克） 约束限制 不涉及 取值范围 (0, 1e9] 默认取值 不涉及

表 3-562 material_types

参数	是否必选	参数类型	描述
material_code	是	String	参数解释 箱子的材质名称/编码 约束限制 不涉及 取值范围 字符串长度1~128 默认取值 不涉及

参数	是否必选	参数类型	描述
priority	是	Integer	参数解释 装载优先级 约束限制 此材质箱子的装载优先级 取值范围 (0, 1e9] 默认取值 不涉及

响应参数

状态码：200

表 3-563 <添加求解任务>成功响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据 约束限制： 不涉及 取值范围： 详情参见 表3-564 默认取值： 不涉及

表 3-564 data 返回数据详情

参数	参数类型	描述
create_time	String	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： • created（任务已创建） • pending（任务排队中） • running（任务执行中） • completed（任务求解完成） • failed（任务失败） • deleted（任务已删除） 默认取值： 不涉及
task_id	String	参数解释： 任务ID,用于后续查询任务接口使用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-565 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "time_limit": 120,
  "containers": [
    {
      "container_code": "br_container",
      "length": 587,
      "width": 233,
      "height": 220,
      "max_load_weight": 1e+20,
      "door_height": 220
    }
  ],
  "box_types": [
    {
      "box_type_code": "br1_1",
      "length": 114,
      "width": 77,
      "height": 42,
      "allowed_orient": [
        0,
        1
      ]
    },
    {
      "box_type_code": "br1_2",
      "length": 105,
      "width": 81,
      "height": 74,
      "allowed_orient": [
        0,
        1
      ]
    },
    {
      "box_type_code": "br1_3",
      "length": 76,
      "width": 73,
      "height": 50,
      "allowed_orient": [
        0,
        1
      ]
    }
  ],
  "boxes": [
    {
      "box_id": "0",
      "box_type_code": "br1_1",
```



```
"load_platform": "DefaultLoad",
"unload_platform": "DefaultUnload",
"weight": 3.6867600000000005,
"group": "br1_Order"
},
{
  "box_id": "1",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "2",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "3",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "4",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "5",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "6",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "7",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "8",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
}
```

```
{
  "box_id": "9",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "10",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "11",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "12",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "13",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "14",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "15",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "16",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
},
{
  "box_id": "17",
  "box_type_code": "br1_1",
  "load_platform": "DefaultLoad",
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "group": "br1_Order"
}
```

```
    "weight": 3.6867600000000005,  
    "group": "br1_Order"  
  },  
  {  
    "box_id": "18",  
    "box_type_code": "br1_1",  
    "load_platform": "DefaultLoad",  
    "unload_platform": "DefaultUnload",  
    "weight": 3.6867600000000005,  
    "group": "br1_Order"  
  },  
  {  
    "box_id": "19",  
    "box_type_code": "br1_1",  
    "load_platform": "DefaultLoad",  
    "unload_platform": "DefaultUnload",  
    "weight": 3.6867600000000005,  
    "group": "br1_Order"  
  }  
],  
"routes": {  
  "platform_codes": [  
    "DefaultLoad",  
    "DefaultUnload"  
  ],  
  "platform_types": [  
    0,  
    1  
  ]  
}  
}
```

响应示例

```
{  
  "data": {  
    "create_time": "2025-01-01 10:00:00.000000",  
    "status": "created",  
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"  
  }  
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)

3.7.7.2 查询任务详情

功能介绍

通过“查询任务详情”接口来具体查看当前任务的进度。当任务状态为“completed”时，说明任务执行完成，可从指定的OBS路径中查看完成的求解结果。

URI

GET /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-566 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-567 <查询任务详情>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-568 默认取值： 不涉及

表 3-568 <查询任务详情>"data" 参数说明

参数	参数类型	描述
create_time	string	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
logs	string	参数解释： 当前任务的执行日志详情。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
output	Object	参数解释： 任务处理结果，任务状态为completed时携带。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： • created（任务已创建） • pending（任务排队中） • running（任务执行中） • completed（任务求解完成） • failed（任务失败） • deleted（任务已删除） 默认取值： 不涉及
task_id	String	参数解释： 当前任务ID 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-569 output

参数	参数类型	描述
results	Array of results objects	参数解释 载具装载结果 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及

表 3-570 results

参数	参数类型	描述
container_code	String	参数解释 载具名称 约束限制 不涉及 取值范围 字符串长度1~128 默认取值 不涉及
packing_plan	Array of packing_plan objects	参数解释 载具的装载计划列表 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及
route	Array of strings	参数解释 实际装载路线（提卸货点的名称/编码） 约束限制 不涉及 取值范围 不涉及 默认取值 不涉及
volume_rate	Number	参数解释 体积装载率 约束限制 不涉及 取值范围 [0.0, 1.0] 默认取值 不涉及

参数	参数类型	描述
weight_rate	Number	参数解释 重量装载率 约束限制 不涉及 取值范围 [0.0, 1.0] 默认取值 不涉及

表 3-571 packing_plan

参数	参数类型	描述
box_id	String	参数解释 箱子的唯一识别码 约束限制 不涉及 取值范围 字符串长度1~128 默认取值 不涉及
box_type_code	String	参数解释 箱子编码 约束限制 不涉及 取值范围 字符串长度1~128 默认取值 不涉及
length	Integer	参数解释 箱子长度（单位：毫米） 约束限制 不涉及 取值范围 (0, 1e9] 默认取值 不涉及

参数	参数类型	描述
width	Integer	参数解释 箱子宽度（单位：毫米） 约束限制 不涉及 取值范围 (0, 1e9] 默认取值 不涉及
height	Integer	参数解释 箱子高度（单位：毫米） 约束限制 不涉及 取值范围 (0, 1e9] 默认取值 不涉及
weight	Number	参数解释 箱子重量（单位：千克） 约束限制 不涉及 取值范围 (0.0, 1e20] 默认取值 不涉及

参数	参数类型	描述
orientation	Integer	参数解释 箱子的放置方向 约束限制 0表示箱子长边沿X轴，宽边沿Y轴，高边沿Z轴； 1表示箱子宽边沿X轴，长边沿Y轴，高边沿Z轴； 2表示箱子宽边沿X轴，高边沿Y轴，长边沿Z轴； 3表示箱子高边沿X轴，宽边沿Y轴，长边沿Z轴； 4表示箱子长边沿X轴，高边沿Y轴，宽边沿Z轴； 5表示箱子高边沿X轴，长边沿Y轴，宽边沿Z轴 取值范围 枚举值：[0, 1, 2, 3, 4, 5] 默认取值 不涉及
load_platform	String	参数解释 提货平台编码 约束限制 不涉及 取值范围 字符串长度1~128 默认取值 不涉及
unload_platform	String	参数解释 卸货平台编码 约束限制 不涉及 取值范围 字符串长度1~128 默认取值 不涉及

参数	参数类型	描述
group	String	参数解释 箱子分组依据（如订单号） 约束限制 不涉及 取值范围 字符串长度1~128 默认取值 不涉及
x	Integer	参数解释 箱子左底点X方向坐标（单位：毫米） 约束限制 不涉及 取值范围 [0, 1e9] 默认取值 不涉及
y	Integer	参数解释 箱子左底点Y方向坐标（单位：毫米） 约束限制 不涉及 取值范围 [0, 1e9] 默认取值 不涉及
z	Number	参数解释 箱子左底点Z方向坐标（单位：毫米） 约束限制 不涉及 取值范围 [0, 1e9] 默认取值 不涉及

状态码：400

表 3-572 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "create_time": "2025-01-01 10:00:00.000000",
    "logs": "xxx",
    "output": {
      "results": [
        {
          "container_code": "br_container",
          "packing_plan": [
            {
              "box_id": "10",
              "box_type_code": "br1_1",
              "group": "br1_Order",
              "height": 42,
              "length": 114,
              "load_platform": "DefaultLoad",
              "orientation": 1,
              "unload_platform": "DefaultUnload",
              "weight": 3.6867600000000005,
              "width": 77,
              "x": 0,
              "y": 0,
              "z": 0
            },
            {
              "box_id": "19",
```

```
"box_type_code": "br1_1",
"group": "br1_Order",
"height": 42,
"length": 114,
"load_platform": "DefaultLoad",
"orientation": 1,
"unload_platform": "DefaultUnload",
"weight": 3.6867600000000005,
"width": 77,
"x": 0,
"y": 0,
"z": 42
},
{
  "box_id": "18",
  "box_type_code": "br1_1",
  "group": "br1_Order",
  "height": 42,
  "length": 114,
  "load_platform": "DefaultLoad",
  "orientation": 1,
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "width": 77,
  "x": 0,
  "y": 0,
  "z": 84
},
{
  "box_id": "17",
  "box_type_code": "br1_1",
  "group": "br1_Order",
  "height": 42,
  "length": 114,
  "load_platform": "DefaultLoad",
  "orientation": 1,
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "width": 77,
  "x": 0,
  "y": 0,
  "z": 126
},
{
  "box_id": "16",
  "box_type_code": "br1_1",
  "group": "br1_Order",
  "height": 42,
  "length": 114,
  "load_platform": "DefaultLoad",
  "orientation": 1,
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "width": 77,
  "x": 0,
  "y": 0,
  "z": 168
},
{
  "box_id": "15",
  "box_type_code": "br1_1",
  "group": "br1_Order",
  "height": 42,
  "length": 114,
  "load_platform": "DefaultLoad",
  "orientation": 1,
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "width": 77,
```

```
"x": 0,  
"y": 114,  
"z": 0  
},  
{  
  "box_id": "14",  
  "box_type_code": "br1_1",  
  "group": "br1_Order",  
  "height": 42,  
  "length": 114,  
  "load_platform": "DefaultLoad",  
  "orientation": 1,  
  "unload_platform": "DefaultUnload",  
  "weight": 3.6867600000000005,  
  "width": 77,  
  "x": 0,  
  "y": 114,  
  "z": 42  
},  
{  
  "box_id": "13",  
  "box_type_code": "br1_1",  
  "group": "br1_Order",  
  "height": 42,  
  "length": 114,  
  "load_platform": "DefaultLoad",  
  "orientation": 1,  
  "unload_platform": "DefaultUnload",  
  "weight": 3.6867600000000005,  
  "width": 77,  
  "x": 0,  
  "y": 114,  
  "z": 84  
},  
{  
  "box_id": "12",  
  "box_type_code": "br1_1",  
  "group": "br1_Order",  
  "height": 42,  
  "length": 114,  
  "load_platform": "DefaultLoad",  
  "orientation": 1,  
  "unload_platform": "DefaultUnload",  
  "weight": 3.6867600000000005,  
  "width": 77,  
  "x": 0,  
  "y": 114,  
  "z": 126  
},  
{  
  "box_id": "11",  
  "box_type_code": "br1_1",  
  "group": "br1_Order",  
  "height": 42,  
  "length": 114,  
  "load_platform": "DefaultLoad",  
  "orientation": 1,  
  "unload_platform": "DefaultUnload",  
  "weight": 3.6867600000000005,  
  "width": 77,  
  "x": 0,  
  "y": 114,  
  "z": 168  
},  
{  
  "box_id": "0",  
  "box_type_code": "br1_1",  
  "group": "br1_Order",  
  "height": 42,
```

```
"length": 114,
"load_platform": "DefaultLoad",
"orientation": 1,
"unload_platform": "DefaultUnload",
"weight": 3.6867600000000005,
"width": 77,
"x": 77,
"y": 0,
"z": 0
},
{
  "box_id": "1",
  "box_type_code": "br1_1",
  "group": "br1_Order",
  "height": 42,
  "length": 114,
  "load_platform": "DefaultLoad",
  "orientation": 1,
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "width": 77,
  "x": 77,
  "y": 0,
  "z": 42
},
{
  "box_id": "2",
  "box_type_code": "br1_1",
  "group": "br1_Order",
  "height": 42,
  "length": 114,
  "load_platform": "DefaultLoad",
  "orientation": 1,
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "width": 77,
  "x": 77,
  "y": 0,
  "z": 84
},
{
  "box_id": "3",
  "box_type_code": "br1_1",
  "group": "br1_Order",
  "height": 42,
  "length": 114,
  "load_platform": "DefaultLoad",
  "orientation": 1,
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "width": 77,
  "x": 77,
  "y": 0,
  "z": 126
},
{
  "box_id": "8",
  "box_type_code": "br1_1",
  "group": "br1_Order",
  "height": 42,
  "length": 114,
  "load_platform": "DefaultLoad",
  "orientation": 1,
  "unload_platform": "DefaultUnload",
  "weight": 3.6867600000000005,
  "width": 77,
  "x": 77,
  "y": 0,
  "z": 168
}
```

```
    },
    {
      "box_id": "4",
      "box_type_code": "br1_1",
      "group": "br1_Order",
      "height": 42,
      "length": 114,
      "load_platform": "DefaultLoad",
      "orientation": 1,
      "unload_platform": "DefaultUnload",
      "weight": 3.6867600000000005,
      "width": 77,
      "x": 77,
      "y": 114,
      "z": 0
    },
    {
      "box_id": "5",
      "box_type_code": "br1_1",
      "group": "br1_Order",
      "height": 42,
      "length": 114,
      "load_platform": "DefaultLoad",
      "orientation": 1,
      "unload_platform": "DefaultUnload",
      "weight": 3.6867600000000005,
      "width": 77,
      "x": 77,
      "y": 114,
      "z": 42
    },
    {
      "box_id": "6",
      "box_type_code": "br1_1",
      "group": "br1_Order",
      "height": 42,
      "length": 114,
      "load_platform": "DefaultLoad",
      "orientation": 1,
      "unload_platform": "DefaultUnload",
      "weight": 3.6867600000000005,
      "width": 77,
      "x": 77,
      "y": 114,
      "z": 84
    },
    {
      "box_id": "7",
      "box_type_code": "br1_1",
      "group": "br1_Order",
      "height": 42,
      "length": 114,
      "load_platform": "DefaultLoad",
      "orientation": 1,
      "unload_platform": "DefaultUnload",
      "weight": 3.6867600000000005,
      "width": 77,
      "x": 77,
      "y": 114,
      "z": 126
    },
    {
      "box_id": "9",
      "box_type_code": "br1_1",
      "group": "br1_Order",
      "height": 42,
      "length": 114,
      "load_platform": "DefaultLoad",
      "orientation": 1,
```



```
        "unload_platform": "DefaultUnload",
        "weight": 3.6867600000000005,
        "width": 77,
        "x": 77,
        "y": 114,
        "z": 168
      }
    ],
    "route": [
      "DefaultLoad"
    ],
    "volume_rate": 0.2451,
    "weight_rate": 0.0
  }
},
"status": "completed",
"task_id": "c5edc94b-xxxx-xxxx-xxx-754e481bafa5"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)

3.7.7.3 查询任务列表

功能介绍

通过“查询任务列表”来查询所有求解任务的状态及task_id。

URI

GET /task-list

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-573 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-574 <查询任务列表>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-575 。 默认取值： 不涉及

表 3-575 <查询任务列表>"data" 参数说明

参数	参数类型	描述
count	int	参数解释： 任务数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
tasks	Array(Object)	参数解释： 任务列表详情，其中Object的请求格式参见（ data返回数据详情 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-576 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "count": 2,
    "tasks": [
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "cf2a475e-xxxx-xxxx-xxxx-9f342b1b032e"
      },
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
      }
    ]
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.7.4 删除任务

功能介绍

通过“删除任务”来删除已添加的求解任务。

URI

DELETE /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-577 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-578 <删除任务>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见表3-579。 默认取值： 不涉及

表 3-579 <删除任务>"data" 参数说明

参数	参数类型	描述
status	string	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： 不涉及 默认取值： deleted
task_id	string	参数解释： 当前任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-580 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "status": "deleted",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.8 Pangu-OPT-钣金切割引擎

3.7.8.1 创建求解任务

功能介绍

创建“钣金切割引擎”求解任务同步响应返回“task_id”，服务会将请求任务添加到待处理队列中进行排队（pending）、任务执行中（running）、求解完成（completed）等三个阶段。

URI

POST /task/solve

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-581 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-582 请求参数

参数	是否必选	参数类型	说明
task_name	是	String	参数解释： 任务名，由用户输入，用于标识任务。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_name	是	String	参数解释： 项目名，由用户输入。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_id	否	String	参数解释： 用户名，由用户输入。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
time	是	Integer	参数解释： 用户指定算法运行时间，单位分钟。 约束限制： 不涉及 取值范围： [1,120] 默认取值： 不涉及

参数	是否必选	参数类型	说明
item_spacing	是	Double	参数解释： 零件之间的间距。 约束限制： 不涉及 取值范围： [0,1000] 默认取值： 不涉及
plate_spacing	是	Double	参数解释： 零件距板材的间距。 约束限制： 不涉及 取值范围： [0,1000] 默认取值： 不涉及
forbid_internal_nesting	是	Integer	参数解释： 是否禁止内部套料。 约束限制： 不涉及 取值范围： 0：不禁止 1：禁止内部套料 默认取值： 不涉及
common_cut_nest	是	Integer	参数解释： 是否是共边套料。 约束限制： 不涉及 取值范围： 0：标准套料模式 1：共边套料模式 默认取值： 不涉及

参数	是否必选	参数类型	说明
leadin_before_nesting	是	Integer	参数解释： 是否在套料前加入引入线。 约束限制： 不涉及 取值范围： 1：在套料前加入引线 2：套料前不加入引线 默认取值： 不涉及
internal_entry_in	是	Integer	参数解释： 套料模式是否有内轮廓引入线。 约束限制： 只在leadin_before_nesting = 1时生效。 取值范围： 0：不添加 1：添加 默认取值： 不涉及
internal_entry_out	是	Integer	参数解释： 套料模式是否有内轮廓引出线。 约束限制： 只在leadin_before_nesting = 1时生效。 取值范围： 0：不添加 1：添加 默认取值： 不涉及

参数	是否必选	参数类型	说明
outside_entry_in	是	Integer	参数解释： 套料模式是否有外轮廓引入线。 约束限制： 只在leadin_before_nesting = 1时生效。 取值范围： • 0：不添加 • 1：添加 默认取值： 不涉及
outside_entry_out	是	Integer	参数解释： 套料模式是否有外轮廓引出线。 约束限制： 只在leadin_before_nesting = 1时生效。 取值范围： • 0：不添加 • 1：添加 默认取值： 不涉及
plates	是	Array	参数解释： 钢板数据接口，由多个plate结构体组成，当前仅支持同尺寸整版，余料版暂不考虑。详见 下表 定义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cams	是	Array	参数解释： 零件形状及排版任务列表，由多个cam结构体组成，详见 下表 定义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
total_cams	否	Integer	参数解释： 零件类型数量。非必须属性，由FastCAM用于解析手动调整引入引出线位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
FastPATH	否	Object	参数解释： FastPATH配置代码对象。非必须属性，由FastCAM用于解析手动调整引入引出线位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
entries	否	Array	参数解释： 引线实体位置信息。非必须属性，由FastCAM用于解析手动调整引入引出线位置。详情 下表 定义 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	说明
total_entries	否	Integer	参数解释： 引线实体数量信息。非必须属性，由FastCAM用于解析手动调整引入引出线位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-583 plate 结构体属性列表

参数	是否必选	类型	说明
plate_id	是	Integer	参数解释： 钢板id，从0开始，依序递增。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
plate_name	否	String	参数解释： 钢板名，留作以后余料板图形文件名。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
plate_length	是	Double	参数解释： 钢板长度。 约束限制： 不涉及 取值范围： (0,1000000] 默认取值： 不涉及

参数	是否必选	类型	说明
plate_width	是	Double	参数解释： 钢板宽度。 约束限制： 不涉及 取值范围： (0,1000000] 默认取值： 不涉及
plate_count	是	Integer	参数解释： 钢板可用数量。 约束限制： 不涉及 取值范围： >0 默认取值： 不涉及

表 3-584 cam 结构体属性列表

参数	是否必选	类型	说明
item_id	是	Integer	参数解释： 零件id，从0开始，依序递增。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
item_name	是	String	参数解释： 零件全名称，包括文件保存绝对路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	类型	说明
count	是	Integer	参数解释： 排版零件个数。 约束限制： 不涉及 取值范围： [0,1000] 默认取值： 不涉及
priority	否	Integer	参数解释： 零件排版优先级,0表示不套料，优先级高则优先套料。 约束限制： 不涉及 取值范围： [0,9] 默认取值： 5
rotation_type	是	Integer	参数解释： 零件旋转类型，0表示不旋转，1表示0,180度旋转，2表示0,90度旋转，3表示0,90,180,270度旋转，4表示可任意旋转，5表示优先0,180度旋转，如果效果不明显再任意旋转。 约束限制： 不涉及 取值范围： [0,5] 默认取值： 不涉及
flip	是	Integer	参数解释： 零件是否可以翻转。 约束限制： 不涉及 取值范围： 0：不允许翻转 1：允许翻转 默认取值： 不涉及

参数	是否必选	类型	说明
pair_collinear	是	Integer	参数解释： 是否配对共边。 约束限制： 不涉及 取值范围： 0：不是配对共边零件 1：配对共边 默认取值： 不涉及
collinear_entity_id	是	Integer	参数解释： 共边实体号，如果不是配对共边图形，则此属性无意义，否则表示零件共边实体号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
entities	是	Array	参数解释： 零件实体序列，由多个entity结构体构成，详见下表定义。先表示外轮廓，若有内轮廓，依次表示。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-585 entity 结构体属性列表

参数	是否必选	类型	说明
entity_id	是	Integer	参数解释： 零件实体号，从1开始，依序递增。注意：实体轮廓线顺序由属性last_entity和next_entity决定，该entity_id并不表示轮廓线顺序。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
entity_type	是	Integer	参数解释： 实体类型 约束限制： 不涉及 取值范围： 1：线段 -2：顺时针圆弧 2：逆时针圆弧 0：点 3：文字 默认取值： 不涉及
start_x	是	Double	参数解释： 实体起点x坐标。 约束限制： 不涉及 取值范围： [-1000000,1000000] 默认取值： 不涉及

参数	是否必选	类型	说明
start_y	是	Double	参数解释： 实体起点y坐标。 约束限制： 不涉及 取值范围： [-1000000,1000000] 默认取值： 不涉及
end_x	是	Double	参数解释： 实体终点x坐标。 约束限制： 不涉及 取值范围： [-1000000,1000000] 默认取值： 不涉及
end_y	是	Double	参数解释： 实体终点y坐标。 约束限制： 不涉及 取值范围： [-1000000,1000000] 默认取值： 不涉及
circle_center_x	是	Double	参数解释： 实体圆弧所在圆心x坐标，若实体类型不是圆弧，则其无意义。 约束限制： 不涉及 取值范围： [-1000000,1000000] 默认取值： 不涉及

参数	是否必选	类型	说明
circle_center_y	是	Double	参数解释： 实体圆弧所在圆心y坐标，若实体类型不是圆弧，则其无意义。 约束限制： 不涉及 取值范围： [-1000000,1000000] 默认取值： 不涉及
dxf_name	否	String	参数解释： dxf名，备用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
entry_type	是	Integer	参数解释： entity类别。 约束限制： 不涉及 取值范围： 0：零件entity 1：引入线 2：引出线 默认取值： 不涉及
ifoutside	是	Integer	参数解释： 零件轮廓类别。 约束限制： 当实体类型为点或者文字(entity_type为0或3)时，该属性值为-1。 取值范围： 0：内轮廓 1：外轮廓 -1 默认取值： 不涉及

参数	是否必选	类型	说明
next_entity	是	Integer	参数解释： 与当前实体连接的下一个实体编号（entity_id）。0表示没有下一个实体。next_entity为0的一般情形包括如下： 1）实体类型是点或者文字；2）实体类型为引出线；特殊情形如下：1）非共边零件轮廓线的尾部实体。 约束限制： 所有实体的该属性不能为点或文字。 取值范围： 不涉及 默认取值： 不涉及
last_entity	是	Integer	参数解释： 与当前实体连接的上一个实体编号（entity_id）。0表示没有上一个实体。last_entity为0的一般情形包括如下： 1）实体类型是点或者文字；2）实体类型为引入线；特殊情形如下：1）非共边零件轮廓线的首个实体。 约束限制： 所有实体的该属性不能为点或文字。 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-586 <添加求解任务>成功响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据 约束限制： 不涉及 取值范围： 详情参见 表3-587 默认取值： 不涉及

表 3-587 data 返回数据详情

参数	参数类型	描述
create_time	String	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： • created（任务已创建） • pending（任务排队中） • running（任务执行中） • completed（任务求解完成） • failed（任务失败） • deleted（任务已删除） 默认取值： 不涉及

参数	参数类型	描述
task_id	String	参数解释： 任务ID，用于后续查询任务接口使用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-588 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "task_name": "TESTTASK",
  "project_name": "TESTPRO",
  "time": 1,
  "item_spacing": 10,
  "plate_spacing": 20,
  "forbid_internal_nesting": 0,
  "common_cut_nest": 0,
  "leadin_before_nesting": 1,
```

```
"internal_entry_in": 0,
"internal_entry_out": 0,
"outside_entry_in": 1,
"outside_entry_out": 1,
"plates": [
  {
    "plate_id": 0,
    "plate_name": "",
    "plate_length": 4000,
    "plate_width": 2000,
    "plate_count": 200
  }
],
"cams": [
  {
    "item_id": 0,
    "item_name": "d:\\rectangle2.cam",
    "count": 2,
    "priority": 5,
    "rotation_type": 2,
    "flip": 0,
    "pair_collinear": 0,
    "collinear_entity_id": 0,
    "entities": [
      {
        "entity_id": 1,
        "entity_type": 1,
        "start_x": 0,
        "start_y": 0,
        "end_x": 500,
        "end_y": 0,
        "circle_center_x": 0,
        "circle_center_y": 0,
        "dxf_name": "",
        "entry_type": 0,
        "ifoutside": 1,
        "next_entity": 2,
        "last_entity": 0
      },
      {
        "entity_id": 2,
        "entity_type": 1,
        "start_x": 500,
        "start_y": 0,
        "end_x": 500,
        "end_y": 500,
        "circle_center_x": 0,
        "circle_center_y": 0,
        "dxf_name": "",
        "entry_type": 0,
        "ifoutside": 1,
        "next_entity": 3,
        "last_entity": 1
      },
      {
        "entity_id": 3,
        "entity_type": 1,
        "start_x": 500,
        "start_y": 500,
        "end_x": 0,
        "end_y": 500,
        "circle_center_x": 0,
        "circle_center_y": 0,
        "dxf_name": "",
        "entry_type": 0,
        "ifoutside": 1,
        "next_entity": 4,
        "last_entity": 2
      },
    ]
  }
]
```



```
{
  {
    "entity_id": 4,
    "entity_type": 1,
    "start_x": 0,
    "start_y": 500,
    "end_x": 0,
    "end_y": 0,
    "circle_center_x": 0,
    "circle_center_y": 0,
    "dxf_name": "",
    "entry_type": 0,
    "ifoutside": 1,
    "next_entity": 0,
    "last_entity": 3
  },
  {
    "entity_id": 5,
    "entity_type": 1,
    "start_x": -6,
    "start_y": 0,
    "end_x": 0,
    "end_y": 0,
    "circle_center_x": 0,
    "circle_center_y": 0,
    "dxf_name": "",
    "entry_type": 1,
    "ifoutside": 1,
    "next_entity": 1,
    "last_entity": 0
  },
  {
    "entity_id": 6,
    "entity_type": 1,
    "start_x": 0,
    "start_y": 0,
    "end_x": 0,
    "end_y": -5,
    "circle_center_x": 0,
    "circle_center_y": 0,
    "dxf_name": "",
    "entry_type": 2,
    "ifoutside": 1,
    "next_entity": 0,
    "last_entity": 4
  }
}
]
```

响应示例

```
{
  "data": {
    "create_time": "2025-01-01 10:00:00.000000",
    "status": "created",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)

3.7.8.2 查询任务详情

功能介绍

通过“查询任务详情”来具体查看当前任务的进度。当任务状态为“completed”时，说明任务执行完成，可从指定的OBS路径中查看完成的求解结果。

URI

GET /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-589 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-590 <查询任务详情>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-591 。 默认取值： 不涉及

表 3-591 <查询任务详情>"data" 参数说明

参数	参数类型	描述
create_time	string	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
logs	string	参数解释： 当前任务的执行日志详情。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
output	Object	参数解释: 任务处理结果，任务状态为completed时携带。详见表4 "output" 参数说明。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
status	String	参数解释: 任务当前状态。 约束限制: 不涉及 取值范围: • created（任务已创建） • pending（任务排队中） • running（任务执行中） • completed（任务求解完成） • failed（任务失败） • deleted（任务已删除） 默认取值: 不涉及
task_id	String	参数解释: 当前任务ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-592 output 结构体

参数	类型	说明
task_name	String	参数解释 任务名。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
project_name	String	参数解释 项目名。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
time	Integer	参数解释 用户指定算法运行时间，单位min。 约束限制: 不涉及 取值范围: [1,120] 默认取值: 不涉及
item_spacing	Double	参数解释 零件间距。 约束限制: 不涉及 取值范围: [0,1000] 默认取值: 不涉及

参数	类型	说明
plate_spacing	Double	参数解释 零件距板材间距。 约束限制: 不涉及 取值范围: [0,1000] 默认取值: 不涉及
common_cut_nest	Integer	参数解释 是否是共边套料。 约束限制: 不涉及 取值范围: 0: 标准套料模式 1: 共边套料模式 默认取值: 不涉及
leadin_before_nesting	Integer	参数解释 是否在套料前加入引入线。 约束限制: 不涉及 取值范围: 1: 在套料前加入引线 2: 套料前不加入引线 默认取值: 不涉及
internal_entry_in	Integer	参数解释 套料模式是否有内轮廓引入线。 约束限制: 只在leadin_before_nesting = 1时生效。 取值范围: 0: 不添加 1: 添加 默认取值: 不涉及

参数	类型	说明
internal_entry_out	Integer	参数解释 套料模式是否有内轮廓引出线。 约束限制: 只在leadin_before_nesting = 1时生效。 取值范围: • 0: 不添加 • 1: 添加 默认取值: 不涉及
outside_entry_in	Integer	参数解释 套料模式是否有外轮廓引入线。 约束限制: 只在leadin_before_nesting = 1时生效。 取值范围: • 0: 不添加 • 1: 添加 默认取值: 不涉及
outside_entry_out	Integer	参数解释 套料模式是否有外轮廓引出线。 约束限制: 只在leadin_before_nesting = 1时生效。 取值范围: • 0: 不添加 • 1: 添加 默认取值: 不涉及
plate_count	Integer	参数解释 使用钢板数量。 约束限制: 不涉及 取值范围: >0 默认取值: 不涉及

参数	类型	说明
total_item_count	Integer	参数解释 排版零件数量。 约束限制: 不涉及 取值范围: >0 默认取值: 不涉及
average_ratio	Double	参数解释 所有钢板的平均板材利用率。 约束限制: 不涉及 取值范围: [0,1] 默认取值: 不涉及
nesting	Array	参数解释 排版结果，每个元素表示一个钢板的排版结果，参见 表3-593 详情。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-593 nesting 属性列表

参数	类型	说明
plate_id	Integer	参数解释 钢板id，从0开始，依序递增。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	类型	说明
plate_name	String	参数解释 钢板名，留作以后余料板图形文件名。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
plate_length	Double	参数解释 钢板长度。 约束限制： 不涉及 取值范围： (0,1000000] 默认取值： 不涉及
plate_width	Double	参数解释 钢板宽度。 约束限制： 不涉及 取值范围： (0,1000000] 默认取值： 不涉及
plate_ratio	Double	参数解释 钢板利用率。 约束限制： 不涉及 取值范围： [0,1] 默认取值： 不涉及

参数	类型	说明
item_count	Integer	参数解释 此钢板排版零件数量。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
items	Array	参数解释 钢板中零件排版结果，详细参见 表3-594 。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-594 items 单个零件的排版结果

参数	类型	说明
item_name	String	参数解释 零件名全称，包含绝对地址。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
item_angle	Double	参数解释 零件旋转角度。 约束限制: 不涉及 取值范围: [0,360] 默认取值: 不涉及

参数	类型	说明
flip_x	Integer	参数解释 零件是否沿x轴翻转。 约束限制: 不涉及 取值范围: 0: 不翻转 1: 翻转 默认取值: 不涉及
flip_y	Integer	参数解释 零件是否沿y轴翻转。 约束限制: 不涉及 取值范围: 0: 不翻转 1: 翻转 默认取值: 不涉及
envelope_rect_center_x	Double	参数解释 零件按照先旋转再翻转的顺序进行变换，放置在钢板中。未作变换时零件的水平包络矩形按照相同方式进行变换。该属性值表示该变换包络矩形对角线中心x坐标。 约束限制: 不涉及 取值范围: [0,1000000] 默认取值: 不涉及

参数	类型	说明
envelope_rect_center_y	Double	参数解释 零件按照先旋转再翻转的顺序进行变换，放置在钢板中。未作变换时零件的水平包络矩形按照相同方式进行变换。该属性值表示该变换包络矩形对角线中心y坐标。 约束限制： 不涉及 取值范围： [0,1000000] 默认取值： 不涉及

状态码：400

表 3-595 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
"data": {
  "create_time": "2025-01-01 10:00:00.000000",
  "logs": "xxx",
  "output": {
    "average_ratio": 0.43922290579330253,
    "common_cut_nest": 0,
    "item_spacing": 10.0,
    "nesting": [
      {
        "item_count": 7,
        "items": [
          {
            "envelope_rect_center_x": 1605.0000000000018,
            "envelope_rect_center_y": 1959.4003744920346,
            "flip_x": 0,
            "flip_y": 0,
            "item_angle": 0.0,
            "item_name": "d:\\rectangle.cam"
          },
          {
            "envelope_rect_center_x": 1605.0000000000018,
            "envelope_rect_center_y": 3570.133437492032,
            "flip_x": 0,
            "flip_y": 0,
            "item_angle": 0.0,
            "item_name": "d:\\rectangle.cam"
          },
          {
            "envelope_rect_center_x": 505.0,
            "envelope_rect_center_y": 3348.425682497144,
            "flip_x": 0,
            "flip_y": 0,
            "item_angle": 0.0,
            "item_name": "d:\\xxx.cam"
          },
          {
            "envelope_rect_center_x": 1136.003821693054,
            "envelope_rect_center_y": 1105.7330629999974,
            "flip_x": 0,
            "flip_y": 0,
            "item_angle": 0.0,
            "item_name": "d:\\xxx.cam"
          },
          {
            "envelope_rect_center_x": 705.1606452469719,
            "envelope_rect_center_y": 2827.3374108695393,
            "flip_x": 0,
            "flip_y": 0,
            "item_angle": 0.0,
            "item_name": "d:\\xxx.cam"
          },
          {
            "envelope_rect_center_x": 1001.5517970744211,
            "envelope_rect_center_y": 2606.6574946969886,
            "flip_x": 0,
            "flip_y": 0,
            "item_angle": 0.0,
            "item_name": "d:\\xxx.cam"
          },
          {
            "envelope_rect_center_x": 269.9895399372879,
            "envelope_rect_center_y": 1355.7330629372852,
            "flip_x": 0,
            "flip_y": 0,
            "item_angle": 90.0,
            "item_name": "d:\\xxx.cam"
          }
        ]
      }
    ]
  }
},
```

```
        "plate_id": 0,  
        "plate_length": 3980.0,  
        "plate_name": "",  
        "plate_ratio": 0.43922290579330253,  
        "plate_width": 3980.0  
    },  
    ],  
    "plate_count": 1,  
    "plate_spacing": 20.0,  
    "project_id": "TESTPRO",  
    "task_id": "TESTTASK",  
    "time": 20,  
    "total_item_count": 7  
},  
"status": "completed",  
"task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"  
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)

3.7.8.3 查询任务列表

功能介绍

通过“查询任务列表”来查询所有求解任务的状态及task_id。

URI

GET /task-list

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-596 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-597 <查询任务列表>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-598 。 默认取值： 不涉及

表 3-598 <查询任务列表>"data" 参数说明

参数	参数类型	描述
count	int	参数解释： 任务数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
tasks	Array(Object)	参数解释： 任务列表详情，其中Object的请求格式参见（ data返回数据详情 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-599 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "count": 2,
    "tasks": [
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "cf2a475e-xxxx-xxxx-xxxx-9f342b1b032e"
      },
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
      }
    ]
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.8.4 删除任务

功能介绍

通过“删除任务”来删除已添加的求解任务。

URI

DELETE /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-600 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-601 <删除任务>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-602 默认取值： 不涉及

表 3-602 <删除任务>"data" 参数说明

参数	参数类型	描述
status	string	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： 不涉及 默认取值： deleted
task_id	string	参数解释： 当前任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-603 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释: 错误码 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
error_msg	String	参数解释: 错误信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "status": "deleted",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.9 Pangu-OPT-生产排程引擎

3.7.9.1 创建求解任务

功能介绍

生产排程引擎，根据已有的生产条件，给出在某项或某几项性能指标最优情况下的任务生产加工计划。

URI

POST /task/solve

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-604 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-605 请求 Body 参数

参数	是否必选	参数类型	描述
type	是	String	参数解释： 问题类型，仅支持当前给出的枚举值类型 约束限制： • jsp: 作业调度 • fjsp: 柔性作业调度 • pfsp: 置换流水车间 • hfsp: 混合流水车间 取值范围： 不涉及 默认取值： 不涉及
data	是	data object	参数解释： 问题描述数据 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
time_matrix	否	time_mat rix object	参数解释： 工序间时间间隔矩阵 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-606 data

参数	是否必选	参数类型	描述
jobs	是	Array of jobs objects	参数解释： 作业信息列表 约束限制： 非空 取值范围： 不涉及 默认取值： 不涉及
machines	是	Array of machines objects	参数解释： 机器信息列表 约束限制： 非空 取值范围： 不涉及 默认取值： 不涉及
operations	是	Array of operations objects	参数解释： 工序信息列表 约束限制： 非空 取值范围： 不涉及 默认取值： 不涉及
objective	是	objective object	参数解释： 求解目标信息 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-607 jobs

参数	是否必选	参数类型	描述
job_id	是	Integer	参数解释： 作业索引编号，从 0 开始 约束限制： 作业索引不重复 取值范围： 非负整数 默认取值： 不涉及
operation_list	是	Array<Array<Integer>>	参数解释： 作业工艺路径列表，每个子列表表示一条工艺路径，每个路径包含工序索引，按生产顺序排列 约束限制： 每个子列表包含的工序索引不重复，且每个子列表的元素顺序按工序生产顺序排列 取值范围： 子列表中整数元素为非负值 默认取值： 不涉及

表 3-608 machines

参数	是否必选	类型	说明
machine_id	是	Integer	参数解释： 机器索引编号，从 0 开始 约束限制： 机器索引不重复 取值范围： 非负整数 默认取值： 不涉及

表 3-609 operations

参数	是否必选	参数类型	描述
operation_id	是	Integer	参数解释： 工序索引编号，从 0 开始，与 jobs 中 operation_list 出现的工序索引一一对应 约束限制： 工序索引不重复 取值范围： 非负整数 默认取值： 不涉及
job_id	是	Integer	参数解释： 工序所属作业索引 约束限制： 对应 jobs 中存在的 job_id，且其 operation_list 中应包含该 operation_id 取值范围： 非负整数 默认取值： 不涉及
machine_list	是	Array of integers	参数解释： 可使用机器索引列表 约束限制： 非空，且其中元素对应 machines 中存在的 machine_id 取值范围： 列表中元素为非负整数 默认取值： 不涉及
pre_operation	是	Array of integers	参数解释： 工序的作业前序工序索引，若无则输入 [-1] 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
next_operation	是	Array of integers	参数解释： 工序的作业后继工序索引，若无则输入 [-1] 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
times	是	Object	参数解释： 工序在每个机器上处理时间键值对，每个键表示机器索引，每个值表示在该机器上的加工时间 约束限制： 其键与可用机器列表 machine_list 中元素一一对应 取值范围： 加工时间为正整数 默认取值： 不涉及

表 3-610 objective

参数	是否必选	参数类型	描述
makespan	否	Number	参数解释： makespan 目标权重值 约束限制： 不涉及 取值范围： 非负值 默认取值： 不涉及

表 3-611 time_matrix

参数	是否必选	参数类型	描述
operation_operation	否	Array of operation_operation objects	参数解释： 工序间的切换时间列表 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
machine_machine	否	Array of machine_machine objects	参数解释： 机器间的切换时间列表 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-612 operation_operation

参数	是否必选	参数类型	描述
setup_time	是	setup_time object	参数解释： 切换时间数据，包含切换前工序，切换后工序及两者之间的切换时间 约束限制： 切换前工序和切换后工序为同机器上可能的两个连续工序 取值范围： 不涉及 默认取值： 不涉及

表 3-613 setup_time

参数	是否必选	参数类型	描述
src	是	Integer	参数解释： 切换前工序索引 约束限制： 对应operations中已存在的operation_id 取值范围： 非负整数 默认取值： 不涉及
dst	是	Integer	参数解释： 切换后工序索引 约束限制： 对应operations中已存在的operation_id 取值范围： 非负整数 默认取值： 不涉及
cost	是	Integer	参数解释： 切换时间花费 约束限制： 不涉及 取值范围： 非负整数 默认取值： 不涉及

表 3-614 machine_machine

参数	是否必选	参数类型	描述
transfer_time	是	transfer_time object	参数解释： 转运时间数据，包含转运前机器，转运后机器及两者间转运时间 约束限制： 转运前机器和转运后机器为可能存在转运（运输时间）的两个机器 取值范围： 不涉及 默认取值： 不涉及

表 3-615 transfer_time

参数	是否必选	参数类型	描述
src	是	Integer	参数解释： 转运前机器索引 约束限制： 对应machines中已存在的machine_id 取值范围： 非负整数 默认取值： 不涉及
dst	是	Integer	参数解释： 转运后机器索引 约束限制： 对应machines中已存在的machine_id 取值范围： 非负整数 默认取值： 不涉及

参数	是否必选	参数类型	描述
cost	是	Integer	参数解释： 运输时间花费 约束限制： 不涉及 取值范围： 非负整数 默认取值： 不涉及

响应参数

状态码：200

表 3-616 <添加求解任务>成功响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据 约束限制： 不涉及 取值范围： 详情参见 表3-617 默认取值： 不涉及

表 3-617 data 返回数据详情

参数	参数类型	描述
create_time	String	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： - created（任务已创建） - pending（任务排队中） - running（任务执行中） - completed（任务求解完成） - failed（任务失败） - deleted（任务已删除） 默认取值： 不涉及
task_id	String	参数解释： 任务ID，用于后续查询任务接口使用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-618 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "type": "fjsp",
  "data": {
    "jobs": [ {
      "job_id": 0,
      "operation_list": [ [ 0, 1, 2 ] ]
    }, {
      "job_id": 1,
      "operation_list": [ [ 3, 4, 5 ] ]
    } ],
    "machines": [ {
      "machine_id": 0
    }, {
      "machine_id": 1
    } ],
    "operations": [ {
      "operation_id": 0,
      "job_id": 0,
      "machine_list": [ 0, 1 ],
      "pre_operation": [ -1 ],
      "next_operation": [ 1 ],
      "times": {
        "0": 3,
        "1": 1
      }
    }, {
      "operation_id": 1,
      "job_id": 0,
      "machine_list": [ 0 ],
      "pre_operation": [ 0 ],
      "next_operation": [ 2 ],
      "times": {
        "0": 1
      }
    }, {
      "operation_id": 2,
      "job_id": 0,
      "machine_list": [ 1 ],
      "pre_operation": [ 1 ],
      "next_operation": [ -1 ],
      "times": {
        "1": 5
      }
    }, {
      "operation_id": 3,
      "job_id": 1,
      "machine_list": [ 0 ],
      "pre_operation": [ -1 ],
```



```
{
  "next_operation": [ 4 ],
  "times": {
    "0": 2
  }
}, {
  "operation_id": 4,
  "job_id": 1,
  "machine_list": [ 1 ],
  "pre_operation": [ 3 ],
  "next_operation": [ 5 ],
  "times": {
    "1": 2
  }
}, {
  "operation_id": 5,
  "job_id": 1,
  "machine_list": [ 0, 1 ],
  "pre_operation": [ 4 ],
  "next_operation": [ -1 ],
  "times": {
    "0": 3,
    "1": 6
  }
} ],
"objective": {
  "makespan": 1
}
}
```

响应示例

```
{
  "data": {
    "create_time": "2025-01-01 10:00:00.000000",
    "status": "created",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)

3.7.9.2 查询任务详情

功能介绍

通过“查询任务详情”来具体查看当前任务的进度。当任务状态为“completed”时，说明任务执行完成，可从指定的OBS路径中查看完成的求解结果。

URI

GET /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-619 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-620 <查询任务详情>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-621 。 默认取值： 不涉及

表 3-621 <查询任务详情>"data" 参数说明

参数	参数类型	描述
create_time	string	参数解释： 任务创建时间。 约束限制： yyyy-MM-DD HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
logs	string	参数解释： 当前任务的执行日志详情。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
output	Object	参数解释： 任务处理结果，任务状态为completed时携带。详见 表3-622 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： • created（任务已创建） • pending（任务排队中） • running（任务执行中） • completed（任务求解完成） • failed（任务失败） • deleted（任务已删除） 默认取值： 不涉及
task_id	String	参数解释： 当前任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-622 output

参数	参数类型	描述
opeartions	Array of opeartions objects	参数解释： 工序信息列表 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
jobs	Array of jobs objects	参数解释: 作业信息列表 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
machines	Array of machines objects	参数解释: 机器信息列表 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
makespan	Integer	参数解释: 完工时间 约束限制: 不涉及 取值范围: 非负值 默认取值: 不涉及

表 3-623 opearitions

参数	参数类型	描述
id	Integer	参数解释: 工序索引编号，表示输入工序中索引编号相同的工序 约束限制: 不涉及 取值范围: 非负整数 默认取值: 不涉及

参数	参数类型	描述
job_id	Integer	参数解释： 工序所属作业索引，表示输入作业中索引编号相同的作业 约束限制： 不涉及 取值范围： 非负整数 默认取值： 不涉及
machine_id	Integer	参数解释： 工序使用的机器索引，表示输入机器中索引编号相同的机器 约束限制： 不涉及 取值范围： 非负整数 默认取值： 不涉及
process_start_time	Integer	参数解释： 工序开始加工时间 约束限制： 不涉及 取值范围： 非负整数 默认取值： 不涉及
process_finish_time	Integer	参数解释： 工序结束加工时间 约束限制： 不涉及 取值范围： 非负整数 默认取值： 不涉及

参数	参数类型	描述
process_time	Integer	参数解释： 工序机器上的加工时间 约束限制： 不涉及 取值范围： 非负整数 默认取值： 不涉及

表 3-624 jobs

参数	参数类型	描述
id	Integer	参数解释： 作业索引编号，表示输入作业中索引编号相同的作业 约束限制： 不涉及 取值范围： 非负整数 默认取值： 不涉及
operation_list	Array of integers	参数解释： 该作业工序生产顺序索引列表，表示输入工序中索引编号相同的工序 约束限制： 不涉及 取值范围： 其元素为非负整数 默认取值： 不涉及

参数	参数类型	描述
path_id	Integer	参数解释： 作业工艺路径索引，表示输入工艺路径列表中索引编号相同的工艺路径 约束限制： 不涉及 取值范围： 非负整数 默认取值： 不涉及

表 3-625 machines

参数	参数类型	描述
id	Integer	参数解释： 机器索引编号，表示输入机器中索引编号相同的机器 约束限制： 不涉及 取值范围： 非负整数 默认取值： 不涉及
operation_list	Array of integers	参数解释： 机器执行工序索引顺序列表，表示输入工序中索引编号相同的工序 约束限制： 不涉及 取值范围： 其元素为非负整数 默认取值： 不涉及

状态码：400

表 3-626 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

状态码：200

任务详情

```
{
  "data": {
    "create_time": "2025-01-01 10:00:00.000000",
    "logs": "xxx",
    "output": {
      "jobs": [ {
        "id": 0,
        "operation_list": [ 0, 1, 2 ],
        "path_id": 0
      }, {
        "id": 1,
        "operation_list": [ 3, 4, 5 ]
      } ],
      "machines": [ {
        "id": 1,
        "operation_list": [ 0, 4, 2 ]
      }, {
        "id": 0,
        "operation_list": [ 3, 1, 5 ]
      } ],
      "makespan": 9,
      "operations": [ {
        "id": 0,
```

```
{
  "job_id": 0,
  "machine_id": 1,
  "process_finish_time": 1,
  "process_start_time": 0,
  "process_time": 1
}, {
  "id": 1,
  "job_id": 0,
  "machine_id": 0,
  "process_finish_time": 3,
  "process_start_time": 2,
  "process_time": 1
}, {
  "id": 2,
  "job_id": 0,
  "machine_id": 1,
  "process_finish_time": 9,
  "process_start_time": 4,
  "process_time": 5
}, {
  "id": 3,
  "job_id": 1,
  "machine_id": 0,
  "process_finish_time": 2,
  "process_start_time": 0,
  "process_time": 2
}, {
  "id": 4,
  "job_id": 1,
  "machine_id": 1,
  "process_finish_time": 4,
  "process_start_time": 2,
  "process_time": 2
}, {
  "id": 5,
  "job_id": 1,
  "machine_id": 0,
  "process_finish_time": 7,
  "process_start_time": 4,
  "process_time": 3
}
]
}
"status": "completed",
"task_id": "c5edc94b-xxxx-xxxx-xxx-754e481bafa5"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)

3.7.9.3 查询任务列表

功能介绍

通过“查询任务列表”来查询所有求解任务的状态及task_id。

URI

GET /task-list

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-627 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-628 <查询任务列表>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见表3-629。 默认取值： 不涉及

表 3-629 <查询任务列表>"data" 参数说明

参数	参数类型	描述
count	int	参数解释： 任务数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
tasks	Array(Object)	参数解释： 任务列表详情，其中Object的请求格式参见（ data返回数据详情 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-630 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释: 错误码 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
error_msg	String	参数解释: 错误信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "count": 2,
    "tasks": [
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "cf2a475e-xxxx-xxxx-xxxx-9f342b1b032e"
      },
      {
        "create_time": "2025-01-01 10:00:00.000000",
        "status": "completed",
        "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
      }
    ]
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.7.9.4 删除任务

功能介绍

通过“删除任务”来删除已添加的求解任务。

URI

DELETE /task/<task_id>

接口域名请参考[获取在线部署的大模型推理API接口域名](#)获取。

请求参数

表 3-631 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是（云上部署模型填写）	String	参数解释： 用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型，参数值为“application/json”。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-632 <删除任务>响应参数

参数	参数类型	描述
data	Object	参数解释： 返回数据。 约束限制： 不涉及 取值范围： 详情参见 表3-633 默认取值： 不涉及

表 3-633 <删除任务>"data" 参数说明

参数	参数类型	描述
status	string	参数解释： 任务当前状态。 约束限制： 不涉及 取值范围： 不涉及 默认取值： deleted
task_id	string	参数解释： 当前任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-634 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释: 错误码 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
error_msg	String	参数解释: 错误信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

请求示例

无

响应示例

```
{
  "data": {
    "status": "deleted",
    "task_id": "a3d5a37a-xxxx-xxxx-xxxx-90d57b0d9323"
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.8 向量&重排大模型

3.8.1 Embedding 模型服务

功能介绍

Embedding模型服务在创建知识库中，文本处理阶段，用于对文本文档进行切片，转换成向量化表示。在知识检索阶段，根据用户输入的query对切片进行召回。

URI

POST /pangu/search/v1/vector/query

接口域名获取方式请参见[获取在线部署的大模型推理API接口域名](#)。

请求参数

使用Token认证方式的请求Header参数见[表3-635](#)。

表 3-635 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。
Content-Type	是	String	发送的实体的MIME类型，参数值为“application/json”。

使用API Key认证方式的请求Header参数见[表 请求Header参数（API Key认证）](#)。

表 3-636 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是	String	API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。
Content-Type	是	String	发送的实体的MIME类型，参数值为“application/json”。

表 3-637 请求 Body 参数

参数	是否必选	参数类型	描述
query	是	String	参数解释： 需要向量化的文本内容。 约束限制： 字符串长度限制：1~1000 取值范围： 不涉及 默认取值： 不涉及
embedding_type	否	String	参数解释： 向量化的两种模式： query2query 和 query2doc。 query2query模式：主要用于通过查询语句去找相关度更高的语句。 query2doc模式：主要用于文档检索，通过查询语句去找类似的文档片段。 约束限制： 不涉及 取值范围： query2query、query2doc。 默认取值： query2doc

响应参数

状态码：200

表 3-638 响应 Body 参数

参数	参数类型	描述
embedding	List[List[Float]]	向量化的结果，是一个786维的向量。
ret	String	错误码。
msg	String	错误信息。
cost	Float	模型推理耗时。

状态码：400

表 3-639 响应 Body 参数

参数	参数类型	描述
ret	String	错误码。
msg	String	错误信息。
embedding	List[List[Float]]	向量化的结果，当错误时，值为空。
cost	Float	处理时间。

请求示例

```
POST /pangu/search/v1/vector/query \
--header 'Content-Type: application/json' \
--data '{
  "query": "南京",
  "embedding_type": "query2query"
}'
```

响应示例

```
{"embedding": [[0.30784764885902405, -0.0034346922766417265, 0.09973953664302826,
-0.46510231494903564,...]], "ret": 0, "cost":
0.03413224220275879, "msg": "success"}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.8.2 Rerank 模型服务

功能介绍

Rerank模型服务用于对召回切片，按照query与切片的相关度进行精细化排序，最后返回相关度最高的几个的切片。

URI

POST /pangu/search/v1/rerank
接口域名获取方式请参见[获取在线部署的大模型推理API接口域名](#)。

请求参数

使用Token认证方式的请求Header参数见[表3-640表3-640](#)。

表 3-640 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。
Content-Type	是	String	发送的实体的MIME类型，参数值为“application/json”。

使用API Key认证方式的请求Header参数见[表3-641](#)。

表 3-641 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是	String	API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。
Content-Type	是	String	发送的实体的MIME类型，参数值为“application/json”。

表 3-642 请求 Body 参数

参数	是否必选	参数类型	描述
rerank_order	是	String	参数解释： 由于在文档排序过程中，可能涉及多字段排序的情况，因此排序服务需要将多字段文本拼接到一个整体的文本，此处的rerank_order记录的是docs 中多字段的拼接优先级顺序。 约束限制： 和下列docs字段的具体子字段名称有关。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
docs	是	List[Object]	参数解释： 要排序的多组文本，单组文本支持多字段输入；单组文本具体的结构见 表3-643 描述。 约束限制： 文本字符长度为1~200。 取值范围： 不涉及 默认取值： 不涉及
query	是	String	参数解释： 查询词，重排序模型就是计算查询词和被查询文本的相关度。 约束限制： 查询字符长度为1~64。 取值范围： 不涉及 默认取值： 不涉及
top_n	否	int	参数解释： 返回top_n的结果。 约束限制： 不涉及 取值范围： 0~200 默认取值： 10

表 3-643 docs 的字段

参数	是否必选	参数类型	描述
id	是	String	参数解释： 描述文本信息的唯一标识。 约束限制： id长度为1~20。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
title	否	String	参数解释： 描述文本标题。 约束限制： title和content不能同时为空。 字符串长度为1~10240。 取值范围： 不涉及 默认取值： 不涉及
content	否	String	参数解释： 描述文本的内容。 约束限制： title和content不能同时为空。 字符串长度为1~10240。 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-644 响应 Body 参数

参数	参数类型	描述
rank_result	List[OBJECT]	重排序的结果。
ret	String	错误码。
cost	Float	模型推理耗时。

表 3-645 rank_result 字段

参数	参数类型	描述
id	String	被排序文本的文本唯一id。
score	Float	重排序计算的排序分值。

状态码： 400

表 3-646 响应 Body 参数

参数	参数类型	描述
ret	String	错误码。
msg	String	错误信息。
rank_result	List[List[Float]]	重排序的结果，当错误时，值为空。
cost	Float	处理时间。

请求示例

```
POST 'http://10.155.96.123:9099/pangu/search/v1/rerank' \
--header 'Content-Type: application/json' \
--data '{
  "query": "南京",
  "rerank_order": [
    "title",
    "content"
  ],
  "docs": [
    {
      "id": "a01",
      "title": "南京",
      "content": "简介：南京一般指南京市。南京市，简称“宁”，古称金陵、建康，江苏省省会、副省级市、特大城市、南京都市圈核心城市，国务院批复确定的中国东部地区重要的中心城市、全国重要的科研教育基  
地和综合交通枢纽。"
    },
    {
      "id": "a02",
      "title": "南京",
      "content": "南京市人民政府关于市政府领导同志工作分工的通知·南京市人民政府2021年政府信息公开  
工作年度报告 "
    },
    {
      "id": "a03",
      "title": "南京",
      "content": "唐代以成都为南京不到三年时间。[1] 宋大中祥符七年（1014年），建应天府（今商丘）  
为南京。[2-5] 辽代，以北京为南京。金代，以开封为南京。明永乐十九年（1421年），明成祖迁都，京师应  
天府（今南京）改称为南京，作为留都。"
    },
    {
      "id": "a04",
      "title": "南京",
      "content": "《南京市推进城市运行“一网统管”暂行办法》(下简称《办法》)3月1日开始施行。"
    },
    {
      "id": "a05",
      "title": "南京",
      "content": "一年下来,南京的大部分地方基本都去过了,因为朋友要来国庆玩嘛,问我哪里有什么好玩的地  
方,所以就决定写这篇日志了。"
    },
    {
      "id": "a06",
      "title": "南京",
      "content": "南京市人防指挥信息保障中心民防大厦消防设备采购中标公告 电台升级设备采购项目中  
标结果公告 南京人防短波电台升级改造设备采购项目招标公告 姚坊门水土保持验收中标候..."
    },
    {

```

```
    "id": "a07",
    "title": "南京",
    "content": "1993年11月，京南乡、长发乡分别改为镇。2005年7月，长发镇并入京南镇。行政区划1984年，辖京南、旺安、古榄、思蓬、儒垌、城垌、太平、大岸、纯冲、古参共10个村。2011年末，京南镇辖京南、长发2个社区，京南、旺安、古榄、..."
  },
  {
    "id": "a08",
    "title": "南京",
    "content": "身为首都的北京，是全国四大直辖市中唯一没有“副省级新区”的城市，而天津、重庆以及更早的上海，从制造业为核心的经济新区中获得的“速度效益”，则让北京对“京南新区”充满期许。"
  },
  {
    "id": "a09",
    "title": "南京",
    "content": "落实科技成果转化财税奖补政策，对输出技术合同、吸纳技术合同（技术开发、技术转让）进行补助；推进“京津研发，沧州转化”，深化与京津合作，进一步吸引京津成果落地转化。..."
  }
],
"top_n": 10
}
```

响应示例

```
{"rank_result": [{"score": 0.9975486397743225, "id": "a01"}, {"score": 0.7712018489837646, "id": "a03"}, {"score": 0.37750864028930664, "id": "a06"}, {"score": 0.22653242945671082, "id": "a09"}, {"score": 0.11012815684080124, "id": "a02"}, {"score": 0.08153211325407028, "id": "a05"}, {"score": 0.028581004589796066, "id": "a04"}, {"score": 0.01370169036090374, "id": "a07"}, {"score": 0.010038669221103191, "id": "a08"}], "ret": 0, "cost": 0.5570168495178223}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.9 搜索规划大模型

功能介绍

Pangu-SearchPlan模型，用于RAG场景，提供通用意图分类/多轮查询改写/复杂查询分解/时间抽取等功能，在RAG任务中生产用于检索的query，以及根据query分类路由到后续不同的流程。

URI

POST /app/search/v1/planning

接口域名获取方式请参见[获取在线部署的大模型推理API接口域名](#)。

请求参数

使用Token认证方式的请求Header参数见[表3-647](#)。

表 3-647 请求 Header 参数（Token 认证）

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	用户Token。 用于获取操作API的权限。 获取Token接口 响应消息头中X-Subject-Token的值即为Token。
Content-Type	是	String	发送的实体的MIME类型，参数值为“application/json”。

使用API Key认证方式的请求Header参数见[表 请求Header参数（API Key认证）](#)。

表 3-648 请求 Header 参数（API Key 认证）

参数	是否必选	参数类型	描述
X-Apig-AppCode	是	String	API Key值。 用于获取操作API的权限。 API Key认证 响应消息头中X-Apig-AppCode的值即为API Key。
Content-Type	是	String	发送的实体的MIME类型，参数值为“application/json”。

表 3-649 请求 Body 参数

参数	是否必选	参数类型	描述
query	是	String	参数解释： 查询词。 约束限制： 字符串长度限制：1~1024 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
history	否	List[String]	参数解释： 多轮对话的查询词和大模型的返回。实现逻辑如下： 1. 只参考最近5轮对话。 2. 对话历史和问题总长度 1000token，超长会按照特定逻辑截断。 3. 问题只参考前500字。 约束限制： ● 元素必须为偶数个，如 [Question1, Answer1, Question2, Answer2]。 ● 按照对话顺序从旧到新。 ● 问题 Question 必填。 ● 答案 Answer 可以为空字符串，但必须占位。 取值范围： 数组长度限制：0~50 字符串长度限制：0~4096 默认取值： 不涉及

响应参数

状态码：200

表 3-650 响应 Body 参数

参数	参数类型	描述
category	String	Query分类，对于行业知识类，建议使用前缀匹配。 闲聊类： 坐火车累死了 语言任务类： 请创作一封约460字的邮件，主题是咨询一个新的IT项目的细节，这个邮件将被发送给公司的IT项目经理。 人设类： 你叫什么名字 通用知识类： 豆汁和豆浆的区别 天气类： 明天北京天气 行业知识类： • 行业知识类-金融：贷款重组的定义是什么？ • 行业知识类-政务：《人工智能发展规划的通知》的指导思想是什么？ • 行业知识类-制造： • 行业知识类-医疗：儿童便秘市面上常见西药是什么？对于未考虑到行业知识类的细分类别，一般会分为“行业知识类”。
sub_queries	List[String]	多轮改写和复杂问题分解之后的子查询问题，可能包含多个值。
language	String	查询语言，编码对应 ISO 639-1。 zh: 中文 en: 英文 ar: 阿语 fr: 法语 th: 泰语 mix: 混合 unknown: 未知
timeliness	boolean	时效性查询，比如今天天气怎么样。

参数	参数类型	描述
date_range	String	从query中抽取时间范围，抽取结果如： query: 2022年全网最高用电负荷最大时，外电输入电力是多少？ date_range : 2022-01-01~2022-12-31 query: 一季度收入 date_range : 2024-01-01~2024-03-31 query: 今日时间 date_range: 2024-04-01 query: 2023年11月30日配套储能放电量是多少？ date_range: 2023-11-30~2023-11-30 query: 两天前发生了什么大事 date_range: 2024-03-30~2024-03-30 当有多个子query时，用";"拼接，示例如下： query: 2023年第一季度A地区和B地区的GDP date_range: 2023-01-01~2023-03-31;2023-01-01~2023-03-31
calculation	boolean	计算类查询，比如经济增长率。
output_language	String	query是否涉及“请用xx语言回答”这样的表述，即会输出对应语言编码。如zh、en、ar、fr、th。无结果则输出""。 查询语言，编码对应 ISO 639-1。
cost	float	请求处理耗时，单位ms。

状态码： 400

表 3-651 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

```
POST /app/search/v1/planning \
--header 'Content-Type: application/json' \
--data '
{
  "query": "今天天气怎样？",
  "history": []
}
```

响应示例

```
{
  "sub_queries": [
    "今天天气怎样? "
  ],
  "category": "天气类",
  "calculation": false,
  "timeliness": true,
  "language": "zh",
  "output_language": "",
  "date_range": "2025-05-15~2025-05-15",
  "cost": 164.17336463928223
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10 数据管理

3.10.1 查询数据集详情 v1

功能介绍

用户可以使用该接口查询数据集的详细信息。

接口域名请参考[获取盘古服务外部API域名](#)获取。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/data-management/dataset/
{dataset_name}

表 3-652 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_name	是	String	参数解释： 数据集名称（按照数据集的名称进行查询）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-653 Query 参数

参数	是否必选	参数类型	描述
catalog	是	String	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： • ORIGINAL(执行数据导入产生的数据集类型) • PROCESS(执行数据加工产生的数据集类型) • PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及

请求参数

表 3-654 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码： 200

表 3-655 响应 Body 参数

参数	参数类型	描述
name	String	参数解释： 数据集名称，由用户在创建数据集时填写的名称。 约束限制： 长度为2~63的字符。 取值范围： 以中文、字母开头，以中文、字母、数字结尾，只允许输入中文、字母、数字、中划线、下划线字符。 默认取值： 不涉及
dataset_id	String	参数解释： 数据集id，创建数据集时系统自动生成的数据集的id的编号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_desc	String	参数解释： 数据集描述，用户创建数据集时填写的描述内容。 约束限制： 不超过100个字符 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 数据集的上下线状态，生成数据集的过程中是下线状态，生成成功之后是上线状态。 约束限制： 不涉及 取值范围： ● ONLINE ● OFFLINE 默认取值： 不涉及
catalog	String	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： ● ORIGINAL(执行数据导入产生的数据集类型) ● PROCESS(执行数据加工产生的数据集类型) ● PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及
version	String	参数解释： 用户在生成数据集时系统自动生成的版本号。 约束限制： 当前不支持版本号更新。 取值范围： V1 默认取值： 不涉及

参数	参数类型	描述
size	Long	参数解释： 数据集大小，生成数据集成功后系统根据数据目录中所有文件的大小累加统计得到，除了manifest文件，单位是Byte。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
record_num	Long	参数解释： 数据集中的数据条数：加工和发布任务运行成功后，由任务上报的数据结果条数，举例：nlp中csv和jsonl文件中一行为一条数据，word文档中一个文档为一条数据，图片中一张图片为一条数据。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 数据集创建时间，用户在操作创建数据集时产生的时间。 约束限制： 格式为yyyy-MM-dd HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time_stamp	Long	参数解释： 数据集创建时间，用户在操作创建数据集时产生的时间，示例：1722332141000。 约束限制： 格式为绝对秒数 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 数据集更新时间，用户在操作创建、更新、删除、恢复数据集时产生的时间。 约束限制： 格式为yyyy-MM-dd HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
update_time_stamp	Long	参数解释： 数据集更新时间，用户在操作创建、更新、删除、恢复数据集时产生的时间，示例：1722332141000。 约束限制： 格式为绝对秒数 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
file_format	String	参数解释： 文件格式，由用户创建数据导入任务时选择的数据文件格式类型。 约束限制： 取值范围： • JSONL（后缀为jsonl的文件格式） • TXT（后缀为txt的文件格式） • CSV（后缀为csv的文件格式） • HTML（后缀为html的文件格式） • MOBI（后缀为mobi的文件格式） • EPUB（后缀为epub的文件格式） • DOCX（后缀为docx的文件格式） • PDF（后缀为pdf的文件格式） • MP4（后缀为mp4的文件格式） • AVI（后缀为avi的文件格式） • AVI_MP4（后缀为avi/mp4的文件格式） • JPGS_JSONL（后缀为jsonl, json, tar的文件格式） • JPG_TXT（cv数据类型，图片格式：JPG，标注文件格式：txt） • JPEG_TXT（cv数据类型，图片格式：JPEG，标注文件格式：txt） • PNG_TXT（cv数据类型，图片格式：PNG，标注文件格式：txt） • BMP_TXT（cv数据类型，图片格式：BMP，标注文件格式：txt） • JPG_XML（后缀为xml, jpg, jpeg, png, bmp, manifest的文件格式） • JPEG_XML（cv数据类型，图片格式：JPEG，标注文件格式：xml） • PNG_XML（cv数据类型，图片格式：PNG，标注文件格式：xml） • BMP_XML（cv数据类型，图片格式：BMP，标注文件格式：xml） • TAR（后缀为tar的文件格式） • IMAGE（后缀为jpg、jpeg、png、bmp的文件格式） • PASCAL（后缀为xml, jpg, jpeg, png, bmp的文件格式） • YOLO（后缀为yaml, txt, jpg, jpeg, png, bmp的文件格式）

参数	参数类型	描述
		• IMAGE_JSON（图片+标注格式，图片格式：jpg、jpeg、png、bmp，标注文件格式：json） • IMAGE_PNG（后缀为jpg, png的文件格式） • IMAGE_TXT（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：txt） • IMAGE_XML（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：xml） • VIDEO_JSON（视频+标注格式，视频格式：mp4、avi，标注文件格式：json） • VIDEO_TXT（视频+txt格式，视频格式：mp4、avi，标注格式：txt） • USER_DEFINED（自定义） 默认取值： 不涉及
modal	String	参数解释： 数据集模态，用户根据导入的文件类型选择的模态分类。 约束限制： 不涉及 取值范围： • TEXT("文本") • IMAGE("图片") • VIDEO("视频") • WEATHER("气象") • PREDICT("预测") • OTHER("其他") • AUDIO("音频") 默认取值： 不涉及

参数	参数类型	描述
file_source	String	参数解释： 创建数据导入任务时文件来源的分类。 约束限制： 不涉及 取值范围： • OBS（用户选择的自己的OBS桶路径） • LOCAL（用户选择的本地终端上的文件目录） • GALLERY（用户从Alhub上订阅的数据集） 默认取值： 不涉及

参数	参数类型	描述
content_type	String	参数解释： 数据集中数据内容类型，用户在创建导入任务时选择的，或者在加工和发布任务运行时由系统自动生成的对应模态下的数据内容类型。 约束限制： 不涉及 取值范围： • SINGLE_QA（单轮问答） • SINGLE_QA_MAN（单轮问答人设） • MULTI_QA（多轮问答） • MULTI_QA_MAN（多轮问答人设） • QA_SORTING（问答排序） • PLAIN_TXT（文档） • WEB_PAGE（网页） • PRE_TRAINED_TEXT（预训练文本） • VIDEO（视频） • VIDEO_CLIP_ANNOTATION（视频剪辑标注） • VIDEO_UNDERSTANDING（视频理解） • TIME_SERIES_PREDICT（时序） • REGRESSION_CLASSIFICATION（回归分类） • IMAGE_AND_CAPTION（图片+Caption） • IMAGE_AND_QA（图片+QA对） • IMAGE_AND_CV_ANNOTATION（图片+CV标注） • IMAGE（仅图片） • IMAGE_OBJECT_DETECTION（物体检测） • OCEAN_WEATHER（气象） • CUSTOMIZATION（自定义） • IMAGE_CLASSIFICATION（图像分类） • IMAGE_ANOMALY_DETECTION（异常检测） • IMAGE_SEMANTIC_SEGMENTATION（语义分割） • IMAGE_POSE_ESTIMATION（姿态估计） • IMAGE_INSTANCE_SEGMENTATION（实例分割） • IMAGE_CHANGE_DETECTION（变化检测） • VIDEO_EVENT_DETECTION（事件检测） • VIDEO_CLASSIFICATION（视频分类）

参数	参数类型	描述
		- DPO_QA (偏好优化DPO) - DPO_QA_MAN (偏好优化DPO人设) 默认取值: 不涉及
ext_config	String	参数解释: 系统内部模块使用的预留拓展字段。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
sample_path	String	参数解释: 用户在创建导入任务时选择的, 或者在创建加工和发布任务时系统自动生成的数据文件的OBS桶路径。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
work_path	String	参数解释: 数据集元数据保存在OBS上的根目录, 由系统在创建导入、加工和发布任务生成, 可以在数据详情内查看。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
work_path2	String	参数解释: 任务运行态的临时文件在OBS上的存储根目录。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
file_name	Array of strings	参数解释: 由数据导入和发布任务在生成数据集的时候记录的抽样的数据文件名称。 约束限制: 导入时记录文件个数上限为100，nlp发布时记录的数据集中数据文件的文件名。 取值范围: 不涉及 默认取值: 不涉及
file_num	Integer	参数解释: 数据集中数据目录下面的文件数量，在生成数据集时系统自动统计。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 0
annotation_num	Long	参数解释: 数据集中被标注的数据条数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
video_metadata_dir	String	参数解释: 视频类型数据相关元数据文件的存放目录。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
manifest_file_path	String	参数解释: 由数据发布任务生成cv数据集的时候由系统生成的manifest文件路径。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
language	String	参数解释: 由系统内部定义的，在用户创建数据集时选择的语言类型。 约束限制: 不涉及 取值范围: CHINESE: 中文 ENGLISH: 英文 ARABIC: 阿语 SPANISH: 西语 FRENCH: 法语 NONE: 未设置 默认取值: 不涉及

参数	参数类型	描述
annotation_status	String	参数解释： 标注任务在生成数据集的时候上报的标注项目状态，保存为kv结构，key为标注项名称，value为标注项状态。 如：("VIDEO_QUALITY", "ONLINE") 约束限制： 当前的标注项只支持VIDEO_QUALITY 取值范围： 取值范围为ONLINE和OFFLINE 默认取值： 不涉及
iam_user_name	String	参数解释： 创建该数据集的操作用户账号名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
iam_user_id	String	参数解释： 创建该数据集的操作用户账号ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_capsule_encryption	Boolean	参数解释： 用户在创建数据导入任务时解析的文件加密类型，该功能受限使用，需要配合tics服务使用。 约束限制： 不涉及 取值范围： true（明文数据） false（胶囊加密数据） 默认取值： false

参数	参数类型	描述
capsule	Capsule object	参数解释： 导入数据集为数据胶囊加密时的数据集相关信息，当前只支持文本类数据中的预训练和问答对数据类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_global	Boolean	参数解释： 在创建发布任务时，用户指定的数据集的空间可见范围。 约束限制： 不涉及 取值范围： true（当前用户全空间可见） false（当前空间可见） 默认取值： false
tag	Array of TagListVo objects	参数解释： 数据集标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
tokenize_status	String	参数解释： token化信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
industry	String	参数解释： 由系统内部定义，用户选择的行业类型，可在数据详情内查看。 约束限制： 不涉及 取值范围： GENERAL：通用 GOVERNMENT：政务 FINANCE：金融 MEDICAL：医疗 LAW：法律 AUTOMOBILE：汽车 COAL_MINE：煤矿 MILITARY：军事 TAXATION：税务 EDUCATION：教育 COMPUTER：计算机 INTERNET：互联网 RETAIL：零售 FOOD：食品 ENERGY：能源 MEDIA：传媒 INDUSTRY_AND_COMMERCE：工商 TRANSPORTATION：运输 E_COMMERCE：电商 MANUFACTURING：制造 NONE：不设置 默认取值： NONE
simple_tag	Array of strings	参数解释： 由用户填写的数据集的自定义标签。 约束限制： 单个标签长度为64字节，1个中文字符为3个字节，最多100个标签。 取值范围： 只允许输入中文、字母、数字、中划线、下划线字符。 默认取值： 不涉及

参数	参数类型	描述
data_copyright	String	参数解释： 由用户填写的数据版权内容，包括： 初始数据集名称 样例： 1、Antreas/TALI 2、weitianwen/cmath 初始数据集来源名称 样例： 1、Antreas/TALI 2、weitianwen/cmath 初始数据集版本号 样例： V2 初始数据集许可证 样例： V2 初始数据集授权人信息 样例： @misc{wei2023cmath, title={CMATH: Can Your Language Model Pass Chinese Elementary School Math Test?},author={Tianwen Wei and Jian Luan and Wei Liu and Shuang Dong and Bin Wang}, year={2023}, eprint={2306.16636}, archivePrefix={arXiv}, primaryClass={cs.CL} } 初始数据集许可证文本地址 样例： https://huggingface.co/datasets/choosealicense/licenses/blob/main/markdown/cc-by-4.0.md 初始数据集下载地址 样例： 1、https://huggingface.co/datasets/Antreas/TALI 2、https://huggingface.co/datasets/weitianwen/cmath

参数	参数类型	描述
		用户可在创建数据集或通过更新数据集详情接口修改 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
publish_format	String	参数解释: 用户在创建数据集发布任务时指定的文件内容格式类型。 约束限制: 盘古格式和自定义格式可以被盘古模型训练任务选择。 取值范围: DEFAULT（标准格式） PANGU（盘古格式） USER_DEFINED（自定义格式） 默认取值: 不涉及
scene	String	参数解释: 发布数据盘古格式使用场景，包括TRAIN、EVALUATE。表示训练、评测。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
meta_ext	String	参数解释: 元数据拓展信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
task_id	String	参数解释: 生成数据集时来源的导入、加工或者发布的任务ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
task_display_name	String	参数解释: 生成数据集时来源的导入、加工或者发布的任务名称。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
task_type	String	参数解释: 生成数据集时来源的导入、加工或者发布的任务类型。 约束限制: 不涉及 取值范围: ● IMPORT("导入") ● REFLUX("回流") ● CLEANING("清洗") ● ANNOTATION("标注") ● SYNTHESIS("合成") ● TAGGING("标签") ● EVALUATION("评估") ● COMBINATION("配比") ● CIRCULATION("流通") 默认取值: 不涉及

参数	参数类型	描述
data_source	SourceDatasets object	参数解释： 生成该数据集时来源任务创建时由用户选择的输入数据集ID列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
content_tag	Array of strings	参数解释： 数据加工任务生成的内容标签的id列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_deleted	Boolean	参数解释： 用户删除数据集时保存的删除状态。 约束限制： 不涉及 取值范围： true（删除状态，可通过恢复接口恢复数据集） false（未删除状态） 默认取值： false
format_ext	String	参数解释： 在生成文本类数据集时，由系统导入、加工和发布任务填写的JSONL中的key，比如：QA对中是context，target。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-656 Capsule

参数	参数类型	描述
enc_mode	String	参数解释: 从导入数据胶囊数据时从数据元数据文件中解析的数据加密类型。 约束限制: 不涉及 取值范围: ROW（行级加密） FieldLevel（字段级加密） FileLevel（文件级加密） 默认取值: 不涉及
valid_date_start	Long	参数解释: 从导入数据胶囊数据时从数据元数据文件中解析的胶囊数据有效起始时间。 约束限制: 绝对秒数 取值范围: 不涉及 默认取值: 不涉及
valid_date_end	Long	参数解释: 从导入数据胶囊数据时从数据元数据文件中解析的胶囊数据有效结束时间。 约束限制: 绝对秒数 取值范围: 不涉及 默认取值: 不涉及

表 3-657 TagListVo

参数	参数类型	描述
[数组元素]	Array of TagVo objects	参数解释： 数据集列表对象信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-658 TagVo

参数	参数类型	描述
id	String	参数解释： 数据集标签ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
name	String	参数解释： 数据集标签名。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
level	Integer	参数解释： 数据集标签层级。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-659 SourceDatasets

参数	参数类型	描述
records	Array of SourceDataset objects	参数解释: 来源数据集列表。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-660 SourceDataset

参数	参数类型	描述
dataset_id	String	参数解释: 来源数据集id。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
dataset_name	String	参数解释: 数据集名称。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
catalog	String	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： ● ORIGINAL(执行数据导入产生的数据集类型) ● PROCESS(执行数据加工产生的数据集类型) ● PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及
modal	String	参数解释： 数据集模态，用户根据导入的文件类型选择的模态分类。 约束限制： 不涉及 取值范围： ● TEXT("文本") ● IMAGE("图片") ● VIDEO("视频") ● WEATHER("气象") ● PREDICT("预测") ● OTHER("其他") ● AUDIO("音频") 默认取值： 不涉及

参数	参数类型	描述
content_type	String	参数解释: 数据集中数据内容类型，用户在创建导入任务时选择的，或者在加工和发布任务运行时由系统自动生成的对应模态下的数据内容类型。 约束限制: 不涉及 取值范围: • SINGLE_QA（单轮问答） • SINGLE_QA_MAN（单轮问答人设） • MULTI_QA（多轮问答） • MULTI_QA_MAN（多轮问答人设） • QA_SORTING（问答排序） • PLAIN_TXT（文档） • WEB_PAGE（网页） • PRE_TRAINED_TEXT（预训练文本） • VIDEO（视频） • VIDEO_CLIP_ANNOTATION（视频剪辑标注） • VIDEO_UNDERSTANDING（视频理解） • TIME_SERIES_PREDICT（时序） • REGRESSION_CLASSIFICATION（回归分类） • IMAGE_AND_CAPTION（图片+Caption） • IMAGE_AND_QA（图片+QA对） • IMAGE_AND_CV_ANNOTATION（图片+CV标注） • IMAGE（仅图片） • IMAGE_OBJECT_DETECTION（物体检测） • OCEAN_WEATHER（气象） • CUSTOMIZATION（自定义） • IMAGE_CLASSIFICATION（图像分类） • IMAGE_ANOMALY_DETECTION（异常检测） • IMAGE_SEMANTIC_SEGMENTATION（语义分割） • IMAGE_POSE_ESTIMATION（姿态估计） • IMAGE_INSTANCE_SEGMENTATION（实例分割） • IMAGE_CHANGE_DETECTION（变化检测） • VIDEO_EVENT_DETECTION（事件检测） • VIDEO_CLASSIFICATION（视频分类）

参数	参数类型	描述
		- DPO_QA（偏好优化DPO） - DPO_QA_MAN（偏好优化DPO人设） 默认取值： 不涉及

参数	参数类型	描述
file_format	String	参数解释： 文件格式，由用户创建数据导入任务时选择的数据文件格式类型。 约束限制： 取值范围： • JSONL（后缀为jsonl的文件格式） • TXT（后缀为txt的文件格式） • CSV（后缀为csv的文件格式） • HTML（后缀为html的文件格式） • MOBI（后缀为mobi的文件格式） • EPUB（后缀为epub的文件格式） • DOCX（后缀为docx的文件格式） • PDF（后缀为pdf的文件格式） • MP4（后缀为mp4的文件格式） • AVI（后缀为avi的文件格式） • AVI_MP4（后缀为avi/mp4的文件格式） • JPGS_JSONL（后缀为jsonl, json, tar的文件格式） • JPG_TXT（cv数据类型，图片格式：JPG，标注文件格式：txt） • JPEG_TXT（cv数据类型，图片格式：JPEG，标注文件格式：txt） • PNG_TXT（cv数据类型，图片格式：PNG，标注文件格式：txt） • BMP_TXT（cv数据类型，图片格式：BMP，标注文件格式：txt） • JPG_XML（后缀为xml, jpg, jpeg, png, bmp, manifest的文件格式） • JPEG_XML（cv数据类型，图片格式：JPEG，标注文件格式：xml） • PNG_XML（cv数据类型，图片格式：PNG，标注文件格式：xml） • BMP_XML（cv数据类型，图片格式：BMP，标注文件格式：xml） • TAR（后缀为tar的文件格式） • IMAGE（后缀为jpg、jpeg、png、bmp的文件格式） • PASCAL（后缀为xml, jpg, jpeg, png, bmp的文件格式） • YOLO（后缀为yaml, txt, jpg, jpeg, png, bmp的文件格式）

参数	参数类型	描述
		• IMAGE_JSON（图片+标注格式，图片格式：jpg、jpeg、png、bmp，标注文件格式：json） • IMAGE_PNG（后缀为jpg, png的文件格式） • IMAGE_TXT（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：txt） • IMAGE_XML（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：xml） • VIDEO_JSON（视频+标注格式，视频格式：mp4、avi，标注文件格式：json） • VIDEO_TXT（视频+txt格式，视频格式：mp4、avi，标注格式：txt） • USER_DEFINED（自定义） 默认取值： 不涉及
size	Integer	参数解释： 数据集大小，生成数据集成功后系统根据数据目录中所有文件的大小累加统计得到，除了manifest文件，单位是Byte。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
record_num	Integer	参数解释： 数据集中的数据条数：加工和发布任务运行成功后，由任务上报的数据结果条数，举例：nlp中csv和jsonl文件中一行为一条数据，word文档中一个文档为一条数据，图片中一张图片为一条数据。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
data_num	Number	参数解释： 数据集详情：在发布数据集中所占的配比数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
data_scale	Number	参数解释： 配比比例：在发布数据集中所占的配比比例。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-661 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

无

响应示例

状态码： 200

成功响应示例

```
{
  "name" : "qa073",
  "dataset_id" : "1267898425467342848",
  "dataset_desc" : "",
  "status" : "ONLINE",
  "catalog" : "ORIGINAL",
  "version" : null,
  "size" : 6847,
```

```
"record_num" : 21,
"create_time" : "1722332141000",
"create_time_stamp" : 1722332141000,
"update_time" : null,
"update_time_stamp" : null,
"file_format" : "JSONL",
"file_source" : "LOCAL",
"content_type" : "SINGLE_QA_MAN",
"ext_config" : null,
"sample_path" : "obs://桶名/original/1722332452247/",
"work_path" : "obs://桶名/dataset/5796ca0c-4377-11ef-9eef-0255ac1000aa/ORIGINAL/qa0731267898425467342848/v1",
"work_path2" : "obs://桶名/dataset/5796ca0c-4377-11ef-9eef-0255ac1000aa/ORIGINAL/qa0731267898425467342848/v1",
"file_name" : [ "showcase3QA.jsonl" ],
"file_num" : 1,
"annotation_num" : null,
"video_metadata_dir" : null,
"manifest_file_path" : "obs://桶名/dataset/5796ca0c-4377-11ef-9eef-0255ac1000aa/ORIGINAL/qa0731267898425467342848/v1/qa073.manifest",
"language" : null,
"annotation_status" : null,
"iam_user_name" : "用户名称",
"iam_user_id" : "用户id",
"is_capsule_encryption" : false,
"capsule" : null,
"is_global" : false,
>tag" : null,
"tokenize_status" : null,
"industry" : null,
"simple_tag" : null
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.2 根据 ID 批量查询数据集

功能介绍

根据数据集ID列表批量查询数据集详细信息。

接口域名请参考[获取盘古服务外部API域名](#)获取。

URI

POST /v1/{project_id}/workspaces/{workspace_id}/data-management/datasets

表 3-662 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-663 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-664 请求 Body 参数

参数	是否必选	参数类型	描述
dataset_ids	是	Array of strings	参数解释： 数据集ID列表，从 查询数据集详情v1 接口中可获取dataset_id，支持多个id批量查询。 约束限制： 按照json数组格式填写：例如 ["id1", "id2", "id3"]。 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码： 200

表 3-665 响应 Body 参数

参数	参数类型	描述
total_count	Long	参数解释： 数据集总量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
datasets	Array of DatasetVo objects	参数解释： 数据集详细信息列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
count_info	CountVo object	参数解释： 数据集数量信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-666 DatasetVo

参数	参数类型	描述
dataset_id	String	参数解释： 数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
catalog	String	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： • ORIGINAL(执行数据导入产生的数据集类型) • PROCESS(执行数据加工产生的数据集类型) • PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及
name	String	参数解释： 数据集名称，由用户在创建数据集时填写的名称。 约束限制： 长度为2~63的字符。 取值范围： 以中文、字母开头，以中文、字母、数字结尾，只允许输入中文、字母、数字、中划线、下划线字符。 默认取值： 不涉及
dataset_desc	String	参数解释： 数据集描述，用户创建数据集时填写的描述内容。 约束限制： 不超过100个字符 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 数据集的上下线状态，生成数据集的过程中是下线状态，生成成功之后是上线状态。 约束限制： 不涉及 取值范围： ● ONLINE ● OFFLINE 默认取值： 不涉及
version	String	参数解释： 用户在生成数据集时系统自动生成的版本号，当前不支持版本号更新。 约束限制： 不涉及 取值范围： V1 默认取值： 不涉及
update_time	String	参数解释： 数据集更新时间，用户在操作创建、更新、删除、恢复数据集时产生的时间。 约束限制： 格式为yyyy-MM-dd HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
update_time_stamp	Long	参数解释： 数据集更新时间，用户在操作创建、更新、删除、恢复数据集时产生的时间，示例： 1722332141000。 约束限制： 格式为绝对秒数 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time	String	参数解释： 数据集创建时间，用户在操作创建数据集时产生的时间。 约束限制： 格式为yyyy-MM-dd HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
create_time_stamp	Long	参数解释： 数据集创建时间，用户在操作创建数据集时产生的时间，示例：1722332141000。 约束限制： 格式为绝对秒数 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
file_format	String	参数解释： 文件格式，由用户创建数据导入任务时选择的数据文件格式类型。 约束限制： 取值范围： • JSONL（后缀为jsonl的文件格式） • TXT（后缀为txt的文件格式） • CSV（后缀为csv的文件格式） • HTML（后缀为html的文件格式） • MOBI（后缀为mobi的文件格式） • EPUB（后缀为epub的文件格式） • DOCX（后缀为docx的文件格式） • PDF（后缀为pdf的文件格式） • MP4（后缀为mp4的文件格式） • AVI（后缀为avi的文件格式） • AVI_MP4（后缀为avi/mp4的文件格式） • JPGS_JSONL（后缀为jsonl, json, tar的文件格式） • JPG_TXT（cv数据类型，图片格式：JPG，标注文件格式：txt） • JPEG_TXT（cv数据类型，图片格式：JPEG，标注文件格式：txt） • PNG_TXT（cv数据类型，图片格式：PNG，标注文件格式：txt） • BMP_TXT（cv数据类型，图片格式：BMP，标注文件格式：txt） • JPG_XML（后缀为xml, jpg, jpeg, png, bmp, manifest的文件格式） • JPEG_XML（cv数据类型，图片格式：JPEG，标注文件格式：xml） • PNG_XML（cv数据类型，图片格式：PNG，标注文件格式：xml） • BMP_XML（cv数据类型，图片格式：BMP，标注文件格式：xml） • TAR（后缀为tar的文件格式） • IMAGE（后缀为jpg、jpeg、png、bmp的文件格式） • PASCAL（后缀为xml, jpg, jpeg, png, bmp的文件格式） • YOLO（后缀为yaml, txt, jpg, jpeg, png, bmp的文件格式）

参数	参数类型	描述
		• IMAGE_JSON（图片+标注格式，图片格式：jpg、jpeg、png、bmp，标注文件格式：json） • IMAGE_PNG（后缀为jpg, png的文件格式） • IMAGE_TXT（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：txt） • IMAGE_XML（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：xml） • VIDEO_JSON（视频+标注格式，视频格式：mp4、avi，标注文件格式：json） • VIDEO_TXT（视频+txt格式，视频格式：mp4、avi，标注格式：txt） • USER_DEFINED（自定义） 默认取值： 不涉及
modal	String	参数解释： 数据集模态，用户根据导入的文件类型选择的模态分类。 约束限制： 不涉及 取值范围： • TEXT("文本") • IMAGE("图片") • VIDEO("视频") • WEATHER("气象") • PREDICT("预测") • OTHER("其他") • AUDIO("音频") 默认取值： 不涉及

参数	参数类型	描述
file_source	String	参数解释： 创建数据导入任务时文件来源的分类。 约束限制： 不涉及 取值范围： • OBS（用户选择的自己的OBS桶路径） • LOCAL（用户选择的本地终端上的文件目录） • GALLERY（用户从Alhub上订阅的数据集） 默认取值： 不涉及
language	String	参数解释： 由系统内部定义的，在用户创建数据集时选择的语言类型。 约束限制： 不涉及 取值范围： CHINESE：中文 ENGLISH：英文 ARABIC：阿语 SPANISH：西语 FRENCH：法语 NONE：未设置 默认取值： 不涉及

参数	参数类型	描述
industry	String	参数解释: 由系统内部定义，用户选择的行业类型，可在数据详情内查看。 约束限制: 不涉及 取值范围: GENERAL: 通用 GOVERNMENT: 政务 FINANCE: 金融 MEDICAL: 医疗 LAW: 法律 AUTOMOBILE: 汽车 COAL_MINE: 煤矿 MILITARY: 军事 TAXATION: 税务 EDUCATION: 教育 COMPUTER: 计算机 INTERNET: 互联网 RETAIL: 零售 FOOD: 食品 ENERGY: 能源 MEDIA: 传媒 INDUSTRY_AND_COMMERCE: 工商 TRANSPORTATION: 运输 E_COMMERCE: 电商 MANUFACTURING: 制造 NONE: 不设置 默认取值: NONE
is_global	Boolean	参数解释: 在创建发布任务时，用户指定的数据集的空间可见范围。 约束限制: 不涉及 取值范围: true (当前用户全空间可见) false (当前空间可见) 默认取值: false

参数	参数类型	描述
size	Long	参数解释： 数据集大小，生成数据集成功后系统根据数据目录中所有文件的大小累加统计得到，除了manifest文件，单位是Byte。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
file_num	Integer	参数解释： 数据集中数据目录下面的文件数量，在生成数据集时系统自动统计。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
record_num	Long	参数解释： 数据集中的数据条数：加工和发布任务运行成功后，由任务上报的数据结果条数，举例：nlp中csv和jsonl文件中一行为一条数据，word文档中一个文档为一条数据，图片中一张图片为一条数据。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
content_type	String	参数解释： 数据集中数据内容类型，用户在创建导入任务时选择的，或者在加工和发布任务运行时由系统自动生成的对应模态下的数据内容类型。 约束限制： 不涉及 取值范围： • SINGLE_QA（单轮问答） • SINGLE_QA_MAN（单轮问答人设） • MULTI_QA（多轮问答） • MULTI_QA_MAN（多轮问答人设） • QA_SORTING（问答排序） • PLAIN_TXT（文档） • WEB_PAGE（网页） • PRE_TRAINED_TEXT（预训练文本） • VIDEO（视频） • VIDEO_CLIP_ANNOTATION（视频剪辑标注） • VIDEO_UNDERSTANDING（视频理解） • TIME_SERIES_PREDICT（时序） • REGRESSION_CLASSIFICATION（回归分类） • IMAGE_AND_CAPTION（图片+Caption） • IMAGE_AND_QA（图片+QA对） • IMAGE_AND_CV_ANNOTATION（图片+CV标注） • IMAGE（仅图片） • IMAGE_OBJECT_DETECTION（物体检测） • OCEAN_WEATHER（气象） • CUSTOMIZATION（自定义） • IMAGE_CLASSIFICATION（图像分类） • IMAGE_ANOMALY_DETECTION（异常检测） • IMAGE_SEMANTIC_SEGMENTATION（语义分割） • IMAGE_POSE_ESTIMATION（姿态估计） • IMAGE_INSTANCE_SEGMENTATION（实例分割） • IMAGE_CHANGE_DETECTION（变化检测） • VIDEO_EVENT_DETECTION（事件检测） • VIDEO_CLASSIFICATION（视频分类）

参数	参数类型	描述
		- DPO_QA (偏好优化DPO) - DPO_QA_MAN (偏好优化DPO人设) 默认取值: 不涉及
user_name	String	参数解释: 数据集的创建人。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
sample_path	String	参数解释: 用户在创建导入任务时选择的, 或者在创建加工和发布任务时系统自动生成的数据文件的OBS桶路径。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
annotation_status	String	参数解释: 标注任务在生成数据集的时候上报的标注项目状态, 保存为kv结构, key为标注项名称, value为标注项状态。 如: ("VIDEO_QUALITY", "ONLINE") 约束限制: 当前的标注项只支持VIDEO_QUALITY 取值范围: 取值范围为ONLINE和OFFLINE 默认取值: 不涉及

参数	参数类型	描述
tokenize_status	String	参数解释： 数据集token化的状态。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
platform	String	参数解释： 资产适用平台，包括PANGU、RAG。 约束限制： 不涉及 取值范围： Pangu（用于盘古模型训练）。 默认取值： 不涉及
annotation_num	Long	参数解释： 数据集中被标注的数据条数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
video_metadata_dir	String	参数解释： 视频类型数据相关元数据文件的存放目录。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
is_capsule_encryption	Boolean	参数解释： 用户在创建数据导入任务时解析的文件加密类型，该功能受限使用，需要配合tics服务使用。 约束限制： 不涉及 取值范围： true（明文数据） false（胶囊加密数据） 默认取值： false
capsule	Capsule object	参数解释： 导入数据集为数据胶囊加密时的数据集相关信息，当前只支持文本类数据中的预训练和问答对数据类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
publish_format	String	参数解释： 用户在创建数据集发布任务时指定的文件内容格式类型。 约束限制： 盘古格式和自定义格式可以被盘古模型训练任务选择。 取值范围： • DEFAULT（标准格式） • PANGU（盘古格式） • USER_DEFINED（自定义格式） 默认取值： 不涉及

参数	参数类型	描述
scene	String	参数解释： 发布数据在pangu格式使用场景，包括TRAIN、EVALUATE。表示训练、评测。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
simple_tag	Array of strings	参数解释： 由用户填写的数据集的自定义标签。 约束限制： 单个标签长度为64字节，1个中文字符为3个字节，最多100个标签。 取值范围： 只允许输入中文、字母、数字、中划线、下划线字符。 默认取值： 不涉及
task_id	String	参数解释： 生成数据集时来源的导入、加工或者发布的任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_display_name	String	参数解释： 生成数据集时来源的导入、加工或者发布的任务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
task_type	String	参数解释： 生成数据集时来源的导入、加工或者发布的任务类型。 约束限制： 不涉及 取值范围： • IMPORT("导入") • REFLUX("回流") • CLEANING("清洗") • ANNOTATION("标注") • SYNTHESIS("合成") • TAGGING("标签") • EVALUATION("评估") • COMBINATION("配比") • CIRCULATION("流通") 默认取值： 不涉及
data_source	SourceDataset object	参数解释： 生成该数据集时来源任务创建时由用户选择的输入数据集ID列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_deleted	Boolean	参数解释： 用户删除数据集时保存的删除状态。 约束限制： 不涉及 取值范围： true（删除状态，可通过恢复接口恢复数据集） false（未删除状态） 默认取值： false

参数	参数类型	描述
format_ext	String	参数解释： 在生成文本类数据集时，由系统导入、加工和发布任务填写的JSONL中的key，比如：QA对中是context，target。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-667 Capsule

参数	参数类型	描述
enc_mode	String	参数解释： 数据集加密方式，当前仅支持行加密。 约束限制： 不涉及 取值范围： ROW（行级加密） 默认取值： 不涉及
valid_date_start	Long	参数解释： 从导入数据胶囊数据时从数据元数据文件中解析的胶囊数据有效起始时间。 约束限制： 绝对秒数 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
valid_date_end	Long	参数解释： 从导入数据胶囊数据时从数据元数据文件中解析的胶囊数据有效结束时间。 约束限制： 绝对秒数 取值范围： 不涉及 默认取值： 不涉及

表 3-668 SourceDatasets

参数	参数类型	描述
records	Array of SourceDataset objects	参数解释： 来源数据集列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-669 SourceDataset

参数	参数类型	描述
dataset_id	String	参数解释： 来源数据集id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
dataset_name	String	参数解释： 数据集名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
catalog	String	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： ● ORIGINAL(执行数据导入产生的数据集类型) ● PROCESS(执行数据加工产生的数据集类型) ● PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及
modal	String	参数解释： 数据集模态，用户根据导入的文件类型选择的模态分类。 约束限制： 不涉及 取值范围： ● TEXT("文本") ● IMAGE("图片") ● VIDEO("视频") ● WEATHER("气象") ● PREDICT("预测") ● OTHER("其他") ● AUDIO("音频") 默认取值： 不涉及

参数	参数类型	描述
content_type	String	参数解释： 数据集中数据内容类型，用户在创建导入任务时选择的，或者在加工和发布任务运行时由系统自动生成的对应模态下的数据内容类型。 约束限制： 不涉及 取值范围： • SINGLE_QA（单轮问答） • SINGLE_QA_MAN（单轮问答人设） • MULTI_QA（多轮问答） • MULTI_QA_MAN（多轮问答人设） • QA_SORTING（问答排序） • PLAIN_TXT（文档） • WEB_PAGE（网页） • PRE_TRAINED_TEXT（预训练文本） • VIDEO（视频） • VIDEO_CLIP_ANNOTATION（视频剪辑标注） • VIDEO_UNDERSTANDING（视频理解） • TIME_SERIES_PREDICT（时序） • REGRESSION_CLASSIFICATION（回归分类） • IMAGE_AND_CAPTION（图片+Caption） • IMAGE_AND_QA（图片+QA对） • IMAGE_AND_CV_ANNOTATION（图片+CV标注） • IMAGE（仅图片） • IMAGE_OBJECT_DETECTION（物体检测） • OCEAN_WEATHER（气象） • CUSTOMIZATION（自定义） • IMAGE_CLASSIFICATION（图像分类） • IMAGE_ANOMALY_DETECTION（异常检测） • IMAGE_SEMANTIC_SEGMENTATION（语义分割） • IMAGE_POSE_ESTIMATION（姿态估计） • IMAGE_INSTANCE_SEGMENTATION（实例分割） • IMAGE_CHANGE_DETECTION（变化检测） • VIDEO_EVENT_DETECTION（事件检测） • VIDEO_CLASSIFICATION（视频分类）

参数	参数类型	描述
		- DPO_QA（偏好优化DPO） - DPO_QA_MAN（偏好优化DPO人设） 默认取值： 不涉及

参数	参数类型	描述
file_format	String	参数解释： 文件格式，由用户创建数据导入任务时选择的数据文件格式类型。 约束限制： 取值范围： • JSONL（后缀为jsonl的文件格式） • TXT（后缀为txt的文件格式） • CSV（后缀为csv的文件格式） • HTML（后缀为html的文件格式） • MOBI（后缀为mobi的文件格式） • EPUB（后缀为epub的文件格式） • DOCX（后缀为docx的文件格式） • PDF（后缀为pdf的文件格式） • MP4（后缀为mp4的文件格式） • AVI（后缀为avi的文件格式） • AVI_MP4（后缀为avi/mp4的文件格式） • JPGS_JSONL（后缀为jsonl, json, tar的文件格式） • JPG_TXT（cv数据类型，图片格式：JPG，标注文件格式：txt） • JPEG_TXT（cv数据类型，图片格式：JPEG，标注文件格式：txt） • PNG_TXT（cv数据类型，图片格式：PNG，标注文件格式：txt） • BMP_TXT（cv数据类型，图片格式：BMP，标注文件格式：txt） • JPG_XML（后缀为xml, jpg, jpeg, png, bmp, manifest的文件格式） • JPEG_XML（cv数据类型，图片格式：JPEG，标注文件格式：xml） • PNG_XML（cv数据类型，图片格式：PNG，标注文件格式：xml） • BMP_XML（cv数据类型，图片格式：BMP，标注文件格式：xml） • TAR（后缀为tar的文件格式） • IMAGE（后缀为jpg、jpeg、png、bmp的文件格式） • PASCAL（后缀为xml, jpg, jpeg, png, bmp的文件格式） • YOLO（后缀为yaml, txt, jpg, jpeg, png, bmp的文件格式）

参数	参数类型	描述
		• IMAGE_JSON（图片+标注格式，图片格式：jpg、jpeg、png、bmp，标注文件格式：json） • IMAGE_PNG（后缀为jpg, png的文件格式） • IMAGE_TXT（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：txt） • IMAGE_XML（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：xml） • VIDEO_JSON（视频+标注格式，视频格式：mp4、avi，标注文件格式：json） • VIDEO_TXT（视频+txt格式，视频格式：mp4、avi，标注格式：txt） • USER_DEFINED（自定义） 默认取值： 不涉及
size	Integer	参数解释： 数据集大小，生成数据集成功后系统根据数据目录中所有文件的大小累加统计得到，除了manifest文件，单位是Byte。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
record_num	Integer	参数解释： 数据集中的数据条数：加工和发布任务运行成功后，由任务上报的数据结果条数，举例：nlp中csv和jsonl文件中一行为一条数据，word文档中一个文档为一条数据，图片中一张图片为一条数据。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
data_num	Number	参数解释： 数据集详情：在发布数据集中所占的配比数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
data_scale	Number	参数解释： 配比比例：在发布数据集中所占的配比比例。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-670 CountVo

参数	参数类型	描述
total_count	Long	参数解释： 某类数据集总条数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
online_count	Long	参数解释： 上线数据集条数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
offline_count	Long	参数解释： 未上线数据集条数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-671 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

根据数据集ID列表批量查询数据集详细信息

```
{
  "dataset_ids" : [ "1267804346146492416" ]
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "total_count" : 1,
  "datasets" : [ {
    "dataset_id" : "1267804346146492416",
    "catalog" : "ORIGINAL",
    "name" : "pdf-image2k",
    "dataset_desc" : "",
    "status" : "ONLINE",
    "version" : null,
    "update_time" : null,
    "update_time_stamp" : null,
    "create_time" : null,
    "create_time_stamp" : null,
    "file_format" : "PDF",
    "file_source" : "LOCAL",
    "language" : null,
    "size" : 205670,
    "file_num" : 1,
    "record_num" : 0,
  } ]
}
```

```
"content_type": "PLAIN_TXT",
"user_name": "pangu_pjf",
"sample_path": "obs://桶名/original/1722310020643/",
"annotation_status": null,
"tokenize_status": null,
"platform": null,
"annotation_num": null,
"video_metadata_dir": null,
"is_capsule_encryption": false,
"capsule": null
}],
"count_info": null
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.3 删除数据发布任务

功能介绍

用户可以使用该接口删除数据发布任务， 运行中、停止中、数据集生成中状态的任务不允许删除。

URI

DELETE /v1/{project_id}/workspaces/{workspace_id}/data-publish/jobs/{job_id}

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

表 3-672 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
job_id	是	String	参数解释： 作业ID。获取方法请参见 创建数据发布任务v1 接口返回的id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-673 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：500

表 3-674 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

无

响应示例

无

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.4 批量删除数据集

功能介绍

用户可以使用接口批量删除数据集，仅当数据集存在且没有关联的运行中的任务时可删除数据集，删除操作不可逆。

URI

POST /v1/{project_id}/workspaces/{workspace_id}/data-management/dataset/
batch-delete

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-675 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-676 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-677 请求 Body 参数

参数	是否必选	参数类型	描述
datasets	是	Array of DsNameCatalog objects	参数解释： 数据集名称和数据集形态列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-678 DsNameCatalog

参数	是否必选	参数类型	描述
dataset_name	是	String	参数解释 用户在创建数据集时填写的数据集名称 约束限制: 不涉及 取值范围: 数据集名称以中文、字母开头，以中文、字母、数字结尾，长度2~63字符，只允许输入中文、字母、数字、中划线、下划线等字符 默认取值: 不涉及
catalog	否	String	参数解释: 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集 约束限制: 不涉及 取值范围: ● ORIGINAL(执行数据导入产生的数据集类型) ● PROCESS(执行数据加工产生的数据集类型) ● PUBLISH(执行数据发布产生的数据集类型) 默认取值: 不涉及

响应参数

状态码：200

表 3-679 响应 Body 参数

参数	参数类型	描述
datasets	Array of datasets objects	参数解释： 批量操作的数据集列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-680 datasets

参数	参数类型	描述
dataset_name	String	参数解释 用户在创建数据集时填写的数据集名称 约束限制： 不涉及 取值范围： 数据集名称以中文、字母开头，以中文、字母、数字结尾，长度2~63字符，只允许输入中文、字母、数字、中划线、下划线等字符 默认取值： 不涉及
catalog	String	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集 约束限制： 不涉及 取值范围： • ORIGINAL(执行数据导入产生的数据集类型) • PROCESS(执行数据加工产生的数据集类型) • PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及

参数	参数类型	描述
result	ErrorRsp object	参数解释： 失败时返回的错误对象。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-681 ErrorRsp

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：400

表 3-682 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：401

表 3-683 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：403

表 3-684 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：404

表 3-685 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：500

表 3-686 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

批量删除数据集

```
{
  "datasets": [ {
    "dataset_name": "数据集名称",
    "catalog": "ORIGINAL"
  } ]
}
```

响应示例

状态码：200

成功响应示例

```
{
  "datasets": [ {
    "dataset_name": "qa073001",
    "catalog": "ORIGINAL",
    "result": {
      "error_code": "MAStudio.02010000",
      "error_msg": "BadRequest"
    }
  } ]
}
```

```
  }  
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.5 彻底删除数据发布任务

功能介绍

用户可以使用该接口彻底删除数据发布任务相关信息。

URI

DELETE /v1/{project_id}/workspaces/{workspace_id}/data-publish/jobs/{job_id}/real-delete

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-687 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
job_id	是	String	参数解释： 作业id。获取方法请参见创建作业返回的job_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-688 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：500

表 3-689 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

无

响应示例

无

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.6 创建数据发布任务 v1

功能介绍

用户可以使用该接口创建数据发布任务。

URI

POST /v1/{project_id}/workspaces/{workspace_id}/data-publish/jobs

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-690 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-691 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-692 请求 Body 参数

参数	是否必选	参数类型	描述
job_type	是	String	参数解释： 用户在创建发布任务时，选择的发布任务类型。 约束限制： 不涉及 取值范围： CIRCULATION（“流通任务”） 默认取值： 不涉及
datasets	是	Array of DatasetInfo objects	参数解释： 发布任务的来源数据集信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
file_content_type	是	String	参数解释： 数据集中数据内容类型，用户在创建导入任务时选择的，或者在加工和发布任务运行时由系统自动生成的对应模式下的数据内容类型。 约束限制： 不涉及 取值范围： • SINGLE_QA（单轮问答） • SINGLE_QA_MAN（单轮问答人设） • MULTI_QA（多轮问答） • MULTI_QA_MAN（多轮问答人设） • QA_SORTING（问答排序） • PLAIN_TXT（文档） • WEB_PAGE（网页） • PRE_TRAINED_TEXT（预训练文本） • VIDEO（视频） • VIDEO_CLIP_ANNOTATION（视频剪辑标注） • VIDEO_UNDERSTANDING（视频理解） • TIME_SERIES_PREDICT（时序） • REGRESSION_CLASSIFICATION（回归分类） • IMAGE_AND_CAPTION（图片+Caption） • IMAGE_AND_QA（图片+QA对） • IMAGE_AND_CV_ANNOTATION（图片+CV标注） • IMAGE（仅图片） • IMAGE_OBJECT_DETECTION（物体检测） • OCEAN_WEATHER（气象） • CUSTOMIZATION（自定义）

参数	是否必选	参数类型	描述
			• IMAGE_CLASSIFICATION（图像分类） • IMAGE_ANOMALY_DETECTION（异常检测） • IMAGE_SEMANTIC_SEGMENTATION（语义分割） • IMAGE_POSE_ESTIMATION（姿态估计） • IMAGE_INSTANCE_SEGMENTATION（实例分割） • IMAGE_CHANGE_DETECTION（变化检测） • VIDEO_EVENT_DETECTION（事件检测） • VIDEO_CLASSIFICATION（视频分类） • DPO_QA（偏好优化DPO） • DPO_QA_MAN（偏好优化DPO人设） 默认取值： 不涉及
publish_name	是	String	参数解释： 创建发布任务时，用户指定的发布数据集的名称。 约束限制： 不涉及 取值范围： 数据集名称以中文、字母开头，以中文、字母、数字结尾，长度2~63字符，只允许输入中文、字母、数字、中划线、下划线等字符。 默认取值： 不涉及

参数	是否必选	参数类型	描述
description	否	String	参数解释： 用户创建发布任务时，指定的发布数据集的描述信息。 约束限制： 不超过100个字符 取值范围： 不涉及 默认取值： 不涉及
video_config	否	VideoConfig Dto object	参数解释： 视频数据集发布设置，仅发布视频类数据集时需要填写。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
pangu_config	否	PanguPublish ConfigDto object	参数解释： 盘古训练空间发布设置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_global	否	Boolean	参数解释： 数据集是否在该租户的全空间可见。 约束限制： 不涉及 取值范围： true: 数据集在该租户的全空间可见 false: 数据集仅在该租户创建发布任务所在的空间可见 默认取值： false

参数	是否必选	参数类型	描述
usage	否	String	参数解释： 用户在创建发布任务时，选择的系统定义的发布数据集的目标系统。 约束限制： 不涉及 取值范围： SPACE_ASSET（“空间资产”） 默认取值： 不涉及
v_cpu	否	Double	参数解释： 用户在创建发布任务时，指定的任务运行资源。 约束限制 仅图片多模态和预训练文本类型的数据集的发布任务需要指定。 取值范围： 最小值为0，最大值为用户在平台配置页面设置的mrs资源的vcpu上限 默认取值： 不涉及
tag_info	否	TagInfoVo object	参数解释： 生成的发布数据集的标签属性。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
publish_format	否	String	参数解释： 用户在创建数据集发布任务时指定的文件内容格式类型。 约束限制： 盘古格式和自定义格式可以被盘古模型训练任务选择。 取值范围： DEFAULT（标准格式） PANGU（盘古格式） USER_DEFINED（自定义格式） 默认取值： 不涉及
ud_py_path	否	String	参数解释： 在创建数据发布任务时，用户选择的Python脚本所在OBS路径，用户可以通过该脚本做发布的文本数据的内容格式转换操作，用于平台预置文本内容格式类型到自定义数据格式类型的转换。 约束限制： 预训练文本、单轮问答、单轮问答（人设）、多轮问答、多轮问答（人设）、问答排序、偏好优化DPO、偏好优化DPO（人设）支持自定义文件格式发布。 取值范围： 不涉及 默认取值： 不涉及
train_proportion	否	Double	参数解释： 用户在创建发布任务时，指定的训练集占数据记录条数的比例。 约束限制 物体检测、图像分类、异常检测、语义分割、实例分割、变化检测数据集支持该字段。 取值范围： 0-1 默认取值： 1

表 3-693 DatasetInfo

参数	是否必选	参数类型	描述
dataset_id	否	String	参数解释： 用户创建数据集时，返回的由系统生成的数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_name	是	String	参数解释： 数据集名称，由用户在创建数据集时填写的名称。 约束限制： 以中文、字母开头，以中文、字母、数字结尾，长度为2~63的字符。只允许输入中文、字母、数字、中划线、下划线字符。 取值范围： 数据集名称字符长度不超过128 默认取值： 不涉及
catalog	是	String	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： • ORIGINAL(执行数据导入产生的数据集类型) • PROCESS(执行数据加工产生的数据集类型) • PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及

表 3-694 VideoConfigDto

参数	是否必选	参数类型	描述
video_annotation	否	VideoAnnotationDto object	参数解释： 视频标注过滤请求体。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-695 VideoAnnotationDto

参数	是否必选	参数类型	描述
video_resolution_ratio	否	Array of integers	参数解释： 视频分辨率。 约束限制： 不涉及 取值范围： 0：低质(<360) 1：流畅(480>分辨率≥360) 2：标清(720>分辨率≥480) 3：高清(1080>分辨率≥720) 4：超清(3896>分辨率≥1080) 5：4K(≥ 3896) 可多选。 默认取值： 不涉及
video_duration	否	FloatRangeDto object	参数解释： 视频时长区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
video_frame_rate	否	FloatRangeDto object	参数解释： 视频帧率区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
video_optical	否	FloatRangeDto object	参数解释： 运动幅度估计区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
video_politics	否	FloatRangeDto object	参数解释： 视频政治人物打分区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
video_porn	否	FloatRangeDto object	参数解释： 视频鉴黄打分区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
video_terrorism	否	FloatRangeDto object	参数解释： 视频暴恐打分区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
video_subtitle	否	Array of integers	参数解释： 有无字幕，0—无字幕，1—有字幕，可多选。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及
video_logo	否	Array of integers	参数解释： 有无logo，0—无logo，1—有logo，可多选。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及
video_watermark	否	Array of integers	参数解释： 有无水印，0—无水印，1—有水印，可多选。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及

参数	是否必选	参数类型	描述
video_dense_text	否	Array of integers	参数解释： 密集文字检测，0无，1有，可多选。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及
video_aesthetic	否	FloatRangeDto object	参数解释： 美学评分区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
video_quality	否	Array of integers	参数解释： 对视频质量进行人工评价，0-低 1-中 2-高，可多选。 约束限制： 不涉及 取值范围： 0-2 默认取值： 不涉及
video_base_quality	否	FloatRangeDto object	参数解释： 质量基础评区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
video_base_tag	否	Array of strings	参数解释： 视频内容标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
video_border	否	Array of integers	参数解释： 有黑边，0—无黑边，1—有黑边，可多选。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及

表 3-696 FloatRangeDto

参数	是否必选	参数类型	描述
min	否	Float	参数解释： 浮点数区间最小值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max	否	Float	参数解释： 浮点数区间最大值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-697 PanguPublishConfigDto

参数	是否必选	参数类型	描述
data_usage	否	String	参数解释： 用户在创建多模态图片发布任务时，选择的数据使用场景。 约束限制： 只有在数据集类型为IMAGE_QA或者IMAGE_CAPTION时生效。 取值范围： TRAINING（"训练"） EVALUATION（"评测"） 默认取值： 不涉及

表 3-698 TagInfoVo

参数	是否必选	参数类型	描述
language	否	String	参数解释： 由系统内部定义的，在用户创建数据集时选择的语言类型。 约束限制： 不涉及 取值范围： CHINESE：中文 ENGLISH：英文 ARABIC：阿语 SPANISH：西语 FRENCH：法语 NONE：未设置 默认取值： 不涉及

参数	是否必选	参数类型	描述
industry	否	String	参数解释： 由系统内部定义，用户选择的行业类型，可在数据详情内查看。 约束限制： 不涉及 取值范围： GENERAL：通用、 GOVERNMENT：政务、 FINANCE：金融、 MEDICAL：医疗、 LAW：法律、 AUTOMOBILE：汽车、 COAL_MINE：煤矿、 MILITARY：军事、 TAXATION：税务、 EDUCATION：教育、 COMPUTER：计算机、 INTERNET：互联网、 RETAIL：零售、 FOOD：食品、 ENERGY：能源、 MEDIA：传媒、 INDUSTRY_AND_COMMERCE：工商、 TRANSPORTATION：运输、 E_COMMERCE：电商、 MANUFACTURING：制造、 NONE：不设置 默认取值： NONE

参数	是否必选	参数类型	描述
simple_tag	否	Array of strings	参数解释： 由用户填写的数据集的自定义标签。 约束限制： 单个标签长度为64字节，1个中文字符为3个字节，最多100个标签。 取值范围： 只允许输入中文、字母、数字、中划线、下划线字符。 默认取值： 不涉及

响应参数

状态码：200

表 3-699 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 发布数据集作业的实例id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：500

表 3-700 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

创建数据发布任务

示例URL v1/f0666bc5e820461dac713be6ef1a1d0f/workspaces/5796ca0c-4377-11ef-9eef-0255ac1000aa/data-publish/jobs

```
{
  "job_type": "CIRCULATION",
  "publish_name": "single-ann-zhu-1722325947202",
  "description": null,
  "is_global": false,
  "file_content_type": "SINGLE_QA",
  "datasets": [ {
    "dataset_name": "single-ann-zhu",
    "catalog": "ORIGINAL"
  } ]
}
```

响应示例

状态码：200

成功响应示例

```
{
  "id": "006fb43943044b2388b7003eb6b2a302"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.7 创建数据发布任务 v2

功能介绍

用户可以使用该接口创建数据发布任务。

相比于[创建数据发布任务v1](#)接口，削减了请求参数量。

URI

POST /v2/{project_id}/workspaces/{workspace_id}/data-publish/jobs

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-701 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-702 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-703 请求 Body 参数

参数	是否必选	参数类型	描述
type	是	String	参数解释： 用户在创建发布任务时，选择的发布任务类型。 约束限制： 不涉及 取值范围： CIRCULATION (“流通任务”) 默认取值： 不涉及
source_dataset	是	Array of DatasetInfoV2 objects	参数解释： 发布任务的来源数据集信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
file_content_type	是	String	参数解释： 数据集中数据内容类型，用户在创建导入任务时选择的，或者在加工和发布任务运行时由系统自动生成的对应模式下的数据内容类型。 约束限制： 不涉及 取值范围： • SINGLE_QA（单轮问答） • SINGLE_QA_MAN（单轮问答人设） • MULTI_QA（多轮问答） • MULTI_QA_MAN（多轮问答人设） • QA_SORTING（问答排序） • PLAIN_TXT（文档） • WEB_PAGE（网页） • PRE_TRAINED_TEXT（预训练文本） • VIDEO（视频） • VIDEO_CLIP_ANNOTATION（视频剪辑标注） • VIDEO_UNDERSTANDING（视频理解） • TIME_SERIES_PREDICT（时序） • REGRESSION_CLASSIFICATION（回归分类） • IMAGE_AND_CAPTION（图片+Caption） • IMAGE_AND_QA（图片+QA对） • IMAGE_AND_CV_ANNOTATION（图片+CV标注） • IMAGE（仅图片） • IMAGE_OBJECT_DETECTION（物体检测） • OCEAN_WEATHER（气象） • CUSTOMIZATION（自定义）

参数	是否必选	参数类型	描述
			• IMAGE_CLASSIFICATION（图像分类） • IMAGE_ANOMALY_DETECTION（异常检测） • IMAGE_SEMANTIC_SEGMENTATION（语义分割） • IMAGE_POSE_ESTIMATION（姿态估计） • IMAGE_INSTANCE_SEGMENTATION（实例分割） • IMAGE_CHANGE_DETECTION（变化检测） • VIDEO_EVENT_DETECTION（事件检测） • VIDEO_CLASSIFICATION（视频分类） • DPO_QA（偏好优化DPO） • DPO_QA_MAN（偏好优化DPO人设） 默认取值： 不涉及
publish_data_set	是	Array of PublishDataset objects	参数解释： 创建发布任务时，用户指定的发布数据集的信息。 约束限制： 不涉及 取值范围： 不涉及。 默认取值： 不涉及
video_config	否	VideoConfigDto object	参数解释： 视频数据集发布设置，仅发布视频类数据集时需要填写。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
v_cpu	否	Double	参数解释： 用户在创建发布任务时，指定的任务运行资源。 约束限制 仅图片多模态和预训练文本类型的数据集的发布任务需要指定。 取值范围： 最小值为0，最大值为用户在平台配置页面设置的mrs资源的vcpu上限 默认取值： 不涉及
ud_py_path	否	String	参数解释： 在创建数据发布任务时，用户选择的Python脚本所在OBS路径，用户可以通过该脚本做发布的文本数据的内容格式转换操作，用于平台预置文本内容格式类型到自定义数据格式类型的转换。 约束限制： 预训练文本、单轮问答、单轮问答（人设）、多轮问答、多轮问答（人设）、问答排序、偏好优化DPO、偏好优化DPO（人设）支持自定义文件格式发布。 取值范围： 不涉及 默认取值： 不涉及
train_proportion	否	Double	参数解释： 用户在创建发布任务时，指定的训练集占数据记录条数的比例。 约束限制 物体检测、图像分类、异常检测、语义分割、实例分割、变化检测数据集支持该字段。 取值范围： 0-1 默认取值： 1

参数	是否必选	参数类型	描述
resource_config	否	String	参数解释： 用户在创建发布任务时，配置的任务执行的资源参数。 约束限制 预训练文本，图片+Caption、图片 + QA对、多模态理解类数据集支持该字段。 取值范围： 不涉及 默认取值： 不涉及

表 3-704 DatasetInfoV2

参数	是否必选	参数类型	描述
id	否	String	参数解释： 用户创建数据集时，返回的由系统生成的数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
name	是	String	参数解释： 数据集名称，由用户在创建数据集时填写的名称。 约束限制： 以中文、字母开头，以中文、字母、数字结尾，长度为2~63的字符。只允许输入中文、字母、数字、中划线、下划线字符。 取值范围： 数据集名称字符长度不超过128 默认取值： 不涉及

参数	是否必选	参数类型	描述
catalog	是	String	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： • ORIGINAL(执行数据导入产生的数据集类型) • PROCESS(执行数据加工产生的数据集类型) • PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及

表 3-705 PublishDataset

参数	是否必选	参数类型	描述
name	是	String	参数解释： 创建发布任务时，用户指定的发布数据集的名称。 约束限制： 不涉及 取值范围： 数据集名称以中文、字母开头，以中文、字母、数字结尾，长度 2~63 字符，只允许输入中文、字母、数字、中划线、下划线等字符。 默认取值： 不涉及

参数	是否必选	参数类型	描述
description	否	String	参数解释： 用户创建发布任务时，指定的发布数据集的描述信息。 约束限制： 不超过100个字符 取值范围： 不涉及 默认取值： 不涉及
publish_format	否	String	参数解释： 用户在创建数据集发布任务时指定的文件内容格式类型。 约束限制： 盘古格式和自定义格式可以被盘古模型训练任务选择。 取值范围： DEFAULT（标准格式） PANGU（盘古格式） USER_DEFINED（自定义格式） 默认取值： 不涉及
is_global	否	Boolean	参数解释： 数据集是否在该租户的全空间可见。 约束限制： 不涉及 取值范围： true：数据集在该租户的全空间可见 false：数据集仅在该租户创建发布任务所在的空间可见 默认取值： false

参数	是否必选	参数类型	描述
tag_info	否	TagInfoVo object	参数解释： 生成的发布数据集的标签属性。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-706 TagInfoVo

参数	是否必选	参数类型	描述
language	否	String	参数解释： 由系统内部定义的，在用户创建数据集时选择的语言类型。 约束限制： 不涉及 取值范围： CHINESE：中文 ENGLISH：英文 ARABIC：阿语 SPANISH：西语 FRENCH：法语 NONE：未设置 默认取值： 不涉及

参数	是否必选	参数类型	描述
industry	否	String	参数解释： 由系统内部定义，用户选择的行业类型，可在数据详情内查看。 约束限制： 不涉及 取值范围： GENERAL：通用、 GOVERNMENT：政务、 FINANCE：金融、 MEDICAL：医疗、 LAW：法律、 AUTOMOBILE：汽车、 COAL_MINE：煤矿、 MILITARY：军事、 TAXATION：税务、 EDUCATION：教育、 COMPUTER：计算机、 INTERNET：互联网、 RETAIL：零售、 FOOD：食品、 ENERGY：能源、 MEDIA：传媒、 INDUSTRY_AND_COMMERCE：工商、 TRANSPORTATION：运输、 E_COMMERCE：电商、 MANUFACTURING：制造、 NONE：不设置 默认取值： NONE

参数	是否必选	参数类型	描述
simple_tag	否	Array of strings	参数解释： 由用户填写的数据集的自定义标签。 约束限制： 单个标签长度为64字节，1个中文字符为3个字节，最多100个标签。 取值范围： 只允许输入中文、字母、数字、中划线、下划线字符。 默认取值： 不涉及

表 3-707 VideoConfigDto

参数	是否必选	参数类型	描述
video_annotation	否	VideoAnnotationDto object	参数解释： 视频标注过滤请求体。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-708 VideoAnnotationDto

参数	是否必选	参数类型	描述
video_resolution_ratio	否	Array of integers	参数解释： 视频分辨率。 约束限制： 不涉及 取值范围： 0：低质(<360) 1：流畅(480>分辨率≥360) 2：标清(720>分辨率≥480) 3：高清(1080>分辨率≥720) 4：超清(3896>分辨率≥1080) 5：4K(≥ 3896) 可多选。 默认取值： 不涉及
video_duration	否	FloatRangeDto object	参数解释： 视频时长区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
video_frame_rate	否	FloatRangeDto object	参数解释： 视频帧率区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
video_optical	否	FloatRangeD to object	参数解释： 运动幅度估计区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
video_politics	否	FloatRangeD to object	参数解释： 视频政治人物打分区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
video_porn	否	FloatRangeD to object	参数解释： 视频鉴黄打分区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
video_terroris m	否	FloatRangeD to object	参数解释： 视频暴恐打分区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
video_subtitle	否	Array of integers	参数解释： 有无字幕，0—无字幕，1—有字幕，可多选。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及
video_logo	否	Array of integers	参数解释： 有无logo，0—无logo，1—有logo，可多选。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及
video_watermark	否	Array of integers	参数解释： 有无水印，0—无水印，1—有水印，可多选。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及
video_dense_text	否	Array of integers	参数解释： 密集文字检测，0无，1有，可多选。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及

参数	是否必选	参数类型	描述
video_aesthetic	否	FloatRangeDto object	参数解释： 美学评分区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
video_quality	否	Array of integers	参数解释： 对视频质量进行人工评价，0-低 1-中 2-高，可多选。 约束限制： 不涉及 取值范围： 0-2 默认取值： 不涉及
video_base_quality	否	FloatRangeDto object	参数解释： 质量基础评区间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
video_base_tag	否	Array of strings	参数解释： 视频内容标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
video_border	否	Array of integers	参数解释： 有黑边，0—无黑边，1—有黑边，可多选。 约束限制： 不涉及 取值范围： 0-1 默认取值： 不涉及

表 3-709 FloatRangeDto

参数	是否必选	参数类型	描述
min	否	Float	参数解释： 浮点数区间最小值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max	否	Float	参数解释： 浮点数区间最大值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-710 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 发布数据集作业的实例id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：500

表 3-711 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误信息。

请求示例

创建数据发布任务

```
示例URL /v2/f0666bc5e820461dac713be6ef1a1d0f/workspaces/5796ca0c-4377-11ef-9eef-0255ac1000aa/  
data-publish/jobs  
  
{  
  "type": "CIRCULATION",  
  "file_content_type": "SINGLE_QA",  
  "source_dataset": {  
    "id": "1438613788462026752VW5TYWZISW50ZWdlcg==",  
    "catalog": "ORIGINAL",  
    "name": "single-ann-zhu"  
  },  
  "publish_dataset": {  
    "name": "pub_20251117_1234",  
    "description": null,  
    "is_global": false  
  }  
}
```

响应示例

状态码：200

成功响应示例

```
{  
  "id": "006fb43943044b2388b7003eb6b2a302"  
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.8 删除导入任务

功能介绍

删除导入任务，该删除操作为软删除，仅修改标记位，不删除数据库对应数据，可通过恢复导入任务接口恢复。

URI

DELETE /v1/{project_id}/workspaces/{workspace_id}/data-extraction/import-jobs
接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-712 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-713 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-714 请求 Body 参数

参数	是否必选	参数类型	描述
ids	是	Array of strings	参数解释： 导入任务id数组，任务id可以从创建数据导入任务接口响应体中id字段获取。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
force_delete	否	Boolean	参数解释： 是否彻底删除数据导入任务。 约束限制： 针对彻底删除的数据导入任务无法被恢复。 取值范围： true（彻底删除） false（非彻底删除，可通过恢复数据导入任务接口恢复该任务） 默认取值： false

响应参数

状态码：500

表 3-715 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

无

响应示例

无

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.9 创建数据导入任务

功能介绍

创建数据导入任务，可以选择单一文件或单一目录，部分数据类型支持自定义开源数据集导入，需同步上传转换脚本。

支持自定义开源数据集导入的数据类型包括预训练文本、单轮问答、单轮问答（人设）、多轮问答、多轮问答（人设）、问答排序、偏好优化DPO、偏好优化DPO（人设）。

URI

POST /v1/{project_id}/workspaces/{workspace_id}/data-extraction/import-jobs

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-716 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-717 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-718 请求 Body 参数

参数	是否必选	参数类型	描述
name	是	String	参数解释： 数据集名称，创建导入任务前端页面自动带出或用户手动编辑的数据集名称。 约束限制： 长度2~63字符 取值范围： 数据集名称以中文、字母开头，以中文、字母、数字结尾，只允许输入中文、字母、数字、中划线、下划线等字符。 默认取值： 不涉及

参数	是否必选	参数类型	描述
language	否	String	参数解释： 由系统内部定义的，在用户创建数据集时选择的语言类型。 约束限制： 不涉及 取值范围： CHINESE：中文 ENGLISH：英文 ARABIC：阿语 SPANISH：西语 FRENCH：法语 NONE：未设置 默认取值： 不涉及
is_capsule_en encryption	否	Boolean	参数解释： 用户在创建数据导入任务时解析的文件加密类型，该功能受限使用，需要配合tics服务使用。 约束限制： 不涉及 取值范围： true（明文数据） false（胶囊加密数据） 默认取值： false
is_global	否	Boolean	参数解释： 数据集是否所有空间可见。 约束限制： 不涉及 取值范围： true/false 默认取值： 不涉及

参数	是否必选	参数类型	描述
industry	否	String	参数解释： 由系统内部定义，用户选择的行业类型，可在数据详情内查看。 约束限制： 不涉及 取值范围： GENERAL：通用、 GOVERNMENT：政务、 FINANCE：金融、 MEDICAL：医疗、 LAW：法律、 AUTOMOBILE：汽车、 COAL_MINE：煤矿、 MILITARY：军事、 TAXATION：税务、 EDUCATION：教育、 COMPUTER：计算机、 INTERNET：互联网、 RETAIL：零售、 FOOD：食品、 ENERGY：能源、 MEDIA：传媒、 INDUSTRY_AND_COMMERCE：工商、 TRANSPORTATION：运输、 E_COMMERCE：电商、 MANUFACTURING：制造、 NONE：不设置 默认取值： NONE

参数	是否必选	参数类型	描述
simple_tag	否	Array of strings	参数解释： 由用户填写的数据集的自定义标签。 约束限制： 单个标签长度为64字节，1个中文字符为3个字节，最多100个标签。 取值范围： 只允许输入中文、字母、数字、中划线、下划线字符。 默认取值： 不涉及

参数	是否必选	参数类型	描述
file_format	否	String	参数解释： 文件格式，由用户创建数据导入任务时选择的数据文件格式类型。 约束限制： 不涉及 取值范围： • JSONL（后缀为jsonl的文件格式） • TXT（后缀为txt的文件格式） • CSV（后缀为csv的文件格式） • HTML（后缀为html的文件格式） • MOBI（后缀为mobi的文件格式） • EPUB（后缀为epub的文件格式） • DOCX（后缀为docx的文件格式） • PDF（后缀为pdf的文件格式） • MP4（后缀为mp4的文件格式） • AVI（后缀为avi的文件格式） • AVI_MP4（后缀为avi/mp4的文件格式） • JPGS_JSONL（后缀为jsonl, json, tar的文件格式） • JPG_TXT（cv数据类型，图片格式：JPG，标注文件格式：txt） • JPEG_TXT（cv数据类型，图片格式：JPEG，标注文件格式：txt） • PNG_TXT（cv数据类型，图片格式：PNG，标注文件格式：txt） • BMP_TXT（cv数据类型，图片格式：BMP，标注文件格式：txt）

参数	是否必选	参数类型	描述
			• JPG_XML（后缀为xml, jpg, jpeg, png, bmp, manifest的文件格式） • JPEG_XML（cv数据类型，图片格式：JPEG，标注文件格式：xml） • PNG_XML（cv数据类型，图片格式：PNG，标注文件格式：xml） • BMP_XML（cv数据类型，图片格式：BMP，标注文件格式：xml） • TAR（后缀为tar的文件格式） • IMAGE（后缀为jpg、jpeg、png、bmp的文件格式） • PASCAL（后缀为xml, jpg, jpeg, png, bmp的文件格式） • YOLO（后缀为yaml, txt, jpg, jpeg, png, bmp的文件格式） • IMAGE_JSON（图片+标注格式，图片格式：jpg、jpeg、png、bmp，标注文件格式：json） • IMAGE_PNG（后缀为jpg, png的文件格式） • IMAGE_TXT（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：txt） • IMAGE_XML（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：xml） • VIDEO_JSON（视频+标注格式，视频格式：mp4、avi，标注文件格式：json） • VIDEO_TXT（视频+txt格式，视频格式：mp4、avi，标注格式：txt） • USER_DEFINED（自定义） 默认取值：

参数	是否必选	参数类型	描述
			不涉及
file_source	是	String	参数解释： 创建数据导入任务时文件来源的分类。 约束限制： 不涉及 取值范围： • OBS（用户选择的自己的OBS桶路径） • LOCAL（用户选择的本地终端上的文件目录） • GALLERY（用户从Alhub上订阅的数据集） 默认取值： 不涉及

参数	是否必选	参数类型	描述
content_type	是	String	参数解释： 数据集中数据内容类型，用户在创建导入任务时选择的，或者在加工和发布任务运行时由系统自动生成的对应模式下的数据内容类型。 约束限制： 不涉及 取值范围： • SINGLE_QA（单轮问答） • SINGLE_QA_MAN（单轮问答人设） • MULTI_QA（多轮问答） • MULTI_QA_MAN（多轮问答人设） • QA_SORTING（问答排序） • PLAIN_TXT（文档） • WEB_PAGE（网页） • PRE_TRAINED_TEXT（预训练文本） • VIDEO（视频） • VIDEO_CLIP_ANNOTATION（视频剪辑标注） • VIDEO_UNDERSTANDING（视频理解） • TIME_SERIES_PREDICT（时序） • REGRESSION_CLASSIFICATION（回归分类） • IMAGE_AND_CAPTION（图片+Caption） • IMAGE_AND_QA（图片+QA对） • IMAGE_AND_CV_ANNOTATION（图片+CV标注） • IMAGE（仅图片） • IMAGE_OBJECT_DETECTION（物体检测） • OCEAN_WEATHER（气象） • CUSTOMIZATION（自定义）

参数	是否必选	参数类型	描述
			• IMAGE_CLASSIFICATION（图像分类） • IMAGE_ANOMALY_DETECTION（异常检测） • IMAGE_SEMANTIC_SEGMENTATION（语义分割） • IMAGE_POSE_ESTIMATION（姿态估计） • IMAGE_INSTANCE_SEGMENTATION（实例分割） • IMAGE_CHANGE_DETECTION（变化检测） • VIDEO_EVENT_DETECTION（事件检测） • VIDEO_CLASSIFICATION（视频分类） • DPO_QA（偏好优化DPO） • DPO_QA_MAN（偏好优化DPO人设） 默认取值： 不涉及
obs_path	是	String	参数解释： 导入来源为OBS时：该路径表示客户自己设置的OBS桶路径。 导入来源为LOCAL时：该路径为客户从数据工程上传文件后服务自动生成的OBS桶路径，客户可以从数据集详情页面获取该路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
desc	否	String	参数解释： 用户创建数据导入任务时由用户自定义填写的数据集描述信息。 约束限制： 0-100个字符 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
data_copyright	否	String	参数解释： 由用户填写的数据版权内容，包括： 初始数据集名称 样例： 1、Antreas/TALI 2、weitianwen/cmath 初始数据集来源名称 样例： 1、Antreas/TALI 2、weitianwen/cmath 初始数据集版本号 样例： V2 初始数据集许可证 样例： V2 初始数据集授权人信息 样例： @misc{wei2023cmath, title={CMATH: Can Your Language Model Pass Chinese Elementary School Math Test?}, author={Tianwen Wei and Jian Luan and Wei Liu and Shuang Dong and Bin Wang}, year={2023}, eprint={2306.16636}, archivePrefix={arXiv}, primaryClass={cs.CL} } 初始数据集许可证文本地址 样例： https://huggingface.co/datasets/choosealicense/licenses/blob/main/markdown/cc-by-4.0.md 初始数据集下载地址 样例：

参数	是否必选	参数类型	描述
			1、https://huggingface.co/datasets/Antreas/TALI 2、https://huggingface.co/datasets/weitianwen/cmath 用户可在创建数据集或通过更新数据集详情接口修改 约束限制： 不涉及 取值范围： 不涉及 默认取值： null
ud_py_path	否	String	参数解释： 在创建数据导入任务时，用户选择的Python脚本所在OBS路径，用户可以通过该脚本做导入的文本数据的内容格式转换操作，用于自定义数据格式类型到平台预置文本内容格式类型的转换。 约束限制： 预训练文本、单轮问答、单轮问答（人设）、多轮问答、多轮问答（人设）、问答排序、偏好优化DPO、偏好优化DPO（人设）支持自定义文件格式导入。 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-719 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 导入任务id，用户创建数据导入任务时由系统生成的导入任务id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
name	String	参数解释： 数据集名，导入任务生成数据集名称，对应创建导入任务页面的数据集名称，可由用户自定义，可由系统自动带出。 约束限制： 不涉及 取值范围： 数据集名称以中文、字母开头，以中文、字母、数字结尾，长度2~63字符，只允许输入中文、字母、数字、中划线、下划线等字符。 默认取值： null
desc	String	参数解释： 描述信息，对应创建导入任务页面的描述，选填。 约束限制： 不涉及 取值范围： 不涉及 默认取值： “ ”

参数	参数类型	描述
status	String	参数解释： 数据集导入任务的运行状态。 约束限制： 不涉及 取值范围： RUNNING（运行中） SUCCESS（成功） FAILED（失败） STOPPED（已停止） STOPPING（停止中） 默认取值： 不涉及
update_time	String	参数解释： 导入任务信息更新时间，用户进行创建、停止、删除、恢复操作时会更新该字段。 约束限制： 数据格式：YYYY-MM-DD HH:mm:ss 取值范围： 不涉及 默认取值： 不涉及
update_time_stamp	Long	参数解释： 导入任务信息更新时间，用户在操作创建、停止、删除、恢复导入任务时产生的时间，格式为绝对秒数，示例：1722332141000。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time	String	参数解释： 创建导入任务时间，用户在操作创建数据导入任务时产生的时间。 约束限制： 格式为yyyy-MM-dd HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
create_time_stamp	Long	参数解释： 数据导入任务创建时间，时间戳，用户在操作创建数据导入任务时产生的时间，格式为绝对秒数，示例：1722332141000。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
file_format	String	参数解释： 文件格式，由用户创建数据导入任务时选择的数据文件格式类型。 约束限制： 取值范围： • JSONL（后缀为jsonl的文件格式） • TXT（后缀为txt的文件格式） • CSV（后缀为csv的文件格式） • HTML（后缀为html的文件格式） • MOBI（后缀为mobi的文件格式） • EPUB（后缀为epub的文件格式） • DOCX（后缀为docx的文件格式） • PDF（后缀为pdf的文件格式） • MP4（后缀为mp4的文件格式） • AVI（后缀为avi的文件格式） • AVI_MP4（后缀为avi/mp4的文件格式） • JPGS_JSONL（后缀为jsonl, json, tar的文件格式） • JPG_TXT（cv数据类型，图片格式：JPG，标注文件格式：txt） • JPEG_TXT（cv数据类型，图片格式：JPEG，标注文件格式：txt） • PNG_TXT（cv数据类型，图片格式：PNG，标注文件格式：txt） • BMP_TXT（cv数据类型，图片格式：BMP，标注文件格式：txt） • JPG_XML（后缀为xml, jpg, jpeg, png, bmp, manifest的文件格式） • JPEG_XML（cv数据类型，图片格式：JPEG，标注文件格式：xml） • PNG_XML（cv数据类型，图片格式：PNG，标注文件格式：xml） • BMP_XML（cv数据类型，图片格式：BMP，标注文件格式：xml） • TAR（后缀为tar的文件格式） • IMAGE（后缀为jpg、jpeg、png、bmp的文件格式） • PASCAL（后缀为xml, jpg, jpeg, png, bmp的文件格式）

参数	参数类型	描述
		- YOLO（后缀为yaml, txt, jpg, jpeg, png, bmp的文件格式） - IMAGE_JSON（图片+标注格式，图片格式：jpg、jpeg、png、bmp，标注文件格式：json） - IMAGE_PNG（后缀为jpg, png的文件格式） - IMAGE_TXT（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：txt） - IMAGE_XML（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：xml） - VIDEO_JSON（视频+标注格式，视频格式：mp4、avi，标注文件格式：json） - VIDEO_TXT（视频+txt格式，视频格式：mp4、avi，标注格式：txt） - USER_DEFINED（自定义） 默认取值： 不涉及
file_source	String	参数解释： 创建数据导入任务时文件来源的分类。 约束限制： 不涉及 取值范围： - OBS（用户选择的自己的OBS桶路径） - LOCAL（用户选择的本地终端上的文件目录） - GALLERY（用户从Alhub上订阅的数据集） 默认取值： 不涉及

参数	参数类型	描述
content_type	String	参数解释： 数据集中数据内容类型，用户在创建导入任务时选择的，或者在加工和发布任务运行时由系统自动生成的对应模态下的数据内容类型。 约束限制： 不涉及 取值范围： • SINGLE_QA（单轮问答） • SINGLE_QA_MAN（单轮问答人设） • MULTI_QA（多轮问答） • MULTI_QA_MAN（多轮问答人设） • QA_SORTING（问答排序） • PLAIN_TXT（文档） • WEB_PAGE（网页） • PRE_TRAINED_TEXT（预训练文本） • VIDEO（视频） • VIDEO_CLIP_ANNOTATION（视频剪辑标注） • VIDEO_UNDERSTANDING（视频理解） • TIME_SERIES_PREDICT（时序） • REGRESSION_CLASSIFICATION（回归分类） • IMAGE_AND_CAPTION（图片+Caption） • IMAGE_AND_QA（图片+QA对） • IMAGE_AND_CV_ANNOTATION（图片+CV标注） • IMAGE（仅图片） • IMAGE_OBJECT_DETECTION（物体检测） • OCEAN_WEATHER（气象） • CUSTOMIZATION（自定义） • IMAGE_CLASSIFICATION（图像分类） • IMAGE_ANOMALY_DETECTION（异常检测） • IMAGE_SEMANTIC_SEGMENTATION（语义分割）

参数	参数类型	描述
		• IMAGE_POSE_ESTIMATION（姿态估计） • IMAGE_INSTANCE_SEGMENTATION（实例分割） • IMAGE_CHANGE_DETECTION（变化检测） • VIDEO_EVENT_DETECTION（事件检测） • VIDEO_CLASSIFICATION（视频分类） • DPO_QA（偏好优化DPO） • DPO_QA_MAN（偏好优化DPO人设） 默认取值： 不涉及
language	String	参数解释： 由系统内部定义的，在用户创建数据集时选择的语言类型。 约束限制： 不涉及 取值范围： CHINESE：中文 ENGLISH：英文 ARABIC：阿语 SPANISH：西语 FRENCH：法语 NONE：未设置 默认取值： 不涉及

参数	参数类型	描述
industry	String	参数解释： 由系统内部定义，用户选择的行业类型，可在数据详情内查看。 约束限制： 不涉及 取值范围： GENERAL：通用、 GOVERNMENT：政务、 FINANCE：金融、 MEDICAL：医疗、 LAW：法律、 AUTOMOBILE：汽车、 COAL_MINE：煤矿、 MILITARY：军事、 TAXATION：税务、 EDUCATION：教育、 COMPUTER：计算机、 INTERNET：互联网、 RETAIL：零售、 FOOD：食品、 ENERGY：能源、 MEDIA：传媒、 INDUSTRY_AND_COMMERCE：工商、 TRANSPORTATION：运输、 E_COMMERCE：电商、 MANUFACTURING：制造、 NONE：不设置 默认取值： NONE
size	Long	参数解释： 数据集导入成功后由系统自动统计的数据集大小，单位为Byte。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0

参数	参数类型	描述
file_num	Integer	参数解释： 数据集导入成功后由系统统计的数据集中数据目录下面的文件数量，在生成数据集时系统自动统计。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
record_num	Long	参数解释： 数据集中的数据条数，由数据导入任务自动统计的数据记录条数，csv格式按行统计记录条数（时序、回归分类表头不计入记录条数），JSONL格式按行统计记录条数，其他文件格式一个文件记作一条记录。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
user_name	String	参数解释： 创建数据导入任务时操作的用户账号名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
sample_path	String	参数解释： 用户创建数据导入任务时选择的原始数据所在的obs目录。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
ud_py_path	String	参数解释： 在创建数据导入任务时，用户选择的Python脚本所在OBS路径，用户可以通过该脚本做导入的文本数据的内容格式转换操作，用于自定义数据格式类型到平台预置文本内容格式类型的转换。 约束限制： 支持自定义文件格式导入的数据集类型包括预训练文本、单轮问答、单轮问答（人设）、多轮问答、多轮问答（人设）、问答排序、偏好优化DPO、偏好优化DPO（人设）。 取值范围： 不涉及 默认取值： 不涉及
is_capsule_encryption	Boolean	参数解释： 用户在创建数据导入任务时解析的文件加密类型。 约束限制： 该功能受限使用，需要配合tics服务使用。 取值范围： true（明文数据） false（胶囊加密数据） 默认取值： false
capsule	Capsule object	数据胶囊信息，包括加密方式、胶囊数据有效期起始及结束时间。

参数	参数类型	描述
simple_tag	Array of strings	参数解释： 由用户填写的数据集的自定义标签。 约束限制： 不涉及 取值范围： 只允许输入中文、字母、数字、中划线、下划线字符。 默认取值： 不涉及

参数	参数类型	描述
data_copyright	String	参数解释： 由用户填写的数据版权内容，包括： 初始数据集名称 样例： 1、Antreas/TALI 2、weitianwen/cmath 初始数据集来源名称 样例： 1、Antreas/TALI 2、weitianwen/cmath 初始数据集版本号 样例： V2 初始数据集许可证 样例： V2 初始数据集授权人信息 样例： @misc{wei2023cmath, title={CMATH: Can Your Language Model Pass Chinese Elementary School Math Test?}, author={Tianwen Wei and Jian Luan and Wei Liu and Shuang Dong and Bin Wang}, year={2023}, eprint={2306.16636}, archivePrefix={arXiv}, primaryClass={cs.CL} } 初始数据集许可证文本地址 样例： https://huggingface.co/datasets/choosealicense/licenses/blob/main/markdown/cc-by-4.0.md 初始数据集下载地址 样例： 1、https://huggingface.co/datasets/Antreas/TALI

参数	参数类型	描述
		2、 https://huggingface.co/datasets/weitianwen/cmath 用户可在创建数据集或通过更新数据集详情接口修改 约束限制: 不涉及 取值范围: 不涉及 默认取值: null
is_deleted	Boolean	参数解释: 用户删除数据导入任务时保存的删除状态。 约束限制: 不涉及 取值范围: true（删除状态，可通过恢复接口恢复数据导入任务） false（未删除状态） 默认取值: false
running_time	Long	参数解释: 数据导入任务从创建到运行结束所用时长（单位毫秒），结束状态包括成功和失败，示例：1722332141000000。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
last_operator	String	参数解释： 用户在操作数据导入、停止、删除、恢复时的操作账号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
last_operate_time	String	参数解释： 用户在最近一次操作数据导入、停止、删除、恢复的时间。 约束限制： 数据格式：YYYY-MM-DD HH:mm:ss 取值范围： 不涉及 默认取值： 不涉及

表 3-720 Capsule

参数	参数类型	描述
enc_mode	String	参数解释： 从导入数据胶囊数据时从数据元数据文件中解析的数据加密类型。 约束限制： 不涉及 取值范围： ROW（行级加密） FieldLevel（字段级加密） FileLevel（文件级加密） 默认取值： 不涉及

参数	参数类型	描述
valid_date_start	Long	参数解释： 从导入数据胶囊数据时从数据元数据文件中解析的胶囊数据有效起始时间。 约束限制： 绝对秒数 取值范围： 不涉及 默认取值： 不涉及
valid_date_end	Long	参数解释： 从导入数据胶囊数据时从数据元数据文件中解析的胶囊数据有效结束时间。 约束限制： 绝对秒数 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-721 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：500

表 3-722 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

创建预训练文本数据导入任务

```
{
  "name": "string",
  "file_source": "OBS",
  "content_type": "PRE_TRAINED_TEXT",
  "obs_path": "string"
}
```

响应示例

状态码：200

成功响应示例

```
{
  "id": "1358845763718877184",
  "name": "orig_20250407_92720",
  "desc": "",
  "status": "RUNNING",
  "version": null,
  "update_time": "2025-04-07 16:47:56",
  "update_time_stamp": null,
  "create_time": "2025-04-07 16:47:56",
  "create_time_stamp": null,
  "file_format": "JSONL",
  "file_source": "OBS",
  "content_type": "PRE_TRAINED_TEXT",
  "language": null,
  "industry": null,
  "size": null,
  "file_num": null,
  "record_num": null,
  "user_name": "user",
  "sample_path": "sample_path",
  "ud_py_path": "obs://null",
  "is_capsule_encryption": null,
  "capsule": {
    "enc_mode": null,
    "valid_date_start": null,
    "valid_date_end": null
  },
  "simple_tag": [ ],
  "data_copyright": "{ \"datasetName\": \"\", \"datasourceName\": \"\", \"datasetVersion\": \"\", \"datasetLicense\": \"\", \"datasetLicensor\": \"\", \"datasetLicenseUrl\": \"\", \"datasetUrl\": \"\" }",
  "is_deleted": false,
  "error_msg": null,
  "running_time": null,
  "last_operator": null,
  "last_operate_time": null,
  "target_column": null
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.10 彻底删除数据集

功能介绍

彻底删除数据集。

URI

POST /v1/{project_id}/workspaces/{workspace_id}/data-management/dataset/permanent-delete

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-723 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-724 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-725 请求 Body 参数

参数	是否必选	参数类型	描述
dataset_name	是	String	参数解释： 用户在创建数据集时填写的数据集名称。 约束限制： 不涉及 取值范围： 数据集名称以中文、字母开头，以中文、字母、数字结尾，长度2~63字符，只允许输入中文、字母、数字、中划线、下划线等字符。 默认取值： 不涉及

参数	是否必选	参数类型	描述
catalog	否	String	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： ORIGINAL(执行数据导入产生的数据集类型) PROCESS(执行数据加工产生的数据集类型) PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及
delete_obs	否	Boolean	参数解释： 是否彻底删除数据集的同时，删除obs内的源文件 约束限制： 不涉及 取值范围： TRUE（删除obs内的源文件） FALSE（不删除obs内的源文件） 默认取值： FALSE

响应参数

状态码：200

表 3-726 响应 Body 参数

参数	参数类型	描述
dataset_name	String	参数解释： 数据集名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
catalog	String	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： • ORIGINAL(执行数据导入产生的数据集类型) • PROCESS(执行数据加工产生的数据集类型) • PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及
result	Boolean	参数解释： 删除的结果。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：500

表 3-727 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

彻底删除执行数据导入产生的某一数据集

```
{
  "dataset_name": "数据集名称",
  "catalog": "ORIGINAL",
  "delete_obs": "true"
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "dataset_name": "qa073001",
  "catalog": "ORIGINAL",
  "result": true
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.11 查询 obs 路径关联的数据血缘

功能介绍

根据obs路径查询关联的数据血缘。
接口域名请参考[获取盘古服务外部API域名](#)获取。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/data-management/lineages

表 3-728 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-729 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-730 请求 query 参数

参数	是否必选	参数类型	描述
limit	是	Integer	参数解释： 接口返回的血缘数量上限。 约束限制： 数量限制为[1,1000] 取值范围： 最小值：1 最大值：1000 默认取值： 100
from_path	是	String	参数解释： 来源数据集的obs路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码： 200

表 3-731 响应 Body 参数

参数	参数类型	描述
LineageList	Array of 表 3-732 objects	参数解释： 数据集血缘列表，包括数据集、训练任务、模型资产、部署服务等。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-732 Lineage

参数	参数类型	描述
id	String	参数解释： 血缘ID，创建时传入无效。 约束限制： 不涉及 取值范围： [1, 128] 默认取值： 不涉及
from_id	String	参数解释： 血缘起点ID，数据集、训练任务、模型资产、部署服务等ID。 约束限制： from_type为OBS时，from_id为null。 取值范围： [0, 128] 默认取值： 不涉及

参数	参数类型	描述
from_name	String	参数解释： 血缘起点名称。 约束限制： 不涉及 取值范围： [1, 128] 默认取值： 不涉及
from_catalog	String	参数解释： 血缘起点数据集形态、如原始、加工、发布。 约束限制： from_type为DATASET时才不为null 取值范围： ● ORIGINAL：执行数据导入产生的数据集类型 ● PROCESS：执行数据加工产生的数据集类型 ● PUBLISH：执行数据发布产生的数据集类型 默认取值： 不涉及
from_type	String	参数解释： 血缘起点类型，包括OBS、数据集、训练任务、模型资产等。 约束限制： 不涉及 取值范围： ● OBS：来源于OBS ● DATASET：来源于数据集 ● MODEL：来源于训练任务 ● MODEL_ASSET：来源于模型资产 默认取值： 不涉及

参数	参数类型	描述
to_id	String	参数解释： 血缘终点ID，数据集、训练任务、模型资产、部署服务等ID。 约束限制： 不涉及 取值范围： [1, 128] 默认取值： 不涉及
to_name	String	参数解释： 血缘终点名称 约束限制： 不涉及 取值范围： [1, 128] 默认取值： 不涉及
to_catalog	String	参数解释： 血缘终点数据集形态、如原始、加工、发布。 约束限制： to_type为DATASET时才不为null 取值范围： ● ORIGINAL：执行数据导入产生的数据集类型 ● PROCESS：执行数据加工产生的数据集类型 ● PUBLISH：执行数据发布产生的数据集类型 默认取值： 不涉及

参数	参数类型	描述
to_type	String	参数解释： 血缘终点类型，包括数据集、训练任务、模型资产、部署服务等。 约束限制： 不涉及 取值范围： • DATASET：数据集 • MODEL：训练任务 • MODEL_ASSET：模型资产 • MODEL_SERVICE：部署服务 默认取值： 不涉及
process_id	String	参数解释： 来源任务的ID。 约束限制： 不涉及 取值范围： [1, 128] 默认取值： 不涉及
process_name	String	参数解释： 来源任务的名称。 约束限制： 不涉及 取值范围： [1, 128] 默认取值： 不涉及

参数	参数类型	描述
process_type	String	参数解释： 链路类型，包括数据发布、数据加工、模型训练等。 约束限制： 不涉及 取值范围： • PUBLISH：数据发布 • PROCESS：数据加工 • COMBINATION：数据配比 • MODEL_TRAIN：模型训练 • MODEL_PUBLISH：模型资产发布 • MODEL_DEPLOY：服务部署 默认取值： 不涉及
train_job_name	String	参数解释： 训练任务名称。 约束限制： to_type为MODEL时才不为null 取值范围： [1, 128] 默认取值： 不涉及
model_type	String	参数解释： 模型类型。 约束限制： to_type为MODEL时才不为null 取值范围： • NLP • CV • AI_SCIENCE • PREDICT • MM 默认取值： 不涉及

参数	参数类型	描述
train_type	String	参数解释： 训练类型。 约束限制： to_type为MODEL时才不为null 取值范围： • PRETRAIN • SFT • RLHF 默认取值： 不涉及
create_time	Integer	参数解释： 创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
from_path	String	参数解释： 原始数据集来源obs路径。 约束限制： from_type为OBS时才不为null 取值范围： 不涉及 默认取值： 不涉及
from_path_existed	Boolean	参数解释： 原始数据集来源obs路径是否存在。 约束限制： from_type为OBS时才不为null 取值范围： TRUE：原始数据集来源obs路径存在 FALSE：原始数据集来源obs路径不存在 默认取值： 不涉及

请求示例

```
{
  limit: 1
  from_path: obs://bukcetname/l30002274/datasetname
}
```

响应示例

状态码： 200

成功响应示例

```
{
  id: '126288639882704070'
  from_id: null
  from_name: capsule-test-data-01
  from_catalog: ORIGINAL
  from_type: DATASET
  to_id: null
  to_name: capsule-publish-data
  to_catalog: PUBLISH
  to_type: DATASET
  process_id: 1416ad5f93b4484594b812c05ded6234
  process_name: capsule-publish-data
  process_type: PUBLISH
  train_job_name: null
  model_type: null
  train_type: null
  create_time: 0
  from_path: obs://bukcetname/l30002274/datasetname
  from_path_existed: true
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.12 查询数据集详情 v2

功能介绍

用户可以调用接口查询所有类型及模态的数据集详情。

相比[查询数据集详情v1](#)，v2接口增加creator相关参数，表示创建该数据集的操作用户对应的账号名称信息。

接口域名请参考[获取盘古服务外部API域名](#)获取。

URI

GET /v2/{project_id}/workspaces/{workspace_id}/data-management/datasets/
{dataset_name}

表 3-733 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_name	是	String	参数解释： 数据集名称（按照数据集的名称进行查询）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-734 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-735 请求 query 参数

参数	是否必选	参数类型	描述
catalog	是	String	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： • ORIGINAL(执行数据导入产生的数据集类型) • PROCESS(执行数据加工产生的数据集类型) • PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及

响应参数

状态码： 200

表 3-736 响应 Body 参数列表

名称	类型	是否必选	描述
name	String	否	参数解释： 数据集名称，由用户在创建数据集时填写的名称。 约束限制： 长度为2~63的字符。 取值范围： 以中文、字母开头，以中文、字母、数字结尾，只允许输入中文、字母、数字、中划线、下划线字符。 默认取值： 不涉及

名称	类型	是否必选	描述
dataset_id	String	否	参数解释： 数据集id，创建数据集时系统自动生成的数据集的id的编号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_desc	String	否	参数解释： 数据集描述，用户创建数据集时填写的描述内容。 约束限制： 不超过100个字符 取值范围： 不涉及 默认取值： 不涉及
status	String	否	参数解释： 数据集的上下线状态，生成数据集的过程中是下线状态，生成成功之后是上线状态。 约束限制： 不涉及 取值范围： • ONLINE • OFFLINE 默认取值： 不涉及

名称	类型	是否必选	描述
catalog	String	否	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： • ORIGINAL(执行数据导入产生的数据集类型) • PROCESS(执行数据加工产生的数据集类型) • PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及
version	String	否	参数解释： 用户在生成数据集时系统自动生成的版本号。 约束限制： 当前不支持版本号更新。 取值范围： V1 默认取值： 不涉及
size	Long	否	参数解释： 数据集大小，生成数据集成功后系统根据数据目录中所有文件的大小累加统计得到，除了manifest文件，单位是Byte。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

名称	类型	是否必选	描述
record_num	Long	否	参数解释： 数据集中的数据条数：加工和发布任务运行成功后，由任务上报的数据结果条数，举例：nlp中csv和jsonl文件中一行一条数据，word文档中一个文档为一条数据，图片中一张图片为一条数据。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	否	参数解释： 数据集创建时间，用户在操作创建数据集时产生的时间。 约束限制： 格式为yyyy-MM-dd HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
create_time_stamp	Long	否	参数解释： 数据集创建时间，用户在操作创建数据集时产生的时间，示例：1722332141000。 约束限制： 格式为绝对秒数 取值范围： 不涉及 默认取值： 不涉及

名称	类型	是否必选	描述
update_time	String	否	参数解释： 数据集更新时间，用户在操作创建、更新、删除、恢复数据集时产生的时间。 约束限制： 格式为yyyy-MM-dd HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
update_time_stamp	Long	否	参数解释： 数据集更新时间，用户在操作创建、更新、删除、恢复数据集时产生的时间，示例：1722332141000。 约束限制： 格式为绝对秒数 取值范围： 不涉及 默认取值： 不涉及

名称	类型	是否必选	描述
file_format	String	否	参数解释： 文件格式，由用户创建数据导入任务时选择的数据文件格式类型。 约束限制： 取值范围： • JSONL（后缀为jsonl的文件格式） • TXT（后缀为txt的文件格式） • CSV（后缀为csv的文件格式） • HTML（后缀为html的文件格式） • MOBI（后缀为mobi的文件格式） • EPUB（后缀为epub的文件格式） • DOCX（后缀为docx的文件格式） • PDF（后缀为pdf的文件格式） • MP4（后缀为mp4的文件格式） • AVI（后缀为avi的文件格式） • AVI_MP4（后缀为avi/mp4的文件格式） • JPGS_JSONL（后缀为jsonl, json, tar 的文件格式） • JPG_TXT（cv数据类型，图片格式：JPG，标注文件格式：txt） • JPEG_TXT（cv数据类型，图片格式：JPEG，标注文件格式：txt） • PNG_TXT（cv数据类型，图片格式：PNG，标注文件格式：txt） • BMP_TXT（cv数据类型，图片格式：BMP，标注文件格式：txt） • JPG_XML（后缀为xml, jpg, jpeg, png, bmp, manifest的文件格式） • JPEG_XML（cv数据类型，图片格式：JPEG，标注文件格式：xml） • PNG_XML（cv数据类型，图片格式：PNG，标注文件格式：xml） • BMP_XML（cv数据类型，图片格式：BMP，标注文件格式：xml） • TAR（后缀为tar的文件格式） • IMAGE（后缀为jpg、jpeg、png、bmp的文件格式） • PASCAL（后缀为xml, jpg, jpeg, png, bmp的文件格式）

名称	类型	是否必选	描述
			- YOLO（后缀为yaml, txt, jpg, jpeg, png, bmp的文件格式） - IMAGE_JSON（图片+标注格式，图片格式：jpg、jpeg、png、bmp，标注文件格式：json） - IMAGE_PNG（后缀为jpg, png的文件格式） - IMAGE_TXT（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：txt） - IMAGE_XML（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：xml） - VIDEO_JSON（视频+标注格式，视频格式：mp4、avi，标注文件格式：json） - VIDEO_TXT（视频+txt格式，视频格式：mp4、avi，标注格式：txt） - USER_DEFINED（自定义） 默认取值： 不涉及
modal	String	否	参数解释： 数据集模态，用户根据导入的文件类型选择的模态分类。 约束限制： 不涉及 取值范围： - TEXT(文本) - IMAGE(图片) - VIDEO(视频) - WEATHER(气象) - PREDICT(预测) - OTHER(其他) - AUDIO(音频) 默认取值： 不涉及

名称	类型	是否必选	描述
file_source	String	否	参数解释： 创建数据导入任务时文件来源的分类。 约束限制： 不涉及 取值范围： • OBS（用户选择的自己的OBS桶路径） • LOCAL（用户选择的本地终端上的文件目录） • GALLERY（用户从Alhub上订阅的数据集） 默认取值： 不涉及

名称	类型	是否必选	描述
content_type	String	否	参数解释： 数据集中数据内容类型，用户在创建导入任务时选择的，或者在加工和发布任务运行时由系统自动生成的对应模式下的数据内容类型。 约束限制： 不涉及 取值范围： • SINGLE_QA（单轮问答） • SINGLE_QA_MAN（单轮问答人设） • MULTI_QA（多轮问答） • MULTI_QA_MAN（多轮问答人设） • QA_SORTING（问答排序） • PLAIN_TXT（文档） • WEB_PAGE（网页） • PRE_TRAINED_TEXT（预训练文本） • VIDEO（视频） • VIDEO_CLIP_ANNOTATION（视频剪辑标注） • VIDEO_UNDERSTANDING（视频理解） • TIME_SERIES_PREDICT（时序） • REGRESSION_CLASSIFICATION（回归分类） • IMAGE_AND_CAPTION（图片+Caption） • IMAGE_AND_QA（图片+QA对） • IMAGE_AND_CV_ANNOTATION（图片+CV标注） • IMAGE（仅图片） • IMAGE_OBJECT_DETECTION（物体检测） • OCEAN_WEATHER（气象） • CUSTOMIZATION（自定义） • IMAGE_CLASSIFICATION（图像分类） • IMAGE_ANOMALY_DETECTION（异常检测） • IMAGE_SEMANTIC_SEGMENTATION（语义分割）

名称	类型	是否必选	描述
			• IMAGE_POSE_ESTIMATION（姿态估计） • IMAGE_INSTANCE_SEGMENTATION（实例分割） • IMAGE_CHANGE_DETECTION（变化检测） • VIDEO_EVENT_DETECTION（事件检测） • VIDEO_CLASSIFICATION（视频分类） • DPO_QA（偏好优化DPO） • DPO_QA_MAN（偏好优化DPO人设） 默认取值： 不涉及
ext_config	String	否	参数解释： 系统内部模块使用的预留拓展字段。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
sample_path	String	否	参数解释： 用户在创建导入任务时选择的，或者在创建加工和发布任务时系统自动生成的数据文件的OBS桶路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

名称	类型	是否必选	描述
work_path	String	否	参数解释： 数据集元数据保存在OBS上的根目录，由系统在创建导入、加工和发布任务生成，可以在数据详情内查看。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
work_path2	String	否	参数解释： 任务运行态的临时文件在OBS上的存储根目录。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
file_name	Array of String	否	参数解释： 由数据导入和发布任务在生成数据集的时候记录的抽样的数据文件名称。 约束限制： 导入时记录文件个数上限为100，nlp发布时记录的数据集中数据文件的文件名。 取值范围： 不涉及 默认取值： 不涉及

名称	类型	是否必选	描述
file_num	Integer	否	参数解释： 数据集中数据目录下面的文件数量，在生成数据集时系统自动统计。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
platform	String	否	参数解释： 资产适用平台。 约束限制： 不涉及 取值范围： • PANGU • RAG 默认取值： 不涉及
manifest_file_path	String	否	参数解释： 由数据发布任务生成cv数据集的时候由系统生成的manifest文件路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

名称	类型	是否必选	描述
language	String	否	参数解释： 由系统内部定义的，在用户创建数据集时选择的语言类型。 约束限制： 不涉及 取值范围： CHINESE：中文 ENGLISH：英文 ARABIC：阿语 SPANISH：西语 FRENCH：法语 NONE：未设置 默认取值： 不涉及
annotation_status	String	否	参数解释： 标注任务在生成数据集的时候上报的标注项目状态，保存为kv结构，key为标注项目名称，value为标注项状态。 如：("VIDEO_QUALITY", "ONLINE") 约束限制： 当前的标注项只支持VIDEO_QUALITY 取值范围： 取值范围为ONLINE和OFFLINE 默认取值： 不涉及
creator	String	否	参数解释： 创建该数据集的操作用户账号名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

名称	类型	是否必选	描述
creator_id	String	否	参数解释： 创建该数据集的操作用户账号ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_capsule_encryption	Boolean	否	参数解释： 用户在创建数据导入任务时解析的文件加密类型，该功能受限使用，需要配合 tics 服务使用。 约束限制： 不涉及 取值范围： true（明文数据） false（胶囊加密数据） 默认取值： false
capsule	Capsule	否	参数解释： 导入数据集为数据胶囊加密时的数据集相关信息，当前只支持文本类数据中的预训练和问答对数据类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

名称	类型	是否必选	描述
is_global	Boolean	否	参数解释： 在创建发布任务时，用户指定的数据集的空间可见范围。 约束限制： 不涉及 取值范围： true（当前用户全空间可见） false（当前空间可见） 默认取值： false
tag	Array of TagListVo	否	参数解释： 数据集标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

名称	类型	是否必选	描述
industry	String	否	参数解释： 由系统内部定义，用户选择的行业类型，可在数据详情内查看。 约束限制： 不涉及 取值范围： GENERAL：通用 GOVERNMENT：政务 FINANCE：金融 MEDICAL：医疗 LAW：法律 AUTOMOBILE：汽车 COAL_MINE：煤矿 MILITARY：军事 TAXATION：税务 EDUCATION：教育 COMPUTER：计算机 INTERNET：互联网 RETAIL：零售 FOOD：食品 ENERGY：能源 MEDIA：传媒 INDUSTRY_AND_COMMERCE：工商 TRANSPORTATION：运输 E_COMMERCE：电商 MANUFACTURING：制造 NONE：不设置 默认取值： NONE

名称	类型	是否必选	描述
simple_tag	Array of String	否	参数解释： 由用户填写的数据集的自定义标签。 约束限制： 单个标签长度为64字节，1个中文字符为3个字节，最多100个标签。 取值范围： 只允许输入中文、字母、数字、中划线、下划线字符。 默认取值： 不涉及

名称	类型	是否必选	描述
data_copyright	String	否	参数解释： 由用户填写的数据版权内容，包括： 初始数据集名称 样例： 1、Antreas/TALI 2、weitianwen/cmath 初始数据集来源名称 样例： 1、Antreas/TALI 2、weitianwen/cmath 初始数据集版本号 样例： V2 初始数据集许可证 样例： V2 初始数据集授权人信息 样例： @misc{wei2023cmath, title={CMATH: Can Your Language Model Pass Chinese Elementary School Math Test?},author={Tianwen Wei and Jian Luan and Wei Liu and Shuang Dong and Bin Wang}, year={2023}, eprint={2306.16636}, archivePrefix={arXiv}, primaryClass={cs.CL} } 初始数据集许可证文本地址 样例： https://huggingface.co/datasets/choosealicense/licenses/blob/main/markdown/cc-by-4.0.md 初始数据集下载地址 样例： 1、https://huggingface.co/datasets/Antreas/TALI 2、https://huggingface.co/datasets/weitianwen/cmath

名称	类型	是否必选	描述
			用户可在创建数据集或通过更新数据集详情接口修改 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
publish_format	String	否	参数解释: 用户在创建数据集发布任务时指定的文件内容格式类型。 约束限制: 盘古格式和自定义格式可以被盘古模型训练任务选择。 取值范围: DEFAULT（标准格式） PANGU（盘古格式） USER_DEFINED（自定义格式） 默认取值: 不涉及
scene	String	否	参数解释: 发布数据盘古格式使用场景，包括 TRAIN、EVALUATE。表示训练、评测。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
meta_ext	String	否	参数解释: 元数据拓展信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

名称	类型	是否必选	描述
task_id	String	否	参数解释： 生成数据集时来源的导入、加工或者发布的任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_display_name	String	否	参数解释： 生成数据集时来源的导入、加工或者发布的任务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_type	String	否	参数解释： 生成数据集时来源的导入、加工或者发布的任务类型。 约束限制： 不涉及 取值范围： ● IMPORT(导入) ● REFLUX(回流) ● CLEANING(清洗) ● ANNOTATION(标注) ● SYNTHESIS(合成) ● TAGGING(标签) ● EVALUATION(评估) ● COMBINATION(配比) ● CIRCULATION(流通) 默认取值： 不涉及

名称	类型	是否必选	描述
data_source	SourceDatasets	否	参数解释： 生成该数据集时来源任务创建时由用户选择的输入数据集ID列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_deleted	Boolean	否	参数解释： 用户删除数据集时保存的删除状态。 约束限制： 不涉及 取值范围： true（删除状态，可通过恢复接口恢复数据集） false（未删除状态） 默认取值： false
custom_annotation_name	String	否	参数解释： 标注模板名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
train_proportion	Integer	否	参数解释： 训练集拆分比例。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

名称	类型	是否必选	描述
alias	String	否	参数解释： 数据集的属性名。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_info	String	否	参数解释： 回流数据来源模型json，包含name、version等信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_categories	TaskCategory Enum	否	参数解释： 额外标签，如backflow表示该数据集为回流数据。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
file_formats	Array of String	否	参数解释： 文件格式，支持多值操作。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-737 Capsule

名称	类型	是否必选	描述
enc_mode	String	否	参数解释： 从导入数据胶囊数据时从数据元数据文件中解析的数据加密类型。 约束限制： 不涉及 取值范围： ROW（行级加密） FieldLevel（字段级加密） FileLevel（文件级加密） 默认取值： 不涉及
valid_date_start	Long	否	参数解释： 从导入数据胶囊数据时从数据元数据文件中解析的胶囊数据有效起始时间。 约束限制： 绝对秒数 取值范围： 不涉及 默认取值： 不涉及
valid_date_end	Long	否	参数解释： 从导入数据胶囊数据时从数据元数据文件中解析的胶囊数据有效结束时间。 约束限制： 绝对秒数 取值范围： 不涉及 默认取值： 不涉及

表 3-738 TagListVo

名称	类型	是否必选	描述
TagListVo	Array of TagVo	否	参数解释： 数据集列表对象信息。 约束限制： 不涉及 取值范围： 最大数量:100 默认取值： 不涉及

表 3-739 TagVo

名称	类型	是否必选	描述
id	String	否	参数解释： 数据集标签ID。 约束限制： 不涉及 取值范围： 最小长度:1 最大长度:32 默认取值： 不涉及
name	String	否	参数解释： 数据集标签名。 约束限制： 不涉及 取值范围： 最小长度:1 最大长度:128 默认取值： 不涉及

名称	类型	是否必选	描述
level	Integer	否	参数解释： 数据集标签层级。 约束限制： 不涉及 取值范围： 最小长度:1 最大长度:3 默认取值： 不涉及
tag_group	String	否	参数解释： 预置标签分组。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-740 SourceDatasets

名称	类型	是否必选	描述
records	Array of SourceDataset	否	参数解释： 来源数据集列表。 约束限制： 不涉及 取值范围： 最大数量:100 默认取值： 不涉及

表 3-741 SourceDataset

名称	类型	是否必选	描述
dataset_id	String	否	参数解释： 来源数据集id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_name	String	否	参数解释： 数据集名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
catalog	String	否	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： • ORIGINAL(执行数据导入产生的数据集类型) • PROCESS(执行数据加工产生的数据集类型) • PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及

名称	类型	是否必选	描述
data_num	Number	否	参数解释： 数据集详情：在发布数据集中所占的配比数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
data_scale	Number	否	参数解释： 配比比例：在发布数据集中所占的配比比例。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-742 OperatorManifestLabelBase

名称	类型	是否必选	描述
key	String	是	参数解释： 标签的key值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

名称	类型	是否必选	描述
name	String	是	参数解释： 标签的名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
type	String	是	参数解释： 算子标签类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
items	Array of OperatorManifestLabelItem	否	参数解释： 标签枚举。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max	Double	否	参数解释： 标签最大值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

名称	类型	是否必选	描述
min	Double	否	参数解释： 标签最小值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-743 OperatorManifestLabelItem

名称	类型	是否必选	描述
name	String	是	参数解释： 标签项枚举名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
value	String	是	参数解释： 标签项枚举值 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

状态码： 200
成功响应示例


```
{
  "name": "qa073001",
  "id": "1267898425467342848",
  "desc": "",
  "status": "ONLINE",
  "catalog": "ORIGINAL",
  "size": 6847,
  "record_num": 21,
  "create_time": "1722332141000",
  "create_time_stamp": 1722332141000,
  "file_format": "JSONL",
  "file_source": "LOCAL",
  "content_type": "SINGLE_QA_MAN",
  "sample_path": "obs://桶名/original/1722332452247/",
  "work_path": "obs://桶名/dataset/5796ca0c-4377-11ef-9eef-0255ac1000aa/ORIGINAL/qa0730011267898425467342848/v1",
  "work_path2": "obs://桶名/dataset/5796ca0c-4377-11ef-9eef-0255ac1000aa/ORIGINAL/qa0730011267898425467342848/v1",
  "file_name": [
    "showcase3QA.jsonl"
  ],
  "file_num": 1,
  "manifest_file_path": "obs://桶名/dataset/5796ca0c-4377-11ef-9eef-0255ac1000aa/ORIGINAL/qa0730011267898425467342848/v1/qa073001.manifest",
  "creator": "用户名称",
  "creator_id": "用户id",
  "is_capsule_encryption": false,
  "is_global": false,
  "data_copyright": {
    "datasetName": "",
    "datasourceName": "",
    "datasetVersion": "",
    "datasetLicense": "",
    "datasetLicensor": "",
    "datasetLicenseUrl": "",
    "datasetUrl": ""
  },
  "task_id": 1301215691017424896,
  "task_display_name": "single_qa_test",
  "task_type": "CIRCULATION",
  "data_source": {
    "records": [
      {
        "dataset_id": "1301218797788729344",
        "dataset_name": "original-dataset-1730276745",
        "catalog": "ORIGINAL"
      }
    ]
  },
  "is_deleted": false
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.13 查询数据集列表

功能介绍

查询数据集列表信息。

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

URI

GET /v2/{project_id}/workspaces/{workspace_id}/data-management/datasets

表 3-744 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-745 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-746 请求 query 参数

参数	参数类型	是否必选	描述
catalog	否	String	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： • ORIGINAL(执行数据导入产生的数据集类型) • PROCESS(执行数据加工产生的数据集类型) • PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及
limit	否	Integer	参数解释： 每页数量。 约束限制： 不涉及 取值范围： 最小数值：1 最大数值：1000 默认取值： 10
offset	否	Integer	参数解释： 偏移量 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	是否必选	描述
sort_by	否	String	参数解释： 排序字段，当前支持size、create_time、record_num，分别表示按文件大小排序、按创建时间排序、按记录数排序 约束限制： 不涉及 取值范围： size、create_time、record_num 默认取值： create_time
sort_type	否	String	参数解释： 排序类型 asc、desc，分别表示升序、降序。 约束限制： 不涉及 取值范围： asc、desc 默认取值： desc
name	否	String	参数解释： 数据集名称，支持模糊搜索。 约束限制： 不涉及 取值范围： 最大长度:128 默认取值： 不涉及

参数	参数类型	是否必选	描述
status	否	Array of String	参数解释： 数据集的上下线状态，生成数据集的过程中是下线状态，生成成功之后是上线状态。 约束限制： 不涉及 取值范围： • ONLINE • OFFLINE 默认取值： 不涉及
start_time	否	Date	参数解释： 创建时间范围搜索的起始时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
end_time	否	Date	参数解释： 创建时间范围搜索的结束时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
creator	否	String	参数解释： 数据集的创建人，支持模糊搜索。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	是否必选	描述
mine	否	Boolean	参数解释： 是否只看当前用户创建的。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false
content_type	否	Array of String	参数解释： 数据集类型：文件类型，如单轮问答，多轮问答等。 约束限制： 不涉及 取值范围： 最大数量：30 默认取值： 不涉及
modal	否	String	参数解释： 数据集模态。 约束限制： 不涉及 取值范围： • TEXT(文本) • IMAGE(图片) • VIDEO(视频) • OTHER(其他) 默认取值： 不涉及
platform	否	String	参数解释： 资产适用平台。 约束限制： 不涉及 取值范围： 最大长度：64 默认取值： 不涉及

参数	参数类型	是否必选	描述
file_source	否	String	参数解释： 数据集的文件来源。 约束限制： 不涉及 取值范围： • OBS（用户选择的自己的OBS桶路径） • LOCAL（用户选择的本地终端上的文件目录） • GALLERY（用户从Alhub上订阅的数据集） 默认取值： 不涉及

参数	参数类型	是否必选	描述
file_format	否	String	参数解释： 数据集中文件格式，如JSONL、MP4等。 约束限制： 不涉及 取值范围： • JSONL • TXT • CSV • HTML • MOBI • EPUB • DOCX • PDF • MP4 • AVI • AVI_MP4 • JPGS_JSONL • JPG_TXT • JPEG_TXT • PNG_TXT • BMP_TXT • JPG_XML • JPEG_XML • PNG_XML • BMP_XML 默认取值： 不涉及
tag_id	否	Array of String	参数解释： 数据集的标签id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	是否必选	描述
annotation_type	否	String	参数解释： 数据集的标注类型。 约束限制： 不涉及 取值范围： 最大长度：32 默认取值： 不涉及
tokenize_type	否	String	参数解释： token化模型类型。 约束限制： 不涉及 取值范围： 最大长度：64 默认取值： 不涉及
is_capsule_encryption	否	Boolean	参数解释： 数据集是否胶囊加密。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
publish_format	否	String	参数解释： 发布数据集格式。 约束限制： 不涉及 取值范围： DEFAULT（标准格式） PANGU（盘古格式） USER_DEFINED（自定义格式） 默认取值： 不涉及

参数	参数类型	是否必选	描述
scene	否	String	参数解释： 发布数据PANGU格式使用场景。 约束限制： 不涉及 取值范围： TRAIN、EVALUATE，表示训练、评测。 默认取值： 不涉及
task_id	否	String	参数解释： 生成数据集时来源的导入、加工或者发布的任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_display_name	否	String	参数解释： 生成数据集时来源的导入、加工或者发布的任务名称 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_type	否	String	参数解释： 生成数据集时来源的导入、加工或者发布的任务类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	是否必选	描述
show_deleted	否	Boolean	参数解释： 显示内容是否包含已删除数据集。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false
format_ext	否	String	参数解释： context、target、预训练text等参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
custom_annotation_name	否	String	参数解释： 标注模板名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
simple_tag	否	String	参数解释： 数据集标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	是否必选	描述
no_simple_tag	否	String	参数解释： 数据集标签排除。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
language	否	String	参数解释： 由系统内部定义的，在用户创建数据集时选择的语言类型。 约束限制： 不涉及 取值范围： CHINESE：中文 ENGLISH：英文 ARABIC：阿语 SPANISH：西语 FRENCH：法语 NONE：未设置 默认取值： 不涉及

参数	参数类型	是否必选	描述
industry	否	String	参数解释： 由系统内部定义，用户选择的行业类型，可在数据详情内查看。 约束限制： 不涉及 取值范围： GENERAL：通用 GOVERNMENT：政务 FINANCE：金融 MEDICAL：医疗 LAW：法律 AUTOMOBILE：汽车 COAL_MINE：煤矿 MILITARY：军事 TAXATION：税务 EDUCATION：教育 COMPUTER：计算机 INTERNET：互联网 RETAIL：零售 FOOD：食品 ENERGY：能源 MEDIA：传媒 INDUSTRY_AND_COMMERCE：工商 TRANSPORTATION：运输 E_COMMERCE：电商 MANUFACTURING：制造 NONE：不设置 默认取值： NONE
alias	否	String	参数解释： 数据集的属性名。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	是否必选	描述
file_formats	否	String	参数解释： 数据集中文件格式，支持多值操作。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_category	否	Array of String	参数解释： task分类。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码： 200

表 3-747 响应 Body 参数

参数	参数类型	描述
count	Long	参数解释： 数据集总量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
datasets	Array of DatasetsVo	参数解释: 数据集实体。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
count_info	CountVo	参数解释: 数据集数量信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-748 DatasetsVo

名称	类型	描述
id	String	参数解释: 数据集ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

名称	类型	描述
catalog	String	参数解释: 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制: 不涉及 取值范围: • ORIGINAL(执行数据导入产生的数据集类型) • PROCESS(执行数据加工产生的数据集类型) • PUBLISH(执行数据发布产生的数据集类型) 默认取值: 不涉及
name	String	参数解释: 数据集名称，由用户在创建数据集时填写的名称。 约束限制: 长度为2~63的字符。 取值范围: 以中文、字母开头，以中文、字母、数字结尾，只允许输入中文、字母、数字、中划线、下划线字符。 默认取值: 不涉及
desc	String	参数解释: 数据集描述，用户创建数据集时填写的描述内容。 约束限制: 不超过100个字符 取值范围: 不涉及 默认取值: 不涉及

名称	类型	描述
status	String	参数解释： 数据集的上下线状态，生成数据集的过程中是下线状态，生成成功之后是上线状态。 约束限制： 不涉及 取值范围： • ONLINE • OFFLINE 默认取值： 不涉及
version	String	参数解释： 用户在生成数据集时系统自动生成的版本号，当前不支持版本号更新。 约束限制： 不涉及 取值范围： V1 默认取值： 不涉及
update_time	String	参数解释： 数据集更新时间，用户在操作创建、更新、删除、恢复数据集时产生的时间。 约束限制： 格式为yyyy-MM-dd HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
update_time_stamp	Long	参数解释： 数据集更新时间，用户在操作创建、更新、删除、恢复数据集时产生的时间，示例： 1722332141000。 约束限制： 格式为绝对秒数 取值范围： 不涉及 默认取值： 不涉及

名称	类型	描述
create_time	String	参数解释： 数据集创建时间，用户在操作创建数据集时产生的时间。 约束限制： 格式为yyyy-MM-dd HH:mm:ss.SSS 取值范围： 不涉及 默认取值： 不涉及
create_time_stamp	Long	参数解释： 数据集创建时间，用户在操作创建数据集时产生的时间，示例：1722332141000。 约束限制： 格式为绝对秒数 取值范围： 不涉及 默认取值： 不涉及

名称	类型	描述
file_format	String	参数解释： 文件格式，由用户创建数据导入任务时选择的数据文件格式类型。 约束限制： 取值范围： • JSONL（后缀为jsonl的文件格式） • TXT（后缀为txt的文件格式） • CSV（后缀为csv的文件格式） • HTML（后缀为html的文件格式） • MOBI（后缀为mobi的文件格式） • EPUB（后缀为epub的文件格式） • DOCX（后缀为docx的文件格式） • PDF（后缀为pdf的文件格式） • MP4（后缀为mp4的文件格式） • AVI（后缀为avi的文件格式） • AVI_MP4（后缀为avi/mp4的文件格式） • JPGS_JSONL（后缀为jsonl, json, tar的文件格式） • JPG_TXT（cv数据类型，图片格式：JPG，标注文件格式：txt） • JPEG_TXT（cv数据类型，图片格式：JPEG，标注文件格式：txt） • PNG_TXT（cv数据类型，图片格式：PNG，标注文件格式：txt） • BMP_TXT（cv数据类型，图片格式：BMP，标注文件格式：txt） • JPG_XML（后缀为xml, jpg, jpeg, png, bmp, manifest的文件格式） • JPEG_XML（cv数据类型，图片格式：JPEG，标注文件格式：xml） • PNG_XML（cv数据类型，图片格式：PNG，标注文件格式：xml） • BMP_XML（cv数据类型，图片格式：BMP，标注文件格式：xml） • TAR（后缀为tar的文件格式） • IMAGE（后缀为jpg、jpeg、png、bmp的文件格式） • PASCAL（后缀为xml, jpg, jpeg, png, bmp的文件格式） • YOLO（后缀为yaml, txt, jpg, jpeg, png, bmp的文件格式）

名称	类型	描述
		• IMAGE_JSON（图片+标注格式，图片格式：jpg、jpeg、png、bmp，标注文件格式：json） • IMAGE_PNG（后缀为jpg, png的文件格式） • IMAGE_TXT（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：txt） • IMAGE_XML（图片+txt格式，图片格式：jpg、jpeg、png、bmp，标注格式：xml） • VIDEO_JSON（视频+标注格式，视频格式：mp4、avi，标注文件格式：json） • VIDEO_TXT（视频+txt格式，视频格式：mp4、avi，标注格式：txt） • USER_DEFINED（自定义） 默认取值： 不涉及
modal	String	参数解释： 数据集模态，用户根据导入的文件类型选择的模态分类。 约束限制： 不涉及 取值范围： • TEXT(文本) • IMAGE(图片) • VIDEO(视频) • WEATHER(气象) • PREDICT(预测) • OTHER(其他) • AUDIO(音频) 默认取值： 不涉及

名称	类型	描述
file_source	String	参数解释： 创建数据导入任务时文件来源的分类。 约束限制： 不涉及 取值范围： • OBS（用户选择的自己的OBS桶路径） • LOCAL（用户选择的本地终端上的文件目录） • GALLERY（用户从Alhub上订阅的数据集） 默认取值： 不涉及
language	String	参数解释： 由系统内部定义的，在用户创建数据集时选择的语言类型。 约束限制： 不涉及 取值范围： CHINESE：中文 ENGLISH：英文 ARABIC：阿语 SPANISH：西语 FRENCH：法语 NONE：未设置 默认取值： 不涉及

名称	类型	描述
industry	String	参数解释: 由系统内部定义，用户选择的行业类型，可在数据详情内查看。 约束限制: 不涉及 取值范围: GENERAL: 通用 GOVERNMENT: 政务 FINANCE: 金融 MEDICAL: 医疗 LAW: 法律 AUTOMOBILE: 汽车 COAL_MINE: 煤矿 MILITARY: 军事 TAXATION: 税务 EDUCATION: 教育 COMPUTER: 计算机 INTERNET: 互联网 RETAIL: 零售 FOOD: 食品 ENERGY: 能源 MEDIA: 传媒 INDUSTRY_AND_COMMERCE: 工商 TRANSPORTATION: 运输 E_COMMERCE: 电商 MANUFACTURING: 制造 NONE: 不设置 默认取值: NONE
is_global	Boolean	参数解释: 在创建发布任务时，用户指定的数据集的空间可见范围。 约束限制: 不涉及 取值范围: true (当前用户全空间可见) false (当前空间可见) 默认取值: false

名称	类型	描述
size	Long	参数解释： 数据集大小，生成数据集成功后系统根据数据目录中所有文件的大小累加统计得到，除了manifest文件，单位是Byte。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
file_num	Integer	参数解释： 数据集中数据目录下面的文件数量，在生成数据集时系统自动统计。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
record_num	Long	参数解释： 数据集中的数据条数：加工和发布任务运行成功后，由任务上报的数据结果条数，举例：nlp中csv和jsonl文件中一行为一条数据，word文档中一个文档为一条数据，图片中一张图片为一条数据。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

名称	类型	描述
content_type	String	参数解释: 数据集中数据内容类型，用户在创建导入任务时选择的，或者在加工和发布任务运行时由系统自动生成的对应模态下的数据内容类型。 约束限制: 不涉及 取值范围: • SINGLE_QA（单轮问答） • SINGLE_QA_MAN（单轮问答人设） • MULTI_QA（多轮问答） • MULTI_QA_MAN（多轮问答人设） • QA_SORTING（问答排序） • PLAIN_TXT（文档） • WEB_PAGE（网页） • PRE_TRAINED_TEXT（预训练文本） • VIDEO（视频） • VIDEO_CLIP_ANNOTATION（视频剪辑标注） • VIDEO_UNDERSTANDING（视频理解） • TIME_SERIES_PREDICT（时序） • REGRESSION_CLASSIFICATION（回归分类） • IMAGE_AND_CAPTION（图片+Caption） • IMAGE_AND_QA（图片+QA对） • IMAGE_AND_CV_ANNOTATION（图片+CV标注） • IMAGE（仅图片） • IMAGE_OBJECT_DETECTION（物体检测） • OCEAN_WEATHER（气象） • CUSTOMIZATION（自定义） • IMAGE_CLASSIFICATION（图像分类） • IMAGE_ANOMALY_DETECTION（异常检测） • IMAGE_SEMANTIC_SEGMENTATION（语义分割） • IMAGE_POSE_ESTIMATION（姿态估计） • IMAGE_INSTANCE_SEGMENTATION（实例分割） • IMAGE_CHANGE_DETECTION（变化检测） • VIDEO_EVENT_DETECTION（事件检测） • VIDEO_CLASSIFICATION（视频分类）

名称	类型	描述
		- DPO_QA (偏好优化DPO) - DPO_QA_MAN (偏好优化DPO人设) 默认取值: 不涉及
creator	String	参数解释: 数据集的创建人。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
sample_path	String	参数解释: 用户在创建导入任务时选择的, 或者在创建加工和发布任务时系统自动生成的数据文件的OBS桶路径。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
work_path	String	参数解释: 数据集元数据保存在OBS上的根目录, 由系统在创建导入、加工和发布任务生成, 可以在数据详情内查看。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

名称	类型	描述
annotation_status	String	参数解释： 标注任务在生成数据集的时候上报的标注项目状态，保存为kv结构，key为标注项名称，value为标注项状态。 如：("VIDEO_QUALITY", "ONLINE") 约束限制： 当前的标注项只支持VIDEO_QUALITY 取值范围： 取值范围为ONLINE和OFFLINE 默认取值： 不涉及
platform	String	参数解释： 资产适用平台，包括PANGU、RAG。 约束限制： 不涉及 取值范围： Pangu（用于盘古模型训练）、RAG。 默认取值： 不涉及
is_capsule_encryption	Boolean	参数解释： 用户在创建数据导入任务时解析的文件加密类型，该功能受限使用，需要配合tics服务使用。 约束限制： 不涉及 取值范围： true（明文数据） false（胶囊加密数据） 默认取值： false
capsule	Capsule	参数解释： 导入数据集为数据胶囊加密时的数据集相关信息，当前只支持文本类数据中的预训练和问答对数据类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

名称	类型	描述
publish_format	String	参数解释： 用户在创建数据集发布任务时指定的文件内容格式类型。 约束限制： 盘古格式和自定义格式可以被盘古模型训练任务选择。 取值范围： • DEFAULT（标准格式） • PANGU（盘古格式） • USER_DEFINED（自定义格式） 默认取值： 不涉及
scene	String	参数解释： 发布数据在pangu格式使用场景，包括TRAIN、EVALUATE。表示训练、评测。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
simple_tag	Array of String	参数解释： 由用户填写的数据集的自定义标签。 约束限制： 单个标签长度为64字节，1个中文字符为3个字节，最多100个标签。 取值范围： 只允许输入中文、字母、数字、中划线、下划线字符。 默认取值： 不涉及

名称	类型	描述
task_id	String	参数解释: 生成数据集时来源的导入、加工或者发布的任务ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
task_display_name	String	参数解释: 生成数据集时来源的导入、加工或者发布的任务名称。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
task_type	String	参数解释: 生成数据集时来源的导入、加工或者发布的任务类型。 约束限制: 不涉及 取值范围: ● IMPORT(导入) ● REFLUX(回流) ● CLEANING(清洗) ● ANNOTATION(标注) ● SYNTHESIS(合成) ● TAGGING(标签) ● EVALUATION(评估) ● COMBINATION(配比) ● CIRCULATION(流通) 默认取值: 不涉及

名称	类型	描述
data_source	SourceDatasets	参数解释： 生成该数据集时来源任务创建时由用户选择的输入数据集ID列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_deleted	Boolean	参数解释： 用户删除数据集时保存的删除状态。 约束限制： 不涉及 取值范围： true（删除状态，可通过恢复接口恢复数据集） false（未删除状态） 默认取值： false
custom_annotation_name	String	参数解释： 标注模板名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
train_proportion	Integer	参数解释： 训练集拆分比例。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

名称	类型	描述
alias	String	参数解释： 数据集属性名 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_categories	TaskCategory Enum	参数解释： 数据集额外标签，如backflow表示该数据集为回流数据。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
file_formats	Array of String	参数解释： 文件格式，支持多值操作。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-749 Capsule

名称	类型	描述
enc_mode	String	参数解释： 数据集加密方式，当前仅支持行加密。 约束限制： 不涉及 取值范围： ROW（行级加密） 默认取值： 不涉及

名称	类型	描述
valid_date_start	Long	参数解释: 从导入数据胶囊数据时从数据元数据文件中解析的胶囊数据有效起始时间。 约束限制: 必须为时间戳，不得包含毫秒或纳秒单位 取值范围: 不涉及 默认取值: 不涉及
valid_date_end	Long	参数解释: 从导入数据胶囊数据时从数据元数据文件中解析的胶囊数据有效结束时间。 约束限制: 必须为时间戳，不得包含毫秒或纳秒单位 取值范围: 不涉及 默认取值: 不涉及

表 3-750 SourceDatasets

名称	类型	描述
records	Array of SourceDataset	参数解释: 来源数据集列表。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-751 SourceDataset

名称	类型	描述
dataset_id	String	参数解释： 来源数据集id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_name	String	参数解释： 数据集名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
catalog	String	参数解释： 数据集分类，用户在执行数据导入、加工和发布任务时生成的对应的类型的数据集。 约束限制： 不涉及 取值范围： ● ORIGINAL(执行数据导入产生的数据集类型) ● PROCESS(执行数据加工产生的数据集类型) ● PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及
data_num	Number	参数解释： 数据集详情：在发布数据集中所占的配比数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

名称	类型	描述
data_scale	Number	参数解释： 配比比例：在发布数据集中所占的配比比例。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-752 CountVo

名称	类型	是否必选	描述
total_count	Long	否	参数解释： 某类数据集总条数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
online_count	Long	否	参数解释： 上线数据集条数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
offline_count	Long	否	参数解释： 未上线数据集条数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

状态码： 200

成功响应示例

```
{
  "count":1,
  "datasets":[
    {
      "id":"1264971478995177472",
      "catalog":"ORIGINAL",
      "name":"ocean-1",
      "desc":"",
      "status":"ONLINE",
      "create_time":"2024-07-22 15:45:04",
      "create_time_stamp":1721634304000,
      "file_source":"OBS",
      "size":13257145696,
      "file_num":84,
      "record_num":0,
      "content_type":"OCEAN_WEATHER",
      "creator":"Data-publish-user",
      "sample_path":"obs://桶名/l2025/气象科学计算数据集",
      "is_capsule_encryption":false,
      "publish_format":"DEFAULT",
      "task_id":"lt_8bc09fcbd7404348b591dbbccc58fd92",
      "task_display_name":"预训练-1",
      "task_type":"CIRCULATION",
      "data_source":{
        "records":[
          {
            "dataset_id":"1301220891434291200",
            "dataset_name":"original-dataset-rc",
            "catalog":"ORIGINAL"
          }
        ]
      },
      "is_deleted":false
    }
  ],
  "count_info":{
    "total_count":18,
    "online_count":12,
    "offline_count":6
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.14 查询加工算子列表

功能介绍

查询算子列表，支持按算子ID，算子模态，算子状态等字段过滤。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/operator-manager/operator-list
接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-753 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-754 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
X-Language	否	String	参数解释： 指定请求或响应的语言。支持ISO 639-1语言代码，如en-US（美国英语）、zh-CN（简体中文）。 约束限制： • 必须为有效的ISO 639-1语言代码，可选地区代码。 • 不区分大小写，建议使用小写。 • ISO 639-1语言代码，如en、zh。 • 带地区代码的组合，如en-US、zh-CN。 • 如果未提供X-Language头，系统将使用默认语言en-US（英语）进行响应。 取值范围： • zh-cn • en-us 默认取值： 不涉及

表 3-755 请求 Query 参数

参数	是否必选	参数类型	描述
catalog	否	String	参数解释： 算子的来源，预置算子为SYS，用户自定义算子为USER。 约束限制： 不涉及 取值范围： • SYS（预置算子） • USER（自定义算子） 默认取值： 不涉及
global	否	Boolean	参数解释： 算子是否全空间可见。 约束限制： 不涉及 取值范围： • true • false 默认取值： 不涉及
mine	否	Boolean	参数解释： 是否只看我创建的算子。 约束限制： 不涉及 取值范围： • true • false 默认取值： 不涉及
operator_id	否	String	参数解释： 算子id。获取方法请参见 4.21-获取算子ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
name	否	String	参数解释： 算子展示名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
environment	否	String	参数解释： 算子运行环境，JAVA代表算子运行在JAVA环境，PYTHON代表算子运行在PYTHON环境。 约束限制： 不涉及 取值范围： • PYTHON • JAVA 默认取值： 不涉及
language	否	String	参数解释： 算子支持处理的语言类型，取值范围和算子配置文件tags下的language对应。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
file_format	否	String	参数解释： 算子支持处理的文件格式，取值范围和算子配置文件tags下的format对应。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
category	否	Array of String	参数解释： 算子类型列表，元素取值项为 DL（数据打标）、DT（数据转换）、DS(数据抽样)、DE（数据提取）、DF（数据过滤）、OTHER(其他)。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
modal	否	String	参数解释： 算子支持的数据模态。 约束限制： 不涉及 取值范围： • TEXT（文本） • IMAGE（图片） • VIDEO（视频） • AUDIO（音频） • DOCUMENT（文档） • GEOSPATIAL（坐标） • TABULAR（表格） • 3D（3D视觉数据） • OTHER（其他场景） • MULTIMODEL（多模态） 默认取值： 不涉及
cpu_arch	否	String	参数解释： 算子支持运行的cpu架构。 约束限制： 不涉及 取值范围： • X86 • ARM 默认取值： 不涉及

参数	是否必选	参数类型	描述
xpu_device	否	String	参数解释： 算子支持运行的xpu设备型号。 约束限制： 不涉及 取值范围： • SNT9B 默认取值： 不涉及

响应参数

状态码：200

表 3-756 响应 Body 参数

参数	参数类型	描述
cat	Array of 表5 FirstCatVo Object	参数解释： 一级标签分类的算子列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-757 FirstCatVo

参数	参数类型	描述
first_cat	String	参数解释： 算子分类。 约束限制： 不涉及 取值范围： • 中文：数据打标，英文：Data Labeling • 中文：数据过滤，英文：Data Filtering • 中文：数据提取，英文：Data Extraction • 中文：数据转换，英文：Data Transformation • 中文：数据抽样，英文：Data Sampling • 中文：其他，英文：Other 默认取值： 不涉及
first_cat_type	String	参数解释： 算子分类简称。 约束限制： 与first_cat字段对应，DE代表数据提取，DF代表数据过滤，DL代表数据打标，DS代表数据抽样，DT代表数据转换，OTHER代表其他。 取值范围： • DL • DF • DE • DT • DS • OTHER 默认取值： 不涉及

参数	参数类型	描述
cat_index	Integer	参数解释： 分类索引，用于排序。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
second_cat	Array of 表6 SubCatVo Object	参数解释： 二级分类的算子分组列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-758 SubCatVo

参数	参数类型	描述
second_cat	String	参数解释： 算子二级分类。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
operators	Array of 表7 OperatorInfoDto Console Object	参数解释： 算子信息的列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-759 OperatorInfoDtoConsole

参数	参数类型	描述
operator_name	String	参数解释： 算子名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
operator_id	String	参数解释： 算子id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
operator_desc	String	参数解释： 算子描述信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
catalog	String	参数解释： 算子来源。 约束限制： 不涉及 取值范围： • SYS • USER 默认取值： 不涉及

参数	参数类型	描述
first_cat	String	参数解释： 算子一级分类名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
first_cat_type	String	参数解释： 算子一级分类简称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
disabled	String	参数解释： 是否默认必选。 约束限制： 不涉及 取值范围： • true • false 默认取值： 不涉及
ope_args	Array of 表8 OperatorArgConsoleObject	参数解释： 算子参数信息列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
operator_record_id	String	参数解释： 算子基本信息记录id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
operator_version_id	String	参数解释： 算子版本信息记录id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
version	String	参数解释： 算子版本号。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-760 OperatorArgConsole

参数	参数类型	描述
arg_key	String	参数解释： 参数key值，同一个算子内唯一。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
arg_name	String	参数解释： 算子参数名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
arg_desc	String	参数解释： 算子参数说明信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
arg_val_default	String	参数解释： 参数的默认值。 约束限制： 当visible字段为false时，且required字段为true时，arg_val_default字段是必填项 取值范围： 不涉及 默认取值： 不涉及
required	Boolean	参数解释： 参数是否必填。 约束限制： 不涉及 取值范围： - true - false 默认取值： 不涉及

参数	参数类型	描述
arg_display_type	String	参数解释： 参数展示组件类型。 约束限制： 不涉及 取值范围： • file(OBS输入框) • slider_equal(数字输入框) • slider_between(自定义范围输入框) • flat_radio_button(单选框) • flat_check_box(复选框) • flat_select_drop(下拉单选框) • flat_check_drop(下拉多选框) • input_text(文本输入框) • large_model(大模型) • label_filter(标签过滤) 默认取值： 不涉及
type	String	参数解释： 算子参数类型。INT(整型)、FLOAT(浮点型)、STRING(字符串)、ENUM(枚举)、LIST(列表)、BOOLEAN(布尔)、LARGE_MODEL(大模型)、OBS(OBS服务)、LABEL_FILTER(标签过滤) 约束限制： 不涉及 取值范围： • INT • FLOAT • STRING • ENUM • LIST • BOOLEAN • LARGE_MODEL • OBS • LABEL_FILTER 默认取值： 不涉及

参数	参数类型	描述
visible	Boolean	参数解释： 是否展示给用户。 约束限制： 不涉及 取值范围： • true • false 默认取值： false

请求示例

```
GET /v1/1331931893393920000/workspaces/1331931893393920000/operator-manager/operator-list?
catalog=USER
```

响应示例

状态码：200

成功响应示例

```
{
  "cat": [
    {
      "first_cat": "数据转换",
      "first_cat_type": "DT",
      "cat_index": 1,
      "second_cat": [
        {
          "operators": [
            {
              "first_cat": "数据转换",
              "first_cat_type": "DT",
              "operator_record_id": "1367168174784647168",
              "operator_version_id": "1371883616400969728",
              "operator_id": "IMAGE_OBJECT_DETECTION",
              "version": "v5",
              "catalog": "USER",
              "operator_name": "物体检测数据集转换",
              "operator_desc": "物体检测的数据集转换",
              "disabled": false,
              "ope_args": [
                {
                  "arg_key": "json_path",
                  "arg_name": "待转换数据路径",
                  "arg_desc": "数据转换obs路径",
                  "type": "STRING",
                  "arg_val_default": "obs://",
                  "required": true,
                  "visible": true,
                  "arg_display_type": "input_text"
                },
                {
                  "arg_key": "tar_path",
                  "arg_name": "数据转换后路径",
                  "arg_desc": "数据转换obs路径",

```

```
        "type": "STRING",
        "arg_val_default": "obs://",
        "required": true,
        "visible": true,
        "arg_display_type": "input_text"
      }
    ]
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.10.15 创建加工任务

功能介绍

创建数据集加工任务。

URI

POST /v2/{project_id}/workspaces/{workspace_id}/data-cleaning/jobs
接口域名请参考[获取盘古服务外部APIG域名](#)获取。

表 3-761 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-762 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
X-Language	否	String	参数解释： 指定请求或响应的语言。支持 ISO 639-1语言代码，如en-US（美国英语）、zh-CN（简体中文）。 约束限制： • 必须为有效的ISO 639-1语言代码，可选地区代码。 • 不区分大小写，建议使用小写。 • ISO 639-1语言代码，如en、zh。 • 带地区代码的组合，如en-US、zh-CN。 • 如果未提供X-Language头，系统将使用默认语言en-US（英语）进行响应。 取值范围： • en-US • zh-CN 默认取值： 不涉及

表 3-763 请求 Body 参数

参数	是否必选	参数类型	描述
source_dataset_name	是	String	参数解释： 待加工数据集名称。 约束限制： 不涉及 取值范围： 长度2-64。 默认取值： 不涉及

参数	是否必选	参数类型	描述
source_dataset_catalog	是	String	参数解释： 待加工数据集类别。 约束限制： 不涉及 取值范围： • ORIGINAL(执行数据导入产生的数据集类型) • PROCESS(执行数据加工产生的数据集类型) • PUBLISH(执行数据发布产生的数据集类型) 默认取值： 不涉及
task_operators	是	Array of 表 3-764 objects	参数解释： 算子列表。 约束限制： 不涉及 取值范围： 算子个数限制在1-50个。 默认取值： 不涉及
generate_dataset	否	表3-766 object	参数解释： 生成数据集信息，任务需要自动生成数据集时填写。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
resource_config	否	表3-767 object	参数解释： 资源配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
operator_catalog	是	String	参数解释： 用于数据加工的算子类别。 约束限制： 不涉及 取值范围： • SYS(预置算子) • USER(自定义算子) 默认取值： 不涉及

表 3-764 TaskOperatorReq

参数	是否必选	参数类型	描述
operator_record_id	否	String	参数解释： 算子记录ID。 约束限制： 不涉及 取值范围： 长度1-64。 默认取值： 不涉及
version	否	String	参数解释： 算子版本号。 约束限制： 不涉及 取值范围： 长度1-32。 默认取值： 不涉及
ope_args	否	Array of 表 3-765 objects	参数解释： 算子参数。 约束限制： 不涉及 取值范围： 参数个数不超过20个。 默认取值： 不涉及

表 3-765 OperatorArgReq

参数	是否必选	参数类型	描述
arg_name	是	String	参数解释： 参数键名。 约束限制： 不涉及 取值范围： 长度1-128。 默认取值： 不涉及
arg_val	否	String	参数解释： 参数值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
type	否	String	参数解释： 参数类型。 约束限制： 不涉及 取值范围： • INT • FLOAT • STRING • ENUM • LIST • BOOLEAN • OBS 默认取值： 不涉及

表 3-766 DatasetReq

参数	是否必选	参数类型	描述
name	否	String	参数解释： 数据集名称。 约束限制： 不涉及 取值范围： 长度1-128。 默认取值： 不涉及
desc	否	String	参数解释： 数据集描述。 约束限制： 不涉及 取值范围： 长度0-512。 默认取值： 不涉及

参数	是否必选	参数类型	描述
industry	否	String	参数解释： 行业类型。 约束限制： 不涉及 取值范围： • GENERAL（通用） • GOVERNMENT（政务） • FINANCE（金融） • MEDICAL（医疗） • LAW（法律） • AUTOMOBILE（汽车） • COAL_MINE（煤矿） • MILITARY（军事） • TAXATION（税务） • EDUCATION（教育） • COMPUTER（计算机） • INTERNET（互联网） • RETAIL（零售） • FOOD（食品） • ENERGY（能源） • MEDIA（传媒） • INDUSTRY_AND_COMMERCE（工商） • TRANSPORTATION（运输） • E_COMMERCE（电商） • MANUFACTURING（制造） • NONE（空） 默认取值： 不涉及

参数	是否必选	参数类型	描述
language	否	String	参数解释： 语言类型。 约束限制： 不涉及 取值范围： • CHINESE（中文） • ENGLISH（英文） • ARABIC（阿拉伯语） • SPANISH（西班牙语） • FRENCH（法语） • NONE（空） 默认取值 不涉及
is_global	否	Boolean	参数解释： 数据集是否全局可见。 约束限制： 不涉及 取值范围 • true • false 默认取值 true
simple_tag	否	Array of strings	参数解释： 数据集标签。 约束限制： 不涉及 取值范围 不超过20个。 默认取值 不涉及

参数	是否必选	参数类型	描述
content_type	否	String	参数解释： 数据集类型。 约束限制： 不涉及 取值范围 • SINGLE_QA（单轮问答） • SINGLE_QA_MAN（单轮问答人设） • MULTI_QA（多轮问答） • MULTI_QA_MAN（多轮问答人设） • QA_SORTING（问答排序） • PLAIN_TXT（文档） • WEB_PAGE（网页） • PRE_TRAINED_TEXT（预训练文本） • VIDEO（视频） • VIDEO_CLIP_ANNOTATION（视频剪辑标注） • VIDEO_UNDERSTANDING（视频理解） • TIME_SERIES_PREDICT（时序） • REGRESSION_CLASSIFICATION（回归分类） • IMAGE_AND_CAPTION（图片+Caption） • IMAGE_AND_QA（图片+QA对） • IMAGE_AND_CV_ANNOTATION（图片+CV标注） • IMAGE（仅图片） • IMAGE_OBJECT_DETECTION（物体检测） • OCEAN_WEATHER（气象） • CUSTOMIZATION（自定义） • IMAGE_CLASSIFICATION（图像分类） • IMAGE_ANOMALY_DETECTION（异常检测）

参数	是否必选	参数类型	描述
			• IMAGE_SEMANTIC_SEGME NTATION（语义分割） • IMAGE_POSE_ESTIMATION （姿态估计） • IMAGE_INSTANCE_SEGMEN TATION（实例分割） • IMAGE_CHANGE_DETECTIO N（变化检测） • VIDEO_EVENT_DETECTION （事件检测） • VIDEO_CLASSIFICATION （视频分类） • DPO_QA（偏好优化DPO） • DPO_QA_MAN（偏好优化 DPO人设） 默认取值 不涉及

参数	是否必选	参数类型	描述
file_format	否	String	参数解释： 数据集文件格式。 约束限制： 不涉及 取值范围 - JSONL - TXT - CSV - HTML - MOBI - EPUB - DOCX - PDF - MP4 - AVI - AVI_MP4 - AVI_MP4_TXT - JPGS_JSONL - JPG_TXT - JPEG_TXT - PNG_TXT - BMP_TXT - JPG_XML - JPEG_XML - PNG_XML - BMP_XML - TAR - IMAGE - PASCAL - YOLO - IMAGE_JSON - IMAGE_CORRESPOND_JSON - IMAGE_PNG - IMAGE_TXT - IMAGE_XML - IMAGE_LABEL_JSON - IMAGE_LABEL_TXT - IMAGE_LABEL - IMAGE_JSONL - VIDEO_JSON - VIDEO_SINGLE_JSON - VIDEO_TXT - VIDEO_JSONL - USER_DEFINED - PARQUET - AUDIO - AUDIO_JSONL 默认取值 不涉及

表 3-767 ResourceConfig

参数	是否必选	参数类型	描述
cpu	否	Double	参数解释： 通算单元个数。 约束限制： 不涉及 取值范围： 长度1-128。 默认取值： 不涉及
npu	否	Double	参数解释： 智算单元个数。 约束限制： 不涉及 取值范围： 长度0-512。 默认取值： 不涉及
extra_config	否	String	参数解释： 额外配置，如spark队列，内存，cpu核数，执行器数等。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-768 响应 Body 参数

参数	参数类型	描述
清洗作业ID	String	参数解释： 清洗作业ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
POST /v2/1331931893393920000/workspaces/1331931893393920000/data-cleaning/jobs
{
  "source_dataset_name": "orig_20251124_40148",
  "source_dataset_catalog": "ORIGINAL",
  "task_operators": [
    {
      "operator_record_id": "ope40",
      "ope_args": [],
      "version": "1.0.0"
    }
  ],
  "operator_catalog": "SYS",
  "resource_config": {
    "cpu": 4,
    "npu": 1,
    "extra_config": "{\"numExecutors\":2,\"executorCores\":2,\"executorMemory\":4,\"driverCores\":2,\"driverMemory\":4}"
  },
  "generate_dataset": {
    "name": "proc_20251203_86805",
    "desc": "",
    "is_global": true,
    "industry": null,
    "language": null,
    "simple_tag": []
  }
}
```

响应示例

状态码：200

成功响应示例

```
{
  "job_id": "1445785047637561344"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.11 空间管理

3.11.1 查询空间列表

功能介绍

查询平台中的空间信息。
接口域名请参考[获取盘古服务外部APIG域名](#)获取。

URI

GET /v1/{project_id}/workspaces

表 3-769 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-770 Query 参数

参数	是否必选	参数类型	描述
user_id	否	String	参数解释： 用户ID，用于查询指定用户加入的工作空间列表，您可以参考获取用户ID获取。 约束限制： user_id不为空，则返回user_id所在工作空间列表。 user_id为空，如果鉴权时token用户的权限是vdc_admin则返回资源空间下所有空间，否则返回所在工作空间列表。 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-771 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码： 200

表 3-772 响应 Body 参数

参数	参数类型	描述
workspaces	Array of WorkspaceDto objects	参数解释： 符合条件空间列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
count	Integer	参数解释： 空间数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-773 WorkspaceDto

参数	参数类型	描述
id	String	参数解释: 空间ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
name	String	参数解释: 空间名称。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
eps_id	String	参数解释: 企业项目ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
description	String	参数解释: 空间描述。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
project_id	String	参数解释： 项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
domain_id	String	参数解释： 华为云账号ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
source	Integer	参数解释： 空间来源，当前仅支持0，表明空间是来自“新建工作空间”接口创建的空间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_owner	String	参数解释： 空间所有者用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_user	String	参数解释： 创建空间的用户名。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_user	String	参数解释： 对空间执行过更新操作的用户名。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 空间创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 空间更新时间，调用空间更新接口时该字段会刷新为最新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	Integer	参数解释： 空间状态。 约束限制： 不涉及 取值范围： ● 0：空间正常使用中 ● 1：空间正在删除中 ● 2：空间已被删除 默认取值： 不涉及
extend_properties	String	参数解释： 扩展字段。 扩展字段为json结构，最外层的key为属性类型，如果字段需要加密需要在前面加上SECRET@。比如obs配置信息：{"obs": {"ak": "xxx", "sk": "xxx", "bucket_name": "bucket1"}} 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-774 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

无

响应示例

状态码： 200

成功响应示例

```
{
  "id": "e9584681-8b94-11ef-9709-0255ac100056",
  "name": "test11111",
  "eps_id": "",
  "description": "111111",
  "project_id": "0ba805c3edf64df48732c5bf47c40e70",
  "domain_id": "f7d716ba5f5d474f8480efb926fabd1b",
  "source": 0,
  "workspace_owner": "c1764f03893744fe96648ae747198cbe",
  "create_user": "lizhe",
  "update_user": "lizhe",
  "create_time": "2024-10-16T08:01:55Z",
  "update_time": "2024-10-16T08:07:35Z",
  "status": 0,
  "extend_properties": "{\"obs\":{\"ak\":\"111111\",\"bucket_name\":\"\",\"sk\":\"*****\"}}"
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.11.2 修改工作空间

功能介绍

修改工作空间，支持对工作空间名称、描述、扩展字段进行修改。

URI

PUT /v1/{project_id}/workspaces/{workspace_id}

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

表 3-775 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-776 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-777 请求 Body 参数

参数	是否必选	参数类型	描述
name	否	String	参数解释： 空间名称。 约束限制： 字符串只能由数字、英文字母、中文字符、下划线或短横线组成。 取值范围： 1-32字符 默认取值： 不涉及
description	否	String	参数解释： 空间描述。 约束限制： 不涉及 取值范围： 0-4096字符 默认取值： 不涉及
extend_properties	否	Object	参数解释： 扩展字段，可参考 CreateWorkspace ，修改时会全量覆盖当前保存的 extend_properties，如果只期望修改某个字段，需要通过查询空间详情接口获取全量 extend_properties 然后进行修改，不能只传要修改的字段。 约束限制： 不涉及 取值范围： 0-4096字符 默认取值： 不涉及

响应参数

状态码：200

表 3-778 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
name	String	参数解释： 空间名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
description	String	参数解释： 空间描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 华为云项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
domain_id	String	参数解释： 华为云账号ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
source	Integer	参数解释： 空间来源，当前仅支持0，表明空间是来自“新建工作空间”接口所创建的。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_owner	String	参数解释： 空间所有者的华为云用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_user	String	参数解释： 创建空间的用户的华为云用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
update_user	String	参数解释： 更新空间的用户的华为云用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 空间创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 空间更新时间，调用创建接口或更新时间后update_time会刷新为当前时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
status	Integer	参数解释： 空间状态。 约束限制： 不涉及 取值范围： • 0 空间正常使用中 • 1 空间正在删除中 • 2 空间已被删除 默认取值： 不涉及

参数	参数类型	描述
extend_properties	String	参数解释： 扩展字段，为json结构，最外层的key为属性类型，如果字段需要加密需要在前面加上SECRET@。比如obs配置信息： {"obs": {"ak": "xxx", "sk": "xxx", "bucket_name": "bucket1"}} 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

对工作空间的名称、描述、扩展字段进行修改

```
{
  "name" : "my workspace",
  "description" : "this is a demo",
  "extend_properties" : "default"
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "id" : "e9584681-8b94-11ef-9709-0255ac100056",
  "name" : "test11111",
  "description" : "111111",
  "project_id" : "0ba805c3edf64df48732c5bf47c40e70",
  "domain_id" : "f7d716ba5f5d474f8480efb926fabd1b",
  "source" : 0,
  "workspace_owner" : "c1764f03893744fe96648ae747198cbe",
  "create_user" : "lizhe",
  "update_user" : "lizhe",
  "create_time" : "2024-10-16T08:01:55Z",
  "update_time" : "2024-10-16T08:07:35Z",
  "status" : 0,
  "extend_properties" : "{\"obs\":{\"ak\":\"111111\",\"bucket_name\":\"\",\"sk\":\"*****\"}}"
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.11.3 删除 Workspace

功能介绍

删除指定工作空间。

URI

DELETE /v1/{project_id}/workspaces/{workspace_id}

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-779 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-780 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

请求示例

无

响应示例

状态码：200

成功响应示例

"ok"

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.11.4 新建工作空间

功能介绍

创建工作空间，基于工作空间可以创建训练、部署、评测任务。

URI

POST /v1/{project_id}/workspaces

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

表 3-781 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-782 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-783 请求 Body 参数

参数	是否必选	参数类型	描述
name	是	String	参数解释： 空间名称。 约束限制： 字符串只能由数字、英文字母、中文字符、下划线或短横线组成。 取值范围： 1-32字符 默认取值： 不涉及

参数	是否必选	参数类型	描述
description	否	String	参数解释： 空间描述。 约束限制： 不涉及 取值范围： 0-4096字符 默认取值： 不涉及
extend_properties	否	Map<String,Object>	参数解释： 扩展字段，为json结构，最外层的key为属性类型，如果字段需要加密需要在前面加上SECRET@。比如obs配置信息： {"obs": {"ak": "xxx", "sk": "xxx", "bucket_name": "bucket1"}} 约束限制： 不涉及 取值范围： 0-4096字符 默认取值： 不涉及

响应参数

状态码：200

表 3-784 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
name	String	参数解释： 空间名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
description	String	参数解释： 空间描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 华为云项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
domain_id	String	参数解释： 华为云账号ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
source	Integer	参数解释： 空间来源，当前仅支持0，表明空间是来自“新建工作空间”接口所创建的。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_owner	String	参数解释： 空间所有者的华为云用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_user	String	参数解释： 创建空间的用户的华为云用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_user	String	参数解释： 更新空间的用户的华为云用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time	String	参数解释： 空间创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 空间更新时间，调用创建接口或更新时间后update_time会刷新为当前时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
status	Integer	参数解释： 空间状态。 约束限制： 不涉及 取值范围： • 0 空间正常使用中 • 1 空间正在删除中 • 2 空间已被删除 默认取值： 不涉及

参数	参数类型	描述
extend_properties	String	参数解释： 扩展字段，为json结构，最外层的key为属性类型，如果字段需要加密需要在前面加上SECRET@。比如obs配置信息： {"obs": {"ak": "xxx", "sk": "xxx", "bucket_name": "bucket1"}} 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

创建工作空间

```
{
  "name" : "my workspace",
  "description" : "this is a demo",
  "extend_properties" : "{ \"obs\": { \"ak\": \"YSxxxCC\", \"sk\": \"SECRET@Hxxx3\", \"bucket_name\": \"bucket1\" } }"
}
```

响应示例

状态码：200

成功响应示例

```
{
  "id" : "e9584681-8b94-11ef-9709-0255ac100056",
  "name" : "test11111",
  "description" : "111111",
  "project_id" : "0ba805c3edf64df48732c5bf47c40e70",
  "domain_id" : "f7d716ba5f5d474f8480efb926fabd1b",
  "source" : 0,
  "workspace_owner" : "c1764f03893744fe96648ae747198cbe",
  "create_user" : "lizhe",
  "update_user" : "lizhe",
  "create_time" : "2024-10-16T08:01:55Z",
  "update_time" : "2024-10-16T08:07:35Z",
  "status" : 0,
  "extend_properties" : "{ \"obs\": { \"ak\": \"111111\", \"bucket_name\": \"\", \"sk\": \"*****\" } }"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.11.5 查询 Workspace

功能介绍

根据空间id查询工作空间详细信息。

URI

GET /v1/{project_id}/workspaces/{workspace_id}

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-785 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-786 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-787 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
name	String	参数解释： 空间名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
description	String	参数解释： 空间描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 华为云项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
domain_id	String	参数解释： 华为云账号ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
source	Integer	参数解释： 空间来源，当前仅支持0，表明空间是来自“新建工作空间”接口所创建的。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_owner	String	参数解释： 空间所有者的华为云用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_user	String	参数解释： 创建空间的用户的华为云用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_user	String	参数解释： 更新空间的用户的华为云用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time	String	参数解释： 空间创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 空间更新时间，调用创建接口或更新时间后update_time会刷新为当前时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
status	Integer	参数解释： 空间状态。 约束限制： 不涉及 取值范围： • 0 空间正常使用中 • 1 空间正在删除中 • 2 空间已被删除 默认取值： 不涉及

参数	参数类型	描述
extend_properties	String	参数解释： 扩展字段。 扩展字段为json结构，最外层的key为属性类型，如果字段需要加密需要在前面加上SECRET@。比如obs配置信息： {"obs": {"ak": "xxx", "sk": "xxx", "bucket_name": "bucket1"}} 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

状态码：200

成功响应示例

```
{
  "id" : "e9584681-8b94-11ef-9709-0255ac100056",
  "name" : "test11111",
  "description" : "111111",
  "project_id" : "0ba805c3edf64df48732c5bf47c40e70",
  "domain_id" : "f7d716ba5f5d474f8480efb926fabd1b",
  "source" : 0,
  "workspace_owner" : "c1764f03893744fe96648ae747198cbe",
  "create_user" : "lizhe",
  "update_user" : "lizhe",
  "create_time" : "2024-10-16T08:01:55Z",
  "update_time" : "2024-10-16T08:07:35Z",
  "status" : 0,
  "extend_properties" : "{\"obs\":{\"ak\":\"111111\",\"bucket_name\":\"\",\"sk\":\"*****\"}}"
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.12 资产管理

3.12.1 查询指定空间内的模型资产列表

功能介绍

查询指定空间内的模型资产列表。

接口域名请参考[获取盘古服务外部API域名](#)获取。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/asset-manager/model-assets

表 3-788 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 数据集所在空间的空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-789 Query 参数

参数	是否必选	参数类型	描述
action_type	否	String	参数解释： 操作类型，PRETRAIN/SFT/RLHF/TRANSFORM/QUANTIZATION/EVALUATION/ONLINE-DEPLOY/EDGE-DEPLOY，分别表示预训练/SFT微调/强化学习/转换/量化/评测/在线部署/边缘部署。 约束限制： 不涉及 取值范围： PRETRAIN/SFT/RLHF/TRANSFORM/QUANTIZATION/EVALUATION/ONLINE-DEPLOY/EDGE-DEPLOY 默认取值： 不涉及
asset_ids	否	Array of strings	参数解释： 根据资产ID集合对查询结果进行过滤查询。资产ID需要数据库中进行查询，可联系盘古大模型服务技术支持获取。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
asset_type	否	String	参数解释： 模型类型，NLP/CV/MM/AI4Science/Predict/Profession，分别表示NLP大模型/CV大模型/多模态大模型/科学计算大模型/预测大模型/BI专业大模型。 约束限制： 不涉及 取值范围： 不NLP/CV/MM/AI4Science/Predict/Profession 默认取值： 不涉及
sub_asset_type	否	String	参数解释： 模型子类型，仅科学计算模型生效，取值为Weather_1h、Weather_3h、Weather_6h、Weather_24h、Precip_6h、Ocean_Swell_24h、Ocean_Regional_24h、Ocean_24h。分别表示天气1h、3h、6h、24h、海浪智能预报24h等子类型，用于模型细分查询。 约束限制： 不涉及 取值范围： Weather_1h、Weather_3h、Weather_6h、Weather_24h、Precip_6h、Ocean_Swell_24h、Ocean_Regional_24h、Ocean_24h 默认取值： 不涉及

参数	是否必选	参数类型	描述
sub_asset_type_snip	否	String	参数解释： 模型子类型，可以按照 sub_asset_type 参数的枚举值进行模糊搜索，例如搜索 Weather，Ocean 等公共前缀过滤关键字，用于模糊查询。 约束限制： 仅科学计算模型生效。 取值范围： 不涉及 默认取值： 不涉及
asset_source	否	String	参数解释： 资产来源，默认查询所有来源的模型。来源有Preset/Publish/Import/AI Hub，分别表示预置模型/本空间的模型/导入至空间的模型/订阅的模型。 约束限制： 不涉及 取值范围： Preset/Publish/Import/AI Hub 默认取值： 不涉及
asset_feature	否	String	参数解释： 资产特性。NLP模型为存储参数量，取值有7B，38B。科学计算模型为哈希值，需要在数据库中进行查询，可联系服务技术支持获取。其他类型模型无此参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
user_id	否	String	参数解释： 模型训练完成后，执行发布操作的用户所对应的用户ID，用于界面展示模型列表时，进行模型过滤。可在ManageOne“个人设置”页面查询。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_code	否	String	参数解释： 模型编码，如Pangu-NLP-N1-xxx。取值需要在数据库中进行查询，可联系盘古大模型服务技术支持获取。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_source	否	String	参数解释： 空间来源，是本空间或其他空间，枚举值为current、others。 约束限制： 不涉及 取值范围： current、others 默认取值： 不涉及

参数	是否必选	参数类型	描述
category	否	String	参数解释： 模型分类，盘古模型或三方模型，枚举值为pangu，3rd。 约束限制： 不涉及 取值范围： pangu，3rd 默认取值： 不涉及
is_op_user	否	Boolean	参数解释： 是否是承载租户，承载租户查询为1，普通租户为0。填写user_id参数时，is_op_user需要设置为0。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-790 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码： 200

表 3-791 响应 Body 参数

参数	参数类型	描述
[数组元素]	Array<Array< ModelAsset > >	参数解释： 模型资产信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-792 ModelAsset

参数	参数类型	描述
asset_id	String	参数解释： 模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
root_asset_id	String	参数解释： 来源于哪个预置模型资产ID。若本模型是预置模型，和asset_id值一样，若是用户模型，根据本模型的asset_code, asset_version和asset_type='Preset'可找到预置模型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_name	String	参数解释： 模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_name_en	String	参数解释： 模型英文名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_desc	String	参数解释： 模型描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_version	String	参数解释： 模型版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
external_version	String	参数解释： 对外展示的模型版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_available	Boolean	参数解释： 模型是否对外可见。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_group_desc	String	参数解释： 模型族描述信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
category	String	参数解释： 类别，盘古模型或三方模型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
storage_type	String	参数解释： 存储类型。 约束限制： 不涉及 取值范围： ● OBS存储：OBS ● 纯镜像：Image 默认取值： 不涉及
asset_location	String	参数解释： 模型在OBS存储位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_config_location	String	参数解释： 推理资产所需的配置文件，发布时需要将此目录复制至产物路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_type	String	参数解释： 模型类型，NLP/CV/MM/AI4Science/Predict/Profession，分别表示NLP大模型/CV大模型/多模态大模型/科学计算大模型/预测大模型/BI专业大模型。 约束限制： 不涉及 取值范围： NLP/CV/MM/AI4Science/Predict/Profession 默认取值： 不涉及
sub_asset_type	String	参数解释： 模型子类型，按需设置。 约束限制： AI4Science时，为AI4Science_Weather，AI4Science_Drug，其他模型暂无。 取值范围： 不涉及 默认取值： 不涉及
asset_code	String	参数解释： 模型族谱编码，用于表示模型类型和版本信息，例如Pangu-NLP-N1-Default-2K-L0.C-3.0。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_source	String	参数解释： 资产来源。 约束限制： 不涉及 取值范围： Preset(预置模型)，AI Hub(订阅的模型)，Publish(本空间的模型)，Import(导入至空间的模型) 默认取值： 不涉及

参数	参数类型	描述
asset_feature	String	参数解释： 资产特性。NLP模型为存储参数量，取值有7B，38B。科学计算模型为哈希值，需要在数据库中进行查询，可联系服务技术支持获取。其他类型模型无此参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 模型归属项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	String	参数解释： 模型归属空间ID，发布，导入时，值为涉及空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_tag	String	参数解释： 模型标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
security_policy	String	参数解释： 安全策略。 约束限制： 不涉及 取值范围： - PLAIN：明文 - AES256：加密 - OBFUSCATE：混淆 - SCCBase64：CV加密 默认取值： 不涉及
encode_type	String	参数解释： 编码方式：BASE64。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_password	String	参数解释： 模型加密场景下对应的模型密码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
properties	Map<String,Object>	参数解释： 存储公共变量信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
actions	Array of ModelAction objects	参数解释： 模型支持的操作列表信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_model_id	String	参数解释： 业务侧存储的模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_artifact_id	String	参数解释： 用户发布的模型，所关联的训练模块中对应该模型artifact，一个artifact表示一个模型产物。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_model_source_operation	String	参数解释： 用户发布模型，来源操作类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
user_model_source_job_name	String	参数解释： 用户发布模型，来源任务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_model_source_job_id	String	参数解释： 用户发布模型，来源任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
creator	String	参数解释： 模型创建者。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_id	String	参数解释： 模型创建者ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time	String	参数解释： 模型创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 模型更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
root_asset_name	String	参数解释： 模型来源名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
visibility	String	参数解释： 模型可见性。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
resource_charging_mode	Integer	参数解释： 该参数无实际含义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
execute_id	String	参数解释： 生成该模型时用到的工作流。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 生成该模型时用到的数据集。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-793 ModelAction

参数	参数类型	描述
action_id	String	参数解释： 模型的操作ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_id	String	参数解释： 模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_id	String	参数解释： 工作流ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
action_name	String	参数解释： 模型的操作名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
action_type	String	参数解释： 操作类型定义。 PRETRAIN/SFT/RLHF/TRANSFORM/ QUANTIZATION/EVALUATION/ONLINE- DEPLOY/EDGE-DEPLOY，分别表示预训练/SFT微 调/强化学习/转换/量化/评测/在线部署/边缘部 署。 约束限制： 不涉及 取值范围： PRETRAIN/SFT/RLHF/TRANSFORM/ QUANTIZATION/EVALUATION/ONLINE- DEPLOY/EDGE-DEPLOY 默认取值： 不涉及

参数	参数类型	描述
asset_tag	String	参数解释： 模型标签，如NLP-N1-PERTRAIN。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
depend_assets	Array of ModelAsset objects	参数解释： 依赖的模型标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
super_params	Map<String, Object>	参数解释： 超参定义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
action_env	Array of ActionEnvObj objects	参数解释： 环境变量定义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
action_properties	Map<String,Object>	参数解释: 附加属性定义。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
command	String	参数解释: 执行命令。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
support_checkpoint	String	参数解释: 模型是否支持断点续训。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
sub_dir	String	参数解释: 子目录。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
image	String	参数解释： 镜像。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow	Workflow object	参数解释： 工作流定义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
resources	Array of ActionResource objects	参数解释： 资源信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
use_api_proxy	Boolean	参数解释： 推理是否支持标准API接口(false：透传，true：转发)。 约束限制： 不涉及 取值范围： ● false：透传 ● true：转发 默认取值： 不涉及

参数	参数类型	描述
olc	Map<String,Object>	参数解释： 推理流控配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 模型操作创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 模型操作更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-794 ActionEnvObj

参数	参数类型	描述
env_name	String	参数解释： 环境变量名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
default_value	String	参数解释： 环境变量默认值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
modifiable	Boolean	参数解释： 环境变量是否可更改。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
displayable	Boolean	参数解释： 环境变量是否可显示。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
data_type	String	参数解释： 环境变量的数据类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-795 Workflow

参数	参数类型	描述
workflow_id	String	参数解释： 工作流ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_name	String	参数解释： 工作流名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_name_en	String	参数解释： 工作流英文名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_desc	String	参数解释： 工作流描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
workflow_version	String	参数解释： 工作流版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_tag	String	参数解释： 工作流标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_source	String	参数解释： 资产来源：如平台预置/用户导入。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_location	String	参数解释： 工作流存储位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
dataset_type	String	参数解释： 数据集类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
content_id	String	参数解释： 工作流在AI Hub中注册的资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
depend_content_ids	Array of strings	参数解释： 工作流在AI Hub中注册依赖的算法资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
supported_model_versions	Array of SupportedModelInfo objects	参数解释： 支持的模型版本列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time	String	参数解释: 创建时间。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
update_time	String	参数解释: 更新时间。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-796 SupportedModelInfo

参数	参数类型	描述
asset_code	String	参数解释: 支持的模型的asset_code。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
versions	Array of SupportedModelInfoDetail objects	参数解释: 工作流支持的模型版本和动作信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-797 SupportedModelInfoDetail

参数	参数类型	描述
version	String	参数解释: 工作流支持的模型版本。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
action_type	String	参数解释: 工作流支持的模型的某个动作。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-798 ActionResource

参数	参数类型	描述
resource_id	String	参数解释: 资源ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
action_id	String	参数解释: 关联的动作ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
image_id	String	参数解释: 镜像ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
cpu	Float	参数解释: 要求CPU核数默认值。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
min_cpu	Float	参数解释: 最小要求CPU核数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
max_cpu	Float	参数解释: 最大要求CPU核数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
memory	Float	参数解释: 要求内存数默认值，默认以MB为单位。同上 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
min_memory	Float	参数解释: 最小要求内存数，默认以MB为单位。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
max_memory	Float	参数解释: 最大要求内存数，默认以MB为单位。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
flavor	String	参数解释: flavor默认值为custom，表示基于数据库表的memory, card取值进行资源消耗；非custom则表示ModelArts资源池中具体消耗信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
card_count	Float	参数解释： 需要卡数默认值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
min_card_count	Float	参数解释： 最小要求的卡数量，比如8。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max_card_count	Float	参数解释： 最大要求的卡数量，比如64。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
card_step	Float	参数解释： 卡步长定义，比如8。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
chip_type	String	参数解释： 芯片类型，枚举值：Snt9B3/Snt9B4/D310P。 约束限制： 不涉及 取值范围： Snt9B3/Snt9B4/D310P 默认取值： 不涉及
device_type	String	参数解释： 驱动类型（NPU，NONE）。 约束限制： 不涉及 取值范围： NPU，NONE 默认取值： 不涉及
driver_version	String	参数解释： 驱动版本，23.0.7。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image	Image object	参数解释： 模型关联镜像。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time	String	参数解释： 模型操作类型创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 模型操作类型更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-799 Image

参数	参数类型	描述
image_id	String	参数解释： 镜像ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_name	String	参数解释： 镜像名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
image_version	String	参数解释： 镜像版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_desc	String	参数解释： 镜像描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_url	String	参数解释： 镜像存放地址。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_port	String	参数解释： 镜像端口。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
image_tag	String	参数解释： 镜像标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
arch	String	参数解释： 架构。 约束限制： 不涉及 取值范围： ARM，X86 默认取值： 不涉及
input_types	Array of strings	参数解释： 异步模型支持的输入数据类型列表。 约束限制： 不涉及 取值范围： OBS/VCN/URL/edgerestful/EdgeCamera 默认取值： 不涉及
output_types	Array of strings	参数解释： 异步模型支持的输出数据类型列表，包括OBS/ Webhook。 约束限制： 不涉及 取值范围： OBS/Webhook 默认取值： 不涉及

参数	参数类型	描述
request_mode	String	参数解释： 部署模式。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_config	String	参数解释： 异步：服务配置信息。 约束限制： 为xml格式的字符串。 取值范围： 不涉及 默认取值： 不涉及
task_config	String	参数解释： 异步：任务配置信息。 约束限制： 为xml格式的字符串。 取值范围： 不涉及 默认取值： 不涉及
apis	Map<String,Object>	参数解释： 同步：API信息，为结构体 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
protocol	String	参数解释： 通信协议，枚举值：https/http。 约束限制： 不涉及 取值范围： https/http 默认取值： 不涉及
health_check	Map<String,Object>	参数解释： 安全检查项。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
supported_model_versions	Array of strings	参数解释： 镜像支持的模型版本信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
mount_type	String	参数解释： 镜像加载，枚举值：OBS、SFSTurbo、ENV、None。 约束限制： 不涉及 取值范围： OBS、SFSTurbo、ENV、None 默认取值： 不涉及

参数	参数类型	描述
mount_location	String	参数解释： 镜像加载位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
mount_env_key	String	参数解释： 环境变量加载时，使用的key（键）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
depends_locations	Array of DependLocation objects	参数解释： 依赖的镜像加载配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 镜像表创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
update_time	String	参数解释： 镜像表更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-800 DependLocation

参数	参数类型	描述
asset_name	String	参数解释： 模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_code	String	参数解释： 模型编码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_version	String	参数解释： 模型版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
mount_type	String	参数解释： 绑定的类型。 约束限制： 不涉及 取值范围： OBS，SFSTurbo，ENV，None 默认取值： 不涉及
mount_location	String	参数解释： 绑定挂载路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
mount_env_key	String	参数解释： 环境变量类型的绑定Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-801 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

查询指定空间内的模型资产列表

```
https://127.0.0.1:31016/v1/f0666bc5e820461dac713be6ef1a1d0f/workspaces/7dd73f3f-111a-11ef-b41f-0255ac1000b9/asset-manager/model-assets?asset_code=Pangu-MM-M4-Img2Txt-4K-L0.C-5.0&asset_source=Preset&action_type=SFT
```

响应示例

状态码： 200

成功响应示例

```
[{
  "asset_id": "c6996e1e-3337-4a92-83cc-868246018ee6",
  "root_asset_id": "c6996e1e-3337-4a92-83cc-868246018ee6",
  "asset_name": "盘古-MM-M4-图生文模型-4K",
  "asset_name_en": "Pangu-MM-M4-Img2Txt-4K-L0.C-5.0",
  "asset_desc": "盘古-MM-M4-图生文模型-4K-20240930",
  "asset_version": "1.0.2",
  "storage_type": "OBS",
  "asset_location": "obs://largemodelstudio-assets/preset-workspace/modelassets/MM/Pangu-MM-M4-Img2Txt-4K-L0.C-5.0/1.0.2/models",
  "asset_config_location": "/infer/config",
  "asset_type": "MM",
  "sub_asset_type": "",
  "asset_code": "Pangu-MM-M4-Img2Txt-4K-L0.C-5.0",
  "asset_source": "Preset",
  "asset_feature": "135B",
  "asset_tag": "SFT,ONLINE-DEPLOY",
  "security_policy": "AES256",
  "asset_password": "xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx",
  "properties": {
    "tokenizer_path": "obs://largemodelstudio-assets/preset-workspace/modelassets/MM/Pangu-MM-M4-Img2Txt-4K-L0.C-5.0/1.0.2/models/tokenizer/PanguTokenizer3_Vocab11_71b-60k_38b_7b.pangu"
  },
  "actions": [ {
    "action_id": "70ace299-154f-43c8-92a7-85e1210c6bce",
    "asset_id": "c6996e1e-3337-4a92-83cc-868246018ee6",
    "workflow_id": "5acbc190-d423-4c48-ba0a-11b752cab054",
    "action_name": "ACTION_SFT",
    "action_type": "SFT",
    "asset_tag": "SFT",
    "depend_assets": [ ],
    "super_params": { },
    "action_env": [ ],
    "action_properties": {
      "Snt9B3": {
        "GE_USE_STATIC_MEMORY": "2",
        "MS_ENABLE_GE": "1",
        "GLOG_v": "3",
        "MS_DEV_CELL_REUSE": "1",
        "PP_PARALLEL_NUM": "8",
        "DEBUG_ROUTE_PLAN": "true",
        "OBS_DEFAULT_PART_SIZE": "1048576000",
        "MS_ENABLE_FORMAT_MODE": "1",
        "MS_MEMORY_STATISTIC": "1",
        "ASCEND_SLOG_PRINT_TO_STDOUT": "0",
        "MAX_DEVICE_MEMORY": "55GB",
        "MS_ENABLE_REF_MODE": "1",
        "MS_GE_TRAIN": "1",
        "MA_MOXING_FWVER": "2.1.6.672328e8",
        "MS_DATASET_SINK_QUEUE": "5",
        "ASCEND_GLOBAL_EVENT_ENABLE": "0",
        "SOLUTION": "HCS",
        "ROUTE_PLAN": "true",
        "IAM_CONCURRENT_SLEEP_SEC": "150",
        "ASCEND_GLOBAL_LOG_LEVEL": "3",
        "ROPE_INTERPOLATION": "1",
        "Tensor_parallel_size": "8",
        "CHANGE_UPLOAD_FILE_ACL": "true",

```

```
"PIPELINE_SLICE_SKIP_REDISTRIBUTION" : "1",
"MS_ASCEND_CHECK_OVERFLOW_MODE" : "INFNAN_MODE",
"MA_DETECT_TRAIN_INJECT_CODE" : "0"
}
},
"command" : "",
"support_checkpoint" : "1",
"sub_dir" : "/model",
"workflow" : {
  "workflow_id" : "5acbc190-d423-4c48-ba0a-11b752cab054",
  "workflow_name" : "pangu-mm-m4-img2txt-4k-workflow",
  "workflow_name_en" : "pangu-mm-m4-img2txt-4k-workflow",
  "workflow_desc" : "盘古-MM-M4-图生文模型-4K-流水线",
  "workflow_version" : "1.0.2",
  "workflow_tag" : "MM-M4-SFT",
  "workflow_source" : "preset",
  "workflow_location" : "Pangu-MM-M4-Img2Txt-4K-L0.C-5.0/1.0.2/metadata.json",
  "dataset_type" : "MLLM-N4-SFT",
  "content_id" : "581ac0c4-e5d5-4509-aa1a-a1266c427c6f",
  "depend_content_ids" : [ "c7caf80b-4bc7-4e0b-b74d-b096a085e1cc" ],
  "supported_model_versions" : [ {
    "versions" : [ {
      "action_type" : "SFT",
      "version" : "1.0.2"
    } ],
    "asset_code" : "Pangu-MM-M4-Img2Txt-4K-L0.C-5.0"
  } ],
  "create_time" : "2024-08-01 10:53:55",
  "update_time" : "2024-08-01 10:53:55"
},
"resources" : [ {
  "resource_id" : "fe21ca1b-b2b4-4c53-8fc5-0b69b23cf3bd",
  "action_id" : "70ace299-154f-43c8-92a7-85e1210c6bce",
  "flavor" : "custom",
  "card_count" : 64,
  "min_card_count" : 64,
  "max_card_count" : 64,
  "card_step" : 64,
  "chip_type" : "Snt9B3",
  "device_type" : "NPU",
  "driver_version" : "23.0.RC3",
  "create_time" : "2024-08-01 10:53:49",
  "update_time" : "2024-08-01 10:53:49",
  "computility" : "313t"
} ],
"create_time" : "2024-08-01 10:53:49",
"update_time" : "2024-08-01 10:53:55"
} ],
"create_time" : "2024-08-01 10:53:49",
"update_time" : "2024-08-01 10:53:49",
"root_asset_name" : "盘古-MM-M4-图生文模型-4K",
"visibility" : "all"
}]
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.12.2 查询指定空间内的模型资产详情

功能介绍

查询指定空间内的模型资产详情。

接口域名请参考[获取盘古服务外部API域名](#)获取。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/asset-manager/model-assets/{asset_id}

表 3-802 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
asset_id	是	String	参数解释： 资产ID。 资产ID需要数据库中进行查询，可联系服务技术支持获取。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-803 Query 参数

参数	是否必选	参数类型	描述
action_asset_tag	否	String	参数解释： 根据此模型标签进行过滤。例如查询标签为“NLP-N1-PERTRAIN”的模型信息。需要数据库中进行查询，可联系盘古大模型服务技术支持获取。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_all_action	否	Boolean	参数解释： 是否展示所有的模型支持的操作信息。 约束限制： 不涉及 取值范围： • true：展示模型所有的actions • false：默认按需展示action 默认取值： 不涉及

请求参数

表 3-804 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码： 200

表 3-805 响应 Body 参数

参数	参数类型	描述
asset_id	String	参数解释： 模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
root_asset_id	String	参数解释： 来源于哪个预置模型资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_name	String	参数解释： 模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_name_en	String	参数解释： 模型英文名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_desc	String	参数解释： 模型描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_version	String	参数解释： 模型版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
external_version	String	参数解释： 对外展示的模型版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_available	Boolean	参数解释： 模型是否对外可见。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_group_desc	String	参数解释： 模型族描述信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
category	String	参数解释： 项类别，盘古模型或三方模型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
storage_type	String	参数解释： 存储类型。 约束限制： 不涉及 取值范围： ● OBS存储：OBS ● 纯镜像：Image 默认取值： 不涉及
asset_location	String	参数解释： 模型在OBS存储位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_config_location	String	参数解释： 推理资产所需的配置文件，发布时需要将此目录复制至产物路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_type	String	参数解释: 模型类型，NLP/CV/MM/AI4Science/Predict/Profession，分别表示NLP大模型/CV大模型/多模态大模型/科学计算大模型/预测大模型/BI专业大模型。 约束限制: 不涉及 取值范围: NLP/CV/MM/AI4Science/Predict/Profession 默认取值: 不涉及
sub_asset_type	String	参数解释: 模型子类型，取值为Weather_1h, Weather_3h, Weather_6h, Weather_24h, Precip_6h, Ocean_Swell_24h, Ocean_Regional_24h, Ocean_24h。分别表示天气1h, 3h, 6h, 24h, 海浪智能预报24h等子类型，用于模型细分查询。 约束限制: 仅科学计算模型生效。 取值范围: Weather_1h, Weather_3h, Weather_6h, Weather_24h, Precip_6h, Ocean_Swell_24h, Ocean_Regional_24h, Ocean_24h 默认取值: 不涉及
asset_code	String	参数解释: 模型族谱编码，用于表示模型类型和版本信息，例如Pangu-NLP-N1-Chat-32K。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
asset_source	String	参数解释： 资产来源。 约束限制： 不涉及 取值范围： Preset(预置模型)，AI Hub(订阅的模型)，Publish(本空间的模型)，Import(导入至空间的模型) 默认取值： 不涉及
asset_feature	String	参数解释： 资产特性。NLP模型为存储参数量，取值有7B，38B。科学计算模型为哈希值。其他类型模型无此参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 模型归属项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	String	参数解释： 模型归属空间ID，发布，导入时，值为涉及空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_tag	String	参数解释： 模型标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
security_policy	String	参数解释： 安全策略。 约束限制： 不涉及 取值范围： ● PLAIN：明文 ● AES256：加密 ● OBFUSCATE：混淆 ● SCCBase64：CV加密 默认取值： 不涉及
encode_type	String	参数解释： 编码方式：BASE64。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_password	String	参数解释： 模型加密场景下对应的模型密码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
properties	Map<String,Object>	参数解释: 存储公共变量信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
actions	Array of ModelAction objects	参数解释: 模型支持的操作列表信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
user_model_id	String	参数解释: 业务侧存储的模型ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
user_artifact_id	String	参数解释: 用户发布的模型，所关联的训练模块中对应该模型artifact，一个artifact表示一个模型产物。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
user_model_source_operation	String	参数解释： 用户发布模型，来源操作类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_model_source_job_name	String	参数解释： 用户发布模型，来源任务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_model_source_job_id	String	参数解释： 用户发布模型，来源任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
creator	String	参数解释： 模型创建者。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
user_id	String	参数解释： 模型创建者ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 模型创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 模型更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
root_asset_name	String	参数解释： 模型来源名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
visibility	String	参数解释： 模型可见性。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
resource_charging_mode	Integer	参数解释： 该参数无实际含义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
execute_id	String	参数解释： 生成该模型时用到的工作流。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 生成该模型时用到的数据集。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-806 ModelAction

参数	参数类型	描述
action_id	String	参数解释： 模型操作ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_id	String	参数解释： 资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_id	String	参数解释： 工作流ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
action_name	String	参数解释： 操作名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
action_type	String	参数解释： 操作类型定义， PRETRAIN/SFT/RLHF/TRANSFORM/ QUANTIZATION/EVALUATION/ONLINE- DEPLOY/EDGE-DEPLOY，分别表示预训练/SFT微 调/强化学习/转换/量化/评测/在线部署/边缘部署 约束限制： 不涉及 取值范围： PRETRAIN/SFT/RLHF/TRANSFORM/ QUANTIZATION/EVALUATION/ONLINE- DEPLOY/EDGE-DEPLOY 默认取值： 不涉及
asset_tag	String	参数解释： 模型标签，如NLP-N1-PERTRAIN。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
depend_assets	Array of ModelAsset objects	参数解释： 依赖的模型标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
super_params	Map<String,O bject>	参数解释： 超参定义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
action_env	Array of ActionEnvObj objects	参数解释: 环境变量定义。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
action_properties	Map<String,Object>	参数解释: 附加属性定义。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
command	String	参数解释: 执行命令。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
support_checkpoint	String	参数解释: 是否支持断点续训。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
sub_dir	String	参数解释： 该操作在OBS上相对于asset_location的子目录。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image	String	参数解释： 镜像。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow	Workflow object	参数解释： 工作流定义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
resources	Array of ActionResource objects	参数解释： 资源信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
use_api_proxy	Boolean	参数解释： 推理是否支持标准API接口(false：透传，true：转发)。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
olc	Map<String,Object>	参数解释： 推理流控配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 模型操作创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 模型操作更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-807 ModelAsset

参数	参数类型	描述
asset_id	String	参数解释: 模型ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
root_asset_id	String	参数解释: 来源于哪个预置模型资产ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
asset_name	String	参数解释: 模型名称。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
asset_name_en	String	参数解释: 模型英文名称。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
asset_desc	String	参数解释： 模型描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_version	String	参数解释： 模型版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
external_version	String	参数解释： 对外展示的模型版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_available	Boolean	参数解释： 模型是否对外可见。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_group_desc	String	参数解释： 模型族描述信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
category	String	参数解释： 类别，盘古模型或三方模型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
storage_type	String	参数解释： 存储类型。 约束限制： 不涉及 取值范围： ● OBS存储：OBS ● 纯镜像：Image 默认取值： 不涉及
asset_location	String	参数解释： 模型在OBS存储位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_config_location	String	参数解释： 推理资产所需的配置文件，发布时需要将此目录CP至产物路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_type	String	参数解释： 模型类型，NLP/CV/MM/AI4Science/Predict/Profession，分别表示NLP大模型/CV大模型/多模态大模型/科学计算大模型/预测大模型/BI专业大模型。 约束限制： 不涉及 取值范围： NLP/CV/MM/AI4Science/Predict/Profession 默认取值： 不涉及
sub_asset_type	String	参数解释： 模型子类型，取值为Weather_1h, Weather_3h, Weather_6h, Weather_24h, Precip_6h, Ocean_Swell_24h, Ocean_Regional_24h, Ocean_24h。分别表示天气1h, 3h, 6h, 24h, 海浪智能预报24h等子类型，用于模型细分查询。 约束限制： 仅科学计算模型生效。 取值范围： Weather_1h, Weather_3h, Weather_6h, Weather_24h, Precip_6h, Ocean_Swell_24h, Ocean_Regional_24h, Ocean_24h 默认取值： 不涉及

参数	参数类型	描述
asset_code	String	参数解释： 模型族谱编码，用于表示模型类型和版本信息，例如Pangu-NLP-N1-Chat-32K 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_source	String	参数解释： 资产来源。 约束限制： 不涉及 取值范围： Preset(预置模型)，AI Hub(订阅的模型)，Publish(本空间的模型)，Import(导入至空间的模型) 默认取值： 不涉及
asset_feature	String	参数解释： 资产特性。NLP模型为存储参数量，取值有7B，38B。科学计算模型为哈希值，其他类型模型无此参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 模型归属项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
workspace_id	String	参数解释： 模型归属空间ID，发布，导入时，值为涉及空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_tag	String	参数解释： 模型标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
security_policy	String	参数解释： 安全策略。 约束限制： 不涉及 取值范围： ● PLAIN：明文 ● AES256：加密 ● OBFUSCATE：混淆 ● SCCBase64：CV加密 默认取值： 不涉及
encode_type	String	参数解释： 编码方式。 约束限制： 不涉及 取值范围： BASE64 默认取值： 不涉及

参数	参数类型	描述
asset_password	String	参数解释： 模型加密场景下对应的模型密码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
properties	Map<String,Object>	参数解释： 存储公共变量信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
actions	Array of ModelAction objects	参数解释： 模型支持的操作列表信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_model_id	String	参数解释： 业务侧存储的模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
user_artifact_id	String	参数解释： 用户发布的模型，所关联的训练模块中对应该模型artifact，一个artifact表示一个模型产物。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_model_source_operation	String	参数解释： 用户发布模型，来源操作类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_model_source_job_name	String	参数解释： 用户发布模型，来源任务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_model_source_job_id	String	参数解释： 用户发布模型，来源任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
creator	String	参数解释： 模型创建者。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_id	String	参数解释： 模型创建者ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 模型创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 模型更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
root_asset_name	String	参数解释： 模型来源名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
visibility	String	参数解释： 可见性。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
resource_charging_mode	Integer	参数解释： 该参数无实际含义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-808 ActionEnvObj

参数	参数类型	描述
env_name	String	参数解释： 名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
default_value	String	参数解释： 默认值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
modifiable	Boolean	参数解释： 是否可更改。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
displayable	Boolean	参数解释： 是否可显示。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
data_type	String	参数解释： 数据类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-809 Workflow

参数	参数类型	描述
workflow_id	String	参数解释： 工作流ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_name	String	参数解释： 工作流名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_name_en	String	参数解释： 工作流英文名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_desc	String	参数解释： 工作流描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
workflow_version	String	参数解释： 工作流版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_tag	String	参数解释： 工作流标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_source	String	参数解释： 资产来源：如平台预置/用户导入。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_location	String	参数解释： 工作流存储位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
dataset_type	String	参数解释： 数据集类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
content_id	String	参数解释： 工作流在AI Hub中注册的资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
depend_content_ids	Array of strings	参数解释： 工作流在AI Hub中注册依赖的算法资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
supported_model_versions	Array of SupportedModelInfo objects	参数解释： 支持的模型版本列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time	String	参数解释： 创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-810 SupportedModelInfo

参数	参数类型	描述
asset_code	String	参数解释： 支持的模型的asset_code。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
versions	Array of SupportedModelInfoDetail objects	参数解释： 工作流支持的模型版本和动作信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-811 SupportedModelInfoDetail

参数	参数类型	描述
version	String	参数解释: 工作流支持的模型版本。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
action_type	String	参数解释: 工作流支持的模型的某个动作。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-812 ActionResource

参数	参数类型	描述
resource_id	String	参数解释: 资源ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
action_id	String	参数解释: 关联的动作ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
image_id	String	参数解释： 镜像ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cpu	Float	参数解释： 要求CPU核数默认值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
min_cpu	Float	参数解释： 最小要求CPU核数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max_cpu	Float	参数解释： 最大要求CPU核数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
memory	Float	参数解释: 要求内存数默认值，默认以MB为单位。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
min_memory	Float	参数解释: 最小要求内存数，默认以MB为单位。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
max_memory	Float	参数解释: 最大要求内存数，默认以MB为单位。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
flavor	String	参数解释: 表示基于数据库表的memory, card取值进行资源消耗；非custom则表示ModelArts资源池中具体消耗信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: custom

参数	参数类型	描述
card_count	Float	参数解释: 需要卡数默认值。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
min_card_count	Float	参数解释: 最小要求的卡数量，比如8。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
max_card_count	Float	参数解释: 最大要求的卡数量，比如64。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
card_step	Float	参数解释: 卡步长定义,比如8。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
chip_type	String	参数解释： 芯片类型。 约束限制： 不涉及 取值范围： Snt9B3/Snt9B4/D310P 默认取值： 不涉及
device_type	String	参数解释： 驱动类型（ NPU， NONE ）。 约束限制： 不涉及 取值范围： NPU， NONE 默认取值： 不涉及
driver_version	String	参数解释： 驱动版本，如23.0.7。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image	Image object	参数解释： 模型操作对应的镜像。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time	String	参数解释： 模型资源记录创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 模型资源记录更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-813 Image

参数	参数类型	描述
image_id	String	参数解释： 镜像ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_name	String	参数解释： 镜像名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
image_version	String	参数解释： 镜像版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_desc	String	参数解释： 镜像描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_url	String	参数解释： 镜像存放地址。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_port	String	参数解释： 镜像端口。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
image_tag	String	参数解释： 镜像标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
arch	String	参数解释： 架构。 约束限制： 不涉及 取值范围： ARM，X86 默认取值： 不涉及
input_types	Array of strings	参数解释： 异步模型支持的输入数据类型列表。 约束限制： 不涉及 取值范围： OBS/VCN/URL/edgerestful/EdgeCamera 默认取值： 不涉及
output_types	Array of strings	参数解释： 异步模型支持的输出数据类型列表。 约束限制： 不涉及 取值范围： OBS/Webhook 默认取值： 不涉及

参数	参数类型	描述
request_mode	String	参数解释： 部署模式。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_config	String	参数解释： 异步：服务配置信息。 约束限制： 为xml的字符串。 取值范围： 不涉及 默认取值： 不涉及
task_config	String	参数解释： 异步：任务配置信息。 约束限制： 为xml的字符串。 取值范围： 不涉及 默认取值： 不涉及
apis	Map<String,Object>	参数解释： 同步：API信息，为结构体。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
protocol	String	参数解释： 通信协议。 约束限制： 不涉及 取值范围： https/http 默认取值： 不涉及
health_check	Map<String,Object>	参数解释： 安全检查项。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
supported_model_versions	Array of strings	参数解释： 输入模型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
mount_type	String	参数解释： 镜像加载。 约束限制： 不涉及 取值范围： OBS, SFSTurbo, ENV, None 默认取值： 不涉及

参数	参数类型	描述
mount_location	String	参数解释： 镜像加载位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
mount_env_key	String	参数解释： 环境变量加载时，使用的key（键）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
depends_locations	Array of DependLocation objects	参数解释： 依赖的镜像加载配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
update_time	String	参数解释： 更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-814 DependLocation

参数	参数类型	描述
asset_name	String	参数解释： 模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_code	String	参数解释： 模型编码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_version	String	参数解释： 模型版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
mount_type	String	参数解释： 绑定的类型。 约束限制： 不涉及 取值范围： OBS, SFSTurbo, ENV, None 默认取值： 不涉及
mount_location	String	参数解释： 绑定挂载路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
mount_env_key	String	参数解释： 环境变量类型的绑定Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-815 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

查询指定空间内的模型资产详情

```
https://127.0.0.1:31016/v1/f0666bc5e820461dac713be6ef1a1d0f/workspaces/7dd73f3f-111a-11ef-b41f-0255ac1000b9/asset-manager/model-assets/075a7ba6-a14e-419d-bf23-9fb4458b3db7
```

响应示例

状态码： 200

成功响应示例

```
{
  "asset_id": "075a7ba6-a14e-419d-bf23-9fb4458b3db7",
  "root_asset_id": "075a7ba6-a14e-419d-bf23-9fb4458b3db7",
  "asset_name": "Pangu-NLP-N1-Chat-32K-2024103006",
  "asset_name_en": "Pangu-NLP-N1-Chat-32K",
  "asset_desc": "此版本是2024年10月发布的十亿级模型版本，支持8K训练，4K/32K推理。基于昇腾Snt9B3卡可单卡推理部署，此模型版本支持全量微调、LoRA微调、INT8量化、断点续训、模型评测、在线推理和能力调测特性。单卡部署4K模型版本支持64并发，单卡部署32K模型版本支持32并发。模型版本效果达到GPT4-0409 83分位。",
  "asset_version": "3.1.106",
  "external_version": "2024103006",
  "is_available": true,
  "category": "pangu",
  "storage_type": "OBS",
  "asset_location": "obs://largemodelstudio-assets/preset-workspace/modelassets/NLP/Pangu-NLP-N1-Chat-32K/3.1.106/models",
  "asset_config_location": "/infer/config",
  "asset_type": "NLP",
  "sub_asset_type": "",
  "asset_code": "Pangu-NLP-N1-Chat-32K",
  "asset_source": "Preset",
  "asset_feature": "7B",
  "asset_tag": "SFT,LORA,EVALUATION,ONLINE-DEPLOY-4K-1P,ONLINE-DEPLOY-32K-1P",
  "security_policy": "AES256",
  "asset_password": "xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx",
  "properties": {
    "tokenizer_path": "obs://largemodelstudio-assets/preset-workspace/modelassets/NLP/Pangu-NLP-N1-Chat-32K/3.1.106/models/tokenizer/"
  },
  "actions": [
    {
      "action_id": "475ae4a2-ce92-4068-84f5-e42a10f6b9dc",
      "asset_id": "075a7ba6-a14e-419d-bf23-9fb4458b3db7",
      "workflow_id": "66953923-0a98-4464-a38b-46ed6bd7e239",
      "action_name": "ACTION_SFT",
      "action_type": "SFT",
      "asset_tag": "SFT",
      "depend_assets": [],
      "super_params": {},
      "action_env": [],
      "action_properties": {
        "Snt9B3": {
          "TRAIN_TIME_CALU_RULE": "1200+dataT*11059200+dataT*epochs*2560000000000/160/cardsNum+180+120",
          "OUTPUT_ARTIFACTS": "sft_n1_32k.json",
          "GLOG_v": "3",
          "ASCEND_GLOBAL_EVENT_ENABLE": "1",
          "SOLUTION": "STUDIO",
          "MAIN_LOGIC": "pangu_n1_sft/scripts/pangu_n1_32k/run_n1_32k_ascend.sh",
          "HCCL_EXEC_TIMEOUT": "7200",
          "HCCL_CONNECT_TIMEOUT": "7200",
          "ACTION_TYPE": "sft"
        }
      }
    }
  ],
  "command": "",
  "support_checkpoint": "1",
  "sub_dir": "/model",
  "workflow": {
    "workflow_id": "66953923-0a98-4464-a38b-46ed6bd7e239",
    "workflow_name": "NLP-N1-SFT",
    "workflow_name_en": "NLP-N1-SFT",
    "workflow_desc": "N1-微调 workflow",
    "workflow_version": "3.1.106",
  }
}
```

```
{
  "workflow_tag": "workflow-Pangu-NLP-N1-SFT",
  "workflow_source": "preset",
  "workflow_location": "Pangu-NLP-N1-Chat-32K/finetune/3.1.106/metadata.json",
  "dataset_type": "NLP-N1",
  "content_id": "80f99cf9-600d-4ed3-9d99-eefab7945199",
  "depend_content_ids": [
    "5f2b9841-217e-4e0e-995f-720b5123dffb"
  ],
  "supported_model_versions": [
    {
      "versions": [
        {
          "action_type": "SFT",
          "version": "3.1.106"
        }
      ]
    },
    {
      "asset_code": "Pangu-NLP-N1-Chat-32K"
    }
  ],
  "create_time": "2024-11-06 07:33:55",
  "update_time": "2024-11-06 07:33:55"
},
{
  "resources": [
    {
      "resource_id": "a6cd73c8-4773-4b14-8d73-591ffdbd458b",
      "action_id": "475ae4a2-ce92-4068-84f5-e42a10f6b9dc",
      "flavor": "custom",
      "card_count": 8.0,
      "min_card_count": 8.0,
      "max_card_count": 256.0,
      "card_step": 8.0,
      "chip_type": "Snt9B3",
      "device_type": "NPU",
      "driver_version": "23.0.6",
      "create_time": "2024-11-06 15:33:50",
      "update_time": "2024-11-06 15:33:50",
      "computility": "313t"
    }
  ],
  "use_api_proxy": false,
  "create_time": "2024-11-06 07:33:50",
  "update_time": "2024-11-06 07:33:55"
}
],
"create_time": "2024-11-06 07:33:50",
"update_time": "2024-11-06 07:33:50",
"root_asset_name": "Pangu-NLP-N1-Chat-32K",
"visibility": "all",
"resource_charging_mode": 0
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.12.3 获取模型列表

功能介绍

获取训练，推理部署，压缩等所有模型列表。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/asset-manager/model-assets-ext
接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-816 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-817 Query 参数

参数	是否必选	参数类型	描述
limit	否	Integer	参数解释： 分页大小，每一页返回的最大条 目数。 约束限制： 不涉及 取值范围： 0-1000000 默认取值： 10

参数	是否必选	参数类型	描述
offset	否	Integer	参数解释： 分页列表的起始页，默认为0。 约束限制： 不涉及 取值范围： 0-1000000 默认取值： 0
asset_ids	否	Array of strings	参数解释： 根据资产的id集合进行过滤查询，格式如[id,id,id]。资产id即模型训练界面的模型id或模型部署详情界面内的模型id。 约束限制： 字符串只能由数字、英文字母或短横线组成。 取值范围： 不涉及 默认取值： 不涉及
asset_name	否	String	参数解释： 根据平台上已注册的资产的名称进行过滤。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
asset_source	否	String	参数解释： 平台上资产的来源。 约束限制： 不涉及 取值范围： • Preset(预置)：平台已提前预置好的资产 • Publish(发布)：用户训练，压缩操作后发布的资产 • Import(导入)：用户自行导入到平台的资产 • AIGallery(订阅)：用户通过AIHUB订阅的资产 默认取值： 不传参时，默认查询所有。
asset_type	否	String	参数解释： 平台上资产所属的类型。 约束限制： 支持多种类型同时查询，多个值时，以逗号进行连接。 取值范围： • NLP(NLP大模型) • CV(CV大模型) • MM(多模态大模型) • AI4Science (科学计算大模型) • Predict(预测大模型) • Profession(专业大模型) 默认取值： 不涉及

参数	是否必选	参数类型	描述
sub_asset_type	否	String	参数解释： 平台上资产的子类型，由各个类型的算法按需设置。以下为算法目前设置的子类型。 约束限制： 不涉及 取值范围： 各个asset_type下已有的子类型如下。 • NLP模型：暂无子类型 • CV模型：SS(语义分割)、IC(图像分类)、ED(事件检测)、OVD(万物检测)、PE(姿态估计)、AD(异常检测)、ObjectDetection(物体检测)、OpticalCharacterRecognition(文字识别)、OpenVocabularySegmentation(万物分割)、RD(旋转检测) • 科学计算模型： Ocean_Regional_24h(海洋区域24H)、 Weather_24h(天气24H)、 Weather_3h(天气3H)、 Weather_6h(天气6H)、 Precip_6h(降雨6H)、 Ocean_Ecology_24h(海洋生态24H)、Ocean_24h(海洋24H)、Weather_1h(天气1H) • 多模态模型：Img2Txt(文生图) • 预测模型： AnomalyDetection(异常检测)、Classification(分类)、TimeSeries(时序)、Regression(回归)、StructurePredict(结构化预测)、IntegratingModelDataDriven(驾驶数据集成) • Profession：NLP(NLP大模型)

参数	是否必选	参数类型	描述
			组件：package(包)、script(脚本)、PostProcessingCode(处理代码) 默认取值： 不涉及
asset_name_snip	否	String	参数解释： 该字段支持根据资产名称模糊匹配进行过滤，例如可使用Pangu检索平台预置的资产，对于用户训练后自行发布，部署或导入的资产，可通过设置的资产名进行检索。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
visibility	否	String	参数解释： 该字段支持根据资产的可见性进行过滤查询。 约束限制： 不涉及 取值范围： - all：全空间可见 - current：本空间可见 默认取值： 不涉及
workspace_source	否	String	参数解释： 该字段支持根据所查询资产的来源空间进行过滤。 约束限制： 不涉及 取值范围： - current：来自本空间 - others：来自其他空间 默认取值： 不涉及

参数	是否必选	参数类型	描述
category	否	String	参数解释： 根据资产来源进行过滤。 约束限制： 不涉及 取值范围： • pangu(来自盘古大模型) • 3rd(来自用户自行导入的第三方大模型) • pangu-poc(来自poc版本的盘古大模型) • pangu-iit(来自工业智能中枢中的模型) • 3rd-pangu(来自盘古服务所提供的第三方大模型) 默认取值： 不涉及
asset_feature	否	String	参数解释： 模型资产的特性。 约束限制： 不涉及 取值范围： 科学计算大模型根据时间分辨率进行过滤，取值：1h、3h、6h、24h。 NLP根据取值进行过滤，取值：7B，38B，135B（仅支持科学计算大模型和NLP的查询） 默认取值： 不涉及
sort	否	String	参数解释： 查询结果的排序方式。 约束限制： 不涉及 取值范围： • asc：升序 • desc：降序 默认取值： 不涉及

参数	是否必选	参数类型	描述
asset_action	否	String	参数解释： 按照资产的操作类型进行过滤。 约束限制： 支持多种操作类型同时查询，多种操作类型同时查询时以逗号分开。 取值范围： train(训练操作)： ● PRETRAIN(预训练) ● SFT(SFT微调) ● LORA(LORA微调) ● DPO(DPO强化学习) ● RLHF(强化学习) ● TRANSFORM(转换) ● QUANTIZATION(压缩) deploy(部署操作)： ● ONLINE-DEPLOY(在线部署) ● EDGE-DEPLOY(边缘部署) 默认取值： 不涉及

请求参数

表 3-818 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-819 响应 Body 参数

参数	参数类型	描述
total	Integer	参数解释： 查询到的资产总数。 约束限制： 不涉及 取值范围： 取决于根据条件查询到的资产数量。 默认取值： 不涉及
assets	Array of ModelAssetExt objects	参数解释： 查询到的资产列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-820 ModelAssetExt

参数	参数类型	描述
modelAsset	ModelAsset object	参数解释： 查询到的模型资产信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
can_deploy	Boolean	参数解释： 该模型资产是否支持部署。 约束限制： 不涉及 取值范围： • true：支持 • false：不支持 默认取值： 不涉及
can_train	Boolean	参数解释： 该模型资产是否支持训练。 约束限制： 不涉及 取值范围： • true：支持 • false：不支持 默认取值： 不涉及
can_delete	Boolean	参数解释： 该模型资产是否支持删除。 约束限制： 不涉及 取值范围： • true：支持 • false：不支持 默认取值： 不涉及

参数	参数类型	描述
can_eval	Boolean	参数解释： 该模型资产是否支持评估。 约束限制： 不涉及 取值范围： • true：支持 • false：不支持 默认取值： 不涉及
can_quantize	Boolean	参数解释： 该模型资产是否支持压缩。 约束限制： 不涉及 取值范围： • true：支持 • false：不支持 默认取值： 不涉及
model_id	String	参数解释： 所查询到的模型ID。该模型为预置模型时，model_id即为asset_id，该模型即为业务推送过来的user_model_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_used	Boolean	参数解释： 所查询到的模型是否已经被推理部署、压缩和训练使用。 约束限制： 不涉及 取值范围： • true：已使用 • false：未使用 默认取值： 不涉及

参数	参数类型	描述
can_export	Boolean	参数解释： 该模型资产是否支持导出。 约束限制： 不涉及 取值范围： • true：支持 • false：不支持 默认取值： 不涉及
publish_info	AssetPublishInfo VO object	参数解释： 该模型的相关发布信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
subscribe_info	AssetSubscribeInfo VO object	参数解释： 该模型的相关订阅信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-821 ModelAsset

参数	参数类型	描述
asset_id	String	参数解释： 所查询到的模型资产的ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
root_asset_id	String	参数解释： 查询到的模型资产所归属的预置模型资产的ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_name	String	参数解释： 模型资产的名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_name_en	String	参数解释： 模型资产的英文名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_desc	String	参数解释： 模型资产的描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_version	String	参数解释： 模型资产内核版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
external_version	String	参数解释： 模型资产版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_available	Boolean	参数解释： 模型资产是否对外可见。 约束限制： 不涉及 取值范围： • true 可见 • false 不可见 默认取值： 不涉及

参数	参数类型	描述
category	String	参数解释： 资产的来源。 约束限制： 不涉及 取值范围： • pangu(来自盘古大模型) • 3rd(来自用户自行导入的第三方大模型) • pangu-poc(来自poc版本的盘古大模型) • pangu-iit(来自工业智能中枢中的模型) • 3rd-pangu(来自盘古服务所提供的第三方大模型) 默认取值： 不涉及
storage_type	String	参数解释： 模型资产在平台上所存储的类型。 约束限制： 不涉及 取值范围： • OBS：保存在OBS上 • Image：以纯镜像的形式保存 默认取值： 不涉及
asset_location	String	参数解释： 模型在OBS的存储位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_config_location	String	参数解释： 推理资产所需的配置文件。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_type	String	参数解释： 平台上资产所属的类型。 约束限制： 不涉及 取值范围： • NLP：NLP大模型 • CV：CV大模型 • MM：多模态大模型 • AI4Science：科学计算大模型 • Predict：预测大模型 • Profession：专业大模型 默认取值： 不涉及

参数	参数类型	描述
sub_asset_type	String	参数解释： 资产子类型，由算法按需设置。 约束限制： 不涉及 取值范围： 各个asset_type下已有的子类型如下。 • NLP模型：暂无子类型 • CV模型：SS(语义分割)、IC(图像分类)、ED(事件检测)、OVD(万物检测)、PE(姿态估计)、AD(异常检测)、ObjectDetection(物体检测)、OpticalCharacterRecogniton(文字识别)、OpenVocabularySegmentation(万物分割)、RD(旋转检测) • 科学计算模型： Ocean_Regional_24h(海洋区域24H)、 Weather_24h(天气24H)、 Weather_3h(天气3H)、 Weather_6h(天气6H)、 Precip_6h(降雨6H)、 Ocean_Ecology_24h(海洋生态24H)、Ocean_24h(海洋24H)、 Weather_1h(天气1H) • 多模态模型：Img2Txt(图生文) • 预测模型：AnomalyDetection(异常检测)、Classification(分类)、TimeSeries(时序)、Regression(回归)、StructurePredict(结构化预测)、IntegratingModelDataDriven(数据驱动集成) • Profession：NLP(NLP大模型) • 组件：package(包)、script(脚本)、PostProcessingCode(处理代码) 默认取值： 不涉及

参数	参数类型	描述
asset_code	String	参数解释: 模型资产的族谱编码，如：Pangu-NLP-N1-Default-2K-L0.C-3.0。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
asset_source	String	参数解释: 平台上资产的来源。 约束限制: 不涉及 取值范围: • Preset(预置)：平台已提前预置好的资产 • Publish(发布)：用户训练，压缩操作后发布的资产 • Import(导入)：用户自行导入到平台的资产 • AIGallery(订阅)：用户通过AIHUB订阅的资产 默认取值: 不涉及
asset_feature	String	参数解释: 模型资产的特性，如：NLP存储参数量，如11B，科学计算，如存储hashcode。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
project_id	String	参数解释： 模型资产所归属的项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	String	参数解释： 模型资产所归属的空间ID，本空间发布和分享情况下不为空。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_tag	String	参数解释： 模型资产的标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
security_policy	String	参数解释： 模型资产的安全策略。 约束限制： 不涉及 取值范围： • PLAIN：明文， • AES256：通过AES256加密， • OBFUSCATE：混淆， • SCCBase64：通过SCCBase64加密 默认取值： 不涉及

参数	参数类型	描述
encode_type	String	参数解释： 模型资产密码的编码方式：BASE64。 约束限制： 不涉及 取值范围： BASE64 默认取值： 不涉及
asset_password	String	参数解释： 模型加密场景下对应的模型密码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
properties	Map<String,Object>	参数解释： 用于存储公共变量的信息，包括 gallery_info 信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
actions	Array of ModelAction objects	参数解释： 模型资产的操作信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
user_model_id	String	参数解释： 业务侧存储的模型资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_artifact_id	String	参数解释： NLP场景，多产物场景的artifactID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_model_source_operation	String	参数解释： 用户发布的模型所来源的操作类型。 约束限制： 不涉及 取值范围： • PRETRAIN(预训练) • SFT(SFT微调) • LORA(LORA微调) • DPO(DPO强化学习) • RLHF(强化学习) • TRANSFORM(转换) • QUANTIZATION(压缩) • ONLINE-DEPLOY(在线部署) • EDGE-DEPLOY(边缘部署) 默认取值： 不涉及

参数	参数类型	描述
user_model_source_job_name	String	参数解释： 用户发布的模型资产所来源的训练任务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_model_source_job_id	String	参数解释： 用户发布的模型资产所来源的训练任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
creator	String	参数解释： 模型资产的创建者。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_id	String	参数解释： 模型资产的创建者ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time	String	参数解释： 模型资产的创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 模型资产的更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
root_asset_name	String	参数解释： 该模型资产所来源的资产名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
visibility	String	参数解释： 该模型资产的可见性。 约束限制： 不涉及 取值范围： • true 可见 • false 不可见 默认取值： 不涉及

参数	参数类型	描述
resource_charging_mode	Integer	参数解释： 计费模式。 约束限制： 不涉及 取值范围： 0：限时免费 1：包周期 2：按需计费 默认取值： 不涉及
resource_spec_codes	Array of strings	参数解释： 订购资源spec code数组。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_scenes	Array of strings	参数解释： 该模型资产的应用场景，由所注册的资产决定，如：LongTextInference(长文本推理)，LogicalInference(逻辑推理)，SemanticSegmentation(语义分割)。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-822 ModelAction

参数	参数类型	描述
action_id	String	参数解释： 模型资产相关操作的操作ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_id	String	参数解释： 模型资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_id	String	参数解释： 模型资产相关的工作流ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
action_name	String	参数解释： 模型资产相关的操作名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
action_type	String	参数解释： 模型资产相关操作的类型定义。 约束限制： 不涉及 取值范围： train(训练操作)： • PRETRAIN(预训练) • SFT(SFT微调) • LORA(LORA微调) • DPO(DPO强化学习) • RLHF(强化学习) • TRANSFORM(转换) • QUANTIZATION(压缩) deploy(部署操作)： • ONLINE-DEPLOY(在线部署) • EDGE-DEPLOY(边缘部署) 默认取值： 不涉及
asset_tag	String	参数解释： 模型资产的标签信息，如NLP-N1-PERTRAIN。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
depend_assets	Array of ModelAsset objects	参数解释： 模型资产所依赖的模型标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
super_params	Map<String,Object>	参数解释： 该模型资产相关的超参定义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
action_env	Array of ActionEnvObj objects	参数解释： 该模型资产相关的环境变量定义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
action_properties	Map<String,Object>	参数解释： 该模型资产相关的附加属性定义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
command	String	参数解释： 模型资产相关操作的执行命令。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
support_checkpoint	String	参数解释： 该模型资产是否支持断点续训。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
support_ckpt_release	Boolean	参数解释： 该模型资产是否支持checkpoint发布成资产。 约束限制： 不涉及 取值范围： 0：不支持， 1：支持 默认取值： 不涉及
checkpoint_transform_command	String	参数解释： checkpoint模型转换命令。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
support_mindstudio_insight	Boolean	参数解释： 是否支持输出mindinsight的监控 约束限制： 不涉及 取值范围： - true 支持 - false 不支持 默认取值： 不涉及

参数	参数类型	描述
sub_dir	String	参数解释： 模型资产的子目录。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image	String	参数解释： 模型资产的运行镜像。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow	Workflow object	参数解释： 模型资产相关工作流定义。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
resources	Array of ActionResource objects	参数解释： 资源相关信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
use_api_proxy	Boolean	参数解释： 推理-是否支持标准API接口。 约束限制： 不涉及 取值范围： • false：透传 • true：转发 默认取值： 不涉及
olc	Map<String,Object>	参数解释： 推理-流控配置，接口请求次数的限制。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
api_env	Array of ActionApiEnv objects	参数解释： 推理-API参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 模型资产相关操作的创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
update_time	String	参数解释： 模型资产相关操作的更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-823 ActionEnvObj

参数	参数类型	描述
env_name	String	参数解释： 模型资产的环境变量名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
default_value	String	参数解释： 环境变量的默认值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
modifiable	Boolean	参数解释： 环境变量是否可更改。 约束限制： 不涉及 取值范围： • true 可更改 • false 不可更改 默认取值： 不涉及

参数	参数类型	描述
displayable	Boolean	参数解释： 环境变量是否可显示。 约束限制： 不涉及 取值范围： • true 可显示 • false 不可显示 默认取值： 不涉及
data_type	String	参数解释： 环境变量数据类型。 约束限制： 不涉及 取值范围： • string(字符串) • float(小数) • boolean(布尔值) • enum(枚举值) • integer(整数) 默认取值： 不涉及
enum_values	String	参数解释： 环境变量枚举值列表，逗号分隔的字符串。例如：4K,8K,当数据类型为enum时，该字段必选。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
des	String	参数解释： 环境变量描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
label	String	参数解释： 环境变量的显示名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-824 Workflow

参数	参数类型	描述
workflow_id	String	参数解释： 模型资产相关的工作流ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_name	String	参数解释： 模型资产相关的工作流名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
workflow_name_en	String	参数解释： 模型资产相关的工作流英文名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_desc	String	参数解释： 模型资产相关的工作流描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_version	String	参数解释： 模型资产相关的工作流版本，如：2.1.1。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_tag	String	参数解释： 模型资产相关的工作流标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
workflow_source	String	参数解释： 模型资产的来源：如平台预置/用户导入。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_location	String	参数解释： 工作流存储的位置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_type	String	参数解释： 数据集类型。 约束限制： 不涉及 取值范围： OBS，CLASSIFICATION， TIME_SERIES_PREDICT，DeepSeek- V3，NLP-N2，REGRESSION，MM-M2- TRANSFORM，NLP-N1。 默认取值： 不涉及
content_id	String	参数解释： 工作流在AIGallery中注册的资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
depend_content_ids	Array of strings	参数解释： 工作流在AIGallery中注册依赖的算法资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
supported_model_versions	Array of SupportedModelInfo objects	参数解释： 支持的模型版本列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 工作流的创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 工作流的更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-825 SupportedModelInfo

参数	参数类型	描述
asset_code	String	参数解释： 模型资产的族谱编码，如：Pangu-NLP-N1-Default-2K-L0.C-3.0。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
versions	Array of SupportedModelInfoDetail objects	参数解释： 工作流支持的模型版本和动作信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-826 SupportedModelInfoDetail

参数	参数类型	描述
version	String	参数解释： 工作流支持的模型版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
action_type	String	参数解释： 工作流支持的模型的某个动作类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_tag	String	参数解释： 工作流支持的资产标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-827 ActionResource

参数	参数类型	描述
resource_id	String	参数解释： cpu、memory等推理部署所需的资源信息ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
action_id	String	参数解释： 关联的动作ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
image_id	String	参数解释： 模型资产推理部署所需的镜像ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cpu	Float	参数解释： 推理部署所要求的CPU核数的默认值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
min_cpu	Float	参数解释： 推理部署所要求的最小的CPU核数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max_cpu	Float	参数解释： 推理部署所要求的最大的CPU核数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
memory	Float	参数解释： 推理部署所要求的内存数的默认值，默认以MB为单位。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
min_memory	Float	参数解释： 推理部署所要求的内存数的最小值，默认以MB为单位。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max_memory	Float	参数解释： 推理部署所要求的内存数的最大值，默认以MB为单位。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
flavor	String	参数解释： flavor默认值为custom，表示自定义，此时其他资源信息必填，非custom时则为MA资源池中具体消耗信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
card_count	Float	参数解释： 推理部署所需要的显卡数量默认值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
min_card_count	Float	参数解释： 推理部署所需要的显卡数量最小值，比如8。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max_card_count	Float	参数解释： 推理部署所需要的显卡数量最大值，比如64。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
card_step	Float	参数解释： 显卡步长的定义，比如8。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
node_count	Float	参数解释： 显卡所在节点数量，取值[1,8] 约束限制： 不涉及 取值范围： 1-8 默认取值： 不涉及
chip_type	String	参数解释： 芯片类型，枚举值：Snt9A Snt9B1 Snt9B2 Snt9B3 Snt9B4 Snt3P Snt9B3-half NONE ALL 说明 snt9、Snt3的具体值需要联系服务技术支持获取。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
device_type	String	参数解释： 显卡的驱动类型（NPU，NONE）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
driver_version	String	参数解释： 显卡的驱动版本，C86/C87。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
image	Image object	参数解释： 推理部署相关的镜像。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 推理部署服务的创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 推理部署服务的更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-828 Image

参数	参数类型	描述
image_id	String	参数解释： 推理部署的镜像ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
image_name	String	参数解释： 推理部署的镜像名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_version	String	参数解释： 推理部署的镜像版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_desc	String	参数解释： 推理部署的镜像描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_url	String	参数解释： 推理部署的镜像存放地址，存放于SWR容器镜像服务。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
image_port	String	参数解释： 推理部署的镜像端口。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_tag	String	参数解释： 推理部署的镜像标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
arch	String	参数解释： 推理部署镜像的架构, 枚举值：ARM, X86 约束限制： 不涉及 取值范围： - ARM - X86 默认取值： 不涉及
input_types	Array of strings	参数解释： 异步模型支持的输入数据类型列表，包括：OBS。 约束限制： 不涉及 取值范围： OBS 默认取值： 不涉及

参数	参数类型	描述
output_types	Array of strings	参数解释： 异步模型支持的输出数据类型列表，包括OBS。 约束限制： 不涉及 取值范围： • OBS 默认取值： 不涉及
request_mode	String	参数解释： 推理镜像的部署模式。 约束限制： 不涉及 取值范围： • sync：同步 • async：异步 默认取值： 不涉及
service_config	String	参数解释： 异步：服务配置信息，为xml的字符串。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_config	String	参数解释： 异步：任务配置信息，为xml的字符串。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
apis	Array of Apis objects	参数解释： 同步：API信息，为结构体。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
protocol	String	参数解释： 推理服务的通信协议。 约束限制： 不涉及 取值范围： - https - http 默认取值： 不涉及
health_check	Map<String,Object>	参数解释： 推理服务的安全检查项。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
supported_model_versions	Array of strings	参数解释： 输入模型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
mount_type	String	参数解释： 镜像加载的方式。 约束限制： 不涉及 取值范围： • OBS：对象存储服务，通过OBS加载镜像 • SFSTurbo：高性能弹性文件服务，通过SFSTurbo加载镜像 • ENV：当前部署环境，通过ENV加载镜像 • None：空 默认取值： 不涉及
mount_location	String	参数解释： 容器内模型挂载的路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
mount_env_key	String	参数解释： 环境变量加载时，使用的key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
depends_locations	Array of DependLocation objects	参数解释： 依赖的镜像加载配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time	String	参数解释： 服务部署的创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 服务部署的更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-829 Apis

参数	参数类型	描述
type	String	参数解释： 服务部署API类型，目前只涉及NLP大模型。 约束限制： 不涉及 取值范围： NLP_OPENAI_CHAT 默认取值： 不涉及
url	String	参数解释： 服务部署APIURL。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
method	Array of strings	参数解释： 服务部署API方法。 约束限制： 不涉及 取值范围： POST 默认取值： 不涉及

表 3-830 DependLocation

参数	参数类型	描述
asset_name	String	参数解释： 模型资产名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_code	String	参数解释： 模型资产的族谱编码，如：Pangu-NLP-N1-Default-2K-L0.C-3.0。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_version	String	参数解释： 模型资产的版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
mount_type	String	参数解释： 挂载绑定的类型。 约束限制： 不涉及 取值范围： • OBS：对象存储服务 • SFSTurbo：高性能弹性文件服务 • ENV：当前部署环境 • None：空 默认取值： 不涉及
mount_location	String	参数解释： 绑定的挂载路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
mount_env_key	String	参数解释： 环境变量类型的绑定Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-831 ActionApiEnv

参数	参数类型	描述
type	String	参数解释： 操作类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
env_list	Array of ActionApiEnvItem objects	参数解释： 推理-API参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-832 ActionApiEnvItem

参数	参数类型	描述
des	String	参数解释： 推理服务的描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
label	String	参数解释： 环境变量显示的名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
env_name	String	参数解释： 推理服务环境变量的名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
data_type	String	参数解释： 环境变量的数据类型。 约束限制： 不涉及 取值范围： • string(字符串) • float(小数) • boolean(布尔值) • enum(枚举值) • integer(整数) 默认取值： 不涉及
modifiable	Boolean	参数解释： 环境变量是否可更改。 约束限制： 不涉及 取值范围： • true(可更改) • false(不可更改) 默认取值： 不涉及

参数	参数类型	描述
displayable	Boolean	参数解释： 环境变量是否可显示。 约束限制： 不涉及 取值范围： • true(可显示) • false(不可显示) 默认取值： 不涉及
enum_values	String	参数解释： 枚举值之间以逗号进行分隔。当数据类型为enum时，该字段必选。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
default_value	String	参数解释： 环境变量的默认值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
min	String	参数解释： 环境变量的最大值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
max	String	参数解释： 环境变量的最小值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-833 AssetPublishInfoVO

参数	参数类型	描述
can_publish_to_gallery	Boolean	参数解释： 模型资产是否可发布。 约束限制： 不涉及 取值范围： • true：可发布 • false：不可发布 默认取值： 不涉及
can_check_publish_info	Boolean	参数解释： 模型资产是否可查看发布信息。 约束限制： 不涉及 取值范围： • true：可查看 • false：不可查看 默认取值： 不涉及

参数	参数类型	描述
can_cancel_publish	Boolean	参数解释： 模型资产是否可取消发布。 约束限制： 不涉及 取值范围： • true：可取消发布 • false：不可取消发布 默认取值： 不涉及

表 3-834 AssetSubscribeInfoVO

参数	参数类型	描述
can_check_subscription	Boolean	参数解释： 是否可查看模型资产订阅信息。 约束限制： 不涉及 取值范围： • true：可查看 • false：不可查看 默认取值： 不涉及
can_cancel_subscription	Boolean	参数解释： 是否可取消模型资产订阅。 约束限制： 不涉及 取值范围： • true：可取消 • false：不可取消 默认取值： 不涉及

参数	参数类型	描述
can_continue_order	Boolean	参数解释： 是否可续订模型资产。 约束限制： 不涉及 取值范围： • true：可续订 • false：不可续订 默认取值： 不涉及
can_reorder	Boolean	参数解释： 是否可重新订阅模型资产。 约束限制： 不涉及 取值范围： • true：可重新订阅 • false：不可重新订阅 默认取值： 不涉及

请求示例

无

响应示例

状态码：200

成功响应示例

```
{
  "total": 1,
  "assets": [ {
    "modelAsset": {
      "asset_id": "1a0bca39-78f4-4fe7-abdc-42be76c03280",
      "root_asset_id": "435e1e32-c741-4ead-b85b-972bbf78c85c",
      "asset_name": "pretrain-0320-0000-发布资产",
      "asset_desc": "",
      "asset_version": "1.1.6",
      "external_version": "",
      "is_available": true,
      "category": "3rd-pangu",
      "storage_type": "OBS",
      "asset_location": "/user-models/0ba805c3edf64df48732c5bf47c40e70/098d1ba1-fc21-4f9f-8cba-380486f72212/model-assets/ThrNLP/DeepSeek-V3/3d35ef0b-a653-4145-89ed-1c124ed126e4/",
      "asset_config_location": "/infer/config",
      "asset_type": "NLP",
      "sub_asset_type": "",
      "asset_code": "DeepSeek-V3",
```

```
"asset_source" : "Publish",
"asset_feature" : "",
"project_id" : "0ba805c3edf64df48732c5bf47c40e70",
"workspace_id" : "098d1ba1-fc21-4f9f-8cba-380486f72212",
"asset_tag" : "SFT,ONLINE-DEPLOY-32K-1P,LORA,ONLINE-DEPLOY-4K-1P",
"security_policy" : "PLAIN",
"asset_password" : "",
"properties" : {
  "tokenizer_path" : "/tokenizer/"
},
"actions" : [ {
  "action_id" : "4d9b8819-fbeb-4cc5-8143-4c9f07290e05",
  "asset_id" : "435e1e32-c741-4ead-b85b-972bbf78c85c",
  "workflow_id" : "f801a4eb-0114-48e7-8291-1d796842928a",
  "action_name" : "ACTION_SFT",
  "action_type" : "SFT",
  "asset_tag" : "SFT",
  "depend_assets" : [ ],
  "super_params" : { },
  "action_env" : [ ],
  "action_properties" : {
    "Snt9B3" : {
      "SECURITY_POLICY" : "plain",
      "TRAIN_TIME_CALU_RULE" : "1200+dataT*11059200+dataT*epochs*2560000000000/160/cardsNum
+180+120",
      "MOX_FILE_LARGE_FILE_PART_SIZE" : "8589934592",
      "MODEL_VERSION" : "deepseek_v3",
      "GLOG_v" : "3",
      "MOX_FILE_LARGE_FILE_TASK_NUM" : "1",
      "ASCEND_GLOBAL_EVENT_ENABLE" : "1",
      "SOLUTION" : "STUDIO",
      "HCCL_CONNECT_TIMEOUT" : "7200",
      "MOX_COPY_PARALLEL_THREADS" : "8",
      "OUTPUT_SECURITY_POLICY" : "plain",
      "SEQ_LENGTH" : "4096",
      "OUTPUT_ARTIFACTS" : "sft_deepseek_4k.json",
      "HCCL_EXEC_TIMEOUT" : "7200",
      "ACTION_TYPE" : "sft",
      "MOX_C_ACCELERATE" : "0",
      "MA_DETECT_TRAIN_INJECT_CODE" : "0"
    },
    "CPU" : {
      "PP" : "16",
      "SECURITY_POLICY" : "plain",
      "TRAIN_TIME_CALU_RULE" : "1200+dataT*11059200+dataT*epochs*2560000000000/160/cardsNum
+180+120",
      "MOX_FILE_LARGE_FILE_PART_SIZE" : "8589934592",
      "MODEL_VERSION" : "deepseek_v3_test",
      "GLOG_v" : "3",
      "MOX_FILE_LARGE_FILE_TASK_NUM" : "1",
      "ASCEND_GLOBAL_EVENT_ENABLE" : "1",
      "SOLUTION" : "STUDIO",
      "EP" : "32",
      "HCCL_CONNECT_TIMEOUT" : "7200",
      "MOX_COPY_PARALLEL_THREADS" : "8",
      "OUTPUT_SECURITY_POLICY" : "plain",
      "SEQ_LENGTH" : "4096",
      "OUTPUT_ARTIFACTS" : "sft_deepseek_4k.json",
      "HCCL_EXEC_TIMEOUT" : "7200",
      "TP" : "1",
      "ACTION_TYPE" : "sft",
      "MOX_C_ACCELERATE" : "0",
      "MA_DETECT_TRAIN_INJECT_CODE" : "0"
    }
  },
  "command" : "",
  "support_checkpoint" : "1",
  "support_ckpt_release" : false,
  "support_mindstudio_insight" : false,
```

```
"sub_dir": "/model",
"workflow": {
  "workflow_id": "f801a4eb-0114-48e7-8291-1d796842928a",
  "workflow_name": "DeepSeek-V3-32K-SFT",
  "workflow_name_en": "DeepSeek-V3-32K-SFT",
  "workflow_desc": "DeepSeek-V3-32K-SFT",
  "workflow_version": "1.1.2",
  "workflow_tag": "DeepSeek-V3-32K-SFT",
  "workflow_source": "preset",
  "workflow_location": "DeepSeek-V3/finetune/1.1.2/metadata.json",
  "dataset_type": "NLP-N2",
  "content_id": "219eb96f-2f2b-4150-b945-c36dbe47a080",
  "depend_content_ids": [ "66cab07d-8ffe-4a2f-8149-8a083f674e81" ],
  "supported_model_versions": [ {
    "versions": [ {
      "action_type": "SFT",
      "version": "1.1.6"
    } ],
    "asset_code": "DeepSeek-V3-32K"
  } ],
  "create_time": "2025-03-20 16:08:34",
  "update_time": "2025-03-20 16:08:34"
},
"resources": [ {
  "resource_id": "467795a1-a214-4c86-af3b-e2756a612bea",
  "action_id": "4d9b8819-fbeb-4cc5-8143-4c9f07290e05",
  "flavor": "custom",
  "card_count": 8,
  "min_card_count": 8,
  "max_card_count": 5120,
  "card_step": 8,
  "node_count": 1,
  "chip_type": "CPU",
  "device_type": "NPU",
  "driver_version": "23.0.7",
  "create_time": "2025-03-20 11:17:34",
  "update_time": "2025-03-20 11:17:34",
  "computility": "313t"
}, {
  "resource_id": "cecab05a-2457-4c9f-ba2c-2ff0fafa8b3e",
  "action_id": "4d9b8819-fbeb-4cc5-8143-4c9f07290e05",
  "flavor": "custom",
  "card_count": 512,
  "min_card_count": 512,
  "max_card_count": 5120,
  "card_step": 512,
  "node_count": 1,
  "chip_type": "Snt9B3",
  "device_type": "NPU",
  "driver_version": "23.0.7",
  "create_time": "2025-03-20 11:17:34",
  "update_time": "2025-03-20 11:17:34",
  "computility": "313t"
} ],
"use_api_proxy": false,
"create_time": "2025-03-20 11:17:34",
"update_time": "2025-03-20 16:14:41"
}, {
  "action_id": "d7e688fb-0fc1-49fa-94df-03fa3510d213",
  "asset_id": "435e1e32-c741-4ead-b85b-972bbf78c85c",
  "action_name": "ACTION_LORA",
  "action_type": "LORA",
  "asset_tag": "LORA",
  "depend_assets": [ ],
  "super_params": { },
  "action_env": [ ],
  "action_properties": {
    "Snt9B3": {
      "SECURITY_POLICY": "plain",
```



```
"TRAIN_TIME_CALU_RULE" : "1200+dataT*11059200+dataT*epochs*2560000000000/160/cardsNum
+180+120",
"MOX_FILE_LARGE_FILE_PART_SIZE" : "8589934592",
"MODEL_VERSION" : "deepseek_v3",
"GLOG_v" : "3",
"MOX_FILE_LARGE_FILE_TASK_NUM" : "1",
"ASCEND_GLOBAL_EVENT_ENABLE" : "1",
"SOLUTION" : "STUDIO",
"HCCL_CONNECT_TIMEOUT" : "7200",
"MOX_COPY_PARALLEL_THREADS" : "8",
"OUTPUT_SECURITY_POLICY" : "plain",
"SEQ_LENGTH" : "4096",
"OUTPUT_ARTIFACTS" : "lora_deepseek_4k.json",
"HCCL_EXEC_TIMEOUT" : "7200",
"ACTION_TYPE" : "lora",
"MOX_C_ACCELERATE" : "0",
"MA_DETECT_TRAIN_INJECT_CODE" : "0"
}
},
"command" : "",
"support_checkpoint" : "0",
"support_ckpt_release" : false,
"support_mindstudio_insight" : false,
"sub_dir" : "/model_lora",
"resources" : [ {
  "resource_id" : "25005b97-e87b-4e9e-8303-886453c9b38d",
  "action_id" : "d7e688fb-0fc1-49fa-94df-03fa3510d213",
  "flavor" : "custom",
  "card_count" : 64,
  "min_card_count" : 64,
  "max_card_count" : 5120,
  "card_step" : 64,
  "node_count" : 1,
  "chip_type" : "Snt9B3",
  "device_type" : "NPU",
  "driver_version" : "23.0.7",
  "create_time" : "2025-03-20 11:17:34",
  "update_time" : "2025-03-20 11:17:34",
  "computility" : "313t"
} ],
"use_api_proxy" : false,
"create_time" : "2025-03-20 11:17:34",
"update_time" : "2025-03-20 11:17:34"
} ],
"user_model_id" : "07ebaa6a-1dfe-4ec9-8db0-3b9630e6f9a8",
"user_artifact_id" : "07ebaa6a-1dfe-4ec9-8db0-3b9630e6f9a8",
"user_model_source_operation" : "PRETRAIN",
"user_model_source_job_name" : "DS-pretrain-0320-0000",
"user_model_source_job_id" : "c14fdb0c-b7dc-4916-ab60-ef7d852bf465",
"execute_id" : "2a6e7f65-fcd3-422a-96de-077e386f6267",
"dataset_id" : "1322512842196389888",
"creator" : "lizhe",
"user_id" : "c1764f03893744fe96648ae747198cbe",
"create_time" : "2025-03-24 20:18:25",
"update_time" : "2025-03-27 14:14:48",
"root_asset_name" : "DeepSeek-V3-32K",
"visibility" : "all",
"asset_series" : "deepseek"
},
"can_deploy" : false,
"can_train" : true,
"can_delete" : true,
"can_eval" : false,
"can_quantize" : false,
"is_used" : false,
"can_export" : true,
"publish_info" : {
  "can_publish_to_gallery" : true,
  "can_check_publish_info" : false,
}
```

```
    "can_cancel_publish" : false
  }
}]]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.12.4 导出 ModelArts Site 平台格式资产

功能介绍

在指定工作空间内导出符合ModelArts Site平台格式的资产。

注意：通过该接口导出的模型仅供ModelArts Site平台使用。

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/asset-manager/model-assets/{asset_id}/export-site

表 3-835 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_id	是	String	参数解释： 模型资产ID，取值为 查询指定空间内的模型资产列表 接口响应参数中的asset_id参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-836 Query 参数

参数	是否必选	参数类型	描述
export_obs_path	是	String	参数解释： 模型的导出路径。需要是最终租户创建的OBS桶路径，路径格式为：obs://{桶名}/{文件夹名}/ 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
esn	是	String	参数解释： 导出模型资产至ModelArts Site平台所需的ESN码，ESN码由导入方提供给导出方使用，为字母数字组成的随机字符串，示例：G3M3ER2CT32SJ7RYDBB7MFFBKNB77QM7XQQA。 约束限制： 长度为1-64的字符串。 取值范围： 字母（a-z, A-Z）、数字（0-9）、下划线_、连字符 - 默认取值： 不涉及

请求参数

表 3-837 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-838 响应 Body 参数

参数	参数类型	描述
download_url	String	参数解释： 导出后模型的下载链接或文件地址。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-839 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：404

表 3-840 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

无

响应示例

状态码：200

成功响应示例

```
{
  "download_url": "obs://data-exchange/52712C-55c62b88-4eb1-406e-a0bc-0c2afc51ebc4.tar"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.12.5 查询模型导出任务列表

功能介绍

在指定工作空间内查询模型导出任务列表及任务状态。

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/asset-manager/model-assets/migrate/tasks

表 3-841 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-842 Query 参数

参数	是否必选	参数类型	描述
limit	否	Integer	参数解释： 分页大小，每一页返回的最大条 目数。 约束限制： 不涉及 取值范围： 0-1000000 默认取值： 10
offset	否	Integer	参数解释： 分页列表的起始页，默认为0。 约束限制： 不涉及 取值范围： 0-1000000 默认取值： 0

参数	是否必选	参数类型	描述
status	否	string	参数解释： 根据列表中的任务状态进行过滤。 约束限制： 不涉及 取值范围： • Success：迁移任务成功 • Failed：迁移任务失败 • Importing：导入中 • Exporting：导出中 • Publishing：发布中 • Subscribing：订阅中 • Copying：拷贝中 • OnShelf：已上架 • OffShelf：已下架 • Cancelled：模型已被取消发布/下架删除/模型已取消订阅 • Expired：订阅到期 • Cancelled-SubscribeSupported：模型已取消订阅，支持再订阅 • Expired-SubscribeSupported：订阅的模型到期，支持再订阅 默认取值： 不涉及

参数	是否必选	参数类型	描述
direction	否	string	参数解释： 根据列表中的迁移任务类型进行过滤。 约束限制： 不涉及 取值范围： • import：空间资产导入 • preset_import：模型广场导入 • export：空间资产导出 • publish：发布 • subscribe：订阅 默认取值： 不涉及
sort_by	否	string	参数解释： 查询结果的排序方式。 约束限制： 不涉及 取值范围： • asc：升序 • desc：降序 默认取值： 不涉及
type	否	string	参数解释： 根据列表中的模型类型进行过滤。 约束限制： 不涉及 取值范围： • model：模型 • assembly：组件 默认取值： 不涉及

请求参数

表 3-843 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-844 响应 Body 参数

参数	参数类型	描述
count	Integer	参数解释： 查询到的任务总数。 约束限制： 不涉及 取值范围： 取决于根据条件查询到的任务数量。 默认取值： 不涉及

参数	参数类型	描述
migrate_tasks	Array of MigrateTask objects	参数解释： 查询到的模型迁移任务列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-845 MigrateTask

参数	参数类型	描述
task_id	String	参数解释： 迁移任务id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 项目id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	String	参数解释： 工作空间id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_id	String	参数解释： 迁移模型资产的id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_type	String	参数解释： 平台上资产所属的类型。 约束限制： 不涉及 取值范围： • NLP：NLP大模型 • CV：CV大模型 • MM：多模态大模型 • AI4Science：科学计算大模型 • Predict：预测大模型 • Profession：专业大模型 默认取值： 不涉及
asset_name	String	参数解释： 迁移资产的名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
sub_asset_type	String	参数解释： 资产子类型，由算法按需设置。 约束限制： 不涉及 取值范围： 各个asset_type下已有的子类型如下。 • NLP模型：暂无子类型 • CV模型：SS(语义分割)、IC(图像分类)、ED(事件检测)、OVD(万物检测)、PE(姿态估计)、AD(异常检测)、ObjectDetection(物体检测)、OpticalCharacterRecogniton(文字识别)、OpenVocabularySegmentation(万物分割)、RD(旋转检测) • 科学计算模型： Ocean_Regional_24h(海洋区域24H)、 Weather_24h(天气24H)、 Weather_3h(天气3H)、 Weather_6h(天气6H)、 Precip_6h(降雨6H)、 Ocean_Ecology_24h(海洋生态24H)、Ocean_24h(海洋24H)、 Weather_1h(天气1H) • 多模态模型：Img2Txt(图生文) • 预测模型：AnomalyDetection(异常检测)、Classification(古典)、TimeSeries(时序)、Regression(回归)、StructurePredict(结构化预测)、IntegratingModelDataDriven(驾驶数据集成) • Profession：NLP(NLP大模型) • 组件：package(包)、script(脚本)、PostProcessingCode(处理代码) 默认取值： 不涉及

参数	参数类型	描述
content_id	String	参数解释： 平台上的模型id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
subscription_id	String	参数解释： 订阅用，订阅的id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
visibility	String	参数解释： 资产的可见性，导入/发布/订阅用。 约束限制： 不涉及 取值范围： • public：公开可见 • group：指定群组可见 • private：个人可见 默认取值： 不涉及
region	String	参数解释： 资产的可用区域，发布/订阅用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
users	String	参数解释： 发布资产，如果可见性为group，则必须输入可用的用户的domainId。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
output_obs_path	String	参数解释： 导出资产文件的OBS路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 任务状态。 约束限制： 不涉及 取值范围： • Success：迁移任务成功 • Failed：迁移任务失败 • Importing：导入中 • Exporting：导出中 • Publishing：发布中 • Subscribing：订阅中 • Copying：拷贝中 • OnShelf：已上架 • OffShelf：已下架 • Cancelled：已被取消发布下架删除/模型已取消订阅 • Expired：订阅到期 • Cancelled-SubscribeSupported：模型已取消订阅，支持再订阅 • Expired-SubscribeSupported：订阅的模型到期，支持再订阅 默认取值： 不涉及
direction	String	参数解释： 迁移任务的类型。 约束限制： 不涉及 取值范围： • import：空间资产导入 • preset_import：模型广场导入 • export：空间资产导出 • publish：发布 • subscribe：订阅 默认取值： 不涉及

参数	参数类型	描述
user_id	String	参数解释： 操作迁移任务的用户id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
domain_id	String	参数解释： 操作的租户id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_name	String	参数解释： 操作导入导出任务的用户名。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 迁移任务失败原因。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time	String	参数解释： 任务创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 任务更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_desc	String	参数解释： 任务描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
training_products_publish_enabled	String	参数解释： 产物是否允许发布。 约束限制： 不涉及 取值范围： 0：不允许发布 1：允许发布 默认取值： 不涉及

参数	参数类型	描述
publish_version_info	String	参数解释： 发布到AI Hub资产版本信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-846 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：404

表 3-847 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

无

响应示例

状态码：200

成功响应示例

```
{
  "count": 1,
  "migrate_tasks": [
    {
      "task_id": "55c62b88-4eb1-406e-a0bc-0c2afc51ebc4",
      "project_id": "0ba805c3edf64df48732c5bf47c40e70",
      "workspace_id": "8b8ef35c-6662-46ba-89ff-28057ce97b11",
    }
  ]
}
```

```
{
  "asset_id": "24e2787e-dca3-4083-b663-7a5ee682495b",
  "asset_name": "MyAsset",
  "output_obs_path": "data-exchange/52712C-55c62b88-4eb1-406e-a0bc-0c2afc51ebc4.tar",
  "status": "Success",
  "direction": "export",
  "user_id": "c1764f03893744fe96648ae747198cbe",
  "user_name": "lizhe",
  "create_time": "2025-10-25 12:34:01",
  "update_time": "2025-10-25 12:34:04",
  "training_products_publish_enabled": true
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.13 训练任务管理

3.13.1 获取训练任务 workflow 执行指标信息

功能介绍

获取训练任务 workflow 执行指标信息。

接口域名请参考[获取盘古服务外部API域名](#)获取。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/model-train/executions/{execution_id}/metric

表 3-848 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
execution_id	是	String	参数解释： workflow执行ID。 获取方法 查询指定空间内的模型资产列表 接口响应体中的execute_id字段。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-849 Query 参数

参数	是否必选	参数类型	描述
model_type	是	String	参数解释： 模型类型。取值为：NLP MM CV Predict AI4Science，依次为：NLP大模型、多模态模型、CV模型、预测模型、科学计算模型。 获取方法请见 查询指定空间内的模型资产列表 接口响应体中的asset_type字段。 约束限制： 不涉及 取值范围： NLP MM CV Predict AI4Science 默认取值： 不涉及

请求参数

表 3-850 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码： 200

表 3-851 响应 Body 参数

参数	参数类型	描述
loss	Object	参数解释： 当前训练任务的loss曲线数据。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
metric	Object	参数解释： 当前训练任务的监控指标数据，具体的监控指标以模型实际支持的为准。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-852 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

无

响应示例

状态码： 200

成功响应示例

```
{
  "metric": {
    "precision": 0.7227212247367847,
    "recall": 0.017308359347901495
  },
  "loss": [ 2.89861820765904, 2.629472351074219, 2.4382923671177457, 2.235746547154018,
2.347676740373884, 2.0648768833705358, 2.140458461216518, 2.103682599748884,
1.8132451738630022, 2.0050855364118303 ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.13.2 停止/重试训练任务操作

功能介绍

停止/重试训练任务。对已创建的训练任务进行停止或者重试操作，操作与训练任务的状态相关。

- 态为running|pending支持停止操作。
- 状态为failed支持重试操作。

训练任务状态获取参考[查询训练任务详情](#)接口。

URI

POST /v1/{project_id}/workspaces/{workspace_id}/model-train/train-task/{task_id}/action

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-853 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
task_id	是	String	参数解释： 训练任务ID，取自 查询训练任务详情 接口的响应体task_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-854 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-855 请求 Body 参数

参数	是否必选	参数类型	描述
action_name	是	String	参数解释： 对已经创建的训练任务支持的操作类型。 约束限制： 不涉及 取值范围： • retry：对任务状态为failed（失败）的任务进行重试。 • stop：对任务状态为running（运行中）、pending（排队中）的任务进行停止。 默认取值： 不涉及

响应参数

状态码：200

表 3-856 响应 Body 参数

参数	参数类型	描述
-	String	-

状态码：400

表 3-857 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。
details	Array of DetailErrorCode objects	ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。

表 3-858 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。
error_message	String	错误详情。

请求示例

停止指定task_id的训练任务。

```
POST https://endpoint/v1/{project_id}/workspaces/{workspace_id}/model-train/train-task/{task_id}/action
{
  "action_name": "stop"
}
```

响应示例

状态码：200

成功响应示例

```
{
  "task_id": "ssak23msn2832nsjekd"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.13.3 查询训练任务详情

功能介绍

指定task_id，查询训练任务详情。

URI

```
GET /v1/{project_id}/workspaces/{workspace_id}/model-train/train-task/{task_id}
```

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

表 3-859 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_id	是	String	参数解释： 训练任务ID，取自 新建训练任务 接口的响应体task_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-860 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-861 响应 Body 参数

参数	参数类型	描述
project_id	String	参数解释： 项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
workflow_id	String	参数解释： 工作空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_id	String	参数解释： 训练任务ID，训练任务的唯一标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_name	String	参数解释： 训练任务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 创建本次训练任务使用的训练数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
dataset_name	String	参数解释： 创建本次训练任务使用的训练数据集名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_version_id	String	参数解释： 创建本次训练任务使用的训练数据集版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
execution_id	String	参数解释： 当前任务执行记录ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
steps_execution	String	参数解释： 执行节点信息，如果当前训练任务包含多个节点，例如包含了数据预处理和训练两个节点时，该字段包含了每个节点执行任务的job_id及状态等信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
task_status	String	参数解释： 训练任务状态。 约束限制： 不涉及 取值范围： • init：任务初始化 • pending：任务排队中 • running：任务运行中 • stopping：任务停止中 • stopped：任务已停止 • failed：任务已失败 • completed：任务已完成 默认取值： 不涉及
eval_dataset_name	String	参数解释： 创建训练任务所使用的验证数据集名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
eval_dataset_id	String	参数解释： 验证数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
eval_dataset_version	String	参数解释： 验证数据集版本ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
checkpoint_id	String	参数解释： 训练过程中产生恢复点的唯一标识UUID，当基于某个任务的中间恢复点进行续训或者重训时使用。 约束限制： 必须符合标准UUID格式（32位十六进制数，8-4-4-4-12分组）。 取值范围： 不涉及 默认取值： 不涉及
source_model_id	String	参数解释： 标识当前续训或者重训任务使用的恢复点来源任务使用的模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
source_model_name	String	参数解释： 标识当前续训或者重训任务使用的恢复点来源任务使用的模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
steps	Integer	参数解释： 续训或者重训任务使用的恢复点对应的步数。 约束限制： 不涉及 取值范围： 1-10000 默认取值： 不涉及
skipped_steps	Integer	参数解释： 指定跳过步数创建续训任务时所跳过的步数。 约束限制： 不涉及 取值范围： 1-10000 默认取值： 不涉及
dataset_split_ratio	Integer	参数解释： 训练、验证数据集分割比率。 约束限制： 不涉及 取值范围： 1-100 默认取值： 不涉及
model_id	String	参数解释： 当前训练任务所使用的模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
model_type	String	参数解释： 模型类型，取值为NLP MM CV Predict AI4Science，依次为：NLP大模型、多模态模型、CV模型、预测模型、科学计算模型。 约束限制： 不涉及 取值范围： NLP MM CV Predict AI4Science 默认取值： 不涉及
train_type	String	参数解释： 训练类型，支持SFT（全量微调）、PRETRAIN（预训练）、LORA（lora微调）、DPO（dpo强化学习）。 约束限制： 不涉及 取值范围： SFT（全量微调）、PRETRAIN（预训练）、LORA（lora微调）、DPO（dpo强化学习）。 默认取值： 不涉及
checkpoint_config	Object	参数解释： 任务开启续训功能的相关配置，包含了保存断点的最大个数及跳过步数等信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
task_parameter	Object	参数解释： 本次训练任务的参数配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
pool_node_count	Integer	参数解释： 本次训练任务使用的资源池节点数量。 约束限制： 不涉及 取值范围： 1-100 默认取值： 不涉及
flavor	Integer	参数解释： 当前资源池的算力规格313/280。 约束限制： 不涉及 取值范围： 1-100 默认取值： 不涉及
t_flops	Integer	参数解释： 当前训练任务使用的总算力数。 约束限制： 不涉及 取值范围： 1-1000000 默认取值： 不涉及

参数	参数类型	描述
train_task_desc	String	参数解释： 训练任务描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	Long	参数解释： 训练任务创建时间。 约束限制： 不涉及 取值范围： 1-2147483647 默认取值： 不涉及
update_time	Long	参数解释： 训练任务更新时间，当任务状态刷新或者修改描述时更新时间变化。 约束限制： 不涉及 取值范围： 1-2147483647 默认取值： 不涉及
train_process	Double	参数解释： 训练任务进度，取值0-1。 约束限制： 不涉及 取值范围： 0.0-1.0 默认取值： 不涉及

参数	参数类型	描述
parent_model	String	参数解释： 本次训练任务使用的模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
parent_model_id	String	参数解释： 本次训练任务使用的模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
train_cost_time	Long	参数解释： 训练任务执行时间，单位ms。 约束限制： 不涉及 取值范围： 1-2147483647 默认取值： 不涉及
train_predict_time	Long	参数解释： 训练预估耗时，单位ms。 约束限制： 不涉及 取值范围： 1-2147483647 默认取值： 不涉及

参数	参数类型	描述
plog_level	Integer	参数解释： 训练任务配置的plog日志的级别。 约束限制： 不涉及 取值范围： • -1：不开启plog日志 • 0：info日志级别 • 1：debug日志级别 • 2：warning日志级别 • 3：error日志级别 默认取值： -1
pfs_path	String	参数解释： 训练监控数据存放路径，当资产支持对接mindstudio insight时不为空。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-862 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。
details	Array of DetailErrorCode objects	ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。

表 3-863 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。

参数	参数类型	描述
error_message	String	错误详情。

请求示例

查询指定task_id的训练任务详情。

GET https://endpoint/v1/{project_id}/workspaces/{workspace_id}/model-train/train-task/{task_id}

响应示例

状态码：200

成功响应示例

```
{
  "project_id": "0ba805c3edf64df48732c5bf47c40e70",
  "user_id": "c1764f03893744fe96648ae747198cbe",
  "user_name": "shili",
  "workflow_id": "bf8a98dd-8120-4937-8a6e-ae061018f521",
  "workspace_id": "098d1ba1-fc21-4f9f-8cba-380486f72212",
  "task_id": "09c07c72-078c-4da3-9376-8ed9ef648a69",
  "task_name": "test4153_clone",
  "dataset_id": "1354105944346333184",
  "dataset_name": "pub_pollution_20250322",
  "execution_id": "3c15d8da-b76d-4cbc-b4e5-351615fa2dbe",
  "steps_execution": "[{"status": "completed", "name": "train_url", "type": "obs", "config": {"metric": null, "obs_url": "/largemodelstudio-assets/user-models/0ba805c3edf64df48732c5bf47c40e70/098d1ba1-fc21-4f9f-8cba-380486f72212/model-assets/AI4Science/Pangu-AI4S-Regional-Pollution/3c15d8da-b76d-4cbc-b4e5-351615fa2dbe/data/", "metric_file": null}, {"duration": 370, "step_name": "prepare_data", "step_title": "数据预处理", "uuid": "81c5c78f-bea4-4984-ba60-34e4e5e96a82", "created_at": "2025-04-15T17:52:13.284285+08:00", "updated_at": "2025-04-15T17:58:23.416986+08:00", "instance_id": "job_id\\\\"b19b2c17-d50c-4956-96b0-366a33555b55\\", "execution_uuid": "3c15d8da-b76d-4cbc-b4e5-351615fa2dbe"}, {"status": "stopped", "name": "train_url", "type": "obs", "config": {"metric": null, "obs_url": "/largemodelstudio-assets/user-models/0ba805c3edf64df48732c5bf47c40e70/098d1ba1-fc21-4f9f-8cba-380486f72212/model-assets/AI4Science/Pangu-AI4S-Regional-Pollution/3c15d8da-b76d-4cbc-b4e5-351615fa2dbe/", "metric_file": null}, {"duration": 350, "step_name": "model_train", "step_title": "模型训练", "uuid": "8b6b2c4f-8bef-4dc6-a9f1-f92526057202", "created_at": "2025-04-15T17:58:23.694203+08:00", "updated_at": "2025-04-15T18:04:13.744785+08:00", "instance_id": "job_id\\\\"8c79cba6-71cd-439c-91fd-a8c47fd85e75\\", "execution_uuid": "3c15d8da-b76d-4cbc-b4e5-351615fa2dbe"}]",
  "task_parameter": {"parameters": [{"name": "prepare_data_flavor", "format": "train_flavor", "description": "数据预处理资源规格", "type": "json", "used_steps": ["prepare_data"], "value": {"flavor_id": "modelarts.pool.visual.xlarge", "pool_id": "studio-pool-dev-infer-419bb663f3874716965442b2850e4d81"}, {"name": "training_flavor", "format": "train_flavor", "description": "训练资源规格", "type": "json", "used_steps": ["model_train"], "value": {"flavor_id": "modelarts.pool.visual.xlarge"}}]},
  "is_input_finished": 1,
  "is_reuse_parameter": 0,
  "task_status": "stopped",
  "train_task_desc": "",
  "create_time": 1744710732000,
  "update_time": 1744711495000,
  "train_process": 0,
  "parent_model": "Pangu-AI4S-Regional-Pollution-1h-1.1.9",
  "parent_model_id": "c40e4659-8ccc-4ace-b833-eb730b13a812",
  "parent_model_source": "SYSTEM",
  "asset_id": "c40e4659-8ccc-4ace-b833-eb730b13a812",
  "model_type": "AI4Science",
  "model_source": "pangu",
  "train_type": "PRETRAIN",
  "train_cost_time": 343000,
```



```
"sfs_config" : "{ \"model_sfs_enable\":false,\"dataset_sfs_enable\":false,\"dataset_preload\n\":false,\"model_sfs_id\":null,\"model_sfs_ip_addr\":null,\"model_sfs_dir_pre\":null,\"export_task_info\n\":null,\"dataset_sfs_id\":null,\"dataset_sfs_ip_addr\":null,\"dataset_sfs_dir_pre\n\":null,\"eval_dataset_sfs_dir_pre\":null,\"token_dataset_obs_path\":null,\"dataset_export_task_info\":null},\n\"resource_config\" : \"{ \"pool_type\": \"private\", \"chip_type\": \"Snt9B3\", \"asset_code\": \"Pangu-AI4S-Regional-Pollution\", \"category\": \"pangu\", \"pool_id\": \"studio-pool-dev-infer-419bb663f3874716965442b2850e4d81\", \"pool_name\": null, \"flavor_id\": \"modelarts.pool.visual.xlarge\", \"flavor_name\": null, \"node_count\": 1, \"fp16\": 313, \"t_flops\": 313.0, \"training_unit\": 1},\n\"task_label\" : \"{ \"is_pool_unsubscribe\": true, \"charging_mode\": \"charging\" },\n\"can_deploy\" : false,\n\"pool_id\" : \"studio-pool-dev-infer-419bb663f3874716965442b2850e4d81\",\n\"model_id\" : \"c40e4659-8ccc-4ace-b833-eb730b13a812\",\n\"pool_node_count\" : 1,\n\"flavor\" : 313,\n\"model_asset_num\" : 0,\n\"t_flops\" : 313,\n\"training_unit\" : 1,\n\"sub_asset_type\" : \"Pollution_1h\",\n\"plog_level\" : 3,\n\"support_ckpt_release\" : false,\n\"category\" : \"pangu\"\n}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.13.4 获取 workflow 训练任务某一步执行日志信息

功能介绍

查询 workflow 训练任务某一步执行日志信息。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/model-train/execution/{execution_id}/training-jobs/{job_id}/tasks/{task_id}/preview

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-864 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
execution_id	是	String	参数解释： 训练任务执行ID，取自 查询训练任务详情 接口响应体中 execution_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
job_id	是	String	参数解释： 工作流执行步骤对应的JOB_ID，取自 查询训练任务详情 接口响应体中的steps_execution字段中的job_id，当本次训练任务有多个子任务时，对应多个job_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_id	是	String	参数解释： 日志任务节点ID，例如work-0，取自 获取训练任务某一步执行的节点信息 接口的响应体。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-865 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-866 响应 Header 参数

参数	参数类型	描述
X-request-id	String	参数解释： 该字段是用于任务跟踪的请求ID编号。 约束限制： 格式为request_uuid-时间戳-主机名。 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-867 响应 Header 参数

参数	参数类型	描述
X-request-id	String	参数解释： 该字段是用于任务跟踪的请求ID编号。 约束限制： 格式为request_uuid-时间戳-主机名。 取值范围： 不涉及 默认取值： 不涉及

表 3-868 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。
details	Array of DetailErrorCode objects	参数解释： ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-869 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。
error_message	String	错误详情。

状态码：404

表 3-870 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。
details	Array of DetailErrorCode objects	参数解释： ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-871 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。
error_message	String	错误详情。

请求示例

无

响应示例

状态码：200

成功响应示例

```
{
  "content" : "time=\"2025-03-31T09:37:01+08:00\" level=info msg=\"init logger suc\",
  "full_size" : 2049851,
  "current_size" : 2049851
}
```

状态码：400

Error response

```
{
  "error_code" : "string",
  "error_msg" : "string",
  "details" : [ { } ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.13.5 新建训练任务

功能介绍

创建模型训练任务。

URI

POST /v1/{project_id}/workspaces/{workspace_id}/model-train/train-task

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

表 3-872 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-873 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-874 请求 Body 参数

参数	是否必选	参数类型	描述
asset_id	是	String	参数解释： 模型资产ID，通过 获取模型列表 接口获取。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
task_name	是	String	参数解释： 训练任务名称。 约束限制： 可包含数字、中文、字母、中划线、下划线，不能以数字开头，长度不超过64。 取值范围： 不涉及 默认取值： 不涉及
dataset_id	否	String	参数解释： 训练数据集ID，取自 查询数据集详情v1 接口响应体dataset_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_name	否	String	参数解释： 训练数据集名称，取自 查询数据集详情v1 接口响应体name。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_version_id	否	String	参数解释： 训练数据集版本，取自 查询数据集详情v1 接口响应体version。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
eval_dataset_id	否	String	参数解释： 验证数据集ID，使用已有数据集作为验证集时使用，取自 查询数据集详情v1 接口响应体dataset_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
eval_dataset_name	否	String	参数解释： 验证数据集名称，使用已有数据集作为验证集时使用，取自 查询数据集详情v1 接口响应体name。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
eval_dataset_version_id	否	String	参数解释： 验证数据集版本ID，使用已有数据集作为验证集时使用，取自 查询数据集详情v1 接口响应体version。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
checkpoint_id	否	String	参数解释： 断点续训场景所使用的恢复点 UUID，取自 查询执行任务的断点信息（本接口用于调用其他接口时获取请求参数使用） 接口的 checkpoint_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_split_ratio	否	Integer	参数解释： 训练、验证数据集分割比率，当该模型支持验证集且验证集来自选择的训练集时使用，取值大于等于1，小于等于50。 约束限制： 不涉及 取值范围： 0-100 默认取值： 不涉及
model_id	否	String	参数解释： 训练模型ID，多模态和NLP大模型为必填，当使用的模型为预置模型时，取值与asset_id相同，当使用模型为训练后的作业模型时，取值来自于 获取发布的模型列表 接口model_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
model_type	是	String	参数解释： 模型类型，取值为NLP MM CV Predict AI4Science，依次为：NLP大模型、多模态模型、CV模型、预测模型、科学计算模型。 约束限制： 不涉及 取值范围： NLP MM CV Predict AI4Science 默认取值： 不涉及
reward_model_id	否	String	参数解释： 奖励模型ID，强化学习RLHF场景使用，当前不支持。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
train_type	是	String	参数解释： 训练类型，支持SFT（全量微调）、PRETRAIN（预训练）、LORA（lora微调）、DPO（dpo强化学习）。 约束限制： 不涉及 取值范围： SFT（全量微调）、PRETRAIN（预训练）、LORA（lora微调）、DPO（dpo强化学习） 默认取值： SFT

参数	是否必选	参数类型	描述
checkpoint_config	否	CheckpointConfig object	参数解释： 断点续训相关配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
sfs_config	否	SfsConfig object	参数解释： 模型训练开启Sfs Turbo时相关配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
resource_config	否	ResourceConfig object	参数解释： 训练任务资源配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_parameter	是	Object	参数解释： 训练任务运行参数，参数取于 获取模型详情（本接口用于调用其他接口时获取请求参数使用） 接口中的workflow_info.parameters，需要根据实际训练任务进行配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
pool_node_count	否	Integer	参数解释： 本次训练所使用的资源池节点数。 约束限制： 不涉及 取值范围： 0-10000 默认取值： 1
flavor	否	Integer	参数解释： 资源池算力规格，当前常见的类型为313/280。 约束限制： 不涉及 取值范围： 0-10000 默认取值： 不涉及
t_flops	是	Integer	参数解释： 训练任务使用的总算力数，为本次训练需要的卡数*flavor。 约束限制： 不涉及 取值范围： 0-2147483647 默认取值： 0
is_input_finished	否	Integer	参数解释： 训练参数是否已全部输入。 约束限制： 不涉及 取值范围： 0-2147483647 默认取值： 1

参数	是否必选	参数类型	描述
train_task_desc	否	String	参数解释： 训练任务描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_name	否	String	参数解释： 模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
output_artifact_name	否	String	参数解释： 任务输出产物名称，量化场景使用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_source	是	String	参数解释： 模型来源盘古/三方，取值pangu third pangu-third，依次为盘古预置模型、三方模型、盘古预置三方模型。 约束限制： 不涉及 取值范围： pangu third pangu-third 默认取值： 不涉及

参数	是否必选	参数类型	描述
task_env	否	Object	参数解释： 训练任务环境变量，三方模型训练配置的环境变量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
plog_level	否	Integer	参数解释： 训练任务的plog日志的级别。 • -1：不开启plog日志， • 0：info日志级别 • 1：debug日志级别 • 2：warning日志级别 • 3：error日志级别 约束限制： 不涉及 取值范围： -1-3 默认取值： -1
quantization_type	否	String	参数解释： 量化算法类型，取值QUANTIZATION-W8A8C等，具体以支持的量化策略为准。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-875 CheckpointConfig

参数	是否必选	参数类型	描述
save_checkpoints_max	否	Integer	参数解释： 当前训练任务是否开启断点续训，当配置大于0时，表示开启断点续训，并且保存指定数量的断点。 0：关闭不保，-1：自动无限制。 约束限制： 不涉及 取值范围： 0-2147483647 默认取值： 0
skipped_steps	否	Integer	参数解释： 在断点续训场景可指定基于某一断点跳过指定训练步数进行续训，0表示不跳过。 约束限制： 不涉及 取值范围： 0-2147483647 默认取值： 0
restore_training	否	Integer	参数解释： 是否为续训任务。 0：非续训,基于某一断点重新创建训练任务，可修改训练参数和数据集，1:续训，基于某一断点继续训练，不知修改训练参数及数据集等配置。 约束限制： 不涉及 取值范围： 0-2147483647 默认取值： 不涉及

参数	是否必选	参数类型	描述
checkpoint_publish_info	否	CheckpointPublishVo object	参数解释： 断点发布的请求体。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-876 CheckpointPublishVo

参数	是否必选	参数类型	描述
checkpoint_id	否	String	参数解释： 当前要发布的断点ID，取自 查询执行任务的断点信息（本接口用于调用其他接口时获取请求参数使用） 接口的checkpoint_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
visibility	否	String	参数解释： 全局可见性，取值current all，标识当前空间可见或全部空间可见。 约束限制： 不涉及 取值范围： 不涉及 默认取值： current

参数	是否必选	参数类型	描述
asset_name	否	String	参数解释： 发布到资产中心的用户模型的名 称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
description	否	String	参数解释： 发布到资产中心的用户模型的描 述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-877 SfsConfig

参数	是否必选	参数类型	描述
model_sfs_en able	否	Boolean	参数解释： 模型SFS加速开关，开启加速后 可缩短模型训练过程中下载模型 的时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false

参数	是否必选	参数类型	描述
dataset_sfs_enable	否	Boolean	参数解释： 数据SFS加速开关，开启加速后可缩短模型训练过程中下载训练数据的时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false
dataset_preload	否	Boolean	参数解释： 通过提前预热加载数据，可缩短训练时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： false

表 3-878 ResourceConfig

参数	是否必选	参数类型	描述
pool_type	否	String	参数解释： 资源池类型，公共池 专属池。 约束限制： 不涉及 取值范围： 不涉及 默认取值： private

参数	是否必选	参数类型	描述
chip_type	否	String	参数解释： 资源规格类型，取自获取模型详情（本接口用于调用其他接口时获取请求参数使用）接口响应体 chip_type，例如Snt9B3、Snt9B4等。 说明 snt9的具体值需要联系服务技术支持获取。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
pool_id	否	String	参数解释： 资源池ID，公共池为空，专属池有值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
pool_name	否	String	参数解释： 资源池名称，公共池为空，专属池有值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
flavor_id	否	String	参数解释： 规格卡数，公共池为节点规格，专属池为1 2 4 8卡。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
flavor_name	否	String	参数解释： 规格名称，前端传递用于详情展示后端不做处理。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
node_count	否	Integer	参数解释： 模型训练所需要的实例数，当 flavor_id 为 8 时，可配置 node_count 大于 1，代表开启多机多卡训练。 约束限制： 不涉及 取值范围： 1-10000000 默认取值： 1
fp16	否	Integer	参数解释： 资源池算力规格，对应 313 或者 280。 约束限制： 不涉及 取值范围： 0-10000000 默认取值： 不涉及

参数	是否必选	参数类型	描述
t_flops	否	Double	参数解释： 训练任务使用的总算力。 约束限制： 不涉及 取值范围： 0.0-2.147483647E9 默认取值： 0.0
training_unit	否	Integer	参数解释： 训练单元。 约束限制： 不涉及 取值范围： 0-10000000 默认取值： 0

响应参数

状态码：200

表 3-879 响应 Body 参数

参数	参数类型	描述
project_id	String	参数解释： 项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
workflow_id	String	参数解释： 工作空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_id	String	参数解释： 训练任务ID，训练任务的唯一标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_name	String	参数解释： 训练任务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 创建本次训练任务使用的训练数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
dataset_name	String	参数解释： 创建本次训练任务使用的训练数据集名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_version_id	String	参数解释： 创建本次训练任务使用的训练数据集版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
execution_id	String	参数解释： 当前任务执行记录ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
steps_execution	String	参数解释： 执行节点信息，如果当前训练任务包含多个节点，例如包含了数据预处理和训练两个节点时，该字段包含了每个节点执行任务的job_id及状态等信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
task_status	String	参数解释： 训练任务状态。 约束限制： 不涉及 取值范围： • init：任务初始化 • pending：任务排队中 • running：任务运行中 • stopping：任务停止中 • stopped：任务已停止 • failed：任务已失败 • completed：任务已完成 默认取值： 不涉及
eval_dataset_name	String	参数解释： 创建训练任务所使用的验证数据集名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
eval_dataset_id	String	参数解释： 验证数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
eval_dataset_version	String	参数解释： 验证数据集版本ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
checkpoint_id	String	参数解释： 训练过程中产生恢复点的唯一标识UUID，当基于某个任务的中间恢复点进行续训或者重训时使用。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
source_model_id	String	参数解释： 项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
source_model_name	String	参数解释： 标识当前续训或者重训任务使用的恢复点来源任务使用的模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
steps	Integer	参数解释： 续训或者重训任务使用的恢复点对应的步数。 约束限制： 不涉及 取值范围： 1-10000 默认取值： 不涉及
skipped_steps	Integer	参数解释： 在断点续训场景可指定基于某一断点跳过指定训练步数进行续训，0表示不跳过。 约束限制： 不涉及 取值范围： 1-10000 默认取值： 不涉及
dataset_split_ratio	Integer	参数解释： 训练、验证数据集分割比率。 约束限制： 不涉及 取值范围： 1-100 默认取值： 不涉及
model_id	String	参数解释： 当前训练任务所使用的模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
model_type	String	参数解释： 模型类型，取值为NLP MM CV Predict AI4Science，依次为：NLP大模型、多模态模型、CV模型、预测模型、科学计算模型。 约束限制： 不涉及 取值范围： NLP MM CV Predict AI4Science 默认取值： 不涉及
train_type	String	参数解释： 训练类型，支持SFT（全量微调）、PRETRAIN（预训练）、LORA（lora微调）、DPO（dpo强化学习）。 约束限制： 不涉及 取值范围： SFT（全量微调）、PRETRAIN（预训练）、LORA（lora微调）、DPO（dpo强化学习） 默认取值： 不涉及
checkpoint_config	Object	参数解释： 任务开启续训功能的相关配置，包含了保存断点的最大个数及跳过步数等信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
task_parameter	Object	参数解释： 本次训练任务的参数配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
pool_node_count	Integer	参数解释： 本次训练任务使用的资源池节点数量。 约束限制： 不涉及 取值范围： 1-100 默认取值： 不涉及
flavor	Integer	参数解释： 当前资源池的算力规格313/280。 约束限制： 不涉及 取值范围： 1-100 默认取值： 不涉及
t_flops	Integer	参数解释： 当前训练任务使用的总算力数。 约束限制： 不涉及 取值范围： 1-1000000 默认取值： 不涉及

参数	参数类型	描述
train_task_desc	String	参数解释： 训练任务描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	Long	参数解释： 训练任务创建时间。 约束限制： 不涉及 取值范围： 1-2147483647 默认取值： 不涉及
update_time	Long	参数解释： 训练任务更新时间，当任务状态刷新或者修改描述时更新时间变化。 约束限制： 不涉及 取值范围： 1-2147483647 默认取值： 不涉及
train_process	Double	参数解释： 训练任务进度，取值0-1。 约束限制： 不涉及 取值范围： 0.0-1.0 默认取值： 不涉及

参数	参数类型	描述
parent_model	String	参数解释： 本次训练任务使用的模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
parent_model_id	String	参数解释： 本次训练任务使用的模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
train_cost_time	Long	参数解释： 训练任务执行时间，单位ms。 约束限制： 不涉及 取值范围： 1-2147483647 默认取值： 不涉及
train_predict_time	Long	参数解释： 训练预估耗时，单位ms。 约束限制： 不涉及 取值范围： 1-2147483647 默认取值： 不涉及

参数	参数类型	描述
train_resource	Object	参数解释： 训练资源。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
can_deploy	Boolean	参数解释： 是否可以部署。 约束限制： 不涉及 取值范围： 0：不可部署 1：可以部署 默认取值： 不涉及
plog_level	Integer	参数解释： 训练任务配置的plog日志的级别。 -1：不开启plog日志 0：info日志级别 1：debug日志级别 2：warning日志级别 3：error日志级别 约束限制： 不涉及 取值范围： -1-3 默认取值： -1

参数	参数类型	描述
pfs_path	String	参数解释： 训练监控数据存放路径，当资产支持对接mindstudio insight时不为空。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-880 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。
details	Array of DetailErrorCode objects	ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。

表 3-881 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。
error_message	String	错误详情。

请求示例

创建一个NLP的lora微调训练任务。

```
https://endpoint/v1/0ba805c3edf64df48732c5bf47c40e70/workspaces/098d1ba1-fc21-4f9f-8cba-380486f72212/model-train/train-task

{
  "task_name": "NLP-N2-4K-sft-test",
  "train_task_desc": "",
  "model_type": "NLP",
  "train_type": "LORA",
  "task_parameter": {
    "parameters": [ {
      "description": "训练资源规格",
      "format": "train_flavor",
```

```
"name": "training_flavor",
"type": "json",
"value": {
  "flavor_id": "modelarts.pool.visual.8xlarge",
  "pool_id": "pool-Snt9b-64-c3140321fbc4401fa3aa571976cbebc"
},
"used_steps": [ "training_job" ]
}, {
  "format": "nfs",
  "name": "sfs_model_key",
  "required": false,
  "type": "json",
  "used_steps": [ "training_job" ]
}, {
  "format": "nfs",
  "name": "sfs_train_dataset_key",
  "required": false,
  "type": "json",
  "used_steps": [ "training_job" ]
}, {
  "format": "nfs",
  "name": "sfs_eval_dataset_key",
  "required": false,
  "type": "json",
  "used_steps": [ "training_job" ]
}, {
  "format": "pfs",
  "name": "mind_studio_insight_pfs",
  "required": false,
  "type": "json",
  "value": {
    "local_path": "/pfs_summary_key/",
    "pfs_path": "/train-insight/user-models/c3140321fbc4401fa3aa571976cbebc/52d0a83d-c396-11ef-b797-0255ac100036/model-assets/NLP/Pangu-NLP-N2-4K/af1d6a7b-a69c-4250-91a0-44f098ee5177/"
  },
  "used_steps": [ "training_job" ]
}, {
  "default": 0.01,
  "name": "warmup",
  "description": "warmup, 热身阶段占整体训练的比例。刚开始训练时若选择一个较大的学习率, 可能带来模型的不稳定, 选择使用warmup热身的方式, 可以使得开始训练的热身阶段内学习率较小, 在热身阶段的小学习率下, 模型可以慢慢趋于稳定, 等模型相对稳定后再逐渐提升至预设的最大学习率进行训练。使用热身可以使模型收敛速度更快, 效果更佳。",
  "constraint": {
    "min": 0,
    "max": 0.05
  },
  "type": "float",
  "title": "热身比例",
  "used_steps": [ "training_job" ],
  "value": 0.01,
  "step": 0.01,
  "format": "N2"
}, {
  "default": 16,
  "name": "batch_size",
  "description": "数据批量大小定义了一个训练step中将通过网络训练的样本数量, 通常来说数据批量越大, 梯度会越稳定, 但是同时也会使用更大的显存, 受硬件限制可能会OOM, 并延长单次训练时长。",
  "type": "enum",
  "title": "数据批量大小",
  "enum": [ 8, 16, 32, 64 ],
  "used_steps": [ "training_job" ],
  "value": 16,
  "options": [ {
    "label": 8
  }, {
    "label": 16
  }, {
    "label": 32
```

```
    }, {
      "label": 64
    }
  ], {
    "default": 0.05,
    "name": "lr_decay_ratio",
    "description": "lr_decay_ratio, 学习率衰减比率",
    "constraint": {
      "min": 0,
      "max": 1
    },
    "type": "float",
    "title": "学习率衰减比率",
    "used_steps": [ "training_job" ],
    "value": 0.05,
    "step": 0.01,
    "format": "N2"
  }, {
    "default": 1.0E-4,
    "name": "learning_rate",
    "description": "learning_rate, 学习率用于控制每个训练step参数更新的幅度, 一般来说需要选择一个合适的学习率, 否则当学习率过大的时候会导致模型难以收敛, 过小的时候会收敛速度过慢。",
    "constraint": {
      "min": 1.0E-6,
      "max": 0.001
    },
    "type": "float",
    "title": "学习率",
    "used_steps": [ "training_job" ],
    "value": 1.0E-4,
    "step": 1.0E-4,
    "format": "N4"
  }, {
    "default": 4,
    "name": "epochs",
    "description": "epochs, 完成全部训练数据集训练的次数。",
    "constraint": {
      "min": 1,
      "max": 50
    },
    "type": "int",
    "title": "训练轮数",
    "used_steps": [ "training_job" ],
    "value": 4
  }, {
    "default": 16,
    "name": "lora_rank",
    "description": "LoRA_rank, 在Lora矩阵中, Rank的值通常用于衡量矩阵的复杂度和信息量。Rank的值越高, 表示矩阵中包含的信息越多, 也就意味着矩阵的复杂度越高。",
    "type": "enum",
    "title": "Lora矩阵的秩",
    "enum": [ 8, 16, 32, 64, 128 ],
    "used_steps": [ "training_job" ],
    "value": 16,
    "options": [ {
      "label": 8
    }, {
      "label": 16
    }, {
      "label": 32
    }, {
      "label": 64
    }, {
      "label": 128
    } ]
  }, {
    "default": false,
    "name": "is_agent_data",
    "description": "主要用于Agent模型微调, 功能开启后, 用户自己设置prompt, 具体的prompt请联系华为工
```

```
    程师",
    "type": "bool",
    "title": "Agent微调",
    "used_steps": [ "training_job" ],
    "value": false
  }, {
    "default": 0.1,
    "name": "weight_decay",
    "description": "weight_decay, 权重衰减系数, 通过在损失函数中增加一个与模型权重大小相关的惩罚项,
来鼓励模型保持权重较小, 从而防止模型过于复杂或过拟合训练数据",
    "constraint": {
      "min": 0.01,
      "max": 0.2
    },
    "type": "float",
    "title": "权重衰减系数",
    "used_steps": [ "training_job" ],
    "value": 0.1,
    "step": 0.1,
    "format": "N1"
  }, {
    "default": "adamw",
    "name": "optimizer",
    "description": "optimizer, 训练中对模型参数进行更新的算法",
    "type": "enum",
    "title": "优化器",
    "enum": [ "adamw" ],
    "used_steps": [ "training_job" ],
    "value": "adamw",
    "options": [ {
      "label": "adamw"
    } ]
  } ],
  "storages": [ {
    "name": "output_storage",
    "description": "",
    "type": "obs",
    "title": "输出目录"
  } ],
  "data_requirements": [ ]
},
"model_source": "pangu",
"plog_level": 3,
"t_flops": 2504,
"train_target": "LORA",
"model_id": "c62f31af-1ab3-4c07-b4cf-d88817584c0f",
"asset_id": "c62f31af-1ab3-4c07-b4cf-d88817584c0f",
"dataset_id": "1344341274190286848",
"dataset_name": "单轮-人设-jq",
"dataset_version_id": "",
"pool_node_count": 1,
"flavor": 313,
"sfs_config": {
  "model_sfs_enable": false,
  "dataset_sfs_enable": false,
  "dataset_preload": false
}
}
```

响应示例

状态码: 200

成功响应示例

```
{
  "project_id": "string",
  "workflow_id": "string",
  "task_id": "string",
}
```

```
"task_name" : "训练任务240328204547",
"dataset_id" : "bK4S4dCoRBWwbHOvzzU",
"dataset_name" : "test-dataset",
"dataset_version_id" : "qnjglHyC71lJnGyPqzD",
"dataset_version_name" : "string",
"dataset_type" : "string",
"execution_id" : "string",
"steps_execution" : "string",
"is_reuse_parameter" : "string",
"reuse_parameter_task_name" : "string",
"task_status" : "string",
"eval_dataset_name" : "string",
"eval_dataset_id" : "string",
"eval_dataset_version" : "string",
"checkpoint_id" : "string",
"source_model_id" : "string",
"source_model_name" : "string",
"steps" : 10000,
"skipped_steps" : 10000,
"dataset_split_ratio" : 100,
"model_id" : "string",
"model_type" : "string",
"reward_model_id" : "string",
"train_type" : "string",
"checkpoint_config" : { },
"task_parameter" : {
  "parameters" : [ {
    "name" : "task_name",
    "type" : "str",
    "description" : "请输入一个只包含大小写字母、数字、下划线、破折号或汉字的名称。如果填写已有的标注任务名称，则直接使用该标注任务；如果填写新的标注任务名称，则自动创建新的标注任务",
    "required" : true,
    "used_steps" : [ "labeling" ],
    "value" : "classift-vehicle-0317"
  }, {
    "name" : "train_ratio",
    "type" : "str",
    "description" : "训练集划分比例(0-1)",
    "default" : "1.0",
    "required" : true,
    "used_steps" : [ "release" ],
    "value" : "0.9"
  }, {
    "name" : "V100_flavor",
    "type" : "json",
    "format" : "train_flavor",
    "description" : "训练资源规格",
    "required" : true,
    "used_steps" : [ "classification_model_train_job" ],
    "value" : {
      "flavor_id" : "modelarts.p3.8xlarge.public",
      "pool_id" : ""
    }
  }, {
    "name" : "batch_size",
    "type" : "int",
    "title" : "batch_size",
    "description" : "训练数据批次大小",
    "default" : 64,
    "required" : true,
    "used_steps" : [ "classification_model_train_job" ],
    "value" : 64
  }, {
    "name" : "xxx_num",
    "type" : "int",
    "title" : "xxx_num",
    "description" : "xxx数量",
    "default" : 1,
    "required" : true,
```

```
"used_steps" : [ "classification_model_train_job" ],
"value" : 8
}, {
  "name" : "epochs",
  "type" : "int",
  "title" : "epochs",
  "description" : "模型训练迭代轮数",
  "default" : 10,
  "required" : true,
  "used_steps" : [ "classification_model_train_job" ],
  "value" : 10
}, {
  "name" : "is_hpo",
  "type" : "enum",
  "title" : "is_hpo",
  "description" : "是否进行参数搜索（可能会花费较长时间）",
  "default" : "False",
  "required" : true,
  "enum" : [ "True", "False" ],
  "used_steps" : [ "classification_model_train_job" ],
  "value" : "False",
  "options" : [ {
    "label" : "True"
  }, {
    "label" : "False"
  } ]
}, {
  "name" : "hpo_epochs",
  "type" : "int",
  "title" : "hpo_epochs",
  "description" : "参数搜索迭代轮次",
  "default" : 10,
  "required" : true,
  "used_steps" : [ "classification_model_train_job" ],
  "value" : 10
}, {
  "name" : "T4_flavor",
  "type" : "json",
  "format" : "train_flavor",
  "description" : "训练资源规格",
  "required" : true,
  "used_steps" : [ "T4_model_convert_job", "service_image_update_job" ],
  "value" : {
    "flavor_id" : "modelarts.pool.visual.xlarge",
    "pool_id" : "pool-pangu-cv-5aaf999415664e61a42e739e9ce1a1b9"
  }
}, {
  "name" : "replaced_image_name",
  "type" : "str",
  "title" : "replaced_image_name",
  "description" : "基础镜像名",
  "default" : "swr.xxx/xxx/xxx:1.6.1.1.20231023100655",
  "required" : true,
  "used_steps" : [ "service_image_update_job" ],
  "value" : "swr.xxx/xxx/xxx:1.6.1.1.20231023100655"
}, {
  "name" : "new_image_prefix",
  "type" : "str",
  "title" : "new_image_prefix",
  "description" : "新镜像名前缀",
  "default" : "swr.xxx/xxx/xxx",
  "required" : true,
  "used_steps" : [ "service_image_update_job" ],
  "value" : "swr.xxx/xxx/xxx"
} ],
"storages" : [ {
  "name" : "output_storage",
  "title" : "output_storage",
  "description" : "输出目录统一配置",
```

```
{
  "type": "obs",
  "path": "/pangu-cv/train-output/"
}],
"data_requirements": [ {
  "name": "input_data",
  "type": "dataset",
  "used_steps": [ "labeling" ],
  "value": {
    "data_type": 0,
    "dataset_id": "bK4S4dCoRBWwbHOvzzU",
    "version_id": "qnjglHyC71lJnGyPqzD"
  }
}
],
"pool_node_count": 100,
"flavor": 100,
"t_flops": 1000000,
"is_input_finished": null,
"train_task_desc": "图像分类工作流现网问题复现",
"create_time": 2147483647,
"update_time": 2147483647,
"train_process": 1,
"parent_model": "string",
"parent_model_id": "string",
"train_cost_time": 2147483647,
"train_predict_time": 2147483647,
"train_resource": { },
"can_deploy": true,
"plog_level": -1,
"pfs_path": "string"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.13.6 获取训练任务某一步执行的节点信息

功能介绍

获取训练任务某一步执行的节点信息，用来获取该节点上的训练任务日志，配合[获取工作流训练任务某一步执行日志信息](#)使用，为task_id的取值。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/model-train/execution/{execution_id}/training-jobs/{job_id}

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-882 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
execution_id	是	String	参数解释： 训练任务执行ID，取自 查询训练任务详情 接口响应体中 execution_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
job_id	是	String	参数解释： 训练任务执行节点对应的JOB_ID，取自 查询训练任务详情 接口响应体中steps_execution字段中的job_id，若当前训练任务有多个子任务例如数据预处理和训练，则job_id有多个。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-883 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-884 响应 Header 参数

参数	参数类型	描述
X-request-id	String	参数解释： 该字段是用于任务跟踪的请求ID编号。 约束限制： 格式为request_uuid-时间戳-主机名。 取值范围： 不涉及 默认取值： 不涉及

表 3-885 响应 Body 参数

参数	参数类型	描述
status	JobTasks object	参数解释： 任务节点列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-886 JobTasks

参数	参数类型	描述
tasks	Array of strings	参数解释： 任务列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-887 响应 Header 参数

参数	参数类型	描述
X-request-id	String	参数解释： 该字段是用于任务跟踪的请求ID编号。 约束限制： 格式为request_uuid-时间戳-主机名。 取值范围： 不涉及 默认取值： 不涉及

表 3-888 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。
details	Array of DetailErrorCode objects	ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。

表 3-889 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。
error_message	String	错误详情。

状态码：404

表 3-890 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

参数	参数类型	描述
details	Array of DetailErrorCode objects	ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。

表 3-891 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。
error_message	String	错误详情。

请求示例

无

响应示例

状态码：200

成功响应示例

```
{
  "status": {
    "tasks": [ "worker-0" ]
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.13.7 发布训练模型

功能介绍

训练任务运行成功后，将产生的模型信息发布到资产中心，进行部署或者再次训练等操作。

URI

POST /v1/{project_id}/workspaces/{workspace_id}/model-train/model/publish

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-892 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-893 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-894 请求 Body 参数

参数	是否必选	参数类型	描述
execution_id	是	String	参数解释： workflows执行ID，取自 查询训练任务详情 接口响应体 execution_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_id	是	String	参数解释： 模型ID，取自 获取发布的模型列表 接口响应体model_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
visibility	是	String	参数解释： 全局可见性，用来控制资产是当前空间可见或者全部空间可见，取值current all。 约束限制： 不涉及 取值范围： current all 默认取值： current
category	否	String	参数解释： 模型资产来源。 约束限制： 不涉及 取值范围： • pangu(来自盘古大模型) • 3rd(来自用户自行导入的第三方大模型) • pangu-poc(来自poc版本的盘古大模型) • pangu-iit(来自工业智能中枢中的模型) • 3rd-pangu(来自盘古服务所提供的第三方大模型) 默认取值： pangu
asset_name	是	String	参数解释： 发布到资产中心的用户模型的名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
description	否	String	参数解释： 发布到资产中心的用户模型的描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-895 响应 Header 参数

参数	参数类型	描述
X-request-id	String	参数解释： 该字段是用于任务跟踪的请求ID编号。 约束限制： 格式为request_uuid-时间戳-主机名。 取值范围： 不涉及 默认取值： 不涉及

表 3-896 响应 Body 参数

参数	参数类型	描述
model_id	String	参数解释： 模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-897 响应 Header 参数

参数	参数类型	描述
X-request-id	String	参数解释： 该字段是用于任务跟踪的请求ID编号。 约束限制： 格式为request_uuid-时间戳-主机名。 取值范围： 不涉及 默认取值： 不涉及

表 3-898 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。
details	Array of DetailErrorCode objects	ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。

表 3-899 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。
error_message	String	错误详情。

状态码：404

表 3-900 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

参数	参数类型	描述
details	Array of DetailErrorCode objects	ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。

表 3-901 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。
error_message	String	错误详情。

请求示例

发布已训练完成的模型到资产中心。

```
POST https://endpoint/v1/{project_id}/workspaces/{workspace_id}/model-train/model/publish
{
  "execution_id" : "e1afe47f-b570-4079-b24a-f1540bef4c4d",
  "model_id" : "3b62e672-35b9-4c26-972d-15b22f3404c9",
  "asset_name" : "验证发布0415",
  "description" : "",
  "visibility" : "all",
  "category" : "3rd"
}
```

响应示例

状态码：200

成功响应示例

```
{
  "model_id" : "28f61af50fc9452aa0ed5ea25c3cc3d3"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.13.8 获取发布的模型列表

功能介绍

训练任务完成，获取发布的模型列表。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/model-train/models

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

表 3-902 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-903 Query 参数

参数	是否必选	参数类型	描述
action_type	否	String	参数解释： 操作类型定义，枚举值： PRETRAIN（预训练）、SFT（全量微调）、LORA（lora微调）、QUANTIZATION（量化）、DPO（dpo强化学习）。 约束限制： 不涉及 取值范围： PRETRAIN（预训练）、SFT（全量微调）、LORA（lora微调）、QUANTIZATION（量化）、DPO（dpo强化学习） 默认取值： 不涉及
model_type	否	String	参数解释： 模型类型，取值为NLP MM CV Predict AI4Science，依次为：NLP大模型、多模态模型、CV模型、预测模型、科学计算模型。 约束限制： 不涉及 取值范围： NLP MM CV Predict AI4Science 默认取值： 不涉及
weather_job_type	否	String	参数解释： 气象作业类型(AI科学计算大模型使用)。 约束限制： AI科学计算大模型使用 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
weather_data_config	否	String	参数解释： 气象数据配置(AI科学计算大模型使用)。 约束限制： AI科学计算大模型使用 取值范围： 不涉及 默认取值： 不涉及
model_name	否	String	参数解释： 模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
execution_id	是	String	参数解释： 训练任务执行ID，取值自 查询训练任务详情 接口响应体 execution_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
limit	否	Integer	参数解释： 分页大小。 约束限制： 不涉及 取值范围： 1-1000 默认取值： 不涉及

参数	是否必选	参数类型	描述
page	否	Integer	参数解释： 查询开始的记录数。 约束限制： 不涉及 取值范围： 1-1000 默认取值： 不涉及
status	否	String	参数解释： 模型状态，published（已发布）、unpublished（未发布）。 约束限制： 不涉及 取值范围： published（已发布）、unpublished（未发布） 默认取值： 不涉及
temporal_resolution	否	String	参数解释： 气象时间分辨率(AI科学计算大模型使用)。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
train_task_id	否	String	参数解释： 训练作业ID，取值来自 查询训练任务详情 响应体task_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-904 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-905 响应 Header 参数

参数	参数类型	描述
X-request-id	String	参数解释： 该字段是用于任务跟踪的请求ID编号。 约束限制： 格式为request_uuid-时间戳-主机名。 取值范围： 不涉及 默认取值： 不涉及

表 3-906 响应 Body 参数

参数	参数类型	描述
count	Long	参数解释： 可发布模型的总数。 约束限制： 不涉及 取值范围： 1-10000 默认取值： 不涉及
models	Array of ModelListIntroduction objects	参数解释： 模型列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-907 ModelListIntroduction

参数	参数类型	描述
model_id	String	参数解释： 训练产生的模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_name	String	参数解释： 待发布模型的名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
create_time	String	参数解释： 模型的生成时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 模型的更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_type	String	参数解释： 模型类型，取值为NLP MM CV Predict AI4Science，依次为：NLP大模型、多模态模型、CV模型、预测模型、科学计算模型。 约束限制： 不涉及 取值范围： NLP MM CV Predict AI4Science 默认取值： 不涉及
execution_id	String	参数解释： 工作流执行ID，标识了产生该模型的训练任务执行记录的ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
workflow_id	String	参数解释： 本次训练任务使用的工作流UUID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 租户项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_id	String	参数解释： 训练产生该模型时使用的数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_version_id	String	参数解释： 训练产该模型时使用的数据集版本ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 模型状态。 约束限制： 不涉及 取值范围： - completed：训练完成，模型未发布 - published：模型已发布 默认取值： 不涉及
workflow_asset_id	String	参数解释： 生成该模型的训练任务使用的资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
train_task_id	String	参数解释： 产生该模型的训练任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_id	String	参数解释： 创建产生该模型训练任务的用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
artifacts	Array of Artifacts objects	参数解释： 模型产物。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_desc	String	参数解释： 模型描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	String	参数解释： 工作空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
action_type	Array of strings	参数解释： 该模型支持的任务类型。 约束限制： 不涉及 取值范围： • PRETRAIN：预训练 • LORA：lora微调 • SFT：全量微调 • ONLINE-DEPLOY：部署 默认取值： 不涉及

表 3-908 Artifacts

参数	参数类型	描述
project_id	String	参数解释： 项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	String	参数解释： 工作空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
artifact_id	String	参数解释： 训练生成的产物ID，一个训练完成的模型可支持多个类型任务的产物。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_id	String	参数解释： 模型ID，当前产物关联的模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
model_location	String	参数解释： 模型产物在OBS的存储路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_tag	String	参数解释： 资产标签。 约束限制： 不涉及 取值范围： ● PRETRAIN：预训练 ● LORA：lora微调 ● SFT：全量微调 ● ONLINE-DEPLOY：部署 与ACTION中的asset_tag进行匹配， 表示下一步支持的动作 默认取值： 不涉及
action_type	String	参数解释： 操作类型定义。 约束限制： 不涉及 取值范围： ● PRETRAIN：预训练 ● SFT：全量微调 ● LORA：lora微调 ● TRANSFORM：转换，当中间查无发布成资产时使用 ● QUANTIZATION：量化 ● DPO：dpo强化学习 默认取值： 不涉及

参数	参数类型	描述
chip_type	String	参数解释： 卡类型，当前产物支持的资源类型，取值一般为ascend。 约束限制： 不涉及 取值范围： ascend 默认取值： 不涉及
model_specifications	String	参数解释： 模型产物支持的资源规格类型，取值一般为Snt9B3/Snt9B4。 约束限制： 不涉及 取值范围： Snt9B3/Snt9B4 默认取值： 不涉及
security_policy	String	参数解释： 当前产物的加密策略。 约束限制： 不涉及 取值范围： - PLAIN：明文不加密 - AES256：AES256算法加密 - SCCBase64：SCCBase64加密 默认取值： 不涉及
properties	String	参数解释： 产物的扩展属性。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_id	String	参数解释： 当前产物发布为资产的ID，若资产未发布，则为空。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
status	String	参数解释： 产物的状态，标识当前产物是否被发布。 约束限制： 不涉及 取值范围： - completed：训练完成，产物未发布 - published：产物已发布 默认取值： 不涉及

状态码：400

表 3-909 响应 Header 参数

参数	参数类型	描述
X-request-id	String	参数解释： 该字段是用于任务跟踪的请求ID编号。 约束限制： 格式为request_uuid-时间戳-主机名。 取值范围： 不涉及 默认取值： 不涉及

表 3-910 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。
details	Array of DetailErrorCode objects	ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。

表 3-911 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。
error_message	String	错误详情。

状态码：404

表 3-912 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。
details	Array of DetailErrorCode objects	ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。

表 3-913 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。
error_message	String	错误详情。

请求示例

无

响应示例

状态码：200

成功响应示例

```
{
  "count": 1,
  "models": [ {
    "project_id": "0ba805c3edf64df48732c5bf47c40e70",
    "model_id": "3b62e672-35b9-4c26-972d-15b22f3404c9",
    "execution_id": "e1afe47f-b570-4079-b24a-f1540bef4c4d",
    "model_name": "deepseek-sft-mock-1621-20250415083050",
    "model_type": "NLP",
    "model_location": "/user-models/0ba805c3edf64df48732c5bf47c40e70/098d1ba1-fc21-4f9f-8cba-380486f72212/model-assets/ThrNLP/DeepSeek-V3/2988ac7d-ea73-46d4-92ee-5eb02bf0d771/",
    "train_model_location": "",
    "create_time": "2025-04-15 16:30:51.0",
    "update_time": "2025-04-15 16:30:51.0",
    "status": "completed",
    "workflow_id": "b418c4e3-cb57-4b3a-a002-dbab91cbbabd",
    "model_desc": "",
    "dataset_id": "1356553117507915776",
    "dataset_version_id": "",
    "workflow_asset_id": "93cba17a-598c-40d7-8494-2320a1ac57b2",
    "train_task_id": "2d17dbdd-3a8d-415d-87f9-cde881a1d214",
    "user_id": "c1764f03893744fe96648ae747198cbe",
    "asset_tag": "",
    "workspace_id": "098d1ba1-fc21-4f9f-8cba-380486f72212",
    "action_type": [ "PRETRAIN", "LORA", "SFT", "TRANSFORM", "ONLINE-DEPLOY", "ONLINE-DEPLOY" ],
    "artifacts": [ {
      "project_id": "0ba805c3edf64df48732c5bf47c40e70",
      "workspace_id": "098d1ba1-fc21-4f9f-8cba-380486f72212",
      "artifact_id": "29771c5b-1d44-454f-bb4b-a114ac309eff",
      "model_id": "3b62e672-35b9-4c26-972d-15b22f3404c9",
      "model_location": "obs://largemodelstudio-assets/user-models/0ba805c3edf64df48732c5bf47c40e70/098d1ba1-fc21-4f9f-8cba-380486f72212/model-assets/ThrNLP/DeepSeek-V3/2988ac7d-ea73-46d4-92ee-5eb02bf0d771/models/sft/",
      "asset_tag": "SFT",
      "action_type": "SFT",
      "model_file_type": "PT",
      "chip_type": "ascend",
      "model_specifications": "Snt9B3",
      "parent_artifact_id": "",
      "security_policy": "PLAIN",
      "properties": "{}",
      "asset_id": "93cba17a-598c-40d7-8494-2320a1ac57b2",
      "status": "completed",
      "create_time": 1744705851000,
      "update_time": 1744705851000
    } ]
  } ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.13.9 批量删除已下发训练任务

功能介绍

批量删除训练任务。

约束与限制：当前训练任务的产物包括发布为资产的中间产物如果被发布成资产或者被用于其它任务，例如量化或者部署，则不允许直接删除，如果删除请先删除对应子任务。

URI

DELETE /v1/{project_id}/workspaces/{workspace_id}/model-train/train-tasks

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

表 3-914 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-915 Query 参数

参数	是否必选	参数类型	描述
train_task_id_list	是	String	参数解释： 训练任务ID列表，任务ID取自 新建训练任务 接口响应体task_id，用逗号分隔。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-916 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-917 响应 Body 参数

参数	参数类型	描述
success_num	Integer	参数解释： 成功删除任务数。 约束限制： 不涉及 取值范围： 0-2147483647 默认取值： 不涉及
failed_num	Integer	参数解释： 删除失败任务数。 约束限制： 不涉及 取值范围： 0-2147483647 默认取值： 不涉及

状态码：400

表 3-918 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。
details	Array of DetailErrorCode objects	ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。

表 3-919 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。

参数	参数类型	描述
error_message	String	错误详情。

请求示例

批量删除训练任务。

```
DELETE https://endpoint/v1/{project_id}/workspaces/{workspace_id}/model-train/train-tasks?train_task_id_list=0963e928-7147-4385-b1f8-f2fb87c7365c
```

响应示例

状态码：200

成功响应示例

```
{  "success_num" : 1,  "failed_num" : 0}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.13.10 查询执行任务的断点信息（本接口用于调用其他接口时获取请求参数使用）

功能介绍

获取开启了续训功能的训练任务产生的恢复点列表。

URI

```
GET /v1/{project_id}/workspaces/{workspace_id}/model-train/execution/{execution_id}/checkpoints
```

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-920 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
execution_id	是	String	参数解释： 训练任务执行ID，取自 查询训练任务详情 接口响应体中 execution_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-921 Query 参数

参数	是否必选	参数类型	描述
limit	否	Integer	参数解释： 分页查询大小。 约束限制： 不涉及 取值范围： 1-1000 默认取值： 10
page	否	Integer	参数解释： 分页查询页数。 约束限制： 不涉及 取值范围： 1-100 默认取值： 1

请求参数

表 3-922 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-923 响应 Body 参数

参数	参数类型	描述
count	Long	参数解释： 查询到的断点总数。 约束限制： 不涉及 取值范围： 0-2147483647 默认取值： 不涉及
train_tasks	Array of CheckPointResp objects	参数解释： 断点信息列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-924 CheckPointResp

参数	参数类型	描述
checkpoint_id	String	参数解释： 开启了续训功能的训练任务所产生的恢复点UUID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
train_id	String	参数解释： 产生该恢复点的训练任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
execution_id	String	参数解释： 当前训练任务的执行记录ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
workspace_id	String	参数解释： 工作空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
steps	Integer	参数解释： 产生该恢复点的训练步数。 约束限制： 不涉及 取值范围： 0-2147483647 默认取值： 不涉及
loss	Integer	参数解释： 当前该恢复点的loss值。 约束限制： 不涉及 取值范围： 0-2147483647 默认取值： 不涉及
create_time	String	参数解释： 当前该恢复点的创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-925 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。
details	Array of DetailErrorCode objects	ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。

表 3-926 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。
error_message	String	错误详情。

请求示例

获取当前训练任务的恢复点列表信息。

```
GET https://endpoint/v1/{project_id}/workspaces/{workspace_id}/model-train/execution/{execution_id}/checkpoints
```

响应示例

状态码：200

成功响应示例

```
{
  "count": 1,
  "checkpoints": [ {
    "checkpoint_id": "3ceaa1da-939a-4d07-9bce-c1f6df1c8f49",
    "train_id": "2d17dbdd-3a8d-415d-87f9-cde881a1d214",
    "execution_id": "e1afe47f-b570-4079-b24a-f1540bef4c4d",
    "project_id": "0ba805c3edf64df48732c5bf47c40e70",
    "workspace_id": "098d1ba1-fc21-4f9f-8cba-380486f72212",
    "steps": 10000,
    "loss": 0.1,
    "create_time": 1744705832000,
    "model_type": "NLP",
    "train_type": "SFT"
  } ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.13.11 获取模型详情（本接口用于调用其他接口时获取请求参数使用）

功能介绍

查询模型详情。

URI

POST /v1/{project_id}/workspaces/{workspace_id}/model-train/model-detail

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

表 3-927 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-928 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-929 请求 Body 参数

参数	是否必选	参数类型	描述
model_type	是	String	参数解释： 模型类型，取值为NLP MM CV Predict AI4Science，依次为： 大语言模型、多模态模型、CV模型、预测模型、科学计算模型。 约束限制： 不涉及 取值范围： NLP MM CV Predict AI4Science 默认取值： 不涉及

参数	是否必选	参数类型	描述
train_type	是	String	参数解释： 训练类型，支持SFT（全量微调）、PRETRAIN（预训练）、LORA（lora微调）、DPO（dpo强化学习）、RFT（rft强化学习）。 约束限制： 不涉及 取值范围： SFT（全量微调）、PRETRAIN（预训练）、LORA（lora微调）、DPO（dpo强化学习）、RFT（rft强化学习） 默认取值： 不涉及
model_source	是	String	参数解释： 模型来源，取值SYSTEM、USER，依次为来自于盘古发布的预置模型、来自于训练任务产生的模型。 约束限制： 不涉及 取值范围： SYSTEM、USER 默认取值： 不涉及
model_id	是	String	参数解释： 本次训练使用的模型ID，取自资产列表响应体的asset_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
quantization_strategy	否	String	参数解释： 模型支持的量化策略，具体以资产中支持的为准。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-930 响应 Body 参数

参数	参数类型	描述
model_id	String	参数解释： 本次训练使用的模型ID，取自资产列表响应体的asset_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_name	String	参数解释： 训练所使用的模型名称,如果是系统模型名称为资产列表接口的model_name_code，如果为训练产生的模型，为发布模型时自定义的名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
model_type	String	参数解释： 模型类型，取值为NLP MM CV Predict AI4Science，依次为：大语言模型、多模态模型、CV模型、预测模型、科学计算模型。 约束限制： 不涉及 取值范围： NLP MM CV Predict AI4Science 默认取值： 不涉及
asset_id	String	参数解释： 预置模型资产id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_source	String	参数解释： 模型来源。 约束限制： 不涉及 取值范围： • USER：来自于训练任务产生的模型 • SYSTEM：来自于盘古发布的预置模型 默认取值： 不涉及
is_supported_checkpoint	String	参数解释： 当前模型资产是否支持断点续训。 约束限制： 不涉及 取值范围： 0：不支持；1：支持 默认取值： 不涉及

参数	参数类型	描述
super_params	SuperParams object	参数解释： 训练模型支持的超参。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_train_resource	Array of ActionResource objects	参数解释： 模型训练所需的资源信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_info	Object	参数解释： 训练任务使用的工作流信息，包含训练超参等。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-931 SuperParams

参数	参数类型	描述
parameters	Array of objects	参数解释： 当前模型资产支持的训练超参。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
storages	Storage object	参数解释： 当前资产定义的训练产物的OBS存储路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
data_requirements	Array of DataRequirement objects	参数解释： 训练使用的数据要求。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-932 Storage

参数	参数类型	描述
name	String	参数解释： 资源的名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
title	String	参数解释： 资源的中文名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
description	String	参数解释： 描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
type	String	参数解释： 类型。例如：obs。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
path	String	参数解释： 存储目录。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-933 DataRequirement

参数	参数类型	描述
name	String	参数解释： 训练数据的名称。 约束限制： 填写1-64位，仅包含英文、数字、下划线（_）和中划线（-），并且以英文开头的名称。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
type	String	参数解释： 数据来源类型。 约束限制： 不涉及 取值范围： 当前仅支持OBS 默认取值： 不涉及
conditions	Array of Constraint objects	参数解释： 数据约束条件。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
value	Map<String,Object>	参数解释： 数据的值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
used_steps	Array of strings	参数解释： 使用了这条数据的工作流节点。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
delay	Boolean	参数解释： 延时参数标记。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-934 Constraint

参数	参数类型	描述
attribute	String	参数解释： 属性，参数的某个字段值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
operator	String	参数解释： 操作，当前只支持equal操作。 约束限制： 不涉及 取值范围： equal 默认取值： 不涉及
value	Object	参数解释： 取值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-935 ActionResource

参数	参数类型	描述
resource_id	String	参数解释： 资源ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cpu	String	参数解释： cpu消耗。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
min_cpu	String	参数解释： 最低cpu消耗。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max_cpu	String	参数解释： 最高cpu消耗。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
memory	String	参数解释： 内存。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
min_memory	String	参数解释： 最低内存。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max_memory	String	参数解释： 最高内存。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
flavor	String	参数解释： 卡类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
min_card_count	String	参数解释： 最低卡数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
max_card_count	String	参数解释： 最高卡数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
card_step	String	参数解释： 卡的步长。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
chip_type	String	参数解释： 芯片类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
device_type	String	参数解释： 设备类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
driver_version	String	参数解释： 驱动版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image	Image object	-

表 3-936 Image

参数	参数类型	描述
image_id	String	参数解释： 镜像ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_name	String	参数解释： 镜像名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
image_version	String	参数解释： 镜像版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_url	String	参数解释： 镜像存放地址。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_port	String	参数解释： 镜像端口。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
image_desc	String	参数解释： 镜像描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
image_tag	String	参数解释： 镜像标识。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
arch	String	参数解释： 架构 arm/x86。 约束限制： 不涉及 取值范围： arm/x86 默认取值： 不涉及
input_mode	Array of strings	参数解释： 输入模型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
output_mode	Array of strings	参数解释： 输出模型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
request_mode	String	参数解释： 部署模型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
http_protocol	String	参数解释： HTTP/HTTPS。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
chip_type	String	参数解释： 芯片类型 如Snt9B3。 说明 snt9的具体值需要联系服务技术支持获取。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
device_type	String	参数解释： 驱动类型GPU/CPU/NONE。 约束限制： 不涉及 取值范围： GPU/CPU/NONE 默认取值： 不涉及

参数	参数类型	描述
driver_version	String	参数解释： 驱动版本C86/C87。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
support_model_versions	Array of strings	参数解释： 支持的模型版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
storage_type	String	参数解释： 存储类型。 约束限制： 不涉及 取值范围： OBS或sfs Turbo 默认取值： 不涉及
health_check	HealthCheck object	参数解释： 健康检查。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-937 HealthCheck

参数	参数类型	描述
url	String	参数解释： 健康检查URL。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
protocol	String	参数解释： 健康检查接口协议。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
initial_delay_seconds	String	参数解释： 健康检查初始化延迟时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
timeout_seconds	String	参数解释： 健康检查超时时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
period_seconds	String	参数解释： 健康检查周期。填写大于0且小于等于2147483647的整数，单位为秒。 约束限制： 不涉及 取值范围： 大于0且小于等于2147483647的整数 默认取值： 不涉及
failure_threshold	String	参数解释： 健康检查最大失败次数。填写大于0且小于等于2147483647的整数。 约束限制： 不涉及 取值范围： 大于0且小于等于2147483647的整数 默认取值： 不涉及
check_method	String	参数解释： 健康检查方式。 约束限制： 不涉及 取值范围： HTTP 或者 EXEC（命令行） 默认取值： 不涉及
command	String	参数解释： 命令行命令。 约束限制： 以空格分隔的字符串 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-938 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。
details	Array of DetailErrorCode objects	ModelArts Studio平台依赖的三方调用错误码列表服务异常信息。

表 3-939 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。
error_message	String	错误详情。

请求示例

查询模型详情

```
{
  "model_id": "aa0c2d63-3354-4006-8d3c-77c6e25da48e",
  "train_type": "sft",
  "model_source": "pangu",
  "model_type": "NLP"
}
```

响应示例

状态码：200

成功响应示例

```
{
  "category": "pangu",
  "model_id": "06255b9e-60ca-4c02-8975-2bb62019453e",
  "model_name": "Pangu-NLP-N2-4K-3.2.35",
  "model_type": "NLP",
  "asset_id": "06255b9e-60ca-4c02-8975-2bb62019453e",
  "asset_code": "Pangu-NLP-N2-4K",
  "asset_source": "Preset",
  "model_source": "SYSTEM",
  "is_supported_checkpoint": "1",
  "model_train_resource": [ {
    "computility": "280t",
    "resource_id": "4a7fe8fd-cfb8-4f43-b7b8-2bc09dd39fea",
    "action_id": "8461d9fa-632e-4062-bce6-8b13ace47ad5",
    "cpu": 0,
    "min_cpu": 0,
    "max_cpu": 0,
    "memory": 0,
    "min_memory": 0,
    "max_memory": 0,
  }
]
```

```
"flavor": "custom",
"card_count": 32,
"min_card_count": 32,
"max_card_count": 1024,
"card_step": 32,
"chip_type": "Snt9B4",
"device_type": "NPU",
"driver_version": "23.0.7",
"create_time": "2025-03-17 21:03:41",
"update_time": "2025-03-17 21:03:41"
}, {
  "computility": "313t",
  "resource_id": "7bc62e46-dc19-4fb5-9122-0cb60f9200f8",
  "action_id": "8461d9fa-632e-4062-bce6-8b13ace47ad5",
  "cpu": 0,
  "min_cpu": 0,
  "max_cpu": 0,
  "memory": 0,
  "min_memory": 0,
  "max_memory": 0,
  "flavor": "custom",
  "card_count": 32,
  "min_card_count": 32,
  "max_card_count": 1024,
  "card_step": 32,
  "chip_type": "Snt9B3",
  "device_type": "NPU",
  "driver_version": "23.0.7",
  "create_time": "2025-03-17 21:03:41",
  "update_time": "2025-03-17 21:03:41"
}],
"workflow_info": {
  "storages": [ {
    "name": "output_storage",
    "description": "",
    "type": "obs",
    "title": "输出目录"
  } ],
  "extend": {
    "allow_update_steps": true,
    "model_security_steps": [ "training_job" ]
  },
  "data_requirements": [ ],
  "assets": [ {
    "content_id": "b8724ee5-b5b4-4e60-97f5-610ff5b7c1bd",
    "name": "fa45364fd6a94f408fd0da34f7d5d236",
    "type": "algorithm2"
  } ],
  "data": [ ],
  "name": "n2-pretrain-workflow",
  "description": "盘古-NLP-N2-预训练流水线",
  "steps": [ {
    "outputs": [ ],
    "inputs": [ ],
    "name": "training_job",
    "type": "job",
    "title": "模型训练",
    "depend_steps": [ ],
    "properties": {
      "metadata": {
        "name": "workflow-80d9a431dc5c4ba6a7c6a057bd12df63"
      },
      "kind": "job",
      "spec": {
        "log_export_path": {
          "obs_url": "$ref/storages(with_execution_id=True,create_dir=True)/output_storage/log"
        },
        "resource": {
          "flavor": "$ref/parameters/training_flavor",
```

```
    "node_count" : 1,
    "policy" : "regular"
  },
  "volumes" : [ {
    "nfs" : "$ref/parameters/sfs_model_key"
  }, {
    "nfs" : "$ref/parameters/sfs_train_dataset_key"
  }, {
    "nfs" : "$ref/parameters/sfs_eval_dataset_key"
  }, {
    "pfs" : "$ref/parameters/mind_studio_insight_pfs"
  } ],
  "schedule_policy" : {
    "priority" : 3
  }
},
"algorithm" : {
  "subscription_id" : "$ref/assets/fa45364fd6a94f408fd0da34f7d5d236",
  "item_version_id" : "uRSpdn",
  "parameters" : [ {
    "name" : "warmup",
    "value" : "$ref/parameters/warmup"
  }, {
    "name" : "batch_size",
    "value" : "$ref/parameters/batch_size"
  }, {
    "name" : "lr_decay_ratio",
    "value" : "$ref/parameters/lr_decay_ratio"
  }, {
    "name" : "weight_decay",
    "value" : "$ref/parameters/weight_decay"
  }, {
    "name" : "optimizer",
    "value" : "$ref/parameters/optimizer"
  }, {
    "name" : "learning_rate",
    "value" : "$ref/parameters/learning_rate"
  }, {
    "name" : "epochs",
    "value" : "$ref/parameters/epochs"
  }, {
    "name" : "save_checkpoint_steps",
    "value" : "$ref/parameters/save_checkpoint_steps"
  }, {
    "name" : "files_processes",
    "value" : "$ref/parameters/files_processes"
  } ]
},
"policy" : {
  "max_execution_minutes" : 999999,
  "poll_interval_seconds" : 1
},
"parameters" : [ {
  "name" : "training_flavor",
  "format" : "train_flavor",
  "description" : "训练资源规格",
  "type" : "json",
  "used_steps" : [ "training_job" ]
}, {
  "name" : "sfs_model_key",
  "format" : "nfs",
  "type" : "json",
  "required" : false,
  "used_steps" : [ "training_job" ]
}, {
  "name" : "sfs_train_dataset_key",
  "format" : "nfs",
```

```
"type": "json",
"required": false,
"used_steps": [ "training_job" ]
}, {
  "name": "sfs_eval_dataset_key",
  "format": "nfs",
  "type": "json",
  "required": false,
  "used_steps": [ "training_job" ]
}, {
  "name": "mind_studio_insight_pfs",
  "format": "pfs",
  "type": "json",
  "required": false,
  "used_steps": [ "training_job" ]
}, {
  "default": 0.01,
  "name": "warmup",
  "description": "warmup, 热身阶段占整体训练的比例。刚开始训练时若选择一个较大的学习率, 可能带来模型的不稳定, 选择使用warmup热身的方式, 可以使得开始训练的热身阶段内学习率较小, 在热身阶段的小学习率下, 模型可以慢慢趋于稳定, 等模型相对稳定后再逐渐提升至预设的最大学习率进行训练。使用热身可以使模型收敛速度更快, 效果更佳。",
  "constraint": {
    "min": 0,
    "max": 0.1
  },
  "type": "float",
  "title": "热身比例",
  "used_steps": [ "training_job" ]
}, {
  "default": 128,
  "name": "batch_size",
  "description": "数据批量大小定义了一个训练step中将通过网络训练的样本数量, 通常来说数据批量越大, 梯度会越稳定, 但是同时也会使用更大的显存, 受硬件限制可能会OOM, 并延长单次训练时长。",
  "type": "int",
  "title": "数据批量大小",
  "enum": [ 16, 32, 64, 128, 256, 512 ],
  "used_steps": [ "training_job" ]
}, {
  "default": 1,
  "name": "lr_decay_ratio",
  "description": "lr_decay_ratio, 学习率衰减比率",
  "constraint": {
    "min": 0,
    "max": 1
  },
  "type": "float",
  "title": "学习率衰减比率",
  "used_steps": [ "training_job" ]
}, {
  "default": 0.1,
  "name": "weight_decay",
  "description": "weight_decay, 权重衰减系数, 通过在损失函数中增加一个与模型权重大小相关的惩罚项, 来鼓励模型保持权重较小, 从而防止模型过于复杂或过拟合训练数据",
  "constraint": {
    "min": 0.01,
    "max": 0.2
  },
  "type": "float",
  "title": "权重衰减系数",
  "used_steps": [ "training_job" ]
}, {
  "default": "adamw",
  "name": "optimizer",
  "description": "optimizer, 训练中对模型参数进行更新的算法",
  "type": "str",
  "title": "优化器",
  "enum": [ "adamw" ],
  "used_steps": [ "training_job" ]
```

```
{
  "default": 5.0E-6,
  "name": "learning_rate",
  "description": "learning_rate, 学习率用于控制每个训练step参数更新的幅度，一般来说需要选择一个合适的学习率，否则当学习率过大的时候会导致模型难以收敛，过小的时候会收敛速度过慢。",
  "constraint": {
    "min": 1.0E-6,
    "max": 1.0E-4
  },
  "type": "float",
  "title": "学习率",
  "used_steps": [ "training_job" ]
}, {
  "default": 1,
  "name": "epochs",
  "description": "epochs, 完成全部训练数据集训练的次数。",
  "constraint": {
    "min": 1,
    "max": 10
  },
  "type": "int",
  "title": "训练轮数",
  "used_steps": [ "training_job" ]
}, {
  "default": 100000,
  "name": "save_checkpoint_steps",
  "description": "save_checkpoint_steps, 模型每隔多少步保存一次",
  "constraint": {
    "min": 1000,
    "max": 100000
  },
  "type": "int",
  "title": "模型保存步数",
  "used_steps": [ "training_job" ]
}, {
  "default": 50,
  "name": "files_processes",
  "description": "files_processes, 数据预处理并发个数",
  "constraint": {
    "min": 10,
    "max": 50
  },
  "type": "int",
  "title": "数据预处理并发个数",
  "used_steps": [ "training_job" ]
} ],
"policy": { }
},
"content_id": "7497bf3f-a8b3-4f9b-8c25-be5afad79dd6",
"thr_env": [ ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.13.12 获取指定租户及工作空间，时间范围内训练任务的耗时

功能介绍

获取指定时间范围的训练任务运行时长，按照工作空间及任务运行所使用的资源池算力规格粒度汇聚。该接口会统计训练任务的实际运行时间。CPU资源池任务、工业资产、AI Hub订阅资产的任务不进行统计。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/model-train/resource-usage

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-940 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-941 Query 参数

参数	是否必选	参数类型	描述
start_time	是	Long	参数解释： 统计查询开始时间，毫秒时间戳，当统计时间超过3个月，返回统计结果以天为单位。 约束限制： 时间戳（毫秒级） 取值范围： 不涉及 默认取值： 不涉及
end_time	是	Long	参数解释： 统计窗口结束时间，毫秒时间戳，当统计时间在3个月以内，返回统计结果以分钟为单位。 约束限制： 时间戳（毫秒级） 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-942 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-943 响应 Body 参数

参数	参数类型	描述
total_size	Integer	参数解释： 本次查询到的数据条目数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
tasks_info	Array of TaskRunningInfo objects	参数解释： 训练任务运行时长信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-944 TaskRunningInfo

参数	参数类型	描述
chip_type	String	参数解释： 任务运行所使用的资源池算力规格，例如sntb3。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_type	String	参数解释： 统计运行时长的任务类型。 约束限制： 不涉及 取值范围： train：训练任务 quantization：量化任务 默认取值： 不涉及
duration	Float	参数解释： 任务运行时长，单位卡x分钟或者卡x小时，当统计时间大于3个月时为小时，小于3个月时为分钟。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-945 响应 Body 参数

参数	参数类型	描述
error_code	String	参数解释： 错误码 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_msg	String	参数解释： 错误描述 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
details	Array of DetailErrorCode objects	参数解释： 错误详情信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
description	String	参数解释： 错误说明。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
solution	String	参数解释： 错误解决方案。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-946 DetailErrorCode

参数	参数类型	描述
error_code	String	参数解释： 错误码。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
error_message	String	参数解释： 错误详情。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
trace_id	String	参数解释： 模型训练过程中调用链的唯一标识，UUID格式。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
train_phase	String	参数解释： 模型训练任务阶段，如running表示训练过程中产生异常。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
node	String	参数解释： 模型训练过程的物理节点，如worker-0。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

状态码：200

```
{
  "total_size" : 2,
  "tasks_info" : [ {
    "chip_type" : "snt9b3",
    "task_type" : "quantization",
    "duration" : 76.467
  }, {
    "chip_type" : "snt9b3",
    "task_type" : "train",
    "duration" : 0.217
  } ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.13.13 获取指定资源池或资源池节点上运行的任务

功能介绍

指定资源池或资源池的节点查询调度到该资源池或者节点的训练任务，当前支持查询专属资源池运行的任务。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/model-train/tasks

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-947 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-948 Query 参数

参数	是否必选	参数类型	描述
pool_id	是	String	参数解释： 资源池ID，取自 查询资源池列表详情 接口响应体metadata字段中的name参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
node_ip	否	String	参数解释： 资源池节点IP，取自 查询资源池列表详情 接口响应体status字段中的privatelp参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-949 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-950 响应 Body 参数

参数	参数类型	描述
count	Long	参数解释： 查询到的训练任务总数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
train_tasks	Array of TrainTaskRsp objects	参数解释： 训练任务列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-951 TrainTaskRsp

参数	参数类型	描述
project_id	String	参数解释： 项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workflow_id	String	参数解释： 工作空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_id	String	参数解释： 训练任务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_name	String	参数解释： 训练任务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
dataset_id	String	参数解释： 本次训练任务使用的训练数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_name	String	参数解释： 本次训练任务使用的训练数据集名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_version_id	String	参数解释： 本次训练任务使用的训练数据集版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_type	String	参数解释： 本次训练任务使用数据集类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
execution_id	String	参数解释： 任务执行ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
steps_execution	String	参数解释： 如果训练任务工作流有多个执行节点，例如数据预处理节点、训练节点等，执行节点信息则包含了这些节点的详情。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_status	String	参数解释： 训练任务状态。 约束限制： 不涉及 取值范围： init：初始化 wait_created：等待创建 pending：排队中 running：运行中 stopping：停止中 stopped：已停止 failed：失败 completed：已完成 默认取值： 不涉及

参数	参数类型	描述
eval_dataset_name	String	参数解释： 验证数据集名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
eval_dataset_id	String	参数解释： 验证数据集ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
eval_dataset_version	String	参数解释： 验证数据集版本ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
checkpoint_id	String	参数解释： 断点续训场景所使用的断点ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
source_model_id	String	参数解释： 续训任务来源模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
source_model_name	String	参数解释： 续训任务来源模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
dataset_split_ratio	Integer	参数解释： 训练、评估数据集分割比率。 约束限制： 不涉及 取值范围： 1-100 默认取值： 不涉及
model_id	String	参数解释： 模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
model_type	String	参数解释： 模型类型，取值为NLP、MM、CV、Predict、AI4Science，依次为：NLP大模型、多模态模型、CV模型、预测模型、科学计算模型。 约束限制： 不涉及 取值范围： NLP、MM、CV、Predict、AI4Science 默认取值： 不涉及
train_type	String	参数解释： 训练类型，支持SFT（全量微调）、PRETRAIN（预训练）、LORA（lora微调）、DPO（dpo强化学习）、RFT（rft强化学习）。 约束限制： 不涉及 取值范围： SFT（全量微调）、PRETRAIN（预训练）、LORA（lora微调）、DPO（DPO强化学习）、RFT（RFT强化学习） 默认取值： SFT
checkpoint_config	Object	参数解释： 断点续训相关配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
task_parameter	Object	参数解释： 训练任务运行参数，参数取于获取模型详情（本接口用于调用其他接口时获取请求参数使用）接口中的 workflow_info.parameters，需要根据实际训练任务进行配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
pool_node_count	Integer	参数解释： 资源池节点数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
flavor	Integer	参数解释： 资源池算力规格。 约束限制： 不涉及 取值范围： 常用规格有313、280 默认取值： 不涉及
t_flops	Integer	参数解释： 本次训练任务使用的总算力。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
train_task_desc	String	参数解释： 训练任务描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	Long	参数解释： 创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	Long	参数解释： 训练任务更新时间，当修改、或者训练任务状态发生变化时进行更新。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
train_process	Double	参数解释： 训练任务进度。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
parent_model	String	参数解释： 本次训练任务所使用的模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
parent_model_id	String	参数解释： 本次训练任务所使用的模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
plog_level	Integer	参数解释： 训练任务配置的plog日志级别。 约束限制： 不涉及 取值范围： -1：关闭 0：debug 1：info 2：warning 3：error 默认取值： 不涉及
pfs_path	String	参数解释： 监控数据存放路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
datasets_config	Array of DatasetConfig objects	参数解释： 该训练任务数据集相关的配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
priority	Integer	参数解释： 训练任务调度优先级，只有等待创建状态可以修改。 约束限制： 不涉及 取值范围： 1：低 2：中 3：高 默认取值： 3

表 3-952 DatasetConfig

参数	参数类型	描述
dataset_name	String	参数解释： 训练数据集名称，取自 查询数据集详情 v1 接口响应体name参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
dataset_source	String	参数解释： 所使用的数据集来源。 约束限制： 不涉及 取值范围： 取值datamng、OBS、DB，分别表示来自于数据工程、OBS、DWS数据库（部分预测大模型训练时可使用DWS数据库的数据） 默认取值： 不涉及
dataset_id	String	参数解释： 训练数据集ID，取自 查询数据集详情v1 接口响应体dataset_id参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
split_ratio	Integer	参数解释： 训练、验证数据集分割比率，当该模型支持验证集且验证集来自选择的训练集时使用，取值大于等于1，小于等于50。 约束限制： 不涉及 取值范围： 取值大于等于1，小于等于50 默认取值： 不涉及
used_step	String	参数解释： 数据集使用的阶段。 约束限制： 不涉及 取值范围： 取值为train、eval、test，分别表示该数据集用于训练、验证、测试 默认取值： 不涉及

参数	参数类型	描述
dataset_proportion	Integer	参数解释： 数据集配比比率，表示使用多少比率的该数据集进行训练。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-953 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。
details	Array of DetailErrorCode objects	本服务调用三方异常信息。
error_desc	String	错误说明。
error_solution	String	错误解决方案。

表 3-954 DetailErrorCode

参数	参数类型	描述
error_code	String	错误码。
error_message	String	错误详情。
trace_id	String	用于追踪请求在整个系统中流转过程的唯一标识符。
train_phase	String	平台创建训练任务的阶段，例如：buildModel。
node	String	训练任务运行的节点，例如：worker-0 等。

参数	参数类型	描述
step_name	String	模型训练的阶段，例如：download-dataset，用户标识模型训练异常的阶段。

请求示例

无

响应示例

状态码：200

训练任务详情

```
{
  "count" : 33,
  "train_tasks" : [ {
    "project_id" : "c3140321fbc4401fa3aa571976cbebc",
    "train_task_desc" : "",
    "create_time" : 1743491919000,
    "update_time" : 1743491920000,
    "train_process" : 0,
    "model_type" : "NLP",
    "train_type" : "QUANTIZATION",
    "train_cost_time" : 0,
    "can_deploy" : false,
    "model_id" : "1abc2f8f-114d-49f5-a2fe-82cfc37e08f3",
    "pool_node_count" : 1,
    "plog_level" : 0
  } ]
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.14 推理任务管理

3.14.1 获取服务列表

功能介绍

获取推理服务列表信息。

接口域名请参考[获取盘古服务外部API域名](#)获取。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/model-service/services

表 3-955 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-956 Query 参数

参数	是否必选	参数类型	描述
asset_type	否	String	参数解释： 资产类型，分为：NLP(NLP大模型)，CV(CV大模型)，MM(多模态大模型)，Predict(预测大模型)，AI4Science(科学计算)，Profession(专业大模型)。 约束限制： 不涉及 取值范围： • NLP • CV • MM • Predict • AI4Science • Profession 默认取值： 不涉及
service_name	否	String	参数解释： 创建模型部署任务所填写的部署任务名称，支持模糊搜索。 约束限制： 中文，英文（大小写），数字（0-9），-，_，长度64。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
status	否	String	参数解释： 模型部署后服务的运行状态，不传该参数时默认全部筛选。 约束限制： 不涉及 取值范围： • init 初始化 • deploying 部署中 • running 运行中 • concerning 告警 • stopping 停止中 • stopped 已停止 • failed 失败 • deleting 删除中 • updating 更新中 • update_failed 更新失败 • wait_child 等待子任务 • child_failed 子任务失败 默认取值： 不涉及
request_mode	否	String	参数解释： 模型部署请求方式。 约束限制： 科学计算需要填async，其他模型需要填写sync。 取值范围： sync（同步部署），async（异步部署） 默认取值： 不涉及

参数	是否必选	参数类型	描述
infer_type	否	String	参数解释： 推理服务类型。分为： online(在线部署)，edge(边缘部署)。 约束限制： 不涉及 取值范围： • online 在线部署 • edge 边缘部署 默认取值： 不涉及
category	否	String	参数解释： 模型来源。 约束限制： 不涉及 取值范围： • pangu(来自盘古大模型) • 3rd(来自用户自行导入的第三方大模型) • pangu-poc(来自poc版本的盘古大模型) • pangu-iit(来自工业智能中枢中的模型) • 3rd-pangu(来自盘古服务所提供的第三方大模型) 默认取值： 不涉及
limit	否	Integer	参数解释： 分页大小，每一页返回的最大条目数，该字段和offset的乘积需要小于可查询的数据的最大值1000。 约束限制： 不涉及 取值范围： 1-1000 默认取值： 10

参数	是否必选	参数类型	描述
offset	否	Integer	参数解释： 分页列表的起始页，该字段和 limit 的乘积需要小于可查询的数据的最大值1000。 约束限制： 不涉及 取值范围： 0-1000 默认取值： 0
sort_by	否	String	参数解释： 指定排序字段。 约束限制： 不涉及 取值范围： ● create_time 部署任务创建时间 ● service_name 部署任务名称 默认取值： create_time
order	否	String	参数解释： 查询模型部署服务列表的排序方式，可选“asc”或“desc”，代表递增排序及递减排序。 约束限制： 不涉及 取值范围： ● desc 递减 ● asc 递增 默认取值： desc

参数	是否必选	参数类型	描述
scene	否	String	参数解释： 场景类型，包括Weather，Precip，Ocean_Swell，Ocean_Ecology。分别表示气象/降水/海浪/生态。 约束限制： 资产类型为科学计算时使用。 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-957 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码： 200

表 3-958 响应 Body 参数

参数	参数类型	描述
count	Integer	参数解释： 服务总数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
services	Array of GetModelServiceRsp objects	参数解释： 模型服务信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
status_count	Array of GetModelServiceStatusCountRsp objects	参数解释： 不同状态下的服务数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-959 GetModelServiceRsp

参数	参数类型	描述
assets	Array of ModelAssetInfo objects	参数解释： 模型部署服务所关联的模型资产信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_id	String	参数解释： 模型部署服务的用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_name	String	参数解释： 模型部署服务的用户名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 模型部署服务的创建者的项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
workspace_id	String	参数解释： 模型部署服务所在的工作空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_id	String	参数解释： 模型部署服务的服务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_name	String	参数解释： 模型部署服务的服务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_desc	String	参数解释： 模型部署服务的描述信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 模型服务状态。 约束限制： 不涉及 取值范围： • init 初始化 • deploying 部署中 • running 运行中 • concerning 告警 • stopping 停止中 • stopped 已停止 • failed 失败 • deleting 删除中 • updating 更新中 默认取值： 不涉及
arch	String	参数解释： 架构类型。 约束限制： 不涉及 取值范围： • X86 X86架构 • ARM ARM架构 默认取值： 不涉及

参数	参数类型	描述
category	String	参数解释： 资产来源。 约束限制： 不涉及 取值范围： • pangu(来自盘古大模型) • 3rd(来自用户自行导入的第三方大模型) • pangu-poc(来自poc版本的盘古大模型) • pangu-iit(来自工业智能中枢中的模型) • 3rd-pangu(来自盘古服务所提供的第三方大模型) 默认取值： 不涉及
infer_type	String	参数解释： 部署服务类型。 约束限制： 不涉及 取值范围： • online 在线部署 • edge 边缘部署 默认取值： 不涉及
device_type	String	参数解释： 部署服务端的设备类型（NPU，GPU，NONE）信息。 约束限制： 不涉及 取值范围： • GPU • NPU • NONE 默认取值： 不涉及

参数	参数类型	描述
chip_type	String	参数解释： 芯片类型，如Snt9B3。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
request_mode	String	参数解释： 模型部署服务的推理类型。 约束限制： 不涉及 取值范围： • sync 同步 • async异步 默认取值： 不涉及
model_config	ModelConfig object	参数解释： 模型服务的模型配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_config	ServiceConfig object	参数解释： 模型部署的服务配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
service_info	Object	参数解释： 模型部署在modelarts服务详情信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 模型服务的创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 模型服务的更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
elb_id	String	参数解释： 模型边缘部署的负载均衡ID。 约束限制： 仅边缘部署涉及。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
access_port_id	String	参数解释： 模型边缘部署服务的访问端口ID。 约束限制： 仅边缘部署涉及 取值范围： 不涉及 默认取值： 不涉及
access_url	String	参数解释： 模型服务访问url，在线服务为URL，边缘服务为ELB访问路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_rollback	Boolean	参数解释： 模型部署服务是否触发回滚。 约束限制： 不涉及 取值范围： true：触发回滚；false：未触发回滚 默认取值： 不涉及
consume	ResourceConsume object	参数解释： 模型服务所消耗的资源信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
model_info	String	参数解释： 模型服务部署在modelarts服务详情信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
api_url	String	参数解释： 模型服务的外部API访问地址。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
security_bar_type	String	参数解释： 安全护栏类型。 约束限制： 不涉及 取值范围： ● ENABLE 开启 ● DISABLE 关闭 ● NOT_SUPPORT 不支持 默认取值： 不涉及
is_preset	Integer	参数解释： 是否为预置模型。 约束限制： 不涉及 取值范围： ● 0 非预置服务 ● 1 预置服务 默认取值： 不涉及

参数	参数类型	描述
template_id	String	参数解释： 后处理代码模板ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cluster_id	String	参数解释： 推理服务所属资源池ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cluster_name	String	参数解释： 推理服务所属资源池名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-960 ModelAssetInfo

参数	参数类型	描述
asset_id	String	参数解释： 资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_type	String	参数解释: 资产类型，分为：NLP(NLP大模型)，CV(CV大模型)，MM(多模态大模型)，Predict(预测大模型)，AI4Science(科学计算)，Profession(专业大模型)。 约束限制: 不涉及 取值范围: ● NLP NLP大模型 ● CV CV大模型 ● MM 多模态大模型 ● Predict 预测大模型 ● AI4Science 科学计算大模型 ● Profession 专业大模型 默认取值: 不涉及
asset_sub_type	String	参数解释: 资产子类型。资产类型的子类型，描述了资产的具体类型。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-961 ModelConfig

参数	参数类型	描述
cmd	String	参数解释: 启动命令配置。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
service_config	String	参数解释： 异步模型的配置参数。 约束限制： xml格式的字符串。 取值范围： 不涉及 默认取值： 不涉及
task_config	String	参数解释： 异步模型的作业配置参数。 约束限制： xml格式的字符串。 取值范围： 不涉及 默认取值： 不涉及
input_types	Array of strings	参数解释： 异步模型支持的输入数据类型。 约束限制： 异步场景下必选。 取值范围： OBS、VCN、URL、edgerestful、EdgeCamera 默认取值： 不涉及
output_types	Array of strings	参数解释： 异步模型支持的输出数据类型列表。 约束限制： 异步场景下必选。 取值范围： OBS、Webhook 默认取值： 不涉及

参数	参数类型	描述
obs_path	String	参数解释： 模型所在obs路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
swr_image_path	String	参数解释： swr镜像地址，批量部署资产时必选。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-962 ServiceConfig

参数	参数类型	描述
cluster_id	String	参数解释： 资源池ID。online为在线资源池ID，edge为边缘资源池ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
specification	String	参数解释： 资源规格信息，默认为custom，表示自定义规格。 约束限制： 不涉及 取值范围： 不涉及 默认取值： custom

参数	参数类型	描述
custom_spec	CustomSpec object	参数解释: 自定义资源规格配置。 约束限制: 仅支持在部署到专属资源池时生效。specification 为 custom 时生效。 取值范围: 不涉及 默认取值: 不涉及
user_env	Array of EnvInfo objects	参数解释: 用户自定义环境变量信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
instance_count	Integer	参数解释: 模型部署的实例数。 约束限制: 实例数取值必须大于0。 在线场景必须选择。 取值范围: 1-128 默认取值: 不涉及
additional_properties	ServiceAdditionalProperties object	参数解释: 模型部署附加属性。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
elb_id	String	参数解释： 负载均衡ID。 约束限制： 边缘部署负载均衡访问使用。 取值范围： 不涉及 默认取值： 不涉及

表 3-963 CustomSpec

参数	参数类型	描述
cpu	Float	参数解释： CPU核数，支持配置小数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
gpu	Float	参数解释： GPU个数，可选，默认不使用，支持配置小数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
ascend	Integer	参数解释： Ascend芯片个数，可选，默认不使用。 约束限制： 不支持与gpu同时配置。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
memory	Integer	参数解释： 内存，单位为MB。 约束限制： 仅支持整数。 取值范围： 不涉及 默认取值： 不涉及

表 3-964 EnvInfo

参数	参数类型	描述
key	String	参数解释： 模型环境变量Key值。例如：batch_size 数据批处理 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
value	String	参数解释： 模型环境变量value值。例如：32 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
modifiable	Boolean	参数解释： 环境变量是否可更改。例如：false 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
displayable	Boolean	参数解释： 环境变量是否可显示。例如：true 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-965 ServiceAdditionProperties

参数	参数类型	描述
max_surge	Float	参数解释： 必须大于0，不配置默认值为1。当小于1时，代表滚动升级时增加的实例数的百分比；当大于1时，代表滚动升级时最大扩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及
max_unavailable	Float	参数解释： 必须大于0，不配置默认值为0。当小于1时，代表滚动升级时允许缩容的实例数的百分比；当大于1时，代表滚动升级时允许缩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及

表 3-966 ResourceConsume

参数	参数类型	描述
consumption	Double	参数解释: 资源总消耗量。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
is_setta_l_quot a	Double	参数解释: 部署服务是否已经触发资源消耗。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

表 3-967 GetModelServiceStatusCountRsp

参数	参数类型	描述
initing	Integer	参数解释: 初始化状态数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
running	Integer	参数解释: 运行中状态数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
deploying	Integer	参数解释： 部署中状态数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
concerning	Integer	参数解释： 异常状态数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
stopping	Integer	参数解释： 停止中状态数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
stopped	Integer	参数解释： 停止状态数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
failed	Integer	参数解释： 失败状态数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
deleting	Integer	参数解释： 删除状态数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
updating	Integer	参数解释： 更新状态数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-968 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

无

响应示例

状态码： 200

成功响应示例

```
{
  "count": 1,
  "services": [
    {
      "assets": [
        {
          "asset_id": "00d985af-2fbd-4775-98b6-0b53203c6965",
          "asset_type": "NLP",
          "sub_asset_type": "",
          "asset_tag": "ONLINE-DEPLOY-4K-1P",
          "is_master": true,
          "asset_code": "Pangu-NLP-N1-Chat-32K"
        }
      ],
      "arch": "ARM",
      "service_id": "a977bc11-c2e5-42f6-8533-a015e1d33d22",
      "service_name": "test-zzz01",
      "user_id": "c1764f03893744fe96648ae747198cbe",
      "user_name": "lizhe",
      "project_id": "0ba805c3edf64df48732c5bf47c40e70",
      "workspace_id": "098d1ba1-fc21-4f9f-8cba-380486f72212",
      "status": "running",
      "asset_tag": "ONLINE-DEPLOY-4K-1P",
      "chip_type": "Snt9B3",
      "cluster_id": "hilens-1e256b69c6bc4b058f1a362b01bfd628",
      "cluster_name": "edge-pool-64d7-910b",
      "device_type": "NPU",
      "infer_type": "online",
      "ma_service_id": "3bc9c0ba-7f8c-4a80-8ad6-8e3b446c462e",
      "service_config": {
        "user_env": [
          {
            "key": "MODEL_SIZE",
            "value": "N1",
            "modifiable": false,
            "displayable": false
          },
          {
            "key": "BATCH_SIZE",
            "value": "64",
            "modifiable": false,
            "displayable": false
          },
          {
            "key": "VOCAB_SIZE",
            "value": "-1",
            "modifiable": false,
            "displayable": false
          },
          {
            "key": "STARTMODE",
            "value": "no_nginx",
            "modifiable": false,
            "displayable": false
          },
          {
            "key": "MODELARTS_SERVICE_LOCAL_CACHE_VOLUME",
            "value": "host_path:/mnt/paas/kubernetes/kubelet/infer/cache/,mount_path:/cache",
            "modifiable": false,
            "displayable": false
          },
          {
            "key": "DOWNLOAD_METHOD",
            "value": "studio",

```



```
        "modifiable": false,
        "displayable": false
    },
    {
        "key": "USE_MA_SDK",
        "value": "True",
        "modifiable": false,
        "displayable": false
    },
    {
        "key": "IS_SUPPORT_API_SERVICE",
        "value": "true",
        "modifiable": false,
        "displayable": false
    },
    {
        "key": "KV_CACHE_DTYPE",
        "value": "int8",
        "modifiable": false,
        "displayable": false
    },
    {
        "key": "ASSET_TAG",
        "value": "ONLINE-DEPLOY",
        "modifiable": false,
        "displayable": false
    },
    {
        "key": "PTA_TORCHAIR_DECODE_GEAR_LIST",
        "value": "2,4,8,16,32,64",
        "modifiable": false,
        "displayable": false
    }
},
"instance_count": 1,
"cluster_id": "studio-dev-pool-419bb663f3874716965442b2850e4d81"
},
"create_time": "2024-11-07 20:19:50",
"update_time": "2024-11-07 20:41:23",
"request_mode": "sync",
"access_url": "https://inference-test.xxx.com/v1/infers/3bc9c0ba-7f8c-4a80-8ad6-8e3b446c462e",
"is_rollback": false,
"category": "pangu",
"security_bar_type": "ENABLE",
"api_url": "https://mas.xxx.com/v1/0ba805c3edf64df48732c5bf47c40e70/deployments/a977bc11-c2e5-42f6-8533-a015e1d33d22/chat/completions",
"use_type": "poc"
}
],
"status_count": {
    "init": 0,
    "running": 1,
    "deploying": 0,
    "concerning": 0,
    "stopping": 0,
    "stopped": 0,
    "failed": 0,
    "deleting": 0,
    "updating": 0,
    "update_failed": 0
}
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.14.2 查询模型服务详情

功能介绍

查询模型推理服务详情。

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/model-service/services/{service_id}

表 3-969 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
service_id	是	String	参数解释： 服务ID。可通过调用 获取服务列表 接口获取。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-970 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码： 200

表 3-971 响应 Body 参数

参数	参数类型	描述
assets	Array of ModelAssetInfo objects	参数解释： 模型部署服务所关联的模型资产信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_id	String	参数解释： 模型部署服务的用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_name	String	参数解释： 模型部署服务的用户名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 模型部署服务的创建者的项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
workspace_id	String	参数解释： 模型部署服务所在的工作空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_id	String	参数解释： 模型部署服务的服务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_name	String	参数解释： 模型部署服务的服务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_desc	String	参数解释： 模型部署服务的描述信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 模型服务状态。 约束限制： 不涉及 取值范围： • init 初始化 • deploying 部署中 • running 运行中 • concerning 告警 • stopping 停止中 • stopped 已停止 • failed 失败 • deleting 删除中 • updating 更新中 默认取值： 不涉及
arch	String	参数解释： • X86 X86架构 • ARM ARM架构 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
category	String	参数解释： 资产来源。 约束限制： 不涉及 取值范围： • pangu(来自盘古大模型) • 3rd(来自用户自行导入的第三方大模型) • pangu-poc(来自poc版本的盘古大模型) • pangu-iit(来自工业智能中枢中的模型) • 3rd-pangu(来自盘古服务所提供的第三方大模型) 默认取值： 不涉及
infer_type	String	参数解释： 模型部署类型。 约束限制： 不涉及 取值范围： • online 在线部署 • edge 边缘部署 默认取值： 不涉及
device_type	String	参数解释： 部署服务端的设备类型（NPU，GPU，NONE）信息。 约束限制： 不涉及 取值范围： • GPU • NPU • NONE 默认取值： 不涉及

参数	参数类型	描述
chip_type	String	参数解释： 模型部署服务的芯片类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
request_mode	String	参数解释： 模型部署请求方式。 约束限制： 科学计算需要填async，其他模型需要填写sync。 取值范围： • sync 同步部署 • async 异步部署 默认取值： 不涉及
model_config	ModelConfig object	参数解释： 模型服务的模型配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_config	ServiceConfig object	参数解释： 模型部署的服务配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
service_info	Object	参数解释： 模型部署在modelarts服务详情信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 模型服务的创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 模型服务的更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
elb_id	String	参数解释： 模型边缘部署的负载均衡ID，仅边缘部署涉及。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
access_port_id	String	参数解释： 模型边缘部署服务的访问端口ID，仅边缘部署涉及。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
access_url	String	参数解释： 模型服务访问url，在线服务为URL，边缘服务为ELB访问路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_rollback	Boolean	参数解释： 模型部署服务是否触发回滚。 约束限制： 不涉及 取值范围： • true：触发回滚 • false：未触发回滚 默认取值： 不涉及
consume	ResourceConsume object	参数解释： 模型服务所消耗的资源信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
model_info	String	参数解释： 模型服务部署在modelarts服务详情信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
api_url	String	参数解释： 模型服务的外部API访问地址。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
security_bar_type	String	参数解释： 安全护栏类型。 约束限制： 不涉及 取值范围： ● ENABLE 开启 ● DISABLE 关闭 ● NOT_SUPPORT 不支持 默认取值： 不涉及
is_preset	Integer	参数解释： 是否预置模型。 约束限制： 不涉及 取值范围： ● 0 ● 1 默认取值： 不涉及

参数	参数类型	描述
template_id	String	参数解释： 后处理代码模板ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-972 ModelAssetInfo

参数	参数类型	描述
asset_id	String	参数解释： 资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_type	String	参数解释： 资产类型。 约束限制： 不涉及 取值范围： ● NLP NLP大模型 ● CV CV大模型 ● MM 多模态大模型 ● Predict 预测大模型 ● AI4Science 科学计算大模型 ● Profession 专业大模型 默认取值： 不涉及

参数	参数类型	描述
asset_sub_type	String	参数解释： 资产子类型。资产类型的子类型，描述了资产的具体类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-973 ModelConfig

参数	参数类型	描述
cmd	String	参数解释： 启动命令配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_config	String	参数解释： 异步模型的配置参数。 约束限制： xml格式的字符串。 取值范围： 不涉及 默认取值： 不涉及
task_config	String	参数解释： 异步模型的作业配置参数。 约束限制： xml格式的字符串。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
input_types	Array of strings	参数解释： 异步模型支持的输入数据类型。 约束限制： 异步场景下必选。 取值范围： OBS、VCN、URL、edgerestful、EdgeCamera 默认取值： 不涉及
output_types	Array of strings	参数解释： 异步模型支持的输出数据类型列表。 约束限制： 异步场景下必选 取值范围： OBS、Webhook 默认取值： 不涉及
obs_path	String	参数解释： 模型所在obs路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
swr_image_path	String	参数解释： swr镜像地址，批量部署资产时必选。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-974 ServiceConfig

参数	参数类型	描述
cluster_id	String	参数解释: 资源池ID。online为在线资源池ID，edge为边缘资源池ID。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
specification	String	参数解释: 资源规格信息，当前只支持custom，表示自定义规格。 约束限制: 不涉及 取值范围: custom 默认取值: 不涉及
custom_spec	CustomSpec object	参数解释: 自定义资源规格配置。 约束限制: 仅支持在部署到专属资源池时生效。specification为custom时生效。 取值范围: 不涉及 默认取值: 不涉及
user_env	Array of EnvInfo objects	参数解释: 用户自定义环境信息。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
instance_count	Integer	参数解释： 模型部署的实例数。实例数取值必须大于0。在线场景必须选择。 约束限制： 不涉及 取值范围： 1-128 默认取值： 不涉及
additional_properties	ServiceAdditionProperties object	参数解释： 模型部署附加属性。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
elb_id	String	参数解释： 负载均衡ID。 约束限制： 边缘部署负载均衡访问使用。 取值范围： 不涉及 默认取值： 不涉及

表 3-975 CustomSpec

参数	参数类型	描述
cpu	Float	参数解释： CPU核数，支持配置小数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
gpu	Float	参数解释： GPU个数，可选，默认不使用，支持配置小数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
ascend	Integer	参数解释： Ascend芯片个数，可选，默认不使用。 约束限制： 不支持与gpu同时配置。 取值范围： 不涉及 默认取值： 不涉及
memory	Integer	参数解释： 内存，单位为MB。 约束限制： 仅支持整数。 取值范围： 不涉及 默认取值： 不涉及

表 3-976 EnvInfo

参数	参数类型	描述
key	String	参数解释： 模型环境变量Key值。例如：batch_size 数据批处理 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
value	String	参数解释： 模型环境变量value值。例如： 32 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
modifiable	Boolean	参数解释： 环境变量是否可更改。例如： false 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
displayable	Boolean	参数解释： 环境变量是否可显示。例如： true 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-977 ServiceAdditionProperties

参数	参数类型	描述
max_surge	Float	参数解释： 必须大于0，不配置默认值为1。当小于1时，代表滚动升级时增加的实例数的百分比；当大于1时，代表滚动升级时最大扩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及

参数	参数类型	描述
max_unavailable	Float	参数解释： 必须大于0，不配置默认值为0。当小于1时，代表滚动升级时允许缩容的实例数的百分比；当大于1时，代表滚动升级时允许缩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及

表 3-978 Volume

参数	参数类型	描述
destination	String	参数解释： 卷挂载路径，必须是合法的路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
server	String	参数解释： nfs服务地址，source为nfs为必填。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
key	String	参数解释： 卷的类型，参数取值固定为hostPath。 约束限制： 不涉及 取值范围： • hostPath 默认取值： 不涉及
name	String	参数解释： 卷名称。 约束限制： 小写字母或数字，最长63个字符。 取值范围： 不涉及 默认取值： 不涉及
read_only	Boolean	参数解释： 读写权限。 约束限制： configMap和secret类型只支持读权限。 取值范围： 不涉及 默认取值： 不涉及
source	String	参数解释： 卷来源。 约束限制： type为hostPath时输入路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
type	String	参数解释： 卷的类型，参数固定取值为hostPath。 约束限制： 不涉及 取值范围： • hostPath 默认取值： hostPath

表 3-979 ResourceConsume

参数	参数类型	描述
consumption	Double	参数解释： 模型部署实例的资源总消耗量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_settal_quota	Double	参数解释： 模型部署服务是否触发资源消耗。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-980 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

无

响应示例

状态码： 200

成功响应示例

```
[
  {
    "asset_id": "00d985af-2fbd-4775-98b6-0b53203c6965",
    "root_asset_id": "00d985af-2fbd-4775-98b6-0b53203c6965",
    "asset_name": "Pangu-NLP-N1-Chat-32K-20241030",
    "asset_name_en": "Pangu-NLP-N1-Chat-32K",
    "asset_desc": "此版本是2024年10月发布的十亿级模型版本，支持8K训练，4K/32K推理。基于昇腾卡可单卡推理部署，此模型版本支持全量微调、LoRA微调、INT8量化、断点续训、模型评测、在线推理和能力评测特性。单卡部署4K模型版本支持64并发，单卡部署32K模型版本支持32并发。",
    "asset_version": "3.1.1",
    "external_version": "20241030",
    "is_available": true,
    "category": "pangu",
    "storage_type": "OBS",
    "asset_location": "obs://largemodelstudio-assets/preset-workspace/modelassets/NLP/Pangu-NLP-N1-Chat-32K/3.1.1/models",
    "asset_config_location": "/infer/config",
    "asset_type": "NLP",
    "sub_asset_type": "",
    "asset_code": "Pangu-NLP-N1-Chat-32K",
    "asset_source": "Preset",
    "asset_feature": "7B",
    "asset_tag": "SFT,LORA,EVALUATION,ONLINE-DEPLOY-4K-1P,ONLINE-DEPLOY-32K-1P",
    "security_policy": "AES256",
    "asset_password": "AAAA****/qge0=",
    "properties": {
      "tokenizer_path": "obs://largemodelstudio-assets/preset-workspace/modelassets/NLP/Pangu-NLP-N1-Chat-32K/3.1.1/models/tokenizer/"
    },
    "actions": [
      {
        "action_id": "294df5d0-1059-4dc4-ba0d-a02326114579",
        "asset_id": "00d985af-2fbd-4775-98b6-0b53203c6965",
        "workflow_id": "a59ee3ff-d352-470b-a014-006dd76e0b15",
        "action_name": "ACTION_SFT",
        "action_type": "SFT",
        "asset_tag": "SFT",
        "depend_assets": [],
        "super_params": {},
        "action_env": [],
        "action_properties": {
          "Snt9B3": {
            "TRAIN_TIME_CALU_RULE": "1200+dataT*11059200+dataT*epochs*2560000000000/160/cardsNum+180+120",
            "OUTPUT_ARTIFACTS": "sft_n1_32k.json",
            "GLOG_v": "3",
            "ASCEND_GLOBAL_EVENT_ENABLE": "1",
            "SOLUTION": "STUDIO",
            "MAIN_LOGIC": "pangu_n1_sft/scripts/pangu_n1_32k/run_n1_32k_ascend.sh",
            "HCCL_EXEC_TIMEOUT": "7200",
            "HCCL_CONNECT_TIMEOUT": "7200",
            "ACTION_TYPE": "sft"
          }
        }
      },
      {
        "command": "",
        "support_checkpoint": "1",
        "sub_dir": "/model",
        "workflow": {
```

```
"workflow_id": "a59ee3ff-d352-470b-a014-006dd76e0b15",
"workflow_name": "NLP-N1-SFT",
"workflow_name_en": "NLP-N1-SFT",
"workflow_desc": "N1-微调 workflow",
"workflow_version": "3.1.2",
"workflow_tag": "workflow-Pangu-NLP-N1-SFT",
"workflow_source": "preset",
"workflow_location": "Pangu-NLP-N1-Chat-32K/finetune/3.1.2/metadata.json",
"dataset_type": "NLP-N1",
"content_id": "608c3041-0a3f-4c77-a937-33ebee463292",
"depend_content_ids": [
  "b65baa8b-aa60-4b0a-9023-978774f0afe4"
],
"supported_model_versions": [
  {
    "versions": [
      {
        "action_type": "SFT",
        "version": "3.1.1"
      }
    ]
  },
  {
    "asset_code": "Pangu-NLP-N1-Chat-32K"
  }
],
"create_time": "2024-11-07 19:59:11",
"update_time": "2024-11-07 19:59:11"
},
"resources": [
  {
    "resource_id": "16f9c509-ebc6-467e-a1ff-31a9820d22b2",
    "action_id": "294df5d0-1059-4dc4-ba0d-a02326114579",
    "flavor": "custom",
    "card_count": 8.0,
    "min_card_count": 8.0,
    "max_card_count": 256.0,
    "card_step": 8.0,
    "chip_type": "Snt9B3",
    "device_type": "NPU",
    "driver_version": "23.0.6",
    "create_time": "2024-11-05 14:54:11",
    "update_time": "2024-11-05 14:54:11",
    "computility": "313t"
  }
],
"use_api_proxy": false,
"create_time": "2024-11-05 14:54:11",
"update_time": "2024-11-07 19:59:11"
},
{
  "action_id": "4e8dfe6e-71a9-4222-b52c-e45d083f3f87",
  "asset_id": "00d985af-2fbd-4775-98b6-0b53203c6965",
  "workflow_id": "8103dc23-4818-45cd-9936-b318d0ad7f00",
  "action_name": "ACTION_LORA",
  "action_type": "LORA",
  "asset_tag": "LORA",
  "depend_assets": [],
  "super_params": {},
  "action_env": [],
  "action_properties": {
    "Snt9B3": {
      "TRAIN_TIME_CALU_RULE": "1200+dataT*11059200+dataT*epochs*2560000000000/160/cardsNum+180+120",
      "OUTPUT_ARTIFACTS": "lora_n1_32k.json",
      "GLOG_v": "3",
      "ASCEND_GLOBAL_EVENT_ENABLE": "1",
      "SOLUTION": "STUDIO",
      "MAIN_LOGIC": "pangu_n1_sft/scripts/pangu_n1_32k/run_n1_32k_ascend.sh",
      "HCCL_EXEC_TIMEOUT": "7200",
      "HCCL_CONNECT_TIMEOUT": "7200",
```

```
    "ACTION_TYPE": "lora"
  }
},
"command": "",
"support_checkpoint": "0",
"sub_dir": "/model",
"workflow": {
  "workflow_id": "8103dc23-4818-45cd-9936-b318d0ad7f00",
  "workflow_name": "NLP-N1-LORA",
  "workflow_name_en": "NLP-N1-LORA",
  "workflow_desc": "N1-LORA工作流",
  "workflow_version": "3.1.2",
  "workflow_tag": "workflow-Pangu-NLP-N1-lora",
  "workflow_source": "preset",
  "workflow_location": "Pangu-NLP-N1-Chat-32K/lora/3.1.2/metadata.json",
  "dataset_type": "NLP-N1",
  "content_id": "32c3350b-9d30-4d99-bbb2-8569b823b6fa",
  "depend_content_ids": [
    "a6ba513d-7c1a-4860-a5f4-489ac26232be"
  ],
  "supported_model_versions": [
    {
      "versions": [
        {
          "action_type": "LORA",
          "version": "3.1.1"
        }
      ],
      "asset_code": "Pangu-NLP-N1-Chat-32K"
    }
  ],
  "create_time": "2024-11-07 19:59:18",
  "update_time": "2024-11-07 19:59:18"
},
"resources": [
  {
    "resource_id": "c8b585e8-3bee-4e3b-be6c-550e0a4d5c0d",
    "action_id": "4e8dfe6e-71a9-4222-b52c-e45d083f3f87",
    "flavor": "custom",
    "card_count": 8.0,
    "min_card_count": 8.0,
    "max_card_count": 16.0,
    "card_step": 8.0,
    "chip_type": "Snt9B3",
    "device_type": "NPU",
    "driver_version": "23.0.6",
    "create_time": "2024-11-05 14:54:11",
    "update_time": "2024-11-05 14:54:11",
    "computility": "313t"
  }
],
"use_api_proxy": false,
"create_time": "2024-11-05 14:54:11",
"update_time": "2024-11-07 19:59:18"
},
{
  "action_id": "f920578c-dc9a-49ea-8024-3c686ab6d2e8",
  "asset_id": "00d985af-2fbd-4775-98b6-0b53203c6965",
  "action_name": "ACTION_EVALUATION",
  "action_type": "EVALUATION",
  "asset_tag": "EVALUATION",
  "super_params": {},
  "action_env": [
    {
      "env_name": "SOLUTION",
      "data_type": "string",
      "displayable": false,
      "default_value": "STUDIO",
      "modifiable": true
    }
  ]
}
```



```
    },
    {
      "env_name": "MAIN_LOGIC",
      "data_type": "string",
      "displayable": false,
      "default_value": "pangu_n1_sft/scripts/pangu_n1_32k/run_n1_32k_eval_ascend.sh",
      "modifiable": true
    },
    {
      "env_name": "ASCEND_GLOBAL_EVENT_ENABLE",
      "data_type": "string",
      "displayable": false,
      "default_value": "1",
      "modifiable": true
    },
    {
      "env_name": "GLOG_v",
      "data_type": "string",
      "displayable": false,
      "default_value": "3",
      "modifiable": true
    },
    {
      "env_name": "HCCL_CONNECT_TIMEOUT",
      "data_type": "string",
      "displayable": false,
      "default_value": "7200",
      "modifiable": true
    },
    {
      "env_name": "HCCL_EXEC_TIMEOUT",
      "data_type": "string",
      "displayable": false,
      "default_value": "7200",
      "modifiable": true
    }
  ],
  "action_properties": {},
  "command": "mkdir -p /home/ma-user/code && cp -r /home/ma-user/code_so/* /home/ma-user/
code && cd /home/ma-user/code && bash entry.sh",
  "sub_dir": "/eval",
  "resources": [
    {
      "resource_id": "7d54d9c7-4b3a-4f8c-a81f-97c0c31ed94",
      "action_id": "f920578c-dc9a-49ea-8024-3c686ab6d2e8",
      "image_id": "401fea26-eb1b-4bf9-86b1-9c2290cdcd62",
      "flavor": "custom",
      "card_count": 1.0,
      "min_card_count": 1.0,
      "max_card_count": 1.0,
      "card_step": 1.0,
      "chip_type": "Snt9B3",
      "device_type": "NPU",
      "driver_version": "23.0.6",
      "image": {
        "image_id": "401fea26-eb1b-4bf9-86b1-9c2290cdcd62",
        "image_name": "pangu_nlp_snt9b_pytorch",
        "image_version": "can_8.0.rc1_torch_2.1.0_20241104151805",
        "image_url": "swr.xxx.com/com-huaweicloud-lmstudio-dev/
pangu_nlp_snt9b_pytorch:can_8.0.rc1_torch_2.1.0_20241104151805",
        "image_tag": "pangu_nlp_snt9b_pytorch:can_8.0.rc1_torch_2.1.0_20241104151805",
        "arch": "ARM",
        "input_types": [
          "OBS",
          "VCN",
          "URL",
          "edgerestful",
          "EdgeCamera"
        ]
      }
    }
  ],
```

```
        "output_types": [
            "OBS",
            "WebHook"
        ],
        "supported_model_versions": [],
        "create_time": "2024-11-05 14:54:11",
        "update_time": "2024-11-05 14:54:11"
    },
    "create_time": "2024-11-05 14:54:11",
    "update_time": "2024-11-05 14:54:11",
    "computility": "313t"
}
],
"use_api_proxy": false,
"create_time": "2024-11-05 14:54:11",
"update_time": "2024-11-05 14:54:11"
}
],
"create_time": "2024-11-05 14:54:10",
"update_time": "2024-11-05 14:54:10",
"root_asset_name": "Pangu-NLP-N1-Chat-32K",
"visibility": "all",
"resource_charging_mode": 0
}
]
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.14.3 获取服务监控详情

功能介绍

获取模型推理服务监控详情信息。

接口域名请参考[获取盘古服务外部API域名](#)获取。

URI

GET /v1/{project_id}/workspaces/{workspace_id}/model-service/services/{service_id}/monitors

表 3-981 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_id	是	String	参数解释： 服务ID。可通过调用 获取服务列表 接口获取。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-982 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码： 200

表 3-983 响应 Body 参数

参数	参数类型	描述
service_id	String	参数解释： 模型部署服务的服务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
service_name	String	参数解释： 模型服务的服务名称，以"lms-mod-"开头。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
monitors	Array of Monitor objects	参数解释： 监控信息详情。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_running_instance_count	Integer	参数解释： 服务运行中实例数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_instance_count	Integer	参数解释： 服务实例数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
req_count_per_min	Long	参数解释： 服务分钟调用量，这里指当前时间上一分钟的服务调用总量，云上部署模型字段。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-984 Monitor

参数	参数类型	描述
model_id	String	参数解释： 部署模型服务的模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_name	String	参数解释： 部署模型服务的模型名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_version	String	参数解释： 部署模型服务的模型版本。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
invocation_times	Long	参数解释： 模型服务实例的总调用次数。 约束限制： 云上部署模型字段。 取值范围： 不涉及 默认取值： 不涉及
failed_times	Long	参数解释： 模型服务实例调用失败次数。 约束限制： 云上部署模型字段。 取值范围： 不涉及 默认取值： 不涉及
cpu_core_usage	Float	参数解释： 模型服务已使用CPU核数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cpu_core_total	Float	参数解释： 资源池总CPU核数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
cpu_memory_usage	Integer	参数解释: 模型服务已使用内存，单位MB。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
cpu_memory_total	Integer	参数解释: 总内存，单位MB。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
gpu_usage	Float	参数解释: 模型服务已使用GPU个数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及
gpu_total	Float	参数解释: 资源池总GPU个数。 约束限制: 不涉及 取值范围: 不涉及 默认取值: 不涉及

参数	参数类型	描述
model_running_instance_count	Integer	参数解释： 模型服务运行中的实例数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_instance_count	Integer	参数解释： 模型服务所部署的实例数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
gpu_memory_total	Float	参数解释： gpu总显存，单位MB。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
gpu_memory_usage	Float	参数解释： 模型服务已使用gpu显存，单位MB。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
npu_total	Float	参数解释： 资源池总NPU个数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
npu_usage	Float	参数解释： 模型服务已使用NPU个数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
npu_memory_total	Float	参数解释： 资源池npu总显存，单位MB。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
npu_memory_usage	Float	参数解释： 模型服务已使用npu显存，单位MB。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-985 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

无

响应示例

状态码： 200

成功响应示例

```
{
  "monitors": [
    {
      "model_id": "5301fb44-aaa8-4c82-958b-4ca3f674cbbd",
      "model_name": "lms-mod-a977bc11-c2e5-42f6-8533-a015e1d33d22-1730981981790",
      "model_version": "0.0.1",
      "invocation_times": 89,
      "failed_times": 0,
      "cpu_core_usage": 0.0,
      "cpu_core_total": 10.0,
      "cpu_memory_usage": 0,
      "cpu_memory_total": 163840,
      "gpu_usage": 0.0,
      "gpu_total": 0.0,
      "model_running_instance_count": 1,
      "model_instance_count": 1,
      "gpu_memory_total": 0.0,
      "gpu_memory_usage": 0.0,
      "npu_total": 1.0,
      "npu_usage": 0.0,
      "npu_memory_total":65536.0,
      "npu_memory_usage":58564.934
    }
  ],
  "service_id": "3bc9c0ba-7f8c-4a80-8ad6-8e3b446c462e",
  "service_name": "lms-svc-a977bc11-c2e5-42f6-8533-a015e1d33d22-1730982338353",
  "service_running_instance_count": 1,
  "service_instance_count": 1,
  "req_count_per_min": 0
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.14.4 部署服务

功能介绍

部署模型服务，支持在线/边缘，同步/异步场景（仅科学计算支持异步场景）。

URI

POST /v1/{project_id}/workspaces/{workspace_id}/model-service/services

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-986 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-987 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-988 请求 Body 参数

参数	是否必选	参数类型	描述
asset_id	否	String	参数解释： 部署模型服务的资产ID，单资产部署，跟资产asset_ids二选一，通过 获取模型列表 接口获取。 约束限制： 字符串需要满足UUID格式，如“550e8400-e29b-41d4-a716-446655440000”。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
asset_ids	否	Array of strings	参数解释： 根据资产的id集合进行过滤查询，格式如[id,id,id]。资产id即模型训练界面的模型id或模型部署详情界面内的模型id。 约束限制： 字符串只能由数字、英文字母或短横线组成。 取值范围： 不涉及 默认取值： 不涉及
asset_type	否	String	参数解释： 资产类型。部署的大模型类型，从 获取模型列表 接口中获取（Asset信息中的asset_type字段）。 约束限制： 不涉及 取值范围： ● NLP： NLP大模型 ● CV： CV大模型 ● MM： 多模态大模型 ● Predict： 预测大模型 ● AI4Science： 科学计算大模型 ● Profession： 专业大模型 默认取值： 不涉及

参数	是否必选	参数类型	描述
asset_tag	否	String	参数解释： 资产标签，量化模型必填(同一资产同时存在多个量化模型时通过asset_tag获取唯一的部署信息)，从获取模型列表接口中获取（ Action信息中的asset_tag字段）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
device_type	否	String	参数解释： 设备类型(NPU，GPU，NONE)，从获取模型列表接口中获取(Resource信息中的device_type字段)。 NONE仅为CPU部署，不使用卡。NPU为使用昇腾卡部署。 约束限制： 不涉及 取值范围： ● GPU ● NPU ● NONE 默认取值： NONE
chip_type	否	String	参数解释： 芯片类型。device_type为NONE时, chip_type会进行忽略，从获取模型列表接口中获取(Resource信息中的chip_type字段)。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
request_mode	否	String	参数解释： 请求方式，从获取模型列表接口中获取(Image信息中的request_mode字段)。 约束限制： 部署科学计算模型需要填async。 取值范围： • sync: 同步 • async: 异步 默认取值： sync
category	否	String	参数解释： 资产来源。默认为pangu，从获取模型列表接口中获取（Asset信息中的category字段）。 约束限制： 不涉及 取值范围： • pangu(来自盘古大模型) • 3rd(来自用户自行导入的第三方大模型) • pangu-poc(来自poc版本的盘古大模型) • pangu-iit(来自工业智能中枢中的模型) • 3rd-pangu(来自盘古服务所提供的第三方大模型) 默认取值： 不涉及

参数	是否必选	参数类型	描述
service_name	是	String	参数解释： 服务名称。 约束限制： 支持1~64位可见字符（含中文）， 字符串只能由数字、英文字母、中文字符、下划线或短横线组成。 取值范围： 不涉及 默认取值： 不涉及
service_desc	否	String	参数解释： 服务描述。 约束限制： 支持0~128位可见字符（含中文），不包含^!<>=&"'等字符。 取值范围： 不涉及 默认取值： 不涉及
arch	是	String	参数解释： 架构类型。从 获取模型列表 接口中获取（Image信息中的arch字段）。 约束限制： 不涉及 取值范围： • X86 • ARM 默认取值： 不涉及

参数	是否必选	参数类型	描述
infer_type	是	String	参数解释： 推理类型。分为在线部署 (online)，边缘部署(edge)，从 获取模型列表 接口中获取进行匹配(Action信息中的action_type 字段)。 约束限制： 如果选择的action_type为 ONLINE-DEPLOY，则填入 online。 如果选择的action_type为 EDGE-DEPLOY，则填入edge。 取值范围： • online • edge 默认取值： 不涉及
model_config	是	ModelConfig object	参数解释： 模型配置信息。 约束限制： 仅部署科学计算模型时需要设置， 其他模型传{}即可。 取值范围： 不涉及 默认取值： 不涉及
service_config	是	ServiceConfig object	参数解释： 服务配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
security_bar_type	否	String	参数解释： 安全护栏类型。开启后会对推理内容进行内容审核。如需使用安全护栏功能，请参考《华为云 Stack 8.6.0 技术中台与AI数据中台服务软件安装指南》“人工智能套件”章节完成AI Kits服务的安装。注意安装AI Kits服务完成后，在执行订购操作时，只需要订购Pangu Guard服务。Pangu Guard服务订购完成后，需要在安装指南中找到“盘古大模型服务 > 盘古护栏部署配置说明（可选）”打通网络。 约束限制： 不涉及 取值范围： • ENABLE 开启 • DISABLE 关闭 • NOT_SUPPORT 不支持 默认取值： 不涉及
security_bar_edition	否	String	参数解释： 安全护栏版本信息。安全护栏类型为ENABLE时必填。 约束限制： 目前内容审核只支持BASE基础版。 取值范围： • BASE 基础版 • ADVANCED 高阶版 默认取值： 不涉及

参数	是否必选	参数类型	描述
scene	否	String	参数解释： 场景类型。区分不同的推理场景。分别为Weather(天气)，Precip(降水)，Ocean(全球海洋)，Ocean_Regional(区域海洋)，Ocean_Ecology(海洋生态)，Ocean_Swell(海浪)，Pollution(区域污染物)。 从获取模型列表接口中获取进行匹配(Asset信息中的sub_asset_type字段)，并截取最后一个下划线之前的内容（去除最后一个下划线及后面的时间，如Ocean_Ecology_3h，改为Ocean_Ecology）。 约束限制： 资产类型为科学计算时使用。 取值范围： • Weather • Precip • Ocean • Ocean_Regional • Ocean_Ecology • Ocean_Swell • Pollution 默认取值： 不涉及
deployed_model	否	String	参数解释： 模型部署唯一标识。用户自定义的唯一标识。 约束限制： 长度小于等于64。 取值范围： 不涉及 默认取值： 不涉及

表 3-989 ModelConfig

参数	是否必选	参数类型	描述
task_config	否	String	参数解释： 异步模型的作业配置参数xml格式的字符串。从 获取模型列表 接口中获取（ Image信息中的 task_config字段 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
input_types	否	Array of strings	参数解释： 异步模型支持的输入数据类型。异步场景下-必选。 约束限制： 不涉及 取值范围： • OBS 默认取值： 不涉及
output_types	否	Array of strings	参数解释： 异步模型支持的输出数据类型列表。异步场景下-必选。支持的类型包括OBS。 约束限制： 不涉及 取值范围： • OBS 默认取值： 不涉及

表 3-990 ServiceConfig

参数	是否必选	参数类型	描述
specification	否	String	参数解释： 资源规格信息，为custom时，custom_spec生效。资源规格信息为专属池时，默认传custom，目前只支持专属池。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
custom_spec	否	CustomSpec object	参数解释： 自定义资源规格配置。 约束限制： 仅支持在部署到专属资源池时生效。specification为custom时生效。 取值范围： 不涉及 默认取值： 不涉及
user_env	否	Array of EnvInfo objects	参数解释： 用户自定义环境信息。从获取模型列表接口中获取（ Action信息中的action_env字段 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
instance_count	是	Integer	参数解释： 模型部署的实例数。 约束限制： 实例数取值必须大于0。在线部署场景必须选择。 取值范围： 1-128 默认取值： 不涉及
additional_properties	否	ServiceAdditionProperties object	参数解释： 模型部署附加属性。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
access_port	否	String	参数解释： 端口号。系统自动生成。 约束限制： 边缘访问方式为ELB负载均衡时使用。 取值范围： 不涉及 默认取值： 不涉及
edge_acc_port_name	否	String	参数解释： 边缘服务绑定的端口名。系统自动生成。 约束限制： 边缘访问方式为ELB负载均衡时使用。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
elb_id	否	String	参数解释： 负载均衡ID，获取方式详见获取负载均衡ID信息。 约束限制： 边缘部署负载均衡访问使用。 取值范围： 不涉及 默认取值： 不涉及
volumes	否	Array of Volume objects	参数解释： 边缘场景挂载卷配置。 约束限制： 目前仅当部署工业智能中枢模型使用。 取值范围： 不涉及 默认取值： 不涉及
channel_count	否	Integer	参数解释： 路数。 约束限制： 对于CV场景边缘部署中的工业资产使用，支持部署路数设置。使用时instance_count实例数必须为1。 取值范围： 不涉及 默认取值： 不涉及
https_client_verify	否	Boolean	参数解释： 是否开启https客户端验证。 约束限制： 目前仅当部署工业智能中枢模型使用。 取值范围： 不涉及 默认取值： false

参数	是否必选	参数类型	描述
edge_access_mode	否	String	参数解释： 边缘访问模式。可选：ELB(负载均衡)，NODE(节点)，MONITOR-GATEWAY(监控网关)。 MONITOR-GATEWAY(监控网关)创建方式详见 创建监控插件 。 约束限制： 不涉及 取值范围： • ELB • NODE • MONITOR-GATEWAY 默认取值： ELB
edge_node_port	否	String	参数解释： 边缘服务端口，边缘NODE节点访问方式使用。 约束限制： 不涉及 取值范围： 30000-40000 默认取值： 不涉及
deploy_scene	否	DeployScene object	参数解释： 在线部署类型信息。 约束限制： 仅PD分离场景使用。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
asset_assembl y_id	否	String	参数解释： 后处理组件资产ID， 获取模型列表 接口获取的asset_id，查询条件asset_type=Assembly，sub_asset_type=PostProcessing Code，asset_source=import。 约束限制： 字符串需要满足UUID格式，如“550e8400-e29b-41d4-a716-446655440000”。 取值范围： 不涉及 默认取值： 不涉及
https_secrets	否	String	参数解释： ModelArts服务的密钥信息，边缘部署支持https请求调用时使用，获取方式详见 创建SSL证书信息(HTTPS负载均衡使用) 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cluster_id	是	String	参数解释： 资源池ID, online为在线资源池ID，edge为边缘资源池ID，获取方式详见 获取资源池ID信息 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-991 CustomSpec

参数	是否必选	参数类型	描述
cpu	是	Float	参数解释： CPU核数，支持配置小数。从 获取模型列表 接口中获取 (Resource信息中的cpu字段)。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
gpu	否	Float	参数解释： GPU个数，可选。 约束限制： 默认不使用，支持配置小数。 取值范围： 不涉及 默认取值： 不涉及
ascend	否	Integer	参数解释： Ascend芯片个数，可选，不支持与gpu同时配置。从 获取模型列表 接口中获取 (Resource信息中的card_count字段)。 约束限制： 默认不使用。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
memory	是	Integer	参数解释： 内存，单位为MB。从 获取模型列表 接口中获取(Resource信息中的memory字段)。 约束限制： 仅支持整数。 取值范围： 不涉及 默认取值： 不涉及

表 3-992 EnvInfo

参数	是否必选	参数类型	描述
key	否	String	参数解释： 环境变量Key。从 获取模型列表 接口中获取（Action信息中的action_env字段）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
value	否	String	参数解释： 环境变量值。从 获取模型列表 接口中获取（Action信息中的action_env字段）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
modifiable	否	Boolean	参数解释： 是否可更改。从 获取模型列表 接口中获取（ Action信息中的 action_env字段 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
displayable	否	Boolean	参数解释： 是否可显示。从 获取模型列表 接口中获取（ Action信息中的 action_env字段 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
label	否	String	参数解释： 显示名称。从 获取模型列表 接口中获取（ Action信息中的 action_env字段 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
des	否	String	参数解释： 描述。从 获取模型列表 接口中获取（ Action信息中的action_env 字段 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-993 ServiceAdditionProperties

参数	是否必选	参数类型	描述
max_surge	否	Float	参数解释： 必须大于0，不配置默认值为1。当小于1时，代表滚动升级时增加的实例数的百分比；当大于1时，代表滚动升级时最大扩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及
max_unavailable	否	Float	参数解释： 必须大于0，不配置默认值为0。当小于1时，代表滚动升级时允许缩容的实例数的百分比；当大于1时，代表滚动升级时允许缩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及

表 3-994 Volume

参数	是否必选	参数类型	描述
destination	是	String	参数解释： 边缘部署时卷挂载路径，必须是合法的路径。 约束限制： 目前仅当部署工业智能中枢模型时使用。 取值范围： 不涉及 默认取值： 不涉及
server	否	String	参数解释： nfs服务地址。 约束限制： source为nfs为必填。 取值范围： 不涉及 默认取值： 不涉及
key	否	String	参数解释： 卷的类型。 约束限制： 不涉及 取值范围： ● hostPath 默认取值： 不涉及
name	是	String	参数解释： 卷名称。 约束限制： 小写字母或数字，最长63个字符。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
read_only	否	Boolean	参数解释： 读写权限。 约束限制： configMap和secret类型只支持读权限。 取值范围： • true：只读 • false：非只读 默认取值： 不涉及
source	否	String	参数解释： 卷来源。 约束限制： type为hostPath时输入路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及 默认取值： 不涉及
type	是	String	参数解释： 卷的类型。 约束限制： 不涉及 取值范围： • hostPath 默认取值： 不涉及

表 3-995 DeployScene

参数	是否必选	参数类型	描述
infer_type	否	String	参数解释： 在线部署类型（ 获取模型列表 Action信息中action_properties的scenes字段）。 约束限制： 不涉及 取值范围： - 混合部署：default - PD分离部署： infer_vllmpd(模型框架为VLLM的部署类型)、 infer_mindiepd(模型框架为MindIE的部署类型) 默认取值： 不涉及
scene_name	否	String	参数解释： 场景名称，例如： pd分离部署场景的名称： Low_concurrency（低并发部署），High_concurrency（高并发部署）。 （ 获取模型列表 Action信息中action_properties的scenes字段） 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
works	否	Array of Work objects	参数解释： 工作pod的信息列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-996 Work

参数	是否必选	参数类型	描述
type	否	String	参数解释： work pod工作节点类型, 从获取模型列表接口中获取（ Action信息中action_properties的scenes字段列表里面的works字段 ）。 约束限制： 支持pd分离部署的资产会存在该字段。 取值范围： 不涉及 默认取值： 不涉及
count	否	Integer	参数解释： work pod工作节点的数量, 从获取模型列表接口中获取（ Action信息中action_properties的scenes字段列表里面的works字段 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码： 200

表 3-997 响应 Body 参数

参数	参数类型	描述
assets	Array of ModelAssetInfo objects	参数解释： 模型部署服务所关联的模型资产信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_id	String	参数解释： 模型部署服务的用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_name	String	参数解释： 模型部署服务的用户名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 模型部署服务的创建者的项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
workspace_id	String	参数解释： 模型部署服务所在的工作空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_id	String	参数解释： 模型部署服务的服务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_name	String	参数解释： 模型部署服务的服务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_desc	String	参数解释： 模型部署服务的描述信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	String	参数解释： 模型服务状态。init(初始化)， deploying(部署中)，running(运行中)， concerning(告警)，stopping(停止中)， stopped(已停止)，failed(部署失败)， deleting(删除中)，updating(更新中)。 约束限制： 不涉及 取值范围： • init • deploying • running • concerning • stopping • stopped • failed • deleting • updating 默认取值： 不涉及
arch	String	参数解释： 架构类型。 约束限制： 不涉及 取值范围： • X86 • ARM 默认取值： 不涉及

参数	参数类型	描述
category	String	参数解释： 资产来源。 约束限制： 不涉及 取值范围： • pangu(来自盘古大模型) • 3rd(来自用户自行导入的第三方大模型) • pangu-poc(来自poc版本的盘古大模型) • pangu-iit(来自工业智能中枢中的模型) • 3rd-pangu(来自盘古服务所提供的第三方大模型) 默认取值： 不涉及
infer_type	String	参数解释： 推理类型。online(在线)，edge(边缘)> 约束限制： 不涉及 取值范围： • online • edge 默认取值： 不涉及
ma_service_id	String	参数解释： 模型部署在modelarts服务的服务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
device_type	String	参数解释： 部署服务端的设备类型（NPU，GPU，NONE）信息。 约束限制： 不涉及 取值范围： • GPU • NPU • NONE 默认取值： 不涉及
chip_type	String	参数解释： 模型部署服务的芯片类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
request_mode	String	参数解释： 模型部署服务的请求方式。sync(同步)，async(异步)。 约束限制： 不涉及 取值范围： • sync • async 默认取值： 不涉及
model_config	ModelConfig object	参数解释： 模型服务的模型配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
service_config	ServiceConfig object	参数解释： 模型部署的服务配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_info	Object	参数解释： 模型部署在modelarts服务详情信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 模型服务的创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 模型服务的更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
elb_id	String	参数解释： 模型边缘部署的负载ID。 约束限制： 仅边缘部署涉及。 取值范围： 不涉及 默认取值： 不涉及
access_port_id	String	参数解释： 模型边缘部署服务的访问端口ID。 约束限制： 仅边缘部署涉及。 取值范围： 不涉及 默认取值： 不涉及
access_url	String	参数解释： 模型服务访问url，在线服务为URL，边缘服务为ELB访问路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_rollback	Boolean	参数解释： 模型部署服务是否触发回滚。 约束限制： 不涉及 取值范围： • true：触发回滚 • false：未触发回滚 默认取值： 不涉及

参数	参数类型	描述
consumes	Array of ResourceConsume objects	参数解释： 模型服务所消耗的资源信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_info	String	参数解释： 模型服务部署在modelarts服务详情信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
api_url	String	参数解释： 模型服务的外部API访问地址。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
security_bar_type	String	参数解释： 安全护栏类型。 约束限制： 不涉及 取值范围： • ENABLE 开启 • DISABLE 关闭 • NOT_SUPPORT 不支持 默认取值： 不涉及

参数	参数类型	描述
security_bar_editi on	String	参数解释： 安全护栏版本信息。 约束限制： 不涉及 取值范围： ● BASE 基础版 ● ADVANCED 高阶版 默认取值： 不涉及
is_preset	Integer	参数解释： 是否预置模型。 ● 0：非预置服务 ● 1：预置服务 约束限制： 不涉及 取值范围： ● 0 ● 1 默认取值： 不涉及
apis	String	参数解释： 模型服务的api信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
app_auths	Array of InferAppAuth objects	参数解释： 模型服务绑定的App应用信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
olc	Object	参数解释： 模型服务对应模型资产的流控信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_unsubscribe	Integer	参数解释： 模型服务是否退订服务。 约束限制： 不涉及 取值范围： • 0 退订 • 1 未退订 默认取值： 不涉及

表 3-998 ModelAssetInfo

参数	参数类型	描述
asset_id	String	参数解释： 资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_type	String	参数解释： 资产类型，分为：NLP(NLP大模型)，CV(CV大模型)，MM(多模态大模型)，Predict(预测大模型)，AI4Science(科学计算大模型)，Profession(专业大模型)。 约束限制： 不涉及 取值范围： • NLP • CV • MM • Predict • AI4Science • Profession 默认取值： 不涉及
asset_sub_type	String	参数解释： 资产子类型。资产类型的子类型，描述了资产的具体类型。例如多模态的子资产类型为文生图Txt2Img。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_master	Boolean	参数解释： 是否主资产。选择单资产部署时默认为主资产，多资产部署默认送的第一条资产信息为主资产，更新时如果不更新资产信息，需将主资产信息放到第一条。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-999 ModelConfig

参数	参数类型	描述
task_config	String	参数解释： 异步模型的作业配置参数xml格式的字符串。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
input_types	Array of strings	参数解释： 异步模型支持的输入数据类型。 约束限制： 异步场景下必选。 取值范围： OBS 默认取值： 不涉及
output_types	Array of strings	参数解释： 异步模型支持的输出数据类型列表。支持的类型包括OBS。 约束限制： 异步场景下必选。 取值范围： • OBS 默认取值： 不涉及

表 3-1000 ServiceConfig

参数	参数类型	描述
specification	String	参数解释： 资源规格信息。 约束限制： 为custom时，custom_spec生效。专属池默认传custom，目前只支持专属池。 取值范围： 不涉及 默认取值： 不涉及
custom_spec	CustomSpec object	参数解释： 自定义资源规格配置。 约束限制： 仅支持在部署到专属资源池时生效。specification为custom时生效。 取值范围： 不涉及 默认取值： 不涉及
user_env	Array of EnvInfo objects	参数解释： 用户自定义环境信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
instance_count	Integer	参数解释： 模型部署的实例数。 约束限制： 实例数取值必须大于0。在线场景必须选择。 取值范围： 1-128 默认取值： 不涉及

参数	参数类型	描述
additional_properties	ServiceAdditionalProperties object	参数解释： 模型部署附加属性。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
access_port	String	参数解释： 端口号。系统自动生成。 约束限制： 边缘访问方式为ELB负载均衡时使用。 取值范围： 不涉及 默认取值： 不涉及
edge_acc_port_name	String	参数解释： 边缘服务绑定的端口名。系统自动生成。 约束限制： 边缘访问方式为ELB负载均衡时使用。 取值范围： 不涉及 默认取值： 不涉及
elb_id	String	参数解释： 负载均衡ID，边缘部署负载均衡访问使用，获取方式详见 获取负载均衡ID信息 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
volumes	Array of Volume objects	参数解释： 边缘场景挂载卷配置。 约束限制： 目前仅工业资产使用。 取值范围： 不涉及 默认取值： 不涉及
channel_count	Integer	参数解释： 路数。 约束限制： 对于CV场景边缘部署中的工业资产使用，支持部署路数设置。使用时 instance_count实例数必须为1。 取值范围： 不涉及 默认取值： 不涉及
https_client_verify	Boolean	参数解释： 是否开启https客户端验证。 约束限制： 不涉及 取值范围： 目前仅工业资产使用。 默认取值： false
edge_access_mode	String	参数解释： 边缘访问模式，可选：ELB(负载均衡)，NODE(节点)， MONITOR-GATEWAY(监控网关)。 约束限制： 不涉及 取值范围： • ELB • NODE • MONITOR-GATEWAY 默认取值： ELB

参数	参数类型	描述
edge_node_port	String	参数解释： 边缘服务端口，边缘节点访问方式使用。 约束限制： 不涉及 取值范围： 30000-40000 默认取值： 不涉及
deploy_scene	DeployScene object	参数解释： 在线部署类型信息。 约束限制： 仅PD分离场景使用。 取值范围： 不涉及 默认取值： 不涉及
asset_assembly_id	String	参数解释： 后处理组件资产ID， 获取模型列表 接口 获取的asset_id，查询条件 asset_type=Assembly， sub_asset_type=PostProcessingCode， asset_source=import 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
https_secrets	String	参数解释： ModelArts服务密钥信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
cluster_id	String	参数解释： 资源池ID。online为在线资源池ID，edge为边缘资源池ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1001 CustomSpec

参数	参数类型	描述
cpu	Float	参数解释： CPU核数，支持配置小数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
gpu	Float	参数解释： GPU个数，可选，默认不使用，支持配置小数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
ascend	Integer	参数解释： Ascend芯片个数，可选，默认不使用。 约束限制： 不支持与gpu同时配置。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
memory	Integer	参数解释： 内存，单位为MB，仅支持整数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1002 EnvInfo

参数	参数类型	描述
key	String	参数解释： 环境变量Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
value	String	参数解释： 环境变量值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
modifiable	Boolean	参数解释： 是否可更改。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
displayable	Boolean	参数解释： 是否可显示。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
label	String	参数解释： 显示名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
des	String	参数解释： 描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1003 ServiceAdditionProperties

参数	参数类型	描述
max_surge	Float	参数解释： 必须大于0，不配置默认值为1。当小于1时，代表滚动升级时增加的实例数的百分比；当大于1时，代表滚动升级时最大扩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及
max_unavailable	Float	参数解释： 必须大于0，不配置默认值为0。当小于1时，代表滚动升级时允许缩容的实例数的百分比；当大于1时，代表滚动升级时允许缩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及

表 3-1004 Volume

参数	参数类型	描述
destination	String	参数解释： 卷挂载路径。 约束限制： 必须是合法的路径。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
server	String	参数解释： nfs服务地址。 约束限制： source为nfs为必填。 取值范围： 不涉及 默认取值： 不涉及
key	String	参数解释： 卷的类型，支持hostPath。 约束限制： 不涉及 取值范围： • hostPath 默认取值： 不涉及
name	String	参数解释： 卷名称。 约束限制： 小写字母或数字，最长63个字符。 取值范围： 不涉及 默认取值： 不涉及
read_only	Boolean	参数解释： 读写权限。 约束限制： configMap和secret类型只支持读权限。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
source	String	参数解释： 卷来源。 约束限制： type为hostPath时输入路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及 默认取值： 不涉及
type	String	参数解释： 卷的类型，hostPath。 约束限制： 不涉及 取值范围： hostPath 默认取值： 不涉及

表 3-1005 DeployScene

参数	参数类型	描述
infer_type	String	参数解释： 在线部署类型。 约束限制： 不涉及 取值范围： - 混合部署：default - PD分离部署：infer_vllmpd、infer_mindiepd 默认取值： 不涉及

参数	参数类型	描述
scene_name	String	参数解释： 场景名称，例如：pd分离部署场景的名称：Low_concurrency（低并发），High_concurrency（高并发）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
works	Array of Work objects	参数解释： 工作pod的信息列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1006 Work

参数	参数类型	描述
type	String	参数解释： work pod工作类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
count	Integer	参数解释： work pod的数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1007 ResourceConsume

参数	参数类型	描述
consumption	Double	参数解释： 总消耗量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_settal_quota	Double	参数解释： 是否已经触发资源消耗。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
unit	String	参数解释： 消耗单位。例如：实例消耗INSTANCE，算力消耗TFLOPS@FP16，卡消耗CARD。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1008 InferAppAuth

参数	参数类型	描述
infer_app_id	String	参数解释： 模型服务创建过程中导入的应用ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
infer_app_name	String	参数解释： 模型服务创建过程中导入的应用名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
domain_id	String	参数解释： 创建部署模型服务的用户账号id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_id	String	参数解释： 创建模型部署服务的用户id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
infer_app_code_hash	String	参数解释： 不可逆算法加密的appcode。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
salt	String	参数解释： 不可逆算法加密使用的盐值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1009 OlcProperties

参数	参数类型	描述
total_rpm	Integer	参数解释： 服务级分钟流控值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_rpm	Integer	参数解释： 用户级分钟流控值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
expand_ratio	Float	参数解释： 流控系数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-1010 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：401

表 3-1011 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：403

表 3-1012 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：404

表 3-1013 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：500

表 3-1014 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

在线部署，来自盘古大模型的某一资产。

```
{
  "service_name": "test",
  "category": "pangu",
  "asset_id": "5ac7679c-a516-4804-8578-1bd13b0f78f2",
  "arch": "ARM",
  "request_mode": "sync",
  "asset_tag": "ONLINE-DEPLOY",
  "chip_type": "D310P",
  "device_type": "NPU",
  "infer_type": "online",
  "asset_type": "CV",
  "model_config": {},
  "service_config": {
    "cluster_id": "pool-310p-c3140321fbc4401fa3aa571976cbebc",
    "specification": "custom",
    "custom_spec": {
      "cpu": 4,
      "memory": 8192,
      "ascend": 1
    }
  },
  "user_env": [
    {
      "key": "MOUNT_LOCATION",
      "value": "/home/HwHiAiUser/mount_location",
      "modifiable": false,
      "displayable": false
    }
  ],
  "instance_count": 1
},
"infer_version": "v1"
}
```

响应示例

状态码：200

成功响应示例

```
{
  "arch": "ARM",
  "service_id": "3962bb80",
  "service_name": "aaa",
  "user_id": 123,
  "user_name": "pangu",
  "workspace_id": 0,
  "status": "running",
  "infer_type": "online",
  "service_config": {
    "user_env": [ ],
    "instance_count": 1,
    "additional_properties": { },
    "cluster_id": "pool-111"
  },
  "request_mode": "sync",
  "category": "pangu",
  "model_name": "pangu",
  "deployed_model": "pangu-nlp"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.14.5 更新服务配置信息

功能介绍

更新服务配置信息，包含配置更新，资产更新，扩缩容等。

URI

PUT /v1/{project_id}/workspaces/{workspace_id}/model-service/services/
{service_id}

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

表 3-1015 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_id	是	String	参数解释： 模型服务ID，来源于 查询模型服务详情 的返回体中的service_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-1016 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-1017 请求 Body 参数

参数	是否必选	参数类型	描述
asset_id	否	String	参数解释： 部署模型服务的资产ID，单资产部署，跟资产IDs二选一，通过 获取模型列表 接口获取。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
asset_ids	否	Array of strings	参数解释： 根据资产的id集合进行过滤查询，格式如[id,id,id]。资产id即模型训练界面的模型id或模型部署详情界面内的模型id。 约束限制： 字符串只能由数字、英文字母或短横线组成。 取值范围： 不涉及 默认取值： 不涉及
service_name	否	String	参数解释： 服务名称。 约束限制： 支持1~64位可见字符（含中文），名称可以包含字母、中文、数字、中划线、下划线。 取值范围： 不涉及 默认取值： 不涉及
service_desc	否	String	参数解释： 服务描述。 约束限制： 支持0~128位可见字符（含中文），不包含^!<>=&"'等字符。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
model_config	是	ModelConfig object	参数解释： 模型配置信息。 约束限制： 仅科学计算模型使用， 其他模型传{}即可。 取值范围： 不涉及 默认取值： 不涉及
service_config	是	BaseServiceConfig object	参数解释： 服务配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_tag	否	String	参数解释： 资产标签，量化模型必填，从 获取模型列表 接口中获取（ Action 信息中的asset_tag字段 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
device_type	否	String	参数解释： 设备类型(NPU, GPU, NONE)，从 获取模型列表 接口中获取(Resource信息中的device_type字段)。NONE仅为CPU部署，不使用卡。 约束限制： 不涉及 取值范围： • GPU • NPU • NONE 默认取值： NONE
chip_type	否	String	参数解释： 芯片类型。device_type为NONE时，chip_type会进行忽略，从 获取模型列表 接口中获取(Resource信息中的chip_type字段)。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
request_mode	否	String	参数解释： 请求方式，从 获取模型列表 接口中获取(Image信息中的request_mode字段)。 约束限制： 科学计算需要填async2。 取值范围： sync, async 默认取值： sync

表 3-1018 ModelConfig

参数	是否必选	参数类型	描述
task_config	否	String	参数解释： 异步模型的作业配置参数。从获取模型列表接口中获取（ Image 信息中的task_config字段 ）。 约束限制： xml格式的字符串。 取值范围： 不涉及 默认取值： 不涉及
input_types	否	Array of strings	参数解释： 异步模型支持的输入数据类型。 异步场景下-必选，支持的类型包括OBS。 约束限制： 不涉及 取值范围： ● OBS 默认取值： 不涉及 枚举值：
output_types	否	Array of strings	参数解释： 异步模型支持的输出数据类型列表。异步场景下-必选，支持的类型包括OBS。 约束限制： 不涉及 取值范围： ● OBS 默认取值： 不涉及

表 3-1019 BaseServiceConfig

参数	是否必选	参数类型	描述
specification	否	String	参数解释： 资源规格信息。 约束限制： 为custom时，custom_spec生效。 专属池默认传custom，目前只支持专属池。 取值范围： 不涉及 默认取值： custom
custom_spec	否	CustomSpec object	参数解释： 自定义资源规格配置。 约束限制： 仅支持在部署到专属资源池时生效。specification为custom时生效。 取值范围： 不涉及 默认取值： 不涉及
user_env	是	Array of EnvInfo objects	参数解释： 用户自定义环境信息。从 获取模型列表 接口中获取（ Action信息中的action_env字段 ）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
instance_count	是	Integer	参数解释： 模型部署的实例数。实例数取值必须大于0。 约束限制： 在线部署场景必须设置。 取值范围： 1-128 默认取值： 不涉及
additional_properties	否	ServiceAdditionProperties object	参数解释： 模型更新的配置信息，模型更新支持全量升级和滚动升级两种形式，全量升级需要该服务所消耗资源的2倍，用于保障全量一次性升级；滚动升级通过空出部分实例资源用于滚动升级，扩/缩实例数越大，升级速度越快。默认全量升级，不需要传该参数，滚动升级时必选。 约束限制： 不涉及 取值范围： - 全量升级 - 滚动升级 默认取值： 全量升级
access_port	否	String	参数解释： 端口号。 约束限制： 边缘访问方式为ELB负载均衡时使用，系统自动生成。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
edge_acc_port_name	否	String	参数解释： 负载均衡ID，获取方式详见 获取负载均衡ID信息 。 约束限制： 边缘部署负载均衡访问使用。 取值范围： 不涉及 默认取值： 不涉及
elb_id	否	String	参数解释： 负载均衡ID，边缘部署负载均衡访问使用，获取方式详见 获取负载均衡ID信息 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
volumes	否	Array of Volume objects	参数解释： 边缘场景挂载卷配置。 约束限制： 目前仅工业资产使用。 取值范围： 不涉及 默认取值： 不涉及
channel_count	否	Integer	参数解释： 路数。 约束限制： 对于CV场景边缘部署中的工业资产使用，支持部署路数设置。使用时instance_count实例数必须为1。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
https_client_verify	否	Boolean	参数解释： 是否开启https客户端验证。 约束限制： 目前仅工业资产使用。 取值范围： 不涉及 默认取值： false
edge_access_mode	否	String	参数解释： 边缘访问模式，可选：ELB(负载均衡)，NODE(节点访问)，MONITOR-GATEWAY(监控网关)。 约束限制： 不涉及 取值范围： • ELB • NODE • MONITOR-GATEWAY 默认取值： 不涉及
edge_node_port	否	String	参数解释： 边缘服务端口，即edge_access_mode取值为NODE时，取值范围：30000-40000。 约束限制： 边缘部署访问模式选择节点访问时使用。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
deploy_scene	否	DeployScene object	参数解释： 在线部署类型信息。 约束限制： 仅PD分离场景使用。 取值范围： 不涉及 默认取值： 不涉及
asset_assembly_id	否	String	参数解释： 后处理组件资产ID， 获取模型列表 接口获取的asset_id，查询条件asset_type=Assembly，sub_asset_type=PostProcessing Code，asset_source=import 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
https_secrets	否	String	参数解释： ModelArts服务的密钥信息，获取方式详见 创建SSL证书信息(HTTPS负载均衡使用) 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1020 CustomSpec

参数	是否必选	参数类型	描述
cpu	是	Float	参数解释： CPU核数，支持配置小数。从 获取模型列表 接口中获取 (Resource信息中的cpu字段)。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
gpu	否	Float	参数解释： GPU个数，可选，默认不使用，支持配置小数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
ascend	否	Integer	参数解释： Ascend芯片个数，可选，默认不使用，从 获取模型列表 接口中获取 (Resource信息中的 card_count字段)。 约束限制： 不支持与gpu同时配置。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
memory	是	Integer	参数解释： 内存，单位为MB。从 获取模型列表 接口中获取(Resource信息中的memory字段)。 约束限制： 仅支持整数。 取值范围： 不涉及 默认取值： 不涉及

表 3-1021 EnvInfo

参数	是否必选	参数类型	描述
key	否	String	参数解释： 环境变量Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
value	否	String	参数解释： 环境变量值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
modifiable	否	Boolean	参数解释： 是否可更改。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
displayable	否	Boolean	参数解释： 是否可显示。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
label	否	String	参数解释： 显示名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
des	否	String	参数解释： 描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1022 ServiceAdditionProperties

参数	是否必选	参数类型	描述
max_surge	否	Float	参数解释： 必须大于0，不配置默认值为1。当小于1时，代表滚动升级时增加的实例数的百分比；当大于1时，代表滚动升级时最大扩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及
max_unavailable	否	Float	参数解释： 必须大于0，不配置默认值为0。当小于1时，代表滚动升级时允许缩容的实例数的百分比；当大于1时，代表滚动升级时允许缩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及

表 3-1023 Volume

参数	是否必选	参数类型	描述
destination	是	String	参数解释： 卷挂载路径。 约束限制： 必须是合法的路径。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
server	否	String	参数解释： nfs服务地址，source为nfs为必填。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
key	否	String	参数解释： 卷的类型，支持hostPath。 约束限制： 不涉及 取值范围： • hostPath 默认取值： 不涉及
name	是	String	参数解释： 卷名称。 约束限制： 小写字母或数字，最长63个字符。 取值范围： 不涉及 默认取值： 不涉及
read_only	否	Boolean	参数解释： 读写权限， 约束限制： configMap和secret类型只支持读权限。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
source	否	String	参数解释： 卷来源。 约束限制： type为hostPath时输入路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及 默认取值： 不涉及
type	是	String	参数解释： 卷的类型。 约束限制： 不涉及 取值范围： hostPath 默认取值： 不涉及

表 3-1024 DeployScene

参数	是否必选	参数类型	描述
infer_type	否	String	参数解释： 在线部署类型。 约束限制： 不涉及 取值范围： - 混合部署：default - PD分离部署： infer_vllmpd、 infer_mindiepd 默认取值： 不涉及

参数	是否必选	参数类型	描述
scene_name	否	String	参数解释： 场景名称，例如： pd分离部署场景的名称： Low_concurrency（低并发）， High_concurrency（高并发）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
works	否	Array of Work objects	参数解释： 工作pod的信息列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1025 Work

参数	是否必选	参数类型	描述
type	否	String	参数解释： work pod工作类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
count	否	Integer	参数解释： work pod的数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-1026 响应 Body 参数

参数	参数类型	描述
assets	Array of ModelAssetInfo objects	参数解释： 模型部署服务所关联的模型资产信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_id	String	参数解释： 模型部署服务的用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
user_name	String	参数解释： 模型部署服务的用户名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 模型部署服务的创建者的项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	String	参数解释： 模型部署服务所在的工作空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_id	String	参数解释： 模型部署服务的服务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
service_name	String	参数解释： 模型部署服务的服务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_desc	String	参数解释： 模型部署服务的描述信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
status	String	参数解释： 模型服务状态。init(初始化)， deploying(部署中)，running(运行中)， concerning(告警)，stopping(停止中)， stopped(已停止)，failed(部署失败)， deleting(删除中)，updating(更新中)。 约束限制： 不涉及 取值范围： • init • deploying • running • concerning • stopping • stopped • failed • deleting • updating 默认取值： 不涉及

参数	参数类型	描述
arch	String	参数解释： 架构类型。 约束限制： 不涉及 取值范围： • X86 • ARM 默认取值： 不涉及
category	String	参数解释： 资产来源。 约束限制： 不涉及 取值范围： • pangu(来自盘古大模型) • 3rd(来自用户自行导入的第三方大模型) • pangu-poc(来自poc版本的盘古大模型) • pangu-iit(来自工业智能中枢中的模型) • 3rd-pangu(来自盘古服务所提供的第三方大模型) 默认取值： 不涉及
infer_type	String	参数解释： 推理类型。online(在线)，edge(边缘) 约束限制： 不涉及 取值范围： • online • edge 默认取值： 不涉及

参数	参数类型	描述
ma_service_id	String	参数解释： 模型部署在modelarts服务的服务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
device_type	String	参数解释： 部署服务端的设备类型（NPU，GPU，NONE）信息。 约束限制： 不涉及 取值范围： - GPU - NPU - NONE 默认取值： 不涉及
chip_type	String	参数解释： 模型部署服务的芯片类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
request_mode	String	参数解释： 模型部署服务的请求方式。sync(同步)，async(异步)。 约束限制： 不涉及 取值范围： - sync - async 默认取值： 不涉及

参数	参数类型	描述
model_config	ModelConfig object	参数解释： 模型服务的模型配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_config	ServiceConfig object	参数解释： 模型部署的服务配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_info	Object	参数解释： 模型部署在modelarts服务详情信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 模型服务的创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
update_time	String	参数解释： 模型服务的更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
elb_id	String	参数解释： 模型边缘部署的负载ID。 约束限制： 仅边缘部署涉及。 取值范围： 不涉及 默认取值： 不涉及
access_port_id	String	参数解释： 模型边缘部署服务的访问端口ID。 约束限制： 仅边缘部署涉及。 取值范围： 不涉及 默认取值： 不涉及
access_url	String	参数解释： 模型服务访问url，在线服务为URL，边缘服务为ELB访问路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
is_rollback	Boolean	参数解释： 模型部署服务是否触发回滚。 约束限制： 不涉及 取值范围： • true：触发回滚 • false：未触发回滚 默认取值： 不涉及
consumes	Array of ResourceConsume objects	参数解释： 模型服务所消耗的资源信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_info	String	参数解释： 模型服务部署在modelarts服务详情信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
api_url	String	参数解释： 模型服务的外部API访问地址。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
security_bar_type	String	参数解释： 安全护栏类型。ENABLE(开启)，DISABLE(关闭)，NOT_SUPPORT(不支持)。 约束限制： 不涉及 取值范围： • ENABLE • DISABLE • NOT_SUPPORT 默认取值： 不涉及
security_bar_editon	String	参数解释： 安全护栏版本信息。BASE(基础版)，ADVANCED(高阶版)。 约束限制： 不涉及 取值范围： • BASE • ADVANCED 默认取值： 不涉及
is_preset	Integer	参数解释： 是否预置服务。0-非预置服务，1-预置服务。 约束限制： 不涉及 取值范围： • 0 • 1 默认取值： 不涉及

参数	参数类型	描述
apis	String	参数解释： 模型服务的api信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
app_auths	Array of InferAppAuth objects	参数解释： 模型服务绑定的App应用信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
olc	Object	参数解释： 模型服务对应模型资产的流控信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_unsubscribe	Integer	参数解释： 模型服务是否退订服务。 约束限制： 不涉及 取值范围： • 0 退订 • 1 未退订 默认取值： 不涉及

表 3-1027 ModelAssetInfo

参数	参数类型	描述
asset_id	String	参数解释： 部署模型服务的资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
asset_type	String	参数解释： 资产类型，分为：NLP(NLP大模型)，CV(CV大模型)，MM(多模态大模型)，Predict(预测大模型)，AI4Science(科学计算大模型)，Profession(专业大模型)。 约束限制： 不涉及 取值范围： • NLP • CV • MM • Predict • AI4Science • Profession 默认取值： 不涉及
asset_sub_type	String	参数解释： 资产子类型。资产类型的子类型，描述了资产的具体类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
is_master	Boolean	参数解释： 是否主资产。选择单资产部署时默认为主资产，多资产部署默认送的第一条资产信息为主资产，更新时如果不更新资产信息，需将主资产信息放到第一条。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉

表 3-1028 ModelConfig

参数	参数类型	描述
task_config	String	参数解释： 异步模型的作业配置参数。 约束限制： xml格式的字符串。 取值范围： 不涉及 默认取值： 不涉及
input_types	Array of strings	参数解释： 异步模型支持的输入数据类型。 约束限制： 异步场景下-必选。 取值范围： • OBS 默认取值： 不涉及

参数	参数类型	描述
output_types	Array of strings	参数解释： 异步模型支持的输出数据类型列表。异步场景下-必选.支持的类型包括OBS。 约束限制： 不涉及 取值范围： • OBS 默认取值： 不涉及

表 3-1029 ServiceConfig

参数	参数类型	描述
specification	String	参数解释： 资源规格信息，为custom时，custom_spec生效。专属池默认传custom，目前只支持专属池。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
custom_spec	CustomSpec object	参数解释： 自定义资源规格配置。 约束限制： 仅支持在部署到专属资源池时生效。specification为custom时生效。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
user_env	Array of EnvInfo objects	参数解释： 用户自定义环境信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
instance_count	Integer	参数解释： 模型部署的实例数。实例数取值必须大于0。在线场景必须选择。 约束限制： 不涉及 取值范围： 1-128 默认取值： 不涉及
additional_properties	ServiceAdditionalProperties object	参数解释： 模型部署附加属性。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
access_port	String	参数解释： 端口号。 约束限制： 边缘访问方式为ELB负载均衡时使用，系统自动生成。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
edge_acc_port_name	String	参数解释： 边缘服务绑定的端口名。 约束限制： 边缘访问方式为ELB负载均衡时使用，系统自动生成。 取值范围： 不涉及 默认取值： 不涉及
elb_id	String	参数解释： 负载均衡ID，边缘部署负载均衡访问使用，获取方式详见 获取负载均衡ID信息 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
volumes	Array of Volume objects	参数解释： 边缘场景挂载卷配置。 约束限制： 目前仅工业资产使用。 取值范围： 不涉及 默认取值： 不涉及
channel_count	Integer	参数解释： 路数。 约束限制： 对于CV场景边缘部署中的工业资产使用，支持部署路数设置。使用时instance_count实例数必须为1。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
https_client_verify	Boolean	参数解释： 是否开启https客户端验证。 约束限制： 目前仅工业资产使用。 取值范围： 不涉及 默认取值： false
edge_access_mode	String	参数解释： 边缘访问模式，可选：ELB(负载均衡)， NODE(节点)， MONITOR- GATEWAY(监控网关)。 约束限制： 不涉及 取值范围： • ELB • NODE • MONITOR-GATEWAY 默认取值： ELB
edge_node_port	String	参数解释： 边缘服务端口。 约束限制： 边缘节点访问方式使用。 取值范围： 30000-40000 默认取值： 不涉及
deploy_scene	DeployScene object	参数解释： 在线部署类型信息。 约束限制： 仅PD分离场景使用。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_assembly_id	String	参数解释： 后处理组件资产ID， 获取模型列表 接口获取的asset_id，查询条件 asset_type=Assembly， sub_asset_type=PostProcessingCode， asset_source=import 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
https_secrets	String	参数解释： ModelArts服务的密钥信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cluster_id	String	参数解释： 资源池ID。online为在线资源池ID， edge为边缘资源池ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1030 CustomSpec

参数	参数类型	描述
cpu	Float	参数解释： CPU核数，支持配置小数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
gpu	Float	参数解释： GPU个数，可选，默认不使用。 约束限制： 支持配置小数。 取值范围： 不涉及 默认取值： 不涉及
ascend	Integer	参数解释： Ascend芯片个数，可选，默认不使用。 约束限制： 不支持与gpu同时配置。 取值范围： 不涉及 默认取值： 不涉及
memory	Integer	参数解释： 内存，单位为MB。 约束限制： 仅支持整数。 取值范围： 不涉及 默认取值： 不涉及

表 3-1031 EnvInfo

参数	参数类型	描述
key	String	参数解释： 环境变量Key。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
value	String	参数解释： 环境变量值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
modifiable	Boolean	参数解释： 是否可更改。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
displayable	Boolean	参数解释： 是否可显示。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
label	String	参数解释： 显示名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
des	String	参数解释： 描述。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1032 ServiceAdditionProperties

参数	参数类型	描述
max_surge	Float	参数解释： 必须大于0，不配置默认值为1。当小于1时，代表滚动升级时增加的实例数的百分比；当大于1时，代表滚动升级时最大扩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及

参数	参数类型	描述
max_unavailable	Float	参数解释： 必须大于0，不配置默认值为0。当小于1时，代表滚动升级时允许缩容的实例数的百分比；当大于1时，代表滚动升级时允许缩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及

表 3-1033 Volume

参数	参数类型	描述
destination	String	参数解释： 卷挂载路径。 约束限制： 必须是合法的路径。 取值范围： 不涉及 默认取值： 不涉及
server	String	参数解释： nfs服务地址，source为nfs为必填。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
key	String	参数解释： 卷的类型。 约束限制： 不涉及 取值范围： hostPath 默认取值： 不涉及
name	String	参数解释： 卷名称。 约束限制： 小写字母或数字，最长63个字符。 取值范围： 不涉及 默认取值： 不涉及
read_only	Boolean	参数解释： 读写权限。 约束限制： configMap和secret类型只支持读权限。 取值范围： 不涉及 默认取值： 不涉及
source	String	参数解释： 卷来源。 约束限制： type为hostPath时输入路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
type	String	参数解释： 卷的类型。 约束限制： 不涉及 取值范围： hostPath 默认取值： 不涉及

表 3-1034 DeployScene

参数	参数类型	描述
infer_type	String	参数解释： 在线部署类型。 约束限制： 不涉及 取值范围： - 混合部署：default - PD分离部署：infer_vllmpd、infer_mindiepd 默认取值： 不涉及
scene_name	String	参数解释： 场景名称，例如： pd分离部署场景的名称： Low_concurrency（低并发）， High_concurrency（高并发）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
works	Array of Work objects	参数解释： 工作pod的信息列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1035 Work

参数	参数类型	描述
type	String	参数解释： work pod工作类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
count	Integer	参数解释： work pod的数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1036 ResourceConsume

参数	参数类型	描述
consumption	Double	参数解释： 总消耗量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_settal_quota	Double	参数解释： 是否已经触发资源消耗。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
unit	String	参数解释： 消耗单位。例如：实例消耗INSTANCE，算力消耗TFLOPS@FP16，卡消耗CARD。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1037 InferAppAuth

参数	参数类型	描述
infer_app_id	String	参数解释： 模型服务创建过程中导入的应用ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
infer_app_name	String	参数解释： 模型服务创建过程中导入的应用名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
domain_id	String	参数解释： 创建部署模型服务的用户账号id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_id	String	参数解释： 创建模型部署服务的用户id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
infer_app_code_hash	String	参数解释： 不可逆算法加密的 appcode。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
salt	String	参数解释： 不可逆算法加密使用的盐值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1038 OlcProperties

参数	参数类型	描述
total_rpm	Integer	参数解释： 服务级分钟流控值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_rpm	Integer	参数解释： 用户级分钟流控值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
expand_ratio	Float	参数解释： 流控系数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-1039 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：404

表 3-1040 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：500

表 3-1041 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

更新服务配置信息。

```
{
  "asset_id": "6123f0f4-8b13-4399-9a96-547f1c984ff0",
  "model_config": {},
  "service_config": {
    "specification": "custom",
    "custom_spec": {
      "cpu": 4,
      "memory": 8192,
      "ascend": 1
    },
  },
  "user_env": [
    {
      "key": "MOUNT_LOCATION",
      "value": "/home/HwHiAiUser/mount_location",
      "modifiable": false,
      "displayable": false,
      "env_type": "default"
    }
  ],
  "additional_properties": {},
  "instance_count": 1,
  "log_configs": [],
  "cluster_id": "pool-9da2-c3140321fbc4401fa3aa571976cbebc"
}
```

响应示例

状态码：200

成功响应示例

```
{
  "assets": [ {
    "asset_id": "1696b75a-37bd-4194-81e3-945b276f37b9",
    "asset_type": "CV",
    "sub_asset_type": "ObjectDetection",
    "asset_tag": "ONLINE-DEPLOY",
    "is_master": true
  } ],
  "arch": "ARM",
  "service_id": "76beab07-7d6c-42d3-91b0-dc6a235853be",
  "service_name": "物体检测",
  "user_id": 123,
  "user_name": "pangu",
  "status": "running",
  "workspace_id": 0,
  "project_id": "76beab07",
  "service_desc": "desc",
  "asset_tag": "ONLINE-DEPLOY",
  "infer_type": "online",
  "model_config": { },
  "service_config": {
    "user_env": [ ],
    "instance_count": 1,
    "additional_properties": { },
    "cluster_id": "pool-111"
  },
  "create_time": "2025-04-02 11:30:32",
  "update_time": "2025-04-02 15:07:27",
  "cluster_id": "pool-111"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.14.6 删除模型部署的服务

功能介绍

删除模型部署的服务。

说明

初始化状态的模型部署服务不可删除。

URI

DELETE /v1/{project_id}/workspaces/{workspace_id}/model-service/services/{service_id}

接口域名请参考[获取盘古服务外部APIG域名](#)获取。

表 3-1042 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
service_id	是	String	参数解释： 模型服务ID，来源于 查询模型服务详情 的返回体中的service_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-1043 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：400

表 3-1044 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：404

表 3-1045 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：500

表 3-1046 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

无

响应示例

无

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.14.7 启停服务

功能介绍

停止或启动模型部署服务。

URI

POST /v1/{project_id}/workspaces/{workspace_id}/model-service/services/{service_id}/start-or-stop

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-1047 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
service_id	是	String	参数解释： 模型服务ID，来源于 查询模型服务详情 的返回体中的service_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-1048 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-1049 请求 Body 参数

参数	是否必选	参数类型	描述
status	是	String	参数解释： 服务状态，可设置状态为“running”或“stopped”来启动、停止服务。 约束限制： 不涉及 取值范围： • running 运行中 • stopped 停止 默认取值： 不涉及

响应参数

状态码：200

表 3-1050 响应 Body 参数

参数	参数类型	描述
assets	Array of ModelAssetInfo objects	参数解释： 模型部署服务所关联的模型资产信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_id	String	参数解释： 模型部署服务的用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
user_name	String	参数解释： 模型部署服务的用户名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 模型部署服务的创建者的项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	String	参数解释： 模型部署服务所在的工作空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_id	String	参数解释： 模型部署服务的服务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
service_name	String	参数解释： 模型部署服务的服务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_desc	String	参数解释： 模型部署服务的描述信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
status	String	参数解释： 模型服务状态。 约束限制： 不涉及 取值范围： • init 初始化 • deploying 部署中 • running 运行中 • concerning 告警 • stopping 停止中 • stopped 已停止 • failed 失败 • deleting 删除中 • updating 更新中 默认取值： 不涉及

参数	参数类型	描述
arch	String	参数解释： 架构类型。 约束限制： 不涉及 取值范围： • X86 • ARM 默认取值： 不涉及
category	String	参数解释： 资产来源。 约束限制： 不涉及 取值范围： • pangu(来自盘古大模型) • 3rd(来自用户自行导入的第三方大模型) • pangu-poc(来自poc版本的盘古大模型) • pangu-iit(来自工业智能中枢中的模型) • 3rd-pangu(来自盘古服务所提供的第三方大模型) 默认取值： 不涉及
infer_type	String	参数解释： 资产类型。 约束限制： 不涉及 取值范围： • online 在线部署 • edge 边缘部署 默认取值： 不涉及

参数	参数类型	描述
ma_service_id	String	参数解释： 模型部署在modelarts服务的服务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
device_type	String	参数解释： 部署服务端的设备类型（NPU，GPU，NONE）信息。 约束限制： 不涉及 取值范围： • GPU • NPU • NONE 默认取值： 不涉及
chip_type	String	参数解释： 芯片类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
request_mode	String	参数解释： 模型部署服务的推理类型。 约束限制： 不涉及 取值范围： • sync 表示模型为同步部署 • async 表示模型为异步部署 默认取值： 不涉及

参数	参数类型	描述
model_config	ModelConfig object	参数解释： 模型服务的模型配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_config	ServiceConfig object	参数解释： 模型部署的服务配置信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_info	Object	参数解释： 模型部署服务详情信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 模型服务的创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
update_time	String	参数解释： 模型服务的更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
elb_id	String	参数解释： 模型边缘部署的负载均衡ID。 约束限制： 仅边缘部署涉及。 取值范围： 不涉及 默认取值： 不涉及
access_port_id	String	参数解释： 模型边缘部署服务的访问端口ID。 约束限制： 仅边缘部署涉及。 取值范围： 不涉及 默认取值： 不涉及
access_url	String	参数解释： 模型服务访问url，在线服务为URL，边缘服务为ELB访问路径。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
is_rollback	Boolean	参数解释： 模型部署服务是否触发回滚。 约束限制： 不涉及 取值范围： • true：触发回滚 • false：未触发回滚 默认取值： 不涉及
consumes	Array of ResourceConsum e objects	参数解释： 模型服务所消耗的资源信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_info	String	参数解释： 模型服务部署在modelarts服务详情信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
api_url	String	参数解释： 模型服务的外部API访问地址。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
security_bar_type	String	参数解释： 安全护栏类型。 约束限制： 不涉及 取值范围： • ENABLE 开启 • DISABLE 关闭 • NOT_SUPPORT 不支持 默认取值： 不涉及
security_bar_editi on	String	参数解释： 安全护栏版本信息。 约束限制： 不涉及 取值范围： • BASE 基础版 • ADVANCED 高阶版 默认取值： 不涉及
is_preset	Integer	参数解释： 是否预置模型。 约束限制： 不涉及 取值范围： • 0 非预置服务 • 1 预置服务 默认取值： 不涉及
apis	String	参数解释： 模型服务的api信息。包含服务部署APIURL和服务部署API方法信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
app_auths	Array of InferAppAuth objects	参数解释： 模型服务绑定的App应用信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
olc	Object	参数解释： 模型服务对应模型资产的流控信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_unsubscribe	Integer	参数解释： 模型服务是否退订服务。 约束限制： 不涉及 取值范围： • 0 退订 • 1 未退订 默认取值： 不涉及

表 3-1051 ModelAssetInfo

参数	参数类型	描述
asset_id	String	参数解释： 部署模型服务的资产ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_type	String	参数解释： 资产类型，分为：NLP(NLP大模型)，CV(CV大模型)，MM(多模态大模型)，Predict(预测大模型)，AI4Science(科学计算大模型)，Profession(专业大模型)。 约束限制： 不涉及 取值范围： • NLP NLP大模型 • CV CV大模型 • MM 多模态大模型 • Predict 预测大模型 • AI4Science 科学计算 • Profession 专业大模型 默认取值： 不涉及

参数	参数类型	描述
sub_asset_type	String	参数解释： 资产子类型。资产类型的子类型，描述了资产的具体类型。 约束限制： 不涉及 取值范围： • NLP模型：暂无子类型 • CV模型：SS(语义分割)、IC(图像分类)、ED(事件检测)、OVD(万物检测)、PE(姿态估计)、AD(异常检测)、ObjectDetection(物体检测)、OpticalCharacterRecogniton(文字识别)、OpenVocabularySegmentation(万物分割)、RD(旋转检测) • 科学计算模型： Ocean_Regional_24h(海洋区域24H)、 Weather_24h(天气24H)、 Weather_3h(天气3H)、 Weather_6h(天气6H)、 Precip_6h(降雨6H)、 Ocean_Ecology_24h(海洋生态24H)、Ocean_24h(海洋24H)、 Weather_1h(天气1H) • 多模态模型：Img2Txt(文生图) • 预测模型：AnomalyDetection(异常检测)、Classification(分类)、TimeSeries(时序)、Regression(回归)、StructurePredict(结构化预测)、IntegratingModelDataDriven(驾驶数据集成) • Profession：NLP(NLP大模型) • 组件：package(包)、script(脚本)、PostProcessingCode(处理代码) 默认取值： 不涉及

参数	参数类型	描述
is_master	Boolean	参数解释： 是否主资产。选择单资产部署时默认为主资产，多资产部署默认送的第一条资产信息为主资产，更新时如果不更新资产信息，需将主资产信息放到第一条。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1052 ModelConfig

参数	参数类型	描述
task_config	String	参数解释： 异步模型的作业配置参数。 约束限制： xml格式的字符串。 取值范围： 不涉及 默认取值： 不涉及
input_types	Array of strings	参数解释： 异步模型支持的输入数据类型。异步场景下-必选.支持的类型包括OBS。 约束限制： 不涉及 取值范围： • OBS 默认取值： 不涉及

参数	参数类型	描述
output_types	Array of strings	参数解释： 异步模型支持的输出数据类型列表。 约束限制： 异步场景下-必选。 取值范围： • OBS 默认取值： 不涉及 枚举值：

表 3-1053 ServiceConfig

参数	参数类型	描述
specification	String	参数解释： 资源规格信息。 约束限制： 为custom时，custom_spec生效。专属池默认传custom，目前只支持专属池。 取值范围： 不涉及 默认取值： 不涉及
custom_spec	CustomSpec object	参数解释： 自定义资源规格配置。 约束限制： 仅支持在部署到专属资源池时生效。specification为custom时生效。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
user_env	Array of EnvInfo objects	参数解释： 用户自定义环境信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
instance_count	Integer	参数解释： 模型部署的实例数。 约束限制： 实例数取值必须大于0。在线场景必须选择。 取值范围： 1-128 默认取值： 不涉及
additional_properties	ServiceAdditionalProperties object	参数解释： 模型部署附加属性。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
access_port	String	参数解释： 端口号。 约束限制： 边缘访问方式为ELB负载均衡时使用，系统自动生成。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
edge_acc_port_name	String	参数解释： 边缘服务绑定的端口名。 约束限制： 边缘访问方式为ELB负载均衡时使用，系统自动生成。 取值范围： 不涉及 默认取值： 不涉及
elb_id	String	参数解释： 负载均衡ID。 约束限制： 边缘部署负载均衡访问使用。 取值范围： 不涉及 默认取值： 不涉及
volumes	Array of Volume objects	参数解释： 边缘场景挂载卷配置。 约束限制： 目前仅工业资产使用。 取值范围： 不涉及 默认取值： 不涉及
channel_count	Integer	参数解释： 路数。 约束限制： 对于CV场景边缘部署中的工业资产使用，支持部署路数设置。使用时instance_count实例数必须为1。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
https_client_verify	Boolean	参数解释： 是否开启https客户端验证。 约束限制： 目前仅工业资产使用。 取值范围： 不涉及 默认取值： false
edge_access_mode	String	参数解释： 边缘访问模式，可选：ELB，NODE，MONITOR-GATEWAY。 约束限制： 不涉及 取值范围： • ELB 负载均衡 • NODE 节点 • MONITOR-GATEWAY 监控网关 默认取值： ELB
edge_node_port	String	参数解释： 边缘服务端口，边缘节点访问方式使用。 约束限制： 不涉及 取值范围： 30000-40000 默认取值： 不涉及
deploy_scene	DeployScene object	参数解释： 在线部署类型信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
asset_assembly_id	String	参数解释： 后处理代码的资产ID，目前仅用于工业视觉大模型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
https_secrets	String	参数解释： ModelArts服务密钥信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
cluster_id	String	参数解释： 资源池ID，online为在线资源池ID，edge为边缘资源池ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1054 CustomSpec

参数	参数类型	描述
cpu	Float	参数解释： CPU核数，支持配置小数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
gpu	Float	参数解释： GPU个数，可选，默认不使用，支持配置小数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
ascend	Integer	参数解释： Ascend芯片个数，可选，默认不使用，不支持与gpu同时配置。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
memory	Integer	参数解释： 内存，单位为MB，仅支持整数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1055 EnvInfo

参数	参数类型	描述
key	String	参数解释： 模型服务环境变量Key。例如： batch_size 数据批处理 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
value	String	参数解释： 模型服务环境变量值。例如：32 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
modifiable	Boolean	参数解释： 环境变量是否可更改。例如：true 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
displayable	Boolean	参数解释： 环境变量是否可显示。例如：true 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
label	String	参数解释： 环境变量显示名称。例如：数据批处理 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
des	String	参数解释： 环境变量描述信息。例如：数据批处理信息 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1056 ServiceAdditionProperties

参数	参数类型	描述
max_surge	Float	参数解释： 必须大于0，不配置默认值为1。当小于1时，代表滚动升级时增加的实例数的百分比；当大于1时，代表滚动升级时最大扩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及

参数	参数类型	描述
max_unavailable	Float	参数解释： 必须大于0，不配置默认值为0。当小于1时，代表滚动升级时允许缩容的实例数的百分比；当大于1时，代表滚动升级时允许缩容的实例数。 约束限制： 不涉及 取值范围： ≥0 默认取值： 不涉及

表 3-1057 Volume

参数	参数类型	描述
destination	String	参数解释： 卷挂载路径。 约束限制： 必须是合法的路径。 取值范围： 不涉及 默认取值： 不涉及
server	String	参数解释： nfs服务地址，source为nfs为必填。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
key	String	参数解释： 卷的类型。 约束限制： 不涉及 取值范围： • hostPath 默认取值： 不涉及
name	String	参数解释： 卷名称。 约束限制： 小写字母或数字，最长63个字符。 取值范围： 不涉及 默认取值： 不涉及
read_only	Boolean	参数解释： 读写权限。 约束限制： configMap和secret类型只支持读权限。 取值范围： 不涉及 默认取值： 不涉及
source	String	参数解释： 卷来源。 约束限制： type为hostPath时输入路径，要求以/开头，后面可包含中划线，反斜杠，下划线，点号，字母，数字。 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
type	String	参数解释： 卷的类型。 约束限制： 不涉及 取值范围： • hostPath 默认取值： 不涉及

表 3-1058 DeployScene

参数	参数类型	描述
infer_type	String	参数解释： 模型的在线部署类型。 约束限制： 不涉及 取值范围： • 混合部署：default • PD分离部署：infer_vllmpd、infer_mindiepd 默认取值： 不涉及
scene_name	String	参数解释： 场景名称，例如： pd分离部署场景的名称： Low_concurrency（低并发）， High_concurrency（高并发）。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
works	Array of Work objects	参数解释： 工作pod的信息列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1059 Work

参数	参数类型	描述
type	String	参数解释： pd分离部署时pod的类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
count	Integer	参数解释： pd分离部署时pod的数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1060 ResourceConsume

参数	参数类型	描述
consumption	Double	参数解释： 资源总消耗量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
is_settal_quota	Double	参数解释： 是否已经触发资源消耗。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
unit	String	参数解释： 消耗单位。例如：实例消耗INSTANCE，算力消耗TFLOPS@FP16，卡消耗CARD。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1061 InferAppAuth

参数	参数类型	描述
infer_app_id	String	参数解释： 模型服务创建过程中导入的应用ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
infer_app_name	String	参数解释： 模型服务创建过程中导入的应用名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
domain_id	String	参数解释： 创建部署模型服务的用户账号id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及c
user_id	String	参数解释： 创建模型部署服务的用户id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
infer_app_code_hash	String	参数解释： 不可逆算法加密的appcode。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
salt	String	参数解释： 不可逆算法加密使用的盐值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1062 OlcProperties

参数	参数类型	描述
total_rpm	Integer	参数解释： 模型服务级分钟流控值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_rpm	Integer	参数解释： 模型服务用户级分钟流控值。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
expand_ratio	Float	参数解释： 模型服务流控系数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码：400

表 3-1063 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：404

表 3-1064 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

状态码：500

表 3-1065 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

启动服务


```
{  
  "status": "running"  
}
```

响应示例

状态码：200

成功响应示例

```
{  
  "assets": [ {  
    "asset_id": "1696b75a-37bd-4194-81e3-945b276f37b9",  
    "asset_type": "CV",  
    "sub_asset_type": "ObjectDetection",  
    "asset_tag": "ONLINE-DEPLOY",  
    "is_master": true  
  } ],  
  "arch": "ARM",  
  "service_id": "76beab07-7d6c-42d3-91b0-dc6a235853be",  
  "service_name": "物体检测",  
  "user_id": 123,  
  "user_name": "pangu",  
  "status": "stopping",  
  "workspace_id": 0,  
  "project_id": "76beab07",  
  "service_desc": "desc",  
  "asset_tag": "ONLINE-DEPLOY",  
  "infer_type": "online",  
  "model_config": { },  
  "service_config": {  
    "user_env": [ ],  
    "instance_count": 1,  
    "additional_properties": { },  
    "cluster_id": "pool-111"  
  },  
  "create_time": "2025-04-02 11:30:32",  
  "update_time": "2025-04-02 15:07:27",  
  "cluster_id": "pool-111"  
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.14.8 获取模型服务运行日志

功能介绍

获取模型服务运行日志信息。

URI

POST /v1/{project_id}/workspaces/{workspace_id}/model-service/services/
{service_id}/runlog

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-1066 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_id	是	String	参数解释： 模型服务ID，来源于 查询模型服务详情 的返回体中的service_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-1067 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-1068 请求 Body 参数

参数	是否必选	参数类型	描述
start_time	是	Long	参数解释： 日志查询的开始时间。 约束限制： 时间戳（毫秒级） 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
end_time	是	Long	参数解释： 日志查询的结束时间。 约束限制： 时间戳（毫秒级）。 取值范围： 不涉及 默认取值： 不涉及
type	是	String	参数解释： 查询日志的类型方式。约束限制：为init（初始化查询），next（向后查询），pre（向前查询）其中一个。 约束限制： type和line_num参数配合使用。第一次查询时，type为init，line_num可以不填；在进行分页查询时，如果是向下分页，则type为next，line_num为上次查询的最后一行日志的行数；如果是向上分页，则type为pre，line为上次查询的第一行日志的行数。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
keyword	否	String	参数解释： 1.支持关键词精确搜索。关键词指相邻两个分词符之间的单词。 2.支持关键词模糊匹配搜索，例如输入“RROR”或“ERRO?”或“ROR”或“ERR*”或“ER*OR”。 3.支持短语精确搜索，例如输入“Start to refresh alm Statistic”。 4.支持关键词的“与”、“或”组合搜索。格式为“query&&logs”或“query logs”。 说明 当前默认分词符有, "" ;=() [] {} @&<> /: \n\t\r 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
line_num	否	Long	参数解释： 部署服务的日志单行序列号，第一次查询时不需要此参数，后续分页查询时需要使用可从上次查询的返回信息中获取。 约束限制： type和line_num参数配合使用。第一次查询时，type为init，line_num可以不填；在进行分页查询时，如果是向下分页，则type为next，line_num为上次查询的最后一行日志的行数；如果是向上分页，则type为pre，line为上次查询的第一行日志的行数。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
size	否	Integer	参数解释： 查询部署服务的日志大小。单位：行。约束限制：1到500之间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码：200

表 3-1069 响应 Body 参数

参数	参数类型	描述
model_nodes_id	Array of ModelNodeInfo objects	参数解释： 模型所在节点信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
logs	String	参数解释： 所查询的模型服务的日志信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
start_line_num	String	参数解释： 服务日志的起始行。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
end_line_num	String	参数解释： 服务日志的结束行。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1070 ModelNodeInfo

参数	参数类型	描述
model_nodes_id	String	参数解释： 模型服务所部署节点的节点ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_nodes_aliases	String	参数解释： 模型服务所部署节点的节点名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

获取模型服务运行日志信息

```
{
  "start_time": 1742461444980,
  "end_time": 1742461744980,
  "type": "init",
  "size": 100
}
```

响应示例

状态码：200

成功响应示例

```
{
  "logs" : "INFO 03-25 11:00:14 metrics.py:351] Avg prompt throughput: 0.0 tokens/s, Avg generation throughput: 0.0 tokens/s, reqs, GPU KV cache usage: 0.0%, CPU KV cache usage: 0.0%.\nINFO 03-25 11:00:34 metrics.py:351] Avg prompt throughput: 0.0 tokens/s",
  "model_nodes_id" : [ {
    "model_nodes_id" : "b634591d-ccae-4f4f-aa86-e973aa1e223b-ywa48h8a-5595946c89-tvczb",
    "model_nodes_alias" : "lms-mod-e015bae2-1e0f-445a-bfd8-84842790e60f-1742823274440_0.0.1_1"
  } ],
  "start_line_num" : 1742871614606345200,
  "end_line_num" : 1742871904705815000
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.14.9 获取模型服务指定节点的运行日志详情

功能介绍

获取模型服务所在节点的运行日志信息详情。

URI

POST /v1/{project_id}/workspaces/{workspace_id}/model-service/services/{service_id}/nodes/{model_node_id}/runlogs

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-1071 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
service_id	是	String	参数解释： 模型服务ID，参数来源于接口 获取服务列表 的返回体中的service_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_node_id	是	String	参数解释： 模型服务所在节点id。来源于 获取模型服务运行日志 返回体的model_nodes_id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-1072 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-1073 请求 Body 参数

参数	是否必选	参数类型	描述
start_time	是	Long	参数解释： 日志查询的开始时间。 约束限制： 时间戳（毫秒级） 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
end_time	是	Long	参数解释： 日志查询的结束时间。 约束限制： 时间戳（毫秒级） 取值范围： 不涉及 默认取值： 不涉及
type	是	String	参数解释： 查询日志的类型方式。约束限制：为init（初始化查询），next（向后查询），pre（向前查询）其中一个。 约束限制： type和line_num参数配合使用。第一次查询时，type为init，line_num可以不填；在进行分页查询时，如果是向下分页，则type为next，line_num为上次查询的最后一行日志的行数；如果是向上分页，则type为pre，line为上次查询的第一行日志的行数。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
keyword	否	String	参数解释： 1.支持关键词精确搜索。关键词指相邻两个分词符之间的单词。 2.支持关键词模糊匹配搜索，例如输入“RROR”或“ERRO?”或“ROR”或“ERR*”或“ER*OR”。 3.支持短语精确搜索，例如输入“Start to refresh alm Statistic”。 4.支持关键词的“与”、“或”组合搜索。格式为“query&&logs”或“query logs”。 说明 当前默认分词符有, "" ;=() [] {}@&<>/: \n\t\r 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
line_num	否	Long	参数解释： 部署服务的日志单行序列号，第一次查询时不需要此参数，后续分页查询时需要使用可从上次查询的返回信息中获取。 约束限制： type和line_num参数配合使用。第一次查询时，type为init，line_num可以不填；在进行分页查询时，如果是向下分页，则type为next，line_num为上次查询的最后一行日志的行数；如果是向上分页，则type为pre，line为上次查询的第一行日志的行数。 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
size	否	Integer	参数解释： 查询部署服务的日志大小。单位：行。 约束限制： 不涉及 取值范围： 1到500之间。 默认取值： 不涉及

响应参数

状态码：200

表 3-1074 响应 Body 参数

参数	参数类型	描述
model_nodes_id	Array of ModelNodeInfo objects	参数解释： 模型所在节点信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
logs	String	参数解释： 所查询的模型服务的日志信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
start_line_num	String	参数解释： 服务日志的起始行。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
end_line_num	String	参数解释： 服务日志的结束行。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1075 ModelNodeInfo

参数	参数类型	描述
model_nodes_id	String	参数解释： 模型服务所部署节点的节点ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
model_nodes_aliases	String	参数解释： 模型服务所部署节点的节点名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

获取模型服务所在节点的运行日志信息详情

```
{
  "end_time" : 1743588171679,
  "size" : 2000,
  "start_time" : 1743587871679,
  "type" : "init"
}
```

响应示例

状态码：200

成功响应示例

```
{
  "logs" : "INFO 03-25 11:00:14 metrics.py:351] Avg prompt throughput: 0.0 tokens/s, Avg generation throughput: 0.0 tokens/s, reqs, GPU KV cache usage: 0.0%, CPU KV cache usage: 0.0%.\nINFO 03-25 11:00:34 metrics.py:351] Avg prompt throughput: 0.0 tokens/s",
  "start_line_num" : 1742871614606345200,
  "end_line_num" : 1742871904705815000
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.14.10 获取资源池节点上运行任务信息

功能介绍

获取专属资源池节点上运行任务信息。

接口域名请参考[获取盘古服务外部API域名](#)获取。

URI

GET /v1/{project_id}/model-service/tasks

表 3-1076 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1077 Query 参数

参数	是否必选	参数类型	描述
pool_id	是	String	参数解释： 资源池ID。pool_id值取自 查询资源池列表详情 接口响应体的metadata中name参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
host_ip	否	String	参数解释： 资源池节点IP。host_ip值取自 查询资源池列表详情 接口响应体的privateIp参数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-1078 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-1079 响应 Body 参数

参数	参数类型	描述
total_size	Integer	参数解释： 部署在该资源池或者该节点上的服务数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
project_id	String	参数解释： 该租户的项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
pool_id	String	参数解释： 部署服务的资源池ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
host_ip	String	参数解释： 部署服务部署所在的资源池的节点IP。 约束限制： 查询条件中host_ip值为null时，不返回该字段的值。 取值范围： 不涉及 默认取值： 不涉及
pool_node_services	Array of PoolNodeService objects	参数解释： 资源池节点部署的服务信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1080 PoolNodeService

参数	参数类型	描述
service_id	String	参数解释： 部署服务的服务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
create_time	String	参数解释： 部署服务的创建时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
update_time	String	参数解释： 部署服务的更新时间。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 部署该服务用户的项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
user_id	String	参数解释： 部署该服务用户的用户ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
user_name	String	参数解释： 部署该服务用户的用户名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	String	参数解释： 部署该服务所在工作空间的空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
access_url	String	参数解释： 服务部署成功后访问服务的url。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
api_url	String	参数解释： 访问该服务的外部api访问地址。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
arch	String	参数解释： 服务架构信息。 约束限制： 不涉及 取值范围： • X86 • ARM 默认取值： 不涉及
category	String	参数解释： 模型来源。 约束限制： 不涉及 取值范围： • pangu：盘古模型 • 3rd：来自用户自行导入的三方模型 • 3rd-pangu：由盘古服务提供的三方模型 默认取值： 不涉及

参数	参数类型	描述
chip_type	String	参数解释： 芯片类型。 约束限制： 不涉及 取值范围： • Snt9B3 • Snt9B3 • Snt3P 默认取值： 不涉及
pool_id	String	参数解释： 服务部署在该资源池的资源池ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
device_type	String	参数解释： 部署服务的设备类型，NPU,GPU，NONE。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
domain_id	String	参数解释： 部署该服务的用户的租户id。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
infer_type	String	参数解释： 模型部署方式。 约束限制： 不涉及 取值范围： • online：在线部署 • edge：边缘部署 默认取值： 不涉及
is_preset	Boolean	参数解释： 是否为预置模型服务。 约束限制： 不涉及 取值范围： • true：预置服务 • false：非预置服务 默认取值： 不涉及
ma_model_id	String	参数解释： 模型在ModelArts服务中的模型ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
ma_service_id	String	参数解释： 模型服务部署在ModelArts服务的服务ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
name	String	参数解释： 模型服务的服务名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
ma_infer_version	String	参数解释： 模型服务部署在ModelArts服务的版本类型，v1或者v2。 约束限制： 不涉及 取值范围： v1或者v2 默认取值： 不涉及
host_ip	String	参数解释： 模型服务部署的节点IP。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "total_size": 1,
  "project_id": "c3140321fbc4401fa3aa571976cbebc",
  "pool_id": "pool-xxx-64-c3140321fbc4401fa3aa571976cbebc",
  "pool_node_services": [
    {
      "service_id": "063dd81d-d8f5-4b0f-921e-6fe6760d4794",
      "access_url": "https://8.28.11.44/v1/infers/5e805f45-df50-4d49-b89d-88c4da8fab8b",
      "api_url": "https://8.28.11.173:31004/v1/c3140321fbc4401fa3aa571976cbebc/deployments/063dd81d-d8f5-4b0f-921e-6fe6760d4794/chat/completions",
      "arch": "ARM",
      "category": "3rd",
      "chip_type": "Snt9B3",
```



```
    "pool_id": "pool-jq-test-c3140321fbc4401fa3aa571976cbebc",
    "device_type": "NPU",
    "domain_id": "845a62407a0649c7b18474881c0046a8",
    "infer_type": "online",
    "ma_service_id": "5e805f45-df50-4d49-b89d-88c4da8fab8b",
    "name": "3RD-Qwen25-VL-32B-004-z30022114",
    "ma_infer_version": "v1"
  }
]
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

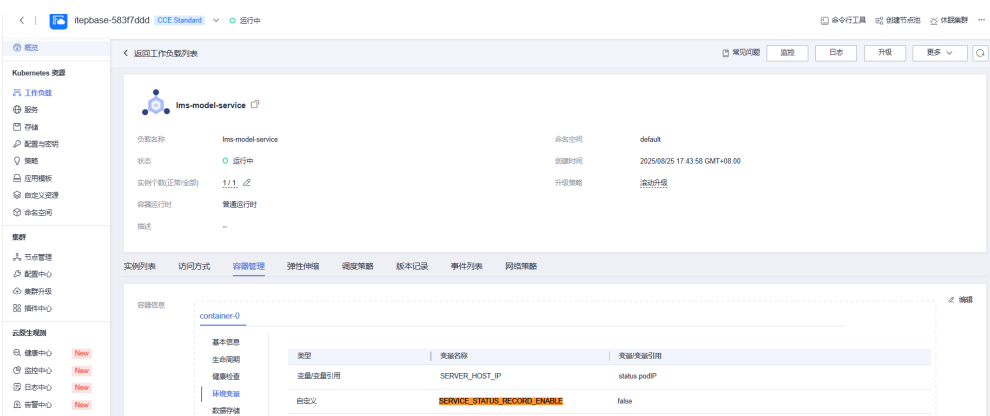
3.14.11 获取规定时间内的推理任务使用卡的资源数

功能介绍

获取规定时间内的推理任务使用卡的资源数。

使用该接口前请使用承载租户登录CCE服务，查看itepbase-xxx集群中lms-model-service工作负载中的环境变量SERVICE_STATUS_RECORD_ENABLE，将该环境变量改为true，即可调用该接口。

注意：开启该环境变量之后，部署的推理任务的卡资源数才可以被统计到。



URI

GET /v1/{project_id}/workspaces/{workspace_id}/model-service/resource-usage

接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-1081 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1082 Query 参数

参数	是否必选	参数类型	描述
start_time	是	Long	参数解释： 统计查询开始时间，毫秒时间戳，当统计时间超过3个月，返回统计结果以天为单位。 约束限制： 时间戳（毫秒级） 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
end_time	是	Long	参数解释： 统计窗口结束时间，毫秒时间戳，当统计时间在3个月以内，返回统计结果以分钟为单位。 约束限制： 时间戳（毫秒级） 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-1083 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

响应参数

状态码：200

表 3-1084 响应 Body 参数

参数	参数类型	描述
total_size	Integer	参数解释： 本次查询到的数据条目数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
project_id	String	参数解释： 租户项目ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	String	参数解释： 工作空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
infer_resource_info	Array of InferResourceInfo objects	参数解释： 推理任务运行时长信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1085 InferResourceInfo

参数	参数类型	描述
chip_type	String	参数解释： 任务运行所使用的资源池算力规格。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
task_type	String	参数解释： 统计运行时长的任务类型。 约束限制： 不涉及 取值范围： infer：推理任务 默认取值： 不涉及
duration	Float	参数解释： 推理任务的卡占用时长，单位：卡×分钟或者卡×小时，当统计时间大于3个月时为小时，小于3个月时为分钟。 例如：服务运行30min，使用的卡数量为2，那么计算公式为：2卡×30min = 60卡分钟 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

无

响应示例

```
{
  "total_size": 1,
  "project_id": "c3140321fbc4401fa3aa571976cbebc",
  "workspace_id": "c088961e-8df7-4f1e-8ba1-d70218afbcef",
  "infer_resource_infos": [
```

```
{
  {
    "chip_type": "3xxx",
    "task_type": "infer",
    "duration": 0.83
  }
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.15 资源池管理

3.15.1 查询资源池列表详情

功能介绍

通过该接口可以查询用户在ModelArts中创建的专属资源池列表。

URI

POST /v1/{project_id}/pangu/studio/resource-pool/online/{workspace_id}/pool
接口域名请参考[获取盘古服务外部API域名](#)获取。

表 3-1086 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-1087 请求 Body 参数

参数	是否必选	参数类型	描述
arch	是	String	参数解释： 架构类型。 约束限制： 不涉及 取值范围： • X86 • ARM 默认取值： 不涉及
device_type	否	String	参数解释： 设备类型。 约束限制： 不涉及 取值范围： • GPU • NPU • NONE 默认取值： 不涉及

参数	是否必选	参数类型	描述
chip_types	否	Array of strings	参数解释： 资源池的卡类型，支持多卡资源池查询。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
job_type	否	String	参数解释： 资源池支持的作业类型。 约束限制： 不涉及 取值范围： • Train：训练作业 • Infer：推理作业 默认取值： 不涉及
status	否	String	参数解释： 资源池状态。 约束限制： 不涉及。 取值范围： 可选值如下： • created：创建成功的资源池。 • failed：创建失败的资源池，创建失败的资源池记录保留3天。 • creating：创建中的资源池。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1088 响应 Body 参数

参数	参数类型	描述
kind	String	参数解释： 资源的类型。 约束限制： 不涉及 取值范围： 可选值如下： PoolList：资源池列表 默认取值： 不涉及
pools	Array of pools objects	参数解释： 资源池列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
fp16	Integer	参数解释： 芯片算力。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
arch	String	参数解释： 架构类型。 约束限制： 不涉及 取值范围： - X86 - ARM 默认取值： 不涉及

参数	参数类型	描述
device_type	String	参数解释： 设备类型。 约束限制： 不涉及 取值范围： - GPU - NPU - NONE 默认取值： 不涉及

表 3-1089 pools

参数	参数类型	描述
kind	String	参数解释： 资源的类型。 约束限制： 不涉及 取值范围： 可选值如下： Pool：资源池 默认取值： 不涉及
apiVersion	String	参数解释： 资源的API版本。 约束限制： 不涉。 取值范围： 可选值如下： v2：当前资源版本为v2 默认取值： 不涉及

参数	参数类型	描述
metadata	metadata object	参数解释： 资源池的元信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
spec	spec object	参数解释： 资源池的规格信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
status	status object	参数解释： 资源池的状态信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
nodes	Array of 表16 node objects	参数解释： 节点资源列表。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1090 metadata

参数	参数类型	描述
name	String	参数解释： 资源池的ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
creationTimestamp	String	参数解释： 资源池的创建时间，例如 "2025-11-01T03:49:41Z"。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
labels	labels object	参数解释： 资源池的标签信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
annotations	annotations object	参数解释： 资源池的注释信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1091 labels

参数	参数类型	描述
os.modelarts/ name	String	参数解释： 资源池的显示名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
os.modelarts/ workspace.id	String	参数解释： 工作空间ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 0
os.modelarts/ resource.id	String	参数解释： 资源池计费使用的资源ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1092 annotations

参数	参数类型	描述
os.modelarts/ description	String	参数解释： 资源池的描述信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
os.modelarts/ flavor.resource.ids	String	参数解释： 资源池中资源规格对应的资源ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
os.modelarts/ tms.tags	String	参数解释： 资源池上的资源标签。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
os.modelarts/ billing.mode	String	参数解释： 计费模式。 约束限制： 不涉及 取值范围： 0：按需 1：按周期 默认取值： 不涉及
os.modelarts/ order.id	String	参数解释： 资源池订阅时传递的订单ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
os.modelarts.pool/ subpools.count	String	参数解释： 逻辑子池的数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1093 spec

参数	参数类型	描述
type	String	参数解释： 资源池类型。 约束限制： 不涉及 取值范围： • Dedicate：物理资源池，独立的网络，支持网络打通，定制驱动，定制作业类型。 • Logical：逻辑资源池。没有独立的网络，不支持网络打通，资源池创建和扩缩容相较物理资源池更快。 默认取值： 不涉及
scope	Array of strings	参数解释： 资源池支持的作业类型。 约束限制： 不涉及 取值范围： • Train：训练作业 • Infer：推理作业 默认取值： 不涉及

参数	参数类型	描述
resources	Array of resources objects	参数解释： 资源池中的资源规格信列表，包括资源规格和相应规格的资源数量。 约束限制： 至少包含一个资源信息。 取值范围： 不涉及 默认取值： 不涉及
network	network object	参数解释： 资源池网络参数。 约束限制： 物理资源池该参数必选。 取值范围： 不涉及 默认取值： 不涉及

表 3-1094 resources

参数	参数类型	描述
flavor	String	参数解释： 资源规格ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
count	Integer	参数解释： 资源池中资源规格实例数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1095 network

参数	参数类型	描述
name	String	参数解释： 网络ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1096 status

参数	参数类型	描述
phase	String	参数解释： 资源池的状态。 约束限制： 不涉及 取值范围： • Creating：资源池在创建中。 • Running：资源池在运行中。 • Abnormal：资源池异常。 • Deleting：资源池在删除中。 • Error：资源池错误。 默认取值： 不涉及
root	String	参数解释： 资源池根资源池的ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
scope	Array of scope objects	参数解释： 资源池当前支持的业务类型的状态信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
resources	resources object	参数解释： 资源池中不同状态的资源信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1097 scope

参数	参数类型	描述
scopeType	String	参数解释： 资源池的业务类型。 约束限制： 不涉及 取值范围： • Train：训练任务。 • Infer：推理任务。 默认取值： 不涉及

参数	参数类型	描述
state	String	参数解释： 资源池业务类型状态。 约束限制： 不涉及 取值范围： • Enabling：启动中。 • Enabled：已启动。 • Disabling：关闭中。 • Disabled：已关闭。 默认取值： 不涉及

表 3-1098 resources

参数	参数类型	描述
available	Array of available objects	参数解释： 资源池中可用状态的资源信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1099 available

参数	参数类型	描述
flavor	String	参数解释： 资源规格ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
count	Integer	参数解释： 资源池中资源规格实例数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
azs	Array of azs objects	参数解释： 资源池中期望创建的资源规格实例的az分布。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1100 azs

参数	参数类型	描述
az	String	参数解释： 可用区名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
count	Integer	参数解释： 可用区资源实例的数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1101 node

参数	参数类型	描述
kind	String	参数解释： 资源的类型。 约束限制： 不涉及 取值范围： 可选值如下： Node：节点。 默认取值： 不涉及
apiVersion	String	参数解释： 资源的API版本。 约束限制： 不涉及 取值范围： 可选值如下： v2：当前资源版本为v2。 默认取值： 不涉及
metadata	metadata object	参数解释： 节点资源的元信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
spec	spec object	参数解释： 节点资源的规格信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
status	status object	参数解释： 节点资源的状态信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1102 metadata

参数	参数类型	描述
name	String	参数解释： 节点资源的ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
creationTimestamp	String	参数解释： 节点的创建时间，例如 "2025-11-01T03:49:41Z"。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1103 spec

参数	参数类型	描述
flavor	String	参数解释： 节点资源规格ID。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1104 status

参数	参数类型	描述
phase	String	参数解释： 节点当前状态。 约束限制： 不涉及 取值范围： 可选值如下： - Available：节点可用。 - Creating：节点创建中。 - Deleting：节点删除中。 - Abnormal：节点异常。 - Checking：节点自检中。 默认取值： 不涉及
az	String	参数解释： 节点所在的az。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
privatelp	String	参数解释： 资源池节点的IP地址。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
resources	resources object	参数解释： 节点资源量信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
availableResources	resources object	参数解释： 节点可用资源量信息。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

表 3-1105 resources

参数	参数类型	描述
cpu	String	参数解释： 节点的CPU核心数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
memory	String	参数解释： 节点的内存大小。以Gi为单位。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
huawei.com/ ascend-310	String	参数解释： 节点的snt3型NPU卡数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
nvidia.com/gpu	String	参数解释： 节点的GPU卡数。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
huawei.com/ ascend-1980	String	参数解释： 节点的snt9型NPU卡数量。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求示例

```
{
  "status": "created",
  "job_type": "Infer",
  "arch": "ARM",
  "chip_types": [
```

```
    "D310P"  
  ]  
}
```

响应示例

```
{  
  "kind": "PoolList",  
  "pools": [  
    {  
      "kind": "Pool",  
      "metadata": {  
        "name": "pool-310p-c3140321fbc4401fa3aa571976cbebc",  
        "create_time": "2024-11-29T08:09:31Z",  
        "labels": {  
          "os.modelarts/workspace.id": "0",  
          "os.modelarts/name": "pool-310p",  
          "os.modelarts/resource.id": "maos-pool-310p-6vk7j",  
          "os.modelarts/tenant.domain.id": "845a62407a0649c7b18474881c0046a8",  
          "os.modelarts.pool/biz": "private",  
          "os.modelarts/tenant.project.id": "c3140321fbc4401fa3aa571976cbebc",  
          "os.modelarts/create-from": "console",  
          "os.modelarts/node.prefix": ""  
        },  
        "annotations": {  
          "os.modelarts.pool/subpools.count": "0",  
          "os.modelarts/tenant.domain.name": "MAStudio_test"  
        }  
      },  
      "spec": {  
        "type": "Dedicate",  
        "scope": [  
          "Infer",  
          "X-Infer"  
        ],  
        "resources": [  
          {  
            "flavor": "modelarts.vm.snt3p.300i.kun.16u32g",  
            "count": 1  
          }  
        ],  
        "network": {  
          "name": "network-29a5-c3140321fbc4401fa3aa571976cbebc"  
        }  
      },  
      "status": {  
        "phase": "Running",  
        "resources": {  
          "available": [  
            {  
              "flavor": "modelarts.vm.snt3p.300i.kun.16u32g",  
              "count": 1,  
              "maxCount": 1,  
              "azs": [  
                {  
                  "az": "arm.az",  
                  "count": 1  
                }  
              ]  
            }  
          ]  
        }  
      },  
      "scope": [  
        {  
          "scopeType": "Infer",  
          "state": "Enabled"  
        },  
        {  
          "scopeType": "X-Infer",
```

```
        "state": "Enabled"
      }
    ]
  },
  "chip_type": "D310P",
  "nodes": [
    {
      "apiVersion": "v2",
      "kind": "Node",
      "metadata": {
        "name": "os-node-created-c4ffz",
        "creationTimestamp": "2024-11-29T08:14:36Z"
      },
      "spec": {
        "flavor": "modelarts.vm.snt3p.300i.kun.16u32g"
      },
      "status": {
        "phase": "Available",
        "az": "arm.az",
        "privateIp": "25.212.71.239",
        "resources": {
          "cpu": "15890m",
          "memory": "27951Mi",
          "huawei.com/ascend-310": "1"
        },
        "availableResources": {
          "cpu": "6020m",
          "memory": "407Mi",
          "huawei.com/ascend-310": "0"
        }
      }
    }
  ],
  "fp16": 70,
  "arch": "ARM"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.16 边学边用

3.16.1 数据结果回传

功能介绍

边学边用功能支持用户通过“数据结果回传”API将模型推理过程中发现的效果不好的数据，通过该接口回传至ModelArts Studio平台，并与平台中已有的旧数据集合并形成一个新的数据集。

 说明

仅支持将CV模型中以下类型的数据集进行回传：
物体检测、图像分类、异常检测、旋转检测、实例分割、视频分类格式数据集

URI

POST /v1/{project_id}/workspaces/{workspace_id}/data-extraction/original-dataset/backhaul

表 3-1106 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 项目ID。 获取方法请参见 获取项目ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
workspace_id	是	String	参数解释： 空间ID。 获取方法请参见 获取空间ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

请求参数

表 3-1107 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 用于获取操作API的权限。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-1108 请求 Body 参数

参数	是否必选	参数类型	描述
dataset_id	是	String	参数解释： ModelArts Studio平台中已有数据集的ID。 可以使用发布成功的发布数据集ID。获取方法请参见 获取数据集ID 。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	是否必选	参数类型	描述
sample_path	是	String	参数解释： 待回传数据所在的OBS目录。 约束限制： 要求与dataset_id参数所指定的数据集格式一致，需要提前将待回传的数据上传至OBS中。例如物体检测训练的数据集是jpg+xml格式，回传的数据也需要是jpg+xml格式。 sample_path参数填写示例如下，需要指定待回传数据文件所在的文件夹。 obs://data-original/testdata 取值范围： 不涉及 默认取值： 不涉及

响应参数

状态码： 200

表 3-1109 响应 Body 参数

参数	参数类型	描述
dataset_id	String	参数解释： 数据回传至ModelArts Studio平台后，所生成的新数据集的ID。新数据集会显示在平台“原始数据集”页面。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

参数	参数类型	描述
dataset_name	String	参数解释： 生成的新数据集名称。 约束限制： 不涉及 取值范围： 不涉及 默认取值： 不涉及

状态码： 400

表 3-1110 响应 Body 参数

参数	参数类型	描述
error_code	String	错误码。
error_msg	String	错误描述。

请求示例

将推理过程中发现的效果不好的数据回传至平台，并与平台中已有的旧数据集合并形成一个新的数据集

```
{
  "dataset_id": "1314278395571474432",
  "sample_path": "obs://data-original/testdata"
}
```

响应示例

状态码： 200

成功响应示例

```
{
  "dataset_id": "1314238911412834304",
  "dataset_name": "original_20241129-1733389337888"
}
```

状态码

请参见[状态码](#)。

错误码

请参见[错误码](#)。

3.17 Agent

3.17.1 开发态

3.17.1.1 知识库管理

3.17.1.1.1 查询知识库使用的模型列表

功能介绍

说明

软件版本为8.6.301，才支持此功能。

查询知识库使用的模型列表，并返回相关信息。

适用场景：

- 新建知识库：需要使用该接口查询需要使用的向量模型和精排模型信息。
- 知识库高级设置：需要修改精排模型时，可以通过此接口查询模型信息。

URI

GET /v2/{project_id}/agent-manager/knowledge-bases/models

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1111 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

表 3-1112 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考获取工作区ID。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
model_name	否	String	参数解释： 模型名称。 约束限制： 不涉及。 取值范围： ● 必须由英文字母（大小写均可）、数字、连字符（-）或下划线（_）组成。 ● 长度限制：1至64个字符。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
repo_id	否	String	参数解释： 知识库的ID。 获取方式： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 知识库”。 3. 在知识库列表的“知识库 ID”列，复制知识库ID。 约束限制： 不涉及。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过64位字符。 默认取值： 不涉及。 说明 传入知识库ID，表示查询此知识库已使用的模型列表；未传入此参数，表示查询知识库可以使用的模型列表。
model_type	否	String	参数解释： 模型类型。 约束限制： 不涉及。 取值范围： - embedding项目：模型。 - rerank：精排模型。 - ocr：OCR模型。 默认取值： 全部。
offset	否	Integer	参数解释： 分页记录的起始位置偏移量。 约束限制： 必须为整数，且不超过10000。 取值范围： 0 至 10000（含）。 默认取值： 0。

参数	是否必选	参数类型	描述
limit	否	Integer	参数解释： 每一页的数量。 约束限制： 必须为正整数，且不超过系统最大返回限制。 取值范围： 1 至 1000（含）。 默认取值： 10。

请求参数

表 3-1113 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1114 响应 Body 参数

参数	参数类型	描述
total	Integer	参数解释： 结果总数。 取值范围： 不涉及。

参数	参数类型	描述
models	Array of ModelInfo objects	参数解释： 模型列表。 取值范围： 不涉及。

表 3-1115 ModelInfo

参数	参数类型	描述
name	String	参数解释： 模型名称。 取值范围： 不涉及。
id	String	参数解释： 模型ID。 取值范围： 不涉及。
type	String	参数解释： 模型类型。 取值范围： - embedding：向量模型。 - rerank：精排模型。
status	String	参数解释： 模型状态。 取值范围： - ready：模型可访问。 - error：模型不可用。

请求示例

查询知识库使用的模型列表。

```
{
  "method": "GET",
  "url": "https://api.example.com/v2/{project_id}/agent-manager/knowledge-bases/models?model_type=embedding",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  }
}
```

响应示例

状态码：200

查询模型列表响应体。

```
{
  "total": 1,
  "models": [ {
    "name": "embedding-en",
    "detail": "英文模型",
    "type": "embedding",
    "status": "ready"
  } ]
}
```

状态码

状态码	描述
200	查询模型列表响应体。

错误码

请参见[错误码](#)。

3.17.1.1.2 创建知识库

功能介绍

说明

软件版本为8.6.301，才支持此功能。

用于创建新知识库。调用时需指定名称、描述、向量模型（embedding）和精排模型（rerank）等参数。

适用场景：

- 工作流集成：可以在工作流的「知识检索」节点中关联该知识库，实现工作流内的知识库检索。
- 智能体配置：在智能体配置中添加该知识库，实现在对话过程中基于知识库检索结果进行回复。

URI

POST /v1/{project_id}/agent-manager/knowledges

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1116 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

表 3-1117 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1118 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 3-1119 请求 Body 参数

参数	是否必选	参数类型	描述
display_name	是	String	参数解释： 知识库展示名称。 约束限制 不涉及。 取值范围： 支持汉字、字母、数字、下划线及连字符；必须以汉字、字母或数字开头。 长度限制：1至50个字符。 默认取值 不涉及。
description	是	String	参数解释： 知识库的描述。 约束限制 不涉及。 取值范围： 不涉及。 默认取值 不涉及。

参数	是否必选	参数类型	描述
embedding_model	否	ModelConf object	参数解释： 向量模型信息。 约束限制 不涉及。 取值范围： 不涉及。 默认取值 不涉及。
rerank_model	否	ModelConf object	参数解释： 精排模型信息。 约束限制 不涉及。 取值范围： 不涉及。 默认取值 不涉及。
parse_conf	否	ParseConf object	参数解释： 知识库解析配置。包含是否使用OCR增强、是否解析图片、解析图片是否需要提取文字、是否解析页眉页脚、是否解析目录页等。 约束限制 不涉及。 取值范围： 不涉及。 默认取值 不涉及。

参数	是否必选	参数类型	描述
split_conf	否	SplitConf object	参数解释： 知识库拆分配置。包括分段方式设置、层级解析模式设置、标题层级深度设置、标题保存方式设置、分段长度配置、标题匹配pattern配置等。 约束限制 不涉及。 取值范围： 不涉及。 默认取值 不涉及。
icon	否	String	参数解释： 知识库图标。 约束限制 不涉及。 取值范围： 不涉及。 默认取值 不涉及。
rag_chunk_parser_conf	否	RagChunkParserConf object	参数解释： 自研RAG知识库拆分配置。 约束限制 不涉及。 取值范围： 不涉及。 默认取值 不涉及。

表 3-1120 ModelConf

参数	是否必选	参数类型	描述
id	否	String	参数解释： 模型ID。 获取方式： 调用 查询知识库使用的模型列表 接口返回模型列表中的id属性。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
name	是	String	参数解释： 模型名。 获取方式： 调用 查询知识库使用的模型列表 接口返回模型列表中的name属性。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 3-1121 ParseConf

参数	是否必选	参数类型	描述
ocr_enabled	否	Boolean	参数解释： 是否开启OCR增强。 约束限制 不涉及。 取值范围： • true：开启OCR增强。 • false：不开启OCR增强。 默认取值 false。

参数	是否必选	参数类型	描述
image_enabled	否	Boolean	参数解释： 是否开启图片增强。 约束限制 不涉及。 取值范围： • true：开启图片增强。 • false：不开启图片增强。 默认取值 false。
header_footer_enabled	否	Boolean	参数解释： 是否解析页眉页脚。 约束限制 不涉及。 取值范围： • true：解析页眉页脚。 • false：不解析页眉页脚。 默认取值 false。
catalog_enabled	否	Boolean	参数解释： 是否解析目录页。 约束限制 不涉及。 取值范围： • true：解析目录页。 • false：不解析目录页。 默认取值 false。

参数	是否必选	参数类型	描述
image_conf	否	String	参数解释： 图片识别配置。 约束限制 该配置仅当<i>image_enabled</i>为<i>true</i>时生效，<i>image_enabled</i>为<i>true</i>时必选。 取值范围： • TEXT：文字提取，会提取图片中的文字。 • IMAGE：图片提取，只保留原图，不做识别。 默认取值 IMAGE。

表 3-1122 SplitConf

参数	是否必选	参数类型	描述
split_mode	否	String	参数解释： 文档拆分规则。 约束限制 不涉及。 取值范围： • LENGTH：长度拆分，即为字数拆分。 • CATALOG：层级分段下的自动解析。 • RULE：层级分段下的规则解析。 • AUTO：自动拆分，自动识别文档格式匹配适合的拆解析方式。 默认取值 AUTO。

参数	是否必选	参数类型	描述
separator_ids	否	Array of strings	参数解释： 分段标识符ID列表。 约束限制 <i>split_mode</i>为<i>AUTO</i>时可不填。 取值范围： 文件解析分类： • space_en：空格。 • period_zh：中文句号。 • period_en：英文句号。 • exclamation_mark_zh：中文叹号。 • exclamation_mark_en：英文叹号。 • question_mark_zh：中文问号。 • question_mark_en：英文问号。 • comma_zh：中文逗号。 • comma_en：英文逗号。 默认取值 comma_en。
rule_regex_id	否	String	参数解释： 用户定义解析规则ID。 约束限制 不涉及。 取值范围： 字段长度[1, 256]。 默认取值 不涉及。
chunk_size	否	Integer	参数解释： 分段预计长度。 约束限制 不涉及。 取值范围： [0, 600]。 默认取值 500。

参数	是否必选	参数类型	描述
title_level	否	Integer	参数解释： 标题层级深度。 约束限制 不涉及。 取值范围： [1, 10]。 默认取值 3。
combine_title	否	Boolean	参数解释： 是否要合并标题。 每一个分片都有一个标题属性，指是否合并分片的标题。标题有层级关系，合并标题就是将该分片的多级标题合并，例如标题1标题2标题3。不合并时，只会保留最小层级标题。 约束限制 不涉及。 取值范围： • false：保留最后一级。 • true：保存多标题组合。 默认取值 false。
merge_titles	否	Boolean	参数解释： 是否跨标题合并，不同标题段落文字较少时，会自动合并到指定的分段长度，有助于生成更全面的结果。 约束限制 不涉及。 取值范围： • true：跨标题合并。 • false：不跨标题合并。 默认取值 true。

表 3-1123 RagChunkParserConf

参数	是否必选	参数类型	描述
chunk_method	否	String	参数解释： 切片类型。 约束限制 不涉及。 取值范围： • naive：通用。 • qa：问答。 • table：表格。 • book：书籍。 • laws：法律条文。 • one：直接作为一个切片。 默认取值 native。
auto_keywords	否	Integer	参数解释： 自动关键词提取。 约束限制 不涉及。 取值范围： [0, 32]。 默认取值 0。
auto_questions	否	Integer	参数解释： 自动问题提取。 约束限制 不涉及。 取值范围： [0, 10]。 默认取值 0。

参数	是否必选	参数类型	描述
chunk_token_num	否	Integer	参数解释： 建议文本块大小。 约束限制 不涉及。 取值范围： [1, 2048]。 默认取值 512。
delimiter	否	Array of strings	参数解释： 分段标识符ID列表。 约束限制 不涉及。 取值范围： 支持中文句号、英文句号、中文感叹号、英文感叹号、中文问号、英文问号、中文逗号、英文逗号、空格、换行。 默认取值 /n。

响应参数

状态码：200

表 3-1124 响应 Body 参数

参数	参数类型	描述
knowledge_repo_id	String	参数解释： 知识库ID。 取值范围： 不涉及。

请求示例

创建知识库请求体。

```
{
  "method": "POST",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN"*****!!
  }
}
```



```
},
"body": {
  "display_name": "测试知识库",
  "description": "测试知识库",
  "parse_conf": {
    "ocr_enabled": true,
    "image_enabled": true,
    "header_footer_enabled": true,
    "catalog_enabled": true,
    "image_conf": "IMAGE"
  },
  "embedding_model": {
    "name": "embedding-en"
  },
  "rerank_model": {
    "name": "rerank-zh"
  },
  "split_conf": {
    "split_mode": "RULE",
    "rule_regex_id": "default-rule-1",
    "title_level": 3,
    "combine_title": true,
    "merge_titles": true,
    "separator_ids": [ "period_zh", "period_en", "exclamation_mark_zh", "exclamation_mark_en",
"question_mark_zh", "question_mark_en" ],
    "chunk_size": 500
  }
}
```

响应示例

状态码：200

创建知识库响应体。

```
{
  "knowledge_repo_id": "e0fffc7bc4b24a84bdb675d10489efe9"
}
```

状态码

状态码	描述
200	创建知识库响应体。

错误码

请参见[错误码](#)。

3.17.1.1.3 查询知识库列表

功能介绍

 说明

软件版本为8.6.301，才支持此功能。

根据指定查询条件查询知识库列表，支持分页查询并提供筛选功能。

适用场景：

- 工作流集成：在「知识检索」节点中配置知识库时，调用此接口获取可选资源列表。
- 智能体配置：在为智能体开启知识库能力时，通过此接口检索并关联目标知识库。

URI

GET /v2/{project_id}/agent-manager/knowledge-bases

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1125 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

表 3-1126 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
offset	否	Integer	参数解释： 分页记录的起始位置偏移量。 约束限制： 必须为整数，且不超过10000。 取值范围： 0 至 10000（含）。 默认取值： 0。
limit	否	Integer	参数解释： 每一页的数量。 约束限制： 必须为正整数，且不超过系统最大返回限制。 取值范围： 1 至 1000（含）。 默认取值： 10。
share_scope	否	String	参数解释： 知识库可见范围。 约束限制： 不涉及。 取值范围： - SELF：当前空间下可见。 - GLOBAL：当前租户下可见。 - ALL：当前空间和租户下可见。 默认取值： 不涉及。
name	否	String	参数解释： 知识库名称。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
type	否	String	参数解释： 知识库类型。 约束限制： 不涉及。 取值范围： • internal：用户在Versatile平台创建的知识库。 • external：用户在外部知识库平台创建的知识库，在Versatile平台中进行引用。 默认取值： 不涉及。
knowledge_base_connection_id	否	String	参数解释： 接入知识库的连接ID。 约束限制： 仅在查询第三方知识库时生效。 取值范围： 字段长度：[0, 100]。 默认取值： 不涉及。 说明 当前暂未提供获取第三方知识库连接 ID 的接口。如无需基于特定第三方知识库进行过滤，请直接忽略此参数，不传即可。
status	否	String	参数解释： 知识库状态。 约束限制： 不涉及。 取值范围： • OPEN：启用。 • CLOSE：停用。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
knowledge_base_ids	否	Array of strings	参数解释： 知识库ID列表。 约束限制： 不涉及。 取值范围： • 数组长度为1～100。 • 单个ID最大长度为128字符。 默认取值： 不涉及。

请求参数

表 3-1127 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1128 响应 Body 参数

参数	参数类型	描述
total	Long	参数解释： 结果总数。 取值范围： 不涉及。

参数	参数类型	描述
items	Array of KnowledgeBaseListItem objects	参数解释： 知识库列表。 取值范围： 不涉及。

表 3-1129 KnowledgeBaseListItem

参数	参数类型	描述
knowledge_base_id	String	参数解释： 知识库ID。 取值范围： 不涉及。
icon	String	参数解释： 知识库图标。 取值范围： 不涉及。
type	String	参数解释： 知识库类型。 取值范围： - internal：用户在Versatile平台创建的知识库。 - external：用户在外置知识库平台创建的知识库，在Versatile平台中进行引用。
workspace_id	String	参数解释： 空间ID。 取值范围： 不涉及。
share_scope	String	参数解释： 知识库可见范围。 取值范围： - SELF：当前空间下可见。 - GLOBAL：当前租户下可见。 - ALL：当前空间和租户下可见。
source	ExternalKnowledgeBaseSource object	知识库来源。

参数	参数类型	描述
name	String	参数解释： 知识库展示名称。 取值范围： 不涉及。
description	String	参数解释： 知识库的描述。 取值范围： 不涉及。
status	String	参数解释： 知识库状态。 取值范围： • OPEN：启用。 • CLOSE：停用。
created_user_id	String	参数解释： 创建人ID。 取值范围： 不涉及。
created_user_name	String	参数解释： 创建人名称。 取值范围： 不涉及。
create_time	Long	参数解释： 创建知识库时间戳（以毫秒为单位）。 取值范围： 不涉及。
last_update_user_id	String	参数解释： 更新人ID。 取值范围： 不涉及。
last_update_user_name	String	参数解释： 更新人名称。 取值范围： 不涉及。

参数	参数类型	描述
update_time	Long	参数解释： 更新知识库的时间戳（以毫秒为单位）。 取值范围： 不涉及。

表 3-1130 ExternalKnowledgeBaseSource

参数	参数类型	描述
knowledge_base_connector_id	String	参数解释： 第三方知识库的连接器ID。 取值范围： 不涉及。
knowledge_base_connection_id	String	参数解释： 第三方知识库的连接ID。 取值范围： 不涉及。
knowledge_base_connection_name	String	参数解释： 第三方知识库的连接名称。 取值范围： 不涉及。
detail_page_url	String	参数解释： 第三方知识库详情页的跳转地址。 取值范围： 不涉及。

请求示例

查询知识库列表。

```
{
  "method": "GET",
  "url": "https://api.example.com/v2/{project_id}/agent-manager/knowledge-bases?offset=0&limit=10",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  }
}
```

响应示例

状态码：200

知识库列表。

```
{
  "total": 1,
  "items": [ {
    "knowledge_base_id": "e0fffc7bc4b24a84bdb675d10489efe9",
    "icon": "data:image/svg+xml;base64,xxxxxx",
    "repo_type": "share",
    "type": "internal",
    "workspace_id": "default",
    "share_scope": "SELF",
    "source": {
      "knowledge_base_connector_id": "KooSearchInside",
      "knowledge_base_connection_id": "550e8400e29b41d4a716446655440003",
      "knowledge_base_connection_name": "KooSearchInside-4",
      "detail_page_url": ""
    },
    "name": "测试知识库",
    "description": "测试知识库",
    "status": "OPEN",
    "created_user_id": "2e8565cb0e234840a3d2016b577061dc",
    "created_user_name": "test_user",
    "create_time": 1768467256222,
    "last_update_user_id": "2e8565cb0e234840a3d2016b577061dc",
    "last_update_user_name": "test_user",
    "update_time": 1768467256222
  } ]
}
```

状态码

状态码	描述
200	知识库列表。

错误码

请参见[错误码](#)。

3.17.1.1.4 修改知识库

功能介绍

 说明

软件版本为8.6.301，才支持此功能。

修改知识库，包括：知识库图标、知识库名称、描述、高级设置。

适用场景：

- 更改知识库基本信息：知识库图标、知识库名称、描述。
- 调整高级设置：更新知识库所使用的大模型配置、解析策略、拆分方式等。如果想让新配置即时生效，需重新解析相关文档。

 说明

知识库必须处于停用状态才可以进行上述修改。

URI

PUT /v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1131 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法 请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
knowledge_repo_id	是	String	参数解释： 知识库的ID。 获取方式： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 知识库”。 3. 在知识库列表的“知识库 ID”列，复制知识库ID。 约束限制： 不涉及。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过64位字符。 默认取值： 不涉及。

表 3-1132 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1133 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 3-1134 请求 Body 参数

参数	是否必选	参数类型	描述
display_name	是	String	参数解释： 知识库展示名称。 约束限制 不涉及。 取值范围： 不涉及。 默认取值 不涉及。
description	是	String	参数解释： 知识库的描述。 约束限制 不涉及。 取值范围： 不涉及。 默认取值 不涉及。
icon	否	String	参数解释： 知识库图标。 约束限制 不涉及。 取值范围： 不涉及。 默认取值 不涉及。
rerank_model	否	ModelConf object	参数解释： 精排模型配置。 约束限制 不涉及。 取值范围： 不涉及。 默认取值 不涉及。

参数	是否必选	参数类型	描述
parse_conf	否	ParseConf object	参数解释： 知识库文档解析配置。 约束限制 split_conf不为空时，必传。 取值范围： 不涉及。 默认取值 不涉及。
split_conf	否	SplitConf object	参数解释： 知识库文档拆分配置。 约束限制 parse_conf不为空时，必传。 取值范围： 不涉及。 默认取值 不涉及。
rag_chunk_parser_conf	否	RagChunkParserConf object	参数解释： 自研RAG知识库拆分配置。 约束限制 不涉及。 取值范围： 不涉及。 默认取值 不涉及。

表 3-1135 ModelConf

参数	是否必选	参数类型	描述
id	否	String	参数解释： 模型ID。 获取方式： 调用 查询知识库使用的模型列表 接口返回模型列表中的id属性。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
name	是	String	参数解释： 模型名。 获取方式： 调用 查询知识库使用的模型列表 接口返回模型列表中的name属性。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 3-1136 ParseConf

参数	是否必选	参数类型	描述
ocr_enabled	否	Boolean	参数解释： 是否开启OCR增强。 约束限制 不涉及。 取值范围： • true：开启OCR增强。 • false：不开启OCR增强。 默认取值 false。

参数	是否必选	参数类型	描述
image_enabled	否	Boolean	参数解释： 是否开启图片增强。 约束限制 不涉及。 取值范围： • true：开启图片增强。 • false：不开启图片增强。 默认取值 false。
header_footer_enabled	否	Boolean	参数解释： 是否解析页眉页脚。 约束限制 不涉及。 取值范围： • true：解析页眉页脚。 • false：不解析页眉页脚。 默认取值 false。
catalog_enabled	否	Boolean	参数解释： 是否解析目录页。 约束限制 不涉及。 取值范围： • true：解析目录页。 • false：不解析目录页。 默认取值 false。

参数	是否必选	参数类型	描述
image_conf	否	String	参数解释： 图片识别配置。 约束限制 该配置仅当<i>image_enabled</i>为<i>true</i>时生效，<i>image_enabled</i>为<i>true</i>时必选。 取值范围： • TEXT：文字提取，会提取图片中的文字。 • IMAGE：图片提取，只保留原图，不做识别。 默认取值 IMAGE。

表 3-1137 SplitConf

参数	是否必选	参数类型	描述
split_mode	否	String	参数解释： 文档拆分规则。 约束限制 不涉及。 取值范围： • LENGTH：长度拆分，即为字数拆分。 • CATALOG：层级分段下的自动解析。 • RULE：层级分段下的规则解析。 • AUTO：自动拆分，自动识别文档格式匹配适合的拆解析方式。 默认取值 AUTO。

参数	是否必选	参数类型	描述
separator_ids	否	Array of strings	参数解释： 分段标识符ID列表。 约束限制 <i>split_mode</i>为<i>AUTO</i>时可不填。 取值范围： 文件解析分类： • space_en：空格。 • period_zh：中文句号。 • period_en：英文句号。 • exclamation_mark_zh：中文叹号。 • exclamation_mark_en：英文叹号。 • question_mark_zh：中文问号。 • question_mark_en：英文问号。 • comma_zh：中文逗号。 • comma_en：英文逗号。 默认取值 comma_en。
rule_regex_id	否	String	参数解释： 用户定义解析规则ID。 约束限制 不涉及。 取值范围： 字段长度[1, 256]。 默认取值 不涉及。
chunk_size	否	Integer	参数解释： 分段预计长度。 约束限制 不涉及。 取值范围： [0, 600]。 默认取值 500。

参数	是否必选	参数类型	描述
title_level	否	Integer	参数解释： 标题层级深度。 约束限制 不涉及。 取值范围： [1, 10]。 默认取值 3。
combine_title	否	Boolean	参数解释： 是否要合并标题。 每一个分片都有一个标题属性，指是否合并分片的标题。标题有层级关系，合并标题就是将该分片的多级标题合并，例如标题1标题2标题3。不合并时，只会保留最小层级标题。 约束限制 不涉及。 取值范围： • false：保留最后一级。 • true：保存多标题组合。 默认取值 false。
merge_titles	否	Boolean	参数解释： 是否跨标题合并，不同标题段落文字较少时，会自动合并到指定的分段长度，有助于生成更全面的结果。 约束限制 不涉及。 取值范围： • true：跨标题合并。 • false：不跨标题合并。 默认取值 true。

表 3-1138 RagChunkParserConf

参数	是否必选	参数类型	描述
chunk_method	否	String	参数解释： 切片类型。 约束限制 不涉及。 取值范围： • naive：通用。 • qa：问答。 • table：表格。 • book：书籍。 • laws：法律条文。 • one：直接作为一个切片。 默认取值 native。
auto_keywords	否	Integer	参数解释： 自动关键词提取。 约束限制 不涉及。 取值范围： [0, 32]。 默认取值 0。
auto_questions	否	Integer	参数解释： 自动问题提取。 约束限制 不涉及。 取值范围： [0, 10]。 默认取值 0。

参数	是否必选	参数类型	描述
chunk_token_num	否	Integer	参数解释： 建议文本块大小。 约束限制 不涉及。 取值范围： [1, 2048]。 默认取值 512。
delimiter	否	Array of strings	参数解释： 分段标识符ID列表。 约束限制 不涉及。 取值范围： 支持中文句号、英文句号、中文感叹号、英文感叹号、中文问号、英文问号、中文逗号、英文逗号、空格、换行。 默认取值 /n。

响应参数

状态码：200

表 3-1139 响应 Body 参数

参数	参数类型	描述
knowledge_repo_id	String	知识库ID。

请求示例

修改知识库请求体。

```
{
  "method": "PUT",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  },
  "body": {
    "display_name": "测试知识库",
    "description": "测试知识库",
  }
}
```

```
"parse_conf": {
  "ocr_enabled": false,
  "image_enabled": false,
  "header_footer_enabled": false,
  "catalog_enabled": false,
  "image_conf": "IMAGE"
},
"embedding_model": {
  "type": "embedding",
  "name": "embedding-zh"
},
"split_conf": {
  "split_mode": "AUTO"
}
}
```

响应示例

状态码：200

修改知识库响应体。

```
{
  "knowledge_repo_id": "e0fffc7bc4b24a84bdb675d10489efe9"
}
```

状态码

状态码	描述
200	修改知识库响应体。

错误码

请参见[错误码](#)。

3.17.1.1.5 查询知识库详情

功能介绍

 说明

软件版本为8.6.301，才支持此功能。

查询知识库详情。

适用场景：

- 获取知识库的基础元数据，如知识库ID、创建时间、容量等。
- 在管理后台展示知识库详情页面。

URI

GET /v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1140 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法 请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
knowledge_repo_id	是	String	参数解释： 知识库的ID。 获取方式： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 知识库”。 3. 在知识库列表的“知识库 ID”列，复制知识库ID。 约束限制： 不涉及。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过64位字符。 默认取值： 不涉及。

表 3-1141 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1142 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1143 响应 Body 参数

参数	参数类型	描述
knowledge_repo_id	String	参数解释： 知识库ID。 取值范围： 不涉及。
project_id	String	参数解释： 租户唯一标识。 取值范围： 不涉及。
display_name	String	参数解释： 知识库展示名称。 取值范围： 不涉及。
workspace_id	String	参数解释： 项目空间ID。 取值范围： 不涉及。
description	String	参数解释： 知识库的描述。 取值范围： 不涉及。
type	String	参数解释： 知识库类型。 取值范围： - internal：用户在Versatile平台创建的知识库。 - external：用户在外部知识库平台创建的知识库，在Versatile平台中进行引用。
repo_type	String	参数解释： 知识库类型。 取值范围 - share：共享。 - exclusive：专享。

参数	参数类型	描述
size	Long	参数解释： 知识库中所有文件的总大小（ bytes ）。 取值范围： 不涉及。
max_size	Long	参数解释： 租户可用的最大容量。 取值范围： 不涉及。
remain_size	Long	参数解释： 租户目前可用的容量。 取值范围： 不涉及。
creator	String	参数解释： 知识库创建者。 取值范围： 不涉及。
update_user_name	String	参数解释： 更新人。 取值范围： 不涉及。
parse_conf	ParseConf object	参数解释： 知识库文档解析配置。 取值范围： 不涉及。
split_conf	SplitConf object	参数解释： 知识库文档拆分配置。 取值范围： 不涉及。
embedding_model	String	参数解释： 知识库使用的向量模型名称。 取值范围： 不涉及。
rerank_model	String	参数解释： 知识库使用的精排模型名称。 取值范围： 不涉及。

参数	参数类型	描述
icon	String	参数解释： 知识库图标。 取值范围： 不涉及。
icon_name	String	参数解释： 知识库图标名称。 取值范围： 不涉及。
status	String	参数解释： 知识库状态。 取值范围： • OPEN：启用。 • CLOSE：停用。
metadata	String	参数解释： 扩展参数。 取值范围： 不涉及。
create_time	String	参数解释： 创建知识库时间戳（以毫秒为单位）。 取值范围： 不涉及。 说明 当前接口返回的时间格式为yyyy-MM-dd HH:mm:ss，最新版本已统一采用13位毫秒级时间戳，建议不要使用，防止升级后出现兼容问题。
update_time	String	参数解释： 更新知识库的时间戳（以毫秒为单位）。 取值范围： 不涉及。 说明 当前接口返回的时间格式为yyyy-MM-dd HH:mm:ss，最新版本已统一采用13位毫秒级时间戳，建议不要使用，防止升级后出现兼容问题。
rag_chunk_parser_conf	RagChunkParser Conf object	参数解释： 自研RAG知识库拆分配置。 取值范围： 不涉及。

参数	参数类型	描述
share_scope	String	参数解释： 知识库可见范围。 取值范围： - SELF：当前空间下可见。 - GLOBAL：当前租户下可见。 - ALL：当前空间和租户下可见。

表 3-1144 ParseConf

参数	参数类型	描述
ocr_enabled	Boolean	参数解释： 是否开启OCR增强。 约束限制 不涉及。 取值范围： - true：开启OCR增强。 - false：不开启OCR增强。 默认取值 false。
image_enabled	Boolean	参数解释： 是否开启图片增强。 约束限制 不涉及。 取值范围： - true：开启图片增强。 - false：不开启图片增强。 默认取值 false。
header_footer_enabled	Boolean	参数解释： 是否解析页眉页脚。 约束限制 不涉及。 取值范围： - true：解析页眉页脚。 - false：不解析页眉页脚。 默认取值 false。

参数	参数类型	描述
catalog_enabled	Boolean	参数解释： 是否解析目录页。 约束限制 不涉及。 取值范围： • true：解析目录页。 • false：不解析目录页。 默认取值 false。
image_conf	String	参数解释： 图片识别配置。 约束限制 该配置仅当 <code>image_enabled</code> 为 <code>true</code> 时生效， <code>image_enabled</code> 为 <code>true</code> 时必选。 取值范围： • TEXT：文字提取，会提取图片中的文字。 • IMAGE：图片提取，只保留原图，不做识别。 默认取值 IMAGE。

表 3-1145 SplitConf

参数	参数类型	描述
split_mode	String	参数解释： 文档拆分规则。 约束限制 不涉及。 取值范围： • LENGTH：长度拆分，即为字数拆分。 • CATALOG：层级分段下的自动解析。 • RULE：层级分段下的规则解析。 • AUTO：自动拆分，自动识别文档格式匹配适合的拆分解析方式。 默认取值 AUTO。

参数	参数类型	描述
separator_ids	Array of strings	参数解释： 分段标识符ID列表。 约束限制 <i>split_mode</i>为<i>AUTO</i>时可不填。 取值范围： 文件解析分类： • space_en：空格。 • period_zh：中文句号。 • period_en：英文句号。 • exclamation_mark_zh：中文叹号。 • exclamation_mark_en：英文叹号。 • question_mark_zh：中文问号。 • question_mark_en：英文问号。 • comma_zh：中文逗号。 • comma_en：英文逗号。 默认取值 comma_en。
rule_regex_id	String	参数解释： 用户定义解析规则ID。 约束限制 不涉及。 取值范围： 字段长度[1, 256]。 默认取值 不涉及。
chunk_size	Integer	参数解释： 分段预计长度。 约束限制 不涉及。 取值范围： [0, 600]。 默认取值 500。

参数	参数类型	描述
title_level	Integer	参数解释： 标题层级深度。 约束限制 不涉及。 取值范围： [1, 10]。 默认取值 3。
combine_title	Boolean	参数解释： 是否要合并标题。 每一个分片都有一个标题属性，指是否合并分片的标题。标题有层级关系，合并标题就是将该分片的多级标题合并，例如标题1标题2标题3。不合并时，只会保留最小层级标题。 约束限制 不涉及。 取值范围： • false：保留最后一级。 • true：保存多标题组合。 默认取值 false。
merge_titles	Boolean	参数解释： 是否跨标题合并，不同标题段落文字较少时，会自动合并到指定的分段长度，有助于生成更全面的结果。 约束限制 不涉及。 取值范围： • true：跨标题合并。 • false：不跨标题合并。 默认取值 true。

表 3-1146 RagChunkParserConf

参数	参数类型	描述
chunk_method	String	参数解释： 切片类型。 约束限制 不涉及。 取值范围： - naive：通用。 - qa：问答。 - table：表格。 - book：书籍。 - laws：法律条文。 - one：直接作为一个切片。 默认取值 native。
auto_keywords	Integer	参数解释： 自动关键词提取。 约束限制 不涉及。 取值范围： [0, 32]。 默认取值 0。
auto_questions	Integer	参数解释： 自动问题提取。 约束限制 不涉及。 取值范围： [0, 10]。 默认取值 0。

参数	参数类型	描述
chunk_token_num	Integer	参数解释： 建议文本块大小。 约束限制 不涉及。 取值范围： [1, 2048]。 默认取值 512。
delimiter	Array of strings	参数解释： 分段标识符ID列表。 约束限制 不涉及。 取值范围： 支持中文句号、英文句号、中文感叹号、英文感叹号、中文问号、英文问号、中文逗号、英文逗号、空格、换行。 默认取值 /n。

请求示例

查询一个知识库详情。

```
{
  "method": "GET",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  }
}
```

响应示例

状态码：200

知识库详情。

```
{
  "knowledge_repo_id": "cea3eed887694fb9bec18790d87ed8df",
  "project_id": "787b9e18fc5511f0bebdfa163e5cee82",
  "display_name": "test2",
  "workspace_id": "default",
  "description": "test2",
  "type": "internal",
  "source": "KooSearch",
  "repo_type": "share",
  "size": 0,
  "max_size": 21474836480,
}
```



```
"remain_size" : 21429542375,
"creator" : "test_user",
"update_user_name" : "test_user",
"parse_conf" : {
  "ocr_enabled" : true,
  "image_enabled" : true,
  "header_footer_enabled" : true,
  "catalog_enabled" : true,
  "image_conf" : "IMAGE"
},
"split_conf" : {
  "split_mode" : "RULE",
  "separator_ids" : [ "period_zh", "period_en", "exclamation_mark_zh", "exclamation_mark_en",
"question_mark_zh", "question_mark_en" ],
  "rule_regex_id" : "default-rule-1",
  "chunk_size" : 500,
  "title_level" : 3,
  "combine_title" : true,
  "merge_titles" : true
},
"embedding_model" : "embedding-en",
"rerank_model" : "rerank-zh",
"icon" : "data:image/svg+xml;base64,xxxxxx",
"status" : "OPEN",
"create_time" : "2026-01-21 16:44:56",
"update_time" : "2026-01-21 16:44:56",
"share_scope" : "SELF"
}
```

状态码

状态码	描述
200	知识库详情。

错误码

请参见[错误码](#)。

3.17.1.1.6 删除知识库

功能介绍

 说明

软件版本为8.6.301，才支持此功能。

删除指定的知识库及其关联资源。

适用场景：

- 清理不再使用或已废弃的知识库。
- 在知识库配置错误或内容异常时进行重建。
- 业务调整导致知识库不再需要时释放存储资源。

URI

DELETE /v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1147 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
knowledge_repo_id	是	String	参数解释： 知识库的ID。 获取方式： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 知识库”。 3. 在知识库列表的“知识库ID”列，复制知识库ID。 约束限制： 必须为已创建且处于可用状态的知识库ID；不支持跨项目访问。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过64位字符。 默认取值： 不涉及。

表 3-1148 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1149 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1150 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 删除对象ID。 取值范围： 不涉及。

请求示例

删除一个知识库。

```
{
  "method": "DELETE",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  }
}
```

响应示例

状态码：200

删除知识库响应体。

```
{
  "id": "e4e302f124414597834ef7d4affbca4e"
}
```

状态码

状态码	描述
200	删除知识库响应体。

错误码

请参见[错误码](#)。

3.17.1.1.7 开启一个知识库

功能介绍

 说明

软件版本为8.6.301，才支持此功能。

启用指定知识库，使其进入可用状态。

适用场景：

被停用的知识库重新恢复服务。

URI

PUT /v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/start

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1151 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法 请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
knowledge_repo_id	是	String	参数解释： 知识库的ID。 获取方式： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 知识库”。 3. 在知识库列表的“知识库 ID”列，复制知识库ID。 约束限制： 不涉及。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过64位字符。 默认取值： 不涉及。

表 3-1152 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1153 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1154 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 知识库ID。 取值范围： 不涉及。

请求示例

启用知识库。

```
{
  "method" : "PUT",
  "url" : "https://api.example.com/v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/start",
  "headers" : {
    "Content-Type" : "application/json",
    "X-Auth-Token" : "TEST-TOKEN*****"
  }
}
```

响应示例

状态码：200

启用知识库响应体。

```
{
  "id" : "e4e302f124414597834ef7d4affbca4e"
}
```

状态码

状态码	描述
200	启用知识库响应体。

错误码

请参见[错误码](#)。

3.17.1.1.8 停用知识库

功能介绍

 说明

软件版本为8.6.301，才支持此功能。

停用知识库，停用后的知识库无法再被智能体或工作流关联，已关联的检索结果为空。

适用场景：

- 对知识库进行编辑、修改高级配置或删除前，需先停用知识库。
- 临时下线知识库，使其不参与已关联的智能体或工作流的检索流程。
- 暂时忽略知识库在智能体或工作流中的查询结果。

URI

PUT /v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/stop

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1155 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
knowledge_repo_id	是	String	参数解释： 知识库的ID。 获取方式： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 知识库”。 3. 在知识库列表的“知识库ID”列，复制知识库ID。 约束限制： 不涉及。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过64位字符。 默认取值： 不涉及。

表 3-1156 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1157 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1158 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 知识库ID。 取值范围： 不涉及。

请求示例

停用知识库。

```
{
  "method": "PUT",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/stop",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  }
}
```

响应示例

状态码：200

停用知识库响应体。

```
{
  "id": "e4e302f124414597834ef7d4affbca4e"
}
```

状态码

状态码	描述
200	停用知识库响应体。

错误码

请参见[错误码](#)。

3.17.1.1.9 检索知识库，命中测试

功能介绍

 说明

软件版本为8.6.301，才支持此功能。

提供单知识库检索能力，支持语义、关键词、混合及FAQ四种检索模式。

适用场景：

对已上传文档并解析成功的知识库进行检索测试和验证。

URI

POST /v1/{project_id}/agent-manager/knowledges/search-text

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1159 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

表 3-1160 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
offset	否	Integer	参数解释： 分页记录的起始位置偏移量。 约束限制： 必须为整数，且不超过10000。 取值范围： 0 至 10000（含）。 默认取值： 0。
limit	否	Integer	参数解释： 每一页的数量。 约束限制： 必须为正整数，且不超过系统最大返回限制。 取值范围： 1 至 1000（含）。 默认取值： 10。

请求参数

表 3-1161 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 3-1162 请求 Body 参数

参数	是否必选	参数类型	描述
knowledge_repo_id	是	String	参数解释： 知识库ID。 约束限制 不涉及。 取值范围： 不涉及。
query	是	String	参数解释： 知识库命中测试输入。 约束限制 不涉及。 取值范围： 不涉及。
search_mode	是	String	参数解释： 检索策略模式。 约束限制 不涉及。 取值范围： • doc：语义检索。 • keyword：关键词检索。 • mix：混合检索。 • faq：FAQ检索。 默认取值 doc。

响应参数

状态码：200

表 3-1163 响应 Body 参数

参数	参数类型	描述
total	Integer	参数解释： 结果总数。 取值范围： 不涉及。

参数	参数类型	描述
search_result_list	Array of ChatReferenceInfo objects	参数解释： 命中文档列表。 取值范围： 不涉及。

表 3-1164 ChatReferenceInfo

参数	参数类型	描述
file_id	String	参数解释： 文件/FAQ的ID。 取值范围： 不涉及。
chunk_id	String	参数解释： 分片ID。 取值范围： 不涉及。
title	String	参数解释： 标题。 取值范围： 不涉及。
content	String	参数解释： 文本内容。 取值范围： 不涉及。
update_date_time	String	参数解释： 更新时间（以毫秒为单位）。 取值范围： 不涉及。
doc_type	String	参数解释： 文档类型。 取值范围： - doc：文档。 - faq：问答。

参数	参数类型	描述
file_path	String	参数解释： 文档归档路径。 取值范围： 不涉及。
category	String	参数解释： 文档目录，单值，对应目录树中的叶子节点。 取值范围： 不涉及。
tags	Array of strings	参数解释： 文档标签列表。 取值范围： 不涉及。
score	Float	参数解释： ES打分。 取值范围： 不涉及。
subtitle	String	参数解释： 文档子标题。 取值范围： 不涉及。
repo_id	String	参数解释： 知识库标识。 取值范围： 不涉及。
image_ids	Array of strings	参数解释： 切片中图片的ID列表。 取值范围： 不涉及。
image_paths	Array of strings	参数解释： 切片中图片的访问路径列表。 取值范围： 不涉及。

请求示例

命中测试请求体。

```
{
  "method": "POST",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/search-text?offset=0&limit=1",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  },
  "body": {
    "knowledge_repo_id": "329e4e5e61e14e48b775d43fa179772e",
    "query": "test_query",
    "search_mode": "doc"
  }
}
```

响应示例

状态码：200

知识库检索响应体。

```
{
  "total": 11,
  "search_result_list": [ {
    "file_id": "34034186f5d657ffcf0f5f64031bb3c1",
    "chunk_id": "6d5c489f08a245fb830582a74ea6a4d9",
    "title": "语文知识.docx",
    "content": "A. 他操作计算机非常熟练，已经到了为所欲为的程度。\\n B. 这部小说情节曲折，人物形象生动，确实引人入胜。\\n C. 同学们经常向老师请教问题，这种不耻下问的精神值得提倡。\\n D. 王小刚同学心直口快，对有缺点的同学总是诚惶诚恐地提出批评。\\n答案：B\\n 解析：\\n A项，“为所欲为”指想干什么就干什么（多含贬义），用于操作熟练不恰当，可改为“得心应手”。\\n C项，“不耻下问”指不以向地位、学识不如自己的人请教为耻。学生向老师请教，不能算“下问”，对象错误。\\n D项，“诚惶诚恐”形容非常小心谨慎以至于害怕不安的样子。与“心直口快”、“提出批评”的语境矛盾。\\n B项，“引人入胜”指吸引人进入美妙的境界，多指风景或文艺作品非常吸引人，使用正确。",
    "update_date_time": "1768479994938",
    "file_path": "uni-search/files/b25446daeb1a41a7953c5deba2b2677a/8ce3a2ba-942b-47c9-9acf-b07aa7cbf872/9e244a5d-3eb7-4925-b8a6-2dcc2826e20e/34034186f5d657ffcf0f5f64031bb3c1/语文知识(新).docx",
    "score": 0.028259277,
    "subtitle": "语文知识（新）\\n1 第一部分：基础知识 1.2 下列句子中，加点的成语使用恰当的一项是（ ）",
    "repo_id": "9e244a5d-3eb7-4925-b8a6-2dcc2826e20e"
  } ]
}
```

状态码

状态码	描述
200	知识库检索响应体。

错误码

请参见[错误码](#)。

3.17.1.2 知识库文档规则管理

3.17.1.2.1 创建知识库分层规则

功能介绍

 说明

软件版本为8.6.301，才支持此功能。

创建知识库分层规则。

适用场景：

创建解析规则用于文档拆分时的规则拆分模式。在上传解析规则之后，会返回一个规则ID，通过此ID引用到对应解析规则。

URI

POST /v1/{project_id}/agent-manager/knowledges/rule-regex

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1165 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

表 3-1166 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1167 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 3-1168 请求 Body 参数

参数	是否必选	参数类型	描述
rule_regexs	是	Array of strings	参数解释： 知识分层规则。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1169 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 知识分层规则ID。 取值范围： 不涉及。

请求示例

创建知识库分层规则请求体。

```
{
  "method": "POST",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/rule-regex",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  },
  "body": {
    "rule_regexs": [ "^\\d{1,5}\\." ]
  }
}
```

响应示例

状态码：200

创建知识库分层规则响应体。

```
{
  "id": "2011773132075782146"
}
```

状态码

状态码	描述
200	创建知识库分层规则响应体。

错误码

请参见[错误码](#)。

3.17.1.2.2 查询知识库分层规则列表

功能介绍

说明

软件版本为8.6.301，才支持此功能。

查询知识库分层规则列表。

适用场景：

新建知识库时，用户可查询分层规则列表，选择合适的文档切分策略。

URI

GET /v1/{project_id}/agent-manager/knowledges/rule-regex

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1170 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

表 3-1171 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考获取工作区ID。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
repo_id	否	String	参数解释： 知识库的ID。 获取方式： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 知识库”。 3. 在知识库列表的“知识库 ID”列，复制知识库ID。 约束限制： 不涉及。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过100位字符。 默认取值： 不涉及。

请求参数

表 3-1172 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1173 响应 Body 参数

参数	参数类型	描述
count	Integer	参数解释： 结果总数。 取值范围： 不涉及。
rule_list	Array of KnowledgeSegmentRule objects	参数解释： 规则列表。 取值范围： 不涉及。

表 3-1174 KnowledgeSegmentRule

参数	参数类型	描述
id	String	参数解释： 知识分层规则ID。 取值范围： 不涉及。

参数	参数类型	描述
rule_regexs	Array of strings	参数解释： 知识分层规则。 取值范围： 不涉及。
project_id	String	参数解释： 租户项目ID。 取值范围： 不涉及。
creator	String	参数解释： 规则创建者用户名。 取值范围： 不涉及。
creator_id	String	参数解释： 规则创建者用户ID。 取值范围： 不涉及。
create_time	String	参数解释： 规则创建时间。 取值范围： 不涉及。 说明 当前接口返回的时间格式为yyyy-MM-dd HH:mm:ss，最新版本已统一采用13位毫秒级时间戳，建议不要使用，防止升级后出现兼容问题。
update_time	String	参数解释： 规则更新时间。 取值范围： 不涉及。 说明 当前接口返回的时间格式为yyyy-MM-dd HH:mm:ss，最新版本已统一采用13位毫秒级时间戳，建议不要使用，防止升级后出现兼容问题。

请求示例

查询知识库分层规则列表。

```
{
  "method": "GET",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/rule-regex",
```

```
"headers" : {  
  "Content-Type" : "application/json",  
  "X-Auth-Token" : "TEST-TOKEN*****"  
}
```

响应示例

状态码：200

知识库分层规则列表响应体。

```
{  
  "count" : 2,  
  "rule_list" : [ {  
    "id" : "default-rule-1",  
    "rule_regexs" : [ "^第([零〇一二三四五六七八九十百千万1-9]{1,7})章", "^第([零〇一二三四五六七八九十百  
    千万1-9]{1,7})节", "^第([零〇一二三四五六七八九十百千万1-9]{1,7})条" ],  
    "project_id" : ""  
  }, {  
    "id" : "2011765607326633986",  
    "rule_regexs" : [ "^\\d{1,5}\\." ],  
    "project_id" : "787b9e18fc5511f0bebdfa163e5cee82",  
    "creator" : "user_test",  
    "create_time" : "2025-12-02 19:31:54",  
    "update_time" : "2025-12-02 19:31:54"  
  } ]  
}
```

状态码

状态码	描述
200	知识库分层规则列表响应体。

错误码

请参见[错误码](#)。

3.17.1.2.3 修改知识库分层规则

功能介绍

 说明

软件版本为8.6.301，才支持此功能。

修改知识库分层规则。

适用场景：

允许用户对已创建的知识库分层规则进行动态调整，以优化文档的切分效果。

 说明

修改分层规则仅影响后续新导入的文档，已入库文档不会自动重新切分；如需对历史文档应用新规则，请对指定历史文档重新切分。

URI

PUT /v1/{project_id}/agent-manager/knowledges/rule-regex/{id}

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1175 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考获取项目ID。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
id	是	String	参数解释： 知识库分层规则ID。 获取方式： - 调用创建知识库分层规则接口并成功创建后，接口返回结果中的id字段。 - 调用查询知识库分层规则列表接口获取返回列表中的id字段。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 3-1176 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1177 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 3-1178 请求 Body 参数

参数	是否必选	参数类型	描述
rule_regexs	是	Array of strings	参数解释： 知识分层规则。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1179 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 知识分层规则ID。 取值范围： 不涉及。

请求示例

修改知识库分层请求体。

```
{
  "method": "PUT",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/rule-regex/{id}",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  },
  "body": {
    "rule_regexs": [ "test_regular" ]
  }
}
```

响应示例

状态码：200

修改知识库分层规则响应体。

```
{
  "id": "2011773132075782146"
}
```

状态码

状态码	描述
200	修改知识库分层规则响应体。

错误码

请参见[错误码](#)。

3.17.1.2.4 删除知识库分层规则

功能介绍

说明

软件版本为8.6.301，才支持此功能。

删除知识库分层规则。

适用场景：

- 当前分层规则已不再使用，需清理冗余配置。
- 规则存在错误或冲突，需移除后重新创建。

URI

DELETE /v1/{project_id}/agent-manager/knowledges/rule-regex/{id}

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1180 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
id	是	String	参数解释： 知识库分层规则ID。 获取方式： - 调用创建知识库分层规则接口并成功创建后，接口返回结果中的<i>id</i>字段。 - 调用查询知识库分层规则列表接口获取返回列表中的<i>id</i>字段。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 3-1181 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1182 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1183 响应 Body 参数

参数	参数类型	描述
id	String	参数解释： 删除对象ID。 取值范围： 不涉及。

请求示例

删除知识分层规则。

```
{
  "method": "DELETE",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/rule-regex/{id}",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  }
}
```

响应示例

状态码：200

删除知识分层规则响应体。

```
{
  "id" : "2011773132075782146"
}
```

状态码

状态码	描述
200	删除知识分层规则响应体。

错误码

请参见[错误码](#)。

3.17.1.3 知识库知识文档管理

3.17.1.3.1 在知识库中上传文档

功能介绍

 说明

软件版本为8.6.301，才支持此功能。

在知识库中上传文档。

支持格式：

psd, tiff, bmp, gif, csv, tif, ico, md, jpeg, jpg, xlsx, pcx, dps, png, webp, ofd, docx, et, pptx, txt, pdf, ppt, doc, wps, xls。

适用场景：

- 向知识库中新增文档以构建内容库。
- 知识库文档需更新时，可重新上传同名文档以覆盖原有内容。

URI

POST /v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/files

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1184 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考获取项目ID。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
knowledge_repo_id	是	String	参数解释： 知识库的ID。 获取方式： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 知识库”。 3. 在知识库列表的“知识库 ID”列，复制知识库ID。 约束限制： 不涉及。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过100位字符。 默认取值： 不涉及。

表 3-1185 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1186 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 3-1187 FormData 参数

参数	是否必选	参数类型	描述
file	是	File	参数解释： 待上传的文档文件。 约束限制： - 支持格式：psd，tiff，bmp，gif，csv，tif，ico，md，jpeg，jpg，xlsx，pcx，dps，png，webp，ofd，docx，et，pptx，txt，pdf，ppt，doc，wps，xls。 - 文档大小：单个文件大小不得超过60MB。 取值范围： 有效的二进制文件流，符合上述格式与大小要求。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1188 响应 Body 参数

参数	参数类型	描述
file_id	String	参数解释： 文件ID。 取值范围： 不涉及。

请求示例

```
null

{
  "method": "POST",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/files",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  },
  "body": {
    "form-data": {
      "file": "example_document.docx"
    }
  }
}
```

```
}  
}
```

响应示例

状态码：200

文档上传响应体。

```
{  
  "file_id" : "529b5de500a02fe74b4480d101930a4b"  
}
```

状态码

状态码	描述
200	文档上传响应体。

错误码

请参见[错误码](#)。

3.17.1.3.2 查询知识库中的文件列表

功能介绍

说明

软件版本为8.6.301，才支持此功能。

根据查询条件查询知识库中的文件列表。

适用场景：

查看知识库中已上传的文档，提供根据文档名、文件类型、文件状态等筛选条件。

URI

GET /v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/files

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1189 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法 请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
knowledge_repo_id	是	String	参数解释： 知识库的ID。 获取方式： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 知识库”。 3. 在知识库列表的“知识库 ID”列，复制知识库ID。 约束限制： 不涉及。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过64位字符。 默认取值： 不涉及。

表 3-1190 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
offset	否	Integer	参数解释： 分页记录的起始位置偏移量。 约束限制： 必须为整数，且不超过65534。 取值范围： 0 至 65534（含）。 默认取值： 0。
limit	否	Integer	参数解释： 每一页的数量。 约束限制： 必须为正整数，且不超过系统最大返回限制。 取值范围： 1 至 1000（含）。 默认取值： 10。
name	否	String	参数解释： 文件名称。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
type	否	String	参数解释： 文件类型。 约束限制： 不涉及。 取值范围： psd, tiff, bmp, gif, csv, tif, ico, md, jpeg, jpg, xlsx, pcx, dps, png, webp, ofd, docx, et, pptx, txt, pdf, ppt, doc, wps, xls。 默认取值： 所有类型。
status	否	String	参数解释： 文件状态。 约束限制： 不涉及。 取值范围： • SUCCESS：成功。 • RUNNING：执行中。 • PENDING：初始化。 • ERROR：失败。 默认取值： 全部。

请求参数

表 3-1191 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1192 响应 Body 参数

参数	参数类型	描述
count	Integer	参数解释： 结果总数。 取值范围： 不涉及。
file_info_list	Array of FileInfo objects	参数解释： 文件信息列表。 取值范围： 不涉及。

表 3-1193 FileInfo

参数	参数类型	描述
file_id	String	参数解释： 文档ID。 取值范围： 不涉及。

参数	参数类型	描述
project_id	String	参数解释： 租户唯一标识。 取值范围： 不涉及。
file_name	String	参数解释： 文件名称。 取值范围： 不涉及。
file_type	String	参数解释： 文件类型。 取值范围： psd, tiff, bmp, gif, csv, tif, ico, md, jpeg, jpg, xlsx, pcx, dps, png, webp, ofd, docx, et, pptx, txt, pdf, ppt, doc, wps, xls。
file_size	Long	参数解释： 文件大小（ bytes ）。 取值范围： 不涉及。
file_status	String	参数解释： 文档解析任务状态。 取值范围： • SUCCESS：成功。 • RUNNING：执行中。 • PENDING：初始化。 • ERROR：失败。 • IMPORT_EXCEPTION：导入异常。 • FILE_ENCODING_ERROR：编码错误。
failure_reason	String	参数解释： 当文件解析失败时，用于表示失败原因。 取值范围： 不涉及。
metadata	String	参数解释： 扩展参数。 取值范围： 不涉及。

参数	参数类型	描述
create_time	String	参数解释： 创建时间。 取值范围： 不涉及。 说明 当前接口返回的时间格式为 yyyy-MM-dd HH:mm:ss，最新版本已统一采用13位毫秒级时间戳，建议不要使用，防止升级后出现兼容问题。
update_time	String	参数解释： 更新时间。 取值范围： 不涉及。 说明 当前接口返回的时间格式为 yyyy-MM-dd HH:mm:ss，最新版本已统一采用13位毫秒级时间戳，建议不要使用，防止升级后出现兼容问题。

请求示例

查询知识库中的文件列表。

```
{
  "method": "GET",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/files?offset=0&limit=10",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  }
}
```

响应示例

状态码：200

知识库中的文件列表。

```
{
  "count": 1,
  "file_info_list": [ {
    "file_id": "9f486ecac4e1c95318f2b6aeb84d8830",
    "project_id": "3ee5ceb06b7240b7ae058c196d4b3344",
    "file_name": "测试.txt",
    "file_type": "txt",
    "file_size": 9855,
    "file_status": "SUCCESS",
    "create_time": "2026-01-27 12:09:40",
    "update_time": "2026-01-27 12:09:40"
  } ]
}
```

状态码

状态码	描述
200	知识库中的文件列表。

错误码

请参见[错误码](#)。

3.17.1.3.3 查询知识库中指定的文档信息

功能介绍

说明

软件版本为8.6.301，才支持此功能。

查询知识库中指定的文档信息。

适用场景：

查看指定文档的元信息，如文件名称、文件格式、文件大小、上传时间及更新时间。

URI

GET /v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/files/{file_id}

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1194 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
file_id	是	String	参数解释： 知识文档ID。 获取方式： - 通过在知识库中上传文档接口成功时返回。 - 通过查询知识库中的文件列表接口返回。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
knowledge_repo_id	是	String	参数解释： 知识库的ID。 获取方式： - 进入Versatile智能体平台。 - 在左侧导航选择“开发中心 > 知识库”。 - 在知识库列表的“知识库ID”列，复制知识库ID。 约束限制： 不涉及。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过64位字符。 默认取值： 不涉及。

表 3-1195 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1196 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1197 响应 Body 参数

参数	参数类型	描述
file_id	String	参数解释： 文档ID。 取值范围： 不涉及。
project_id	String	参数解释： 租户唯一标识。 取值范围： 不涉及。
file_name	String	参数解释： 文件名称。 取值范围： 不涉及。
file_type	String	参数解释： 文件类型。 取值范围： psd, tiff, bmp, gif, csv, tif, ico, md, jpeg, jpg, xlsx, pcx, dps, png, webp, ofd, docx, et, pptx, txt, pdf, ppt, doc, wps, xls。
file_size	Long	参数解释： 文件大小（ bytes ）。 取值范围： 不涉及。
file_status	String	参数解释： 文档解析任务状态。 取值范围： • SUCCESS：成功。 • RUNNING：执行中。 • PENDING：初始化。 • ERROR：失败。 • IMPORT_EXCEPTION：导入异常。 • FILE_ENCODING_ERROR：编码错误。

参数	参数类型	描述
failure_reason	String	参数解释： 当文件解析失败时，用于表示失败原因。 取值范围： 不涉及。
metadata	String	参数解释： 扩展参数。 取值范围： 不涉及。
create_time	String	参数解释： 创建时间。 取值范围： 不涉及。 说明 当前接口返回的时间格式为yyyy-MM-dd HH:mm:ss，最新版本已统一采用13位毫秒级时间戳，建议不要使用，防止升级后出现兼容问题。
update_time	String	参数解释： 更新时间。 取值范围： 不涉及。 说明 当前接口返回的时间格式为yyyy-MM-dd HH:mm:ss，最新版本已统一采用13位毫秒级时间戳，建议不要使用，防止升级后出现兼容问题。

请求示例

获取知识库中的指定文档信息。

```
{
  "method": "GET",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/files/{file_id}",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  }
}
```

响应示例

状态码：200

文件信息。

```
{
  "file_id": "9f486ecac4e1c95318f2b6aeb84d8830",
  "project_id": "3ee5ceb06b7240b7ae058c196d4b3344",
  "file_name": "测试切片提取.txt",
  "file_type": "txt",
  "file_size": 9855,
  "file_status": "SUCCESS",
  "create_time": "2026-01-27 12:09:40",
  "update_time": "2026-01-27 12:09:40"
}
```

状态码

状态码	描述
200	文件信息。

错误码

请参见[错误码](#)。

3.17.1.3.4 从知识库中批量删除文档

功能介绍

 说明

软件版本为8.6.301，才支持此功能。

从知识库中批量删除文档。

适用场景：

- 删除因上传错误、内容不合规或格式异常导致的错误文档。
- 批量清理不再需要的文档，释放知识库存储资源。

URI

POST /v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/files/
batch-delete

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1198 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法 请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
knowledge_repo_id	是	String	参数解释： 知识库的ID。 获取方式： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 知识库”。 3. 在知识库列表的“知识库 ID”列，复制知识库ID。 约束限制： 必须为已创建且处于可用状态的知识库ID；不支持跨项目访问。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过64位字符。 默认取值： 不涉及。

表 3-1199 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1200 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 3-1201 请求 Body 参数

参数	是否必选	参数类型	描述
file_ids	是	Array of strings	参数解释： 待删除文件ID列表。 约束限制： 数组大小： [1, 1000]。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码： 200

表 3-1202 响应 Body 参数

参数	参数类型	描述
total_count	Integer	参数解释： 总数量。 取值范围： 不涉及。
deleted_count	Integer	参数解释： 删除成功数量。 取值范围： 不涉及。

请求示例

从知识库中批量删除文档。

```
{
  "method": "POST",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/files/
batch-delete",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  },
  "body": {
    "file_ids": [ "ea321f03acb33b215c8c83734fb6ce58", "34034186f5d657ffc0f5f64031bb3c1" ]
  }
}
```

响应示例

状态码：200

批量删除文件响应体。

```
{
  "total_count" : 2,
  "deleted_count" : 2
}
```

状态码

状态码	描述
200	批量删除文件响应体。

错误码

请参见[错误码](#)。

3.17.1.4 知识库任务管理

3.17.1.4.1 创建知识库任务

功能介绍

说明

软件版本为8.6.301，才支持此功能。

创建知识库任务，知识文件重新解析。

适用场景：

- 文档解析失败，需重新触发解析任务场景。
- 知识库高级配置（如模型配置、解析配置、拆分配置等）被修改后，需对文档重新进行解析场景。

URI

POST /v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/tasks

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1203 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法 请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
knowledge_repo_id	是	String	参数解释： 知识库的ID。 获取方式： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 知识库”。 3. 在知识库列表的“知识库 ID”列，复制知识库ID。 约束限制： 必须为已创建且处于可用状态的知识库ID；不支持跨项目访问。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过64位字符。 默认取值： 不涉及。

表 3-1204 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1205 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 3-1206 请求 Body 参数

参数	是否必选	参数类型	描述
task_type	是	String	参数解释： 任务类型。 约束限制： 不涉及。 取值范围： - RETRY_FILES：部分文件重试。 - QA：QA生成。 默认取值： 不涉及。
file_ids	否	Array of strings	参数解释： 文件ID列表。 约束限制： 数组长度：[1, 1000]。 取值范围： ID长度需在1到64个字符之间，只能包含字母、数字、下划线_和连字符-。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1207 响应 Body 参数

参数	参数类型	描述
total_count	Integer	参数解释： 需要创建任务数量。 取值范围： 不涉及。
created_count	Integer	参数解释： 成功创建任务数量。 取值范围： 不涉及。

请求示例

创建知识库任务请求体。

```
{
  "method": "POST",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/tasks",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  },
  "body": {
    "task_type": "RETRY_FILES",
    "file_ids": [ "34034186f5d657ffc0f5f64031bb3c1" ]
  }
}
```

响应示例

状态码：200

创建知识库任务响应体。

```
{
  "total_count": 1,
  "created_count": 1
}
```

状态码

状态码	描述
200	创建知识库任务响应体。

错误码

请参见[错误码](#)。

3.17.1.4.2 查询知识库任务

功能介绍

说明

软件版本为8.6.301，才支持此功能。

根据条件查询单个知识库的任务列表。

适用场景：

实时查看知识库文档解析任务的当前状态，便于追踪处理进度。

URI

GET /v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/tasks

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1208 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法 请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
knowledge_repo_id	是	String	参数解释： 知识库的ID。 获取方式： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 知识库”。 3. 在知识库列表的“知识库 ID”列，复制知识库ID。 约束限制： 必须为已创建且处于可用状态的知识库ID；不支持跨项目访问。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过64位字符。 默认取值： 不涉及。

表 3-1209 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
offset	否	Integer	参数解释： 分页记录的起始位置偏移量。 约束限制： 必须为整数，且不超过10000。 取值范围： 0 至 10000（含）。 默认取值： 0。
limit	否	Integer	参数解释： 每一页的数量。 约束限制： 必须为正整数，且不超过系统最大返回限制。 取值范围： 1 至 1000（含）。 默认取值： 10。
task_type	否	String	参数解释： 任务类型。 约束限制： 不涉及。 取值范围： - QA：QA生成任务。 - RETRY_FILES：重试任务。 默认取值： 全部。

参数	是否必选	参数类型	描述
task_status	否	String	参数解释： 任务状态。 约束限制： 不涉及。 取值范围： • SUCCESS：成功。 • RUNNING：执行中。 • PENDING：初始化。 • ERROR：失败。 • IMPORT_EXCEPTION：导入异常。 • FILE_ENCODING_ERROR：编码错误。 默认取值： 全部。
file_name	否	String	参数解释： 文件名称。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 3-1210 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。通过调用IAM服务获取用户Token接口获取（响应消息头中X-Subject-Token的值）。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1211 响应 Body 参数

参数	参数类型	描述
total	Integer	参数解释： 总数量。 取值范围： 不涉及。
fail_count	Integer	参数解释： 失败任务数量。 取值范围： 不涉及。
success_count	Integer	参数解释： 成功任务数量。 取值范围： 不涉及。
running_count	Integer	参数解释： 正在运行任务数量。 取值范围： 不涉及。

参数	参数类型	描述
pending_count	Integer	参数解释： 正在排队任务数量。 取值范围： 不涉及。
tasks	Array of KnowledgeTaskInfo objects	参数解释： 知识库任务对象。 取值范围： 不涉及。

表 3-1212 KnowledgeTaskInfo

参数	参数类型	描述
id	String	参数解释： 任务ID。 取值范围： 不涉及。
name	String	参数解释： 文档名。 取值范围： 不涉及。
type	String	参数解释： 任务类型。 取值范围： - RETRY_FILES：部分文件重试。 - QA：QA生成。
status	String	参数解释： 任务状态。 取值范围： - SUCCESS：成功。 - RUNNING：执行中。 - PENDING：初始化。 - ERROR：失败。 - IMPORT_EXCEPTION：导入异常。 - FILE_ENCODING_ERROR：编码错误。

参数	参数类型	描述
process	Float	参数解释： 任务进度。 取值范围： [0, 1]。
create_time	Long	参数解释： 创建时间（以毫秒为单位）。 取值范围： 不涉及。
task_desc	String	参数解释： 任务描述。 取值范围： 不涉及。

请求示例

```
null

{
  "method": "GET",
  "url": "https://api.example.com/v1/{project_id}/agent-manager/knowledges/{knowledge_repo_id}/tasks",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  }
}
```

响应示例

状态码：200
查询知识库任务响应体。

```
{
  "total": 1,
  "fail_count": 0,
  "success_count": 1,
  "running_count": 0,
  "pending_count": 0,
  "tasks": [ {
    "id": "97a40c91-0bb3-494f-a0f3-ae86fe85be2",
    "type": "RETRY_FILES",
    "status": "SUCCESS",
    "process": 1,
    "create_time": 1768478143062,
    "task_desc": "success"
  } ]
}
```

状态码

状态码	描述
200	查询知识库任务响应体。

错误码

请参见[错误码](#)。

3.17.2 运行态

3.17.2.1 工作流/智能体

3.17.2.1.1 调用工作流应用

功能介绍

该接口用于运行场景化应用，支持在指定的项目、工作流和对话上下文中执行工作流逻辑。接口支持流式响应模式，可以根据需要返回增量执行结果，适用于实时交互场景。

适用场景：

- 在项目中运行预定义的工作流。
- 支持调试模式和发布模式，适用于不同开发和生产环境。
- 支持流式响应，适用于需要实时反馈的场景（如聊天机器人、实时数据分析等）。

URI

POST /v1/{project_id}/workflows/{workflow_id}/conversations/{conversation_id}

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1213 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法 请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
workflow_id	是	String	参数解释： 工作流应用的ID。 获取方式： 1. 登录ModelArts Studio平台，在首页单击“AGENT开发”，进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 应用管理 > 工作流应用”。 3. 在待复制ID的工作流应用卡片上，单击“... > 复制ID”。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
conversation_id	是	String	参数解释： 会话ID，每个会话的唯一标识符。用户可将会话ID设置为无分隔符UUID格式的任何值，例如“123e4567e89b12d3a456426614174000”，无需在其他地方获取。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

表 3-1214 Query 参数

参数	是否必选	参数类型	描述
workspace_id	否	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
version	否	String	参数解释： 发布版本号。 获取方式： 1. 登录ModelArts Studio平台，在首页单击“AGENT开发”，进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 应用管理 > 工作流应用”。 3. 选择需要查找的工作流应用。 4. 在工作流界面右上角，单击“发布历史”，获取ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求参数

表 3-1215 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json
X-Invoke-Mode	否	String	参数解释： 该参数用于标识工作流应用运行的模式。 约束限制： 不涉及。 取值范围： • X-Invoke-Mode的值为 debug时，工作流应用的运行模式为调试模式。调试模式会生成日志、详细的执行步骤，便于排查问题。 • X-Invoke-Mode的值为 published时，工作流应用的运行模式为发布模式。 默认取值： published。
stream	否	Boolean	参数解释： 是否开启流式调用。 • 当stream为true时，服务器以流式方式逐步返回结果，适合需要实时反馈的场景。 • 当stream为false时，服务器在处理完成后一次性返回结果，适合处理较小数据或不需要实时反馈的场景。 约束限制： 不涉及。 取值范围： • true：开启。 • false：不开启。 默认取值： true。

表 3-1216 请求 Body 参数

参数	是否必选	参数类型	描述
inputs	是	Map<String,Object>	参数解释： 用户提出的问题，作为运行工作流的输入，与 workflow_start 节点输入参数对应。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
plugin_configs	否	Array of PluginConfig objects	参数解释： 插件配置信息。 约束限制： 不涉及。 取值范围： 当 workflow 关联插件节点，并且插件是“用户级鉴权”时，需要配置对应的鉴权信息。其他情况该参数无需传值，plugin_configs 传空数组。 默认取值： 不涉及。

表 3-1217 PluginConfig

参数	是否必选	参数类型	描述
plugin_id	否	String	参数解释： 插件ID。 获取方式： 1. 登录ModelArts Studio平台，在首页单击“AGENT开发”，进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 组件库 > 我的插件”。 3. 在待复制ID的插件卡片上，单击“... > 复制ID”。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
config	否	Map<String,String>	参数解释： 配置插件信息。当 workflow 关联插件节点，并且插件是“用户级鉴权”时，需要在此配置对应的鉴权信息。例如，针对如下插件，config 可以配成：{"key2": "value"}。其他情况该参数无需传值，plugin_configs 传空数组即可。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1218 响应 Body 参数

参数	参数类型	描述
event	Map<String,Object>	参数解释： 工作流最终输出内容表示工作流运行。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
data	Array of Message objects	参数解释： 工作流助手回复内容。例如，提问器节点问题消息。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
status	Map<String,Object>	参数解释： 状态信息。 约束限制： 不涉及。 取值范围： 状态码。 默认取值： 不涉及。
start_time	Long	参数解释： 开始时间。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	参数类型	描述
end_time	Long	参数解释： 结束时间。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

表 3-1219 Message

参数	参数类型	描述
role	String	参数解释： 会话角色。 约束限制： 不涉及。 取值范围： - user：用户输入的消息，包括提示词和上下文信息。 - assistant：模型生成的回复内容。 默认取值： 不涉及。
content	String	参数解释： 会话内容。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求示例

```
{
  "method": "POST",
  "url": "https://api.example.com/v1/12345/workflows/67890/conversations/67890",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token":
      "MIINRwYJKoZIhvcNAQcCoIINODCCDTQCAQEExDTALBglghkgBZQMEAgEwgguVBgkqhkiG...",
    "stream": true
  }
}
```

```
},
"body": {
  "inputs": {
    "query": "你好"
  },
  "plugin_configs": [ {
    "plugin_id": "xxxxxxx",
    "config": {
      "key": "value"
    }
  } ]
}
```

响应示例

状态码：200

成功响应。

```
{
  "event": "workflow_finished",
  "data": {
    "status": {
      "code": 1,
      "desc": "succeeded"
    },
    "outputs": {
      "responseContent": "《朝花夕拾》是关于某篇文章、某个人物或某个主题，欢迎继续提问。"
    },
    "start_time": 1757729064202,
    "end_time": 1757729120126
  }
}
```

状态码

状态码	描述
200	成功响应。

错误码

请参见[错误码](#)。

3.17.2.1.2 调用智能体应用

功能介绍

该接口用于运行知识型智能体应用，支持单智能体和多智能体，支持在指定的项目、智能体和对话上下文中执行智能体逻辑。接口支持流式响应模式，可以根据需要返回增量执行结果，适用于实时交互场景。

适用场景：

- 在项目中运行预定义的知识型智能体应用。
- 支持调试模式和发布模式，适用于不同开发和生产环境。
- 支持流式响应，适用于需要实时反馈的场景（如聊天机器人、实时数据分析等）。

URI

POST /v1/{project_id}/agents/{agent_id}/conversations/{conversation_id}

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1220 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法 请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
agent_id	是	String	参数解释： 智能体应用ID。 获取方式： 1. 登录ModelArts Studio平台，在首页单击“AGENT开发”，进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 应用管理 > 单智能体应用”或选择“开发中心 > 应用管理 > 多智能体应用”。 3. 在待复制ID的智能体应用卡片上，单击“... > 复制ID”。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
conversation_id	是	String	参数解释： 会话ID，每个会话的唯一标识符。用户可将会话ID设置为无分隔符UUID格式的任何值，例如“123e4567e89b12d3a456426614174000”，无需在其他地方获取。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

表 3-1221 Query 参数

参数	是否必选	参数类型	描述
workspace_id	否	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
version	否	String	参数解释： 发布版本号。 获取方式： 1. 登录ModelArts Studio平台，在首页单击“AGENT开发”，进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 应用管理 > 单智能体应用”或选择“开发中心 > 应用管理 > 多智能体应用”。 3. 选择需要查找的智能体应用。 4. 在智能体界面右上角，单击“发布历史”，获取ID。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
type	否	String	参数解释： 该参数允许调用者指定智能体应用的执行类型，支持不同的执行方式和返回模式。 约束限制： 不涉及。 取值范围： • type为controller时，为多智能体。 • type为agent时，为单智能体。 默认取值： agent。

请求参数

表 3-1222 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json
X-Invoke-Mode	否	String	参数解释： 该参数用于标识智能体应用运行的模式。 约束限制： 不涉及。 取值范围： - X-Invoke-Mode的值为 debug时，智能体应用的运行模式为调试模式。调试模式会生成日志、详细的执行步骤，便于排查问题。 - X-Invoke-Mode的值为 published时，智能体应用的运行模式为发布模式。 默认取值： published。

参数	是否必选	参数类型	描述
stream	否	Boolean	参数解释： 是否开启流式调用。当前智能体应用只支持流式调用。 - 当stream为true时，服务器以流式方式逐步返回结果，适合需要实时反馈的场景。 - 当stream为false时，服务器在处理完成后一次性返回结果，适合处理较小数据或不需要实时反馈的场景。 约束限制： 不涉及。 取值范围： - true：开启。 - false：不开启。 默认取值： true。

表 3-1223 请求 Body 参数

参数	是否必选	参数类型	描述
inputs	是	Map<String,Object>	参数解释： 用户提出的问题，作为运行工作流的输入，与工作流开始节点输入参数对应。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1224 响应 Body 参数

参数	参数类型	描述
data	String	当请求参数“stream”值为“true”时，智能体的消息以流式形式返回。生成的内容以增量的方式逐步发送回来，每个data字段均包含一部分生成的内容，直到所有data返回，响应结束。
event	String	参数解释： 数据单元类型。 约束限制： 不涉及。 取值范围： - start：开始节点，表示开始调用模型进行会话。 - message：消息节点，表示模型返回的消息。 - plugin_start：插件调用请求节点，表示调用插件的请求信息。 - plugin_end：插件调用响应节点，表示调用插件的响应信息。 - statistic_data：执行数据节点，包含本次调用的耗时信息。 - summary_response：消息总结节点，包含本次调用的全量响应信息。 - done：流式调用结束节点，表示流式响应结束。 默认取值： 不涉及。
content	Object	参数解释： 消息块内容。“event”参数类型不同，内容结构不同。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	参数类型	描述
createdTime	Long	参数解释： 消息块返回的时间戳。例如，1733817348963。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
latency	latency object	参数解释： 耗时。 约束限制： 不涉及。 取值范围： - plugin： 插件调用耗时。 - model： 模型调用耗时。 - overall： 总耗时。 默认取值： 不涉及。
plugin	plugin object	参数解释： 插件请求信息。 约束限制： 不涉及。 取值范围： - name： 插件名。 - arguments： 插件入参名。 默认取值： 不涉及。

表 3-1225 latency

参数	参数类型	描述
plugin	Long	插件调用耗时。
model	Long	模型调用耗时。
overall	Long	总耗时。

表 3-1226 plugin

参数	参数类型	描述
name	String	插件名。
arguments	Object	插件入参名。

请求示例

```
{
  "method": "POST",
  "url": "https://{endpoint}/v1/{project_id}/agents/{agent_id}/conversations/{conversation_id}",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token":
"MIINRwYJKoZIhvcNAQcCoIINODCCDTQCAQExDTALBgIghkgBZQMEAgEwgguVBgkqhkiG...",
    "stream": true
  },
  "body": {
    "inputs": {
      "query": "查询A12会议室在9:00到10:00的状态"
    }
  }
}
```

响应示例

状态码：200

流式响应，返回模型生成内容的增量数据块。

```
data:{"event":"start","createTime":1735558575017}
data:{"event":"message","content":"好的","createTime":1735558576300}
data:{"event":"message","content":", ","createTime":1735558576301}
data:{"event":"message","content":"我将","createTime":1735558576301}
data:{"event":"message","content":"调用","createTime":1735558576302}
data:{"event":"message","content":"query","createTime":1735558576302}
data:{"event":"statistic_data","latency":{"overall":1.97},"createTime":1735558576986}
data:{"event":"summary_response","content":"A12会议室在9:00到10:00的时间段内是空闲的。","role":"assistant","createTime":1735558576987}
data:{"event":"done","createTime":1735558577011}
```

状态码

状态码	描述
200	流式响应，返回模型生成内容的增量数据块。

错误码

请参见[错误码](#)。

3.17.2.1.3 上传文件

功能介绍

该接口用于智能体上传文件，支持多种图片、文档、表格等多种格式的文件上传。接口返回临时下载路径，可用于临时下载文件。

适用场景：在智能体应用中上传文件。

格式要求：

- 办公文档：DOC、DOCX、XLS、XLSX、PPT、PPTX、PDF、Numbers、CSV。
- 图像文件：JPG、JPEG、PNG、GIF、WEBP、HEIC、HEIF、BMP、PCD、TIFF。
- 音频文件：WAV、MP3、FLAC、M4A、AAC、OGG、WMA、MIDI。
- 文本文件：JS、CPP、PY、JAVA、C、TXT、CSS、JAVASCRIPT、HTML、JSON、MD。

URI

POST /v1/{project_id}/agent-runtime/upload-file

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1227 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考获取项目ID。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

表 3-1228 Query 参数

参数	是否必选	参数类型	描述
workspace_id	是	String	参数解释： 工作空间ID，用于标识特定的工作空间。 获取方法请参考 获取工作区ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。
file	是	Object	参数解释： 上传的文件。 约束限制： 不涉及。 取值范围： 大小不超过60MB。 默认取值： 不涉及。
expires	否	Integer	参数解释： 访问授权过期时间（天）。 约束限制： 最长180天。 取值范围： 不涉及。 默认取值： 不涉及。
is_image	否	Boolean	参数解释： 是否是图片上传。 约束限制： 不涉及。 取值范围： • true：文件为图片格式。 • false：文件为非图片格式。 默认取值： false。

请求参数

表 3-1229 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-1230 请求 Body 参数

参数	是否必选	参数类型	描述
file	是	String	参数解释： 用户上传的文档。 约束限制： 不涉及。 取值范围： 文件大小小于60MB。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
is_image	否	Boolean	参数解释： 用户上传的文档是否是图片。 约束限制： 不涉及。 取值范围： • true：文件为图片格式。 • false：文件为非图片格式。 默认取值： false。

响应参数

状态码：200

表 3-1231 响应 Body 参数

参数	参数类型	描述
url	String	参数解释： 临时有效，用于访问存储在OBS上的文件的下载地址。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
headers	Object	参数解释： 请求访问的域名，是OBS签名验证的关键信息。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	参数类型	描述
file_name	String	参数解释： 文件名。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

请求示例

```
{
  "method": "POST",
  "url": "https://api.example.com/v1/{project_id}/agent-runtime/upload-file",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token":
"MIINRwYJKoZIhvcNAQcCoIINODCCDTQCAQExDTALBgIghkgBZQMEAgEwgguVBgkqhkiG...",
    "stream": true
  },
  "body": {
    "file": "C:\\Users\\Desktop\\market-CFrwA1xu.png"
  }
}
```

响应示例

状态码：200

Agent文件上传结束的响应体。

```
{
  "url": "https://test-agent-poc.obs.*****.*****.huawei.com:443/file/3fd960a8-ca5d-4423-b8da-bb8866e21c28.docx?AccessKeyId=8SL1ZFp1ELHHMAWYJHCJ&Expires=1758282352&Signature=r02Qxi3%2Bhv1FtnMo3XcCvReBQGo%3D",
  "headers": [ {
    "Host": "test-agent-poc.obs.*****.*****.huawei.com:443"
  } ]
}
```

状态码

状态码	描述
200	Agent文件上传结束的响应体。

错误码

请参见[错误码](#)。

3.17.2.2 知识库

3.17.2.2.1 知识库检索

功能介绍

提供多知识库并行检索能力，支持语义、关键词、混合及FAQ四种检索模式，并允许自定义相似度阈值与返回结果数量，实现精准高效的信息匹配。

适用场景：

- 同时从多个知识库或文档集合中搜索相关内容。
- 在预设的问答列表中快速定位最相关的答案（FAQ检索）。
- 通过混合模式或调整阈值，兼顾搜索结果的准确性和全面性。

URI

POST /v2/{project_id}/knowledge-bases/retrieve

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1232 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考获取项目ID。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1233 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-1234 请求 Body 参数

参数	是否必选	参数类型	描述
knowledge_base_ids	是	Array of strings	参数解释： 知识库ID列表。 约束限制： 最多可同时检索3个知识库。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
query	是	String	参数解释： 用户输入的问题或关键词。 约束限制： 不涉及。 取值范围： 长度 1 至 4096 字符。 默认取值： 不涉及。
search_mode	否	String	参数解释： 检索策略模式。 约束限制： 不涉及。 取值范围： • doc：语义检索。 • keyword：关键词检索。 • mix：混合检索。 • faq：FAQ检索。 默认取值： doc。
top_k	否	Integer	参数解释： 每个知识库最多返回的检索结果数量。 约束限制： 若传入小数，系统会默认截断小数部分。 取值范围： 1 至 100（含）。 默认取值： 10。
similarity_threshold	否	Float	参数解释： 检索结果的最低相关度得分，低于此值的片段将被过滤。 约束限制： 不涉及。 取值范围： [0.0, 1.0]，包含两端。 默认取值： 0.5。

响应参数

状态码：200

表 3-1235 响应 Body 参数

参数	参数类型	描述
total	Integer	参数解释： 检索结果总数。 取值范围： 不涉及。
retrieve_result_list	Array of RetrievalResultInfo objects	参数解释： 检索结果列表。 取值范围： 不涉及。

表 3-1236 RetrievalResultInfo

参数	参数类型	描述
file_id	String	参数解释： 文件ID（或FAQ ID）。 取值范围： 不涉及。
title	String	参数解释： 文档标题（如果是FAQ，返回QUESTION）。 取值范围： 不涉及。
chunk_id	String	参数解释： 分片ID。 取值范围： 不涉及。
content	String	参数解释： 文本内容（如果是FAQ，返回ANSWER）。 取值范围： 不涉及。

参数	参数类型	描述
similarity	Float	参数解释： 相似度。 取值范围： [0.0, 1.0]，包含两端。
knowledge_base_id	String	参数解释： 知识库ID。 取值范围： 不涉及。

请求示例

```
• {
  "method": "POST",
  "url": "https://api.example.com/v2/{project_id}/knowledge-bases/retrieve",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  },
  "body": {
    "knowledge_base_ids": [ "bad2ef8771e6443096b528a8a7gh...." ],
    "query": "测试检索问题。",
    "search_mode": "DOC",
    "top_k": 10,
    "similarity_threshold": 0.5
  }
}
```

响应示例

状态码：200

知识库检索结果。

```
{
  "total": 1,
  "retrieve_result_list": [ {
    "file_id": "687c7914cbddcc8702cb6698f6230...",
    "title": "test",
    "chunk_id": "840003a72d6f4325958920e52c5a9...",
    "content": "测试检索召回内容。",
    "similarity": 0.9785156,
    "knowledge_base_id": "b56c5138-96e3-4630-8381-7846dfdbcdd5"
  } ]
}
```

状态码

状态码	描述
200	知识库检索结果。

错误码

请参见[错误码](#)。

3.17.2.2.2 知识库检索（v1.5）

功能介绍

适配知识库1.5接口，可根据知识库ID进行知识库检索。

适用场景：

- 必须使用内置RAGFlow知识库。
- 仅支持FAQ场景（适配知识库1.5检索接口切片提取问答）。

URI

POST /v1/{project_id}/knowledge-bases/{knowledge_base_id}/retrieve

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1237 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考 获取项目ID 。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
knowledge_base_id	是	String	参数解释： 知识库的ID。 获取方式： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 知识库”。 3. 在知识库列表的“知识库 ID”列，复制知识库ID。 约束限制： 必须为已创建且处于可用状态的知识库ID；不支持跨项目访问。 取值范围： 由英文、数字、“-”、“_”组成，长度不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1238 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 Token认证 响应消息头中X-Subject-Token的值即为Token。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
Content-Type	是	String	参数解释： 发送的实体的MIME类型。 约束限制： 不涉及 取值范围： 不涉及 默认取值： application/json

表 3-1239 请求 Body 参数

参数	是否必选	参数类型	描述
similarity_min	否	Float	参数解释： 检索结果的最小相似度阈值，用于过滤低相关性片段。 约束限制： 不涉及。 取值范围： [0.0, 1.0]，包含两端。 默认取值： 0.5。
limit	是	Integer	参数解释： 指定返回的检索结果最大数量。 约束限制： 必须为正整数，且不超过系统最大返回限制。 取值范围： 1 至 100（含）。 默认取值： 10。
keyword	是	String	参数解释： 用户输入的检索关键字。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1240 响应 Body 参数

参数	参数类型	描述
data	Array of ChunkData objects	参数解释： 切片明细。 取值范围： 不涉及。

表 3-1241 ChunkData

参数	参数类型	描述
document	String	参数解释： 检索命中的文本内容片段。 取值范围： 不涉及。
chunk_fragments	Map<String,String>	参数解释： 切片片段，应用于FAQ场景。 取值范围： 不涉及。
similarity	Float	参数解释： 检索字段（document）和用户检索关键字（keyword）的相似度。 取值范围： 不涉及。

请求示例

知识库检索（v1.5）。

```
{
  "method": "POST",
  "url": "https://api.example.com/v1/{project_id}/knowledge-bases/{knowledge_base_id}/retrieve",
  "headers": {
    "Content-Type": "application/json",
    "X-Auth-Token": "TEST-TOKEN*****"
  },
  "body": {
    "similarity_min": 0.9,
    "limit": 5,
```

```
"keyword": "测试检索问题。"
}
```

响应示例

状态码：200

知识库检索结果。

```
{
  "data": [ {
    "document": "测试检索召回内容。",
    "chunk_fragments": null,
    "similarity": 0.9765625
  } ]
}
```

状态码

状态码	描述
200	知识库检索结果。

错误码

请参见[错误码](#)。

3.17.2.2.3 文件下载

功能介绍

下载知识库中的指定文件。

 说明

软件版本为8.6.301，才支持此功能。

适用场景：

- 智能体中添加知识库时，可以通过本接口下载检索结果中的文件。
- 工作流中添加知识检索节点时，当工作流运行完成后，可以通过本接口下载检索结果中的文件。

 说明

知识库内的文件不能通过该接口直接下载。
文件的默认有效期为7天。

URI

GET /v2/{project_id}/knowledge-bases/{knowledge_base_id}/files/{file_id}/content

接口域名请参考[获取Agent接口域名](#)获取。

表 3-1242 路径参数

参数	是否必选	参数类型	描述
project_id	是	String	参数解释： 当前租户项目ID。 获取方法请参考获取项目ID。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

参数	是否必选	参数类型	描述
knowledge_base_id	是	String	参数解释： 知识库ID。 获取方式： 方式一： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 应用管理”，选择工作流应用。 3. 添加“知识检索节点”，选择需要检索的知识库。 4. 运行工作流，完成后在右上角选择“调试 > 调用详情 > 知识检索”，在输出栏内获取“knowledge_base_id”。 5. 如果是通过“调用工作流应用”接口调用，可在返回信息中获取“knowledge_base_files_info”字段，从该字段中获取“knowledge_base_id”。 方式二： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 应用管理”，选择智能体应用。 3. 添加“知识库”，选择需要检索的知识库。 4. 运行智能体，完成后选择“retrieval”，在返回结果中获取“knowledge_base_id”。 5. 如果是通过“调用智能体应用”接口调用，可在返回信息中获取“knowledge_base_files_info”字段，从该字段中获取“knowledge_base_id”。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值：

参数	是否必选	参数类型	描述
			不涉及。
file_id	是	String	参数解释： 文件ID。 方式一： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 应用管理”，选择工作流应用。 3. 添加“知识检索节点”，选择需要检索的知识库。 4. 运行工作流，完成后在右上角选择“调试 > 调用详情 > 知识检索”，在输出栏内获取“file_id”。 5. 如果是通过“调用工作流应用”接口调用，可在返回信息中获取“knowledge_base_files_info”字段，从该字段中获取“file_id”。 方式二： 1. 进入Versatile智能体平台。 2. 在左侧导航选择“开发中心 > 应用管理”，选择智能体应用。 3. 添加“知识库”，选择需要检索的知识库。 4. 运行智能体，完成后选择“retrieval”，在返回结果中获取“file_id”。 5. 如果是通过“调用智能体应用”接口调用，可在返回信息中获取“knowledge_base_files_info”字段，从该字段中获取“file_id”。 约束限制： 不涉及。 取值范围： 由英文，数字，“-”，“_”组成，不超过64位字符。 默认取值： 不涉及。

请求参数

表 3-1243 请求 Header 参数

参数	是否必选	参数类型	描述
X-Auth-Token	是	String	参数解释： 用户Token。 Token认证 响应消息头中X-Subject-Token的值。 约束限制： 不涉及。 取值范围： 不涉及。 默认取值： 不涉及。

响应参数

状态码：200

表 3-1244 响应 Body 参数

参数	参数类型	描述
-	File	文件流。

请求示例

下载知识库中的指定文件。

```
{
  "method": "GET",
  "url": "https://api.example.com/v2/{project_id}/knowledge-bases/files/{file_id}",
  "headers": {
    "X-Auth-Token": "TEST-TOKEN*****"
  }
}
```

响应示例

状态码：200

文件流。

状态码

状态码	描述
200	文件流。

错误码

请参见[错误码](#)。

3.17.3 应用示例

3.17.3.1 调用 workflows 应用示例

操作场景

该接口用于运行场景化应用，支持在指定的项目、工作流和对话上下文中执行工作流逻辑。接口支持流式响应模式，可以根据需要返回增量执行结果，适用于实时交互场景。

适用场景：

- 在项目中运行预定义的工作流。
- 支持调试模式和发布模式，适用于不同开发和生产环境。
- 支持流式响应，适用于需要实时反馈的场景（如聊天机器人、实时数据分析等）。

下面介绍如何[调用 workflows 应用](#)API使用智能体应用，API的调用方法请参见[如何调用 REST API](#)。

调用 workflows

如下示例是调用 workflows 应用的配置。

```
POST https://1.2.3.4/v1/12345/workflows/67890/conversations/67890

Request Header:
Content-Type: application/json
X-Auth-Token: MIINRwYJKoZlhvcNAQcCoIINODCCDTQCAQExDTALBgIghkgBZQMEAgEwgguVBgkqhkiG...
stream: true

Request Body:
{
  "inputs": {
    "query": "你好"
  },
  "plugin_configs": [
    {
      "plugin_id": "xxxxxxx",
      "config": {
        "key": "value"
      }
    }
  ]
}
```

- endpoint: 终端节点, 获取方法请参考[获取Agent接口域名](#)。
- project_id: 当前项目ID, 获取方法请参考[获取项目ID](#)。
- workflow_id: 工作流应用ID, 获取方法如下:
 - a. 登录ModelArts Studio平台, 在首页单击“AGENT开发”, 进入Versatile智能体平台。
 - b. 在左侧导航选择“开发中心 > 应用管理 > 工作流应用”。
 - c. 在待复制ID的工作流应用卡片上, 单击“... > 复制ID”。
- conversation_id: 会话ID, 每个会话的唯一标识符。用户可将会话ID设置为无分隔符UUID格式的任意值, 例如“123e4567e89b12d3a456426614174000”, 无需在其他地方获取。字符串长度为1~64个字符, 支持英文字母、数字、中划线、下划线。

3.17.3.2 调用智能体应用示例

操作场景

该接口用于运行知识型智能体应用（单智能体应用、多智能体应用），支持在指定的项目、智能体和对话上下文中执行智能体逻辑。接口支持流式响应模式，可以根据需要返回增量执行结果，适用于实时交互场景。

适用场景：

- 在项目中运行预定义的知识型智能体应用。
- 支持调试模式和发布模式，适用于不同开发和生产环境。
- 支持流式响应，适用于需要实时反馈的场景（如聊天机器人、实时数据分析等）。

下面介绍如何[调用智能体应用](#)API使用智能体应用，API的调用方法请参见[如何调用REST API](#)。

调用应用

如下示例是调用智能体应用的配置。

```
POST https://1.2.3.4/v1/074cabeea7800f622f0ec010bffa6c59/agents/7c5be653-71b8-48e7-9058-7191ec0f44e8/conversations/eeb9884b-ef09-4dd5-a13a-803a09339960?workspace_id=default

Request Header:
Content-Type: application/json
X-Auth-Token: MIINRwYJKoZlhcNAQcCoIINODCCDTQCAQExDTALBglghkgBZQMEAgEwgguVBgkqhkiG...
stream: true

Request Body:
{
  "inputs": {
    "query": "查询A12会议室在9:00到10:00的状态"
  }
}
```

- endpoint: 终端节点, 获取方法请参考[获取Agent接口域名](#)。
- project_id: 当前项目ID, 获取方法请参考[获取项目ID](#)。
- agent_id: 智能体应用ID, 获取方法如下:
 - a. 登录ModelArts Studio平台, 在首页单击“AGENT开发”, 进入Versatile智能体平台。

- b. 在左侧导航选择“开发中心 > 应用管理 > 单智能体应用”或选择“开发中心 > 应用管理 > 多智能体应用”。
 - c. 在待复制ID的智能体应用卡片上，单击“... > 复制ID”。
- conversation_id: 会话ID，每个会话的唯一标识符。用户可将会话ID设置为无分隔符UUID格式的任意值，例如“123e4567e89b12d3a456426614174000”，无需在其他地方获取。字符串长度为1~64个字符，支持英文字母、数字、中划线、下划线。

4 附录

4.1 状态码

HTTP状态码为三位数，分成五个类别：1xx：相关信息；2xx：操作成功；3xx：重定向；4xx：客户端错误；5xx：服务器错误。

状态码如下所示。

状态码	编码	状态说明
100	Continue	继续请求。 这个临时响应用来通知客户端，它的部分请求已经被服务器接收，且仍未被拒绝。
101	Switching Protocols	切换协议。只能切换到更高级的协议。 例如，切换到HTTPS的新版本协议。
200	OK	服务器已成功处理了请求。
201	Created	创建类的请求完全成功。
202	Accepted	已经接受请求，但未处理完成。
203	Non-Authoritative Information	非授权信息，请求成功。
204	No Content	请求完全成功，同时HTTP响应不包含响应体。 在响应OPTIONS方法的HTTP请求时返回此状态码。
205	Reset Content	重置内容，服务器处理成功。
206	Partial Content	服务器成功处理了部分GET请求。
300	Multiple Choices	多种选择。请求的资源可包括多个位置，相应可返回一个资源特征与地址的列表用于用户终端（例如：浏览器）选择。

状态码	编码	状态说明
301	Moved Permanently	永久移动，请求的资源已被永久的移动到新的URI，返回信息会包括新的URI。
302	Found	资源被临时移动。
303	See Other	查看其它地址，使用GET和POST请求查看。
304	Not Modified	所请求的资源未修改，服务器返回此状态码时，不会返回任何资源。
305	Use Proxy	所请求的资源必须通过代理访问。
306	Unused	已经被废弃的HTTP状态码。
400	Bad Request	非法请求。 建议直接修改该请求，不要重试该请求。
401	Unauthorized	在客户端提供认证信息后，返回该状态码，表明服务端指出客户端所提供的认证信息不正确或非法。
402	Payment Required	保留请求。
403	Forbidden	请求被拒绝访问。 返回该状态码，表明请求能够到达服务端，且服务端能够理解用户请求，但是拒绝做更多的事情，因为该请求被设置为拒绝访问，建议直接修改该请求，不要重试该请求。
404	Not Found	所请求的资源不存在。 建议直接修改该请求，不要重试该请求。
405	Method Not Allowed	请求中带有该资源不支持的方法。 建议直接修改该请求，不要重试该请求。
406	Not Acceptable	服务器无法根据客户端请求的内容特性完成请求。
407	Proxy Authentication Required	请求要求代理的身份认证，与401类似，但请求者应当使用代理进行授权。
408	Request Timeout	服务器等候请求时发生超时。 客户端可以随时再次提交该请求而无需进行任何更改。
409	Conflict	服务器在完成请求时发生冲突。 返回该状态码，表明客户端尝试创建的资源已经存在，或者由于冲突请求的更新操作不能被完成。
410	Gone	客户端请求的资源已经不存在。 返回该状态码，表明请求的资源已被永久删除。

状态码	编码	状态说明
411	Length Required	服务器无法处理客户端发送的不带Content-Length的请求信息。
412	Precondition Failed	未满足前提条件，服务器未满足请求者在请求中设置的其中一个前提条件。
413	Request Entity Too Large	由于请求的实体过大，服务器无法处理，因此拒绝请求。为防止客户端的连续请求，服务器可能会关闭连接。如果只是服务器暂时无法处理，则会包含一个Retry-After的响应信息。
414	Request URI Too Long	请求的URI过长（URI通常为网址），服务器无法处理。
415	Unsupported Media Type	服务器无法处理请求附带的媒体格式。
416	Requested Range Not Satisfiable	客户端请求的范围无效。
417	Expectation Failed	服务器无法满足Expect的请求头信息。
422	Unprocessable Entity	请求格式正确，但是由于含有语义错误，无法响应。
429	Too Many Requests	表明请求超出了客户端访问频率的限制或者服务端接收到多于它能处理的请求。建议客户端读取相应的Retry-After首部，然后等待该首部指出的时间后再重试。
500	Internal Server Error	表明服务端能被请求访问到，但是不能理解用户的请求。
501	Not Implemented	服务器不支持请求的功能，无法完成请求。
502	Bad Gateway	充当网关或代理的服务器，从远端服务器接收到了一个无效的请求。
503	Service Unavailable	被请求的服务无效。 建议直接修改该请求，不要重试该请求。
504	Gateway Timeout	请求在给定的时间内无法完成。客户端仅在为请求指定超时（Timeout）参数时会得到该响应。
505	HTTP Version Not Supported	服务器不支持请求的HTTP协议的版本，无法完成处理。

4.2 错误码

当您调用API时，如果遇到“ModelArts”开头的错误码，请参见《[ModelArts 使用指南\(for 华为云Stack 8.6.0\)](#)》。

表 4-1 错误码

错误码	错误信息	说明	建议解决方法
INF.0400	The content and data fields cannot be empty at the same time.	请求参数中 content和data 字段不能同时为空。	请参考API请求示例，正确填写content和data参数。
INF.0400	The request body data format is incorrect. 1. The request body complies with the JSON specification. 2. The request body is in UTF-8 encoding format.	请求体数据格式不正确。 1、请求体需要符合JSON规范。2、采用 UTF-8编码格式。	确保请求体是有效的JSON格式，并使用UTF-8编码。
INF.0400	The xxx must be of type float.	xxx参数必须为float类型。	请检查参数类型是否为float类型。
INF.0400	the value range of the xxx is xxx.	xxx参数取值范围是xxx。	请检查参数值是否超出取值范围。
INF.0400	argument valid error.	参数验证错误。	检查并确保所有请求参数符合预期的格式和取值范围。
INF.0404	uri is not found.	接口uri不存在。	检查调用的接口是否拼写错误。
INF.0405	The method is not allowed for the requested URL.	不允许对请求的URL使用该方法。	确保使用正确的HTTP方法（POST，GET等）来调用API。
INF.0500	Inner service exception.	内部错误。	请联系服务技术支持协助解决。
INF.0500	Internal server error, please contact related service personnel.	内部错误。	请联系服务技术支持协助解决。
PANGU.0001	unknown error.	未知错误。	请联系服务技术支持协助解决。
PANGU.0010	- The value range of xxx must be between xxx and xxx. - Failed to parse the URL, please check the URL.	- xxx参数取值范围是xxx。 - 解析URL失败，请检查URL。	- 请检查参数值是否超出取值范围。 - 请检查URL是否拼写正确，如果调用CV模型或者预测模型，URL填写正确，仍然出现报错，请检查URL结尾是否没有添加/，请添加后重新调用接口。

错误码	错误信息	说明	建议解决方法
PANGU.0010	The value of xxx does not exist or is empty	xxx参数不存在或者为空。	请检查参数设置是否正确或有遗漏。
PANGU.0011	auth failed.	认证失败。	认证鉴权失败，请参考《API 文档》“认证鉴权”章节重新进行认证。
PANGU.0012	Inner service exception.	服务内部异常。	请联系服务技术支持协助解决。
PANGU.3259	NLP service status is not running or have been deleted.	推理服务状态异常。	请检查调用API时 deploymentId是否正确，并检查模型的部署状态是否存在异常，如果仍无法解决请联系服务技术支持协助解决。
PANGU.3267	qps exceed the limit.	QPS超出限制。	请降低请求频率。
PANGU.3278	required api parameter is not present.	请求参数丢失。	请检查调用API时请求参数是否填写完整、是否有拼写错误、取值是否正确。
PANGU.3305	call cal tokens failed	获取token错误。	请检查调用API时使用的 token是否完整，是否存在错误。
PANGU.3306	The accessed API's model does not match instance's model.	访问的API模型与实例模型不匹配。	请检查参数是否正确，或联系服务技术支持协助解决。
PANGU.3307	domain has not added the opened API.	账号未开通该API服务。	请确认是否已开通该API服务。
PANGU.3308	The accessed API does not match the existing API.	访问的API与已开通的API服务不匹配。	请确认调用的API是否填写错误。
PANGU.3315	The accessed API's model instance is not public.	API模型实例未公开。	请检查是否具备使用权限，或联系服务运维人员协助解决。
PANGU.3316	create agency fail.	创建代理失败。	请联系服务运维人员协助解决。
PANGU.3317	The parameter of xxx should be between xxx and xxx.	xxx参数取值范围是xxx。	请检查参数值是否超出取值范围。

错误码	错误信息	说明	建议解决方法
PANGU.3318	total ContentLength Illegal.	Content长度不合法。	请参考《API文档》检查请求参数中输入的Content参数长度是否不在范围内，并重新调试API。
PANGU.3319	Private service permission error.	权限错误。	请联系服务技术支持协助解决。
PANGU.3320	The parameter xxx can only be xxx or xxx when calling non-streaming.	非流式调用时，xxx参数取值只能是xxx。	请检查参数值是否超出取值范围。
PANGU.3321	The parameter [n] can only be 1 when calling streaming.	流式调用推理服务n只能取1。	请使用正确的取值：1。
PANGU.3342	Failed to invoke the inference service. Please check the details field.	调用推理服务失败。请检查详细信息字段。	请检查API参数是否设置正确。
IIT.0201	The input param is invalid!/The input param is invalid, please check your key!	请求参数不合法。	请检查请求参数是否填写正确。
IIT.0202	Interval Server Error!	内部错误。	请联系服务技术支持协助解决。
IIT.0203	The input param is invalid, the input data lens is less than the train data lens!	请求参数不合法，输入参数中的数据长度小于训练所用数据长度。	请确认请求body中特征名称、特征数量是否与训练数据中的特征一致。
PREDICT.0102	Json format is wrong!或者其他与数据相关的特定报错信息	请求数据非JSON格式；或者其他与数据相关的特定错误。	请将请求体设置为JSON格式；或者根据数据相关的特定报错信息调整请求体。
PREDICT.0201	The input param is invalid!/The input param is invalid, please check your key!	请求参数不合法。	请检查请求参数是否填写正确。

错误码	错误信息	说明	建议解决方法
PREDICT.0202	Interval Server Error!	内部错误。	请联系服务技术支持协助解决。
PREDICT.0203	The input param is invalid, the input data lens is less than the train data lens!	请求参数不合法，输入参数中的数据长度小于训练所用数据长度。	请确认请求body中特征名称、特征数量是否与训练数据中的特征一致。
ERROR.001	parameter 'image_base64' must be provided.	image_base64是必填项目，必须输入。	请检查请求参数是否遗漏。
ERROR.002	Decoding of the request parameter 'image_base64' fails.	请求参数 image_base64 的元素解码 base64失败。	请检查图片的base64编码是否正确。
ERROR.003	Invalid input parameters, value type of 'image_base64' must be string.	请求体 Request Body 的内容存在错误，image_base64 必须是string 类型。	请参考API请求示例，正确填写请求体。
ERROR.004	Input json is wrong, please check.	请求体 Request Body 的内容存在错误，请校验是否为JSON格式。	确保请求体是有效的JSON格式。
AIS.0012	The request parameter Content-Type is not supported.	请求头 Content-Type 参数格式错误。	请求头Content-Type并重新调用接口。
AIS.0014	The JSON format of the input data is incorrect.	输入数据JSON 格式校验失败。	确保请求体是有效的JSON格式。
AIS.0501	The input parameter xxx is invalid.	输入参数xxx非法。	请检查请求参数是否填写正确。
AIS.0502	The image format is not supported.	输入图像格式不支持。	请参考API参数要求，输入正确的图片。
AIS.0503	The image is damaged.	输入图像内容解析失败。	请参考API参数要求，请检查图片是否满足要求。若无法解决请联系服务技术支持。

错误码	错误信息	说明	建议解决方法
AIS.0504	The size of the image does not meet the requirements.	图像大小不符合算法约束。	请参考API参数要求，输入正确大小的图片。
AIS.0505	An algorithm failure occurred.	算法异常。	请联系服务技术支持协助解决。
AIS.0506	An internal error occurred.	内部错误。	请联系服务技术支持协助解决。
ModelArts.0010	Internal error.	内部错误。	请联系服务技术支持协助解决。
ModelArts.0101	Invalid argument.	无效参数。	检查并确保所有请求参数的格式和值都是有效且符合要求。
ModelArts.0107	The values of the request parameters xxx are invalid.	请求的参数值xxx是无效的。	检查提示的参数值是否是有效的。
ModelArts.0108	You are not authorized to perform the xxx operation.	您未被授权执行xxx的操作。	检查是否有OBS权限或者接口操作权限。
ModelArts.1120	Parameter verification failed.	参数校验失败	请按规范填写请求参数。
ModelArts.0203	Invalid token.	无效的token。	重新生成一个token进行重试。
ModelArts.0204	Token must contain projectId info.	token信息中必须包含projectId的信息。	检查token是否为project token。
MAStudio.00420427	No static resource xxx.	无有效的资源。	请检查接口是否拼接正确或接口对应的功能是否运行正常。
APIC.0101	The API does not exist: method xxx not found.	API不存在：未找到请求方法xxx。	确保使用了正确的API请求方法，并检查API文档以确认方法的存在。
APIC.0101	The API does not exist or has not been published in the environment.	访问的API不存在或尚未在环境中发布。	- 请检查API的URL是否拼写正确。例如，URL中是否缺少project_id。 - HTTP请求方法（POST，GET等）是否正确。

错误码	错误信息	说明	建议解决方法
APIC.0301	Incorrect IAM authentication information.	IAM身份验证信息不正确： • decrypt token fail: token 解析失败。 • token expires: token过期。 • x-auth-token not found: 未找到x-auth-token 参数。	• token解析失败，请检查获取token的方法，请求体信息是否填写正确，token是否正确；检查获取token的环境与调用的环境是否一致。 • token超时（token expires），请重新获取token，使用不过期的token。 • 检查请求header参数X-Auth-Token是否拼写正确。
APIC.0602	Bad request: invalid method xxx.	错误请求，请求方法xxx无效。	检查HTTP请求方法（POST，GET等）是否正确。
STRUCT_TABLE.0102	Json format is wrong!	输入数据JSON格式校验失败。	确保请求体是有效的JSON格式。
STRUCT_TABLE.0201	raw struct data value error!	数据特征值校验失败。	请检查数据参数值是否是有效的。
STRUCT_TABLE.0202	raw struct data feature error!	数据特征不存在。	请检查对应的数据特征是否存在。
OptVerse.00000001	Parameter xxx error: xxx.	输入参数xxx错误	请检查参数设置是否正确。
OptVerse.00000002	Failed to access OBS service.	访问OBS服务失败。	请检查obs路径是否设置正确。
OptVerse.00000004	Access obs object xxx:xxx failed with: xxx, xxx	obs访问当前桶信息失败	请根据具体错误原因查看obs路径是否正确。
OptVerse.00000005	Failed to load service xxxx message: xxxx.	加载算法服务失败	请根据具体错误原因查看是否当前服务不合法。
OptVerse.00000006	Algorithm check input failed.	参数合法性校验失败	请按规范填写请求参数。
OptVerse.00001001	Failed to access data storage service	访问数据服务失败	请联系服务技术支持协助解决。

错误码	错误信息	说明	建议解决方法
OptVerse.000 01002	Request task xxx not exist.	当前请求任务 不存在	请求任务或被删除。
OptVerse.000 01003	Failed to create the task: xxx.	创建请求任务 失败	请联系服务技术支持协助解 决。
OptVerse.000 01004	Request service type xxx unsupported.	不支持当前的 请求类型	请检查请求方式。
OptVerse.000 00099	The service encountered an internal error and was unable to complete your request.	服务遇到内部 错误，无法完 成请求。	请联系服务技术支持协助解 决。
OptVerse.000 09999	The service catch an unknown error.	服务捕获未知 错误。	请联系服务技术支持协助解 决。
MAStudio.00 310101	The service_id {0} does not exist in project_id {1} and workspace_id {2}	服务ID不存在	服务ID为部署模型生成的ID, 请检查该ID是否拼写正确。
MAStudio.00 310102	The service can not change status to running	服务当前状态 不支持启动	模型部署任务为非停止状 态，无法进行再次启动，只 有处于已停止的状态才能执 行启动操作。
MAStudio.00 310103	The service can not change status to stopped.	服务当前状态 不支持停止	模型部署任务为非运行中/非 告警状态/非部署中时，不能 进行停止操作。
MAStudio.00 310104	The service is nothing to change	服务无需更新	更新模型部署任务时，检查 到请求更新的任务信息与第 一次无任何变化（例如更新 的资产模型及实例数）。
MAStudio.00 310105	The operation is not allowed in the current service status.	当前服务状态 不允许该操作	联系服务技术支持。
MAStudio.00 310106	Create application failed.	应用创建失败	模型部署任务下发到 ModelArts中，创建AI应用 时失败，需联系服务技术支 持。
MAStudio.00 310107	The config is null.	服务配置 config为空	部署科学计算模型时，检测 到模型资产的配置 mode_config信息为空，需 联系服务技术支持检查资产 信息。

错误码	错误信息	说明	建议解决方法
MAStudio.00310108	The service is deploying.	服务正在部署中	等待服务部署完成。
MAStudio.00310109	Get service runlog failed.	获取服务部署日志失败	调用ModelArts的部署日志接口失败，联系服务技术支持。
MAStudio.00310110	Get service deploy events failed.	获取服务部署事件失败	调用ModelArts的部署事件接口失败，联系服务技术支持。
MAStudio.00310111	Get service monitor info failed.	获取服务监控信息失败	调用ModelArts的服务监控信息接口失败，联系服务技术支持。
MAStudio.00310112	Get model import events failed.	获取模型导入事件失败	调用ModelArts的模型导入事件接口失败，联系服务技术支持。
MAStudio.00310113	service name {0} has been used	服务名称重复	创建部署任务时，部署任务名字重复，请更换名称。
MAStudio.00310114	The service status not allowed to update.	服务当前状态不允许更新	仅运行中、告警、已停止、更新失败状态的服务支持更新。
MAStudio.00310115	The service model config need update, now can not update status.	服务的模型配置需要更新	当前更新为非模型资产的更新，请检查更新的信息。
MAStudio.00310116	Update asset type not match, can not update.	更新的资产类型不匹配，不支持更新	更新的资产类型信息与原部署的资产类型信息不一致，不支持更新。
MAStudio.00310117	Failed get asset.	获取资产失败	查询资产信息失败，需联系服务技术支持。
MAStudio.00310118	Env {0} is wrong.	环境变量不存在或者值有误	环境变量信息不存在，联系服务技术支持，检查环境变量配置。
MAStudio.00310119	Image is not exist.	镜像不存在	查询镜像信息报错，联系服务技术支持，检查镜像信息是否存在。
MAStudio.00310120	The deployment no resources available, cause : {0}.	在线服务部署集群已无可用资源	请释放资源后，再次尝试部署服务。
MAStudio.00310121	The image is pushing, imagePath: {0}.	当前镜像正在推送中	查询镜像信息报错，联系服务技术支持，检查镜像信息是否存在。

错误码	错误信息	说明	建议解决方法
MAStudio.00310122	The service has no related inner service, can not update.	当前服务无关联的内部服务，不支持更新	联系服务技术支持，检查相关服务是否存在。
MAStudio.00310123	Parse service config failed.	xml解析错误	联系服务技术支持，检查XML文件格式是否正确。
MAStudio.00310124	The service is used by parent service: {0}.	服务正在被使用	该服务被其他父服务使用，无法进行删除，请先删除父服务。
MAStudio.00310125	Pool specification not exists error!	资源池specification信息不存在	资产池规格信息不存在，联系服务技术支持。
MAStudio.00310126	Delete access port failed!	删除访问端口失败	调用ModelArts删除访问端口接口失败，联系服务技术支持。
MAStudio.00310127	Pool flavor not exists error!	资源池flavor信息不存在	资源池的规格信息不存在，联系服务技术支持。
MAStudio.00310128	Create access port failed!	创建边缘服务访问端口失败	调用ModelArts创建访问端口接口失败，联系服务技术支持。
MAStudio.00310129	Update egde elb failed!	更新边缘集群ELB失败	调用ModelArts更新负载均衡接口失败，联系服务技术支持。
MAStudio.00310130	Failed to query the ELB list of the edge cluster!	查询边缘集群ELB列表失败	调用ModelArts查询负载均衡列表接口失败，联系服务技术支持。
MAStudio.00310131	Failed to query the access port list of the edge service!	查询边缘服务访问端口列表失败	调用ModelArts查询访问端口列表接口失败，联系服务技术支持。
MAStudio.00310132	Asset does not exists error!	资产信息不存在	资产ID对应的资产信息不存在，联系服务技术支持。
MAStudio.00310133	Asset info is empty!	资产列表及资产信息均为空	请求的资产ID信息为空，或资产ID对应信息不存在，联系服务技术支持。
MAStudio.00310134	Asset info error.	资产列表及资产信息都存在	请求的资产ID与资产IDs信息不能都存在值，请检查请求参数。

错误码	错误信息	说明	建议解决方法
MAStudio.00 310135	Asset choose error.	资产选择错误	科学计算模型多资产部署时，资产类型与资产子类型数量不一致，联系服务技术支持。
MAStudio.00 310136	Asset resource or image info error.	资产资源或镜像信息录入有误	部署的资产信息检测出不唯一，联系服务技术支持。
MAStudio.00 310137	The model service debug failed, project id: {0}, workspace id: {1}, service id: {2}.	模型调试失败	模型调试失败，联系服务技术支持。
MAStudio.00 310138	Incorrect interface URL format.	推理接口url格式错误	推理接口返回的URL格式有误，联系服务技术支持。
MAStudio.00 310139	Inference interface request failed, cause : {0}.	调用推理接口错误	调用推理接口错误，联系服务技术支持。
MAStudio.00 310140	Service status not ready, service id: {0}, status: {1}.	服务状态未就绪	服务状态不是运行态，请等待服务状态就绪。
MAStudio.00 310141	Only one of the asset id and asset id lists can be non-empty!	资产id和资产id列表参数只能有一个不为空	请求参数资产ID与资产IDs只能有一个不为空，请检查请求参数。
MAStudio.00 310142	The security policy does not exist!	模型加解密方式不存在	模型的加密策略为空，请检查资产加密策略参数。
MAStudio.00 310143	No enough available ports, need {0}, available {1}.	没有足够的可用的端口	没有足够的负载均衡访问端口，联系服务技术支持。
MAStudio.00 310144	Failed to calculate resource consumption. Cause: {0}.	计算资源消耗失败	进行Licenses资源计算时失败，联系服务技术支持。
MAStudio.00 310145	An error occurred during resource consumption control. The reason is: {0}.	资源消耗/释放时发生错误	进行Licenses资源消耗/释放时失败，联系服务技术支持。

错误码	错误信息	说明	建议解决方法
MAStudio.00310146	The model asset being deployed has no asset_code or category information.	资产没有产品信息	资产的资产编码/资产来源信息不存在，联系服务技术支持。
MAStudio.00310147	Failed to deploy the model. The cause is: {0}.	模型部署失败	联系服务技术支持。
MAStudio.00310148	The related service count already exceeded the upper limit count {0}.	模型部署已经超过上限	删除不需要的服务后再次提交。
MAStudio.00310149	The related service count will exceed the upper limit count {0},current count is {1}, plan deploy count is {2}.	模型部署将超过上限	联系服务技术支持。
MAStudio.00310150	Error max_surge value:{0}.	滚动升级 max_surge参数错误	滚动升级时，输入的参数值 max_surge错误，请检查请求参数。
MAStudio.00310151	Error max_unavailable value:{0}.	滚动升级 max_unavailable参数错误	滚动升级时，输入的参数值 max_unavailable错误，请检查请求参数。
MAStudio.00310152	The edge load balancer cannot be found. The load balancer ID is {0} and the cluster ID is {1}.	没有找到指定 elb	请求参数中的elbid与环境中的信息不匹配，联系服务技术支持。
MAStudio.00310153	The selected edge load balancer {0} is not in the RUNNING state.	elb不是 RUNNING状态	请求参数elbid对应的状态不是RUNNING状态，请等待状态正常或联系服务技术支持。
MAStudio.00310154	Failed to update the model service. The cause is: {0}.	模型服务更新失败	模型服务更新失败，联系服务技术支持。
MAStudio.00310155	Failed to delete the model service. The cause is: {0}.	模型服务删除失败	模型服务删除失败，联系服务技术支持。

错误码	错误信息	说明	建议解决方法
MAStudio.00310156	Failed to start or stop the model service. The cause is: {0}.	模型服务启停失败	模型服务启动/停止失败，联系服务技术支持。
MAStudio.00310157	The security bar type should enable.	安全护栏必须为开启状态	当前模型必须开启安全护栏，请开启安全护栏。
MAStudio.00310158	The security bar type can not update.	安全护栏不能更新	当前预置服务的安全护栏不支持关闭，不支持更新操作。
MAStudio.00310159	The resource pool does not exist or does not match.	资源池不存在或不匹配	请求的资源池ID对应的订单信息不存在，联系服务技术支持。
MAStudio.00310160	The use_type does not match the asset.	所选资产的计费模式与部署使用类型不匹配	请求参数中的使用类型与选择资产中的计费模型不匹配，联系服务技术支持。
MAStudio.00310161	Failed to get the edge pool detail info. The cause is: {0}.	获取边缘资源池详情信息失败	调用ModelArts查询边缘资源池详情接口失败，联系服务技术支持。
MAStudio.00310162	The edge pool detail info is empty, please check the info, pool id: {0}.	边缘资源池信息为空，请检查资源池信息	查询边缘资源池信息为空，检查请求参数资源池ID是否正确或联系服务技术支持。
MAStudio.00310163	The deployed service instance count must be [1] in virtual edge pool.	虚拟边缘资源池实例数检查错误	虚拟共享资源池时，部署实例数需要为1，联系服务技术支持。
MAStudio.00310164	The security bar cannot be enabled for this asset type.	资产不支持开启安全护栏	当前资产不支持开启安全护栏。
MAStudio.00310165	Service deployment scenario pod number check error	服务部署场景pod数量检查错误	PD分离部署时，工作pod的类型数量必须大于1，请检查请求参数或联系服务技术支持。

错误码	错误信息	说明	建议解决方法
MAStudio.00310166	Service deployment scenario work pod identification check error	服务部署场景工作pod标识检查错误	PD分离部署时，工作pod类型不一致，请检查请求参数或联系服务技术支持。
MAStudio.00310167	The number of service deployment instance pods is calculated incorrectly	服务部署实例pod数量计算错误	请求参数中部署场景名称不正确，计算pod数量错误，请检查请求参数或联系服务技术支持。
MAStudio.00310168	The service_id {0} does not exist in project_id {1} and workspace_id {2}	边缘节点端口已存在	修改边缘节点端口号后再次提交。
MAStudio.00310169	The edge node port is insufficient, the number of available ports is: {0}.	边缘节点端口不足	删除不用的边缘服务。
MAStudio.00310170	The parameter does not exist, the parameter is: {0}.	参数不存在	边缘节点端口为空，请检查请求参数。
MAStudio.00310171	This application does not exist or has been deleted.	该应用App不存在或已删除	请求参数对应的应用App信息不存在，请检查请求参数。
MAStudio.00310172	The parameter app_ids is empty.	参数app_ids为空	请求参数app_ids不能为空，请检查参数或联系服务技术支持。
MAStudio.00310173	The edge elb is updating, the elb id is: {0}.	边缘服务的负载均衡器正在更新	等待负载均衡器更新完成。
MAStudio.00310174	Gallery asset quota is insufficient, unable to deploy service.	Gallery资产配额不足，无法部署服务	Gallery资产配额不足，无法部署服务，联系服务技术支持。
MAStudio.00310175	Get gallery asset license from modelarts error.	从modelarts获取Gallery资产配额失败	调用ModelArts获取Gallery资产配额失败，联系服务技术支持。

错误码	错误信息	说明	建议解决方法
MAStudio.00 310176	lit asset consume info is missing, unable to deploy service.	IIT资产消耗信息 缺失，无法 部署服务	工业资产的资源消耗信息不 全，联系服务技术支持。
MAStudio.00 310177	Orchestration asset consume info is missing, unable to deploy service.	编排资产消耗 信息缺失，无 法部署服务	编排资产消耗信息缺失，联 系服务技术支持。
MAStudio.00 310178	The app name {0} has been used.	应用名称重复	修改应用名称后再次提交。
MAStudio.00 310179	The parameter app_name is empty.	参数 app_name为 空	参数app_name不能为空， 请检查请求参数。
MAStudio.00 310180	The parameter service_ids is empty.	参数 service_ids为 空	参数service_ids不能为空， 请检查请求参数。
MAStudio.00 310181	The current resources are insufficient, Please try again later.	当前资源不 足，请稍后再 试	请确保有足够的资源，停止 服务后等待5分钟再试。
MAStudio.00 310182	The edge cluster not bound prometheus.	边缘资源池未 绑定 prometheus	检查边缘池是否创建监控插 件。
MAStudio.00 310183	Query aom prom error.	查询aom prometheus信 息失败	查询aom prometheus信息 失败，请检查请求参数是否 正确。
MAStudio.00 310184	Invalid params error.	入参校验失败	监控信息参数输入有误，请 检查请求参数或联系服务技 术支持。
MAStudio.00 310185	Prometheus not existed.	aom prometheus不 存在	请求参数clusterId对应的 prometheus不存在，请检查 资源池是否已绑定 prometheus插件。
MAStudio.00 310186	Related functions can be used only after service authorization is obtained.	需获取服务授 权后才能正常 使用相关功能	请检查是否进行相关模型部 署的授权。
MAStudio.00 310187	The third party service error.	第三方服务错 误	调用第三方服务接口报错， 请查看报错详情或联系服务 技术支持。

错误码	错误信息	说明	建议解决方法
MAStudio.00310188	The service resource has been unsubscribed and only deletion is allowed.	该服务资源已退订，只允许进行删除	退订标记的服务只能进行删除操作。
MAStudio.00310189	SSL certificate key information of edge does not exist.	边缘SSL证书密钥信息不存在	边缘SSL证书密钥信息不存在，检查证书密钥是否正常。
MAStudio.00310190	The loadbalancer info dose not exist.	负载均衡信息不存在	检查是否已创建负载均衡。
MAStudio.00310191	The protocol of load balance does not match, the protocol is: {0}.	负载均衡通信策略不匹配	检查请求参数的负载均衡的通信策略是否选择正确，联系服务技术支持。
MAStudio.00310192	The related application count already exceeded the upper limit count {0}.	AppCode应用数已超过上限	删除不需要的应用后再次提交。
MAStudio.00310193	Please add a custom name, the deployed_model already exists : {0}.	Deployed_Model重复	修改Deployed_Model后再次提交。
MAStudio.00310194	The tenant is expired.	租户未订购或订单信息过期	租户未订购或订单已过期，请重新进行订购或联系服务技术支持。
MAStudio.02010001	dataset name [%s] already exists	数据集名[{0}]已存在	创建数据集名称重复，请更换创建数据集的名称。
MAStudio.02010005	content type [%s] not support, only [%s] support	文件内容[{0}]不支持, 只支持[{1}]	请参考报错信息中的文件内容类型，报错信息会返回支持的文件内容，请使用正确的文件内容。
MAStudio.02010027	dataset [%s] status is not online	数据集[{0}]状态不是online	请使用状态是在线状态的数据集。
MAStudio.02010028	dont have role [%s]	没有[{0}]角色	无操作权限，请根据错误提示申请对应空间内的角色操作权限。

错误码	错误信息	说明	建议解决方法
MAStudio.02 060009	Verification failed. Please check the content format is consistent with the template requirements.	校验失败，请 检查文件内容 格式与样例要 求一致	文件内容与样例文件要求不 一致，修改校验失败的文件 使之与样例文件格式相同。
MAStudio.02 060013	Currently, the content_type [{0}] of dataset is not supported, please purchase the relevant feature pack.	当前不支持数 据集类型 [{0}]，请先订 购相关特性包	不支持当前导入选择的数据 集类型，需要订购相关的数 据工程特性包。
MAStudio.02 060019	import user defined file [{0}] to [{1}] failed.	导入用户自定 义文件[{0}]到 [{1}]失败	导入任务调用用户自定义导 入数据转换格式脚本时发生 错误，请检查错误信息中导 入文件以及脚本文件是否正 确。
MAStudio.02 060021	The request for the data- management service failed, and returned [{0}].	请求数据管理 服务失败，返 回[{0}]	调用数据管理接口更新数据 集时发生异常，请检查数据 管理微服务是否运行正常。
MAStudio.02 060022	A running task cannot be started again.	运行中的任务 不能再次启动	请等待数据导入任务运行结 束或手动停止任务后再启 动。
MAStudio.02 060023	A stopping task cannot be stopped again.	停止中的任务 不能再次停止	数据导入任务停止中，任务 无法重复停止。
MAStudio.02 060025	The file [{0}] size exceeds the maximum limit of [{1}].	文件[{0}]大小 超过最大限制 [{1}]	导入任务限制导入的TAR压 缩文件大小不得超过 500MB，请确认文件大小是 否满足要求。
MAStudio.02 060026	There is no jsonl file in the directory.	目录下没有 jsonl文件	导入图片+Caption及图片 +QA对类型数据集时，要求 源数据中包含jsonl文件，在 对当前导入数据进行校验时 未匹配到jsonl文件，请确认 导入数据中包含jsonl文件。
MAStudio.02 071031	Job [%s] is [%s] and can not be deleted.	任务[{0}]处于 处理中状态， 无法删除。	运行中的数据发布任务无法 被删除，等待任务运行结束 后删除。

错误码	错误信息	说明	建议解决方法
MAStudio.02010002	X-Auth-Token is invalid	X-Auth-Token 不合法	该token没有权限访问，使用确保该用户在IAM中配置正确权限。
MAStudio.02060018	X-Auth-Token is invalid: [{0}].	X-Auth-Token 无效: [{0}]	解析或获取token失败，请检查调用接口时传入的X-Auth-Token是否有效以及X-Auth-Token与ProjectId是否匹配。
MAStudio.02012001	forbidden to do this action	无权进行该操作	该操作用户无操作权限，请获取对应IAM权限后再重试。
MAStudio.02010003	dataset [%s] not found in catalog [%s] workspace [%s]	数据集[{0}]无法在目录[{1}]下空间[{2}]中找到	该数据集在报错信息中提示的空间和catalog中不存在，请填写正确的参数。
MAStudio.02010043	user [{0}] [{1}] not found in workspace [{2}]	数据集[{0}]在空间[{1}]中没有文件，请检查	请进入该空间下检查对应的数据集在该空间下是否存在。
MAStudio.02011003	user [{0}] [{1}] not found in workspace [{2}]	在空间[{2}]中未查询到用户[{0}] [{1}]	请确认对应操作数据集的用户在该空间下具备操作权限。
MAStudio.02060032	Call mrs api failed: [{0}].	调用MRS API 失败: [{0}]	调用MRS服务失败，请优先检查MRS集群是否运行正常，如无法解决，请联系MRS服务技术支持。
MAStudio.02060033	Mrs job is failed, job id: [{0}].	MRS作业失败, 作业id: [{0}]	MRS作业失败，请根据错误信息中的作业id查看MRS manager运维界面上yarn组件中找到对应的application运行日志定位问题。
MAStudio.02071001	Read file [%s] failed	读取文件[{0}] 失败	数据发布任务无法读取数据集文件，请检查当前操作用户是否具备OBS桶相关的文件读权限，确保权限配置正确。
MAStudio.02071002	Dataset [%s] is not found	找不到数据集[{0}]	数据集查找失败，请检查数据发布任务中填写的数据集信息是否填写正确。
MAStudio.02071003	Dataset [%s] status is invalid	数据集[{0}]状态不合法	该状态数据集无法被发布，确保发布任务中填写的数据集状态为上线状态。

错误码	错误信息	说明	建议解决方法
MAStudio.02 071005	Write file [%s] failed	写入文件[{0}] 失败	数据发布任务无法写入数据集文件，请检查当前操作用户是否具备OBS桶相关的文件写权限，确保权限配置正确。
MAStudio.02 071011	Data format is invalid, please check dataset [%s] line [%s].	数据格式不合 法，请检查数 据集[{0}]第 [{1}]行。	数据集的文件内容不合法，请根据错误描述中查找对应数据集文件格式是否正确。
MAStudio.02 071017	source datasets size is up to limit [%s]GB	待发布数据大 小超过上限 [{0}]GB	发布任务选择的数据集超过错误信息中提示的数据大小上限，请删除数据集中的部分文件以满足发布要求。
MAStudio.02 072003	Mrs job is failed, job id: [%s]	Mrs作业失 败，作业id: [{0}]	MRS作业失败，请根据错误信息中的作业id查看MRS manager运维界面上yarn组件中找到对应的application运行日志定位问题。
MAStudio.00 510007	The request parameter is not valid.	参数校验失败	根据返回的错误消息体提示进行修改。
MAStudio.00 510001	Internal Server Error	服务内部错误	请稍后重试或联系技术支持。
WORKSPACE. 0001	Invalid workspace parameter.	工作空间参数 非法	按照文档检查工作空间参数，包括空间名称描述是否符合长度及正则要求。
WORKSPACE. 0010	Invalid workspace query parameter.	工作空间查询 参数非法	按照文档修改参数，符合文档规范后，重新发起请求。
WORKSPACE. 0016	Invalid bound user permission parameter.	绑定用户权限 参数非法	绑定用户权限过低，确保绑定用户是空间管理员、超级管理员等角色，确认无问题后重试接口。
WORKSPACE. 0018	Invalid parameter for updating the user and permission.	更新用户与权 限参数非法	修改参数后重试。
WORKSPACE. 0023	Invalid parameter for querying the workspace user.	查询工作空间 用户参数非法	确保用户id是否符合文档规范，修改用户id后重试。

错误码	错误信息	说明	建议解决方法
WORKSPACE.0007	Cannot delete users that already exist in the current workspace.	无法删除当前工作空间已存在用户	检查当前角色是否具有删除权限。
WORKSPACE.0011	The user does not have the permission to perform this operation.	此操作用户无权限	检查用户权限是否满足。
WORKSPACE.0014	The user does not have the permission.	用户不存在该权限	联系空间管理员，添加对应权限。
WORKSPACE.0020	Prevent deleting workspace creators	禁止删除工作空间创建者	禁止删除工作空间创建者。
WORKSPACE.0024	Invalid token.	无效的Token	传入有效Token后重试。
WORKSPACE.0026	The amount of workspace exceeds the quota.	空间数量超过配额。	联系服务运维人员，调整空间配额后重试。
WORKSPACE.0009	The current user does not exist in any workspace	当前用户不存在于任何工作空间	确认用户ID是否正确，修改用户ID后重试。
WORKSPACE.0012	The user does not exist in the workspace.	工作空间不存在该用户	检查用户id是否正确，修改用户id后重试。
WORKSPACE.0025	The workspace does not exist.	工作空间不存在	确认传入空间id是否正确。
WORKSPACE.0003	The workspace already exists.	工作空间已经存在。	修改参数后重试。
WORKSPACE.0002	An error occurred when querying the workspace.	查询工作空间异常。	请联系服务技术支持协助解决。
WORKSPACE.0004	Workspace creation failed.	工作空间创建失败。	检查空间名称、空间描述、扩展字段等参数是否符合文档规范，修改后重新创建空间。
WORKSPACE.0005	Workspace update failed	工作空间更新失败	修改参数后重试。

错误码	错误信息	说明	建议解决方法
WORKSPACE.0006	An error occurred when querying workspace users.	查询工作空间用户异常	请联系服务技术支持协助解决。
WORKSPACE.0008	Failed to delete the workspace.	工作空间删除失败	请联系服务技术支持协助解决。
WORKSPACE.0013	Failed to query user rights.	查询用户权限失败	请检查是否订购以及拥有相应权限
WORKSPACE.0015	Failed to unbind the user from the permission.	解绑用户与权限失败	请联系服务技术支持协助解决。
WORKSPACE.0017	Failed to bind user rights.	绑定用户权限失败	请联系服务技术支持协助解决。
WORKSPACE.0019	Failed to update the user and permission.	更新用户与权限失败	请联系服务技术支持协助解决。
WORKSPACE.0021	Failed to unbind the user permission.	解绑用户权限失败	请联系服务技术支持协助解决。
WORKSPACE.0022	Failed to delete the workspace user.	删除工作空间用户失败	请联系服务技术支持协助解决。
MAStudio.00101001	This parameter: [%s] cannot be empty.	缺少请求参数	请基于报错信息检查是否有漏填的请求参数。
MAStudio.00101004	Error params: [%s].	错误的参数信息	请检查请求参数是否合法，例如请求体中填写的训练参数是否为json格式，或者按照异常提示进行排查。
MAStudio.00101005	Method argument type mismatch, Error field is %s, which value is %s.	请求参数的类型与处理器方法参数类型不匹配	请检查传入的参数类型是否与接口要求匹配，例如某参数要求类型为Integer，但实际传入的为String。
MAStudio.00101007	The JSON format of the input data is incorrect.	请求体不是json格式或者格式异常	请检查请求体格式是否正确（非json格式或者请求体被截断）。
MAStudio.00101009	Bad Request.	错误请求	请联系技术支持。
MAStudio.00101012	An training is being created.	工作流正在创建中	请勿频繁重复提交创建训练任务。

错误码	错误信息	说明	建议解决方法
MAStudio.00 101013	The workflow execution is being published	workflows 执行训练模型正在发布中	请勿频繁重复提交模型发布。
MAStudio.00 101014	The task is not running, can not be [%s].	非运行中的任务不支持当前操作	请确保训练任务状态为运行中再进行操作，可通过“查询训练任务详情”接口查询状态。
MAStudio.00 101018	Retry is supported only in the failed status.	只有失败状态支持重试	请确保该操作在任务状态为失败时进行，可通过“查询训练任务详情”接口查询状态。
MAStudio.00 101019	The checkpoint has been released.	断点已经被发布，不能再进行发布	不用处理。
MAStudio.00 101020	The model: %s has been released.	模型已经被发布，不能再进行发布	不用处理。
MAStudio.00 101022	The current asset does not support the configured number of training cards. The number of training cards must be [%s, %s]. The step is %s.	资源卡数不满足资产训练要求	修改资源配置。
MAStudio.00 101025	Retry train task failed. cause by: %s.	任务重试失败	请联系技术支持。
MAStudio.00 101026	Convert storagesNode to list failed. cause by: %s.	JsonNode转换list失败	请联系技术支持。
MAStudio.00 101028	The training task is creating.	这个训练任务已经在创建中	请勿频繁重复提交创建训练任务。
MAStudio.00 101029	When the checkpoint model SFS is enabled, the model SFS of the new task must also be enabled.	产生断点的任务开启了模型 SFS Turbo加速，基于断点的新任务的模型 SFS Turbo也必须启用。	产生断点的任务开启了模型 SFS Turbo加速，请确保基于断点的续训或者重训任务的模型 SFS Turbo开启，在创建新训练任务时将“新建训练任务”接口参数“sfs_config”打开。

错误码	错误信息	说明	建议解决方法
MAStudio.00 101030	The SFS path should be a file, not a directory.	这个模型或数据加速存储路径应该是一个文件，而不是目录	请联系技术支持。
MAStudio.00 101031	%s model cannot be deleted.	模型已被发布或使用，无法删除	请先在MAStudio的“空间资产”中删除该模型或者删除基于此模型创建的训练、量化或者部署任务。
MAStudio.00 101032	The number of non-final tasks of a single tenant exceeds the upper limit %s.	单个租户未结束的任务数超过上限	请等待当前租户创建的训练任务完成后再进行创建。
MAStudio.00 101033	The number of checkpoints exceeds the upper limit %s.	checkpoints数量超过上限	请确保创建训练任务时保存 checkpoints数量设置小于可保存数量最大值（最大值限制请参考报错提示）。
MAStudio.00 101034	The monitor task related train task not exist or not authorization	监控任务关联的训练任务不存在或者无权限关联该任务。	不用处理。
MAStudio.00 101035	The current task status: %s cannot be stopped.	当前任务状态不支持停止	不用处理。
MAStudio.00 101036	The task is not in the final state and cannot be published.	任务未完成不支持发布	不用处理。
MAStudio.00 101037	The task type cannot be published as an asset.	训练类型不支持发布	不用处理。
MAStudio.00 101038	The number of published tasks of a single tenant exceeds the upper limit	单个训练任务发布的断点数量超过上限	单个训练任务发布的断点数量超过上限，不支持再发布。
MAStudio.00 101039	Mind insight do not support	mind insight 能力不支持	请联系技术支持。

错误码	错误信息	说明	建议解决方法
MAStudio.00101040	Operate train task failed.	训练任务停止或者重试失败	请确保操作类型为stop（停止训练作业）或者retry（重试训练）。
MAStudio.00101041	The asset: %s has been taken offline, and is no longer available for training.	资产下线无法训练	当前资产已经被下线，无法继续用于训练。
MAStudio.00101042	The number of nodes in the resource pool is insufficient. nodeCount: %s	资源池节点数不够	扩容或者减少训练资源用量。
MAStudio.00103021	Mount sfsTurbo failed.	挂载sfsTurbo失败。	请联系技术支持。
MAStudio.00103022	Umount sfsTurbo failed.	解除挂载sfsTurbo失败。	请联系技术支持。
MAStudio.00103023	Failed to delete the sfsTurbo file.	删除sfsTurbo文件失败	请联系技术支持。
MAStudio.00103028	The order of the user is empty.	用户订单信息为空	请确保已订购选择的模型。
MAStudio.00103029	The model order status is abnormal.	模型订单的状态为不正常	请确保订购的模型订单状态是正常。
MAStudio.00103030	User or Model expired for project %s.	资源或模型订单已过期	请确保模型和资源池在有效期内。
MAStudio.00103032	The asset %s action type: %s is invalidate, workflow info can not be empty.	资产操作类型已失效， workflow信息不能为空。	请联系技术支持。
MAStudio.00104005	The content: %s is not exist.	模型或工作流资产不可用	请联系技术支持。
MAStudio.00104007	The workflow[%s] execution[%s] is not exist.	当前工作流执行记录不存在	请联系技术支持。
MAStudio.00104009	The model: %s is not exist.	模型不存在	请联系技术支持。

错误码	错误信息	说明	建议解决方法
MAStudio.00104027	No available SFS found.	没找到可用的SFSTurbo实例	请检查SFS Turbo服务中的实例是否被删除。
MAStudio.00104028	The SFS file does not exist.	SFSTurbo文件不存在	请联系技术支持。
MAStudio.00104029	Charging mode %s is not found.	计费模式未找到	请联系技术支持。
MAStudio.00104030	The resource order of the user is not found. projectId: %s.	未找到用户的资源订单	请先订购资源池。
MAStudio.00104031	Specifications: %s not available.	规格不可用	请检查训练资源规格信息。
MAStudio.00104033	Failed to obtain the resource information of chipType: %s.	获取chipType的resource资产失败	请联系技术支持。
MAStudio.00104034	The number of cards is incorrect. Failed to convert the number of nodes.	卡数转节点数失败	请联系技术支持。
MAStudio.00104036	The checkpoint: %s is already published, cannot be deleted.	已发布的checkpoints不能删除	不用处理。
MAStudio.00100001	The request is unauthorized, cause by: [%s].	无权限访问	请检查请求头是否存在token，或者token信息是否正确。
MAStudio.00100002	token expires.	token过期	请替换新的token。
MAStudio.00100003	Failed to obtain the certificate, cause by: [%s]	获取临时AK/SK失败	请联系技术支持。
MAStudio.00100004	The obs path [%s] can't access	该OBS路径禁止访问	请联系技术支持。
MAStudio.00103014	The sfsTurbo does not find the associated bucket.	SFSTurbo服务未绑定OBS桶	请联系技术支持。
MAStudio.00103024	Failed to obtain the file content.	获取OBS/SFS文件内容失败	请联系技术支持。

错误码	错误信息	说明	建议解决方法
MAStudio.00 103025	SFSTurbo is enabled, but SFSTurbo-related parameters are not found.	开启了SFS服务，但是没有查询到SFS相关参数。	关闭SFS或检查SFS Turbo服务是否正常。
MAStudio.00 103031	Failed to obtain system setting bound to the poc user.	获取系统设置失败	请联系技术支持。
MAStudio.00 104001	Not Found.	未知异常	请联系技术支持。
MAStudio.00 104003	The obs bucket [%s] not found.	OBS桶不存在	请检查OBS桶是否存在。
MAStudio.00 104004	The obs path [%s] not found.	OBS路径不存在	请检查OBS路径是否存在。
MAStudio.00 104006	The workflow not found.	工作流不存在	请联系技术支持。
MAStudio.00 104011	The training task is not exist.	训练任务不存在	请联系技术支持。
MAStudio.00 104012	The workflow execution parameter is not exist.	工作流执行参数不存在	请联系技术支持。
MAStudio.00 104013	No model artifact found.	任务完成，模型产物不存在	请联系技术支持。
MAStudio.00 104015	The model asset action: %s is not exist.	模型无可执行action	请联系技术支持。
MAStudio.00 104016	No resource pool is available.	无可用的资源池	请联系技术支持。
MAStudio.00 104018	The checkpoint is not exist.	checkpoint不存在	请联系技术支持。
MAStudio.00 104019	The reward model is not exist.	奖励模型不存在	请联系技术支持。
MAStudio.00 104021	Asset invalid, Check Integrity.	资产不可用，检查完整性	请联系技术支持。

错误码	错误信息	说明	建议解决方法
MAStudio.00 104022	The current resource pool is not associated with an SFS Turbo model instance. Contact the super administrator to associate it with an SFS Turbo model instance.	当前资源池未关联SFS Turbo 模型实例	请联系账号管理员是否对资源池开启了模型绑定功能。
MAStudio.00 104023	The current resource pool is not associated with an SFS Turbo dataset instance. Contact the super administrator to associate it with an SFS Turbo dataset instance."	当前资源池未关联SFS Turbo 数据集实例	请联系账号管理员是否对资源池开启了数据绑定功能。
MAStudio.00 104024	The current SFS Turbo instance is not bound to the OBS bucket where the dataset resides. Bind the OBS bucket to the SFS Turbo service first.	当前SFS Turbo 实例未绑定数据集所在的OBS桶。	请使用SFS Turbo上绑定的OBS桶中的数据。
MAStudio.00 104025	Failed to obtain the available SFS model bound to the resource pool network.	获取资源池网络绑定的SFS 可用型号失败。	请联系账号管理员是否对资源池开启了模型绑定功能。
MAStudio.00 104026	Failed to obtain the available SFS dataset bound to the resource pool network.	获取资源池网络绑定的可用SFS数据集失败。	请联系账号管理员是否对资源池开启了数据绑定功能。
MAStudio.00 101006	The request method %s is not allowed.	接口请求方法类型错误	请检查请求方法信息。
MAStudio.00 101011	The name already exists : %s.	任务名已存在	任务名不能重复，请输入新的名称。

错误码	错误信息	说明	建议解决方法
MAStudio.00102001	Failed to complete the request because of an internal service error.	服务内部错误	请联系技术支持。
MAStudio.00102003	scc %s the object failed.	scc解密/加密失败	请联系技术支持。
MAStudio.00102004	Failed to save the model. cause by: %s.	保存模型失败	请联系技术支持。
MAStudio.00103001	Request 3rd party client error.	请求第三方服务错误	请联系技术支持。
MAStudio.00103002	Request 3rd party service error.	第三方服务错误	请联系技术支持。
MAStudio.00103003	Use 3rd sdk error	第三方sdk错误	请联系技术支持。
MAStudio.00103010	The subscription failed, please retry	订阅工作流失败	请联系技术支持。
MAStudio.00103011	The restart subscription failed, please retry.	重新订阅失败	请联系技术支持。
MAStudio.00103012	Failed to set the OBS bucket policy. Check whether you have the permission to modify the bucket policy.	设置obs桶策略失败	请联系技术支持。
MAStudio.00103013	Sfs Turbo internal error.	sfs服务内部错误	请检查当前局点SFS Turbo服务页面是否正常。
MAStudio.00103015	The sfsTurbo import failed.	sfs导入失败	请联系技术支持。
MAStudio.00103016	Get dataset encryption key failed.	获取数据集加密密钥失败	请联系技术支持。
MAStudio.00103017	Get dataset detail failed from data-manager.	获取数据集详情失败	请联系技术支持。
MAStudio.00103018	The dataset: %s detail is empty.	获取数据集详情为空	请联系技术支持。

错误码	错误信息	说明	建议解决方法
MAStudio.00 103019	The dataset is encrypted, but the encryption key is empty.	数据集被加密，但加密密钥为空。	请联系技术支持。
MAStudio.00 103020	The model's asset is invalidate, may cause by the workflow's content id or algorithm's content id: [%s] not auth, please contact Huawei technical support personnel.	模型资产失效，可能是由于工作流的内容ID或算法的内容ID未认证导致	请联系技术支持。
MAStudio.00 103027	Failed to %s resources. cause by: %s.	资源扣减或释放失败	请联系技术支持。
MAStudio.00 103034	Create job no response from modelarts.	创建监控任务响应为空	请联系技术支持。
MAStudio.00 103036	Unrecognizable order type.	无法识别的订单类型	请联系技术支持。
MAStudio.00 103037	Failed to obtain ma workspaceId. cause by: %s	获取MA WorkspaceId 信息失败	请联系技术支持。
APIG.0301	Incorrect IAM authentication information.	IAM身份验证信息不正确： decrypt token fail: token解析失败。 token expires: token过期。 x-auth-token not found: 未找到x-auth-token参数。	token解析失败，请检查获取token的方法，请求体信息是否填写正确，token是否正确；检查获取token的环境与调用的环境是否一致。 token超时（token expires），请重新获取token，使用不过期的token。 检查调用API时，请求header参数X-Auth-Token是否拼写正确。
APIG.0101	The API does not exist or has not been published in the environment.	访问的API不存在或尚未在环境中发布。	请检查API的URL是否拼写正确，例如，URL中是否缺少project_id。 HTTP请求方法（POST，GET等）是否正确。

错误码	错误信息	说明	建议解决方法
APIG.0308	The throttling threshold has been reached: policy user over ratelimit,limit:XX,time:1 minute.	发送请求超过了服务的默认配置限流。	通过重试机制，在代码里检查返回值，碰到并发错误可以延时一小段时间（如2-5s）重试请求。 后端检查上一个请求结果，上一个请求返回之后再发送下一个请求，避免请求过于频繁。
APIG.0201	Backend timeout.	请求超时。	请检查原调用请求是否过于频繁，如果是并发过大，可以通过重试机制解决，在代码里检查返回值，碰到这个并发错误可以延时一小段时间（如2-5s）重试请求；也可以后端检查上一个请求结果，上一个请求返回之后再发送下一个请求，避免请求过于频繁。
TFDS.0110	The input image number does not equal the input photo number.	该部件工位图片数与传过来的photo_number不一致，或者请求uri不存在。	请联系技术支持工程师。
TFDS.0107	Too many requests.	请求过于频繁，服务端压力过大（当前设置的10000辆车，约200列车），需降低请求压力。	请联系技术支持工程师。
TFDS.0105	Recognition failed, Exception occurred.	- 识别进程算法崩溃。 - 整车接口发送请求到识别进程识别时发生异常时，构建0105错误码作为结果发送给结果接收端。	请联系技术支持工程师。

错误码	错误信息	说明	建议解决方法
TFDS.0101	The input parameter is invalid,maybe not json data.	输入参数不符合规范。	请检查输入image或url的参数是否正确。
TFDS.0102	The image format is not supported.	图像数据格式不支持，只支持常见jpg/bmp/png/tiff。	请检查输入图片格式。
TFDS.0103	Image depth does not meet requirements, check channels or dtypes.	图像深度不支持，请检查图像通道数或图像数据类型。	请检查图片尺寸。
TFDS.0104	The image is not supported or the image quality is poor.	非支持的图片类型或车型（当前不支持的转向架及车型都会报这个）。	请检查图片类型与图片质量。
TFDS.0106	Key error.	输入json存在Key error。	请检查输入json。
TFDS.0108	Internal error.	内部错误。	请联系技术支持工程师。
TFDS.0109	Backend timeout.	- 服务端响应超时，如三次请求识别都超时。 - 列车排队时间超过6小时。	请联系技术支持工程师。
TFDS.0111	It's snowing or raining, please check the image manually.	雨雪天气，判为故障，请人工审核图片（当前下雪放在侧架工位判断输出，下雨放在制动梁工位判断输出）。	请联系技术支持工程师。

错误码	错误信息	说明	建议解决方法
TFDS.0115	Part Missing or Image Missing, please check the image manually.	出现部件丢失或者部件部分图片丢失时，判为故障抛出此错误码，请人工审核图片。	请联系技术支持工程师。
TFDS.0114	The image is too dark, blurred or exposed.	- 输入图片为黑图、高曝光的情况下，判为故障抛出此错误码，请人工审核图片。 - 互钩差未检测到任何部件框时。	请联系技术支持工程师。
TFDS.0116	The image may have an incorrect position or shooting angle direction.	图片出现错位或窜图，判为故障抛出此错误码，请人工审核图片。	请联系技术支持工程师。
TFDS.0117	The project ID does not match the token.	算法服务鉴权失败。	请联系技术支持工程师。

4.3 获取项目 ID

从控制台获取项目 ID

- 使用最终租户登录ManageOne运营面，在界面右上角，单击租户名称后，选择“个人设置”，进入个人信息界面。

图 4-1 个人设置



2. 在个人信息页，参考下图获取项目ID（project id）。

图 4-2 项目 ID 获取



调用 API 获取项目 ID

获取项目ID的接口为“GET https://{endpoint}/v3/projects”，其中“{endpoint}”为IAM的终端节点。接口的认证鉴权请参见[认证鉴权](#)。

响应示例如下，依据服务的部署区域在响应消息体中查找“name”参数“projects”下的“id”即为项目ID。

```
{
  "projects": [
    {
      "domain_id": "65382450e8f64ac0870cd180d14e684b",
      "is_domain": false,
      "parent_id": "65382450e8f64ac0870cd180d14e684b",
      "name": "xxx",
      "description": "",
      "links": {
        "next": null,
        "previous": null,
        "self": "https://www.example.com/v3/projects/a4a5d4098fb4474fa22cd05f897d6b99"
      }
    }
  ]
}
```



```
{
  "id": "a4a5d4098fb4474fa22cd05f897d6b99",
  "enabled": true
},
"links": {
  "next": null,
  "previous": null,
  "self": "https://www.example.com/v3/projects"
}
}
```

4.4 获取用户 ID


1. 使用最终租户登录ManageOne运营面，在界面右上角，单击租户名称后，选择“个人设置”，进入个人信息界面。

图 4-3 个人设置



2. 在个人设置页面查询用户ID。

图 4-4 获取用户 ID



4.5 获取空间 ID

1. 使用最终租户登录ModelArts Studio平台，进入所需空间。
2. 在左侧“空间资产”导航栏中选择带有资产的页签，例如选择“数据”页签。
3. 在所选择的页面中按F12打开开发者工具并进入“Network”页签，单击资产列表的刷新按钮。在开发者工具的“Network”中找到assets接口，在接口的响应体（Response）中查询空间ID。


图 4-5 获取空间 ID



4.6 获取数据集 ID

1. 使用最终租户登录ModelArts Studio平台，进入所需空间。
2. 在左侧“数据工程”导航栏中选择“数据管理 > 数据集”，进入“发布数据集”页面，在页面中找到已发布成功的发布数据集。
3. 在页面中按F12打开开发者工具并进入“Network”页签。单击刷新按钮。在开发者工具的“Network”中找到与数据集列表接口，在接口的响应体（Response）中查询数据集ID。

图 4-6 获取数据集 ID




4.7 获取资源池 ID 信息

在线资源池 ID 获取

使用最终租户登录ModelArts平台，如图4-7，在菜单栏依次单击“资源管理 > AI专属资源池 > 弹性集群 Cluster > 资源池”。

选择需要部署的资源池，鼠标放置到服务名称上，获取资源池描述中的资源池ID信息。

图 4-7 在线资源池




边缘资源池 ID 获取

使用最终租户登录ModelArts平台，如图2 边缘资源池，在菜单栏依次单击“资源管理 > 边缘资源池 Edge > 资源池”。

选择需要部署的资源池，获取资源池名称下方的ID即为边缘资源池ID信息。

图 4-8 边缘资源池



4.8 获取负载均衡 ID 信息


获取负载均衡 ID 信息

使用最终租户登录ModelArts平台，如图4-9，在菜单栏依次单击“模型部署 > 边缘服务 > 负载均衡 > 负载均衡”。

选择所需对应协议的负载均衡信息，复制名称下面的ID信息，即为负载均衡ID。

如不存在，则需登录MA Studio界面[创建负载均衡](#)。


图 4-9 负载均衡 ID



创建负载均衡


使用最终租户登录ModelArts Studio平台，如图4-10，在菜单栏依次单击“空间管理 > 资源池管理”，选择需要部署的资源池，单击操作列“创建负载均衡”按钮创建负载均衡。

图 4-10 创建负载均衡 1



选择需要的协议类型，输入名称和监听端口进行负载均衡创建。
选择HTTPS协议需要[创建及关联SSL证书](#)。


图 4-11 创建负载均衡 2



4.9 获取工作区 ID

在调用接口的时候，部分URL中需要填入工作区ID，工作区ID获取方法如下。

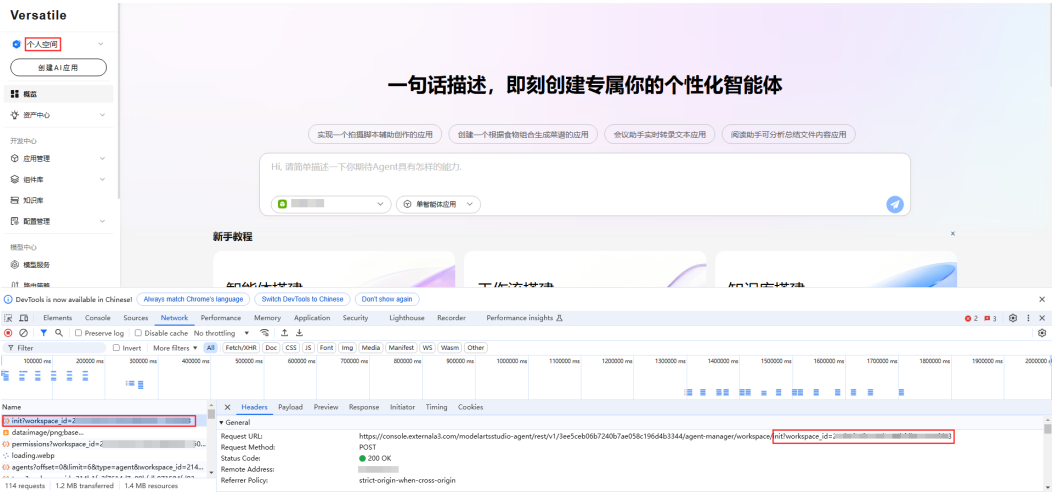
- 步骤1 使用最终租户登录MangeOne运营面。
- 步骤2 在ManageOne运营面首页左上角单击 ，选择“盘古大模型”。
- 步骤3 在ModelArts Studio平台，单击“AGENT开发”，进入Versatile智能体平台。



步骤4 打开F12，选择“Network”，单击任意页面，例如，个人空间。

步骤5 可以在接口调用中看到workspace_id=xxx。xxx为工作区ID的值。

图 4-12 获取工作区 ID



----结束

4.10 创建 SSL 证书信息(HTTPS 负载均衡使用)

步骤1 使用最终租户登录ModelArts Studio平台，如图4-13，在菜单栏依次单击“空间管理 > 资源池管理”，检查“边缘资源池”下方是否存在“查看证书”按钮。

- 如果存在已经创建好的SSL证书，使用HTTPS创建负载均衡时直接引用已存在的证书即可。
- 如果不存在“查看证书”按钮，则会提示创建SSL证书。单击提示创建证书，可以参考[创建证书](#)。


图 4-13 查看证书



步骤2 获取证书信息(https_secrets)

F12打开控制台界面，单击“查看证书”按钮。如图控制台响应体中的id即为https_secrets信息。

图 4-14 https_secrets



步骤3 创建证书

1. 准备一台Linux系统的服务器（已安装OpenSSL），依次执行以下命令制作证书。
执行命令时会提示输入至少四位数的密码，请记住密码后续步骤会使用。
1. 生成server.key命令：
openssl genrsa -aes256 -f4 -out server.key 2048

2. 生成不加密的server.key：
openssl rsa -in server.key -out server.key

3. 生成ca.crt命令：
openssl req -new -x509 -key server.key -out ca.crt -days 3650

4. 生成server.csr命令：
openssl req -new -key server.key -out server.csr

5. 生成server.crt命令：
openssl x509 -req -days 3650 -in server.csr -CA ca.crt -CAkey server.key -CAcreateserial -out server.crt

图 4-15 命令执行示例

```
.....+++++
.....+++++
a is 65537 (0x010001)
Enter pass phrase for server.key:
Verifying - Enter pass phrase for server.key:
[root@ecs-arm test]# openssl rsa -in server.key -out server.key
Enter pass phrase for server.key:
writing RSA key
[root@ecs-arm test]# openssl req -new -x509 -key server.key -out ca.crt -days 3650
You are about to be asked to enter information that will be incorporated
into your certificate request.
What you are about to enter is what is called a Distinguished Name or a DN.
There are quite a few fields but you can leave some blank
For some fields there will be a default value,
If you enter '.', the field will be left blank.
-----
Country Name (2 letter code) [AU]:
State or Province Name (full name) [Some-State]:
Locality Name (eg, city) []:
Organization Name (eg, company) [Internet Widgits Pty Ltd]:
Organizational Unit Name (eg, section) []:
Common Name (e.g. server FQDN or YOUR name) []:
Email Address []:
[root@ecs-arm test]# openssl req -new -key server.key -out server.csr
You are about to be asked to enter information that will be incorporated
into your certificate request.
What you are about to enter is what is called a Distinguished Name or a DN.
There are quite a few fields but you can leave some blank
For some fields there will be a default value,
If you enter '.', the field will be left blank.
-----
Country Name (2 letter code) [AU]:
State or Province Name (full name) [Some-State]:
Locality Name (eg, city) []:
Organization Name (eg, company) [Internet Widgits Pty Ltd]:
Organizational Unit Name (eg, section) []:
Common Name (e.g. server FQDN or YOUR name) []:
Email Address []:
Please enter the following 'extra' attributes
to be sent with your certificate request
A challenge password []:
An optional company name []:
[root@ecs-arm test]# openssl x509 -req -days 3650 -in server.csr -CA ca.crt -CAkey server.key -CAcreateserial -out server.crt
Signature ok
subject=C = AU, ST = Some-State, O = Internet Widgits Pty Ltd
Getting CA Private Key
[root@ecs-arm test]#
[root@ecs-arm test]#
[root@ecs-arm test]#
[root@ecs-arm test]#
[root@ecs-arm test]#
[root@ecs-arm test]# ls
ca.crt  ca.srl  server.crt  server.csr  server.key
[root@ecs-arm test]#
```

2. 证书制作完成后，执行ls命令可查看生成的证书文件。证书文件与ModelArts Studio平台中证书填写项对应关系如下。
- ca.crt -- CA
- server.crt -- CERT
- server.key -- KEY

图 4-16 证书密钥

密钥

密钥键	密钥值
CA ?	
CERT ?	
KEY ?	

3. 可通过view命令查看证书密钥值，例如view server.crt。输入ModelArts Studio平台的密钥值，需要经过base64加密（echo -n "复制的密钥值内容" | base64）。
- 结束

4.11 获取在线部署的大模型推理 API 接口域名

获取 NLP、多模态大模型接口域名

模型在部署成功后，API接口域名可以在“模型开发 > 模型部署”页面获取，获取方式如下。

1. 登录ModelArts Studio平台，进入所需空间。
2. 在左侧导航栏中选择“模型开发 > 模型部署”，单击模型名称在“API调用”页面获取API接口域名，以及完整的API地址。

只有处于“运行中”状态的模型才可以正常调用。


图 4-17 获取接口域名



获取 BI 大模型接口域名


1. 登录ModelArts Studio平台，进入所需空间，找到左侧的“模型开发 > 模型部署”。
2. 单击模型部署，找到您准备调用的模型服务单击进入详情，在部署配置中可以看到API URL相关信息， 如果已经包含https://ip:port相关信息则直接拷贝使用，如果不包含则参考下面的步骤进行获取。API域名获取到之后根据调用服务的模型类型参考《API参考》中对应类型的模型API列表，将URL拼接到API域名后，填写参数进行访问调用即可。
3. 如果没有包含https://ip:port相关信息，请参考以下步骤进行获取。使用承载租户登录ManageOne运营面，进入CCE服务。单击“lmstudio-business-cce”集群，在工作负载中找到“lms-api-service”工作负载。
4. 单击工作负载名称，并进入“访问方式”页签，在“访问类型”列找到负载均衡对应的端口。

图 4-18 获取端口



5. 单击负载均衡处的链接，跳转至负载均衡“基本信息”页面，获取弹性IP地址。若无弹性IP请基于界面提示进行绑定。

图 4-19 获取弹性 ip 地址



6. 将获取的弹性IP地址、端口按照https://ip:port格式进行拼接，形成完整的API接口域名。

获取 CV、预测大模型接口域名

模型在部署成功后，API接口域名可以在“模型开发 > 模型部署”页面获取，获取方式如下。

方式一：

模型部署完成后，单击模型名称，如果有“API调用”页签，可以直接在该页签获取接口地址。

注意完整的接口地址需要结合API URL和调用示例进行拼接，如果获取到请求地址后，无法调通，请在其后添加/。




方式二：

模型部署完成后，单击模型名称，没有“API调用”页签时，可以参考以下方式获取请求地址。

1. 登录ModelArts Studio平台，进入所需空间。
2. 在左侧导航栏中选择“模型开发 > 模型部署”，单击模型名称在“详情”页面获取API接口域名。
只有处于“运行中”状态的模型才可以正常调用。

图 4-20 获取 API 接口域名



3. 获取API请求地址后，需要在此URL后拼接上模型接口的path才能调通对应接口，具体的path在各个模型文档中的URI说明中有介绍。

获取科学计算大模型接口域名

模型在部署成功后，API接口域名可以在“模型开发 > 模型部署”页面获取，获取方式如下。

1. 登录ModelArts Studio平台，进入所需空间。
2. 在左侧导航栏中选择“模型开发 > 模型部署”，单击模型名称在“详情”页面获取API接口域名。
只有处于“运行中”状态的模型才可以正常调用。

图 4-21 获取 API 请求地址



3. 获取API请求地址后，在这个基础上去除末尾的/tasks即是域名。

获取求解器模型接口域名

模型在部署成功后，API接口域名可以在“模型开发 > 模型部署”页面获取，获取方式如下。

1. 登录ModelArts Studio平台，进入所需空间。
2. 在左侧导航栏中选择“模型开发 > 模型部署”，单击模型名称在“详情”页面获取API接口域名。

只有处于“运行中”状态的模型才可以正常调用。

图 4-22 获取接口域名



3. 域名获取后，与接口的URI进行拼接，得到完整的接口。以Pangu-OPT-数学规划求解器为例，获取到域名后，需要在域名后面拼接/task/solve构成完整的接口。

获取向量&重排大模型、搜索规划大模型接口域名

模型在部署成功后，API接口域名可以在“模型开发 > 模型部署”页面获取，获取方式如下。

1. 登录ModelArts Studio平台，进入所需空间。
2. 在左侧导航栏中选择“模型开发 > 模型部署”，单击模型名称在“详情”页面获取API接口域名。
只有处于“运行中”状态的模型才可以正常调用。

图 4-23 获取接口域名



3. 域名获取后，与接口的URI进行拼接，得到完整的接口。以[搜索规划大模型](#)为例，获取到域名后，需要在域名后面拼接/app/search/v1/planning构成完整的接口。

4.12 获取边缘部署的大模型推理 API 接口域名

边缘部署的模型与云上部署的模型调用方式基本相同，主要差异点在于获取域名方法不同。以下是边缘部署的模型获取域名指导。

方式一：

模型部署完成后，单击模型名称，如果有“API调用”页签，可以直接在该页签获取接口地址。

注意完整的接口地址需要结合API URL和调用示例进行拼接，如果获取到请求地址后，无法调通，请在其后添加/。




方式二：

模型部署完成后，单击模型名称，没有“API调用”页签时，可以参考以下方式获取请求地址。

1. 使用最终租户登录ModelArts Studio平台，进入所需空间，找到左侧的“模型开发 > 模型部署”。
2. 单击模型部署，找到您准备调用的模型服务单击进入详情，查看访问模式。

图 4-24 查看边缘部署访问模式示例图



3. 如果是节点访问，则记录当前部署配置中的主机端口，在监控信息中获取节点IP，按照https://ip:port的格式，或者http://ip:port格式来拼接即可获取接口的调用域名。
具体是使用https，还是http请在部署详情页面确认。

图 4-25 确认访问协议类型示例图






图 4-26 获取监控信息示例图



4. 如果是负载均衡的访问模式，获取部署配置中的ELB IP、ELB 负载端口、API URL 信息。按照http://ip:port+API URL的格式或者https://ip:port+API URL的格式来拼接即可获得接口的调用域名。

图 4-27 获取 ELB 信息示例图



5. 如果是监控网关的访问模式，获取部署配置中的ELB IP、ELB 负载端口、API URL 信息。按照https://ip:port+API URL的格式或者https://ip:port+API URL的格式来拼接即可获得接口的调用域名。

4.13 获取边学边用 API 接口域名

- 1. 使用承载租户登录ManageOne运营面，进入CCE服务。
- 2. 进入itepbase-xxx集群，在“工作负载 > 无状态负载”页面找到data-cleaning工作负载。
- 3. 单击工作负载名称，在“访问方式”页签获取负载均衡对应的公网地址和访问端口。域名按照“https://ip:port”格式拼接即可获得域名。

图 4-28 访问方式



4. 如果没有公网地址，请单击负载均衡链接，进入“基本信息”页面。单击“绑定弹性IP”，选择任一弹性IP进行绑定。

图 4-29 负载均衡




图 4-30 绑定弹性 IP



5. 如果没有弹性IP，单击“绑定弹性IP”弹窗中的“查看弹性IP”进入弹性IP页面，根据页面提示申请弹性IP。

图 4-31 查看弹性 IP

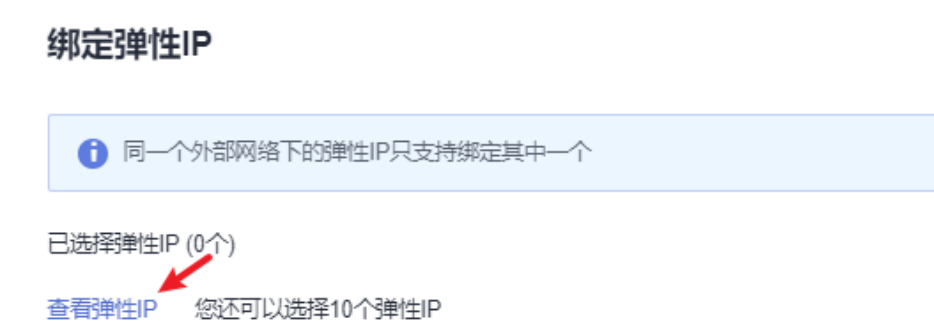



图 4-32 申请弹性 IP



4.14 获取 Agent 接口域名

- 步骤1 使用最终租户登录MangeOne运营面。
- 步骤2 在ManageOne运营面首页左上角单击 ，选择“盘古大模型”。
- 步骤3 在ModelArts Studio平台，单击“AGENT开发”，进入Versatile智能体平台。



- 步骤4 在左侧导航，选择“开发中心 > 应用管理 > 单智能体应用”或“开发中心 > 应用管理 > 工作流应用”。
- 步骤5 单击已发布的单智能体应用或工作流应用卡片，进入编辑页面，单击 。

步骤6 在“发布管理”页面，“API调用”区域，查看URL地址，IP地址:端口号即为API的请求地址。

图 4-33 获取 IP 地址:端口号



----结束

4.15 运行 Webhook Service

CV大模型视频分类算法的输出结果支持通过post请求，将作业的运行结果直接发送给用户设置好的终端地址Webhook URL。在调用算法前，需确保Webhook Service已运行成功。

下面以一个简单的python脚本作为示例，展示如何启动Webhook Service并保存接收的数据。

1. 准备一台本地的Linux服务器，确保Linux服务器和ModelArts Studio平台网络通畅，并已安装Python环境。
2. 使用ifconfig命令在Linux服务器上查询服务器IP地址。
3. 修改脚本make_server内容，填入Linux服务器IP地址。

图 4-34 示例脚本

```
1 import json
2 from wsgiref.simple_server import make_server
3
4
5 def application(environ, start_response):
6     start_response('200 OK', [('Content-Type', 'application/json')])
7
8     request_body = environ["wsgi.input"].read(int(environ.get("CONTENT_LENGTH", 0)))
9
10    f=open('./post.txt','a')
11    f.write(request_body)
12    f.write("\n")
13    f.close()
14    return ("200 success\n")
15
16 if __name__ == "__main__":
17     port = 6006
18     httpd = make_server("192.168.223", port, application)
19     print "serving http on port {0}...".format(str(port))
20     httpd.serve_forever()
```

```
import json
from wsgiref.simple_server import make_server

def application(environ, start_response):
    start_response('200 OK', [('Content-Type', 'application/json')])
    request_body = environ["wsgi.input"].read(int(environ.get("CONTENT_LENGTH", 0)))

    f=open('./post.txt','a')
    f.write(request_body)
    f.write("\n")
    f.close()
    return ("200 success\n")

if __name__ == "__main__":
    port = 6006
    httpd = make_server("10.10.10.1", port, application)
    print "serving http on port {0}...".format(str(port))
    httpd.serve_forever()
```

说明

脚本中的端口6006可以根据用户实际需要修改。

调用算法时，算法输出Webhook URL设置为：http://{IP}:{port}。例如，http://10.10.10.1:6006。

4. 执行脚本，启动Webhook Service。

python post.py

图 4-35 执行脚本成功

```
[root@ ~]# python post.py
serving http on port 6006...
1 21 - - [13/Apr/2020 14:24:59] "POST / HTTP/1.1" 200 12
```

4.16 创建监控插件

创建监控插件


使用最终租户登录ModelArts Studio平台，如图4-36，在菜单栏依次单击“空间管理 > 资源池管理”，选择需要部署的资源池，单击操作列“创建监控插件”按钮创建监控插件。

图 4-36 创建监控插件 1



选择AOM，如不存在需要单击右边的“新建AOM”按钮，进行AOM创建。
选择负载均衡，如不存在则需创建负载均衡。

图 4-37 创建监控插件 2




创建 AOM(创建 Prometheus 实例)

单击图4-37的“新建AOM”按钮后跳转到图4-38，单击左上角的“创建Prometheus实例”按钮，填写实例名称，选择企业项目(默认default)，选择实例类型(Prometheus for CCE)，单击“确定”按钮进行创建。


创建成功后重新选择AOM。

图 4-38 创建 Prometheus 实例




4.17 获取盘古服务外部 APIG 域名


步骤1 登录并进入新版CloudScope平台，在左侧导航栏选择“云服务运维 > CloudOpsPortal”，进入盘古大模型服务ServiceCM页面。



步骤2 在pangulargemodels-console插件中单击“配置管理 > 配置项管理”，配置项名称搜索external-global-domain-name。
查看external-global-domain-name-cfg的值，即为环境公共外部APIG域名。




步骤3 配置项名称搜索“region-id”。
查看common-region-id-cfg的值，即为环境公共region-id。



步骤4 盘古外部APIG域名为pangulargemodels + 环境公共region-id + 环境公共外部APIG域名。
拼接示例：pangulargemodels.sa-fb-1.out.a3.com

步骤5 在环境节点中ping该域名，即可获得对应ip。



步骤6 拼接ip和盘古外部APIG域名，并将值填写到本地的hosts文件中（hosts文件一般在C:\Windows\System32\drivers\etc路径中）。

填写示例：

142.62.9.8 pangualargemodels.sa-fb-1.out.a3.com

在调用API时，注意在盘古外部APIG域名前添加https://。

GET

https://pangualargemodels.sa-fb-1.out.a3.com/v1/3ee5ceb06b7240b7ae058c196d4b3344/workspaces/b3c682de-35fd-40c7-aeb7-6708c00133ef/model-service/services

Params Authorization Headers (9) Body Pre-request Script Tests Settings

Headers

7 hidden

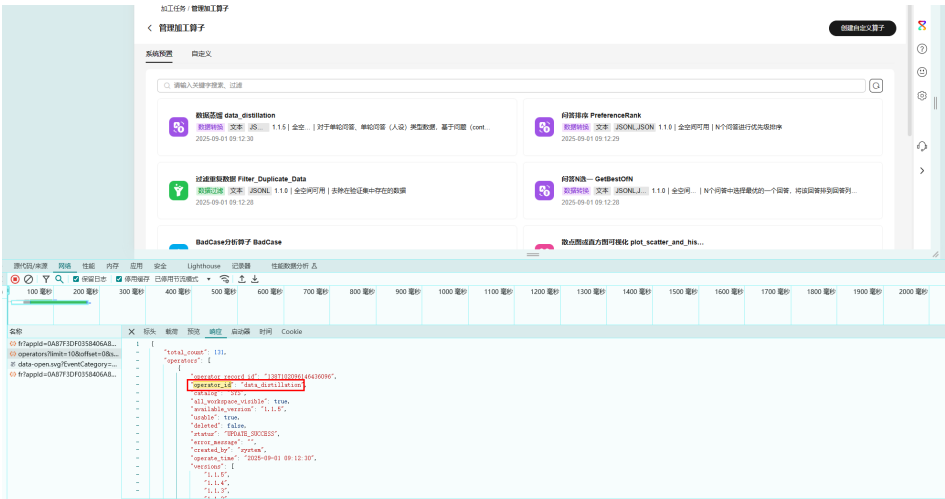
	KEY	VALUE	DESCRIPTION
☒	X-Auth-Token	MIIEuwYJKoZlhcNAQcColIERDCCBKgCAQExDTALBglghkgBZQMEAgEwgglj2Bg...	
☒	Content-Type	application/json	
	Key	Value	Description

----结束

4.18 获取算子 ID

1. 使用最终租户登录ModelArts Studio平台，进入所需空间。
2. 在左侧“数据工程”导航栏中选择“数据加工 > 加工任务”，进入“加工任务”页面，在页面右上角点击“管理加工算子”，进入算子管理页面。
3. 在页面中按F12打开开发者工具并进入“Network”页签。单击刷新按钮。在开发者工具的“Network”中找到与数据集列表接口，在接口的响应体（Response）中查询算子ID。

图 4-39 获取算子 ID



5 修订记录

发布版本	修订记录
8.6.300	CV大模型新增接口：Pangu-Railway-CV-货车故障轨旁图像检测-V3、Pangu-CV-图片数据合成-V3
8.6.200	CV大模型新增接口：Pangu-CV-开集分类-V3、Pangu-CV-异常检测-V3、Pangu-CV-目标跟踪-V3、Pangu-CV-直线检测-V2 预测大模型新增接口：表格直推预测大模型 数据管理新增接口：查询数据集详情v2、查询数据集列表、创建数据发布任务v2、查询加工算子列表、创建加工任务 资产管理新增接口：导出ModelArts Site平台格式资产、查询模型导出任务列表 Agent新增接口：知识库检索、知识库检索（v1.5）
8.6.0	训练任务管理新增获取指定资源池或资源池节点上运行的任务接口。 推理任务管理新增获取资源池节点上运行任务信息接口、获取规定时间内的推理任务使用卡的资源数接口。 新增资源池管理接口。 CV大模型新增接口：Pangu-CV-物体检测-V1、Pangu-CV-实例分割-V1、Pangu-CV-图像分类-V1、Pangu-CV-语义分割-V1、Pangu-CV-异常检测-V1、Pangu-CV-视频分类-V1、Pangu-CV-目标跟踪-V1、Pangu-CV-姿态估计-V1、Pangu-CV-事件检测-V1、Pangu-CV-目标跟踪-V2、Pangu-CV-万物检测-V2。 预测大模型新增接口：智慧配煤模型、行业场景预测大模型、高炉行业场景预测大模型。 管理类接口可以使用获取的外部APIG域名调用API。 新增DeepSeek模型调用接口。 Agent：优化调用动作流应用、调用智能体应用，新增上传文件接口。

发布版本	修订记录
8.5.1.SPC3	多模态模型支持OpenAI格式接口；预测大模型新增表格预测模型接口、时序异常检测模型接口、智慧配煤模型接口；新增向量&重排大模型接口；新增搜索规划大模型接口；CV模型新增物体检测-S3.1.0、Mine-物体检测、RS-语义分割-2.1.0、旋转检测-2.1.0、视频分类-2.1.0、视觉交互检测-S-3.1.0接口。 科学计算模型接口合一。训练任务管理中移除查询工作流执行详情接口。
8.5.1.SPC1	新增天筹求解器接口，数据管理、空间管理、资产管理、训练任务管理、推理任务管理类接口功能扩充。
8.5.1	新增Agent功能接口。
8.5.0.SPC1	新增数据管理、模型资产管理、训练任务管理、推理任务管理接口。
8.5.0	新增CV大模型、预测大模型、科学计算大模型接口。